

Probabilistische Datenwissenschaft für die Psychologie

Dirk Ostwald

Inhaltsverzeichnis

Willkommen **3**
Zitation . . . 3
Lizenz . . . 3

I. Mathematische Grundlagen **4**

1. Sprache und Logik **6**
1.1. Mathematik ist eine Sprache . . . 6
1.2. Grundbausteine . . . 7
1.3. Aussagenlogik . . . 8
1.4. Äquivalenzumformungen . . . 14
1.5. Beweistechniken . . . 17

2. Mengen **21**
2.1. Grundlegende Definitionen . . . 21
2.2. Verknüpfungen . . . 24
2.3. Spezielle Mengen . . . 33

3. Summen, Produkte, Potenzen **41**
3.1. Summen . . . 41
3.2. Produkte . . . 44
3.3. Potenzen . . . 47

4. Funktionen **50**
4.1. Definition und Eigenschaften . . . 50
4.2. Funktionentypen . . . 56
4.3. Elementare Funktionen . . . 59

5. Folgen, Grenzwerte, Stetigkeit **64**
5.1. Folgen . . . 64
5.2. Grenzwerte . . . 66
5.3. Stetigkeit . . . 72

6. Differenzialrechnung **76**
6.1. Definitionen und Rechenregeln . . . 76
6.2. Analytische Optimierung . . . 82
6.3. Differenzialrechnung multivariater reellwertiger Funktionen . . . 85

7. Integralrechnung **94**
7.1. Unbestimmte Integrale . . . 94
7.2. Bestimmte Integrale . . . 96
7.3. Uneigentliche Integrale . . . 104

7.4. Mehrdimensionale Integrale . . . 105

8. Vektoren 108
8.1. Reeller Vektorraum . . . 108
8.2. Euklidischer Vektorraum . . . 113
8.3. Lineare Unabhängigkeit . . . 119
8.4. Vektorraumbasen . . . 121

9. Matrizen 125
9.1. Definition . . . 125
9.2. Grundlegende Matrixoperationen . . . 127
9.3. Matrixmultiplikation . . . 132
9.4. Matrixinversion . . . 137
9.5. Determinanten . . . 140
9.6. Spezielle Matrizen . . . 143
9.7. Eigenanalyse . . . 147
9.8. Orthonormalzerlegung . . . 153
9.9. Singulärwertzerlegung . . . 156

10. Deskriptivstatistiken 158
10.1. Häufigkeitsverteilungen . . . 160
10.2. Histogramme . . . 163
10.3. Empirische Verteilungsfunktionen . . . 167
10.4. Quantile und Boxplots . . . 172
10.5. Maße der zentralen Tendenz . . . 175
10.6. Maße der Variabilität . . . 183

II. Imperative Programmierung 193

11. Informatische Grundbegriffe 196
11.1. Rechnerarchitektur . . . 197
11.2. Algorithmen und Programme . . . 198
11.3. Programmiersprachen . . . 199
11.4. **R** . . . 202
11.5. Visual Studio Code . . . 203

12. Arithmetik und Variablen 204
12.1. Arithmetik . . . 204
12.2. Präzedenz . . . 207
12.3. Variablen . . . 209

13. Datenstrukturen 217
13.1. Datenstrukturen in **R** . . . 218

14. Vektoren 222
14.1. Erzeugung . . . 222
14.2. Charakterisierung . . . 227
14.3. Indizierung . . . 229
14.4. Arithmetik numerischer Vektoren . . . 232
14.5. Attribute . . . 234

15. Matrizen und Arrays **237**
15.1. Matrizen . . . 237
15.2. Arrays . . . 243

16. Listen, Dataframes und Tibbles **247**
16.1. Listen . . . 247
16.2. Dataframes . . . 253
16.3. Tibbles . . . 258

17. Datenmanagement **262**
17.1. Das FAIR-Datenideal . . . 262
17.2. Dateiformate . . . 264
17.3. Verzeichnismanagement . . . 266
17.4. Datenimport und Datenexport . . . 269

18. Kontrollstrukturen **271**
18.1. Konditionale Kontrollstrukturen . . . 271
18.2. Iterative Kontrollstrukturen . . . 275

III. Wahrscheinlichkeitstheorie **278**

19. Wahrscheinlichkeitsräume **283**
19.1. Definition und erste Eigenschaften . . . 283
19.2. Wahrscheinlichkeitsfunktionen . . . 290
19.3. Beispiele bei endlichem Ergebnisraum . . . 292
19.4. Literaturhinweise . . . 298

20. Elementare Wahrscheinlichkeiten **300**
20.1. Gemeinsame Wahrscheinlichkeiten . . . 300
20.2. Bedingte Wahrscheinlichkeiten . . . 302
20.3. Unabhängige Ereignisse . . . 309
20.4. Literaturhinweise . . . 312

21. Zufallsvariablen **314**
21.1. Definition . . . 314
21.2. Wahrscheinlichkeitsmassefunktionen . . . 319
21.3. Wahrscheinlichkeitsdichtefunktionen . . . 322
21.4. Kumulative Verteilungsfunktionen . . . 326
21.5. Zufallsergebnisse und Zufallsvariablen . . . 332
21.6. Literaturhinweise . . . 333

22. Zufallsvektoren **335**
22.1. Definition und multivariate Verteilungen . . . 335
22.2. Marginalverteilungen . . . 339
22.3. Bedingte Verteilungen . . . 341
22.4. Unabhängige Zufallsvariablen . . . 343

23. Erwartungswerte **347**
23.1. Definitionen . . . 347
23.2. Eigenschaften . . . 351

23.3. Bedingter Erwartungswert . . . 353

24. Varianzen **356**
24.1. Definition . . . 356
24.2. Eigenschaften . . . 360
24.3. Bedingte Varianz . . . 362

25. Kovarianzen **365**
25.1. Definitionen . . . 365
25.2. Eigenschaften . . . 366
25.3. Bedingte Kovarianz . . . 373
25.4. Kovarianzmatrizen . . . 374

26. Ungleichungen **379**
26.1. Wahrscheinlichkeitsungleichungen . . . 379
26.2. Erwartungswertungleichungen . . . 381

27. Grenzwerte **385**
27.1. Gesetze der großen Zahlen . . . 385
27.2. Zentrale Grenzwertsätze . . . 387
27.3. Literaturhinweise . . . 390

28. Transformationen **391**
28.1. Univariate Transformationstheoreme . . . 393
28.2. Multivariate Transformationstheoreme . . . 395

29. Normalverteilungen **398**
29.1. Konstruktion multivariater Normalverteilungen . . . 398
29.2. Definition multivariater Normalverteilungen . . . 400
29.3. Sphärizität . . . 402
29.4. Marginale, bedingte und gemeinsame Verteilungen . . . 403
29.5. Marginale Normalverteilungen . . . 404
29.6. Multivariate Transformationen . . . 406
29.7. Transformationen normalverteilter Zufallsvariablen . . . 408
29.8. Literaturhinweise . . . 422

IV. Inferenz **423**

30. Frequentistische Inferenz **424**
30.1. Frequentistische Inferenzmodelle . . . 424
30.2. Statistiken und Schätzer . . . 426
30.3. Standardannahmen und Standardproblemstellungen . . . 427

31. Punktschätzung **432**
31.1. Maximum-Likelihood-Schätzung . . . 433
31.2. Schätzereigenschaften bei endlichen Stichproben . . . 437
31.3. Asymptotische Schätzereigenschaften . . . 453
31.4. Eigenschaften von Maximum-Likelihood-Schätzern . . . 460
31.5. Literaturhinweise . . . 460

32. Konfidenzintervalle **462**
32.1. Definition . . . 462
32.2. Beispiele für Konfidenzintervalle . . . 463
32.3. Literaturhinweise . . . 474

33. Hypothesentests **476**
33.1. Testhypothesen und Tests . . . 477
33.2. Testgütekriterien und Testkonstruktion . . . 480
33.3. Testbeispiele . . . 486
33.4. Konfidenzintervalle und Hypothesentests . . . 501
33.5. Literaturhinweise . . . 503

V. Allgemeines Lineares Modell **505**

34. Regression **506**
34.1. Methode der kleinsten Quadrate . . . 507
34.2. Einfache lineare Regression . . . 512
34.3. Literaturhinweise . . . 517

35. Korrelation **518**
35.1. Grundlagen . . . 518
35.2. Korrelation und Bestimmheitsmaß . . . 522
35.3. Korrelation und linear-affine Abhängigkeit . . . 526
35.4. Literaturhinweise . . . 528

36. Modellformulierung **529**
36.1. Allgemeine Theorie . . . 529
36.2. Identifizierbarkeit und Schätzbarkeit . . . 532
36.3. Designspektrum . . . 534
36.4. Literaturhinweise . . . 535

37. Parameterschätzung **537**
37.1. Betaparameterschätzung . . . 537
37.2. Varianzparameterschätzung . . . 539
37.3. Unabhängig identisch normalverteilte Zufallsvariablen . . . 540
37.4. Einfache lineare Regression . . . 541
37.5. Frequentistische Schätzerverteilungen . . . 544
37.6. Literaturhinweise . . . 547

38. T-Statistiken **548**
38.1. Definition und Beispiele . . . 548
38.2. Konfidenzintervalle für Betaparameterkomponenten . . . 552
38.3. Literaturhinweise . . . 555

39. F-Statistiken **556**
39.1. Likelihood-Quotienten-Statistiken . . . 556
39.2. Definition und Verteilung . . . 558
39.3. Literaturhinweise . . . 562

40. T-Tests **564**
40.1. Einstichproben-T-Tests . . . 564
40.2. Modellevaluation . . . 566
40.3. Zweistichproben-T-Tests . . . 567
40.4. Literaturhinweise . . . 573

41. Einfaktorielle Varianzanalyse **574**
41.1. Anwendungsszenario . . . 574
41.2. Anwendungsbeispiel . . . 574
41.3. Modellformulierung . . . 575
41.4. Modellschätzung . . . 580
41.5. Modellevaluation . . . 582
41.6. Literaturhinweise . . . 592

42. Zweifaktorielle Varianzanalyse **593**
42.1. Anwendungsszenario . . . 593
42.2. Modellformulierung . . . 596
42.3. Modellschätzung . . . 605
42.4. Modellevaluation . . . 609
42.5. Literaturhinweise . . . 614

43. Partielle Korrelation **615**
43.1. Motivation . . . 615
43.2. Bedingte Korrelation . . . 617
43.3. Bedingte Korrelation bei Normalverteilung . . . 619
43.4. Partielle Korrelation . . . 620
43.5. Literaturhinweise . . . 623

44. Multiple Regression **624**
44.1. Anwendungsszenario . . . 624
44.2. Modellformulierung . . . 625
44.3. Modellschätzung . . . 626
44.4. Modellevaluation . . . 632
44.5. Literaturhinweise . . . 634

Referenzen **635**

Willkommen

Herzlich willkommen zur Arbeitsversion von *Probabilistische Datenwissenschaft für die Psychologie (PDWP)*, einem Lehrbuch zur datenwissenschaftlichen Methodenlehre am Institut für Psychologie der Otto-von-Guericke-Universität Magdeburg.



Abbildung 1. Probabilistische Datenwissenschaft für die Psychologie

Zitation

Ostwald, D. (2024) Probabilistische Datenwissenschaft für die Psychologie. 10.5281/zenodo.10730199

Lizenz

Dieses Werk ist lizenziert unter einer Creative Commons Namensnennung 4.0 International Lizenz.

Teil I.

Mathematische Grundlagen

Als Sprache der naturwissenschaftlichen Modellbildung ist die Mathematik auch die Sprache der probabilistischen Datenwissenschaft der Psychologie. Die Funktion der Mathematik ist dabei die einer Vermittlerin zwischen intuitiver Wissenschaftssprache und der Vielfalt von Programmiersprachen, die zur Implementation datenwissenschaftlicher Analysen eingesetzt werden. Mathematische Begriffsbildungen erlauben es, Konzepte sehr genau und allgemein verständlich zu greifen und unabhängig von den Ungenauigkeiten der naturwissenschaftlichen Alltagssprache oder den Idiosynkratien verschiedener Programmiersprachen zu kommunizieren. Natürlich kann die mathematische Sprache diese Rolle nicht losgelöst von wissenschaftssprachlicher Intuition oder praktischer Anwendung einnehmen. Die Mathematik ist in der probabilistischen Datenanalyse also nie Selbstzweck, sondern immer als angewandte Mathematik zu verstehen.

In diesem Teil stellen wir nach einigen Gedanken zu den grundlegenden Konzepten der Mathematik (Kapitel 1) mit den Mengen und den Funktionen (Kapitel 2 und Kapitel 4) die beiden Grundpfeiler der modernen Mathematik in komprimierter Form dar. Wir ergänzen diese Darstellung durch einige notationelle Aspekte in Kapitel 3. Eng verwoben mit dem Begriff der Funktion sind die Differenzialrechnung und die Integralrechnung (Kapitel 6 und Kapitel 7). Auch hier geht es nicht um eine erschöpfende Darstellung, sondern insbesondere um die Erläuterung einiger Grundlagen, die für die datenwissenschaftlich zentralen Konzepte der Optimierung sowie für den Umgang mit Wahrscheinlichkeitsfunktionen zentral sind. Wir ergänzen diese Abschnitte mit einigen einführenden Gedanken zu den analytischen Grundlagen der Differenzialrechnung und Integralrechnung in Kapitel 5. Im Umgang mit den großen Datenmengen der zeitgenössischen Wissenschaft hat sich die Matrixschreibweise als hilfreich erwiesen. Wir widmen uns diesem Teilbereich der linearen Algebra zunächst für einspaltige Matrizen in Kapitel 14 und dann ausführlich in Kapitel 9, wiederum mit dem Ziel, notationelle und rechnerische Grundlagen für spätere Abschnitte bereitzustellen.

Insgesamt dient dieser Teil also vor allem der Kurzeinführung von Grundlagen, die in anderen Teilen wieder aufgegriffen werden, und dabei vor allem auch der Einführung einer einheitlichen Notation. Je nach Bedarf und Interesse ist natürlich ein vertieftes Selbststudium der verschiedenen Inhalte angezeigt. In den folgenden Literaturhinweisen führen wir überblicksartig Quellen und Leseempfehlungen zu den hier betrachteten Inhalten.

Literaturhinweise

Bärwolff (2017) und Arens et al. (2018) bilden die primäre Grundlage für viele hier dargestellten Themen und bieten einen exzellenten und umfassenden Einstieg in die behandelte Materie. Auf internationaler Ebene geben Spivak (2008) und Strang (2009) sehr gut lesbare Einführungen in die Differenzialrechnung bzw. die lineare Algebra. Ein tieferes Verständnis insbesondere analytischer Konzepte liefern zum Beispiel Abbott (2015) und Chiossi (2021). S. Searle (1982) bietet eine kompakte Darstellung derjenigen Aspekte der Matrizenrechnung und linearen Algebra, die im Bereich der probabilistischen Datenanalyse hauptsächlich zum Einsatz kommen. Deisenroth et al. (2020) bietet einen Überblick über viele der hier behandelten Themen unter dem Moniker des maschinellen Lernens.

1. Sprache und Logik

1.1. Mathematik ist eine Sprache

Mathematik ist die Sprache der naturwissenschaftlichen Modellbildung. So entspricht zum Beispiel der Ausdruck

$$F = ma \tag{1.1}$$

im Sinne des zweiten Newtonschen Axioms einer Theorie zur Bewegung von Objekten unter der Einwirkung von Kräften (Newton (1687)). Gleichermaßen entspricht der Ausdruck

$$\max_{q(z)} \int q(z) \ln \left(\frac{p(y,z)}{q(z)} \right) dz \tag{1.2}$$

im Sinne der Variational Inference der zeitgenössischen Theorie zur Funktionsweise des Gehirns (Friston (2005)). Mathematische Symbolik dient dabei insbesondere der genauen Kommunikation wissenschaftlicher Erkenntnisse und zielt darauf ab, komplexe Sachverhalte exakt und effizient zu beschreiben. Wie beim reflektierten Umgang mit jeder Form von Sprache steht also die Frage "Was soll das heißen?" als Leitfrage im Umgang mit mathematischen Inhalten und Symbolismen immer im Vordergrund.

Als Sprachgebäude weist die Mathematik einige Besonderheiten auf. Zum einen sind ihre Inhalte oft abstrakt. Dies rührt daher, dass sich die Mathematik um eine möglichst breite Allgemeinverständlichkeit und Anwendbarkeit bemüht. Mathematische Zugänge zu den Phänomenen der Welt sind dabei an einer möglichst einfachen Transferierbarkeit von Erkenntnissen in andere Kontexte interessiert. Um dies zu ermöglichen, versucht die Mathematik möglichst genau und verständlich, also im Sinne präziser Begriffe zu arbeiten. Sie geht dabei streng hierarchisch vor, sodass an späterer Stelle eingeführte Begriffe oft ein gutes Verständnis der ihnen zugrundeliegenden und an früherer Stelle eingeführten Begriffe voraussetzen.

Die Genauigkeit der mathematischen Sprache impliziert eine hohe Informationsdichte. Sie ist daher eher nüchtern und lässt Überflüssiges weg, sodass in mathematischen Texten im besten Fall *alles* für die Kommunikation einer Idee relevant ist. Als Rezipient:in mathematischer Texte nimmt man ihre Informationsdichte anhand des hohen Verbrauchs kognitiver Energie beim Lesen eines mathematischen Textes wahr. Dieser hohe Energieverbrauch gebietet insbesondere Ruhe und Langsamkeit bei einem auf ein gutes Verständnis abzielenden Lesen. Als Leitsatz im Umgang mit mathematischen Texten mag dabei folgendes Zitat dienen: "Einen mathematischen Text kann man nicht lesen wie einen Roman, man muss ihn sich erarbeiten" (Unger (2000)). Nach dem Lesen eines kurzen mathematischen Textes sollte man sich immer kritisch fragen, ob man das Gelesene wirklich verstanden hat oder ob man zur Klärung des Sachverhaltes weitere Quellen heranziehen sollte. Auch ist es hilfreich, sich im Sinne des berühmten Zitats "What I cannot create, I do not understand" von Richard Feynman eigene Aufzeichnungen anzufertigen und mathematische Sprachgebäude selbst nachzukonstruieren.

Möchte man sich also die Welt der naturwissenschaftlichen Modellbildung erschließen, so ist es hilfreich, beim Umgang mit ihrer mathematischen Ausdrucksweise und Symbolik die gleichen Strategien wie beim Erlernen einer Fremdsprache anzuwenden. Hierzu gehört neben dem Eintauchen in den entsprechenden Sprachraum, also der ständigen Exposition mit mathematischen Ausdrucksweisen, sicherlich auch zunächst einmal das Auswendiglernen von Begriffen und das Übersetzen von Texten in die Alltagssprache. Ein tiefes und sicheres Verständnis mathematischer Modellbildung ergibt sich dann insbesondere durch die Anwendung mathematischer Herangehensweisen in schriftlicher und mündlicher Form.

1.2. Grundbausteine

Im Folgenden stellen wir mit den Begriffen der *Definition*, des *Theorems* und des *Beweises* drei Grundbausteine mathematischer Kommunikation vor, die uns durchgängig begleiten.

Definition

Eine *Definition* ist ein Grundstein eines mathematischen Systems, der innerhalb dieses Systems weder begründet noch deduktiv abgeleitet wird. Definitionen können nur nach ihrer Nützlichkeit innerhalb eines mathematischen Systems bewertet werden. Eine Definition lernt man am besten erst einmal auswendig und hinterfragt sie erst dann, wenn man ihren Nutzen in der Anwendung verstanden hat oder von diesem nicht überzeugt ist. Etwas Entspannung und Ruhe beim Umgang mit auf den ersten Blick komplexen Definitionen ist generell hilfreich. Um zu kennzeichnen, dass wir ein Symbol als etwas definieren, nutzen wir die Schreibweise "$:=$". Zum Beispiel definiert der Ausdruck "$a := 2$" das Symbol a als die Zahl zwei. Definitionen enden in diesem Text immer mit dem Symbol $\bullet$.

Theorem

Ein *Theorem* ist eine mathematische Aussage, die mittels eines Beweises als richtig (wahr) erkannt werden kann. Das heißt, ein Theorem wird immer aus Definitionen und/oder anderen Theoremen hergeleitet. Theoreme sind in diesem Sinne die empirischen Ergebnisse der Mathematik. Im Deutschen werden Theoreme oft auch als *Sätze* bezeichnet. In der angewandten, datenanalytischen Mathematik sind Theoreme häufig für Berechnungen hilfreich. Es lohnt sich also, sie auswendig zu lernen, da sie meist die Grundlage für Datenauswertung und Dateninterpretation bilden. Oft tauchen in Theoremen Gleichungen auf. Diese ergeben sich dabei aus den Voraussetzungen des Theorems. Um Gleichungen zu kennzeichnen, nutzen wir das Gleichheitszeichen "$=$". So besagt beispielsweise der Ausdruck "$a = 2$" in einem gegebenen Kontext, dass aufgrund bestimmter Voraussetzungen die Variable a den Wert zwei hat. Theoreme enden in diesem Text immer mit dem Symbol $\circ$.

Beweis

Ein *Beweis* ist eine Argumentationskette, die auf bekannte Definitionen und Theoreme zurückgreift, um die Richtigkeit (Wahrheit) eines Theorems zu belegen. Kurze Beweise tragen dabei oft zum Verständnis eines Theorems bei, lange Beweise eher nicht. Beweise sind also insbesondere die Antwort auf die Frage, warum eine mathematische Aussage gilt ("Warum ist das so?"). Beweise lernt man nicht auswendig. Wenn Beweise kurz sind, ist es sinnvoll, sie durchzuarbeiten, da sie meist als bekannt vorausgesetzte Inhalte wiederholen. Wenn sie lang sind, ist es sinnvoller, sie zunächst zu übergehen, um sich nicht in Details

zu verlieren und vom eigentlichen Weg durch das mathematische Gebäude abzukommen. Beweise enden in diesem Text immer mit dem Symbol □.

Neben Definitionen, Theoremen und Beweisen gibt es mit *Axiomen*, *Lemmata*, *Korollaren* und *Vermutungen* noch weitere typische Bausteine mathematischer Texte. Wir werden diese Begriffe nicht verwenden und geben deshalb für sie nur einen kurzen Überblick.

- *Axiome* sind unbewiesene Grundannahmen, in dem Sinne, dass sie als Ausgangspunkte zum Aufbau mathematischer Systeme dienen. Der Übergang zwischen Definitionen und Axiomen ist dabei oft fließend. Da wir mathematisch nicht besonders tief arbeiten, bevorzugen wir in den allermeisten Fällen den Begriff der Definition.
- Ein *Lemma* ist ein "Hilfstheorem", also eine mathematische Aussage, die zwar bewiesen wird, aber nicht so bedeutend ist wie ein Theorem. Da wir einerseits auf bedeutende Inhalte fokussieren und andererseits mathematische Aussagen nicht diskriminieren wollen, verzichten wir auf diesen Begriff und nutzen stattdessen durchgängig den Begriff des Theorems.
- Ein *Korollar* ist eine mathematische Aussage, die sich durch einen einfachen Beweis aus einem Theorem ergibt. Da die "Einfachheit" mathematischer Beweise eine relative Eigenschaft ist, verzichten wir auf diesen Begriff und nutzen stattdessen auch hier durchgängig den Begriff des Theorems.
- *Vermutungen* sind mathematische Aussagen, von denen unbekannt ist, ob sie beweisbar oder widerlegbar sind. Da wir im Bereich der angewandten Mathematik arbeiten, treffen wir nicht auf Vermutungen.

1.3. Aussagenlogik

Nachdem wir nun einige Grundbausteine mathematischer Sprachgebäude kennengelernt haben, wollen wir uns mit der *Aussagenlogik* einem einfachen System nähern, das es erlaubt, Beziehungen zwischen mathematischen Aussagen herzustellen und zu formalisieren. Die Aussagenlogik spielt zum Beispiel in der Definition von Mengenoperationen, bei Optimierungsbedingungen von Funktionen und in vielen Beweisen eine tragende Rolle. In der datenanalytischen Anwendung ist die Aussagenlogik die Grundlage der Booleschen Logik der Programmierung. In der mathematischen Psychologie ist die Aussagenlogik die Grundlage der Repräsentationstheorie des Messens.

Wir beginnen mit der Definition des Begriffs der mathematischen *Aussage*.

Definition 1.1 (Aussage)**.** Eine *Aussage* ist ein Satz, dem eindeutig die Eigenschaft *wahr* oder *falsch* zugeordnet werden kann.

•

Das Adjektiv *wahr* kann auch als *richtig* verstanden werden. Wir kürzen wahr mit "w" und falsch mit "f" ab. Im Körper der reellen Zahlen ist zum Beispiel die Aussage $1+1=2$ wahr und die Aussage $1+1=3$ falsch. Man beachte, dass die Binärität des Wahrheitsgehalts von Aussagen eine Grundannahme der Aussagenlogik und damit formal wissenschaftlich und nicht empirisch zu verstehen ist. Wahrheitsgehalte beziehen sich nicht auf Definitionen; Definitionen legen Bedeutungen fest.

Eine erste Möglichkeit, mit Aussagen zu arbeiten, ist, sie zu negieren. Dies führt auf folgende Definition.

Definition 1.2 (Negation)**.** A sei eine Aussage. Dann ist die *Negation von* A die Aussage, die falsch ist, wenn A wahr ist und die wahr ist, wenn A falsch ist. Die Negation von A wird mit $\neg A$, gesprochen als "nicht A", bezeichnet.

•

Beispiel 1.1 (Negation von Aussagen)**.** Die Negation der Aussage "Die Sonne scheint" ist die Aussage "Die Sonne scheint nicht". Die Negation der Aussage $1 + 1 = 2$ ist die Aussage $1 + 1 \neq 2$, und die Negation der Aussage $x > 1$ ist die Aussage $x \leq 1$.

△

Tabellarisch stellt man die Definition der Negation einer Aussage A wie folgt dar:

Tabelle 1.1. Wahrheitstafel der Negation

A	$\neg A$
w	f
f	w

Tabellen dieser Form nennt man *Wahrheitstafeln*. Sie sind ein beliebtes Hilfsmittel in der Aussagenlogik, das wir im Folgenden oft einsetzen werden.

Möchte man zwei Aussagen logisch verbinden, so bieten sich die Begriffe der *Konjunktion* und der *Disjunktion* an.

Definition 1.3 (Konjunktion)**.** A und B seien Aussagen. Dann ist die *Konjunktion von* A *und* B die Aussage, die dann und nur dann wahr ist, wenn A und B beide wahr sind. Die Konjunktion von A und B wird mit $A \wedge B$, gesprochen als "A und B", bezeichnet.

•

Die Definition der Konjunktion impliziert folgende Wahrheitstafel:

Tabelle 1.2. Wahrheitstafel der Konjunktion

A	B	$A \wedge B$
w	w	w
w	f	f
f	w	f
f	f	f

Beispiel 1.2 (Konjunktion von Aussagen)**.** Es sei A die Aussage $2 \geq 1$ und B die Aussage $2 > 1$. Da sowohl A als auch B wahr sind, ist auch die Aussage $(2 \geq 1) \wedge (2 > 1)$ wahr.

Als weiteres Beispiel sei A die Aussage $1 \geq 1$ und B die Aussage $1 > 1$. Hier ist nur A wahr und B falsch. Also ist die Aussage $(1 \geq 1) \wedge (1 > 1)$ falsch.

△

Definition 1.4 (Disjunktion)**.** A und B seien Aussagen. Dann ist die *Disjunktion von A und B* die Aussage, die dann und nur dann wahr ist, wenn mindestens eine der beiden Aussagen A und B wahr ist. Die Disjunktion von A und B wird mit $A \vee B$, gesprochen als "A oder B", bezeichnet.

•

Die Definition der Disjunktion impliziert folgende Wahrheitstafel:

Tabelle 1.3. Wahrheitstafel der Disjunktion

A	B	$A \vee B$
w	w	w
w	f	w
f	w	w
f	f	f

$A \vee B$ ist also insbesondere auch dann wahr, wenn A und B beide wahr sind. Damit ist das hier betrachtete "oder" genauer ein "und/oder". Man nennt die Disjunktion daher auch ein "nicht-exklusives oder". Als Beispiel sei A die Aussage $2 \geq 1$ und B die Aussage $2 > 1$. A ist wahr und B ist wahr. Also ist die Aussage $(2 \geq 1) \vee (2 > 1)$ wahr. Sei nun wiederum A die Aussage $1 \geq 1$ und B die Aussage $1 > 1$. Dann ist A wahr und B falsch. Also ist die Aussage $(1 \geq 1) \vee (1 > 1)$ wahr.

Eine Möglichkeit, Aussagen in einen mechanischen logischen Zusammenhang zu stellen, ist die *Implikation*. Diese ist wie folgt definiert.

Definition 1.5 (Implikation)**.** A und B seien Aussagen. Dann ist die *Implikation*, bezeichnet mit $A \Rightarrow B$, die Aussage, die dann und nur dann falsch ist, wenn A wahr und B falsch ist. A heißt dabei die *Voraussetzung (Prämisse)* und B der *Schluss (Konklusion)* der Implikation. $A \Rightarrow B$ spricht man als "aus A folgt B", "A impliziert B" oder "wenn A, dann B".

•

Die Definition der Implikation kann durch folgende Wahrheitstafel dargestellt werden:

Tabelle 1.4. Wahrheitstafel der Implikation

A	B	$A \Rightarrow B$
w	w	w
w	f	f
f	w	w
f	f	w

Beispiel 1.3 (Beschädigung und Sperrung einer Brücke)**.** Zur Illustration von Tabelle 1.4 betrachten wir ein lebensnahes Beispiel. Dazu betrachten wir eine bestimmte Brücke zu einem bestimmten Zeitpunkt. Es sei A die Aussage "Die Brücke ist beschädigt", B die Aussage "Die Brücke ist gesperrt" und $A \Rightarrow B$ die Implikation "Wenn die Brücke beschädigt ist, dann ist die Brücke gesperrt". Wir diskutieren die vier Fälle von Tabelle 1.4.

1. A wahr, B wahr, $A \Rightarrow B$ wahr. Wenn A wahr ist, dann ist die Brücke beschädigt und wenn dazu auch B wahr ist, dann ist die Brücke außerdem gesperrt. In diesem Fall ist die Implikation "Wenn die Brücke beschädigt ist, dann ist die Brücke gesperrt" also offensichtlich wahr.
2. A wahr, B falsch, $A \Rightarrow B$ falsch. Wenn A wahr ist, dann ist die Brücke beschädigt und wenn B falsch ist, dann ist die Brücke also nicht gesperrt. In diesem Fall ist die Implikation "Wenn die Brücke beschädigt ist, dann ist die Brücke gesperrt" also offensichtlich falsch.
3. A falsch, B wahr, $A \Rightarrow B$ wahr. Wenn A falsch ist, dann ist die Brücke nicht beschädigt und wenn B wahr ist, dann ist die Brücke gesperrt. Da die Voraussetzung A falsch ist, ist die Implikation $A \Rightarrow B$ nach Definition wahr.
4. A falsch, B falsch, $A \Rightarrow B$ wahr. Wenn A falsch ist, dann ist die Brücke nicht beschädigt und wenn B falsch ist, dann ist die Brücke nicht gesperrt. Da die Voraussetzung A falsch ist, ist die Implikation $A \Rightarrow B$ nach Definition auch in diesem Fall wahr.

△

Beispiel 1.4 ($x = 2 \Rightarrow x^2 = 4$)**.** Wir wollen Tabelle 1.4 anhand der Implikation

$$x = 2 \Rightarrow x^2 = 4 \tag{1.3}$$

diskutieren. Dazu betrachten wir die Aussagen

$$A : x = 2 \text{ und } B : x^2 = 4. \tag{1.4}$$

Sowohl A als auch B können, je nach Definition von x, wahr oder falsch sein. Gilt zum Beispiel $x := 1$, so sind sowohl $A : x = 2$ als auch $B : x^2 = 4$ falsch. Betrachten wir die Zeilen von Tabelle 1.4 nacheinander.

1. A wahr, B wahr, $A \Rightarrow B$ wahr. In diesem Fall muss $x := 2$ gelten, denn dann sind $2 = 2$ und $2^2 = 4$ wahr. Das ist der Fall, den die Implikation unmittelbar beschreibt: Wenn $x = 2$, dann ist tatsächlich $x^2 = 4$.
2. A wahr, B falsch, $A \Rightarrow B$ falsch. Hier müsste gleichzeitig $x = 2$ und $x^2 \neq 4$ gelten. Dieser Fall kann jedoch nicht auftreten, denn aus $x = 2$ folgt $x^2 = 2 \cdot 2 = 4$. Damit ist der einzige Fall ausgeschlossen, in dem die Implikation falsch wäre.
3. A falsch, B wahr, $A \Rightarrow B$ wahr. Dieser Fall kann auftreten, denn für $x := -2$ gilt, dass A falsch ist, aber B wahr ist. Dies ändert nach Definition in Tabelle 1.4 aber nichts am Wahrheitsgehalt der Implikation.
4. A falsch, B falsch, $A \Rightarrow B$ wahr. Auch dieser Fall kann auftreten, widerspricht der Implikation aber nicht, da zum Beispiel für $x := 3$ die Aussage A falsch ist und damit die Voraussetzung der Implikation nicht erfüllt ist.

△

Eine Implikation gilt für alle betrachteten Werte genau dann, wenn für keinen dieser Werte A wahr und B falsch ist. Ein einziges Gegenbeispiel widerlegt diese allgemeine Behauptung. Im folgenden Beispiel nutzen wir erneut den Ausschluss des Falls A wahr, B falsch.

Beispiel 1.5 (Gerades Quadrat und gerade Zahl)**.** Wir wollen zeigen: Ist das Quadrat einer ganzen Zahl m gerade, so ist auch m gerade. Formal haben wir für eine fest gewählte ganze Zahl m die Aussagen

$$A : m^2 \text{ ist gerade}, B : m \text{ ist gerade} \tag{1.5}$$

und wollen die Wahrheit von $A \Rightarrow B$ für jede ganze Zahl m zeigen. Dies können wir schreiben als

- Für jede ganze Zahl m gilt, dass wenn m^2 gerade ist, dann auch m gerade ist.
- Für jede ganze Zahl m gilt "m^2 ist gerade $\Rightarrow$ m ist gerade".

Nach der Wahrheitstafel der Implikation ist $A \Rightarrow B$ nur dann falsch, wenn A wahr und B falsch ist. Wir müssen nur sicherstellen, dass der Fall "m^2 ist gerade" und "die ganze Zahl m ist ungerade" nicht auftreten kann. Dazu zeigen wir: Ist die ganze Zahl m ungerade, so ist auch m^2 ungerade.

Sei also die ganze Zahl m ungerade. Dann gibt es eine ganze Zahl k, für die $m = 2k + 1$ gilt. Für das Quadrat eines solchen m gilt dann

$$m^2 = (2k + 1)^2 = 4k^2 + 4k + 1 = 2(2k^2 + 2k) + 1. \tag{1.6}$$

Damit ist m^2 wiederum von der Form $2n + 1$, und zwar für die ganze Zahl $n := 2k^2 + 2k$. Der Fall "A wahr und B falsch" kann also nicht auftreten. Damit ist die Implikation

$$m^2 \text{ ist gerade} \Rightarrow m \text{ ist gerade} \tag{1.7}$$

für jede ganze Zahl m wahr.

△

Ein weiteres intuitives Verständnis der Definition der Implikation im Sinne obiger Wahrheitstafel ergibt sich, indem man sie als Versuch liest, die Vorstellung einer Folgerung im Kontext der Aussagenlogik abzubilden und zu formalisieren. Dazu liest man die Wahrheitszustände in Tabelle 1.4 in der Reihenfolge Wahrheitszustand von A, Wahrheitszustand von $A \Rightarrow B$ und betrachtet schließlich den Wahrheitszustand von B. Liest man die Wahrheitstafel auf diese Weise, so sieht man, dass, wenn A wahr ist und $A \Rightarrow B$ wahr ist, B wahr ist. Konstruiert man basierend auf einer wahren Aussage also (zum Beispiel durch das Umformen von Gleichungen) eine wahre Implikation, so folgt, dass auch B wahr ist. Wenn A wahr und $A \Rightarrow B$ falsch ist, dann ist B falsch. Auch so lassen sich Aussagen widerlegen. Schließlich sieht man, dass, wenn A falsch ist und $A \Rightarrow B$ wahr ist, B wahr oder falsch sein kann. Nur aus einer wahren Voraussetzung folgt also bei wahrer Implikation immer eine wahre Konklusion. Bei falscher Voraussetzung ist die Implikation unabhängig vom Wahrheitswert der Konklusion wahr. Aus der Wahrheit von $A \Rightarrow B$ und der Falschheit von A lässt sich daher nicht bestimmen, ob B wahr oder falsch ist.

Im Kontext der Implikation ergeben sich die Begriffe der *hinreichenden* und der *notwendigen* Bedingungsaussagen: Wenn $A \Rightarrow B$ wahr ist, sagt man, dass "A *hinreichend* für B ist" und dass "B *notwendig* für A ist". Diese Sprechweise erklärt sich im Kontext der Implikation folgendermaßen: Wenn $A \Rightarrow B$ wahr ist, gilt, dass, wenn A wahr ist, auch B wahr ist. Die Wahrheit von A reicht also für die Wahrheit von B aus. A ist also hinreichend (ausreichend) für B. Weiterhin gilt: Wenn $A \Rightarrow B$ wahr und B falsch ist, dann ist auch A falsch. Die Wahrheit von B ist also für die Wahrheit von A notwendig.

Ein sehr häufig auftretender Zusammenhang zwischen zwei Aussagen ist ihre *Äquivalenz*.

Definition 1.6 (Äquivalenz)**.** A und B seien Aussagen. Die *Äquivalenz von A und B* ist die Aussage, die dann und nur dann wahr ist, wenn A und B beide wahr sind oder wenn A und B beide falsch sind. Die Äquivalenz von A und B wird mit $A \Leftrightarrow B$ bezeichnet und gesprochen als "A genau dann, wenn B" oder "A ist äquivalent zu B".

•

Die Definition der Äquivalenz impliziert folgende Wahrheitstafel:

Tabelle 1.5. Wahrheitstafel der Äquivalenz

A	B	$A \Leftrightarrow B$
w	w	w
w	f	f
f	w	f
f	f	w

Die Definition des Begriffs der *logischen Äquivalenz* erlaubt es unter anderem, die Äquivalenz zweier Aussagen mithilfe von Implikationen nachzuweisen.

Definition 1.7 (Logische Äquivalenz)**.** Zwei Aussagen heißen *logisch äquivalent*, wenn ihre Wahrheitstafeln gleich sind.

•

Als Beispiele für logische Äquivalenzen, die häufig in Beweisargumentationen genutzt werden, zeigen wir die Aussagen des folgenden Theorems.

Theorem 1.1 (Logische Äquivalenzen)**.** *A und B seien zwei Aussagen. Dann sind folgende Aussagen logisch äquivalent:*

(1) $A \Leftrightarrow B$ *und* $(A \Rightarrow B) \wedge (B \Rightarrow A)$
(2) $A \Rightarrow B$ *und* $(\neg B) \Rightarrow (\neg A)$

∘

Beweis. Nach Definition des Begriffs der logischen Äquivalenz müssen wir zeigen, dass die Wahrheitstafeln der betrachteten Aussagen gleich sind. Wir zeigen erst (1), dann (2).

(1) Wir erinnern an die Wahrheitstafel von $A \Leftrightarrow B$:

A	B	$A \Leftrightarrow B$
w	w	w
w	f	f
f	w	f
f	f	w

Wir betrachten weiterhin die Wahrheitstafel von $(A \Rightarrow B) \wedge (B \Rightarrow A)$:

A	B	$A \Rightarrow B$	$B \Rightarrow A$	$(A \Rightarrow B) \wedge (B \Rightarrow A)$
w	w	w	w	w
w	f	f	w	f
f	w	w	f	f
f	f	w	w	w

Der Vergleich der Wahrheitstafel von $A \Leftrightarrow B$ mit den ersten beiden und der letzten Spalte der Wahrheitstafel von $(A \Rightarrow B) \wedge (B \Rightarrow A)$ zeigt ihre Gleichheit.

(2) Wir erinnern an die Wahrheitstafel von $A \Rightarrow B$:

A	B	$A \Rightarrow B$
w	w	w
w	f	f
f	w	w
f	f	w

Wir betrachten weiterhin die Wahrheitstafel von $(\neg B) \Rightarrow (\neg A)$:

A	B	$\neg B$	$\neg A$	$(\neg B) \Rightarrow (\neg A)$
w	w	f	f	w
w	f	w	f	f
f	w	f	w	w
f	f	w	w	w

Der Vergleich der Wahrheitstafel von $A \Rightarrow B$ mit den ersten beiden und der letzten Spalte der Wahrheitstafel von $(\neg B) \Rightarrow (\neg A)$ zeigt ihre Gleichheit. □

Die erste Aussage von Theorem 1.1 besagt, dass die Aussage "A und B sind äquivalent" logisch äquivalent zur Aussage "Aus A folgt B und aus B folgt A" ist. Dies ist die Grundlage für viele sogenannte *direkte Beweise* mithilfe von Äquivalenzumformungen. Die zweite Aussage von Theorem 1.1 besagt, dass die Aussage "Aus A folgt B" logisch äquivalent zur Aussage "Aus nicht B folgt nicht A" ist. Dies ist die Grundlage für die Technik des *indirekten Beweises*. Wir betrachten diese Beweistechniken im folgenden Abschnitt genauer. Zunächst fassen wir die Bedeutungen der in diesem Abschnitt eingeführten Symbole noch einmal in untenstehender Tabelle zusammen.

Tabelle 1.6. Symbolübersicht. A und B sind Aussagen, d. h. A und B sind entweder wahr oder falsch.

Symbol	Bedeutung	Bemerkung
$\neg A$	Nicht A	Wahr, wenn A falsch ist und umgekehrt
$A \wedge B$	A und B	Nur wahr, wenn A und B beide wahr sind
$A \vee B$	A und/oder B	Wahr, wenn mindestens eine der Aussagen wahr ist
$A \Rightarrow B$	Aus A folgt B	B ist notwendig für A, A ist hinreichend für B
$A \Leftrightarrow B$	A ist äquivalent zu B	Es gelten $A \Rightarrow B$ und $B \Rightarrow A$

1.4. Äquivalenzumformungen

Mathematische Probleme führen oft auf den Fall, dass Information über eine unbekannte Variable implizit mithilfe einer Gleichung oder einer Ungleichung dargestellt wird. Um die möglichen Werte der Variablen, also die Lösungsmenge der Gleichung oder Ungleichung, explizit zu bestimmen, nutzt man *Äquivalenzumformungen*. Wir betrachten hier lediglich die aus der Schulmathematik bekannten Äquivalenzumformungen von Gleichungen und Ungleichungen bezüglich reeller Variablen. Äquivalenzumformungen von Gleichungen und Ungleichungen haben die Eigenschaft, dass sich der Wahrheitswert für jeden Wert der Variablen im betrachteten Definitionsbereich nicht ändert. Häufig geschieht dies durch Anwendung derselben geeigneten Operation auf beiden Seiten. Damit es sich bei einer

Umformung einer Gleichungs- oder Ungleichungsaussage A in eine Gleichungs- oder Ungleichungsaussage B um eine Äquivalenzumformung handelt, müssen für jeden Wert der Variablen im betrachteten Definitionsbereich sowohl $A \Rightarrow B$ als auch $B \Rightarrow A$ gelten. Die Umformung muss also in beiden Richtungen gültig sein.

Bei Gleichungen sind zulässige Äquivalenzumformungen insbesondere

- die Addition einer Zahl auf beiden Seiten der Gleichung,
- die Subtraktion einer Zahl auf beiden Seiten der Gleichung,
- die Multiplikation mit einer von null verschiedenen Zahl auf beiden Seiten der Gleichung,
- die Division durch eine von null verschiedene Zahl auf beiden Seiten der Gleichung,
- die Anwendung einer invertierbaren Funktion auf beiden Seiten der Gleichung, sofern beide Seiten in ihrem Definitionsbereich liegen.

Beispiel 1.6 (Äquivalenzumformung einer Exponentialgleichung)**.** Wir betrachten unter Vorgriff auf Kapitel 4.3 die Aussage

$$2\exp(x) - 2 = 0. \tag{1.8}$$

Dann gelten

$$\begin{aligned} & 2\exp(x) - 2 = 0 \\ \Leftrightarrow\ & 2\exp(x) - 2 + 2 = 0 + 2 \\ \Leftrightarrow\ & 2\exp(x) = 2 \\ \Leftrightarrow\ & \frac{1}{2} \cdot 2\exp(x) = \frac{1}{2} \cdot 2 \\ \Leftrightarrow\ & \exp(x) = 1 \\ \Leftrightarrow\ & \ln(\exp(x)) = \ln(1) \\ \Leftrightarrow\ & x = 0. \end{aligned} \tag{1.9}$$

Zusammengefasst gilt also

$$2\exp(x) - 2 = 0 \Leftrightarrow x = 0. \tag{1.10}$$

△

Bei Ungleichungen sind zulässige Äquivalenzumformungen insbesondere

- die Addition einer Zahl auf beiden Seiten der Ungleichung,
- die Subtraktion einer Zahl auf beiden Seiten der Ungleichung,
- die Multiplikation mit einer von null verschiedenen Zahl auf beiden Seiten der Ungleichung, wobei die Multiplikation mit einer negativen Zahl das Ungleichungszeichen umkehrt,
- die Division durch eine von null verschiedene Zahl auf beiden Seiten der Ungleichung, wobei die Division durch eine negative Zahl das Ungleichungszeichen umkehrt,
- die Anwendung einer streng monoton wachsenden oder streng monoton fallenden Funktion auf beiden Seiten der Ungleichung, sofern beide Seiten in ihrem Definitionsbereich liegen. Bei streng monoton fallenden Funktionen wird das Ungleichungszeichen umgekehrt.

Beispiel 1.7 (Äquivalenzumformung einer Ungleichung)**.** Wir betrachten die Aussage

$$-5x - 2 \geq 8. \tag{1.11}$$

Dann gelten

$$\begin{aligned} & -5x - 2 \geq 8 \\ \Leftrightarrow & -5x - 2 + 2 \geq 8 + 2 \\ \Leftrightarrow & -5x \geq 10 \\ \Leftrightarrow & -\frac{1}{5} \cdot 5x \geq \frac{1}{5} \cdot 10 \\ \Leftrightarrow & -x \geq 2 \\ \Leftrightarrow & x \leq -2. \end{aligned} \tag{1.12}$$

Zusammengefasst gilt also

$$-5x - 2 \geq 8 \Leftrightarrow x \leq -2. \tag{1.13}$$

△

Wir wollen den Begriff der *Äquivalenzumformung* noch in Bezug zu dem oben eingeführten Begriff der *Äquivalenz* setzen. Eine Äquivalenzumformung ist eine Umformung einer Gleichung oder Ungleichung, bei der die ursprüngliche und die umgeformte Gleichung beziehungsweise Ungleichung für jeden Wert der Variablen im betrachteten Definitionsbereich denselben Wahrheitswert haben. Sie besitzen also dieselbe Lösungsmenge. Betrachten wir zum Beispiel die Umformung

$$x + 3 = 7 \Leftrightarrow x = 4, \tag{1.14}$$

die man durch Subtraktion von 3 auf beiden Seiten der ersten Gleichung erhält. Die erste Aussage $A : x + 3 = 7$ und die zweite Aussage $B : x = 4$ haben für jeden Wert von x denselben Wahrheitswert. So sind zum Beispiel für $x = 4$ beide Aussagen wahr, für $x \neq 4$ dagegen beide Aussagen falsch. Es kommen also mit Bezug auf Tabelle 1.5 nur die beiden Fälle vor, in denen die Äquivalenz wahr ist. Dies entspricht insbesondere der Tatsache, dass beide Gleichungen dieselbe Lösungsmenge haben, nämlich

$$\{x|x + 3 = 7\} = \{x|x = 4\} = \{4\}. \tag{1.15}$$

Allerdings sind nicht alle Umformungen von Gleichungen oder Ungleichungen Äquivalenzumformungen. Für die Aussagen

$$A : x = 2 \text{ und } B : x^2 = 4 \tag{1.16}$$

gilt $A \Rightarrow B$ für jedes $x \in \mathbb{R}$. Die Rückrichtung $B \Rightarrow A$ gilt dagegen nicht für alle $x \in \mathbb{R}$, denn für $x = -2$ ist B wahr und A falsch. Nach der Wahrheitstafel der Äquivalenz (Tabelle 1.5) sind die beiden Aussagen daher nicht für alle $x \in \mathbb{R}$ äquivalent. Betrachtet man die beiden Gleichungen bezüglich ihrer Lösungsmengen, so gilt entsprechend, dass ihre Lösungsmengen nicht gleich sind, denn die Lösungsmenge von A ist

$$\{x|x = 2\} = \{2\} \tag{1.17}$$

und die Lösungsmenge von B ist

$$\{x|x^2 = 4\} = \{-2, 2\}. \tag{1.18}$$

1.5. Beweistechniken

In diesem Abschnitt wollen wir mit den Begriffen des *direkten Beweises*, des *Beweises durch Kontraposition* sowie des *Beweises durch Widerspruch* drei fundamentale Beweistechniken zum Nachweis einer Implikation $A \Rightarrow B$ skizzieren. Beweise durch Kontraposition und Beweise durch Widerspruch werden auch *indirekte Beweise* genannt.

Direkte Beweise nutzen in der Regel kleine Schritte, in unseren Anwendungen meist bestehend aus Umformungen von Gleichungen, um $A \Rightarrow B$ zu zeigen. Formal reicht es dabei, die Richtung

$$A \Rightarrow A_1 \Rightarrow A_2 \Rightarrow \cdots \Rightarrow B \tag{1.19}$$

zu zeigen. Besteht in einem solchen Beweis die gesamte Kette aus Äquivalenzen,

$$A \Leftrightarrow A_1 \Leftrightarrow A_2 \Leftrightarrow \cdots \Leftrightarrow B, \tag{1.20}$$

so zeigt ein solcher Beweis sogar

$$A \Leftrightarrow B \tag{1.21}$$

und damit mehr, als eigentlich verlangt.

Beispiel 1.8 (Direkter Beweis von $x = 2 \Rightarrow x^2 = 4$)**.** Als Beispiel betrachten wir für eine reelle Zahl x die Aussagen

$$A : x = 2 \qquad \text{und} \qquad B : x^2 = 4. \tag{1.22}$$

Für einen direkten Beweis von $A \Rightarrow B$ nehmen wir $x = 2$ an. Dann folgt

$$x^2 = 2^2 = 4. \tag{1.23}$$

Damit ist die Implikation

$$x = 2 \Rightarrow x^2 = 4 \tag{1.24}$$

bewiesen.

Die Rechnung lässt sich auch als Kette

$$x = 2 \Leftrightarrow 2x = 4 \Rightarrow x^2 = 4 \tag{1.25}$$

darstellen. Hier ist nur der erste Schritt eine Äquivalenz, der zweite dagegen nur eine Implikation: Der Wert $x = -2$ erfüllt $x^2 = 4$, aber nicht $2x = 4$. Insgesamt folgt aus dieser Kette daher lediglich

$$x = 2 \Rightarrow x^2 = 4. \tag{1.26}$$

Die Rückrichtung gilt nicht, sodass die beiden Aussagen nicht äquivalent sind.

△

Beweise durch Kontraposition nutzen die logische Äquivalenz von $A \Rightarrow B$ und $(\neg B) \Rightarrow (\neg A)$. Man nimmt also $\neg B$ an und leitet daraus $\neg A$ her. Die Kontraposition wird dabei direkt bewiesen. Der Fall A wahr, B falsch ist damit ausgeschlossen: Aus falschem B müsste auch falsches A folgen.

Beispiel 1.9 (Beweis durch Kontraposition von $x = 2 \Rightarrow x^2 = 4$)**.** Für die Aussagen

$$A : x = 2 \qquad \text{und} \qquad B : x^2 = 4 \tag{1.27}$$

lauten die Negationen

$$\neg A : x \neq 2 \qquad \text{und} \qquad \neg B : x^2 \neq 4. \tag{1.28}$$

Wir wollen daher die Kontraposition

$$x^2 \neq 4 \Rightarrow x \neq 2 \tag{1.29}$$

zeigen. Dazu nehmen wir $x^2 \neq 4$ an. Durch Subtraktion von 4 folgt

$$x^2 - 4 \neq 0. \tag{1.30}$$

Nach der dritten binomischen Formel gilt außerdem

$$x^2 - 4 = x^2 - 2^2 = (x-2)(x+2). \tag{1.31}$$

Damit erhalten wir

$$(x-2)(x+2) \neq 0. \tag{1.32}$$

Da das Produkt ungleich null ist, muss insbesondere $x-2 \neq 0$ gelten: Wäre dieser Faktor null, wäre auch das Produkt null. Damit folgt $x \neq 2$. Somit ist die Kontraposition und damit die ursprüngliche Implikation

$$x = 2 \Rightarrow x^2 = 4 \tag{1.33}$$

bewiesen.

△

Beweise durch Widerspruch nutzen die Tatsache, dass die Implikation $A \Rightarrow B$ gemäß Tabelle 1.4 nur in einem einzigen Fall falsch ist, nämlich wenn A wahr und B falsch ist. Dieser Fall wird durch die Aussage $A \wedge (\neg B)$ beschrieben. In einem Widerspruchsbeweis nimmt man deshalb $A \wedge (\neg B)$ an und zeigt, dass diese Annahme zu einem Widerspruch führt, etwa zu einer Aussage der Form $C \wedge (\neg C)$. Damit ist der einzige Fall ausgeschlossen, in dem die Implikation falsch wäre. Folglich ist die Implikation wahr.

Beispiel 1.10 (Beweis durch Widerspruch von $x = 2 \Rightarrow x^2 = 4$)**.** Betrachtet man unter diesen Gesichtspunkten die Implikation $A \Rightarrow B$ für

$$A : x = 2 \qquad \text{und} \qquad B : x^2 = 4, \tag{1.34}$$

so entspricht $A \wedge (\neg B)$ der Aussage

$$x = 2 \qquad \text{und} \qquad x^2 \neq 4. \tag{1.35}$$

Gleichzeitig gilt: Wenn x den Wert 2 annimmt, dann nimmt x^2 den Wert 4 an. Unter der Annahme $A \wedge (\neg B)$ gilt also

$$x^2 = 4 \qquad \text{und} \qquad x^2 \neq 4. \tag{1.36}$$

Dies ist ein Widerspruch. Daher ist

$$x = 2 \Rightarrow x^2 = 4 \tag{1.37}$$

bewiesen.

△

Abschließend demonstrieren wir die drei Beweistechniken an demselben Theorem.

Theorem 1.2 (Quadrate positiver Zahlen)**.** *Es seien a und b zwei positive reelle Zahlen. Dann gilt*

$$a^2 < b^2 \Rightarrow a < b. \tag{1.38}$$

∘

Beweis. Es seien

$$A : a^2 < b^2 \qquad \text{und} \qquad B : a < b. \tag{1.39}$$

Wir geben drei alternative Beweise der Implikation $A \Rightarrow B$.

Direkter Beweis

Wegen $a, b > 0$ gilt $b + a > 0$. Daher erhalten wir

$$\begin{aligned} a^2 < b^2 &\Leftrightarrow 0 < b^2 - a^2 \\ &\Leftrightarrow 0 < (b + a)(b - a) \\ &\Leftrightarrow 0 < b - a \\ &\Leftrightarrow a < b. \end{aligned} \tag{1.40}$$

Beim dritten Schritt wird durch die positive Zahl $b + a$ dividiert. Damit ist $A \Rightarrow B$ bewiesen. Da die gesamte Kette aus Äquivalenzen besteht, ist hier sogar $A \Leftrightarrow B$ gezeigt.

Beweis durch Kontraposition

Die Negationen der Aussagen lauten

$$\neg A : a^2 \geq b^2 \qquad \text{und} \qquad \neg B : a \geq b. \tag{1.41}$$

Wir nehmen $\neg B$, also $a \geq b$, an. Da $a, b > 0$, folgt durch Multiplikation mit a beziehungsweise b

$$a^2 \geq ab \qquad \text{und} \qquad ab \geq b^2. \tag{1.42}$$

Damit gilt

$$a^2 \geq ab \geq b^2, \tag{1.43}$$

also $\neg A$. Somit ist die Kontraposition $(\neg B) \Rightarrow (\neg A)$ und damit die ursprüngliche Implikation $A \Rightarrow B$ bewiesen.

Beweis durch Widerspruch

Wir nehmen $A \wedge (\neg B)$, also

$$a^2 < b^2 \qquad \text{und} \qquad a \geq b, \tag{1.44}$$

an. Wegen $a, b > 0$ folgt aus $a \geq b$ durch Multiplikation mit a beziehungsweise b

$$a^2 \geq ab \geq b^2. \tag{1.45}$$

Somit gilt $a^2 \geq b^2$. Dies widerspricht der ebenfalls angenommenen Aussage $a^2 < b^2$. Die Annahme $A \wedge (\neg B)$ ist damit ausgeschlossen, und die Implikation $A \Rightarrow B$ ist bewiesen. □

Selbstkontrollfragen

1. Erläutern Sie die Besonderheiten der mathematischen Sprache.
2. Was sind wesentliche Tätigkeiten zum Erlernen einer Sprache?
3. Erläutern Sie den Begriff der Definition.
4. Erläutern Sie den Begriff des Theorems.
5. Erläutern Sie den Begriff des Beweises.
6. Geben Sie die Definition einer mathematischen Aussage wieder.
7. Geben Sie die Definition der Negation einer mathematischen Aussage wieder.
8. Geben Sie die Definition der Konjunktion zweier mathematischer Aussagen wieder.
9. Geben Sie die Definition der Disjunktion zweier mathematischer Aussagen wieder.
10. Geben Sie die Definition der Implikation wieder.
11. Geben Sie die Definition der Äquivalenz wieder.
12. Geben Sie die Definition der logischen Äquivalenz wieder.
13. Erläutern Sie den Begriff des direkten Beweises.
14. Erläutern Sie den Begriff des indirekten Beweises.
15. Erläutern Sie den Begriff des Beweises durch Widerspruch.

Lösungen

1. Die mathematische Sprache ist präzise, abstrakt und hierarchisch aufgebaut. Sie besitzt eine hohe Informationsdichte und zielt auf möglichst allgemeine Aussagen. Siehe Kapitel 1.1.
2. Wesentliche Tätigkeiten sind das Eintauchen in den Sprachraum, das Auswendiglernen von Begriffen, das Übersetzen in die Alltagssprache und die schriftliche sowie mündliche Anwendung. Siehe Kapitel 1.1.
3. Eine Definition legt die Bedeutung eines Begriffs oder Symbols fest. Siehe Kapitel 1.2.
4. Ein Theorem ist eine mathematische Aussage, deren Wahrheit durch einen Beweis auf Grundlage von Definitionen, Voraussetzungen und bereits bekannten Resultaten gezeigt wird. Siehe Kapitel 1.2.
5. Ein Beweis ist eine logische Argumentationskette, die die Wahrheit einer Aussage aus ihren Voraussetzungen und bekannten Resultaten herleitet. Siehe Kapitel 1.2.
6. Siehe Definition 1.1.
7. Siehe Definition 1.2.
8. Siehe Definition 1.3.
9. Siehe Definition 1.4.
10. Siehe Definition 1.5.
11. Siehe Definition 1.6.
12. Siehe Definition 1.7.
13. Ein direkter Beweis leitet die Konklusion B aus der Voraussetzung A durch gültige Schlussfolgerungen her. Dabei können insbesondere Äquivalenzumformungen verwendet werden. Siehe Kapitel 1.5.
14. Ein indirekter Beweis leitet die Negation der Voraussetzung $\neg A$ aus der Negation der Konklusion $\neg B$ durch gültige Schlussfolgerungen her. Dabei nutzt man die logische Äquivalenz von $A \Rightarrow B$ und $(\neg B) \Rightarrow (\neg A)$. Siehe Kapitel 1.5.
15. Ein Beweis durch Widerspruch nimmt die Voraussetzung A und die Negation der Konklusion $\neg B$ an und leitet daraus eine falsche Aussage her. Damit wird der einzige Fall ausgeschlossen, in dem $A \Rightarrow B$ falsch ist. Siehe Kapitel 1.5.

2. Mengen

2.1. Grundlegende Definitionen

Mengen fassen mathematische Objekte zusammen und bilden die Grundlage der modernen Mathematik. Wir beginnen mit folgender Definition.

Definition 2.1 (Mengen)**.** Nach Cantor (1895) ist eine *Menge* M definiert als "eine Zusammenfassung von bestimmten wohlunterschiedenen Objekten m unserer Anschauung oder unseres Denkens (welche die Elemente der Menge genannt werden) zu einem Ganzen". Wir schreiben

$$m \in M \text{ bzw. } m \notin M, \tag{2.1}$$

um auszudrücken, dass m ein Element bzw. kein Element von M ist.

•

Zur Definition von Mengen gibt es mindestens folgende Möglichkeiten:

- Auflisten der Elemente in geschweiften Klammern, z. B. $M := \{1, 2, 3\}$.
- Angabe der Eigenschaften der Elemente, z. B. $M := \{x \in \mathbb{N} | x < 4\}$.
- Gleichsetzen mit einer anderen eindeutig definierten Menge, z. B. $M := \mathbb{N}_3$.

Die Schreibweise $\{x \in \mathbb{N} | x < 4\}$ wird gelesen als "$x \in \mathbb{N}$, für die gilt, dass $x < 4$ ist", wobei die Bedeutung von $\mathbb{N}$ im Folgenden noch zu erläutern sein wird. Es ist wichtig zu erkennen, dass Mengen *ungeordnete* mathematische Objekte sind, das heißt, dass die Reihenfolge der Auflistung der Elemente einer Menge keine Rolle spielt. Zum Beispiel bezeichnen $\{1, 2, 3\}$, $\{1, 3, 2\}$ und $\{2, 3, 1\}$ dieselbe Menge, nämlich die Menge der ersten drei natürlichen Zahlen.

Grundlegende Beziehungen zwischen mehreren Mengen werden in der nächsten Definition festgelegt.

Definition 2.2 (Teilmengen und Mengengleichheit)**.** M und N seien zwei Mengen.

- Eine Menge M heißt *Teilmenge* einer Menge N, wenn für jedes Element $m \in M$ gilt, dass auch $m \in N$. Ist M eine Teilmenge von N, so schreibt man

  $$M \subseteq N \tag{2.2}$$

  und nennt M *Untermenge* von N und N *Obermenge* von M.
- Eine Menge M heißt *echte Teilmenge* einer Menge N, wenn für jedes Element $m \in M$ gilt, dass auch $m \in N$, es aber zumindest ein Element $n \in N$ gibt, für das gilt $n \notin M$. Ist M eine echte Teilmenge von N, so schreibt man

  $$M \subset N. \tag{2.3}$$

- Zwei Mengen M und N heißen *gleich*, wenn für jedes Element $m \in M$ gilt, dass auch $m \in N$, und wenn für jedes Element $n \in N$ gilt, dass auch $n \in M$. Sind die Mengen M und N gleich, so schreibt man

$$M = N. \tag{2.4}$$

•

Beispiel 2.1 (Teilmengen und Mengengleichheit)**.** Betrachten wir zum Beispiel die Mengen $M := \{1\}$, $N := \{1, 2\}$ und $O := \{1, 2\}$. Dann gilt mit obigen Definitionen, dass $M \subset N$, weil $1 \in M$ und $1 \in N$, aber $2 \in N$ und $2 \notin M$. Weiterhin gilt, dass $N \subseteq O$, weil $1 \in N$ und $1 \in O$ sowie $2 \in N$ und $2 \in O$ und es kein Element von O gibt, welches nicht in N ist. Ebenso gilt $O \subseteq N$, weil $1 \in O$ und $1 \in N$ sowie $2 \in O$ und $2 \in N$ und es kein Element von N gibt, welches nicht in O ist. Schließlich gilt sogar $N = O$, weil für jedes Element $n \in N$ gilt, dass auch $n \in O$, und gleichzeitig für jedes Element $o \in O$ gilt, dass auch $o \in N$. Wir stellen diese Zusammenhänge schematisch mithilfe von *Venn-Euler-Diagrammen* in Abbildung 2.1 dar.

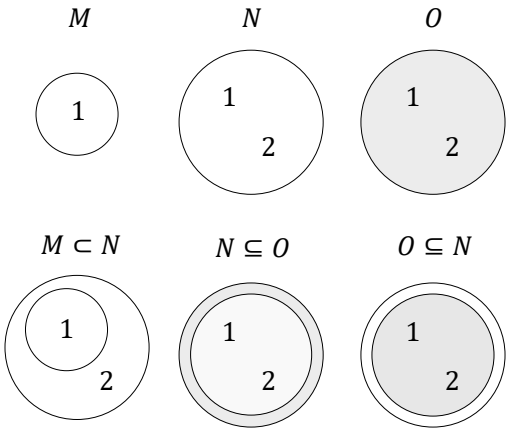


Abbildung 2.1. Venn-Euler-Diagramme der Teilmengeneigenschaften der Mengen $M := \{1\}$, $N := \{1, 2\}$ und $O := \{1, 2\}$.

△

Eine wichtige Eigenschaft einer Menge ist die Anzahl der in ihr enthaltenen Elemente. Diese wird als *Kardinalität* der Menge bezeichnet.

Definition 2.3 (Kardinalität)**.** Die Anzahl der Elemente einer Menge M heißt *Kardinalität* und wird mit $|M|$ bezeichnet.

•

Eine besondere Menge ist die Menge ohne Elemente.

Definition 2.4 (Leere Menge)**.** Eine Menge mit Kardinalität null heißt *leere Menge* und wird mit $\emptyset$ bezeichnet.

•

Als Beispiele seien $M := \{1, 2, 3\}$, $N = \{a, b, c, d\}$ und $O := \emptyset$. Dann gelten $|M| = 3$, $|N| = 4$ und $|O| = 0$.

Zu jeder Menge kann man die Menge aller Teilmengen dieser Menge betrachten. Dies führt auf den wichtigen Begriff der *Potenzmenge*.

Definition 2.5 (Potenzmenge)**.** Die Menge aller Teilmengen einer Menge M heißt *Potenzmenge von* M und wird mit $\mathcal{P}(M)$ bezeichnet.

•

Man beachte, dass die leere Untermenge von M und M selbst auch immer Elemente von $\mathcal{P}(M)$ sind. Dies erschließt sich intuitiv wie folgt: anschaulich entspricht jede Teilmenge von M einer Auswahl von Elementen aus M. Dabei kann man auch kein Element auswählen, wodurch die leere Menge entsteht, oder alle Elemente auswählen, wodurch man M selbst erhält. Die Potenzmenge selbst umfasst systematisch alle diese Auswahlmöglichkeiten.

Beispiel 2.2 (Potenzmengen)**.** Wir betrachten die Potenzmengen von Mengen mit null, einem, zwei und drei Elementen.

- $M_0 := \emptyset$ sei die leere Menge. Dann gilt
$$\mathcal{P}(M_0) = \{\emptyset\}. \tag{2.5}$$
- $M_1 := \{a\}$ sei eine einelementige Menge. Dann gilt
$$\mathcal{P}(M_1) = \{\emptyset, \{a\}\}. \tag{2.6}$$
- Es sei $M_2 := \{a, b\}$. Dann hat M_2 sowohl ein- als auch zweielementige Teilmengen und es gilt
$$\mathcal{P}(M_2) = \{\emptyset, \{a\}, \{b\}, \{a, b\}\}. \tag{2.7}$$
- Schließlich sei $M_3 := \{a, b, c\}$. Dann hat M_3 ein-, zwei- und dreielementige Teilmengen und es gilt
$$\mathcal{P}(M_3) = \{\emptyset, \{a\}, \{b\}, \{c\}, \{a, b\}, \{a, c\}, \{b, c\}, \{a, b, c\}\}. \tag{2.8}$$

△

Theorem 2.1 (Kardinalität der Potenzmenge)**.** *Gegeben sei eine Menge M mit Kardinalität $|M| = n$ und $\mathcal{P}(M)$ sei ihre Potenzmenge. Dann gilt $|\mathcal{P}(M)| = 2^n$.*

∘

Beweis. Um die Aussage des Theorems zu beweisen, assoziieren wir jedes Element P der Potenzmenge von M eindeutig mit einer binären Folge der Länge n, wobei der Eintrag an der i -ten Stelle repräsentiert, ob das i -te Element von M ein Element von P ist oder nicht. Seien beispielsweise $M := \{m_1, m_2, m_3\}$ und $P := \{m_2, m_3\}$. Dann entspricht P der binären Folge 011. Der leeren Menge $P := \emptyset$ entspricht die binäre Folge 000 und der Ausgangsmenge $P = M$ entspricht die binäre Folge 111. Es ergibt sich also die Frage, wie viele eindeutige binäre Folgen der Länge n es gibt. Da es für jedes Element der Folge zwei mögliche Zustände gibt, ergeben sich n Faktoren $2 \cdot 2 \cdots 2$, also 2^n. □

In den obigen Beispielen haben wir die Fälle

- $|M_0| = 0 \Rightarrow |\mathcal{P}(M_0)| = 2^0 = 1$,

- $|M_1| = 1 \Rightarrow |\mathcal{P}(M_1)| = 2^1 = 2$,
- $|M_2| = 2 \Rightarrow |\mathcal{P}(M_2)| = 2^2 = 4$,
- $|M_3| = 3 \Rightarrow |\mathcal{P}(M_3)| = 2^3 = 8$,

wovon man sich durch Nachzählen der Elemente der entsprechenden Potenzmengen überzeugt.

2.2. Verknüpfungen

Zwei Mengen können auf unterschiedliche Weise miteinander verknüpft werden. Das Ergebnis einer solchen Verknüpfung ist eine weitere Menge. Wir bezeichnen die Verknüpfung zweier Mengen als *Mengenoperation* und geben folgende Definitionen.

Definition 2.6 (Mengenoperationen)**.** M und N seien zwei Mengen.

- Die *Vereinigung von M und N* ist definiert als die Menge

$$M \cup N := \{x | x \in M \vee x \in N\}, \tag{2.9}$$

  wobei $\vee$ gemäß der Definition der Disjunktion als *nicht-exklusives oder*, also als und/oder, zu verstehen ist.

- Der *Durchschnitt von M und N* ist definiert als die Menge

$$M \cap N := \{x | x \in M \wedge x \in N\}. \tag{2.10}$$

  Wenn für M und N gilt, dass $M \cap N = \emptyset$, dann heißen M und N *disjunkt*.

- Die *Differenz von M und N* ist definiert als die Menge

$$M \setminus N := \{x | x \in M \wedge x \notin N\}. \tag{2.11}$$

- Die *symmetrische Differenz von M und N* ist definiert als die Menge

$$M \Delta N := \{x | (x \in M \vee x \in N) \wedge x \notin M \cap N\}. \tag{2.12}$$

  Die symmetrische Differenz kann also als *exklusives oder* verstanden werden.

•

Beispiel 2.3 (Mengenoperationen)**.** Als Beispiel betrachten wir die Mengen $M := \{1, 2, 3\}$ und $N := \{2, 3, 4, 5\}$. Dann gelten

- $M \cup N = \{1, 2, 3, 4, 5\}$, weil $1 \in M$, $2 \in M$, $3 \in M$, $4 \in N$ und $5 \in N$.
- $M \cap N = \{2, 3\}$, weil nur für 2 und 3 gilt, dass $2 \in M, 3 \in M$ und auch $2 \in N, 3 \in N$. Für 1 gilt lediglich, dass $1 \in M$ und für 4 und 5 gilt lediglich, dass $4 \in N$ und $5 \in N$.
- $M \setminus N = \{1\}$, weil $1 \in M$, aber $1 \notin N$ und $2 \in M$, aber auch $2 \in N$.
- $N \setminus M = \{4, 5\}$, weil $4 \in N$ und $5 \in N$, aber $4 \notin M$ und $5 \notin M$. Dies zeigt insbesondere, dass die Differenz von M und N *nicht* symmetrisch ist, also dass *nicht* zwangsläufig gilt, dass $M \setminus N$ gleich $N \setminus M$ ist.
- $M \Delta N = \{1, 4, 5\}$, weil $1 \in M$, aber $1 \notin \{2, 3\}$, $2 \in M$, aber $2 \in \{2, 3\}$, $3 \in M$, aber $3 \in \{2, 3\}$, $4 \in N$, aber $4 \notin \{2, 3\}$ und $5 \in N$, aber $5 \notin \{2, 3\}$.

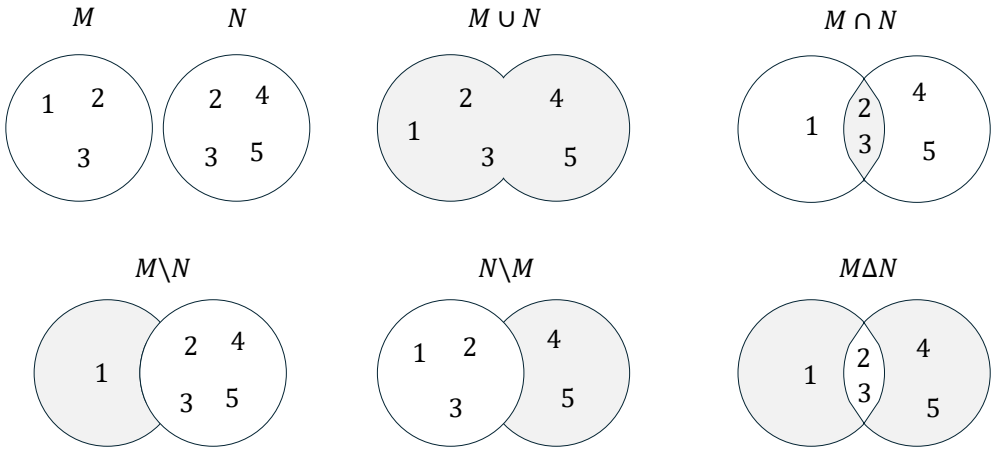


Abbildung 2.2. Venn-Euler-Diagramme der im Beispiel für $M := \{1, 2, 3\}$ und $N := \{2, 3, 4, 5\}$ betrachteten Mengenoperationen. Die grau hinterlegten Flächen entsprechen jeweils den sich ergebenden Mengen.

Abbildung 2.2 visualisiert die in diesem Beispiel betrachteten Mengenoperationen.

△

Für die Verknüpfung von drei Mengen gelten die folgenden Assoziativ- und Distributivgesetze. Die Assoziativgesetze erlauben es, bei wiederholten Vereinigungen oder Durchschnitten die Klammerung frei zu wählen. Die Distributivgesetze beschreiben das Zusammenspiel von Vereinigung und Durchschnitt.

Theorem 2.2 (Assoziativ- und Distributivgesetze für Vereinigung und Durchschnitt)**.** *Es seien M, N, O Mengen. Dann gelten*

1. *Assoziativgesetz der Vereinigung*

$$(M \cup N) \cup O = M \cup (N \cup O). \tag{2.13}$$

2. *Assoziativgesetz des Durchschnitts*

$$(M \cap N) \cap O = M \cap (N \cap O). \tag{2.14}$$

3. *Distributivgesetz des Durchschnitts über die Vereinigung*

$$M \cap (N \cup O) = (M \cap N) \cup (M \cap O). \tag{2.15}$$

4. *Distributivgesetz der Vereinigung über den Durchschnitt*

$$M \cup (N \cap O) = (M \cup N) \cap (M \cup O). \tag{2.16}$$

∘

Beweis. 1. Sei zunächst $x \in (M \cup N) \cup O$. Dann gilt $x \in M \cup N$ oder $x \in O$. Somit gehört x zu mindestens einer der Mengen M, N, O. Also gilt $x \in M$ oder $x \in N \cup O$ und damit

$$(M \cup N) \cup O \subseteq M \cup (N \cup O). \tag{2.17}$$

Sei umgekehrt $x \in M \cup (N \cup O)$. Dann gilt $x \in M$ oder $x \in N \cup O$. Wieder gehört x zu mindestens einer der Mengen M, N, O. Also gilt $x \in M \cup N$ oder $x \in O$ und damit

$$M \cup (N \cup O) \subseteq (M \cup N) \cup O. \tag{2.18}$$

Zusammengenommen folgt

$$(M \cup N) \cup O = M \cup (N \cup O). \tag{2.19}$$

2. Sei zunächst $x \in (M \cap N) \cap O$. Dann gilt $x \in M \cap N$ und $x \in O$. Somit gelten $x \in M$, $x \in N$ und $x \in O$. Also gilt $x \in M$ und $x \in N \cap O$ und damit

$$(M \cap N) \cap O \subseteq M \cap (N \cap O). \tag{2.20}$$

Sei umgekehrt $x \in M \cap (N \cap O)$. Dann gilt $x \in M$ und $x \in N \cap O$. Somit gelten wiederum $x \in M$, $x \in N$ und $x \in O$. Also gilt $x \in M \cap N$ und $x \in O$ und damit

$$M \cap (N \cap O) \subseteq (M \cap N) \cap O. \tag{2.21}$$

Zusammengenommen folgt

$$(M \cap N) \cap O = M \cap (N \cap O). \tag{2.22}$$

3. Sei zunächst $x \in M \cap (N \cup O)$. Dann gilt $x \in M$ und außerdem $x \in N$ oder $x \in O$. Im ersten Fall gilt $x \in M \cap N$, im zweiten Fall $x \in M \cap O$. Damit gilt

$$M \cap (N \cup O) \subseteq (M \cap N) \cup (M \cap O). \tag{2.23}$$

Sei umgekehrt $x \in (M \cap N) \cup (M \cap O)$. Dann gilt $x \in M \cap N$ oder $x \in M \cap O$. In beiden Fällen gehört x zu M und zu mindestens einer der Mengen N, O. Also gilt $x \in M \cap (N \cup O)$ und damit

$$(M \cap N) \cup (M \cap O) \subseteq M \cap (N \cup O). \tag{2.24}$$

Zusammengenommen folgt

$$M \cap (N \cup O) = (M \cap N) \cup (M \cap O). \tag{2.25}$$

4. Sei zunächst $x \in M \cup (N \cap O)$. Falls $x \in M$, gehört x sowohl zu $M \cup N$ als auch zu $M \cup O$. Falls $x \notin M$, muss $x \in N \cap O$ gelten. Dann gehört x ebenfalls sowohl zu $M \cup N$ als auch zu $M \cup O$. Damit gilt

$$M \cup (N \cap O) \subseteq (M \cup N) \cap (M \cup O). \tag{2.26}$$

Sei umgekehrt $x \in (M \cup N) \cap (M \cup O)$. Falls $x \in M$, gilt unmittelbar $x \in M \cup (N \cap O)$. Falls $x \notin M$, folgt aus $x \in M \cup N$, dass $x \in N$, und aus $x \in M \cup O$, dass $x \in O$. Dann gilt $x \in N \cap O$ und somit ebenfalls $x \in M \cup (N \cap O)$. Damit gilt auch

$$(M \cup N) \cap (M \cup O) \subseteq M \cup (N \cap O). \tag{2.27}$$

Zusammengenommen folgt

$$M \cup (N \cap O) = (M \cup N) \cap (M \cup O). \tag{2.28}$$

□

Definition 2.7 (Komplement)**.** M und O seien Mengen mit $M \subseteq O$. Dann heißt die Menge

$$M^c := O \setminus M = \{x | x \in O \wedge x \notin M\} \tag{2.29}$$

das *Komplement von M bezüglich O.*

•

Im Kontext von Definition 2.7 heißt O auch *Grundmenge* oder *Universum*. Das Komplement M^c enthält dabei alle Elemente dieser Grundmenge, die nicht zu M gehören. Allgemein nennt man die in Definition 2.6 definierte Differenz $A \setminus B$ zweier beliebiger Mengen auch das *relative Komplement von B bezüglich A*. Dafür muss B aber explizit keine Teilmenge von A sein. Ist hingegen eine Grundmenge O festgelegt und $M \subseteq O$, so greift Definition 2.7. Zur Unterscheidung wird $M^c = O \setminus M$ auch als *absolutes Komplement von M* bezeichnet und bildet einen Spezialfall des relativen Komplements. Man beachte, dass die Bezeichnung *absolut* hier nicht bedeutet, dass das Komplement unabhängig von der Grundmenge wäre. Vielmehr wird die festgelegte Grundmenge in der Schreibweise M^c nur nicht ausdrücklich genannt.

Die folgende Abbildung veranschaulicht das Komplement von (M) bezüglich (O).

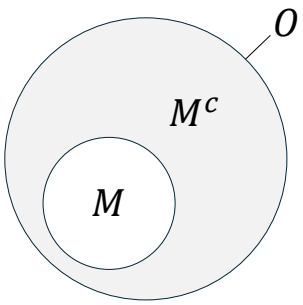


Abbildung 2.3. Venn-Euler-Diagramm des Komplements von M bezüglich O. Die grau hinterlegte Fläche entspricht $M^c = O \setminus M$.

Theorem 2.3 (Eigenschaften von Komplementen)**.** *M und O seien Mengen mit $M \subseteq O$ und M^c sei das Komplement von M bezüglich O. Dann gelten*

1. $M^c \cup M = O$,
2. $M^c \cap M = \emptyset$,
3. $(M^c)^c = M$.

Dabei werden beide Komplemente in Aussage 3. bezüglich derselben Grundmenge O gebildet.

∘

Beweis. 1. Wir zeigen die Gleichheit der Mengen durch den Nachweis beider Teilmengenbeziehungen. Sei zunächst $x \in M^c \cup M$. Nach Definition der Vereinigung gilt dann $x \in M^c$ oder $x \in M$. Im ersten Fall folgt aus der Definition des Komplements, dass $x \in O$. Im zweiten Fall folgt wegen $M \subseteq O$ ebenfalls $x \in O$. Also gilt

$$M^c \cup M \subseteq O. \tag{2.30}$$

Sei umgekehrt $o \in O$. Dann gilt entweder $o \in M$ oder $o \notin M$. Im ersten Fall ist $o \in M^c \cup M$. Im zweiten Fall gilt nach Definition des Komplements $o \in M^c$, also ebenfalls $o \in M^c \cup M$. Damit gilt auch

$$O \subseteq M^c \cup M. \tag{2.31}$$

Zusammengenommen folgt $M^c \cup M = O$.

2. Angenommen, es gäbe ein Element $x \in M^c \cap M$. Nach Definition des Durchschnitts müssten dann gleichzeitig $x \in M^c$ und $x \in M$ gelten. Aus $x \in M^c$ folgt aber nach Definition des Komplements $x \notin M$. Dies ist ein Widerspruch. Der Durchschnitt $M^c \cap M$ enthält also kein Element, sodass

$$M^c \cap M = \emptyset. \tag{2.32}$$

3. Sei zunächst $x \in (M^c)^c$. Nach Definition des Komplements gilt dann $x \in O$ und $x \notin M^c$. Wäre $x \notin M$, so würde wegen $x \in O$ auch $x \in M^c$ gelten. Dies widerspricht $x \notin M^c$. Also gilt $x \in M$ und damit

$$(M^c)^c \subseteq M. \tag{2.33}$$

Sei umgekehrt $m \in M$. Wegen $M \subseteq O$ gilt dann $m \in O$. Außerdem gilt $m \notin M^c$, weil das Komplement von M nur Elemente enthält, die nicht zu M gehören. Nach Definition des Komplements folgt somit $m \in (M^c)^c$. Also gilt auch

$$M \subseteq (M^c)^c. \tag{2.34}$$

Zusammengenommen folgt $(M^c)^c = M$. □

Die folgenden Aussagen beschreiben, wie Mengen in disjunkte Teilmengen zerlegt werden können. Abbildung 2.4 veranschaulicht die drei Zerlegungen.

Theorem 2.4 (Disjunkte Zerlegungen von Mengen)**.** *M, N und O seien Mengen mit $M \subseteq O$ und $N \subseteq O$. Die Komplemente von M und N seien bezüglich O gebildet. Dann gelten*

1. *Falls $M \subseteq N$, so gilt*

$$N = M \cup (N \cap M^c) \text{ und } M \cap (N \cap M^c) = \emptyset. \tag{2.35}$$

2. *Es gilt*

$$M = (M \cap N) \cup (M \cap N^c) \text{ und } (M \cap N) \cap (M \cap N^c) = \emptyset. \tag{2.36}$$

3. *Es gilt*

$$M \cup N = (M \cap N^c) \cup N \text{ und } (M \cap N^c) \cap N = \emptyset. \tag{2.37}$$

∘

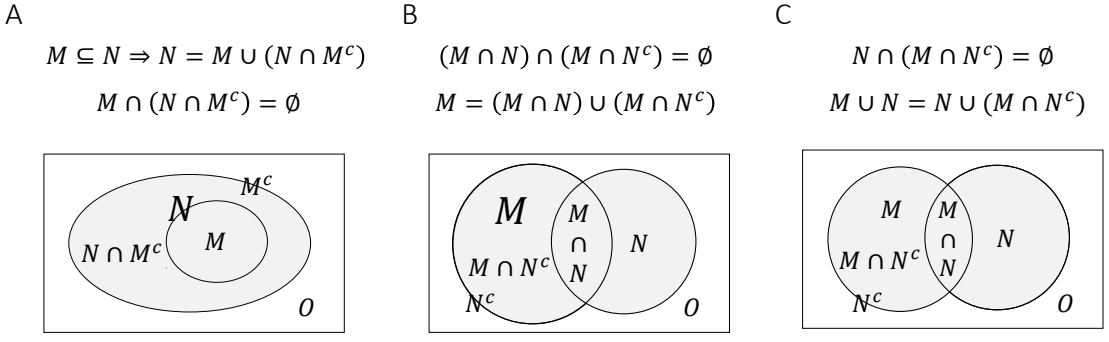


Abbildung 2.4. Venn-Euler-Diagramme zu Theorem 2.4. A. Zerlegung der Obermenge N bei $M \subseteq N$. B. Zerlegung von M anhand von N. C. Zerlegung der Vereinigung $M \cup N$. Die Rechtecke stellen jeweils die Grundmenge O dar.

Beweis. 1. Es gelte $M \subseteq N$. Wir zeigen zunächst die Mengengleichheit. Sei dazu $n \in N$. Dann gibt es zwei Möglichkeiten. Gilt $n \in M$, so gilt auch $n \in M \cup (N \cap M^c)$. Gilt dagegen $n \notin M$, so folgt wegen $n \in N \subseteq O$, dass $n \in M^c$. Zusammen mit $n \in N$ ergibt sich $n \in N \cap M^c$, also ebenfalls $n \in M \cup (N \cap M^c)$. Damit gilt

$$N \subseteq M \cup (N \cap M^c). \tag{2.38}$$

Sei umgekehrt $x \in M \cup (N \cap M^c)$. Dann gilt $x \in M$ oder $x \in N \cap M^c$. Im ersten Fall folgt aus $M \subseteq N$, dass $x \in N$. Im zweiten Fall folgt $x \in N$ direkt aus der Definition des Durchschnitts. Also gilt auch

$$M \cup (N \cap M^c) \subseteq N. \tag{2.39}$$

Zusammengenommen folgt die behauptete Mengengleichheit.

Zum Nachweis der Disjunktheit nehmen wir an, dass es ein Element $x \in M \cap (N \cap M^c)$ gäbe. Dann würden insbesondere $x \in M$ und $x \in M^c$ gelten. Nach Definition des Komplements ist dies unmöglich. Also gilt

$$M \cap (N \cap M^c) = \emptyset. \tag{2.40}$$

2. Sei zunächst $m \in M$. Gilt $m \in N$, so gilt $m \in M \cap N$. Gilt dagegen $m \notin N$, so folgt wegen $m \in M \subseteq O$, dass $m \in N^c$ und damit $m \in M \cap N^c$. In beiden Fällen gilt also $m \in (M \cap N) \cup (M \cap N^c)$. Damit ist

$$M \subseteq (M \cap N) \cup (M \cap N^c) \tag{2.41}$$

gezeigt. Sei umgekehrt $x \in (M \cap N) \cup (M \cap N^c)$. Dann gehört x zu mindestens einer der Mengen $M \cap N$ und $M \cap N^c$. In beiden Fällen folgt aus der Definition des Durchschnitts, dass $x \in M$. Also gilt auch

$$(M \cap N) \cup (M \cap N^c) \subseteq M. \tag{2.42}$$

Zusammengenommen folgt die behauptete Mengengleichheit.

Gäbe es ein Element $x \in (M \cap N) \cap (M \cap N^c)$, so würden insbesondere $x \in N$ und $x \in N^c$ gelten. Dies ist nach Definition des Komplements unmöglich. Also gilt

$$(M \cap N) \cap (M \cap N^c) = \emptyset. \tag{2.43}$$

3. Sei zunächst $x \in M \cup N$. Gilt $x \in N$, so gilt unmittelbar $x \in (M \cap N^c) \cup N$. Gilt dagegen $x \notin N$, so muss wegen $x \in M \cup N$ gelten, dass $x \in M$. Wegen $M \subseteq O$ folgt außerdem $x \in O$ und damit $x \in N^c$. Also gilt $x \in M \cap N^c$ und somit ebenfalls $x \in (M \cap N^c) \cup N$. Damit gilt

$$M \cup N \subseteq (M \cap N^c) \cup N. \tag{2.44}$$

Sei umgekehrt $x \in (M \cap N^c) \cup N$. Dann gilt $x \in M \cap N^c$ oder $x \in N$. Im ersten Fall folgt $x \in M$ und damit $x \in M \cup N$. Im zweiten Fall gilt ebenfalls $x \in M \cup N$. Also gilt auch

$$(M \cap N^c) \cup N \subseteq M \cup N. \tag{2.45}$$

Zusammengenommen folgt die behauptete Mengengleichheit.

Gäbe es ein Element $x \in (M \cap N^c) \cap N$, so würden gleichzeitig $x \in N^c$ und $x \in N$ gelten. Dies ist nach Definition des Komplements unmöglich. Also gilt

$$(M \cap N^c) \cap N = \emptyset. \tag{2.46}$$

□

Theorem 2.5 (De Morgansche Regeln)**.** *M, N und O seien Mengen mit $M \subseteq O$ und $N \subseteq O$. Alle Komplemente seien bezüglich O gebildet. Dann gelten*

1. $(M \cap N)^c = M^c \cup N^c$,
2. $(M \cup N)^c = M^c \cap N^c$.

∘

Beweis. 1. Wir zeigen die Gleichheit der Mengen durch den Nachweis beider Teilmengenbeziehungen. Sei zunächst $x \in (M \cap N)^c$. Nach Definition des Komplements gilt dann $x \in O$ und $x \notin M \cap N$. Es können also nicht gleichzeitig $x \in M$ und $x \in N$ gelten. Damit gilt $x \notin M$ oder $x \notin N$. Wegen $x \in O$ folgt daraus $x \in M^c$ oder $x \in N^c$, also $x \in M^c \cup N^c$. Damit gilt

$$(M \cap N)^c \subseteq M^c \cup N^c. \tag{2.47}$$

Sei umgekehrt $x \in M^c \cup N^c$. Dann gilt $x \in M^c$ oder $x \in N^c$. In beiden Fällen folgt $x \in O$. Im ersten Fall gilt $x \notin M$, im zweiten Fall $x \notin N$. In beiden Fällen kann x daher nicht zum Durchschnitt $M \cap N$ gehören. Also gilt $x \in (M \cap N)^c$ und damit

$$M^c \cup N^c \subseteq (M \cap N)^c. \tag{2.48}$$

Zusammengenommen folgt $(M \cap N)^c = M^c \cup N^c$.

2. Sei zunächst $x \in (M \cup N)^c$. Nach Definition des Komplements gilt dann $x \in O$ und $x \notin M \cup N$. Also gehört x weder zu M noch zu N. Wegen $x \in O$ folgen daraus $x \in M^c$ und $x \in N^c$, also $x \in M^c \cap N^c$. Damit gilt

$$(M \cup N)^c \subseteq M^c \cap N^c. \tag{2.49}$$

Sei umgekehrt $x \in M^c \cap N^c$. Dann gelten $x \in M^c$ und $x \in N^c$. Nach Definition des Komplements folgen daraus $x \in O$, $x \notin M$ und $x \notin N$. Also gilt $x \notin M \cup N$ und damit $x \in (M \cup N)^c$. Somit gilt auch

$$M^c \cap N^c \subseteq (M \cup N)^c. \tag{2.50}$$

Zusammengenommen folgt $(M \cup N)^c = M^c \cap N^c$. □

Für die Verknüpfung mehrerer Mengen verwenden wir eine abkürzende Schreibweise.

Definition 2.8 (Mehrfache Mengenverknüpfungen)**.** Es seien $n \in \mathbb{N}$ und $M_1, \ldots, M_n$ Mengen. Es bezeichnen

- die *Vereinigung mehrerer Mengen*

$$\bigcup_{i=1}^{n} M_i := M_1 \cup M_2 \cup \cdots \cup M_n, \tag{2.51}$$

- der *Durchschnitt mehrerer Mengen*

$$\bigcap_{i=1}^{n} M_i := M_1 \cap M_2 \cap \cdots \cap M_n. \tag{2.52}$$

Dabei stehen

- die Symbole $\bigcup$ und $\bigcap$ für die jeweilige Mengenoperation,
- das Subskript $i = 1$ für den *Laufindex* und den *Startindex*,
- das Superskript n für den *Endindex* und
- $M_1, \ldots, M_n$ für die verknüpften Mengen.

Die Vereinigung enthält alle Elemente, die zu mindestens einer der Mengen M_i gehören. Der Durchschnitt enthält alle Elemente, die zu jeder der Mengen M_i gehören.

•

Die Indizes müssen eindeutig festgelegt sein. Die Bezeichnung des Laufindexes ist dagegen für das Ergebnis der Mengenoperation irrelevant. Beispielsweise gilt

$$\bigcup_{i=1}^{n} M_i = \bigcup_{j=1}^{n} M_j. \tag{2.53}$$

Manchmal wird der Laufindex als Element einer *Indexmenge* angegeben. Ist beispielsweise $I := \{1, 5, 7\}$, so gilt

$$\bigcup_{i \in I} M_i := M_1 \cup M_5 \cup M_7. \tag{2.54}$$

Die entsprechende Schreibweise verwenden wir auch für den Durchschnitt mehrerer Mengen.

Die Schreibweise lässt sich auch auf abzählbar unendlich viele Mengen $A_1, A_2, ...$ übertragen. Ihre Vereinigung $\bigcup_{i=1}^{\infty} A_i$ enthält genau die Elemente, die zu mindestens einer der Mengen A_i gehören. Entsprechend enthält der Durchschnitt $\bigcap_{i=1}^{\infty} M_i$ genau die Elemente, die zu jeder der Mengen M_i gehören.

Theorem 2.6 (Abzählbare Distributivität)**.** *Es seien $A_1, A_2, ...$ und B Mengen. Dann gilt*

$$\left(\bigcup_{i=1}^{\infty} A_i \right) \cap B = \bigcup_{i=1}^{\infty} (A_i \cap B). \tag{2.55}$$

∘

Beweis. Sei zunächst

$$x \in \left(\bigcup_{i=1}^{\infty} A_i \right) \cap B. \tag{2.56}$$

Dann gilt $x \in B$ und es gibt ein $i \in \mathbb{N}$ mit $x \in A_i$. Für dieses i gilt somit $x \in A_i \cap B$. Also ist

$$x \in \bigcup_{i=1}^{\infty} (A_i \cap B). \tag{2.57}$$

Damit gilt

$$\left(\bigcup_{i=1}^{\infty} A_i \right) \cap B \subseteq \bigcup_{i=1}^{\infty} (A_i \cap B). \tag{2.58}$$

Sei umgekehrt

$$x \in \bigcup_{i=1}^{\infty} (A_i \cap B). \tag{2.59}$$

Dann gibt es ein $i \in \mathbb{N}$ mit $x \in A_i \cap B$. Für dieses i gelten $x \in A_i$ und $x \in B$. Also gehört x zur Vereinigung der A_i und zugleich zu B. Damit gilt

$$\bigcup_{i=1}^{\infty} (A_i \cap B) \subseteq \left(\bigcup_{i=1}^{\infty} A_i \right) \cap B. \tag{2.60}$$

Zusammengenommen folgt

$$\left(\bigcup_{i=1}^{\infty} A_i \right) \cap B = \bigcup_{i=1}^{\infty} (A_i \cap B). \tag{2.61}$$

□

Theorem 2.7 (Durchschnitte disjunkter Mengen)**.** *Es seien M, N, O Mengen mit $M \cap N = \emptyset$. Dann gilt*

$$(M \cap O) \cap (N \cap O) = \emptyset. \tag{2.62}$$

∘

Beweis. Gäbe es ein Element

$$x \in (M \cap O) \cap (N \cap O), \tag{2.63}$$

so würden insbesondere $x \in M$ und $x \in N$ gelten. Dann wäre $x \in M \cap N$, im Widerspruch zur vorausgesetzten Disjunktheit. Also gilt

$$(M \cap O) \cap (N \cap O) = \emptyset. \tag{2.64}$$

□

Theorem 2.8 (Abzählbare de Morgansche Regeln)**.** *Es seien $M_1, M_2, ... \subseteq O$. Alle Komplemente seien bezüglich der Grundmenge O gebildet. Dann gelten*

1. *Es gilt*

$$\left(\bigcap_{i=1}^{\infty} M_i \right)^c = \bigcup_{i=1}^{\infty} M_i^c. \tag{2.65}$$

2. *Es gilt*

$$\left(\bigcup_{i=1}^{\infty} M_i \right)^c = \bigcap_{i=1}^{\infty} M_i^c. \tag{2.66}$$

∘

Beweis. 1. Sei zunächst

$$x \in \left(\bigcap_{i=1}^{\infty} M_i \right)^c. \tag{2.67}$$

Dann gehört x zu O, aber nicht zu jeder der Mengen M_i. Es gibt also ein $i \in \mathbb{N}$ mit $x \notin M_i$. Für dieses i gilt $x \in M_i^c$. Damit gilt

$$\left(\bigcap_{i=1}^{\infty} M_i \right)^c \subseteq \bigcup_{i=1}^{\infty} M_i^c. \tag{2.68}$$

Sei umgekehrt

$$x \in \bigcup_{i=1}^{\infty} M_i^c. \tag{2.69}$$

Dann gibt es ein $i \in \mathbb{N}$ mit $x \in M_i^c$. Somit gilt $x \in O$ und $x \notin M_i$. Also gehört x nicht zum Durchschnitt aller M_i, wohl aber zu dessen Komplement bezüglich O. Damit gilt auch

$$\bigcup_{i=1}^{\infty} M_i^c \subseteq \left(\bigcap_{i=1}^{\infty} M_i \right)^c. \tag{2.70}$$

Zusammengenommen folgt

$$\left(\bigcap_{i=1}^{\infty} M_i \right)^c = \bigcup_{i=1}^{\infty} M_i^c. \tag{2.71}$$

2. Sei zunächst

$$x \in \left(\bigcup_{i=1}^{\infty} M_i \right)^c. \tag{2.72}$$

Dann gehört x zu O, aber zu keiner der Mengen M_i. Für jedes $i \in \mathbb{N}$ gilt daher $x \in M_i^c$. Damit gilt

$$\left(\bigcup_{i=1}^{\infty} M_i \right)^c \subseteq \bigcap_{i=1}^{\infty} M_i^c. \tag{2.73}$$

Sei umgekehrt

$$x \in \bigcap_{i=1}^{\infty} M_i^c. \tag{2.74}$$

Dann gilt für jedes $i \in \mathbb{N}$, dass $x \in M_i^c$. Somit gehört x zu O und zu keiner der Mengen M_i. Also gehört x zum Komplement ihrer Vereinigung. Damit gilt auch

$$\bigcap_{i=1}^{\infty} M_i^c \subseteq \left(\bigcup_{i=1}^{\infty} M_i \right)^c. \tag{2.75}$$

Zusammengenommen folgt

$$\left(\bigcup_{i=1}^{\infty} M_i \right)^c = \bigcap_{i=1}^{\infty} M_i^c. \tag{2.76}$$

□

Schließlich wollen wir noch den Begriff der Partition einer Menge einführen.

Definition 2.9 (Partition)**.** M sei eine Menge und $P := \{N_i\}$ sei eine Menge von Mengen N_i mit $i = 1, ..., n$, sodass gilt

$$(M = \cup_{i=1}^{n} N_i) \wedge \left(N_i \cap N_j = \emptyset \text{ für } i, j = 1, ..., n \text{ und } i \neq j \right). \tag{2.77}$$

Dann heißt P eine *Partition von* M.

•

Die Partition einer Menge entspricht also dem Aufteilen der Menge in disjunkte Teilmengen. Partitionen sind generell nicht eindeutig, das heißt, es gibt meist verschiedene Möglichkeiten, eine gegebene Menge zu partitionieren.

Als Beispiel betrachten wir die Menge $M := \{1, 2, 3, 4, 5, 6\}$. Dann sind $P_1 := \{\{1\}, \{2, 3, 4, 5, 6\}\}$, $P_2 := \{\{1, 2, 3\}, \{4, 5, 6\}\}$ und $P_3 := \{\{1, 2\}, \{3, 4\}, \{5, 6\}\}$ drei mögliche Partitionen von M. Abbildung 2.5 visualisiert die in diesem Beispiel betrachteten Partitionen.

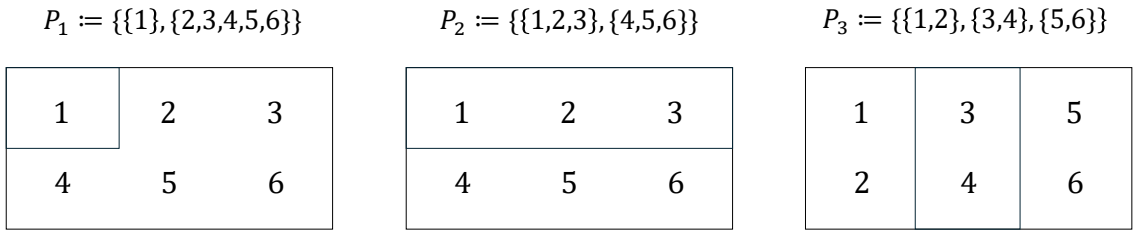


Abbildung 2.5. Diagramme der im Beispiel für $M := \{1, 2, 3, 4, 5, 6\}$ betrachteten Partitionen.

2.3. Spezielle Mengen

Zahlenmengen

In der Naturwissenschaft versucht man, in der Vorstellung intuitiv als diskret oder kontinuierlich identifizierte Phänomene der Welt mit Zahlen zu beschreiben. Je nach Art des Phänomens bieten sich dazu verschiedene Zahlenmengen an. Die Mathematik stellt unter anderem die in folgender Definition gegebenen Zahlenmengen bereit.

Definition 2.10 (Zahlenmengen)**.** Es bezeichnen

- $\mathbb{N} := \{1, 2, 3, ...\}$ die *natürlichen Zahlen*,
- $\mathbb{N}_n := \{1, 2, 3, ..., n\}$ die *natürlichen Zahlen der Ordnung* n,
- $\mathbb{N}^0 := \mathbb{N} \cup \{0\}$ die *natürlichen Zahlen* und null,
- $\mathbb{Z} := \{..., -3, -2, -1, 0, 1, 2, 3, ...\}$ die *ganzen Zahlen*,
- $\mathbb{Q} := \{\frac{p}{q} | p \in \mathbb{Z}, q \in \mathbb{N}\}$ die *rationalen Zahlen*,
- $\mathbb{R}$ die *reellen Zahlen* und
- $\mathbb{C} := \{a + ib | a, b \in \mathbb{R}, i := \sqrt{-1}\}$ die *komplexen Zahlen.*

•

Die natürlichen und die ganzen Zahlen eignen sich zum Quantifizieren diskreter Phänomene. Die rationalen und insbesondere die reellen Zahlen eignen sich zum Quantifizieren kontinuierlicher Phänomene. Die schrittweise Erweiterung dieser Zahlenmengen lässt sich intuitiv durch Gleichungen motivieren, die in der jeweils kleineren Zahlenmenge nicht immer lösbar sind. So besitzt die Gleichung $5 + x = 3$ keine Lösung in $\mathbb{N}^0$, aber mit $x = -2$ eine Lösung in $\mathbb{Z}$. Insbesondere die negativen ganzen Zahlen ermöglichen also die uneingeschränkte Subtraktion natürlicher Zahlen. Die Gleichung $2x = 5$ besitzt wiederum keine Lösung in $\mathbb{Z}$, aber mit $x = \frac{5}{2}$ eine Lösung in $\mathbb{Q}$. Die Gleichung $x^2 = 1 + 1$ führt auf die positive Lösung $x = \sqrt{2}$. Geometrisch entspricht $\sqrt{2}$ der Länge der Hypotenuse eines rechtwinkligen Dreiecks, dessen Katheten jeweils die Länge 1 haben, wie Abbildung 2.6 veranschaulicht. Obwohl sich dieses Dreieck zeichnen und seine Hypotenuse messen lässt, reicht die Menge der rationalen Zahlen zur Beschreibung ihrer exakten Länge nicht aus. Hierfür werden die reellen Zahlen benötigt, wie wir unten zeigen. Schließlich besitzt die Gleichung $x^2 = -1$ keine Lösung in $\mathbb{R}$, denn das Quadrat einer reellen Zahl ist stets nichtnegativ. In $\mathbb{C}$ ist sie dagegen durch $x = i$ und $x = -i$ lösbar, wobei für die imaginäre Einheit i gilt, dass $i^2 = -1$.

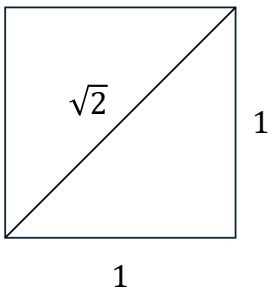


Abbildung 2.6. Geometrische Konstruktion einer Strecke der Länge $\sqrt{2}$. Die Diagonale des Quadrats ist die Hypotenuse eines rechtwinkligen Dreiecks. Nach dem Satz des Pythagoras gilt für die Kathetenlängen a, b und die Hypotenusenlänge c, dass $a^2 + b^2 = c^2$. Für $a = b = 1$ ergibt sich also $c = \sqrt{2}$. Diese Länge lässt sich geometrisch leicht konstruieren, aber nach Theorem 2.9 durch keine rationale Zahl exakt beschreiben.

Die reellen Zahlen umfassen die rationalen Zahlen und die sogenannten *irrationalen Zahlen* $\mathbb{R} \setminus \mathbb{Q}$. Rationale Zahlen sind Zahlen, die sich durch Brüche ganzer und natürlicher Zahlen ausdrücken lassen. Hierzu gehören alle ganzen Zahlen sowie alle positiven und negativen

Dezimalzahlen mit endlicher oder periodischer Dezimaldarstellung, beispielsweise $-\frac{9}{10} = -0.9$, $\frac{1}{3} = 0.\bar{3}$ und $\frac{196}{100} = 1.96$. Zwischen zwei beliebigen verschiedenen rationalen Zahlen liegen unendlich viele weitere rationale Zahlen. Insbesondere liegt zwischen $a, b \in \mathbb{Q}$ mit $a < b$ stets die rationale Zahl $\frac{a+b}{2}$, und dieses Argument kann zwischen den entstehenden Zahlen beliebig oft wiederholt werden. Auch zwischen zwei verschiedenen reellen Zahlen liegen unendlich viele weitere reelle Zahlen. Irrationale Zahlen sind dagegen Zahlen, die sich nicht als rationale Zahlen ausdrücken lassen. Beispiele hierfür sind die *Eulersche Zahl* $e \approx 2.71$, die *Kreiszahl* $\pi \approx 3.14$ und die Quadratwurzel von 2, $\sqrt{2} \approx 1.41$.

Die reellen Zahlen enthalten als Teilmengen die natürlichen, ganzen und rationalen Zahlen. Insbesondere gilt $\mathbb{N} \subset \mathbb{Z} \subset \mathbb{Q} \subset \mathbb{R}$. Es gibt also sehr viele reelle Zahlen. Tatsächlich hat Cantor (1874) bewiesen, dass es mehr reelle Zahlen als natürliche Zahlen gibt, obwohl es sowohl unendlich viele reelle Zahlen als auch unendlich viele natürliche Zahlen gibt. Diese Eigenschaft der reellen Zahlen bezeichnet man als die *Überabzählbarkeit* der reellen Zahlen. Wir vertiefen diesen Begriff in Kapitel 4. Positiv-Unendlich ∞ und Negativ-Unendlich $-\infty$ sind dagegen keine Zahlen, mit denen in der Standardmathematik gerechnet werden könnte. Sie gehören auch nicht zu den in obiger Definition gegebenen Zahlenmengen, es gelten also $\infty \notin \mathbb{R}$ und $-\infty \notin \mathbb{R}$. Komplexe Zahlen schließlich eignen sich zur Beschreibung zweidimensionaler kontinuierlicher Phänomene. Dabei werden die Werte der ersten Dimension im Realteil a und die Werte der zweiten Dimension im Imaginärteil b einer komplexen Zahl repräsentiert. Komplexe Zahlen kommen beispielsweise bei der Modellierung physikalischer Phänomene und im Bereich der Fourieranalyse zum Einsatz.

Die Standardmenge zur Beschreibung kontinuierlicher Phänomene sind sicherlich die reellen Zahlen, auch wenn im täglichen Leben und insbesondere in der numerischen Mathematik de-facto reelle Zahlen in der Regel durch rationalen Zahlen approximiert werden. Wir werden auf das Wesen der reellen Zahlen an verschiedenen Stellen zurückkommen. An dieser Stelle wollen wir zunächst nur zeigen, dass in der Tat die Menge der rationalen Zahlen nicht ausreicht, um die Gleichung $x^2 = 2$ nach x aufzulösen, denn die Quadratwurzel von 2 ist keine rationale Zahl.

Theorem 2.9 (Irrationalität von $\sqrt{2}$)**.** *Die Quadratwurzel von* 2 *ist keine rationale Zahl,*

$$\sqrt{2} \notin \mathbb{Q} \tag{2.78}$$

∘

Beweis. Mit der Notation für Beweise durch Widerspruch aus Kapitel 1.5 wollen wir zeigen, dass für die Aussagen (A) $x = \sqrt{2}$ und (B) $x \notin \mathbb{Q}$ die Implikation $A \Rightarrow B$ gilt. Wir zeigen dies nach Abbott (2015, Kapitel 1) durch einen Beweis durch Widerspruch. Dazu zeigen wir, dass die Annahme $(\neg B) \wedge A$ zu einer falschen Aussage führt.

Die Aussage $\neg B$ lautet im vorliegenden Fall $x \in \mathbb{Q}$. Es gibt also $p, q \in \mathbb{Z}$ mit $q \neq 0$, sodass

$$x = \frac{p}{q} \tag{2.79}$$

gilt. Ohne Einschränkung wählen wir diese Darstellung vollständig gekürzt, sodass p und q teilerfremd sind. Andernfalls könnten Zähler und Nenner durch einen gemeinsamen ganzzahligen Teiler größer als 1 gekürzt werden, beispielsweise 12/9 durch den gemeinsamen Teiler 3 zu 4/3.

Unter der Annahme $(\neg B) \wedge A$ gelten zugleich $x = p/q$ und $x^2 = 2$. Daher gilt

$$\left(\frac{p}{q}\right)^2 = 2. \tag{2.80}$$

Umformung von Gleichung (2.80) ergibt

$$\left(\frac{p}{q}\right)^2 = 2 \Leftrightarrow \frac{p^2}{q^2} = 2 \Leftrightarrow p^2 = 2q^2. \tag{2.81}$$

Daraus folgt, dass p^2 durch 2 teilbar und somit gerade ist. Daher muss auch p gerade sein, da eine ganze Zahl mit geradem Quadrat immer gerade ist, wie in Beispiel 1.5 in Kapitel 1 gezeigt. Wir können p also mit einem $r \in \mathbb{Z}$ als $p = 2r$ schreiben. Einsetzen in die letzte Gleichheit in (2.81) ergibt

$$p^2 = 2q^2 \Leftrightarrow (2r)^2 = 2q^2 \Leftrightarrow 4r^2 = 2q^2 \Leftrightarrow 2r^2 = q^2. \tag{2.82}$$

Die letzte Gleichheit zeigt, dass q^2 gerade ist. Folglich ist auch q gerade. Damit sind sowohl p als auch q durch 2 teilbar. Dies widerspricht der Annahme, dass p und q teilerfremd sind.

Damit führt die Annahme $(\neg B) \wedge A$ zu einem Widerspruch. Sie ist also falsch. Folglich gilt

$$x = \sqrt{2} \Rightarrow x \notin \mathbb{Q}. \tag{2.83}$$

Damit ist gezeigt, dass $\sqrt{2}$ keine rationale Zahl ist. □

Wichtige Teilmengen der reellen Zahlen sind die sogenannten *Intervalle*. Wir geben folgende Definitionen.

Intervalle

Definition 2.11 (Intervalle)**.** Zusammenhängende Teilmengen der reellen Zahlen heißen *Intervalle*. Für $a, b \in \mathbb{R}$ unterscheidet man

- das *abgeschlossene Intervall*

$$[a, b] := \{x \in \mathbb{R} | a \leq x \leq b\}, \tag{2.84}$$

- das *offene Intervall*

$$]a, b[:= \{x \in \mathbb{R} | a < x < b\}, \tag{2.85}$$

- und die *halboffenen Intervalle*

$$]a, b] := \{x \in \mathbb{R} | a < x \leq b\} \text{ und } [a, b[:= \{x \in \mathbb{R} | a \leq x < b\}. \tag{2.86}$$

•

Exemplarisch stellen wir in Abbildung 2.7 die Intervalle $[1, 2]$, $]1, 2]$, $[1, 2[$ und $]1, 2[$ grafisch dar. Dabei stellt man sich die reellen Zahlen als kontinuierlichen Zahlenstrahl vor und muss jeweils beachten, ob die linken bzw. rechten Endpunkte Teil des Intervalls sind oder nicht. Wie oben erwähnt sind Positiv-Unendlich (∞) und Negativ-Unendlich $-\infty$ keine Elemente von $\mathbb{R}$. Es gilt also immer $]-\infty, b]$ oder $]-\infty, b[$ bzw. $]a, \infty[$ oder $[a, \infty[$, sowie $\mathbb{R} =]-\infty, \infty[$.

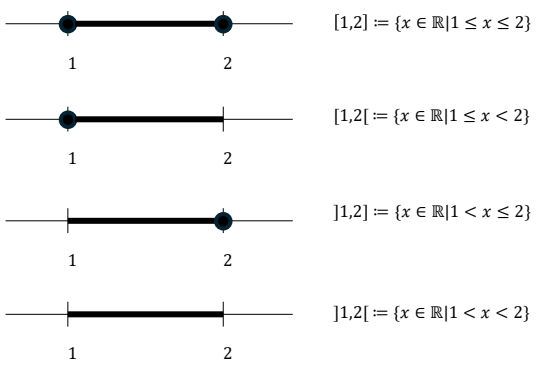


Abbildung 2.7. Darstellung von Intervallen am Zahlenstrahl. Der schwarze Punkt signalisiert dabei, dass die entsprechende Zahl Teil des Intervalls ist.

Kartesische Produkte

Oft möchte man mehrere unabhängige Eigenschaften eines Phänomens gleichzeitig quantitativ beschreiben. Zu diesem Zweck können die oben definierten eindimensionalen Zahlenmengen durch Bildung *kartesischer Produkte* auf mehrdimensionale Zahlenmengen erweitert werden. Die Elemente kartesischer Produkte nennt man *geordnete Tupel* oder *Vektoren*.

Definition 2.12 (Kartesische Produkte)**.** M und N seien zwei Mengen. Dann ist das *Kartesische Produkt der Mengen M und N* die Menge aller geordneten Tupel (m, n) mit $m \in M$ und $n \in N$, formal

$$M \times N := \{(m, n) | m \in M, n \in N\}. \tag{2.87}$$

Das Kartesische Produkt einer Menge M mit sich selbst wird bezeichnet mit

$$M^2 := M \times M. \tag{2.88}$$

Seien weiterhin $M_1, \ldots, M_n$ Mengen. Dann ist das *Kartesische Produkt der Mengen $M_1, \ldots, M_n$* die Menge aller geordneten n-Tupel $(m_1, \ldots, m_n)$ mit $m_i \in M_i$ für $i = 1, \ldots, n$, formal

$$\times_{i=1}^{n} M_i := M_1 \times \cdots \times M_n := \{(m_1, \ldots, m_n) | m_i \in M_i \text{ für } i = 1, \ldots, n\}. \tag{2.89}$$

Das *n-fache Kartesische Produkt* einer Menge M mit sich selbst wird bezeichnet mit

$$M^n := \times_{i=1}^{n} M := \{(m_1, \ldots, m_n) | m_i \in M \text{ für } i = 1, \ldots, n\}. \tag{2.90}$$

•

Im Gegensatz zu Mengen sind die in Definition 2.12 eingeführten Tupel *geordnet*. Das heißt, für Mengen gilt beispielsweise $\{1, 2\} = \{2, 1\}$, aber für Tupel gilt $(1, 2) \neq (2, 1)$.

Beispiel 2.4 (Kartesische Produkte)**.** Es seien $M := \{1, 2\}$ und $N := \{1, 2, 3\}$. Dann ist das Kartesische Produkt $M \times N$ gegeben durch

$$M \times N := \{(1, 1), (1, 2), (1, 3), (2, 1), (2, 2), (2, 3)\} \tag{2.91}$$

und das Kartesische Produkt $N \times M$ ist gegeben durch

$$N \times M := \{(1, 1), (1, 2), (2, 1), (2, 2), (3, 1), (3, 2)\} \tag{2.92}$$

Das Kartesische Produkt ist also im Allgemeinen nicht kommutativ, es gilt also nicht notwendigerweise, dass $M \times N = N \times M$. Man mag sich die in diesem Beispiel konstruierten Mengen $M \times N \neq N \times M$ mithilfe von Tabelle 2.1 und Tabelle 2.2 konstruieren.

Tabelle 2.1. Kartesisches Produkt $M \times N$

(m, n)	$n = 1$	$n = 2$	$n = 3$
$m = 1$	$(1, 1)$	$(1, 2)$	$(1, 3)$
$m = 2$	$(2, 1)$	$(2, 2)$	$(2, 3)$

Tabelle 2.2. Kartesisches Produkt $N \times M$

(n, m)	$m = 1$	$m = 2$
$n = 1$	$(1, 1)$	$(1, 2)$
$n = 2$	$(2, 1)$	$(2, 2)$
$n = 3$	$(3, 1)$	$(3, 2)$

△

$\mathbb{R}$ **hoch** n

Wie oben beschrieben, eignen sich insbesondere die reellen Zahlen zur Beschreibung kontinuierlicher Phänomene. Zur simultanen Beschreibung mehrerer Aspekte eines kontinuierlichen Phänomens bietet sich entsprechend die *Menge der reellen Tupel n- ter Ordnung*, kurz $\mathbb{R}$ hoch n, an.

Definition 2.13 (Menge der reellen Tupel n-ter Ordnung)**.** Das n- fache Kartesische Produkt der reellen Zahlen mit sich selbst wird bezeichnet mit

$$\mathbb{R}^n := \times_{i=1}^{n} \mathbb{R} := \{x := (x_1, \dots, x_n) | x_i \in \mathbb{R} \text{ für } i = 1, \dots, n\}. \tag{2.93}$$

und wird "$\mathbb{R}$ hoch n" gesprochen. Wir schreiben die Elemente von $\mathbb{R}^n$ als Spalten

$$x := \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \tag{2.94}$$

und nennen sie *n- dimensionale Vektoren*. Zur Abgrenzung nennen wir die Elemente von $\mathbb{R}^1 = \mathbb{R}$ auch *Skalare*.

•

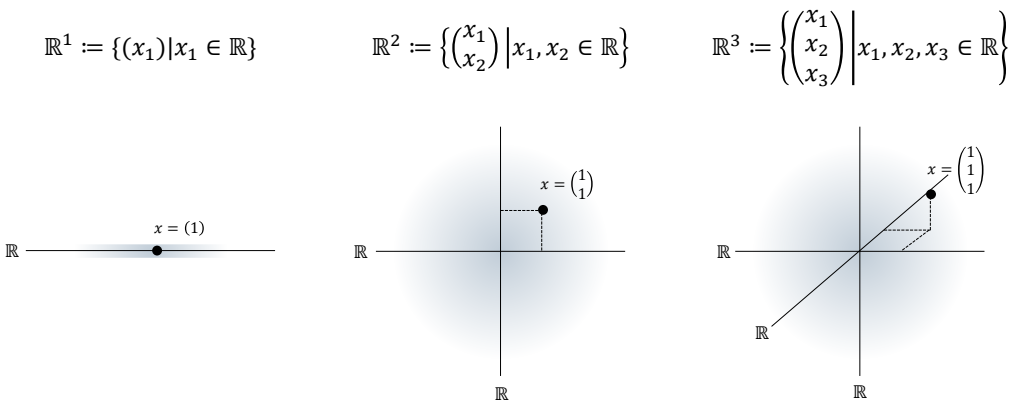


Abbildung 2.8. $\mathbb{R}^n$ für $n = 1, n = 2$ und $n = 3$. Die schwarzen Punkte stellen jeweils ein Element der entsprechenden Menge dar.

Beispiel 2.5 (Reelle Vektoren)**.** Vertraute Beispiele von $\mathbb{R}^n$ sind $\mathbb{R}^1$ als Menge der reellen Zahlen, $\mathbb{R}^2$ als Menge der reellen Tupel im Modell der zweidimensionalen Ebene und $\mathbb{R}^3$ als Menge der reellen Tripel im Modell des dreidimensionalen Raumes. Abbildung 2.8 veranschaulicht diese drei Fälle.

Ein Beispiel für einen Vektor $x \in \mathbb{R}^4$ ist

$$x = \begin{pmatrix} 0.16 \\ 1.76 \\ 0.23 \\ 7.11 \end{pmatrix}. \tag{2.95}$$

△

Selbstkontrollfragen

1. Geben Sie die Definition einer Menge nach Cantor (1895) wieder.
2. Nennen Sie drei Möglichkeiten zur Definition einer Menge.
3. Erläutern Sie die Ausdrücke $m \in M$ und $m \notin M$.
4. Erläutern Sie die Ausdrücke $M \subseteq N, M \subset N$ für zwei Mengen M und N.
5. Geben Sie die Definition der Kardinalität einer Menge wieder.
6. Geben Sie die Definition der Potenzmenge einer Menge wieder.
7. Es sei $M \coloneqq \{1, 2\}$. Bestimmen Sie $\mathcal{P}(M)$.
8. Es seien $M \coloneqq \{1, 2\}, N \coloneqq \{1, 4, 5\}$. Bestimmen Sie $M \cup N, M \cap N, M \setminus N, M \Delta N$.
9. Erläutern Sie die Symbole $\mathbb{N}$, $\mathbb{N}_n$ und $\mathbb{N}^0$.
10. Erläutern Sie die Unterschiede zwischen $\mathbb{N}$ und $\mathbb{Z}$ und zwischen $\mathbb{R}$ und $\mathbb{Q}$.
11. Geben Sie die Definition abgeschlossener, offener und halboffener Intervalle wieder.
12. Es seien M und N Mengen. Erläutern Sie die Notation $M \times N$.
13. Geben Sie die Definition von $\mathbb{R}^n$ wieder.

Lösungen

1. Siehe Definition 2.1.
2. Siehe Definition 2.1.

3. Siehe Definition 2.1.
4. Siehe Definition 2.2.
5. Siehe Definition 2.3.
6. Siehe Definition 2.5.
7. Es gilt $\mathcal{P}(M) = \{\emptyset, \{1\}, \{2\}, \{1, 2\}\}$
8. Es gelten $M \cup N = \{1, 2, 4, 5\}$, $M \cap N = \{1\}$, $M \setminus N = \{2\}$, $M \Delta N = \{2, 4, 5\}$
9. $\mathbb{N}$ bezeichnet die natürlichen Zahlen, also $1, 2, \ldots$. $\mathbb{N}_n$ bezeichnet die natürlichen Zahlen bis und inklusive n, also $1, 2, \ldots, n$. $\mathbb{N}^0$ bezeichnet die natürlichen Zahlen und null, also $0, 1, 2, \ldots$.
10. $\mathbb{Z}$ enthält die negativen natürlichen Zahlen und die Null, $\mathbb{N}$ nicht. $\mathbb{R}$ enthält neben den rationalen Zahlen $\mathbb{Q}$ auch diejenigen Zahlen, die sich nicht als rationale Zahl darstellen lassen, wie zum Beispiel die Kreiszahl π.
11. Siehe Definition 2.11.
12. Siehe Definition 2.12.
13. Siehe Definition 2.13.

3. Summen, Produkte, Potenzen

Diese Einheit führt Schreibweisen für die Grundrechenarten ein.

3.1. Summen

Definition 3.1 (Summenzeichen)**.** Es bezeichnet

$$\sum_{i=1}^{n} x_i = x_1 + x_2 + \cdots + x_n. \tag{3.1}$$

Dabei stehen

- Σ für das griechische *S*igma, mnemonisch für *S*umme,
- das Subskript $i = 1$ für den *Laufindex der Summanden* und den *Startindex*,
- das Superskript n für den *Endindex* und
- $x_1, x_2, ..., x_n$ für die *Summanden*.

•

Die Indizes der Summation müssen eindeutig festgelegt sein. Dies kann durch einen Start- und Endindex oder durch eine Indexmenge erfolgen. Die genaue Bezeichnung des Laufindexes ist dagegen für den Wert der Summe irrelevant, es gilt

$$\sum_{i=1}^{n} x_i = \sum_{j=1}^{n} x_j. \tag{3.2}$$

Manchmal wird der Laufindex auch als Element einer *Indexmenge* angegeben. Ist z. B. die Indexmenge $I := \{1, 5, 7\}$ definiert, so ist

$$\sum_{i \in I} x_i := x_1 + x_5 + x_7. \tag{3.3}$$

Im Folgenden wollen wir kurz einige Beispiele für die Benutzung des Summenzeichens betrachten.

- *Summation vordefinierter Summanden.* Es seien $x_1 := 2$, $x_2 := 10$, $x_3 := -4$. Dann gilt

$$\sum_{i=1}^{3} x_i = x_1 + x_2 + x_3 = 2 + 10 - 4 = 8. \tag{3.4}$$

- *Summation gewichteter vordefinierter Summanden.* Es seien wiederum $x_1 := 2$, $x_2 := 10$, $x_3 := -4$. Weiterhin seien die *Wichtungskoeffizienten* $a_1 := \frac{1}{2}$, $a_2 := \frac{1}{5}$, $a_3 := 2$ definiert. Dann gilt

$$\sum_{i=1}^{3} a_i x_i = a_1 x_1 + a_2 x_2 + a_3 x_3 = \frac{1}{2} \cdot 2 + \frac{1}{5} \cdot 10 + 2 \cdot (-4) = 1 + 2 - 8 = -5. \quad (3.5)$$

  Ausdrücke der Form $\sum_{i=1}^{n} a_i x_i$ werden auch als *Linearkombinationen* der $x_1, ..., x_n$ mit den *Koeffizienten* oder *Wichtungsparametern* $a_1, ..., a_n$ bezeichnet.
- *Summation natürlicher Zahlen.* Es gilt

$$\sum_{i=1}^{5} i = 1 + 2 + 3 + 4 + 5 = 15. \quad (3.6)$$

- *Summation gerader natürlicher Zahlen.* Es gilt

$$\sum_{i=1}^{5} 2i = 2 \cdot 1 + 2 \cdot 2 + 2 \cdot 3 + 2 \cdot 4 + 2 \cdot 5 = 2 + 4 + 6 + 8 + 10 = 30. \quad (3.7)$$

- *Summation ungerader natürlicher Zahlen.* Es gilt

$$\sum_{i=1}^{5} (2i-1) = 2 \cdot 1 - 1 + 2 \cdot 2 - 1 + 2 \cdot 3 - 1 + 2 \cdot 4 - 1 + 2 \cdot 5 - 1 = 1 + 3 + 5 + 7 + 9 = 25. \quad (3.8)$$

Der Umgang mit dem Summenzeichen kann oft durch die Anwendung folgender Rechenregeln vereinfacht werden.

Theorem 3.1 (Rechenregeln für Summen)**.**

(1) Summen gleicher Summanden

$$\sum_{i=1}^{n} x = nx \quad (3.9)$$

(2) Addition von Summen gleicher Länge

$$\sum_{i=1}^{n} x_i + \sum_{i=1}^{n} y_i = \sum_{i=1}^{n} (x_i + y_i) \quad (3.10)$$

(3) Distributivität bei Multiplikation mit einer Konstanten

$$\sum_{i=1}^{n} a x_i = a \sum_{i=1}^{n} x_i \quad (3.11)$$

(4) Aufspalten von Summen mit $1 < m < n$

$$\sum_{i=1}^{n} x_i = \sum_{i=1}^{m} x_i + \sum_{i=m+1}^{n} x_i \quad (3.12)$$

(5) Umindizierung

$$\sum_{i=0}^{n} x_i = \sum_{j=m}^{n+m} x_{j-m} \quad (3.13)$$

∘

Beweis. Man überzeugt sich von diesen Rechenregeln durch Ausschreiben der Summen und Anwenden der Rechenregeln von Addition und Multiplikation. Wir zeigen hier exemplarisch die Addition von Summen gleicher Länge und die Distributivität bei Multiplikation mit einer Konstanten. Hinsichtlich ersterer haben wir

$$\begin{aligned}\sum_{i=1}^{n} x_i + \sum_{i=1}^{n} y_i &= x_1 + x_2 + \cdots + x_n + y_1 + y_2 + \cdots + y_n \\ &= x_1 + y_1 + x_2 + y_2 + \cdots + x_n + y_n \\ &= \sum_{i=1}^{n} (x_i + y_i).\end{aligned} \tag{3.14}$$

Hinsichtlich letzterer gilt

$$\begin{aligned}\sum_{i=1}^{n} a x_i &= a x_1 + a x_2 + \cdots + a x_n \\ &= a(x_1 + x_2 + \cdots + x_n) \\ &= a \sum_{i=1}^{n} x_i.\end{aligned} \tag{3.15}$$

□

Beispiel 3.1 (Mittelwert)**.** Es seien $x_1, \ldots, x_n \in \mathbb{R}$ und $n \geq 1$. Der Mittelwert dieser Zahlen ist ihre Summe geteilt durch ihre Anzahl. Die Distributivität bei Multiplikation mit einer Konstanten liefert

$$\frac{1}{n} \sum_{i=1}^{n} x_i = \sum_{i=1}^{n} \frac{x_i}{n}. \tag{3.16}$$

Wir können also zunächst summieren und anschließend durch n teilen oder zunächst jeden Summanden durch n teilen und anschließend summieren.

Für $x_1 := 1$, $x_2 := 4$, $x_3 := 2$ und $x_4 := 1$ gilt

$$\frac{1}{4} \sum_{i=1}^{4} x_i = \frac{1 + 4 + 2 + 1}{4} = 2, \tag{3.17}$$

$$\sum_{i=1}^{4} \frac{x_i}{4} = \frac{1}{4} + \frac{4}{4} + \frac{2}{4} + \frac{1}{4} = 2. \tag{3.18}$$

△

Beispiel 3.2 (Umindizierung)**.** Es seien $n := 3$, $m := 2$ sowie $x_0 := 2$, $x_1 := 3$, $x_2 := 5$ und $x_3 := 10$. Dann gilt

$$\sum_{i=0}^{3} x_i = x_0 + x_1 + x_2 + x_3 = 2 + 3 + 5 + 10 = 20. \tag{3.19}$$

Mit dem neuen Laufindex $j := i + 2$ erhalten wir dieselben Summanden:

$$\sum_{j=2}^{5} x_{j-2} = x_{2-2} + x_{3-2} + x_{4-2} + x_{5-2} \tag{3.20}$$

$$= x_0 + x_1 + x_2 + x_3 \tag{3.21}$$

$$= 2 + 3 + 5 + 10 \tag{3.22}$$

$$= 20. \tag{3.23}$$

Die Umindizierung verändert die Bezeichnung des Laufindexes und die Summationsgrenzen, lässt die Summanden und den Wert der Summe aber unverändert.

△

Doppelsummen

Nicht selten trifft man in der Anwendung auf Ausdrücke, die mehrere Summationen hintereinander ausführen. Dabei gelten für jede der Summen die oben gelisteten Definitionen und Rechenregeln. Man macht sich die Bedeutung von Doppelsummen am besten dadurch klar, dass man sie von innen nach außen ausschreibt und dabei beachtet, dass für jede Iteration der inneren Summe der Laufindex der äußeren Summe konstant bleibt.

Beispiel 3.3 (Auswertung von Doppelsummen)**.** Wir werten die innere Summe jeweils bei festem Laufindex der äußeren Summe aus und summieren anschließend die Ergebnisse.

(1) Summanden als Summe der Laufindizes

Es gilt

$$\sum_{i=1}^{2}\sum_{j=1}^{3}(i+j) = \sum_{i=1}^{2}((i+1)+(i+2)+(i+3)) \tag{3.24}$$
$$= ((1+1)+(1+2)+(1+3))+((2+1)+(2+2)+(2+3)) \tag{3.25}$$
$$= 9+12 \tag{3.26}$$
$$= 21. \tag{3.27}$$

(2) Summanden als Summe zweier indizierter Zahlen

Für $x_1, x_2, y_1, y_2, y_3 \in \mathbb{R}$ gilt

$$\sum_{i=1}^{2}\sum_{j=1}^{3}(x_i+y_j) = \sum_{i=1}^{2}(3x_i+y_1+y_2+y_3) \tag{3.28}$$
$$= (3x_1+y_1+y_2+y_3)+(3x_2+y_1+y_2+y_3) \tag{3.29}$$
$$= 3(x_1+x_2)+2(y_1+y_2+y_3). \tag{3.30}$$

Jede Zahl x_i tritt dreimal auf, jede Zahl y_j zweimal.

(3) Summanden als Produkt zweier indizierter Zahlen

Für $x_1, x_2, x_3, y_1, y_2 \in \mathbb{R}$ gilt

$$\sum_{i=1}^{3}\sum_{j=1}^{2}x_i y_j = \sum_{i=1}^{3}(x_i y_1 + x_i y_2) \tag{3.31}$$
$$= (x_1y_1+x_1y_2)+(x_2y_1+x_2y_2)+(x_3y_1+x_3y_2) \tag{3.32}$$
$$= (x_1+x_2+x_3)(y_1+y_2). \tag{3.33}$$

Die Doppelsumme enthält alle Produkte aus einer der drei Zahlen x_i und einer der beiden Zahlen y_j.

△

3.2. Produkte

Eine analoge Schreibweise zum Summenzeichen bietet das Produktzeichen für Produkte.

Definition 3.2 (Produktzeichen)**.** Es bezeichnet

$$\prod_{i=1}^{n} x_i = x_1 \cdot x_2 \cdot \dots \cdot x_n. \tag{3.34}$$

Dabei stehen

- $\prod$ für das griechische *P*i, mnemonisch für *P*rodukt,
- das Subskript $i = 1$ für den *Laufindex der Produktterme* und den *Startindex*,
- das Superskript n für den *Endindex* und
- $x_1, x_2, ..., x_n$ für die *Produktterme*.

•

Die Indizes der Multiplikation müssen eindeutig festgelegt sein. Dies kann durch einen Start- und Endindex oder durch eine Indexmenge erfolgen. Die genaue Bezeichnung des Laufindexes ist wiederum irrelevant, es gilt

$$\prod_{i=1}^{n} x_i = \prod_{j=1}^{n} x_j. \tag{3.35}$$

Auch hier wird in seltenen Fällen der Laufindex als Element einer Indexmenge angegeben. Ist z. B. die Indexmenge $J := \mathbb{N}_2^0$ definiert, so ist

$$\prod_{j \in J} x_j := x_0 \cdot x_1 \cdot x_2. \tag{3.36}$$

Ein Beispiel für die Benutzung des Produktzeichens ist etwa die Definition der *Fakultät* einer natürlichen Zahl n durch

$$n! := \prod_{i=1}^{n} i. \tag{3.37}$$

So ist etwa

$$4! = \prod_{i=1}^{4} i = 1 \cdot 2 \cdot 3 \cdot 4 = 24. \tag{3.38}$$

Auch für Produkte gibt es eine Reihe von Rechenregeln, die den Umgang mit ihnen oft vereinfachen. Wir listen einige im folgenden Theorem. Dabei machen wir vorgreifend Gebrauch der in Kapitel 3.3 definierten Schreibweise von *Potenzen*.

Theorem 3.2 (Rechenregeln für Produkte)**.** *Für $x, a, x_1, \dots, x_n, y_1, \dots, y_n \in \mathbb{R}$ und $n \in \mathbb{N}$ gelten folgende Rechenregeln.*

(1) Produkte gleicher Faktoren

$$\prod_{i=1}^{n} x = x^n. \tag{3.39}$$

(2) Potenzierung von Konstanten

$$\prod_{i=1}^{n} a x_i = a^n \prod_{i=1}^{n} x_i. \tag{3.40}$$

(3) Aufspalten von Produkten mit $1 < m < n$

$$\prod_{i=1}^{n} x_i = \prod_{i=1}^{m} x_i \prod_{j=m+1}^{n} x_j. \tag{3.41}$$

(4) Produkt von Produkten

$$\prod_{i=1}^{n} x_i y_i = \prod_{i=1}^{n} x_i \prod_{i=1}^{n} y_i. \tag{3.42}$$

∘

Beweis. Man überzeugt sich von diesen Rechenregeln durch Ausschreiben der Produkte und Anwenden der Rechenregeln der Multiplikation sowie der Definition von Potenzen. Wir zeigen hier exemplarisch die Potenzierung von Konstanten und das Produkt von Produkten.

Hinsichtlich ersterer gilt

$$\prod_{i=1}^{n} ax_i = (ax_1)(ax_2)\cdots(ax_n) = \underbrace{a \cdot a \cdots a}_{n \text{ Faktoren}}(x_1 x_2 \cdots x_n) = a^n \prod_{i=1}^{n} x_i. \tag{3.43}$$

Hinsichtlich letzterem gilt

$$\prod_{i=1}^{n} x_i y_i = (x_1 y_1)(x_2 y_2)\cdots(x_n y_n) = (x_1 x_2 \cdots x_n)(y_1 y_2 \cdots y_n) = \prod_{i=1}^{n} x_i \prod_{i=1}^{n} y_i. \tag{3.44}$$

Dabei erlauben das Assoziativgesetz und das Kommutativgesetz der Multiplikation jeweils das Umgruppieren und Umordnen der Faktoren. □

Doppelprodukte

Beispielhaft betrachten wir die folgenden Doppelprodukte.

Beispiel (1)

$$\begin{aligned}\prod_{i=1}^{2}\prod_{j=1}^{3}(i+j) &= \prod_{i=1}^{2}(i+1)(i+2)(i+3) \\ &= (1+1)(1+2)(1+3)\cdot(2+1)(2+2)(2+3) \\ &= 24 \cdot 60 \\ &= 1440.\end{aligned} \tag{3.45}$$

Beispiel (2)

$$\begin{aligned}\prod_{i=1}^{2}\prod_{j=1}^{3}(x_i+y_j) &= \prod_{i=1}^{2}(x_i+y_1)(x_i+y_2)(x_i+y_3) \\ &= (x_1+y_1)(x_1+y_2)(x_1+y_3)\cdot(x_2+y_1)(x_2+y_2)(x_2+y_3).\end{aligned} \tag{3.46}$$

Beispiel (3)

$$\begin{aligned}\prod_{i=1}^{3}\prod_{j=1}^{2}(x_i y_j) &= \prod_{i=1}^{3}(x_i y_1)(x_i y_2) \\ &= (x_1 y_1)(x_1 y_2)\cdot(x_2 y_1)(x_2 y_2)\cdot(x_3 y_1)(x_3 y_2).\end{aligned} \tag{3.47}$$

3.3. Potenzen

Produkte von Zahlen mit sich selbst können mithilfe der Potenzschreibweise abgekürzt werden.

Definition 3.3 (Potenz)**.** Für $a \in \mathbb{R}$ und $n \in \mathbb{N}^0$ ist die *n-te Potenz von a* definiert durch

$$a^0 := 1 \text{ und } a^{n+1} := a^n \cdot a. \tag{3.48}$$

Weiterhin ist für $a \in \mathbb{R} \setminus \{0\}$ und $n \in \mathbb{N}^0$ die *negative n-te Potenz von a* definiert durch

$$a^{-n} := (a^n)^{-1} := \frac{1}{a^n}. \tag{3.49}$$

a wird dabei *Basis* und n wird *Exponent* genannt.

•

Die Art der Definition von a^{n+1} mit Rückbezug auf die Potenz a^n in obiger Definition nennt man *rekursiv*. Die Definition $a^0 := 1$ nennt man dabei den *Rekursionsanfang*. Er macht die rekursive Definition von a^{n+1} erst möglich. Die Definition $a^{n+1} := a^n \cdot a$ nennt man auch *Rekursionsschritt*. Folgende Rechenregeln vereinfachen das Rechnen mit Potenzen.

Theorem 3.3 (Rechenregeln für Potenzen)**.** *Für $a, b \in \mathbb{R}$ und $n, m \in \mathbb{Z}$ gelten folgende Rechenregeln, sofern alle auftretenden Potenzen definiert sind. Bei negativen Exponenten müssen die jeweiligen Basen ungleich null sein. Für die Quotientenregel muss außerdem $b \neq 0$ gelten.*

$$a^n a^m = a^{n+m}, \tag{3.50}$$
$$(ab)^n = a^n b^n, \tag{3.51}$$
$$\left(\frac{a}{b}\right)^n = \frac{a^n}{b^n}, \tag{3.52}$$
$$(a^n)^m = a^{nm}. \tag{3.53}$$

∘

Beispiel 3.4 (Anwendung der Potenzregeln)**.** Die folgenden Rechnungen veranschaulichen die vier Potenzregeln durch Ausschreiben der jeweiligen Faktoren.

(1) Produkt von Potenzen mit gleicher Basis

Bei gleicher Basis werden die Exponenten addiert:

$$2^2 \cdot 2^3 = (2 \cdot 2) \cdot (2 \cdot 2 \cdot 2) = 2^{2+3} = 2^5. \tag{3.54}$$

(2) Potenz eines Produktes

Die Potenz eines Produktes ist das Produkt der Potenzen:

$$(2 \cdot 4)^2 = (2 \cdot 4) \cdot (2 \cdot 4) = (2 \cdot 2) \cdot (4 \cdot 4) = 2^2 \cdot 4^2. \tag{3.55}$$

(3) Potenz eines Quotienten

Die Potenz eines Quotienten ist der Quotient der Potenzen:

$$\left(\frac{2}{3}\right)^3 = \frac{2}{3} \cdot \frac{2}{3} \cdot \frac{2}{3} = \frac{2 \cdot 2 \cdot 2}{3 \cdot 3 \cdot 3} = \frac{2^3}{3^3}. \tag{3.56}$$

(4) Potenz einer Potenz

Beim Potenzieren einer Potenz werden die Exponenten multipliziert:

$$(3^2)^3 = (3 \cdot 3) \cdot (3 \cdot 3) \cdot (3 \cdot 3) = 3^{2 \cdot 3} = 3^6. \tag{3.57}$$

△

In enger Beziehung zur Potenz steht die Definition der n-ten Wurzel:

Definition 3.4 (n-te Wurzel)**.** Für $a \in \mathbb{R}_{\geq 0}$ und $n \in \mathbb{N}$ ist die *n-te Wurzel von a* definiert als die nichtnegative reelle Zahl r mit

$$r^n = a. \tag{3.58}$$

•

Beim Rechnen mit Wurzeln ist die Potenzschreibweise von Wurzeln oft hilfreich, da sie die direkte Anwendung der Rechenregeln für Potenzen ermöglicht.

Definition 3.5 (Potenzschreibweise der n-ten Wurzel)**.** Es sei $a \in \mathbb{R}_{\geq 0}$, $n \in \mathbb{N}$ und r die n-te Wurzel von a. Wir definieren

$$a^{\frac{1}{n}} := r. \tag{3.59}$$

•

Das Rechnen mit Quadratwurzeln wird durch die Potenzschreibweise

$$\sqrt{x} = x^{\frac{1}{2}} \tag{3.60}$$

sehr erleichtert. So gilt zum Beispiel

$$\frac{2\pi}{\sqrt{2\pi}} = \frac{2\pi}{(2\pi)^{\frac{1}{2}}} = (2\pi)^1 \cdot (2\pi)^{-\frac{1}{2}} = (2\pi)^{1-\frac{1}{2}} = (2\pi)^{\frac{1}{2}} = \sqrt{2\pi}. \tag{3.61}$$

Folgender Zusammenhang zwischen Quadrat, Wurzel und Betrag wird des Öfteren genutzt.

Theorem 3.4 (Wurzel und Betrag)**.** *Es sei $x \in \mathbb{R}$ und es bezeichne*

$$|x| := \begin{cases} x & \text{für } x \geq 0 \\ -x & \text{für } x < 0 \end{cases} \tag{3.62}$$

den Betrag von x*. Dann gilt*

$$\sqrt{x^2} = |x|. \tag{3.63}$$

◦

Beweis. Wir betrachten die Fälle $x \geq 0$ und $x < 0$. Sei zunächst $x \geq 0$. Dann gilt

$$x \geq 0 \Rightarrow x^2 \geq 0 \Rightarrow \sqrt{x^2} = x = |x|. \tag{3.64}$$

Sei nun $x < 0$. Dann gilt

$$x < 0 \Rightarrow x^2 > 0 \Rightarrow \sqrt{x^2} = -x = |x|. \tag{3.65}$$

□

Selbstkontrollfragen

1. Geben Sie die Definition des Summenzeichens wieder.
2. Berechnen Sie die Summen $\sum_{i=1}^{3} 2$, $\sum_{i=1}^{3} i^2$ und $\sum_{i=1}^{3} \frac{2}{3} i$.
3. Schreiben Sie die Summe $1 + 3 + 5 + 7 + 9 + 11$ mithilfe des Summenzeichens.
4. Schreiben Sie die Summe $0 + 2 + 4 + 6 + 8 + 10$ mithilfe des Summenzeichens.
5. Geben Sie die Definition des Produktzeichens wieder.
6. Geben Sie die Definition der n-ten Potenz von $a \in \mathbb{R}$ wieder.
7. Berechnen Sie $2^2 \cdot 2^3$ und 2^5 und geben Sie die zugehörige Potenzregel wieder.
8. Berechnen Sie 6^2 und $2^2 \cdot 3^2$ und geben Sie die zugehörige Potenzregel wieder.
9. Geben Sie die Definition der Potenzschreibweise $a^{\frac{1}{n}}$ für $a \geq 0$ und $n \in \mathbb{N}$ wieder.

Lösungen

1. Siehe Definition 3.1.
2. Es gelten
$$\begin{aligned} \sum_{i=1}^{3} 2 &= 2 + 2 + 2 = 6 \\ \sum_{i=1}^{3} i^2 &= 1 + 4 + 9 = 14 \\ \sum_{i=1}^{3} \frac{2}{3} i &= \frac{2}{3}(1 + 2 + 3) = 4. \end{aligned} \tag{3.66}$$
3. Es gilt
$$1 + 3 + 5 + 7 + 9 + 11 = \sum_{i=1}^{6} (2i - 1). \tag{3.67}$$
4. Es gilt
$$0 + 2 + 4 + 6 + 8 + 10 = \sum_{i=0}^{5} 2i. \tag{3.68}$$
5. Siehe Definition 3.2.
6. Siehe Definition 3.3.
7. Es gilt $a^n \cdot a^m = a^{n+m}$, hier also
$$2^2 \cdot 2^3 = 4 \cdot 8 = 32 = 2^5. \tag{3.69}$$
Siehe Theorem 3.3.
8. Es gilt $(ab)^n = a^n b^n$, hier also
$$6^2 = 36 = 4 \cdot 9 = 2^2 \cdot 3^2. \tag{3.70}$$
Siehe Theorem 3.3.
9. Für $a \geq 0$ und $n \in \mathbb{N}$ definieren wir $a^{\frac{1}{n}} := r$, wobei r die eindeutig bestimmte nichtnegative reelle Zahl mit $r^n = a$ ist. Siehe Definition 3.5.

4. Funktionen

Funktionen bilden neben den Mengen den zweiten Grundpfeiler der modernen Mathematik. In dieser Einheit definieren wir den Begriff der Funktion, führen erste Eigenschaften von Funktionen ein und geben eine Übersicht über einige elementare Funktionen.

4.1. Definition und Eigenschaften

Definition 4.1 (Funktion)**.** Eine *Funktion* oder *Abbildung* f ist eine Zuordnungsvorschrift, die jedem Element einer Menge D genau ein Element einer Menge Z zuordnet. D wird dabei *Definitionsmenge von* f und Z wird *Zielmenge von* f genannt. Wir schreiben

$$f : D \to Z, x \mapsto f(x), \tag{4.1}$$

wobei $f : D \to Z$ gelesen wird als "die Funktion f bildet alle Elemente der Menge D eindeutig auf Elemente in Z ab" und $x \mapsto f(x)$ gelesen wird als "x, welches ein Element von D ist, wird durch die Funktion f auf $f(x)$ abgebildet, wobei $f(x)$ ein Element von Z ist". Der Pfeil $\to$ steht für die Abbildung zwischen den Mengen D und Z, der Pfeil $\mapsto$ steht für die Abbildung zwischen einem Element von D und einem Element von Z.

•

Es ist zentral, zwischen der *Funktion* f als Zuordnungsvorschrift und einem *Wert der Funktion* $f(x)$ als Element von Z zu unterscheiden. x ist das *Argument* der Funktion (der *Input* der Funktion), $f(x)$ der Wert, den die Funktion f für das Argument x annimmt (der *Output* der Funktion). Üblicherweise folgt in der Definition einer Funktion $f(x)$ die Definition der *funktionalen Form von* f, also einer Regel, wie aus x der Wert $f(x)$ zu bilden ist. Zum Beispiel wird in folgender Definition einer Funktion

$$f : \mathbb{R} \to \mathbb{R}_{\geq 0}, x \mapsto f(x) := x^2 \tag{4.2}$$

die Definition der Potenz genutzt. Man beachte, dass Funktionen immer *eindeutig* sind, das heißt, dass sie jedem $x \in D$ bei jeder Anwendung der Funktion immer ein und dasselbe $f(x) \in Z$ zuordnen.

Abbildung 4.1 visualisiert einige Aspekte der Funktionsdefinition. Abbildung 4.1 A stellt dabei zunächst die zentralen Begriffe der Funktionsdefinition bildlich dar. Abbildung 4.1 B visualisiert ein erstes Beispiel für eine Funktion, bei der die den Argumenten zugeordneten Funktionswerte nicht durch eine Rechenregel, sondern durch direkte Definition bestimmt sind. Abbildung 4.1 C und Abbildung 4.1 D bedienen sich der Bildsprache, um zwei Aspekte der Definition von Funktionen mithilfe von Gegenbeispielen hervorzuheben: Bei der Zeichnung in Abbildung 4.1 C handelt es sich nicht um die Darstellung einer Funktion, da nach Definition 4.1 eine Funktion *jedem Element* einer Menge D genau ein Element einer Zielmenge Z zuordnet. Die hier angedeutete Zuordnungsvorschrift ordnet

dem Element $2 \in D$ aber kein Element in Z zu und ist deshalb keine Funktion. Ebenso gilt nach Definition 4.1, dass eine Funktion jedem Element einer Menge D *genau ein Element einer Zielmenge* Z zuordnet. Die in Abbildung 4.1 D angedeutete Zuordnungsvorschrift ordnet $1 \in D$ aber sowohl das Element $a \in Z$ als auch das Element $b \in Z$ zu und ist deshalb mit Definition 4.1 nicht vereinbar.

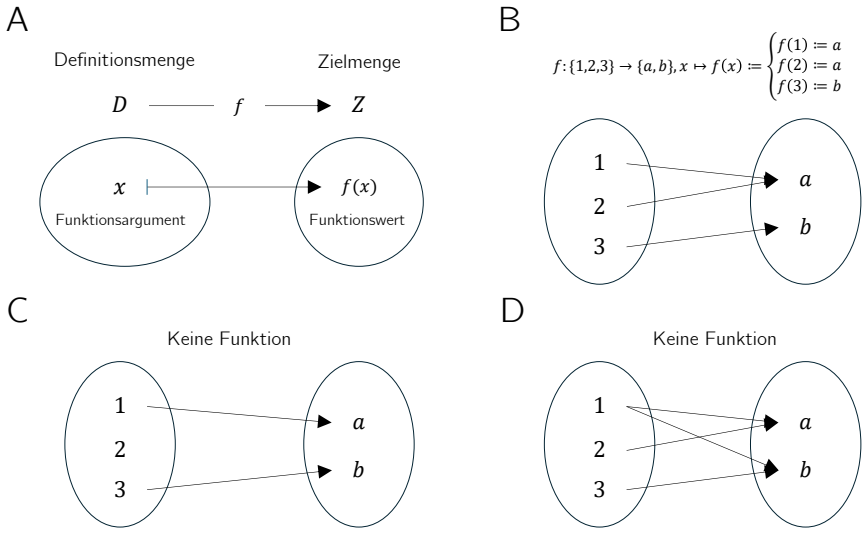


Abbildung 4.1. Aspekte der Funktionsdefinition

Funktionen setzen also Elemente von Mengen miteinander in Beziehung. Die Mengen dieser Elemente erhalten spezielle Bezeichnungen.

Definition 4.2 (Bildmenge, Wertebereich, Urbildmenge, Urbild)**.** Es sei $f : D \to Z, x \mapsto f(x)$ eine Funktion und es seien $D' \subseteq D$ und $Z' \subseteq Z$. Die Menge

$$f(D') := \{z \in Z | \text{Es gibt ein } x \in D' \text{ mit } z = f(x)\} \tag{4.3}$$

heißt die *Bildmenge von* D' und $f(D) \subseteq Z$ heißt der *Wertebereich* von f. Weiterhin heißt die Menge

$$f^{-1}(Z') := \{x \in D | f(x) \in Z'\} \tag{4.4}$$

die *Urbildmenge von* Z'. Ein $x \in D$ mit $z = f(x) \in Z$ heißt ein *Urbild von* z.

•

Man beachte, dass der Wertebereich $f(D)$ von f und die Zielmenge Z von f nicht notwendigerweise identisch sein müssen.

Beispiel 4.1 (Bildmenge, Wertebereich, Urbildmenge und Urbild)**.** Um die in Definition 4.2 eingeführten Begriffe zu verdeutlichen, betrachten wir die in Abbildung 4.2 A dargestellte Funktion

$$f : \{1,2,3,4,5\} \to \{a,b,c,d\}, x \mapsto \begin{cases} f(1) & := b \\ f(2) & := d \\ f(3) & := c \\ f(4) & := c \\ f(5) & := d \end{cases}. \tag{4.5}$$

Nach Definition 4.2 ist eine Bildmenge immer bezüglich einer Teilmenge D' der Definitionsmenge D definiert. Sei also wie in Abbildung 4.2 B dargestellt $D' := \{2, 3\} \subset D$. Dann ist die Bildmenge von D' die Menge der $z \in Z$, für die ein $x \in D'$ existiert, sodass $z = f(x)$. Diejenigen $z \in Z$, für die ein $x \in D'$ mit $z = f(x)$ existiert, sind aber hier gerade $c, d \in Z$, da $f(2) = d$ und $f(3) = c$. Darüber hinaus gibt es keine $z \in Z$ mit $f(x) = z$ und $x \in \{2, 3\}$. Der Wertebereich $f(D)$ ist nach Definition 4.2 die Teilmenge der $z \in Z$, für die gilt, dass ein $x \in D$ existiert, für das $z = f(x)$ ist. Dies ist für alle Elemente von Z der Fall, außer für $a \in Z$, da für dieses kein $x \in D$ existiert mit $a = f(x)$. Der Wertebereich von f ist für die betrachtete Funktion also durch $f(D) := \{b, c, d\}$ gegeben.

Umgekehrt ist nach Definition 4.2 eine Urbildmenge immer bezüglich einer Teilmenge Z' der Zielmenge Z definiert. Sei also wie in Abbildung 4.2 C dargestellt $Z' := \{c, d\} \subset Z$. Dann ist die Urbildmenge von Z' die Menge der $x \in D$, für die gilt, dass $f(x) \in Z'$. Diejenigen Elemente von D, deren Funktionswerte unter f durch Elemente von Z' gegeben sind, sind gerade $\{2, 3, 4, 5\}$. $1 \in D$ dagegen ist kein Element von $f^{-1}(Z')$, da $f\ 1 \in D$ auf $b \in Z$ abbildet und $b \notin Z'$. Nichtsdestotrotz ist natürlich $1 \in D$ ein Urbild von b.

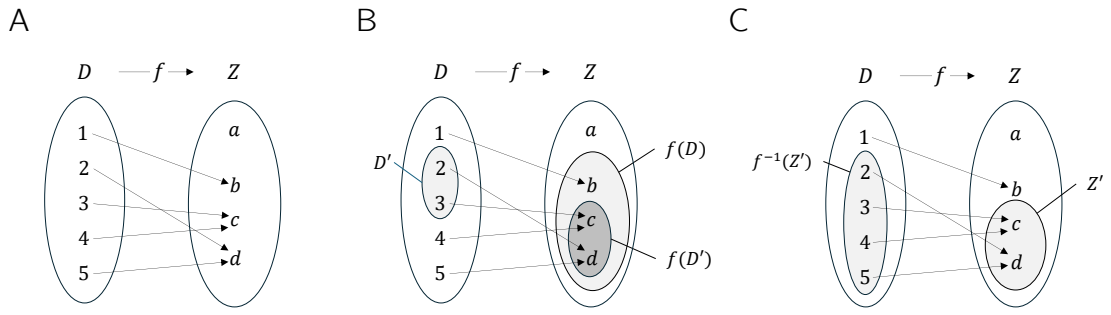


Abbildung 4.2. (A) Visualisierung der Funktion Gleichung 4.5. (B) Wertebereich und eine Bildmenge von f. (C) Urbildmenge einer Menge Z' unter f.

△

Grundlegende Eigenschaften von Funktionen werden in folgender Definition benannt.

Definition 4.3 (Injektivität, Surjektivität, Bijektivität)**.** Es sei $f : D \to Z, x \mapsto f(x)$ eine Funktion.

- Die Funktion f heißt *injektiv*, wenn es zu jedem Bild $z \in f(D)$ genau ein Urbild $x \in D$ gibt.
- Die Funktion f heißt *surjektiv*, wenn $f(D) = Z$ gilt, wenn also jedes Element der Zielmenge Z ein Urbild in der Definitionsmenge D hat.
- Die Funktion f heißt *bijektiv*, wenn f injektiv und surjektiv ist. Bijektive Funktionen heißen auch *eineindeutige Funktionen* (engl. *one-to-one correspondences*).

•

Beispiel 4.2 (Injektivität, Surjektivität, Bijektivität)**.** Wir verdeutlichen Definition 4.3 zunächst anhand dreier Beispiele und Gegenbeispiele in Abbildung 4.3. Abbildung 4.3 A visualisiert dabei die *nicht injektive* Funktion

$$f : \{1, 2, 3\} \to \{a, b\}, x \mapsto \begin{cases} f(1) & := a \\ f(2) & := a\ . \\ f(3) & := b \end{cases} \tag{4.6}$$

Die Funktion ist nicht injektiv, weil es zum Element a in der Bildmenge von f mehr als ein Urbild in der Definitionsmenge von f gibt, nämlich die Elemente 1 und 2. Abbildung 4.3 B visualisiert die *nicht surjektive* Funktion

$$g : \{1,2,3\} \rightarrow \{a,b,c,d\}, x \mapsto \begin{cases} g(1) & := a \\ g(2) & := b \\ g(3) & := d \end{cases}. \tag{4.7}$$

Die Funktion ist nicht surjektiv, weil das Element c in der Zielmenge von g kein Urbild in der Definitionsmenge von g hat. Abbildung 4.3 C schließlich visualisiert die bijektive Funktion

$$h : \{1,2,3\} \rightarrow \{a,b,c\}, x \mapsto \begin{cases} h(1) & := a \\ h(2) & := b \\ h(3) & := c \end{cases}. \tag{4.8}$$

Zu *jedem* Element in der Zielmenge von h gibt es *genau ein* Urbild, die Funktion ist also injektiv und surjektiv und damit bijektiv.

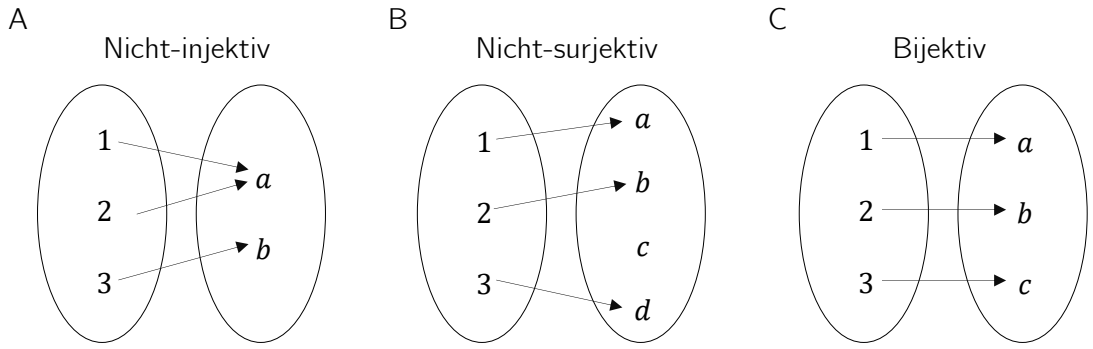


Abbildung 4.3. Injektivität, Surjektivität, Bijektivität.

Als weiteres Beispiel betrachten wir die Funktion

$$f : \mathbb{R} \rightarrow \mathbb{R}, x \mapsto f(x) := x^2 \tag{4.9}$$

Diese Funktion ist nicht injektiv, weil z. B. für $x_1 = 2 \neq -2 = x_2$ gilt, dass $f(x_1) = 2^2 = 4 = (-2)^2 = f(x_2)$. Weiterhin ist f auch nicht surjektiv, weil z. B. $-1 \in \mathbb{R}$ kein Urbild unter f hat. Schränkt man die Definitionsmenge von f allerdings auf die nichtnegativen reellen Zahlen ein, definiert man also die Funktion

$$\tilde{f} : [0,\infty[\rightarrow [0,\infty[, x \mapsto \tilde{f}(x) := x^2, \tag{4.10}$$

so ist $\tilde{f}$ im Gegensatz zu f injektiv und surjektiv, also bijektiv.

△

Theorem 4.1. *Es sei $f : D \rightarrow Z, x \mapsto f(x)$ eine Funktion. Dann gilt*

$$f \text{ ist injektiv} \Leftrightarrow \text{ Aus } x_1, x_2 \in D \text{ mit } x_1 \neq x_2 \text{ folgt, dass } f(x_1) \neq f(x_2). \tag{4.11}$$

∘

Beweis. Wie in Kapitel 1.5 diskutiert, beweisen wir eine Äquivalenz, indem wir beide Implikationen zeigen.

"⇒": Sei f injektiv und seien $x_1, x_2 \in D$ beliebig. Wir zeigen die Implikation

$$x_1 \neq x_2 \Rightarrow f(x_1) \neq f(x_2) \tag{4.12}$$

durch einen *indirekten Beweis*. Dazu setzen wir

$$A : x_1 \neq x_2,\ B : f(x_1) \neq f(x_2). \tag{4.13}$$

Nach dem Prinzip des indirekten Beweises genügt es, aus $\neg B$ die Aussage $\neg A$ herzuleiten. Es gelte also $f(x_1) = f(x_2)$. Dann sind x_1 und x_2 Urbilder desselben Bildes. Da f injektiv ist, hat dieses Bild genau ein Urbild. Somit gilt $x_1 = x_2$, wie zu zeigen war.

"⇐": Es gelte, dass aus $x_1, x_2 \in D$ mit $x_1 \neq x_2$ stets $f(x_1) \neq f(x_2)$ folgt. Wir zeigen, dass f injektiv ist. Sei dazu $z \in f(D)$ beliebig. Nach der Definition der Bildmenge hat z mindestens ein Urbild.

Dass z höchstens ein Urbild hat, zeigen wir durch einen *Beweis durch Widerspruch*. Angenommen, z hätte zwei verschiedene Urbilder $x_1, x_2 \in D$. Dann wäre $x_1 \neq x_2$, und nach unserer Voraussetzung müsste $f(x_1) \neq f(x_2)$ gelten. Da beide Argumente Urbilder von z sind, gilt jedoch

$$f(x_1) = z = f(x_2). \tag{4.14}$$

Dies ist ein Widerspruch. Folglich hat z genau ein Urbild. Da $z \in f(D)$ beliebig gewählt war, ist f injektiv. □

Bei einer injektiven Funktion haben verschiedene Argumentwerte also stets verschiedene Funktionswerte.

Beispiel 4.3 (Zur Überabzählbarkeit der reellen Zahlen)**.** Wir wollen an dieser Stelle die Begriffe der Surjektivität und Bijektivität von Funktionen nutzen, um den Begriff der *Überabzählbarkeit der reellen Zahlen* zu vertiefen (vgl. Kapitel 2.3). Dieser besagt, dass es verschiedene Arten von Unendlichkeiten gibt, was zunächst sicherlich intuitiv nicht leicht zu fassen ist. Speziell wollen wir an dieser Stelle das *Cantorsche Diagonalargument* (Cantor (1891), Gray (1994)) zur Überabzählbarkeit der reellen Zahlen grob skizzieren. Wir beginnen damit festzuhalten, was vor dem Hintergrund bijektiver Abbildungen mit einer *endlichen* und einer *abzählbar unendlichen* Menge gemeint ist.

Definition 4.4 (Endliche und abzählbar unendliche Menge)**.** Eine Menge M heißt *endlich*, wenn $M = \emptyset$ gilt oder wenn es für ein $n \in \mathbb{N}$ eine bijektive Abbildung

$$f : \mathbb{N}_n \to M \tag{4.15}$$

gibt. Weiterhin heißt eine Menge M *abzählbar unendlich*, wenn es eine bijektive Abbildung

$$f : \mathbb{N} \to M \tag{4.16}$$

gibt.

•

Im Falle einer endlichen Menge kann jedem Element der Menge im Sinne einer bijektiven Abbildung eine natürliche Zahl mit maximalem Wert $n < \infty$ zugeordnet werden. Im Falle einer abzählbar unendlichen Menge kann jedem Element der Menge zumindest eine natürliche Zahl zugeordnet werden. Die Elemente dieser Mengen können also abgezählt werden. Cantor (1891) hat gezeigt, dass dies für die reellen Zahlen nicht möglich ist. Es kann keine bijektive Abbildung zwischen den natürlichen Zahlen und den reellen Zahlen konstruiert werden. Tatsächlich ist bereits das offene Intervall $]0, 1[$ überabzählbar. Um dies zu zeigen, nehmen wir im Sinne eines Widerspruchsbeweises an, es gebe eine surjektive Funktion

$$f : \mathbb{N} \to]0, 1[, n \mapsto f(n). \tag{4.17}$$

Dann müsste jede Zahl aus $]0,1[$ als $f(n)$ für mindestens ein $n \in \mathbb{N}$ auftreten. Um zu sehen, dass dies nicht sein kann, schreiben wir zunächst jedes $f(n)$ in seiner Dezimaldarstellung

$$f(n) = 0{,}a_{n,1}a_{n,2}a_{n,3}\dots, \tag{4.18}$$

wobei $a_{n,k} \in \{0,1,\dots,9\}$ die k-te Dezimalziffer von $f(n)$ bezeichnet. Eine solche vermeintlich vollständige Auflistung kann beispielsweise wie in Tabelle 4.1 beginnen.

Tabelle 4.1. Abbildung $f : \mathbb{N} \to]0,1[$. Die Punkte $\cdots$ und $\vdots$ zeigen an, dass die Tabelle bis ins Unendliche nach rechts und nach unten fortgesetzt wird.

n	$f(n)$									
1	0,	**3**	1	4	1	5	9	2	6	5	$\cdots$
2	0,	8	**9**	4	5	9	7	8	1	0	$\cdots$
3	0,	9	6	**2**	3	2	1	5	8	7	$\cdots$
4	0,	5	3	6	**8**	8	8	9	7	3	$\cdots$
5	0,	7	4	3	8	**1**	8	0	9	7	$\cdots$
$\vdots$	$\vdots$										

Wir konstruieren nun eine weitere Dezimalzahl. Dazu betrachten wir für jedes $n \in \mathbb{N}$ die n-te Dezimalziffer von $f(n)$, also die fett hervorgehobenen Diagonalziffern in Tabelle 4.1. Ist diese Ziffer von 1 verschieden, ersetzen wir sie durch 1. Ist sie gleich 1, ersetzen wir sie durch 2. Für die ersten fünf Zeilen des Beispiels ergibt sich damit die in Tabelle 4.2 dargestellte Konstruktion.

Tabelle 4.2. Konstruktion der Dezimalziffern einer weiteren Zahl in $]0,1[$.

n	$f(n)$									
1	0,	**1**	1	4	1	5	9	2	6	5	$\cdots$
2	0,	8	**1**	4	5	9	7	8	1	0	$\cdots$
3	0,	9	6	**1**	3	2	1	5	8	7	$\cdots$
4	0,	5	3	6	**1**	8	8	9	7	3	$\cdots$
5	0,	7	4	3	8	**2**	8	0	9	7	$\cdots$
$\vdots$	$\vdots$										

Die fett hervorgehobenen Ziffern definieren eine neue Zahl z. Im dargestellten Beispiel beginnt diese Zahl mit

$$z = 0{,}11112\dots \tag{4.19}$$

und wird nach demselben Verfahren für alle weiteren Zeilen fortgesetzt. Da jede Dezimalziffer von z entweder 1 oder 2 ist, liegt z in $]0,1[$. Die Zahl z unterscheidet sich von $f(1)$ an der ersten Dezimalstelle, von $f(2)$ an der zweiten Dezimalstelle und allgemein von $f(n)$ an der n-ten Dezimalstelle. Daher gilt $z \neq f(n)$ für jedes $n \in \mathbb{N}$. Damit liegt z nicht im Wertebereich von f. Dies widerspricht der Annahme, dass f surjektiv ist. Somit gibt es keine surjektive und daher insbesondere keine bijektive Abbildung von $\mathbb{N}$ nach $]0,1[$. Das Intervall $]0,1[$ ist also nicht abzählbar unendlich, sondern *überabzählbar*. Da $]0,1[\subset \mathbb{R}$ gilt, sind auch die reellen Zahlen überabzählbar.

△

4.2. Funktionentypen

Durch Verkettung lassen sich aus Funktionen weitere Funktionen bilden.

Definition 4.5 (Verkettung von Funktionen)**.** Es seien $f : D \to Z$ und $g : E \to S$ zwei Funktionen mit $f(D) \subseteq E$. Der Wertebereich von f sei also in der Definitionsmenge von g enthalten. Dann ist durch

$$g \circ f : D \to S, x \mapsto (g \circ f)(x) := g(f(x)) \tag{4.20}$$

eine Funktion definiert, die die *Verkettung von f und g* genannt wird.

•

Die Schreibweise für verkettete Funktionen ist etwas gewöhnungsbedürftig. Wichtig ist es zu erkennen, dass $g \circ f$ die verkettete Funktion und $(g \circ f)(x)$ ein Element in der Zielmenge der verketteten Funktion bezeichnen. Intuitiv wird bei der Auswertung von $(g \circ f)(x)$ zunächst die Funktion f auf x angewendet und dann die Funktion g auf das Element $f(x)$ von Z angewendet. Dies ist in der funktionalen Form $g(f(x))$ festgehalten. Der Einfachheit halber benennt man die Verkettung zweier Funktionen auch oft mit einem einzelnen Buchstaben und schreibt beispielsweise $h := g \circ f$ mit $h(x) = g(f(x))$. Leicht zur Verwirrung kann es führen, wenn Elemente in der Zielmenge von f mit y bezeichnet werden, also die Schreibweise $y = f(x)$ und $h(x) = g(y)$ genutzt wird. Allerdings ist diese Schreibweise manchmal zur notationellen Vereinfachung nötig. Wir visualisieren Definition 4.5 in Abbildung 4.4.

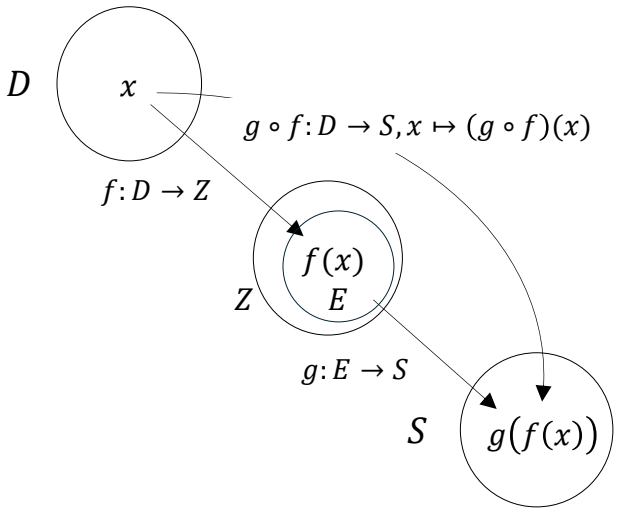


Abbildung 4.4. Verkettung von Funktionen.

Als Beispiel für die Verkettung zweier Funktionen betrachten wir

$$f : \mathbb{R} \to \mathbb{R}, x \mapsto f(x) := -x^2 \tag{4.21}$$

und

$$g : \mathbb{R} \to \mathbb{R}, x \mapsto g(x) := \exp(x). \tag{4.22}$$

Die Verkettung von f und g ergibt sich in diesem Fall zu

$$g \circ f : \mathbb{R} \to \mathbb{R}, x \mapsto (g \circ f)(x) := g(f(x)) = \exp\left(-x^2\right). \tag{4.23}$$

Eine erste Anwendung der Verkettung von Funktionen findet sich in folgender Definition.

Definition 4.6 (Inverse Funktion)**.** Es sei $f : D \to Z, x \mapsto f(x)$ eine bijektive Funktion. Dann heißt die Funktion $f^{-1} : Z \to D$, die jedem $z \in Z$ sein eindeutig bestimmtes Urbild in D zuordnet, *inverse Funktion*, *Umkehrfunktion* oder einfach *Inverse von* f. Es gelten

$$f^{-1}(f(x)) = x \text{ für alle } x \in D \tag{4.24}$$

und

$$f(f^{-1}(z)) = z \text{ für alle } z \in Z. \tag{4.25}$$

•

Inverse Funktionen sind immer bijektiv. Dies folgt, weil f bijektiv ist und damit jedem $x \in D$ genau ein $f(x) = z \in Z$ zugeordnet wird. Damit wird aber auch jedem $z \in Z$ genau ein $x \in D$, nämlich $f^{-1}(f(x)) = x$, zugeordnet. Intuitiv macht die inverse Funktion von f den Effekt von f auf ein Element x rückgängig. Wir visualisieren Definition 4.6 in Abbildung 4.5 A.

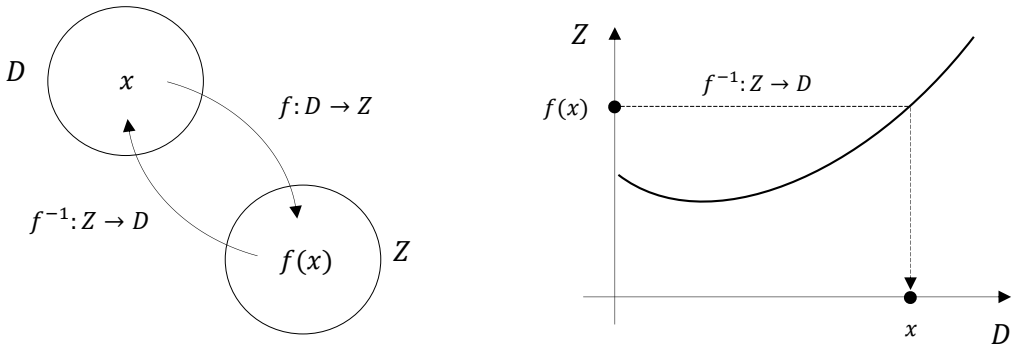


Abbildung 4.5. Inverse Funktion.

Betrachtet man konkret den Graphen einer Funktion in einem Kartesischen Koordinatensystem, so führt die Auswertung einer Funktion von einem Wert auf der x-Achse zu einem Wert auf der y-Achse. Die Auswertung der inversen Funktion führt dementsprechend von einem Wert auf der y-Achse zu einem Wert auf der x-Achse. Wir visualisieren dies in Abbildung 4.5 B. Betrachten wir beispielsweise die Funktion

$$f : \mathbb{R} \to \mathbb{R}, x \mapsto f(x) := 2x =: y. \tag{4.26}$$

Dann ist die inverse Funktion von f gegeben durch

$$f^{-1} : \mathbb{R} \to \mathbb{R}, y \mapsto f^{-1}(y) := \frac{1}{2}y, \tag{4.27}$$

weil für jedes $x \in \mathbb{R}$ gilt, dass

$$(f^{-1} \circ f)(x) = f^{-1}(f(x)) = f^{-1}(2x) = \frac{1}{2} \cdot 2x = x. \tag{4.28}$$

Eine wichtige Klasse von Funktionen sind *lineare Abbildungen*.

Definition 4.7 (Lineare Abbildung)**.** Es seien D und Z Mengen. Eine Abbildung $f : D \to Z, x \mapsto f(x)$ heißt *lineare Abbildung*, wenn für alle $x, y \in D$ und alle $c \in \mathbb{R}$ gilt, dass

$$f(x + y) = f(x) + f(y) \qquad \text{(Additivität)}$$

und

$$f(cx) = cf(x). \qquad \text{(Homogenität)}$$

Eine Abbildung, die diese Bedingungen nicht erfüllt, heißt *nichtlineare Abbildung*.

•

Lineare Abbildungen sind oft als "gerade Linien" bekannt. Die allgemeine Definition linearer Abbildungen ist mit dieser Intuition nicht komplett kongruent. Insbesondere sind lineare Abbildungen nur solche Funktionen, die den Nullpunkt auf den Nullpunkt abbilden. Wir zeigen dazu folgendes Theorem.

Theorem 4.2 (Lineare Abbildung der Null)**.** *$f : D \to Z$ sei eine lineare Abbildung. Dann gilt*

$$f(0) = 0. \tag{4.29}$$

∘

Beweis. Wir halten zunächst fest, dass mit der Additivität von f gilt, dass

$$f(0) = f(0 + 0) = f(0) + f(0). \tag{4.30}$$

Addition von $-f(0)$ zu beiden Seiten obiger Gleichung ergibt dann

$$f(0) - f(0) = f(0) + f(0) - f(0) \Leftrightarrow f(0) = 0 \tag{4.31}$$

und damit ist alles gezeigt. □

Wir wollen den Begriff der linearen Abbildung noch an zwei Beispielen verdeutlichen.

- Für $a \in \mathbb{R}$ ist die Abbildung

  $$f : \mathbb{R} \to \mathbb{R}, x \mapsto f(x) := ax \tag{4.32}$$

  eine lineare Abbildung, weil gilt, dass

  $$f(x+y) = a(x+y) = ax+ay = f(x)+f(y) \text{ und } f(cx) = acx = cax = cf(x). \tag{4.33}$$

- Für $a, b \in \mathbb{R}$ mit $b \neq 0$ ist dagegen die Abbildung

  $$f : \mathbb{R} \to \mathbb{R}, x \mapsto f(x) := ax + b \tag{4.34}$$

  nichtlinear, weil z. B. für $a := b := 1$ gilt, dass

  $$f(x + y) = 1(x + y) + 1 = x + y + 1 \neq x + 1 + y + 1 = f(x) + f(y). \tag{4.35}$$

Eine Abbildung der Form $f(x) := ax + b$ heißt *linear-affine Abbildung* oder *linear-affine Funktion*. Etwas unsauber werden Funktionen der Form $f(x) := ax + b$ auch manchmal als *lineare Funktionen* bezeichnet.

Neben den bisher diskutierten Funktionentypen gibt es noch viele weitere Klassen von Funktionen. In folgender Definition klassifizieren wir Funktionen anhand der Dimensionalität ihrer Definitions- und Zielmengen. Diese Art der Funktionsklassifikation ist oft hilfreich, um sich einen ersten Überblick über ein mathematisches Modell zu verschaffen.

Definition 4.8 (Funktionenarten)**.** Wir unterscheiden

- *univariate reellwertige Funktionen* der Form

$$f : \mathbb{R} \to \mathbb{R}, x \mapsto f(x), \tag{4.36}$$

- *multivariate reellwertige Funktionen* der Form

$$f : \mathbb{R}^n \to \mathbb{R}, x \mapsto f(x) = f(x_1, \dots, x_n), \tag{4.37}$$

- und *multivariate vektorwertige Funktionen* der Form

$$f : \mathbb{R}^n \to \mathbb{R}^m, x \mapsto f(x) = \begin{pmatrix} f_1(x_1, \dots, x_n) \\ \vdots \\ f_m(x_1, \dots, x_n) \end{pmatrix}, \tag{4.38}$$

  wobei $f_i, i = 1, \dots, m$ die *Komponentenfunktionen* von f genannt werden.

•

In der Physik werden multivariate reellwertige Funktionen *Skalarfelder* und multivariate vektorwertige Funktionen *Vektorfelder* genannt. In manchen Anwendungen treten auch *matrixvariate matrixwertige Funktionen* auf.

4.3. Elementare Funktionen

Als *elementare Funktionen* bezeichnen wir eine kleine Schar von univariaten reellwertigen Funktionen, die häufig als Bausteine komplexerer Funktionen auftreten. Dies sind die *Polynomfunktionen*, die *Exponentialfunktion*, die *Logarithmusfunktion* und die *Gammafunktion*. Im Folgenden geben wir die Definitionen dieser Funktionen sowie ihre wesentlichen Eigenschaften als Theoreme an und stellen ihre Graphen dar. Für Beweise der Eigenschaften der hier vorgestellten Funktionen verweisen wir auf die weiterführende Literatur.

Definition 4.9 (Polynomfunktionen)**.** Für $k \in \mathbb{N}^0$ und $a_0, a_1, \dots, a_k \in \mathbb{R}$ heißt eine Funktion der Form

$$f : \mathbb{R} \to \mathbb{R}, x \mapsto f(x) := \sum_{i=0}^{k} a_i x^i = a_0 + a_1 x + \cdots + a_k x^k \tag{4.39}$$

Polynomfunktion. Ist $a_k \neq 0$, so hat sie den *Grad* k. Sind alle Koeffizienten null, so heißt sie *Nullpolynom*. Dem Nullpolynom weisen wir hier keinen Grad zu. Typische Polynomfunktionen sind in folgender Tabelle aufgelistet:

Tabelle 4.3. Polynomfunktionen.

Name	Funktionale Form	Koeffizienten
Konstante Funktion	$f(x) = a$	$a_0 := a$, $a_i := 0$, $i > 0$
Identitätsfunktion	$f(x) = x$	$a_0 := 0$, $a_1 := 1$, $a_i := 0$, $i > 1$

Name	Funktionale Form	Koeffizienten
Linear-affine Funktion	$f(x) = ax + b$	$a_0 := b$, $a_1 := a$, $a_i := 0$, $i > 1$
Quadratfunktion	$f(x) = x^2$	$a_0 := 0$, $a_1 := 0$, $a_2 := 1$, $a_i := 0$, $i > 2$

•

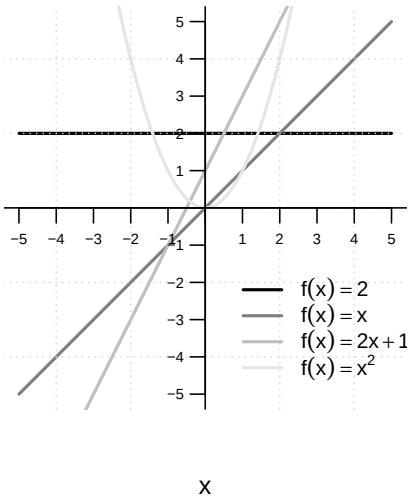


Abbildung 4.6. Ausgewählte Polynomfunktionen

Abbildung 4.6 zeigt die Graphen der in Definition 4.9 aufgelisteten Polynomfunktionen.

Ein wichtiges Funktionenpaar sind die Exponentialfunktion und die Logarithmusfunktion.

Theorem 4.3 (Exponentialfunktion und ihre Eigenschaften)**.** *Die* Exponentialfunktion *ist definiert als*

$$\exp : \mathbb{R} \to \mathbb{R}_{>0}, x \mapsto \exp(x) := e^x := \sum_{n=0}^{\infty} \frac{x^n}{n!} = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \frac{x^4}{4!} + \cdots \tag{4.40}$$

Die Exponentialfunktion hat die in folgender Tabelle aufgeführten Eigenschaften. Dabei seien $x, y \in \mathbb{R}$.

Tabelle 4.4. Eigenschaften der Exponentialfunktion.

Eigenschaft	*Bedeutung*
Wertebereich	$x \in]-\infty, 0[\Rightarrow \exp(x) \in]0, 1[$ $x \in]0, \infty[\Rightarrow \exp(x) \in]1, \infty[$

Eigenschaft	*Bedeutung*
Monotonie	$x < y \Rightarrow \exp(x) < \exp(y)$
Spezielle Werte	$\exp(0) = 1$ *und* $\exp(1) = e$
Summationseigenschaft	$\exp(x + y) = \exp(x)\exp(y)$
Subtraktionseigenschaft	$\exp(x - y) = \frac{\exp(x)}{\exp(y)}$

∘

Insbesondere nimmt die Exponentialfunktion nur positive Werte an und schneidet die y-Achse bei $x = 0$. Die Zahl $\exp(1) := e \approx 2{,}71\ldots$ heißt *Eulersche Zahl*. Schließlich gilt mit den speziellen Werten der Exponentialfunktion auch

$$\exp(x)\exp(-x) = \exp(x - x) = \exp(0) = 1. \tag{4.41}$$

Theorem 4.4 (Logarithmusfunktion und ihre Eigenschaften)**.** *Die* Logarithmusfunktion *ist definiert als inverse Funktion der Exponentialfunktion,*

$$\ln :]0, \infty[\to \mathbb{R}, x \mapsto \ln(x) \text{ } \textit{mit} \text{ } \ln(\exp(x)) = x \textit{ für alle } x \in \mathbb{R}. \tag{4.42}$$

Die Logarithmusfunktion hat die in folgender Tabelle aufgeführten Eigenschaften. Dabei seien $x, y > 0$ und $c \in \mathbb{R}$.

Tabelle 4.5. Eigenschaften der Logarithmusfunktion.

Eigenschaft	*Bedeutung*
Wertebereich	$x \in]0, 1[\Rightarrow \ln(x) \in]-\infty, 0[$ $x \in]1, \infty[\Rightarrow \ln(x) \in]0, \infty[$
Monotonie	$x < y \Rightarrow \ln(x) < \ln(y)$
Spezielle Werte	$\ln(1) = 0$ *und* $\ln(e) = 1$
Produkteigenschaft	$\ln(xy) = \ln(x) + \ln(y)$
Potenzeigenschaft	$\ln(x^c) = c\ln(x)$
Divisionseigenschaft	$\ln\left(\frac{1}{x}\right) = -\ln(x)$

∘

Im Gegensatz zur Exponentialfunktion nimmt die Logarithmusfunktion sowohl negative als auch positive Werte an. Die Logarithmusfunktion schneidet die x- Achse bei $x = 1$. Die Produkteigenschaft und die Potenzeigenschaft sind beim Rechnen mit der Logarithmusfunktion zentral. Man merkt sie sich intuitiv als "Die Logarithmusfunktion wandelt Produkte in Summen und Potenzen in Produkte um." Die Graphen der Exponential- und Logarithmusfunktion sind in Abbildung 4.7 abgebildet.

Ein häufiger Begleiter in der Wahrscheinlichkeitstheorie ist die *Gammafunktion*.

Theorem 4.5 (Gammafunktion und ihre Eigenschaften)**.** *Die* Gammafunktion *ist für positive reelle Argumente definiert durch*

$$\Gamma : \mathbb{R}_{>0} \to \mathbb{R}_{>0}, x \mapsto \Gamma(x) := \int_0^\infty \xi^{x-1}\exp(-\xi)\, d\xi. \tag{4.43}$$

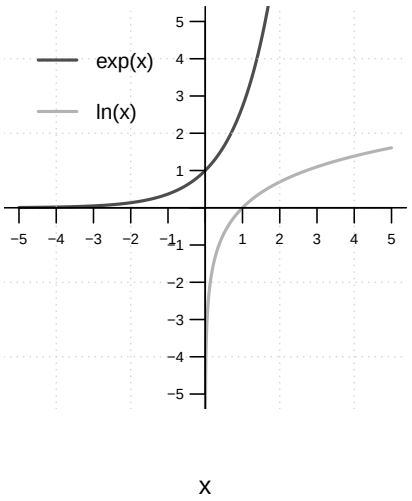


Abbildung 4.7. Exponentialfunktion und Logarithmusfunktion

Die Gammafunktion hat die in folgender Tabelle aufgeführten Eigenschaften.

Tabelle 4.6. Eigenschaften der Gammafunktion.

Eigenschaft	*Bedeutung*
Spezielle Werte	$\Gamma(1) = 1$
	$\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$
	$\Gamma(n) = (n-1)!$ *für* $n \in \mathbb{N}$
Rekursionseigenschaft	*Für* $x > 0$ *gilt* $\Gamma(x+1) = x\Gamma(x)$

°

Ein Ausschnitt des Graphen der Gammafunktion ist in Abbildung 4.8 dargestellt.

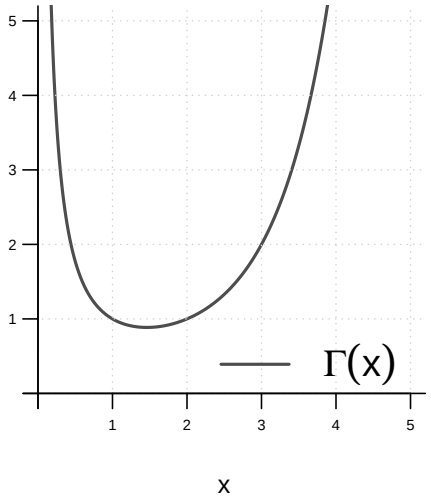


Abbildung 4.8. Gammafunktion

10. Geben Sie die Definitionen der Begriffe der univariat-reellwertigen, multivariat-reellwertigen und multivariat-vektorwertigen Funktion wieder.
11. Geben Sie die Summations- und Subtraktionseigenschaften der Exponentialfunktion an.
12. Geben Sie die Produkt-, Potenz- und Divisionseigenschaften der Logarithmusfunktion an.
13. Skizzieren Sie die Identitätsfunktion und die konstante Funktion für $a := 1$.
14. Skizzieren Sie die lineare Funktion $f(x) = ax + b$ für $a = 2$ und $b = 3$.
15. Skizzieren Sie die Funktionen $f(x) := (x - 1)^2$ und $g(x) := (x + 3)^2$.
16. Skizzieren Sie die Exponential- und Logarithmusfunktionen.

Lösungen

1. Siehe Definition 4.1.
2. Siehe Definition 4.2.
3. Siehe Definition 4.3.
4. Die Funktion ist nicht injektiv, denn $f(-2) = f(2) = 4$, obwohl $-2 \neq 2$. Sie ist nicht surjektiv, denn negative reelle Zahlen haben kein Urbild unter f.
5. Die Funktion ist bijektiv, denn für jedes $z \in \mathbb{R}_{\geq 0}$ gibt es genau ein $x \in \mathbb{R}_{\geq 0}$ mit $f(x) = z$, nämlich $x = \sqrt{z}$.
6. Siehe Definition 4.5.
7. Siehe Definition 4.6.
8. Die inverse Funktion ist
$$f^{-1} : \mathbb{R}_{\geq 0} \to \mathbb{R}_{\geq 0}, z \mapsto f^{-1}(z) := \sqrt{z}. \tag{4.44}$$
Für $x, z \in \mathbb{R}_{\geq 0}$ gelten $f^{-1}(f(x)) = \sqrt{x^2} = x$ und $f(f^{-1}(z)) = (\sqrt{z})^2 = z$.
9. Siehe Definition 4.7.
10. Siehe Definition 4.8.
11. Für $x, y \in \mathbb{R}$ gelten
$$\begin{aligned} \exp(x + y) &= \exp(x) \exp(y) \\ \exp(x - y) &= \frac{\exp(x)}{\exp(y)}. \end{aligned} \tag{4.45}$$
Siehe Theorem 4.3.
12. Für $x, y > 0$ und $c \in \mathbb{R}$ gelten
$$\begin{aligned} \ln(xy) &= \ln(x) + \ln(y) \\ \ln(x^c) &= c \ln(x) \\ \ln\left(\frac{1}{x}\right) &= -\ln(x). \end{aligned} \tag{4.46}$$
Siehe Theorem 4.4.
13. Der Graph der Identitätsfunktion ist die Gerade durch $(0, 0)$ und $(1, 1)$. Der Graph der konstanten Funktion mit $a = 1$ ist die horizontale Gerade durch $(0, 1)$. Siehe Abbildung 4.6.
14. Der Graph von $f(x) = 2x + 3$ ist eine Gerade mit Steigung 2 und Achsenabschnitt 3. Sie verläuft beispielsweise durch $(0, 3)$ und $(1, 5)$. Siehe Tabelle 4.3.
15. Beide Graphen sind nach oben geöffnete Normalparabeln. Der Graph von $f(x) = (x - 1)^2$ hat den Scheitelpunkt $(1, 0)$, der Graph von $g(x) = (x + 3)^2$ den Scheitelpunkt $(-3, 0)$. Sie entstehen aus dem Graphen der Quadratfunktion durch Verschiebung um 1 nach rechts beziehungsweise 3 nach links. Siehe Abbildung 4.6.
16. Siehe Abbildung 4.7. Die Exponentialfunktion ist streng monoton steigend, verläuft durch $(0, 1)$ und nähert sich für $x \to -\infty$ der x-Achse. Die Logarithmusfunktion ist streng monoton steigend, verläuft durch $(1, 0)$ und besitzt die vertikale Asymptote $x = 0$. Die beiden Graphen sind Spiegelbilder an der Geraden $y = x$.

5. Folgen, Grenzwerte, Stetigkeit

Die in diesem Kapitel behandelten Themen sind in der probabilistischen Datenwissenschaft nicht zentral, sondern bilden Grundbausteine der reellen Analysis. Durch die enge Verschränkung der modernen Wahrscheinlichkeitstheorie mit analytischen Ansätzen dienen sie jedoch dem Verständnis bestimmter Resultate der Wahrscheinlichkeitstheorie. Ein Beispiel für ein solches Resultat ist der *Zentrale Grenzwertsatz*. Der Zentrale Grenzwertsatz wiederum bildet die Grundlage für die weit verbreitete Normalverteilungsannahme in der probabilistischen Datenwissenschaft. Die hier betrachteten Grundlagen erhöhen also mittelbar das Verständnis datenwissenschaftlicher Prinzipien. In aller Kürze ist der Zentrale Grenzwertsatz eine Aussage über die *Grenzfunktion* einer *Funktionenfolge*, genauer einer Folge von Zufallsvariablen. Das Wissen um das Wesen von *Folgen*, *Funktionenfolgen* und ihren *Grenzwerten* erlaubt also einen informierten Zugang zum Studium des Zentralen Grenzwertsatzes. Weiterhin ermöglichen die in diesem Kapitel behandelten Themen zumindest einen ersten Einstieg in das Verständnis der Stetigkeit und Glattheit von Funktionen, die beispielsweise in der nichtlinearen Optimierung zur Bestimmung von Parameterschätzern probabilistischer Modelle wichtige Grundkonzepte bilden. Weitere Anwendungen sind die Grenzwertdefinition der Ableitung sowie die links- und rechtsseitige Stetigkeit von Funktionen. Letztere ist insbesondere für kumulative Verteilungsfunktionen wichtig.

5.1. Folgen

Wir beginnen mit der Definition des Begriffs der *reellen Folge*.

Definition 5.1 (Reelle Folge)**.** Eine *reelle Folge* ist eine Funktion der Form

$$f : \mathbb{N} \to \mathbb{R}, n \mapsto f(n). \tag{5.1}$$

Die Funktionswerte $f(n)$ einer reellen Folge werden üblicherweise mit x_n bezeichnet und *Folgenglieder* genannt. Übliche Schreibweisen für Folgen sind

$$(x_1, x_2, ...) \text{ oder } (x_n)_{n=1}^{\infty} \text{ oder } (x_n)_{n\in\mathbb{N}} \text{ oder } (x_n). \tag{5.2}$$

•

Man beachte, dass eine reelle Folge, weil es unendlich viele natürliche Zahlen gibt, immer unendlich viele Folgenglieder hat. Dies sollte man sich insbesondere bei der Schreibweise $(x_1, x_2, ...)$ bewusst machen. Wir wollen drei Standardbeispiele für reelle Folgen betrachten.

Beispiel 5.1 (Sprungfolge, harmonische und geometrische Folgen)**.** *(Sprungfolge)* Eine reelle Folge der Form

$$f : \mathbb{N} \to \mathbb{R}, n \mapsto f(n) := 2 + \frac{(-1)^n}{n} \tag{5.3}$$

ist ein Beispiel für eine *Sprungfolge*. Die vorliegende Sprungfolge hat die Folgengliederform

$$\left(2 - 1, 2 + \frac{1}{2}, 2 - \frac{1}{3}, 2 + \frac{1}{4}, 2 - \frac{1}{5}, ...\right) = \left(1, \frac{5}{2}, \frac{5}{3}, \frac{9}{4}, \frac{9}{5}, ...\right). \tag{5.4}$$

(Harmonische Folge) Reelle Folgen der Form

$$f : \mathbb{N} \to \mathbb{R}, n \mapsto f(n) := \left(\frac{1}{n}\right)^{\frac{p}{q}} \text{ mit } p, q \in \mathbb{N} \tag{5.5}$$

nennt man *harmonische Folgen*. Für $p := q := 1$ hat eine harmonische Folge die Folgengliederform

$$\left(\frac{1}{1}, \frac{1}{2}, \frac{1}{3}, ...\right). \tag{5.6}$$

(Geometrische Folge) Reelle Folgen der Form

$$f : \mathbb{N} \to \mathbb{R}, n \mapsto f(n) := q^n \text{ mit } q \in]-1, 1[\tag{5.7}$$

nennt man *geometrische Folgen*. Für $q := \frac{1}{2}$ hat eine geometrische Folge die Folgengliederform

$$\left(\left(\frac{1}{2}\right)^1, \left(\frac{1}{2}\right)^2, \left(\frac{1}{2}\right)^3, ...\right) = \left(\frac{1^1}{2^1}, \frac{1^2}{2^2}, \frac{1^3}{2^3}, ...\right) = \left(\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, ...\right) \tag{5.8}$$

Die drei Beispiele sind in Abbildung 5.1 dargestellt.

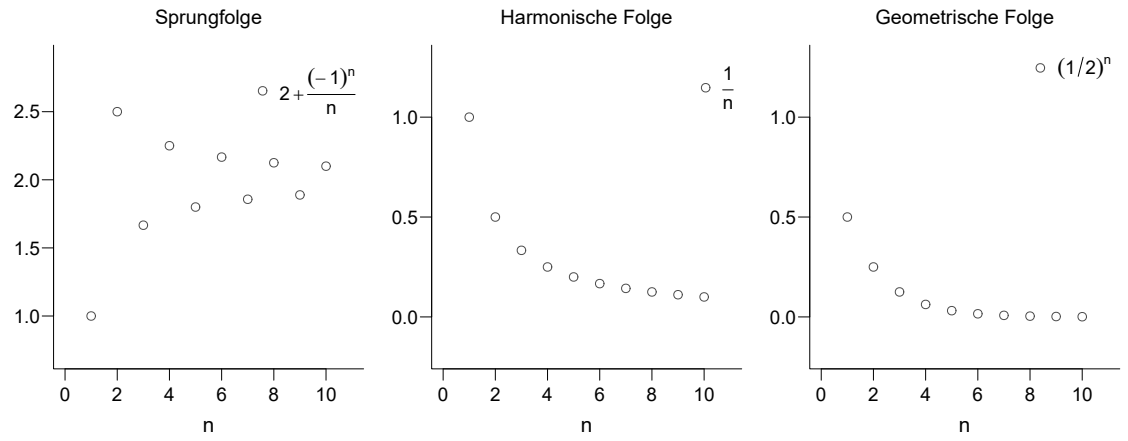


Abbildung 5.1. Sprungfolge, harmonische Folge und geometrische Folge ohne eingezeichnete Grenzwerte.

△

Neben den reellen Folgen, also Folgen reeller Zahlen, kann man auch Folgen anderer mathematischer Objekte betrachten. Eine wichtige Folgenart sind die *Funktionenfolgen*.

Definition 5.2 (Funktionenfolge)**.** Es sei ϕ eine Menge univariater reellwertiger Funktionen mit Definitionsmenge $D \subseteq \mathbb{R}$. Dann ist eine Funktionenfolge eine Funktion der Form

$$F : \mathbb{N} \to \phi, n \mapsto F(n). \tag{5.9}$$

Die Funktionswerte $F(n)$ einer Funktionenfolge werden üblicherweise mit f_n bezeichnet und *Folgenglieder* genannt. Übliche Schreibweisen für Funktionenfolgen sind

$$(f_1, f_2, ...) \text{ oder } (f_n)_{n=1}^{\infty} \text{ oder } (f_n)_{n\in\mathbb{N}} \text{ oder } (f_n). \tag{5.10}$$

•

Die Definition einer Funktionenfolge ist offenbar analog zur Definition einer reellen Folge. Der Unterschied zwischen einer reellen Folge und einer Funktionenfolge ist, dass die Folgenglieder einer reellen Folge reelle Zahlen, die Folgenglieder einer Funktionenfolge dagegen univariate reellwertige Funktionen sind. Auch hier wollen wir zwei Standardbeispiele diskutieren.

Beispiel 5.2 (Potenzen und Partialsummen als Funktionenfolgen)**.** Als erstes Beispiel betrachten wird die Menge ϕ der univariaten reellwertigen Funktionen der Form

$$\phi := \{f_n | f_n : [0, 1] \to \mathbb{R},\, x \mapsto f_n(x) := x^n \text{ für } n \in \mathbb{N}\} \tag{5.11}$$

Dann definiert

$$F : \mathbb{N} \to \phi, n \mapsto F(n) := f_n \tag{5.12}$$

eine Funktionenfolge. Für die Funktionswerte der Folgenglieder von F gilt

$$f_1(x) := x^1, f_2(x) := x^2, f_3(x) := x^3, ... \tag{5.13}$$

Für ein weiteres Beispiel sei $a > 0$. Wir betrachten die Menge ϕ der univariaten reellwertigen Funktionen der Form

$$\phi := \left\{ f_n | f_n : [-a, a] \to \mathbb{R},\, x \mapsto f_n(x) := \sum_{k=0}^{n} \frac{x^k}{k!} \text{ für } n \in \mathbb{N} \right\} \tag{5.14}$$

Dann definiert

$$F : \mathbb{N} \to \phi, n \mapsto F(n) := f_n \tag{5.15}$$

eine Funktionenfolge. Für die Funktionswerte der Folgenglieder von F gilt

$$f_1(x) := \sum_{k=0}^{1} \frac{x^k}{k!}, f_2(x) := \sum_{k=0}^{2} \frac{x^k}{k!}, f_3(x) := \sum_{k=0}^{3} \frac{x^k}{k!}, ... \tag{5.16}$$

△

5.2. Grenzwerte

Wir betrachten zunächst Grenzwerte reeller Folgen, dann Grenzfunktionen von Funktionenfolgen und schließlich Grenzwerte von Funktionen.

Wenn man die Folgenglieder einer Folge betrachtet, kann man sich fragen, welche Werte eine Folge wohl annimmt, wenn der Folgenindex n sehr groß wird, also gegen unendlich strebt. Wenn in diesem Fall die Folgenglieder sehr ähnliche Werte annehmen (und nicht etwa auch unendlich groß werden), so ist man auf den Begriff des *Grenzwerts* für reelle Folgen bzw. der *Grenzfunktion* für Funktionenfolgen geführt.

Definition 5.3 (Grenzwert einer reellen Folge)**.** $x \in \mathbb{R}$ heißt Grenzwert einer reellen Folge $(x_n)_{n=1}^{\infty}$, wenn es zu jedem $\epsilon > 0$ ein $m \in \mathbb{N}$ gibt, so dass

$$|x_n - x| < \epsilon \text{ für alle } n \geq m. \tag{5.17}$$

Eine Folge, die einen Grenzwert besitzt, wird *konvergente Folge* genannt, eine Folge, die keinen Grenzwert besitzt, wird *divergente Folge* genannt. Dafür, dass $x \in \mathbb{R}$ Grenzwert der Folge $(x_n)_{n=1}^{\infty}$ ist, schreibt man auch

$$\lim_{n\to\infty} x_n = x \text{ oder } x_n \to x \text{ für } n \to \infty \text{ oder } x_n \xrightarrow{n\to\infty} x. \tag{5.18}$$

•

Eine Folge mit Grenzwert 0 nennt man *Nullfolge*.

Nach 1 kann der Grenzwert einer Folge existieren, muss es aber nicht.

Beispiel 5.3 (Eine divergente reelle Folge)**.** Die Folge

$$f : \mathbb{N} \to \mathbb{R}, n \mapsto f(n) := n \tag{5.19}$$

hat keinen Grenzwert, da hier sowohl n als auch $f(n)$ unendlich groß werden.

△

Für eine konvergente Folge, also eine Folge, deren Grenzwert existiert, gilt nach 1, dass sich für ein beliebig kleines, aber positives ϵ ein $m \in \mathbb{N}$ angeben lässt, sodass für alle Folgenglieder x_n mit $n \geq m$ der Abstand in positiver oder negativer Richtung vom Grenzwert kleiner als ϵ ist. Die Folgenglieder mit $n \geq m$ liegen also beliebig nah am Grenzwert x. Oft mag es so sein, dass für ein kleineres ϵ ein größeres m erforderlich ist.

Beispiel 5.4 (Grenzwerte reeller Folgen)**.** Die oben betrachteten Beispiele für reelle Folgen dagegen haben Grenzwerte.

(Sprungfolge) Wir betrachten die reelle Folge mit den Folgengliedern

$$x_n := 2 + \frac{(-1)^n}{n}, \tag{5.20}$$

Dann gilt

$$\lim_{n\to\infty} x_n = 2. \tag{5.21}$$

Beweis

Sei $\epsilon > 0$ beliebig. Wir wählen eine natürliche Zahl m mit $m > 1/\epsilon$. Zum Beispiel wählen wir also für $\epsilon = 0.01 > 0$ das m als $m := 101$, denn dann gilt

$$m > \frac{1}{\epsilon} = \frac{1}{0.01} = 100. \tag{5.22}$$

Für alle $n \geq m$ gilt dann mit $x = 2$:

$$|x_n - 2| = \left|\frac{(-1)^n}{n}\right| = \frac{1}{n} \leq \frac{1}{m} < \epsilon. \tag{5.23}$$

Damit ist die Grenzwertdefinition erfüllt und $x = 2$ ist Grenzwert der Folge $(x_n)_{n=1}^{\infty}$. Man beachte, dass die Wahl von m von ϵ abhängt. Für kleinere ϵ kann ein größeres m erforderlich sein. Man kann aber immer ein hinreichend großes m finden, sodass die Grenzwertdefinition erfüllt ist.

(Harmonische Folgen) Für die harmonischen Folgen gilt mit $p, q \in \mathbb{N}$

$$\lim_{n\to\infty} \left(\frac{1}{n}\right)^{\frac{p}{q}} = 0. \tag{5.24}$$

(Geometrische Folgen) Für die geometrischen Folgen gilt mit $q \in]-1, 1[$

$$\lim_{n\to\infty} q^n = 0. \tag{5.25}$$

Man nennt die harmonischen und geometrischen Folgen entsprechend auch *Nullfolgen*. Für allgemeine Beweise von Gleichung 5.24 und Gleichung 5.25 verweisen wir auf die weiterführende Literatur. Tatsächlich sind diese Beweise nicht trivial und rühren an den Grundannahmen über das Wesen der reellen Zahlen. Die Beweise beruhen auf dem Archimedischen Axiom und der Bernoulli-Ungleichung. Für die zugrunde liegenden Tatsachen verweisen wir ebenfalls auf die weiterführende Literatur.

Wir visualisieren die ersten zehn Folgenglieder sowie die Grenzwerte der Sprungfolge, der harmonischen Folge für $p := q := 1$ und der geometrischen Folge für $q := 1/2$ in Abbildung 5.2. Die durch Punkte dargestellten Folgenglieder liegen für höheres n offenbar zunehmend näher an dem durch eine graue Linie dargestellten Grenzwert.

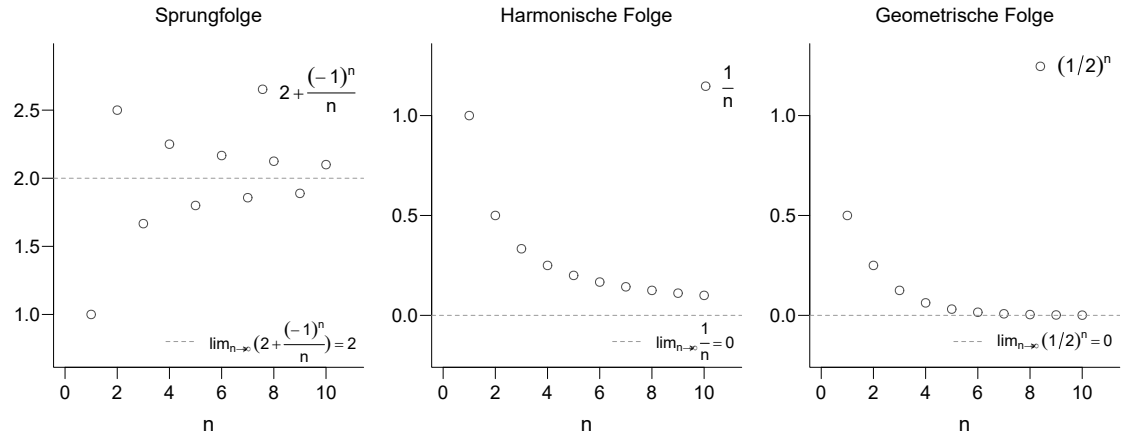


Abbildung 5.2. Grenzwerte der Sprungfolge, der harmonischen und der geometrischen Folge.

△

Beispiel 5.5 (Nachweis des Grenzwerts der harmonischen Folge)**.** Für den Spezialfall der harmonischen Folge mit $p = q = 1$ wollen wir die Argumentation für den Grenzwert

$$\lim_{n\to\infty} \frac{1}{n} = 0 \tag{5.26}$$

kurz darstellen. Nach 1 gilt Gleichung 5.26 genau dann, wenn sich für ein beliebiges $\epsilon > 0$ (also insbesondere ein beliebig kleines) ein $m \in \mathbb{N}$ angeben lässt, so dass für alle $n \geq m$ gilt, dass

$$\left|\frac{1}{n} - 0\right| < \epsilon \Leftrightarrow \frac{1}{n} < \epsilon.$$

Setzt man also mit der Aufrundungsfunktion $\lceil \cdot \rceil$ für ein beliebiges $\epsilon > 0$

$$m := \left\lceil \frac{1}{\epsilon} \right\rceil + 1,$$

also z. B. bei $\epsilon := 0.01$ entsprechend $m := \lceil \frac{1}{0.01} \rceil + 1 = 101$, so gilt für alle $n \geq m$, dass $\frac{1}{n} < \epsilon$. Da $\epsilon > 0$ beliebig gewählt wurde, ist diese Konstruktion für alle $\epsilon > 0$ möglich.

△

Theorem 5.1 (Rechenregeln für Grenzwerte reeller Folgen)**.** *Es seien (x_n) und (y_n) konvergente reelle Folgen mit $\lim_{n\to\infty} x_n = x$ und $\lim_{n\to\infty} y_n = y$. Für jedes $c \in \mathbb{R}$ gilt*

$$\lim_{n\to\infty} (x_n + y_n) = x + y, \quad \lim_{n\to\infty} (cx_n) = cx, \quad \lim_{n\to\infty} (x_n y_n) = xy. \tag{5.27}$$

Ist zusätzlich $y \neq 0$, so gilt $y_n \neq 0$ ab einem hinreichend großen Index und für die ab dort definierte Quotientenfolge gilt

$$\lim_{n\to\infty} \frac{x_n}{y_n} = \frac{x}{y}. \tag{5.28}$$

∘

Für einen Beweis verweisen wir auf die weiterführende Literatur.

Für Funktionenfolgen ist eine Möglichkeit der Erweiterung der Begriffe der Konvergenz und des Grenzwertes folgende.

Definition 5.4 (Punktweise Konvergenz und Grenzfunktion einer Funktionenfolge)**.** $F = (f_n)_{n\in\mathbb{N}}$ sei eine Funktionenfolge von univariaten reellwertigen Funktionen mit Definitionsbereich D. F heißt *punktweise konvergent*, wenn die reelle Folge $(f_n(x))_{n\in\mathbb{N}}$ für jedes $x \in D$ eine konvergente Folge ist, also einen Grenzwert besitzt. Die Funktion, die jedem $x \in D$ diesen Grenzwert von $(f_n(x))_{n\in\mathbb{N}}$ zuordnet, heißt dann die *Grenzfunktion der Funktionenfolge F* und hat die Form

$$f : D \to \mathbb{R}, x \mapsto f(x) := \lim_{n\to\infty} f_n(x). \tag{5.29}$$

•

Man beachte, dass die Grenzwerte von konvergenten reellen Folgen reelle Zahlen sind, die Grenzfunktionen von punktweise konvergenten Funktionenfolgen dagegen sind Funktionen. Neben der punktweisen Konvergenz von Funktionenfolgen gibt es noch den mächtigeren Begriff der *gleichmäßigen Konvergenz* von Funktionenfolgen, für den wir aber auf die weiterführende Literatur verweisen. Als Beispiel betrachten wir die Grenzfunktionen der oben diskutierten Funktionenfolgen, wobei wir für Beweise auf die weiterführende Literatur verweisen.

Beispiel 5.6 (Grenzfunktionen von Potenzen und Partialsummen)**.** Wir betrachten die Funktionenfolge

$$F : \mathbb{N} \to \phi, n \mapsto F(n) := f_n \tag{5.30}$$

mit

$$\phi := \{f_n | f_n : [0, 1] \to \mathbb{R},\ x \mapsto f_n(x) := x^n \text{ für } n \in \mathbb{N}\} \tag{5.31}$$

Dann ist F punktweise konvergent mit Grenzfunktion

$$f : [0, 1] \to \mathbb{R},\ x \mapsto f(x) := \begin{cases} 0, & \text{für } x \in [0, 1[, \\ 1, & \text{für } x = 1. \end{cases} \tag{5.32}$$

Da $f_n(x) := x^n$ für $x \in [0, 1[$ eine geometrische Folge und damit eine Nullfolge ist und für $x = 1$ eine konstante Folge mit Wert 1, konvergiert die Funktionenfolge F gegen eine Funktion, die auf dem gesamten Intervall $[0, 1]$ gleich null ist, außer im Punkt 1. Diese Funktion hat offenbar einen Sprung.

(Exponentialfunktion) Sei $a > 0$. Wir betrachten die Funktionenfolge

$$F : \mathbb{N} \to \phi, n \mapsto F(n) := f_n \tag{5.33}$$

mit

$$\phi := \left\{ f_n | f_n : [-a, a] \to \mathbb{R},\ x \mapsto f_n(x) := \sum_{k=0}^{n} \frac{x^k}{k!} \text{ für } n \in \mathbb{N} \right\} \tag{5.34}$$

Dann ist F punktweise konvergent mit Grenzfunktion

$$f : [-a, a] \to \mathbb{R},\ x \mapsto f(x) := \sum_{k=0}^{\infty} \frac{x^k}{k!} = \exp(x). \tag{5.35}$$

Die Funktionenfolge F konvergiert also punktweise gegen die Exponentialfunktion auf $[-a, a]$. Umgekehrt betrachtet ist die Exponentialfunktion gerade durch

$$\exp(x) := \sum_{k=0}^{\infty} \frac{x^k}{k!} \tag{5.36}$$

definiert.

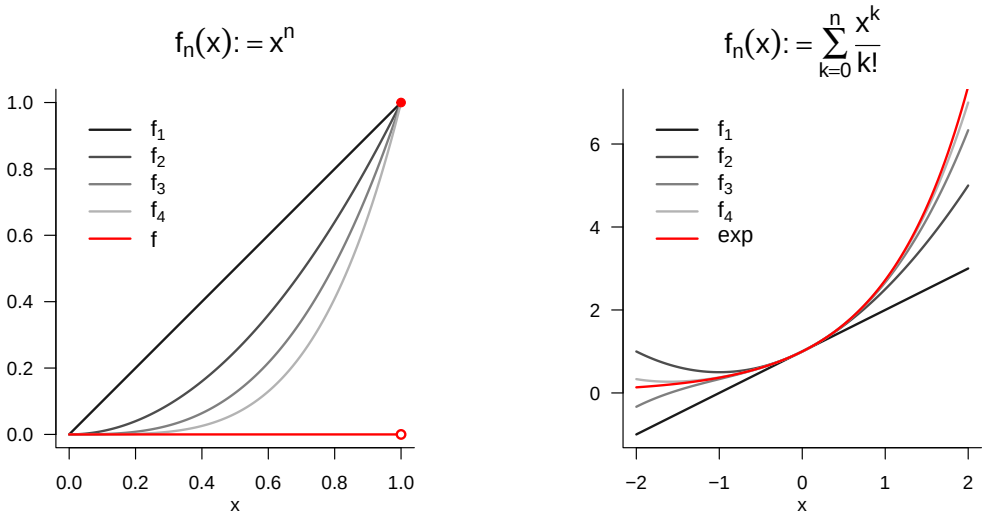


Abbildung 5.3. Beispiele für Grenzwerte von Funktionenfolgen

△

Bei einer reellen Folge betrachten wir das Verhalten der Folgenglieder für immer größer werdende Indizes n. Die Schreibweise

$$\lim_{n \to \infty} f(n) = x \tag{5.37}$$

bedeutet, dass die Folgenglieder $f(n)$ beliebig nahe bei x liegen, sobald n hinreichend groß ist. Bei einer Funktion betrachten wir dagegen das Verhalten ihrer Werte für Argumente x, die sich einer Stelle a nähern. Die Schreibweise

$$\lim_{x \to a} f(x) = b \tag{5.38}$$

bedeutet, dass die Funktionswerte $f(x)$ beliebig nahe bei b liegen, sobald x hinreichend nahe bei a liegt und $x \neq a$ ist.

Gemeinsam ist beiden Grenzwertbegriffen, dass sich die Funktionswerte beliebig nahe an einen Grenzwert annähern. Der Unterschied besteht in den Argumenten: Bei $n \to \infty$ werden die natürlichen Zahlen n immer größer, bei $x \to a$ nähern sich die reellen Zahlen x einer festen Zahl a. n muss nicht gleich Unendlich sein und kann dies als natürliche Zahl auch gar nicht. Beim Funktionsgrenzwert muss x nicht gleich a sein. Insbesondere muss a nicht zur Definitionsmenge der Funktion gehören. Um die Annäherung an a präzise zu beschreiben, führen wir zunächst den Begriff des Häufungspunkts ein.

Definition 5.5 (Häufungspunkt)**.** Es sei $D \subseteq \mathbb{R}$. Ein Punkt $a \in \mathbb{R}$ heißt *Häufungspunkt von D*, wenn es zu jedem $\delta > 0$ ein $x \in D$ mit

$$0 < |x - a| < \delta \tag{5.39}$$

gibt.

•

Beispiel 5.7 (Ein Häufungspunkt der reellen Zahlen)**.** Für $D := \mathbb{R}$ ist $a := 0$ ein Häufungspunkt. Beispielsweise nähern sich 0.1, 0.01, 0.001, ... der Zahl 0. Zu jedem $\delta > 0$ wählen wir $x := \delta/2$. Dann gilt $x \in \mathbb{R}$ und

$$0 < |x - 0| = \frac{\delta}{2} < \delta. \tag{5.40}$$

△

Definition 5.6 (Grenzwert einer Funktion an einer Stelle)**.** Es seien $D \subseteq \mathbb{R}$ und $f : D \to \mathbb{R}$ eine Funktion. Sei a ein Häufungspunkt von D. Eine Zahl $b \in \mathbb{R}$ heißt *Grenzwert von f für $x \to a$*, wenn es zu jedem $\epsilon > 0$ ein $\delta > 0$ gibt, sodass für alle $x \in D$ gilt:

$$0 < |x - a| < \delta \Rightarrow |f(x) - b| < \epsilon. \tag{5.41}$$

Man schreibt dann $\lim_{x \to a} f(x) = b$.

•

Diese Definition heißt ϵ-δ-Kriterium nach Karl Weierstraß (Vorlesungen von 1861). Dabei beschreibt ϵ den geforderten Abstand der Funktionswerte zum Grenzwert. δ beschreibt einen dafür hinreichenden Abstand der Argumente zur Stelle a. Der Wert $f(a)$ spielt für diesen Grenzwert keine Rolle.

Beispiel 5.8 (Grenzwert der Funktion $f(x) := 2x$ an der Stelle $a = 1$)**.** Wir wollen zeigen, dass der Grenzwert der Funktion

$$f : \mathbb{R} \to \mathbb{R}, x \mapsto f(x) := 2x \tag{5.42}$$

an der Stelle $a = 1$ gegeben ist durch $b := 2$, also

$$\lim_{x \to 1} 2x = 2. \tag{5.43}$$

Sei dazu ein beliebiges $\epsilon > 0$ vorgegeben. Für $\delta := \frac{1}{2}\epsilon$ gilt dann für jedes $x \in \mathbb{R}$ mit $0 < |x - 1| < \delta$, dass

$$|f(x) - b| = |2x - 2| = |2(x - 1)| = |2||x - 1| = 2|x - 1| < 2\delta = 2\frac{1}{2}\epsilon = \epsilon. \tag{5.44}$$

Damit ist der behauptete Grenzwert gezeigt.

△

5.3. Stetigkeit

Intuitiv bedeutet Stetigkeit, dass hinreichend kleine Änderungen des Arguments zu beliebig kleinen Änderungen des Funktionswerts führen. Wir können dies mit der folgenden Definition präzisieren.

Definition 5.7 (Stetigkeit einer Funktion)**.** Es seien $D, Z \subseteq \mathbb{R}$ und $f : D \to Z$ eine Funktion. Die Funktion f heißt *stetig in* $a \in D$, wenn es zu jedem $\epsilon > 0$ ein $\delta > 0$ gibt, sodass für alle $x \in D$ gilt:

$$|x - a| < \delta \Rightarrow \ |f(x) - f(a)| < \epsilon. \tag{5.45}$$

Ist a außerdem ein Häufungspunkt von D, so ist diese Bedingung gemäß Definition 5.6 äquivalent zu

$$\lim_{x \to a} f(x) = f(a). \tag{5.46}$$

Ist f in jedem $a \in D$ stetig, so heißt f *stetig auf* D.

•

Definition 5.7 besagt intuitiv, dass $f(x)$ beliebig nahe bei $f(a)$ liegt, sofern $x \in D$ hinreichend nahe bei a liegt. Anders als beim Funktionsgrenzwert muss hier allerdings $f(a)$ definiert sein. Typische Beispiele für stetige Funktionen sind die elementaren Funktionen aus Kapitel 4.3, jeweils auf ihrem Definitionsbereich. Ein typisches Beispiel für eine unstetige Funktion ist die Heaviside-Funktion.

Beispiel 5.9 (Stetigkeit von $f(x) := 2x$ auf $\mathbb{R}$)**.** In Beispiel 5.8 haben wir bereits gesehen, dass für $a = 1$ und damit $f(a) = 2$ gilt, dass

$$\lim_{x \to a} f(x) = f(a) \tag{5.47}$$

und die Funktion somit stetig in $a = 1$ ist. Seien zum Nachweis der Stetigkeit der Funktion auf ganz $\mathbb{R}$ nun $a \in \mathbb{R}$ beliebig und ein $\epsilon > 0$ vorgegeben. Für $\delta := \frac{1}{2}\epsilon$ gilt dann für jedes $x \in \mathbb{R}$ mit $|x - a| < \delta$, dass

$$|f(x) - f(a)| = |2x - 2a| = |2(x - a)| = |2||x - a| = 2|x - a| < 2\delta = 2\frac{1}{2}\epsilon = \epsilon. \tag{5.48}$$

Also ist f an jeder Stelle $a \in \mathbb{R}$ stetig und damit stetig auf $\mathbb{R}$.

△

Theorem 5.2 (Grenzwertbildung bei stetigen Funktionen)**.** *Es seien* $D, H \subseteq \mathbb{R}$, $f : D \to \mathbb{R}$ *und* $g : H \to D$ *Funktionen sowie* $a \in D$*. Dabei sei* 0 *ein Häufungspunkt von* H*. Ist* f *stetig in* a *und gilt*

$$\lim_{h \to 0} g(h) = a, \tag{5.49}$$

so gilt auch

$$\lim_{h \to 0} f(g(h)) = f(a). \tag{5.50}$$

∘

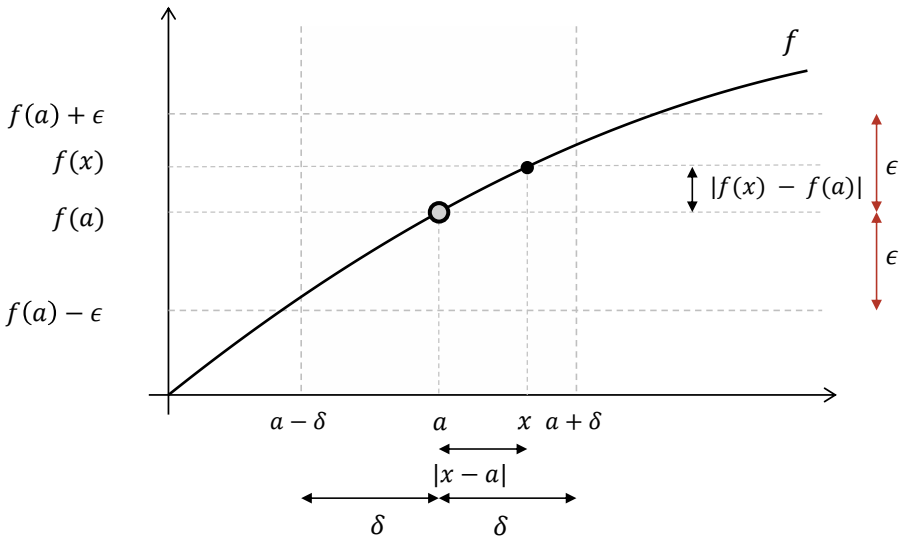


Abbildung 5.4. Zu jedem $\epsilon > 0$ lässt sich ein $\delta > 0$ so wählen, dass für alle $x \in D$ aus $|x - a| < \delta$ die Ungleichung $|f(x) - f(a)| < \epsilon$ folgt.

Beweis. Sei $\epsilon > 0$ beliebig. Wegen der Stetigkeit von f in a gibt es ein $\delta > 0$, sodass für alle $t \in D$ gilt:

$$|t - a| < \delta \Rightarrow |f(t) - f(a)| < \epsilon. \tag{5.51}$$

Wegen $\lim_{h \to 0} g(h) = a$ gibt es zu diesem $\delta > 0$ ein $\eta > 0$, sodass für alle $h \in H$ gilt:

$$0 < |h| < \eta \Rightarrow |g(h) - a| < \delta. \tag{5.52}$$

Da $g(h) \in D$ liegt, können wir die erste Implikation mit $t = g(h)$ anwenden. Somit gilt für alle $h \in H$:

$$0 < |h| < \eta \Rightarrow |g(h) - a| < \delta \Rightarrow |f(g(h)) - f(a)| < \epsilon. \tag{5.53}$$

Damit ist die Definition des Funktionsgrenzwerts für $f \circ g$ erfüllt. □

Definition 5.8 (Linksseitige und rechtsseitige Stetigkeit)**.** Es seien $D, Z \subseteq \mathbb{R}$ und $f : D \to Z$ eine Funktion. Die Funktion f heißt *linksseitig stetig in* $a \in D$, wenn es zu jedem $\epsilon > 0$ ein $\delta > 0$ gibt, sodass für alle $x \in D$ mit $x \leq a$ gilt:

$$|x - a| < \delta \Rightarrow |f(x) - f(a)| < \epsilon. \tag{5.54}$$

Die Funktion f heißt *rechtsseitig stetig in* $a \in D$, wenn es zu jedem $\epsilon > 0$ ein $\delta > 0$ gibt, sodass für alle $x \in D$ mit $x \geq a$ gilt:

$$|x - a| < \delta \Rightarrow |f(x) - f(a)| < \epsilon. \tag{5.55}$$

•

Bei linksseitiger Stetigkeit betrachten wir nur Argumente links von a oder gleich a. Bei rechtsseitiger Stetigkeit betrachten wir dagegen nur Argumente rechts von a oder gleich a. Eine Funktion ist genau dann stetig in a, wenn sie dort sowohl linksseitig als auch rechtsseitig stetig ist.

Beispiel 5.10 (Einseitige Stetigkeit der Heaviside-Funktion)**.** Wir betrachten die Heaviside-Funktion mit der Festlegung $f(0) = 1$:

$$f : \mathbb{R} \to \mathbb{R}, x \mapsto f(x) := \begin{cases} 0 & \text{für } x < 0, \\ 1 & \text{für } x \geq 0. \end{cases} \tag{5.56}$$

Rechtsseitige Stetigkeit in 0

Sei $\epsilon > 0$ beliebig. Wir wählen $\delta := 1$. Für alle $x \geq 0$ mit $|x| < \delta$ gilt

$$|f(x) - f(0)| = |1 - 1| = 0 < \epsilon. \tag{5.57}$$

Also ist f rechtsseitig stetig in 0.

Keine linksseitige Stetigkeit in 0

Wir wählen $\epsilon := 1/2$. Zu jedem $\delta > 0$ gibt es $x := -\delta/2 < 0$ mit $|x| < \delta$, aber

$$|f(x) - f(0)| = |0 - 1| = 1 > \epsilon. \tag{5.58}$$

Also ist f nicht linksseitig stetig und damit auch nicht stetig in 0.

f ist die kumulative Verteilungsfunktion einer Zufallsvariable, die mit Wahrscheinlichkeit 1 den Wert 0 annimmt. Kumulative Verteilungsfunktionen sind stets rechtsseitig stetig, können aber Sprungstellen besitzen.

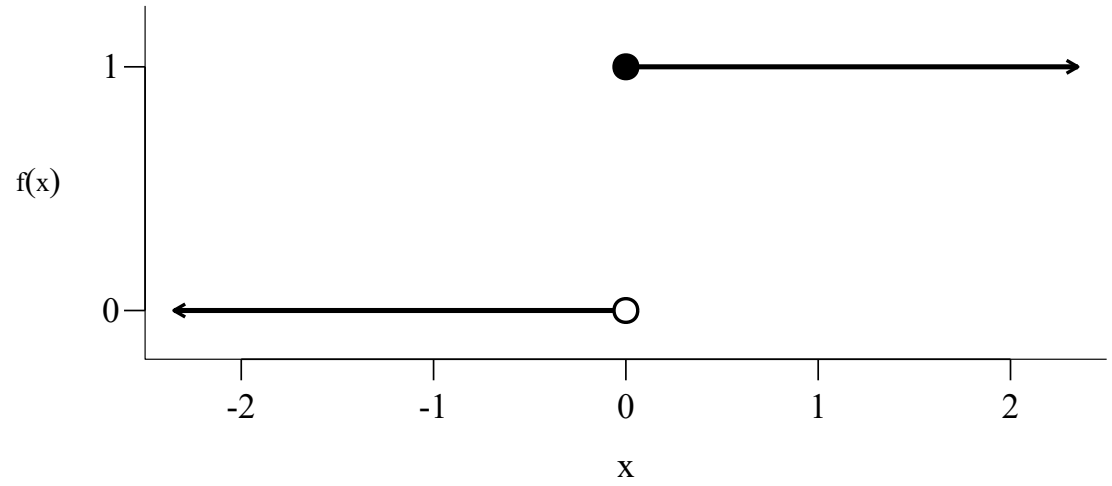


Abbildung 5.5. Heaviside-Funktion mit $f(0) = 1$.

Der weiße Punkt bei $(0, 0)$ gehört nicht zum Graphen. Der schwarze Punkt bei $(0, 1)$ gehört dagegen zum Graphen, es gilt $f(0) = 1$. Bei 0 springt f von 0 auf 1 und ist nur rechtsseitig stetig.

△

Selbstkontrollfragen

1. Geben Sie die Definition einer reellen Folge wieder.
2. Was unterscheidet eine Funktionenfolge von einer reellen Folge?
3. Geben Sie die ersten drei Glieder der Folgen $x_n := 1/n$ und $y_n := (1/2)^n$ an.
4. Definieren Sie Konvergenz, Divergenz und den Begriff der Nullfolge.
5. Bestimmen Sie die Grenzwerte der beiden Folgen aus Frage 3.

6. Wählen Sie für $x_n := 1/n$ ein $m \in \mathbb{N}$, sodass für alle $n \geq m$ gilt, dass $|x_n| < 0.01$ ist.
7. Konvergiert die Folge $x_n := (-1)^n$? Begründen Sie Ihre Antwort.
8. Was bedeutet punktweise Konvergenz einer Funktionenfolge?
9. Bestimmen Sie die Grenzfunktion von $f_n(x) := x^n$ für $0 \leq x \leq 1$.
10. Gegen welche Funktion konvergieren die Partialsummen $f_n(x) := \sum_{k=0}^{n} x^k/k!$ für $x \in \mathbb{R}$?
11. Geben Sie die Definition der Stetigkeit einer Funktion wieder.
12. Ist die Grenzfunktion aus Frage 9 in $x = 1$ stetig?

Lösungen

1. Eine reelle Folge ist eine Funktion $f : \mathbb{N} \to \mathbb{R}, n \mapsto f(n) =: x_n$. Die Werte x_n heißen Folgenglieder. Siehe Definition 5.1.
2. Die Glieder einer reellen Folge sind reelle Zahlen. Die Glieder einer Funktionenfolge sind Funktionen.
3. Es gelten $(x_1, x_2, x_3) = (1, 1/2, 1/3)$ und $(y_1, y_2, y_3) = (1/2, 1/4, 1/8)$.
4. Eine Folge (x_n) konvergiert gegen $x \in \mathbb{R}$, wenn es zu jedem $\epsilon > 0$ ein $m \in \mathbb{N}$ gibt, sodass für alle $n \geq m$ gilt: $|x_n - x| < \epsilon$. Sie heißt divergent, wenn kein solcher reeller Grenzwert existiert. Eine Nullfolge ist eine Folge mit Grenzwert 0. Siehe

1.

1. Beide Folgen konvergieren gegen 0.
2. Man kann $m := 101$ wählen. Für alle $n \geq 101$ gilt $|x_n| = 1/n \leq 1/101 < 0.01$.
3. Nein. Für gerade Indizes sind die Folgenglieder 1, für ungerade Indizes -1. Diese beiden Teilfolgen haben verschiedene Grenzwerte.
4. Für jedes feste Argument x aus der gemeinsamen Definitionsmenge konvergiert die reelle Folge der Funktionswerte $(f_n(x))$ gegen $f(x)$. Das heißt, $\lim_{n\to\infty} f_n(x) = f(x)$ gilt für jedes $x \in D$.
5. Die Grenzfunktion ist
$$f(x) = \begin{cases} 0, & \text{für } 0 \leq x < 1, \\ 1, & \text{für } x = 1. \end{cases} \tag{5.59}$$
6. Die Partialsummen konvergieren punktweise gegen $\exp(x)$.
7. Eine Funktion $f : D \to \mathbb{R}$ heißt stetig in $a \in D$, wenn es zu jedem $\epsilon > 0$ ein $\delta > 0$ gibt, sodass für alle $x \in D$ gilt: $|x - a| < \delta \Rightarrow |f(x) - f(a)| < \epsilon$. Sie heißt stetig auf D, wenn sie in jedem $a \in D$ stetig ist. Siehe Definition 5.7.
8. Nein. Für $\epsilon := 1/2$ und jedes $\delta > 0$ liegt $x := 1 - \min(\delta/2, 1/2)$ in der Definitionsmenge und erfüllt $|x - 1| < \delta$, aber $|f(x) - f(1)| = 1 > \epsilon$.

6. Differenzialrechnung

Die Differenzialrechnung befasst sich mit der Änderung von Funktionen. Sie bildet einerseits die Grundlage für die mathematische Modellierung dynamischer Systeme mithilfe von *Differenzialgleichungen*, also der Beschreibung von Funktionen anhand ihrer Änderungsraten. Zum anderen bildet die Differenzialrechnung die Grundlage der *Optimierung*, also des Bestimmens von Extremstellen von Funktionen. In Kapitel 6.1 führen wir zunächst den Begriff der Ableitung und mit ihm verbundene elementare Rechenregeln ein. In Kapitel 6.2 widmen wir uns dann der Frage, wie man mithilfe von Ableitungen Extremstellen von Funktionen bestimmen kann.

6.1. Definitionen und Rechenregeln

Wir beginnen mit folgender Definition.

Definition 6.1 (Differenzierbarkeit und Ableitung)**.** Es sei $I \subseteq \mathbb{R}$ ein offenes Intervall und $f : I \to \mathbb{R}$ eine univariate reellwertige Funktion. Die Funktion f heißt *differenzierbar in* $a \in I$, wenn der Grenzwert

$$f'(a) := \lim_{h \to 0} \frac{f(a+h) - f(a)}{h} \tag{6.1}$$

als reelle Zahl existiert. Dabei wird der Quotient nur für $h \neq 0$ und $a + h \in I$ betrachtet. Die Zahl $f'(a)$ heißt *Ableitung von f an der Stelle a*. Ist f in jedem $x \in I$ differenzierbar, so heißt f *differenzierbar auf I*. Die Funktion

$$f' : I \to \mathbb{R}, x \mapsto f'(x) \tag{6.2}$$

heißt dann *Ableitung von f*.

•

Für $h > 0$ heißt der Ausdruck

$$\frac{f(a+h) - f(a)}{h} \tag{6.3}$$

Newtonscher Differenzquotient. Wie in Abbildung 6.1 dargestellt, misst der Newtonsche Differenzquotient die Änderung $f(a + h) - f(a)$ von f auf der y-Achse pro Strecke h auf der x-Achse. Wenn also zum Beispiel $f(a)$ und $f(a + h)$ die Position eines Objektes zu einem Zeitpunkt a und zu einem späteren Zeitpunkt $a + h$ repräsentieren, dann ist $f(a + h) - f(a)$ die von diesem Objekt in der Zeit h zurückgelegte Strecke, also seine durchschnittliche Geschwindigkeit über den Zeitraum h. Für $h \to 0$ misst der Newtonsche Differenzquotient dann die instantane Änderungsrate von f in a, also in diesem Beispiel die Geschwindigkeit des Objektes zu einem Zeitpunkt a.

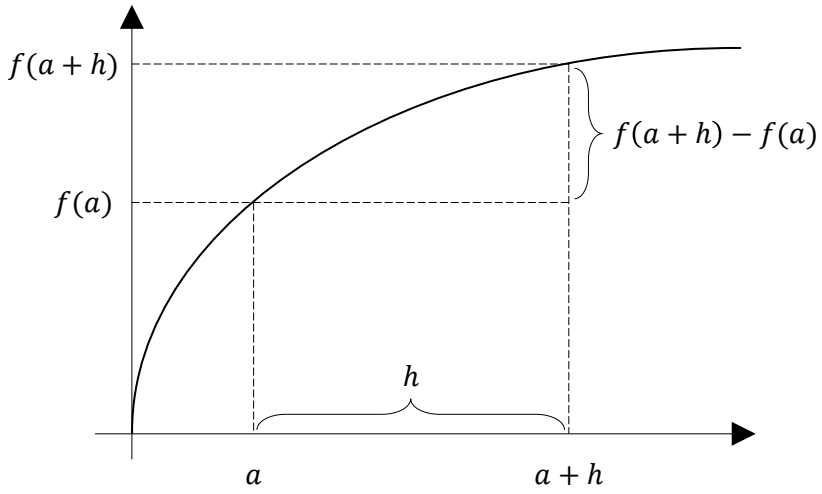


Abbildung 6.1. Elemente des Newtonschen Differenzquotienten.

Aus mathematischer Sicht ist es wichtig, bei der Definition der Ableitung zwischen den Symbolen $f'(a)$ und f' zu unterscheiden. Wie üblich bezeichnet $f'(a)$ den Wert einer Funktion, also eine Zahl. f' dagegen bezeichnet eine Funktion, nämlich die Funktion, deren Werte als $f'(a)$ für alle $a \in I$ bestimmt sind.

Die Definition des Grenzwerts einer Funktion (Definition 5.6) aus dem Kapitel Kapitel 5 gilt auch für den Differenzquotienten. Dabei nähert sich die Schrittweite h der Zahl 0, während die Ableitungsstelle a fest bleibt. Wie in Definition 6.1 sei $f : I \to \mathbb{R}$ auf einem offenen Intervall I definiert und $a \in I$. Für dieses feste a betrachten wir den Differenzquotienten als eigene Funktion

$$g : D_a \to \mathbb{R}, h \mapsto g(h) := \frac{f(a+h) - f(a)}{h}, \tag{6.4}$$

mit der Definitionsmenge

$$D_a := \{h \in \mathbb{R} | h \neq 0,\ a + h \in I\}. \tag{6.5}$$

Weil I offen ist und $a \in I$ liegt, enthält D_a beliebig kleine positive und negative Schrittweiten. Somit ist 0 nach Definition 5.5 ein Häufungspunkt von D_a, obwohl 0 selbst nicht zu D_a gehört.

Wir wenden die Grenzwertdefinition also auf die Funktion g mit der Argumentvariable h, der Grenzwertstelle 0 und einem möglichen Grenzwert $c \in \mathbb{R}$ an. Die Aussage

$$\lim_{h \to 0} g(h) = c \tag{6.6}$$

bedeutet, dass es zu jedem $\epsilon > 0$ ein $\delta > 0$ gibt, sodass für alle $h \in D_a$ gilt:

$$0 < |h| < \delta \Longrightarrow \left| \frac{f(a+h) - f(a)}{h} - c \right| < \epsilon. \tag{6.7}$$

Existiert dieser Grenzwert c, so ist f nach Definition 6.1 in a differenzierbar und $f'(a) = c$. Die Grenzwertstelle der Funktion g ist also 0, die Ableitungsstelle der Funktion f dagegen a.

Beispiel 6.1 (Ableitung der Quadratfunktion)**.** Wir betrachten die Quadratfunktion

$$f : \mathbb{R} \to \mathbb{R}, x \mapsto f(x) := x^2. \tag{6.8}$$

Mithilfe von Definition 5.6 und Definition 6.1 zeigen wir, dass f auf $\mathbb{R}$ differenzierbar ist und die Ableitung

$$f' : \mathbb{R} \to \mathbb{R}, x \mapsto f'(x) = 2x \tag{6.9}$$

besitzt.

Sei dazu $a \in \mathbb{R}$ beliebig und fest. Der Differenzquotient definiert die Funktion

$$g : \mathbb{R} \setminus \{0\} \to \mathbb{R}, h \mapsto g(h) := \frac{f(a+h) - f(a)}{h}. \tag{6.10}$$

Für jedes $h \neq 0$ gilt

$$g(h) = \frac{(a+h)^2 - a^2}{h} = \frac{a^2 + 2ah + h^2 - a^2}{h} = \frac{2ah + h^2}{h} = 2a + h. \tag{6.11}$$

Wir weisen nun mit Definition 5.6 nach, dass $\lim_{h \to 0} g(h) = 2a$ gilt. Sei $\epsilon > 0$ beliebig. Wir wählen $\delta := \epsilon$. Für alle h mit $0 < |h| < \delta$ gilt dann

$$|g(h) - 2a| = |2a + h - 2a| = |h| < \epsilon. \tag{6.12}$$

Damit ist die Grenzwertdefinition erfüllt. Nach Definition 6.1 ist f in a differenzierbar mit

$$f'(a) = \lim_{h \to 0} g(h) = 2a. \tag{6.13}$$

Da a beliebig gewählt war, ist f auf ganz $\mathbb{R}$ differenzierbar und es gilt $f'(x) = 2x$.

△

Es existieren in der Literatur verschiedene, historisch gewachsene Notationen für Ableitungen, welche alle das identische Konzept der Ableitung repräsentieren.

Definition 6.2 (Notation für Ableitungen univariater reellwertiger Funktionen)**.** Es sei f eine differenzierbare univariate reellwertige Funktion. Äquivalente Schreibweisen für die Ableitung von f und die Ableitung von f an einer Stelle x sind

- die *Lagrange-Notation* f' und $f'(x)$,
- die *Leibniz-Notation* $\frac{df}{dx}$ und $\frac{df(x)}{dx}$,
- die *Newton-Notation* $\dot{f}$ und $\dot{f}(x)$,
- die *Euler-Notation* Df und $Df(x)$.

•

Wir werden im Folgenden für univariate reellwertige Funktionen vor allem die Lagrange-Notation f' und $f'(x)$ als Bezeichner wählen. In Berechnungen nutzen wir auch eine adaptierte Form der Leibniz-Notation und verstehen dort die Schreibweise $\frac{d}{dx} f(x)$ als den Auftrag, die Ableitung von f zu berechnen. Die Newton-Notation wird vor allem eingesetzt, wenn das Funktionsargument die Zeit repräsentiert und das dann üblicherweise mit t für *time* bezeichnet wird. $\dot{f}(t)$ bezeichnet dann entsprechend die Änderungsrate von f zum Zeitpunkt t. Die Euler-Notation ist vor allem im Kontext multivariater reell- oder vektorwertiger Funktionen nützlich.

Wir setzen eine Reihe von Ableitungen elementarer Funktionen als bekannt voraus. Diese sind in Tabelle 6.1 zusammengestellt. Für Beweise verweisen wir auf die weiterführende Literatur.

Theorem 6.1 (Ableitungen elementarer Funktionen)**.** *Für $k \in \mathbb{N}_0$ und reelle Koeffizienten $a_0, \ldots, a_k, a, b$ gelten die folgenden Ableitungen. Die Funktionen sind auf $\mathbb{R}$ definiert, die Logarithmusfunktion auf $]0, \infty[$.*

Tabelle 6.1. Ableitungen elementarer Funktionen.

Name	*Definition*	*Ableitung*
Polynomfunktion	$f(x) := \sum_{i=0}^{k} a_i x^i$	$f'(x) = \sum_{i=1}^{k} i a_i x^{i-1}$
Konstante Funktion	$f(x) := a$	$f'(x) = 0$
Identitätsfunktion	$f(x) := x$	$f'(x) = 1$
Linear-affine Funktion	$f(x) := ax + b$	$f'(x) = a$
Quadratfunktion	$f(x) := x^2$	$f'(x) = 2x$
Exponentialfunktion	$f(x) := \exp(x)$	$f'(x) = \exp(x)$
Logarithmusfunktion	$f(x) := \ln(x)$	$f'(x) = \frac{1}{x}$

∘

In Abbildung 6.2 visualisieren wir die Identitätsfunktion, eine lineare Funktion und die Quadratfunktion zusammen mit ihrer jeweiligen Ableitung. In Abbildung Abbildung 6.3 visualisieren wir die Exponential- und Logarithmusfunktionen zusammen mit ihrer jeweiligen Ableitung.

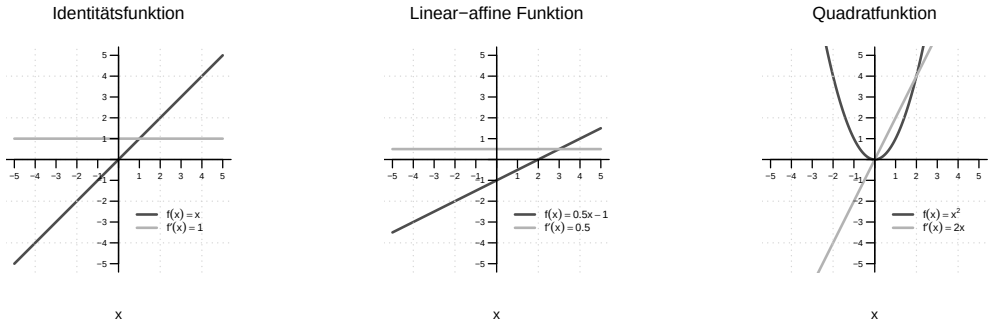


Abbildung 6.2. Ableitungen dreier elementarer Funktionen. Die Ableitung der Identitätsfunktion ist die konstante Funktion mit Wert 1, die Ableitung der betrachteten linear-affinen Funktion ist die konstante Funktion mit Wert 0.5 und die Ableitung der Quadratfunktion ist die linear-affine Funktion mit $a = 2$ und $b = 0$

Basierend auf der Definition der Ableitung einer univariaten reellwertigen Funktion lassen sich leicht weitere Ableitungen einer solchen Funktion definieren.

Definition 6.3 (Höhere Ableitungen)**.** Es sei f eine univariate reellwertige Funktion und

$$f^{(1)} := f' \tag{6.14}$$

sei die Ableitung von f. Die k-te Ableitung von f ist rekursiv definiert durch

$$f^{(k)} := \left(f^{(k-1)}\right)' \text{ für } k > 1, \tag{6.15}$$

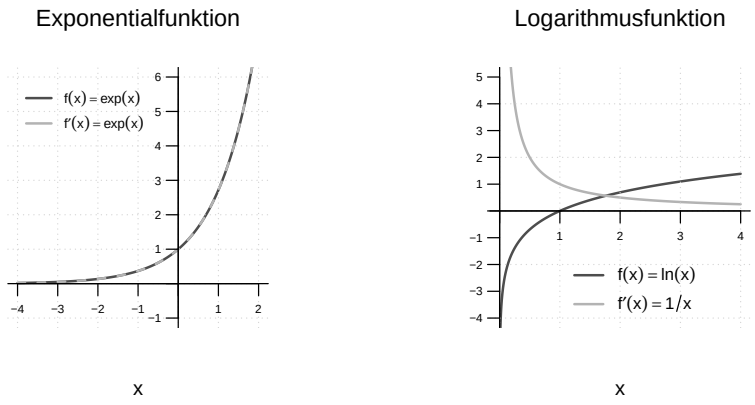


Abbildung 6.3. Ableitungen von Exponentialfunktion und Logarithmusfunktion. Die Ableitung der Exponentialfunktion ist die Exponentialfunktion selbst, die Ableitung der Logarithmusfunktion hat die Funktionswerte $1/x$

unter der Annahme, dass $f^{(k-1)}$ differenzierbar ist. Insbesondere ist die *zweite Ableitung von* f definiert durch die Ableitung von f', also

$$f'' := (f')'. \tag{6.16}$$

•

In Analogie zu oben Gesagtem schreiben wir in Berechnungen auch $\frac{d^2}{dx^2} f(x)$ für den Auftrag, die zweite Ableitung einer Funktion f zu bestimmen. Die nullte Ableitung $f^{(0)}$ von f ist f selbst. Der Tradition und Einfachheit halber schreibt man für $k < 4$ gemäß der Lagrange-Notation meist f', f'' und f''' anstelle von $f^{(1)}$, $f^{(2)}$ und $f^{(3)}$.

Beispiel 6.2 (Höhere Ableitungen einer Quadratfunktion)**.** Es sei

$$f : \mathbb{R} \to \mathbb{R}, x \mapsto f(x) := x^2 \tag{6.17}$$

Dann gilt

$$f^{(1)}(x) = f'(x) = \frac{d}{dx}\left(x^2\right) = 2x \tag{6.18}$$

Weiterhin gelten

$$\begin{aligned} f^{(2)}(x) &= \left(f^{(2-1)}\right)'(x) = \left(f^{(1)}\right)'(x) = \frac{d}{dx}(2x) = 2, \\ f^{(3)}(x) &= \left(f^{(3-1)}\right)'(x) = \left(f^{(2)}\right)'(x) = \frac{d}{dx}(2) = 0, \\ f^{(4)}(x) &= \left(f^{(4-1)}\right)'(x) = \left(f^{(3)}\right)'(x) = \frac{d}{dx}(0) = 0. \end{aligned} \tag{6.19}$$

Man berechnet also durchgängig lediglich erste Ableitungen.

△

Zum Bestimmen der Ableitung einer Funktion sind eine Reihe von Rechenregeln hilfreich, die es erlauben, die Ableitung einer Funktion aus den Ableitungen ihrer Unterfunktionen herzuleiten. Für Beweise der in folgendem Theorem eingeführten Rechenregeln verweisen wir auf die weiterführende Literatur.

Theorem 6.2 (Rechenregeln für Ableitungen)**.** *Es seien $I, J \subseteq \mathbb{R}$ offene Intervalle. Es gelten folgende Rechenregeln für Ableitungen:*

(Summenregel) Für $n \in \mathbb{N}$ und differenzierbare Funktionen $g_i : I \to \mathbb{R}$ mit $i = 1, \dots, n$ gilt

$$f(x) := \sum_{i=1}^{n} g_i(x) \Rightarrow f'(x) = \sum_{i=1}^{n} g_i'(x). \tag{6.20}$$

(Produktregel) Für differenzierbare Funktionen $g_1, g_2 : I \to \mathbb{R}$ gilt

$$f(x) := g_1(x)g_2(x) \Rightarrow f'(x) = g_1'(x)g_2(x) + g_1(x)g_2'(x). \tag{6.21}$$

(Quotientenregel) Für differenzierbare Funktionen $g_1, g_2 : I \to \mathbb{R}$ gilt an allen Stellen mit $g_2(x) \neq 0$

$$f(x) := \frac{g_1(x)}{g_2(x)} \Rightarrow f'(x) = \frac{g_1'(x)g_2(x) - g_1(x)g_2'(x)}{g_2(x)^2}. \tag{6.22}$$

(Kettenregel) Für differenzierbare Funktionen $g_2 : I \to J$ und $g_1 : J \to \mathbb{R}$ gilt

$$f(x) := g_1(g_2(x)) \Rightarrow f'(x) = g_1'(g_2(x))g_2'(x). \tag{6.23}$$

∘

Beispiel 6.3 (Summenregel)**.** Es sei

$$f : \mathbb{R} \to \mathbb{R}, x \mapsto f(x) := 4x^3 + 3x^2 \tag{6.24}$$

Dann hat f die Form

$$f(x) = \sum_{i=1}^{2} g_i(x) = g_1(x) + g_2(x) \text{ mit } g_1(x) := 4x^3 \text{ und } g_2(x) := 3x^2. \tag{6.25}$$

Es gelten außerdem

$$g_1'(x) = \frac{d}{dx}\left(4x^3\right) = 12x^2 \text{ und } g_2'(x) = \frac{d}{dx}\left(3x^2\right) = 6x. \tag{6.26}$$

Also gilt mit der Summenregel

$$f'(x) = \sum_{i=1}^{2} g_i'(x) = g_1'(x) + g_2'(x) = 12x^2 + 6x. \tag{6.27}$$

△

Beispiel 6.4 (Produktregel)**.** Es sei

$$f :]0, \infty[\to \mathbb{R},\ x \mapsto f(x) := x^2 \ln(x). \tag{6.28}$$

Dann hat f die Form

$$f(x) = g_1(x)g_2(x) \text{ mit } g_1(x) := x^2 \text{ und } g_2(x) := \ln(x). \tag{6.29}$$

Es gelten außerdem

$$g_1'(x) = \frac{d}{dx}\left(x^2\right) = 2x \text{ und } g_2'(x) = \frac{d}{dx}\left(\ln(x)\right) = \frac{1}{x}. \tag{6.30}$$

Also gilt mit der Produktregel

$$f'(x) = g_1'(x)g_2(x) + g_1(x)g_2'(x) = 2x\ln(x) + x^2\frac{1}{x} = 2x\ln(x) + x. \tag{6.31}$$

△

Beispiel 6.5 (Quotientenregel)**.** Es sei

$$f : \mathbb{R} \to \mathbb{R} \setminus -1, x \mapsto f(x) := \frac{x^2}{x+1}. \tag{6.32}$$

Dann hat f die Form

$$f(x) = \frac{g_1(x)}{g_2(x)} \text{ mit } g_1(x) := x^2 \text{ und } g_2(x) := x + 1. \tag{6.33}$$

Es gelten außerdem

$$g_1'(x) = \frac{d}{dx}\left(x^2\right) = 2x \text{ und } g_2'(x) = \frac{d}{dx}\left(1 + x\right) = 1. \tag{6.34}$$

Also gilt mit der Quotientenregel

$$f'(x) = \frac{g_1'(x)g_2(x) - g_1(x)g_2'(x)}{g_2^2(x)} = \frac{2x(x+1) - x^2}{(x+1)^2} = \frac{2x^2 + 2x - x^2}{(x+1)^2} = \frac{x^2 + 2x}{(x+1)^2}. \tag{6.35}$$

△

Beispiel 6.6 (Kettenregel)**.** Es sei

$$f : \mathbb{R} \to \mathbb{R}, x \mapsto f(x) := \exp\left(-x^2\right) \tag{6.36}$$

Dann hat f die Form

$$f(x) = g_1(g_2(x)) \text{ mit } g_1(x) := \exp(x) \text{ und } g_2(x) := -x^2 \tag{6.37}$$

Es gelten außerdem

$$g_1'(x) = \frac{d}{dx}\left(\exp(x)\right) = \exp(x) \text{ und } g_2'(x) = \frac{d}{dx}\left(-x^2\right) = -2x. \tag{6.38}$$

Also gilt mit der Kettenregel

$$f'(x) = g_1'(g_2(x))g_2'(x) = \exp\left(-x^2\right)(-2x) = -2x\exp\left(-x^2\right). \tag{6.39}$$

Man kann sich die resultierende Ableitung der Kettenregel also merken als “Die Ableitung der äußeren Funktion an der Stelle der inneren Funktion mal die Ableitung der inneren Funktion.”

△

6.2. Analytische Optimierung

Eine wichtige Anwendung der Differenzialrechnung ist das Bestimmen von Extremstellen von Funktionen. Dabei geht es im Kern um die Frage, für welche Werte ihrer Definitionsmenge eine Funktion ein Maximum oder ein Minimum annimmt. Bei einfachen Funktionen ist dies analytisch möglich. Die generelle Vorgehensweise dabei ist oft auch unter dem Stichwort “Kurvendiskussion” bekannt. In der Anwendung ist ein analytisches Vorgehen zur Optimierung von Funktionen meist nicht möglich und es werden numerische Algorithmen zur Bestimmung von Extremstellen genutzt. Ein Verständnis dieser Algorithmen setzt allerdings ein Verständnis der Prinzipien der analytischen Optimierung voraus. In diesem Abschnitt geben wir eine Einführung in die analytische Optimierung von univariaten reellwertigen Funktionen. Wir beginnen damit, die Begriffe der erwähnten Maxima und Minima von univariaten reellwertigen Funktionen zu präzisieren.

Definition 6.4 (Extremstellen und Extremwerte)**.** Es seien $I \subseteq \mathbb{R}$ und $f : I \to \mathbb{R}$ eine univariate reellwertige Funktion. f hat an der Stelle $x_0 \in I$

- ein *lokales Minimum*, wenn es eine offene Umgebung $U :=]a, b[$ von x_0 gibt mit

$$f(x_0) \leq f(x) \text{ für alle } x \in U \cap I, \tag{6.40}$$

- ein *globales Minimum*, wenn gilt, dass

$$f(x_0) \leq f(x) \text{ für alle } x \in I, \tag{6.41}$$

- ein *lokales Maximum*, wenn es eine offene Umgebung $U :=]a, b[$ von x_0 gibt mit

$$f(x_0) \geq f(x) \text{ für alle } x \in U \cap I, \tag{6.42}$$

- ein *globales Maximum*, wenn gilt, dass

$$f(x_0) \geq f(x) \text{ für alle } x \in I. \tag{6.43}$$

Der Wert $x_0 \in I$ der Definitionsmenge von f heißt entsprechend *lokale* oder *globale Minimalstelle* oder *Maximalstelle*, der Funktionswert $f(x_0) \in \mathbb{R}$ heißt entsprechend *lokales* oder *globales Minimum* oder *Maximum*. Generell heißt der Wert $x_0 \in I$ *Extremstelle* und der Funktionswert $f(x_0) \in \mathbb{R}$ *Extremwert*.

Ein lokales Minimum beziehungsweise Maximum heißt *strikt*, wenn es eine offene Umgebung $U :=]a, b[$ von x_0 gibt, sodass für alle $x \in U \cap I$ mit $x \neq x_0$ die strikte Ungleichung $f(x_0) < f(x)$ beziehungsweise $f(x_0) > f(x)$ gilt.

Minimalstellen und Maximalstellen werden auch mit

$$\arg\min_{x \in I} f(x) \text{ beziehungsweise } \arg\max_{x \in I} f(x) \tag{6.44}$$

bezeichnet. Diese Ausdrücke bezeichnen die Mengen der globalen Minimalstellen beziehungsweise Maximalstellen. Die zugehörigen Extremwerte werden mit

$$\min_{x \in I} f(x) \text{ beziehungsweise } \max_{x \in I} f(x) \tag{6.45}$$

bezeichnet.

•

Abbildung 6.4 visualisiert die verschiedenen Arten von Extremwerten nach Definition 6.4.

Die analytische Optimierung von univariaten reellwertigen Funktionen basiert auf den sogenannten *notwendigen* und *hinreichenden Bedingungen für Extrema*. Erstere machen eine Aussage über das Verhalten der ersten Ableitung einer Funktion an einer Extremstelle. Letztere machen eine Aussage über das Verhalten einer Funktion an einer Stelle, die bestimmten Forderungen an ihre erste und zweite Ableitung genügt.

Theorem 6.3 (Notwendige Bedingung für Extrema)**.** *Es sei $I \subseteq \mathbb{R}$ ein offenes Intervall und $f : I \to \mathbb{R}$ eine differenzierbare Funktion. Ist $x_0 \in I$ eine lokale Extremstelle von f, so gilt*

$$f'(x_0) = 0. \tag{6.46}$$

∘

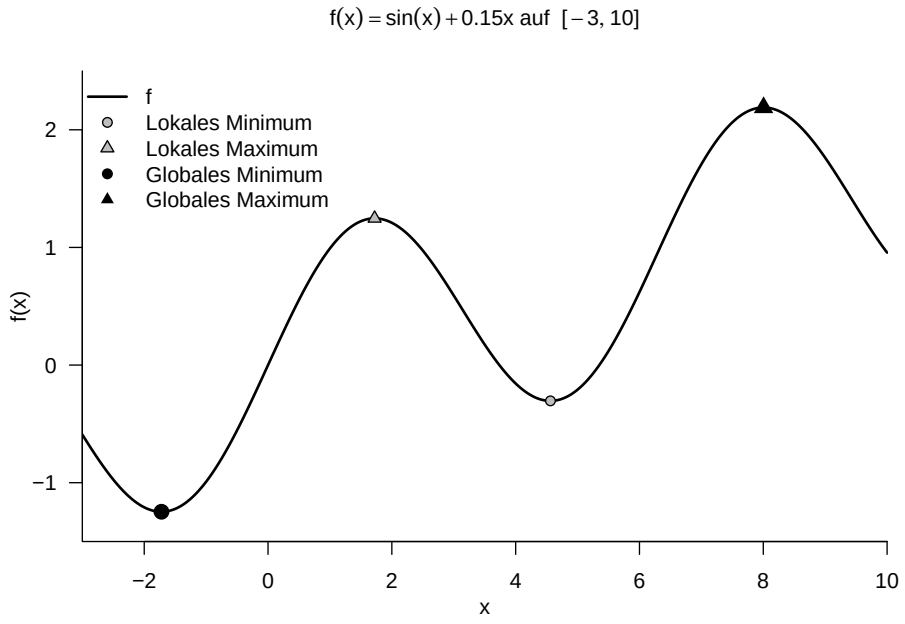


Abbildung 6.4. Extremstellen einer Funktion.

Unter den Voraussetzungen des Theorems ist die erste Ableitung an jeder lokalen Extremstelle null. Die Umkehrung gilt nicht: Für $f(x) := x^3$ gilt $f'(0) = 0$, obwohl 0 keine Extremstelle ist.

Theorem 6.4 (Hinreichende Bedingungen für lokale Extrema)**.** *Es sei $I \subseteq \mathbb{R}$ ein offenes Intervall und $f : I \to \mathbb{R}$ eine zweimal differenzierbare Funktion. Für $x_0 \in I$ gelten folgende Aussagen:*

- *Wenn $f'(x_0) = 0$ und $f''(x_0) > 0$ gelten, dann hat f in x_0 ein striktes lokales Minimum.*
- *Wenn $f'(x_0) = 0$ und $f''(x_0) < 0$ gelten, dann hat f in x_0 ein striktes lokales Maximum.*

∘

Wir verzichten wiederum auf einen Beweis und verdeutlichen uns die Bedingung an dem in Abbildung 6.5 gezeigten Beispiel. Hier ist offenbar $x_0 = 1$ eine lokale Minimalstelle von $f(x) = (x-1)^2$. Man erkennt: links von x_0 fällt f ab, rechts von x_0 steigt f an. In x_0 steigt f weder an noch fällt f ab, also ist $f'(x_0) = 0$. Weiter gilt, dass links und rechts von x_0 und in x_0 die Änderung f'' von f' positiv ist: links von x_0 schwächt sich die Negativität von f' zu 0 ab und rechts von x_0 verstärkt sich die Positivität von f'.

Insbesondere die hinreichenden Bedingungen für lokale Extrema legen folgendes *Standardverfahren* zur Bestimmung von lokalen Extremstellen nahe.

Theorem 6.5 (Standardverfahren der analytischen Optimierung)**.** *Es sei $I \subseteq \mathbb{R}$ ein offenes Intervall und $f : I \to \mathbb{R}$ eine zweimal differenzierbare Funktion. Zur Untersuchung lokaler Extremstellen dient folgendes* Standardverfahren der analytischen Optimierung*:*

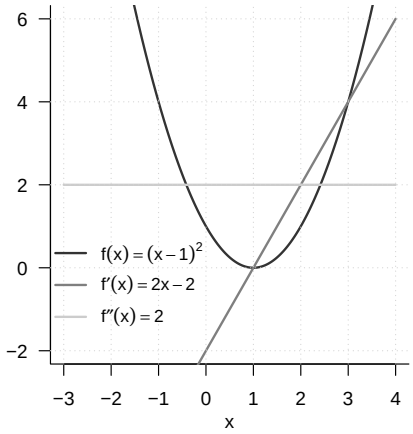


Abbildung 6.5. Analytische Optimierung von $f(x) := (x-1)^2$

- *Berechnen der ersten und zweiten Ableitung von f.*
- *Bestimmen aller Nullstellen $x^* \in I$ von f' durch Lösen der Gleichung $f'(x^*) = 0$. Diese Nullstellen sind Kandidaten für lokale Extremstellen.*
- *Auswerten von $f''(x^*)$: Bei $f''(x^*) > 0$ ist x^* eine strikte lokale Minimalstelle. Bei $f''(x^*) < 0$ ist x^* eine strikte lokale Maximalstelle. Bei $f''(x^*) = 0$ erlaubt dieses Kriterium keine Entscheidung.*

∘

Beispiel 6.7 (Analytische Optimierung einer Quadratfunktion)**.** Anstelle eines Beweises betrachten wir beispielhaft die Funktion

$$f : \mathbb{R} \to \mathbb{R}, x \mapsto f(x) := (x-1)^2. \tag{6.47}$$

Die erste Ableitung von f aus Abbildung 6.5 ergibt sich mit der Kettenregel zu

$$f'(x) = \frac{d}{dx}\left((x-1)^2\right) = 2(x-1) \cdot \frac{d}{dx}(x-1) = 2x - 2. \tag{6.48}$$

Die zweite Ableitung von f ergibt sich zu

$$f''(x) = \frac{d}{dx}f'(x) = \frac{d}{dx}(2x-2) = 2 > 0 \text{ für alle } x \in \mathbb{R}. \tag{6.49}$$

Auflösen von $f'(x^*) = 0$ nach x^* ergibt

$$f'(x^*) = 0 \Leftrightarrow 2x^* - 2 = 0 \Leftrightarrow 2x^* = 2 \Leftrightarrow x^* = 1. \tag{6.50}$$

$x^* = 1$ ist folglich eine Minimalstelle von f mit zugehörigem Minimalwert $f(1) = 0$.

△

6.3. Differenzialrechnung multivariater reellwertiger Funktionen

Wir erinnern zunächst an den Begriff der multivariaten reellwertigen Funktion.

Definition 6.5 (Multivariate reellwertige Funktion)**.** Eine Funktion der Form

$$f : \mathbb{R}^n \to \mathbb{R}, x \mapsto f(x) = f(x_1, ..., x_n) \tag{6.51}$$

heißt *multivariate reellwertige* Funktion.

•

Die Argumente multivariater reellwertiger Funktionen sind also reelle n-Tupel der Form $x := (x_1, ..., x_n)$, während ihre Funktionswerte reelle Zahlen sind. Ein Beispiel für eine multivariate reellwertige Funktion mit $n := 2$ ist

$$f : \mathbb{R}^2 \to \mathbb{R}, x \mapsto f(x) := x_1^2 + x_2^2. \tag{6.52}$$

Wir visualisieren diese Funktion in Abbildung 6.6. Dabei zeigt die rechte Abbildung eine Darstellung mithilfe sogenannter *Isokonturen*, also Linien im Definitionsbereich der Funktion, für die die Funktion identische Werte annimmt. Die entsprechenden Werte sind für ausgewählte Isokonturen in der Abbildung vermerkt.

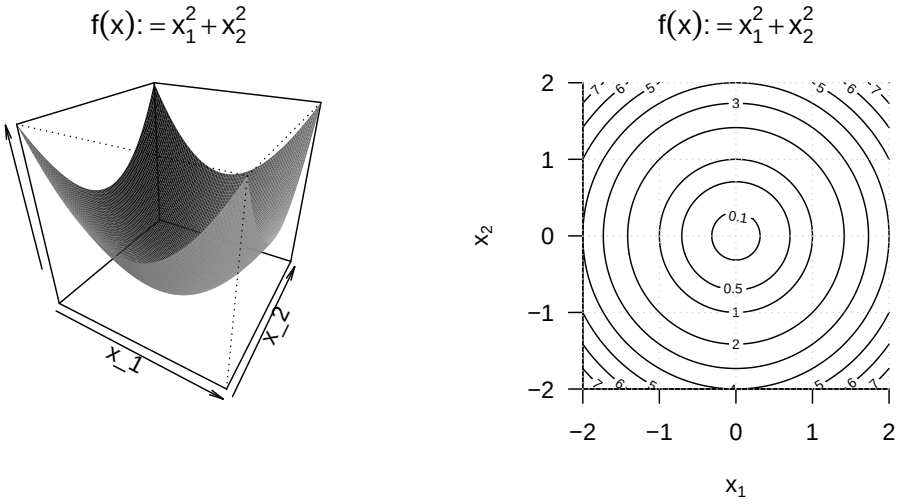


Abbildung 6.6. Visualisierungen einer bivariaten Funktion. Die linke Darstellung visualisiert die Funktionswerte als Fläche über der zweidimensionalen Definitionsmenge der Funktion. Auch wenn diese Darstellung einen gewissen dreidimensionalen Charakter hat, handelt es sich um eine bivariate Funktion mit entsprechend zweidimensionaler Definitionsmenge. Die rechte Abbildung visualisiert Linien mit gleichen Funktionswerten in der zweidimensionalen Definitionsmenge der Funktion.

Wir wollen nun beginnen, die Begriffe der Differenzierbarkeit und der Ableitung univariater reellwertiger Funktionen auf den Fall multivariater reellwertiger Funktionen zu erweitern. Dazu führen wir zunächst die Begriffe der *partiellen Differenzierbarkeit* und der *partiellen Ableitung* ein.

Definition 6.6 (Partielle Differenzierbarkeit und partielle Ableitung)**.** Es sei $D \subseteq \mathbb{R}^n$ offen, $n \in \mathbb{N}$ und $f : D \to \mathbb{R}$ eine multivariate reellwertige Funktion. Für $i \in \{1, ..., n\}$ bezeichne e_i den i-ten kanonischen Einheitsvektor. Die Funktion f heißt *nach* x_i *partiell differenzierbar in* $a \in D$, wenn der Grenzwert

$$\frac{\partial}{\partial x_i} f(a) := \lim_{h \to 0} \frac{f(a + he_i) - f(a)}{h} \tag{6.53}$$

als reelle Zahl existiert. Dabei gilt $h \neq 0$ und $a + he_i \in D$. Dieser Wert heißt *partielle Ableitung von f nach x_i an der Stelle a*. Existiert er für alle $a \in D$, so heißt f *nach x_i partiell differenzierbar auf D*, und die Funktion

$$\frac{\partial}{\partial x_i} f : D \to \mathbb{R}, x \mapsto \frac{\partial}{\partial x_i} f(x) \tag{6.54}$$

heißt *partielle Ableitung von f nach x_i*. Die Funktion f heißt *partiell differenzierbar in a*, wenn alle n partiellen Ableitungen in a existieren. Sie heißt *partiell differenzierbar auf D*, wenn dies für alle $a \in D$ gilt.

•

In Definition 6.6 bezeichnet $e_i \in \mathbb{R}^n$ den i-ten kanonischen Einheitsvektor, für den gilt, dass $(e_i)_j = 1$ für $i = j$ und $(e_i)_j = 0$ für $i \neq j$ mit $j = 1, ..., n$ (vgl. den Abschnitt über kanonische Einheitsvektoren im Kapitel Vektoren). In Analogie und Verallgemeinerung zum Newtonschen Differenzquotienten misst der hier auftretende Differenzquotient

$$\frac{f(x + he_i) - f(x)}{h} \tag{6.55}$$

damit die Änderung $f(x+he_i)-f(x)$ von f pro Strecke h in Richtung e_i. Wir visualisieren die Bestandteile dieses Quotienten im Falle einer bivariaten Funktion in Abbildung 6.7.

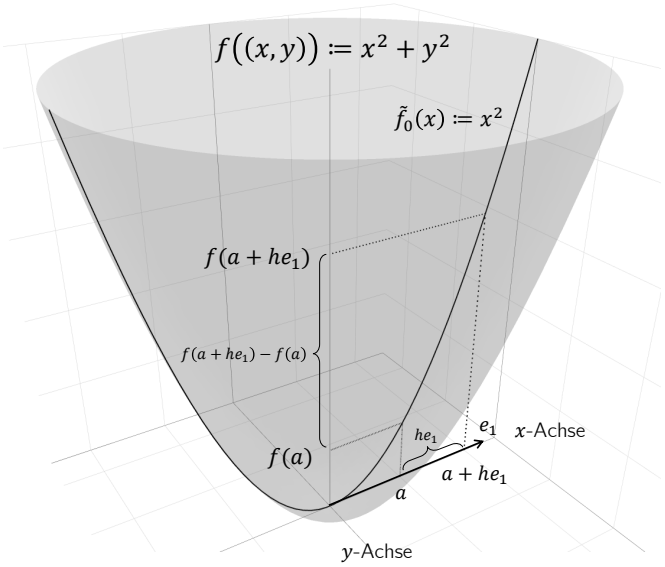


Abbildung 6.7. Komponenten des partiellen Newtonschen Differenzquotienten

Für $h \to 0$ misst der Differenzquotient entsprechend die *Änderungsrate* von f in x in Richtung e_i. Wie bei der Betrachtung von Ableitungen gilt, dass $\frac{\partial}{\partial x_i} f(x)$ eine Zahl, $\frac{\partial}{\partial x_i} f$ dagegen eine Funktion ist. Praktisch berechnet man $\frac{\partial}{\partial x_i} f$ als die (einfache) Ableitung

$$\frac{d}{dx_i} \tilde{f}_{x_1,...,x_{i-1},x_{i+1},...,x_n}(x_i) \tag{6.56}$$

der univariaten reellwertigen Funktion

$$\tilde{f} : \mathbb{R} \to \mathbb{R}, x_i \mapsto \tilde{f}_{x_1,...,x_{i-1},x_{i+1},...,x_n}(x_i) := f(x_1, ..., x_i, ..., x_n). \tag{6.57}$$

Man betrachtet für die i-te partielle Ableitung also alle x_j mit $j \neq i$ als Konstanten und ist auf das gewohnte Berechnen von Ableitungen von univariaten reellwertigen Funktionen geführt. Wir wollen das Vorgehen zum Berechnen von partiellen Ableitungen an einem ersten Beispiel verdeutlichen.

Beispiel 6.8 (Partielle Ableitungen einer quadratischen Funktion)**.** Wir betrachten die Funktion

$$f : \mathbb{R}^2 \to \mathbb{R}, x \mapsto f(x) := x_1^2 + x_2^2. \tag{6.58}$$

Weil die Definitionsmenge dieser Funktion zweidimensional ist, kann man zwei partielle Ableitungen berechnen

$$\frac{\partial}{\partial x_1} f : \mathbb{R}^2 \to \mathbb{R}, x \mapsto \frac{\partial}{\partial x_1} f(x) \text{ und } \frac{\partial}{\partial x_2} f : \mathbb{R}^2 \to \mathbb{R}, x \mapsto \frac{\partial}{\partial x_2} f(x). \tag{6.59}$$

Um die erste dieser partiellen Ableitungen zu berechnen, betrachtet man die Funktion

$$f_{x_2} : \mathbb{R} \to \mathbb{R}, x_1 \mapsto f_{x_2}(x_1) := x_1^2 + x_2^2, \tag{6.60}$$

wobei x_2 hier die Rolle einer Konstanten einnimmt. Um explizit zu machen, dass x_2 kein Argument der Funktion ist, die Funktion aber weiterhin von x_2 abhängt, haben wir die Subskriptnotation $f_{x_2}(x_1)$ verwendet. Um nun die partielle Ableitung zu berechnen, berechnen wir die (einfache) Ableitung von f_{x_2},

$$f'_{x_2}(x_1) = 2x_1. \tag{6.61}$$

Es ergibt sich also

$$\frac{\partial}{\partial x_1} f : \mathbb{R}^2 \to \mathbb{R}, x \mapsto \frac{\partial}{\partial x_1} f(x) = \frac{\partial}{\partial x_1}(x_1^2 + x_2^2) = f'_{x_2}(x_1) = 2x_1. \tag{6.62}$$

Analog gilt mit der entsprechenden Formulierung von f_{x_1}, dass

$$\frac{\partial}{\partial x_2} f : \mathbb{R}^2 \to \mathbb{R}, x \mapsto \frac{\partial}{\partial x_2} f(x) = \frac{\partial}{\partial x_2}(x_1^2 + x_2^2) = f'_{x_1}(x_2) = 2x_2. \tag{6.63}$$

△

Wie bei der Ableitung einer univariaten reellwertigen Funktion ist es auch für eine multivariate reellwertige Funktion möglich, rekursiv eine höhere Ableitung zu definieren.

Definition 6.7 (Zweite partielle Ableitungen)**.** Es sei $D \subseteq \mathbb{R}^n$ offen und $f : D \to \mathbb{R}$ eine partiell differenzierbare Funktion. Für $i, j \in \{1, \dots, n\}$ sei die Funktion $\frac{\partial}{\partial x_i} f$ in $x \in D$ nach x_j partiell differenzierbar. Dann heißt

$$\frac{\partial^2}{\partial x_j \partial x_i} f(x) := \frac{\partial}{\partial x_j} \left(\frac{\partial}{\partial x_i} f \right)(x) \tag{6.64}$$

zweite partielle Ableitung von f zuerst nach x_i und dann nach x_j.

•

Man beachte, dass es zu jeder partiellen Ableitung $\frac{\partial}{\partial x_i} f$ für $i = 1, ..., n$ insgesamt n zweite partielle Ableitungen $\frac{\partial^2}{\partial x_j \partial x_i} f$ für $j = 1, ..., n$ gibt. Die so resultierenden n^2 zweiten partiellen Ableitungen sind jedoch nicht alle verschieden. Dies ist eine wesentliche Aussage des *Satzes von Schwarz*.

Theorem 6.6 (Satz von Schwarz)**.** *Es sei $D \subseteq \mathbb{R}^n$ offen und $f : D \to \mathbb{R}$ eine Funktion, deren zweite partielle Ableitungen auf D existieren und stetig sind. Dann gilt für alle $x \in D$ und $i, j \in \{1, \dots, n\}$*

$$\frac{\partial^2}{\partial x_j \partial x_i} f(x) = \frac{\partial^2}{\partial x_i \partial x_j} f(x). \tag{6.65}$$

∘

Für einen Beweis verweisen wir auf die weiterführende Literatur. Der Satz von Schwarz besagt insbesondere auch, dass bei Bildung der zweiten partiellen Ableitungen die Reihenfolge des partiellen Ableitens irrelevant ist. Der Satz erleichtert auf diese Weise die Berechnung von zweiten partiellen Ableitungen und hilft darüber hinaus, analytische Fehler bei der Berechnung zweiter partieller Ableitungen aufzudecken. Wir verdeutlichen dies in Fortführung obigen Beispiels.

Beispiel 6.9 (Partielle Ableitungen zweiter Ordnung einer quadratischen Funktion)**.** Wir wollen die partiellen Ableitungen zweiter Ordnung der Funktion

$$f : \mathbb{R}^2 \to \mathbb{R}, x \mapsto f(x) := x_1^2 + x_2^2 \tag{6.66}$$

berechnen. Mit den Ergebnissen für die partiellen Ableitungen erster Ordnung dieser Funktion ergibt sich

$$\begin{aligned}
\frac{\partial^2}{\partial x_1 \partial x_1} f(x) &= \frac{\partial}{\partial x_1}\left(\frac{\partial}{\partial x_1} f(x)\right) = \frac{\partial}{\partial x_1}(2x_1) = 2 \\
\frac{\partial^2}{\partial x_1 \partial x_2} f(x) &= \frac{\partial}{\partial x_1}\left(\frac{\partial}{\partial x_2} f(x)\right) = \frac{\partial}{\partial x_1}(2x_2) = 0 \\
\frac{\partial^2}{\partial x_2 \partial x_1} f(x) &= \frac{\partial}{\partial x_2}\left(\frac{\partial}{\partial x_1} f(x)\right) = \frac{\partial}{\partial x_2}(2x_1) = 0 \\
\frac{\partial^2}{\partial x_2 \partial x_2} f(x) &= \frac{\partial}{\partial x_2}\left(\frac{\partial}{\partial x_2} f(x)\right) = \frac{\partial}{\partial x_2}(2x_2) = 2
\end{aligned} \tag{6.67}$$

Offenbar gilt

$$\frac{\partial^2}{\partial x_1 \partial x_2} f(x) = \frac{\partial^2}{\partial x_2 \partial x_1} f(x). \tag{6.68}$$

△

Beispiel 6.10 (Partielle Ableitungen einer Funktion mit drei Variablen)**.** Als weiteres Beispiel wollen wir die partiellen Ableitungen erster und zweiter Ordnung der Funktion

$$f : \mathbb{R}^2 \times]0, \infty[\to \mathbb{R}, x \mapsto f(x) := x_1^2 + x_1 x_2 + x_2 \sqrt{x_3} \tag{6.69}$$

berechnen. Mit den Rechenregeln für Ableitungen ergibt sich für die partiellen Ableitungen erster Ordnung

$$\begin{aligned}
\frac{\partial}{\partial x_1} f(x) &= \frac{\partial}{\partial x_1}\left(x_1^2 + x_1 x_2 + x_2 \sqrt{x_3}\right) = 2x_1 + x_2, \\
\frac{\partial}{\partial x_2} f(x) &= \frac{\partial}{\partial x_2}\left(x_1^2 + x_1 x_2 + x_2 \sqrt{x_3}\right) = x_1 + \sqrt{x_3}, \\
\frac{\partial}{\partial x_3} f(x) &= \frac{\partial}{\partial x_3}\left(x_1^2 + x_1 x_2 + x_2 \sqrt{x_3}\right) = \frac{x_2}{2\sqrt{x_3}}.
\end{aligned} \tag{6.70}$$

Für die zweiten partiellen Ableitungen hinsichtlich x_1 ergibt sich

$$\begin{aligned}
\frac{\partial^2}{\partial x_1 \partial x_1} f(x) &= \frac{\partial}{\partial x_1}\left(\frac{\partial}{\partial x_1} f(x)\right) = \frac{\partial}{\partial x_1}(2x_1 + x_2) = 2, \\
\frac{\partial^2}{\partial x_2 \partial x_1} f(x) &= \frac{\partial}{\partial x_2}\left(\frac{\partial}{\partial x_1} f(x)\right) = \frac{\partial}{\partial x_2}(2x_1 + x_2) = 1, \\
\frac{\partial^2}{\partial x_3 \partial x_1} f(x) &= \frac{\partial}{\partial x_3}\left(\frac{\partial}{\partial x_1} f(x)\right) = \frac{\partial}{\partial x_3}(2x_1 + x_2) = 0.
\end{aligned} \tag{6.71}$$

Für die zweiten partiellen Ableitungen hinsichtlich x_2 ergibt sich

$$\begin{aligned}
\frac{\partial^2}{\partial x_1 \partial x_2} f(x) &= \frac{\partial}{\partial x_1}\left(\frac{\partial}{\partial x_2} f(x)\right) = \frac{\partial}{\partial x_1}(x_1 + \sqrt{x_3}) = 1, \\
\frac{\partial^2}{\partial x_2 \partial x_2} f(x) &= \frac{\partial}{\partial x_2}\left(\frac{\partial}{\partial x_2} f(x)\right) = \frac{\partial}{\partial x_2}(x_1 + \sqrt{x_3}) = 0, \\
\frac{\partial^2}{\partial x_3 \partial x_2} f(x) &= \frac{\partial}{\partial x_3}\left(\frac{\partial}{\partial x_2} f(x)\right) = \frac{\partial}{\partial x_3}(x_1 + \sqrt{x_3}) = \frac{1}{2\sqrt{x_3}}.
\end{aligned} \tag{6.72}$$

Für die zweiten partiellen Ableitungen hinsichtlich x_3 ergibt sich

$$\begin{aligned}
\frac{\partial^2}{\partial x_1 \partial x_3} f(x) &= \frac{\partial}{\partial x_1}\left(\frac{\partial}{\partial x_3} f(x)\right) = \frac{\partial}{\partial x_1}\left(\frac{x_2}{2\sqrt{x_3}}\right) = 0, \\
\frac{\partial^2}{\partial x_2 \partial x_3} f(x) &= \frac{\partial}{\partial x_2}\left(\frac{\partial}{\partial x_3} f(x)\right) = \frac{\partial}{\partial x_2}\left(\frac{x_2}{2\sqrt{x_3}}\right) = \frac{1}{2\sqrt{x_3}}, \\
\frac{\partial^2}{\partial x_3 \partial x_3} f(x) &= \frac{\partial}{\partial x_3}\left(\frac{\partial}{\partial x_3} f(x)\right) = \frac{\partial}{\partial x_3}\left(x_2 \frac{1}{2} x_3^{-\frac{1}{2}}\right) = -\frac{1}{4} x_2 x_3^{-\frac{3}{2}}.
\end{aligned} \tag{6.73}$$

Weiterhin erkennt man, dass die Reihenfolge der partiellen Ableitungen irrelevant ist, denn es gilt

$$\begin{aligned}
\frac{\partial^2}{\partial x_1 \partial x_2} f(x) &= \frac{\partial^2}{\partial x_2 \partial x_1} f(x) = 1, \\
\frac{\partial^2}{\partial x_1 \partial x_3} f(x) &= \frac{\partial^2}{\partial x_3 \partial x_1} f(x) = 0, \\
\frac{\partial^2}{\partial x_2 \partial x_3} f(x) &= \frac{\partial^2}{\partial x_3 \partial x_2} f(x) = \frac{1}{2\sqrt{x_3}}.
\end{aligned} \tag{6.74}$$

△

Wie oben gesehen gibt es für eine multivariate reellwertige Funktion $f : \mathbb{R}^n \to \mathbb{R}$ insgesamt n erste partielle Ableitungen und n^2 zweite partielle Ableitungen. Diese werden im *Gradienten* und der *Hesse-Matrix* einer multivariaten reellwertigen Funktion zusammengefasst.

Definition 6.8 (Gradient)**.** Es sei $D \subseteq \mathbb{R}^n$ offen und $f : D \to \mathbb{R}$ eine partiell differenzierbare Funktion. Dann ist der *Gradient* $\nabla f(x)$ von f an der Stelle $x \in D$ definiert als

$$\nabla f(x) := \begin{pmatrix} \frac{\partial}{\partial x_1} f(x) \\ \frac{\partial}{\partial x_2} f(x) \\ \vdots \\ \frac{\partial}{\partial x_n} f(x) \end{pmatrix} \in \mathbb{R}^n. \tag{6.75}$$

•

Man beachte, dass Gradienten multivariate vektorwertige Funktionen der Form

$$\nabla f : D \to \mathbb{R}^n, x \mapsto \nabla f(x) \tag{6.76}$$

sind. Für $n = 1$ gilt $\nabla f(x) = f'(x)$. Eine wichtige Eigenschaft des Gradienten ist, dass $-\nabla f(x)$ die Richtung des steilsten Abstiegs von f in $\mathbb{R}^n$ anzeigt. Diese Einsicht ist aber nicht trivial und soll an späterer Stelle vertieft werden. Als Beispiele betrachten wir die Gradienten der oben analysierten Funktionen.

Beispiel 6.11 (Gradient einer quadratischen Funktion)**.** Für die in Gleichung 6.66 betrachtete Funktion $f : \mathbb{R}^2 \to \mathbb{R}$ gilt

$$\nabla f(x) := \begin{pmatrix} \frac{\partial}{\partial x_1} f(x) \\ \frac{\partial}{\partial x_2} f(x) \end{pmatrix} = \begin{pmatrix} 2x_1 \\ 2x_2 \end{pmatrix} \in \mathbb{R}^2. \tag{6.77}$$

In Abbildung 6.8 visualisieren wir farbkodiert ausgewählte Werte dieses Gradienten für $(0.7, 0.7)^T$, $(-0.3, 0.1)^T$, $(-0.5, -0.4)^T$ und $(0.1, -1.0)^T$.

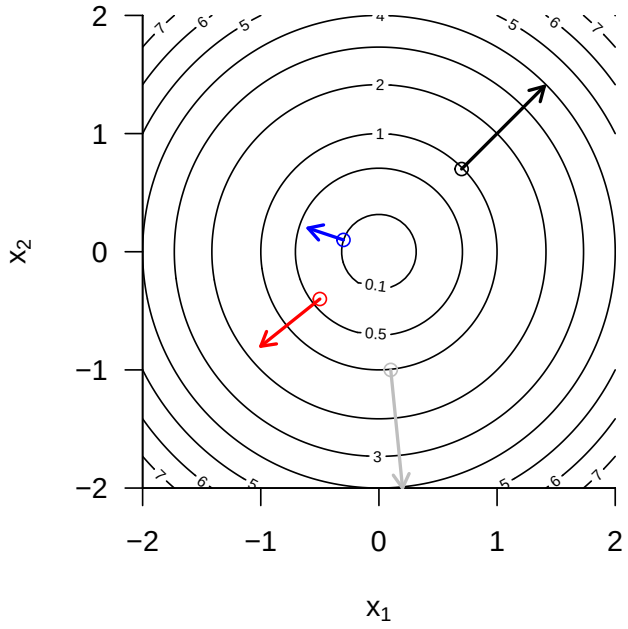


Abbildung 6.8. Exemplarische Gradientenwerte der bivariaten Funktion $f(x) = x_1^2 + x_2^2$.

△

Beispiel 6.12 (Gradient einer Funktion mit drei Variablen)**.** Für die in Gleichung 6.69 betrachtete Funktion $f : \mathbb{R}^2 \times]0, \infty[\to \mathbb{R}$ gilt

$$\nabla f(x) := \begin{pmatrix} \frac{\partial}{\partial x_1} f(x) \\ \frac{\partial}{\partial x_2} f(x) \\ \frac{\partial}{\partial x_3} f(x) \end{pmatrix} = \begin{pmatrix} 2x_1 + x_2 \\ x_1 + \sqrt{x_3} \\ \frac{x_2}{2\sqrt{x_3}} \end{pmatrix} \in \mathbb{R}^3. \tag{6.78}$$

△

Schließlich widmen wir uns der Zusammenfassung der zweiten partiellen Ableitungen einer multivariaten reellwertigen Funktion in der *Hesse-Matrix*.

Definition 6.9 (Hesse-Matrix)**.** Es sei $D \subseteq \mathbb{R}^n$ offen und $f : D \to \mathbb{R}$ eine Funktion, deren zweite partielle Ableitungen auf D existieren. Dann ist die *Hesse-Matrix* $\nabla^2 f(x)$ von f an der Stelle $x \in D$ definiert als

$$\nabla^2 f(x) := \begin{pmatrix} \frac{\partial^2}{\partial x_1 \partial x_1} f(x) & \frac{\partial^2}{\partial x_1 \partial x_2} f(x) & \cdots & \frac{\partial^2}{\partial x_1 \partial x_n} f(x) \\ \frac{\partial^2}{\partial x_2 \partial x_1} f(x) & \frac{\partial^2}{\partial x_2 \partial x_2} f(x) & \cdots & \frac{\partial^2}{\partial x_2 \partial x_n} f(x) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2}{\partial x_n \partial x_1} f(x) & \frac{\partial^2}{\partial x_n \partial x_2} f(x) & \cdots & \frac{\partial^2}{\partial x_n \partial x_n} f(x) \end{pmatrix} \in \mathbb{R}^{n \times n}. \tag{6.79}$$

•

Man beachte, dass Hesse-Matrizen multivariate matrixwertige Abbildungen der Form

$$\nabla^2 f : D \to \mathbb{R}^{n \times n}, x \mapsto \nabla^2 f(x) \tag{6.80}$$

sind. Für $n = 1$ gilt $\nabla^2 f(x) = f''(x)$. Unter den Voraussetzungen des Satzes von Schwarz folgt aus

$$\frac{\partial^2}{\partial x_i \partial x_j} f(x) = \frac{\partial^2}{\partial x_j \partial x_i} f(x) \text{ für } 1 \leq i, j \leq n \tag{6.81}$$

dass die Hesse-Matrix symmetrisch ist, dass also gilt

$$\left(\nabla^2 f(x)\right)^T = \nabla^2 f(x). \tag{6.82}$$

Beispiel 6.13 (Hesse-Matrix einer quadratischen Funktion)**.** Für die in Gleichung 6.66 betrachtete Funktion $f : \mathbb{R}^2 \to \mathbb{R}$ gilt

$$\nabla^2 f(x) := \begin{pmatrix} \frac{\partial^2}{\partial x_1 \partial x_1} f(x) & \frac{\partial^2}{\partial x_1 \partial x_2} f(x) \\ \frac{\partial^2}{\partial x_2 \partial x_1} f(x) & \frac{\partial^2}{\partial x_2 \partial x_2} f(x) \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} \in \mathbb{R}^{2 \times 2}. \tag{6.83}$$

Die Hesse-Matrix dieser Funktion ist also eine konstante Funktion, die nicht von x abhängt.

△

Beispiel 6.14 (Hesse-Matrix einer Funktion mit drei Variablen)**.** Für die in Gleichung 6.69 betrachtete Funktion $f : \mathbb{R}^2 \times]0, \infty[\to \mathbb{R}$ gilt

$$\nabla^2 f(x) := \begin{pmatrix} \frac{\partial^2}{\partial x_1 \partial x_1} f(x) & \frac{\partial^2}{\partial x_1 \partial x_2} f(x) & \frac{\partial^2}{\partial x_1 \partial x_3} f(x) \\ \frac{\partial^2}{\partial x_2 \partial x_1} f(x) & \frac{\partial^2}{\partial x_2 \partial x_2} f(x) & \frac{\partial^2}{\partial x_2 \partial x_3} f(x) \\ \frac{\partial^2}{\partial x_3 \partial x_1} f(x) & \frac{\partial^2}{\partial x_3 \partial x_2} f(x) & \frac{\partial^2}{\partial x_3 \partial x_3} f(x) \end{pmatrix} = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 0 & \frac{1}{2\sqrt{x_3}} \\ 0 & \frac{1}{2\sqrt{x_3}} & -\frac{1}{4} x_2 x_3^{-3/2} \end{pmatrix}. \tag{6.84}$$

Im Gegensatz zu Beispiel (1) ist die Hesse-Matrix der hier betrachteten Funktion keine konstante Funktion und ihr Wert hängt vom Wert des Funktionsarguments $x \in \mathbb{R}^2 \times]0, \infty[$ ab.

△

Selbstkontrollfragen

1. Geben Sie die Definition des Begriffs der Ableitung $f'(a)$ einer Funktion f an einer Stelle a wieder.
2. Geben Sie die Definition des Begriffs der Ableitung f' einer Funktion f wieder.
3. Erläutern Sie die Symbole $f'(x)$, $\dot{f}(x)$, $\frac{df(x)}{dx}$ und $\frac{d}{dx}f(x)$.
4. Geben Sie die Definition des Begriffs der zweiten Ableitung f'' einer Funktion f wieder.
5. Geben Sie die Summen-, Produkt-, Quotienten- und Kettenregel für Ableitungen wieder.
6. Geben Sie die Definition der Begriffe des globalen und lokalen Maximums/Minimums einer univariaten reellwertigen Funktion wieder.
7. Geben Sie die notwendige Bedingung für ein Extremum einer Funktion wieder.
8. Geben Sie die hinreichende Bedingung für ein lokales Extremum einer Funktion wieder.
9. Geben Sie das Standardverfahren der analytischen Optimierung wieder.
10. Geben Sie die Definition der partiellen Ableitung $\frac{\partial}{\partial x_i}f(a)$ einer Funktion f an einer Stelle a wieder.
11. Geben Sie die Definition der partiellen Ableitung $\frac{\partial}{\partial x_i}f$ einer Funktion f wieder.
12. Geben Sie die Definition der zweiten partiellen Ableitung $\frac{\partial^2}{\partial x_i \partial x_j}f$ einer Funktion f wieder.
13. Geben Sie den Satz von Schwarz wieder.
14. Geben Sie die Definition des Gradienten einer multivariaten reellwertigen Funktion wieder.
15. Geben Sie die Definition der Hesse-Matrix einer multivariaten reellwertigen Funktion wieder.

Lösungen

1. Siehe Definition 6.1.
2. Siehe Definition 6.1.
3. Siehe Definition 6.2.
4. Siehe Definition 6.3.
5. Siehe Theorem 6.2.
6. Siehe Definition 6.4.
7. Siehe Theorem 6.3.
8. Siehe Theorem 6.4.
9. Siehe Theorem 6.5.
10. Siehe Definition 6.6.
11. Siehe Definition 6.6.
12. Siehe Definition 6.7.
13. Siehe Theorem 6.6.
14. Siehe Definition 6.8.
15. Siehe Definition 6.9.

7. Integralrechnung

Dieses Kapitel gibt einen Überblick über zentrale Begriffe der Integralrechnung. Das Hauptaugenmerk liegt dabei durchgängig auf der Klärung von Begrifflichkeiten, ihrer mathematischen Symbolik und der durch sie vermittelten Intuition und weniger auf der konkreten Berechnung von Integralen.

Integrale kommen in der probabilistischen Datenanalyse bei der Definition von Wahrscheinlichkeitsdichtefunktionen (WDF), bei der Berechnung von Wahrscheinlichkeiten und bei der Beziehung zwischen WDF und kumulativen Verteilungsfunktionen (KVF) vor. Auch Erwartungswerte, Varianzen und Kovarianzen werden mithilfe von Integralen beschrieben. Im Mittelpunkt steht hier das aus der Schule bekannte Riemannintegral.

7.1. Unbestimmte Integrale

Wir beginnen mit der Definition des unbestimmten Integrals und dem Begriff der Stammfunktion.

Definition 7.1 (Unbestimmtes Integral und Stammfunktion)**.** Es sei $I \subseteq \mathbb{R}$ ein offenes Intervall und $f : I \to \mathbb{R}$ eine Funktion. Eine differenzierbare Funktion $F : I \to \mathbb{R}$ heißt *Stammfunktion von* f, wenn $F' = f$ gilt. Ist F eine Stammfunktion von f, so heißt die Menge aller Stammfunktionen

$$\{F + c | c \in \mathbb{R}\} \tag{7.1}$$

das *unbestimmte Integral von* f. Man schreibt dafür auch

$$\int f(x)\,dx = F(x) + c, \text{ mit } c \in \mathbb{R}. \tag{7.2}$$

Dabei heißt c *Integrationskonstante* und $f(x)$ *Integrand*.

•

Obige Definition besagt, dass die Ableitung der Stammfunktion einer Funktion f eben f ist. Das unbestimmte Integral einer Funktion f ist darüber hinaus die Menge *aller* durch Addition verschiedener Konstanten $c \in \mathbb{R}$ gegebenen Stammfunktionen von f. Eine solche Konstante $c \in \mathbb{R}$ heißt auch *Integrationskonstante*. Es gilt $\frac{d}{dx}c = 0$. Das Symbol $\int f(x)\,dx$ wird als $F(x) + c$ geschrieben. $f(x)$ wird in diesem Ausdruck *Integrand* genannt. $\int$ und dx haben keine eigentliche Bedeutung, sondern sind lediglich Symbole.

Für die in den vorherigen Abschnitten eingeführten elementaren Funktionen ergeben sich die in Tabelle 7.1 aufgelisteten Stammfunktionen. Man überzeugt sich davon durch Ableiten der jeweiligen Stammfunktion mithilfe der Rechenregeln der Differenzialrechnung. Die unbestimmten Integrale dieser elementaren Funktionen ergeben sich dann direkt aus diesen Stammfunktionen durch Addition einer Integrationskonstanten.

Theorem 7.1 (Stammfunktionen elementarer Funktionen)**.** *Für $k \in \mathbb{N}_0$ und reelle Koeffizienten $a_0, \ldots, a_k, a, b$ sind folgende Funktionen jeweils Stammfunktionen. Die Definitionsmenge ist $\mathbb{R}$, bei der Logarithmusfunktion $]0, \infty[$.*

Tabelle 7.1. Stammfunktionen elementarer Funktionen.

Name	*Funktion*	*Stammfunktion*
Polynomfunktion	$f(x) := \sum_{i=0}^{k} a_i x^i$	$F(x) = \sum_{i=0}^{k} \frac{a_i}{i+1} x^{i+1}$
Konstante Funktion	$f(x) := a$	$F(x) = ax$
Identitätsfunktion	$f(x) := x$	$F(x) = \frac{1}{2}x^2$
Linear-affine Funktion	$f(x) := ax + b$	$F(x) = \frac{1}{2}ax^2 + bx$
Quadratfunktion	$f(x) := x^2$	$F(x) = \frac{1}{3}x^3$
Exponentialfunktion	$f(x) := \exp(x)$	$F(x) = \exp(x)$
Logarithmusfunktion	$f(x) := \ln(x)$	$F(x) = x\ln(x) - x$

∘

Die in nachfolgendem Theorem zusammengestellten Rechenregeln sind oft hilfreich, um Stammfunktionen von Funktionen zu bestimmen, die sich aus Funktionen mit bekannten Stammfunktionen zusammensetzen.

Theorem 7.2 (Rechenregeln für Stammfunktionen)**.** *Es seien $I, J \subseteq \mathbb{R}$ offene Intervalle. Die folgenden Gleichheiten unbestimmter Integrale gelten bis auf additive Konstanten.*

(Summenregel) Besitzen $f, g : I \to \mathbb{R}$ Stammfunktionen, so gilt für $a, b \in \mathbb{R}$

$$\int (af(x) + bg(x))\,dx = a\int f(x)\,dx + b\int g(x)\,dx. \tag{7.3}$$

(Partielle Integration) Für stetig differenzierbare Funktionen $f, g : I \to \mathbb{R}$ gilt

$$\int f'(x)g(x)\,dx = f(x)g(x) - \int f(x)g'(x)\,dx. \tag{7.4}$$

(Substitutionsregel) Besitzt $f : J \to \mathbb{R}$ eine Stammfunktion F und ist $g : I \to J$ differenzierbar, so gilt

$$\int f(g(x))g'(x)\,dx = F(g(x)) + c, \text{ mit } c \in \mathbb{R}. \tag{7.5}$$

∘

Beweis. Wir beweisen die Rechenregeln für Stammfunktionen mithilfe der Ableitungsregeln. Dazu leiten wir jeweils die rechte Seite der Gleichung ab und zeigen, dass die Ableitung dem Integranden auf der linken Seite entspricht.

(Summenregel) Es seien

$$F := \int f(x)\,dx \text{ und } G := \int g(x)\,dx \tag{7.6}$$

Stammfunktionen von f und g. Dann gilt mit der Summenregel der Ableitung

$$(aF + bG)' = af + bg \Leftrightarrow \int (af(x) + bg(x))\,dx = a\int f(x)\,dx + b\int g(x)\,dx. \tag{7.7}$$

(Partielle Integration) Es sei

$$H := \int f(x)g'(x)\,dx \tag{7.8}$$

eine Stammfunktion von fg'. Dann folgt aus der Summenregel und der Produktregel der Ableitung

$$(fg - H)' = f'g + fg' - fg' = f'g \Leftrightarrow \int f'(x)g(x)\,dx = f(x)g(x) - \int f(x)g'(x)\,dx, \tag{7.9}$$

d.h. $f(x)g(x) - \int f(x)g'(x)\,dx$ ist eine Stammfunktion von $f'(x)g(x)$.

(Substitutionsregel) Für die Substitutionsregel liefert die Kettenregel

$$(F(g(x)))' = F'(g(x))g'(x) = f(g(x))g'(x). \tag{7.10}$$

Damit ist $F(g(x))$ eine Stammfunktion von $f(g(x))g'(x)$ und dies beweist die Substitutionsregel. □

Unbestimmte Integrale nehmen in der Lösung von Differenzialgleichungen einen zentralen Platz ein. Naheliegender ist aber zunächst die Anwendung unbestimmter Integrale im Kontext der Auswertung *bestimmter Integrale*, wie im nächsten Abschnitt eingeführt.

7.2. Bestimmte Integrale

Anschaulich entspricht ein bestimmtes Integral der vorzeichenbehafteten und auf ein Intervall $[a, b]$ beschränkten Fläche zwischen dem Graphen einer Funktion f und der x- Achse (vgl. Abbildung 7.1). *Vorzeichenbehaftet* heißt dabei, dass Flächen zwischen der x- Achse und positiven Werten von f positiv zur Fläche beitragen, Flächen zwischen der x- Achse und negativen Werten von f dagegen negativ. So ergeben sich zum Beispiel der Wert des in Abbildung 7.1 A gezeigten bestimmten Integrals zu 0.68, der Wert des in Abbildung Abbildung 7.1 B gezeigten bestimmten Integrals zu 0.95 (die eingezeichnete Fläche ist offensichtlich größer als in Abbildung 7.1 A) und der Wert des in Abbildung 7.1 C gezeigten bestimmten Integrals zu 0 (die eingezeichneten positiven und negativen Flächen gleichen sich genau aus). Der Durchschnittswert von f auf $[a, b]$ ist $\frac{1}{b-a}\int_a^b f(x)\,dx$.

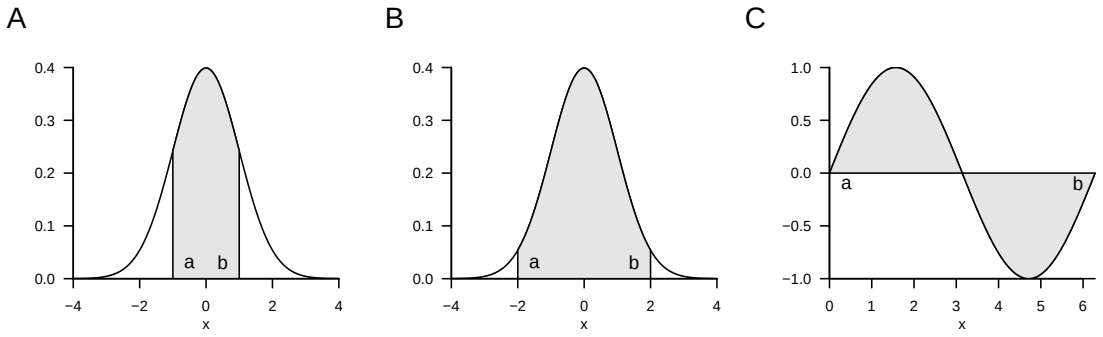


Abbildung 7.1. Beispiele bestimmter Integrale

Um den Begriff des *bestimmten Integrals* im Sinne des *Riemannschen Integrals* einführen zu können, müssen wir zunächst etwas Vorarbeit leisten. Wir beginnen damit, einen Begriff für die Aufteilung eines Intervalls in kleinere Abschnitte einzuführen.

Definition 7.2 (Zerlegung eines Intervalls und Feinheit)**.** Es seien $a, b \in \mathbb{R}$ mit $a < b$ und $n \in \mathbb{N}$. Punkte $x_0, \ldots, x_n$ mit

$$a = x_0 < x_1 < \cdots < x_n = b \tag{7.11}$$

definieren eine *Zerlegung* $Z := (x_0, \ldots, x_n)$ des Intervalls $[a, b]$. Die zugehörigen Teilintervalle sind $[x_{i-1}, x_i]$ mit Längen

$$\Delta x_i := x_i - x_{i-1}, \text{ für } i \in \{1, \ldots, n\}. \tag{7.12}$$

Die größte Teilintervalllänge

$$\delta(Z) := \max_{1 \leq i \leq n} \Delta x_i \tag{7.13}$$

heißt *Feinheit der Zerlegung* Z.

•

Anschaulich ist Δx_i die Breite der Rechtecke in Abbildung 7.2, wie wir in der Folge sehen werden. Mithilfe der Begriffe der Zerlegung eines Intervalls können wir nun den Begriff der *Riemannschen Summen* einführen.

Definition 7.3 (Riemannsche Summen)**.** Es sei $f : [a, b] \to \mathbb{R}$ beschränkt. Es existiere also ein $c > 0$ mit $|f(x)| \leq c$ für alle $x \in [a, b]$. Es sei $Z := (x_0, \ldots, x_n)$ eine Zerlegung von $[a, b]$ und $\xi := (\xi_1, \ldots, \xi_n)$ eine Wahl von Zwischenpunkten mit $\xi_i \in [x_{i-1}, x_i]$ für $i \in \{1, \ldots, n\}$. Dann heißt

$$R(f, Z, \xi) := \sum_{i=1}^{n} f(\xi_i) \Delta x_i \tag{7.14}$$

Riemannsche Summe von f bezüglich der Zerlegung Z und der Zwischenpunkte ξ.

•

$|x|$ bezeichnet den *Betrag* von $x \in \mathbb{R}$. Grob gesprochen nutzt die Obersumme auf jedem Teilintervall das Maximum von f, die Untersumme das Minimum. In Abbildung 7.2 bilden die dunkelgrauen Rechtecke die Untersumme. Zusammen mit den hellgrauen Ergänzungen bilden sie die Obersumme. Für Riemann-integrierbares f geht die Differenz zwischen Ober- und Untersumme bei $\delta(Z) \to 0$ gegen null.

Definition 7.4 (Bestimmtes Riemannsches Integral)**.** Es sei $f : [a, b] \to \mathbb{R}$ beschränkt. Die Funktion f heißt *Riemann-integrierbar*, wenn eine Zahl $L \in \mathbb{R}$ existiert, sodass für jede Folge von Zerlegungen $Z_k := (x_{k,0}, \ldots, x_{k,n_k})$ mit $\delta(Z_k) \to 0$ und jede Wahl von Zwischenpunkten $\xi_{k,i} \in [x_{k,i-1}, x_{k,i}]$ gilt, dass

$$\lim_{k \to \infty} R(f, Z_k, \xi_k) = L. \tag{7.15}$$

Die Zahl L heißt *bestimmtes Riemannsches Integral von f* und wird mit

$$\int_a^b f(x)\, dx := L \tag{7.16}$$

bezeichnet. Dabei heißen a und b *untere* beziehungsweise *obere Integrationsgrenze*, $f(x)$ *Integrand* und x *Integrationsvariable*.

•

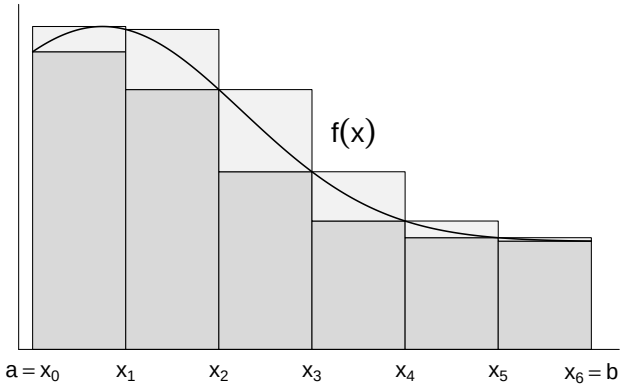


Abbildung 7.2. Zerlegung und Riemannsche Ober- und Untersummen

Die Riemannsche Integrierbarkeit einer Funktion und der Wert eines bestimmten Riemannschen Integrals sind also im Sinne einer Grenzwertbildung definiert. Die Theorie der Riemannschen Integrale lässt sich allerdings um die Hauptsätze der Differenzial- und Integralrechnung erweitern, sodass zur konkreten Berechnung eines bestimmten Integrals die Bildung von Zerlegungen und die Bestimmung eines Grenzwertes nur selten nötig ist. Der Einfachheit halber verzichten wir in der Folge auf die Bezeichnungen *Riemannsche* und sprechen einfach von *bestimmten Integralen.*

Ein erster Schritt zur Vereinfachung der Berechnung von bestimmten Integralen ist das Feststellen folgender Rechenregeln, für deren Beweis wir auf die weiterführende Literatur verweisen.

Theorem 7.3 (Rechenregeln für bestimmte Integrale)**.** *Es seien $a < b$ und $f, g : [a, b] \to \mathbb{R}$ Riemann-integrierbar. Dann gelten folgende Rechenregeln:*

(Linearität) Für $c_1, c_2 \in \mathbb{R}$ gilt

$$\int_a^b (c_1 f(x) + c_2 g(x))\, dx = c_1 \int_a^b f(x)\, dx + c_2 \int_a^b g(x)\, dx. \tag{7.17}$$

(Additivität) Für $a < c < b$ gilt

$$\int_a^b f(x)\, dx = \int_a^c f(x)\, dx + \int_c^b f(x)\, dx. \tag{7.18}$$

(Orientierung) Man setzt

$$\int_b^a f(x)\, dx := -\int_a^b f(x)\, dx. \tag{7.19}$$

(Integrationsvariable) Es gilt

$$\int_a^b f(x)\, dx = \int_a^b f(y)\, dy. \tag{7.20}$$

∘

Ein konstanter Faktor skaliert alle Höhen und damit auch das Integral. Beim Addieren der Funktionen addieren sich die Höhen an jeder Stelle. Die beiden Flächen ergeben zusammen die Fläche unter der Summenfunktion. Abbildung 7.3 zeigt dies für $c_1 = 1.3$ und $c_2 = 1.2$. Die ungewichteten Funktionen f und g sind gestrichelt eingezeichnet.

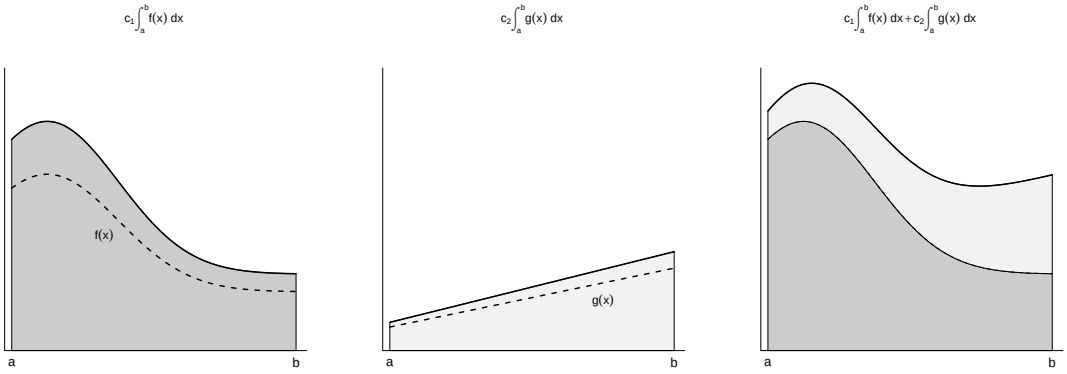


Abbildung 7.3. Linearität bestimmter Integrale

Man beachte, dass die Linearität des bestimmten Integrals analog zur Assoziativität bei Summen gleicher Länge und der Distributivität bei Multiplikation mit einer Konstante ist (vgl. Theorem 3.1),

$$\sum_{i=1}^{n} (c_1 x_i + c_2 y_i) = c_1 \sum_{i=1}^{n} x_i + c_2 \sum_{i=1}^{n} y_i, \tag{7.21}$$

die Additivität bestimmter Integrale analog zum Aufspalten von Summen ist, und dass auch die Unabhängigkeit des Werts eines Integrals von der Wahl der Integrationsvariablen in der Unabhängigkeit des Werts einer Summe von ihrem Laufindex ihre Entsprechung findet. Eine grafische Darstellung der Integralrechenregel der Additivität zeigt Abbildung 7.4. Die Summe der durch die bestimmten Integrale gegebenen Flächen $\int_a^c f(x)\,dx$ und $\int_c^b f(x)\,dx$ mit $a < c < b$ ergibt sich dabei zur Fläche von $\int_a^b f(x)\,dx$.

Die Orientierungskonvention ist mit der Additivität verträglich:

$$\int_a^b f(x)\,dx + \int_b^a f(x)\,dx = 0 = \int_a^a f(x)\,dx. \tag{7.22}$$

Abbildung 7.5 zeigt dieselben Rechtecke mit derselben Höhe $f(\xi)$, aber umgekehrten Schritten. Bei der Integration von a nach b gilt $x_{i+1} - x_i > 0$, beim Rückweg gilt $x_i - x_{i+1} < 0$. Die Summenbeiträge wechseln also ihr Vorzeichen:

$$f(\xi)(x_i - x_{i+1}) = -f(\xi)(x_{i+1} - x_i). \tag{7.23}$$

Die *Hauptsätze der Differenzial- und Integralrechnung* schließlich ermöglichen es, bestimmte Integrale einer Funktion f direkt mithilfe der Stammfunktion F von f zu berechnen. Für den Beweis des ersten Hauptsatzes der Differenzial- und Integralrechnung benötigen wir den *Mittelwertsatz der Integralrechnung*, welchen wir hier ohne Beweis wiedergeben und in Abbildung 7.6 veranschaulichen.

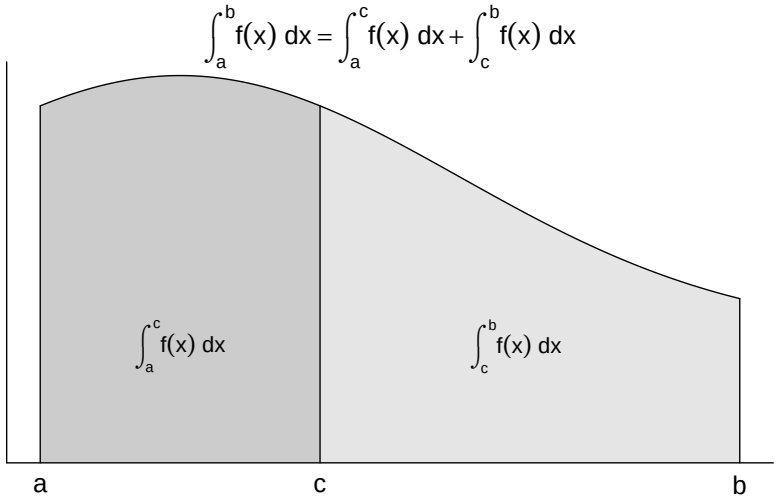


Abbildung 7.4. Additivität bestimmter Integrale

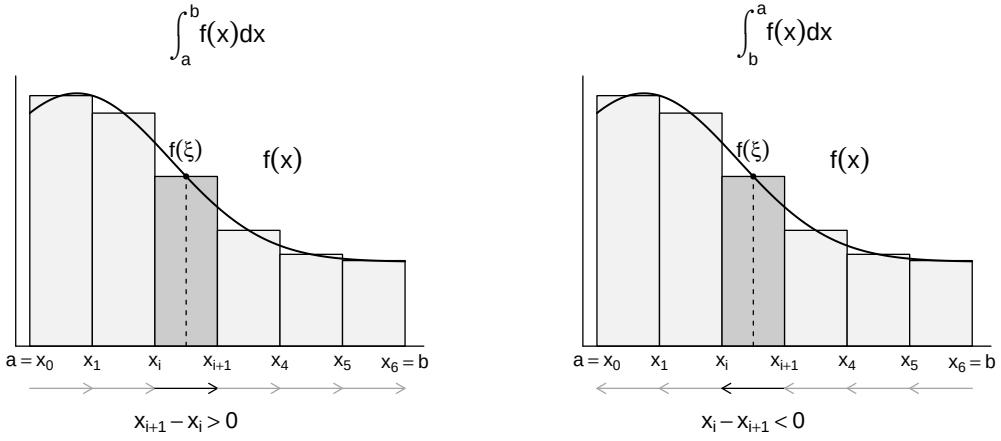


Abbildung 7.5. Orientierung bestimmter Integrale

Theorem 7.4 (Mittelwertsatz der Integralrechnung)**.** *Es seien $a < b$ und $f : [a, b] \to \mathbb{R}$ stetig. Dann existiert ein $\xi \in]a, b[$ mit*

$$\int_a^b f(x)\,dx = f(\xi)(b-a). \tag{7.24}$$

Der Mittelwert *von f auf $[a, b]$ ist daher*

$$\frac{1}{b-a}\int_a^b f(x)\,dx = f(\xi). \tag{7.25}$$

∘

Der Mittelwertsatz der Integralrechnung garantiert die Existenz eines $\xi \in]a, b[$, sodass das bestimmte Integral $\int_a^b f(x)\,dx$ gleich dem Produkt aus der "Rechteckhöhe" $f(\xi)$ und der "Rechteckbreite" $(b-a)$ ist. In Abbildung 7.6 liegt dieses ξ genau mittig zwischen a und b. Dass die sich so ergebende grau eingefärbte Rechteckfläche gleich $\int_a^b f(x)\,dx$ ist, ergibt sich aus der visuell zumindest nachvollziehbaren Tatsache, dass die Flächen zwischen $f(x)$ und $f(\xi)$ im Intervall $[a, \xi]$ und zwischen $f(\xi)$ und $f(x)$ im Intervall $[\xi, b]$ den gleichen Betrag haben, erstere aber mit einem negativen Vorzeichen behaftet ist. Der Mittelwertsatz der Integralrechnung garantiert im Allgemeinen aber nur die Existenz eines $\xi \in]a, b[$ mit der diskutierten Eigenschaft, gibt aber keine Formel zur Bestimmung von ξ an.

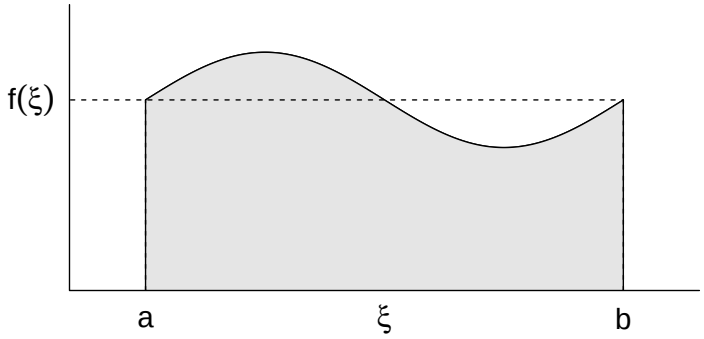


Abbildung 7.6. Zum Mittelwertsatz der Integralrechnung

Mit dieser Vorarbeit können wir nun den ersten Hauptsatz der Differenzial- und Integralrechnung formulieren und beweisen.

Theorem 7.5 (Erster Hauptsatz der Differenzial- und Integralrechnung)**.** *Es sei $I \subseteq \mathbb{R}$ ein offenes Intervall, $f : I \to \mathbb{R}$ stetig und $a \in I$ fest. Dann ist die Funktion*

$$F : I \to \mathbb{R}, x \mapsto F(x) := \int_a^x f(t)\,dt \tag{7.26}$$

eine Stammfunktion von f. Es gilt also $F'(x) = f(x)$ für alle $x \in I$.

∘

Beweis. Es sei $x \in I$ und $h \neq 0$ so klein, dass $x + h \in I$. Additivität und Orientierung des Integrals ergeben für den Newtonschen Differenzenquotienten zunächst

$$\frac{1}{h}\left(F(x+h) - F(x)\right) = \frac{1}{h}\left(\int_a^{x+h} f(t)\,dt - \int_a^{x} f(t)\,dt\right) = \frac{1}{h}\int_x^{x+h} f(t)\,dt. \tag{7.27}$$

Der Mittelwertsatz der Integralrechnung liefert für positive wie negative h dann einen Punkt ξ_h zwischen x und $x + h$ mit

$$\frac{1}{h}\left(F(x+h) - F(x)\right) = \frac{1}{h}\int_x^{x+h} f(t)\,dt = f(\xi_h). \tag{7.28}$$

Für jedes hinreichend kleine $h \neq 0$ wählen wir einen solchen Punkt ξ_h und definieren $g(h) := \xi_h$. Wegen $|g(h) - x| = |\xi_h - x| \leq |h|$ gilt $\lim_{h\to 0} g(h) = x$. Aus der Stetigkeit von f in x und Theorem 5.2 folgt dann

$$F'(x) := \lim_{h\to 0} \frac{1}{h}\left(F(x+h) - F(x)\right) = \lim_{h\to 0} f(\xi_h) = f(x). \tag{7.29}$$

□

Der zweite Hauptsatz der Differenzial- und Integralrechnung besagt, wie man mithilfe der Stammfunktion ein bestimmtes Integral berechnet.

Theorem 7.6 (Zweiter Hauptsatz der Differenzial- und Integralrechnung)**.** *Es sei $I \subseteq \mathbb{R}$ ein offenes Intervall, $f : I \to \mathbb{R}$ stetig und F eine Stammfunktion von f. Dann gilt für alle $a, b \in I$*

$$\int_a^b f(x)\,dx = F(b) - F(a) =: F(x)|_a^b. \tag{7.30}$$

∘

Beweis. Wir wählen einen festen Punkt $\alpha \in I$ und setzen $H(x) := \int_\alpha^x f(t)\,dt$. Nach dem ersten Hauptsatz ist H eine Stammfunktion von f. Daher gilt $F = H + c$ für eine Konstante $c \in \mathbb{R}$. Bei der Differenz fällt diese Konstante weg:

$$F(b) - F(a) = H(b) - H(a) = \int_\alpha^b f(t)\,dt - \int_\alpha^a f(t)\,dt. \tag{7.31}$$

Additivität und Orientierung des Integrals ergeben dann

$$F(b) - F(a) = \int_\alpha^b f(t)\,dt - \int_\alpha^a f(t)\,dt = \int_a^\alpha f(t)\,dt + \int_\alpha^b f(t)\,dt = \int_a^b f(t)\,dt = \int_a^b f(x)\,dx. \tag{7.32}$$

□

Wir wollen den Zweiten Hauptsatz der Differenzial- und Integralrechnung in drei Beispielen anwenden (vgl. Abbildung 7.7).

Beispiel 7.1 (Bestimmtes Integral der Identitätsfunktion)**.** Wir betrachten die Identitätsfunktion

$$f : \mathbb{R} \to \mathbb{R}, x \mapsto f(x) := x \tag{7.33}$$

und wollen das bestimmte Integral dieser Funktion auf dem Intervall $[0, 1]$, also

$$\int_0^1 f(x)\,dx = \int_0^1 x\,dx \tag{7.34}$$

berechnen. Dazu erinnern wir uns, dass eine Stammfunktion von f durch

$$F : \mathbb{R} \to \mathbb{R}, x \mapsto F(x) := \frac{1}{2}x^2 \tag{7.35}$$

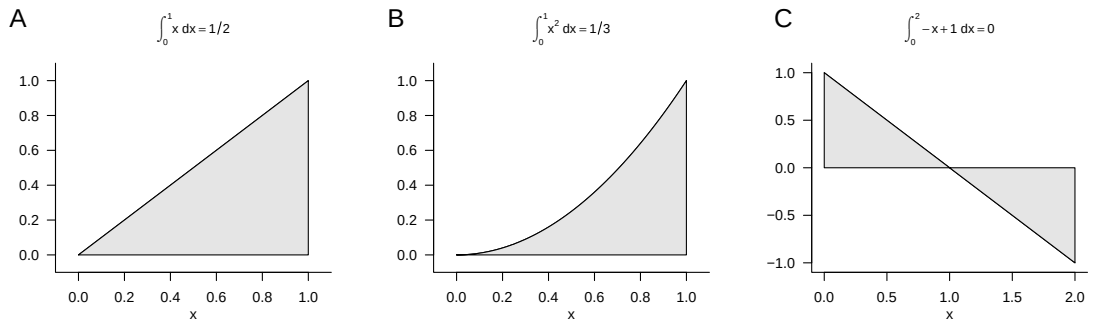


Abbildung 7.7. Beispiele zum Zweiten Hauptsatz der Differenzial- und Integralrechnung

gegeben ist, weil

$$F'(x) = \frac{d}{dx}\left(\frac{1}{2}x^2\right) = 2 \cdot \frac{1}{2}x^{2-1} = x. \tag{7.36}$$

Einsetzen in den zweiten Hauptsatz der Differenzial- und Integralrechnung ergibt dann

$$\int_0^1 x\,dx = \frac{1}{2}1^2 - \frac{1}{2}0^2 = \frac{1}{2}. \tag{7.37}$$

Dieses Ergebnis ist mit der Intuition, die sich anhand der grauen Fläche in Abbildung 7.7 A ergibt, kongruent.

△

Beispiel 7.2 (Bestimmtes Integral der Quadratfunktion)**.** Als nächstes betrachten wir die Quadratfunktion

$$f : \mathbb{R} \to \mathbb{R}, x \mapsto f(x) := x^2 \tag{7.38}$$

und wollen das bestimmte Integral dieser Funktion auf dem Intervall $[0, 1]$, also

$$\int_0^1 f(x)\,dx = \int_0^1 x^2\,dx \tag{7.39}$$

berechnen. Dazu erinnern wir uns, dass eine Stammfunktion von f durch

$$F : \mathbb{R} \to \mathbb{R}, x \mapsto F(x) := \frac{1}{3}x^3 \tag{7.40}$$

gegeben ist, weil

$$F'(x) = \frac{d}{dx}\left(\frac{1}{3}x^3\right) = 3 \cdot \frac{1}{3}x^{3-1} = x^2. \tag{7.41}$$

Einsetzen in den zweiten Hauptsatz der Differenzial- und Integralrechnung ergibt dann

$$\int_0^1 x^2\,dx = \frac{1}{3}1^3 - \frac{1}{3}0^3 = \frac{1}{3}. \tag{7.42}$$

Dieses Ergebnis ist mit der Intuition, die sich aus dem Vergleich der grauen Flächen in Abbildung 7.7 A und Abbildung 7.7 B ergibt, kongruent.

△

Beispiel 7.3 (Bestimmtes Integral einer linear-affinen Funktion)**.** Schließlich betrachten wir die linear-affine Funktion

$$f : \mathbb{R} \to \mathbb{R}, x \mapsto f(x) := -x + 1 \tag{7.43}$$

und wollen das bestimmte Integral dieser Funktion auf dem Intervall $[0, 2]$, also

$$\int_0^2 f(x)\,dx = \int_0^2 -x + 1\,dx \tag{7.44}$$

berechnen. Dazu erinnern wir uns, dass eine Stammfunktion der linear-affinen Funktion mit $a = -1$ und $b = 1$ (vgl. Tabelle 7.1) durch

$$F : \mathbb{R} \to \mathbb{R}, x \mapsto F(x) := -\frac{1}{2}x^2 + x \tag{7.45}$$

gegeben ist, weil

$$F'(x) = \frac{d}{dx}\left(-\frac{1}{2}x^2 + x\right) = -2 \cdot \frac{1}{2}x^{2-1} + 1 \cdot x^{1-1} = -x + 1. \tag{7.46}$$

Einsetzen in den Zweiten Hauptsatz der Differenzial- und Integralrechnung ergibt dann

$$\int_0^2 -x + 1\,dx = \left(-\frac{1}{2}2^2 + 2\right) - \left(-\frac{1}{2}0^2 + 0\right) = -2 + 2 - 0 = 0. \tag{7.47}$$

Dieses Ergebnis ist mit der Intuition kongruent, dass sich die positive und die negative graue Fläche in Abbildung 7.7 C ausgleichen.

△

7.3. Uneigentliche Integrale

Uneigentliche Integrale erweitern den Integralbegriff auf unendliche Integrationsgrenzen. Ihr Wert wird durch Grenzwerte bestimmter Integrale erklärt.

Definition 7.5 (Uneigentliche Integrale)**.** $f : \mathbb{R} \to \mathbb{R}$ sei eine univariate reellwertige Funktion. Mit den Definitionen

$$\int_{-\infty}^b f(x)\,dx := \lim_{a \to -\infty} \int_a^b f(x)\,dx \text{ und } \int_a^\infty f(x)\,dx := \lim_{b \to \infty} \int_a^b f(x)\,dx \tag{7.48}$$

und der Additivität von Integralen

$$\int_{-\infty}^\infty f(x)\,dx = \int_{-\infty}^b f(x)\,dx + \int_b^\infty f(x)\,dx \tag{7.49}$$

wird der Begriff des bestimmten Integrals auf die unbeschränkten Integrationsintervalle $]-\infty, b]$, $[a, \infty[$ und $]-\infty, \infty[$ erweitert. Integrale mit unbeschränkten Integrationsintervallen heißen *uneigentliche Integrale*. Wenn die entsprechenden Grenzwerte existieren, sagt man, dass die uneigentlichen Integrale *konvergieren*.

•

Für die WDF f einer Zufallsvariable ist die Forderung $\int_{-\infty}^\infty f(x)\,dx = 1$ zentral.

Beispiel 7.4 (Uneigentliches Integral)**.** Als Beispiel betrachten wir das uneigentliche Integral der Funktion

$$f :]0, \infty[\to \mathbb{R}, x \mapsto f(x) := \frac{1}{x^2} \tag{7.50}$$

über alle $x \geq 1$, also

$$\int_1^\infty \frac{1}{x^2}\, dx. \tag{7.51}$$

Nach den Festlegungen in der Definition uneigentlicher Integrale gilt

$$\int_1^\infty \frac{1}{x^2}\, dx = \lim_{b \to \infty} \int_1^b \frac{1}{x^2}\, dx. \tag{7.52}$$

Mit der Stammfunktion $F(x) = -x^{-1}$ von $f(x) = x^{-2}$ ergibt sich für das bestimmte Integral in obiger Gleichung

$$\int_1^b \frac{1}{x^2}\, dx = F(b) - F(1) = -\frac{1}{b} - \left(-\frac{1}{1}\right) = -\frac{1}{b} + 1. \tag{7.53}$$

Es ergibt sich also

$$\int_1^\infty \frac{1}{x^2}\, dx = \lim_{b \to \infty} \int_1^b \frac{1}{x^2}\, dx = \lim_{b \to \infty} \left(-\frac{1}{b} + 1\right) = -\lim_{b \to \infty} \frac{1}{b} + \lim_{b \to \infty} 1 = 0 + 1 = 1. \tag{7.54}$$

△

7.4. Mehrdimensionale Integrale

Bisher haben wir nur Integrale univariater reellwertiger Funktionen betrachtet. Der Integralbegriff lässt sich auch auf multivariate reellwertige Funktionen erweitern. Allerdings ist dann der Integrationsbereich der Funktion nicht notwendigerweise so einfach zu beschreiben wie ein Intervall. Insbesondere sind beispielsweise schon bei bivariaten Funktionen arbiträr geformte Integrationsbereiche möglich. Wir wollen hier nun den einfachsten Fall eines *Hyperrechtecks* betrachten. In diesem Fall können wir mehrdimensionale bestimmte Integrale wie folgt definieren.

Definition 7.6 (Mehrdimensionale Integrale)**.** $f : \mathbb{R}^n \to \mathbb{R}$ sei eine multivariate reellwertige Funktion. Dann heißen Integrale der Form

$$\int\limits_{[a_1,b_1]\times\cdots\times[a_n,b_n]} f(x)\, dx = \int_{a_1}^{b_1} \cdots \int_{a_n}^{b_n} f(x_1, \ldots, x_n)\, dx_n \cdots dx_1 \tag{7.55}$$

mehrdimensionale bestimmte Integrale auf Hyperrechtecken. Weiterhin heißen Integrale der Form

$$\int_{\mathbb{R}^n} f(x)\, dx = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f(x_1, ..., x_n)\, dx_1 ... dx_n \tag{7.56}$$

mehrdimensionale uneigentliche Integrale.

•

Man kann multivariate reellwertige Funktionen nicht nur auf Hyperrechtecken, sondern im Prinzip auf beliebigen Integrationsgebieten integrieren. Dies kann sich jedoch oft schwierig gestalten. Der *Satz von Fubini* besagt, dass man mehrdimensionale Integrale in beliebiger Koordinatenfolge auswerten kann, also dass zum Beispiel

$$\int_{a_1}^{b_1} \left(\int_{a_2}^{b_2} f(x_1, x_2)\, dx_2 \right) dx_1 = \int_{a_2}^{b_2} \left(\int_{a_1}^{b_1} f(x_1, x_2)\, dx_1 \right) dx_2. \tag{7.57}$$

Für die WDF eines Zufallsvektors ist die Forderung $\int_{\mathbb{R}^n} f(x)\, dx = 1$ zentral.

Beispiel 7.5 (Zweidimensionalens bestimmtes Integral)**.** Als Beispiel für Definition 7.6 betrachten wir das zweidimensionale bestimmte Integral der Funktion

$$f : \mathbb{R}^2 \to \mathbb{R}, (x_1, x_2) \mapsto f(x_1, x_2) := x_1^2 + 4x_2 \tag{7.58}$$

auf dem Rechteck $[0, 1] \times [0, 1]$. Wir betrachten

$$\int_0^1 \int_0^1 x_1^2 + 4x_2\, dx_1\, dx_2 = \int_0^1 \left(\int_0^1 x_1^2 + 4x_2\, dx_1 \right) dx_2 \tag{7.59}$$

also zunächst das innere Integral. x_2 nimmt dabei die Rolle einer Konstanten ein. Eine Stammfunktion von $g(x_1) := x_1^2 + 4x_2$ ist $G(x_1) = \frac{1}{3}x_1^3 + 4x_2x_1$, wovon man sich durch Ableiten von G überzeugt. Es ergibt sich also für das innere Integral

$$\begin{aligned} \int_0^1 x_1^2 + 4x_2\, dx_1 &= G(1) - G(0) \\ &= \frac{1}{3} \cdot 1^3 + 4x_2 \cdot 1 - \frac{1}{3} \cdot 0^3 - 4x_2 \cdot 0 \\ &= \frac{1}{3} + 4x_2. \end{aligned} \tag{7.60}$$

Betrachten des äußeren Integrals

$$\int_0^1 4x_2 + \frac{1}{3}\, dx_2$$

ergibt dann mit der Stammfunktion

$$H(x_2) = 2x_2^2 + \frac{1}{3}x_2 \tag{7.61}$$

von

$$h(x_2) := 4x_2 + \frac{1}{3}, \tag{7.62}$$

dass

$$\begin{aligned} \int_0^1 \int_0^1 x_1^2 + 4x_2\, dx_1\, dx_2 &= \int_0^1 4x_2 + \frac{1}{3}\, dx_2 \\ &= H(1) - H(0) \\ &= 2 \cdot 1^2 + \frac{1}{3} \cdot 1 - 2 \cdot 0^2 - \frac{1}{3} \cdot 0 \\ &= \frac{7}{3}. \end{aligned} \tag{7.63}$$

△

Selbstkontrollfragen

1. Geben Sie die Definition des Begriffs der Stammfunktion wieder.
2. Geben Sie die Definition des Begriffs des unbestimmten Integrals wieder.
3. Erläutern Sie die intuitive Bedeutung des Begriffs des Riemannschen Integrals.
4. Geben Sie den Ersten Hauptsatz der Differenzial- und Integralrechnung wieder.
5. Geben Sie den Zweiten Hauptsatz der Differenzial- und Integralrechnung wieder.
6. Erläutern Sie den Begriff des uneigentlichen Integrals.
7. Erläutern Sie den Begriff des mehrdimensionalen Integrals.

Lösungen

1. Siehe Definition 7.1.
2. Siehe Definition 7.1.
3. Das Riemannsche Integral entspricht der vorzeichenbehafteten Fläche zwischen dem Funktionsgraphen und der x-Achse.
4. Siehe Theorem 7.5.
5. Siehe Theorem 7.6.
6. Uneigentliche Integrale behandeln unendliche Integrationsgrenzen durch geeignete Grenzwerte.
7. Mehrdimensionale Integrale sind Integrale multivariater Funktionen über Teilmengen ihrer Definitionsmenge.

8. Vektoren

In der naturwissenschaftlichen Modellbildung betrachtet man häufig Phänomene, die sich durch das Vorliegen mehrerer quantitativer Merkmale auszeichnen. So ist zum Beispiel die Position eines Objektes im dreidimensionalen Raum durch drei Koordinaten hinsichtlich der drei Achsen eines Kartesischen Koordinatensystems festgelegt. Analog mag der Gesundheitszustand einer Person durch das Vorliegen dreier Messwerte, beispielsweise eines Selbstauskunftsscores, eines Biomarkers und einer Expert:inneneinschätzung charakterisiert sein. Zum Modellieren und Analysieren solcher mehrdimensionaler quantitativer Phänomene stellt die Mathematik mit dem reellen Vektorraum ein vielseitig einsetzbares Hilfsmittel bereit. In diesem Kapitel wollen wir zunächst den Begriff des reellen Vektorraums und das grundlegende Rechnen mit Vektoren einführen (Kapitel 8.1). Eine Vektorraumstruktur, die sich stark an der dreidimensionalen räumlichen Intuition orientiert, bietet dann der Euklidische Vektorraum (Kapitel 8.2). Mithilfe der Vektorrechnung können alle Vektoren eines Vektorraums aus einer kleinen Schar ausgezeichneter Vektoren gebildet werden. Die diesem Prinzip zugrundeliegenden Konzepte diskutieren wir in Kapitel 8.3 und Kapitel 8.4.

8.1. Reeller Vektorraum

Wir beginnen mit der allgemeinen Definition eines Vektorraums, die grundlegende Regeln zum Rechnen mit Vektoren festlegt.

Definition 8.1 (Vektorraum)**.** Es seien V eine nichtleere Menge und S eine Menge von Skalaren. Weiterhin sei eine Abbildung

$$+ : V \times V \to V, (v_1, v_2) \mapsto +(v_1, v_2) =: v_1 + v_2, \tag{8.1}$$

genannt *Vektoraddition*, definiert. Schließlich sei eine Abbildung

$$\cdot : S \times V \to V, (s, v) \mapsto \cdot(s, v) =: sv, \tag{8.2}$$

genannt *Skalarmultiplikation* definiert. Dann wird das Tupel $(V, S, +, \cdot)$ genau dann *Vektorraum* genannt, wenn für beliebige Elemente $v, w, u \in V$ und $a, b \in S$ folgende Bedingungen gelten:

(1) *Kommutativität der Vektoraddition.*

$$v + w = w + v.$$

(2) *Assoziativität der Vektoraddition.*

$$(v + w) + u = v + (w + u)$$

(3) *Existenz eines neutralen Elements der Vektoraddition.*

$$\text{Es gibt einen Vektor } 0 \in V \text{ mit } v + 0 = 0 + v = v.$$

(4) *Existenz inverser Elemente der Vektoraddition*

$$\text{Für alle Vektoren } v \in V \text{ gibt es einen Vektor } -v \in V \text{ mit } v + (-v) = 0.$$

(5) *Existenz eines neutralen Elements der Skalarmultiplikation.*

$$\text{Es gibt einen Skalar } 1 \in S \text{ mit } 1 \cdot v = v.$$

(6) *Assoziativität der Skalarmultiplikation.*

$$a \cdot (b \cdot v) = (a \cdot b) \cdot v.$$

(7) *Distributivität hinsichtlich der Vektoraddition.*

$$a \cdot (v + w) = a \cdot v + a \cdot w.$$

(8) *Distributivität hinsichtlich der Skalaraddition.*

$$(a + b) \cdot v = a \cdot v + b \cdot v.$$

•

Es fällt auf, dass Definition 8.1 zwar festlegt, wie mit Vektoren gerechnet werden soll, jedoch keine Aussage darüber macht, was ein Vektor, über ein Element einer Menge hinaus, eigentlich ist. Dies ist der Tatsache geschuldet, dass es verschiedenste mathematische Objekte gibt, für die Vektorraumstrukturen definiert werden können. Beispiele dafür sind die Menge der reellen m-Tupel, die Menge der Matrizen, die Menge der Polynome, die Menge der Lösungen eines linearen Gleichungssystems, die Menge der reellen Folgen, die Menge der stetigen Funktionen u.v.a.m.

Wir sind hier zunächst nur am Vektorraum der Menge der reellen m-Tupel interessiert. Wir erinnern dazu daran, dass wir die reellen m-Tupel mit

$$\mathbb{R}^m := \left\{ \begin{pmatrix} x_1 \\ \vdots \\ x_m \end{pmatrix} | x_i \in \mathbb{R} \text{ für alle } 1 \leq i \leq m \right\} \tag{8.3}$$

bezeichnen und $\mathbb{R}^m$ als "$\mathbb{R}$ hoch m" aussprechen. Die Elemente $x \in \mathbb{R}^m$ nennen wir *reelle Vektoren* oder auch einfach *Vektoren*. Wir wollen nun der Definition eines Vektorraums die Menge $\mathbb{R}^m$ zugrunde legen. Dazu definieren wir zunächst die Vektoraddition für Elemente von $\mathbb{R}^m$ und die Skalarmultiplikation für Elemente von $\mathbb{R}$ und $\mathbb{R}^m$.

Definition 8.2 (Vektoraddition und Skalarmultiplikation in $\mathbb{R}^m$)**.** Für alle $x, y \in \mathbb{R}^m$ und $a \in \mathbb{R}$ sei die *Vektoraddition* durch

$$+ : \mathbb{R}^m \times \mathbb{R}^m \to \mathbb{R}^m, (x, y) \mapsto x + y = \begin{pmatrix} x_1 \\ \vdots \\ x_m \end{pmatrix} + \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix} := \begin{pmatrix} x_1 + y_1 \\ \vdots \\ x_m + y_m \end{pmatrix} \tag{8.4}$$

und die *Skalarmultiplikation* durch

$$\cdot : \mathbb{R} \times \mathbb{R}^m \to \mathbb{R}^m, (a, x) \mapsto ax = a \begin{pmatrix} x_1 \\ \vdots \\ x_m \end{pmatrix} := \begin{pmatrix} ax_1 \\ \vdots \\ ax_m \end{pmatrix} \tag{8.5}$$

definiert.

•

Es ergibt sich dann folgendes Resultat.

Theorem 8.1 (Reeller Vektorraum)**.** $(\mathbb{R}^m, \mathbb{R}, +, \cdot)$ *mit den Rechenregeln der Addition und Multiplikation in* $\mathbb{R}$ *ist ein Vektorraum.*

∘

Für einen Beweis, auf den wir hier verzichten wollen, muss man die Bedingungen (1) bis (8) aus Definition 8.1 für die hier betrachtete Menge und die hier festgelegten Formen der Vektoraddition und der Skalarmultiplikation nachweisen. Diese ergeben sich aber leicht aus den Rechenregeln von Addition und Multiplikation in $\mathbb{R}$ und der Tatsache, dass Vektoraddition und Skalarmultiplikation für Elemente von $\mathbb{R}^m$ in Definition 8.2 komponentenweise definiert wurden. Wir definieren damit den Begriff des *reellen Vektorraums*.

Definition 8.3 (Reeller Vektorraum)**.** Für $\mathbb{R}^m$ seien $+$ und $\cdot$ die in Definition 8.2 definierte Vektoraddition und Skalarmultiplikation. Dann nennen wir auf Grundlage von Theorem 8.1 den Vektorraum $(\mathbb{R}^m, \mathbb{R}, +, \cdot)$ den *reellen Vektorraum*.

•

Auf Grundlage von Definition 8.3 wollen wir uns nun das Rechnen mit reellen Vektoren anhand einiger Beispiele verdeutlichen.

Beispiele

(1) Für

$$x := \begin{pmatrix} 1 \\ 2 \\ 3 \\ 4 \end{pmatrix} \in \mathbb{R}^4 \text{ und } y := \begin{pmatrix} 2 \\ 1 \\ 0 \\ 1 \end{pmatrix} \in \mathbb{R}^4$$

gilt

$$x + y = \begin{pmatrix} 1 \\ 2 \\ 3 \\ 4 \end{pmatrix} + \begin{pmatrix} 2 \\ 1 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 1+2 \\ 2+1 \\ 3+0 \\ 4+1 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \\ 3 \\ 5 \end{pmatrix} \in \mathbb{R}^4.$$

In **R** implementiert man dieses Beispiel wie folgt

```
x = matrix(c(1,2,3,4), nrow = 4)      # Vektordefinition
y = matrix(c(2,1,0,1), nrow = 4)      # Vektordefinition
x + y                                 # Vektoraddition
```

```
     [,1]
[1,]    3
[2,]    3
[3,]    3
[4,]    5
```

(2) Für

$$x := \begin{pmatrix} 2 \\ 3 \end{pmatrix} \in \mathbb{R}^2 \text{ und } y := \begin{pmatrix} 1 \\ 3 \end{pmatrix} \in \mathbb{R}^2$$

gilt

$$x - y = \begin{pmatrix} 2 \\ 3 \end{pmatrix} - \begin{pmatrix} 1 \\ 3 \end{pmatrix} = \begin{pmatrix} 2-1 \\ 3-3 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \in \mathbb{R}^2.$$

In **R** implementiert man dieses Beispiel wie folgt

```
x = matrix(c(2,3), nrow = 2)          # Vektordefinition
y = matrix(c(1,3), nrow = 2)          # Vektordefinition
x - y                                 # Vektorsubtraktion
```

```
     [,1]
[1,]    1
[2,]    0
```

(3) Für

$$x := \begin{pmatrix} 2 \\ 1 \\ 3 \end{pmatrix} \in \mathbb{R}^3 \text{ und } a := 3 \in \mathbb{R}$$

gilt

$$ax = 3 \begin{pmatrix} 2 \\ 1 \\ 3 \end{pmatrix} = \begin{pmatrix} 3 \cdot 2 \\ 3 \cdot 1 \\ 3 \cdot 3 \end{pmatrix} = \begin{pmatrix} 6 \\ 3 \\ 9 \end{pmatrix} \in \mathbb{R}^3.$$

In **R** implementiert man dieses Beispiel wie folgt

```
x = matrix(c(2,1,3), nrow = 3)        # Vektordefinition
a = 3                                 # Skalardefinition
a*x                                   # Skalarmultiplikation
```

```
     [,1]
[1,]    6
[2,]    3
[3,]    9
```

Für $m \in \{1, 2, 3\}$ kann man sich reelle Vektoren und das Rechnen mit ihnen visuell veranschaulichen. Für $m > 3$, wenn also zum Beispiel für eine Person mehr als drei quantitative Merkmale zu ihrem Gesundheitszustand vorliegen, was in der Anwendung regelmäßig der Fall ist, ist dies nicht möglich. Trotzdem mag die visuelle Intuition für $m \leq 3$ einen Einstieg in das Verständnis von Vektorräumen erleichtern. Wir fokussieren hier auf den Fall $m := 2$. In diesem Fall liegen die betrachteten reellen Vektoren in der zweidimensionalen Ebene und werden üblicherweise als Punkte oder Pfeile visualisiert (Abbildung 8.1).

Abbildung 8.2 visualisiert die Vektoraddition

$$\begin{pmatrix} 1 \\ 2 \end{pmatrix} + \begin{pmatrix} 3 \\ 1 \end{pmatrix} = \begin{pmatrix} 4 \\ 3 \end{pmatrix}. \tag{8.6}$$

Der Summenvektor entspricht dabei der Diagonale des von den beiden Summanden aufgespannten Parallelogramms.

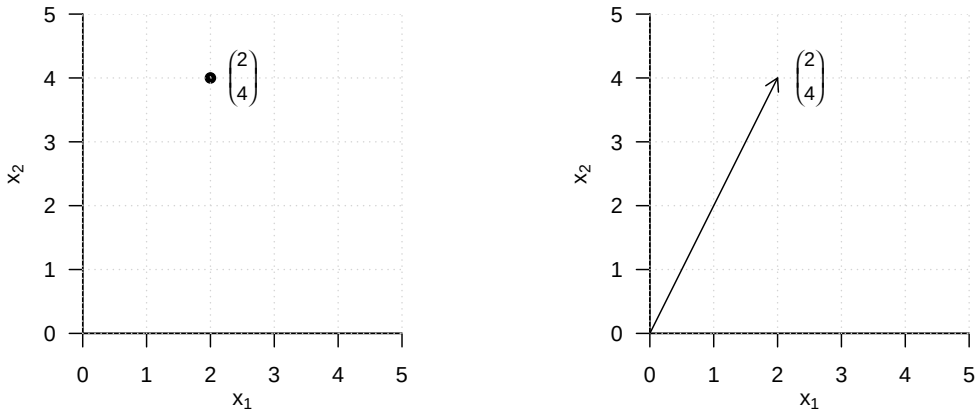


Abbildung 8.1. Visualisierung von Vektoren in $\mathbb{R}^2$

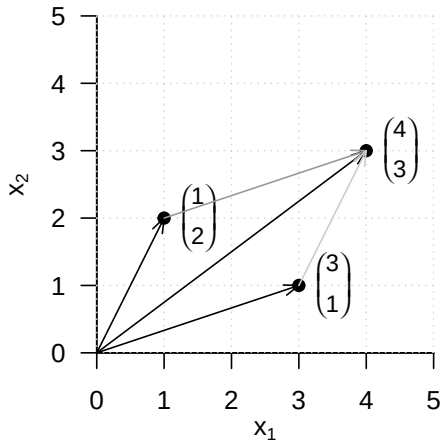


Abbildung 8.2. Vektoraddition in $\mathbb{R}^2$

Abbildung 8.3 visualisiert die Vektorsubtraktion

$$\begin{pmatrix}1\\2\end{pmatrix} - \begin{pmatrix}3\\1\end{pmatrix} = \begin{pmatrix}1\\2\end{pmatrix} + \begin{pmatrix}-3\\-1\end{pmatrix} = \begin{pmatrix}-2\\1\end{pmatrix} \tag{8.7}$$

Der resultierende Vektor entspricht dabei der Diagonale des von dem ersten Vektor und dem entgegengesetzten Vektor des zweiten Vektors aufgespannten Parallelogramms.

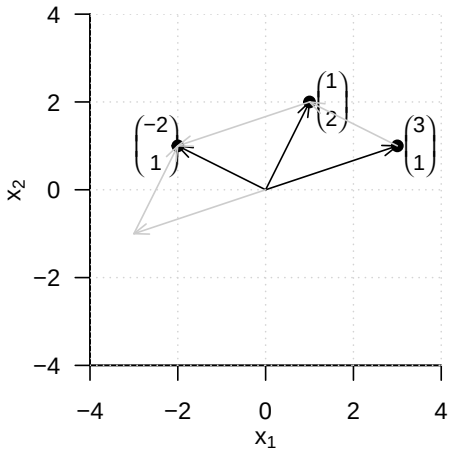


Abbildung 8.3. Vektorsubtraktion in $\mathbb{R}^2$

Abbildung 8.4 schließlich visualisiert die Skalarmultiplikation

$$3\begin{pmatrix}1\\1\end{pmatrix} = \begin{pmatrix}3\\3\end{pmatrix} \tag{8.8}$$

Die Multiplikation eines Vektors mit einem positiven Skalar ändert dabei nur seine Länge, nicht jedoch seine Richtung.

8.2. Euklidischer Vektorraum

Der reelle Vektorraum kann durch Definition des *Skalarprodukts* im Sinne eines *Euklidischen Vektorraums* mit räumlich-geometrischer Intuition versehen werden. Diese ermöglicht es insbesondere, Begriffe wie die *Länge eines Vektors*, den *Abstand zwischen zwei Vektoren*, und nicht zuletzt den *Winkel zwischen zwei Vektoren* zu definieren und zu berechnen. Wir führen zunächst das *Skalarprodukt* ein.

Definition 8.4 (Skalarprodukt auf $\mathbb{R}^m$)**.** Das *Skalarprodukt auf* $\mathbb{R}^m$ ist definiert als die Abbildung

$$\langle\rangle : \mathbb{R}^m \times \mathbb{R}^m \to \mathbb{R}, (x, y) \mapsto \langle(x, y)\rangle := \langle x, y\rangle := \sum_{i=1}^{m} x_i y_i. \tag{8.9}$$

•

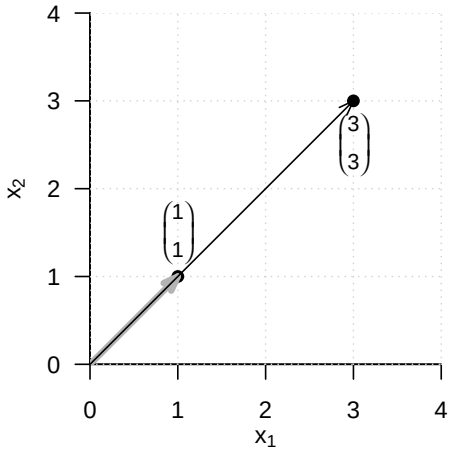


Abbildung 8.4. Skalarmultiplikation in $\mathbb{R}^2$

Das Skalarprodukt heißt Skalarprodukt, weil es einen Skalar ergibt, nicht etwa, weil mit Skalaren multipliziert wird. Das Skalarprodukt steht in enger Beziehung zum Matrixprodukt, wie wir an späterer Stelle sehen werden. Wir betrachten zunächst ein Beispiel und seine Implementation in **R**.

Beispiel 8.1 (Skalarprodukt zweier Vektoren)**.** Es seien

$$x := \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} \text{ und } y := \begin{pmatrix} 2 \\ 0 \\ 1 \end{pmatrix} \tag{8.10}$$

Dann ergibt sich

$$\langle x, y \rangle = x_1 y_1 + x_2 y_2 + x_3 y_3 = 1 \cdot 2 + 2 \cdot 0 + 3 \cdot 1 = 2 + 0 + 3 = 5. \tag{8.11}$$

In **R** gibt es verschiedene Möglichkeiten, ein Skalarprodukt auszuwerten. Wir führen zwei von ihnen für das gegebene Beispiel untenstehend auf.

```
# Vektordefinitionen
x = matrix(c(1,2,3), nrow = 3)
y = matrix(c(2,0,1), nrow = 3)

# Skalarprodukt mithilfe von R's komponentenweiser Multiplikation und sum() Funktion
sum(x*y)
```

```
[1] 5
```

```
# Skalarprodukt mithilfe von R's Matrixtransposition und -multiplikation
t(x) %*% y
```

```
     [,1]
[1,]    5
```

△

Mithilfe des Skalarprodukts kann der Begriff des reellen Vektorraums zum Begriff des *reellen kanonischen Euklidischen Vektorraums* erweitert werden.

Definition 8.5 (Euklidischer Vektorraum)**.** Das Tupel $((\mathbb{R}^m, +, \cdot), \langle\rangle)$ aus dem reellen Vektorraum $(\mathbb{R}^m, +, \cdot)$ und dem Skalarprodukt $\langle\rangle$ auf $\mathbb{R}^m$ heißt *reeller kanonischer Euklidischer Vektorraum.*

•

Generell heißt jedes Tupel aus einem Vektorraum und einem Skalarprodukt "Euklidischer Vektorraum". Informell sprechen wir aber oft auch einfach von $\mathbb{R}^m$ als "Euklidischer Vektorraum" und insbesondere bei $((\mathbb{R}^m, +, \cdot), \langle\rangle)$ vom "Euklidischen Vektorraum". Ein Euklidischer Vektorraum ist ein Vektorraum mit geometrischer Struktur, die durch das Skalarprodukt induziert wird. Insbesondere bekommen im Euklidischen Vektorraum nun die geometrischen Begriffe von *Länge*, *Abstand* und *Winkel* eine Bedeutung. Wir definieren sie wie folgt.

Definition 8.6. $((\mathbb{R}^m, +, \cdot), \langle\rangle)$ sei der Euklidische Vektorraum.

(1) Die *Länge* eines Vektors $x \in \mathbb{R}^m$ ist definiert als

$$\|x\| := \sqrt{\langle x, x\rangle}. \tag{8.12}$$

(2) Der *Abstand* zweier Vektoren $x, y \in \mathbb{R}^m$ ist definiert als

$$d(x, y) := \|x - y\|. \tag{8.13}$$

(3) Der *Winkel* α zwischen zwei Vektoren $x, y \in \mathbb{R}^m$ mit $x, y \neq 0$ ist definiert durch

$$0 \leq \alpha \leq \pi \text{ und } \cos\alpha := \frac{\langle x, y\rangle}{\|x\|\|y\|} \tag{8.14}$$

•

Die Länge $\|x\|$ eines Vektors $x \in \mathbb{R}^m$ heißt auch *Euklidische Norm von* x oder ℓ_2*-Norm von* x oder einfach *Norm von* x. Sie wird häufig auch mit $\|x\|_2$ bezeichnet. Wir betrachten drei Beispiele für die Bestimmung der Länge eines Vektors und ihre entsprechende **R** Implementation. Wir veranschaulichen diese Beispiele in Abbildung 8.5.

Beispiel 8.2 (Norm des Vektors $(2, 0)^T$)**.**

$$\left\|\begin{pmatrix}2\\0\end{pmatrix}\right\| = \sqrt{\left\langle\begin{pmatrix}2\\0\end{pmatrix}, \begin{pmatrix}2\\0\end{pmatrix}\right\rangle} = \sqrt{2^2 + 0^2} = \sqrt{4} = 2.00 \tag{8.15}$$

```
norm(matrix(c(2,0),nrow = 2), type = "2")            # Vektorlänge = l_2 Norm
```

```
[1] 2
```

△

Beispiel 8.3 (Norm des Vektors $(2, 2)^T$)**.**

$$\left\|\begin{pmatrix}2\\2\end{pmatrix}\right\| = \sqrt{\left\langle\begin{pmatrix}2\\2\end{pmatrix}, \begin{pmatrix}2\\2\end{pmatrix}\right\rangle} = \sqrt{2^2 + 2^2} = \sqrt{8} \approx 2.83 \tag{8.16}$$

```
norm(matrix(c(2,2),nrow = 2), type = "2")            # Vektorlänge = l_2 Norm
```

```
[1] 2.828427
```

△

Beispiel 8.4 (Norm des Vektors $(2,4)^T$)**.**

$$\left\| \begin{pmatrix} 2 \\ 4 \end{pmatrix} \right\| = \sqrt{\left\langle \begin{pmatrix} 2 \\ 4 \end{pmatrix}, \begin{pmatrix} 2 \\ 4 \end{pmatrix} \right\rangle} = \sqrt{2^2 + 4^2} = \sqrt{20} \approx 4.47 \tag{8.17}$$

```
norm(matrix(c(2,4),nrow = 2), type = "2")            # Vektorlänge = l_2 Norm
```

```
[1] 4.472136
```

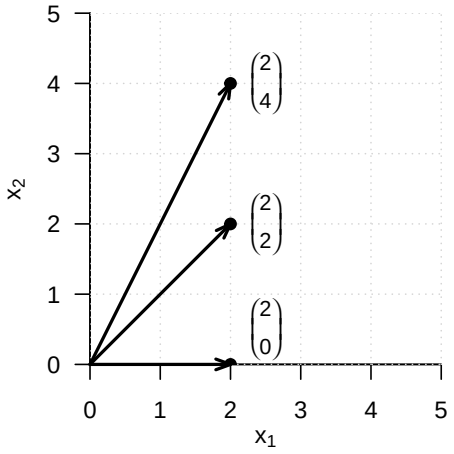


Abbildung 8.5. Vektorlänge in $\mathbb{R}^2$

△

Für den Abstand $d(x, y)$ zweier Vektoren $x, y \in \mathbb{R}^m$ halten wir ohne Beweis fest, dass er zum einen nicht-negativ und symmetrisch ist, also dass

$$d(x, y) \geq 0, d(x, x) = 0 \text{ und } d(x, y) = d(y, x) \tag{8.18}$$

gelten. Zudem erfüllt $d(x, y)$ die sogenannte *Dreiecksungleichung*, die besagt, dass die direkte Wegstrecke zwischen zwei Punkten im Raum immer kürzer ist als eine indirekte Wegstrecke über einen dritten Punkt,

$$d(x, y) \leq d(x, z) + d(z, y). \tag{8.19}$$

Damit erfüllt $d(x, y)$ wichtige Aspekte der räumlichen Anschauung. Wir geben zwei Beispiele für die Bestimmung von Abständen von Vektoren in $\mathbb{R}^2$, die wir in Abbildung 8.6 visualisieren.

Beispiel 8.5 (Abstand der Vektoren $(1,1)^T$ und $(2,2)^T$)**.**

$$d\left(\begin{pmatrix}1\\1\end{pmatrix},\begin{pmatrix}2\\2\end{pmatrix}\right) = \left\|\begin{pmatrix}1\\1\end{pmatrix} - \begin{pmatrix}2\\2\end{pmatrix}\right\| = \left\|\begin{pmatrix}-1\\-1\end{pmatrix}\right\| = \sqrt{(-1)^2 + (-1)^2} = \sqrt{2} \approx 1.41 \tag{8.20}$$

```
norm(matrix(c(1,1),nrow = 2) - matrix(c(2,2),nrow = 2), type = "2")
```

```
[1] 1.414214
```

△

Beispiel 8.6 (Abstand der Vektoren $(1,1)^T$ und $(4,1)^T$)**.**

$$d\left(\begin{pmatrix}1\\1\end{pmatrix},\begin{pmatrix}4\\1\end{pmatrix}\right) = \left\|\begin{pmatrix}1\\1\end{pmatrix} - \begin{pmatrix}4\\1\end{pmatrix}\right\| = \left\|\begin{pmatrix}-3\\0\end{pmatrix}\right\| = \sqrt{(-3)^2 + 0^2} = \sqrt{9} = 3 \tag{8.21}$$

```
norm(matrix(c(1,1),nrow = 2) - matrix(c(1,4),nrow = 2), type = "2")
```

```
[1] 3
```

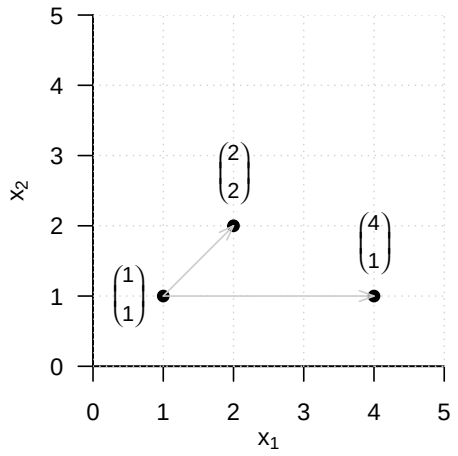


Abbildung 8.6. Vektorabstände in $\mathbb{R}^2$

△

Schließlich halten wir fest, dass für die Berechnung des Winkels zwischen zwei Vektoren anhand obiger Definition gilt, dass die Kosinusfunktion cos auf $[0, \pi]$ bijektiv, also invertierbar mit der Umkehrfunktion *acos*, der Arkuskosinusfunktion, ist. Auch für den Begriff des Winkels wollen wir zwei Beispiele betrachten. Man beachte dabei insbesondere, dass die Definition 8.6 den Winkel im Bogenmaß angibt. Für eine Angabe in Grad ist eine entsprechende Umrechnung erforderlich.

Beispiel 8.7 (Winkel zwischen den Vektoren $(3,0)^T$ und $(3,3)^T$).

$$\text{acos}\left(\frac{\left\langle \begin{pmatrix}3\\0\end{pmatrix}, \begin{pmatrix}3\\3\end{pmatrix} \right\rangle}{\left\| \begin{pmatrix}3\\0\end{pmatrix} \right\| \left\| \begin{pmatrix}3\\3\end{pmatrix} \right\|}\right) = \text{acos}\left(\frac{3\cdot 3 + 3\cdot 0}{\sqrt{3^2+0^2}\cdot\sqrt{3^2+3^2}}\right) = \text{acos}\left(\frac{9}{3\cdot\sqrt{18}}\right) = \frac{\pi}{4} \approx 0.785 \tag{8.22}$$

Die Umrechnung in Grad ergibt dann

$$0.785 \cdot \frac{180°}{\pi} = 45° \tag{8.23}$$

In **R** implementiert man dies wie folgt.

```
x = matrix(c(3,0), nrow = 2)                              # Vektor 1
y = matrix(c(3,3), nrow = 2)                              # Vektor 2
w = acos(sum(x*y)/(sqrt(sum(x*x))*sqrt(sum(y*y)))) * 180/pi  # Winkel in Grad
print(w)
```

```
[1] 45
```

△

Beispiel 8.8 (Winkel zwischen den Vektoren $(3,0)^T$ und $(0,3)^T$).

$$\alpha = \text{acos}\left(\frac{\left\langle \begin{pmatrix}3\\0\end{pmatrix}, \begin{pmatrix}0\\3\end{pmatrix} \right\rangle}{\left\| \begin{pmatrix}3\\0\end{pmatrix} \right\| \left\| \begin{pmatrix}0\\3\end{pmatrix} \right\|}\right) = \text{acos}\left(\frac{3\cdot 0 + 0\cdot 3}{\sqrt{3^2+0^2}\cdot\sqrt{0^2+3^2}}\right) = \text{acos}\left(\frac{0}{3\cdot 3}\right) = \frac{\pi}{2} \approx 1.57 \tag{8.24}$$

Die Umrechnung in Grad ergibt dann

$$\frac{\pi}{2} \cdot \frac{180°}{\pi} = 90° \tag{8.25}$$

Die entsprechende **R** Implementation lautet wie folgt.

```
x = matrix(c(3,0), nrow = 2)                              # Vektor 1
y = matrix(c(0,3), nrow = 2)                              # Vektor 2
w = acos(sum(x*y)/(sqrt(sum(x*x))*sqrt(sum(y*y)))) * 180/pi  # Winkel in Grad
print(w)
```

```
[1] 90
```

△

Die Tatsache, dass zwei Vektoren einen rechten Winkel bilden können, also gewissermaßen maximal nicht-parallel sein können, ist ein wichtiges geometrisches Prinzip und wird deshalb mit folgender Definition speziell ausgezeichnet.

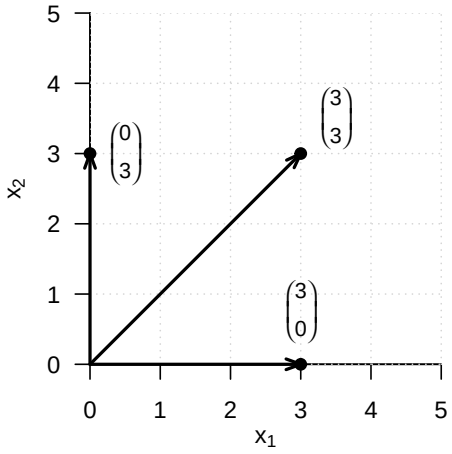


Abbildung 8.7. Winkel in $\mathbb{R}^2$

Definition 8.7 (Orthogonalität und Orthonormalität von Vektoren)**.** $((\mathbb{R}^m, +, \cdot), \langle\rangle)$ sei der Euklidische Vektorraum.

(1) Zwei Vektoren $x, y \in \mathbb{R}^m$ heißen *orthogonal*, wenn gilt, dass

$$\langle x, y \rangle = 0 \tag{8.26}$$

(2) Zwei Vektoren $x, y \in \mathbb{R}^m$ heißen *orthonormal*, wenn gilt, dass

$$\langle x, y \rangle = 0 \text{ und } \|x\| = \|y\| = 1. \tag{8.27}$$

•

Für orthogonale und orthonormale Vektoren gilt also insbesondere auch

$$\cos \alpha = \frac{\langle x, y \rangle}{\|x\|\|y\|} = \frac{0}{\|x\|\|y\|} = 0, \tag{8.28}$$

also

$$\alpha = \frac{\pi}{2} = 90°. \tag{8.29}$$

8.3. Lineare Unabhängigkeit

In diesem Abschnitt führen wir den Begriff der *linearen Unabhängigkeit* von Vektoren ein. Wir definieren dazu zunächst den Begriff der *Linearkombination* von Vektoren.

Definition 8.8 (Linearkombination)**.** $\{v_1, v_2, ..., v_k\}$ sei eine Menge von k Vektoren eines Vektorraums V und $a_1, a_2, ..., a_k$ seien Skalare. Dann ist die *Linearkombination* der Vektoren in $\{v_1, v_2, ..., v_k\}$ mit den *Koeffizienten* $a_1, a_2, ..., a_k$ definiert als der Vektor

$$w := \sum_{i=1}^{k} a_i v_i \in V. \tag{8.30}$$

•

Beispiel 8.9 (Linearkombination dreier Vektoren)**.** Es seien

$$v_1 := \begin{pmatrix} 2 \\ 1 \end{pmatrix}, v_2 := \begin{pmatrix} 1 \\ 1 \end{pmatrix}, v_3 := \begin{pmatrix} 0 \\ 1 \end{pmatrix} \text{ und } a_1 := 2, a_2 := 3, a_3 := 0. \tag{8.31}$$

Dann ergibt sich die Linearkombination von v_1, v_2, v_3 mit den Koeffizienten a_1, a_2, a_3 zu

$$\begin{aligned} w &= a_1 v_1 + a_2 v_2 + a_3 v_3 \\ &= 2 \cdot \begin{pmatrix} 2 \\ 1 \end{pmatrix} + 3 \cdot \begin{pmatrix} 1 \\ 1 \end{pmatrix} + 0 \cdot \begin{pmatrix} 0 \\ 1 \end{pmatrix} \\ &= \begin{pmatrix} 4 \\ 2 \end{pmatrix} + \begin{pmatrix} 3 \\ 3 \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ &= \begin{pmatrix} 7 \\ 5 \end{pmatrix}. \end{aligned} \tag{8.32}$$

△

Basierend auf dem Begriff der Linearkombination kann man nun den Begriff der *Linearen Unabhängigkeit* von Vektoren definieren.

Definition 8.9 (Lineare Unabhängigkeit)**.** V sei ein Vektorraum. Eine Menge $W := \{w_1, w_2, ..., w_k\}$ von Vektoren in V heißt *linear unabhängig*, wenn die einzige Repräsentation des Nullelements $0 \in V$ durch eine Linearkombination der $w \in W$ die sogenannte *triviale Repräsentation*

$$0 = a_1 w_1 + a_2 w_2 + \cdots + a_k w_k \text{ mit } a_1 = a_2 = \cdots = a_k = 0 \tag{8.33}$$

ist. Wenn die Menge W nicht linear unabhängig ist, dann heißt sie *linear abhängig*.

•

Um zu prüfen, ob eine gegebene Menge von Vektoren linear abhängig oder unabhängig ist, muss man prinzipiell prüfen, ob eine mögliche Linearkombination der gegebenen Vektoren null ist. Theorem 8.2 und Theorem 8.3 zeigen, wie dies für zwei bzw. endlich viele Vektoren auch mit weniger Aufwand gelingen kann.

Theorem 8.2 (Lineare Abhängigkeit von zwei Vektoren)**.** *V sei ein Vektorraum. Zwei Vektoren $v_1, v_2 \in V$ sind linear abhängig, wenn einer der Vektoren ein skalares Vielfaches des anderen Vektors ist.*

◦

Beweis. v_1 sei ein skalares Vielfaches von v_2, also

$$v_1 = \lambda v_2 \text{ mit } \lambda \neq 0. \tag{8.34}$$

Dann gilt

$$v_1 - \lambda v_2 = 0. \tag{8.35}$$

Dies aber entspricht der Linearkombination

$$a_1 v_1 + a_2 v_2 = 0 \tag{8.36}$$

mit $a_1 = 1 \neq 0$ und $a_2 = -\lambda \neq 0$. Es gibt also eine Linearkombination des Nullelementes, die nicht die triviale Repräsentation ist, und damit sind v_1 und v_2 nicht linear unabhängig. □

Theorem 8.3 (Lineare Abhängigkeit einer Menge von Vektoren)**.** *V sei ein Vektorraum und $w_1, ..., w_k \in V$ sei eine Menge von Vektoren in V. Wenn einer der Vektoren w_i mit $i = 1, ..., k$ eine Linearkombination der anderen Vektoren ist, dann ist die Menge der Vektoren linear abhängig.*

∘

Beweis. Die Vektoren $w_1, ..., w_k$ sind genau dann linear abhängig, wenn gilt, dass $\sum_{i=1}^{k} a_i w_i = 0$ mit mindestens einem $a_i \neq 0$. Es sei also zum Beispiel $a_j \neq 0$. Dann gilt

$$0 = \sum_{i=1}^{k} a_i w_i = \sum_{i=1, i\neq j}^{k} a_i w_i + a_j w_j \tag{8.37}$$

Also folgt

$$a_j w_j = -\sum_{i=1, i\neq j}^{k} a_i w_i \tag{8.38}$$

und damit

$$w_j = -a_j^{-1} \sum_{i=1, i\neq j}^{k} a_i w_i = -\sum_{i=1, i\neq j}^{k} (a_j^{-1} a_i) w_i \tag{8.39}$$

Also ist w_j eine Linearkombination der w_i für $i = 1, ..., k$ mit $i \neq j$. □

8.4. Vektorraumbasen

In diesem Abschnitt wollen wir den Begriff der *Vektorraumbasis* einführen. Eine Basis eines Vektorraums ist eine Untermenge von Vektoren des Vektorraums, die zur Darstellung aller Vektoren des Vektorraums genutzt werden kann. Im Sinne der linearen Kombination von Vektoren enthält also eine Vektorraumbasis alle nötigen Informationen zur Konstruktion des entsprechenden Vektorraums. Allerdings ist eine Vektorraumbasis in der Regel nicht eindeutig und viele Vektorräume haben in der Tat unendlich viele Basen. Die folgende Definition sagt zunächst aus, wie aus einer beschränkten Anzahl von Vektoren mithilfe von Linearkombinationen unendlich viele Vektoren gebildet werden können.

Definition 8.10 (Lineare Hülle und Aufspannen)**.** V sei ein Vektorraum und es sei $W := \{w_1, ..., w_k\} \subset V$. Dann ist die *lineare Hülle* von W definiert als die Menge aller Linearkombinationen der Elemente von W,

$$\text{Span}(W) := \left\{ \sum_{i=1}^{k} a_i w_i | a_1, ..., a_k \text{ sind skalare Koeffizienten} \right\} \tag{8.40}$$

Man sagt, dass eine Menge von Vektoren $W \subseteq V$ *einen Vektorraum* V *aufspannt*, wenn jedes $v \in V$ als eine Linearkombination von Vektoren in W geschrieben werden kann.

•

Wir definieren nun den Begriff der *Basis* eines Vektorraums.

Definition 8.11 (Basis)**.** V sei ein Vektorraum und es sei $B \subseteq V$. B heißt eine *Basis von* V, wenn

(1) die Vektoren in B linear unabhängig sind und
(2) die Vektoren in B den Vektorraum V aufspannen.

•

Basen von Vektorräumen haben folgende wichtige Eigenschaften.

Theorem 8.4 (Eigenschaften von Basen)**.**

(1) Alle Basen eines Vektorraums beinhalten die gleiche Anzahl von Vektoren.
(2) Jede Menge von m linear unabhängigen Vektoren ist Basis eines m-dimensionalen Vektorraums.

◦

Für einen Beweis dieses sehr tiefen Theorems verweisen wir auf die weiterführende Literatur. Die mit obigem Theorem benannte eindeutige Anzahl der Vektoren einer Basis eines Vektorraums heißt die *Dimension des Vektorraums*. Da es in der Regel unendlich viele Mengen von m linear unabhängigen Vektoren in einem Vektorraum gibt, haben Vektorräume in der Regel unendlich viele Basen.

Betrachtet man nun einen einzelnen Vektor in einem Vektorraum, so kann man sich fragen, wie man diesen mithilfe einer Vektorraumbasis darstellen kann. Dies führt auf folgende Begriffsbildungen.

Definition 8.12 (Basisdarstellung und Koordinaten)**.** $B := \{b_1, ..., b_m\}$ sei eine Basis eines m-dimensionalen Vektorraumes V und es sei $v \in V$. Dann heißt die Linearkombination

$$v = \sum_{i=1}^{m} c_i b_i \tag{8.41}$$

die *Darstellung von v bezüglich der Basis B* und die Koeffizienten $c_1, ..., c_m$ heißen die *Koordinaten von v bezüglich der Basis B*.

•

Bei fester Basis sind auch die Koordinaten eines Vektors bezüglich dieser Basis fest und eindeutig. Dies ist die Aussage des folgenden Theorems.

Theorem 8.5 (Eindeutigkeit der Basisdarstellung)**.** *Die Basisdarstellung eines $v \in V$ bezüglich einer Basis B ist eindeutig.*

◦

Beweis. Ohne Beschränkung der Allgemeinheit nehmen wir an, dass der Vektorraum von Dimension m ist. Nehmen wir an, dass zwei Darstellungen von v bezüglich der Basis B existieren, also dass

$$\begin{aligned} v &= a_1 b_1 + \cdots + a_m b_m \\ v &= c_1 b_1 + \cdots + c_m b_m \end{aligned} \tag{8.42}$$

Subtraktion der unteren von der oberen Gleichung ergibt

$$0 = (a_1 - c_1)b_1 + \cdots + (a_m - c_m)b_m \tag{8.43}$$

Weil die $b_1, ..., b_m$ linear unabhängig sind, gilt aber, dass $(a_i - c_i) = 0$ für alle $i = 1, ..., m$ und somit sind die beiden Darstellungen von v bezüglich der Basis B identisch. □

Zum Abschluss dieses Abschnitts wollen wir eine spezielle Basis des reellen Vektorraums betrachten.

Definition 8.13 (Orthonormalbasis von $\mathbb{R}^m$)**.** Eine Menge von m Vektoren $v_1, ..., v_m \in \mathbb{R}^m$ heißt *Orthonormalbasis* von $\mathbb{R}^m$, wenn $v_1, ..., v_m$ jeweils die Länge 1 haben und wechselseitig orthogonal sind, also wenn

$$\langle v_i, v_j \rangle = \begin{cases} 1 & \text{für } i = j \\ 0 & \text{für } i \neq j \end{cases}. \tag{8.44}$$

•

Wir wollen zunächst ein Beispiel für eine Orthonormalbasis betrachten.

Beispiel 8.10 (Kanonische Orthonormalbasis von $\mathbb{R}^2$)**.** Es ist

$$B_1 := \left\{ \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \end{pmatrix} \right\} \tag{8.45}$$

eine Orthonormalbasis von $\mathbb{R}^2$, denn B_1 besteht aus zwei Vektoren und es gelten

$$\left\langle \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \end{pmatrix} \right\rangle = 1 \cdot 1 + 0 \cdot 0 = 1 + 0 = 1 \tag{8.46}$$

sowie

$$\left\langle \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \end{pmatrix} \right\rangle = 0 \cdot 0 + 1 \cdot 1 = 0 + 1 = 1 \tag{8.47}$$

und

$$\left\langle \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \end{pmatrix} \right\rangle = 1 \cdot 0 + 0 \cdot 1 = 0 + 0 = 0 \tag{8.48}$$

△

Für allgemeine reelle Vektorräume werden Basen der Form von B_1 mit dem Begriff der *kanonischen Basis* speziell ausgezeichnet.

Definition 8.14 (Kanonische Basis und kanonische Einheitsvektoren)**.** Die Orthonormalbasis

$$B := \left\{ e_1, ..., e_m | (e_i)_j = 1 \text{ für } i = j \text{ und } (e_i)_j = 0 \text{ für } i \neq j,\ i, j = 1, ..., m \right\} \subset \mathbb{R}^m \tag{8.49}$$

heißt die *kanonische Basis* von $\mathbb{R}^m$ und die e_i heißen *kanonische Einheitsvektoren.*

•

B_1 aus Beispiel (1) ist also die kanonische Basis von $\mathbb{R}^2$.

Die kanonische Basis von $\mathbb{R}^3$ ist

$$B := \left\{ \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} \right\}. \tag{8.50}$$

Allerdings gibt es auch nicht kanonische Orthonormalbasen. Dazu betrachten wir ein weiteres Beispiel

Beispiel 8.11 (Gedrehte Orthonormalbasis von $\mathbb{R}^2$)**.** Es ist auch

$$B_2 := \left\{ \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}, \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} \right\} \tag{8.51}$$

eine Orthonormalbasis von $\mathbb{R}^2$, denn B_2 besteht aus zwei Vektoren und es gelten

$$\left\langle \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}, \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} \right\rangle = \frac{1}{\sqrt{2}} \cdot \frac{1}{\sqrt{2}} + \frac{1}{\sqrt{2}} \cdot \frac{1}{\sqrt{2}} = \frac{1}{2} + \frac{1}{2} = 1, \tag{8.52}$$

sowie

$$\left\langle \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}, \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} \right\rangle = \left(-\frac{1}{\sqrt{2}}\right) \cdot \left(-\frac{1}{\sqrt{2}}\right) + \frac{1}{\sqrt{2}} \cdot \frac{1}{\sqrt{2}} = \frac{1}{2} + \frac{1}{2} = 1 \tag{8.53}$$

und

$$\left\langle \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}, \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} \right\rangle = -\frac{1}{\sqrt{2}} \cdot \frac{1}{\sqrt{2}} + \frac{1}{\sqrt{2}} \cdot \frac{1}{\sqrt{2}} = -\frac{1}{2} + \frac{1}{2} = 0 \tag{8.54}$$

Wir visualisieren die beiden Orthonormalbasen B_1 und B_2 von $\mathbb{R}^2$ in Abbildung 8.8.

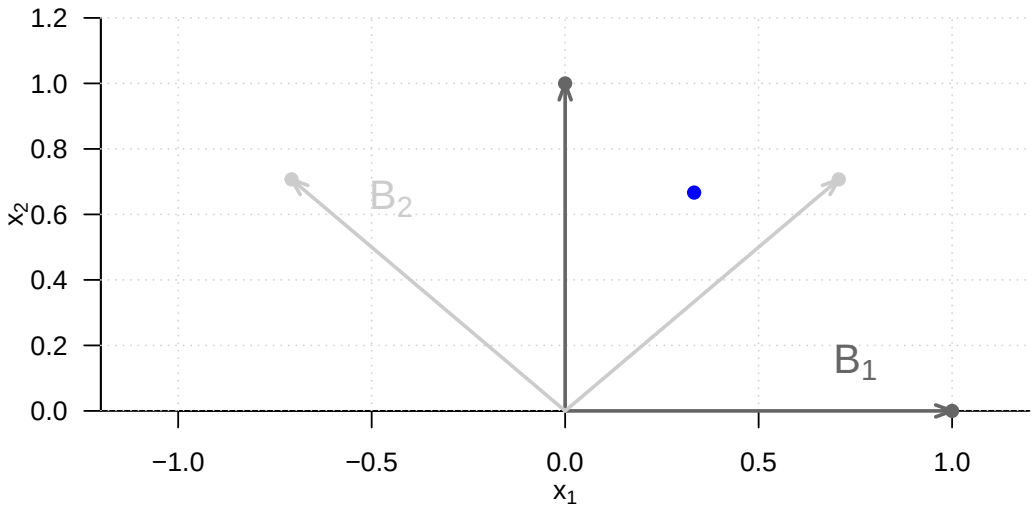


Abbildung 8.8. Zwei Basen von $\mathbb{R}^2$

△

9. Matrizen

Matrizen sind die Worte der Sprache der modernen Datenanalyse. Ein Verständnis moderner datenanalytischer Verfahren und ihrer Implementation ist ohne ein Grundverständnis des Matrixbegriffs und ein Wissen um die grundlegenden Matrixoperationen nicht möglich. Matrizen können dabei sehr unterschiedliche Rollen spielen. So können Matrizen zum Beispiel Daten, experimentelle Designs und Modellparameter repräsentieren. Im Kontext der Linearen Algebra dienen Matrizen zur Repräsentation linearer Abbildungen und von Vektorräumen, hier werden Vektoren dann als spezielle Matrizen aufgefasst.

In diesem Kapitel geben wir eine Einführung zum Umgang mit Matrizen, wobei wir auf abstrakte Begrifflichkeiten der Linearen Algebra im Wesentlichen verzichten. Wir führen zunächst den Matrixbegriff ein und diskutieren dann mit der Matrixaddition, Matrixsubtraktion, Skalarmultiplikation und der Matrixtransposition erste grundlegende Matrixoperationen (Kapitel 9.1 und Kapitel 9.2). Wir führen dann die zentralen Begriffe der Matrixmultiplikation und der Matrixinversion ein (Kapitel 9.3 und Kapitel 9.4). Mit der Matrixdeterminante diskutieren wir dann in Kapitel 9.5 eine erste Maßzahl zur Beschreibung von Matrizen. Wir schließen in Kapitel 9.6 mit einer Übersicht zu besonders häufig auftretenden Matrizen.

9.1. Definition

Wir beginnen mit der Definition einer Matrix.

Definition 9.1. Eine Matrix ist eine rechteckige Anordnung von Zahlen, die wie folgt bezeichnet wird

$$A := \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{pmatrix} := (a_{ij})_{1 \leq i \leq n,\, 1 \leq j \leq m}. \tag{9.1}$$

•

Matrizen bestehen aus *Zeilen (rows)* und *Spalten (columns)*. Die Matrixeinträge a_{ij} werden mit einem *Zeilenindex* i und einem *Spaltenindex* j indiziert. Zum Beispiel gilt für

$$A := \begin{pmatrix} 2 & 7 & 5 & 2 \\ 8 & 2 & 5 & 6 \\ 6 & 4 & 0 & 9 \\ 9 & 2 & 1 & 2 \end{pmatrix}, \tag{9.2}$$

dass $a_{32} = 4$. Die *Größe* oder *Dimension* einer Matrix ergibt sich aus der Anzahl ihrer Zeilen $n \in \mathbb{N}$ und Spalten $m \in \mathbb{N}$. Matrizen mit $n = m$ heißen *quadratische Matrizen*.

In der Folge benötigen wir nur Matrizen mit reellen Einträgen, also $a_{ij} \in \mathbb{R}$ für alle $i = 1, ..., n$ und $j = 1, ..., m$. Wir nennen die Matrizen mit reellen Einträgen *reelle Matrizen* und bezeichnen die Menge der reellen Matrizen mit n Zeilen und m Spalten mit $\mathbb{R}^{n \times m}$. An dem Ausdruck

$$A \in \mathbb{R}^{n \times m} \tag{9.3}$$

können wir also ablesen, dass A eine reelle Matrix mit n Zeilen und m Spalten ist. Wir identifizieren dabei die Menge $\mathbb{R}^{1 \times 1}$ mit der Menge $\mathbb{R}$, die Menge $\mathbb{R}^{n \times 1}$ mit der Menge $\mathbb{R}^n$. Reelle Matrizen mit einer Spalte und n Zeilen entsprechen also n-dimensionalen reellen Vektoren und reelle Matrizen mit einer Spalte und einer Zeile entsprechen reellen Zahlen.

Definition von Matrizen in R

In **R** werden Matrizen definiert, indem **R** Vektoren mithilfe der `matrix()` Funktion in die Repräsentation einer mathematischen Matrix transformiert werden. Die Einträge eines **R** Vektors werden dabei anhand der spezifizierten Zeilenanzahl `nrow` entsprechend ihrer Gesamtanzahl auf die Matrix verteilt. Wollen wir beispielsweise die Matrix

$$A := \begin{pmatrix} 2 & 3 & 0 \\ 1 & 6 & 5 \end{pmatrix} \tag{9.4}$$

in **R** definieren, so ergibt sich

```
# Spaltenweise Definition von A (R default)
A = matrix(c(2,1,3,6,0,5), nrow = 2)
print(A)
```

```
     [,1] [,2] [,3]
[1,]    2    3    0
[2,]    1    6    5
```

R folgt hier per default einer sogenannten *column-major-order*, das heißt, die Elemente des **R** Vektors `c(2,1,3,6,0,5)` werden der Reihe nach von oben nach unten in die Spalten der Matrix von links nach rechts überführt. Einen etwas klareren Zusammenhang zwischen dem visuellen Layout des **R** Codes und der resultierenden Matrix erhält man, indem man den **R** Vektor mithilfe von Zeilenumbrüchen anhand des intendierten Matrixlayouts formatiert und dann die column-major-order mithilfe des Arguments `byrow = TRUE` zu einer *row-major-order* umstellt. Es wird dann zunächst die erste Zeile der Matrix von links nach rechts mit den Elementen des **R** Vektors gefüllt und dann die zweite Zeile usw. bis alle Elemente des Vektors auf die Matrix verteilt sind.

```
# Zeilenweise Definition von A (byrow = TRUE)
A = matrix(c(2,3,0,
             1,6,5),
             nrow = 2,
             byrow = TRUE)
print(A)
```

```
     [,1] [,2] [,3]
[1,]    2    3    0
[2,]    1    6    5
```

```
# Zeilenweise Definition von B
B = matrix(c(4,1,0,
            -4,2,0),
            nrow = 2,
            byrow = TRUE)
print(B)
```

```
     [,1] [,2] [,3]
[1,]    4    1    0
[2,]   -4    2    0
```

9.2. Grundlegende Matrixoperationen

Man kann mit Matrizen rechnen. Dabei sind folgende Matrixoperationen grundlegend:

- Die Addition von Matrizen gleicher Größe, genannt *Matrixaddition*,
- die Subtraktion von Matrizen gleicher Größe, genannt *Matrixsubtraktion*,
- die Multiplikation einer Matrix mit einem Skalar, genannt *Skalarmultiplikation*,
- das Vertauschen der Zeilen und Spalten einer Matrix, genannt *Matrixtransposition*.

Wir führen diese Operationen in der Folge in Operatorform, also als Funktionen ein. Dies dient insbesondere dazu, bei jeder Operation mit Hilfe ihrer Definitionsmenge zu betonen, von welcher Art die Objekte der jeweiligen Operation sind und mithilfe ihrer Bildmenge zu betonen, von welcher Art das Resultat der jeweiligen Operation ist.

9.2.1. Matrixaddition

Definition 9.2. Es seien $A, B \in \mathbb{R}^{n\times m}$. Dann ist die *Addition* von A und B definiert als die Abbildung

$$+ : \mathbb{R}^{n\times m} \times \mathbb{R}^{n\times m} \to \mathbb{R}^{n\times m},\ (A, B) \mapsto +(A, B) := A + B \tag{9.5}$$

mit

$$\begin{aligned} A + B &= \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{pmatrix} + \begin{pmatrix} b_{11} & b_{12} & \cdots & b_{1m} \\ b_{21} & b_{22} & \cdots & b_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ b_{n1} & b_{n2} & \cdots & b_{nm} \end{pmatrix} \\ &:= \begin{pmatrix} a_{11} + b_{11} & a_{12} + b_{12} & \cdots & a_{1m} + b_{1m} \\ a_{21} + b_{21} & a_{22} + b_{22} & \cdots & a_{2m} + b_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} + b_{n1} & a_{n2} + b_{n2} & \cdots & a_{nm} + b_{nm} \end{pmatrix}. \end{aligned} \tag{9.6}$$

•

Die Definition der Matrixaddition legt insbesondere fest, dass nur Matrizen gleicher Größe addiert werden können und dass die Operation der Matrixaddition elementweise definiert ist.

Beispiel 9.1 (Matrixaddition)**.** Es seien $A, B \in \mathbb{R}^{2\times 3}$ definiert als

$$A := \begin{pmatrix} 2 & -3 & 0 \\ 1 & 6 & 5 \end{pmatrix} \text{ und } B := \begin{pmatrix} 4 & 1 & 0 \\ -4 & 2 & 0 \end{pmatrix}. \tag{9.7}$$

Da A und B gleich groß sind, können wir sie addieren

$$\begin{aligned} C = A + B &= \begin{pmatrix} 2 & -3 & 0 \\ 1 & 6 & 5 \end{pmatrix} + \begin{pmatrix} 4 & 1 & 0 \\ -4 & 2 & 0 \end{pmatrix} \\ &= \begin{pmatrix} 2+4 & -3+1 & 0+0 \\ 1-4 & 6+2 & 5+0 \end{pmatrix} \\ &= \begin{pmatrix} 6 & -2 & 0 \\ -3 & 8 & 5 \end{pmatrix}. \end{aligned} \tag{9.8}$$

In **R** führt man obige Rechnung wie folgt aus.

```r
# Definition
A = matrix(c(2, -3, 0,
             1,  6, 5),
           nrow  = 2,
           byrow = TRUE)
B = matrix(c( 4, 1, 0,
             -4, 2, 0),
            nrow = 2,
           byrow = TRUE)

# Addition
C = A + B
print(C)
```

```
     [,1] [,2] [,3]
[1,]    6   -2    0
[2,]   -3    8    5
```

△

9.2.2. Matrixsubtraktion

Die Subtraktion von Matrizen gleicher Größe ist analog zur Addition definiert.

Definition 9.3 (Matrixsubtraktion)**.** Es seien $A, B \in \mathbb{R}^{n \times m}$. Dann ist die *Subtraktion* von A und B definiert als die Abbildung

$$- : \mathbb{R}^{n \times m} \times \mathbb{R}^{n \times m} \to \mathbb{R}^{n \times m},\ (A, B) \mapsto -(A, B) := A - B \tag{9.9}$$

mit

$$\begin{aligned} A - B &= \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{pmatrix} - \begin{pmatrix} b_{11} & b_{12} & \cdots & b_{1m} \\ b_{21} & b_{22} & \cdots & b_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ b_{n1} & b_{n2} & \cdots & b_{nm} \end{pmatrix} \\ &:= \begin{pmatrix} a_{11} - b_{11} & a_{12} - b_{12} & \cdots & a_{1m} - b_{1m} \\ a_{21} - b_{21} & a_{22} - b_{22} & \cdots & a_{2m} - b_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} - b_{n1} & a_{n2} - b_{n2} & \cdots & a_{nm} - b_{nm} \end{pmatrix}. \end{aligned} \tag{9.10}$$

•

Wie bei der Matrixaddition legt die Definition der Matrixsubtraktion fest, dass nur Matrizen gleicher Größe voneinander subtrahiert werden können und dass die Subtraktion zweier gleich großer Matrizen elementweise definiert ist.

Beispiel 9.2 (Matrixsubtraktion)**.** Wir können die im Beispiel zur Matrixaddition definierten Matrizen A und B auch voneinander subtrahieren,

$$\begin{aligned} D = A - B &= \begin{pmatrix} 2 & -3 & 0 \\ 1 & 6 & 5 \end{pmatrix} - \begin{pmatrix} 4 & 1 & 0 \\ -4 & 2 & 0 \end{pmatrix} \\ &= \begin{pmatrix} 2-4 & -3-1 & 0-0 \\ 1+4 & 6-2 & 5-0 \end{pmatrix} \\ &= \begin{pmatrix} -2 & -4 & 0 \\ 5 & 4 & 5 \end{pmatrix}. \end{aligned} \tag{9.11}$$

In **R** führt man diese Rechnung wie folgt aus.

```
# Subtraktion
D = A - B
print(D)
```

```
     [,1] [,2] [,3]
[1,]   -2   -4    0
[2,]    5    4    5
```

△

9.2.3. Skalarmultiplikation

Die *Skalarmultiplikation* einer Matrix bezeichnet die Multiplikation eines Skalars mit einer Matrix.

Definition 9.4 (Skalarmultiplikation)**.** Es sei $c \in \mathbb{R}$ ein Skalar und $A \in \mathbb{R}^{n \times m}$. Dann ist die *Skalarmultiplikation* von c und A definiert als die Abbildung

$$\cdot : \mathbb{R} \times \mathbb{R}^{n \times m} \to \mathbb{R}^{n \times m},\ (c, A) \mapsto \cdot(c, A) := cA \tag{9.12}$$

mit

$$cA = c \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{pmatrix} := \begin{pmatrix} ca_{11} & ca_{12} & \cdots & ca_{1m} \\ ca_{21} & ca_{22} & \cdots & ca_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ ca_{n1} & ca_{n2} & \cdots & ca_{nm} \end{pmatrix}. \tag{9.13}$$

•

Die Skalarmultiplikation ist mit dieser Definition also elementweise definiert.

Beispiel 9.3 (Skalarmultiplikation einer Matrix)**.** Es seien $c := -3$ und $A \in \mathbb{R}^{4 \times 3}$ definiert als

$$A := \begin{pmatrix} 3 & 1 & 1 \\ 5 & 2 & 5 \\ 2 & 7 & 1 \\ 3 & 4 & 2 \end{pmatrix}. \tag{9.14}$$

Dann ergibt sich

$$B := cA = -3 \begin{pmatrix} 3 & 1 & 1 \\ 5 & 2 & 5 \\ 2 & 7 & 1 \\ 3 & 4 & 2 \end{pmatrix} = \begin{pmatrix} -3 \cdot 3 & -3 \cdot 1 & -3 \cdot 1 \\ -3 \cdot 5 & -3 \cdot 2 & -3 \cdot 5 \\ -3 \cdot 2 & -3 \cdot 7 & -3 \cdot 1 \\ -3 \cdot 3 & -3 \cdot 4 & -3 \cdot 2 \end{pmatrix} = \begin{pmatrix} -9 & -3 & -3 \\ -15 & -6 & -15 \\ -6 & -21 & -3 \\ -9 & -12 & -6 \end{pmatrix}. \tag{9.15}$$

In **R** führt man diese Skalarmultiplikation aus wie folgt.

```
# Definitionen
A = matrix(c(3,1,1,
             5,2,5,
             2,7,1,
             3,4,2),
           nrow = 4,
           byrow = TRUE)
c = -3

# Skalarmultiplikation
B = c*A
print(B)
```

```
     [,1] [,2] [,3]
[1,]   -9   -3   -3
[2,]  -15   -6  -15
[3,]   -6  -21   -3
[4,]   -9  -12   -6
```

△

Mithilfe der Definition von Matrixaddition und Skalarmultiplikation ist es möglich, einen Vektorraum zu definieren, dessen Elemente die reellen Matrizen sind. Insbesondere legt diese Definition auch die Rechenregeln beim Umgang mit Matrixaddition und Skalarmultiplikation fest.

Theorem 9.1 (Vektorraum der reellwertigen Matrizen)**.** *Das Tripel* $(\mathbb{R}^{n\times m}, +, \cdot)$ *mit der oben definierten Matrixaddition und Skalarmultiplikation ist ein Vektorraum. Insbesondere gelten damit für* $A, B, C \in \mathbb{R}^{n\times m}$ *und* $r, s, t \in \mathbb{R}$ *folgende Rechenregeln:*

(1) Kommutativität der Addition: $A + B = B + A$.
(2) Assoziativität der Addition: $(A + B) + C = A + (B + C)$.
(3) Existenz eines neutralen Elements der Addition: $\exists\, 0 \in \mathbb{R}^{n\times m}$ *mit* $A + 0 = 0 + A = A$.
(4) Existenz inverser Elemente der Addition: $\forall A \exists -A \in \mathbb{R}^{n\times m}$ *mit* $A + (-A) = 0$.
(5) Existenz eines neutralen Elements der Skalarmultiplikation: $\exists\, 1 \in \mathbb{R}$ *mit* $1 \cdot A = A$.
(6) Assoziativität der Skalarmultiplikation: $r \cdot (s \cdot A) = (r \cdot s) \cdot A$.
(7) Distributivität hinsichtlich der Matrixaddition: $r \cdot (A + B) = r \cdot A + r \cdot B$.
(8) Distributivität hinsichtlich der Skalaraddition: $(r + s) \cdot A = r \cdot A + s \cdot A$.

∘

Wir verzichten auf einen Beweis, der sich mit einigem Notationsaufwand direkt aus dem elementweisen Charakter von Matrixaddition und Skalarmultiplikation sowie den aus dem Umgang mit den reellen Zahlen bekannten Rechenregeln ergibt. Das im Theorem erwähnte neutrale Element der Addition wird *Nullmatrix* genannt, wir werden dazu später eine allgemeine Notation einführen. Die inversen Elemente der Addition sind durch

$$-A := (-a_{ij})_{1\leq i\leq n, 1\leq j\leq m} \tag{9.16}$$

gegeben und erlauben es, die Matrixsubtraktion als Spezialfall der Matrixaddition zu betrachten.

9.2.4. Matrixtransposition

Eine weitere häufig auftretende grundlegende Matrixoperation ist das Vertauschen der Zeilen- und Spaltenanordnung einer Matrix, genannt *Matrixtransposition*.

Definition 9.5 (Matrixtransposition)**.** Es sei $A \in \mathbb{R}^{n\times m}$. Dann ist die *Transposition* von A definiert als die Abbildung

$$\cdot^T : \mathbb{R}^{n\times m} \to \mathbb{R}^{m\times n},\ A \mapsto \cdot^T(A) := A^T \tag{9.17}$$

mit

$$A^T = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{pmatrix}^T := \begin{pmatrix} a_{11} & a_{21} & \cdots & a_{n1} \\ a_{12} & a_{22} & \cdots & a_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1m} & a_{2m} & \cdots & a_{nm} \end{pmatrix}. \tag{9.18}$$

•

Für $A \in \mathbb{R}^{n \times m}$ gilt damit also immer $A^T \in \mathbb{R}^{m \times n}$. Weiterhin gelten folgende Rechenregeln der Matrixtransposition, wie man sich an Beispielen klar macht:

(1) Für $A \in \mathbb{R}^{1 \times 1}$ gilt

$$A^T = A. \tag{9.19}$$

(2) Es gilt

$$\left(A^T\right)^T = A. \tag{9.20}$$

(3) Es gilt

$$(a_{ii})_{1 \leq i \leq \min(n,m)} = (a_{ii})^T_{1 \leq i \leq \min(n,m)}. \tag{9.21}$$

Letztere Eigenschaft der Transposition besagt, dass die Elemente auf der Hauptdiagonalen einer Matrix bei Transposition unberührt bleiben.

Beispiel 9.4 (Matrixtransposition)**.** Es sei $A \in \mathbb{R}^{2 \times 3}$ definiert durch

$$A := \begin{pmatrix} 2 & 3 & 0 \\ 1 & 6 & 5 \end{pmatrix}, \tag{9.22}$$

Dann gilt $A^T \in \mathbb{R}^{3 \times 2}$ und speziell

$$A^T := \begin{pmatrix} 2 & 1 \\ 3 & 6 \\ 0 & 5 \end{pmatrix}. \tag{9.23}$$

Weiterhin gilt offenbar $\min(m, n) = 2$ und folglich

$$(a_{11}) = (a_{11})^T \text{ und } (a_{22}) = (a_{22})^T. \tag{9.24}$$

In **R** führt man die Transposition einer Matrix wie folgt durch.

```
# Definition
A = matrix(c(2,3,0,
             1,6,5),
           nrow = 2,
           byrow = TRUE)
print(A)
```

```
     [,1] [,2] [,3]
[1,]    2    3    0
[2,]    1    6    5
```

```
# Transposition
AT = t(A)
print(AT)
```

```
     [,1] [,2]
[1,]    2    1
[2,]    3    6
[3,]    0    5
```

△

Schließlich gelten in der Verbindung mit der Matrixaddition, Matrixsubtraktion und der Skalarmultiplikation folgende Rechenregeln, wie man sich an Beispielen klar macht:

(1) Für $A, B \in \mathbb{R}^{n \times m}$ gilt
$$(A + B)^T = A^T + B^T. \tag{9.25}$$

(2) Für $A, B \in \mathbb{R}^{n \times m}$ gilt
$$(A - B)^T = A^T - B^T. \tag{9.26}$$

(3) Für $c \in \mathbb{R}$ und $A \in \mathbb{R}^{n \times m}$ gilt
$$(cA)^T = cA^T. \tag{9.27}$$

9.3. Matrixmultiplikation

Die Matrixmultiplikation ist die zentrale Operation beim Rechnen mit Matrizen. Sie ist definiert wie folgt.

Definition 9.6 (Matrixmultiplikation)**.** Es seien $A \in \mathbb{R}^{n \times m}$ und $B \in \mathbb{R}^{m \times k}$. Dann ist die *Matrixmultiplikation* von A und B definiert als die Abbildung

$$\cdot : \mathbb{R}^{n \times m} \times \mathbb{R}^{m \times k} \to \mathbb{R}^{n \times k},\ (A, B) \mapsto \cdot(A, B) := AB \tag{9.28}$$

mit

$$\begin{aligned} AB &= \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{pmatrix} \begin{pmatrix} b_{11} & b_{12} & \cdots & b_{1k} \\ b_{21} & b_{22} & \cdots & b_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ b_{m1} & b_{m2} & \cdots & b_{mk} \end{pmatrix} \\ &:= \begin{pmatrix} \sum_{i=1}^m a_{1i} b_{i1} & \sum_{i=1}^m a_{1i} b_{i2} & \cdots & \sum_{i=1}^m a_{1i} b_{ik} \\ \sum_{i=1}^m a_{2i} b_{i1} & \sum_{i=1}^m a_{2i} b_{i2} & \cdots & \sum_{i=1}^m a_{2i} b_{ik} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^m a_{ni} b_{i1} & \sum_{i=1}^m a_{ni} b_{i2} & \cdots & \sum_{i=1}^m a_{ni} b_{ik} \end{pmatrix} \\ &= \left(\sum_{i=1}^m a_{ji} b_{il} \right)_{1 \le j \le n, 1 \le l \le k} \end{aligned} \tag{9.29}$$

•

Das Matrixprodukt AB ist also nur dann definiert, wenn A genau so viele Spalten hat wie B Zeilen hat. Informell gilt für die beteiligten Matrixgrößen dabei die Merkregel

$$(n \times m)(m \times k) = (n \times k). \tag{9.30}$$

Der Eintrag $(AB)_{ij}$ in AB entspricht der Summe der multiplizierten $i$ten Zeile von A und $j$ten Spalte von B. Zum Berechnen von $(AB)_{ij}$ geht man für $i = 1, ..., n$ und $j = 1, ..., k$ also in Gedanken wie folgt vor:

(1) Man legt die Transposition der $i$ten Zeile von A über die $j$te Spalte von B.

(2) Weil A genau m Spalten hat und B genau m Zeilen hat, gibt es dann zu jedem Element der Zeile aus A ein korrespondierendes Element in der Spalte von B.
(3) Man multipliziert die korrespondierenden Elemente miteinander.
(4) Die Summe dieser Produkte ist dann der Eintrag mit Index ij in AB.

Beispiel 9.5 (Matrixmultiplikation)**.** $A \in \mathbb{R}^{2\times 3}$ und $B \in \mathbb{R}^{3\times 2}$ seien definiert als

$$A := \begin{pmatrix} 2 & -3 & 0 \\ 1 & 6 & 5 \end{pmatrix} \text{ und } B := \begin{pmatrix} 4 & 2 \\ -1 & 0 \\ 1 & 3 \end{pmatrix}. \tag{9.31}$$

Wir wollen $C := AB$ und $D := BA$ berechnen. Mit $n = 2, m = 3$ und $k = 2$ wissen wir schon, dass $C \in \mathbb{R}^{2\times 2}$ und $D \in \mathbb{R}^{3\times 3}$, weil

$$(2 \times 3)(3 \times 2) = (2 \times 2) \tag{9.32}$$

und

$$(3 \times 2)(2 \times 3) = (3 \times 3). \tag{9.33}$$

Es gilt hier also sicher $AB \neq BA$. Für C ergibt sich dann

$$\begin{aligned} C &= AB \\ &= \begin{pmatrix} 2 & -3 & 0 \\ 1 & 6 & 5 \end{pmatrix} \begin{pmatrix} 4 & 2 \\ -1 & 0 \\ 1 & 3 \end{pmatrix} \\ &= \begin{pmatrix} 2\cdot 4 + (-3)\cdot(-1) + 0\cdot 1 & 2\cdot 2 + (-3)\cdot 0 + 0\cdot 3 \\ 1\cdot 4 + 6\cdot(-1) + 5\cdot 1 & 1\cdot 2 + 6\cdot 0 + 5\cdot 3 \end{pmatrix} \\ &= \begin{pmatrix} 8+3+0 & 4+0+0 \\ 4-6+5 & 2+0+15 \end{pmatrix} \\ &= \begin{pmatrix} 11 & 4 \\ 3 & 17 \end{pmatrix}. \end{aligned} \tag{9.34}$$

In **R** nutzt man für die Matrixmultiplikation den **%*%** Operator.

```
# Definitionen
A = matrix(c(2,-3,0,
             1, 6,5),
           nrow  = 2,
           byrow = TRUE)
B = matrix(c( 4,2,
             -1,0,
              1,3),
           nrow  = 3,
           byrow = TRUE)

# Matrixmultiplikation
C = A %*% B
print(C)
```

```
     [,1] [,2]
[1,]   11    4
[2,]    3   17
```

Für D ergibt sich weiterhin

$$
\begin{aligned}
D &= BA \\
&= \begin{pmatrix} 4 & 2 \\ -1 & 0 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} 2 & -3 & 0 \\ 1 & 6 & 5 \end{pmatrix} \\
&= \begin{pmatrix} 4 \cdot 2 + 2 \cdot 1 & 4 \cdot (-3) + 2 \cdot 6 & 4 \cdot 0 + 2 \cdot 5 \\ (-1) \cdot 2 + 0 \cdot 1 & (-1) \cdot (-3) + 0 \cdot 6 & (-1) \cdot 0 + 0 \cdot 5 \\ 1 \cdot 2 + 3 \cdot 1 & 1 \cdot (-3) + 3 \cdot 6 & 1 \cdot 0 + 3 \cdot 5 \end{pmatrix} \\
&= \begin{pmatrix} 8 + 2 & -12 + 12 & 0 + 5 \\ -2 + 0 & 3 + 0 & 0 + 0 \\ 2 + 3 & -3 + 18 & 0 + 15 \end{pmatrix} \\
&= \begin{pmatrix} 10 & 0 & 10 \\ -2 & 3 & 0 \\ 5 & 15 & 15 \end{pmatrix}
\end{aligned}
\tag{9.35}
$$

In **R** überprüft man diese Rechnung wie folgt.

```
# Definitionen
A = matrix(c(2,-3,0,
             1, 6,5),
           nrow  = 2,
           byrow = TRUE)
B = matrix(c( 4,2,
             -1,0,
              1,3),
           nrow  = 3,
           byrow = TRUE)

# Matrixmultiplikation
D = B %*% A
print(D)
```

```
     [,1] [,2] [,3]
[1,]   10    0   10
[2,]   -2    3    0
[3,]    5   15   15
```

Ist allerdings eine Matrixmultiplikation aufgrund nicht-adäquater Matrizengrößen nicht definiert, so lässt sich diese auch nicht numerisch auswerten.

```
# Beispiel für eine undefinierte Matrixmultiplikation
E = t(A) %*% B      # (3 x 2)(3 x 2)
```

```
Error in `t(A) %*% B`:
! non-conformable arguments
```

△

Folgendes Theorem, das wir nicht beweisen wollen, stellt den Bezug zwischen dem Skalarprodukt zweier Vektoren und der Multiplikation zweier Matrizen her. Dieser ergibt sich im Wesentlichen durch die Identifikation von $\mathbb{R}^n$ und $\mathbb{R}^{n \times 1}$ und der Tatsache, dass nach Definition der Eintrag $(AB)_{ij}$ im Produkt von $A \in \mathbb{R}^{n \times m}$ und $B \in \mathbb{R}^{m \times k}$ dem Vektorskalarprodukt der $i$ten Spalte von A^T und der $j$ten Spalte von B entspricht.

Theorem 9.2 (Matrixmultiplikation und Vektorskalarprodukt)**.** *Es seien $x, y \in \mathbb{R}^n$. Dann gilt*

$$\langle x, y \rangle = x^T y. \tag{9.36}$$

Weiterhin seien für $A \in \mathbb{R}^{n \times m}$ für $i = 1, ..., n$

$$\bar{a}_i := (a_{ij})_{1 \leq j \leq m} \in \mathbb{R}^m \tag{9.37}$$

die Spalten von A^T und für $B \in \mathbb{R}^{m \times k}$ für $j = 1, ..., k$

$$\bar{b}_j := (b_{ij})_{1 \leq i \leq m} \in \mathbb{R}^m \tag{9.38}$$

die Spalten von B, also

$$A^T = \begin{pmatrix} \bar{a}_1 & \bar{a}_2 & \cdots & \bar{a}_n \end{pmatrix} \in \mathbb{R}^{m \times n} \text{ und } B = \begin{pmatrix} \bar{b}_1 & \bar{b}_2 & \cdots & \bar{b}_k \end{pmatrix} \in \mathbb{R}^{m \times k}. \tag{9.39}$$

Dann gilt

$$AB = \left(\langle \bar{a}_i, \bar{b}_j \rangle \right)_{1 \leq i \leq n, 1 \leq j \leq k}. \tag{9.40}$$

∘

9.3.1. Rechenregeln der Matrixmultiplikation

Im Folgenden stellen wir einige grundlegende Rechenregeln der Matrixmultiplikation, insbesondere auch in Kombination mit anderen Matrixoperationen zusammen.

Für Beweise der folgenden zwei Theoreme zur Assoziativität und Distributivität, die sich im Wesentlichen mit den entsprechenden Rechenregeln für Summen und Produkte der reellen Zahlen ergeben, verweisen wir auf die weiterführende Literatur.

Theorem 9.3 (Assoziativität)**.** *Es seien $A \in \mathbb{R}^{n \times m}$, $B \in \mathbb{R}^{m \times k}$, $C \in \mathbb{R}^{k \times p}$ und $c \in \mathbb{R}$. Dann gelten*

(1) Die Multiplikation von Matrizen ist assoziativ, es gilt

$$A(BC) = (AB)C. \tag{9.41}$$

(2) Die Kombination von Matrizenmultiplikation und Skalarmultiplikation ist assoziativ,

$$c(AB) = (cA)B = A(cB). \tag{9.42}$$

∘

Die Assoziativität von Matrizenmultiplikation und Skalarmultiplikation erkennt man leicht bei Betrachtung des j, lten Elements von $c(AB), (cA)B$ und $A(cB)$ anhand von

$$c \left(\sum_{i=1}^{m} a_{ji} b_{il} \right) = \sum_{i=1}^{m} \left(c a_{ji} \right) b_{il} = \sum_{i=1}^{m} a_{ji} \left(c b_{il} \right). \tag{9.43}$$

Theorem 9.4 (Distributivität)**.** *Es seien $A \in \mathbb{R}^{n \times m}$, $B \in \mathbb{R}^{n \times m}$, $C \in \mathbb{R}^{m \times p}$. Dann gelten*

$$(A + B)C = AC + BC \tag{9.44}$$

und

$$C^T(A + B) = C^TA + C^TB \tag{9.45}$$

∘

Im Gegensatz zur Kommutativität der Multiplikation reeller Zahlen ist die Matrixmultiplikation im Allgemeinen nicht kommutativ.

Theorem 9.5 (Nichtkommutativität)**.** *Es seien $A \in \mathbb{R}^{n \times m}$ und $B \in \mathbb{R}^{m \times p}$. Dann gilt im Allgemeinen*

$$AB \neq BA. \tag{9.46}$$

∘

Beweis. Im Fall $p \neq n$ ist BA nicht definiert, wir betrachten also nur den Fall $p = n$. Wir zeigen durch Angabe eines Gegenbeispiels mit $A, B \in \mathbb{R}^{2 \times 2}$, dass im Allgemeinen $AB = BA$ *nicht* gilt. Es seien

$$A \coloneqq \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix} \text{ und } B \coloneqq \begin{pmatrix} 0 & 0 \\ 1 & 0 \end{pmatrix}. \tag{9.47}$$

Dann gilt

$$AB = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 0 & 0 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \neq \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix} = BA. \tag{9.48}$$

□

Theorem 9.6 (Kombination von Matrixmultiplikation und Transposition)**.** *Es seien $A \in \mathbb{R}^{m \times n}$ und $B \in \mathbb{R}^{n \times k}$. Dann gilt*

$$(AB)^T = B^TA^T. \tag{9.49}$$

∘

Beweis. Ein Beweis ergibt sich wie folgt

$$\begin{aligned} (AB)^T &= \left(\left(\sum_{i=1}^{n} a_{ji} b_{il} \right)_{1 \leq j \leq m, 1 \leq l \leq k} \right)^T \\ &= \left(\sum_{i=1}^{n} a_{li} b_{ij} \right)_{1 \leq j \leq k, 1 \leq l \leq m} \\ &= \left(\sum_{i=1}^{n} b_{ij} a_{li} \right)_{1 \leq j \leq k, 1 \leq l \leq m} \\ &= B^TA^T. \end{aligned} \tag{9.50}$$

□

9.4. Matrixinversion

Um den Begriff der inversen Matrix zu motivieren, betrachten wir zunächst das Problem des *Lösens eines linearen Gleichungssystems*. Dazu seien $A \in \mathbb{R}^{n \times n}$, $x \in \mathbb{R}^n$ und $b \in \mathbb{R}^n$ und es gelte

$$Ax = b. \tag{9.51}$$

A und b seien als bekannt vorausgesetzt, x sei unbekannt. Konkret seien beispielsweise

$$A := \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \text{ und } b := \begin{pmatrix} 5 \\ 11 \end{pmatrix}. \tag{9.52}$$

Dann liegt folgendes lineares Gleichungssystem mit zwei Gleichungen und zwei Unbekannten vor:

$$Ax = b \Leftrightarrow \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 5 \\ 11 \end{pmatrix} \Leftrightarrow \begin{matrix} 1x_1 + 2x_2 & = 5 \\ 3x_1 + 4x_2 & = 11 \end{matrix}. \tag{9.53}$$

Ziel des Lösens von linearen Gleichungssystemen ist bekanntlich, herauszufinden, für welche x das Gleichungssystem erfüllt ist. Um in diesem Kontext den Begriff der inversen Matrix von A einzuführen, vereinfachen wir die Situation weiter. Wir nehmen an, dass $A = a$ eine 1×1 Matrix, also ein Skalar, sei und ebenso x und b, dass wir also für $a, x, b \in \mathbb{R}$ die Gleichung

$$ax = b \tag{9.54}$$

haben. Um diese Gleichung nach x aufzulösen würde man natürlich beide Seiten der Gleichung mit dem *multiplikativen Inversen* von a multiplizieren, wobei das *multiplikative Inverse* von a den Wert bezeichnet, der mit a multipliziert 1 ergibt. Dieser ist bekanntlich durch

$$a^{-1} = \frac{1}{a} \tag{9.55}$$

gegeben. Dann würde gelten

$$ax = b \Leftrightarrow a^{-1}ax = a^{-1}b \Leftrightarrow 1 \cdot x = a^{-1}b \Leftrightarrow x = \frac{b}{a}. \tag{9.56}$$

Ganz konkret etwa

$$2x = 6 \Leftrightarrow 2^{-1}2x = 2^{-1}6 \Leftrightarrow \frac{1}{2}2x = \frac{1}{2}6 \Leftrightarrow x = 3. \tag{9.57}$$

Analog zu dem Fall, dass die Matrizen in $Ax = b$ allesamt Skalare sind, möchte man im Fall eines linearen Gleichungssystems beide Seiten der Gleichung mit dem *multiplikativen Inversen* A^{-1} von A multiplizieren können, sodass eine Gleichung der Form

$$A^{-1}A = \text{"1"}. \tag{9.58}$$

resultiert. Dann hätte man nämlich

$$Ax = b \Leftrightarrow A^{-1}Ax = A^{-1}b \Leftrightarrow x = A^{-1}b. \tag{9.59}$$

Diese intuitive Idee des multiplikativen Inversen einer Matrix A wird im Folgenden unter dem Begriff der *inversen Matrix* formalisiert. Dazu benötigen wir zunächst den Begriff der *Einheitsmatrix*.

Definition 9.7 (Einheitsmatrix)**.** Die Matrix

$$I_n := (a_{ij})_{1\leq i\leq n, 1\leq j\leq n} \in \mathbb{R}^{n\times n} := \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix} \tag{9.60}$$

mit $a_{ij} = 1$ für $i = j$ und $a_{ij} = 0$ für $i \neq j$ heißt *n-dimensionale Einheitsmatrix.*

•

In **R** wird I_n mit dem Befehl `diag(n)` erzeugt. Die Einheitsmatrix ist für die Matrixmultiplikation das Analog zur 1 bei der Multiplikation reeller Zahlen. Das ist die Aussage des folgenden Theorems.

Theorem 9.7 (Neutrales Element der Matrixmultiplikation)**.** *I_n ist das neutrale Element der Matrixmultiplikation, das heißt es gilt für $A \in \mathbb{R}^{n\times m}$, dass*

$$I_n A = A \text{ und } AI_m = A. \tag{9.61}$$

∘

Beweis. Es sei $B = (b_{ij}) = I_n A \in \mathbb{R}^{n\times m}$. Dann gilt für alle $1 \leq i \leq n$ und alle $1 \leq j \leq m$

$$b_{ij} = 0 \cdot a_{1j} + 0 \cdot a_{2j} + \cdots + 0 \cdot a_{i-1,j} + 1 \cdot a_{ij} + \cdots + 0 \cdot a_{i+1,j} + 0 \cdot a_{nj} = a_{ij}. \tag{9.62}$$

Analog zeigt man dies für AI_m. □

Mit dem Begriff der Einheitsmatrix können wir jetzt die Begriffe der inversen Matrix und der invertierbaren Matrix definieren:

Definition 9.8 (Invertierbare Matrix und inverse Matrix)**.** Eine quadratische Matrix $A \in \mathbb{R}^{n\times n}$ heißt *invertierbar*, wenn es eine quadratische Matrix $A^{-1} \in \mathbb{R}^{n\times n}$ gibt, so dass

$$A^{-1}A = AA^{-1} = I_n \tag{9.63}$$

ist. Die Matrix A^{-1} heißt die *inverse Matrix von A.*

•

Man beachte, dass sich die Begriffe der inversen Matrix und der Invertierbarkeit *nur* auf quadratische Matrizen beziehen. Insbesondere können quadratische Matrizen invertierbar sein, müssen es aber nicht sein (lineare Gleichungssysteme können also Lösungen haben, müssen es aber nicht). Nicht invertierbare Matrizen nennt man auch *singuläre* Matrizen, invertierbare Matrizen manchmal auch *nicht-singuläre* Matrizen. Schließlich beachte man, dass Definition 9.8 lediglich aussagt, was eine inverse Matrix ist, aber nicht wie man sie berechnet.

Beispiel für eine invertierbare Matrix

Die Matrix

$$A := \begin{pmatrix} 2.0 & 1.0 \\ 3.0 & 4.0 \end{pmatrix} \tag{9.64}$$

ist invertierbar und ihre inverse Matrix ist gegeben durch

$$A^{-1} = \begin{pmatrix} 0.8 & -0.2 \\ -0.6 & 0.4 \end{pmatrix}, \tag{9.65}$$

denn

$$\begin{pmatrix} 2.0 & 1.0 \\ 3.0 & 4.0 \end{pmatrix} \begin{pmatrix} 0.8 & -0.2 \\ -0.6 & 0.4 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 0.8 & -0.2 \\ -0.6 & 0.4 \end{pmatrix} \begin{pmatrix} 2.0 & 1.0 \\ 3.0 & 4.0 \end{pmatrix}, \tag{9.66}$$

wovon man sich durch Nachrechnen überzeugt.

Beispiel für eine nicht-invertierbare Matrix

Die Matrix

$$B := \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \tag{9.67}$$

ist nicht invertierbar, denn wäre B invertierbar, dann gäbe es

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} \tag{9.68}$$

mit

$$\begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} a & b \\ c & d \end{pmatrix} = \begin{pmatrix} a & b \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}. \tag{9.69}$$

Das würde aber bedeuten, dass $0 = 1$ in $\mathbb{R}$ und das ist ein Widerspruch. Also kann B nicht invertierbar sein.

Zum Berechnen inverser Matrizen

2×2 bis etwa 5×5 Matrizen kann man prinzipiell per Hand invertieren, dazu stellt die Lineare Algebra verschiedene Verfahren bereit. Wir wollen hier auf eine Einführung in die Matrizeninvertierung per Hand verzichten, da in der Anwendung Matrizen standardmäßig numerisch invertiert werden. Die numerische Matrixinversion ist dann auch ein großes Feld der Forschung zur Numerischen Mathematik, die eine Vielzahl von Algorithmen zu diesem Zweck bereitstellt. In **R** werden Matrizen per default mit der Funktion `solve()`, in Anlehnung an das Lösen linearer Gleichungssysteme, invertiert. Für das obige Beispiel einer invertierbaren Matrix ergibt sich dabei folgender **R** Code.

```
# Definition
A = matrix(c(2,1,
             3,4),
           nrow  = 2,
           byrow = TRUE)

# Berechnen von A^{-1}
print(solve(A))
```

```
     [,1] [,2]
[1,]  0.8 -0.2
[2,] -0.6  0.4
```

```
# Überprüfen der Eigenschaften einer inversen Matrix
print(solve(A) %*% A)
```

```
     [,1] [,2]
[1,]    1    0
[2,]    0    1
```

```
# Bei der umgekehrten Berechnung ergeben sich kleine Rundungsfehler
print(A %*% solve(A))
```

```
     [,1]          [,2]
[1,]    1 -5.551115e-17
[2,]    0  1.000000e+00
```

Nicht-invertierbare Matrizen sind dabei natürlich auch numerisch nicht-invertierbar, wie folgende Fehlermeldung in **R** bezüglich obigen Beispiels einer nicht-invertierbaren Matrix demonstriert.

```
B = matrix(c(1,0,
             0,0),
           nrow  = 2,
           byrow = TRUE)
solve(B)
```

```
Error in `solve.default()`:
! Lapack routine dgesv: system is exactly singular: U[2,2] = 0
```

9.5. Determinanten

Die Determinante ist eine vielseitig einsetzbare Maßzahl einer quadratischen Matrix. Für das Verständnis der *Eigenanalyse* und der *Matrixzerlegung* ist der Begriff der Determinante im Kontext des *charakteristischen Polynoms* grundlegend.

Allgemein ist eine Determinante eine nichtlineare Abbildung der Form

$$|\cdot| : \mathbb{R}^{n\times n} \to \mathbb{R}, A \mapsto |A|, \tag{9.70}$$

das heißt, eine Determinante ordnet einer quadratischen Matrix A die reelle Zahl $|A|$ zu. Die Zahl $|A|$ wird dabei rekursiv anhand folgender Definition bestimmt.

Definition 9.9 (Determinante)**.** Für $A = (a_{ij})_{1\leq i,j\leq n} \in \mathbb{R}^{n\times n}$ mit $n > 1$ sei $A_{ij} \in \mathbb{R}^{n-1\times n-1}$ die Matrix, die aus A durch Entfernen der $i$ten Zeile und der $j$ten Spalte entsteht. Dann heißt die Zahl

$$|A| := a_{11} \qquad \text{für } n = 1 \tag{9.71}$$

$$|A| := \sum_{j=1}^{n} a_{1j}(-1)^{1+j} \det\left(A_{1j}\right) \quad \text{für } n > 1 \tag{9.72}$$

die *Determinante von* A.

•

Die Definition führt die Bestimmung der Determinante einer quadratischen Matrix also sukzessive durch Streichen von Zeilen und Spalten auf die Determinante einer 1×1 Matrix zurück, die durch ihr einziges Element gegeben ist. Für

$$A := \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{pmatrix} \in \mathbb{R}^{3\times 3} \tag{9.73}$$

ergeben sich dabei zum Beispiel folgende Matrizen der Form $A_{ij} \in \mathbb{R}^{3-1 \times 3-1}$:

$$A_{11} = \begin{pmatrix} 5 & 6 \\ 8 & 9 \end{pmatrix}, A_{12} = \begin{pmatrix} 4 & 6 \\ 7 & 9 \end{pmatrix}, A_{21} = \begin{pmatrix} 2 & 3 \\ 8 & 9 \end{pmatrix}, A_{22} = \begin{pmatrix} 1 & 3 \\ 7 & 9 \end{pmatrix}. \tag{9.74}$$

Für die Berechnung der Determinanten von zwei- und dreidimensionalen quadratischen Matrizen gibt es direkte, nicht-rekursive Rechenregeln, die in folgendem Theorem festgehalten sind.

Theorem 9.8 (Determinanten von zwei- und dreidimensionalen Matrizen)**.**

Es sei $A = (a_{ij})_{1 \leq i,j \leq 2} \in \mathbb{R}^{2 \times 2}$*. Dann gilt*

$$|A| = a_{11}a_{22} - a_{12}a_{21}. \tag{9.75}$$

Es sei $A = (a_{ij})_{1 \leq i,j \leq 3} \in \mathbb{R}^{3 \times 3}$*. Dann gilt*

$$|A| = a_{11}a_{22}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32} - a_{12}a_{21}a_{33} - a_{11}a_{23}a_{32} - a_{13}a_{22}a_{31}. \tag{9.76}$$

∘

Beweis. Für $A \in \mathbb{R}^{2 \times 2}$ gilt nach Definition

$$\begin{aligned} |A| &= \sum_{j=1}^{n} a_{1j}(-1)^{1+j}|A_{1j}| \\ &= a_{11}(-1)^{1+1}|A_{11}| + a_{12}(-1)^{1+2}|A_{12}| \\ &= a_{11}|(a_{22})| - a_{12}|(a_{21})| \\ &= a_{11}a_{22} - a_{12}a_{21}. \end{aligned} \tag{9.77}$$

Für $A \in \mathbb{R}^{3 \times 3}$ gilt nach Definition und mit der Formel für Determinanten von 2×2 Matrizen

$$\begin{aligned} |A| &= \sum_{j=1}^{n} a_{1j}(-1)^{1+j}|A_{1j}| \\ &= a_{11}(-1)^{1+1}|A_{11}| + a_{12}(-1)^{1+2}|A_{12}| + a_{13}(-1)^{1+3}|A_{13}| \\ &= a_{11}|A_{11}| - a_{12}|A_{12}| + a_{13}|A_{13}| \\ &= a_{11}\left|\begin{pmatrix} a_{22} & a_{23} \\ a_{32} & a_{33} \end{pmatrix}\right| - a_{12}\left|\begin{pmatrix} a_{21} & a_{23} \\ a_{31} & a_{33} \end{pmatrix}\right| + a_{13}\left|\begin{pmatrix} a_{21} & a_{22} \\ a_{31} & a_{32} \end{pmatrix}\right| \\ &= a_{11}(a_{22}a_{33} - a_{23}a_{32}) - a_{12}(a_{21}a_{33} - a_{23}a_{31}) + a_{13}(a_{21}a_{32} - a_{22}a_{31}) \\ &= a_{11}a_{22}a_{33} - a_{11}a_{23}a_{32} - a_{12}a_{21}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32} - a_{13}a_{22}a_{31} \\ &= a_{11}a_{22}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32} - a_{12}a_{21}a_{33} - a_{11}a_{23}a_{32} - a_{13}a_{22}a_{31}. \end{aligned} \tag{9.78}$$

□

Für die Bestimmung der Determinanten von 2×2 und 3×3 Matrizen gilt somit die sogenannte *Sarrusche Merkregel*:

"Summe der Produkte auf den Diagonalen minus Summe der Produkte auf den Gegendiagonalen."

Dabei bezieht sich die Merkregel bei 3×3 Matrizen auf das Schema

$$\left(\begin{array}{ccc|cc} a_{11} & a_{12} & a_{13} & a_{11} & a_{12} \\ a_{21} & a_{22} & a_{23} & a_{21} & a_{22} \\ a_{31} & a_{32} & a_{33} & a_{31} & a_{32} \end{array}\right). \tag{9.79}$$

Beispiele für Determinanten von 2×2 und 3×3 Matrizen

Es seien

$$A := \begin{pmatrix} 2 & 1 \\ 3 & 4 \end{pmatrix}, B := \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \text{ und } C := \begin{pmatrix} 2 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 3 \end{pmatrix} \tag{9.80}$$

Dann ergeben sich

$$|A| = 2 \cdot 4 - 1 \cdot 3 = 8 - 3 = 5 \tag{9.81}$$

und

$$|B| = 1 \cdot 0 - 0 \cdot 0 = 0 - 0 = 0 \tag{9.82}$$

und

$$|C| = 2 \cdot 1 \cdot 3 + 0 \cdot 0 \cdot 0 + 0 \cdot 0 \cdot 0 - 0 \cdot 0 \cdot 3 - 0 \cdot 0 \cdot 0 - 0 \cdot 1 \cdot 0 = 2 \cdot 1 \cdot 3 = 6. \tag{9.83}$$

In **R** rechnet man dies mithilfe der `det()` Funktion wie folgt nach.

```
# Matrixdefinition und Determinantenberechnung
A = matrix(c(2,1,
             3,4),
           nrow = 2,
           byrow = TRUE)
det(A)
```

```
[1] 5
```

```
# Matrixdefinition und Determinantenberechnung
B = matrix(c(1,0,
             0,0),
           nrow = 2,
           byrow = TRUE)
det(B)
```

```
[1] 0
```

```
# Matrixdefinition und Determinantenberechnung
C = matrix(c(2,0,0,
             0,1,0,
             0,0,3),
           nrow = 3,
           byrow = TRUE)
det(C)
```

```
[1] 6
```

Für Determinanten bestehen zahlreiche Rechenregeln im Zusammenspiel mit Matrixmultiplikation und Matrixinversion. Ohne Beweis stellen wir diese in folgendem Theorem zusammen.

Theorem 9.9 (Rechenregeln für Determinanten)**.**

(Determinantenmultiplikationssatz). Für $A, B \in \mathbb{R}^{n \times n}$ gilt

$$|AB| = |A||B|. \tag{9.84}$$

(Transposition). Für $A \in \mathbb{R}^{n \times n}$ gilt

$$|A| = \left|A^T\right|. \tag{9.85}$$

(Inversion). Für eine invertierbare Matrix $A \in \mathbb{R}^{n \times n}$ gilt

$$\left|A^{-1}\right| = \frac{1}{|A|}. \tag{9.86}$$

(Dreiecksmatrizen). Für Matrizen $A = (a_{ij})_{1 \leq i,j \leq n} \in \mathbb{R}^{n \times n}$ mit $a_{ij} = 0$ für $i > j$ oder $a_{ij} = 0$ für $j > i$ gilt

$$|A| = \prod_{i=1}^{n} a_{ii}. \tag{9.87}$$

∘

Folgendes sehr tiefgehendes Theorem, welches wir nicht vollständig beweisen wollen, gibt eine Möglichkeit an, anhand der Determinante einer quadratischen Matrix zu bestimmen, ob sie invertierbar ist.

Theorem 9.10. *$A \in \mathbb{R}^{n \times n}$ ist dann und nur dann invertierbar, wenn gilt, dass $|A| \neq 0$. Es gilt also*

$$A \text{ ist invertierbar} \Leftrightarrow |A| \neq 0 \text{ und } A \text{ ist nicht invertierbar} \Leftrightarrow |A| = 0. \tag{9.88}$$

∘

Beweis. Wir deuten einen Beweis lediglich an und zeigen, dass aus der Invertierbarkeit von A folgt, dass $|A|$ nicht gleich Null sein kann. Nehmen wir also an, dass A invertierbar ist. Dann gibt es eine Matrix B mit $AB = I_n$ und mit dem Determinantenmultiplikationssatz folgt

$$|AB| = |A||B| = |I_n| = 1. \tag{9.89}$$

Also kann $|A| = 0$ nicht gelten, denn sonst wäre $0 = 1$. □

Visuelle Intuition

Der abstrakte Begriff der Determinante einer quadratischen Matrix kann mithilfe des Vektorraumbegriffs etwas veranschaulicht werden. Dazu seien $a_1, ..., a_n \in \mathbb{R}^n$ die Spalten von $A \in \mathbb{R}^{n \times n}$. Dann gilt (wie wir nicht beweisen wollen), dass $|A|$ dem signierten Volumen des von $a_1, ..., a_n \in \mathbb{R}^n$ aufgespannten Parallelotops entspricht. Um dies visuell zu veranschaulichen betrachten wir die Matrizen

$$A_1 = \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix}, A_2 = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}, A_3 = \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix} \tag{9.90}$$

mit den jeweiligen Determinanten

$$|A_1| = 3 \cdot 2 - 1 \cdot 1 = 5, \quad |A_2| = 2 \cdot 2 - 0 \cdot 0 = 4, \quad |A_3| = 2 \cdot 2 - 2 \cdot 2 = 0. \tag{9.91}$$

Abbildung 9.1 visualisiert die entsprechende Intuition.

9.6. Spezielle Matrizen

In dieser Sektion stellen wir einige häufig auftretende Typen von Matrizen und ihre Eigenschaften zusammen. Zum Beweis der allermeisten Eigenschaften verweisen wir dabei auf die weiterführende Literatur.

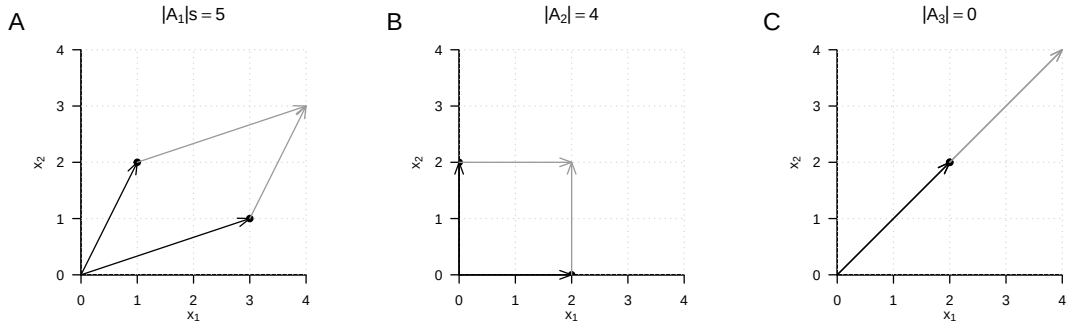


Abbildung 9.1. Determinanten als Parallelotopvolumina.

9.6.1. Einheitsmatrizen

Die Einheitsmatrix und die Einheitsvektoren haben wir bereits kennengelernt. Wir fassen sie hier noch einmal in einer gemeinsamen Definition zusammen.

Definition 9.10 (Einheitsmatrix und Einheitsvektoren)**.** Wir bezeichnen die *Einheitsmatrix* mit

$$I_n := (i_{jk})_{1 \leq j \leq n, 1 \leq k \leq n} \in \mathbb{R}^{n \times n} \text{ mit } i_{jk} = 1 \text{ für } j = k \text{ und } i_{jk} = 0 \text{ für } j \neq k. \tag{9.92}$$

Wir bezeichnen die *Einheitsvektoren* $e_i, i = 1, ..., n$ mit

$$e_i := (e_{i_j})_{1 \leq j \leq n} \in \mathbb{R}^n \text{ mit } e_{i_j} = 1 \text{ für } i = j \text{ und } e_{i_j} = 0 \text{ für } i \neq j. \tag{9.93}$$

•

Die Einheitsmatrix I_n besteht nur aus Nullen und Diagonalelementen gleich Eins, die Einheitsvektoren bestehen nur aus Nullen und einer Eins in der jeweils indizierten Komponente. Es gilt

$$I_n = \begin{pmatrix} e_1 & \cdots & e_n \end{pmatrix} \in \mathbb{R}^{n \times n} \tag{9.94}$$

Für $n = 3$ gilt also zum Beispiel

$$I_3 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \text{ und } e_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, e_2 = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, e_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}. \tag{9.95}$$

Weiterhin gelten für die Einheitsvektoren bekanntlich für $1 \leq i, j \leq n$

$$e_i^T e_j = 0 \text{ für } i \neq j, e_i^T e_i = 1 \text{ und } e_i^T v = v^T e_i = v_i \text{ für } v \in \mathbb{R}^n. \tag{9.96}$$

9.6.2. Einsmatrizen und Nullmatrizen

Definition 9.11 (Nullmatrizen, Nullvektoren, Einsmatrizen, Einsvektoren)**.** Wir bezeichnen *Nullmatrizen* und *Nullvektoren* mit

$$0_{nm} := (0)_{1 \leq i \leq n, 1 \leq j \leq m} \in \mathbb{R}^{n \times m} \text{ und } 0_n := (0)_{1 \leq i \leq n} \in \mathbb{R}^n. \tag{9.97}$$

Wir bezeichnen *Einsmatrizen* und *Einsvektoren* mit

$$1_{nm} := (1)_{1 \leq i \leq n, 1 \leq j \leq m} \in \mathbb{R}^{n \times m} \text{ und } 1_n := (1)_{1 \leq i \leq n} \in \mathbb{R}^n. \tag{9.98}$$

•

0_{nm} und 0_n bestehen also nur aus Nullen und 1_{nm} und 1_n bestehen nur aus Einsen. Es gilt also beispielsweise

$$0_{32} = \begin{pmatrix} 0 & 0 \\ 0 & 0 \\ 0 & 0 \end{pmatrix}, 0_3 = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, 1_{32} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \\ 1 & 1 \end{pmatrix} \text{ und } 1_3 = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}. \tag{9.99}$$

Weiterhin gelten zum Beispiel

$$0_n 0_n^T = 0_{nn} \text{ und } 1_n 1_n^T = 1_{nn}, \tag{9.100}$$

wovon man sich durch Nachrechnen überzeugt.

9.6.3. Diagonalmatrizen

Definition 9.12 (Diagonalmatrix)**.** Eine Matrix $D \in \mathbb{R}^{n \times m}$ heißt *Diagonalmatrix*, wenn $d_{ij} = 0$ für $1 \leq i \leq n, 1 \leq j \leq m$ mit $i \neq j$.

•

Eine quadratische Diagonalmatrix $D \in \mathbb{R}^{n \times n}$ mit den Diagonalelementen $d_1, ..., d_n \in \mathbb{R}$ schreibt man auch als

$$D = \text{diag}(d_1, ..., d_n). \tag{9.101}$$

Zum Beispiel gelten

$$D := \text{diag}(1, 2, 3) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3 \end{pmatrix} \tag{9.102}$$

und für $\sigma^2 \in \mathbb{R}$

$$\Sigma = \text{diag}(\sigma^2, \sigma^2, \sigma^2) = \begin{pmatrix} \sigma^2 & 0 & 0 \\ 0 & \sigma^2 & 0 \\ 0 & 0 & \sigma^2 \end{pmatrix} = \sigma^2 I_3. \tag{9.103}$$

In folgendem Theorem stellen wir einige wichtige Eigenschaften von quadratischen Diagonalmatrizen zusammen.

Theorem 9.11 (Eigenschaften quadratischer Diagonalmatrizen)**.**

(Determinante.) $D := diag(d_1, ..., d_n) \in \mathbb{R}^{n \times n}$ sei eine quadratische Diagonalmatrix. Dann gilt

$$|D| = \prod_{i=1}^{n} d_i. \tag{9.104}$$

◦

9.6.4. Symmetrische Matrizen

Symmetrische Matrizen sind quadratische Matrizen, die bei Transposition unverändert bleiben:

Definition 9.13. Eine Matrix $S \in \mathbb{R}^{n \times n}$ heißt *symmetrisch*, wenn $S^T = S$.

•

Ein Beispiel für eine symmetrische Matrix ist

$$S := \begin{pmatrix} 1 & 2 & 3 \\ 2 & 1 & 2 \\ 3 & 2 & 1 \end{pmatrix}. \tag{9.105}$$

In folgendem Theorem stellen wir einige wichtige Eigenschaften symmetrischer Matrizen zusammen.

Theorem 9.12 (Eigenschaften symmetrischer Matrizen)**.**

(Summation.) $S_1 \in \mathbb{R}^{n \times n}$ und $S_2 \in \mathbb{R}^{n \times n}$ seien symmetrische Matrizen. Dann gilt

$$S_1 + S_2 = (S_1 + S_2)^T. \tag{9.106}$$

(Inverse.) S sei eine invertierbare symmetrische Matrix und S^{-1} ihre Inverse. Dann ist auch S^{-1} eine symmetrische Matrix, das heißt es gilt

$$\left(S^{-1}\right)^T = S^{-1}. \tag{9.107}$$

◦

9.6.5. Orthogonale Matrizen

Definition 9.14. Eine Matrix $Q \in \mathbb{R}^{n \times n}$ heißt *orthogonal*, wenn $Q^T Q = I_n$.

•

Die Spalten einer orthogonalen Matrix sind also paarweise orthogonal, es gilt für

$$Q = \begin{pmatrix} q_1 & \cdots & q_n \end{pmatrix} \text{ mit } q_i \in \mathbb{R}^n \text{ für } 1 \leq i \leq n, \tag{9.108}$$

dass

$$q_i^T q_j = 0 \text{ für } i \neq j \text{ und } q_i^T q_j = 1 \text{ für } i = j \text{ mit } 1 \leq i, j \leq n. \tag{9.109}$$

Theorem 9.13 (Eigenschaften orthogonaler Matrizen)**.** *$Q \in \mathbb{R}^{n \times n}$ sei eine orthogonale Matrix. Dann gelten folgende Eigenschaften von Q.*

(Inverse.) Die Inverse von Q ist Q^T, es gilt

$$Q^{-1} = Q^T. \tag{9.110}$$

(Transposition) Die Zeilen von Q sind orthonormal, es gilt

$$QQ^T = I_n \tag{9.111}$$

◦

Beweis. (Inverse) Unter der Annahme, dass Q^{-1} existiert, gilt

$$Q^T Q = I_n \Leftrightarrow Q^T Q Q^{-1} = I_n Q^{-1} \Leftrightarrow Q^{-1} = Q^T. \tag{9.112}$$

(Transposition) Es gilt

$$Q^T Q = I_n \Leftrightarrow Q Q^T Q = Q I_n \Leftrightarrow Q Q^T Q Q^T = Q Q^T \Leftrightarrow Q Q^T = I_n. \tag{9.113}$$

□

9.6.6. Positiv-definite Matrizen

Positiv-definite Matrizen sind für die probabilistische Modellbildung unter Verwendung multivariater Normalverteilungen zentral.

Definition 9.15. Eine quadratische Matrix $C \in \mathbb{R}^{n \times n}$ heißt positiv-definit (p.d.), wenn

- C eine symmetrische Matrix ist und
- für alle $x \in \mathbb{R}^n, x \neq 0_n$ gilt, dass $x^T C x > 0$ ist.

•

In folgendem Theorem stellen wir einige wichtige Eigenschaften positiv-definiter Matrizen zusammen.

Theorem 9.14 (Eigenschaften positiv-definiter Matrizen)**.**

(Inverse.) $C \in \mathbb{R}^{n \times n}$ sei eine positiv-definite Matrix. Dann gilt, dass C^{-1} existiert und ebenfalls positiv-definit ist.

∘

9.7. Eigenanalyse

Mit der *Eigenanalyse einer quadratischen Matrix*, der *Orthonormalzerlegung einer symmetrischen Matrix* und der *Singulärwertzerlegung einer beliebigen Matrix* behandeln wir in diesem Abschnitt drei eng zusammenhängende Konzepte der Matrixtheorie, die in vielen Gebieten der datenanalytischen Anwendung zentrale Rollen spielen. Allerdings erschließt sich die Bedeutung dieser Konzepte dann vor allem im jeweiligen Anwendungskontext, so dass dieser Abschnitt notwendigerweise etwas abstrakt anmuten mag.

Eigenvektoren und Eigenwerte

Unter der *Eigenanalyse* einer quadratischen Matrix versteht man das Bestimmen ihrer *Eigenvektoren* und *Eigenwerte*. Diese sind für eine quadratische Matrix wie folgt definiert.

Definition 9.16 (Eigenvektor und Eigenwert)**.** $A \in \mathbb{R}^{m \times m}$ sei eine quadratische Matrix. Dann heißt jeder vom Nullvektor 0_m verschiedene Vektor $v \in \mathbb{R}^m$, für den mit einem Skalar $\lambda \in \mathbb{R}$ gilt, dass

$$Av = \lambda v \tag{9.114}$$

ist, ein *Eigenvektor von* A und λ heißt dann ein *Eigenwert von* A.

•

Nach Definition hat also jeder Eigenvektor einen zugehörigen Eigenwert, allerdings können die Eigenwerte verschiedener Eigenvektoren durchaus identisch sein. Intuitiv bedeutet die Definition von Eigenvektor und Eigenwert, dass ein Eigenvektor einer Matrix durch Multiplikation mit eben dieser Matrix in seiner Länge, nicht aber in seiner Richtung, verändert wird. Der zugehörige Eigenwert des Eigenvektors entspricht dem Faktor der Längenänderung. Allerdings ist die Zuordnung von Eigenvektoren und Eigenwerten nicht eindeutig, wie das folgende Theorem zeigt.

Theorem 9.15 (Multiplikativität von Eigenvektoren)**.** *$A \in \mathbb{R}^{m \times m}$ sei eine quadratische Matrix. Wenn $v \in \mathbb{R}^m$ Eigenvektor von A mit Eigenwert $\lambda \in \mathbb{R}$ ist, dann ist für $c \in \mathbb{R} \setminus \{0\}$ auch $cv \in \mathbb{R}^m$ Eigenvektor von A und zwar wiederum mit Eigenwert $\lambda \in \mathbb{R}$.*

∘

Beweis. Es gilt

$$Av = \lambda v \Leftrightarrow cAv = c\lambda v \Leftrightarrow A(cv) = \lambda(cv). \tag{9.115}$$

Also ist cv ein Eigenvektor von A mit Eigenwert λ. □

Um nun die Uneindeutigkeit in der Definition des zu einem Eigenwert zugeordneten Eigenvektors aufzulösen, nutzen wir die Konvention, nur diejenigen Vektoren als Eigenvektoren zu einem Eigenwert λ zu betrachten, die die Länge 1 haben, für die also gilt, dass

$$\|v\| = 1. \tag{9.116}$$

Sollten wir also einen Eigenvektor v zu einem Eigenwert λ einer Matrix A finden, der nicht von der Länge 1 ist, so können wir ihn immer mit $\|v\|^{-1}$ multiplizieren. Der resultierende Vektor $v' = v/\|v\|$ hat dann die Länge 1 und ist nach Theorem 9.15 ebenso ein Eigenvektor von A zum Eigenwert λ. Bevor wir uns der Bestimmung von Eigenwerten und Eigenvektoren widmen, wollen wir die Konzepte von Eigenwert und Eigenvektor für den Fall einer 2×2 Matrix an einem Beispiel veranschaulichen.

Beispiel 9.6 (Eigenvektor einer symmetrischen Matrix)**.** Es sei

$$A := \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \tag{9.117}$$

Dann ist der Vektor der Länge 1

$$v := \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix} \tag{9.118}$$

ein Eigenvektor von A zum Eigenwert $\lambda = 3$, da gilt, dass

$$\begin{aligned} Av &= \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \left(\frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix} \right) \\ &= \frac{1}{\sqrt{2}} \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} \\ &= \frac{1}{\sqrt{2}} \begin{pmatrix} 3 \\ 3 \end{pmatrix} \\ &= \frac{1}{\sqrt{2}} 3 \begin{pmatrix} 1 \\ 1 \end{pmatrix} \\ &= 3 \left(\frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix} \right) \\ &= \lambda v. \end{aligned} \tag{9.119}$$

Inspektion von Abbildung 9.2 zeigt dementsprechend, dass für die hier definierte Matrix A die Vektoren v und Av in die gleiche Richtung zeigen, dass aber Av um den Faktor λ länger ist als v.

Der Vektor

$$w := \begin{pmatrix} 1 \\ 0 \end{pmatrix} \tag{9.120}$$

dagegen hat zwar die Länge 1, ist aber im Gegensatz zu v kein Eigenvektor von A, da es im Falle von

$$Aw = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix} \tag{9.121}$$

keinen Skalar λ geben kann, der mit Null, dem zweiten Eintrag von w, multipliziert einen Wert ungleich Null ergeben kann. Inspektion von Abbildung 9.2 zeigt dementsprechend, dass der aus der Multiplikation von w mit A resultierende Vektor in eine andere Richtung zeigt als w.

△

Bestimmung von Eigenwerten und Eigenvektoren

Folgendes Theorem besagt, wie die Eigenwerte und Eigenvektoren einer quadratischen Matrix berechnet werden können.

Theorem 9.16 (Bestimmung von Eigenwerten und Eigenvektoren)**.** *$A \in \mathbb{R}^{m \times m}$ sei eine quadratische Matrix. Dann ergeben sich die Eigenwerte von A als die Nullstellen des charakteristischen Polynoms*

$$\chi_A(\lambda) := |A - \lambda I_m| \tag{9.122}$$

von A. Weiterhin seien $\lambda_i^*, i = 1, 2, \ldots$ die auf diese Weise bestimmten Eigenwerte von A. Die entsprechenden Eigenvektoren $v_i, i = 1, 2, \ldots$ von A können dann durch Lösen der linearen Gleichungssysteme

$$(A - \lambda_i^* I_m) v_i = 0_m \text{ für } i = 1, 2, \ldots \tag{9.123}$$

bestimmt werden.

∘

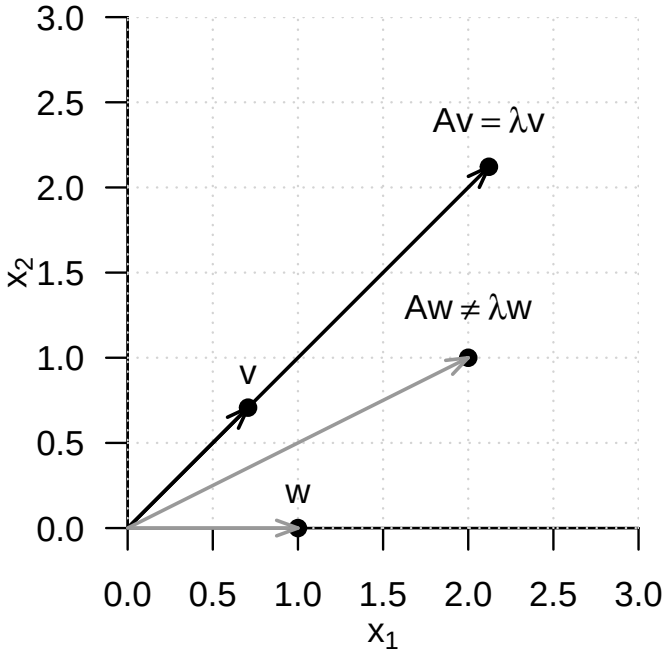


Abbildung 9.2. Eigenvektor einer 2×2 Matrix. Für die im Text definierte Matrix A ist v ein Eigenvektor, w jedoch nicht.

Beweis. (1) Bestimmen von Eigenwerten

Wir halten zunächst fest, dass mit der Definition von Eigenvektoren und Eigenwerten gilt, dass

$$Av = \lambda v \Leftrightarrow Av - \lambda v = 0_m \Leftrightarrow (A - \lambda I_m)v = 0_m. \tag{9.124}$$

Für den Eigenwert λ wird der Eigenvektor v also durch Multiplikation mit $(A - \lambda I_m)$ auf den Nullvektor 0_m abgebildet. Weil aber per Definition $v \neq 0_m$ gilt, ist die Matrix $(A - \lambda I_m)$ somit nicht invertierbar: sowohl der Nullvektor als auch v werden durch $(A - \lambda I_m)$ auf 0_m abgebildet, die Abbildung

$$f : \mathbb{R}^m \to \mathbb{R}^m, x \mapsto (A - \lambda I_m)x \tag{9.125}$$

ist also nicht bijektiv, und $(A - \lambda I_m)^{-1}$ kann nicht existieren. Die Tatsache, dass $(A - \lambda I_m)$ nicht invertierbar ist, ist aber äquivalent dazu, dass die Determinante von $(A - \lambda I_m)$ gleich Null ist. Also ist

$$\chi_A(\lambda) = |A - \lambda I_m| = 0 \tag{9.126}$$

eine notwendige und hinreichende Bedingung dafür, dass λ ein Eigenwert von A ist.

(2) Bestimmen von Eigenvektoren

Es sei λ_i^* ein Eigenwert von A. Dann gilt mit den obigen Überlegungen, dass Auflösen von

$$(A - \lambda_i^* I_m)v_i^* = 0_m \tag{9.127}$$

nach v_i^* einen Eigenvektor zum Eigenwert λ_i^* ergibt. □

Allgemein müssen zur Bestimmung von Eigenwerten und Eigenvektoren also Polynomnullstellen bestimmt und lineare Gleichungssysteme gelöst werden. Dies kann für kleine Matrizen mit $m \leq 4$ durchaus manuell geschehen. Die in der Anwendung auftretenden Matrizen sind jedoch meist weitaus größer, so dass zur Eigenanalyse numerische Verfahren der Nullstellenbestimmung und des Lösens linearer Gleichungssysteme eingesetzt werden, die zum Beispiel in Funktionen wie **R**'s `eigen()`, **SciPy's** `linalg.eig()` oder **Julia**'s `eigvals()` und `eigvecs()` genutzt werden. Für Details zu diesen Verfahren verweisen wir auf die weiterführende Literatur, zum Beispiel Burden et al. (2016) und Richter & Wick (2017). Wir wollen Theorem 9.16 hier lediglich anhand eines Beispiels illustrieren.

Beispiel 9.7 (Bestimmung von Eigenwerten und Eigenvektoren)**.** Dazu sei wiederum

$$A := \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \tag{9.128}$$

Wir wollen zunächst die Eigenwerte von A berechnen. Nach Theorem 9.16 sind dies die Nullstellen des charakteristischen Polynoms von A. Wir berechnen also zunächst das charakteristische Polynom von A durch

$$\chi_A(\lambda) = \left| \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} - \begin{pmatrix} \lambda & 0 \\ 0 & \lambda \end{pmatrix} \right| = \left| \begin{pmatrix} 2-\lambda & 1 \\ 1 & 2-\lambda \end{pmatrix} \right| = (2-\lambda)^2 - 1. \tag{9.129}$$

Mithilfe der pq-Formel zur Lösung quadratischer Gleichungen findet man dann

$$(2 - \lambda_{1/2}^*)^2 - 1 = 0 \Leftrightarrow \lambda_1^* = 3 \text{ oder } \lambda_2^* = 1. \tag{9.130}$$

Die Eigenwerte von A sind also $\lambda_1 = 3$ und $\lambda_2 = 1$. Die zugehörigen Eigenvektoren ergeben sich dann für $i = 1, 2$ durch Lösen des linearen Gleichungssystems

$$(A - \lambda_i I_2)v_i = 0_2. \tag{9.131}$$

Speziell ergibt sich hier, dass für $\lambda_1 = 3$ aus

$$(A - 3I_2)v_1 = 0_2 \Leftrightarrow \begin{pmatrix} -1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} v_{1_1} \\ v_{1_2} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \tag{9.132}$$

folgt, dass

$$v_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix} \tag{9.133}$$

ein Eigenvektor zum Eigenwert λ_1 ist und dass für $\lambda_2 = 1$ aus

$$(A - I_2)v_2 = 0_2 \Leftrightarrow \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} v_{2_1} \\ v_{2_2} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \tag{9.134}$$

folgt, dass

$$v_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \end{pmatrix} \tag{9.135}$$

ein Eigenvektor zum Eigenwert $\lambda_2 = 1$ ist. Weiterhin gelten hier offenbar

$$v_1^T v_2 = 0 \text{ und } \|v_1\| = \|v_2\| = 1. \tag{9.136}$$

Folgender **R** Code demonstriert die Bestimmung der Eigenwerte und Eigenvektoren der hier betrachteten Matrix mithilfe der `eigen()` Funktion.

```
# Matrixdefinition
A = matrix(c(2,1,
             1,2),
           nrow  = 2,
           byrow = TRUE)

# Eigenanalyse
eigen(A)
```

```
eigen() decomposition
$values
[1] 3 1

$vectors
           [,1]       [,2]
[1,] 0.7071068 -0.7071068
[2,] 0.7071068  0.7071068
```

△

Zum Abschluss dieses Abschnittes betrachten wir zwei technische Theoreme, die Aussagen zum Zusammenhang spezieller Matrixprodukte und ihrer Eigenwerte und Eigenvektoren machen. Wir benötigen diese Theoreme im Kontext der Kanonischen Korrelationsanalyse.

Theorem 9.17 (Eigenwerte und Eigenvektoren von Matrixprodukten)**.** *Für $A \in \mathbb{R}^{n \times m}$ und $B \in \mathbb{R}^{m \times n}$ sind die Eigenwerte von $AB \in \mathbb{R}^{n \times n}$ und $BA \in \mathbb{R}^{m \times m}$ gleich. Weiterhin gilt, dass für einen Eigenvektor v zu einem von Null verschiedenen Eigenwert λ von AB $w := Bv$ ein Eigenvektor von BA zum Eigenwert λ ist.*

∘

Für einen Beweis verweisen wir auf Mardia et al. (1979), S. 468. Wir demonstrieren die Aussage dieses Theorems anhand untenstehenden **R** Codes.

```
A   = matrix(1:6, nrow = 2,  byrow = T)          # Matrix A \in \mathbb{R}^{2 x 3}
B   = matrix(1:6, ncol = 2,  byrow = T)          # Matrix B \in \mathbb{R}^{3 x 2}
EAB = eigen(A %*% B)                             # Eigenanalyse von AB \in \mathbb{R}^{2 \times 2}
EBA = eigen(B %*% A)                             # Eigenanalyse von BA \in \mathbb{R}^{3 \times 3}
w   = B %*% EAB$vectors[,1]                      # Eigenvektor von BA
cat("Eigenwerte von AB :"  , EAB$values[1:2],
    "\nEigenwerte von BA :", EBA$values[1:2],
    "\nBAw mit w = Bv    :", B %*% A %*% w,
    "\nlw mit w = Bv     :", EBA$values[1] * w)
```

```
Eigenwerte von AB : 85.57934 0.4206623
Eigenwerte von BA : 85.57934 0.4206623
BAw mit w = Bv    : -191.1333 -416.7586 -642.3839
lw mit w = Bv     : -191.1333 -416.7586 -642.3839
```

Theorem 9.18. *Für $A \in \mathbb{R}^{n\times m}, B \in \mathbb{R}^{p\times n}, a \in \mathbb{R}^m$ und $b \in \mathbb{R}^p$ gilt, dass der einzige von Null verschiedene Eigenwert von $Aab^TB \in \mathbb{R}^{n\times n}$ gleich b^TBAa mit zugehörigem Eigenvektor Aa ist.*

∘

Für einen Beweis verweisen wir auf Mardia et al. (1979), S. 468. Wir demonstrieren die Aussage dieses Theorems anhand untenstehenden **R** Codes.

```
A      = matrix(1:6, nrow = 2,  byrow = T)     # Matrix A \in \mathbb{R}^{2 x 3}
B      = matrix(1:8, ncol = 2,  byrow = T)     # Matrix B \in \mathbb{R}^{4 x 2}
a      = matrix(1:3, nrow = 3,  byrow = T)     # Vektor a \in \mathbb{R}^{3 x 1}
b      = matrix(1:4, nrow = 4,  byrow = T)     # Vektor b \in \mathbb{R}^{4 x 1}
EAabTB = eigen(A %*% a %*% t(b) %*% B)         # Eigenanalyse von Aab^TB \in \mathbb{R}^{2 x 2}
cat("Eigenwerte von AabTB :", EAabTB$values,
    "\nbTBAa                :", t(b) %*% B %*% A %*% a,
    "\nAa                   :", A %*% a,
    "\n(AabTB)Aa            :",(A %*% a %*% t(b) %*% B) %*% A %*% a,           # Mv
    "\n(bTBAa)Aa            :",as.vector((t(b) %*% B %*% A %*% a)) * (A %*% a)) # = \lambda v
```

```
Eigenwerte von AabTB : 2620 0
bTBAa                : 2620
Aa                   : 14 32
(AabTB)Aa            : 36680 83840
(bTBAa)Aa            : 36680 83840
```

9.8. Orthonormalzerlegung

Mit dem Begriff der *Zerlegung* einer Matrix wird das Aufspalten einer gegebenen Matrix in das Matrixprodukt mehrerer Matrizen bezeichnet. Verschiedenste Matrixzerlegungen spielen in vielen mathematischen Anwendungen eine wichtige Rolle, für einen Überblick siehe beispielsweise Golub & Van Loan (2013). In diesem Abschnitt führen wir mit der *Orthonormalzerlegung einer symmetrischen Matrix* eine spezielle Matrixzerlegung ein, die direkt auf der Eigenanalyse aufbaut. Wir halten zunächst folgendes grundlegendes Theorem zu den Eigenwerten und Eigenvektoren symmetrischer Matrizen fest.

Theorem 9.19 (Eigenwerte und Eigenvektoren symmetrischer Matrizen)**.**

$S \in \mathbb{R}^{m\times m}$ sei eine symmetrische Matrix. Dann gelten

(1) Die Eigenwerte von S sind reell.

(2) Die Eigenvektoren zu je zwei verschiedenen Eigenwerten von S sind orthogonal.

∘

Beweis. Wir setzen die Tatsache, dass eine symmetrische Matrix m reelle Eigenwerte hat, als gegeben voraus und zeigen lediglich, dass die Eigenvektoren zu je zwei verschiedenen Eigenwerten einer symmetrischen Matrix orthogonal sind. Ohne Beschränkung der Allgemeinheit seien also $\lambda_i, \lambda_j \in \mathbb{R}$ mit $1 \leq i, j \leq m$ und $\lambda_i \neq \lambda_j$ zwei verschiedene Eigenwerte von S mit zugehörigen Eigenvektoren q_i und q_j, respektive. Dann ergibt sich wie unten gezeigt, dass

$$\lambda_i q_i^T q_j = \lambda_j q_i^T q_j. \tag{9.137}$$

Mit $q_i \neq 0_m, q_j \neq 0_m$ und $\lambda_i \neq \lambda_j$ folgt damit $q_i^T q_j = 0$, weil es keine andere Zahl c als die Null gibt, für die bei $a, b \in \mathbb{R}$ und $a \neq b$ gilt, dass

$$ac = bc. \tag{9.138}$$

Um abschließend

$$\lambda_i q_i^T q_j = \lambda_j q_i^T q_j. \tag{9.139}$$

zu zeigen, halten wir zunächst fest, dass

$$Sq_i = \lambda_i q_i \Leftrightarrow (Sq_i)^T = (\lambda_i q_i)^T \Leftrightarrow q_i^T S^T = \lambda_i q_i^T \Leftrightarrow q_i^T S = \lambda_i q_i^T \Leftrightarrow q_i^T S q_j = \lambda_i q_i^T q_j \tag{9.140}$$

und

$$Sq_j = \lambda_j q_j \Leftrightarrow q_j^T S = \lambda_j q_j^T \Leftrightarrow q_j^T S q_i = \lambda_j q_j^T q_i \Leftrightarrow (q_j^T S q_i)^T = (\lambda_j q_j^T q_i)^T \Leftrightarrow q_i^T S q_j = \lambda_j q_i^T q_j \tag{9.141}$$

gelten. Sowohl $\lambda_i q_i^T q_j$ als auch $\lambda_j q_i^T q_j$ sind also mit $q_i^T S q_j$ und damit auch miteinander identisch. □

Offenbar haben wir nur Aussage (2) von Theorem 9.19 bewiesen. Ein vollständiger Beweis des Theorems findet sich zum Beispiel bei Strang (2009). Wir merken außerdem an, dass, weil wir nach Konvention Eigenvektoren der Länge 1 betrachten, die in Theorem 9.19 angesprochenen orthogonalen Eigenvektoren insbesondere auch orthonormal sind. Mithilfe von Theorem 9.19 können wir nun die Orthonormalzerlegung einer symmetrischen Matrix formulieren und ihre Existenz beweisen.

Theorem 9.20 (Orthonormalzerlegung einer symmetrischen Matrix)**.** *$S \in \mathbb{R}^{m \times m}$ sei eine symmetrische Matrix mit m verschiedenen Eigenwerten. Dann kann S geschrieben werden als*

$$S = Q \Lambda Q^T, \tag{9.142}$$

wobei $Q \in \mathbb{R}^{m \times m}$ eine orthogonale Matrix ist und $\Lambda \in \mathbb{R}^{m \times m}$ eine Diagonalmatrix ist.

∘

Beweis. Es seien $\lambda_1 > \lambda_2 > \ldots > \lambda_m$ die der Größe nach geordneten Eigenwerte von S und $q_1, \ldots, q_m$ die zugehörigen orthonormalen Eigenvektoren. Mit

$$Q := \begin{pmatrix} q_1 & q_2 & \cdots & q_m \end{pmatrix} \in \mathbb{R}^{m \times m} \text{ und } \Lambda := \operatorname{diag}\left(\lambda_1, \lambda_2, \ldots, \lambda_m\right) \in \mathbb{R}^{m \times m}, \tag{9.143}$$

folgt dann mit den Definitionen von Eigenwerten und Eigenvektoren zunächst, dass

$$Sq_i = \lambda_i q_i \text{ für } i = 1, \ldots, m \Leftrightarrow SQ = Q\Lambda. \tag{9.144}$$

Rechtsseitige Multiplikation mit Q^T ergibt dann mit $QQ^T = I_m$, dass

$$SQQ^T = Q\Lambda Q^T \Leftrightarrow SI_m = Q\Lambda Q^T \Leftrightarrow S = Q\Lambda Q^T. \tag{9.145}$$

□

Man nennt das Aufspalten von S in das Matrixprodukt $Q\Lambda Q^T$ aufgrund der Diagonalität von Λ auch eine *Diagonalisierung von S*. Wie im Beweis gezeigt, wählt man zur Darstellung von S in Diagonaldarstellung für die Diagonalelemente von Λ die der Größe nach geordneten Eigenwerte von S und für die Spalten von Q die jeweils zugehörigen Eigenvektoren von S. Wir verdeutlichen dies an einem Beispiel.

Beispiel 9.8 (Orthonormalzerlegung einer symmetrischen Matrix)**.** Für die symmetrische Matrix

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \tag{9.146}$$

mit den oben bestimmten Eigenwerten $\lambda_1 = 3$ und $\lambda_2 = 1$ sowie den zugehörigen orthonormalen Eigenvektoren

$$v_1 = \frac{1}{\sqrt{2}}\begin{pmatrix}1\\1\end{pmatrix}, v_2 = \frac{1}{\sqrt{2}}\begin{pmatrix}-1\\1\end{pmatrix} \tag{9.147}$$

seien

$$Q := \begin{pmatrix}v_1 & v_2\end{pmatrix} \text{ und } \Lambda = \text{diag}(\lambda_1, \lambda_2). \tag{9.148}$$

Dann ergibt sich offenbar

$$\begin{aligned}
Q\Lambda Q^T &= \begin{pmatrix}v_1 & v_2\end{pmatrix} \text{diag}(\lambda_1, \lambda_2) \begin{pmatrix}v_1 & v_2\end{pmatrix}^T \\
&= \left(\frac{1}{\sqrt{2}}\begin{pmatrix}1 & -1\\1 & 1\end{pmatrix}\begin{pmatrix}3 & 0\\0 & 1\end{pmatrix}\right)\left(\frac{1}{\sqrt{2}}\begin{pmatrix}1 & 1\\-1 & 1\end{pmatrix}\right) \\
&= \left(\frac{1}{\sqrt{2}}\begin{pmatrix}3 & -1\\3 & 1\end{pmatrix}\right)\left(\frac{1}{\sqrt{2}}\begin{pmatrix}1 & 1\\-1 & 1\end{pmatrix}\right) \\
&= \frac{1}{2}\begin{pmatrix}4 & 2\\2 & 4\end{pmatrix} \\
&= \begin{pmatrix}2 & 1\\1 & 2\end{pmatrix} \\
&= A
\end{aligned}$$

und wir haben Theorem 9.20 für dieses Beispiel verifiziert.

△

Symmetrische Quadratwurzel einer Matrix

Die Definition der Orthonormalzerlegung einer symmetrischen Matrix erlaubt es, den Begriff der *symmetrischen Quadratwurzel einer Matrix* einzuführen.

Definition 9.17 (Symmetrische Quadratwurzel einer Matrix)**.** $S \in \mathbb{R}^{m\times m}$ sei eine invertierbare symmetrische Matrix mit positiven Eigenwerten. Dann sind für $r \in \mathbb{N}^0$ und $s \in \mathbb{N}$ die rationalen Potenzen von S mit der orthonormalen Matrix $Q \in \mathbb{R}^{m\times m}$ der Eigenvektoren von S und der Diagonalmatrix $\Lambda = \text{diag}(\lambda_i) \in \mathbb{R}^{m\times m}$ der zugehörigen Eigenwerte $\lambda_1, ..., \lambda_m$ von S definiert als

$$S^{r/s} = Q\Lambda^{r/s}Q^T \text{ mit } \Lambda^{r/s} = \text{diag}\left(\lambda_i^{r/s}\right). \tag{9.149}$$

Der Spezialfall $r := 1, s := 2$ wird als *symmetrische Quadratwurzel von* S bezeichnet und hat die Form

$$S^{1/2} = Q\Lambda^{1/2}Q^T \text{ mit } \Lambda^{1/2} = \text{diag}\left(\lambda_i^{1/2}\right). \tag{9.150}$$

•

Wir halten fest, dass mit Definition 9.17 offenbar gilt, dass

$$\left(S^{1/2}\right)^2 = Q\Lambda^{1/2}Q^TQ\Lambda^{1/2}Q^T = Q\Lambda^{1/2}\Lambda^{1/2}Q^T = Q\Lambda Q^T = S. \tag{9.151}$$

Weiterhin gilt, dass

$$\left(S^{-1/2}\right)^2 = Q\Lambda^{-1/2}Q^TQ\Lambda^{-1/2}Q^T = Q\Lambda^{-1/2}\Lambda^{-1/2}Q^T = Q\Lambda^{-1}Q^T = S^{-1}. \tag{9.152}$$

Schließlich gilt, dass

$$\begin{aligned} S^{-1/2}SS^{-1/2} &= Q\Lambda^{-1/2}Q^TQ\Lambda Q^TQ\Lambda^{-1/2}Q^T \\ &= Q\Lambda^{-1/2}\Lambda\Lambda^{-1/2}Q^T \\ &= Q\Lambda\Lambda^{-1}Q^T \\ &= I_m \end{aligned} \tag{9.153}$$

9.9. Singulärwertzerlegung

Eine vielseitig einsetzbare Matrixzerlegung einer beliebigen Matrix ist die *Singulärwertzerlegung*. Wir sind an dieser Stelle lediglich an dem Zusammenhang von Singulärwertzerlegung und Eigenanalyse interessiert und verweisen für eine ausführliche Diskussion der Singulärwertzerlegung auf die weiterführende Literatur, beispielsweise Strang (2009). Der Begriff der Singulärwertzerlegung ist wie folgt definiert.

Definition 9.18 (Singulärwertzerlegung)**.** $Y \in \mathbb{R}^{m\times n}$ sei eine Matrix. Dann heißt die Zerlegung

$$Y = USV^T, \tag{9.154}$$

wobei $U \in \mathbb{R}^{m\times m}$ eine orthogonale Matrix ist, $S \in \mathbb{R}^{m\times n}$ eine Diagonalmatrix ist und $V \in \mathbb{R}^{n\times n}$ eine orthogonale Matrix ist, *Singulärwertzerlegung* von Y. Die Diagonalelemente von S heißen die *Singulärwerte* von Y.

•

Singulärwertzerlegungen werden auf Englisch *singular value decompositions* genannt und entsprechend mit *SVD* abgekürzt. Wir verzichten auf eine Diskussion der Berechnung einer Singulärwertzerlegung und weisen lediglich daraufhin, dass Singulärwertzerlegungen zum Beispiel in **R** mit der Funktion `svd()`, in **SciPy** mit `scipy.linalg.svd()` und in **Julia** mit `svd()` berechnet werden können. Folgendes Theorem beschreibt den Zusammenhang zwischen Singulärwertzerlegung und Eigenanalyse und wird an vielen Stellen eingesetzt.

Theorem 9.21 (Singulärwertzerlegung und Eigenanalyse)**.**

$Y \in \mathbb{R}^{m\times n}$ sei eine Matrix und

$$Y = USV^T \tag{9.155}$$

sei ihre Singulärwertzerlegung. Dann gilt:

- *Die Spalten von U sind die Eigenvektoren von YY^T,*
- *die Spalten von V sind die Eigenvektoren von Y^TY und*
- *die Singulärwerte sind die Quadratwurzeln der zugehörigen Eigenwerte.*

◦

Beweis. Wir halten zunächst fest, dass mit

$$\left(YY^T\right)^T = YY^T \text{ und } \left(Y^TY\right)^T = Y^TY, \tag{9.156}$$

YY^T und Y^TY symmetrische Matrizen sind und somit Orthonormalzerlegungen haben. Wir halten weiterhin fest, dass mit $V^TV = I_n$ und $U^TU = I_m$ gilt, dass

$$YY^T = USV^T\left(USV^T\right)^T = USV^TVS^TU^T = USS^TU^T =: U\Lambda_U U^T \tag{9.157}$$

und

$$Y^TY = \left(USV^T\right)^T USV^T = VS^TU^TUSV^T = VS^TSV^T =: V\Lambda_V V^T \tag{9.158}$$

ist, wobei wir $\Lambda_U := SS^T$ und $\Lambda_V := S^TS$ definiert haben. Weil das Produkt von Diagonalmatrizen wieder eine Diagonalmatrix ist, sind Λ_U und Λ_V Diagonalmatrizen und per Definition sind U und V orthogonale Matrizen. Wir haben also YY^T und Y^TY in Form der Orthonormalzerlegungen

$$YY^T = U\Lambda_U U^T \text{ und } Y^TY = V\Lambda_V V^T \tag{9.159}$$

geschrieben, wobei für die von null verschiedenen Diagonalelemente von Λ_U und Λ_V gilt, dass sie die quadrierten Singulärwerte, also die quadrierten Diagonalelemente von S, sind. □

10. Deskriptivstatistiken

Ziel der Auswertung von Deskriptivstatistiken ist es, Datensätze möglichst effizient der menschlichen Betrachtung zugänglich zu machen. Sobald die Anzahl der Datenpunkte eines Datensatzes eine gewisse Anzahl überschreitet, sind reine Zahlendarstellungen für die menschliche Kognition meist eher schwer zu erfassen. Hier setzt die Deskriptivstatistik an und bietet neben grafischen Darstellungen größerer Datensätze auch Maßzahlen an, die im Sinne der Datenreduktion bestimmte charakteristische Aspekte eines Datensatzes wie seinen "durchschnittlichen" Wert oder seine Variabilität beschreiben. In diesem Abschnitt wollen wir mit den univariaten Deskriptivstatistiken erste Verfahren und Maße kennenlernen, die es erlauben, Datensätze, in denen pro Studieneinheit eine Zahl vorliegt, zusammenzufassen. Wir betrachten dabei insbesondere *Häufigkeitsverteilungen* und *Histogramme*, *Verteilungsfunktionen* und *Quantile* sowie *Maße der zentralen Tendenz*, die Aussagen über "durchschnittliche" Datenwerte erlauben und *Maße der Datenvariabilität*, die Aussagen über die Streuung der Datenwerte erlauben.

In Abgrenzung zur probabilistischen Modellierung im Rahmen der Frequentistischen und Bayesianischen Inferenz basiert die deskriptive Statistik nicht auf der Wahrscheinlichkeitstheorie, kann also losgelöst von dieser betrachtet werden. Allerdings ergeben viele Aspekte der Deskriptivstatistik letztlich nur vor dem Hintergrund wahrscheinlichkeitstheoretischer Betrachtungen Sinn und umgekehrt sind viele Begriffe der Wahrscheinlichkeitstheorie durch deskriptivstatistische Konzepte motiviert. Wenn also der vorliegende Abschnitt ohne einen wahrscheinlichkeitstheoretischen Hintergrund auskommt, so erschließt sich seine volle Bedeutung sicherlich erst im Kontext der Begriffe der Wahrscheinlichkeitstheorie.

Wir fokussieren in diesem Abschnitt auf Deskriptivstatistiken zur Beschreibung eines Datensatzes der Form

$$y := (y_1, ..., y_n) \text{ mit } y_i \in \mathbb{R} \text{ für } i = 1, ..., n. \tag{10.1}$$

Dabei ist es zunächst unerheblich, ob ein solcher Datensatz in Form eines Spaltenvektors $y \in \mathbb{R}^{n \times 1}$ oder eines Zeilenvektors $y \in \mathbb{R}^{1 \times n}$ vorliegt. Weiterhin fokussieren wir auf die praktische Auswertung der betrachteten Deskriptivstatistiken, geben also viele Beispiele für ihre Berechnung mit **R**.

Anwendungsbeispiel

Als Anwendungsbeispiel betrachten wir durchgängig einen Datensatz zur evidenzbasierten Evaluation von Psychotherapie bei Depression. Dazu nehmen wir an, dass $n = 100$ Patient:innen zufällig auf eine Treatment- und eine Kontrollstudienbedingung aufgeteilt wurden und zu Beginn der jeweiligen Intervention mithilfe des BDI-II-Fragebogens zu ihrer Depressionsschwere befragt wurden. Die nach den Interventionen erhobenen BDI-II-Werte wollen wir in diesem Kapitel nicht betrachten. Wir nehmen also an, dass wir einen Datensatz wie durch folgenden **R**-Code in Tabelle 10.1 dargestellt vorliegen haben.

```
D = read.csv("./_data/110-deskriptive-statistik.csv")   # Datensatz laden
knitr::kable(D[,1:2], digits = 2, align = "c")          # Tabellenausgabe
```

Tabelle 10.1. BDI-II-Werte (PRE) von n = 100 Patient:innen in einer Treatmentgruppe (T) und einer Kontrollstudiengruppe (C) vor Beginn einer psychologischen Intervention

GROUP	PRE
T	17
T	20
T	16
T	18
T	21
T	17
T	17
T	17
T	18
T	18
T	20
T	17
T	16
T	18
T	16
T	18
T	17
T	14
T	18
T	18
T	20
T	20
T	21
T	19
T	19
T	17
T	20
T	21
T	17
T	17
T	19
T	20
T	22
T	20
T	21
T	20
T	16
T	15
T	15
T	18
T	21
T	17
T	18
T	21
T	17
T	19
T	16
T	17
T	17
T	18
C	22
C	19

Tabelle 10.1. BDI-II-Werte (PRE) von n = 100 Patient:innen in einer Treatmentgruppe (T) und einer Kontrollstudiengruppe (C) vor Beginn einer psychologischen Intervention

GROUP	PRE
C	21
C	18
C	19
C	17
C	20
C	19
C	19
C	19
C	17
C	20
C	18
C	20
C	18
C	18
C	15
C	18
C	17
C	19
C	19
C	19
C	20
C	19
C	20
C	19
C	21
C	19
C	19
C	18
C	20
C	16
C	21
C	19
C	20
C	18
C	23
C	18
C	19
C	18
C	21
C	17
C	20
C	21
C	21
C	20
C	18
C	18
C	19
C	19

10.1. Häufigkeitsverteilungen

Wir beginnen mit den Begriffen der *absoluten* und der *relativen Häufigkeitsverteilung*. Für Datensätze mit Werten, in denen der gleiche Wert mehrfach auftritt, können Häufigkeits-

verteilungen einen ersten Eindruck von der Beschaffenheit des Datensatzes liefern.

Definition 10.1 (Absolute und relative Häufigkeitsverteilungen)**.** $y := (y_1, ..., y_n)$ sei ein Datensatz und $W := \{w_1, ..., w_k\}$ mit $k \leq n$ sei die Menge der im Datensatz vorkommenden Werte. Dann heißt die Funktion

$$h : W \to \mathbb{N}, w \mapsto h(w) := \text{Anzahl der } y_i \text{ aus } y \text{ mit } y_i = w \tag{10.2}$$

die *absolute Häufigkeitsverteilung* der Werte von y und die Funktion

$$r : W \to [0, 1], w \mapsto r(w) := \frac{h(w)}{n} \tag{10.3}$$

heißt die *relative Häufigkeitsverteilung* der Werte von y.

•

Häufigkeitsverteilungen können in **R** durch Kombination der `table()`- und `barplot()`-Funktion ausgewertet und dargestellt werden. Folgender **R**-Code erzeugt zunächst die absolute und die relative Häufigkeitsverteilung der Pre-Interventions-BDI-II-Daten des Beispieldatensatzes.

```
D        = read.csv("./_data/110-deskriptive-statistik.csv")    # Datensatz laden
y        = D$PRE                                                # PRE-Werte als double
n        = length(y)                                            # Anzahl der Werte (100)
H        = as.data.frame(table(y))                              # Absolute Häufigkeiten
names(H) = c("w", "ah")                                         # Spaltenbenennung
H$rh     = H$ah/n                                               # Relative Häufigkeiten
print(H, digits = 1)                                            # Ausgabe
```

```
    w ah   rh
1  14  1 0.01
2  15  3 0.03
3  16  6 0.06
4  17 17 0.17
5  18 21 0.21
6  19 20 0.20
7  20 17 0.17
8  21 12 0.12
9  22  2 0.02
10 23  1 0.01
```

An der Ausgabe des Dataframes `H` können wir ablesen, dass im betrachteten Datensatz 10 verschiedene Werte `w` zwischen 14 und 23 vorkommen, wobei zum Beispiel die Werte 18 und 22 jeweils 21-mal bzw. zweimal auftreten. Sowohl die absolute als auch die relative Häufigkeitsverteilung zeigen, dass Werte um 18 im vorliegenden Datensatz gehäuft auftreten, Extremwerte wie 14 oder 23 dagegen eher selten. Man beachte, dass es sich bei der relativen Häufigkeitsverteilung lediglich um eine skalierte Form der absoluten Häufigkeitsverteilung handelt. Qualitativ, also hinsichtlich des gehäuften oder selteneren Vorkommens bestimmter Werte, unterscheiden sich beide Häufigkeitsverteilungen nicht. Dies wird insbesondere auch deutlich, wenn man wie in Abbildung 10.1 beide Häufigkeitsverteilungen visualisiert. Folgender **R**-Code nutzt zu diesem Zweck die Funktion `barplot()`. Die Höhe des über einem Wert w aufgetragenen Balkens entspricht dabei den Funktionswerten $h(w)$

bzw. $r(w)$. Die visuelle Einsicht entspricht natürlich der Inspektion des Dataframes `H`. Beide Häufigkeitsverteilungen zeigen, dass Werte um 18 im vorliegenden Datensatz gehäuft auftreten, wohingegen niedrigere oder höhere Werte wie 14 bzw. 23 dagegen eher selten sind.

```
pdf(                                                    # PDF-Datei öffnen
  file     = "./_figures/110-haeufigkeitsverteilungen.pdf",  # Dateiname
  width    = 7,                                         # Breite in Zoll
  height   = 4)                                         # Höhe in Zoll
par(                                                    # Grafikparameter
  mfcol    = c(1,2),                                    # Grafikanordnung
  las      = 1,                                         # Achsentextlage
  cex      = 0.7,                                       # Textvergrößerung
  cex.main = 1.3)                                       # Titelvergrößerung
h        = H$ah                                         # h(w)-Werte
r        = H$rh                                         # r(w)-Werte
names(h) = H$w                                          # w-Werte als Balkennamen
names(r) = H$w                                          # w-Werte als Balkennamen
barplot(                                                # Balkendiagramm
  h,                                                    # absolute Häufigkeiten
  col      = "gray90",                                  # Balkenfarbe
  xlab     = "w",                                       # x-Achsentext
  ylab     = "h(w)",                                    # y-Achsentext
  ylim     = c(0,25),                                   # y-Achsengrenzen
  main     = "Absolute Häufigkeitsverteilung")          # Titel
barplot(                                                # Balkendiagramm
  r,                                                    # relative Häufigkeiten
  col      = "gray90",                                  # Balkenfarbe
  xlab     = "w",                                       # x-Achsentext
  ylab     = "r(w)",                                    # y-Achsentext
  ylim     = c(0,.25),                                  # y-Achsengrenzen
  main     = "Relative Häufigkeitsverteilung")          # Titel
dev.off()                                               # Grafik schließen
```

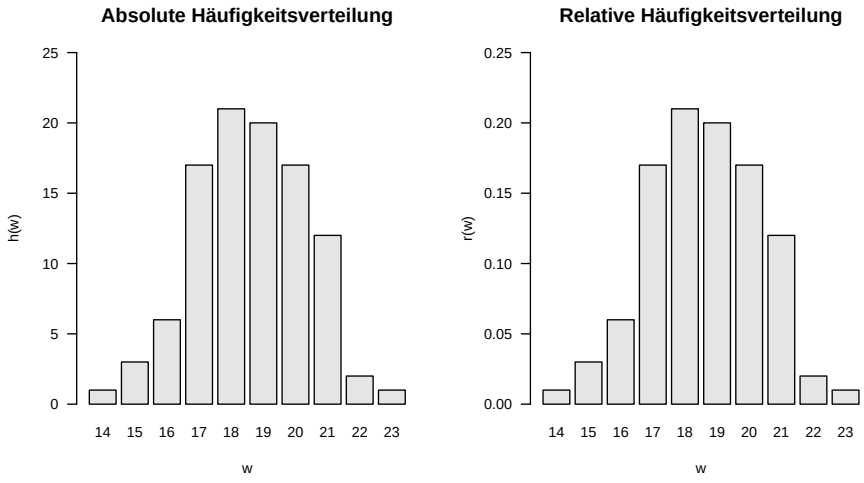


Abbildung 10.1. Absolute und relative Häufigkeitsverteilungen der Pre-Interventions-BDI-II-Werte.

10.2. Histogramme

Wenn in einem Datensatz keine Werte mehrfach vorkommen, nehmen die absoluten und relativen Häufigkeitsverteilungen für jeden dieser Werte den Wert 1 bzw. $1/n$ an und bieten dann keinen Mehrwert über die visuelle Inspektion des Datensatzes hinaus. Die in diesem Abschnitt vorgestellten Histogramme bieten jedoch eine Möglichkeit, auch in diesem Fall visuelle Darstellungen von Häufigkeitsverteilungen zu generieren. Dabei werden verschiedene Werte, die in einem wohldefinierten Sinne "nah beieinander" liegen, zu Klassen zusammengefasst und die absoluten oder relativen Häufigkeiten dieser Klassen bestimmt. Da bei Datensätzen, in denen die gleichen Werte mehrfach vorkommen, diese Werte der Natur nach in der gleichen Klasse liegen, können Histogramme auch in dem in Kapitel 10.1 betrachteten Fall sinnvoll angewendet werden. Histogramme verallgemeinern also die im vorherigen Abschnitt betrachteten Häufigkeitsverteilungen bei Datensätzen mit mehrfach auftretenden Werten.

Wir geben zunächst eine Definition des Histogrammbegriffs. Man beachte, dass in dieser Definition der Vorgang der Klassenbildung, die Bestimmung ihrer absoluten und relativen Häufigkeiten sowie die Visualisierung dieser Häufigkeiten eng verzahnt sind. Dies ist der Konvention geschuldet, dass der Begriff des Histogramms sowohl eine bestimmte Form der Datenanalyse als auch ihre Visualisierung beschreibt.

Definition 10.2 (Histogramm)**.** $y := (y_1, \dots, y_n)$ sei ein Datensatz mit mindestens zwei verschiedenen Werten. Die Klassengrenzen seien $b_0 < b_1 < \cdots < b_k$ mit

$$b_0 := \min_{1 \leq i \leq n} y_i \text{ und } b_k := \max_{1 \leq i \leq n} y_i. \tag{10.4}$$

Die Klassen sind definiert als

$$C_1 := \{t \in \mathbb{R} | b_0 \leq t \leq b_1\} \tag{10.5}$$

und für $2 \leq j \leq k$ als

$$C_j := \{t \in \mathbb{R} | b_{j-1} < t \leq b_j\}. \tag{10.6}$$

Wir betrachten zunächst Klassen gleicher Breite $d := b_j - b_{j-1} > 0$. Jeder Datenwert gehöre genau einer Klasse an. Die *absolute Klassenhäufigkeit* und die *relative Klassenhäufigkeit* sind definiert als

$$h_j := \left|\{i \in \{1, \dots, n\} | y_i \in C_j\}\right| \text{ und } r_j := \frac{h_j}{n}. \tag{10.7}$$

Ein *Häufigkeitshistogramm* stellt über jeder Klasse C_j ein Rechteck der Breite d und der Höhe h_j beziehungsweise r_j dar. Davon zu unterscheiden ist ein *Dichtehistogramm*. Bei Klassenbreiten $d_j > 0$ hat das Rechteck über C_j die Höhe

$$\frac{r_j}{d_j}. \tag{10.8}$$

Seine Fläche entspricht damit der relativen Klassenhäufigkeit r_j. Die Gesamtfläche aller Rechtecke beträgt eins.

•

Natürlich ist das visuelle Erscheinungsbild eines Histogramms stark davon abhängig, wie genau die Werte eines Datensatzes zu Klassen zusammengefasst werden. Der entscheidende Parameter dafür ist nach Definition 10.2 die Anzahl der Klassen k, die zwischen dem Minimalwert b_0 und dem Maximalwert b_k des Datensatzes gewählt werden. Im Folgenden stellen wir einige konventionelle Werte für die Anzahl der Klassen k vor und berechnen und visualisieren sie am Beispiel des Beispieldatensatzes. Dabei gehen wir durchgängig davon aus, dass die benachbarten Klassen C_j mit $j = 1, ..., k$ für die Anzahl von Klassen k mit konstanter Breite $d = b_j - b_{j-1}$ gewählt werden.

Zur Berechnung und Visualisierung von Histogrammen nutzen wir die **R**-Funktion `hist()`. Bei dieser werden die Klassengrenzen als das Argument `breaks` festgelegt. Mit `right = TRUE` und `include.lowest = TRUE` werden die rechtsgeschlossenen Klassen aus Definition 10.2 verwendet. Die erste Klasse schließt zusätzlich den Minimalwert ein. Speziell ist `breaks` der **R**-Vektor `c(b_0,b_1,...,b_k)` mit Länge $k + 1$.

Mit `prob = TRUE` erzeugt `hist()` ein Dichtehistogramm. Die Fläche jedes Rechtecks entspricht dann der relativen Klassenhäufigkeit; die Gesamtfläche beträgt eins.

Um den Effekt verschiedener Wahlen der Anzahl der Klassen zu veranschaulichen, lesen wir zunächst den Datensatz ein und bestimmen seine minimalen und maximalen Werte b_0 und b_k.

```
# Datensatz
D   = read.csv("./_data/110-deskriptive-statistik.csv")     # Datensatz laden
y   = D$PRE                                                 # PRE-BDI-II-Daten
n   = length(y)                                             # Anzahl der Datenwerte
b_0 = min(y)                                                # Minimum
b_k = max(y)                                                # Maximum
```

```
Minimum b_0                :  14
Maximum b_k                :  23
```

Eine erste Möglichkeit der Wahl der Klassen k besteht darin, möglichst genau eine gewünschte konstante Breite d zu erzielen. Hierzu setzt man

$$k := \left\lceil \frac{b_k - b_0}{d} \right\rceil . \tag{10.9}$$

Wie in Definition 10.2 betrachten wir Datensätze mit mindestens zwei verschiedenen Werten. Die Anwendung der Aufrundungsfunktion impliziert, dass die resultierende Klassenbreite höchstens dem gewünschten Wert entspricht, aber auch kleiner sein kann. Folgender **R**-Code verdeutlicht diesen Effekt.

```
# Histogramm mit gewünschter Klassenbreite d = 2
d = 2                                       # Gewünschte Klassenbreite
k = ceiling((b_k - b_0)/d)                  # Anzahl der Klassen
b = seq(b_0, b_k, length.out = k + 1)       # Klassengrenzen
```

```
Gew<U+00FC>nschte Klassenbreite d :  2
Klassenanzahl k            :  5
Klassengrenzen b_j         :  14 15.8 17.6 19.4 21.2 23
Erzielte Klassenbreite  d  :  1.8
```

Die Wahl einer gewünschten Klassenbreite von $d = 1.5$ dagegen führt für den vorliegenden Datensatz auf eine resultierende Klassenbreite, die dem Wunsch entspricht.

```
# Histogramm mit gewünschter Klassenbreite d = 1.5
d = 1.5                                  # Gewünschte Klassenbreite
k = ceiling((b_k - b_0)/d)               # Anzahl der Klassen
b = seq(b_0, b_k, length.out = k + 1)    # Klassengrenzen
```

```
Gew<U+00FC>nschte Klassenbreite d :  1.5
Klassenanzahl k            :  6
Klassengrenzen b_j         :  14 15.5 17 18.5 20 21.5 23
Erzielte Klassenbreite  d  :  1.5
```

Eine weitere Möglichkeit ist es, die Anzahl der Klassen abhängig von der Anzahl der Datenpunkte im Datensatz zu machen. Die *Wurzelregel* setzt

$$k := \lceil \sqrt{n} \rceil. \tag{10.10}$$

Folgender **R**-Code implementiert diese Wahl für den vorliegenden Datensatz.

```
# Histogramm mit Wurzelregel
k = ceiling(sqrt(n))                     # Anzahl der Klassen
b = seq(b_0, b_k, length.out = k + 1)    # Klassengrenzen
```

```
Anzahl Datenpunkte n       :  100
Klassenanzahl k            :  10
Klassengrenzen b_j         :  14 14.9 15.8 16.7 17.6 18.5 19.4 20.3 21.2 22.1 23
Erzielte Klassenbreite  d  :  0.9
```

Ähnlich gelagert wie die Wurzelregel ist die von Sturges (1926) vorgeschlagene Klassenanzahl, welche die Darstellung unter einer impliziten Normalverteilungsannahme optimiert und durch

$$k := \lceil \log_2 n + 1 \rceil \tag{10.11}$$

gegeben ist. Im vorliegenden Fall erhalten wir:

```
# Klassenanzahl nach Sturges (1926)
k = ceiling(log2(n) + 1)                 # Anzahl der Klassen
b = seq(b_0, b_k, length.out = k + 1)    # Klassengrenzen
```

```
Anzahl Datenpunkte n       :  100
Klassenanzahl k            :  8
Klassengrenzen b_j         :  14 15.125 16.25 17.375 18.5 19.625 20.75 21.875 23
Erzielte Klassenbreite  d  :  1.125
```

Eine weitere Möglichkeit ist es, Deskriptivstatistiken des Datensatzes in die Wahl der Klassenanzahl einfließen zu lassen. Als Maß für die Streuung der Daten im Datensatz nutzt die Klassenanzahl nach Scott (1979) die empirische Standardabweichung (cf. Kapitel 10.6), um durch das Histogramm eine Dichteschätzung bei Normalverteilung zu realisieren. Wir wollen den nichtparametrischen Hintergrund dieses Vorgehens hier nicht vertiefen, sondern

halten lediglich fest, dass die Wahl der Klassenanzahl nach Scott (1979) durch Festlegung der Klassenbreite zu

$$d := 3.49S/n^{1/3} \tag{10.12}$$

und die anschließende Wahl der Klassenanzahl durch

$$k := \left\lceil \frac{b_k - b_0}{d} \right\rceil \tag{10.13}$$

gegeben ist, wobei S die Standardabweichung des Datensatzes bezeichnet. Im vorliegenden Fall erhalten wir:

```
# Klassenanzahl nach Scott (1979)
S = sd(y)                                    # Empirische Standardabweichung
d = 3.49*S/(n^(1/3))                         # Klassenbreite nach Scott
k = ceiling((b_k - b_0)/d)                   # Anzahl der Klassen
b = seq(b_0, b_k, length.out = k + 1)        # Klassengrenzen
```

```
Anzahl Datenpunkte n       :  100
Standardabweichung         :  1.740167
Klassenbreite nach Scott d :  1.308428
Klassenanzahl k            :  7
Klassengrenzen b_j         :  14 15.28571 16.57143 17.85714 19.14286 20.42857 21.71429 23
Erzielte Klassenbreite  d  :  1.285714
```

Per Default nutzt die in **R** implementierte `hist()`-Funktion eine Modifikation der von Sturges (1926) vorgeschlagenen Klassenanzahl und bietet eine Reihe von weiteren Möglichkeiten zur Wahl der Klassen. Einen Überblick dazu liefert `?hist`. Folgender **R**-Code visualisiert die absoluten Häufigkeiten der Werte des Beispieldatensatzes anhand der oben spezifizierten Klassen.

```
# Grafikparameter
pdf(                                                    # PDF-Datei öffnen
  file     = "./_figures/110-histogramme.pdf",          # Dateiname
  width    = 6,                                         # Breite in Zoll
  height   = 9)                                         # Höhe in Zoll
par(                                                    # Grafikparameter
  mfcol    = c(3,2),                                    # Grafikanordnung
  las      = 1,                                         # Achsentextlage
  cex      = .7,                                        # Textvergrößerung
  cex.main = .9)                                        # Titelvergrößerung
x_min    = 12                                           # x-Achsengrenze
x_max    = 25                                           # x-Achsengrenze
y_min    = 0                                            # y-Achsengrenze
y_max    = 45                                           # y-Achsengrenze
label    = c("", "", "Wurzelregel", "Sturges", "Scott")  # Titel

# Histogramme mit vordefinierter Klassenanzahl und Klassenbreite
for(i in 1:5){
  hist(                                                 # Histogramm
    y,                                                  # Datensatz
    right          = TRUE,                              # rechtsgeschlossene Klassen
    include.lowest = TRUE,                              # Einschluss des Minimalwerts
    breaks   = bs[[i]],                                 # breaks-Argument
    xlim     = c(x_min, x_max),                         # x-Achsengrenzen
    ylim     = c(y_min, y_max),                         # y-Achsengrenzen
```

```
    ylab     = "Häufigkeit",                          # y-Achsentext
    xlab     = "BDI",                                 # x-Achsentext
    main = sprintf(                                   # Titel
      paste(label[i], "k = %.0f, d = %.2f"),          # Textmuster
      ks[i],                                          # Klassenanzahl
      ds[i]))                                         # Klassenbreite
}

# R-Standardhistogramm
hist(                                                 # Histogramm
  y,                                                  # Datensatz
  right          = TRUE,                              # rechtsgeschlossene Klassen
  include.lowest = TRUE,                              # Einschluss des Minimalwerts
  xlim     = c(x_min, x_max),                         # x-Achsengrenzen
  ylim     = c(y_min, y_max),                         # y-Achsengrenzen
  ylab     = "Häufigkeit",                            # y-Achsentext
  xlab     = "",                                      # x-Achsentext
  main     = "R Default")                             # Titel
dev.off()                                             # Grafik schließen
```

10.3. Empirische Verteilungsfunktionen

Neben der Frage, wie häufig in einem Datensatz bestimmte Werte oder Klassen von Werten vorkommen, kann es interessant sein, zu untersuchen, wie häufig Werte vorkommen, die kleiner als ein bestimmter Wert sind. Obwohl die Antwort auf diese Frage natürlich in den absoluten und relativen Häufigkeiten bzw. den entsprechenden Histogrammen implizit ist, ist es manchmal von Vorteil, diese Information direkt verfügbar zu haben. Die in diesem Abschnitt eingeführten Begriffe der *kumulativen absoluten und relativen Häufigkeitsverteilung* sowie der *empirischen Verteilungsfunktion* bezeichnen die entsprechenden Analoga zu den in Kapitel 10.1 und Kapitel 10.2 diskutierten Begriffen. Wir beginnen mit der Definition der *kumulativen absoluten* und *kumulativen relativen Häufigkeitsverteilungen*.

Definition 10.3 (Kumulative absolute und relative Häufigkeitsverteilungen)**.** $y = (y_1, ..., y_n)$ sei ein Datensatz und $W := \{w_1, ..., w_k\}$ mit $k \leq n$ sei die Menge der im Datensatz vorkommenden Zahlenwerte. Weiterhin seien h die absolute und r die relative Häufigkeitsverteilung der Werte von y. Dann heißt die Funktion

$$H : W \to \mathbb{N}, w \mapsto H(w) := \sum_{w' \leq w} h(w') \tag{10.14}$$

die *kumulative absolute Häufigkeitsverteilung* von y und die Funktion

$$R : W \to [0, 1], w \mapsto R(w) := \sum_{w' \leq w} r(w') \tag{10.15}$$

die *kumulative relative Häufigkeitsverteilung* der Zahlenwerte von y.

•

Im Sinne der Definition Definition 10.1 gilt für die kumulativen Häufigkeitsverteilungen also

$$H(w) = \text{Anzahl der } y_i \text{ aus } y \text{ mit } y_i \leq w \tag{10.16}$$

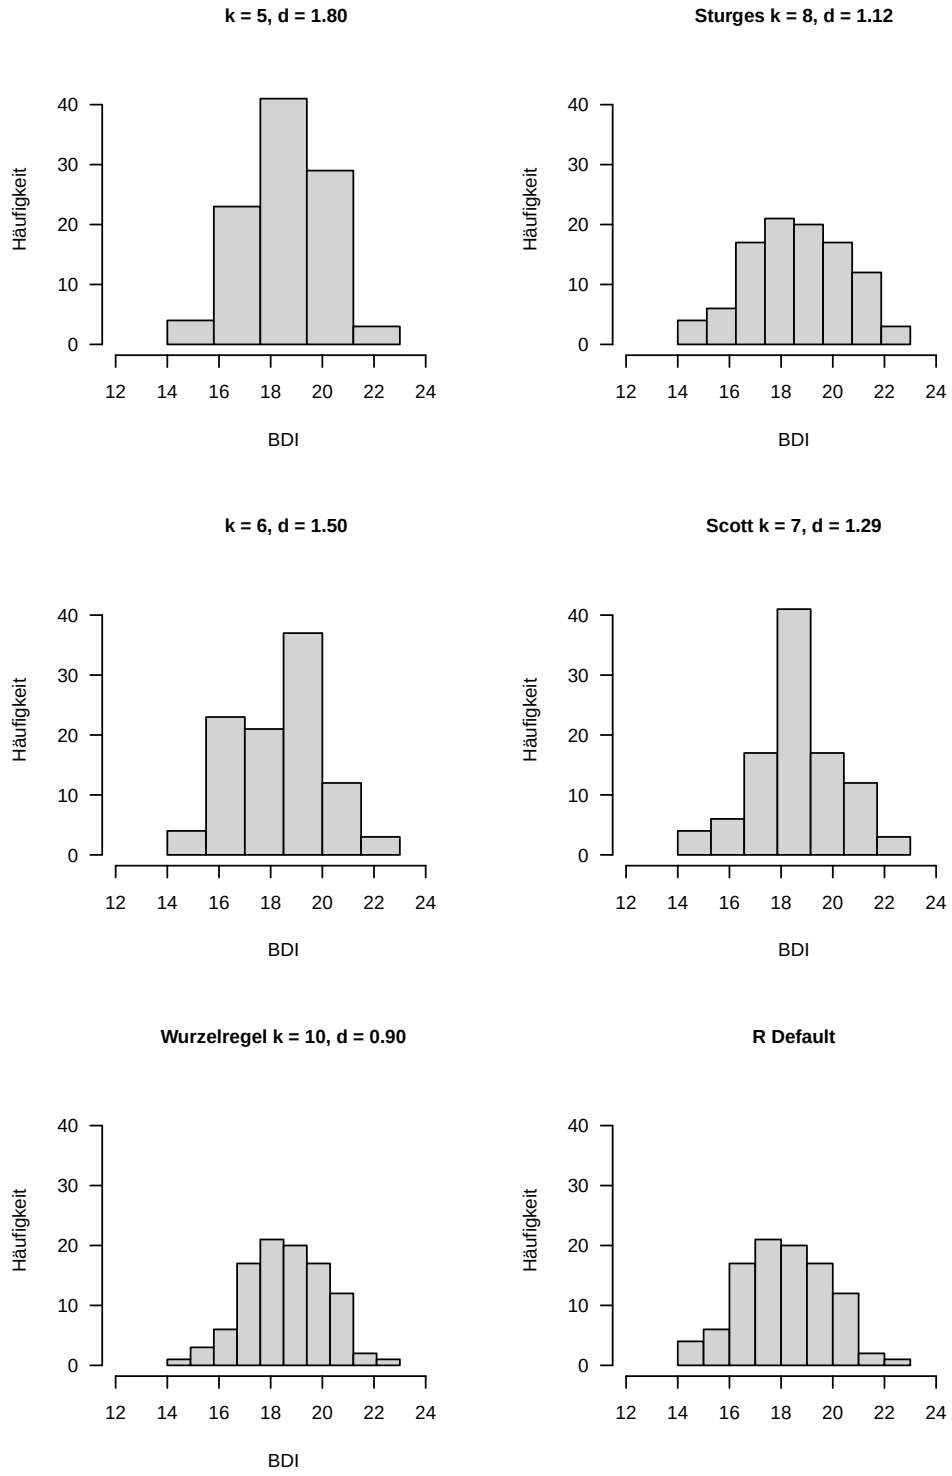


Abbildung 10.2. Histogramme der absoluten Häufigkeiten der Pre-Interventions-BDI-II-Werte. Man beachte, dass der qualitative Eindruck, dass im Datensatz Werte um 18 gehäuft auftreten und niedrigere und höhere Werte seltener sind, über alle Wahlen der Klassenanzahl konstant ist. Das genaue quantitative Erscheinungsbild ist dagegen von der exakten Wahl der Klassenanzahl und Klassenbreite abhängig.

und

$$R(w) = \text{Anzahl der } y_i \text{ aus } y \text{ mit } y_i \leq w \text{ geteilt durch } n. \tag{10.17}$$

In **R** erlaubt die Funktion `cumsum()` die Berechnung kumulativer Summen und ermöglicht damit die Auswertung kumulativer Häufigkeitsverteilungen, wie folgender **R**-Code anhand des Beispieldatensatzes demonstriert.

```
D         = read.csv("./_data/110-deskriptive-statistik.csv")    # Datensatz laden
y         = D$PRE                                                # PRE-BDI-II-Daten
n         = length(y)                                            # Anzahl der Datenwerte
H         = as.data.frame(table(y))                              # Absolute Häufigkeiten
names(H) = c("w", "h")                                           # Spaltenbenennung
H$H       = cumsum(H$h)                                          # Kumulierte Anzahlen
H$r       = H$h/n                                                # Relative Häufigkeiten
H$R       = cumsum(H$r)                                          # Kumulierte Anteile
print(H, digits = 1)
```

```
    w  h   H    r    R
1  14  1   1 0.01 0.01
2  15  3   4 0.03 0.04
3  16  6  10 0.06 0.10
4  17 17  27 0.17 0.27
5  18 21  48 0.21 0.48
6  19 20  68 0.20 0.68
7  20 17  85 0.17 0.85
8  21 12  97 0.12 0.97
9  22  2  99 0.02 0.99
10 23  1 100 0.01 1.00
```

Man beachte dabei insbesondere die Gegenüberstellung von `h` und `H` sowie von `r` und `R`, die die kumulativen Summen in Definition 10.3 verdeutlichen. Folgender **R**-Code ermöglicht die Darstellung der so bestimmten kumulativen Häufigkeitsverteilungen wie in Abbildung 10.3 gezeigt. Offensichtlich sind die absolute und die relative Häufigkeit von Werten kleiner als der kleinste Wert im Datensatz null. Die absolute und relative Häufigkeit von Werten kleiner oder gleich dem größten Wert im Datensatz ist dagegen n bzw. $n/n = 1$.

```
pdf(                                                             # PDF-Datei öffnen
  file   = "./_figures/110-kumulative-haeufigkeitsverteilungen.pdf",  # Dateiname
  width  = 10,                                                   # Breite in Zoll
  height = 5)                                                    # Höhe in Zoll
Hw        = H$H                                                  # H(w)-Werte
Rw        = H$R                                                  # R(w)-Werte
names(Hw) = H$w                                                  # Balkennamen
names(Rw) = H$w                                                  # Balkennamen
par(                                                             # Grafikparameter
  mfcol     = c(1,2),                                            # Grafikanordnung
  las       = 1,                                                 # Achsentextlage
  cex       = 1)                                                 # Textvergrößerung
barplot(                                                         # Balkendiagramm
  Hw,                                                            # H(w)-Werte
  col       = "gray90",                                          # Balkenfarbe
  xlab      = "w",                                               # x-Achsentext
  ylab      = "H(w)",                                            # y-Achsentext
  ylim      = c(0,110),                                          # y-Achsengrenzen
  las       = 1,                                                 # Achsentextlage
```

```
  main      = "Absolute kumulative Häufigkeit PRE")                # Titel
barplot(                                                           # Balkendiagramm
  Rw,                                                              # R(w)-Werte
  col       = "gray90",                                            # Balkenfarbe
  xlab      = "w",                                                 # x-Achsentext
  ylab      = "R(w)",                                              # y-Achsentext
  ylim      = c(0,1),                                              # y-Achsengrenzen
  las       = 1,                                                   # Achsentextlage
  main      = "Relative kumulative Häufigkeit PRE")                # Titel
dev.off()                                                          # Grafik schließen
```

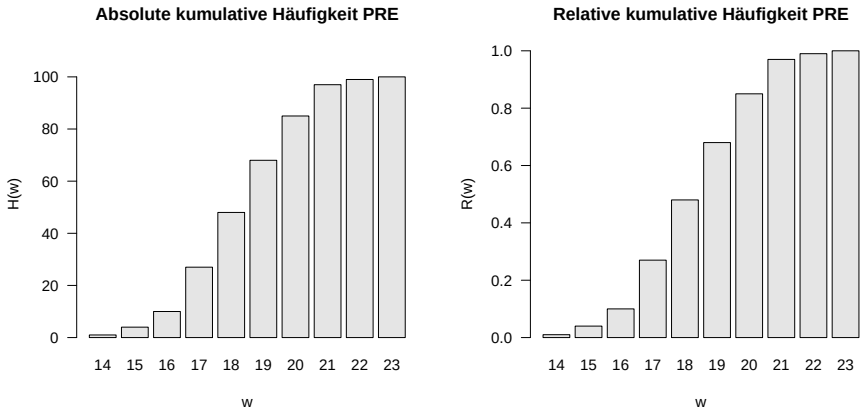


Abbildung 10.3. Absolute und relative kumulative Häufigkeitsverteilungen der Pre-Interventions-BDI-II-Werte.

Das kumulative Analogon zu einem Histogramm ist die *empirische Verteilungsfunktion*. Im Unterschied zu einem Histogramm ist für die Bestimmung einer empirischen Verteilungsfunktion allerdings keine Definition von Klassen erforderlich. An die Stelle der Intervalleinteilung der reellen Zahlen zwischen dem Minimum und dem Maximum eines Datensatzes treten bei der empirischen Verteilungsfunktion einfach die reellen Zahlen, wie folgende Definition verdeutlicht.

Definition 10.4 (Empirische Verteilungsfunktion)**.** $y = (y_1, ..., y_n)$ sei ein Datensatz. Dann heißt die Funktion

$$F : \mathbb{R} \to [0, 1], x \mapsto F(x) := \frac{\text{Anzahl der } y_i \text{ aus } y \text{ mit } y_i \leq x}{n} \tag{10.18}$$

die empirische Verteilungsfunktion (EVF) von y.

•

Die empirische Verteilungsfunktion wird manchmal auch die *empirische kumulative Verteilungsfunktion* genannt. Allgemein beschränkt man sich bei der empirischen Verteilungsfunktion wie in Definition 10.4 auf die Angabe der relativen Häufigkeiten. Natürlicherweise kommen in Datensätzen nicht alle reellen Zahlen vor. Dies impliziert, dass die relative Häufigkeit, die reellen Zahlen zugeordnet wird, die zwischen zwei benachbarten Werten des Datensatzes liegen, derjenigen des kleineren der beiden Werte entspricht. Typischerweise sind empirische Verteilungsfunktionen also Treppenfunktionen. In **R** kann die Funktion `ecdf()` zur Evaluation und Visualisierung der empirischen Verteilungsfunktion eingesetzt

werden, wie folgender **R**-Code anhand des Beispieldatensatzes demonstriert und in Abbildung 10.4 visualisiert ist. Man liest aus Abbildung 10.4 zum Beispiel ab, dass die relative Häufigkeit von Werten kleiner als 17.9 etwa 0.3 ist. Die gleiche relative Häufigkeit haben Werte kleiner als 17.8.

```
D      = read.csv("./_data/110-deskriptive-statistik.csv")  # Datensatz laden
y      = D$PRE                                              # PRE-BDI-II-Daten
evf    = ecdf(y)                                            # Evaluation der EVF
pdf(                                                        # PDF-Datei öffnen
  file   = "./_figures/110-ecdf.pdf",                       # Dateiname
  width  = 8,                                               # Breite in Zoll
  height = 5)                                               # Höhe in Zoll
plot(                                                       # EVF darstellen
  evf,                                                      # ecdf-Objekt
  xlab   = "BDI",                                           # x-Achsentext
  ylab   = "Relative Häufigkeit",                           # y-Achsentext
  main   = "Empirische Verteilungsfunktion")                # Titel
dev.off()                                                   # Grafik schließen
```

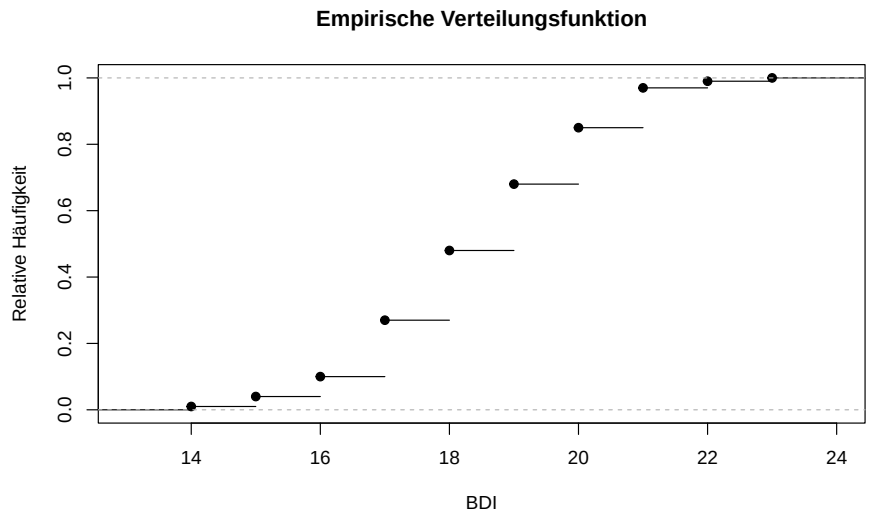


Abbildung 10.4. Empirische Verteilungsfunktion der PRE-Werte.

Die mit `ecdf()` erzeugte Funktion lässt sich auch an einzelnen Stellen auswerten.

```
evf = ecdf(D$PRE)                       # Empirische Verteilungsfunktion: PRE-Werte
evf(17)                                 # Anteil der Werte kleiner oder gleich 17
```

```
[1] 0.27
```

```
evf(19)                                 # Anteil der Werte kleiner oder gleich 19
```

```
[1] 0.68
```

Im Beispieldatensatz sind 27 % der BDI-PRE-Werte kleiner oder gleich 17 und 68 % kleiner oder gleich 19.

10.4. Quantile und Boxplots

Die empirische Verteilungsfunktion gibt eine zumindest grafisch dargestellte Antwort auf die Frage, wie groß der relative Anteil der Werte eines Datensatzes ist, die kleiner als ein gegebener Wert sind. Die in diesem Abschnitt eingeführten Quantile können als Inversion dieser Datensatzinterrogation verstanden werden. Bei Quantilen gibt man einen relativen Anteil $0 \leq p \leq 1$ vor und bestimmt einen Wert, sodass mindestens $p \cdot 100\%$ der Datenwerte kleiner oder gleich diesem Wert und mindestens $(1-p) \cdot 100\%$ der Datenwerte größer oder gleich diesem Wert sind. Wir nutzen folgende Definition des Begriffs des *p-Quantils*.

Definition 10.5 (p-Quantil)**.** $y := (y_1, \dots, y_n)$ sei ein Datensatz mit $n \geq 1$ und $y_{(1)} \leq \dots \leq y_{(n)}$ seien seine aufsteigend sortierten Werte. Weiterhin bezeichne $\lfloor \cdot \rfloor$ die Abrundungsfunktion. Dann heißt für $0 \leq p \leq 1$ die Zahl

$$y_p := \begin{cases} y_{(1)} & p = 0, \\ y_{(\lfloor np+1 \rfloor)} & 0 < p < 1,\ np \notin \mathbb{N}, \\ \frac{y_{(np)} + y_{(np+1)}}{2} & 0 < p < 1,\ np \in \mathbb{N}, \\ y_{(n)} & p = 1 \end{cases} \tag{10.19}$$

das *p-Quantil* des Datensatzes y.

•

Man beachte, dass das p-Quantil y_p nach Definition 10.5 entweder ein Wert des Datensatzes oder ein Wert zwischen zwei Werten des Datensatzes ist. Nach Konstruktion von y_p gilt, dass mindestens $p \cdot 100\%$ aller Werte des Datensatzes kleiner oder gleich y_p und mindestens $(1-p) \cdot 100\%$ aller Werte größer oder gleich y_p sind. Diese Anteile müssen nicht exakt erreicht werden. Insbesondere können wiederholt auftretende Datenwerte dazu führen, dass die jeweiligen Anteile größer sind. Je nach Wahl von p erhalten die p-Quantile spezielle Bezeichnungen:

- $y_{0.25}, y_{0.50}, y_{0.75}$ heißen in dieser Reihenfolge *unteres Quartil*, *Median* und *oberes Quartil*,
- $y_{j \cdot 0.10}$ für $j = 1, \dots, 9$ heißen *Dezile* und
- $y_{j \cdot 0.01}$ für $j = 1, \dots, 99$ heißen *Perzentile*.

Um den Begriff des p-Quantils zu verdeutlichen, betrachten wir ein an Henze (2018), Kapitel 5 orientiertes Beispiel. Dazu seien zunächst der in untenstehender Tabelle dargestellte Datensatz und seine aufsteigend sortierte Version gegeben.

i	1	2	3	4	5	6	7	8	9	10
y_i	8.5	1.5	75	4.5	6.0	3.0	3.0	2.5	6.0	9.0
$y_{(i)}$	1.5	2.5	3.0	3.0	4.5	6.0	6.0	8.5	9.0	75

Wir wollen zunächst das untere Quartil, also das 0.25-Quantil, dieses Datensatzes bestimmen. Es ist offenbar $n = 10$ und wir haben $p := 0.25$ gewählt. Basierend auf Definition 10.5 finden wir, dass

$$np = 10 \cdot 0.25 = 2.5 \notin \mathbb{N}. \tag{10.20}$$

Also gilt nach Definition 10.5, dass

$$y_{0.25} = y_{(\lfloor 2.5+1 \rfloor)} = y_{(3)} = 3.0. \tag{10.21}$$

Das untere Quartil des betrachteten Datensatzes ist also der Wert 3.0. Die vier Datenwerte 1.5, 2.5, 3.0 und 3.0 sind kleiner oder gleich diesem Wert. Damit sind 40% der Datenwerte kleiner oder gleich dem unteren Quartil. Dieser Anteil übersteigt die geforderten 25%, was mit der Quantildefinition vereinbar ist.

Als Nächstes wollen wir das 0.80-Quantil des Datensatzes bestimmen. Es ist offenbar weiterhin $n = 10$ und wir haben nun $p := 0.80$ gewählt. Wir finden in diesem Fall, dass

$$np = 10 \cdot 0.80 = 8 \in \mathbb{N}. \tag{10.22}$$

Also folgt nach Definition 10.5

$$y_{0.80} = \frac{1}{2}\left(y_{(8)} + y_{(8+1)}\right) = \frac{1}{2}\left(y_{(8)} + y_{(9)}\right) = \frac{8.5 + 9.0}{2} = 8.75. \tag{10.23}$$

Das 0.80-Quantil des betrachteten Datensatzes ist mit 8.75 also der Wert zwischen den Werten 8.5 und 9 des Datensatzes. In **R** wertet man die so bestimmten Quantile wie folgt aus.

```
y   = c(8.5,1.5,75,4.5,6.0,3.0,3.0,2.5,6.0,9.0)     # Beispieldaten
n   = length(y)                                     # Anzahl Datenwerte
y_s = sort(y)                                       # sortierter Datensatz
p   = 0.25                                          # np ist nicht ganzzahlig
y_p = y_s[floor(n*p + 1)]                           # 0.25-Quantil
cat("0.25-Quantil: ", round(y_p,2))                 # Ausgabe
```

```
0.25-Quantil:  3
```

```
p   = 0.80                                          # np ist ganzzahlig
y_p = (1/2)*(y_s[n*p] + y_s[n*p + 1])               # 0.80-Quantil
cat("0.80-Quantil: ", round(y_p,2))                 # Ausgabe
```

```
0.80-Quantil:  8.75
```

Mit `quantile()` stellt **R** eine Funktion bereit, die die Quantilbestimmung eines Datensatzes automatisiert. Die in Definition 10.5 angegebene Quantildefinition entspricht in **R** der Einstellung `type = 2`. Mit `quantile(y, p, type = 2)` lassen sich daher die nach dieser Definition bestimmten Quantile berechnen. Die Einstellung `type` erlaubt auch die Auswahl anderer Quantildefinitionen. Einen Überblick geben Hyndman & Fan (1996) auf theoretischer Ebene und `?quantile` auf Implementationsebene. Wir bestimmen das 0.25-Quantil des Pre-Interventions-BDI-II-Beispieldatensatzes mit `type = 2`.

```
D   = read.csv("./_data/110-deskriptive-statistik.csv")     # Datensatz laden
y   = D$PRE                                                 # PRE-BDI-II-Daten
y_p = quantile(y, 0.25, type = 2)                           # 0.25-Quantil nach Typ 2
```

```
0.25-Quantil (Type = 2):  17
```

Ein *Boxplot* visualisiert eine Zusammenfassung eines Datensatzes durch fünf Kennzahlen. Im folgenden Beispiel reichen die Whisker aufgrund der Einstellung `range = 0` bis zum Minimum und Maximum. Die Grenzen der zentralen Box bilden die *untere Tukey-Hinge* und die *obere Tukey-Hinge*. Der Median wird als Strich innerhalb der Box dargestellt.

Zur Bestimmung der Tukey-Hinges wird der Datensatz zunächst aufsteigend sortiert. Bei gerader Anzahl der Datenwerte wird er in zwei gleich große Hälften geteilt. Bei ungerader Anzahl wird der mittlere Datenwert beiden Hälften zugeordnet. Die untere Tukey-Hinge ist der Median der unteren Hälfte, die obere Tukey-Hinge der Median der oberen Hälfte. Diese Konstruktion gehört zur *Fünfzahlenzusammenfassung* nach Tukey (1977), Abschnitt 2C, und wird in **R** durch `fivenum()` berechnet.

Die Tukey-Hinges stimmen nicht für jeden Datensatz mit den Quartilen der oben angegebenen Quantildefinition überein. Für den Datensatz

$$y := (1, 2, 3, 4, 5, 6, 7) \tag{10.24}$$

sind die beiden Hälften $(1, 2, 3, 4)$ und $(4, 5, 6, 7)$. Ihre Mediane und damit die Tukey-Hinges betragen

$$h_\mathrm{u} := \frac{2+3}{2} = 2.5 \text{ und } h_\mathrm{o} := \frac{5+6}{2} = 5.5. \tag{10.25}$$

Die Quartile nach Definition 10.5 betragen dagegen $y_{0.25} = 2$ und $y_{0.75} = 6$. Der folgende **R**-Code vergleicht die Tukey-Hinges und Quartile für dieses separate Beispiel.

```
y_beispiel = 1:7                                    # Separates Beispiel
fivenum(y_beispiel)                                 # Fünfzahlenzusammenfassung
```

```
[1] 1.0 2.5 4.0 5.5 7.0
```

```
quantile(y_beispiel, c(0.25, 0.75), type = 2)   # Quartile nach der Definition
```

```
25% 75%
  2   6
```

Der Interquartilsabstand $d_Q := y_{0.75} - y_{0.25}$ ist ein Maß für die Streuung der Daten. Er ist nicht allgemein mit der Differenz der Tukey-Hinges identisch. Im separaten Beispiel $y = (1, \ldots, 7)$ beträgt der Interquartilsabstand $6 - 2 = 4$, während die Differenz der Tukey-Hinges $5.5 - 2.5 = 3$ beträgt.

Folgender **R**-Code erstellt einen Boxplot des Pre-Interventions-BDI-II-Datensatzes.

```
D          = read.csv("./_data/110-deskriptive-statistik.csv")  # Datensatz laden
pdf(                                                            # PDF-Datei öffnen
  file       = "./_figures/110-boxplot.pdf",                    # Dateiname
  width      = 8,                                               # Breite in Zoll
  height     = 5)                                               # Höhe in Zoll
boxplot(                                                        # Boxplot
  D$PRE,                                                        # Datensatz
  horizontal = T,                                               # Horizontal darstellen
  range      = 0,                                               # Antennen: Min./Max.
  xlab       = "BDI",                                           # x-Achsentext
  main       = "Boxplot")                                       # Titel
dev.off()                                                       # Grafik schließen
```

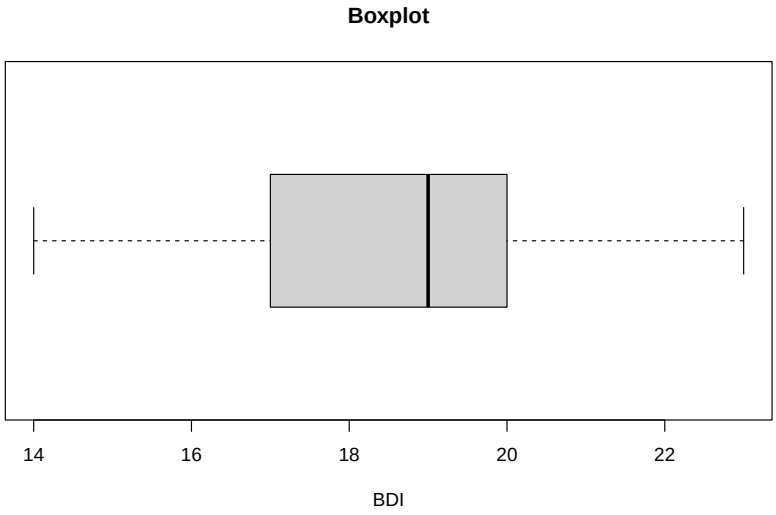


Abbildung 10.5. Boxplot der Pre-Interventions-BDI-Werte des Beispieldatensatzes.

Die fünf im Boxplot dargestellten Kennzahlen erhält man mit `fivenum()`. Für die BDI-PRE-Werte ergeben sich 14, 17, 19, 20 und 23.

```
fivenum(D$PRE)                    # Min., untere Hinge, Median, obere Hinge, Max.
```

```
[1] 14 17 19 20 23
```

In Abbildung 10.5 werden $\min y$ und $\max y$ als Whiskerendpunkte dargestellt. Die untere und die obere Tukey-Hinge bilden die Grenzen der zentralen grauen Box. Der Median $y_{0.50}$ wird als Strich innerhalb der Box abgebildet. Es gibt viele Boxplotvariationen, vgl. McGill et al. (1978). Eine genaue Erläuterung der grafisch dargestellten Datensatzeigenschaften ist daher immer nötig. Schließlich sei angemerkt, dass die Darstellung von Datensätzen mithilfe von Boxplots in den letzten zwanzig Jahren etwas aus der Mode gekommen ist und man sie nur noch sehr selten in aktuellen wissenschaftlichen Publikationen findet.

10.5. Maße der zentralen Tendenz

In diesem Abschnitt betrachten wir einige grundlegende Kennzahlen von Datensätzen, die für die deskriptive Statistik zentral sind und Aussagen zu dem "durchschnittlichen" Wert eines Datensatzes machen. Wir beginnen mit der Definition des Mittelwerts.

10.5.1. Mittelwert

Definition 10.6 (Mittelwert)**.** $y = (y_1, ..., y_n)$ sei ein Datensatz. Dann heißt

$$\bar{y} := \frac{1}{n} \sum_{i=1}^{n} y_i \tag{10.26}$$

der *Mittelwert* von y.

•

Der Mittelwert eines Datensatzes ist also die Summe der Datenwerte geteilt durch die Anzahl der Datenwerte. Der hier definierte Mittelwert wird auch als *arithmetisches Mittel* oder *Durchschnitt* bezeichnet. Im Kontext der Frequentistischen Inferenz werden wir den Mittelwert vor dem Hintergrund des Modells der Zufallsstichprobe als *Stichprobenmittel* bezeichnen. Insbesondere erlauben die Modelle der Frequentistischen Inferenz auch, die funktionale Form des Mittelwertes tiefer zu begründen, wie wir an gegebener Stelle sehen werden. Mithilfe der Summenfunktion berechnet man den Mittelwert eines Datensatzes in **R** wie folgt.

```
D     = read.csv("./_data/110-deskriptive-statistik.csv")   # Datensatz laden
y     = D$PRE                                               # PRE-BDI-II-Daten
n     = length(y)                                           # Anzahl der Werte
y_bar = (1/n)*sum(y)                                        # Mittelwertsberechnung
```

```
Mittelwert der PRE-BDI-II-Daten  18.61
```

Mit der `mean()`-Funktion stellt **R** natürlich auch eine Funktion zur automatisierten Berechnung des Mittelwerts bereit.

```
cat("Mittelwert der PRE-BDI-II-Daten ", mean(y))    # Ausgabe
```

```
Mittelwert der PRE-BDI-II-Daten  18.61
```

In folgendem Theorem halten wir zunächst zwei Eigenschaften des Mittelwerts eines Datensatzes fest, die seine Einordnung als Maß der zentralen Tendenz eines Datensatzes plausibel machen.

Theorem 10.1 (Zentralitätseigenschaften des Mittelwerts)**.** *$y = (y_1, ..., y_n)$ sei ein Datensatz und $\bar{y}$ sei der Mittelwert von y. Dann gelten*

(1) Die Summe der Abweichungen vom Mittelwert ist null,

$$\sum_{i=1}^{n}(y_i - \bar{y}) = 0. \tag{10.27}$$

(2) Die absoluten Summen negativer und nichtnegativer Abweichungen vom Mittelwert sind gleich. Die Indexmengen

$$J := \{i \in \{1, \dots, n\} | y_i - \bar{y} < 0\} \tag{10.28}$$

und

$$K := \{i \in \{1, \dots, n\} | y_i - \bar{y} \geq 0\} \tag{10.29}$$

erfassen die negativen beziehungsweise nichtnegativen Abweichungen. Dann gilt

$$\left|\sum_{i \in J}(y_i - \bar{y})\right| = \left|\sum_{i \in K}(y_i - \bar{y})\right|. \tag{10.30}$$

◦

Beweis. (1) Es gilt

$$\begin{aligned}\sum_{i=1}^{n}(y_i - \bar{y}) &= \sum_{i=1}^{n} y_i - \sum_{i=1}^{n} \bar{y} \\ &= \sum_{i=1}^{n} y_i - n\bar{y} \\ &= \sum_{i=1}^{n} y_i - \frac{n}{n}\sum_{i=1}^{n} y_i \\ &= \sum_{i=1}^{n} y_i - \sum_{i=1}^{n} y_i \\ &= 0.\end{aligned} \tag{10.31}$$

(2) Weil J und K die Datenpunktindizes vollständig und ohne Überschneidung aufteilen, gilt mit Aussage (1)

$$0 = \sum_{i=1}^{n}(y_i - \bar{y}) = \sum_{i \in J}(y_i - \bar{y}) + \sum_{i \in K}(y_i - \bar{y}). \tag{10.32}$$

Also gilt

$$\sum_{i \in K}(y_i - \bar{y}) = -\sum_{i \in J}(y_i - \bar{y}) \tag{10.33}$$

und damit

$$\left|\sum_{i \in J}(y_i - \bar{y})\right| = \left|\sum_{i \in K}(y_i - \bar{y})\right|. \tag{10.34}$$

□

Nach Theorem 10.1 liegt der Mittelwert eines Datensatzes also gerade so, dass sich in Summe die Abweichungen der Datenpunkte von diesem Wert zu null ausgleichen und dass sich positive und negative Abweichungen vom Mittelwert die Waage halten. In **R** kann man Theorem 10.1 am Beispieldatensatz wie folgt verifizieren.

```
# Datensatz
D   = read.csv("./_data/110-deskriptive-statistik.csv")     # Datensatz laden
y   = D$PRE                                                 # PRE-BDI-II-Daten
s   = sum(y - mean(y))                                      # Summe der Abweichungen
s_1 = sum(y[y < mean(y)] - mean(y))                         # Negative Abweichungen
s_2 = sum(y[y >= mean(y)]  - mean(y))                       # Nichtneg. Abweichungen
```

```
Summe der Abweichungen vom Mittelwert           :  0
Summen der negativen und nichtnegativen Abweichungen :  -71.28 71.28
```

Theorem 10.2 (Summationseigenschaften des Mittelwerts)**.** *Gegeben seien zwei Datensätze $y = (y_1, ..., y_n)$ und $z = (z_1, ..., z_n)$ gleichen Umfangs und es sei durch*

$$y + z := (y_1 + z_1, ..., y_n + z_n) \tag{10.35}$$

die Summe dieser Datensätze definiert. Weiterhin seien $\bar{y}$ und $\bar{z}$ die Mittelwerte der Datensätze y und z in dieser Reihenfolge. Dann gilt

$$\overline{y + z} = \bar{y} + \bar{z} \tag{10.36}$$

∘

Beweis. Es gilt

$$\begin{aligned}\overline{y+z} &:= \frac{1}{n}\sum_{i=1}^{n}(y_i + z_i) \\ &= \frac{1}{n}\sum_{i=1}^{n} y_i + \frac{1}{n}\sum_{i=1}^{n} z_i \\ &=: \bar{y} + \bar{z}.\end{aligned} \tag{10.37}$$

□

Betrachtet man die Summe zweier Datensätze, so ist es für die Bestimmung ihres Mittelwerts also unerheblich, ob man zunächst die Datensätze aufaddiert und dann den Mittelwert des summierten Datensatzes bestimmt oder ob man für jeden der beiden Datensätze den Mittelwert bestimmt und diese aufaddiert. Wir verifizieren dieses Ergebnis exemplarisch mithilfe der Pre- und Post-Interventions-BDI-II-Daten des Beispieldatensatzes in **R** wie folgt.

```
D         = read.csv("./_data/110-deskriptive-statistik.csv")    # Datensatz laden
y         = D$PRE                                                # PRE-BDI-II-Daten
y_bar     = mean(y)                                              # Mittelwert PRE
z         = D$POS                                                # POS-BDI-II-Daten
z_bar     = mean(z)                                              # Mittelwert POS
yz_bar_1 = mean(y + z)                                           # Mittelwert von PRE+POS
yz_bar_2 = y_bar + z_bar                                         # Summe der Mittelwerte
```

```
Mittelwert von y + z              :  31.68
Summe der Mittelwerte von y und z :  31.68
```

Theorem 10.3 (Mittelwert bei linear-affiner Transformation)**.** *$y = (y_1, ..., y_n)$ sei ein Datensatz und $\bar{y}$ sei der Mittelwert von y. Weiterhin sei für $a, b \in \mathbb{R}$ mit*

$$ay + b := (ay_1 + b, ..., ay_n + b) \tag{10.38}$$

ein linear-affin transformierter Datensatz von y definiert. Dann gilt, dass

$$\overline{ay + b} = a\bar{y} + b \tag{10.39}$$

∘

Beweis. Es gilt

$$\begin{aligned}\overline{ay+b} &:= \frac{1}{n}\sum_{i=1}^{n}(ay_i + b) \\ &= \sum_{i=1}^{n}\left(\frac{1}{n}ay_i + \frac{1}{n}b\right) \\ &= \left(\sum_{i=1}^{n}\frac{1}{n}ay_i\right) + \left(\sum_{i=1}^{n}\frac{1}{n}b\right) \\ &= a\left(\frac{1}{n}\sum_{i=1}^{n} y_i\right) + \frac{1}{n}\sum_{i=1}^{n} b \\ &= a\bar{y} + \frac{1}{n}nb \\ &= a\bar{y} + b.\end{aligned} \tag{10.40}$$

□

Eine linear-affine Transformation eines Datensatzes transformiert den Mittelwert des Datensatzes also linear-affin. Dies kann man sich zunutze machen, wenn man sich überlegt, wie der Mittelwert lauten sollte, wenn man einen Datensatz neu skaliert, also z. B. von Gramm in Kilogramm umrechnet. Natürlich kann man zur Sicherheit aber auch einfach den Mittelwert des neu skalierten Datensatzes bestimmen. Wir demonstrieren diese Eigenschaft exemplarisch durch Reskalierung des Pre-Interventions-BDI-II-Datensatzes mit dem Wert $a = 2$ unter gleichzeitiger Addition der Konstante $b := 5$.

```
D         = read.csv("./_data/110-deskriptive-statistik.csv")    # Datensatz laden
y         = D$PRE                                                # PRE-BDI-II-Daten
y_bar     = mean(y)                                              # Mittelwert PRE
a         = 2                                                    # Skalierungsfaktor
b         = 5                                                    # Addierter Wert
z         = a*y + b                                              # PRE-Werte: a*y + b
z_bar     = mean(z)                                              # Mittelwert nach a*y+b
ay_bar_b = a*y_bar + b                                           # a*Mittelwert + b
```

```
Mittelwert des transformierten Datensatzes :  42.22
Transformation des Mittelwertes            : 42.22
```

10.5.2. Median

In den oben definierten Mittelwert geht jeder Wert eines Datensatzes summativ mit gleichem Gewicht $1/n$ ein. Dies betrifft insbesondere auch solche Werte, die im Vergleich zu den übrigen Werten des Datensatzes sehr untypisch sind. Eine Möglichkeit, die "Mitte" eines Datensatzes unabhängig von solchen untypischen Werten zu bestimmen, besteht in der Bestimmung seines Medians, den wir nachfolgend definieren. Wir haben den Median bereits in Abschnitt Kapitel 10.4 als das 0.5-Quantil kennengelernt, mit dem er identisch ist.

Definition 10.7 (Median)**.** $y = (y_1, ..., y_n)$ sei ein Datensatz und $y_s = (y_{(1)}, ..., y_{(n)})$ der zugehörige aufsteigend sortierte Datensatz. Dann ist der Median von y definiert als

$$\tilde{y} := \begin{cases} y_{((n+1)/2)} & \text{falls } n \text{ ungerade,} \\ \frac{1}{2}\left(y_{(n/2)} + y_{(n/2+1)}\right) & \text{falls } n \text{ gerade.} \end{cases} \tag{10.41}$$

•

Definition 10.7 impliziert, dass mindestens 50% aller Datenwerte y_i des Datensatzes kleiner oder gleich $\tilde{y}$ sind und dass gleichzeitig mindestens 50% aller Datenwerte y_i des Datensatzes größer oder gleich $\tilde{y}$ sind. Anstelle eines formalen Beweises dieser Aussagen verweisen wir auf Abbildung 10.6. Wie in der Definition des Medians unterscheiden wir dort die Fälle, dass die Anzahl der Datenpunkte ungerade ist (hier $n = 5$, Abbildung 10.6 A) oder gerade ist ($n = 6$, Abbildung 10.6 B). Im Fall der ungeraden Anzahl an Datenpunkten ist der Median der Datenwert mit der Indexzahl, die in der Mitte der Indexzahlen des sortierten Datensatzes liegt, im Beispiel Abbildung 10.6 A also der Wert $y_{(3)}$. Damit sind im vorliegenden Fall 3/5, also 60% der Datenwerte (speziell $y_{(1)}$, $y_{(2)}$ und $y_{(3)}$) kleiner oder gleich dem Median, gleichzeitig aber auch 3/5, also 60% der Datenwerte (speziell $y_{(3)}$, $y_{(4)}$ und $y_{(5)}$) größer oder gleich dem Median. Im Fall einer geraden Anzahl von Datenpunkten ist die Lage des Medians etwas intuitiver: Der Median liegt in der Mitte

der beiden mittleren Werte des sortierten Datensatzes (in Abbildung 10.6 B speziell in der Mitte der Werte $y_{(3)}$ und $y_{(4)}$). Damit sind dann 3/6, also 50% der Datenwerte (speziell $y_{(1)}$, $y_{(2)}$ und $y_{(3)}$) kleiner als der Median und 3/6, also 50% der Datenwerte (speziell $y_{(4)}$, $y_{(5)}$ und $y_{(6)}$) größer als der Median.

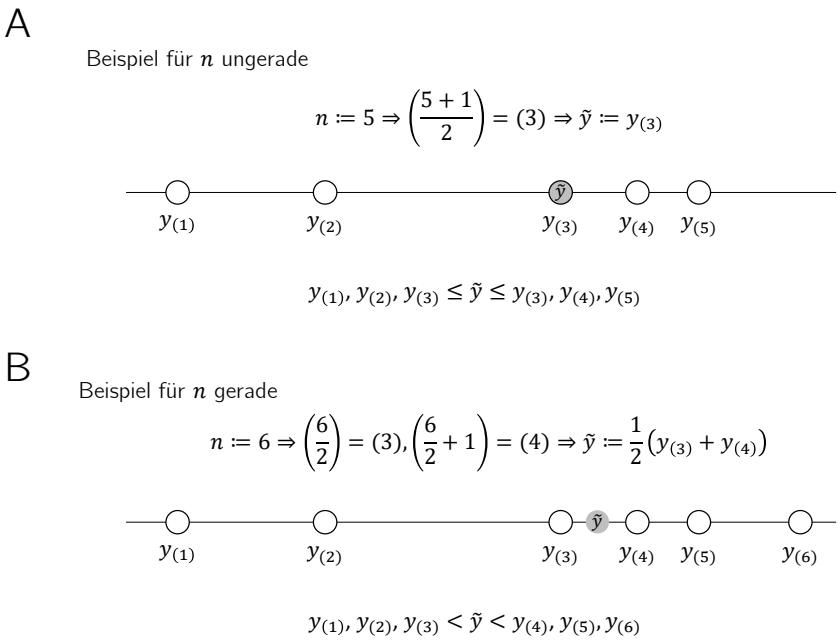


Abbildung 10.6. Bestimmung und Eigenschaften des Medians.

Folgender **R**-Code bestimmt den Median des Beispieldatensatzes anhand von Definition 10.7.

```
D       = read.csv("./_data/110-deskriptive-statistik.csv")  # Datensatz laden
y       = D$PRE                                              # PRE-BDI-II-Daten
n       = length(y)                                          # Anzahl der Werte
y_s     = sort(y)                                            # Aufsteigend sortieren
if(n %% 2 == 1){                                             # n ungerade, n mod 2 == 1
   y_tilde = y_s[(n+1)/2]                                    # Median für ungerades n
} else {                                                     # n gerade, n mod 2 == 0
   y_tilde = (y_s[n/2] + y_s[n/2 + 1])/2}                    # Median für gerades n
```

```
Median der PRE-BDI-II-Daten:  19
```

Natürlich stellt **R** mit `median()` auch eine Funktion zur direkten Bestimmung des Medians bereit, wie folgender **R**-Code demonstriert.

```
cat("Median der PRE-BDI-II-Daten: ", median(y))     # Ausgabe
```

```
Median der PRE-BDI-II-Daten:  19
```

Folgende Simulation zeigt beispielhaft, dass der Median als Maß der Mitte eines Datensatzes weniger anfällig für Ausreißer ist als der Mittelwert.

```
D = read.csv("./_data/110-deskriptive-statistik.csv")   # Datensatz laden
y = D$PRE                                               # PRE-BDI-II-Daten
```

```
Mittelwert und Median f<U+00FC>r Datensatz ohne Ausrei<U+00DF>er:  18.61 19
```

```
z    = y                                    # neuer simulierter Datensatz
z[1] = 10000                                # ... mit einem Extremwert
```

```
Mittelwert und Median f<U+00FC>r Datensatz mit Ausrei<U+00DF>er:  118.44 19
```

Obwohl der Median also als robusteres Maß für die zentrale Tendenz eines Datensatzes als der Mittelwert erscheint, ist die Bestimmung von Mittelwerten sicherlich das üblichere Vorgehen. Dies ist einerseits dadurch begründet, dass sich der Mittelwert aufgrund seiner mathematisch weniger komplexen Definition einfacher im analytischen Kontext zur Gestaltung von probabilistischen Modellen eignet. Andererseits ist das Auftreten von Extremwerten üblicherweise ein Anzeichen von Datenerhebungsfehlern (z. B. sollte ein BDI-II-Wert von 10.000 schlicht nicht vorkommen) oder großen Unterschieden zwischen den betrachteten experimentellen Einheiten, die durch visuelle Inspektion des Datensatzes meist vor der Bestimmung von Maßen der zentralen Tendenz auffallen. Es gibt allerdings ein ganzes Unterfeld der Statistik, das sich mit – im weitesten Sinne – ausreißerunabhängigen Maßen beschäftigt, vgl. z. B. Huber (1981).

10.5.3. Modalwert

Wenn in einem Datensatz manche Werte wiederholt auftreten, ist mit dem *Modalwert* als dem in einem Datensatz am häufigsten vorkommenden Wert ein drittes Maß der zentralen Tendenz gegeben. Wir nutzen folgende Definition.

Definition 10.8 (Modalwert)**.** $y := (y_1, \ldots, y_n)$ sei ein Datensatz, W die Menge seiner verschiedenen Zahlenwerte und h seine absolute Häufigkeitsverteilung. Dann heißt jeder Wert $w \in W$, für den

$$h(w) = \max_{v \in W} h(v), \tag{10.42}$$

gilt, ein *Modalwert* von y. Die Menge aller Modalwerte ist

$$M := \{w \in W | h(w) = \max_{v \in W} h(v)\}. \tag{10.43}$$

Enthält M genau einen Wert, ist der Modalwert eindeutig.

•

In **R** kann man alle Modalwerte eines Datensatzes wie folgt bestimmen.

```
D        = read.csv("./_data/110-deskriptive-statistik.csv")    # Datensatz laden
y        = D$PRE                                                # PRE-BDI-II-Daten
n        = length(y)                                            # Anzahl der Werte (100)
H        = as.data.frame(table(y))                              # Absolute Häufigkeiten
names(H) = c("a", "w")                                          # konsistente Benennung
mod      = as.numeric(as.character(H$a[H$w == max(H$w)]))       # alle Modalwerte
```

```
cat("Modalwerte der PRE-BDI-II-Daten: ", mod)   # Ausgabe der Modalwerte
```

```
Modalwerte der PRE-BDI-II-Daten:  18
```

10.5.4. Datenverteilungsformen und Maße zentraler Tendenz

Wie sinnhaft es ist, mit dem Mittelwert, dem Median oder dem Modalwert eine Angabe über die zentrale Tendenz eines Datensatzes zu geben, hängt stark von der Beschaffenheit des Datensatzes ab. Hat man beispielsweise einen Datensatz hochaufgelöster Daten vorliegen, in dem kein Datenwert mehrfach auftaucht, eignet sich der Modalwert sicherlich nicht, um eine quantitative Aussage über die zentrale Tendenz des Datensatzes zu machen. Man sollte die Angabe eines Maßes der zentralen Tendenz also immer im Kontext der Gesamtbeschaffenheit des Datensatzes sowie, wenn zutreffend, des inferenzstatistischen Modells, das man zur Interrogation des Datensatzes nutzt, betrachten. In Abbildung 10.7 geben wir vier Beispiele, wie sich die oben betrachteten Maße der zentralen Tendenz in verschiedenen Szenarien der Datenwertverteilung verhalten können. Diese vier Szenarien sind natürlich nicht erschöpfend und jeder Datensatz ist in Hinblick auf ein sinnvolles Maß der zentralen Tendenz kritisch zu betrachten.

Abbildung 10.7 A visualisiert die Lage von Mittelwert, Median und Modalwerten in einem Datensatz, der sich symmetrisch um einen Wert von etwa $y = 50$ verteilt und für den Werte nah bei diesem zentralen Wert häufig vorkommen und Werte fern von diesem zentralen Wert eher selten. Wie wir später sehen, entspricht dies den typischen Charakteristika normalverteilter Datenwerte. Die Werte 53 und 55 kommen mit jeweils 45 Beobachtungen gleich häufig und am häufigsten vor; beide sind daher Modalwerte dieses Datensatzes. In diesem Fall liegen Mittelwert, Median und die beiden Modalwerte recht nahe beieinander und beschreiben die zentrale Tendenz des Datensatzes.

Abbildung 10.7 B visualisiert die Lage von Mittelwert, Median und Modalwerten in einem Datensatz, in dem die Datenwerte um zwei Werte von etwa $y = 25$ und $y = 75$ gehäuft auftreten und jeweils in positive und negative Richtung von diesen Werten entfernt eher selten auftreten. So liegen zum Beispiel um $y = 50$ recht wenige Datenpunkte dieses Datensatzes. Mittelwert und Median nehmen nun aber gerade Werte um $y = 50$ an. Als solche geben sie bei diesem Datensatz also keine Auskunft darüber, welche Werte besonders häufig vorkommen, sondern lediglich darüber, wo sich der mittlere "physikalische Schwerpunkt" des Datensatzes befindet. Die beiden Modalwerte 72 und 74 kommen mit jeweils 27 Beobachtungen am häufigsten vor und liegen beide beim größeren der beiden Datenhäufungspunkte. Insgesamt betrachtet beschreibt keines der drei Maße bei einem solchen Datensatz, den man auch *bimodal* nennt, die zentrale Tendenz der Datenwerte wirklich zufriedenstellend.

Abbildung 10.7 C visualisiert die Lage von Mittelwert, Median und Modalwert in einem Datensatz, in dem die Datenwerte in der betrachteten Breite etwa durchgängig gleich häufig auftreten. Hier liegt der Modalwert relativ arbiträr bei etwa $y = 28$, da sich dort eine minimale Häufung von Datenwerten zeigt. Mittelwert und Median liegen wiederum im Sinne des "physikalischen Schwerpunkts" des Datensatzes bei etwa $y = 50$, auch wenn die Werte dieses Datensatzes dort keinerlei Tendenz haben, häufiger als andernorts aufzutreten. Wirklich zufriedenstellend ist auch hier die Beschreibung der zentralen Tendenz des Datensatzes durch die betrachteten Maße nicht. Zusammen betrachtet kann man anhand

von Abbildung 10.7 B und Abbildung 10.7 C vielleicht festhalten, dass, wenn ein Datensatz keine klare zentrale Tendenz hat, die Maße der zentralen Tendenz diese auch nicht abbilden können.

Abbildung 10.7 D zeigt die Lage von Mittelwert, Median und Modalwert für einen Datensatz mit *rechtsschiefer Verteilung*. Die Daten werden aus einer Gammaverteilung mit Formparameter 2 und Rate 2 simuliert. Die zugehörige Dichte hat ihren Modalwert bei 0.5. Höhere Werte treten mit abnehmender Dichte auf, wobei die Verteilung nach rechts einen langen Ausläufer besitzt. Im psychologischen Kontext haben insbesondere Reaktionszeiten oft eine ähnliche Verteilung, da sie nicht negativ sein können, in den meisten Fällen etwa im Bereich von 0.3 bis 0.6 Sekunden liegen, aber in manchen Fällen durch Unaufmerksamkeit oder Stimulusvariabilität auch sehr viel länger sein können. In diesem Fall beschreibt der Median die tatsächliche zentrale Tendenz der Datenwerte etwas besser als der Mittelwert, da dieser durch die selten vorkommenden Ausreißerwerte etwas zu höheren Werten verschoben ist.

Insgesamt ist die Angabe eines oder mehrerer Maße der zentralen Tendenz also immer kritisch vor dem Hintergrund der Verteilung der Werte eines Datensatzes zu betrachten und qualitativ einzuordnen.

10.6. Maße der Variabilität

Neben der Frage, welchen "durchschnittlichen Wert" ein Datensatz annimmt, ist es oft von Interesse zu quantifizieren, wie sehr die Werte im Datensatz streuen oder anders ausgedrückt, wie "variabel" sie sind. Als quantitative Maße für die Variabilität eines Datensatzes betrachten wir hier die *Spannbreite*, die *empirische Varianz* und die *empirische Standardabweichung*. Wie auch für den Mittelwert erschließt sich die volle Bedeutung letzterer Maße vor allem im Kontext inferenzstatistischer Verfahren.

10.6.1. Spannbreite

Die Spannbreite eines Datensatzes ist die Differenz zwischen seinem größten und seinem kleinsten Wert.

Definition 10.9 (Spannbreite)**.** $y = (y_1, ..., y_n)$ sei ein Datensatz. Dann ist die *Spannbreite* von $y_1, ..., y_n$ definiert als

$$r := \max(y_1, ..., y_n) - \min(y_1, ..., y_n). \tag{10.44}$$

•

In **R** bestimmt man die Spannbreite entweder durch Evaluation des Maximums und des Minimums des Datensatzes mithilfe der `max()`- und `min()`-Funktionen oder direkt mithilfe der `range()`-Funktion. Folgender **R**-Code demonstriert die Anwendung der `max()`- und `min()`-Funktionen.

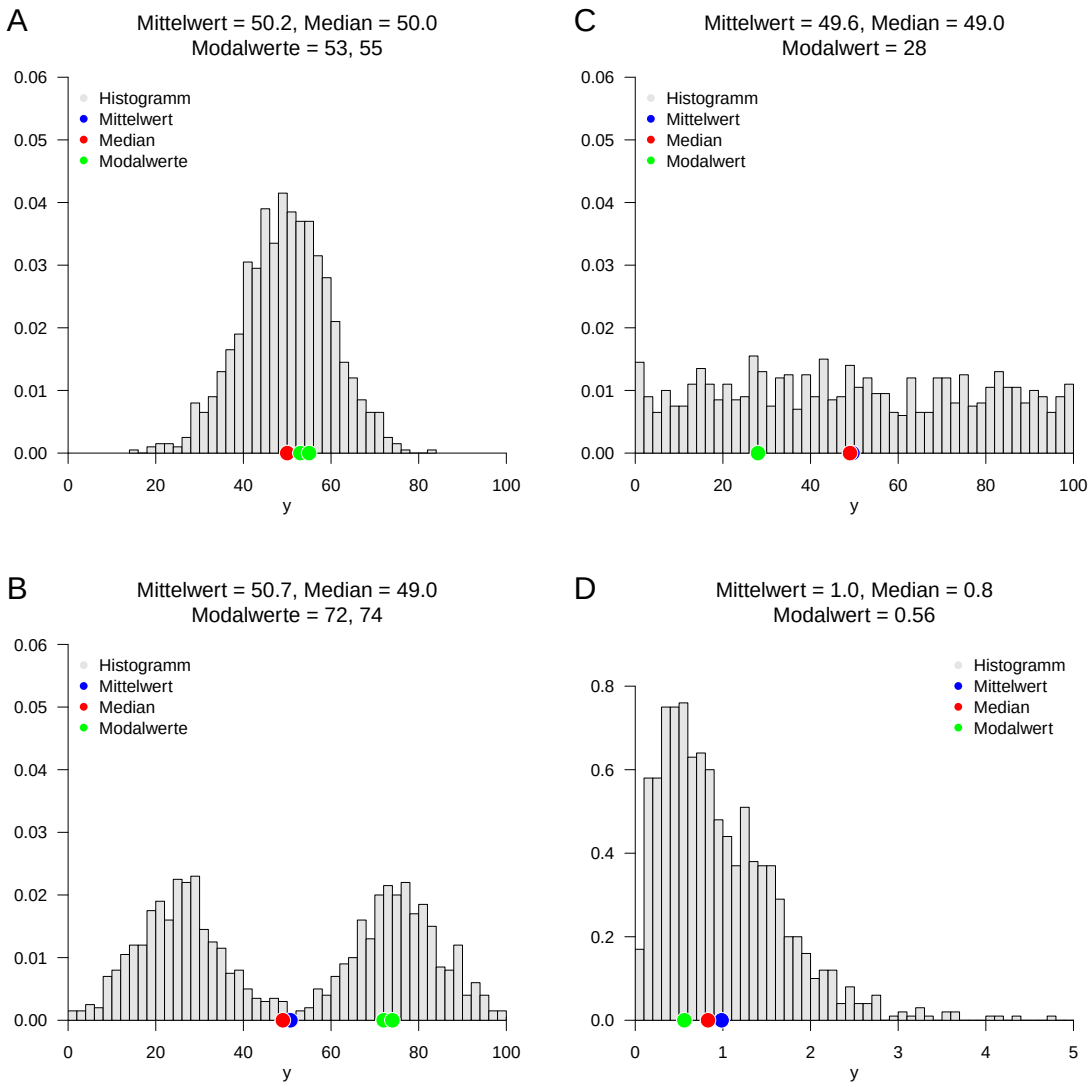


Abbildung 10.7. Visuelle Intuition zu Maßen zentraler Tendenz bei verschiedenen Datenverteilungsformen

```
D     = read.csv("./_data/110-deskriptive-statistik.csv")   # Datensatz laden
y     = D$PRE                                               # PRE-BDI-II-Daten
y_max = max(y)                                              # Maximum der PRE-Werte
y_min = min(y)                                              # Minimum der PRE-Werte
r     = y_max - y_min                                       # Spannbreite
```

```
Spannbreite der PRE-BDI-II-Daten:  9
```

Folgender **R**-Code demonstriert die Anwendung der `range()`-Funktion.

```
MinMax = range(y)                           # Minimum und Maximum
r      = MinMax[2] - MinMax[1]              # Spannbreite
```

```
Spannbreite der PRE-BDI-II-Daten:  9
```

10.6.2. Empirische Varianz

Ein typisches statistisches Maß für die Variabilität von Datensätzen ist die standardisierte Summe der quadrierten Differenzen zwischen den einzelnen Datensatzwerten und ihrem Mittelwert. Die quadrierten Differenzen zwischen den einzelnen Datensatzwerten und ihrem Mittelwert werden auch als *Abweichungsquadrate* bezeichnet. Je nach Form der Standardisierung, also der Bildung eines Durchschnitts der Abweichungsquadrate, unterscheidet man eine *unkorrigierte empirische Varianz* und eine *empirische Varianz*, wie folgende Definition festsetzt.

Definition 10.10 (Unkorrigierte empirische Varianz und empirische Varianz)**.** $y := (y_1, \ldots, y_n)$ sei ein Datensatz mit $n \geq 1$ und $\bar{y}$ sei sein Mittelwert. Dann ist die *unkorrigierte empirische Varianz* von y definiert als

$$\tilde{s}^2 := \frac{1}{n} \sum_{i=1}^{n} (y_i - \bar{y})^2 \tag{10.45}$$

Für $n > 1$ ist die *empirische Varianz* von y definiert als

$$s^2 := \frac{1}{n-1} \sum_{i=1}^{n} (y_i - \bar{y})^2. \tag{10.46}$$

•

Wir haben in Theorem 10.1 gesehen, dass die Summe der Differenzen zwischen den Datenwerten und ihrem Mittelwert immer gleich null ist. Die Quadrierung der Differenzen

$$y_i - \bar{y} \text{ für } i = 1, ..., n \tag{10.47}$$

in Definition 10.10 führt nun gerade dazu, dass sich negative und positive Differenzen von Datenpunkten nicht ausgleichen und, je nach Höhe der positiven und negativen Differenzen, mit

$$\sum_{i=1}^{n} (y_i - \bar{y})^2 \tag{10.48}$$

ein höheres oder geringeres Maß für die Gesamtabweichung der Datenwerte von ihrem Mittelwert bestimmt werden kann. Dabei ist die Summe der Abweichungsquadrate gerade dann null, wenn alle Datenwerte identisch und damit auch identisch mit ihrem Mittelwert sind. Alternativ wäre zum Beispiel auch die Bestimmung der Absolutbeträge $|y_i - \bar{y}|$ denkbar, allerdings erfüllt das so entstehende Maß der Variabilität andere Eigenschaften als das Maß der quadrierten Abweichungen in Definition 10.10, weshalb dieses, auch in Hinblick auf seine Nähe zu probabilistischen Normalverteilungsmodellen, in der Regel bevorzugt wird. Die unkorrigierte empirische Varianz $\tilde{s}^2$ und die (korrigierte) empirische Varianz s^2 unterscheiden sich dann hinsichtlich der Form der Durchschnittsbildung der Abweichungsquadrate. Für $\tilde{s}^2$ wird die Summe der Abweichungsquadrate durch n, für s^2 durch $n-1$ geteilt. Die unkorrigierte empirische Varianz $\tilde{s}^2$ ist höchstens so groß wie die empirische Varianz s^2. Für $n > 1$ gilt

$$\tilde{s}^2 = \frac{n-1}{n} s^2 \leq s^2. \tag{10.49}$$

Bei positiver Varianz ist $\tilde{s}^2 < s^2$. Sind alle Datenwerte identisch, sind beide Varianzen null. Allerdings wird dieser Unterschied für großes n eher gering ausfallen, man denke beispielsweise an den numerischen Unterschied zwischen $\frac{1}{3}$ und $\frac{1}{2}$ bei kleinem n sowie zwischen $\frac{1}{1001}$ und $\frac{1}{1000}$ bei großem n. Man beachte, dass die empirische Varianz für $n = 1$ nicht definiert ist, die unkorrigierte empirische Varianz jedoch auch in diesem Spezialfall prinzipiell bestimmt werden kann. Der Begriff *unkorrigiert* (und implizit *korrigiert*) kann sich an dieser Stelle noch nicht erschließen, sondern ergibt nur vor dem Hintergrund eines frequentistischen Inferenzmodells Sinn und wird in Kapitel 37 erläutert werden.

Wir fassen die obige Diskussion im folgenden Theorem zusammen.

Theorem 10.4 (Verhältnis von unkorrigierter empirischer Varianz und empirischer Varianz)**.** *$y = (y_1, ..., y_n)$ sei ein Datensatz mit $n > 1$ und $\tilde{s}^2$ und s^2 seien in dieser Reihenfolge seine unkorrigierte empirische Varianz und seine empirische Varianz. Dann gelten*

(1) (Umrechnung)

$$\tilde{s}^2 = \frac{n-1}{n} s^2 \text{ und } s^2 = \frac{n}{n-1} \tilde{s}^2. \tag{10.50}$$

(2) (Ungleichung)

$$0 \leq \tilde{s}^2 \leq s^2. \tag{10.51}$$

∘

Beweis. (1) Nach Definition 10.10 gilt zum einen

$$\begin{aligned} \tilde{s}^2 &= \frac{1}{n} \sum_{i=1}^{n} (y_i - \bar{y})^2 \\ \Leftrightarrow \frac{n-1}{n-1} \tilde{s}^2 &= \frac{n-1}{n-1} \frac{1}{n} \sum_{i=1}^{n} (y_i - \bar{y})^2 \\ \Leftrightarrow \tilde{s}^2 &= \frac{n-1}{n} \frac{1}{n-1} \sum_{i=1}^{n} (y_i - \bar{y})^2 \\ \Leftrightarrow \tilde{s}^2 &= \frac{n-1}{n} s^2 \end{aligned} \tag{10.52}$$

und zum anderen

$$\begin{aligned} s^2 &= \frac{1}{n-1}\sum_{i=1}^{n}(y_i-\bar{y})^2 \\ \Leftrightarrow \frac{n}{n}s^2 &= \frac{n}{n}\frac{1}{n-1}\sum_{i=1}^{n}(y_i-\bar{y})^2 \\ \Leftrightarrow s^2 &= \frac{n}{n-1}\frac{1}{n}\sum_{i=1}^{n}(y_i-\bar{y})^2 \\ \Leftrightarrow s^2 &= \frac{n}{n-1}\tilde{s}^2. \end{aligned} \tag{10.53}$$

(2) Mit der Nichtnegativität der Quadratfunktion sowie $\frac{1}{n} > 0$ und $\frac{1}{n-1} > 0$ für $n > 1$ ergeben sich $\tilde{s}^2 \geq 0$ und $s^2 \geq 0$ direkt. Schließlich gilt für $\sum_{i=1}^{n}(y_i-\bar{y})^2 \neq 0$

$$\frac{1}{n} < \frac{1}{n-1} \Leftrightarrow \frac{1}{n}\sum_{i=1}^{n}(y_i-\bar{y})^2 < \frac{1}{n-1}\sum_{i=1}^{n}(y_i-\bar{y})^2 \Leftrightarrow \tilde{s}^2 < s^2. \tag{10.54}$$

und für $\sum_{i=1}^{n}(y_i-\bar{y})^2 = 0$ offenbar $\tilde{s}^2 = s^2$. Insgesamt gilt also

$$0 \leq \tilde{s}^2 \leq s^2. \tag{10.55}$$

□

Folgender **R**-Code demonstriert die Bestimmung der unkorrigierten empirischen Varianz und der empirischen Varianz anhand der in Definition 10.10 festgelegten Formeln.

```
D        = read.csv("./_data/110-deskriptive-statistik.csv")    # Datensatz laden
y        = D$PRE                                                # PRE-BDI-II-Daten
n        = length(y)                                            # Anzahl der Werte
s2_tilde = (1/n)*sum((y - mean(y))^2)                           # Unkorrigierte Varianz
s2       = (1/(n-1))*sum((y - mean(y))^2)                       # empirische Varianz
```

```
Unkorrigierte empirische Varianz der PRE-BDI-II-Daten :  2.998
Empirische Varianz der PRE-BDI-II-Daten               :  3.028
```

Die **R**-Funktion `var()` bestimmt per Default die empirische Varianz. Mithilfe von Aussage (1) in Theorem 10.4 kann basierend auf dieser Funktion auch die unkorrigierte empirische Varianz bestimmt werden.

```
s2       = var(y)                          # empirische Varianz
s2_tilde = ((n-1)/n)*var(y)                # Unkorrigierte Varianz
```

```
Unkorrigierte empirische Varianz der PRE-BDI-II-Daten:  2.998
Empirische Varianz der PRE-BDI-II-Daten              :  3.028
```

Folgendes Theorem besagt, wie sich die empirische Varianz bei linear-affiner Transformation eines Datensatzes verhält.

Theorem 10.5 (Varianz bei linear-affinen Transformationen)**.** *$y := (y_1, \dots, y_n)$ sei ein Datensatz mit $n > 1$ und empirischer Varianz s_y^2 und $z = (ay_1 + b, ..., ay_n + b)$ sei der mit $a, b \in \mathbb{R}$ linear-affin transformierte Datensatz mit empirischer Varianz s_z^2. Dann gilt*

$$s_z^2 = a^2 s_y^2. \tag{10.56}$$

∘

Beweis.

$$
\begin{aligned}
s_z^2 &= \frac{1}{n-1}\sum_{i=1}^{n}(z_i - \bar{z})^2 \\
&= \frac{1}{n-1}\sum_{i=1}^{n}(ay_i + b - (a\bar{y} + b))^2 \\
&= \frac{1}{n-1}\sum_{i=1}^{n}(ay_i + b - a\bar{y} - b)^2 \\
&= \frac{1}{n-1}\sum_{i=1}^{n}(a(y_i - \bar{y}))^2 \\
&= \frac{1}{n-1}\sum_{i=1}^{n}a^2(y_i - \bar{y})^2 \\
&= a^2\frac{1}{n-1}\sum_{i=1}^{n}(y_i - \bar{y})^2 \\
&= a^2 s_y^2.
\end{aligned}
\tag{10.57}
$$

□

Beispielsweise ändert also das Umrechnen eines Datensatzes von Meter in Zentimeter die Varianz des Ausgangsdatensatzes um den Faktor 100^2. Wir reproduzieren Theorem 10.5 beispielhaft mithilfe folgenden **R**-Codes.

```
y   = D$PRE                                                    # PRE-BDI-II-Daten
s2y = var(y)                                                   # Varianz von y
a   = 2                                                        # Skalierungsfaktor
b   = 5                                                        # Addierter Wert
z   = a*y + b                                                  # z_i = ay_i + b
s2z = var(z)                                                   # Varianz von z
cat(                                                           # Ausgabe
  "Empirische Varianz von z_1,...,z_n durch direkte Berechnung : ",  # Beschriftung
  round(s2z,3))                                                # Gerundeter Wert
```

```
Empirische Varianz von z_1,...,z_n durch direkte Berechnung :  12.113
```

```
s2z = a^2*s2y                                                  # Varianz von z
cat(                                                           # Ausgabe
  "Empirische Varianz von z_1,...,z_n nach Theorem           : ",  # Beschriftung
  round(s2z,3))                                                # Gerundeter Wert
```

```
Empirische Varianz von z_1,...,z_n nach Theorem           :  12.113
```

Folgendes Theorem zeigt eine Möglichkeit auf, die unkorrigierte empirische Varianz eines Datensatzes allein durch die Bestimmung von Mittelwerten zu bestimmen. Das Theorem findet seine analytische Entsprechung im Verschiebungssatz der Varianz, Theorem 24.2.

Theorem 10.6 (Verschiebungssatz zur unkorrigierten empirischen Varianz)**.** *$y = (y_1, ..., y_n)$ sei ein Datensatz, $y^2 := (y_1^2, ..., y_n^2)$ sei sein elementweises Quadrat und $\bar{y}$ und $\overline{y^2}$ seien die respektiven Mittelwerte. Dann gilt*

$$
\tilde{s}^2 = \overline{y^2} - \bar{y}^2 \tag{10.58}
$$

∘

Beweis.

$$
\begin{aligned}
\tilde{s}^2 &:= \frac{1}{n}\sum_{i=1}^{n}(y_i - \bar{y})^2 \\
&= \frac{1}{n}\sum_{i=1}^{n}(y_i^2 - 2y_i\bar{y} + \bar{y}^2) \\
&= \frac{1}{n}\sum_{i=1}^{n}y_i^2 - 2\bar{y}\frac{1}{n}\sum_{i=1}^{n}y_i + \frac{1}{n}\sum_{i=1}^{n}\bar{y}^2 \\
&= \overline{y^2} - 2\bar{y}\bar{y} + \frac{1}{n}n\bar{y}^2 \\
&= \overline{y^2} - 2\bar{y}^2 + \bar{y}^2 \\
&= \overline{y^2} - \bar{y}^2.
\end{aligned}
\tag{10.59}
$$

□

Wir reproduzieren Theorem 10.6 beispielhaft mithilfe folgenden **R**-Codes.

```
y        = D$PRE                                    # PRE-BDI-II-Daten
s2_def   = sum((y - mean(y))^2)/length(y)           # Varianz nach Definition
s2_tilde = mean(y^2) - mean(y)^2                    # Per Verschiebungssatz
s2       = var(y)                                   # Empirische Varianz

cat(                                                # Ausgabe
  "Unkorrigierte Varianz nach Definition       :",  # Beschriftung
  round(s2_def,6),                                  # Gerundeter Wert
  "\n")                                             # Zeilenumbruch
```

```
Unkorrigierte Varianz nach Definition       : 2.9979
```

```
cat(                                                # Ausgabe
  "Unkorrigierte Varianz nach Verschiebungssatz:",  # Beschriftung
  round(s2_tilde,6),                                # Gerundeter Wert
  "\n")                                             # Zeilenumbruch
```

```
Unkorrigierte Varianz nach Verschiebungssatz: 2.9979
```

```
cat(                                                # Ausgabe
  "Empirische Varianz                         :",   # Beschriftung
  round(s2,6),                                      # Gerundeter Wert
  "\n")                                             # Zeilenumbruch
```

```
Empirische Varianz                          : 3.028182
```

Man beachte, dass der Verschiebungssatz der unkorrigierten empirischen Varianz für die empirische Varianz nicht zutrifft, da in diesem Fall der Multiplikationsfaktor $\frac{1}{n-1}$ nicht auf die entsprechenden Mittelwerte führt. Insbesondere haben wir oben schon gesehen, dass für den betreffenden Beispieldatensatz gilt, dass $s^2 = 3.028$.

10.6.3. Empirische Standardabweichung

Die empirische Varianz ergibt sich wie oben gesehen als durchschnittliches Abweichungsquadrat eines Datensatzwertes von seinem Mittelwert. Ist die Einheit des Datensatzes dabei zum Beispiel in einer Reaktionszeitaufgabe die Millisekunde, so ergibt sich durch Differenzbildung und anschließende Quadrierung die Einheit Millisekunde^2, eine nicht sehr intuitive Einheit. Um ein Streuungsmaß zu erhalten, dessen Einheit der Einheit des Ausgangsdatensatzes entspricht, wird auf die empirische Varianz häufig noch die Quadratwurzelfunktion angewendet. Dies führt auf den Begriff der *empirischen Standardabweichung*.

Definition 10.11 (Empirische Standardabweichung)**.** $y := (y_1, \dots, y_n)$ sei ein Datensatz mit $n \geq 1$. Die *unkorrigierte empirische Standardabweichung* von y ist definiert als

$$\tilde{s} := \sqrt{\tilde{s}^2}. \tag{10.60}$$

Für $n > 1$ ist die *empirische Standardabweichung* von y definiert als

$$s := \sqrt{s^2}. \tag{10.61}$$

•

In Analogie zu den Eigenschaften der empirischen Varianz und ihrer unkorrigierten Version kann auch die unkorrigierte empirische Standardabweichung leicht in die empirische Standardabweichung umgerechnet werden und umgekehrt. Für $n > 1$ gelten

$$\tilde{s} = \sqrt{\frac{n-1}{n}} s \text{ und } s = \sqrt{\frac{n}{n-1}} \tilde{s}. \tag{10.62}$$

Folgender **R**-Code demonstriert die Bestimmung der empirischen Standardabweichung anhand der in Definition 10.11 festgelegten Formel.

```
y = D$PRE                                  # PRE-BDI-II-Daten
n = length(y)                              # Anzahl der Werte
s = sqrt((1/(n-1))*sum((y - mean(y))^2))   # Standardabweichung
```

```
Empirische Standardabweichung :  1.74
```

Die **R**-Funktion `sd()` bestimmt per Default die empirische Standardabweichung.

```
s = sd(y)
```

```
Empirische Standardabweichung :  1.74
```

Transformiert man einen Datensatz linear-affin, so geht die Multiplikationskonstante der Transformation lediglich im Sinne ihres Betrages in die Transformation der empirischen Standardabweichung ein. Dies ist die Aussage des folgenden Theorems.

Theorem 10.7 (Empirische Standardabweichung bei linear-affinen Transformationen)**.** *$y := (y_1, \dots, y_n)$ sei ein Datensatz mit $n > 1$ und empirischer Standardabweichung s_y und $z = (ay_1 + b, \dots, ay_n + b)$ sei der mit $a, b \in \mathbb{R}$ linear-affin transformierte Datensatz mit empirischer Standardabweichung s_z. Dann gilt*

$$s_z = |a| s_y. \tag{10.63}$$

∘

Beweis.

$$\begin{aligned}
s_z &:= \left(\frac{1}{n-1} \sum_{i=1}^{n} (z_i - \bar{z})^2 \right)^{1/2} \\
&= \left(\frac{1}{n-1} \sum_{i=1}^{n} (ay_i + b - (a\bar{y} + b))^2 \right)^{1/2} \\
&= \left(\frac{1}{n-1} \sum_{i=1}^{n} (a(y_i - \bar{y}))^2 \right)^{1/2} \\
&= \left(\frac{1}{n-1} \sum_{i=1}^{n} a^2 (y_i - \bar{y})^2 \right)^{1/2} \\
&= (a^2)^{1/2} \left(\frac{1}{n-1} \sum_{i=1}^{n} (y_i - \bar{y})^2 \right)^{1/2}.
\end{aligned} \tag{10.64}$$

Also gilt $s_z = a s_y$, wenn $a \geq 0$ und $s_z = -a s_y$, wenn $a < 0$. Dies aber entspricht $s_z = |a| s_y$. □

Wir reproduzieren Theorem 10.7 beispielhaft mithilfe folgenden **R**-Codes einmal für den Fall $a \geq 0$ und einmal für den Fall $a < 0$.

```
# a >= 0
D  = read.csv("./_data/110-deskriptive-statistik.csv")  # Datensatz laden
y  = D$PRE                                              # PRE-BDI-II-Daten
a  = 2                                                  # Skalierungsfaktor
b  = 5                                                  # Addierter Wert
z  = a*y + b                                            # z_i = ay_i + b
sz = sd(z)                                              # Standardabweichung z
```

```
Empirische Standardabweichung nach Transformation :  3.48
```

```
sz = a*sd(y)                                  # Empirische Standardabweichung nach Theorem
```

```
Empirische Standardabweichung nach Transformation :  3.48
```

```
# a < 0
D  = read.csv("./_data/110-deskriptive-statistik.csv")  # Datensatz laden
y  = D$PRE                                              # PRE-BDI-II-Daten
a  = -3                                                 # Skalierungsfaktor
b  = 10                                                 # Addierter Wert
z  = a*y + b                                            # z_i = ay_i + b
sz = sd(z)                                              # Standardabweichung z
```

```
Empirische Standardabweichung nach Transformation :  5.221
```

```
sz = -a*sd(y)                                  # Empirische Standardabweichung nach Theorem
```

```
Empirische Standardabweichung nach Transformation :  5.221
```

Teil II.

Imperative Programmierung

Zur Bedeutung der imperativen Programmierung in der Psychologie

Heutzutage liegen wissenschaftliche Daten in der Regel in digitaler Form vor. Um diese digitalen Daten auszuwerten, werden sie mithilfe eines Computers analysiert. Dazu schreibt man spezielle Computerprogramme, die genau auf die jeweilige Fragestellung zugeschnitten sind. Solche Programme bezeichnet man als Datenanalyseskripte.

Die computergestützte Datenanalyse folgt dabei einer typischen Struktur. Zunächst wird ein digitaler Datensatz eingelesen und bereinigt, um fehlerhafte oder unvollständige Daten zu korrigieren und für die Analyse vorzubereiten. Anschließend werden meist deskriptive Statistiken berechnet und visualisiert, um einen ersten Überblick über die Daten zu gewinnen. Darauf folgt häufig ein Schritt der probabilistischen Modellierung und Inferenz, bei der auf der Wahrscheinlichkeitstheorie basierende Modelle verwendet werden, um Hypothesen zu testen oder Vorhersagen zu treffen. Abschließend werden die Ergebnisse, wiederum mithilfe des Computers, dokumentiert und anschaulich präsentiert.

Zentrales Element der computergestützten Datenanalyse ist das *Datenanalyseskript*, eine Textdatei, die alle Schritte vom Rohdatum bis hin zur finalen Datenvisualisierung dokumentiert und so Datenanalyseprozesse transparent und nachvollziehbar macht. So ermöglicht ein Datenanalyseskript Dritten die Reproduktion wissenschaftlicher Ergebnisse, was einen Grundpfeiler guter wissenschaftlicher Praxis darstellt. Datenanalyseskripte sind damit unverzichtbare Werkzeuge der täglichen wissenschaftlichen Arbeit und essenzielle Bestandteile wissenschaftlicher Publikationen. In den folgenden Abschnitten wollen wir ausgehend von der Diskussion einiger informatischer Grundbegriffe und strukturbildender Elemente der imperativen Programmierung die Entwicklung von Datenanalyseskripten in der Programmierumgebung R kennenlernen.

Zur Analyse psychologischer Daten kommen verschiedene digitale Werkzeuge zum Einsatz. Besonders verbreitet sind frei verfügbare Programmiersprachen und Plattformen wie R, das häufig in der Datenwissenschaft, Statistik und Psychologie genutzt wird, und Python mit seinem breiten Einsatzspektrum in der Datenwissenschaft, dem maschinellen Lernen und der künstlichen Intelligenz. Eher noch ein Nischendasein führt die eigentlich datenanalytisch optimierte freie Programmiersprache Julia, die momentan insbesondere in industriellen Anwendungen noch keine weite Verbreitung gefunden hat. Freie Programmiersprachen haben den Vorteil, dass sie häufig von einer breiten Community von Anwendern weiterentwickelt werden und auf diese Weise eine vielseitige Infrastruktur entwickeln können.

Daneben kommen aber auch im Bereich der Psychologie weiterhin kommerzielle Programmierumgebungen, deren Quellcode nicht einsehbar ist, zum Einsatz. Im Bereich der Neurobildgebung sowie in ingenieurtechnischen Anwendungen ist zum Beispiel auch heute noch die kommerzielle Programmierumgebung MATLAB beliebt. Weiterhin werden einige aus heutiger Sicht eher altmodische Programme verwendet, darunter SPSS, das zur Jahrtausendwende vor allem in den Sozialwissenschaften und in der Psychologie sehr verbreitet war, JMP mit Einsatzschwerpunkten in Biologie und Psychologie und STATA, das unter anderem in der Medizin und den Wirtschaftswissenschaften populär war.

Die Popularität digitaler Werkzeuge unterliegt einem stetigen Wandel. Eine Möglichkeit, die aktuelle Popularität verschiedener Programmiersprachen und -umgebungen zu messen, ist die Quantifizierung von Google-Suchanfragen zu Programmiersprachentutorials. Einen Überblick über aktuelle Trends bietet der PYPL Index, der auf der Analyse solcher Suchanfragen basiert.

Zusammenfassend lässt sich festhalten, dass die Digitalisierung insbesondere auch die Wissenschaft nachhaltig prägt. Ein effektives Forschungsdatenmanagement stellt dabei eine akute Herausforderung dar, der sich Forschende stellen müssen. Programmierung entwickelt sich zunehmend zu einem zentralen Handwerkszeug wissenschaftlicher Arbeit, und grundlegende Informatikkenntnisse sind in der modernen Arbeitswelt unverzichtbar geworden. Dies gilt nicht zuletzt auch für Psychotherapeut:innen, etwa im Kontext von Online-Interventionen, digital gestützten Behandlungsangeboten oder der Psychotherapieforschung.

11. Informatische Grundbegriffe

Nach allgemeinem Sprachgebrauch (vgl. Wikipedia) handelt es sich bei der Informatik um die Wissenschaft der systematischen Darstellung, Speicherung, Verarbeitung und Übertragung von Informationen, wobei besonders die automatische Informationsverarbeitung mit Computern betrachtet wird. Die Informatik ist dabei sowohl Grundlagen- und Formalwissenschaft als auch Ingenieurdisziplin.

Zentrale Komponenten der Informatik sind zum einen die *Computer*, zum anderen *Algorithmen und Programme*. *Computer* sind Maschinen, die Daten speichern und einfache Datenoperationen ausführen können. Diese einfachen Operationen führen sie mit extrem hoher Geschwindigkeit aus. Die Universalität von Computern beruht darauf, dass sie sowohl Daten als auch Programme speichern können.

Programme sind in einer Programmiersprache formulierte *Algorithmen*. *Algorithmen* wiederum sind Folgen von *Anweisungen*, die bestimmte *Operationen* vorschreiben. Bei Algorithmen unterscheidet man verschiedene Ebenen: die *Beschreibungsebene*, wie man sie beispielsweise in Form eines Kochrezepts, einer Bauanleitung oder eines Datenanalyseskripts findet, die *Anweisungen* eines Algorithmus, wie "Mehl und Wasser vermengen", die bildhafte Darstellung des Zusammenschraubens zweier Teile oder die Anweisung `x = c(1, 2, 3)` in **R**, und schließlich die *Durchführungsebene*, also der eigentliche Kochvorgang, der Zusammenbau eines Möbelstücks oder das Ausführen des Datenanalyseskripts.

Die Informatik gliedert sich in mehrere Teilgebiete, die auch für die Psychologie von Bedeutung sein können. Die *Theoretische Informatik* beschäftigt sich mit den Grundlagen der Berechnung, wie der Automatentheorie, der Berechenbarkeitstheorie und der Komplexitätstheorie. Die *Angewandte Informatik* befasst sich mit der Entwicklung und Nutzung von Anwendungssoftware, mit Fragen der Mensch-Computer-Interaktion sowie mit den gesellschaftlichen Auswirkungen der Informatik. Die *Technische Informatik* untersucht die Hardwareseite der Informatik, darunter die Mikroprozessortechnik, die Rechnerarchitektur und die Netzwerktechnik. Schließlich behandelt die *Praktische Informatik* die konkrete Umsetzung in Form von Programmierung, der Entwicklung und Analyse von Algorithmen sowie den Aufbau und die Nutzung von Datenbanken. Anwendung in der psychologischen Grundlagenforschung findet vor allem die praktische Informatik. Allerdings sind auch Fragen der Komplexitätstheorie und damit der theoretischen Informatik in der Entwicklung quantitativer psychologischer Theorien von Interesse (vgl. Van Rooij & Wareham (2012)) und die Mensch-Computer-Interaktion bildet eines der Themengebiete der modernen Arbeitspsychologie (vgl. Dahm (2005)).

Darüber hinaus gibt es zahlreiche Spezialgebiete der Informatik, die eng mit der Psychologie verbunden sind. Dazu gehört insbesondere natürlich der Bereich *Maschinelles Lernen* und *Künstliche Intelligenz*, der seine Ursprünge in der quantitativen Kognitionspsychologie hat und es heutzutage ermöglicht, große Datenmengen automatisiert zu analysieren und Vorhersagen zu treffen. Ein weiteres wichtiges Feld ist die *Computervisualistik*, die sich mit Bilderkennung und Bildsynthese sowie mit der Gestaltung von Virtueller Realität (VR)

und Augmented Reality (AR) beschäftigt. Diese Technologien nutzen einerseits Erkenntnisse der Wahrnehmungspsychologie und eröffnen andererseits neue Möglichkeiten für Experimente, Therapien und Trainings in der Psychologie. Die *Computerlinguistik* trägt mit Verfahren der Spracherkennung und Sprachsynthese dazu bei, menschliche Kommunikation zu analysieren, zu modellieren und in Anwendungen wie Chatbots oder Assistenzsystemen nutzbar zu machen. Schließlich spielt für die Psychologie auch die *Bioinformatik* eine große Rolle, indem sie etwa Methoden zur Auswertung bildgebender Verfahren in der Medizin, die auch in der neuropsychologischen Forschung und Diagnostik genutzt werden, weiterentwickelt.

11.1. Rechnerarchitektur

Auch wenn wir die technischen Aspekte der Informatik hier nicht vertiefen wollen, ist es für die imperative Programmierung hilfreich, zumindest ein rudimentäres Wissen um den typischen physischen Aufbau, also die Hardware, eines Computers zu besitzen. Ein Computer besteht dabei aus mehreren wesentlichen Hardwarekomponenten, die zusammenarbeiten, um alle Rechen- und Speicheraufgaben zu bewältigen. Im Zentrum steht die Hauptplatine, auch Motherboard oder Mainboard genannt. Sie ist die zentrale Leiterplatte, auf der wichtige Bauteile wie Prozessor, Speicher und Anschlüsse miteinander verbunden sind.

Das Herzstück eines Computers ist die CPU (Central Processing Unit, auch Mikroprozessor), die das Rechenwerk, das Steuerwerk und Register des Systems vereint. Sie übernimmt alle grundlegenden Berechnungen, steuert den Datenfluss und koordiniert die Abläufe. Zusätzlich verfügt sie über einen kleinen, aber sehr schnellen *Cache*, einen flüchtigen Speicher, der häufig benötigte Daten zwischenspeichert, um die Verarbeitung zu beschleunigen. Typische Beispiele aktueller CPUs sind Intel-Core-i-Prozessoren, AMD-Ryzen-Prozessoren oder Apple-Silicon-M-Prozessoren.

Ergänzt wird die CPU durch den RAM (Random Access Memory), den temporären, flüchtigen Arbeitsspeicher des Systems. Hier werden während der Laufzeit des Computers die aktuell benötigten Programme und Daten abgelegt, um schnellen Zugriff zu ermöglichen. Der RAM ist in seiner Kapazität begrenzt, in vielen modernen Systemen zum Beispiel auf 32 bis 64 GB.

Für die dauerhafte Speicherung von Daten und Programmen dient der Massenspeicher, der stationäre Speicher des Computers. Heute werden dafür in der Regel SSDs (Solid State Drives) verwendet, die wesentlich schneller und robuster als herkömmliche magnetbasierte Festplatten sind. Auch Cloudspeicher wird zunehmend als Ergänzung oder Ersatz für lokale Massenspeicher genutzt.

Eine weitere wichtige Komponente ist die GPU (Graphics Processing Unit), ein leistungsstarker, speziell auf Visualisierungsaufgaben optimierter Prozessor. Die GPU entlastet die CPU bei grafikintensiven Anwendungen wie 3D-Rendering oder Videobearbeitung und spielt zudem eine wachsende Rolle bei rechenintensiven Aufgaben wie dem Training neuronaler Netze, bei denen sie die CPU effektiv unterstützen kann.

Die grundlegende funktionale Architektur moderner Computer geht zurück auf Von Neumann (1945) und wird entsprechend als *Von-Neumann-Architektur* bezeichnet. Das entscheidende Charakteristikum der Von-Neumann-Architektur besteht darin, dass sowohl

die Befehle (Programmanweisungen) als auch die Daten im selben Speicher abgelegt werden, und zwar in Form von Binärzahlen. Die zentrale Verarbeitungseinheit (CPU) liest sowohl die Befehle als auch die Daten aus diesem gemeinsamen Speicher. Dadurch können Programme während der Ausführung dynamisch verändert oder sogar neu erzeugt werden, da sie im Speicher lediglich als Daten vorliegen.

Speziell beschreibt Von Neumann (1945) folgenden Rechneraufbau: Der Rechner setzt sich aus den grundlegenden Funktionseinheiten Steuerwerk, Rechenwerk, Speicher, Eingabewerk und Ausgabewerk zusammen. Programme und Daten werden gemeinsam in den Speicher eingegeben, sodass Daten, Programme sowie Zwischen- und Endergebnisse im gleichen Speicherbereich abgelegt sind. Der Speicher selbst ist in gleich große, nummerierte (adressierte) Zellen unterteilt, deren Inhalt über die jeweilige Adresse gezielt abgerufen oder verändert werden kann. Die Befehle eines Programms liegen typischerweise in aufeinanderfolgenden Speicherzellen, sodass das Steuerwerk den jeweils nächsten Befehl durch einfaches Erhöhen der Befehlsadresse um eins aufrufen kann. Dieses Prinzip der sequentiellen Abarbeitung der Befehle stellt dabei das Grundprinzip der imperativen Programmierung dar und ist somit aufs Engste mit der Von-Neumann-Architektur verknüpft. Durch spezielle Sprungbefehle ist es weiterhin möglich, von dieser festen Reihenfolge abzuweichen und an eine andere Stelle im Programm zu springen. Zu den grundlegenden Befehlen gehören dabei arithmetische Operationen wie Addition und Multiplikation, logische Vergleiche wie das logische UND oder ODER sowie Transportbefehle, mit denen Daten beispielsweise vom Eingabewerk in den Speicher oder vom Speicher ins Rechenwerk übertragen werden. Sämtliche Daten, also sowohl Befehle als auch Adressen, werden dabei binär codiert. Die binäre Enkodierung und Dekodierung der Informationen übernimmt dabei eine geeignete Schaltungstechnik im Rechner.

11.2. Algorithmen und Programme

Ein *Realweltproblem* bezeichnet das Problem, das mithilfe eines Computers gelöst werden soll. Ein typisches Beispiel hierfür ist die Auswertung von Fragebogendaten einer psychologischen Studie. Zur Bearbeitung eines solchen Problems erfolgt zunächst eine *Problemspezifikation*, also die genaue sprachliche Fassung des Realweltproblems, wie man sie etwa im Methodenteil einer wissenschaftlichen Publikation findet. Auf dieser Grundlage wird ein *Algorithmus* entworfen, also eine Folge von Anweisungen zur Lösung des Problems, beispielsweise das Einlesen der Daten, die Berechnung von deskriptiven Statistiken und die Durchführung eines statistischen Tests. Schließlich wird der Algorithmus in Form eines *Programms* implementiert, das heißt als in einer Programmiersprache verfasste Textdatei, die von einem Computer ausgeführt werden kann.

Definition 11.1 (Algorithmus)**.** Ein Algorithmus ist eine Folge von Anweisungen, um aus gewissen Eingabedaten bestimmte Ausgabedaten herzuleiten, wobei folgende Bedingungen erfüllt sein müssen:

- Finitheit. Die Anweisungsfolge ist in einem endlichen Text vollständig beschrieben.
- Effektivität. Jede Anweisung muss tatsächlich ausführbar sein.
- Terminierung. Der Algorithmus endet nach endlich vielen Anweisungen.
- Determiniertheit. Der Ablauf des Algorithmus ist zu jeder Zeit vorgeschrieben.

Wenn E die Menge der zulässigen Eingabedaten und A die Menge der zulässigen Ausgabedaten bezeichnet, dann ist ein Algorithmus also eine Funktion:

$$f : E \to A, \quad e \mapsto f(e). \tag{11.1}$$

Umgekehrt heißen Funktionen, die durch einen Algorithmus beschrieben werden können, *berechenbare Funktionen*.

•

11.3. Programmiersprachen

Programmiersprachen legen die Regeln fest, denen ein Programm gehorchen muss. Sie definieren eine *Syntax*, also das Vokabular und den Aufbau eines Programms, sowie die *Semantik*, also die Bedeutung der erlaubten Anweisungen. Im Folgenden wollen wir einige Begriffsklärungen zur Kategorisierung verschiedener Formen von Programmiersprachen angeben. Dabei unterscheidet man *Maschinensprache* und sogenannte *höhere Programmiersprachen*, verschiedene *Generationen von Programmiersprachen*, die hier im Vordergrund stehende *Imperative Programmierung* von der *Deklarativen Programmierung* sowie *kompilierte* von *interpretierten* Programmiersprachen.

Maschinensprache und höhere Programmiersprachen

Maschinensprache besteht aus elementaren Operationsbefehlen wie Speichern, Vergleichen oder Addieren, die als Binärzahlen kodiert werden. Tabelle 11.1 zeigt einige Beispiele solcher Befehle:

Tabelle 11.1. Beispiele für Maschinensprache

Befehl	Binärcode
Addiere Inhalt R1 zu Inhalt R2	1001 0010
Erhöhe Inhalt R um 1	1001 0110
Übertrage Inhalt R1 nach R3	0010 0011

Programme, die in Maschinensprache geschrieben sind, nennt man Maschinenprogramme. De facto führt ein Computer ausschließlich Maschinenprogramme aus, da diese direkt von der Hardware verstanden werden. Für Menschen ist die Programmierung in Maschinensprache jedoch sehr mühselig, weshalb in der Praxis überwiegend höhere Programmiersprachen verwendet werden.

Höhere Programmiersprachen verwenden an die menschliche Sprache angelehnte Wörter und Sätze, um die Programmierung verständlicher und effizienter zu machen. Programme in höheren Programmiersprachen werden anschließend von einem *Compiler* oder einem *Interpreter* in Maschinensprache übersetzt, damit sie vom Computer ausgeführt werden können. Bekannte Beispiele für höhere Programmiersprachen sind FORTRAN, COBOL, C++, Python oder auch **R**.

Generationen von Programmiersprachen

Die *Programmiersprachen der 1. Generation (1GL)* sind die Maschinensprachen. Programme werden dabei direkt in Form von Binärzahlen geschrieben, etwa `10110000 01100001`,

was in hexadezimaler Darstellung `B0 61` entspricht. Solche Maschinensprachen wurden vor allem auf den ersten Röhren- und Relaiscomputern wie dem ENIAC oder frühen IBM-Großrechnern der 1940er- und frühen 1950er-Jahre eingesetzt.

Mit der *2. Generation (2GL)* entstanden ab den 1950er-Jahren die Assemblersprachen als erste Form der symbolischen Programmierung. Hierbei werden menschenlesbare Kürzel verwendet, die jedoch noch prozessorspezifisch sind. Ein Beispiel für eine solche prozessorspezifische Intel-Anweisung ist `MOV AL, 61H`. Diese Generation von Programmiersprachen wurde vor allem auf Großrechnern wie der IBM 704 oder frühen Mainframes der 1950er- und 1960er-Jahre genutzt, die bereits Transistoren statt Röhren verwendeten.

Ab den 1970er-Jahren setzten sich die *Programmiersprachen der 3. Generation (3GL)* durch. Dazu zählen höhere Programmiersprachen wie FORTRAN, C, C++ und Java. Sie sind wesentlich programmierfreundlicher und vor allem prozessorunabhängig, was die Portabilität von Programmen deutlich verbessert. Solche Sprachen wurden zunächst auf Minicomputern wie DEC PDP-11 und später auf Workstations, PCs und Servern weit verbreitet verwendet.

Schließlich entwickelten sich ab den 1980er-Jahren die *Programmiersprachen der 4. Generation (4GL)*, zu denen Sprachen wie Python, MATLAB und **R** gehören. Diese zeichnen sich durch die Minimierung von Code-Overhead, hohe Flexibilität, Unterstützung multiparadigmatischer Ansätze und einen hohen Grad an Automatisierung aus. Sie finden vor allem auf modernen PCs, High-Performance-Computing-Clustern (HPC-Clustern) und cloudbasierten Systemen Anwendung, die seit den 1990er-Jahren zunehmend verfügbar wurden.

Imperative und deklarative Programmierung

Bei der *Imperativen Programmierung* (von *imperare*, lat. “befehlen”) wird der Problemlösungsweg als Folge von Anweisungen beziehungsweise Befehlen vorgegeben. Diese Befehle verarbeiten Daten, die über Variablen adressiert werden. Innerhalb der imperativen Programmierung unterscheidet man mit der *prozeduralen* und der *objektorientierten* imperativen Programmierung zwei verschiedene Ansätze.

In der *prozeduralen imperativen Programmierung* werden Daten und die sie manipulierenden Befehle getrennt behandelt. Das zentrale Strukturkonzept bilden hier Prozeduren oder Funktionen, die wiederverwendbare Einheiten von Anweisungen kapseln. Demgegenüber werden in der *objektorientierten imperativen Programmierung* Daten und die auf sie wirkenden Befehle als Objekte zusammengefasst. Diese Objekte sind zugleich Datenträger und Funktionsanbieter und bilden das zentrale Strukturkonzept dieses Ansatzes.

In der Praxis kommen häufig Mischformen aus beiden Paradigmen zum Einsatz, da sich die Ansätze je nach Problemstellung gut kombinieren lassen. Ein Beispiel für eine solche Mischform ist die neuere Programmiersprache Julia, die keinen klassischen objektorientierten Ansatz, sondern stattdessen einen *Multiple-Dispatch*-Ansatz bietet: Funktionen können je nach Typ der Argumente unterschiedliche Implementierungen haben und so Aspekte der objektorientierten und der prozeduralen Programmierung verbinden.

Bei der *Deklarativen Programmierung* steht nicht der Lösungsweg, sondern die Beschreibung des Problems selbst im Vordergrund. Der Programmierende formuliert, was erreicht werden soll, und nicht im Detail, wie der Computer dieses Ziel schrittweise erreichen soll. Der Lösungsweg wird dabei anhand vorgegebener Regeln und Mechanismen automatisch vom System ermittelt.

Ein typisches Merkmal deklarativer Ansätze ist, dass der Fokus auf der Definition von Beziehungen, Bedingungen oder Zielen liegt anstatt auf einer expliziten Abfolge von Befehlen. Der Programmierende beschreibt also das gewünschte Ergebnis in einer formalen Sprache, und der Computer sucht eigenständig nach einer Lösung, die diesen Bedingungen genügt.

Bekannte Ansätze der deklarativen Programmierung sind zum Beispiel die logische Programmierung, wie sie in der Sprache Prolog umgesetzt ist, oder die funktionale Programmierung, wie in Haskell. In der logischen Programmierung werden Fakten und Regeln formuliert, aus denen das System per Inferenz Schlüsse zieht. In der funktionalen Programmierung werden Berechnungen durch die Komposition von Funktionen beschrieben, wobei der Zustand der Daten nicht explizit verändert wird. Deklarative Programmierung eignet sich besonders für Probleme, bei denen der Lösungsweg komplex und vielfältig sein kann, aber die gewünschten Eigenschaften des Ergebnisses klar spezifiziert werden können. Typische Anwendungsgebiete sind zum Beispiel Datenbankabfragen (z. B. SQL), Wissensbasen, Constraint-Lösungen und formale Beweise.

Ein modernes Beispiel für den Einsatz deklarativer Programmierung ist das System Lean, ein sogenannter *Theorem Prover*. Lean wird eingesetzt, um mathematische Sätze formal zu beweisen. Hierbei formuliert der Benutzer in einer Mischung aus deklarativen und interaktiven Befehlen die Axiome, Definitionen und zu beweisenden Aussagen. Das System prüft automatisch, ob die angegebenen Schritte gültig sind, und ergänzt nach festgelegten Regeln die fehlenden Teile des Beweises. Damit verbindet Lean deklarative Programmierung mit automatischer Beweisführung und erlaubt es, große mathematische Theorien formal korrekt zu entwickeln. Für eine Einführung in Lean im Rahmen mathematischer Beweisführung siehe zum Beispiel The Mechanics of Proof.

Kompilierte und interpretierte Programmiersprachen

Kompilierte Programmiersprachen zeichnen sich dadurch aus, dass der gesamte Quellcode vor der Ausführung in Maschinensprache übersetzt wird. Für diese Übersetzung wird ein spezielles Programm, der sogenannte *Compiler*, verwendet. Der vom Compiler erzeugte Maschinencode wird direkt vom Prozessor ausgeführt, was eine sehr schnelle Ausführung des Programms ermöglicht. Da das ausführbare Programm bereits in Maschinensprache vorliegt, muss es zur Laufzeit nicht mehr übersetzt werden. Allerdings ist es notwendig, bei jeder Änderung des Quellcodes das Programm erneut zu kompilieren. Typische Beispiele für kompilierte Programmiersprachen sind C, C++ und Rust.

Im Gegensatz dazu wird bei *interpretierten Programmiersprachen* der Quellcode während der Ausführung in eine maschinennahe Sprache übersetzt. Dies übernimmt ein spezielles Programm, der sogenannte *Interpreter*. Da die Übersetzung und Ausführung gleichzeitig stattfinden, ist die Ausführung im Vergleich zu kompilierten Programmen in der Regel langsamer. Ein Vorteil besteht jedoch darin, dass nach Änderungen kein separater Kompilierungsschritt erforderlich ist. Das Programm kann sofort ausgeführt werden. Typische Beispiele für interpretierte Programmiersprachen sind Python und **R**.

Im Sinne der hier eingeführten Begriffsbildungen ist **R** eine interpretierte multiparadigmatische Programmiersprache der 4. Generation, die objektorientierte Konzepte unterstützt, aber häufig prozedural und funktional genutzt wird und auf die statistische Datenanalyse zugeschnitten ist.

11.4. R

R ist eine Programmiersprache und ein Softwarepaket, das ursprünglich von Ross Ihaka (Ihaka & Gentleman (1996)) entwickelt wurde. Es handelt sich um einen freien Dialekt der proprietären Software S, die von Becker et al. (Becker et al. (1988)) eingeführt wurde. Heute wird **R** vom R Core Team und der R Foundation weiterentwickelt und gepflegt. **R** verfügt über eine große und aktive Community, die bislang mehr als 20.000 **R**-Pakete beigetragen hat, die das System um zahlreiche Erweiterungen ergänzen. Dabei entwickelt sich der Kern von **R** bewusst evolutionär und konservativ weiter, während die Vielzahl an R-Paketen eine konsistente und progressive Weiterentwicklung ermöglicht. **R** lässt sich einfach von CRAN herunterladen und installieren.

Mit **R** kann man Datensätze laden, manipulieren und in verschiedenen Formaten speichern. Die Sprache ermöglicht es, eine Vielzahl von Berechnungen auf unterschiedlichen Datenstrukturen durchzuführen. Darüber hinaus bietet **R** ein breites Spektrum statistischer Analysemethoden, die sich direkt auf die Daten anwenden lassen. Typisch ist auch das Schreiben von reproduzierbaren Datenanalyseskripten, mit denen sich Analysen automatisieren und Ergebnisse nachvollziehbar dokumentieren lassen. Schließlich eignet sich **R** hervorragend zur Erstellung von Abbildungen und Visualisierungen, um Daten anschaulich zu präsentieren.

Allerdings lassen sich mit **R** einige Dinge, die in der psychologischen Datenwissenschaft von Bedeutung sind, nur eingeschränkt umsetzen. So fehlt **R** per se eine eigene moderne, ansprechende Entwicklungsumgebung. Hier schafft die Einbettung von **R** in VS Code Abhilfe. Im Bereich des Scientific Computing stößt **R** an seine Grenzen. Hier bieten Sprachen wie Python, MATLAB oder Julia oft leistungsfähigere und flexiblere Werkzeuge. Schließlich eignet sich **R** kaum zum Programmieren psychologischer Experimente, wofür ebenfalls eher Python oder MATLAB zum Einsatz kommen.

Um Hilfe zu **R** zu bekommen, gibt es viele Möglichkeiten. Ganz klassisch hilft oft schon eine schnelle Suche bei Google, eine Anfrage bei ChatGPT oder eine Interaktion mit Copilot in VS Code. Während der Programmierung und wenn man den Namen einer Funktion bereits kennt, kann man direkt in **R** Hilfe aufrufen:

```
?mean
help(mean)
```

Für umfassendere, längere Tutorials und Hintergrundinformationen lohnt sich ein Blick in die sogenannten *Vignetten* der installierten Pakete:

```
browseVignettes()
```

Darüber hinaus gibt es zahlreiche hilfreiche Online-Ressourcen, zum Beispiel die spezialisierte Suchmaschine rseek oder die vielen Artikel und Anleitungen auf R-Bloggers, wobei die meisten Informationen auf diesen Plattformen sicherlich auch Teil der über Chatbots zugänglichen Datenbanken wie ChatGPT, Gemini, Claude oder DeepSeek sind.

11.5. Visual Studio Code

Visual Studio Code (VS Code) ist ein kostenloser Quelltext-Editor von Microsoft, der seit 2015 für Windows, macOS und Linux verfügbar ist. Grob gesagt ist VS Code so etwas wie die (vielleicht eher bekannte) RStudio-Umgebung, nur eben für alle Programmiersprachen. VS Code lässt sich über Erweiterungen flexibel erweitern und als integrierte Entwicklungsumgebung (IDE) für nahezu jede Sprache nutzen, zum Beispiel für **R**, Python, Julia, Shell, Quarto und viele mehr. Seit 2018 gilt VS Code als der beliebteste Editor überhaupt, wie jährliche Umfragen zeigen. Bemerkenswerterweise ist damit ausgerechnet ein Microsoft-Produkt der meistgenutzte Editor auch in der Linux-Welt. VS Code ist sehr konfigurierbar, stark von der Community geprägt und ermöglicht über Microsofts GitHub die Synchronisation der Einstellungen und Erweiterungen über mehrere Endgeräte hinweg. Eine ausführliche Dokumentation mit Anleitungen zur Nutzung findet man unter www.code.visualstudio.com/docs. Einen Einstieg zum Arbeiten mit **R** in VS Code liefert die entsprechende Dokumentation R in Visual Studio Code.

12. Arithmetik und Variablen

12.1. Arithmetik

Öffnet man ein **R**-Terminal, so kann man dieses zunächst einmal als Taschenrechner nutzen, wie folgendes Beispiel zeigt.

```
1+1                                     # Addition
```

```
[1] 2
```

Im Terminal erscheint dabei einerseits das Ergebnis 2, andererseits mit `[1]` ein Hinweis darauf, dass das Ergebnis der erste Eintrag in dem von **R** erzeugten Ergebnisvektor ist. Vektoren werden wir in Kapitel 14 im Detail behandeln. Weitere Beispiele für den Gebrauch eines **R**-Terminals als Taschenrechner sind folgende.

```
2*3                                     # Multiplikation
```

```
[1] 6
```

```
sqrt(2)                                 # Quadratwurzel
```

```
[1] 1.414214
```

```
exp(0)                                  # Exponentialfunktion
```

```
[1] 1
```

```
log(1)                                  # Logarithmusfunktion
```

```
[1] 0
```

Tabelle 12.1 gibt einen ersten Überblick über die in Base **R** verfügbaren arithmetischen Operatoren. Neben den vertrauten Operationen der Addition, Subtraktion, Multiplikation, Division und Potenzierung bietet Base **R** auch spezielle Operatoren für weitergehende arithmetische Berechnungen. Dazu gehören etwa die *Matrixmultiplikation*, die *ganzzahlige Division* (`5 %/% 2 = 2`) sowie die *Modulo-Operation*, die den Rest einer ganzzahligen Division liefert (`5 %% 2 = 1`).

Tabelle 12.1. Beispiele arithmetischer Operatoren in Base **R**.

Operation	Operator
Addition	`+`
Subtraktion	`-`
Multiplikation	`*`
Division	`/`
Potenz	`^`
Matrixmultiplikation	`%*%`
Ganzzahlige Division	`%/%`
Modulo-Operation	`%%`

Neben den arithmetischen Operatoren zur Verknüpfung zweier Zahlen bietet Base **R** natürlich auch die Möglichkeit, mathematische Standardfunktionen auszuwerten. Einen ersten Überblick dazu gibt Tabelle 12.2.

Tabelle 12.2. Beispiele mathematischer Funktionen in Base **R**.

Funktion	Aufruf
Exponentialfunktion	`exp(x)`
Logarithmusfunktion	`log(x)`
Betrag	`abs(x)`
Wurzel	`sqrt(x)`
Aufrunden	`ceiling(x)`
Abrunden	`floor(x)`
Mathematisches Runden	`round(x)`

Obwohl die in Tabelle 12.1 aufgeführten Operatoren und die in Tabelle 12.2 aufgeführten Funktionen auf den ersten Blick einen etwas anderen Charakter haben, unterscheidet Base **R** formal nicht zwischen Operatoren und Funktionen. Speziell können Operatoren mithilfe der sogenannten *Infixnotation* auch als Funktionen mehrerer Argumente genutzt und verstanden werden. Untenstehender **R**-Code zeigt, wie die arithmetische Verknüpfung $2 + 3$ als Ausführung einer Funktion der Form $+ : \mathbb{R}^2 \to \mathbb{R}$ mit der Bezeichnung "+" verstanden werden kann.

```
`+`(2,3)                                # Infixnotation für 2 + 3
```

```
[1] 5
```

Schließlich bietet Base **R** wie jede Programmiersprache auch die Möglichkeit, Ausdrücke auf ihren logischen Gehalt hin auszuwerten. Dabei ist Logik hier im Sinne der aus Kapitel 1 bekannten Aussagenlogik zu verstehen, in der Aussagen einen von zwei Werten annehmen können, wahr (TRUE) oder falsch (FALSE). Die in Tabelle 12.3 aufgeführten Relationsoperatoren `<`, `<=`, `>` und `>=` werden zumeist auf numerische Werte angewendet. Die Gleichheitsoperatoren `==` und `!=` können auf beliebige Datenstrukturen angewendet werden. Die Operatoren zur Verknüpfung logischer Werte `&` und `|` schließlich entsprechen den aus Kapitel 1 bekannten Begriffen der logischen Konjunktion ("und") und Disjunktion ("nicht-exklusives oder").

Tabelle 12.3. Beispiele logischer Operatoren in Base **R**.

Logische Verknüpfung	Operator
Gleich	`==`
Ungleich	`!=`
Konjunktion	`&`
Disjunktion	`|`
Kleiner	`<`
Kleiner-gleich	`<=`

Die in Tabelle 12.1, Tabelle 12.2 und Tabelle 12.3 aufgelisteten Operatoren und Funktionen stellen nur einen kleinen Auszug der von Base **R** bereitgestellten Operatoren und Funktionen dar. Einen vollständigen Überblick bietet der Aufruf `names(methods:::.BasicFunsList)`, der die Namen aller von Base **R** bereitgestellten Funktionen auflistet. Viele dieser Funktionen werden wir im weiteren Verlauf kennenlernen.

```
names(methods:::.BasicFunsList)
```

```
  [1] "$"                 "$<-"               "["
  [4] "[<-"               "[["                "[[<-"
  [7] "crossprod"         "tcrossprod"        "xtfrm"
 [10] "c"                 "all"               "any"
 [13] "sum"               "prod"              "max"
 [16] "min"               "range"             "cummax"
 [19] "rep"               "^"                 "cos"
 [22] "levels<-"          "cumsum"            "asin"
 [25] "anyNA"             "<="                "Conj"
 [28] "exp"               "is.matrix"         "log10"
 [31] "as.environment"    "ceiling"           "asinh"
 [34] "abs"               "as.raw"            "is.infinite"
 [37] "is.array"          "floor"             "=="
 [40] "sign"              "cummin"            "|"
 [43] "round"             "Re"                "!"
 [46] "is.numeric"        "acosh"             "!="
 [49] "names<-"           "&"                 "atanh"
 [52] "sinh"              ">="                "sin"
 [55] "*"                 "atan"              "+"
 [58] "length"            "length<-"          "sinpi"
 [61] "-"                 "is.nan"            "/"
 [64] "sqrt"              "%/%"               "as.numeric"
 [67] "seq.int"           "trunc"             "digamma"
 [70] "acos"              "<"                 "as.logical"
 [73] "cosh"              "Mod"               "tanpi"
 [76] "%*%"               "dimnames<-"        "log2"
 [79] ">"                 "tanh"              "is.na"
 [82] "dim"               "signif"            "gamma"
 [85] "is.finite"         "as.integer"        "dim<-"
 [88] "as.double"         "lgamma"            "Arg"
 [91] "log1p"             "trigamma"          "%%"
 [94] "tan"               "cumprod"           "Im"
 [97] "expm1"             "as.call"           "log"
[100] "as.complex"        "cospi"             "as.character"
[103] "dimnames"          "names"             "("
[106] ":"                 "="                 "@"
```

```
[109] "{"                 "~"                 "&&"
[112] ".C"                "baseenv"           "quote"
[115] "::"                "<-"                "is.name"
[118] "if"                "||"                "attr<-"
[121] "untracemem"        ".cache_class"      "substitute"
[124] "interactive"       "is.call"           "switch"
[127] "function"          "is.single"         "is.null"
[130] "is.language"       "is.pairlist"       ".External.graphics"
[133] "declare"           "globalenv"         "class<-"
[136] ".Primitive"        "is.logical"        "enc2utf8"
[139] "UseMethod"         ".subset"           "proc.time"
[142] "enc2native"        "repeat"            ":::"
[145] "<<-"               "@<-"               "missing"
[148] "nargs"             "isS4"              ".isMethodsDispatchOn"
[151] "forceAndCall"      "Exec"              ".primTrace"
[154] "storage.mode<-"    ".Call"             "unclass"
[157] "gc.time"           ".subset2"          "environment<-"
[160] "emptyenv"          "seq_len"           ".External2"
[163] "is.symbol"         "class"             "on.exit"
[166] "is.raw"            "for"               "is.complex"
[169] "list"              "invisible"         "is.character"
[172] "oldClass<-"        "is.environment"    "attributes"
[175] "break"             "return"            "attr"
[178] "tracemem"          "next"              ".Call.graphics"
[181] "standardGeneric"   "is.atomic"         "retracemem"
[184] "expression"        "is.expression"     "call"
[187] "is.object"         "pos.to.env"        "attributes<-"
[190] ".primUntrace"      "...length"         "Tailcall"
[193] ".External"         "oldClass"          ".Internal"
[196] ".Fortran"          "browser"           "is.double"
[199] ".class2"           "while"             "nzchar"
[202] "is.list"           "lazyLoadDBfetch"   "unCfillPOSIXlt"
[205] "...elt"            "...names"          "is.integer"
[208] "is.function"       "is.recursive"      "seq_along"
[211] "unlist"            "as.vector"         "lengths"
```

12.2. Präzedenz

Eine wichtige Eigenschaft bei der Benutzung von Operatoren ist ihre durch die jeweilige Programmiersprache festgelegte *Präzedenz*. Dabei handelt es sich um von den Programmiersprachenentwicklern festgelegte Regeln zur Rangfolge von Operatoren. Aus der Mathematik ist man insbesondere die Präzedenzregel "Punktrechnung geht vor Strichrechnung" gewohnt. Diese besagt, dass in Ausdrücken, in denen sowohl Produkte oder Divisionen als auch Summen oder Differenzen vorkommen, die Produkte oder Divisionen als Erstes ausgeführt werden und ihre Ergebnisse dann als Zweites in die Summen- oder Differenzbildung eingehen. So ergibt sich zum Beispiel

$$2 \cdot 5 - 3 = 10 - 3 = 7 \tag{12.1}$$

und nicht etwa

$$2 \cdot 5 - 3 \neq 2 \cdot 2 = 4. \tag{12.2}$$

Wir setzen als bekannt voraus, dass die Präzedenzregeln durch Klammerbildung betont oder überschrieben werden können. So ist beispielsweise der Ausdruck in Gleichung 12.1 äquivalent zu

$$(2 \cdot 5) - 3 = 10 - 3 = 7 \tag{12.3}$$

und die in Gleichung 12.2 beabsichtigte Rechnung kann durch Klammersetzung als

$$2 \cdot (5 - 3) = 2 \cdot 2 = 4 \tag{12.4}$$

richtiggestellt werden. Diese vertrauten Rechenregeln und ihre Überschreibung durch Klammern finden sich in **R** entsprechend implementiert:

```
2*5 - 3
```

```
[1] 7
```

```
2*(5 - 3)
```

```
[1] 4
```

Eine weitere als bekannt vorausgesetzte Präzedenzregel ist, dass Potenzen eine höhere Präzedenz als Produkte oder Divisionen und Summen oder Differenzen haben. Es ergibt sich also beispielsweise

$$2^3 + 3 = (2 \cdot 2 \cdot 2) + 3 = 8 + 3 = 11 \tag{12.5}$$

und nicht etwa

$$2^3 + 3 \neq 2^{3+3} = 2^6 = 64. \tag{12.6}$$

Entsprechend gelten in **R**

```
2^3 + 3
```

```
[1] 11
```

```
2^(3 + 3)
```

```
[1] 64
```

Eine wichtige Besonderheit hinsichtlich der Präzedenzregeln in **R** ist, dass auch *unäre Vorzeichen*, also Vorzeichen, die eine Zahl als eine negative Zahl identifizieren, in den Bereich der Operatorpräzedenz fallen. Wenn man auch geneigt sein könnte, einen Ausdruck der Form -1^2 als $(-1)^2 = 1$ zu interpretieren, so folgt **R** dennoch der Regel, dass in -1^2 zunächst die Potenz und dann das Vorzeichen ausgewertet werden, dass also $-1^2 = -(1^2) = -1$ gilt:

```
-1^2                                    # -(1^2) = -1
```

```
[1] -1
```

```
(-1)^2                                  # (-1)^2 = 1
```

```
[1] 1
```

Weiterhin werden in **R** Potenzen von rechts nach links abgearbeitet, Produkte, Divisionen, Summen und Differenzen dagegen von links nach rechts. So gelten beispielsweise

```
2^2^3                                   # 2^(2^3) = 2^8 = 256
```

```
[1] 256
```

```
(2^2)^3                                 # (2^2)^3 = 4^3 = 64
```

```
[1] 64
```

aber

```
2+3/4*5                                 # 2+(3/4)*5 = 2+(0.75*5) = 2+3.75 = 5.75
```

```
[1] 5.75
```

```
2+3/(4*5)                               # 2+3/(4*5) = 2+3/20 = 2+0.15 = 2.15
```

```
[1] 2.15
```

Generell gilt, dass man in der Programmierung Präzedenzregeln nicht raten sollte oder versuchen sollte, sie logisch herzuleiten. Ebenso wenig sollte man darauf vertrauen, dass die Programmiersprachenentwickler die Präzedenzregeln vermutlich gemäß dem eigenen Kenntnisstand implementiert haben werden. Stattdessen sollte man Berechnungen immer kritisch überprüfen und zur Sicherheit die beabsichtigte Rechnung lieber einmal zu viel als einmal zu wenig mit Klammern betonen.

Neben den hier betrachteten Präzedenzregeln für die Grundrechenarten gibt es in **R** eine ganze Reihe weiterer Regeln zum Umgang mit vielen weiteren Operatoren, von denen wir bisher nur sehr wenige kennengelernt haben. Wenn man sich beim Erlernen einer Programmiersprache mit einem neuen Operator vertraut macht, sollte man also für sich auch unbedingt die Präzedenz dieses Operators klären. Der in Abbildung 12.1 gezeigte und mit dem Befehl `?Syntax` aufzurufende Text der **R**-Dokumentation diskutiert die in **R** geltenden Präzedenzregeln vollumfänglich und sollte bei der Arbeit mit **R** häufig konsultiert werden.

12.3. Variablen

In der Programmierung sind *Variablen* abstrakte Behälter für Daten, deren Inhalt im Verlauf einer Programmausführung geändert werden kann. Variablen werden im Programmcode mit Namen bezeichnet und besitzen bei Programmausführung eine Adresse im Arbeitsspeicher. Variablen können verschiedenen *Typs* sein. Das heißt, dass Variablen unterschiedliche Arten von Daten, und nur diese, repräsentieren. In traditionellen Programmiersprachen wird der Typ einer Variablen explizit *deklariert*. Dabei wird zu Beginn der Programmausführung festgelegt, welche Art von Daten eine bestimmte Variable repräsentieren kann. Die Deklaration einer Variablen `A`, die zum Beispiel ganze Zahlen und eben nur diese repräsentieren kann, hat etwa die Form

Operator Syntax and Precedence

Description

Outlines R syntax and gives the precedence of operators.

Details

The following unary and binary operators are defined. They are listed in precedence groups, from highest to lowest.

`:: :::`	access variables in a namespace
`$ @`	component / slot extraction
`[ [[`	indexing
`^`	exponentiation (right to left)
`- +`	unary minus and plus
`:`	sequence operator
`%any% |>`	special operators (including %% and %/%)
`* /`	multiply, divide
`+ -`	(binary) add, subtract
`< > <= >= == !=`	ordering and comparison
`!`	negation
`& &&`	and
`| ||`	or
`~`	as in formulae
`-> ->>`	rightwards assignment
`<- <<-`	assignment (right to left)
`=`	assignment (right to left)
`?`	help (unary and binary)

Within an expression operators of equal precedence are evaluated from left to right except where indicated. (Note that = is not necessarily an operator.)

Abbildung 12.1. Präzedenzregeln in **R**.

```
VAR A : INTEGER                                 # Integer-Variable A (ganze Zahl)
```

In der Folge kann der Variablen `A` dann ein Wert vom Typ ganze Zahl zugewiesen werden, beispielsweise in der Form

```
A := 1                                          # Der Variablen A den Wert 1 zuweisen
```

In einer 4GL-Sprache wie **R** wird der Variablentyp üblicherweise direkt durch eine Initialisierungsanweisung festgelegt. So deklariert folgender **R**-Code die Variable `a` gleichzeitig als vom Typ `double` (Dezimalzahl) mit dem Wert `1`:

```
a = 1                                           # double-Variable a mit Wert 1
```

In den allermeisten Programmiersprachen ist der Zuweisungsbefehl `=`. **R** ist dahingehend besonders, dass es mit `<-` und `->` zusätzliche Zuweisungsbefehle erlaubt: `<-` weist von rechts nach links zu, `->` von links nach rechts. Die übliche Zuweisung von rechts nach links wird auch durch `=` erreicht. Offiziell empfohlener Zuweisungsbefehl für **R** ist `<-`. Dies ist jedoch sehr idiosynkratisch und wir benutzen weitestgehend `=` wie in jeder anderen Programmiersprache. Ein erstes Beispiel soll den Umgang mit Variablen verdeutlichen.

Beispiel 12.1 (Variablen in einer Textaufgabe)**.** Wir betrachten folgende Aufgabe:

"Lina geht ins Schreibwarengeschäft und kauft vier Hefte und zwei Stifte. Ein Heft koste 1 Euro und ein Stift koste 3 Euro. Wie viele Dinge kauft Lina insgesamt und wie viel Euro muss Lina insgesamt bezahlen?"

Um die Aufgabe zu lösen, definieren wir zunächst die Variablen `anzahl_hefte` und `anzahl_stifte` und weisen ihnen dabei ihre jeweiligen Werte aus der Aufgabe zu.

```
anzahl_hefte        = 4
anzahl_stifte       = 2
```

Nach Zuweisung existieren die Variablen mit den ihnen zugewiesenen Werten nun im Arbeitsspeicher, dem sogenannten *Workspace*. Der Befehl `ls()` zeigt die existierenden benutzbaren Variablen im Arbeitsspeicher an.

```
ls()
```

```
[1] "anzahl_hefte"    "anzahl_stifte"   "pandoc_dir"      "quarto_bin_path"
```

Entscheidend ist, dass die Variablennamen jetzt wie Zahlen in Berechnungen genutzt werden können. `print()` gibt dabei Variablenwerte in einem **R**-Terminal aus:

```
anzahl_dinge = anzahl_hefte + anzahl_stifte
print(anzahl_dinge)
```

```
[1] 6
```

Um den Gesamtpreis zu berechnen, definieren wir als Nächstes die Variablen `preis_heft` und `preis_stift` anhand der Aufgabenspezifikation.

```
preis_heft        = 1
preis_stift       = 3                       # Preis pro Stift in Euro
```

Der Gesamtpreis berechnet sich dann wie folgt.

```
gesamtpreis = anzahl_hefte*preis_heft + anzahl_stifte*preis_stift
print(gesamtpreis)
```

```
[1] 10
```

Variablen im Workspace können auch wieder gelöscht werden. `rm()` (remove) erlaubt das Löschen einzelner Variablen.

```
rm(gesamtpreis)
ls()
```

```
[1] "anzahl_dinge"    "anzahl_hefte"    "anzahl_stifte"   "pandoc_dir"
[5] "preis_heft"      "preis_stift"     "quarto_bin_path"
```

`rm(list=ls())` löscht alle Variablen.

```
rm(list = ls())
ls()
```

```
character(0)
```

△

Variablennamen

Prinzipiell ist man in der Wahl der Namen für Variablen mit kleineren Einschränkungen frei. Zulässige Variablennamen in **R**

- bestehen aus Buchstaben, Zahlen, Punkten (.) und Unterstrichen (_),
- beginnen mit einem Buchstaben oder einem Punkt, dann allerdings nicht gefolgt von einer Zahl,
- dürfen keine in **R** schon belegten Ausdrücke wie `for`, `if`, `NaN`, … sein.

Hilfestellung zu den Einschränkungen von Variablennamen gibt `?reserved`. Eine Funktion, um aus beliebigen Vorschlägen einen syntaktisch zulässigen Variablennamen zu generieren, ist `make.names()`. Ihre Hilfe beschreibt auch die hier skizzierten Regeln zur Variablenbenennung in weiteren Details. Generell sind sinnvolle Variablen kurz, um im Code Platz zu sparen, und aussagekräftig, um das menschliche Verständnis des Codes zu erhöhen. Meist bestehen Variablen nur aus Kleinbuchstaben und Unterstrichen.

Variablenrepräsentation

Wir wollen uns noch etwas genauer mit dem Verhältnis von Variablennamen (Bezeichnern) und Variableninhalten (Objekten im Arbeitsspeicher) befassen. Die folgenden Begriffe und

Zusammenhänge sind insbesondere dann wichtig, wenn Berechnungen an die Grenzen des verfügbaren Arbeitsspeichers gelangen und optimiert werden müssen.

Wir beginnen mit dem Begriff des *Bindings*. Dazu betrachten wir zunächst die folgende Variableninitialisierung:

```
x = 1
```

Intuitiv wird durch dieses Statement eine Variable namens `x` mit dem Wert `1` erzeugt. Auf technischer Ebene geschehen dabei zwei Dinge (vgl. Abbildung 12.2):

1. **R** erzeugt ein Objekt (Vektor mit Wert 1) mit Arbeitsspeicheradresse `lobstr::obj_addr(x)`.
2. **R** verbindet dieses Objekt mit dem Namen `x` (*binding*), der das Objekt im Arbeitsspeicher referenziert.

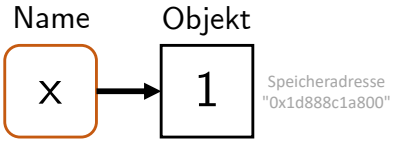


Abbildung 12.2. Binding eines Namens mit einem Objekt im Arbeitsspeicher.

Betrachten wir nun folgendes Statement:

```
y = x
```

Intuitiv wird dabei eine Variable, genannt `y`, mit Wert gleich dem Wert von `x` erzeugt. Auf technischer Ebene wird dabei ein neuer Name `y` erzeugt, der dasselbe Objekt im Arbeitsspeicher referenziert wie `x` (vgl. Abbildung 12.3).

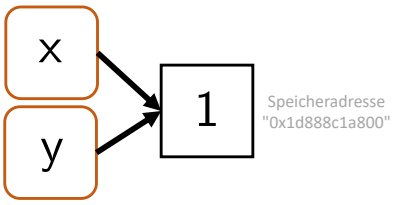


Abbildung 12.3. Binding zweier Namen mit einem Objekt im Arbeitsspeicher.

Man kann sich mithilfe von `lobstr::obj_addr(x)` und `lobstr::obj_addr(y)` davon überzeugen, dass die Adressen des Objekts im Arbeitsspeicher identisch sind:

```
print(lobstr::obj_addr(x))
```

```
[1] "0x13315453e08"
```

```
print(lobstr::obj_addr(y))
```

```
[1] "0x13315453e08"
```

Das betreffende Objekt wird also bei Zuordnung zu `y` *nicht* kopiert. Dadurch wird Arbeitsspeicher eingespart.

Weiterhin nutzt **R** das sogenannte *Copy-on-modify*-Prinzip. Dieses Prinzip besagt, dass ein Objekt im Arbeitsspeicher kopiert wird und eine neue Adresse erhält, sobald es modifiziert wird. Das ursprüngliche Objekt im Arbeitsspeicher bleibt dabei unverändert. Abbildung 12.4 und folgender **R**-Code verdeutlichen zunächst das *Copy-on-modify*-Prinzip:

```
x = 1                                   # Neues Objekt; x verweist z. B. auf 0x74b
y = x                                   # y verweist ebenfalls auf 0x74b
y = 3                                   # Änderung erzeugt Kopie, z. B. bei 0xcd2
y                                       # y referenziert jetzt (0xcd2)
```

```
[1] 3
```

```
x                                       # x referenziert weiterhin (0x74b)
```

```
[1] 1
```

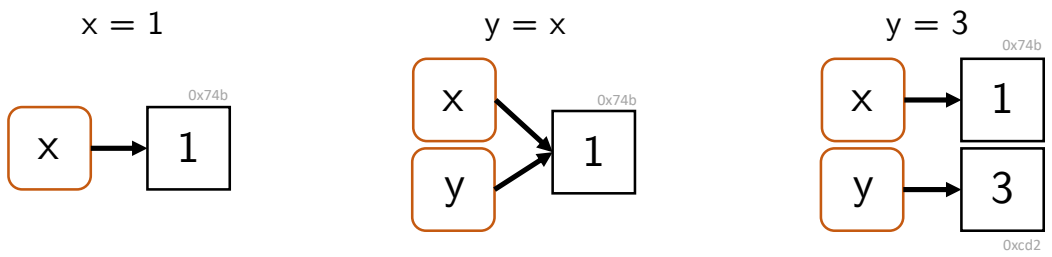


Abbildung 12.4. Copy-on-modify. Erst nach der Änderung des dem Bezeichner `y` zugeordneten Werts wird dieser im Arbeitsspeicher kopiert.

Die Tatsache, dass Objekte bei Veränderung im Arbeitsspeicher kopiert werden, die ursprünglichen Objekte aber im Prinzip unverändert erhalten bleiben, wird auch als die *Immutability* von Objekten in **R** bezeichnet. Allerdings greift die Immutability von Objekten in **R** nicht besonders weit, wie folgendes Beispiel zeigt. Dabei wird zunächst ein Objekt einer `1` im Arbeitsspeicher erzeugt, das mit dem Variablennamen `x` referenziert werden kann. Per *Indexing* (vgl. Kapitel 13) wird das Objekt dann bei einer beabsichtigten Modifikation im Arbeitsspeicher neu adressiert.

```
x   = 1                                 # Neues Objekt; x verweist auf seine Adresse
print(lobstr::obj_addr(x))              # Speicheradresse des Objekts
```

```
[1] "0x13312a098c0"
```

```
x[1] = 2                                # Objekt verändert
print(lobstr::obj_addr(x))              # neue Speicheradresse
```

```
[1] "0x13312aa28c8"
```

Das Copy-on-modify-Prinzip gilt auch in umgekehrter Reihenfolge. Das heißt, wenn ein Objekt, auf das ein weiterer Variablenname zeigt, verändert wird, so ändert sich das ursprünglich referenzierte Objekt nicht. Folgender **R**-Code mag dies verdeutlichen.

```
x = 1                                   # Neues Objekt; x verweist z. B. auf 0x74b
y = x                                   # y verweist ebenfalls auf 0x74b
x = 3                                   # Neues Objekt; x verweist nun auf 0x2a08
y                                       # y verweist weiter auf 0x74b
```

```
[1] 1
```

Schließlich ist auch ein *Unbinding* von Objekten im Arbeitsspeicher möglich, beispielsweise als Folge folgender **R**-Befehle (vgl. Abbildung 12.5):

```
x = 1                                   # x referenziert Objekt (0x74b)
x = "a"                                 # x: 0x2a08; 0x74b jetzt ohne Referenz
```

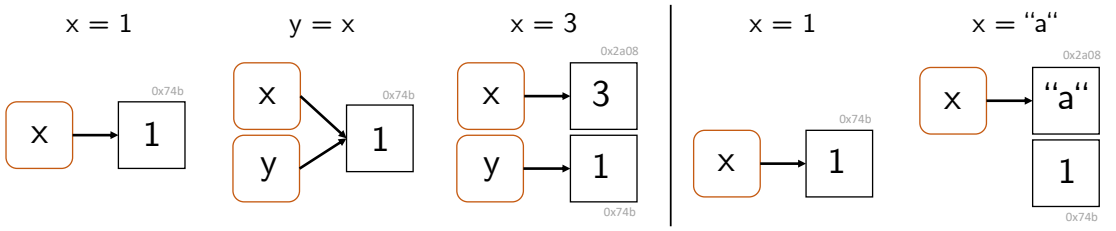


Abbildung 12.5. Unbinding. Es verbleibt belegter Arbeitsspeicher, der durch keinen Bezeichner referenziert wird.

Das Löschen von nicht referenzierten Objekten im Arbeitsspeicher wird als *garbage collection* bezeichnet. **R** löscht nicht referenzierte Objekte im Arbeitsspeicher automatisch, allerdings meist erst dann, wenn der Speicher benötigt wird. Generell funktioniert dies aber gut und es ist in der Regel nicht nötig, aktiv die von **R** bereitgestellte Funktion `gc()` zur Garbage Collection zu benutzen.

Repräsentation fehlender Werte

In der datenanalytischen Programmierung hat man es oft mit fehlenden Werten zu tun, beispielsweise, wenn eine experimentelle Messung bei einer Versuchsperson abgebrochen werden musste. Zur Repräsentation fehlender Werte nutzt **R** `NA` (*not available*). Versucht man mit `NA` zu rechnen, so ergibt dies meist wieder `NA`:

```
3 * NA                                  # Multiplikation eines NA-Wertes ergibt NA
```

```
[1] NA
```

```
NA < 2                                  # Vergleich mit NA ergibt NA
```

```
[1] NA
```

```
NA^0                                    # NA hoch 0 ergibt 1
```

```
[1] 1
```

```
NA & FALSE                                  # NA UND FALSE ergibt FALSE
```

```
[1] FALSE
```

Auf `NA` testet man mit `is.na()`:

```
x = c(NA, 5, NA, 10)                        # Vektor mit NAs
x == NA                                     # Ungeeigneter NA-Test: 5 == NA ergibt NA
```

```
[1] NA NA NA NA
```

```
is.na(x)                                    # Logisches Testen auf NA
```

```
[1]  TRUE FALSE  TRUE FALSE
```

Neben `NA` besitzt **R** mit `NaN` auch eine Möglichkeit zur Darstellung mathematisch nicht definierter Werte. Im Gegensatz zu `NA` ist `NaN` immer vom numerischen Typ. Die Ergebnisse beim Rechnen mit `NaN` ähneln denen mit `NA`.

```
3 * NaN                                     # Multiplikation eines NaN-Wertes ergibt NaN
```

```
[1] NaN
```

```
NaN < 2                                     # Vergleich mit NaN ergibt NA
```

```
[1] NA
```

```
NaN^0                                       # NaN hoch 0 ergibt 1
```

```
[1] 1
```

```
NaN & FALSE                                 # NaN UND FALSE ergibt FALSE
```

```
[1] FALSE
```

Auf `NaN` testet man mit `is.nan()`:

```
x = c(NaN, 5, NaN, 10)                      # Vektor mit NaNs
is.nan(x)                                   # Logisches Testen auf NaN
```

13. Datenstrukturen

In jeder Programmiersprache gibt es abstrakte Behälter, um verschiedene Arten von Daten zu repräsentieren und mit ihnen zu arbeiten. In klassischen 3GL-Programmiersprachen unterscheidet man *fundamentale*, *zusammengesetzte* und *selbstdefinierte* Datenstrukturen.

Fundamentale Datenstrukturen sind in der Programmiersprache vordefiniert. Typische Beispiele sind Behälter für logische Werte (`TRUE`, `FALSE`), ganze Zahlen (`int8`), die z. B. die 256 Werte von -128 bis 127 repräsentieren, Gleitkommazahlen (`single`, `double`) mit unterschiedlicher Genauigkeit oder Schriftzeichen (`a`, `b`), die oft in Anführungszeichen gesetzt werden. Mit diesen grundlegenden Datentypen sind typischerweise passende Operationen verknüpft, wie `AND`/`OR` für logische Werte, `+`, `-` für Ganzzahlen, `+`, `-`, `*` und `/` für Gleitkommazahlen oder die Konkatenation für Zeichen.

Zusammengesetzte Datenstrukturen sind ebenfalls vordefiniert und dienen dazu, mehrere Variablen gleichen Typs zusammenzufassen. Dazu zählen in **R** zum Beispiel Vektoren, Listen, Arrays, Matrizen und Dataframes. Auch für zusammengesetzte Strukturen existieren spezifische Operationen, wie die Vektorindizierung oder die Matrixmultiplikation.

Schließlich lassen sich in 3GL-Programmiersprachen auch *selbstdefinierte Datenstrukturen* erstellen. Sie ermöglichen die Anpassung der Programmumgebung an spezifische Anwendungsfälle und sind daher besonders praxisrelevant. In der Regel werden sie aus vordefinierten Strukturen zusammengesetzt und können im Rahmen objektorientierter Programmierung auch mit eigenen Operationen assoziiert sein.

Wenn man eine Programmiersprache erlernt, ist ein erster wichtiger Schritt, sich mit ihren Datenstrukturen zumindest rudimentär vertraut zu machen. Feinheiten in der Datenstrukturrepräsentation wird man dann in der täglichen praktischen Arbeit mit der Programmiersprache kennenlernen. Um sich also mit den Datenstrukturen einer Programmiersprache vertraut zu machen, bieten sich folgende Leitfragen an:

Fundamentale Datenstrukturen

- Welche fundamentalen Datenstrukturen bietet die Sprache an?
- Welche Operationen darauf sind bereits definiert?
- Wie lautet die Syntax zur Definition einer Variablen eines fundamentalen Datentyps?
- Wie lautet die Syntax, um vordefinierte Operationen aufzurufen?

Zusammengesetzte Datenstrukturen

- Welche Container und zugehörigen Operationen bietet die Programmiersprache?
- Wie lautet die Syntax zum Umgang mit einem Container?

Selbstdefinierte Datenstrukturen

- Wie erzeugt man selbstdefinierte Datenstrukturen und zugehörige Operationen?
- Wie lautet die Syntax zum Umgang mit einer selbstdefinierten Datenstruktur?

13.1. Datenstrukturen in R

Als 4GL-Sprache geht **R** in seinen Datenstrukturen über die klassischen Datenstrukturen von 3GL-Sprachen hinaus. In **R** ist zunächst einmal alles ein *Objekt*. Egal, ob es sich um einen einzelnen Wert, einen Vektor, eine Funktion oder eine komplexe Datenstruktur handelt – alles wird von **R** als Objekt repräsentiert. Allgemein bezeichnet der Begriff des *Objekts* die Möglichkeit, in einer Sinneinheit sowohl Daten als auch Funktionalität zu repräsentieren. Wir sind hier allerdings primär nur an der Datenrepräsentation interessiert.

Generell unterscheidet man in **R** zwischen *atomaren* Objekten und *rekursiven* Objekten. *Atomare Objekte* bestehen aus Komponenten gleichen Datentyps. Typische Beispiele sind numerische Vektoren, logische Vektoren oder Zeichenketten. *Rekursive Objekte* hingegen können Komponenten unterschiedlichen Typs enthalten. Dazu gehören insbesondere Listen und Dataframes, die es erlauben, heterogene Daten zusammenzufassen.

Jedes **R**-Objekt lässt sich eindeutig beschreiben durch drei zentrale Eigenschaften: seinen *Modus*, seine *Länge* und optional durch weitere *Attribute*. Der *Modus* eines Objekts gibt den grundlegenden Datentyp eines Objekts an und ist eng mit dem *Typ* und der *Klasse* eines Objekts verwandt, wie im Folgenden erläutert. Neben dem Modus besitzt jedes Objekt eine *Länge*, die angibt, wie viele Elemente es enthält. Bei einem Vektor ist die Länge zum Beispiel die Anzahl der enthaltenen Werte, bei einer Liste die Zahl ihrer Komponenten. Darüber hinaus können Objekte in **R** mit zusätzlichen *Attributen* versehen sein. Attribute sind Metadaten, die zusätzliche Informationen über das Objekt bereitstellen, etwa Namen der Elemente (`names`), Dimensionen (`dim`) für Matrizen und Arrays oder Klasseninformationen (`class`), die für das objektorientierte Programmieren in **R** relevant sind.

Modus, Typ und Klasse

Die Klassifizierung von Datenstrukturen in **R** ist etwas komplex, da nebeneinander die Begriffe des *Modus*, des *Typs* und der *Klasse* eines Objekts existieren. In der praktischen Anwendung sind die Feinheiten dieser Klassifizierung meist nicht von Belang, außerdem sind der Modus, Typ und die Klasse eines Objekts auch oft identisch.

Grob gesagt entspricht der *Modus* der grundlegenden Natur eines Objekts und ist insbesondere so gewählt, dass eine hohe Kompatibilität zum Datenstrukturklassifikationssystem von **S** (Becker et al. (1988)) besteht. Beispiele für Modi sind `numeric`, `character`, `logical` oder `list`. Der Modus eines Objektes kann mit der Funktion `mode()` abgerufen werden, wie folgendes Beispiel zeigt.

```
mode(42)                                # numeric
```

```
[1] "numeric"
```

```
mode(1L)                                # numeric
```

```
[1] "numeric"
```

```
mode("hallo")                           # character
```

```
[1] "character"
```

```
mode(TRUE)                              # logical
```

```
[1] "logical"
```

```
mode(list(1, 2, 3))                     # list
```

```
[1] "list"
```

```
mode(factor(c("a", "b")))               # R-Faktor => numeric
```

```
[1] "numeric"
```

```
mode(Sys.Date())                        # R-Datum => numeric
```

```
[1] "numeric"
```

```
mode(lm(mpg ~ wt, data=mtcars))         # lineares R-Modell => list
```

```
[1] "list"
```

Etwas näher an der internen Repräsentation eines Objekts im Speicher und damit etwas technischerer Natur ist der *Typ* eines **R**-Objekts. Dies wird insbesondere hinsichtlich Objekten von Modus `numeric` deutlich. Hier gibt es die klassischen 3GL-Typenunterscheidungen `integer` oder `double`. Ein anderes Beispiel ist der Modus *Faktor*. Wie wir an späterer Stelle sehen werden, sehen Faktoren in **R** für den Nutzer aus wie kategorische Daten, oft von Schriftzeichenart. Ihr Modus ist allerdings `numeric` und ihr Typ `integer`. Dies hängt damit zusammen, dass Faktoren in **R** oft dazu genutzt werden, auf der Benutzerebene experimentelle Bedingungen zu spezifizieren, die meist aussagekräftige Namen wie "Treatment" oder "Kontrolle" haben, in der Datenanalyse aber durch mathematische Matrizen mit ganzzahligen Einträgen repräsentiert werden. Der Typ eines Objektes kann mit der Funktion `typeof()` abgerufen werden, wie folgendes Beispiel zeigt. Man beachte die Gemeinsamkeiten und Unterschiede zu den oben aufgerufenen Modi der gleichen Objekte.

```
typeof(42)                              # double
```

```
[1] "double"
```

```
typeof(1L)                              # integer
```

```
[1] "integer"
```

```
typeof("hallo")                         # character
```

```
[1] "character"
```

```
typeof(TRUE)                                # logical
```

```
[1] "logical"
```

```
typeof(list(1,2,3))                         # list
```

```
[1] "list"
```

```
typeof(factor(c("a", "b")))                 # R-Faktor => integer
```

```
[1] "integer"
```

```
typeof(Sys.Date())                          # R-Datum => double
```

```
[1] "double"
```

```
typeof(lm(mpg ~ wt, data=mtcars))           # lineares R-Modell = list
```

```
[1] "list"
```

Die Klasse eines Objektes schließlich spezifiziert die Art eines Objektes aus der Perspektive der objekt-orientierten Programmierung in **R**. Dabei ist es für ein Objekt insbesondere relevant, wie generische Funktionen wie z. B. `print()` oder `summary()` mit dem Objekt umgehen. Im Gegensatz zu Modi und Typen können Programmierende die Klasse von Objekten selbst festlegen und so generische Funktionen entwickeln, die auf viele Objektarten anwendbar sind und trotz ihres gleichen Namens mit unterschiedlichen Objekten unterschiedliche Operationen ausführen. Die Klasse eines Objektes kann mit der Funktion `class()` abgerufen werden, wie folgendes Beispiel zeigt. Man beachte die Gemeinsamkeiten und Unterschiede zu den oben aufgerufenen Modi und Typen der gleichen Objekte.

```
class(42)                                   # numeric
```

```
[1] "numeric"
```

```
class(1L)                                   # integer
```

```
[1] "integer"
```

```
class("hallo")                              # character
```

```
[1] "character"
```

```
class(TRUE)                                 # logical
```

```
[1] "logical"
```

```
class(list(1,2,3))                      # list
```

```
[1] "list"
```

```
class(factor(c("a", "b")))              # R-Faktor => "factor"
```

```
[1] "factor"
```

```
class(Sys.Date())                       # R-Datum => "Date"
```

```
[1] "Date"
```

```
class(lm(mpg ~ wt, data=mtcars))        # lineares R-Modell => "lm"
```

```
[1] "lm"
```

Zusammengefasst lässt sich festhalten: Der Modus beschreibt die allgemeine Art eines Objekts, der Typ beschreibt seine interne, technische Speicherung und die Klasse definiert die Sichtweise von **R** für die funktionale Verarbeitung des Objekts. Für viele Objekte stimmen diese drei Begriffe weitgehend überein, aber bei speziellen Objekten wie Faktoren, Datumswerten oder benutzerdefinierten Objekten unterscheiden sie sich.

14. Vektoren

In diesem Abschnitt wollen wir nun mit den **R**-Vektoren eine erste grundlegende Datenstruktur genauer kennenlernen. Viele Prinzipien, die am Beispiel von Vektoren erläutert werden können, übertragen sich sinngemäß auf komplexere Datenstrukturen in **R**, sodass ein kompetenter Umgang auch mit der hier betrachteten basalen Datenstruktur im Anwendungskontext unverzichtbar ist. Es sei angemerkt, dass sich der Begriff des *Vektors* in diesem Abschnitt streng auf die entsprechende **R**-Datenstruktur, nicht aber auf das gleichnamige mathematische Objekt bezieht. Auch wenn **R**-Vektoren in manchen Eigenschaften ihrem mathematischen Pendant ähneln und bestimmte Operationen zwischen **R**-Vektoren Operationen zwischen den entsprechenden mathematischen Objekten abbilden können, so haben Vektoren in der imperativen Programmierung oft viel mehr und andere Eigenschaften als die entsprechenden mathematischen Objekte.

Allgemein betrachten wir bei der Diskussion einer Datenstruktur immer zunächst, wie sie mithilfe von **R**-Code *erzeugt* wird, durch welche Eigenschaften sie *charakterisiert* ist, wie einzelne Elemente der Datenstruktur *indiziert* und bearbeitet werden können und welche *arithmetischen Operationen* für die Datenstruktur zulässig sind. Schließlich betrachten wir eventuelle weitere Besonderheiten der Datenstruktur. Im Kontext von **R**-Vektoren sind dies beispielsweise die Begriffe der *Datentypangleichung (Coercion)*, des *Recyclings* oder die Repräsentation fehlender Werte in Datensätzen.

R-Vektoren sind geordnete Folgen von Datenwerten. Die einzelnen Datenwerte eines Vektors heißen *Elemente* des Vektors. Vektoren, deren Elemente alle vom gleichen Datentyp sind, heißen *atomar*. Mit dem Begriff *Vektor* soll hier immer ein atomarer Vektor gemeint sein. Die zentralen Datentypen für Vektoren sind die oben eingeführten *numeric* (*double*, *integer*), *logical* und *character*. Abbildung 14.1 zeigt graphische Darstellungen entsprechender Vektoren.

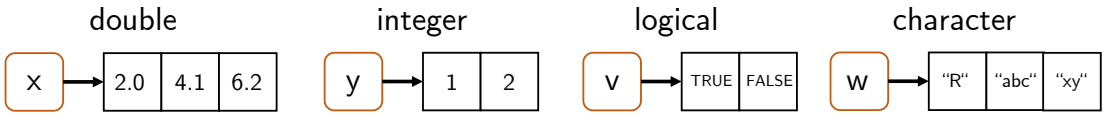


Abbildung 14.1. Vektoren in **R**.

14.1. Erzeugung

Wir betrachten zunächst die Erzeugung einelementiger Vektoren, die auch als *Elementarwerte* bezeichnet werden. Wie alle Datenstrukturen werden auch Elementarwerte durch Zuweisungen der Form

```
Elementarwert = Wert
```

erzeugt. Dabei bestimmt die Spezifikation von `Wert`, welcher Art der erzeugte Elementarwert ist.

Elementarwerte vom Typ `numeric` können durch Zuweisung einer Zahl erzeugt werden. Per Default wird dabei ein Elementarwert vom Typ `double` erzeugt. Die Zahlen können dabei ohne Dezimalstellen, in Dezimalnotation oder in wissenschaftlicher Notation spezifiziert werden. Weitere mögliche Werte zur Erzeugung eines Elementarwerts vom Typ `double` sind `Inf` und `-Inf` für positive und negative Unendlichkeit und `NaN` (Not-a-Number) als Platzhalter für numerische Werte.

```
x = 1                                   # Einelementiger Vektor
typeof(x)                               # vom Typ double
```

```
[1] "double"
```

```
y = 2.1e2                               # Einelementiger Vektor
typeof(y)                               # vom Typ double
```

```
[1] "double"
```

```
z = Inf                                 # Einelementiger Vektor
typeof(z)                               # vom Typ double
```

```
[1] "double"
```

Numerische Elementarwerte vom Typ `integer` werden wie `double` ohne Dezimalstellen erzeugt, gefolgt von einem `L` für `long integer`.

```
x = 1L                                  # Einelementiger Vektor
typeof(x)                               # vom Typ integer
```

```
[1] "integer"
```

```
y = 200L                                # Einelementiger Vektor
typeof(y)                               # vom Typ integer
```

```
[1] "integer"
```

Elementarwerte vom Typ `logical` können durch Zuweisung der logischen Werte `TRUE` oder `FALSE` bzw. abgekürzt `T` oder `F` erzeugt werden.

```
x = TRUE                                # Einelementiger Vektor
typeof(x)                               # vom Typ logical
```

```
[1] "logical"
```

```
y = F                                   # Einelementiger Vektor
typeof(y)                               # vom Typ logical
```

```
[1] "logical"
```

Elementarwerte vom Typ `character` schließlich werden durch die Zuweisung von Werten in Hochkommata (`'a'`) oder Anführungszeichen (`"a"`) erzeugt.

```
x = "a"                                 # Einelementiger Vektor
typeof(x)                               # vom Typ character
```

```
[1] "character"
```

```
y = 'test'                              # Einelementiger Vektor
typeof(y)                               # vom Typ character
```

```
[1] "character"
```

Um nun mehrere Elementarwerte in einem Vektor zusammenzufügen, konkateniert man sie mit der Funktion `c()`. Der Begriff der Konkatenation leitet sich dabei vom Lateinischen *catena* ("die Kette") her.

```
x = c(1,2,3)                            # numerischer Vektor [1,2,3]
s = c("a", "b", "c")                    # Zeichenvektor ["a", "b", "c"]
l = c(TRUE, FALSE)                      # logischer Vektor [TRUE, FALSE]
```

```
x
```

```
[1] 1 2 3
```

```
s
```

```
[1] "a" "b" "c"
```

```
l
```

```
[1]  TRUE FALSE
```

Es können nicht nur Elementarwerte, sondern auch Vektoren mit Elementarwerten oder mit anderen Vektoren konkateniert werden. Mit obigem Vektor `x` erzeugt man beispielsweise folgende Vektoren `y` und `z`:

```
y = c(0,x,4)                            # numerischer Vektor [0,1,2,3,4]
z = c(x,y)                              # numerischer Vektor [1,2,3,0,1,2,3,4]
```

```
y
```

```
[1] 0 1 2 3 4
```

```
z
```

```
[1] 1 2 3 0 1 2 3 4
```

Vektoren müssen nicht mit bereits bestehenden Werten erzeugt werden, sondern es können auch "leere" Vektoren von einem gewünschten Datentyp erzeugt werden. **R** stellt dafür die Funktionen `vector()` sowie `double()`, `integer()`, `logical()` und `character()` bereit. Dies ist potenziell hilfreich, um zu Beginn einer längeren Berechnung bereits Arbeitsspeicher des Computers belegt zu haben, sodass während der Programmausführung nicht nach Arbeitsspeicher gesucht werden muss, was unter Umständen die Programmlaufzeit erhöht.

```
# Erzeugen "leerer" Vektoren mit vector()
v = vector("double",3)                    # double-Vektor [0,0,0]
w = vector("integer",3)                   # integer-Vektor [0,0,0]
l = vector("logical",2)                   # logischer Vektor [FALSE, FALSE]
s = vector("character",4)                 # Zeichenvektor ["", "", "", ""]

# Alternatives Erzeugen "leerer Vektoren"
v = double(3)                             # double-Vektor [0,0,0]
w = integer(3)                            # integer-Vektor [0,0,0]
l = logical(2)                            # logischer Vektor [FALSE, FALSE]
s = character(4)                          # Zeichenvektor ["", "", "", ""]
```

Allerdings sind die so erzeugten "leeren" Vektoren nicht wirklich leer: `v` und `w` bestehen aus Nullen, `l` aus den logischen Werten `FALSE` und `s` aus den Zeichen `""`. Zur Initialisierung von Vektoren als Container und anschließender Befüllung im Rahmen eines Programms sind `vector()`, `double()`, `integer()`, `logical()` und `character()` deshalb nur bedingt geeignet: Übersieht der Code die Befüllung einzelner Einträge, so wird mit den von diesen Funktionen erzeugten Werten gerechnet, was nicht unbedingt beabsichtigt ist. In Kapitel 18 lernen wir eine Methode kennen, um Datenstrukturen zu initialisieren und dabei einigermaßen sicheren Code zu generieren.

Sequenzen

Ein häufiges Hilfsmittel in der Programmierung sind Vektoren, die Folgen von numerischen Werten, z. B. als Repräsentation der Definitionsmengen einer univariaten Funktion, darstellen. **R** stellt zu ihrer Erzeugung den sogenannten *Colonoperator* `:` und die Funktion `seq()` und ihre Varianten zur Verfügung.

Der Colonoperator in der Form `a:b` erzeugt Sequenzen ganzzahliger Schritte zwischen a und b anhand von

$$(s_i)_{i=0,1,2...} \text{ mit } s_i = a + i \text{ für } i = 0, 1, 2, ... \text{ und } s_i \leq b. \tag{14.1}$$

Dabei meint "zwischen `a` und `b`" hier also speziell, dass `a` die erste Zahl der generierten Sequenz ist und `b` die maximal mögliche. Folgende Beispiele verdeutlichen dies:

```
x = 0:5                                   # Sequenz von 0 bis einschließlich 5
y = 1.5:6.1                               # Beginn bei 1.5, Ende bei 5.5 < 6.1
```

```
x
```

```
[1] 0 1 2 3 4 5
```

```
y
```

```
[1] 1.5 2.5 3.5 4.5 5.5
```

Die Funktion `seq()` mit der Syntax `seq(from, to, by)`, wobei `from` den Startwert, `to` den maximalen Endwert und `by` die Schrittweite bezeichnen, bietet weitere Möglichkeiten, Sequenzen nicht nur ganzzahliger Schrittweiten zu erzeugen. Die folgenden Beispiele sollen dies verdeutlichen.

```
x_1  = seq(0,5)                          # wie 0:5
x_2 = seq(0,1,len = 5)                   # 5 Zahlen zwischen 0 (inkl.) und 1 (inkl.)
x_3 = seq(0,2,by = .15)                  # Schrittweite 0.15; von 0 bis höchstens 2
x_4  = seq(1,0,by = -.1)                 # Schrittweite -0.1; von 1 bis 0
```

```
x_1
```

```
[1] 0 1 2 3 4 5
```

```
x_2
```

```
[1] 0.00 0.25 0.50 0.75 1.00
```

```
x_3
```

```
 [1] 0.00 0.15 0.30 0.45 0.60 0.75 0.90 1.05 1.20 1.35 1.50 1.65 1.80 1.95
```

```
x_4
```

```
 [1] 1.0 0.9 0.8 0.7 0.6 0.5 0.4 0.3 0.2 0.1 0.0
```

Die `seq()`-Variante `seq.int()` kann zur Erzeugung von ganzzahligen Folgen genutzt werden und ist unter Umständen schneller als `seq()`. `seq_len()` erzeugt ganzzahlige Folgen einer vorgegebenen Länge, `seq_along()` generiert ganzzahlige Folgen anhand der Einträge eines Vektors.

```
x_1  = seq.int(0,5)                      # wie 0:5, [0,1,2,3,4,5]
x_2 = seq_len(5)                         # Natürliche Zahlen bis 5, [1,2,3,4,5]
x_3 = seq_along(c("a","b"))              # wie seq_len(length(c("a", "b")))
```

```
x_1
```

```
[1] 0 1 2 3 4 5
```

```
x_2
```

```
[1] 1 2 3 4 5
```

```
x_3
```

```
[1] 1 2
```

14.2. Charakterisierung

Zur Charakterisierung von Vektoren stehen mit `length()` und `typeof()` Funktionen bereit, die die Anzahl der Einträge eines Vektors und den Datentyp seiner Einträge ausgeben, wie folgende Beispiele verdeutlichen.

```
x = 0:10                                    # Vektor
length(x)                                   # Anzahl der Elemente des Vektors
```

```
[1] 11
```

```
x = 1:3L                                    # Vektor
typeof(x)                                   # Datentyp des atomaren Vektors
```

```
[1] "integer"
```

```
y = c(T,F,T)                                # Vektor
typeof(y)                                   # Der Datentyp des atomaren Vektors
```

```
[1] "logical"
```

`is.logical()`, `is.double()`, `is.integer()`, `is.character()` testen den Datentyp eines Vektors und geben einen logischen Binärwert aus.

```
is.double(x)                                # Testen obigen Vektors
```

```
[1] FALSE
```

```
is.logical(y)                               # Testen obigen Vektors
```

```
[1] TRUE
```

Datentypangleichung (Coercion)

Versucht man in **R** verschiedene Datentypen in einem Vektor zu konkatenieren, zum Beispiel Elementarwerte vom Typ `numeric`, `character` und `logical`, so erzwingt **R** für den resultierenden Vektor einen einheitlichen Datentyp. Es gilt dabei folgende Rangfolge:

$$\text{character} > \text{double} > \text{integer} > \text{logical}$$

Ist also zum Beispiel einer der Elementarwerte vom Typ `character`, so ist der resultierende Vektor vom Typ `character` und numerische oder logische Werte werden in diesen umgewandelt.

```
x = c(1, "a", TRUE)                         # Konkatenation verschiedener Datentypen
typeof(x)                                   # erzwungener Datentyp
```

```
[1] "character"
```

```
x                                       # Zeichenvektor
```

```
[1] "1"    "a"    "TRUE"
```

Ist dagegen zum Beispiel einer der Elementarwerte vom Typ `integer` und ein anderer vom Typ `logical`, so ist der resultierende Vektor vom Typ `integer` und die logischen Werte werden in ganze Zahlen umgewandelt.

```
x = c(1L, TRUE, FALSE)                  # Gemischte Typen: integer vor logical
typeof(x)                               # Erzeugter Vektor ist vom Typ integer
```

```
[1] "integer"
```

```
x
```

```
[1] 1 1 0
```

Da **R** diese Datentypangleichung implizit vornimmt, sollte man darauf achten, nur Werte gleichen Datentyps mit der Funktion `c()` zu konkatenieren. Um möglichst flexibel zu sein, nimmt **R** auch noch subtilere Datenangleichungen vor. So ist es zum Beispiel möglich, die Summe logischer Werte zu berechnen, wobei die logischen Werte `TRUE` und `FALSE` implizit als die numerischen Werte `1` und `0` behandelt werden.

```
x = c(TRUE, FALSE, TRUE, TRUE)          # logical-Vektor
s = sum(x)                              # Logische Werte als ganze Zahlen summieren
s
```

```
[1] 3
```

Explizite Datentypangleichung erlauben die Funktionen `as.logical()`, `as.integer()`, `as.double()` und `as.character()`. Wendet man diese auf einen Vektor an, so ist der resultierende Vektor vom gewünschten Typ.

```
x = c(0,1,1,0)                          # double-Vektor
typeof(x)
```

```
[1] "double"
```

```
x
```

```
[1] 0 1 1 0
```

```
y = as.logical(x)                       # ... umgewandelt in logical
typeof(y)
```

```
[1] "logical"
```

```
y
```

```
[1] FALSE  TRUE  TRUE FALSE
```

```
z = as.integer(x)
typeof(z)
```

```
[1] "integer"
```

```
z
```

```
[1] 0 1 1 0
```

14.3. Indizierung

In **R** und vielen anderen Programmiersprachen werden einzelne oder mehrere Vektoreinträge durch *Indizierung* adressiert. Indizierung wird dabei auch *indexing*, *subsetting* oder *slicing* genannt. In **R** werden zur Indizierung eckige Klammern der Form [ ] benutzt. **R** nutzt *one-based indexing*, das heißt, der Index des ersten Elements ist `1` (und nicht etwa `0` wie in Python).

Die Indizierung von Vektoreinträgen kann genutzt werden, um einen bestimmten Eintrag eines Vektors in eine andere Datenstruktur zu kopieren:

```
x    = c("a", "b", "c")                    # Zeichenvektor ["a", "b", "c"]
y     = x[2]                               # Kopie von "b" in y
y                                          # Ausgabe
```

```
[1] "b"
```

Ebenso kann die Indizierung von Vektoreinträgen genutzt werden, um einen bestimmten Eintrag des indizierten Vektors zu manipulieren:

```
x    = c("a", "b", "c")                    # Zeichenvektor ["a", "b", "c"]
x[3]  = "d"                                # Änderung von x zu x = ["a", "b", "d"]
x                                          # Ausgabe
```

```
[1] "a" "b" "d"
```

Prinzipiell gilt in **R**, dass die Indizierung

(1) mit einem Vektor positiver Zahlen die entsprechenden Einträge,
(2) mit einem Vektor negativer Zahlen die entsprechenden komplementären Einträge,
(3) mit einem logischen Vektor die Einträge mit dem logischen Wert `TRUE` und
(4) mit einem `character`-Vektor die entsprechend benannten Einträge adressiert.

Wir wollen diese Prinzipien anhand folgender Beispiele verdeutlichen:

(1) Indizierung mit einem Vektor positiver Zahlen

```
x = c(1,4,9,16,25)                      # [1,4,9,16,25] = [1^2, 2^2, 3^2, 4^2, 5^2]
y = x[1:3]                              # Indizes 1 bis 3: [1,4,9]
z = x[c(1,3,5)]                         # Indizes 1, 3 und 5: [1,9,25]
x
```

```
[1]  1  4  9 16 25
```

```
y
```

```
[1] 1 4 9
```

```
z
```

```
[1]  1  9 25
```

(2) Indizierung mit einem Vektor negativer Zahlen

```
x = c(1,4,9,16,25)                      # [1,4,9,16,25] = [1^2, 2^2, 3^2, 4^2, 5^2]
y = x[c(-2,-4)]                         # Ohne Elemente 2 und 4: [1,9,25]
x
```

```
[1]  1  4  9 16 25
```

```
y
```

```
[1]  1  9 25
```

```
z = x[c(-1,2)]                          # Gemischte Vorzeichen ergeben einen Fehler
```

```
Error in `x[c(-1, 2)]`:
! only 0's may be mixed with negative subscripts
```

(3) Indizierung mit einem logischen Vektor

```
x = c(1,4,9,16,25)                      # [1,4,9,16,25] = [1^2, 2^2, 3^2, 4^2, 5^2]
y = x[c(T,T,F,F,T)]                     # TRUE-Komponenten auswählen: [1,4,25]
z = x[x > 5]                            # x > 5 = [F,F,T,T,T], x[x > 5] = [9,16,25]
x
```

```
[1]  1  4  9 16 25
```

```
y
```

```
[1]  1  4 25
```

```
z
```

```
[1]  9 16 25
```

(4) Indizierung mit einem `character`-Vektor

```
x = c(1,4,9,16,25)                    # [1,4,9,16,25] = [1^2, 2^2, 3^2, 4^2, 5^2]
names(x) = c("a","b")                 # Namen: [a, b, NA, NA, NA]
y = x["a"]                            # x["a"] = 1
```

Es bleibt anzumerken, dass **R** eine hohe Flexibilität bei Indizierung aufweist, also oft keine Fehler ausgibt, obwohl eine Indizierung per se keinen Sinn ergibt. So verursachen zum Beispiel Out-of-range-Indizes, also Indizes, die die Anzahl der Einträge eines Vektors überschreiten, keine Fehler, sondern geben `NA` (not available) aus.

```
x = c(1,4,9,16,25)                    # [1,4,9,16,25] = [1^2, 2^2, 3^2, 4^2, 5^2]
y = x[10]                             # x[10] = NA (fehlender Wert)
y
```

```
[1] NA
```

Weiterhin verursachen nichtganzzahlige Indizes keine Fehler, sondern werden durch Abschneiden der Nachkommastellen in Richtung null in ganze Zahlen umgewandelt.

```
y = x[4.9]                            # x[4.9] = x[4] = 16
y
```

```
[1] 16
```

```
z = x[-4.9]                           # x[-4.9] = x[-4] = [1,4,9,25]
z
```

```
[1]  1  4  9 25
```

Leere Indizes schließlich indizieren den gesamten Vektor.

```
y = x[]                               # y = x
```

Die Flexibilität von **R** bei nicht sinnhafter Indizierung hat einerseits den Vorteil, dass Programme seltener mit einem Fehler unterbrochen werden. Auf der anderen Seite hat sie den Nachteil, dass unbeabsichtigte Fehlindizierungen unbemerkt bleiben und Datenanalyseprogramme so zu nicht beabsichtigten Ergebnissen kommen können. Im Umgang mit der Indizierung in **R** ist also ein hohes Maß an Aufmerksamkeit und im Idealfall die Validierung von erstellten Datenanalyseprogrammen anhand simulierter Daten mit bekannten Ergebnissen geboten. Ein ähnliches Maß an Vorsicht ist aufgrund von **R**s *Recycling*-Funktionsweise angezeigt, die wir im nächsten Abschnitt kennenlernen werden.

14.4. Arithmetik numerischer Vektoren

Mit **R**-Vektoren kann man arithmetische Operationen ausführen, das heißt, man kann mit ihnen rechnen. Wir unterscheiden dabei *unäre arithmetische Operationen*, also arithmetische Operationen, die auf einen Vektor angewendet werden, und *binäre arithmetische Operationen*, bei denen zwei Vektoren miteinander verknüpft werden. Allgemein gilt, dass arithmetische Vektoroperatoren in **R** elementweise ausgewertet werden, allerdings sind bei binären Operatoren einige Besonderheiten zu beachten.

Betrachten wir zunächst einige unäre arithmetische Operatoren und die Anwendung von Funktionen auf einen Vektor. In folgendem Beispiel werden die unären Operatoren `-` und `^2` sowie die Funktion `log()` auf einen Vektor `a` angewendet. Die Auswertung der Operatoren bzw. der Funktion geschieht dabei *elementweise*, das heißt, der Operator oder die Funktion wird auf jedes Element des Vektors unabhängig von seinen anderen Elementen angewendet.

```
a   = seq(0,1,len=11)                    # a = [ 0.0 , 0.1 , ..., 0.9 , 1.0 ]
a
```

```
 [1] 0.0 0.1 0.2 0.3 0.4 0.5 0.6 0.7 0.8 0.9 1.0
```

```
b   = -a                                 # b = [-0.0 , -0.1 , ..., -0.9 ,-1.0 ]
b
```

```
 [1]  0.0 -0.1 -0.2 -0.3 -0.4 -0.5 -0.6 -0.7 -0.8 -0.9 -1.0
```

```
v  = a^2                                 # v = [ 0.0^2 , 0.1^2 , ..., 0.9^2 , 1.0^2 ]
v
```

```
 [1] 0.00 0.01 0.04 0.09 0.16 0.25 0.36 0.49 0.64 0.81 1.00
```

```
w   = log(a)                             # [ln(0), ln(0.1), ..., ln(1)]
w
```

```
 [1]       -Inf -2.3025851 -1.6094379 -1.2039728 -0.9162907 -0.6931472
 [7] -0.5108256 -0.3566749 -0.2231436 -0.1053605  0.0000000
```

Die Verknüpfung zweier Vektoren durch binäre arithmetische Operatoren geschieht ebenfalls elementweise. Bei der Verknüpfung zweier Vektoren gleicher Länge werden dabei die Vektoreinträge mit den gleichen Indizes anhand des binären arithmetischen Operators verknüpft. Als Resultat ergibt sich ein Vektor mit der gleichen Länge wie die beiden Ausgangsvektoren.

```
a = c(1,2,3)                             # a = [1,2,3]
b = c(2,1,4)                             # b = [2,1,4]
v = a + b                                # [1+2, 2+1, 3+4] = [3, 3, 7]
v
```

```
[1] 3 3 7
```

```
w = a - b                                    # [1-2, 2-1, 3-4] = [-1, 1, -1]
w
```

```
[1] -1  1 -1
```

```
x = a * b                                    # [1*2, 2*1, 3*4] = [2, 2, 12]
x
```

```
[1]  2  2 12
```

```
y = a / b                                    # [1/2, 2/1, 3/4] = [0.5, 2, 0.75]
y
```

```
[1] 0.50 2.00 0.75
```

Verknüpft man in **R** einen Vektor und einen *Skalar*, also einen Vektor der Länge 1, so erweitert **R** den Skalar auf einen Vektor der gleichen Länge und führt die elementweise Verknüpfung dieser Vektoren aus. Folgende Beispiele verdeutlichen dies.

```
a = c(1,2,3)                                 # a = [1,2,3]
b = 2                                        # b = [2]
v = a + b                                    # [1+2, 2+2, 3+2] = [3, 4, 5]
v
```

```
[1] 3 4 5
```

```
w = a - b                                    # [1-2, 2-2, 3-2] = [-1, 0, 1]
w
```

```
[1] -1  0  1
```

```
x = a * b                                    # [1*2, 2*2, 3*2] = [2, 4, 6]
x
```

```
[1] 2 4 6
```

```
y = a / b                                    # [1/2, 2/2, 3/2] = [0.5, 1, 1.5]
y
```

```
[1] 0.5 1.0 1.5
```

Unter dem Begriff des *Recyclings* erlaubt **R** neben der elementweisen Arithmetik für Vektoren gleicher Länge bzw. für Skalare und Vektoren außerdem auch eine Arithmetik mit Vektoren unterschiedlicher Länge. Dazu werden Elemente des kürzeren von zwei Vektoren zum Aufstocken auf die Länge des längeren Vektors genutzt, also in diesem Sinn *recycled*. Wiederum führt diese Eigenschaft der Vektorarithmetik in **R** dazu, dass Programme seltener mit einem Fehler abbrechen und dass das Recycling unter Umständen in informiert geschriebenem Code elegante Lösungen für Berechnungen anbieten kann. Allerdings hat

es den klaren Nachteil, dass auch unbeabsichtigte Fehlallokationen von Vektoren, beispielsweise durch das Nichtvorhandensein von Datenpunkten, unentdeckt bleiben können. Auch hier ist also bei der Erstellung von Programmen eine hohe Aufmerksamkeit und insbesondere ausführliches Testen angezeigt. Speziell kann man bei Recycling der Vektorarithmetik in **R** zwei Fälle unterscheiden: Ist die Länge des längeren der beiden Vektoren ein ganzzahliges Vielfaches der Länge des kürzeren Vektors, so wird der kürzere Vektor durch die entsprechend häufige Wiederholung seiner Elemente in ihrer originären Reihenfolge expandiert. Folgendes Beispiel soll dies verdeutlichen.

```
x = 1:2                                 # x = [1,2], length(x) = 2
x
```

```
[1] 1 2
```

```
y = 3:6                                 # y = [3,4,5,6], length(y) = 4
y
```

```
[1] 3 4 5 6
```

```
v = x + y                               # v = [1,2,1,2] + [3,4,5,6] = [4,6,6,8]
v
```

```
[1] 4 6 6 8
```

In diesem Sinn ist dann die Arithmetik von Vektoren und Skalaren, also Vektoren der Länge 1, ein Spezialfall dieses Prinzips. Ist die Länge des längeren der beiden Vektoren kein ganzzahliges Vielfaches der Länge des kürzeren Vektors, so werden Elemente des kürzeren Vektors in ihrer originären Reihenfolge so lange zum Auffüllen des kürzeren Vektors genutzt, bis beide Vektoren die gleiche Länge haben. Folgendes Beispiel soll dies verdeutlichen.

```
x = c(1,3,5)                            # x = [1,3,5], length(x) = 3
x
y = c(2,4,6,8,10)                       # y = [2,4,6,8,10], length(y) = 5
y
v = x + y                               # Wiederholtes x + y: [3,7,11,9,13]
v
```

14.5. Attribute

Attribute in **R** sind Metadaten von Objekten in Form von Schlüssel-Wert-Paaren. Generell ruft die Funktion `attributes()` alle Attribute eines Objektes auf. Vektoren haben per se keine Attribute.

```
a = 1:3                                 # ein numerischer Vektor
attributes(a)                           # Aufrufen aller Attribute von a
```

```
NULL
```

Die Funktion `attr()` kann zum Aufrufen und Definieren von Attributen genutzt werden. Folgender Code definiert für den Vektor `a` ein Attribut mit dem Schlüssel (Namen) `"S"` und dem Wert `"W"`.

```
attr(a, "S") = "W"                              # Attribut mit Schlüssel S und Wert W setzen
attr(a, "S")                                    # Attribut S mit Wert W auslesen
```

```
[1] "W"
```

Allerdings werden Attribute bei Operationen oft entfernt.

```
b = a[1]                                        # Erstes Element von a in b kopieren
attributes(b)                                   # Aufrufen aller Attribute von b
```

```
NULL
```

Die Spezifikation des Attributs `names` gibt den Elementen eines Vektors Namen, die zur Indizierung genutzt werden können und die bei Operationen nicht entfernt werden.

```
v = c(x=1,y=2,z=3)                              # Elementnamengeneration bei Vektorerzeugung
v                                               # Vektorausgabe
```

```
x y z
1 2 3
```

Die Indizierung mithilfe von Namen hat folgende Form:

```
v["y"]                                          # Indizierung per Namen
```

```
y
2
```

Im Nachgang der Definition eines Vektors kann die Funktion `names()` genutzt werden, um für die Vektoreinträge Namen zu definieren und diese nachzuschlagen.

```
y = 4:6                                         # Erzeugung eines Vektors
names(y) = c("a","b","c")                       # Definition von Namen
names(y)                                        # Elementnamenaufruf
```

```
[1] "a" "b" "c"
```

Benannte Vektoreinträge können hilfreich sein, wenn der Vektor eine Sinneinheit bildet und zum Beispiel Eigenschaften einer Versuchsperson wie Alter, Größe und Gewicht repräsentiert.

```
p = c(age    = 31,                              # Alter (Jahre)
      height = 198,                             # Größe (cm)
      weight = 75)                              # Gewicht (kg)
p                                               # Vektorausgabe
```

```
age height weight
 31    198     75
```

Allerdings ist die Arbeit mit benannten Vektoreinträgen eher selten. Das Prinzip, Einträge einer Datenstruktur anstelle eines numerischen Indizes mit einer sinntragenden Bezeichnung zu versehen, ist in **R** allerdings nichtsdestotrotz übliche Praxis, wie wir im Umgang mit der zentralen Datenstruktur der Dataframes in Kapitel 16 sehen werden.

15. Matrizen und Arrays

R-Matrizen und Arrays können als höherdimensionale Generalisierungen von **R**-Vektoren verstanden werden. Wie bei den Vektoren ist es wichtig, Matrizen in der Programmierung von ihren gleichnamigen mathematischen Objekten abzugrenzen. So können Matrizen in der Programmierung einfach der tabellarischen Speicherung numerischer Daten dienen, ohne dass dabei das primäre Ziel die Anwendung der mathematischen Matrizenrechnung sein muss. Andersherum bilden die elementweisen arithmetischen Operationen mit Matrizen in der Programmierung in der Mathematik eher sehr spezielle mathematische Operationen wie das Hadamard-Produkt ab. In diesem Abschnitt wollen wir Matrizen und Arrays primär als Datencontainer in der imperativen Programmierung mit **R** untersuchen. Eine Einführung in die Matrizenrechnung mit den gleichen Datenstrukturen gibt Kapitel 9.

15.1. Matrizen

Abstrakt gesprochen sind **R**-Matrizen zweidimensionale, rechteckige Datenstrukturen der Form

$$M = \begin{pmatrix} m_{11} & m_{12} & \cdots & m_{1n_c} \\ m_{21} & m_{22} & \cdots & m_{2n_c} \\ \vdots & \vdots & \ddots & \vdots \\ m_{n_r1} & m_{n_r2} & \cdots & m_{n_rn_c} \end{pmatrix} \tag{15.1}$$

Die Elemente $m_{ij}, i = 1, ..., n_r, j = 1, ..., n_c$ der Matrix sind dabei notwendigerweise vom gleichen Datentyp. In obigem Schema bezeichnet n_r die Anzahl der Zeilen (rows) und n_c die Anzahl der Spalten (columns) der Matrix M. Jedes Element einer Matrix hat damit einen Zeilenindex i und einen Spaltenindex j. Intuitiv sind **R**-Matrizen also numerisch indizierte Tabellen. Formal sind Matrizen in **R** zweidimensional interpretierte atomare Vektoren.

15.1.1. Erzeugung

Zur Erzeugung einer Matrix wird die **R**-Funktion `matrix()` genutzt, die Matrizen mit den Elementen eines Vektors befüllt. Die allgemeine Syntax dieser Funktion ist `M = matrix(v, nrow, ncol, byrow)`, wobei

- `v` einen Vektor der Länge `nrow`· `ncol`,
- `nrow` die gewünschte Zeilenanzahl von `M`,
- `ncol` die gewünschte Spaltenanzahl von `M`,
- die logische Variable `byrow` die Befüllungsordnung von `M`

bezeichnen. Da sich bei gegebener Länge von `v` und gegebener Zeilen- oder Spaltenanzahl die entsprechende Spalten- oder Zeilenanzahl der Matrix ergibt, ist es lediglich nötig, entweder `nrow` oder `ncol` zu spezifizieren, wie folgende Beispiele zeigen.

```
matrix(c(1:12), nrow = 3)                  # 3 x 4-Matrix 1,...,12; spaltenweise
```

```
     [,1] [,2] [,3] [,4]
[1,]    1    4    7   10
[2,]    2    5    8   11
[3,]    3    6    9   12
```

```
matrix(c(1:12), ncol = 4)                  # 3 x 4-Matrix 1,...,12; spaltenweise
```

```
     [,1] [,2] [,3] [,4]
[1,]    1    4    7   10
[2,]    2    5    8   11
[3,]    3    6    9   12
```

```
matrix(c(1:12), nrow = 3, byrow = TRUE)    # 3 x 4-Matrix 1,...,12; zeilenweise
```

```
     [,1] [,2] [,3] [,4]
[1,]    1    2    3    4
[2,]    5    6    7    8
[3,]    9   10   11   12
```

Bestehende Matrizen gleicher Zeilenanzahl können mit der Funktion `cbind()` spaltenweise konkateniert werden.

```
A = matrix(c(1:4) , nrow = 2)              # 2 x 2-Matrix der Zahlen 1,...,4
A
```

```
     [,1] [,2]
[1,]    1    3
[2,]    2    4
```

```
B = matrix(c(5:10), nrow = 2)              # 2 x 3-Matrix der Zahlen 5,...,10
B
```

```
     [,1] [,2] [,3]
[1,]    5    7    9
[2,]    6    8   10
```

```
C = cbind(A,B)                             # spaltenweise Konkatenierung von A und B
C
```

```
     [,1] [,2] [,3] [,4] [,5]
[1,]    1    3    5    7    9
[2,]    2    4    6    8   10
```

Äquivalent können bestehende Matrizen gleicher Spaltenanzahl mit der Funktion `rbind()` zeilenweise konkateniert werden.

```
A = matrix(c(1:6) , nrow = 2, byrow = TRUE)    # 2 x 3-Matrix der Zahlen 1,...,6
print(A)
```

```
     [,1] [,2] [,3]
[1,]    1    2    3
[2,]    4    5    6
```

```
B = matrix(c(7:9), nrow = 1)                    # 1 x 3-Matrix der Zahlen 7,...,9
print(B)
```

```
     [,1] [,2] [,3]
[1,]    7    8    9
```

```
C = rbind(A,B)                                  # zeilenweise Konkatenierung von A und B
print(C)
```

```
     [,1] [,2] [,3]
[1,]    1    2    3
[2,]    4    5    6
[3,]    7    8    9
```

15.1.2. Charakterisierung

Mit der vertrauten Funktion `typeof()` kann der elementare Datentyp einer Matrix ausgegeben werden:

```
typeof(matrix(c(1,0,0,1)    , nrow = 2))    # 2 x 2-Matrix vom Typ double
```

```
[1] "double"
```

```
typeof(matrix(c(1L,0L,0L,1L), nrow = 2))    # 2 x 2-Matrix vom Typ integer
```

```
[1] "integer"
```

```
typeof(matrix(c(T,T,F,F)    , nrow = 2))    # 2 x 2-Matrix vom Typ logical
```

```
[1] "logical"
```

```
typeof(matrix(c("a","b","c"), nrow = 1))    # 1 x 3-Matrix vom Typ character
```

```
[1] "character"
```

Die Zeilen- bzw. Spaltenanzahl einer Matrix kann mit den Funktionen `nrow()` (number of rows) und `ncol()` (number of columns) ausgegeben werden.

```
C = matrix(1:12, nrow = 3)                  # 3 x 4-Matrix
nrow(C)                                     # Anzahl Zeilen
```

```
[1] 3
```

```
ncol(C)                                     # Anzahl Spalten
```

```
[1] 4
```

15.1.3. Indizierung

Generell gilt, dass Matrixelemente mit einem Zeilenindex und einem Spaltenindex indiziert werden. Der erste zweier Matrixindizes indiziert dabei immer die Zeile, der zweite immer die Spalte. Die übrigen Prinzipien der Indizierung von Matrizen entsprechen im Wesentlichen den Prinzipien der Indizierung von Vektoren. Eine Besonderheit ist, dass ein fehlender Zeilen- oder Spaltenindex alle Elemente der entsprechenden Dimension indiziert.

```
A = matrix(c(2:7)^2, nrow = 2)              # 2 x 3-Matrix der Zahlen 2^2,...,7^2
A
```

```
     [,1] [,2] [,3]
[1,]    4   16   36
[2,]    9   25   49
```

```
A[1,3]                                      # Element in 1. Zeile, 3. Spalte von A [36]
```

```
[1] 36
```

```
A[2,2]                                      # Element in 2. Zeile, 2. Spalte von A [25]
```

```
[1] 25
```

```
A[2,]                                       # Alle Elemente der 2. Zeile [9,25,49]
```

```
[1]  9 25 49
```

```
A[,3]                                       # Alle Elemente der 3. Spalte [36,49]
```

```
[1] 36 49
```

```
A[1:2,1:2]                                  # Erste zwei Zeilen und Spalten
```

```
     [,1] [,2]
[1,]    4   16
[2,]    9   25
```

```
A[A>10]                                     # Elemente von A größer 10 [16,25,36,49]
```

```
[1] 16 25 36 49
```

```
A[1,c(F,F,T)]                               # Element in 1. Zeile, 3. Spalte von A [36]
```

```
[1] 36
```

15.1.4. Arithmetik

Wendet man unäre arithmetische Operatoren und Funktionen auf Matrizen an, so werden diese wie bei den Vektoren elementweise ausgewertet.

```
A = matrix(c(1:4), nrow = 2)                # 2 x 2-Matrix der Zahlen 1,2,3,4
A
```

```
     [,1] [,2]
[1,]    1    3
[2,]    2    4
```

```
B = A^2                                     # B[i,j] = A[i,j]^2, 1 <= i,j <= 2
B
```

```
     [,1] [,2]
[1,]    1    9
[2,]    4   16
```

```
C = sqrt(B)                                 # C[i,j] = sqrt(A[i,j]^2), 1 <= i,j <= 2
C
```

```
     [,1] [,2]
[1,]    1    3
[2,]    2    4
```

```
D = exp(A)                                  # D[i,j] = exp(A[i,j]), 1 <= i,j <= 2
D
```

```
         [,1]     [,2]
[1,] 2.718282 20.08554
[2,] 7.389056 54.59815
```

Wie Vektoren können auch Matrizen mit identischen Zeilen- und Spaltenanzahlen mit den binären arithmetischen Operatoren `+`, `-`, `*` und `/` elementweise verknüpft werden. Folgende Beispiele verdeutlichen dies:

```
A = matrix(c(1:4), nrow = 2)                # 2 x 2-Matrix der Zahlen 1,2,3,4
A
```

```
     [,1] [,2]
[1,]    1    3
[2,]    2    4
```

```
B = matrix(c(5:8), nrow = 2)                # 2 x 2-Matrix der Zahlen 5,6,7,8
B
```

```
     [,1] [,2]
[1,]    5    7
[2,]    6    8
```

```
C = A + B                                   # C[i,j] = A[i,j] + B[i,j], 1 <= i,j <= 2
C
```

```
     [,1] [,2]
[1,]    6   10
[2,]    8   12
```

```
D = A * B                                   # D[i,j] = A[i,j] * B[i,j], 1 <= i,j <= 2
D
```

```
     [,1] [,2]
[1,]    5   21
[2,]   12   32
```

Darüber hinaus kann mit **R**-Matrizen im Sinne der Matrizenrechnung der linearen Algebra gerechnet werden. Wir zeigen hier nur einige wenige Beispiele, eine ausführliche Darstellung der mathematischen Prinzipien und ihrer **R**-Implementierung findet sich in Kapitel 9.

```
C = A %*% B                                 # 2 x 2-Matrixprodukt
C
```

```
     [,1] [,2]
[1,]   23   31
[2,]   34   46
```

```
A_T = t(A)                                  # Transposition von A
A_T
```

```
     [,1] [,2]
[1,]    1    2
[2,]    3    4
```

```
A_inv = solve(A)                            # Inverse von A
A_inv
```

```
     [,1] [,2]
[1,]   -2  1.5
[2,]    1 -0.5
```

```
A_det = det(A)                              # Determinante von A
A_det
```

```
[1] -2
```

15.1.5. Attribute

Formal sind Matrizen atomare Vektoren mit einem `dim`-Attribut.

```
A = matrix(1:12, nrow = 4 )                 # 4 x 3-Matrix
attributes(A)                               # Aufrufen der Attribute von A
```

```
$dim
[1] 4 3
```

Wie bei den Vektoren kann man auch den Matrizenelementen Namen geben, allerdings ist dies auch bei Matrizen eher ungewöhnlich. Speziell definieren die Funktionen `rownames()` und `colnames()` das Matrixattribut `dimnames`.

```
rownames(A) = c("P1","P2","P3","P4")        # Benennung der Zeilen von A
colnames(A) = c("Age", "Hgt", "Wgt")        # Benennung der Spalten von A
A                                           # A mit Attribut dimnames
```

```
   Age Hgt Wgt
P1   1   5   9
P2   2   6  10
P3   3   7  11
P4   4   8  12
```

```
attr(A, "dimnames")                         # Aufrufen des Attributs dimnames
```

```
[[1]]
[1] "P1" "P2" "P3" "P4"

[[2]]
[1] "Age" "Hgt" "Wgt"
```

15.2. Arrays

R-Arrays sind d-dimensionale, hyperrechteckige Datenstrukturen. Intuitiv können Arrays als die Generalisierung von Matrizen auf mehr als zwei Dimensionen verstanden werden. Für $d = 1$ entspricht ein Array einem Vektor, für $d = 2$ entspricht ein Array einer Matrix. Wie bei Vektoren und Matrizen müssen die Elemente eines Arrays vom gleichen Datentyp sein. Arrays sind dadurch charakterisiert, wie viele Elemente $d_i, i = 1, ..., d$ die i-te Dimension repräsentieren kann. Jedes Element eines Arrays wird dabei durch einen d-dimensionalen Index $i_1, i_2, ..., i_d$ indiziert.

15.2.1. Erzeugung

In Analogie zur Funktion `matrix()` wird die Funktion `array()` genutzt, um ein Array mit Vektorelementen zu befüllen. Die allgemeine Syntax dieser Funktion ist `A = array(v, dim)`, wobei `v` ein Vektor von Arraydaten und `dim` ein Vektor ganzzahliger Werte ist, der die maximalen Indizes in jeder der `length(dim)` Dimensionen des Arrays repräsentiert. So erzeugt beispielsweise folgender Befehl ein $2 \times 2 \times 3$-Array.

```
A = array(1:12, dim = c(2,2,3))             # 2 x 2 x 3-Array der Zahlen 1,...,12
A
```

```
, , 1

     [,1] [,2]
[1,]    1    3
[2,]    2    4

, , 2

     [,1] [,2]
[1,]    5    7
[2,]    6    8
```

```
, , 3

     [,1] [,2]
[1,]    9   11
[2,]   10   12
```

Dreidimensionale Arrays kann man sich intuitiv als im Raum hintereinander aufgestellte Matrizen vorstellen. Die dritte Dimension repräsentiert dann dabei die "Seiten" des Arrays. Allerdings ist es im Umgang mit höherdimensionalen Arrays sinnvoll, zu versuchen, sich von räumlichen Vorstellungen von Arrays zu lösen und Arrays stattdessen als Datencontainer zu verstehen, deren Elemente eindeutig durch ihre Indizes adressiert werden können.

15.2.2. Charakterisierung

Die `length()`-Funktion gibt die Anzahl der Elemente eines Arrays aus.

```
A = array(1:12, dim = c(2,2,3))             # 2 x 2 x 3-Array der Zahlen 1,...,12
length(A)                                   # Die Anzahl der Elemente des Arrays
```

```
[1] 12
```

Die Funktion `typeof()` gibt den elementaren Datentyp eines Arrays aus:

```
typeof(A)                                   # Der Typ des Arrays
```

```
[1] "integer"
```

Die Funktion `dim()` gibt die Dimensionen eines Arrays aus:

```
dim(A)                                      # Dimension des Arrays
```

```
[1] 2 2 3
```

15.2.3. Indizierung

Die Indizierung von Arrays erfolgt analog zu Vektor- und Matrixindizierung, mit dem Unterschied, dass zur Indizierung eines Arrayelements drei oder mehr Indizes benötigt werden.

```
A        = array(1:12, dim = c(2,2,3))      # 2 x 2 x 3-Array der Zahlen 1,...,12
a_223     = A[2,2,3]                        # Arrayelement mit Indexadresse [2,2,3] (12)
```

15.2.4. Arithmetik

Wie bei Vektoren und Matrizen werden unäre arithmetische Operatoren bei Arrays elementweise ausgewertet. Ebenso analog werden binäre arithmetische Operatoren bei Arrays identischer Dimensionalität elementweise ausgewertet.

```
A     = array(1:4, dim = c(1,2,2))          # 1 x 2 x 2-Array der Zahlen 1,...,4
A
```

```
, , 1

     [,1] [,2]
[1,]    1    2

, , 2

     [,1] [,2]
[1,]    3    4
```

```
B     = array(5:8, dim = c(1,2,2))          # 1 x 2 x 2-Array der Zahlen 5,...,8
B
```

```
, , 1

     [,1] [,2]
[1,]    5    6

, , 2

     [,1] [,2]
[1,]    7    8
```

```
C     = A^2                                 # elementweise Potenzierung
C
```

```
, , 1

     [,1] [,2]
[1,]    1    4

, , 2

     [,1] [,2]
[1,]    9   16
```

```
D       = A + B                             # elementweise Addition
D
```

```
, , 1

     [,1] [,2]
[1,]    6    8

, , 2

     [,1] [,2]
[1,]   10   12
```

15.2.5. Attribute

Formal sind Arrays atomare Vektoren mit einem `dim`-Attribut.

```
A = array(1:12, dim = c(2,2,3))              # 2 x 2 x 3-Array der Zahlen 1,...,12
attributes(A)                                # Aufrufen der Attribute von A
```

```
$dim
[1] 2 2 3
```

Wie bei den Matrizen kann die Funktion `dimnames()` zur Benennung der Arraydimensionen benutzt werden, aber auch hier ist die Benennung von Arraydimensionen eher ungewöhnlich.

16. Listen, Dataframes und Tibbles

16.1. Listen

R-Listen sind geordnete Folgen von **R**-Objekten. Listen werden als rekursiver Datentyp bezeichnet, da sie Objekte verschiedener Datentypen, insbesondere auch wiederum Listen, bündeln können. Obwohl sich die intuitive Sichtweise, dass Listen Objekte "enthalten", anbietet, "enthalten" Listen de facto keine Objekte, sondern lediglich die Referenzen zu den entsprechenden Objekten im Arbeitsspeicher (Abbildung 16.1). Listen sind ein wesentlicher Baustein von **R**-Dataframes.

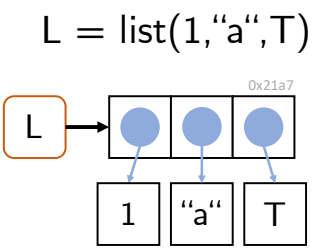


Abbildung 16.1. Listenrepräsentation. Eine Liste in **R** ist eine indizierbare Folge von Referenzen zu **R**-Objekten im Arbeitsspeicher.

Erzeugung

Listen können durch die direkte Konkatenation der Listenelemente mithilfe der Funktion `list()` erzeugt werden.

```
# Erzeugung einer Liste mit einem Vektor-, Matrix- und Funktionselement
L = list(c(1,4,5), matrix(1:8, nrow = 2), exp)
print(L)
```

```
[[1]]
[1] 1 4 5

[[2]]
     [,1] [,2] [,3] [,4]
[1,]    1    3    5    7
[2,]    2    4    6    8

[[3]]
function (x)  .Primitive("exp")
```

Insbesondere können auch Listen selbst Elemente von Listen sein, was ihre Bezeichnung als *rekursiver* Datentyp motiviert.

```
L = list(list(1))                       # Liste mit Element 1 in einer Liste
print(L)                                # Ausgabe
```

Die von den **R**-Vektoren vertraute Funktion `c()` kann auch zum Konkatenieren von mehreren Listen genutzt werden.

```
L = c(list(pi), list("a"))              # Konkatenation zweier Listen
print(L)                                # Ausgabe
```

Charakterisierung

Der Datentyp von Listen ist `list`:

```
L = list(1:2, "a", log)                 # Erzeugung einer Liste
typeof(L)                               # Typenbestimmung
```

```
[1] "list"
```

`length()` gibt die Anzahl der Listenelemente auf dem obersten Listenlevel aus, die Elementinhalte werden also ignoriert:

```
L = list(1:2, list("a", pi), exp)       # Drei Elemente auf oberster Ebene
length(L)                               # length() ignoriert Elementinhalte
```

```
[1] 3
```

Die Dimension, Zeilen- und Spaltenanzahlen von Listen sind `NULL`:

```
L = list(1:2, "a", sin)                 # eine Liste
dim(L)                                  # Die Dimension von Listen ist NULL
```

```
NULL
```

```
nrow(L)                                 # Die Zeilenanzahl von Listen ist NULL
```

```
NULL
```

```
ncol(L)                                 # Die Spaltenanzahl von Listen ist NULL
```

```
NULL
```

Indizierung

Bei der Indizierung von Listen ist zu beachten, dass Listen auf zwei unterschiedliche Arten indiziert werden können. Einfache eckige Klammern `[ ]` indizieren Listenelemente als Listen:

```
L  = list(1:3, "a", exp)                    # eine Liste
l1 = L[1]                                   # Indizierung eines Listenelements
print(l1)                                   # Ausgabe
```

```
[[1]]
[1] 1 2 3
```

```
typeof(l1)                                  # Typbestimmung von l1
```

```
[1] "list"
```

Doppelte eckige Klammern `[[ ]]` indizieren den Inhalt von Listenelementen:

```
L  = list(1:3, "a", exp)                    # eine Liste
i2 = L[[2]]                                 # Indizierung des Listenelementinhalts
print(i2)                                   # Ausgabe des Inhalts von Listenelement L[2]
typeof(i2)                                  # Typbestimmung von i2
```

Auch beim Ersetzen von Listeninhalten sind diese Konventionen zu beachten. So ist es zum Beispiel nicht möglich, durch den Ausdruck `L[1] = c(1,2,3)` das erste Listenelement zu ändern, da der Vektor `c(1,2,3)` keine Liste ist:

```
L       = list(1:3, "a", exp)               # eine Liste
L[1]    = 4:6                               # keine Typkonversion, Fehlermeldung
```

```
Warning in L[1] = 4:6: number of items to replace is not a multiple of
replacement length
```

```
L[1]    = list(4:6)                         # Ersetzung des 1. Listenelementes
L[[3]]  = "c"                               # Ersetzung des 3. Listenelementinhaltes
```

Indizierung

Die Prinzipien der Listenindizierung sind analog zu denen der Vektorindizierung. Vektoren positiver Zahlen adressieren die entsprechenden Elemente:

```
L = list(1:3, "a", pi)                      # eine Liste
l = L[c(1,3)]                               # 1. und 3. Listenelement
l
```

```
[[1]]
[1] 1 2 3

[[2]]
[1] 3.141593
```

Vektoren negativer Zahlen adressieren die zu ihren Werten komplementären Elemente:

```
L = list(1:3, "a", pi)                          # eine Liste
l = L[-c(1,3)]                                  # 2. Listenelement
l
```

```
[[1]]
[1] "a"
```

Logische Vektoren adressieren Elemente mit Index `TRUE`:

```
L = list(1:3, "a", pi)                          # eine Liste
l = L[c(T,T,F)]                                 # 1. und 2. Listenelement
l
```

```
[[1]]
[1] 1 2 3

[[2]]
[1] "a"
```

Zur nicht numerischen Adressierung können Listenelementen auch Namen gegeben werden. Dies ist nach der Erzeugung einer Liste mithilfe der `names()`-Funktion möglich:

```
K        = list(1:2, TRUE)                      # eine unbenannte Liste
names(K) = c("Frodo", "Sam")                    # Namensgebung mit names()
K                                               # Ausgabe
```

```
$Frodo
[1] 1 2

$Sam
[1] TRUE
```

Ebenso ist es möglich, die Namen der Listenelemente direkt bei Erzeugung der Liste durch Zuweisung zu vergeben:

```
L = list(frodo  = 1:3, sam  = "a", eowyn  = "b")    # Benannte Liste erzeugen
```

Sowohl Listenelemente als auch Listenelementinhalte können dann mit ihren Namen adressiert werden:

```
L = list(frodo  = 1:3, sam  = "a", eowyn  = "b")    # Benannte Liste erzeugen
L["frodo"]                                          # Listenelementausgabe
```

```
$frodo
[1] 1 2 3
```

```
typeof(L["frodo"])                                  # Listenelementtyp
```

```
[1] "list"
```

```
L[["frodo"]]                                    # Elementinhalt ausgeben
```

```
[1] 1 2 3
```

```
typeof(L[["sam"]])                              # Typ des Elementinhalts
```

```
[1] "character"
```

Insbesondere können Listenelementinhalte auch mit dem $-Operator und ihrem Namen indiziert werden. Dies stellt im Rahmen der Dataframes die gebräuchlichste Art der Listenindizierung dar:

```
L = list(frodo  = 1:3, sam  = "a", eowyn  = "b")    # Benannte Liste erzeugen
L$frodo                                             # Elementinhalt ausgeben
```

```
[1] 1 2 3
```

```
typeof(L$frodo)                                 # Typ des Elementinhalts
```

```
[1] "integer"
```

```
L$sam                                           # Elementinhalt ausgeben
```

```
[1] "a"
```

```
typeof(L$sam)                                   # Typ des Elementinhalts
```

```
[1] "character"
```

```
L$eowyn                                         # Elementinhalt ausgeben
```

```
[1] "b"
```

```
typeof(L$eowyn)                                 # Typ des Elementinhalts
```

```
[1] "character"
```

Arithmetik

Eine allgemeine Listenarithmetik ist nicht definiert, da Listenelementinhalte ja unterschiedlichen Datentyps sein können, für die unäre oder binäre Operationen nicht definiert sind:

```
L1 = list(1:3, "a" )                    # eine Liste
L2 = list(T, exp )                      # eine Liste
L1+L2                                   # Versuch der Listenaddition
```

```
Error in `L1 + L2`:
! non-numeric argument to binary operator
```

Sind Inhalte von Listenelementen allerdings von einem gemeinsamen Datentyp, für den bestimmte binäre Operationen definiert sind, so können sie auch z. B. arithmetisch verknüpft werden:

```
L1 = list(1:3, pi )                     # eine Liste
L2 = list(4:6, exp )                    # eine Liste
L1[[1]] + L2[[1]]                       # Erste Inhalte addieren: [1+4,2+5,3+6]
```

```
[1] 5 7 9
```

```
L2[[2]](1)                              # Zweiten Inhalt anwenden: exp(1)
```

```
[1] 2.718282
```

Copy-on-modify

Wie bei Vektoren gilt bei Listen das *Copy-on-modify*-Prinzip. Speziell gilt bei Listen, dass sogenannte *shallow copies* bei Modifikation einer Liste erzeugt werden. Dabei wird nur das Listenobjekt selbst kopiert und erhält eine neue Adresse im Arbeitsspeicher, nicht aber die durch die Liste gebundenen Objekte, die an den gleichen Adressen im Arbeitsspeicher verbleiben. `lobstr::ref()` erlaubt es, dieses Verhalten nachzuvollziehen.

```
L1 = list(1,2,3)                        # Erzeugen einer Liste als Objekt
lobstr::ref(L1)                         # Ausgabe der Referenzen
```

```
o [1:0x213604974f8] <list>
+-[2:0x2135e87dac0] <dbl>
+-[3:0x2135e87d8c8] <dbl>
\-[4:0x2135e87d628] <dbl>
```

```
L2 = L1                                 # L1 und L2 referenzieren dasselbe Objekt
lobstr::ref(L2)                         # Ausgabe der Referenzen
```

```
o [1:0x213604974f8] <list>
+-[2:0x2135e87dac0] <dbl>
+-[3:0x2135e87d8c8] <dbl>
\-[4:0x2135e87d628] <dbl>
```

```
L2[[3]] = 4                                    # Flache Kopie bei Änderung
lobstr::ref(L2)                                # Ausgabe der Referenzen
```

```
o [1:0x2136052f9f8] <list>
+-[2:0x2135e87dac0] <dbl>
+-[3:0x2135e87d8c8] <dbl>
\-[4:0x2135e8a1ce8] <dbl>
```

Offenbar ändert die Zuweisung `L2 = L1` zunächst nichts an den Arbeitsspeicheradressen, auf die `L1` und `L2` sowie ihre Elemente verweisen. Die Modifikation des Inhalts des dritten Listenelements von `L2` durch `L2[[3]] = 4` allerdings ändert dann die Adresse des Listenobjekts im Arbeitsspeicher, da eine Kopie des Listenobjekts erzeugt wird. Gleichzeitig ändern sich gemäß dem Shallow-Copy-Prinzip die Adressen der ersten beiden Inhalte von `L2` aber nicht. Abbildung 16.2 visualisiert diese Prinzipien an einem Beispiel.

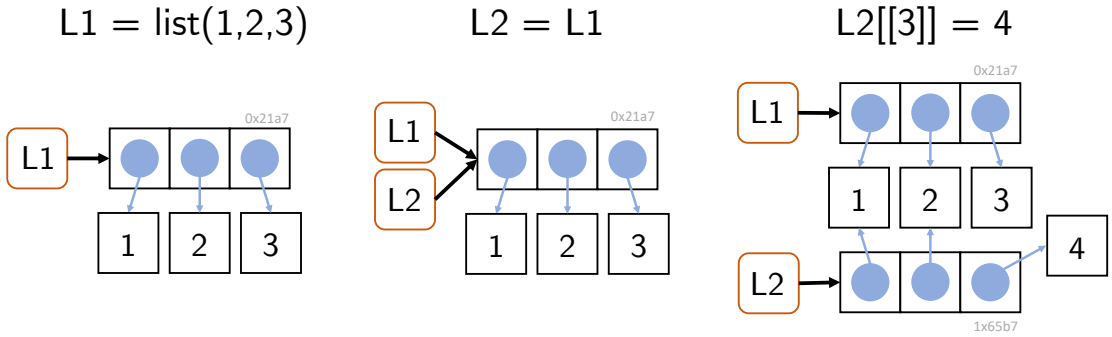


Abbildung 16.2. Effekte der Zuweisung `L2 = L1` für eine Liste `L1` sowie der Modifikation eines Elements von `L2`.

16.2. Dataframes

R-Dataframes sind die zentrale Datenstruktur in **R**. Dataframes stellt man sich am besten als Tabelle vor, deren Spalten Namen haben. Technisch ist ein Dataframe eine Liste, deren Elemente Vektoren gleicher Länge sind. Die Listenelemente entsprechen dabei den Spalten einer Tabelle und die Vektorelemente an gleicher Position entsprechen den Zeilen einer Tabelle.

Erzeugung

Dataframes werden mit der Funktion `data.frame()` erzeugt. Dabei werden als Argumente der Funktion die Spaltennamen und ihre vektorwertigen Inhalte festgelegt:

```
D = data.frame(                                # Dataframe erzeugen
  x = letters[1:4],                            # 1. Spalte mit dem Namen x
  y = 1:4,                                     # 2. Spalte mit dem Namen y
  z = c(T,T,F,T))                              # 3. Spalte mit dem Namen z
print(D)                                       # Ausgabe des Dataframes als Tabelle
```

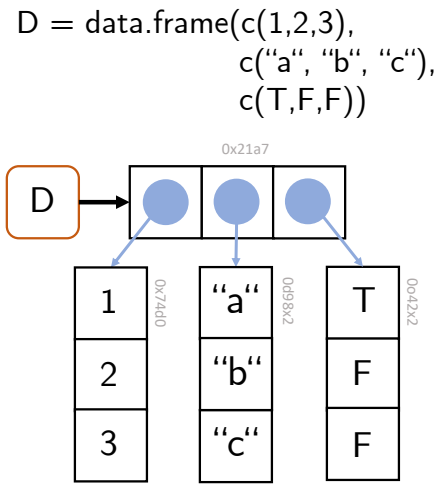


Abbildung 16.3. Dataframerepräsentation. Ein **R**-Dataframe ist eine **R**-Liste, deren Elemente **R**-Vektoren gleicher Länge sind.

```
  x y     z
1 a 1  TRUE
2 b 2  TRUE
3 c 3 FALSE
4 d 4  TRUE
```

Die Spalten des Dataframes müssen die gleiche Länge haben, ansonsten ist ein Dataframe nicht definiert:

```
D = data.frame(                         # Dataframe erzeugen
  x = letters[1:4],                     # 1. Spalte mit dem Namen x
  y = 1:4,                              # 2. Spalte mit dem Namen y
  z = c(T,T,F))                         # 3. Spalte mit dem Namen z
```

```
Error in `data.frame()`:
! arguments imply differing number of rows: 4, 3
```

Die Spalten eines Dataframes können offenbar unterschiedlichen Datentyps sein, dies ist natürlich mit dem Charakter von **R**-Listen kongruent.

Charakterisierung

Mit den Funktionen `names()` und `colnames()` können die Namen der Spalten eines Dataframes ausgegeben werden, mit der Funktion `rownames()` seine Zeilennamen. Per Default sind die Zeilennamen eines Dataframes die ganzen Zahlen 1,2,...,n:

```
D = data.frame(                         # Dataframe erzeugen
  age    = c(30,35,40,45),              # 1. Spalte
  height = c(178,189,165,171),          # 2. Spalte
  weight = c(67, 76, 81, 92))           # 3. Spalte
names(D)                                # names gibt die Spaltennamen aus
```

```
[1] "age"    "height" "weight"
```

```
colnames(D)                                    # colnames entspricht names
```

```
[1] "age"    "height" "weight"
```

```
rownames(D)                                    # Standardmäßige Zeilennamen: 1, 2, ...
```

```
[1] "1" "2" "3" "4"
```

Des Weiteren ist ein Dataframe durch die Anzahl seiner Zeilen und Spalten charakterisiert. Diese können mit den Funktionen `nrow()` bzw. `ncol()` ausgegeben werden. Die Funktion `length()` gibt für Dataframes wie für Listen die Anzahl der Listeneinträge, bei Dataframes also entsprechend die Spaltenanzahl, aus.

```
nrow(D)                                        # Zeilenanzahl
```

```
[1] 4
```

```
ncol(D)                                        # Spaltenanzahl
```

```
[1] 3
```

```
length(D)                                      # Länge ist die Spaltenanzahl
```

```
[1] 3
```

Eine hilfreiche Funktion zur Charakterisierung eines Dataframes ist die Funktion `str()`, die in kompakter Form wesentliche Aspekte eines Dataframes anzeigt. `str()` steht dabei für *structure* und bezeichnet die Spalten des Dataframes als *variables* und Zeileneinträge als *observations*:

```
str(D)
```

```
'data.frame':   4 obs. of  3 variables:
 $ age   : num  30 35 40 45
 $ height: num  178 189 165 171
 $ weight: num  67 76 81 92
```

Attribute

Technisch sind Dataframes Listen mit Attributen für (column) `names` und `row.names`. Dataframes sind von der `class` "data.frame":

```
typeof(D)
```

```
[1] "list"
```

```
attributes(D)
```

```
$names
[1] "age"    "height" "weight"

$class
[1] "data.frame"

$row.names
[1] 1 2 3 4
```

Indizierung

Dataframes kann man sowohl wie Matrizen als auch wie Listen indizieren. Die Prinzipien der Indizierung entsprechen dabei denen von Vektoren. Folgendes Beispiel zeigt zunächst, wie ein Dataframe im Sinne einer Liste mit einfachen Klammern indiziert wird. Das entsprechende Listenelement ist bei Dataframes dann selbst ein Dataframe:

```
D = data.frame(                         # Dataframe erzeugen
  x = letters[1:4],                     # 1. Spalte mit dem Namen x
  y = 1:4,                              # 2. Spalte mit dem Namen y
  z = c(T,T,F,T))                       # 3. Spalte mit dem Namen z
class(D)                                # D ist ein Dataframe
```

```
[1] "data.frame"
```

```
v = D[1]                                # 1. Listenelement als Dataframe
v
```

```
  x
1 a
2 b
3 c
4 d
```

```
class(v)                                # v ist ein Dataframe
```

```
[1] "data.frame"
```

Des Weiteren können Dataframes wie Listen mit doppelten Klammern indiziert werden. Dadurch werden entsprechend die Inhalte eines Listenelements adressiert:

```
w = D[[1]]                              # Inhalt des 1. Listenelements
w
```

```
[1] "a" "b" "c" "d"
```

```
class(w)                                # w ist ein Zeichenvektor
```

```
[1] "character"
```

Die typische Indizierung eines Dataframes erfolgt mit der von den Listen bekannten $-Indizierung, die den Inhalt der entsprechenden Dataframe-Spalte adressiert:

```
y = D$y                                 # $ zur Indizierung der y-Spalte
y
```

```
[1] 1 2 3 4
```

```
class(y)                                # y ist ein Vektor vom Typ "integer" (!)
```

```
[1] "integer"
```

Ist man an speziellen Inhalten des Dataframes in spezifischen Zeilen und Spalten interessiert, so bieten sich die Prinzipien der Matrixindizierung an, wie folgendes Beispiel zeigt:

```
D[2:3,-2]                               # 1. Index: Zeilen; 2. Index: Spalten
```

```
  x     z
2 b  TRUE
3 c FALSE
```

```
D[c(T,F,T,F),]                          # 1. Index: Zeilen; 2. Index: Spalten
```

```
  x y     z
1 a 1  TRUE
3 c 3 FALSE
```

```
D[,c("x", "z")]                         # 1. Index: Zeilen; 2. Index: Spalten
```

```
  x     z
1 a  TRUE
2 b  TRUE
3 c FALSE
4 d  TRUE
```

Copy-on-modify

Zur optimalen Nutzung des Arbeitsspeichers gelten die Copy-on-modify-Prinzipien für Listen auch für Dataframes. Weiterhin gilt dabei, dass die Modifikation einer Spalte zur Kopie der entsprechenden Spalte führt, wohingegen die Modifikation einer Zeile in der Kopie des gesamten Dataframes resultiert.

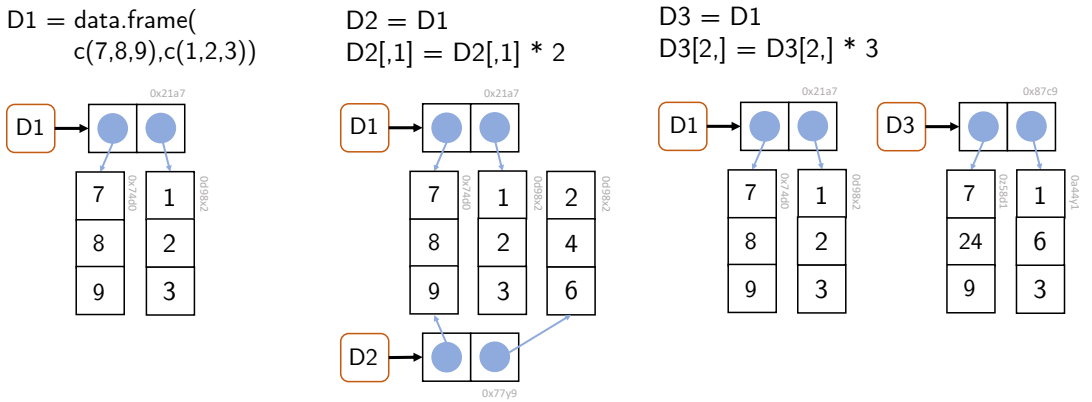


Abbildung 16.4. Effekte von Spalten- und Zeilenmodifikationen bei Dataframes. Die Modifikation einer Spalte führt zur Kopie der entsprechenden Spalte, die Modifikation einer Zeile zur Kopie des gesamten Dataframes.

16.3. Tibbles

In Ergänzung zu den **R**-Dataframes haben in den letzten zehn Jahren die *Tibbles* (Diminutiv für *tables*) als Teil des `tidyverse`-Pakets Verbreitung gefunden. Tibbles sind eine modernere, technisch verbesserte Form von Dataframes und zeigen, wie **R** für datenwissenschaftliche Aufgaben über die Anwendung von klassischen linearen Modellen hinaus erweitert wurde. Zur Nutzung von Tibbles muss das `tidyverse`-Paket installiert und der Tibble-Code geladen sein:

```
install.packages("tidyverse")              # Paket einmalig installieren
library(tibble)                            # Paket für diese Sitzung laden
```

Im Großen und Ganzen entsprechen Tibbles den Dataframes. Wie bei Dataframes handelt es sich bei Tibbles um Listen von Vektorreferenzen, wobei auch hier die Vektoren die gleiche Länge haben und die benannten Spalten einer Tabelle darstellen. Tibbles können mit der Funktion `tibble()` erzeugt werden. Die Anzeige im **R**-Terminal ist im Vergleich zu Dataframes optimiert, wie folgendes Beispiel zeigt:

```
library(tibble)                                                          # Paket
T = tibble(x = c("a", "c", "d"),  y = c(1,2,3), z = c(TRUE,FALSE,FALSE))  # Erzeugung
print(T)                                                                 # Ausgabe
```

```
# A tibble: 3 x 3
  x         y z
  <chr> <dbl> <lgl>
1 a         1 TRUE
2 c         2 FALSE
3 d         3 FALSE
```

```
attributes(T)                                                            # Attribute
```

```
$names
[1] "x" "y" "z"
```

```
$row.names
[1] 1 2 3

$class
[1] "tbl_df"     "tbl"        "data.frame"
```

16.3.1. Tibbles vs. Dataframes

Tibbles wurden 2016 im Rahmen des `tidyverse`-Pakets eingeführt, um wahrgenommene Schwächen der **R**-Dataframes auszugleichen. Dazu gehörte unter anderem, dass die Funktion `data.frame()` character-Vektoren automatisiert in den **R**-Datentyp `factor` umwandelte. Dies ist seit **R**-Version 4.0.0 von 2020 allerdings nicht mehr der Fall, wie folgendes Beispiel zeigt:

```
D = data.frame(x = 1:3, y = c("a", "b", "c"))   # Zeichenvektor y
str(D)                                          # ... bleibt Zeichenvektor
```

```
'data.frame':   3 obs. of  2 variables:
 $ x: int  1 2 3
 $ y: chr  "a" "b" "c"
```

Per Default wandelt `data.frame()` weiterhin nicht zulässige Spaltennamen wie eine Zahl (`1`) in legale Spaltennamen (`X1`) um. Möchte man dies nicht, so kann man dieses Verhalten allerdings durch Setzen des Arguments `check.names` abstellen:

```
names(data.frame(`1` = 1))                      # Ungültige Namen anpassen
```

```
[1] "X1"
```

```
names(data.frame(`1` = 1, check.names = FALSE))     # Namen unverändert lassen
```

```
[1] "1"
```

Wie in Kapitel 14 gesehen, hat **R** die Tendenz, bei Vektoren mit unpassenden Längen selbst Daten durch Recycling zu erzeugen, was leicht zu Fehlern führen kann. So recyclet die Funktion `data.frame()` bei der Erzeugung eines Dataframes zum Beispiel Vektoren, wenn einer davon ein ganzzahliges Vielfaches des anderen ist:

```
D = data.frame(x = 1:2, y = 3:6)            # length(y) = 2 * length(x)
print(D)                                    # Ausgabe
```

```
  x y
1 1 3
2 2 4
3 1 5
4 2 6
```

`tibble()` dagegen ist hier genauer und gibt im obigen Fall einen Fehler aus:

```
T = tibble(x = 1:2, y = 3:6)                # tibble gibt hier einen Fehler aus
```

```
Error in `tibble()`:
! Tibble columns must have compatible sizes.
* Size 2: Existing data.
* Size 4: Column `y`.
i Only values of size one are recycled.
```

Vektoren der Länge 1 werden allerdings auch von `tibble()` recyclet:

```
T = tibble(x = 1:3, y = 3)                  # Vektoren der Länge 1
print(T)                                    # Ausgabe
```

```
# A tibble: 3 x 2
      x     y
  <int> <dbl>
1     1     3
2     2     3
3     3     3
```

Dataframes sind manchmal inkonsistent, was die von ihnen ausgegebenen Datentypen angeht. So ergibt, wie das untere Beispiel zeigt, die Indizierung einer Dataframespalte mit ihrem Namen etwa einen Dataframe, die Indizierung der gleichen Spalte mit ihrem Namen in Matrixindizierung allerdings einen Vektor:

```
D = data.frame(x = 1:3, y = 4:6)            # Dataframe
str(D["x"])                                 # Namensindizierung ergibt einen Dataframe
```

```
'data.frame':   3 obs. of  1 variable:
 $ x: int  1 2 3
```

```
str(D[,"x"])                                # Matrixindizierung ergibt einen Vektor
```

```
 int [1:3] 1 2 3
```

Tibbles sind in dieser Hinsicht konsistenter:

```
T = tibble(x = 1:3, y = 4:6)                # Tibble
str(T["x"])                                 # Indizierung mit Namen ergibt tibble
```

```
tibble [3 x 1] (S3: tbl_df/tbl/data.frame)
 $ x: int [1:3] 1 2 3
```

```
str(T[,"x"])                                # Matrixindizierung mit Namen ergibt tibble
```

```
tibble [3 x 1] (S3: tbl_df/tbl/data.frame)
 $ x: int [1:3] 1 2 3
```

Ein zusätzliches Feature von Tibbles gegenüber Dataframes ist, dass die Funktion `tibble()` es erlaubt, Spaltennamen schon bei Erzeugung eines Tibbles zu referenzieren, was bei Dataframes nicht möglich ist.

```
T = tibble(x = 1, y = 2*x)                # die Spalte x wird definiert und benutzt
D = data.frame(x = 1, y = 2*x)            # data.frame erlaubt dies nicht
```

```
Error:
! object 'x' not found
```

Zusammenfassend lässt sich festhalten, dass Tibbles in mancher Hinsicht weniger flexibel und damit präziser als Dataframes funktionieren. Generell verhalten sich Tibbles in `tidyverse`-Kontexten konsistenter als Dataframes. Allerdings sind die Unterschiede zwischen Dataframes und Tibbles wie oben gesehen eher subtil, sodass ein effizienter Umgang mit Dataframes auch einen effizienten Umgang mit Tibbles ermöglicht. Da nicht alle **R**-Projekte die Pakete des `tidyverse` nutzen, werden wohl auch in Zukunft Dataframes die Standarddatenstruktur für tabellarische Daten in **R** bleiben.

17. Datenmanagement

In diesem Abschnitt wollen wir einige allgemeine Begrifflichkeiten zum Umgang mit Forschungsdaten einführen, gängige Formate zur längerfristigen Speicherung von Daten diskutieren und uns schließlich mit dem praktischen Einlesen und Speichern von Daten im Rahmen des **R**-Verzeichnismanagements beschäftigen.

17.1. Das FAIR-Datenideal

Das FAIR-Datenideal ist ein Prinzip zum Management von Forschungsdaten, das der weiten Verbreitung, Nützlichkeit und Transparenz von Forschungsdaten im Digitalzeitalter Rechnung trägt. Unter *Forschungsdaten* werden dabei im Allgemeinen "elektronisch repräsentierte analoge oder digitale Daten, die im Zuge wissenschaftlicher Vorhaben entstehen oder genutzt werden, z. B. durch Beobachtungen, Experimente, Simulationsrechnungen, Erhebungen, Befragungen, Quellenforschungen, Aufzeichnungen von Audio- und Videosequenzen, Digitalisierung von Objekten, Auswertungen" (Rat für Informationsinfrastrukturen (2017)) verstanden. Konkret handelt es sich dabei etwa um Zahlenarrays oder Characterarrays, aber auch um Computersoftware wie **R**-Skripte, digitale Werkzeuge, Workflows und Analysepipelines.

Neben diesen manchmal auch als *Primärdaten* bezeichneten Datenformen sind für das FAIR-Datenideal sogenannte *Metadaten* von Bedeutung. Dabei handelt es sich um Daten, die Informationen über andere Daten repräsentieren. Man unterscheidet dabei beispielsweise *deskriptive*, *strukturelle* und *administrative Metadaten* (Riley (2017), Ulrich et al. (2022)).

- *Deskriptive Metadaten* dienen dem Auffinden und der Identifikation einer Datenquelle. Beispiele für deskriptive Metadaten sind etwa Titel einer wissenschaftlichen Publikation oder ihr Digital Object Identifier (DOI, Rosenblatt (1997)). DOIs sind alphanumerische Kennungen, die digitale Objekte eindeutig identifizieren und als persistente Links zu Objekten im Internet funktionieren.
- *Strukturelle Metadaten* sind Metadaten über Datencontainer und repräsentieren den strukturellen Aufbau einer Datenquelle. Beispiele sind die Ordnung der Seiten eines Buches oder die For-Schleifen-Enkodierung dreidimensionaler Datenobjekte.
- *Administrative Metadaten* schließlich sind Daten, die das Management einer Datenquelle erleichtern. Beispiele für administrative Metadaten sind Provenienz, das Dateiformat, die Zugangsrechte oder andere technische Informationen zu einer Datenquelle.

Das FAIR-Ideal zum Forschungsdatenmanagement hat seinen Ursprung in Diskussionen im Rahmen der FORCE11-Konferenzserie und wurde 2016 durch Wilkinson et al. (2016) akademisch kommuniziert. Es besagt im Kern, dass Forschungsdaten *Findable*, *Accessible*, *Interoperable* und *Reusable* für Menschen und Maschinen aufbereitet und vorgehalten

werden sollen. Speziell formuliert das FAIR-Datenideal folgende Ansprüche an das Management von Forschungs(meta)daten:

Findability (Auffindbarkeit)

- F1. (Meta)Daten haben einen persistenten global einzigartigen Identifikator.
- F2. Daten werden mit Metadaten angereichert.
- F3. Metadaten sind zweifelsfrei einem Datensatz zuzuordnen.
- F4. (Meta)Daten sind in einer durchsuchbaren Ressource indexiert.

Accessibility (Zugänglichkeit)

- A1. (Meta)Daten sind mit standardisierten Protokollen abrufbar.
- A1.1. Das genutzte Protokoll ist offen, kostenlos und nutzbar.
- A1.2. Das Protokoll ermöglicht Authentifizierung und Rechtevergabe.
- A2. Metadaten bleiben zugänglich, auch wenn Daten nicht mehr vorliegen.

Interoperability (Interoperabilität)

- I1. (Meta)Daten nutzen eine formale, zugängliche, gemeinsam genutzte und breit anwendbare Sprache zur Wissensrepräsentation.
- I2. (Meta)Daten nutzen Vokabularien, die den FAIR-Prinzipien folgen.
- I3. (Meta)Daten enthalten qualifizierte Referenzen auf andere (Meta)Daten.

Reusability (Wiederverwendbarkeit)

- R1. (Meta)Daten haben eine Vielzahl genauer und relevanter Attribute.
- R1.1. (Meta)Daten enthalten eine eindeutige Nutzungslizenz.
- R1.2. (Meta)Daten enthalten detaillierte Provenienz-Informationen.
- R1.3. (Meta)Daten genügen den Standards der jeweiligen Fachcommunity.

Der Anspruch an ein faires Forschungsdatenmanagement ist mittlerweile recht verbreitet, wobei die FAIR-Prinzipien mit mehr oder weniger bürokratischem Aufwand umgesetzt werden können. Es bleibt aber festzuhalten, dass zurzeit die FAIR-Prinzipien im Wesentlichen ein anzustrebendes Datenmanagementideal sind und längst nicht alle Forschungsdaten FAIR verfügbar sind. Tatsächlich ist der Umgang mit digitalen Forschungsdaten auch weiterhin noch sehr unstrukturiert und gerade das deutsche Universitätssystem begreift das digitale Datenmanagement nur sehr langsam als eine Kernaufgabe. In größerem, wenn auch projektbasiertem und damit nicht nachhaltigem Rahmen versucht die Initiative zur Nationalen Forschungsdateninfrastruktur (NFDI), das deutsche digitale Forschungsdatenmanagement zu verbessern. Leider bleibt weiterhin festzuhalten, dass viele durch öffentliche Mittel finanzierte Wissenschaftler:innen von ihnen erhobene Forschungsdaten weder systematisch aufbereiten noch der Öffentlichkeit zur Verfügung stellen wollen. Hier ist also weiterhin auf einen Kulturwandel zu mehr wissenschaftlicher Transparenz zu hoffen und offene, öffentlich finanzierte Forschung (Open Research, vgl. z. B. Toelch & Ostwald (2018), Miedema (2022), Bertram et al. (2023)) bleibt ein anzustrebendes Ideal.

17.2. Dateiformate

Allgemein definieren Dateiformate Syntax und Semantik von Daten innerhalb einer Datei. Dateiformate sind dabei bijektive Abbildungen von Information auf den binären Langzeitspeicher. Allgemein unterscheidet man *Datendateiformate* gegenüber *Softwaredateiformaten*, *textuelle* gegenüber *binären Dateiformaten* und *offene* gegenüber *proprietären*, d. h. urheberrechtlich geschützten, Dateiformaten. Bei binären Datendateiformaten ist das Einlesen von Daten, ihre Inspektion und ihre Manipulation generell nur mit spezieller Software möglich. Beispiele für binäre Dateiformate sind *.docx*, *.pdf*, *.xlsx*, *.jpg* und *.mp4*. Binäre Dateiformate sind dabei oft proprietär. Früher wurden binäre Dateiformate aufgrund ihres geringeren Speicherbedarfs auch für Forschungsdaten bevorzugt eingesetzt. Heutzutage werden dagegen textuelle Datendateiformate wie *.txt*, *.csv*, *.tsv* und *.json* favorisiert. Bei diesen Formaten ist das Einlesen der gespeicherten Daten, ihre Inspektion und ihre Manipulation mit einfachen allgemeinen Editoren wie beispielsweise VS Code problemlos möglich und die Dateiformate sind generell nicht proprietär. Abbildung 17.1 zeigt die Darstellung eines binären Datenformats und eines textuellen Datenformats im Windows-Editor. Generell bieten sich im Forschungskontext und im Sinne der FAIR-Prinzipien also offene, textuelle Datendateiformate an. Exemplarisch wollen wir hier als textuelle Dateiformate das .csv-, das .tsv- sowie das .json-Dateiformat genauer betrachten.

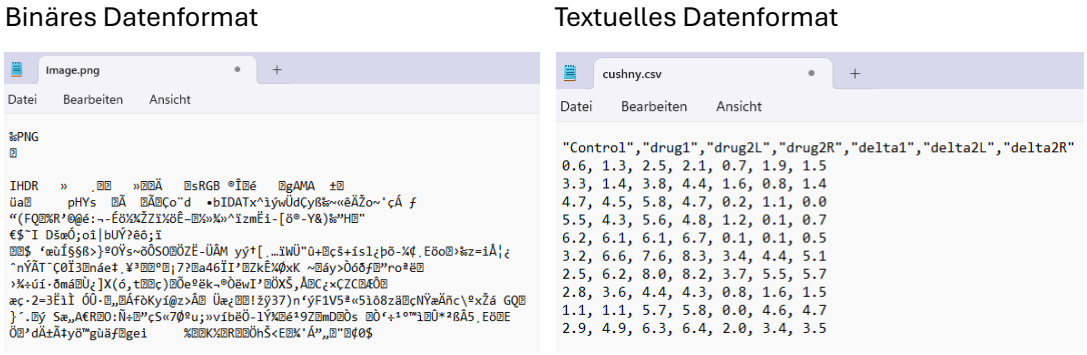


Abbildung 17.1. Binäre und textuelle Dateiformate in Editordarstellung.

17.2.1. .csv- und .tsv-Dateien

.csv- (comma-separated values) und .tsv-Dateien (tab-separated values) sind wichtige Dateiformate zur Speicherung einfacher, tabellarisch strukturierter Daten. Allgemein repräsentieren .csv und .tsv zeilenweise miteinander verknüpfte Datensätze. Dabei werden Datenfelder innerhalb einer Zeile durch Kommata (.csv) oder Tabulatorzeichen (.tsv) und einzelne Datensätze durch Zeilenumbrüche voneinander abgegrenzt. Der Datensatz in der ersten Zeile einer .csv- oder .tsv-Datei enthält typischerweise die Definition der Spaltennamen und wird als Kopfdatensatz (Header) bezeichnet. Ein typisches Beispiel einer .csv-Datei ist in Abbildung 17.1 (rechts) dargestellt. Dabei repräsentieren die Zeilen experimentelle Einheiten (hier Versuchspersonen) und die Spalten verschiedene Variablen, für die jeweils ein Wert bei der Versuchsperson bestimmt wurde.

Im Kontext der Datenanalyse unterscheidet man bei .csv- und .tsv-Dateien eine *Wide-Format*- und eine *Long-Format*-Datenrepräsentation. Bei der Wide-Format- Datenrepräsentation werden alle Variablen einer experimentellen Einheit wie in obigem Beispiel in einer Zeile repräsentiert, vgl. Tabelle 17.1. Allerdings ist es für manche Datenanalysen hilfreicher, die Daten einer experimentellen Einheit über Zeilen zu verteilen. Dies führt auf das sogenannte Long Format, wie in Tabelle 17.2 gezeigt. Generell ist das Wide Format für ein erstes intuitives Verständnis eines Datensatzes oft hilfreicher, wohingegen das Long Format Daten im Rahmen modellbasierter Analysen meist konsistenter mit der Modellarchitektur repräsentiert.

Tabelle 17.1. Wide Format (EE: Experimentelle Einheit, V1,V2,V3: Variablen)

EE	V1	V2	V3
1	10.1	67.5	4
2	12.9	51.2	2
3	20.4	70.8	5
4	17.5	60.3	7

Tabelle 17.2. Long Format (EE: Experimentelle Einheit, V1,V2,V3: Variablen)

Einheit	Variable	Messwert
1	V1	10.1
1	V2	67.5
1	V3	4
2	V1	12.9
2	V2	51.2
2	V3	2
3	V1	20.4
3	V2	70.8
3	V3	5
4	V1	17.5
4	V2	60.3
4	V3	7

17.2.2. .json-Dateien

.json (JavaScript Object Notation) ist ein textuelles Datenformat, das zum Speichern strukturierter Daten in Key-Value-Form verwendet wird. Es weist Ähnlichkeiten mit R-Listen auf, insbesondere mit benannten Listenelementen, und eignet sich daher gut als Format für die Speicherung von Metadaten.

Eine .json-Datei besteht aus Objekten, die in geschweiften Klammern { } notiert werden und eine durch Kommata getrennte Liste von Eigenschaften enthalten. Jede Eigenschaft ist ein Key-Value-Paar, wobei der Key immer als String in Anführungszeichen (” “) geschrieben wird. Der Value kann wiederum ein Objekt, ein Array, ein String, ein Boolean oder eine Zahl sein. Abbildung Abbildung 17.2 zeigt den Inhalt einer .json-Datei zur Speicherung von Studierendeninformationen.

```
{
    "Vorname" : "Maxi",
    "Nachname" : "Musterfrau",
    "Matrikelnummer" : 12345,
    "Fachsemester" : 2,
    "Studiengang" : "BSc Psychologie",
    "Module" :
    {
        "Deskriptive Statistik" : {"Abgeschlossen"' : TRUE, "Note" : 1.0 },
        "Inferenzstatistik" : {"Abgeschlossen" : FALSE, "Note": NA }
    }
}
```

Abbildung 17.2. .json-Dateiformat.

17.3. Verzeichnismanagement

Da Verzeichnissysteme von Computern üblicherweise in Worten (z. B. `C:\Users`) statt numerisch dargestellt sind, ist eine Grundlage für das automatisierte Einlesen von langfristig gespeicherten Daten in den Arbeitsspeicher und umgekehrt das Speichern von Daten aus dem Arbeitsspeicher im langfristigen Speicher das Arbeiten mit sogenannten *Strings* (Zeichenketten). Strings werden in **R** mit Anführungszeichen oder Hochkommata erzeugt:

```
# Anführungszeichen begrenzen Zeichenketten
c("Dies ist ein character vector")
```

```
[1] "Dies ist ein character vector"
```

```
# Hochkommata erlauben Anführungszeichen in der Zeichenkette
c('Dies ist ein "string"')
```

```
[1] "Dies ist ein \"string\""
```

Die Funktion `paste()` konvertiert Vektoren in character und fügt sie elementweise zusammen.

```
# Konvertierung und Konkatenation einelementiger double-Vektoren
paste(1,2)
```

```
[1] "1 2"
```

```
# Einelementige Zeichenvektoren zusammenfügen
paste("Dies ist", "ein String")
```

```
[1] "Dies ist ein String"
```

Die Funktion `paste()` hat darüber hinaus eine Reihe weiterer Funktionalitäten, die manchmal hilfreich sein können:

```
# Wiederholung von Vektorelementen, elementweise Verknüpfung
paste(c("Rote", "Gelbe"), "Blume")
```

```
[1] "Rote Blume"  "Gelbe Blume"
```

```
# Trennzeichen festlegen
paste(c("Rote", "Gelbe"), "Blume",  sep = "-")
```

```
[1] "Rote-Blume"  "Gelbe-Blume"
```

```
# Mit dem gewählten Trennzeichen zusammenfügen
paste(c("Rote", "Gelbe"), "Blume",  collapse = ", ")
```

```
[1] "Rote Blume, Gelbe Blume"
```

Die Funktion `toString()` ist eine `paste()`-Variante für numerische Vektoren:

```
# double-Vektor in eine formatierte Zeichenkette umwandeln
toString(1:10)
```

```
[1] "1, 2, 3, 4, 5, 6, 7, 8, 9, 10"
```

```
# Ausgabe auf width Zeichen begrenzen
toString(1:10, width = 10)
```

```
[1] "1, 2, ...."
```

Um nun die Daten einer Datei im Langzeitspeicher in den Arbeitsspeicher zu laden, benötigt man ihre Adresse in der Verzeichnisstruktur des Computers. Abbildung 17.3 zeigt einen Ausschnitt der Verzeichnisstruktur eines typischen Windows-Rechners.

Die Adressen von Dateien in der Verzeichnisstruktur heißen *Dateipfade* (*paths*). Ein Pfad besteht aus einer durch Schrägstriche getrennten Liste von Verzeichnisnamen. Dabei werden unter Windows traditionell linksgeneigte Schrägstriche (\, *backslash*) und unter Mac und Linux rechtsgeneigte Schrägstriche (/, *slash*) genutzt. Unter Windows findet sich zusätzlich in der Regel an oberster Stelle der Verzeichnisstruktur der Festplattenname (z. B. `C:\` oder `D:\`), unter Mac der Benutzername (`/Users/`) und unter Linux das Heimverzeichnis (`/home/`). Die folgenden Beispiele sind Windows-basiert.

```
# Pfad, der auf einem Verzeichnisnamen endet
C:\Users\dirko\Nextcloud\Home\pdwp-online\dirk-ostwald.github.io\_data

# Pfad, der auf einem Dateinamen endet
C:\Users\dirko\Nextcloud\Home\pdwp-online\dirk-ostwald.github.io\_data\cushny.csv
```

Absolute Dateipfade geben die Adresse eines Verzeichnisses oder einer Datei in der Gesamtverzeichnisstruktur der Festplatte und sind wenig anfällig für Dateiverwechselungen. *Relative Dateipfade* beziehen sich dagegen auf einen Speicherort in Relation zum aktuellen Verzeichnis, wobei `.` und `..` das aktuelle und das übergeordnete Verzeichnis bezeichnen. Bei relativen Dateipfaden kann es durchaus zu Dateiverwechselungen kommen. Generell wird also die Verwendung adaptiv generierter absoluter Pfade empfohlen.

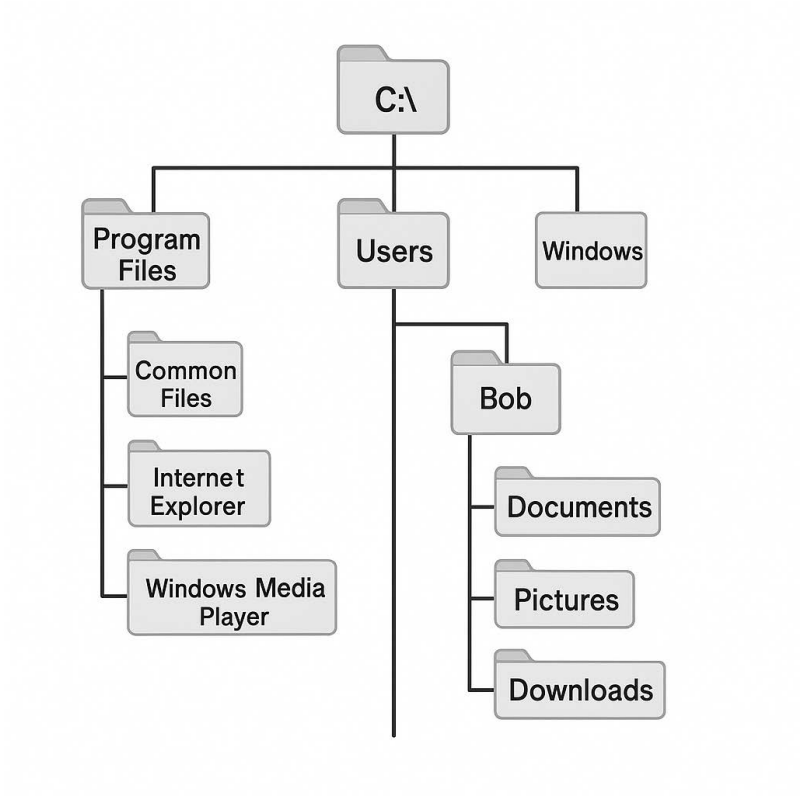


Abbildung 17.3. Windows-Verzeichnisstruktur

```
# Dateiname in absoluter Pfadform
fname =  "D:\Lehre\Daten\cushny.csv"
```

R besitzt ein sogenanntes *working directory*, aus dem per Default Dateien gelesen werden. Bei geöffnetem **R**-Terminal gibt `getwd()` das working directory an.

```
getwd()
```

```
[1] "C:/Home/Home/pdwp-online/dirk-ostwald.github.io/_part_2"
```

`setwd()` ändert das working directory. Dabei ist zu beachten, dass **R** nur mit forward slashes `/` arbeitet. Die manuelle Spezifikation von Windows-Pfaden benötigt deshalb doppelte backward slashes `\\`:

```
setwd("C:\\Users\\dirko\\Nextcloud\\Home\\pdwp-online\\dirk-ostwald.github.io\\_data")
getwd()
```

Mithilfe der Funktion `file.path()` können betriebssystemkonforme Verzeichnis- und Dateipfade erzeugt werden:

```
file.path("D:", "Nextcloud", "Home", "Teaching")
```

Die Funktion `dirname()` gibt das Verzeichnis an, das ein Verzeichnis oder eine Datei enthält:

```
getwd()
```

```
[1] "C:/Home/Home/pdwp-online/dirk-ostwald.github.io/_part_2"
```

```
dirname(getwd())
```

```
[1] "C:/Home/Home/pdwp-online/dirk-ostwald.github.io"
```

Die Funktion `basename()` gibt die unterste Ebene eines Datei- oder Verzeichnispfades an:

```
getwd()
```

```
[1] "C:/Home/Home/pdwp-online/dirk-ostwald.github.io/_part_2"
```

```
basename(getwd())
```

```
[1] "_part_2"
```

17.4. Datenimport und Datenexport

Zum Einlesen von einfach strukturierten .csv-Dateien bietet sich die **R**-Funktion `read.csv()` an. Diese Funktion liest eine Datei ein und speichert ihre Inhalte in einem Dataframe.

```
D = read.csv("_data/cushny.csv")
print(D)
```

```
   Control drug1 drug2L drug2R delta1 delta2L delta2R
1      0.6   1.3    2.5    2.1    0.7     1.9     1.5
2      3.3   1.4    3.8    4.4    1.6     0.8     1.4
3      4.7   4.5    5.8    4.7    0.2     1.1     0.0
4      5.5   4.3    5.6    4.8    1.2     0.1     0.7
5      6.2   6.1    6.1    6.7    0.1     0.1     0.5
6      3.2   6.6    7.6    8.3    3.4     4.4     5.1
7      2.5   6.2    8.0    8.2    3.7     5.5     5.7
8      2.8   3.6    4.4    4.3    0.8     1.6     1.5
9      1.1   1.1    5.7    5.8    0.0     4.6     4.7
10     2.9   4.9    6.3    6.4    2.0     3.4     3.5
```

Folgender **R**-Code definiert den absoluten Pfad der Datei adaptiv in der Verzeichnisstruktur des Computers mithilfe des **R**-Arbeitsverzeichnisses.

```
wdir    = getwd()                          # Arbeitsverzeichnis
ddir    = file.path(wdir, "_part_2/_data") # Datenverzeichnispfad
fname   = "cushny.csv"                     # Dateiname
fpath   = file.path(ddir, fname)           # Dateipfad
D       = read.csv(fpath)                  # Einlesen der Datei
```

Darüber hinaus bietet **R** eine Vielzahl von Möglichkeiten des Datenimports mithilfe spezialisierter Funktionen:

Für .csv-Dateien und andere Textdateien:

- `read.csv()`, `read.csv2()`, `read.delim()`, `read.delim2()` als `read.table()`-Varianten.
- `readLines()` für Low-Level-Textdateiimport.
- `fromJSON()` aus dem Paket `rjson` für .json-Dateien.

Für binäre Dateien:

- `read.xlsx()` und `read.xlsx2()` aus dem Paket `xlsx` für Excel-.xlsx-Dateien.
- `read.spss()` aus dem Paket `foreign` für SPSS-.sav-Dateien.
- `readMat()` aus dem Paket `R.matlab` für MATLAB-.mat-Dateien.

Für Datenbanken:

- SQL-Datenbanken können mithilfe der Pakete `DBI` und `RSQLite` abgefragt werden.

18. Kontrollstrukturen

Per se wird imperativer Programmiercode streng sequentiell Befehl für Befehl ausgeführt. Manchmal möchte man von dieser rein sequentiellen Befehlsreihenfolge allerdings abweichen und die Ausführungsreihenfolge von Befehlen flexibler kontrollieren. Prinzipielle Werkzeuge zu diesem Zweck sind *konditionale Kontrollstrukturen* und *iterative Kontrollstrukturen*. *Konditionale Kontrollstrukturen* steuern die Programmausführung, indem sie festlegen, dass bestimmte Befehle nur dann ausgeführt werden, wenn definierte Bedingungen erfüllt sind. **R** bietet zu diesem Zweck `if()`- und `switch()`-Statements. Oft möchte man bestimmte Codeabschnitte auch in Schleifen häufig wiederholen (*iterieren*). Zu diesem Zweck bietet **R** `for()`-, `while()`- und `repeat()`-Schleifen. In diesem Abschnitt stellen wir die grundlegenden konditionalen und iterativen Kontrollstrukturen in **R** vor und folgen dabei der Darstellung in Cotton (2013), Kapitel 8 und Kapitel 9, sowie Wickham et al. (2019), Kapitel 5.

18.1. Konditionale Kontrollstrukturen

Konditionale Kontrollstrukturen erlauben die bedingungsabhängige Ausführung von Befehlen.

if-Statements

Die grundlegende konditionale Kontrollstruktur ist das if-Statement. Die allgemeine Syntax für ein if-Statement in **R** hat folgende Form:

```
if (Bedingung){
  TrueActions
}
```

Dabei gilt, dass, wenn die Variable `Bedingung` den Wert `TRUE` hat, also wahr ist, die mit `TrueActions` bezeichneten Befehle ausgeführt werden. Ist der Wert der Variablen `Bedingung` dagegen `FALSE`, so werden die Befehle `TrueActions` nicht ausgeführt und die Programmausführung wird in der nächsten Zeile nach dem if-Statement fortgesetzt. Beispielsweise wird in folgendem Code der Befehl `print("x ist größer als 0")` ausgeführt, da `x` ja nach vorheriger Zuordnung den Wert `1` hat.

```
x = 1
if(x > 0){
  print("x ist größer als 0")
}
```

```
[1] "x ist gr<U+00F6><U+00DF>er als 0"
```

Das if-Statement kann durch eine `else`-Bedingung erweitert werden, um zu spezifizieren, welche Befehle in dem Fall ausgeführt werden sollen, dass die Variable `Bedingung` den Wert `FALSE` hat.

```
if (Bedingung){
  TrueActions
} else {
  FalseActions
}
```

Hier werden die Befehle `TrueActions` ausgeführt, wenn die Variable `Bedingung` den Wert `TRUE` hat und es werden die Befehle `FalseActions` ausgeführt, wenn die Variable `Bedingung` den Wert `FALSE` hat. Beispielsweise wird in folgendem Code der Befehl `print("y ist nicht größer als 0")` ausgeführt, da die Bedingung `y > 0` nicht zutrifft.

```
y = -1
if(y > 0){
  print("y ist größer als 0")
} else{
  print("y ist nicht größer als 0")
}
```

```
[1] "y ist nicht gr<U+00F6><U+00DF>er als 0"
```

R umfasst die in Tabelle 18.1 aufgeführten Relationsoperatoren zur Prüfung binärer logischer Bedingungen.

Tabelle 18.1. Relationsoperatoren in **R**

Relationsoperator	Bedeutung
`==`	Gleich
`!=`	Ungleich
`<`, `>`	Kleiner, größer
`<=`, `>=`	Kleiner oder gleich, größer oder gleich
`&`	UND
`|`	ODER

Dabei werden die Relationsoperatoren `<`, `<=`, `>`, `>=` zumeist nur auf numerische Werte angewendet. Die Gleichheitsoperatoren `==`, `!=` können auf beliebige Datenstrukturen angewendet werden, um deren Gleichheit zu überprüfen. Die logischen Verknüpfungen `&` und `|` werden zumeist auf logische Werte angewendet. Die Funktion `xor()` schließlich implementiert das exklusive ODER. Es können beispielsweise folgende Tests auf Gleichheit und Relation durchgeführt werden:

```
# Variablendefinition
x = 1
y = 2

# Test auf Gleichheit
if(x == y){
```

```
  print("x ist gleich y")
} else {
  print("x ist ungleich y")
}
```

```
[1] "x ist ungleich y"
```

```
# Test auf Ungleichheit
if(x < y){
  print("x ist kleiner als y")
} else {
  print("x ist größer oder gleich y")
}
```

```
[1] "x ist kleiner als y"
```

Die if-Statement-Tests können durch logische Bedingungen erweitert werden, wie folgendes Beispiel demonstrieren soll:

```
# Variablendefinition
x = 2
y = 2

# logisches UND/ODER
if(x == y | x < y){
  print("x ist kleiner oder gleich y")
} else {
  print("x ist größer als y")
}
```

```
[1] "x ist kleiner oder gleich y"
```

```
# logisches UND
if(x > y & x != y){
  print("x ist größer als y")
} else {
  print("x ist kleiner oder gleich y")
}
```

```
[1] "x ist kleiner oder gleich y"
```

Bei if-Statements ist es entscheidend, dass die Bedingung einem einzigen logischen Wert entspricht. Folgende Bedingungen sind beispielsweise fehlerhaft:

```
if("x"){
  print(1)
}
```

```
Error in `if ("x") ...`:
! argument is not interpretable as logical
```

```
if(NA){
  print(1)
}
```

```
Error in `if (NA) ...`:
! missing value where TRUE/FALSE needed
```

```
if(c(T,F)){
  print(1)
}
```

```
Error in `if (c(T, F)) ...`:
! the condition has length > 1
```

switch-Statements

Eine weitere konditionale Kontrollstruktur ist das switch-Statement. Switch-Statements sind dadurch motiviert, dass kombinierte if-else-Statements leicht unübersichtlich werden können, wie folgendes Beispiel zeigt:

```
x = 2
if (x == 1){
  print("Aktion 1")
} else if(x == 2){
  print("Aktion 2")
} else if(x == 3){
  print("Aktion 3")
} else if(x == 4){
  print("Aktion 4")
}
```

```
[1] "Aktion 2"
```

Hat man also einen Fall vorliegen, in dem in Abhängigkeit des Wertes einer Variablen eine von vielen Aktionen ausgeführt werden soll, so kann sich ein switch-Statement zur Verbesserung der Codelesbarkeit anbieten. **R** implementiert switch-Statements in der `switch()`-Funktion, die in Abhängigkeit vom Datentyp ihrer Variablen leicht unterschiedlich funktioniert. Ist die switch-Variable vom Typ Integer, so wird die i-te Aktion ausgeführt, wie folgendes Beispiel demonstriert:

```
x = 2                                   # switch-Variable
switch(x,                               # x = 2
print("Aktion 1"),                      # 1. Aktion
print("Aktion 2"),                      # 2. Aktion
print("Aktion 3"),                      # 3. Aktion
print("Aktion 4"))                      # 4. Aktion
```

```
[1] "Aktion 2"
```

Ist die switch-Variable dagegen vom Typ character, so wird die Aktion mit dem entsprechenden Namen ausgeführt:

```
x = "a"                                 # switch-Variable
switch(x,                               # x = "a"
a = print("Aktion a"),                  # a Aktion
b = print("Aktion b"),                  # b Aktion
c = print("Aktion c"),                  # c Aktion
d = print("Aktion d"))                  # d Aktion
```

```
[1] "Aktion a"
```

Generell lässt sich zu if- und switch-Statements festhalten, dass sich jedes if-Statement äquivalent als switch-Statement formulieren lässt und andersherum. If-Statements sind dabei in der Anwendung sicherlich häufiger anzutreffen als switch-Statements. Generell macht es für das menschliche Codeverständnis Sinn, if-else-Statements nicht zu komplex zu formulieren. Ist dies allerdings nötig, so können komplexe if-else-Statements durch switch-Statements vereinfacht werden.

18.2. Iterative Kontrollstrukturen

Iterative Kontrollstrukturen dienen dazu, bestimmte Befehle wiederholt auszuführen. Die grundlegende iterative Kontrollstruktur in **R** ist die `for`-Schleife. Diese hat die generelle Form:

```
for (item in vector){
  perform_action
}
```

Dabei wird der Befehl `perform_action` für jedes `item` in `vector` einmal ausgeführt und der Wert von `item` jeweils aktualisiert. Folgendes Beispiel soll dies verdeutlichen:

```
for (i in 1:3){
  print(i)
}
```

```
[1] 1
[1] 2
[1] 3
```

Der Vektor besteht hier aus `1:3 = [1,2,3]`, der ausgeführte Befehl ist `print(i)` und die `items` sind die Einträge des Vektors. Allerdings muss der Befehl innerhalb der `for`-Schleife nicht zwangsläufig auf die `items` Bezug nehmen, wie folgendes Beispiel zeigt:

```
for (i in 1:3){
  print('a')
}
```

```
[1] "a"
[1] "a"
[1] "a"
```

Hier wird dreimal der konstante Wert `a` ausgegeben. Typischerweise wird innerhalb einer `for`-Schleife etwas erzeugt und gespeichert. Dabei sollte generell die entsprechende Speicherstruktur vorallokiert werden, da dann der entsprechende Platz im Arbeitsspeicher schon bereitgestellt ist und nicht während der Ausführung der `for`-Schleife bereitgestellt werden muss. Der Effizienzgewinn dieser Strategie mag in den meisten Fällen vernachlässigbar sein, allerdings erlaubt dieses Vorgehen auch insbesondere, Fehler leichter zu detektieren, wenn es beispielsweise Dimensionserwartungsunterschiede oder fehlende Einträge gibt, die dann schon als `NaN` alloziert sind. Folgendes Beispiel demonstriert das iterative Auffüllen eines Vektors mit Mittelwerten.

```
nsim  = 3                                  # Anzahl an Simulationen
X_bar = rep(NaN, nsim)                     # Speicherstruktur

# Simulationsiterationen
for(i in 1:nsim){                          # Übliche Iterationsindizes: i, j, k
  X         = rnorm(12)                    # Realisierung von 12 Z-Variablen
  X_bar[i]  = mean(X)                      # Mittelwert der i-ten Realisierung
  print(X_bar)                             # Anzeige zur Demonstration
}
```

```
[1] -0.4457695        NaN        NaN
[1] -0.4457695 -0.2011897        NaN
[1] -0.4457695 -0.2011897 -0.4866380
```

Um linear entlang eines Vektors mit variablen Einträgen zu iterieren, bietet sich die Funktion `seq_along()` an. Diese erzeugt die linearen Indizes `1`, `2`, `3`, … bis zur Länge des betreffenden Vektors, wie folgendes Beispiel demonstriert:

```
mu    = c(0,5,50)                          # Drei Erwartungswertparameter
X_bar = rep(NaN, nsim)                     # Speicherstruktur

# Simulationsiterationen
for(i in seq_along(mu)){                   # Übliche Iterationsindizes: i, j, k
  X         = rnorm(12, mu[i], 1)          # 12 normalverteilte Werte: N(mu, 1)
  X_bar[i]  = mean(X)                      # Mittelwert der i-ten Realisierung
  print(X_bar)                             # Anzeige zur Demonstration
}
```

```
[1] -0.0926322        NaN        NaN
[1] -0.0926322  4.9902793        NaN
[1] -0.0926322  4.9902793 49.9944065
```

`for`-Schleifen können auch geschachtelt werden. Das heißt, innerhalb von `for`-Schleifen können weitere `for`-Schleifen ausgeführt werden. Dies mag etwas gewöhnungsbedürftig sein. Entscheidend ist dabei, dass man sich klarmacht, dass für *jede* Iteration der äußeren Schleife *alle* Iterationen der inneren Schleife durchlaufen werden. Es ist oft hilfreich, sich die generelle Logik einer geschachtelten Schleifenstruktur zunächst mithilfe von `print()`-Statements klarzumachen, wie folgendes Beispiel demonstriert:

```
n_i = 2                                    # Iterationsanzahl der äußeren Schleife
n_j = 3                                    # Iterationsanzahl der inneren Schleife
for(i in 1:n_i){                           # Äußere Schleife
  for (j in 1:n_j){                        # Innere Schleife
    print(c(i,j))                          # Anzeigen der Iterationsindizes [i,j]
    }
}
```

```
[1] 1 1
[1] 1 2
[1] 1 3
[1] 2 1
[1] 2 2
[1] 2 3
```

Folgendes Beispiel etwa erzeugt eine 4 x 5-Matrix, deren Elemente den jeweiligen Spaltenindizes entsprechen. Dabei bedient die innere `for`-Schleife mit der Iteratorvariable `j` die Spaltenindizes und die äußere `for`-Schleife mit der Iteratorvariable `i` bedient die Zeilenindizes:

```
     [,1] [,2] [,3] [,4] [,5]
[1,]    1    2    3    4    5
[2,]    1    2    3    4    5
[3,]    1    2    3    4    5
[4,]    1    2    3    4    5
```

Analog erzeugt folgendes Beispiel eine 4 x 5-Matrix, deren Elemente den jeweiligen Zeilenindizes entsprechen. Dabei bedient die innere `for`-Schleife mit der Iteratorvariable `j` wiederum die Spaltenindizes und die äußere `for`-Schleife mit der Iteratorvariable `i` bedient die Zeilenindizes:

```
     [,1] [,2] [,3] [,4] [,5]
[1,]    1    1    1    1    1
[2,]    2    2    2    2    2
[3,]    3    3    3    3    3
[4,]    4    4    4    4    4
```

In folgendem Beispiel schließlich wird mithilfe zweier geschachtelter `for`-Schleifen und eines `if`-Statements eine 4 x 5-Matrix, deren Elemente gleich den Spaltenindizes sind, wenn der jeweilige Spaltenindex größer oder gleich dem Zeilenindex ist, und deren Elemente ansonsten null sind, erzeugt:

```
     [,1] [,2] [,3] [,4] [,5]
[1,]    1    2    3    4    5
[2,]    0    2    3    4    5
[3,]    0    0    3    4    5
[4,]    0    0    0    4    5
```

Teil III.

Wahrscheinlichkeitstheorie

Die Wahrscheinlichkeitstheorie ist ein mathematisches Modell zur Beschreibung von und zum quantitativen Schlussfolgern über *Zufallsvorgänge* der Realität (Abbildung 18.1). Unter Zufallsvorgängen verstehen wir dabei alle Phänomene, die von uns nicht mit absoluter Sicherheit vorhergesagt werden können, deren Ergebnis also mit Unsicherheit behaftet ist. Offensichtliche und vertraute Beispiele für Zufallsvorgänge sind das Werfen eines Würfels oder einer Münze. Allerdings ist der Begriff des Zufallsvorgangs und damit der Anwendungsbereich der Wahrscheinlichkeitstheorie als sehr viel weiter gefasst zu verstehen. Nicht mit vollständiger Sicherheit vorhersagbar und damit mit Unsicherheit behaftet sind zum Beispiel auch der Ausgang einer Wahl, das morgige Wetter, der Messwert einer Elektroenzephalographie-Elektrode zu einem bestimmten Zeitpunkt oder der Effekt einer Psychotherapieintervention auf den Gesundheitszustand einer Patientin. Beginnt man darüber nachzudenken, welche Phänomene der Realität mit Unsicherheit behaftet sind, so fällt es schwer, nichttriviale Phänomene anzugeben hinsichtlich deren Ergebnis man vollständige Sicherheit besitzt.

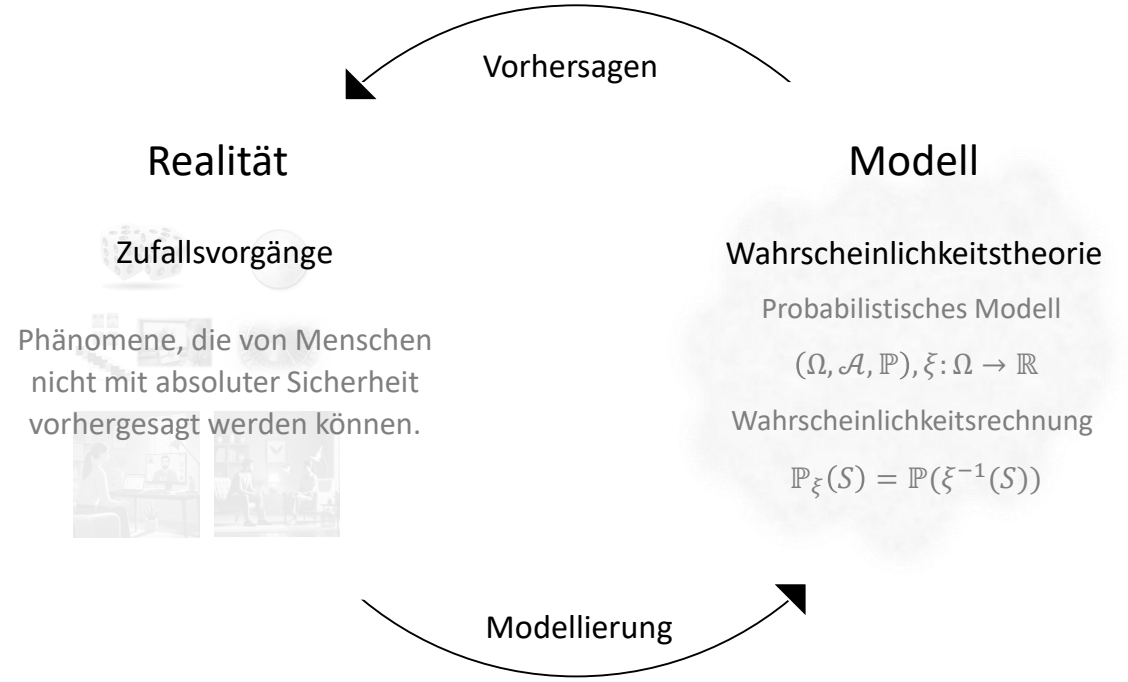


Abbildung 18.1. *Wahrscheinlichkeitstheorie als Modell von Zufallsvorgängen.* Ausgangspunkt der Wahrscheinlichkeitstheorie ist die Absicht, über einen Zufallsvorgang, also ein mit Unsicherheit behaftetes Phänomen der Realität, logisch-quantitative Schlüsse zu ziehen. Die Repräsentation zentraler Aspekte des Zufallsvorgangs mithilfe wahrscheinlichkeitstheoretischer Begrifflichkeiten bezeichnet man als *Modellierung*. Das wahrscheinlichkeitstheoretische Modell selbst garantiert dann im Sinne der Wahrscheinlichkeitsrechnung die Korrektheit logisch-quantitativer Schlussfolgerungen, welche zur Vorhersage von Aspekten des Zufallsvorgangs genutzt werden können.

Als mathematisches Modell von Zufallsvorgängen erlaubt die Wahrscheinlichkeitstheorie insbesondere das vernunftbasierte, quantitative Schlussfolgern über Zufallsvorgänge. Dies schlägt sich primär in der sogenannten *Wahrscheinlichkeitsrechnung* nieder. Quantitative Schlussfolgerungen der Wahrscheinlichkeitsrechnung haben beispielsweise folgende Form: Wenn ich annehme, dass das Ereignis A mit Wahrscheinlichkeit $\mathbb{P}(A)$ und das Ereignis B mit Wahrscheinlichkeit $\mathbb{P}(B)$ eintritt, dann ergibt sich ein Ereignis C eine Wahrscheinlichkeit von $\mathbb{P}(C)$. Dabei ist der Schluss auf die Wahrscheinlichkeit von C logisch-mathematisch abgesichert, in dem gleichen Sinn, wie zum Beispiel logisch-mathematisch

abgesichert ist, dass $1+1=2$ ist. Ob die Annahmen hinsichtlich der Wahrscheinlichkeiten von A und B aber den Gegebenheiten des Zufallsvorgangs in der Realität entsprechen, darüber macht die Wahrscheinlichkeitstheorie keine Aussagen.

Die Wahrscheinlichkeitstheorie selbst bedient sich dabei der mathematischen Theorie der Mengen und Funktionen. Spätestens seit Kolmogoroff (1933) herrscht dabei ein axiomatischer Zugang vor: Man fragt in der Wahrscheinlichkeitstheorie selbst nicht, was denn eine Wahrscheinlichkeit sei oder inwieweit die Vorhersagen der Wahrscheinlichkeitstheorie mit der Realität übereinstimmen, sondern versucht, ein in sich schlüssiges formal-mathematisches System von unbegründeten, aber intuitiv plausiblen, Grundannahmen und ihren Folgerungen zu entwickeln. Ausgangspunkt dieser Entwicklung ist das *Wahrscheinlichkeitsraummodell* eines Zufallsvorgangs, das wir in Kapitel 19 einführen werden. In der Tat gibt es neben dem formal-mathematischen System der Wahrscheinlichkeitstheorie bis heute mathematisch-philosophische Diskussionen darüber, was genau denn unter dem Begriff der "Wahrscheinlichkeit eines Ereignisses" zu verstehen ist. Dabei sind grob gesagt zwei etwas gegensätzliche Interpretationen vorherrschend, zum einen die sogenannte *Frequentistische Interpretation* als prototypisches Beispiel *realistischer Interpretationen*, zum anderen die sogenannte *Bayesianische Interpretation* als allgemeine Form sogenannter *evidenzieller Interpretationen*. Für eine genauere Übersicht verschiedener Interpretationen des Wahrscheinlichkeitsbegriffs, siehe Tabelle 18.2 nach Hájek (2019).

Realistische Interpretationen verstehen Wahrscheinlichkeiten als Eigenschaften der Welt, etwa als relative Häufigkeiten oder physische Neigungen, die unabhängig von unseren Überzeugungen bestehen. Die hier als evidenziell zusammengefassten Interpretationen beziehen Wahrscheinlichkeiten auf Wissen, Information oder Überzeugungen. Dabei unterscheidet Hájek (2019) zwischen dem Grad, in dem vorhandene Evidenz eine Aussage stützt, und dem Grad der Überzeugung einer Person.

Nach der *Frequentistischen Interpretation* ist die Wahrscheinlichkeit eines Ereignisses die idealisierte relative Häufigkeit, mit der ein Ereignis unter den gleichen äußeren Bedingungen einzutreten pflegt. Zum Beispiel ist die Frequentistische Interpretation der Aussage "Mit einer Wahrscheinlichkeit von 1/6 zeigt der Würfel im nächsten Wurf eine 2" die folgende: "Wenn man einen Würfel unendlich oft werfen würde und dabei die relative Häufigkeit des Ereignisses, dass der Würfel eine 2 zeigt, bestimmen würde, dann wäre diese relative Häufigkeit gleich 1/6". Man beachte bei dieser Interpretation, dass man de-facto die Wahrscheinlichkeit eines Ereignisses nicht empirisch bestimmen kann, da man einen Würfel nicht unendlich oft werfen kann. Natürlich kann man die Wahrscheinlichkeit in dieser Interpretation aber empirisch schätzen. Schätzvorgänge selbst wiederum sind allerdings kein Teil der Wahrscheinlichkeitstheorie, sondern der *Inferenz*.

Nach der *Bayesianischen Interpretation* ist die Wahrscheinlichkeit eines Ereignisses der Grad der Sicherheit, den eine Beobachter:in aufgrund ihrer subjektiven Einschätzung der Lage dem Eintreten des Ereignisses zumisst. Zum Beispiel ist die Bayesianische Interpretation der Aussage "Mit einer Wahrscheinlichkeit von 1/6 zeigt der Würfel im nächsten Wurf eine Zwei" dann etwa die folgende: "Basierend auf meiner eigenen und der tradierten Erfahrung mit dem Werfen eines Würfels bin ich mir zu 16.6% sicher, dass der Würfel beim nächsten Wurf eine Zwei zeigt."

In Modellen von tatsächlich zumindest unter ähnlichen Umständen wiederholbaren Zufallsvorgängen wie dem Werfen eines Würfels ist der Unterschied zwischen Frequentistischer und Bayesianischer Interpretation oft eher subtil. Es gibt aber wie oben angedeutet viele

Realistische Interpretationen

Intuition	Anwendungsfeld	Probleme	Referenzen
Endlich Frequentistisch			
Die Wahrscheinlichkeit einer Münze, Kopf zu zeigen, entspricht der relativen Häufigkeit der Münze, bei endlich vielen Beobachtungen Kopf zu zeigen.	–	Bei einmaligem Münzwurf ergibt sich keine sinnvolle Prädiktion, Wahrscheinlichkeiten ändern sich je nach Beobachtungsreihe, sind also nicht eindeutig definiert.	Venn (1876)
Unendlich Frequentistisch			
Die Wahrscheinlichkeit einer Münze, Kopf zu zeigen, entspricht der relativen Häufigkeit der Münze, bei unendlich vielen Beobachtungen Kopf zu zeigen.	Frequentistische Inferenz	Unendliche Beobachtungsreihen sind empirisch nicht verfügbar. Aus endlich vielen Beobachtungen lässt sich die als Grenzwert interpretierte Wahrscheinlichkeit nur schätzen.	Reichenbach (1949) von Mises (1951)
Propensitär			
Die Wahrscheinlichkeit einer Münze, Kopf zu zeigen, entspricht ihrer inhärenten physischen Neigung im Schwerefeld der Erde Kopf zeigend zu landen.	Kausale Inferenz	Zusammenhang zu relativen Häufigkeiten oder physikalischen Theorien nicht unmittelbar klar.	Peirce (1957) Popper (1959) Gillies (2000)

Evidenzielle Interpretationen

Intuition	Anwendungsfeld	Probleme	Referenzen
Klassisch			
In Abwesenheit weiterer Information sind die Wahrscheinlichkeiten einer Münze, Kopf oder Zahl zu zeigen, gleich.	Glücksspiele, Lehrbücher	Beschränkung auf endliche Ergebnisräume	Laplace (1814) Jaynes (1968)
Subjektiv			
Die Wahrscheinlichkeit einer Münze, Kopf zu zeigen, entspricht dem subjektiven Grad der Unsicherheit, dem ein Beobachter dem Ausgang eines Münzwurfs zuweist.	Bayesianische Inferenz	Kohärenz allein legt die Wahrscheinlichkeiten nicht eindeutig fest. Verschiedene Personen können unterschiedliche kohärente Einschätzungen haben.	De Finetti (1975)
Epistemisch			
Die Wahrscheinlichkeit einer Münze, Kopf zu zeigen, entspricht dem subjektiven Grad der Unsicherheit, dem ein rationaler Beobachter dem Ausgang eines Münzwurfs zuweist.	Bayesianische Inferenz	Zusammenhang zu relativen Häufigkeiten oder physikalischen Theorien nicht unmittelbar klar	Ramsey (1926) Jeffreys (1939) Savage (1954)

Tabelle 18.2. Interpretationen von Wahrscheinlichkeit nach Hájek (2019). Die *Frequentistische Interpretation* entspricht in ihren wesentlichen Zügen der *unendlich Frequentistischen realistischen Interpretation*, die *Bayesianische Interpretation* den *subjektiven evidenziellen* und *epistemisch evidenziellen Interpretationen*.

Zufallsvorgänge, die mit Wahrscheinlichkeiten beschrieben werden können, bei denen aufgrund ihrer Einmaligkeit eine Frequentistische Interpretation nicht angemessen ist. Zum Beispiel machen Aussagen der Form “Die Wahrscheinlichkeit dafür, dass die weltweiten Hitzerekorde im Jahr 2023 nicht auf den Klimawandel zurückzuführen sind, ist kleiner als 0.01” (vgl. Philip et al. (2020)) nur unter der Bayesianischen Interpretation Sinn, da es sich bei den Wetteraufzeichnungen des Jahres 2023 um ein einmaliges, nicht wiederholbares Ereignis handelt.

Obwohl also die Interpretation des Begriffes der Wahrscheinlichkeit durchaus nicht eindeutig ist, unterscheiden sich die formalen Definitionen und Rechenregeln für Wahrscheinlichkeiten nicht. Sowohl die Frequentistische als auch die Bayesianische Inferenz haben mit der Wahrscheinlichkeitstheorie ein identisches mathematisches Bezugssystem und gemeinsames Fundament. Im Wesentlichen unterscheidet sich diese Tatsache nicht so sehr von vielen anderen Formen der mathematischen Modellierung. Beispielsweise kann die Ableitung einer Funktion als die Geschwindigkeit eines Objekts oder als die Wachstumsrate einer Bakterienpopulation interpretiert werden. Obwohl sich diese Phänomene intuitiv sehr stark in Bezug auf die Realität unterscheiden, ist das logische Schlussfolgern über beide Phänomene im Bereich der Mathematik identisch.

19. Wahrscheinlichkeitsräume

Ein *Wahrscheinlichkeitsraum* ist ein sehr allgemein gehaltenes formal-mathematisches Modell eines Zufallsvorgangs. Die zentrale Bedeutung dieses Modells für die Wahrscheinlichkeitstheorie und probabilistische Inferenz ergibt sich daraus, dass das Wahrscheinlichkeitsraummodell eine Anleitung dafür gibt, wie man beliebige Zufallsvorgänge, über die man quantitativ schlussfolgern möchte, in das formal-mathematische System der Wahrscheinlichkeitstheorie übersetzen kann. Gleichzeitig garantiert das Wahrscheinlichkeitsraummodell und die auf ihm aufgebauten Konzepte, dass die Mechanik der Wahrscheinlichkeitsrechnung zu logisch sinnvollen quantitativen Schlüssen über Zufallsvorgänge führt. In diesem Kapitel führen wir den Begriff des Wahrscheinlichkeitsraums ein (Kapitel 19.1) und geben dann mithilfe von Wahrscheinlichkeitsfunktionen (Kapitel 19.2) erste Beispiele für die Modellierung von Zufallsvorgängen (Kapitel 19.3).

19.1. Definition und erste Eigenschaften

Wir beginnen mit der Definition des Wahrscheinlichkeitsraummodells nach Kolmogoroff (1933), das wir dann nachfolgend in seinen Einzelteilen aus Frequentistischer Perspektive erläutern wollen.

Definition 19.1 (Wahrscheinlichkeitsraum)**.** Ein *Wahrscheinlichkeitsraum* ist ein Triple $(\Omega, \mathcal{A}, \mathbb{P})$, wobei

- Ω eine beliebige nichtleere Menge von *Ergebnissen* ω ist und *Ergebnismenge* heißt,
- $\mathcal{A}$ eine Menge von Teilmengen von Ω mit den Eigenschaften
  - $\Omega \in \mathcal{A}$,
  - für alle $A \in \mathcal{A}$ gilt, dass auch $A^c := \Omega \setminus A \in \mathcal{A}$,
  - aus $A_1, A_2, ... \in \mathcal{A}$ folgt, dass auch $\cup_{i=1}^{\infty} A_i \in \mathcal{A}$

  ist, *σ-Algebra auf Ω* genannt wird und *Ereignissystem* heißt,
- $\mathbb{P}$ eine Abbildung der Form $\mathbb{P} : \mathcal{A} \to [0, 1]$ mit den Eigenschaften
  - *Nicht-Negativität* $\mathbb{P}(A) \geq 0$ für alle $A \in \mathcal{A}$,
  - *Normiertheit* $\mathbb{P}(\Omega) = 1$ und
  - *σ-Additivität* $\mathbb{P}(\cup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} \mathbb{P}(A_i)$ für paarweise disjunkte $A_i \in \mathcal{A}$

  ist und *Wahrscheinlichkeitsmaß* heißt.

•

Ergebnismenge und Mechanik

Wir beginnen mit Erläuterungen zum Begriff der *Ergebnismenge* Ω und der impliziten Mechanik des Wahrscheinlichkeitsraummodells. Um den Einstieg zu erleichtern, betrachten wir im Folgenden zunächst vor allem *endliche Wahrscheinlichkeitsräume*, bei denen die Kardinalität von Ω nicht unendlich groß ist. Es sei also $|\Omega| < \infty$, Ω habe also nur endlich viele Elemente. Zum Modellieren des Werfens eines Würfels könnte man zum Beispiel $\Omega := \{1, 2, 3, 4, 5, 6\}$ definieren.

Für die hier betrachteten endlichen Ergebnismengen wählen wir $\mathcal{A} = \mathcal{P}(\Omega)$. Damit gehört jede Einzelmenge $\{\omega\}$ zum Ereignissystem.

Hinter der formalen Definition des Wahrscheinlichkeitsraummodells stehen folgende Frequentistisch-geprägten Annahmen über seine Mechanik als Modell eines Zufallsvorgangs. Wir stellen uns zunächst sequentielle Durchgänge eines Zufallsvorgangs vor, also zum Beispiel das wiederholte Werfen eines Würfels. Nach Annahme des Wahrscheinlichkeitsraummodells wird in jedem dieser Durchgänge genau ein ω aus Ω *realisiert*, also als tatsächlich vorliegend ausgewählt. Wirft man zum Beispiel einen Würfel und fällt eine Zwei, so sagt man, dass eine Zwei realisiert wurde. Die Wahrscheinlichkeit, mit der ein ω aus Ω in einem Durchgang realisiert wird, wird durch den Wert $\mathbb{P}(\{\omega\}) \in [0, 1]$ beschrieben. Ist zum Beispiel $\mathbb{P}(\{\omega\}) = 1$, so wird dieses ω in jedem Durchgang des Zufallsvorgangs realisiert, ist $\mathbb{P}(\{\omega\}) = 0$, so wird dieses ω in keinem Durchgang des Zufallsvorgangs realisiert, und ist $\mathbb{P}(\{\omega\}) = 1/2$, so wird ω in etwa der Hälfte der Durchgänge des Zufallsvorgangs realisiert. Beim Modell des Werfens eines fairen Würfels nimmt man üblicherweise $\mathbb{P}(\{\omega\}) = 1/6$ für alle $\omega \in \Omega$ an. Hier könnte zum Beispiel im ersten Durchgang eine Vier realisiert werden, im zweiten Durchgang eine Eins, im dritten Durchgang eine Fünf, dann vielleicht wieder eine Vier und so weiter.

Ereignisse und Ereignissystem

Den Begriff des *Ereignisses* $A \in \mathcal{A}$ stellt man sich am besten als konzeptionelle Zusammenfassung ein oder mehrerer Ergebnisse vor. Beim Werfen eines Würfels sind mögliche Ereignisse zum Beispiel "Es fällt eine gerade Augenzahl", das heißt $\omega \in \{2, 4, 6\}$, "Es fällt eine Augenzahl größer als zwei", das heißt $\omega \in \{3, 4, 5, 6\}$, oder etwa "Es fällt eine Eins oder eine Fünf", das heißt $\omega \in \{1, 5\}$. Man beachte, dass zum Beispiel das Ereignis "Es fällt eine gerade Augenzahl" vor dem Hintergrund der Mechanik des Wahrscheinlichkeitsraums genau dann eintritt, wenn in einem Durchgang des Zufallsvorgangs *Werfen eines Würfels* das realisierte ω ein Element der Menge $\{2, 4, 6\}$ ist, wenn also zum Beispiel eine Vier fällt. Man mag das Eintreten des Ereignisses "Es fällt eine Augenzahl größer als zwei" also auch lesen als "In einem Durchgang des Zufallsvorgangs *Werfen eines Würfels* wird ein Element von $\{3, 4, 5, 6\}$ realisiert", das heißt, konkret fällt entweder eine Drei, eine Vier, eine Fünf oder eine Sechs. Bei der hier gewählten Potenzmenge als Ereignissystem sind auch die Einzelmengen $\{\omega\}$ für $\omega \in \Omega$ Ereignisse, sodass zum Beispiel folgende Interpretationen gelten: Das Ereignis "Es fällt eine Eins" entspricht der Realisation $\omega \in \{1\}$ und das Ereignis "Es fällt eine Sechs" entspricht der Realisation $\omega \in \{6\}$. Betrachtet man in diesem Zusammenhang ein Ergebnis $\omega \in \Omega$ als Ereignis, so nennt man es *Elementarereignis* und schreibt es als einelementige Menge $\{\omega\}$.

Insgesamt entspricht dieses Vorgehen zur Beschreibung zufälliger Ereignisse dem inhärenten Ziel der Definition des Wahrscheinlichkeitsraums. Kolmogoroff (1933) schreibt dazu

"Wir haben die eigentlichen Objekte unserer weiteren Betrachtungen - die zufälligen Ereignisse - als Mengen definiert." Dies hat den Vorteil, dass Mengen mathematische Objekte sind, mit denen mathematisch gearbeitet werden kann und damit ein Aspekt der Realität, ein "zufälliges Ereignis", in den Modellbereich der Mathematik übersetzt wurde.

Alleiniger Sinn des *Ereignissystems* $\mathcal{A}$ ist es nun, alle Ereignisse, die sich basierend auf einer gegebenen Ergebnismenge bei Auswahl eines $\omega \in \Omega$ ergeben können, mathematisch zu repräsentieren. Es soll also keine Ereignisse in der Realität geben, die nicht im Vorhinein im Wahrscheinlichkeitsraummodell des Zufallsvorgangs mitgedacht wurden. Wäre dies der Fall, so wäre das Modell defizitär, da es für bestimmte, in der Realität eintretende Ereignisse keine Wahrscheinlichkeiten angeben könnte. Das Ereignissystem $\mathcal{A}$ soll also die vollständige Menge aller möglichen Ereignisse bei vorgegebenem Ω sein. Die Forderung, dass $\mathcal{A}$ zu diesem Zweck die sogenannten σ-Algebra Kriterien erfüllen soll, begründet sich dabei intuitiv wie folgt.

- Es soll zunächst einmal sichergestellt sein, dass $\omega \in \Omega$ für ein beliebiges ω, dass also irgendein Ergebnis realisiert wird, eines der möglichen Ereignisse ist. Dies entspricht der Eigenschaft $\Omega \in \mathcal{A}$.
- Zu jedem Ereignis A soll auch das Gegenereignis "A tritt nicht ein" zum Ereignissystem gehören. Daher fordern wir, dass mit $A \in \mathcal{A}$ auch $A^c = \Omega \setminus A \in \mathcal{A}$ gilt. Dies impliziert insbesondere auch, dass $\emptyset = \Omega \setminus \Omega \in \mathcal{A}$. Ein Ereignis ist also, dass kein Elementarereignis eintritt, allerdings passiert dies nur mit Wahrscheinlichkeit Null, $\mathbb{P}(\emptyset) = 0$. Es tritt also sicher immer zumindest ein Elementarereignis ein.
- Schließlich soll die Kombination von Ereignissen auch immer ein Ereignis sein. Bei der Modellierung des Werfens eines Würfels soll also zum Beispiel neben den Ereignissen "Es fällt eine gerade Zahl" und "Es fällt eine Zahl größer Zwei" auch das Ereignis "Es fällt eine gerade Zahl und/oder diese Zahl ist größer als zwei" ein Ereignis sein. Dies entspricht, in allgemeinster Form, dass aus $A_1, A_2, ... \in \mathcal{A}$ folgen soll, dass auch $\cup_{i=1}^{\infty} A_i \in \mathcal{A}$ ist.

Wenn auch die Begriffe des Ereignissystems und der σ-Algebra etwas abstrakt anmuten mögen, so stellt ihre Definition in der praktischen Modellierung von Zufallsvorgängen meist keine große Herausforderung dar, da sowohl für endliche Ergebnismengen als auch für unendliche abzählbare und überabzählbare Ergebnismengen passende Ereignissysteme schon lange bekannt sind. So erfüllt bei Ergebnismengen mit endlicher Kardinalität die Potenzmenge der Ergebnismenge immer die Anforderungen eines Ereignissystems und kann immer zur Modellformulierung eines Zufallsvorgangs mit endlicher Ergebnismenge genutzt werden. Dies ist die Aussage folgenden Theorems.

Theorem 19.1 (Ereignissystem bei endlicher Ergebnismenge)**.** *$\Omega := \{\omega_1, \omega_2, ..., \omega_n\}$ mit $n \in \mathbb{N}$ sei eine endliche Menge. Dann ist die Potenzmenge $\mathcal{P}(\Omega)$ von Ω eine σ-Algebra auf Ω und damit ein geeignetes Ereignissystem im Wahrscheinlichkeitsraummodell.*

∘

Beweis. Die Potenzmenge von Ω ist die Menge aller Teilmengen von Ω. Wir überprüfen die σ-Algebra Eigenschaften. Zunächst gilt, dass Ω selbst eine der Teilmengen von Ω ist, also ist die erste σ-Algebra Eigenschaft erfüllt. Sei nun A eine Teilmenge von Ω. Dann ist auch $A^c = \Omega \setminus A$ eine Teilmenge von Ω und somit ist auch die zweite σ-Algebra Eigenschaft erfüllt. Schließlich betrachten wir die Vereinigung von Teilmengen $A_1, A_2, ... \subseteq \Omega$. Dann ist $\cup_{i=1}^{\infty} A_i$ die Menge der $\omega \in \Omega$ für die gilt, dass $\omega \in A_1$ oder $\omega \in A_2$ oder ..., wobei *oder* wie immer nicht-exklusiv als *und/oder* zu verstehen ist. Für jedes $\omega \in \cup_{i=1}^{\infty} A_i$ gilt also, dass ω zumindest Element einer der betrachteten Teilmengen von Ω ist. Damit bilden die $\omega \in \cup_{i=1}^{\infty} A_i$ dann aber selbst eine Teilmenge von Ω und damit ist auch die dritte σ-Algebra Eigenschaft erfüllt. □

Bei überabzählbaren Ergebnismengen wie den reellen Zahlen $\mathbb{R}$ oder dem n-dimensionalen reellen Raum $\mathbb{R}^n$ ist die Konstruktion eines geeigneten Ereignissystems komplexer, sodass wir in dieser Hinsicht für formale Entwicklungen auf die weiterführende Literatur verweisen wollen (vgl. Meintrup & Schäffler (2005), Schmidt (2009)). Mit der auf Borel (1898) zurückgehenden sogenannten *Borelschen σ-Algebra* ist jedoch ein Mengensystem bekannt, das den Anforderungen einer σ-Algebra auf überabzählbaren Ergebnismengen genügt. Wir bezeichnen die Borelsche σ-Algebra auf $\mathbb{R}$ mit $\mathcal{B}(\mathbb{R})$ und die Borelsche σ-Algebra auf $\mathbb{R}^n$ mit $\mathcal{B}(\mathbb{R}^n)$. Die Borelsche σ-Algebra auf $\mathbb{R}$ ist die kleinste σ-Algebra, die alle offenen Teilmengen von $\mathbb{R}$ enthält. Sie enthält insbesondere alle Intervalle und Einzelmengen, aber nicht sämtliche Teilmengen von $\mathbb{R}$. Entsprechend ist die Borelsche σ-Algebra auf $\mathbb{R}^n$ durch dessen offene Teilmengen erzeugt.

Insgesamt ergibt sich also folgendes Vorgehen zur Auswahl von Ereignissystemen in Abhängigkeit von der Ergebnismenge Ω. Ist Ω endlich, so wählt man als Ereignissystem $\mathcal{A}$ die Potenzmenge $\mathcal{P}(\Omega)$ von Ω. Ist Ω gegeben durch $\mathbb{R}$, so wählt man als Ereignissystem $\mathcal{A}$ die Borelsche σ-Algebra $\mathcal{B}(\mathbb{R})$. Ist Ω schließlich gegeben durch $\mathbb{R}^n$, so wählt man für $\mathcal{A}$ die Borelsche σ-Algebra $\mathcal{B}(\mathbb{R}^n)$. In Spezialfällen und für sehr spezielle Ergebnismengen Ω mag man von diesem Vorgehen abweichen wollen, allgemein decken die drei betrachteten Fälle jedoch die meisten Anwendungen ab.

Wahrscheinlichkeitsmaß $\mathbb{P}$

Mit Ω und $\mathcal{A}$, die in Tupleform $(\Omega, \mathcal{A})$ auch als *Messraum* bezeichnet werden, haben wir bisher die *strukturelle Basis* eines Wahrscheinlichkeitsraummodells genauer betrachtet. Viele Wahrscheinlichkeitsräume, zum Beispiel für Zufallsvorgänge die reellen Zahlen betreffend, sind hinsichtlich ihres Messraums identisch. Das *Wahrscheinlichkeitsmaß* $\mathbb{P}$ nun repräsentiert die probabilistischen Charakteristika eines Wahrscheinlichkeitsraummodells und formt damit die *funktionelle Basis* eines solchen. Wir werden im Folgenden, insbesondere nach Einführung der Begriffe der Zufallsvariablen und Zufallsvektoren, sehr viele verschiedene Wahrscheinlichkeitsmaße kennenlernen. An dieser Stelle wollen wir zunächst nur allgemeine Eigenschaften von Wahrscheinlichkeitsmaßen betrachten.

Mit der Definition

$$\mathbb{P} : \mathcal{A} \to [0, 1], A \mapsto \mathbb{P}(A) \tag{19.1}$$

gilt zunächst einmal, dass ein Wahrscheinlichkeitsmaß auf einer Menge von Mengen definiert ist und den Elementen dieser Menge, also den Mengen $A \in \mathcal{A}$, Wahrscheinlichkeiten, also Werte im Intervall $[0, 1]$, zuordnet. Bei der Wahl $\mathcal{A} = \mathcal{P}(\Omega)$ für endliches Ω gehört jede Einzelmenge $\{\omega\}$ zum Ereignissystem. Daher ordnet $\mathbb{P}$ jedem Elementarereignis eine Wahrscheinlichkeit zu. Wir betonen auch, dass nach Definition die Wahrscheinlichkeit $\mathbb{P}(A)$ eines Ereignisses $A \in \mathcal{A}$ eine Zahl im Intervall $[0, 1]$ ist und nicht etwa eine Prozentzahl oder ein Verhältnis. Wir wollen nachfolgend die definierenden Eigenschaften der *Nicht-Negativität*, der *Normiertheit* und der *σ-Additivität* von $\mathbb{P}$ näher beleuchten.

Die *Nicht-Negativität* $\mathbb{P}(A) \geq 0$ für alle $A \in \mathcal{A}$ ist natürlich in der Definition $[0, 1]$ der Zielmenge von $\mathbb{P}$ implizit. Tatsächlich ist die Abbildungsform von $\mathbb{P}$ eine von uns vorgenommene Ergänzung der Formulierung von Kolmogoroff (1933), die der Klarheit dienen soll. Formal folgt die Form der Zielmenge von $\mathbb{P}$ eigentlich aus den definierenden Eigenschaften der Nicht-Negativität, Normiertheit und σ-Additivität von $\mathbb{P}$.

Die *Normiertheit* $\mathbb{P}(\Omega) = 1$ entspricht der Tatsache, dass in jedem Durchgang eines Zufallsvorgangs sicher gilt, dass ein realisiertes ω ein Element von Ω ist. In jedem Durchgang eines Zufallsvorgangs tritt also ein Elementarereignis ein und, je nach Beschaffenheit des Messraums, noch viele weitere. Beim Modell des Werfens eines Würfels gilt also, dass das in einem Durchgang des Zufallsvorgangs realisierte Ergebnis/Elementarereignis mit Wahrscheinlichkeit 1 ein Element von $\Omega := \{1, 2, 3, 4, 5, 6\}$ ist. Ist das realisierte Ergebnis zum Beispiel eine Eins, so treten neben dem Ereignis "Es fällt eine Eins" auch noch die Ereignisse "Eine ungerade Zahl fällt", "Eine Zahl kleiner als drei fällt", "Eine ungerade Zahl kleiner als drei fällt" und viele weitere ein.

Die *σ-Additivität des Wahrscheinlichkeitsmaßes* $\mathbb{P}$ schließlich bildet das Fundament der *Wahrscheinlichkeitsrechnung*, also die Grundlage für das Rechnen mit Wahrscheinlichkeiten. Die σ-Additivität von $\mathbb{P}$ erlaubt es nämlich, aus bereits bekannten Ereigniswahrscheinlichkeiten die Wahrscheinlichkeiten anderer Ereignisse zu berechnen. Man kann damit basierend auf einer Definition von $\Omega, \mathcal{A}$ und $\mathbb{P}$ also Wahrscheinlichkeiten für alle möglichen Ereignisse eines Wahrscheinlichkeitsraummodells berechnen. Ob diese Wahrscheinlichkeiten nun aber tatsächlich etwas mit den realen Ereignissen bezüglich eines Zufallsvorgangs der Realität zu tun haben, kommt darauf an, ob die Modellierung einigermaßen gelungen ist oder nicht. Dabei werden berechnete Wahrscheinlichkeiten aber zumindest rational, also nach den Regeln der Vernunft, das heißt der Logik und der Mathematik, bestimmt. Insgesamt erlaubt das Wahrscheinlichkeitsmodell damit das schlussfolgernde Nachdenken über Zufallsvorgänge, also mit Unsicherheit behaftete Phänomene.

Zur Begründung der Abzählbarkeit bei σ-Algebren und σ-Additivität

Sowohl die Definition einer σ-Algebra als auch die σ-Additivität beziehen sich auf abzählbare Familien von Ereignissen. Warum fordert die Definition des Wahrscheinlichkeitsraums aber auch bei überabzählbaren Ergebnismengen keine Abgeschlossenheit unter beliebigen Vereinigungen und keine Additivität für beliebige Summen? Wir erläutern dies im Folgenden anhand der Gleichverteilung auf $\Omega = [0, 1]$, bei der wir einem Teilintervall eine Wahrscheinlichkeit gemäß seiner Länge zuordnen wollen. Für $0 \leq a \leq b \leq 1$ soll also

$$\mathbb{P}([a, b]) := b - a \tag{19.2}$$

gelten. Dies impliziert unmittelbar

$$\mathbb{P}(\{a\}) = \mathbb{P}([a, a]) = a - a = 0 \quad \text{und} \quad \mathbb{P}([0, 1]) = 1. \tag{19.3}$$

Warum abzählbare Vereinigungen $\bigcup_{i=1}^{\infty} A_i$?

Die Abgeschlossenheit der σ-Algebra unter abzählbaren Vereinigungen stellt sicher, dass auch Ereignisse, die durch eine Folge von Ereignissen beschrieben werden, zum Ereignissystem gehören. Zum Beispiel soll die Aussage „Mindestens eines der Ereignisse $A_1, A_2, ...$ tritt ein" wiederum ein Ereignis beschreiben, wobei jedes einzelne A_i selbst überabzählbar viele Ergebnisse enthalten darf. Eine Forderung nach Abgeschlossenheit unter beliebigen Vereinigungen wäre nun wesentlich stärker. Für die Gleichverteilung auf $[0, 1]$ gehören alle einelementigen Mengen $\{x\}$ zum Ereignissystem. Da sich jede Teilmenge $A \subseteq [0, 1]$ als Vereinigung ihrer einelementigen Teilmengen schreiben lässt, würde diese stärkere Forderung bedeuten, dass jede Teilmenge ein Ereignis sein müsste:

$$A = \bigcup_{x \in A} \{x\}. \tag{19.4}$$

Allerdings gibt es Teilmengen des Intervalls, denen sich keine Länge zuweisen lässt, wenn die üblichen Eigenschaften eines Längenmaßes, insbesondere Verschiebungsinvarianz und abzählbare Additivität, erhalten bleiben sollen. Beispiele hierfür sind sogenannte *Vitali-Mengen* (vgl. Billingsley, 1995, Abschnitt 3, S. 45).

Dies begründet auch, warum man für Wahrscheinlichkeitsmodelle auf $\mathbb{R}$ üblicherweise die *Borelsche σ-Algebra* $\mathcal{B}(\mathbb{R})$ als Ereignissystem verwendet. Sie ist die kleinste σ-Algebra, die alle offenen Teilmengen von $\mathbb{R}$ enthält. Insbesondere enthält sie alle Intervalle und Einzelpunkte sowie alle Mengen, die daraus durch wiederholte Komplementbildung und abzählbare Vereinigungen oder Durchschnitte entstehen. Damit umfasst sie die üblichen Ereignisse wie „Das Ergebnis liegt zwischen a und b“, ohne sämtliche Teilmengen von $\mathbb{R}$ zu Ereignissen erklären zu müssen. Es gilt

$$\mathcal{B}(\mathbb{R}) \subset \mathcal{P}(\mathbb{R}). \tag{19.5}$$

Die Potenzmenge $\mathcal{P}(\mathbb{R})$ ist dabei nicht grundsätzlich als Ereignissystem ausgeschlossen. Beispielsweise lässt sich auf ihr ein Wahrscheinlichkeitsmaß definieren, das einem einzigen Ergebnis Wahrscheinlichkeit eins zuweist. Sie ist jedoch zu groß, wenn man allen Teilmengen die üblichen längenbasierten Wahrscheinlichkeiten zuweisen und dabei die genannten Eigenschaften erhalten möchte. Die Borelsche σ-Algebra bietet dafür einen geeigneten Ausgangspunkt. Auch größere Ereignissysteme sind möglich, beispielsweise die σ-Algebra der Lebesgue-messbaren Mengen, die ebenfalls nicht die gesamte Potenzmenge umfasst (vgl. Billingsley, 1995, Abschnitt 2 und 3).

Warum abzählbare Summation $\sum_{i=1}^{\infty} \mathbb{P}(A_i)$?

Bei der Gleichverteilung auf $[0, 1]$ gilt für jedes $x \in [0, 1]$, dass $\mathbb{P}(\{x\}) = 0$. Das gesamte Intervall besitzt dagegen Wahrscheinlichkeit eins. Würde man Additivität auch für überabzählbare Familien paarweise disjunkter Ereignisse verlangen, erhielte man den Widerspruch

$$1 = \mathbb{P}([0, 1]) = \mathbb{P}\left(\bigcup_{x \in [0,1]} \{x\}\right) = \sum_{x \in [0,1]} \mathbb{P}(\{x\}) = 0. \tag{19.6}$$

Die σ-Additivität führt zu keinem solchen Widerspruch, da die Vereinigung aller Einzelpunkte des Intervalls überabzählbar ist. Die Beschränkung auf abzählbare Summen ermöglicht somit Wahrscheinlichkeitsmodelle, bei denen einzelne Ergebnisse Wahrscheinlichkeit null besitzen, ihre Gesamtheit aber Wahrscheinlichkeit eins hat (vgl. Billingsley, 1995, Abschnitt 2 und 3).

Wir wollen abschließend das auf der σ-Additivität von $\mathbb{P}$ beruhende Rechnen mit Wahrscheinlichkeiten noch an zwei grundlegenden Beispielen verdeutlichen. Das erste Beispiel besagt, dass die Wahrscheinlichkeit dafür, dass das in einem Durchgang eines Zufallsvorgangs realisierte ω kein Element der Ergebnismenge ist, gleich null ist.

Theorem 19.2 (Wahrscheinlichkeit des unmöglichen Ereignisses)**.** *$(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum. Dann gilt*

$$\mathbb{P}(\emptyset) = 0. \tag{19.7}$$

∘

Beweis. Für $i = 1, 2, \ldots$ sei $A_i := \emptyset$. Dann ist $A_1, A_2, \ldots$ eine Folge disjunkter Ereignisse, weil gilt, dass $\emptyset \cap \emptyset = \emptyset$ und es ist $\cup_{i=1}^{\infty} A_i = \emptyset$. Mit der σ-Additivität von $\mathbb{P}$ folgt dann, dass

$$\mathbb{P}(\emptyset) = \mathbb{P}\left(\cup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mathbb{P}\left(A_i\right) = \sum_{i=1}^{\infty} \mathbb{P}\left(\emptyset\right). \tag{19.8}$$

Das unendliche Aufaddieren der Zahl $\mathbb{P}(\emptyset) \in [0, 1]$ soll also wieder $\mathbb{P}(\emptyset)$ ergeben. Dies ist aber nur möglich, wenn $\mathbb{P}(\emptyset) = 0$. □

Fällt der Würfel unerreichbar unter das Sofa, kann seine Augenzahl unbeobachtet bleiben. Soll ein solcher Versuchsausgang ausdrücklich erfasst werden, muss das Modell um ein entsprechendes Ergebnis erweitert werden. Das ursprüngliche Modell weist diesem zusätzlichen Ergebnis keine Wahrscheinlichkeit zu.

Als zweites Beispiel wollen wir zeigen, dass die σ-Additivität, die in der Definition des Wahrscheinlichkeitsraums (nur) für die Vereinigung unendlich vieler disjunkter Ereignisse definiert ist, die σ-Additivität endlich vieler disjunkter Ereignisse, wie sie in der Anwendung oft vorkommen, impliziert.

Theorem 19.3 (σ-Additivität bei endlichen Folgen disjunkter Ereignisse)**.** *$(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und $A_1, ..., A_n$ sei eine endliche Folge paarweise disjunkter Ereignisse. Dann gilt*

$$\mathbb{P}(\cup_{i=1}^{n} A_i) = \sum_{i=1}^{n} \mathbb{P}(A_i). \tag{19.9}$$

∘

Beweis. Wir betrachten eine unendliche Folge von paarweise disjunkten Ereignissen $A_1, A_2, \ldots$ wobei für ein $n \in \mathbb{N}$ gelten soll, dass $A_i := \emptyset$ für $i > n$. Dann gilt mit der σ-Additivität von $\mathbb{P}$ zunächst, dass

$$\mathbb{P}\left(\cup_{i=1}^{n} A_i\right) = \mathbb{P}\left(\cup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mathbb{P}\left(A_i\right) = \sum_{i=1}^{n} \mathbb{P}\left(A_i\right) + \sum_{i=n+1}^{\infty} \mathbb{P}\left(A_i\right). \tag{19.10}$$

Mit $\mathbb{P}\left(A_i\right) = \mathbb{P}(\emptyset) = 0$ für $i = n+1, n+2, \ldots$ folgt dann direkt

$$\mathbb{P}\left(\cup_{i=1}^{n} A_i\right) = \sum_{i=1}^{n} \mathbb{P}\left(A_i\right) + 0 = \sum_{i=1}^{n} \mathbb{P}\left(A_i\right). \tag{19.11}$$

□

Zur Vorbereitung des Begriffs der gemeinsamen Wahrscheinlichkeit von Ereignissen wollen wir abschließend noch eine weitere wichtige Eigenschaft von σ-Algebren betrachten: neben der Abgeschlossenheit von $\mathcal{A}$ unter der Bildung von abzählbaren Vereinigungen ist $\mathcal{A}$ auch unter der Bildung von abzählbaren Durchschnitten abgeschlossen. Dies ist eine direkte Konsequenz der Abgeschlossenheit von $\mathcal{A}$ unter der Bildung von Komplementärmengen und abzählbaren Vereinigungen und wird in folgendem Theorem festgehalten.

Theorem 19.4 (Abgeschlossenheit von σ-Algebren bezüglich Durchschnitten)**.** *$\mathcal{A}$ sei eine σ-Algebra auf einer Menge Ω. Dann folgt aus $A, B \in \mathcal{A}$, dass auch $A \cap B \in \mathcal{A}$. Allgemein gilt für $A_1, A_2, ... \in \mathcal{A}$, dass auch $\cap_{i=1}^{\infty} A_i \in \mathcal{A}$.*

∘

Beweis. Es seien $A_1, A_2, ... \in \mathcal{A}$. Nach Theorem 2.8, Aussage 1., gilt

$$\bigcap_{i=1}^{\infty} A_i = \left(\bigcup_{i=1}^{\infty} A_i^c \right)^c. \tag{19.12}$$

Da $\mathcal{A}$ unter der Bildung von Komplementen abgeschlossen ist, gilt $A_i^c \in \mathcal{A}$ für jedes $i \in \mathbb{N}$. Aus der Abgeschlossenheit unter abzählbaren Vereinigungen folgt

$$\bigcup_{i=1}^{\infty} A_i^c \in \mathcal{A}. \tag{19.13}$$

Erneute Komplementbildung ergibt

$$\bigcap_{i=1}^{\infty} A_i = \left(\bigcup_{i=1}^{\infty} A_i^c \right)^c \in \mathcal{A}. \tag{19.14}$$

Insbesondere folgt für $A, B \in \mathcal{A}$ mit $A_1 = A$ und $A_i = B$ für alle $i \geq 2$, dass

$$A \cap B = \bigcap_{i=1}^{\infty} A_i \in \mathcal{A}. \tag{19.15}$$

□

Nach Theorem 19.4 ist neben den Wahrscheinlichkeiten $\mathbb{P}(A), \mathbb{P}(B)$ und $\mathbb{P}(A \cup B)$ mit $A, B \in \mathcal{A}$ also auch die Wahrscheinlichkeit $\mathbb{P}(A \cap B)$ wohldefiniert.

19.2. Wahrscheinlichkeitsfunktionen

In diesem Abschnitt wollen wir mit den *Wahrscheinlichkeitsfunktionen* eine Möglichkeit kennenlernen, für Wahrscheinlichkeitsräume mit endlicher Ergebnismenge Wahrscheinlichkeitsmaße festzulegen. In Kapitel 21 und Kapitel 22 werden wir Wahrscheinlichkeitsfunktionen unter der Bezeichnung *Wahrscheinlichkeitsmassefunktionen* erneut begegnen. Wir definieren hier den Begriff der Wahrscheinlichkeitsfunktion zunächst wie folgt.

Definition 19.2 (Wahrscheinlichkeitsfunktion)**.** Ω sei eine endliche Menge. Dann heißt eine Funktion $\pi : \Omega \to [0, 1]$ *Wahrscheinlichkeitsfunktion*, wenn gilt, dass

$$\sum_{\omega \in \Omega} \pi(\omega) = 1. \tag{19.16}$$

Sei weiterhin $\mathbb{P}$ ein Wahrscheinlichkeitsmaß auf $(\Omega, \mathcal{P}(\Omega))$. Dann heißt die durch

$$\pi : \Omega \to [0, 1], \omega \mapsto \pi(\omega) := \mathbb{P}(\{\omega\}) \tag{19.17}$$

definierte Funktion *Wahrscheinlichkeitsfunktion* von $\mathbb{P}$ auf Ω.

•

Wir merken an, dass weil $\mathbb{P}$ definitionsgemäß σ-additiv ist, insbesondere auch gilt, dass

$$\mathbb{P}(\Omega) = \mathbb{P}(\cup_{\omega \in \Omega} \{\omega\}) = \sum_{\omega \in \Omega} \mathbb{P}(\{\omega\}) = \sum_{\omega \in \Omega} \pi(\omega) = 1. \tag{19.18}$$

Zur Konstruktion von Wahrscheinlichkeitsmaßen durch Wahrscheinlichkeitsfunktionen stellt folgendes Theorem die formale Basis bereit. Es besagt insbesondere, dass bei endlichem Ω die Wahrscheinlichkeiten *aller* möglichen Ereignisse aus den Wahrscheinlichkeiten der Elementarereignisse $\pi(\omega)$ berechnet werden können.

Theorem 19.5 (Konstruktion eines Wahrscheinlichkeitsmaßes)**.** *Ω sei eine endliche nichtleere Menge, $\mathcal{A} := \mathcal{P}(\Omega)$ und $\pi : \Omega \to [0, 1]$ eine Wahrscheinlichkeitsfunktion. Dann definiert*

$$\mathbb{P} : \mathcal{A} \to [0, 1], \quad A \mapsto \mathbb{P}(A) := \sum_{\omega \in A} \pi(\omega) \tag{19.19}$$

ein Wahrscheinlichkeitsmaß auf $(\Omega, \mathcal{A})$ mit π als Wahrscheinlichkeitsfunktion von $\mathbb{P}$.

∘

Beweis. Wir überprüfen die drei Eigenschaften eines Wahrscheinlichkeitsmaßes.

1. *Nicht-Negativität.* Für jedes $A \in \mathcal{A}$ gilt wegen $\pi(\omega) \in [0, 1]$ für alle $\omega \in \Omega$, dass
$$\mathbb{P}(A) = \sum_{\omega \in A} \pi(\omega) \geq 0. \tag{19.20}$$

2. *Normiertheit.* Da π eine Wahrscheinlichkeitsfunktion ist, summieren sich ihre Funktionswerte über Ω zu eins. Somit gilt
$$\mathbb{P}(\Omega) = \sum_{\omega \in \Omega} \pi(\omega) = 1. \tag{19.21}$$

3. *σ-Additivität.* Seien $A_1, A_2, ... \in \mathcal{A}$ paarweise disjunkte Ereignisse. Dann gilt
$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{\omega \in \bigcup_{i=1}^{\infty} A_i} \pi(\omega) = \sum_{i=1}^{\infty} \sum_{\omega \in A_i} \pi(\omega) = \sum_{i=1}^{\infty} \mathbb{P}(A_i). \tag{19.22}$$

   Zur zweiten Gleichheit beachten wir, dass aufgrund der paarweisen Disjunktheit gilt, dass $\omega \in \bigcup_{i=1}^{\infty} A_i$ äquivalent dazu ist, dass es genau ein $i \in \mathbb{N}$ mit $\omega \in A_i$ gibt. Jedes Ergebnis der Vereinigung gehört also zu genau einem Ereignis A_i, wobei der zugehörige Index i von ω abhängt. Die innere Summe $\sum_{\omega \in A_i} \pi(\omega)$ erfasst für ein festes i nur die Ergebnisse dieses einen Ereignisses. Die äußere Summe über i addiert anschließend die Beiträge aller Ereignisse. Die Summanden werden somit lediglich nach den Ereignissen A_i gruppiert, wobei jeder Summand $\pi(\omega)$ genau einmal berücksichtigt wird. Da Ω endlich ist, sind zudem nur endlich viele der A_i nichtleer, sodass insgesamt nur endlich viele Summanden auftreten.

Damit ist $\mathbb{P}$ ein Wahrscheinlichkeitsmaß auf $(\Omega, \mathcal{A})$. □

Definiert man also für eine gegebene Ergebnismenge Ω eine Funktion $\pi : \Omega \to [0, 1]$ und stellt sicher, dass sich ihre Funktionswerte $\pi(\omega)$ über alle $\omega \in \Omega$ hinweg zu 1 summieren und interpretiert den einzelnen Funktionswert $\pi(\omega)$ dann als die Wahrscheinlichkeit $\mathbb{P}(\{\omega\})$ des Elementarereignisses $\{\omega\} \in \mathcal{A}$, so hat man ein Wahrscheinlichkeitsmaß konstruiert. Definiert man andersherum bei einer endlichen Ergebnismenge Ω für alle Elementarereignisse $\{\omega\} \in \mathcal{A}$ eine Wahrscheinlichkeit $\mathbb{P}(\{\omega\}) \in [0, 1]$ und stellt sicher, dass $\mathbb{P}(\Omega) = 1$ gilt, so erfüllt man implizit natürlich auch die Anforderungen an eine Wahrscheinlichkeitsfunktion. Man kann in diesem Fall die σ—-Additivität von $\mathbb{P}$ für die paarweise disjunkten Elementarereignisse direkt zur Berechnung zusammengesetzter Ereignisse nutzen. Wir verdeutlichen dieses und das Vorgehen mithilfe einer Wahrscheinlichkeitsfunktion in Kapitel 19.3 durch Beispiele.

19.3. Beispiele bei endlichem Ergebnisraum

Aus dem bis hierin Gesagten lässt sich nun zusammenfassend folgendes Vorgehen zur Modellierung eines Zufallsvorgangs mithilfe eines Wahrscheinlichkeitsraums $(\Omega, \mathcal{A}, \mathbb{P})$ festhalten:

(1) In einem ersten Schritt überlegt man sich eine sinnvolle Definition der Ergebnismenge Ω, also der Ergebnisse bzw. Elementarereignisse, die in jedem Durchgang des Zufallsvorgangs realisiert werden sollen.

(2) In einem zweiten Schritt wählt man dann ein geeignetes Ereignissystem. Im Fall einer endlichen Ergebnismenge bietet sich die Potenzmenge $\mathcal{P}(\Omega)$ an.

(3) Im Fall einer endlichen Ergebnismenge definiert man zunächst eine Wahrscheinlichkeitsfunktion $\pi : \Omega \to [0, 1]$, deren Funktionswerte sich über Ω zu eins summieren. Daraus konstruiert man durch

$$\mathbb{P} : \mathcal{A} \to [0, 1], \quad A \mapsto \mathbb{P}(A) := \sum_{\omega \in A} \pi(\omega) \tag{19.23}$$

ein Wahrscheinlichkeitsmaß. Insbesondere folgt daraus für die Wahrscheinlichkeiten der Elementarereignisse

$$\mathbb{P}(\{\omega\}) = \pi(\omega) \quad \text{für alle } \omega \in \Omega. \tag{19.24}$$

In der Folge verdeutlichen wir dieses Vorgehen anhand von Beispielen bei Wahrscheinlichkeitsräumen mit endlicher Ergebnismenge.

Beispiel 19.1 (Würfeln mit einem Würfel)**.** Wir modellieren das Würfeln mit einem Würfel. Es ist sicherlich sinnvoll, die Ergebnismenge als $\Omega := \{1, 2, 3, 4, 5, 6\}$ zu definieren. Allerdings wäre auch die Definition von $\Omega := \{\cdot, \cdot\cdot, \cdot\cdot\cdot, \cdot\cdot\cdot\cdot, \cdot\cdot\cdot\cdot\cdot, \cdot\cdot\cdot\cdot\cdot\cdot\}$ in äquivalenter Weise möglich.

Da es sich um eine endliche Ergebnismenge handelt, wählen wir als σ-Algebra $\mathcal{A}$ die Potenzmenge $\mathcal{P}(\Omega)$. $\mathcal{A}$ enthält dann automatisch alle möglichen Ereignisse. Die Kardinalität von $\mathcal{A} := \mathcal{P}(\Omega)$ ist $|\mathcal{P}(\Omega)| = 2^{|\Omega|} = 2^6 = 64$. In Tabelle 19.1 listen wir sechs dieser 64 Ereignisse in ihrer verbalen Beschreibung und als Teilmenge von Ω auf.

Tabelle 19.1. Ausgewählte Ereignisse beim Modell des Werfens eines Würfels.

Beschreibung	Mengenform
Es fällt eine beliebige Augenzahl	$\omega \in \Omega$
Keine Augenzahl fällt	$\omega \in \emptyset$
Es fällt eine Augenzahl größer als 4	$\omega \in \{5, 6\}$
Es fällt eine gerade Augenzahl	$\omega \in \{2, 4, 6\}$
Es fällt eine Sechs	$\omega \in \{6\}$
Eine Eins, eine Drei oder eine Sechs fällt	$\omega \in \{1, 3, 6\}$

Damit ist die Definition des Messraums $(\Omega, \mathcal{A})$ in der Modellierung des Werfens eines Würfels abgeschlossen.

Für das Modell eines unverfälschten Würfels definieren wir die Wahrscheinlichkeitsfunktion

$$\pi : \Omega \to [0, 1], \quad \omega \mapsto \pi(\omega) := \frac{1}{|\Omega|} = \frac{1}{6}. \tag{19.25}$$

Nach Theorem 19.5 definiert dann

$$\mathbb{P} : \mathcal{A} \to [0,1], \quad A \mapsto \mathbb{P}(A) := \sum_{\omega \in A} \pi(\omega) \tag{19.26}$$

ein Wahrscheinlichkeitsmaß auf $(\Omega, \mathcal{A})$. Insbesondere folgt für die Wahrscheinlichkeiten der Elementarereignisse

$$\mathbb{P}(\{\omega\}) = \pi(\omega) = \frac{1}{6} \quad \text{für alle } \omega \in \Omega. \tag{19.27}$$

Im Fall des unverfälschten Würfels ergibt sich zum Beispiel die Wahrscheinlichkeit für das Ereignis "Es fällt eine gerade Augenzahl" mit der σ-Additivität von $\mathbb{P}$ dann zu

$$\mathbb{P}(\{2,4,6\}) = \mathbb{P}(\{2\} \cup \{4\} \cup \{6\}) = \mathbb{P}(\{2\}) + \mathbb{P}(\{4\}) + \mathbb{P}(\{6\}) = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{3}{6}. \tag{19.28}$$

Für ein Modell eines verfälschten Würfels, der das Werfen einer Sechs bevorzugt, könnten wir dagegen die Wahrscheinlichkeitsfunktion

$$\pi : \Omega \to [0,1], \quad \omega \mapsto \pi(\omega) := \begin{cases} \frac{1}{8}, & \omega \in \{1,2,3,4,5\}, \\ \frac{3}{8}, & \omega = 6 \end{cases} \tag{19.29}$$

definieren. Das durch $\mathbb{P}(A) := \sum_{\omega \in A} \pi(\omega)$ konstruierte Wahrscheinlichkeitsmaß erfüllt dann

$$\mathbb{P}(\{\omega\}) = \frac{1}{8} \quad \text{für } \omega \in \{1,2,3,4,5\} \qquad \text{und} \qquad \mathbb{P}(\{6\}) = \frac{3}{8}. \tag{19.30}$$

Im Fall des obigen Modells eines verfälschten Würfels ergibt sich die Wahrscheinlichkeit für das gleiche Ereignis dagegen zu

$$\mathbb{P}(\{2,4,6\}) = \mathbb{P}(\{2\} \cup \{4\} \cup \{6\}) = \mathbb{P}(\{2\}) + \mathbb{P}(\{4\}) + \mathbb{P}(\{6\}) = \frac{1}{8} + \frac{1}{8} + \frac{3}{8} = \frac{5}{8}. \tag{19.31}$$

Das betrachtete Ereignis hat im Modell des verfälschten Würfels eine höhere Wahrscheinlichkeit als im Modell des unverfälschten Würfels, was intuitiv sinnvoll ist, da die Sechs eine gerade Zahl ist.

△

Beispiel 19.2 (Gleichzeitiges Würfeln mit einem blauen und einem roten Würfel)**.** Wir wollen nun das gleichzeitige Werfen eines blauen und eines roten Würfels modellieren. Dazu ist es sinnvoll, die Ergebnismenge als

$$\Omega := \{(r,b) | r \in \{1,2,3,4,5,6\}, b \in \{1,2,3,4,5,6\}\} \tag{19.32}$$

mit Kardinalität $|\Omega| = 36$ zu definieren. Dabei bezeichnet r die Augenzahl des roten Würfels und b die Augenzahl des blauen Würfels.

Wiederum bietet sich die Wahl der Potenzmenge von Ω als σ-Algebra an, wir definieren also wieder $\mathcal{A} := \mathcal{P}(\Omega)$. Die Anzahl der in diesem Modell möglichen Ereignisse ergibt sich zu $|\mathcal{A}| = 2^{|\Omega|} = 2^{36} = 68.719.476.736$. In Tabelle 19.2 listen wir fünf dieser Ereignisse in ihrer verbalen Beschreibung und als Teilmenge von Ω auf.

Tabelle 19.2. Ausgewählte Ereignisse beim Modell des Werfens eines roten und eines blauen Würfels.

Beschreibung	Mengenform
Auf dem roten Würfel fällt eine Drei	$\omega \in \{(3,1),(3,2),(3,3),(3,4),(3,5),(3,6)\}$
Auf dem blauen Würfel fällt eine Drei	$\omega \in \{(1,3),(2,3),(3,3),(4,3),(5,3),(6,3)\}$
Auf beiden Würfeln fällt eine Drei	$\omega \in \{(3,3)\}$

Beschreibung	Mengenform
Es fällt ein Pasch	$\omega \in \{(1,1),(2,2),(3,3),(4,4),(5,5),(6,6)\}$
Die Summe der gefallenen Zahlen ist vier	$\omega \in \{(1,3),(3,1),(2,2)\}$

Die Definition des Messraums $(\Omega, \mathcal{A})$ ist damit abgeschlossen. Für das Modell zweier unabhängiger fairer Würfel definieren wir die Wahrscheinlichkeitsfunktion

$$\pi : \Omega \to [0,1], \quad \omega \mapsto \pi(\omega) := \frac{1}{|\Omega|} = \frac{1}{36}. \tag{19.33}$$

Nach Theorem 19.5 definiert dann

$$\mathbb{P} : \mathcal{A} \to [0,1], \quad A \mapsto \mathbb{P}(A) := \sum_{\omega \in A} \pi(\omega) \tag{19.34}$$

ein Wahrscheinlichkeitsmaß auf $(\Omega, \mathcal{A})$. Insbesondere folgt für die Wahrscheinlichkeiten der Elementarereignisse

$$\mathbb{P}(\{\omega\}) = \pi(\omega) = \frac{1}{36} \quad \text{für alle } \omega \in \Omega. \tag{19.35}$$

Unter diesem Wahrscheinlichkeitsmaß ergibt sich dann beispielsweise die Wahrscheinlichkeit für das Ereignis "Die Summe der gefallenen Zahlen ist vier" mit der σ-Additivität von $\mathbb{P}$ zu

$$\begin{aligned} \mathbb{P}\left(\{(1,3),(3,1),(2,2)\}\right) &= \mathbb{P}\left(\{(1,3)\} \cup \{(3,1)\} \cup \{(2,2)\}\right) \\ &= \mathbb{P}\left(\{(1,3)\}\right) + \mathbb{P}\left(\{(3,1)\}\right) + \mathbb{P}\left(\{(2,2)\}\right) \\ &= 1/36 + 1/36 + 1/36 \\ &= 1/12. \end{aligned} \tag{19.36}$$

△

Beispiel 19.3 (Werfen einer Münze)**.** Wir modellieren das Werfen einer Münze, deren eine Seite Kopf (Heads) und deren andere Seite Zahl (Tails) zeigt. Es ist sinnvoll, die Ergebnismenge als $\Omega := \{H, T\}$ zu definieren, wobei H "Heads" und T "Tails" repräsentiert. Allerdings wäre auch jede andere binäre Definition von Ω möglich, z.B. $\Omega := \{0,1\}, \Omega := \{-1,1\}$ oder $\Omega := \{1,2\}$.

Die Potenzmenge $\mathcal{A} := \mathcal{P}(\Omega)$ enthält alle möglichen Ereignisse. In diesem Fall können wir das gesamte Mengensystem $\mathcal{A}$ leicht, wie in Tabelle 19.3 gezeigt, komplett auflisten.

Tabelle 19.3. Ereignissystem $\mathcal{A}$ beim Modell des Werfens einer Münze.

Beschreibung	Mengenform
Weder Kopf noch Zahl fällt	$\omega \in \emptyset$
Kopf fällt	$\omega \in \{H\}$
Zahl fällt	$\omega \in \{T\}$
Kopf oder Zahl fällt	$\omega \in \{H, T\}$

Die Definition des Messraums $(\Omega, \mathcal{A})$ ist damit abgeschlossen.

Für das Modell einer Münze definieren wir mit $\mu \in [0,1]$ die Wahrscheinlichkeitsfunktion

$$\pi : \Omega \to [0,1], \quad \omega \mapsto \pi(\omega) := \begin{cases} \mu, & \omega = H, \\ 1-\mu, & \omega = T. \end{cases} \tag{19.37}$$

Nach Theorem 19.5 definiert dann

$$\mathbb{P} : \mathcal{A} \to [0,1], \quad A \mapsto \mathbb{P}(A) := \sum_{\omega \in A} \pi(\omega) \tag{19.38}$$

ein Wahrscheinlichkeitsmaß auf $(\Omega, \mathcal{A})$. Insbesondere folgt für die Wahrscheinlichkeiten der Elementarereignisse

$$\mathbb{P}(\{H\}) = \pi(H) = \mu \qquad \text{und} \qquad \mathbb{P}(\{T\}) = \pi(T) = 1 - \mu. \tag{19.39}$$

Die Normiertheit von $\mathbb{P}$ bedingt hier insbesondere, dass

$$\mathbb{P}(\Omega) = 1 \Leftrightarrow \mathbb{P}(\{H\}) + \mathbb{P}(\{T\}) = 1 \Leftrightarrow \mathbb{P}(\{T\}) = 1 - \mathbb{P}(\{H\}). \tag{19.40}$$

Bei Festlegung der Wahrscheinlichkeit des Elementarereignisses $\{H\}$ wird also die Wahrscheinlichkeit des Elementarereignisses $\{T\}$ sofort mit festgelegt, andersherum gilt dies natürlich ebenso.

Für das Modell einer fairen Münze wählen wir $\mu := 1/2$, also die Wahrscheinlichkeitsfunktion

$$\pi : \Omega \to [0, 1], \quad \omega \mapsto \pi(\omega) := \frac{1}{2}. \tag{19.41}$$

Für das dadurch konstruierte Wahrscheinlichkeitsmaß folgt

$$\mathbb{P}(\{H\}) = \mathbb{P}(\{T\}) = \frac{1}{2}. \tag{19.42}$$

Die Wahrscheinlichkeiten aller möglichen Ereignisse ergeben sich in diesem Fall zu

$$\mathbb{P}(\emptyset) = 0, \quad \mathbb{P}(\{H\}) = 1/2, \quad \mathbb{P}(\{T\}) = 1/2 \quad \text{und} \quad \mathbb{P}(\{H, T\}) = 1. \tag{19.43}$$

△

Beispiel 19.4 (Wert eines BDI-II Items)**.** Wir modellieren den Wert einer Patient:in für das Item "Traurigkeit" der deutschen Version des Beck Depression Inventory II (Hautzinger et al. (2006)),

(0) Ich bin nicht traurig.
(1) Ich bin oft traurig.
(2) Ich bin ständig traurig.
(3) Ich bin so traurig oder unglücklich, dass ich es nicht aushalte.

Der betrachtete Zufallsvorgang sei also die Antwort einer Patient:in für dieses Item. Dabei bietet sich zur Modellierung dann die Ergebnismenge $\Omega := \{0, 1, 2, 3\}$ an. Für eine erste Patient:in ergibt sich beispielsweise die Realisierung $3 \in \Omega$, für eine zweite Patient:in die Realisierung $0 \in \Omega$, für eine dritte Patient:in $1 \in \Omega$ und so weiter. Als Ereignissystem $\mathcal{A}$ bietet sich wiederum die Potenzmenge an. Diese hat im vorliegenden Fall die Kardinalität

$$|\mathcal{P}(\Omega)| = 2^{|\Omega|} = 2^4 = 16 \tag{19.44}$$

und kann wie in Tabelle 19.4 gezeigt leicht vollständig hingeschrieben werden.

Tabelle 19.4. Ausgewählte Ereignisse beim Modell der Beantwortung eines BDI-II Items.

Angegebene Antwort	Mengenform
Keine	$\omega \in \emptyset$
"Ich bin nicht traurig"	$\omega \in \{0\}$
"Ich bin oft traurig"	$\omega \in \{1\}$
"Ich bin ständig traurig"	$\omega \in \{2\}$
"Ich bin so traurig oder unglücklich, dass ich es nicht aushalte"	$\omega \in \{3\}$
"Ich bin nicht traurig" oder "Ich bin oft traurig"	$\omega \in \{0, 1\}$
"Ich bin nicht traurig" oder "Ich bin ständig traurig"	$\omega \in \{0, 2\}$
"Ich bin nicht traurig" oder "Ich bin so traurig oder unglücklich, dass ich es nicht aushalte"	$\omega \in \{0, 3\}$
"Ich bin oft traurig" oder "Ich bin ständig traurig"	$\omega \in \{1, 2\}$
"Ich bin oft traurig" oder "Ich bin so traurig oder unglücklich, dass ich es nicht aushalte"	$\omega \in \{1, 3\}$
"Ich bin ständig traurig" oder "Ich bin so traurig oder unglücklich, dass ich es nicht aushalte"	$\omega \in \{2, 3\}$
Nicht "Ich bin so traurig oder unglücklich, dass ich es nicht aushalte"	$\omega \in \{0, 1, 2\}$
Nicht "Ich bin ständig traurig"	$\omega \in \{0, 1, 3\}$
Nicht "Ich bin oft traurig"	$\omega \in \{0, 2, 3\}$

Angegebene Antwort	Mengenform
Nicht “Ich bin nicht traurig”	$\omega \in \{1, 2, 3\}$
Eine beliebige Antwortmöglichkeit	$\omega \in \{0, 1, 2, 3\}$

Für das Modell der Itemantwort definieren wir die Wahrscheinlichkeitsfunktion

$$\pi : \Omega \to [0, 1], \quad \omega \mapsto \pi(\omega) := \begin{cases} \frac{2}{10}, & \omega = 0, \\ \frac{3}{10}, & \omega = 1, \\ \frac{4}{10}, & \omega = 2, \\ \frac{1}{10}, & \omega = 3. \end{cases} \tag{19.45}$$

Nach Theorem 19.5 definiert dann

$$\mathbb{P} : \mathcal{A} \to [0, 1], \quad A \mapsto \mathbb{P}(A) := \sum_{\omega \in A} \pi(\omega) \tag{19.46}$$

ein Wahrscheinlichkeitsmaß auf $(\Omega, \mathcal{A})$. Insbesondere folgt für die Wahrscheinlichkeiten der Elementarereignisse

$$\mathbb{P}(\{0\}) = \frac{2}{10}, \quad \mathbb{P}(\{1\}) = \frac{3}{10}, \quad \mathbb{P}(\{2\}) = \frac{4}{10}, \quad \mathbb{P}(\{3\}) = \frac{1}{10}. \tag{19.47}$$

Damit ist die Definition des Wahrscheinlichkeitsraummodells $(\Omega, \mathcal{A}, \mathbb{P})$ für das betrachtete Szenario abgeschlossen.

Mithilfe der σ-Additivität von $\mathbb{P}$ lässt sich nun beispielsweise die Wahrscheinlichkeit für eine Itemantwort größer als 1 bestimmen:

$$\mathbb{P}\left(\{2, 3\}\right) = \mathbb{P}\left(\{2\} \cup \{3\}\right) = \mathbb{P}\left(\{2\}\right) + \mathbb{P}\left(\{3\}\right) = \frac{4}{10} + \frac{1}{10} = \frac{5}{10} = \frac{1}{2} \tag{19.48}$$

Ebenso ergibt sich beispielsweise die Wahrscheinlichkeit dafür, dass eine Patient:in eine der beiden Itemantworten “(0) Ich bin nicht traurig” oder “(3) Ich bin so traurig oder unglücklich, dass ich es nicht aushalte” angibt, zu

$$\mathbb{P}\left(\{0, 3\}\right) = \mathbb{P}\left(\{0\} \cup \{3\}\right) = \mathbb{P}\left(\{0\}\right) + \mathbb{P}\left(\{3\}\right) = \frac{2}{10} + \frac{1}{10} = \frac{3}{10}. \tag{19.49}$$

△

Beispiel 19.5 (Handlung eines Agenten)**.** Wir modellieren die registrierte Handlungswahl eines Agenten. Dazu nehmen wir an, der Agent habe drei Handlungsoptionen a, b und c. Wir nehmen weiterhin an, dass der Agent jeder Handlungsoption einen subjektiven *Wert* zumisst. Seien dazu konkret $w_a := -2$, $w_b := 1$ und $w_c := 8$. Ein Agent, der die Handlung mit dem höchsten subjektiven Wert wählt, würde also bei gleichbleibenden Werten immer die Handlungsoption c wählen.

Wir wollen allerdings zulassen, dass bei wiederholter Handlungswahl Störprozesse zwischen der Wahl des Agenten und ihrer Registrierung auftreten. Die von uns registrierte Wahl kann deshalb von der tatsächlichen Wahl des Agenten abweichen. Den Umfang dieser Messfehler beziehungsweise unserer Unsicherheit über die tatsächliche Wahl beschreiben wir durch einen Parameter $\tau \in]0, \infty[$.

Als Ergebnismenge bietet sich $\Omega := \{a, b, c\}$ an. Dabei bezeichnen a, b und c die jeweils registrierte Handlungsoption. Da es sich um eine endliche Ergebnismenge handelt, wählen wir als Ereignissystem wiederum die Potenzmenge $\mathcal{A} := \mathcal{P}(\Omega)$. In Tabelle 19.5 listen wir alle acht möglichen Ereignisse in ihrer verbalen Beschreibung und als Teilmenge von Ω auf. Die Definition des Messraums $(\Omega, \mathcal{A})$ ist damit abgeschlossen.

Tabelle 19.5. Ereignissystem beim Modell der Registrierung der Handlungswahl eines Agenten.

Beschreibung	Mengenform
Keine der drei Handlungsoptionen wird als Wahl registriert	$\omega \in \emptyset$
Als Wahl wird Handlung a registriert	$\omega \in \{a\}$
Als Wahl wird Handlung b registriert	$\omega \in \{b\}$
Als Wahl wird Handlung c registriert	$\omega \in \{c\}$
Als Wahl wird Handlung a oder Handlung b registriert	$\omega \in \{a, b\}$
Als Wahl wird Handlung a oder Handlung c registriert	$\omega \in \{a, c\}$
Als Wahl wird Handlung b oder Handlung c registriert	$\omega \in \{b, c\}$
Eine der drei Handlungsoptionen wird als Wahl registriert	$\omega \in \{a, b, c\}$

Die Wahrscheinlichkeiten für die Registrierung jeder der möglichen Handlungen wollen wir nun anhand der subjektiven Werte modellieren, die der Agent diesen Handlungen zuschreibt. Dazu definieren wir die Wahrscheinlichkeitsfunktion

$$\pi : \Omega \to [0, 1], \quad \omega \mapsto \pi(\omega) := \frac{\exp\left(\tau^{-1} w_\omega\right)}{\sum_{\omega' \in \Omega} \exp\left(\tau^{-1} w_{\omega'}\right)} \tag{19.50}$$

und setzen $\mathbb{P}(\{\omega\}) := \pi(\omega)$. Die Funktionswerte sind positiv und summieren sich zu eins. Damit definiert π eine Wahrscheinlichkeitsfunktion und legt ein Wahrscheinlichkeitsmaß $\mathbb{P}$ fest.

Diese im Bereich der kognitiven Verhaltensmodellierung und künstlichen Intelligenz als *Softmax-Funktion* bezeichnete Zuordnung lässt sich als eine „weichere Maximierung“ verstehen: Anstelle einer ausschließlichen Auswahl der Handlung mit dem höchsten subjektiven Wert werden allen Handlungen positive Wahrscheinlichkeiten zugeordnet. Handlungen mit höheren subjektiven Werten erhalten dabei höhere Wahrscheinlichkeiten. In unserem Modell beschreibt diese Zuordnung die Registrierung der Handlung, während der Agent selbst weiterhin die Handlung mit dem höchsten subjektiven Wert wählt.

Der Parameter τ bestimmt, wie stark sich die Wahrscheinlichkeiten auf die Handlung mit dem höchsten subjektiven Wert konzentrieren. Für kleine Werte von τ wird diese Handlung mit hoher Wahrscheinlichkeit registriert. So gilt für $\tau = 1$, dass

$$\mathbb{P}(\{a\}) \approx 0.00, \quad \mathbb{P}(\{b\}) \approx 0.00, \quad \mathbb{P}(\{c\}) \approx 1.00. \tag{19.51}$$

Wir registrieren also mit an Sicherheit grenzender Wahrscheinlichkeit die Handlung c.

Für größere Werte von τ gleichen sich die Wahrscheinlichkeiten der registrierten Handlungen an. Die Registrierung wird dadurch weniger zuverlässig und die registrierte Handlung schlechter vorhersagbar. So gilt für $\tau = 5$, dass

$$\mathbb{P}(\{a\}) \approx 0.10, \quad \mathbb{P}(\{b\}) \approx 0.18, \quad \mathbb{P}(\{c\}) \approx 0.72, \tag{19.52}$$

und für $\tau = 100$, dass

$$\mathbb{P}(\{a\}) \approx 0.32, \quad \mathbb{P}(\{b\}) \approx 0.33, \quad \mathbb{P}(\{c\}) \approx 0.35. \tag{19.53}$$

Für $\tau \to 0$ nähert sich die Wahrscheinlichkeit für die Registrierung von c dem Wert eins, während die beiden anderen Wahrscheinlichkeiten gegen null gehen. Für $\tau \to \infty$ nähern sich dagegen alle drei Wahrscheinlichkeiten dem Wert 1/3. Die Softmax-Funktion ermöglicht damit einen stetigen Übergang zwischen einer nahezu sicheren Registrierung der wertmaximierenden Handlung und einer nahezu gleichverteilten Registrierung aller Handlungsoptionen.

△

19.4. Literaturhinweise

Die Monographie "Grundbegriffe der Wahrscheinlichkeitsrechnung" von Andrey Kolmogorov (Kolmogoroff (1933)) symbolisiert die Grundlage der modernen Wahrscheinlichkeitsrechnung. Neben der hier diskutierten axiomatischen Einführung des Wahrscheinlichkeitsraummodells betrachtet Kolmogoroff (1933) noch viele weitere Aspekte der Wahrscheinlichkeitsrechnung und bietet so einen gut lesbaren Einstieg in das gesamte Gebiet der Wahrscheinlichkeitstheorie. Natürlich ist der von Kolmogoroff (1933) formulierte Zugang nur ein vorläufiges Endprodukt der langen geschichtlichen Entwicklung der Wahrscheinlichkeitstheorie. Schließlich ist die Entwicklung der mathematischen Modellierung von Zufallvorgängen auch mit Kolmogoroff (1933) keinesfalls an einem Ende angelangt. Spätere Arbeiten im 20. Jahrhundert betrafen insbesondere die Interpretation des Wahrscheinlichkeitsbegriffs (vgl. De Finetti (1975)) oder führen verallgemeinerte quantitative Maße subjektiver Unsicherheit ein (vgl. Walley (1991)). Einen aktuellen Überblick zur Interpretation des Wahrscheinlichkeitsbegriffs und seiner formalen Grundlagen gibt Hájek (2019).

Selbstkontrollfragen

1. Erläutern Sie den Begriff des Zufallsvorgangs.
2. Geben Sie die Definition des Begriffs der σ-Algebra wieder.
3. Geben Sie die Definition des Begriffs des Wahrscheinlichkeitsmaßes wieder.
4. Geben Sie die Definition des Begriffs des Wahrscheinlichkeitsraums wieder.
5. Erläutern Sie den Begriff der Ergebnismenge Ω.
6. Erläutern Sie die stillschweigende Mechanik des Wahrscheinlichkeitsraummodells.
7. Erläutern Sie den Begriff eines Ereignisses $A \in \mathcal{A}$.
8. Erläutern Sie den Begriff des Ereignissystems $\mathcal{A}$.
9. Welche σ-Algebra wählt man sinnvollerweise für einen Wahrscheinlichkeitsraum mit endlicher Ergebnismenge?
10. Erläutern Sie den Begriff des Wahrscheinlichkeitsmaßes $\mathbb{P}$.
11. Geben Sie die Definition des Begriffs der Wahrscheinlichkeitsfunktion wieder.
12. Warum ist der Begriff der Wahrscheinlichkeitsfunktion bei der Modellierung eines Zufallsvorgangs durch einen Wahrscheinlichkeitsraum mit endlicher Ergebnismenge hilfreich?
13. Erläutern Sie die Modellierung des Werfens eines Würfels mithilfe eines Wahrscheinlichkeitsraums.
14. Erläutern Sie die Modellierung des gleichzeitigen Werfens eines roten und eines blauen Würfels mithilfe eines Wahrscheinlichkeitsraums.

Lösungen

1. Ein Zufallsvorgang ist ein Phänomen der Realität, das nicht mit absoluter Sicherheit vorhersagbar ist bzw. für Menschen mit Unsicherheit behaftet ist. Siehe Einleitung zur Wahrscheinlichkeitstheorie.
2. Siehe Definition 19.1 bezüglich $\mathcal{A}$.
3. Siehe Definition 19.1 bezüglich $\mathbb{P}$.
4. Siehe Definition 19.1.
5. Die Ergebnismenge enthält die in einem Durchgang des modellierten Zufallsvorgangs möglichen Elementarereignisse, siehe die Erläuterungen zu **Ergebnismenge und Mechanik**.
6. Siehe die Erläuterungen zu **Ergebnismenge und Mechanik**.
7. Siehe die Erläuterungen zu **Ereignisse und Ereignissysteme**.
8. Siehe die Erläuterungen zu **Ereignisse und Ereignissysteme**.
9. Die Potenzmenge der Ergebnismenge, sie enthält alle prinzipiell möglichen Ereignisse, siehe auch Theorem 19.1.
10. Siehe die Erläuterungen zu **Wahrscheinlichkeitsmaß** $\mathbb{P}$.
11. Siehe Definition 19.2.

12. Durch Definition der Funktionswerte einer Wahrscheinlichkeitsfunktion kann ein Wahrscheinlichkeitsmaß festgelegt werden, siehe auch Kapitel 19.3.
13. Siehe die Erläuterungen zum **Würfeln mit einem Würfel**.
14. Siehe die Erläuterungen zum **Gleichzeitigen Würfeln mit einem blauen und einem roten Würfel**.

20. Elementare Wahrscheinlichkeiten

In diesem Abschnitt führen wir mit den Begriffen der *gemeinsamen Wahrscheinlichkeit* zweier Ereignisse und der *bedingten Wahrscheinlichkeit* eines Ereignisses zwei elementare Formen von Wahrscheinlichkeiten ein. Intuitiv bezieht sich der Begriff der gemeinsamen Wahrscheinlichkeit auf die Wahrscheinlichkeit des "gleichzeitigen" Eintretens zweier Ereignisse A und B und der Begriff der bedingten Wahrscheinlichkeit auf die Wahrscheinlichkeit des Eintretens eines Ereignisses A, "wenn man um das Eintreten eines anderen Ereignisses B weiß". Ist es für die Wahrscheinlichkeit eines Ereignisses A unerheblich, ob ein Ereignis B eingetreten ist oder nicht, so nennt man A und B *unabhängige Ereignisse*. Intuitiv bedeutet die Unabhängigkeit zweier Ereignisse, dass das Wissen um das Eintreten eines Ereignisses die Wahrscheinlichkeit des anderen Ereignisses nicht verändert.

20.1. Gemeinsame Wahrscheinlichkeiten

Der Begriff der gemeinsamen Wahrscheinlichkeit zweier Ereignisse ist wie folgt definiert.

Definition 20.1 (Gemeinsame Wahrscheinlichkeit)**.** $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und es seien $A, B \in \mathcal{A}$. Dann heißt

$$\mathbb{P}(A \cap B) \tag{20.1}$$

die *gemeinsame Wahrscheinlichkeit von A und B*.

•

Wie oben angemerkt entspricht $\mathbb{P}(A \cap B)$ der Wahrscheinlichkeit dafür, dass die Ereignisse A und B "gleichzeitig" eintreten. Dies verdeutlicht man sich am besten vor dem Hintergrund der Mechanik des Wahrscheinlichkeitsraummodells. Danach ist $\mathbb{P}(A \cap B)$ eben die Wahrscheinlichkeit, dass in einem Durchgang eines Zufallsvorgangs ein ω realisiert wird, für das sowohl $\omega \in A$ als auch $\omega \in B$ gelten.

Beispiel 20.1 (Gemeinsame Wahrscheinlichkeit beim fairen Würfel)**.** Als erstes Beispiel für eine gemeinsame Wahrscheinlichkeit zweier Ereignisse wollen wir wieder das Wahrscheinlichkeitsraummodell des Werfens eines fairen Würfels betrachten. Seien dazu A das Ereignis "Es fällt eine gerade Augenzahl", also $A := \{2, 4, 6\}$ und B das Ereignis "Es fällt eine Augenzahl größer als drei", also $B := \{4, 5, 6\}$. Mengentheoretisch gilt dann

$$A \cap B = \{2, 4, 6\} \cap \{4, 5, 6\} = \{4, 6\}. \tag{20.2}$$

Die Interpretation von $A \cap B = \{4, 6\}$ ist dabei gerade "Es fällt eine gerade Augenzahl *und* diese Augenzahl ist größer als Drei". Bei Annahme der Fairness des Würfels, also für $\mathbb{P}(\{4\}) = \mathbb{P}(\{6\}) :=$

1/6 können wir mithilfe der σ-Additivität von $\mathbb{P}$ die Wahrscheinlichkeit dieses Ereignisses leicht berechnen. Es ergibt sich

$$\begin{aligned}\mathbb{P}(A \cap B) &= \mathbb{P}(\{2,4,6\} \cap \{4,5,6\}) \\ &= \mathbb{P}(\{4,6\}) \\ &= \mathbb{P}(\{4\}) + \mathbb{P}(\{6\}) \\ &= \frac{1}{6} + \frac{1}{6} \\ &= \frac{1}{3}.\end{aligned} \tag{20.3}$$

Beim Nachdenken über gemeinsame Wahrscheinlichkeiten ist es natürlich wichtig, die gemeinsame Wahrscheinlichkeit $\mathbb{P}(A \cap B)$ nicht mit der Wahrscheinlichkeit $\mathbb{P}(A \cup B)$ des Ereignisses $A \cup B$ zu verwechseln. Es sei daran erinnert, dass die Vereinigung zweier Mengen $\cup$ dem *inklusiven oder*, also einem *und/oder* entspricht (vgl. Kapitel 1.3 und Kapitel 2.2). Die symmetrische Differenz $A \,\Delta\, B$ entspricht dagegen dem *exklusiven Oder*, also „entweder A oder B, aber nicht beide".

Das Ereignis $A \cup B$ entspricht also dem Ereignis, dass das Ereignis A und/oder das Ereignis B eintritt. Insbesondere ist $\omega \in A \cup B$ also auch schon dann erfüllt, wenn für das Ergebnis eines Durchgangs eines Zufallsvorgangs *nur* $\omega \in A$ oder *nur* $\omega \in B$ gilt. Konkret ergibt sich etwa für die Ereignisse $A := \{2,4,6\}$ und $B := \{4,5,6\}$ aus obigem Würfelbeispiel

$$A \cup B = \{2,4,6\} \cup \{4,5,6\} = \{2,4,5,6\} \tag{20.4}$$

mit der Interpretation "Es fällt eine gerade Augenzahl und/oder es fällt eine Augenzahl größer als drei". Für die entsprechende Wahrscheinlichkeit ergibt sich

$$\mathbb{P}(\{2,4,5,6\}) = \frac{2}{3}, \tag{20.5}$$

sodass in diesem Fall offenbar $\mathbb{P}(A \cap B) \neq \mathbb{P}(A \cup B)$ gilt.

△

Mithilfe folgenden Theorems wollen wir in diesem Abschnitt schließlich noch einige nützliche Eigenschaften zum Rechnen mit Wahrscheinlichkeiten festhalten, die sich direkt aus der Verbindung von Mengenverknüpfungen und der σ-Additivität von Wahrscheinlichkeitsmaßen ergeben. Die benötigten mengentheoretischen Aussagen wurden in Kapitel 2 bewiesen und visualisiert.

Theorem 20.1 (Weitere Eigenschaften von Wahrscheinlichkeiten)**.** *$(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und es seien $A, B \in \mathcal{A}$ Ereignisse. Dann gelten*

1. $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$.
2. $A \subset B \Rightarrow \mathbb{P}(A) \leq \mathbb{P}(B)$.
3. $\mathbb{P}(A \cap B^c) = \mathbb{P}(A) - \mathbb{P}(A \cap B)$
4. $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$.

∘

Beweis. Wir verwenden die in Theorem 2.3 und Theorem 2.4 bewiesenen Aussagen sowie die Normiertheit und σ-Additivität von $\mathbb{P}$. Die Grundmenge ist hier $O = \Omega$; für die Mengen M und N setzen wir die Ereignisse A und B ein.

Zu 1.: Nach Theorem 2.3, Aussagen 1. und 2., gelten $A^c \cup A = \Omega$ und $A^c \cap A = \emptyset$. Mit der Normiertheit und der σ-Additivität von $\mathbb{P}$ folgt dann

$$\mathbb{P}(\Omega) = 1 \Leftrightarrow \mathbb{P}(A^c \cup A) = 1 \Leftrightarrow \mathbb{P}(A^c) + \mathbb{P}(A) = 1 \Leftrightarrow \mathbb{P}(A^c) = 1 - \mathbb{P}(A). \tag{20.6}$$

Zu 2.: Nach Theorem 2.4, Aussage 1., gilt

$$A \subset B \Rightarrow B = A \cup (B \cap A^c) \text{ mit } A \cap (B \cap A^c) = \emptyset. \tag{20.7}$$

Mit der σ-Additivität von $\mathbb{P}$ folgt dann aber

$$\mathbb{P}(B) = \mathbb{P}(A) + \mathbb{P}(B \cap A^c). \tag{20.8}$$

Mit $\mathbb{P}(B \cap A^c) \geq 0$ folgt dann $\mathbb{P}(A) \leq \mathbb{P}(B)$.

Auch bei einer echten Teilmengenbeziehung können zwei Ereignisse dieselbe Wahrscheinlichkeit haben. Betrachten wir beispielsweise einen Wahrscheinlichkeitsraum mit $\Omega = \mathbb{R}$, in dem die Ereignisse $A = [0, 1[$ und $B = [0, 1]$ die Bedingungen $\mathbb{P}(B) > 0$ und $\mathbb{P}(\{1\}) = 0$ erfüllen. Dann ist A eine echte Teilmenge von B, aber es gilt

$$\mathbb{P}(B) = \mathbb{P}(A) + \mathbb{P}(\{1\}) = \mathbb{P}(A). \tag{20.9}$$

Ein konkretes Beispiel liefert die Standardnormalverteilung, die wir später kennenlernen werden.

Zu 3.: Nach Theorem 2.4, Aussage 2., gilt

$$(A \cap B) \cap (A \cap B^c) = \emptyset \text{ und } A = (A \cap B) \cup (A \cap B^c). \tag{20.10}$$

Mit der σ-Additivität von $\mathbb{P}$ folgt dann

$$\mathbb{P}(A) = \mathbb{P}(A \cap B) + \mathbb{P}(A \cap B^c) \Leftrightarrow \mathbb{P}(A \cap B^c) = \mathbb{P}(A) - \mathbb{P}(A \cap B) \tag{20.11}$$

Zu 4.: Nach Theorem 2.4, Aussage 3., gilt

$$B \cap (A \cap B^c) = \emptyset \text{ und } A \cup B = B \cup (A \cap B^c). \tag{20.12}$$

Mit der σ-Additivität von $\mathbb{P}$ folgt dann

$$\mathbb{P}(A \cup B) = \mathbb{P}(B) + \mathbb{P}(A \cap B^c). \tag{20.13}$$

Mit 3. folgt dann

$$\mathbb{P}(A \cup B) = \mathbb{P}(B) + \mathbb{P}(A) - \mathbb{P}(A \cap B). \tag{20.14}$$

□

20.2. Bedingte Wahrscheinlichkeiten

Wir wenden uns nun dem Begriff der bedingten Wahrscheinlichkeit zu.

Definition 20.2 (Bedingte Wahrscheinlichkeit)**.** $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und $A, B \in \mathcal{A}$ seien Ereignisse mit $\mathbb{P}(B) > 0$. Die *bedingte Wahrscheinlichkeit des Ereignisses A gegeben das Ereignis B* ist definiert als

$$\mathbb{P}(A|B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}. \tag{20.15}$$

•

Wir halten fest: Die bedingte Wahrscheinlichkeit $\mathbb{P}(A|B)$ eines Ereignisses A gegeben ein Ereignis B ist die mit $1/\mathbb{P}(B)$ skalierte gemeinsame Wahrscheinlichkeit $\mathbb{P}(A \cap B)$ der Ereignisse A und B. Legt man in der Formulierung eines probabilistischen Modells also die gemeinsame Wahrscheinlichkeit $\mathbb{P}(A \cap B)$ sowie die Wahrscheinlichkeit $\mathbb{P}(B) > 0$ des Ereignisses B fest, so legt man insbesondere auch die bedingte Wahrscheinlichkeit $\mathbb{P}(A|B)$ des Ereignisses A gegeben das Ereignis B fest. Für $\mathbb{P}(A) > 0$ und $\mathbb{P}(B) > 0$ haben die beiden bedingten Wahrscheinlichkeiten denselben Zähler, aber möglicherweise unterschiedliche Nenner (vgl. Herzog & Ostwald (2013)):

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \qquad \text{und} \qquad \mathbb{P}(B|A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}. \tag{20.16}$$

Ist $\mathbb{P}(A \cap B) > 0$, so folgt aus $\mathbb{P}(A) \neq \mathbb{P}(B)$, dass $\mathbb{P}(A|B) \neq \mathbb{P}(B|A)$. Ist dagegen $\mathbb{P}(A \cap B) = 0$, sind beide bedingten Wahrscheinlichkeiten gleich null. Schließlich sei angemerkt, dass eine Verallgemeinerung der bedingten Wahrscheinlichkeit in Definition 20.2 auf den Fall $\mathbb{P}(B) = 0$ möglich, aber technisch aufwändig ist. Wir verweisen dafür auf die weiterführende Literatur, z.B. Meintrup & Schäffler (2005) und Schmidt (2009).

Beispiele

Bedingte Wahrscheinlichkeit beim fairen Würfel - Formale Berechnung

Wir betrachten erneut das Wahrscheinlichkeitsraummodell $(\Omega, \mathcal{A}, \mathbb{P})$ des Werfens eines fairen Würfels mit $\Omega = \{1, 2, 3, 4, 5, 6\}$, $\mathcal{A} = \mathcal{P}(\Omega)$ und $\mathbb{P}(\{\omega\}) = 1/6$ für jedes $\omega \in \Omega$. Wir wollen die bedingte Wahrscheinlichkeit des Ereignisses „Es fällt eine gerade Augenzahl“ gegeben das Ereignis „Es fällt eine Augenzahl größer als drei“ berechnen. Dazu bezeichnen wir die beiden Ereignisse mit

$$A := \{2, 4, 6\} \qquad \text{und} \qquad B := \{4, 5, 6\}. \tag{20.17}$$

Da jedes dieser Ereignisse drei Ergebnisse umfasst, ergibt sich mit der Additivität des Wahrscheinlichkeitsmaßes

$$\mathbb{P}(A) = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{1}{2} \qquad \text{und} \qquad \mathbb{P}(B) = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{1}{2}. \tag{20.18}$$

Der Durchschnitt $A \cap B = \{4, 6\}$ entspricht dem Ereignis „Es fällt eine gerade Augenzahl, die größer als drei ist“. Für seine Wahrscheinlichkeit gilt

$$\mathbb{P}(A \cap B) = \mathbb{P}(\{4, 6\}) = \mathbb{P}(\{4\}) + \mathbb{P}(\{6\}) = \frac{1}{6} + \frac{1}{6} = \frac{1}{3}. \tag{20.19}$$

Wegen $\mathbb{P}(B) = 1/2 > 0$ ist die bedingte Wahrscheinlichkeit von A gegeben B definiert. Durch Einsetzen in die Definitionsgleichung erhalten wir

$$\mathbb{P}(A \mid B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{1/3}{1/2} = \frac{2}{3}. \tag{20.20}$$

Die bedingte Wahrscheinlichkeit ist damit durch das Wahrscheinlichkeitsraummodell und die beiden Ereignisse festgelegt. Im Folgenden betrachten wir zwei unterschiedliche Lesarten des berechneten Wertes.

Bayesianische Lesart - Aktualisierung durch Information

Eine Person wirft einen fairen Würfel unter einem Becher und sieht sich die gefallene Augenzahl an. Ich selbst kann die Zahl nicht sehen. Die Person fragt mich, wie wahrscheinlich es meiner Einschätzung nach ist, dass eine gerade Zahl gefallen ist. Auf Grundlage des Modells des fairen Würfels ordne ich den sechs möglichen Ergebnissen jeweils die Wahrscheinlichkeit 1/6 zu. Für das Ereignis $A = \{2, 4, 6\}$ ergibt sich deshalb

$$\mathbb{P}(A) = \frac{1}{2}. \tag{20.21}$$

Meine Antwort lautet entsprechend: „Die Wahrscheinlichkeit beträgt 1/2." Die Augenzahl steht zu diesem Zeitpunkt bereits fest. Die Wahrscheinlichkeit beschreibt hier meine Unsicherheit darüber, welches Ergebnis realisiert wurde.

Vereinbarungsgemäß teilt mir die Person anschließend wahrheitsgemäß mit, dass die gefallene Zahl größer als drei ist. Ich weiß nun also, dass das Ergebnis im Ereignis $B = \{4, 5, 6\}$ liegt. Meine Einschätzung, dass eine gerade Zahl gefallen ist, beschreibe ich angesichts dieser Information durch die bedingte Wahrscheinlichkeit $\mathbb{P}(A \mid B)$. Wie zuvor berechnet, gilt im Modell des fairen Würfels $\mathbb{P}(A \cap B) = 1/3$ und $\mathbb{P}(B) = 1/2$. Damit ergibt sich

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{1/3}{1/2} = \frac{2}{3}. \tag{20.22}$$

Meine aktualisierte Antwort lautet deshalb: „Die Wahrscheinlichkeit beträgt 2/3."

Die Augenzahl unter dem Becher hat sich durch die Mitteilung nicht verändert. Verändert hat sich mein Informationsstand und damit meine Einschätzung, dass eine gerade Zahl gefallen ist. In dieser Bayesianischen Lesart beschreibt die Wahrscheinlichkeit den Grad meiner Überzeugung, dass ein Ereignis eingetreten ist. Die bedingte Wahrscheinlichkeit $\mathbb{P}(A \mid B)$ beschreibt diese Überzeugung nach Erhalt der Information, dass B eingetreten ist.

Frequentistische Lesart - Relative Häufigkeit in einer Teilfolge

Für die frequentistische Lesart betrachten wir wiederholte Würfe eines fairen Würfels. Wir interessieren uns dafür, wie häufig eine gerade Augenzahl unter denjenigen Würfen auftritt, bei denen die Augenzahl größer als drei ist. Dazu simulieren wir 120 unabhängige Würfe. In unserem Simulationsbeispiel erhalten wir die folgenden Augenzahlen, die zeilenweise gelesen werden:

5	2	**5**	3	**4**	1	**6**	**5**	**5**	3	**6**	3	1	3	3	**4**	2	**6**	2	2
1	1	3	2	**6**	3	**6**	**4**	**5**	**4**	3	1	1	**4**	3	**4**	**4**	2	**5**	2
3	**6**	**4**	**5**	**5**	**6**	2	**6**	2	1	**4**	1	2	**6**	3	**4**	**5**	2	**6**	2
5	**6**	1	1	**4**	2	1	**4**	**4**	**4**	**5**	1	2	2	1	1	**4**	**6**	**6**	3
1	**6**	**6**	1	2	**4**	**5**	3	2	3	1	3	**5**	3	**5**	3	2	**5**	**5**	1
3	3	**6**	2	**6**	**6**	1	1	**6**	**6**	**5**	3	**4**	**4**	2	3	1	1	**4**	3

Aus dieser Folge wählen wir diejenigen Würfe aus, deren Ergebnisse zum Ereignis $B = \{4, 5, 6\}$ gehören. Diese sind fett hervorgehoben. Die ausgeschlossenen Würfe mit den Augenzahlen 1, 2 und 3 sind grau dargestellt. Insgesamt erfüllen 56 der 120 Würfe die Bedingung B.

Unter diesen 56 Würfen zählen wir nun diejenigen, bei denen zusätzlich das Ereignis $A = \{2, 4, 6\}$ eingetreten ist. Dies sind die blau hervorgehobenen Würfe mit einer 4 oder einer 6, also mit einem Ergebnis in $A \cap B = \{4, 6\}$. In unserem Beispiel sind dies 39 Würfe. Die bedingte relative Häufigkeit ergibt sich damit zu

$$\hat{\mathbb{P}}_{120}(A \mid B) := \frac{\text{Anzahl der Würfe mit } A \cap B}{\text{Anzahl der Würfe mit } B} = \frac{39}{56} \approx 0{,}696. \tag{20.23}$$

Der Nenner ist hier die Anzahl der ausgewählten Würfe. Wir bestimmen also den Anteil gerader Augenzahlen innerhalb der durch B festgelegten Teilfolge.

Basierend auf der Definition der bedingten Wahrscheinlichkeit eines Ereignisses unter der Bedingung des Eintretens eines festen Ereignisses B kann man ein Wahrscheinlichkeitsmaß definieren, das die Wahrscheinlichkeiten *aller* Ereignisse des Ereignissystems unter der Bedingung des Eintretens eines festen Ereignisses B angibt. Man nennt dieses Wahrscheinlichkeitsmaß die *bedingte Wahrscheinlichkeit gegeben Ereignis* B.

Theorem 20.2 (Bedingte Wahrscheinlichkeit)**.** *Für ein festes $B \in \mathcal{A}$ mit $\mathbb{P}(B) > 0$ sei*

$$\mathbb{P}(\cdot|B) : \mathcal{A} \to [0, 1], A \mapsto \mathbb{P}(A|B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \tag{20.24}$$

Dann ist $\mathbb{P}(\cdot|B)$ ein Wahrscheinlichkeitsmaß und heißt die bedingte Wahrscheinlichkeit gegeben Ereignis B*.*

∘

Beweis. Wir weisen die definierenden Eigenschaften eines Wahrscheinlichkeitsmaßes nach.

1. *Nicht-Negativität.* $\mathbb{P}(A|B) \geq 0$ für alle $A \in \mathcal{A}$.

Nach Definition der bedingten Wahrscheinlichkeit gilt $\mathbb{P}(A|B) = \mathbb{P}(A \cap B)/\mathbb{P}(B)$ mit $\mathbb{P}(B) > 0$. Mit Theorem 19.4 und der Definition von $\mathbb{P}$ gilt $\mathbb{P}(A \cap B) \geq 0$ und damit folgt die Aussage.

2. *Normiertheit.* $\mathbb{P}(\Omega|B) = 1$.

Es gilt

$$\mathbb{P}(\Omega|B) = \frac{\mathbb{P}(\Omega \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B)}{\mathbb{P}(B)} = 1. \tag{20.25}$$

3. *σ-Additivität.* $\mathbb{P}\left(\cup_{i=1}^{\infty} A_i|B\right) = \sum_{i=1}^{\infty} \mathbb{P}(A_i|B)$ für paarweise disjunkte $A_1, A_2, \ldots \in \mathcal{A}$.

Mit Theorem 2.6 gilt zunächst

$$\left(\bigcup_{i=1}^{\infty} A_i\right) \cap B = \bigcup_{i=1}^{\infty} (A_i \cap B). \tag{20.26}$$

Für $i \neq j$ gilt $A_i \cap A_j = \emptyset$. Nach Theorem 2.7 folgt daraus

$$(A_i \cap B) \cap (A_j \cap B) = \emptyset. \tag{20.27}$$

Die Mengen $A_i \cap B$ sind also ebenfalls paarweise disjunkt. Mit der σ-Additivität von $\mathbb{P}$ folgt damit dann, dass

$$\begin{aligned}
\mathbb{P}\left(\cup_{i=1}^{\infty} A_i|B\right) &= \frac{\mathbb{P}\left((\cup_{i=1}^{\infty} A_i) \cap B\right)}{\mathbb{P}(B)} \\
&= \frac{\mathbb{P}\left(\cup_{i=1}^{\infty} (A_i \cap B)\right)}{\mathbb{P}(B)} \\
&= \frac{\sum_{i=1}^{\infty} \mathbb{P}\left(A_i \cap B\right)}{\mathbb{P}(B)} \\
&= \sum_{i=1}^{\infty} \frac{\mathbb{P}\left(A_i \cap B\right)}{\mathbb{P}(B)} \\
&= \sum_{i=1}^{\infty} \mathbb{P}(A_i|B).
\end{aligned} \tag{20.28}$$

□

Man beachte, dass bei der bedingten Wahrscheinlichkeit $\mathbb{P}(\cdot|B)$ die Rechenregeln der Wahrscheinlichkeitstheorie für die Ereignisse links des Strichs gelten.

Für $\mathbb{P}(B) > 0$ ist $\mathbb{P}(\cdot|B)$ ein Wahrscheinlichkeitsmaß. Insbesondere gilt

$$\mathbb{P}(\Omega|B) = 1. \tag{20.29}$$

Dagegen gilt

$$\mathbb{P}(\Omega \cap B) = \mathbb{P}(B). \tag{20.30}$$

Für $0 < \mathbb{P}(B) < 1$ ist die Abbildung $\mathbb{P}(\cdot \cap B)$ daher nicht normiert und somit kein Wahrscheinlichkeitsmaß. Für $\mathbb{P}(B) = 1$ stimmen beide Abbildungen überein.

Zum Schluss dieses Abschnittes wollen wir noch drei technische Konsequenzen der Definition der bedingten Wahrscheinlichkeit betrachten, die wir als Theoreme formulieren.

Das erste Theorem betrifft den Zusammenhang von gemeinsamen und bedingten Wahrscheinlichkeiten und reiteriert, wie gemeinsame Wahrscheinlichkeiten aus bedingten und totalen Wahrscheinlichkeiten berechnet werden können.

Theorem 20.3 (Gemeinsame und bedingte Wahrscheinlichkeiten)**.** *Es seien $(\Omega, \mathcal{A}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und $A, B \in \mathcal{A}$ mit $\mathbb{P}(A) > 0$ und $P(B) > 0$. Dann gilt*

$$\mathbb{P}(A \cap B) = \mathbb{P}(A|B)\mathbb{P}(B) = \mathbb{P}(B|A)\mathbb{P}(A). \tag{20.31}$$

∘

Beweis. Mit der Definition der jeweiligen bedingten Wahrscheinlichkeit folgen direkt

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \Leftrightarrow \mathbb{P}(A \cap B) = \mathbb{P}(A|B)\mathbb{P}(B) \tag{20.32}$$

und

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(B \cap A)}{\mathbb{P}(A)} \Leftrightarrow \mathbb{P}(A \cap B) = \mathbb{P}(B|A)\mathbb{P}(A). \tag{20.33}$$

□

Ebenso wie das Festlegen von $\mathbb{P}(A \cap B)$ und $\mathbb{P}(A)$ die bedingte Wahrscheinlichkeit $\mathbb{P}(B|A)$ festlegt, legt das Festlegen von $\mathbb{P}(A)$ und $\mathbb{P}(B|A)$ also die gemeinsame Wahrscheinlichkeit $\mathbb{P}(A \cap B)$ fest.

Das nachfolgende sogenannte *Gesetz der totalen Wahrscheinlichkeit* besagt, wie basierend auf gemeinsamen Wahrscheinlichkeiten unbedingte, sogenannte *totale Wahrscheinlichkeiten* berechnet werden können.

Theorem 20.4 (Gesetz der totalen Wahrscheinlichkeit)**.** *$(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und $A_1, ..., A_k$ mit $\mathbb{P}(A_i) > 0$ sei eine Partition von Ω. Dann gilt für jedes $B \in \mathcal{A}$, dass*

$$\mathbb{P}(B) = \sum_{i=1}^{k} \mathbb{P}(B \cap A_i) = \sum_{i=1}^{k} \mathbb{P}(B|A_i)\mathbb{P}(A_i). \tag{20.34}$$

∘

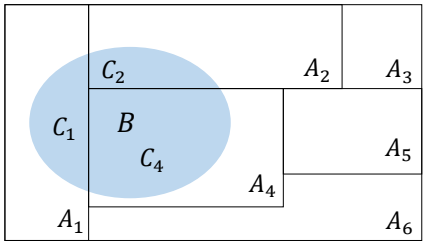


Abbildung 20.1. Venn-Diagramm zum Beweis von Theorem 20.4.

Beweis. Für $i = 1, \ldots, k$ sei $C_i := B \cap A_i$, sodass $\cup_{i=1}^{k} C_i = B$ und $C_i \cap C_j = \emptyset$ für $1 \leq i, j \leq k, i \neq j$. Wir verdeutlichen diese Festlegungen in Abbildung 20.1 mithilfe eines Venn-Diagramms.

Also gilt mit der Definition der bedingten Wahrscheinlichkeit für $\mathbb{P}(A_i) > 0$, dass

$$\mathbb{P}(B) = \sum_{i=1}^{k} \mathbb{P}(C_i) = \sum_{i=1}^{k} \mathbb{P}(B \cap A_i) = \sum_{i=1}^{k} \mathbb{P}(B|A_i)\mathbb{P}(A_i). \tag{20.35}$$

□

Intuitiv entspricht $\mathbb{P}(B)$ also der gewichteten Summe der bedingten Wahrscheinlichkeiten $\mathbb{P}(B|A_i)$, wobei die Gewichtungsfaktoren gerade die unbedingten Wahrscheinlichkeiten $\mathbb{P}(A_i)$ sind.

Die Berechnung einer unbedingten Wahrscheinlichkeit durch Summation gemeinsamer Wahrscheinlichkeiten,

$$\mathbb{P}(B) = \sum_{i=1}^{k} \mathbb{P}(B \cap A_i), \tag{20.36}$$

wird im Kontext von Zufallsvariablen auch als *Marginalisierung* bezeichnet.

Die Forderung $\mathbb{P}(A_i) > 0$ für alle $i = 1, \ldots, k$ ist notwendig, um die gemeinsamen Wahrscheinlichkeiten mithilfe bedingter Wahrscheinlichkeiten (Definition 20.2) darzustellen.

Beispiel 20.2 (Gesetz der totalen Wahrscheinlichkeit beim fairen Würfel)**.** Als Beispiel für die Darstellung der Wahrscheinlichkeit eines Ereignisses mithilfe des Gesetzes der totalen Wahrscheinlichkeit betrachten wir das Wahrscheinlichkeitsraummodell des fairen Würfels. Für den Ergebnisraum $\Omega := \{1, 2, 3, 4, 5, 6\}$ betrachten wir das Ereignis $B := \{2, 4, 6\}$ ("Es fällt eine gerade Zahl") mit Wahrscheinlichkeit $\mathbb{P}(B) = \frac{1}{2}$ sowie die Partition $A_1 := \{1, 2\}$, $A_2 := \{3\}$, $A_3 := \{4, 5\}$, $A_4 := \{6\}$ von Ω. Dann gelten offenbar

$$\begin{array}{rcrcrcl} \mathbb{P}(B \cap A_1) & = & \mathbb{P}(\{2,4,6\} \cap \{1,2\}) & = & \mathbb{P}(\{2\}) & = & \frac{1}{6} \\ \mathbb{P}(B \cap A_2) & = & \mathbb{P}(\{2,4,6\} \cap \{3\}) & = & \mathbb{P}(\emptyset) & = & 0 \\ \mathbb{P}(B \cap A_3) & = & \mathbb{P}(\{2,4,6\} \cap \{4,5\}) & = & \mathbb{P}(\{4\}) & = & \frac{1}{6} \\ \mathbb{P}(B \cap A_4) & = & \mathbb{P}(\{2,4,6\} \cap \{6\}) & = & \mathbb{P}(\{6\}) & = & \frac{1}{6} \end{array} \tag{20.37}$$

Damit ergibt sich dann

$$\begin{aligned} \sum_{i=1}^{4} \mathbb{P}(B \cap A_i) &= \mathbb{P}(B \cap A_1) + \mathbb{P}(B \cap A_2) + \mathbb{P}(B \cap A_3) + \mathbb{P}(B \cap A_4) \\ &= \frac{1}{6} + 0 + \frac{1}{6} + \frac{1}{6} \\ &= \frac{1}{2} \end{aligned} \tag{20.38}$$

und somit

$$\mathbb{P}(B) = \sum_{i=1}^{4} \mathbb{P}(B \cap A_i). \tag{20.39}$$

Man beachte, dass die Partitionseigenschaft von A_1, A_2, A_3, A_4 essenziell für die Validität des Theorems in diesem Beispiel ist. Wäre beispielsweise $A_4 = \{4, 6\}$ und damit A_3 und A_4 nicht disjunkt, so ergäbe die rechte Seite des Gesetzes von der totalen Wahrscheinlichkeit einen Wert größer $\mathbb{P}(B)$. Ergäbe die Vereinigung der A_1, A_2, A_3, A_4 dagegen nicht Ω, weil zum Beispiel $A_4 = \emptyset$, so ergäbe sich umgekehrt ein Wert kleiner $\mathbb{P}(B)$.

△

Schließlich betrachten wir mit dem *Bayesschen Theorem* eine Formel zur alternativen Berechnung von bedingten Wahrscheinlichkeiten.

Theorem 20.5 (Bayessches Theorem)**.** *$(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und $A_1, ..., A_k$ sei eine Partition von Ω mit $\mathbb{P}(A_i) > 0$ für alle $i = 1, ..., k$. Wenn $\mathbb{P}(B) > 0$ gilt, dann gilt für jedes $i = 1, ..., k$, dass*

$$\mathbb{P}(A_i|B) = \frac{\mathbb{P}(B|A_i)\mathbb{P}(A_i)}{\sum_{j=1}^{k} \mathbb{P}(B|A_j)\mathbb{P}(A_j)}. \tag{20.40}$$

∘

Beweis. Mit der Definition der bedingten Wahrscheinlichkeit und dem Gesetz der totalen Wahrscheinlichkeit gilt

$$\mathbb{P}(A_i|B) = \frac{\mathbb{P}(A_i \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B|A_i)\mathbb{P}(A_i)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B|A_i)\mathbb{P}(A_i)}{\sum_{j=1}^{k} \mathbb{P}(B|A_j)\mathbb{P}(A_j)}. \tag{20.41}$$

□

Man beachte, dass das Theorem von Bayes unabhängig von der Frequentistischen oder Bayesianischen Interpretation der Wahrscheinlichkeit ist und lediglich eine Aussage zum Rechnen mit bedingten Wahrscheinlichkeiten macht. Im Rahmen der Frequentistischen Inferenz wird das Theorem von Bayes allerdings recht selten benutzt. Im Rahmen der Bayesianischen Inferenz dagegen ist das Theorem von Bayes zentral. In diesem Kontext wird $\mathbb{P}(A_i)$ dann oft die *Prior-Wahrscheinlichkeit des Ereignisses* A_i und $\mathbb{P}(A_i|B)$ die *Posterior-Wahrscheinlichkeit des Ereignisses* A_i genannt. Wie oben erläutert entspricht $\mathbb{P}(A_i|B)$ der Wahrscheinlichkeit von A_i, wenn man um das Eintreten von B weiß.

In der Anwendung werden die hier als *Gesetz der totalen Wahrscheinlichkeit* (Theorem 20.4), *Theorem zu Gemeinsamen und bedingten Wahrscheinlichkeiten* (Theorem 20.3) und *Bayessches Theorem* (Theorem 20.5) formulierten Resultate oft als die zentralen Rechenregeln der Wahrscheinlichkeitstheorie genutzt. In der Praxis werden sie dabei meist als *Summationsregel*, *Multiplikationsregel* und *Bayesregel* bezeichnet (vgl. Tabelle 20.1).

Tabelle 20.1. Zentrale Rechenregeln der Wahrscheinlichkeitstheorie

Rechenregel	Wahrscheinlichkeitsraumform
Multiplikationsregel	$\mathbb{P}(A \cap B) = \mathbb{P}(B\|A)\,\mathbb{P}(A)$, wenn $\mathbb{P}(A) > 0$
Summenregel	$\mathbb{P}(B) = \sum_{i=1}^{k} \mathbb{P}(B \cap A_i)$, wenn $\Omega = \cup_{i=1}^{k} A_i$ und $A_i \cap A_j = \emptyset$ für $i \neq j$
Bayesregel	$\mathbb{P}(A\|B) = \frac{\mathbb{P}(B\|A)\mathbb{P}(A)}{\mathbb{P}(B)}$, wenn $\mathbb{P}(A) > 0$ und $\mathbb{P}(B) > 0$

20.3. Unabhängige Ereignisse

Intuitiv bedeutet die Unabhängigkeit zweier Ereignisse, dass das Wissen um das Eintreten eines Ereignisses die Wahrscheinlichkeit des anderen Ereignisses nicht verändert. Ihre Definition besagt, dass sich die gemeinsame Wahrscheinlichkeit zweier Ereignisse aus dem Produkt der Wahrscheinlichkeiten der einzelnen Ereignisse ergeben soll. Man spricht in diesem Kontext auch von der *Faktorisierung der gemeinsamen Wahrscheinlichkeit* der Ereignisse. Der Sinn dieser Definition erschließt sich dann im Lichte des Begriffs der bedingten Wahrscheinlichkeit in Theorem 20.6. Wir betrachten zunächst die Definition.

Definition 20.3 (Unabhängige Ereignisse)**.** Zwei Ereignisse $A \in \mathcal{A}$ und $B \in \mathcal{A}$ heißen *unabhängig*, wenn

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B). \tag{20.42}$$

Eine Menge von Ereignissen $\{A_i | i \in I\} \subset \mathcal{A}$ mit beliebiger Indexmenge I heißt *unabhängig*, wenn für jede endliche Untermenge $J \subseteq I$ gilt, dass

$$\mathbb{P}\left(\cap_{j \in J} A_j\right) = \prod_{j \in J} \mathbb{P}(A_j). \tag{20.43}$$

•

Man beachte, dass die Unabhängigkeit bestimmter Ereignisse in der Definition eines probabilistischen Modells vorausgesetzt werden kann oder auch aus der Definition eines probabilistischen Modells folgen kann. Sind zwei Ereignisse nicht unabhängig, so sagt man auch, dass diese Ereignisse *abhängig* sind. Der Sinn der Produkteigenschaft bei Unabhängigkeit erschließt sich, wie wir unten zeigen, im Kontext bedingter Wahrscheinlichkeiten. Zunächst geben wir ein Beispiel, das den Zusammenhang zwischen Unabhängigkeit und paarweiser Unabhängigkeit von Ereignissen verdeutlicht.

Beispiel 20.3 (Paarweise und gemeinsame Unabhängigkeit)**.** Unabhängige Ereignisse sind nach Definition immer auch paarweise unabhängig. Beispielsweise gilt für die Menge $\{A_i | i \in \{1, 2, 3\}\}$ von Ereignissen und die möglichen Untermengen $J_1 := \{1, 2\}$, $J_2 := \{1, 3\}$, $J_3 := \{2, 3\}$, $J := \{1, 2, 3\}$ von $I = \{1, 2, 3\}$, dass die Definitionsbedingung der Unabhängigkeit von A_1, A_2, A_3 die Aussagen

$$\begin{aligned} \mathbb{P}\left(A_1 \cap A_2\right) &= \mathbb{P}\left(A_1\right)\mathbb{P}\left(A_2\right) \\ \mathbb{P}\left(A_1 \cap A_3\right) &= \mathbb{P}\left(A_1\right)\mathbb{P}\left(A_3\right) \\ \mathbb{P}\left(A_2 \cap A_3\right) &= \mathbb{P}\left(A_2\right)\mathbb{P}\left(A_3\right) \\ \mathbb{P}\left(A_1 \cap A_2 \cap A_3\right) &= \mathbb{P}\left(A_1\right)\mathbb{P}\left(A_2\right)\mathbb{P}\left(A_3\right) \end{aligned} \tag{20.44}$$

impliziert. Andersherum kann aus der paarweisen Unabhängigkeit von Ereignissen nicht auf die Unabhängigkeit von Ereignissen geschlossen werden, wie folgendes Beispiel zeigt (vgl. DeGroot & Schervish (2012)). Betrachten wir das Modell des zweifachen Werfens einer fairen Münze mit dem Ergebnisraum

$$\Omega := \{HH, HT, TH, TT\} \tag{20.45}$$

mit den Elementareigniswahrscheinlichkeiten

$$\mathbb{P}\{HH\} = \mathbb{P}\{HT\} = \mathbb{P}\{TH\} = \mathbb{P}\{TT\} = \frac{1}{4} \tag{20.46}$$

Dann sind die in Tabelle 20.2 aufgelisteten Ereignisse zwar paarweise unabhängig, aber nicht unabhängig.

Tabelle 20.2. Münzwurfbeispiel zur Unabhängigkeit

Verbale Beschreibung	Mengenform
Im ersten Wurf fällt Kopf	$A_1 := \{HH, HT\}$
Im zweiten Wurf fällt Kopf	$A_2 := \{HH, TH\}$
In beiden Würfen fällt das gleiche Ergebnis	$A_3 := \{HH, TT\}$

Es gelten hier offenbar

$$\mathbb{P}(A_1) = \mathbb{P}(A_2) = \mathbb{P}(A_3) = \frac{1}{2}, \tag{20.47}$$

sowie

$$\begin{aligned}
\mathbb{P}(A_1 \cap A_2) &= \mathbb{P}(\{HH\}) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = \mathbb{P}(A_1)\,\mathbb{P}(A_2), \\
\mathbb{P}(A_1 \cap A_3) &= \mathbb{P}(\{HH\}) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = \mathbb{P}(A_1)\,\mathbb{P}(A_3), \\
\mathbb{P}(A_2 \cap A_3) &= \mathbb{P}(\{HH\}) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = \mathbb{P}(A_2)\,\mathbb{P}(A_3).
\end{aligned} \tag{20.48}$$

Die Ereignisse sind also paarweise unabhängig. Allerdings gilt auch

$$\mathbb{P}(A_1 \cap A_2 \cap A_3) = \mathbb{P}(\{HH\}) = \frac{1}{4} \neq \frac{1}{8} = \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \mathbb{P}(A_1)\,\mathbb{P}(A_2)\,\mathbb{P}(A_3) \tag{20.49}$$

und die Ereignisse A_1, A_2, A_3 sind damit nicht unabhängig.

△

Abschließend wollen wir mit dem Zusammenhang zwischen Unabhängigkeit und bedingter Wahrscheinlichkeit den Sinn der Produkteigenschaft bei Unabhängigkeit erläutern.

Theorem 20.6 (Bedingte Wahrscheinlichkeit unter Unabhängigkeit)**.** *$(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und $A, B \in \mathcal{A}$ seien unabhängige Ereignisse mit $\mathbb{P}(B) > 0$. Dann gilt*

$$\mathbb{P}(A|B) = \mathbb{P}(A). \tag{20.50}$$

∘

Beweis. Unter den Annahmen des Theorems gilt

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(A)\mathbb{P}(B)}{\mathbb{P}(B)} = \mathbb{P}(A). \tag{20.51}$$

□

Bei gegebener Unabhängigkeit zweier Ereignisse A und B ist es für die Wahrscheinlichkeit des Ereignisses A also unerheblich, ob auch B eintritt oder nicht, die Wahrscheinlichkeit $\mathbb{P}(A)$ bleibt gleich. Damit wird die Unabhängigkeit von Ereignissen also gerade als Faktorisierung der gemeinsamen Wahrscheinlichkeit von A und B modelliert, damit $\mathbb{P}(A|B) = \mathbb{P}(A)$ folgt. Aus Sicht der Modellierung subjektiver Unsicherheit durch Wahrscheinlichkeiten bedeutet die Unabhängigkeit zweier Ereignisse also, dass das Wissen um das Vorliegen eines der beiden Ereignisse die Wahrscheinlichkeit für das Vorliegen des anderen Ereignisses nicht ändert. Andersherum bedeutet die Abhängigkeit zweier Ereignisse, dass das Wissen um das Vorliegen eines der beiden Ereignisse die Wahrscheinlichkeit für das Vorliegen des anderen Ereignisses verändert, also entweder erhöht oder verringert.

Beispiel 20.4 (Bedingte Wahrscheinlichkeit unter Unabhängigkeit beim fairen Würfel)**.** Wir wollen den Zusammenhang von Unabhängigkeit, bedingter Wahrscheinlichkeit und Faktorisierung der gemeinsamen Wahrscheinlichkeit am Beispiel des Modells des fairen Würfels verdeutlichen. Dazu betrachten wir das Ereignis $A := \{2, 4, 6\}$ ("Es fällt eine gerade Zahl") und das Ereignis $B := \{3, 4, 5, 6\}$ ("Es fällt eine Zahl größer als zwei"). Intuitiv verändert sich die Wahrscheinlichkeit dafür, dass eine gerade Zahl gefallen ist, nicht, wenn man weiß, dass eine Zahl größer als zwei gefallen ist: Hat man die Information, dass eine Zahl größer als zwei gefallen ist, nicht vorliegen, so entsprechen drei von sechs Fällen dem Ereignis des Fallens einer geraden Zahl. Hat man diese Information vorliegen, so entsprechen zwei von vier Fällen dem Ereignis des Fallens einer geraden Zahl.

Der relative Anteil der dem Ereignis "Es fällt eine gerade Zahl" entsprechenden Fälle bleibt also angesichts des Nichtvorliegens oder des Vorliegens der Information "Es fällt eine Zahl größer als zwei" gleich.

Formal stellen wir zunächst die Faktorisierung der gemeinsamen Wahrscheinlichkeit der beiden Ereignisse, also des Ereignisses "Es fällt eine gerade Zahl und diese ist größer als zwei" in das Produkt der Wahrscheinlichkeiten der beiden Ereignisse fest. Es gilt hier mit der σ-Additivität von $\mathbb{P}$

$$\begin{aligned}
\mathbb{P}(A \cap B) &= \mathbb{P}\left(\{2, 4, 6\} \cap \{3, 4, 5, 6\}\right) \\
&= \mathbb{P}\left(\{4, 6\}\right) \\
&= \frac{2}{6} \\
&= \frac{1}{2} \cdot \frac{2}{3} \\
&= \mathbb{P}(\{2, 4, 6\}) \cdot \mathbb{P}(\{3, 4, 5, 6\}) \\
&= \mathbb{P}(A)\mathbb{P}(B)
\end{aligned} \tag{20.52}$$

Die gemeinsame Wahrscheinlichkeit von A und B lässt sich also als das Produkt der Wahrscheinlichkeiten von A und B schreiben. Für die bedingte Wahrscheinlichkeit von A gegeben B gilt ferner

$$\begin{aligned}
\mathbb{P}(A|B) &= \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \\
&= \frac{\mathbb{P}\left(\{4, 6\}\right)}{\mathbb{P}(\{3, 4, 5, 6\})} \\
&= \frac{1}{3} \cdot \frac{3}{2} \\
&= \frac{1}{2} \\
&= \mathbb{P}(\{2, 4, 6\}) \\
&= \mathbb{P}(A)
\end{aligned} \tag{20.53}$$

Also sind in diesem Beispiel sowohl Definition 20.3 als auch Theorem 20.6 erfüllt.

△

Die Eigenschaft von Ereignissen, unabhängig zu sein, sollte nicht damit verwechselt werden, dass Ereignisse disjunkt sein können. Tatsächlich gilt folgendes Theorem.

Theorem 20.7 (Disjunktheit und Abhängigkeit von Ereignissen)**.** *$A \in \mathcal{A}$ und $B \in \mathcal{A}$ seien zwei disjunkte Ereignisse mit $\mathbb{P}(A) > 0$ und $\mathbb{P}(B) > 0$. Dann sind A und B abhängige Ereignisse.*

∘

Beweis. Zum einen gilt aufgrund der Disjunktheit von A und B, dass

$$\mathbb{P}(A \cap B) = \mathbb{P}(\emptyset) = 0 \tag{20.54}$$

Zum anderen gilt

$$\mathbb{P}(A)\mathbb{P}(B) > 0, \tag{20.55}$$

da nach Annahme sowohl $\mathbb{P}(A) > 0$ als auch $\mathbb{P}(B) > 0$ gelten. Also gilt

$$\mathbb{P}(A \cap B) \neq \mathbb{P}(A)\mathbb{P}(B) \tag{20.56}$$

und nach Definition 20.3 sind A und B damit nicht unabhängig, also abhängig. □

Beispiel 20.5 (Disjunkte Ereignisse mit positiven Wahrscheinlichkeiten sind abhängig)**.** Wir wollen Theorem 20.7 am Beispiel des fairen Würfels verdeutlichen. Dazu sei $A = \{2, 4, 6\}$ das Ereignis "Es fällt eine gerade Zahl" und $B = \{1, 3, 5\}$ das Ereignis "Es fällt eine ungerade Zahl". Intuitiv sind die Ereignisse abhängig, da die Information, dass eine gerade Zahl gefallen ist, die subjektive Wahrscheinlichkeit dafür, dass eine ungerade Zahl gefallen ist, auf null absenkt. Formal gilt einerseits

$$\mathbb{P}(A)\mathbb{P}(B) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}, \tag{20.57}$$

aber

$$\mathbb{P}(A \cap B) = \mathbb{P}\left(\{2, 4, 6\} \cap \{1, 3, 5\}\right) = \mathbb{P}\left(\emptyset\right) = 0. \tag{20.58}$$

Zum anderen gilt auch

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(\emptyset)}{\mathbb{P}(B)} = \frac{0}{\mathbb{P}(B)} = 0 \neq \frac{1}{2} = \mathbb{P}(\{2, 4, 6\}) = \mathbb{P}(A). \tag{20.59}$$

△

20.4. Literaturhinweise

Viele der in diesem Abschnitt eingeführten Begrifflichkeiten sind aufs Engste mit der geschichtlichen Genese der Wahrscheinlichkeitstheorie verwoben, sodass keine einzelnen Referenzen angegeben werden sollen. Einen Einstieg in die Geschichte der Wahrscheinlichkeitstheorie der letzten zwei Jahrhunderte bietet Hald (1990), einen Überblick über modernere Entwicklungen gibt Von Plato (1994). Das Theorem von Bayes wird allgemein auf Bayes (1763) zurückgeführt, auch wenn es nicht das eigentliche Hauptthema dieser Arbeit ist.

Selbstkontrollfragen

1. Geben Sie die Definition der gemeinsamen Wahrscheinlichkeit zweier Ereignisse wieder.
2. Erläutern Sie die intuitive Bedeutung der gemeinsamen Wahrscheinlichkeit zweier Ereignisse.
3. Geben Sie das Theorem zu weiteren Eigenschaften von Wahrscheinlichkeiten wieder.
4. Geben Sie die Definition der bedingten Wahrscheinlichkeit eines Ereignisses wieder.
5. Geben Sie das Theorem zur bedingten Wahrscheinlichkeit wieder.
6. Geben Sie das Theorem zu gemeinsamen und bedingten Wahrscheinlichkeiten wieder.
7. Geben Sie das Gesetz der totalen Wahrscheinlichkeit wieder.
8. Geben Sie das Theorem von Bayes wieder.
9. Geben Sie den Beweis des Theorems von Bayes wieder.
10. Geben Sie die Definition der Unabhängigkeit zweier Ereignisse wieder.
11. Geben Sie das Theorem zur bedingten Wahrscheinlichkeit unter Unabhängigkeit wieder.
12. Geben Sie den Beweis des Theorems zur bedingten Wahrscheinlichkeit unter Unabhängigkeit wieder.
13. Erläutern Sie das Theorem zur bedingten Wahrscheinlichkeit unter Unabhängigkeit.

Lösungen

1. Siehe Definition 20.1.
2. Siehe Bemerkungen zu Definition 20.1.
3. Siehe Theorem 20.1.
4. Siehe Definition 20.2. Die bedingte Wahrscheinlichkeit $\mathbb{P}(A|B)$ eines Ereignisses A gegeben ein Ereignis B ist ein Wert in $[0, 1]$.
5. Siehe Theorem 20.2. Für ein festes Ereignis B mit $\mathbb{P}(B) > 0$ ist die Abbildung

$$\mathbb{P}(\cdot|B) \colon \mathcal{A} \to [0, 1], \qquad A \mapsto \mathbb{P}(A|B) \tag{20.60}$$

   ein Wahrscheinlichkeitsmaß.
6. Siehe Theorem 20.3.
7. Siehe Theorem 20.4.
8. Siehe Theorem 20.5.
9. Siehe Beweis zu Theorem 20.5.
10. Siehe Definition 20.3.
11. Siehe Theorem 20.6.
12. Siehe Beweis zu Theorem 20.6.
13. Siehe Bemerkungen Theorem 20.6.

21. Zufallsvariablen

Mit dem Begriff der *Zufallsvariable* führen wir in diesem Kapitel das probabilistische Standardmodell für einen univariaten Datenpunkt ein. Zentral ist dabei die Möglichkeit im Rahmen der probabilistischen Modellformulierung, die Verteilungen von Zufallsvariablen mithilfe von Wahrscheinlichkeitsmassefunktion und Wahrscheinlichkeitsdichtefunktionen festzulegen. Weiterhin impliziert die Konstruktion von Zufallsvariablen als Abbildungen zufälliger Ergebnisse mit der Untersuchung der Verteilungen der so transformierten zufälligen Ergebnisse das Kernthema frequentistischer Inferenz.

21.1. Definition

Wir skizzieren zunächst die Konstruktion einer Zufallsvariable und ihrer Verteilung anhand von Abbildung 21.1. Dazu sei $(\Omega, \mathcal{A}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und

$$\xi : \Omega \to \mathcal{X}, \omega \mapsto \xi(\omega) \tag{21.1}$$

eine Abbildung. Weiterhin sei $\mathcal{S}$ eine σ-Algebra auf der Zielmenge $\mathcal{X}$ dieser Abbildung. Für jedes $S \in \mathcal{S}$ sei die Urbildmenge von S gegeben durch (vgl. Definition 4.2)

$$\xi^{-1}(S) := \{\omega \in \Omega | \xi(\omega) \in S\}. \tag{21.2}$$

Wenn nun $\xi^{-1}(S) \in \mathcal{A}$ für alle $S \in \mathcal{S}$ gilt, dann nennt man die Abbildung ξ *messbar*. Nehmen wir also an ξ sei messbar. Dann kann allen $S \in \mathcal{S}$ die Wahrscheinlichkeit

$$\mathbb{P}_\xi : \mathcal{S} \to [0,1], S \mapsto \mathbb{P}_\xi(S) := \mathbb{P}\left(\xi^{-1}(S)\right) = \mathbb{P}\left(\{\omega \in \Omega | \xi(\omega) \in S\}\right) \tag{21.3}$$

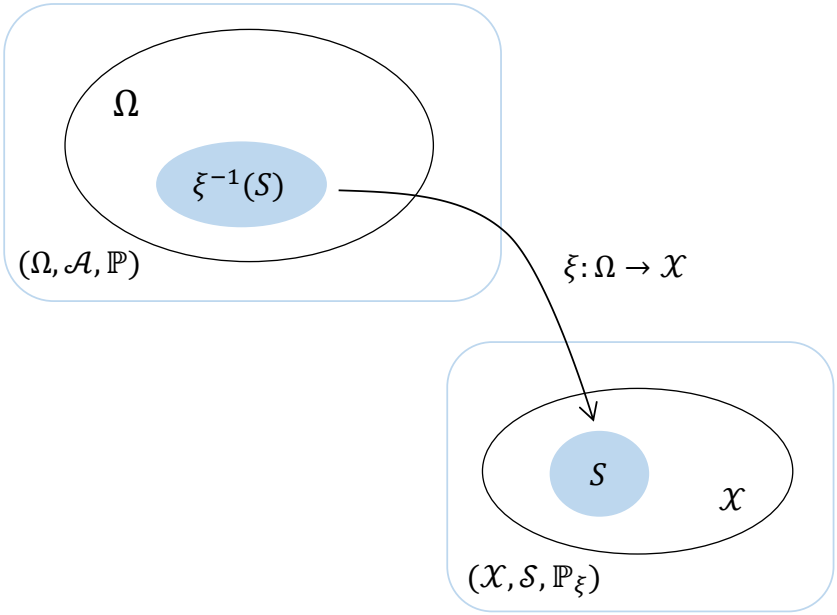
zugeordnet werden. In diesem Kontext nennt man ξ nun eine *Zufallsvariable* und $\mathbb{P}_\xi$ heißt das *Bildmaß* oder die *Verteilung* von ξ. Insgesamt wurde damit ausgehend von dem Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$ mithilfe der Zufallsvariable ξ der Wahrscheinlichkeitsraum $(\mathcal{X}, \mathcal{S}, \mathbb{P}_\xi)$ konstruiert. Formal ist eine Zufallsvariable damit wie folgt definiert.

Definition 21.1 (Zufallsvariable)**.** Es sei $(\Omega, \mathcal{A}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und $(\mathcal{X}, \mathcal{S})$ ein *Messraum*. Dann ist eine *Zufallsvariable* definiert als eine Abbildung $\xi : \Omega \to \mathcal{X}$ mit der *Messbarkeitseigenschaft*

$$\{\omega \in \Omega | \xi(\omega) \in S\} \in \mathcal{A} \text{ für alle } S \in \mathcal{S}. \tag{21.4}$$

•

Nach Definition 21.1 sind Zufallsvariablen weder "zufällig" noch "Variablen", sondern messbare Abbildungen. Fragt man nach der Bedeutung des Zufalls für die Werte $\xi(\omega)$ von Zufallsvariablen, so vermittelt weiterhin die implizite frequentistische Mechanik des Wahrscheinlichkeitsraums $(\Omega, \mathcal{A}, \mathbb{P})$ eine entsprechende Intuition: In jedem Durchgang des modellierten Zufallsvorgangs wird dabei ein ω anhand von $\mathbb{P}$ realisiert und dann (deterministisch) auf $\xi(\omega)$ abgebildet. Wir definieren dementsprechend die Begriffe des *Ergebnisraums* und der *Realisierung* einer Zufallsvariable.



$$\mathbb{P}\left(\xi^{-1}(S)\right) = \mathbb{P}(\{\omega \in \Omega | \xi(\omega) \in S\}) =: \mathbb{P}_\xi(S)$$

Abbildung 21.1. Konstruktion von Zufallsvariable und Verteilung.

Definition 21.2 (Realisierung einer Zufallsvariable)**.** $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum, $(\mathcal{X}, \mathcal{S})$ sei ein Messraum und $\xi : \Omega \to \mathcal{X}$ sei eine Zufallsvariable. Dann heißt $\mathcal{X}$ der *Ergebnisraum der Zufallsvariable* ξ und ein $\xi(\omega) \in \mathcal{X}$ heißt eine *Realisierung der Zufallvariable* ξ.

•

Beispiel 21.1 (Augensumme zweier Würfel als Zufallsvariable)**.** Aufbauend auf dem in Kapitel 19.3 betrachteten Beispiel eines Wahrscheinlichkeitsraums zur Modellierung des geichzeitigen Würfelns mit einem blauem und einem roten Würfel wollen wir mit der Summe der Würfelaugenzahlen ein erstes Beispiel für eine Zufallsvariable und ihre Verteilung betrachten. Wir haben in Kapitel 19.3 gesehen, dass ein sinnvolles Wahrscheinlichkeitsraummodell für das geichzeitige Würfeln mit einem blauem und einem roten Würfel durch $(\Omega, \mathcal{A}, \mathbb{P})$ mit

- $\Omega := \{(r, b) | r \in \mathbb{N}_6, b \in \mathbb{N}_6\}$,
- $\mathcal{A} := \mathcal{P}(\Omega)$ und
- $\mathbb{P} : \mathcal{A} \to [0, 1]$ mit $\mathbb{P}(\{(r, b)\}) = \frac{1}{36}$ für alle $(r, b) \in \Omega$.

gegeben ist. Die Auswertung der Summe der beiden Würfelaugenzahlen wird dann sinnvollerweise durch die Abbildung

$$\xi : \Omega \to \mathcal{X}, (r, b) \mapsto \xi((r, b)) := r + b \tag{21.5}$$

beschrieben, wobei offenbar $\mathcal{X} := \{2, 3, ..., 12\}$ gelten muss. Der Ergebnisraum der Zufallsvariable ist also wiederum endlich und $\mathcal{S} := \mathcal{P}(\mathcal{X})$ ist eine sinnvolle σ-Algebra auf $\mathcal{X}$. Mithilfe der σ-Additivität von $\mathbb{P}$ können wir nun die Verteilung $\mathbb{P}_\xi$ von ξ für alle Elementarereignisse $\{x\} \in \mathcal{S}$ berechnen und damit insbesondere auch die Messbarkeit von ξ nachweisen, wie in Tabelle 21.1 gezeigt.

Tabelle 21.1. Wahrscheinlichkeitsverteilung der Augensumme beim Wurf zweier Würfel

$\mathbb{P}_\xi(\{x\})$	$\mathbb{P}(\xi^{-1}(\{x\}))$	$\mathbb{P}(\{\omega \vert \xi(\omega) \in \{x\}\})$	
$\mathbb{P}_\xi(\{2\})$	$\mathbb{P}\left(\xi^{-1}(\{2\})\right)$	$\mathbb{P}\left(\{(1,1)\}\right)$	$\frac{1}{36}$
$\mathbb{P}_\xi(\{3\})$	$\mathbb{P}\left(\xi^{-1}(\{3\})\right)$	$\mathbb{P}\left(\{(1,2),(2,1)\}\right)$	$\frac{2}{36}$
$\mathbb{P}_\xi(\{4\})$	$\mathbb{P}\left(\xi^{-1}(\{4\})\right)$	$\mathbb{P}\left(\{(1,3),(3,1),(2,2)\}\right)$	$\frac{3}{36}$
$\mathbb{P}_\xi(\{5\})$	$\mathbb{P}\left(\xi^{-1}(\{5\})\right)$	$\mathbb{P}\left(\{(1,4),(4,1),(2,3),(3,2)\}\right)$	$\frac{4}{36}$
$\mathbb{P}_\xi(\{6\})$	$\mathbb{P}\left(\xi^{-1}(\{6\})\right)$	$\mathbb{P}\left(\{(1,5),(5,1),(2,4),(4,2),(3,3)\}\right)$	$\frac{5}{36}$
$\mathbb{P}_\xi(\{7\})$	$\mathbb{P}\left(\xi^{-1}(\{7\})\right)$	$\mathbb{P}\left(\{(1,6),(6,1),(2,5),(5,2),(3,4),(4,3)\}\right)$	$\frac{6}{36}$
$\mathbb{P}_\xi(\{8\})$	$\mathbb{P}\left(\xi^{-1}(\{8\})\right)$	$\mathbb{P}\left(\{(2,6),(6,2),(3,5),(5,3),(4,4)\}\right)$	$\frac{5}{36}$
$\mathbb{P}_\xi(\{9\})$	$\mathbb{P}\left(\xi^{-1}(\{9\})\right)$	$\mathbb{P}\left(\{(3,6),(6,3),(4,5),(5,4)\}\right)$	$\frac{4}{36}$
$\mathbb{P}_\xi(\{10\})$	$\mathbb{P}\left(\xi^{-1}(\{10\})\right)$	$\mathbb{P}\left(\{(4,6),(6,4),(5,5)\}\right)$	$\frac{3}{36}$
$\mathbb{P}_\xi(\{11\})$	$\mathbb{P}\left(\xi^{-1}(\{11\})\right)$	$\mathbb{P}\left(\{(5,6),(6,5)\}\right)$	$\frac{2}{36}$
$\mathbb{P}_\xi(\{12\})$	$\mathbb{P}\left(\xi^{-1}(\{12\})\right)$	$\mathbb{P}\left(\{(6,6)\}\right)$	$\frac{1}{36}$

Die Wahrscheinlichkeiten der Elementarereignisse in $\mathcal{S}$ wiederum erlauben das Berechnen beliebiger Ereigniswahrscheinlichkeiten hinsichtlich der Würfelaugenzahlsumme (vgl. Kapitel 19.2). Insgesamt haben wir basierend auf $(\Omega, \mathcal{A}, \mathbb{P})$ und ξ also ein weiteres Wahrscheinlichkeitsraummodell $(\mathcal{X}, \mathcal{S}, \mathbb{P}_\xi)$ konstruiert.

Folgender **R** Code demonstriert, wie mithilfe der computerbasierten Erzeugung zufälliger Ergebnisse die Konstruktion des hier betrachteten Beispiels für einen Durchgang eines Zufallsvorgangs simuliert werden kann.

```
# Wahrscheinlichkeitsraummodellformulierung
Omega    = list()                               # Ergebnisrauminitialisierung
idx      = 1                                    # Ergebnisindexinitialisierung
for(r in 1:6){                                  # Ergebnisse roter  Würfel
    for(b in 1:6){                              # Ergebnisse blauer Würfel
        Omega[[idx]] = c(r,b)                   # \omega \in \Omega
        idx          = idx + 1 }}               # Ergebnisindexupdate
K        = length(Omega)                        # Kardinalität von \Omega
pi       = rep(1/K,1,K)                         # Wahrscheinlichkeitsfunktion \pi

# Durchgang des Zufallsvorgangs
omega    = Omega[[which(rmultinom(1,1,pi) == 1)]] # Auswahl von \omega anhand \mathbb{P}({\omega})

# Realisierung der Zufallsvariable
xi_omega = sum(omega)                           # \xi(\omega)
```

```
omega     :  3 4
xi(omega) :  7
```

Im Kontext des Vermessens zufällig ausgewählter experimenteller Einheiten dienen Zufallsvariablen oft als Modelle für Messvorgänge. Betrachten wie beispielsweise die Bestimmung des Wertes eins psychologischen Fragebogens (BDI-II) an zufällig ausgewählten Proband:innen (Abbildung 21.2), so ergibt sich folgende Interpretation: Der Ergebnisraum des zugrundeliegenden Wahrscheinlichkeitsraums (Ω) soll die Gesamtheit aller infrage kommender Proband:innen darstellen und die Auswahl einer Proband:in aus diesem Raum die Auswahl eines Ergebnisses ω, welche mit Wahrscheinlichkeit $\mathbb{P}(\{\omega\})$ geschehen soll. Wird nun eine bestimmte Eigenschaft dieser Proband:in in idealisierter Weise gemessen, so handelt es sich dabei um eine deterministische Abbildung auf einen dieser Probandin zugeordneten Messwert $\xi(\omega)$ im Raum der Messwerte $\mathcal{X}$. Die Messwerte selbst unterliegen dann einer Wahrscheinlichkeitsverteilung, die durch die zugrundeliegende Verteilung und die Art des Messvorgangs bestimmt wird.

△

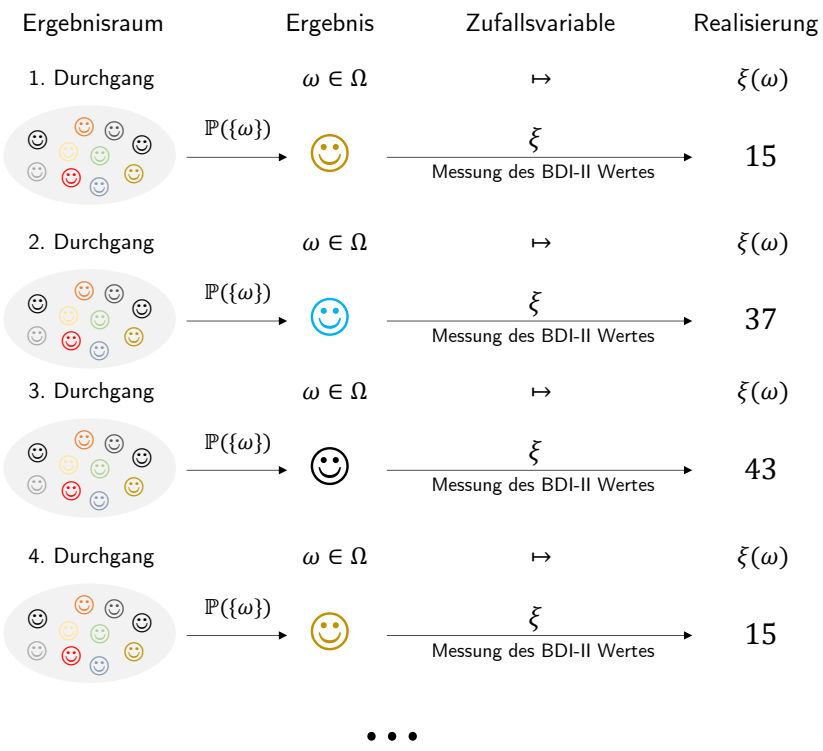


Abbildung 21.2. Zufallsvariable als Modell eines Messvorgangs.

Notation

Die Konventionen zur Notation der mit Zufallsvariablen assoziierten Wahrscheinlichkeiten und Verteilungen sind etwas gewöhnungsbedürftig, sodass wir sie in folgender Definition festhalten wollen.

Definition 21.3 (Notation für Zufallsvariablen)**.** Es seien $(\Omega, \mathcal{A}, \mathbb{P})$ und $(\mathcal{X}, \mathcal{S}, \mathbb{P}_\xi)$ Wahrscheinlichkeitsräume und $\xi : \Omega \to \mathcal{X}$ sei eine Zufallsvariable. Dann gelten mit $S \in \mathcal{S}$ und $x \in \mathcal{X}$ folgende Notationskonventionen für Ereignisse in $\mathcal{A}$:

$$
\begin{aligned}
\{\xi \in S\} &:= \{\omega \in \Omega | \xi(\omega) \in S\} \\
\{\xi = x\} &:= \{\omega \in \Omega | \xi(\omega) = x\} \\
\{\xi \leq x\} &:= \{\omega \in \Omega | \xi(\omega) \leq x\} \\
\{\xi < x\} &:= \{\omega \in \Omega | \xi(\omega) < x\} \\
\{\xi \geq x\} &:= \{\omega \in \Omega | \xi(\omega) \geq x\} \\
\{\xi > x\} &:= \{\omega \in \Omega | \xi(\omega) > x\}
\end{aligned}
$$

Aus diesen Konventionen ergeben sich folgende Konventionen für Wahrscheinlichkeiten

von Verteilungen

$$\begin{aligned}
\mathbb{P}_\xi(\xi \in S) &= \mathbb{P}(\{\xi \in S\}) = \mathbb{P}(\{\omega \in \Omega | \xi(\omega) \in S\}) \\
\mathbb{P}_\xi(\xi = x) &= \mathbb{P}(\{\xi = x\}) = \mathbb{P}(\{\omega \in \Omega | \xi(\omega) = x\}) \\
\mathbb{P}_\xi(\xi \leq x) &= \mathbb{P}(\{\xi \leq x\}) = \mathbb{P}(\{\omega \in \Omega | \xi(\omega) \leq x\}) \\
\mathbb{P}_\xi(\xi < x) &= \mathbb{P}(\{\xi < x\}) = \mathbb{P}(\{\omega \in \Omega | \xi(\omega) < x\}) \\
\mathbb{P}_\xi(\xi \geq x) &= \mathbb{P}(\{\xi \geq x\}) = \mathbb{P}(\{\omega \in \Omega | \xi(\omega) \geq x\}) \\
\mathbb{P}_\xi(\xi > x) &= \mathbb{P}(\{\xi < x\}) = \mathbb{P}(\{\omega \in \Omega | \xi(\omega) > x\}) .
\end{aligned}$$

Oft wird zudem auf das Subskript bei Verteilungssymbolen verzichtet und zum Beispiel $\mathbb{P}_\xi(\xi \in S)$ nur als $\mathbb{P}(\xi \in S)$ geschrieben, solange sich aus dem Kontext keine Verwechselungsmöglichkeit der beiden Wahrscheinlichkeitsmaße ergeben kann.

•

Der Verzicht auf die explizite Bezeichnung von Funktionen eindeutig bestimmter Zufallsvariablen, wie er in Definition 21.3 bezüglich $\mathbb{P}_\xi$ und $\mathbb{P}$ angerissen wird, ist ein grundlegendes Phänomen moderner, anwendungsorientierter Wahrscheinlichkeitstheorie. Speziell werden in den meisten Fällen Funktionen von Zufallsvariablen mithilfe ihrer Argumente identifiziert. So sollte der verständigen Leser:in anhand von "$\mathbb{P}(\xi \in S)$" klar sein, dass es bei $\mathbb{P}$ um das Bildmaß der Zufallsvariable ξ geht, bei "$\mathbb{P}(\{\omega \in \Omega | \xi(\omega) \in S\})$" dagegen um das Wahrscheinlichkeitsmaß auf dem Messraum $(\Omega, \mathcal{A})$. Die Identifikation von Funktionen anhand ihrer Argumente, die insbesondere auch bei den in folgenden Abschnitten diskutierten *Wahrscheinlichkeitsmassefunktionen*, *Wahrscheinlichkeitsdichtefunktionen* und *kumulativen Verteilungsfunktionen* zum Tragen kommt, bezeichnet man in der informatischen Anwendung auch als *Multimethode (multiple dispatch)*.

Zum Abschluss dieses Abschnittes halten wir in Theorem 21.1 fest, dass arithmetische Operationen mit reellwertigen Zufallsvariablen wiederum auf reellwertige Zufallsvariablen führen.

Theorem 21.1 (Arithmetik reeller Zufallsvariablen)**.** *$(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum, $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ sei der reelle Messraum, $\xi_1 : \Omega \to \mathbb{R}$ und $\xi_2 : \Omega \to \mathbb{R}$ seien reellwertige Zufallsvariablen und $c \in \mathbb{R}$ sei eine Konstante. Weiterhin seien*

$$\begin{aligned}
\xi_1 + c : \Omega \to \mathbb{R}, \omega \mapsto (\xi_1 + c)(\omega) &:= \xi_1(\omega) + c \text{ für } c \in \mathbb{R} \\
c\xi_1 : \Omega \to \mathbb{R}, \omega \mapsto (c\xi_1)(\omega) &:= c\xi_1(\omega) \text{ für } c \in \mathbb{R} \\
\xi_1 + \xi_2 : \Omega \to \mathbb{R}, \omega \mapsto (\xi_1 + \xi_2)(\omega) &:= \xi_1(\omega) + \xi_2(\omega) \\
\xi_1\xi_2 : \Omega \to \mathbb{R}, \omega \mapsto (\xi_1\xi_2)(\omega) &:= \xi_1(\omega)\xi_2(\omega)
\end{aligned} \tag{21.6}$$

die Addition einer Konstante zu einer reellwertigen Zufallsvariable, die Multiplikation einer reellwertigen Zufallsvariable mit einer Konstante, die Addition zweier reellwertiger Zufallsvariablen und die Multiplikation zweier reellwertigen Zufallsvariablen, respektive. Dann sind auch $\xi_1 + c$, $c\xi_1$, $\xi_1 + \xi_2$ und $\xi_1\xi_2$ reellwertige Zufallsvariablen.

◦

Für einen Beweis dieses Theorems verweisen wir auf die weiterführende Literatur, beispielsweise Hesse (2009). Intuitiv besagt Theorem 21.1, dass die Addition einer zufälligen Größe zu einer konstanten Größe, die Multiplikation einer zufälligen Größe mit einer Konstante, die Addition zweier zufälliger Größen und die Multiplikation zweier zufälliger Größen immer wieder zufällige Größen mit ihren dann eigenen Verteilungen ergeben.

21.2. Wahrscheinlichkeitsmassefunktionen

In diesem Abschnitt führen wir mit den *Wahrscheinlichkeitsmassefunktionen (WMFen)* ein Hilfsmittel ein, um Verteilungen von Zufallsvariablen mit *diskretem* (genauer *endlichem* oder *abzählbarem*) Ergebnisraum zu definieren. Wir illustrieren den Begriff anhand dreier wichtiger Beispiele, den Bernoulli- und Binomialzufallsvariablen sowie den diskret-gleichverteilten Zufallsvariablen. Wir definieren zunächst den Begriff der WMF wie folgt.

Definition 21.4 (Diskrete Zufallsvariable und Wahrscheinlichkeitsmassefunktion)**.** Eine Zufallsvariable ξ heißt *diskret*, wenn ihr Ergebnisraum $\mathcal{X}$ endlich oder abzählbar ist und eine Funktion der Form

$$p : \mathcal{X} \to \mathbb{R}_{\geq 0}, x \mapsto p(x) \tag{21.7}$$

existiert, für die gilt

(1) $\sum_{x \in \mathcal{X}} p(x) = 1$
(2) $\mathbb{P}(\xi = x) = p(x)$ für alle $x \in \mathcal{X}$.

Eine entsprechende Funktion p heißt *Wahrscheinlichkeitsmassefunktion (WMF)* von ξ.

•

Wir erinnern daran, dass eine Menge *abzählbar* heißt, wenn sie bijektiv auf $\mathbb{N}$ abgebildet werden kann. Im Deutschen nennt man WMFen auch *Zähldichten*. Im Englischen nennt man WMFen *probability mass functions (PMFs)*, an diesem Begriff orientieren wir uns hier. Ohne Beweis halten wir fest, dass jede Funktion $p : \mathcal{X} \to \mathbb{R}_{\geq 0}$, die die Normiertheitseigenschaft $\sum_{x \in \mathcal{X}} p(x) = 1$ besitzt als WMF einer Zufallsvariable interpretiert werden kann.

Beispiele

Wir wollen mit den *Bernoulli-Zufallsvariablen*, den *Binomial-Zufallsvariablen* und den *diskret-gleichverteilten Zufallsvariablen* drei erste Beispiele für die Definition von Verteilungen mithilfe von WMFen betrachten.

Definition 21.5 (Bernoulli-Zufallsvariable)**.** Es sei ξ eine Zufallsvariable mit Ergebnisraum $\mathcal{X} = \{0, 1\}$ und WMF

$$p : \mathcal{X} \to [0, 1], x \mapsto p(x) := \mu^x (1 - \mu)^{1-x} \text{ mit } \mu \in [0, 1]. \tag{21.8}$$

Dann sagen wir, dass ξ einer *Bernoulli-Verteilung mit Parameter* $\mu \in [0, 1]$ unterliegt und nennen ξ eine *Bernoulli-Zufallsvariable*. Wir kürzen dies mit $\xi \sim \text{Bern}(\mu)$ ab. Die WMF einer Bernoulli-Zufallsvariable bezeichnen wir mit

$$\text{Bern}(x; \mu) := \mu^x (1 - \mu)^{1-x}. \tag{21.9}$$

•

Bernoulli-Zufallsvariablen können immer dann zur probabilistischen Modellierung genutzt werden, wenn das betrachtete Phänomen binär ist und die möglichen Werte der Zufallsvariable bijektiv auf $\{0, 1\}$ abgebildet werden können. Man beachte, dass die funktionale Form der Bernoulli-Zufallsvariable $\text{Bern}(x; \mu)$ nur für $x \in \{0, 1\}$ Sinn ergibt und nicht etwa für $x \in \{\text{H}, \text{T}\}$. Bildet man aber die möglichen Ergebnisse eines Münzwurfes auf $\{0, 1\}$ ab, also definiert etwa $0 := \text{H}$ und $1 := \text{T}$, so kann eine Bernoulli-Zufallsvariable durchaus als Modell eines Münzwurfs dienen.

Der Parameter $\mu \in [0, 1]$ einer Bernoulli-Zufallsvariable ist die Wahrscheinlichkeit dafür, dass die Zufallsvariable ξ den Wert 1 annimmt, dies erkennt man anhand von

$$\mathbb{P}(\xi = 1) = p(1) = \mu^1(1 - \mu)^{1-1} = \mu. \tag{21.10}$$

Wir visualisieren die WMFen von Bernoulli-Zufallsvariablen für $\mu := 0.1, \mu := 0.5$ und $\mu := 0.7$ in Abbildung 21.3.

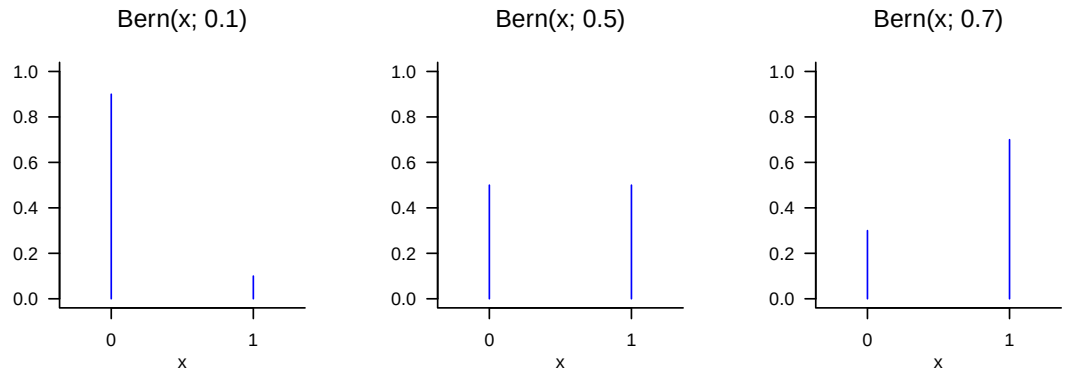


Abbildung 21.3. WMFen von Bernoulli-Zufallsvariablen.

Definition 21.6 (Binomialzufallsvariable)**.** Es sei ξ eine Zufallsvariable mit Ergebnisraum $\mathcal{X} := \mathbb{N}_n^0$ und WMF

$$p : \mathcal{X} \to [0, 1], x \mapsto p(x) := \binom{n}{x} \mu^x (1 - \mu)^{n-x} \text{ für } \mu \in [0, 1]. \tag{21.11}$$

Dann sagen wir, dass ξ einer *Binomialverteilung mit Parametern* $n \in \mathbb{N}$ *und* $\mu \in [0, 1]$ unterliegt und nennen ξ eine *Binomial-Zufallsvariable*. Wir kürzen dies mit $\xi \sim \text{Bin}(n, \mu)$ ab. Die WMF einer Binomial-Zufallsvariable bezeichnen wir mit

$$\text{Bin}(x; n, \mu) := \binom{n}{x} \mu^x (1 - \mu)^{n-x}. \tag{21.12}$$

•

Ohne Beweis halten wir fest, dass eine Binomial-Zufallsvariable als Modell der Summe von n unabhängig und identisch verteilten Bernoulli-Zufallsvariablen genutzt werden kann. Insbesondere gilt also $\text{Bin}(x; 1, \mu) = \text{Bern}(x; \mu)$. Binomial-Zufallsvariablen haben die Eigenschaft, dass mit n einer ihrer Parameter nicht nur die funktionale Form ihrer WMF,

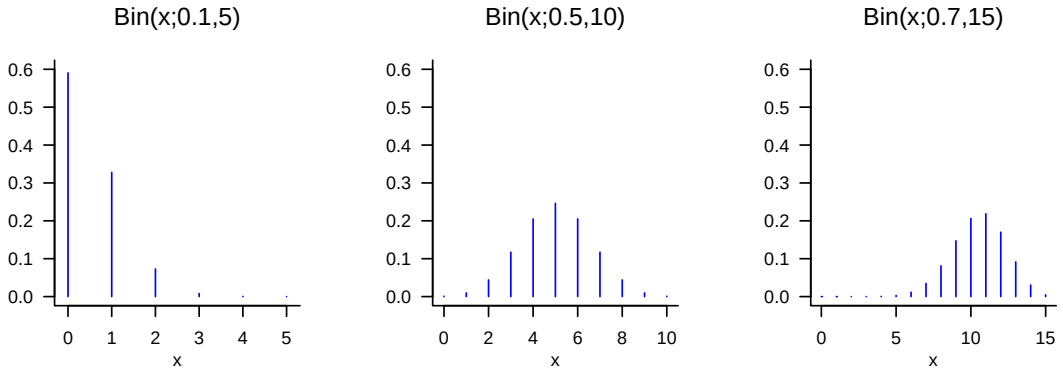


Abbildung 21.4. WMFen von Binomial-Zufallsvariablen.

sondern auch ihren Ergebnisraum $\mathcal{X}$ festlegt. Wir visualisieren die WMFen von Binomial-Zufallsvariablen für $(n, \mu) := (5, 0.1), (n, \mu) := (10, 0.5)$ und $(n, \mu) := (15, 0.7)$ in Abbildung 21.4.

Definition 21.7 (Diskret-gleichverteilte Zufallsvariable)**.** Es sei ξ eine diskrete Zufallsvariable mit endlichem Ergebnisraum $\mathcal{X}$ und WMF

$$p : \mathcal{X} \to \mathbb{R}_{\geq 0}, x \mapsto p(x) := \frac{1}{|\mathcal{X}|}. \tag{21.13}$$

Dann sagen wir, dass ξ einer *diskreten Gleichverteilung* unterliegt und nennen ξ eine *diskret-gleichverteilte Zufallsvariable*. Wir kürzen dies mit $\xi \sim U(|\mathcal{X}|)$ ab. Die WMF einer diskret-gleichverteilten Zufallsvariable bezeichnen wir mit

$$U(x; |\mathcal{X}|) := \frac{1}{|\mathcal{X}|}. \tag{21.14}$$

•

Diskrete-gleichverteilte Zufallsvariable können offenbar immer dann zur probabilistischen Modellierung genutzt werden, wenn die möglichen diskreten Ergebnisse des modellierten Phänomenens die gleiche Wahrscheinlichkeit haben. Im Fall der diskret-gleichverteilten Zufallsvariablen braucht es zur Definition ihrer funktionalen Form nach Festlegung des Ergebnisraums keinen weiteren Parameter. Offenbar gilt für $\mathcal{X} := \{0, 1\}$

$$U(x; |\mathcal{X}|) = \text{Bern}(x; 0.5) = \text{Bin}(x; 1, 0.5). \tag{21.15}$$

Wir visualisieren die WMFen von diskret-gleichverteilten Zufallsvariablen für $\mathcal{X} := \{\{0, 1\}$, $\mathcal{X} := \{-3, -2, -1, 0, 1\}\}$ und $\mathcal{X} := \{-4, -3, -2, -1, 0, 1, 2, 3, 4\}$ in Abbildung 21.5. Man beachte, dass Definition 21.7 formal die Sequentialität der Elemente von $\mathcal{X}$ nicht erfordert, man kann also genauso eine diskret-gleichverteilte Zufallsvariable mit Ergebnisraum $\mathcal{X} := \{1, 5, 7\}$ oder auch nicht numerischen Ergebnisraum $\mathcal{X} := \{a, b, x, y\}$ definieren.

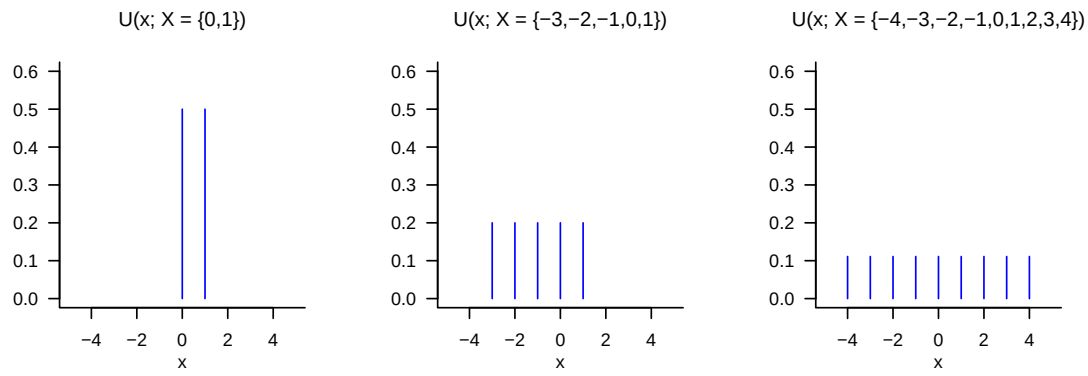


Abbildung 21.5. WMFen von diskret-gleichverteilten Zufallsvariablen.

21.3. Wahrscheinlichkeitsdichtefunktionen

In diesem Abschnitt führen wir mit den *Wahrscheinlichkeitsdichtefunktionen (WDFen)* ein Hilfsmittel ein, um Verteilungen von Zufallsvariablen mit *kontinuierlichem* (genauer *überabzählbarem*) Ergebnisraum zu definieren. Wir illustrieren den Begriff zunächst an der grundlegendsten aller Zufallsvariablen, der normalverteilten Zufallsvariable. Mit der Gamma-Zufallsvariable, der Beta-Zufallsvariable und der gleichverteilten Zufallsvariable wollen wir dann noch drei Beispiele von Zufallsvariablen betrachten, die sowohl in der Modellformulierung der Frequentistischen als auch der Bayesianischen Inferenz an vielen Stellen eingesetzt werden. Wir definieren den Begriff der WDF wie folgt.

Definition 21.8 (Kontinuierliche Zufallsvariable und Wahrscheinlichkeitsdichtefunktion)**.** Eine Zufallsvariable ξ heißt *kontinuierlich*, wenn $\mathbb{R}$ der Ergebnisraum von ξ ist und eine Funktion

$$p : \mathbb{R} \to \mathbb{R}_{\geq 0}, x \mapsto p(x) \tag{21.16}$$

existiert, für die gilt

(1) $\int_{-\infty}^{\infty} p(x)\,dx = 1$ und
(2) $\mathbb{P}(\xi \in [a, b]) = \int_a^b p(x)\,dx$ für alle $a, b \in \mathbb{R}$ mit $a \leq b$.

Eine entsprechende Funktion p heißt *Wahrscheinlichkeitsdichtefunktion (WDF)* von ξ.

•

Im Englischen nennt man WDFen *probability density functions (PDFs)*. Ohne Beweis halten wir fest, dass jede Funktion $p : \mathbb{R} \to \mathbb{R}_{\geq 0}$, für deren uneigentliches Integral $\int_{-\infty}^{\infty} p(x)\,dx = 1$ gilt, die also normiert ist, als WDF einer Zufallsvariable interpretiert werden kann.

Im Umgang mit WDFen und in Abgrenzung zu WMFen sollte man sich die *Dichteeigenschaft* einer WDF immer bewusst machen: Die Werte einer WDF stellen keine Wahrscheinlichkeiten, sondern Wahrscheinlichkeitsdichten dar, Wahrscheinlichkeiten werden aus WDFen anhand von Definition 21.8 (2) durch Integration berechnet. Wie im physikalischen

Sinn ergibt sich die einem reellen Intervall zugeordnete Wahrscheinlichkeitsmasse also erst durch "Multiplikation" mit dem entprechenden "Intervallvolumen". Man denke hierzu auch an die Approximation des bestimmten Integrals $\int_a^b p(x)\,dx$ durch einen Riemannschen Summenterm (vgl. Definition 7.3). Intuitiv gilt also

$$\text{(Wahrscheinlichkeits)Masse} = \text{(Wahrscheinlichkeits)Dichte} \cdot \text{(Mengen)Volumen}, \quad (21.17)$$

wobei sich das Volumen im Sinne des Lebesgue-Maßes auf die Breite des Intervalls $[a, b]$ bezieht. Wie in der physikalischen Analogie ist die Wahrscheinlichkeitsmasse eines Intervalls ohne Volumen gleich null,

$$\mathbb{P}(\xi = a) = \int_a^a p(x)\,dx = 0. \quad (21.18)$$

Ferner gilt, dass bei entsprechend kleinen Intervallen WDFen auch Werte größer als 1 annehmen können, auch wenn dies für die Wahrscheinlichkeit, die sich dann durch entsprechende Integration ergibt, nicht der Fall sein kann. Schließlich sei trotz dieser technischen Feinheiten folgende Intuition betont: Betrachtet man die grafische Darstellung der WDF einer Zufallsvariable und stellt sich eine Zerlegung von $\mathbb{R}$ in gleich große Intervalle vor, so besitzt die Zufallsvariable natürlich eine höhere Wahrscheinlichkeit dafür, Werte in einem Intervall mit assoziierter höherer Wahrscheinlichkeitsdichte anzunehmen als Werte in einem Intervall mit assoziierter relativ niedrigerer Wahrscheinlichkeitsdichte.

Normalverteilte Zufallsvariablen

Mit der normalverteilten Zufallsvariable wollen wir als erstes Beispiel für die Definition einer kontinuierlichen Zufallsvariable mithilfe einer WDF nun die wichtigste Zufallsvariable der probabilistischen Modellbildung einführen.

Definition 21.9 (Normalverteilte Zufallsvariable)**.** Es sei ξ eine Zufallsvariable mit Ergebnisraum $\mathbb{R}$ und WDF

$$p : \mathbb{R} \to \mathbb{R}_{>0}, x \mapsto p(x) := \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right). \quad (21.19)$$

Dann sagen wir, dass ξ einer *Normalverteilung mit Parametern* $\mu \in \mathbb{R}$ *und* $\sigma^2 > 0$ unterliegt und nennen ξ eine *normalverteilte Zufallsvariable*. Wir kürzen dies mit $\xi \sim N(\mu, \sigma^2)$ ab. Die WDF einer normalverteilten Zufallsvariable bezeichnen wir mit

$$N(x; \mu, \sigma^2) := \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right). \quad (21.20)$$

Eine normalverteilte Zufallsvariable mit $\mu = 0$ und $\sigma^2 = 1$ nennt man eine *standardnormalverteilte Zufallsvariable*

•

Wir visualisieren die WDFen von normalverteilten Zufallsvariablen für $(\mu, \sigma^2) := (0, 1), (\mu, \sigma^2) := (-2.5, 10)$ und $(\mu, \sigma^2) := (3, 0.5)$ in Abbildung 21.6. Man macht sich an dieser Abbildung grafisch klar, dass die WDFen von normalverteilten Zufallsvariablen immer genau einen Wert höchster Wahrscheinlichkeitsdichte besitzen - und zwar an der Stelle des Parameters $\mu \in \mathbb{R}$. Dies ergibt sich durch die Tatsache, dass das Argument der

Exponentialfunktion in der funktionalen Form von $N(x; \mu, \sigma^2)$ aufgrund des negativen Vorzeichens des Quadrates von $x - \mu$ und der Positivität von σ^2 immer nicht-positiv ist und die Exponentialfunktion auf den nicht-positiven reellen Zahlen ihr Maximum bei $x = \mu$, also $x - \mu = 0$ annimmt. Weiterhin macht man sich grafisch klar, dass der Parameter $\sigma^2 > 0$ die Breite der WDF einer normalverteilten Zufallsvariable enkodiert.

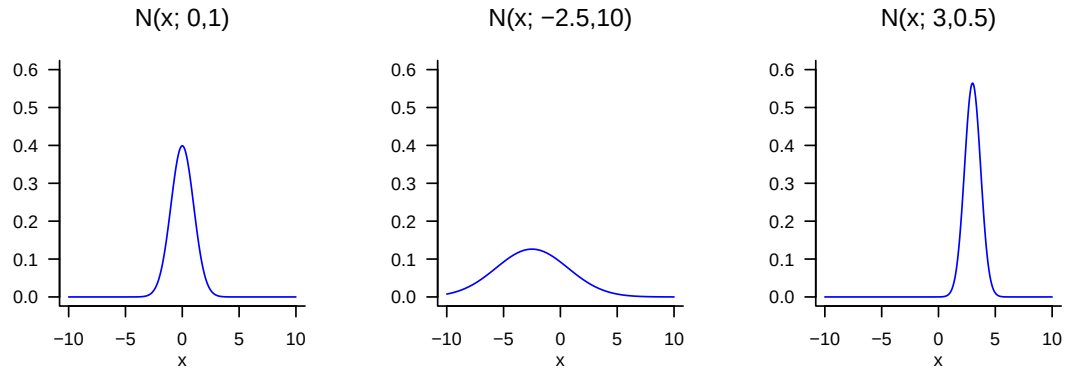


Abbildung 21.6. WDFen von normalverteilten Zufallsvariablen.

Weitere Beispiele

Wir wollen mit den *Gamma-Zufallsvariablen*, den *Beta-Zufallsvariablen* und den *gleichverteilten Zufallsvariablen* drei weitere Beispiele für die Definition von Verteilungen mithilfe von WDFen betrachten.

Definition 21.10 (Gamma-Zufallsvariable)**.** Es sei ξ eine Zufallsvariable mit Ergebnisraum $\mathcal{X} := \mathbb{R}_{>0}$ und WDF

$$p : \mathbb{R}_{>0} \to \mathbb{R}_{>0}, x \mapsto p(x) := \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} \exp\left(-\frac{x}{\beta}\right), \tag{21.21}$$

wobei Γ die Gammafunktion bezeichne. Dann sagen wir, dass ξ einer *Gammaverteilung mit Formparameter $\alpha > 0$ und Skalenparameter $\beta > 0$* unterliegt und nennen ξ eine *gammaverteilte Zufallsvariable*. Wir kürzen dies mit $\xi \sim G(\alpha, \beta)$ ab. Die WDF einer gammaverteilen Zufallsvariable bezeichnen wir mit

$$G(x; \alpha, \beta) := \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} \exp\left(-\frac{x}{\beta}\right). \tag{21.22}$$

•

Die spezielle Gamma-Zufallsvariable mit WDF $G\left(x; \frac{n}{2}, 2\right)$ wird *Chi-Quadrat (χ^2) Verteilung mit n Freiheitsgraden* genannt. Wir visualisieren die WDFen von Gamma-Zufallsvariablen für $(\alpha, \beta) := (1, 1)$, $(\alpha, \beta) := (2, 2)$ und $(\alpha, \beta) := (5, 1)$ in Abbildung 21.7.

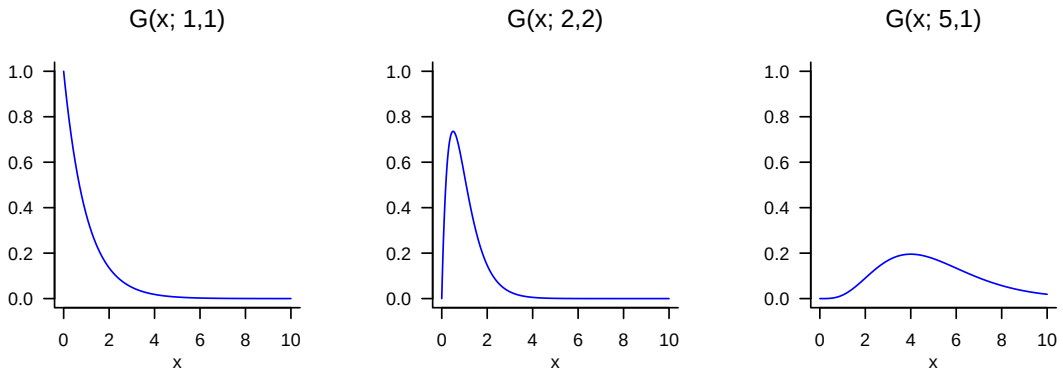


Abbildung 21.7. WDFen von Gamma-Zufallsvariablen.

Definition 21.11 (Beta-Zufallvariable)**.** Es sei ξ eine Zufallsvariable mit Ergebnisraum $\mathcal{X} := [0, 1]$ und WDF

$$p : \mathcal{X} \to [0, 1], x \mapsto p(x) := \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1}(1 - x)^{\beta-1} \text{ mit } \alpha, \beta \in \mathbb{R}_{>0}, \tag{21.23}$$

wobei Γ die Gammafunktion bezeichne. Dann sagen wir, dass ξ einer *Beta-Verteilung* mit Parametern $\alpha > 0$ und $\beta > 0$ unterliegt, und nennen ξ eine *Beta-Zufallsvariable*. Wir kürzen dies mit $\xi \sim \text{Beta}(\alpha, \beta)$ ab. Die WDF einer Beta-Zufallsvariable bezeichnen wir mit

$$\text{Beta}(x; \alpha, \beta) := \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1}(1 - x)^{\beta-1}. \tag{21.24}$$

•

Dadurch, dass der Ergebnisraum einer Beta-Zufallsvariable auf das Intervall $\mathcal{X} := [0, 1]$ (für $\alpha < 1, \beta < 1$ genauer $\mathcal{X} :=]0, 1[$) beschränkt ist, bietet sich eine Beta-Zufallsvariable unter anderem dafür an, Wahrscheinlichkeiten von Wahrscheinlichkeiten (also Werten zwischen 0 und 1) zu beschreiben. Wir visualisieren die WDFen von Beta-Zufallsvariablen für $(\alpha, \beta) := (1, 1), (\alpha, \beta) := (3, 2)$ und $(\alpha, \beta) := (10, 5)$ in Abbildung 21.8.

Mit den gleichverteilten Zufallsvariablen betrachten wir abschließend noch das Analogon zu diskret-gleichverteilten Zufallsvariablen für den Fall kontinuierlicher Zufallsvariablen.

Definition 21.12 (Gleichverteilte Zufallsvariable)**.** Es sei ξ eine kontinuierliche Zufallsvariable mit Ergebnisraum $\mathbb{R}$ und WDF

$$p : \mathbb{R} \to \mathbb{R}_{\geq 0}, x \mapsto p(x) := \begin{cases} \frac{1}{b-a} & x \in [a, b] \\ 0 & x \notin [a, b] \end{cases}. \tag{21.25}$$

Dann sagen wir, dass ξ einer *Gleichverteilung mit Parametern a und b* unterliegt und nennen ξ eine *gleichverteilte Zufallsvariable*. Wir kürzen dies mit $\xi \sim U(a, b)$ ab. Die WDF einer gleichverteilten Zufallsvariablen bezeichnen wir mit

$$U(x; a, b) := \frac{1}{b - a}. \tag{21.26}$$

•

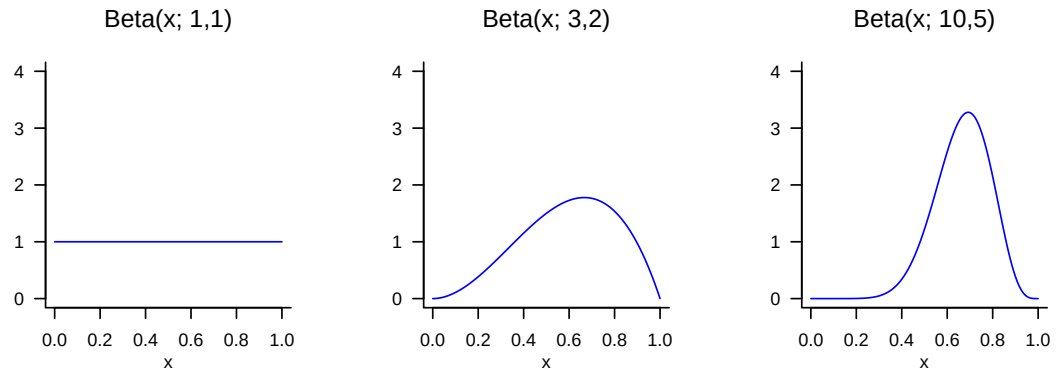


Abbildung 21.8. WDFen von Beta-Zufallsvariablen.

Wir visualisieren die WDFen von gleichverteilten Zufallsvariablen für $(a, b) := (0, 1)$, $(a, b) := (-3, 1)$ und $(a, b) := (-4, 4)$ in Abbildung 21.9.

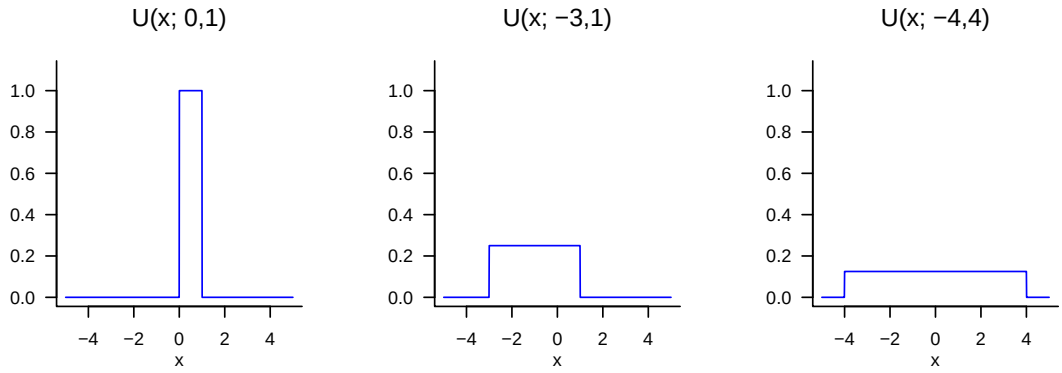


Abbildung 21.9. WDFen von gleichverteilten-Zufallsvariablen.

21.4. Kumulative Verteilungsfunktionen

Im letzten Abschnitt dieses Kapitels wollen wir mit den *kumulativen Verteilungsfunktionen (KVFen)* eine weitere Möglichkeit einführen, die Verteilungen von diskreten oder kontinuierlichen Zufallsvariablen festzulegen. Es ist allgemein allerdings eher üblich, dies mithilfe von WMFen oder WDFen zu tun. Trotzdem sind KVFen an vielen Stellen nützlich, da sie sowohl für diskrete als auch kontinuierliche Zufallsvariablen einen direkten Zusammenhang zwischen Werten der Zufallsvariable und bestimmten Wahrscheinlichkeiten herstellen, der in der Anwendung ohne Summation oder Integration auskommt. Wir betrachten zunächst die allgemeine Definition von KVFen für sowohl diskrete als auch kontinuierliche Zufallsvariablen und wenden uns dann den KVFen von diskreten und den KVFen von kontiniuerlichen Zufallsvariablen im Einzelnen zu. Für eine beliebige Zufallsvariable definieren wir den Begriff der KVF wie folgt.

Definition 21.13 (Kumulative Verteilungsfunktion)**.** Die *kumulative Verteilungsfunktion (KVF)* einer Zufallsvariable ξ ist definiert als

$$P : \mathbb{R} \to [0,1], x \mapsto P(x) := \mathbb{P}(\xi \leq x). \tag{21.27}$$

•

Man beachte, dass $P(x)$ für jedes $x \in \mathbb{R}$ definiert ist, auch wenn für ein gegebenes $x \in \mathbb{R}$ gilt, dass $x \notin \mathcal{X}$. Mithilfe von KVFen können zum Beispiel *Überschreitungswahrscheinlichkeiten* und *Intervallwahrscheinlichkeiten* von Zufallsvariablen direkt ausgewertet werden. Dies ist der Inhalt folgender Theoreme.

Theorem 21.2 (Überschreitungswahrscheinlichkeit)**.** *Es sei ξ eine Zufallsvariable mit Ergebnisraum $\mathcal{X}$ und P ihre kumulative Verteilungsfunktion. Dann gilt für die* Überschreitungswahrscheinlichkeit $\mathbb{P}(\xi > x)$*, dass*

$$\mathbb{P}(\xi > x) = 1 - P(x) \text{ für alle } x \in \mathcal{X}. \tag{21.28}$$

◦

Beweis. Die Ereignisse $\{\xi > x\}$ und $\{\xi \leq x\}$ sind disjunkt und

$$\Omega = \{\omega \in \Omega | \xi(\omega) > x\} \cup \{\omega \in \Omega | \xi(\omega) \leq x\} = \{\xi > x\} \cup \{\xi \leq x\}. \tag{21.29}$$

Mit der σ-Additivität von $\mathbb{P}$ folgt dann

$$\begin{aligned} \mathbb{P}(\Omega) &= 1 \\ \Leftrightarrow \mathbb{P}(\{\xi > x\} \cup \{\xi \leq x\}) &= 1 \\ \Leftrightarrow \mathbb{P}(\{\xi > x\}) + \mathbb{P}(\{\xi \leq x\}) &= 1 \\ \Leftrightarrow \mathbb{P}(\{\xi > x\}) &= 1 - \mathbb{P}(\{\xi \leq x\}) \\ \Leftrightarrow \mathbb{P}(\{\xi > x\}) &= 1 - P(x). \end{aligned} \tag{21.30}$$

□

Theorem 21.3 (Intervallwahrscheinlichkeiten)**.** *Es sei ξ eine Zufallsvariable mit Ergebnisraum $\mathcal{X}$ und P ihre KVF. Dann gilt für die* Intervallwahrscheinlichkeit $\mathbb{P}(\xi \in]x_1, x_2])$*, dass*

$$\mathbb{P}(\xi \in]x_1, x_2]) = P(x_2) - P(x_1) \text{ für alle } x_1, x_2 \in \mathcal{X} \text{ mit } x_1 < x_2. \tag{21.31}$$

◦

Beweis. Wir betrachten die Ereignisse $\{\xi \leq x_1\}$,$\{x_1 < \xi \leq x_2\}$ und $\{\xi \leq x_2\}$, wobei

$$\{\xi \leq x_1\} \cap \{x_1 < \xi \leq x_2\} = \emptyset \text{ und } \{\xi \leq x_1\} \cup \{x_1 < \xi \leq x_2\} = \{\xi \leq x_2\}. \tag{21.32}$$

gelten. Mit der σ-Additivität von $\mathbb{P}$ gilt dann

$$\begin{aligned} \mathbb{P}(\{\xi \leq x_1\} \cup \{x_1 < \xi \leq x_2\}) &= \mathbb{P}(\{\xi \leq x_2\}) \\ \Leftrightarrow \mathbb{P}(\{\xi \leq x_1\}) + \mathbb{P}(\{x_1 < \xi \leq x_2\}) &= \mathbb{P}(\{\xi \leq x_2\}) \\ \Leftrightarrow \mathbb{P}(\{x_1 < \xi \leq x_2\}) &= \mathbb{P}(\{\xi \leq x_2\}) - \mathbb{P}(\{\xi \leq x_1\}) \\ \Leftrightarrow \mathbb{P}(\{x_1 < \xi \leq x_2\}) &= P(x_2) - P(x_1) \\ \Leftrightarrow \mathbb{P}(\xi \in]x_1, x_2]) &= P(x_2) - P(x_1). \end{aligned} \tag{21.33}$$

□

Folgendes Theorem gibt drei zentrale Eigenschaften von KVFen an. Dabei besagt die dritte Eigenschaft, dass eine KVF keine Sprünge hat, wenn man sich Grenzpunkten von rechts nähert. Tatsächlich sind die diskutierten Eigenschaften auch gerade die definierenden Eigenschaften von KVFen, das heißt, jede Funktion P, die die Eigenschaften von Theorem 21.4 erfüllt, kann als eine KVF einer Zufallsvariablen interpretiert werden. Für einen Beweis dieser Tatsache verweisen wir auf die weiterführende Literatur.

Theorem 21.4 (Eigenschaften von kumulative Verteilungsfunktionen)**.** *Es sei ξ eine Zufallsvariable und P ihre kumulative Verteilungsfunktion. Dann hat P die folgenden Eigenschaften*

(1) P ist monoton steigend*, das heißt, wenn $x_1 < x_2$, dann gilt $P(x_1) \leq P(x_2)$.*
(2) $\lim_{x\to-\infty} P(x) = 0$ *und* $\lim_{x\to\infty} P(x) = 1$.
(3) P ist rechtsseitig stetig*, d.h., $P(x) = \lim_{y\to x, y>x} P(y)$ für alle $x \in \mathbb{R}$*

∘

Beweis. Wir betrachten die Eigenschaften nacheinander.

(1) Wir halten zunächst fest, dass für Ereignisse $A \subset B$ gilt, dass $\mathbb{P}(A) \leq \mathbb{P}(B)$. Wir halten dann fest, dass für $x_1 < x_2$,

$$\{\xi \leq x_1\} = \{\omega \in \Omega | \xi(\omega) \leq x_1\} \subset \{\omega \in \Omega | \xi(\omega) \leq x_2\} = \{\xi \leq x_2\}. \tag{21.34}$$

Also gilt

$$\mathbb{P}(\{\xi \leq x_1\}) \leq \mathbb{P}\{\xi \leq x_2\} \Rightarrow P(x_1) \leq P(x_2). \tag{21.35}$$

(2) Für einen Beweis verweisen wir auf die weiterführende Literatur.

(3) Wir definieren

$$P(x^+) = \lim_{y\to x, y>x} P(y). \tag{21.36}$$

Seien nun $y_1 > y_2 > \cdots$ so, dass $\lim_{n\to\infty} y_n = x$. Dann gilt

$$\{\xi \leq x\} = \cap_{n=1}^{\infty} \{\xi \leq y_n\}. \tag{21.37}$$

Es gilt also

$$P(x) = \mathbb{P}(\{\xi \leq x\}) = \mathbb{P}(\cap_{n=1}^{\infty} \{\xi \leq y_n\}) = \lim_{n\to\infty} \mathbb{P}(\{\xi \leq y_n\}) = P(x^+), \tag{21.38}$$

wobei wir die dritte Gleichung unbegründet stehen lassen.

□

KVFen von diskreten Zufallsvariablen

Anhand von Abbildung 21.10 und Abbildung 21.11 wollen wir uns obige Eigenschaften von KVFen diskreter Zufallsvariablen visuell verdeutlichen. Dabei sollte man immer vor Augen haben, dass der Wert $P(x)$ einer KVF für den Ergebniswert x der Zufallsvariable ξ der Wahrscheinlichkeit $\mathbb{P}(\xi \leq x)$ entspricht, also der Wahrscheinlichkeit dafür ist, dass die Zufallsvariable ξ Werte kleiner oder gleich x annimmt. Liest man diese Wahrscheinlichkeiten entsprechend aus den Darstellungen der korrespondierenden WMF ab, so ergeben sich die funktionale Form der KVFen im Vergleich mit den entsprechenden WMFen intuitiv. Weiterhin erschließen sich auch folgende Eigenschaften der KVFen von diskreten Zufallsvariablen intuitiv: Wenn $a < b$ und $\mathbb{P}(a < \xi < b) = 0$ ist, dann ist die KVF von ξ konstant horizontal auf $]a, b[$. Weiterhin gilt, dass an jedem Punkt x mit $\mathbb{P}(\xi = x) > 0$ die KVF um

den Betrag $\mathbb{P}(\xi = x)$ springt, an dieser Stelle also linksseitig nicht stetig ist. Allgemein ist die KVF einer diskreten Zufallsvariablen mit Ergebnisraum $\mathbb{N}_0$ durch

$$P : \mathbb{R} \to [0, 1], x \mapsto P(x) := \sum_{k=0}^{\lfloor x \rfloor} \mathbb{P}(\xi = k) \tag{21.39}$$

gegeben, wobei $\lfloor x \rfloor$ die Abrundungsfunktion bezeichnet.

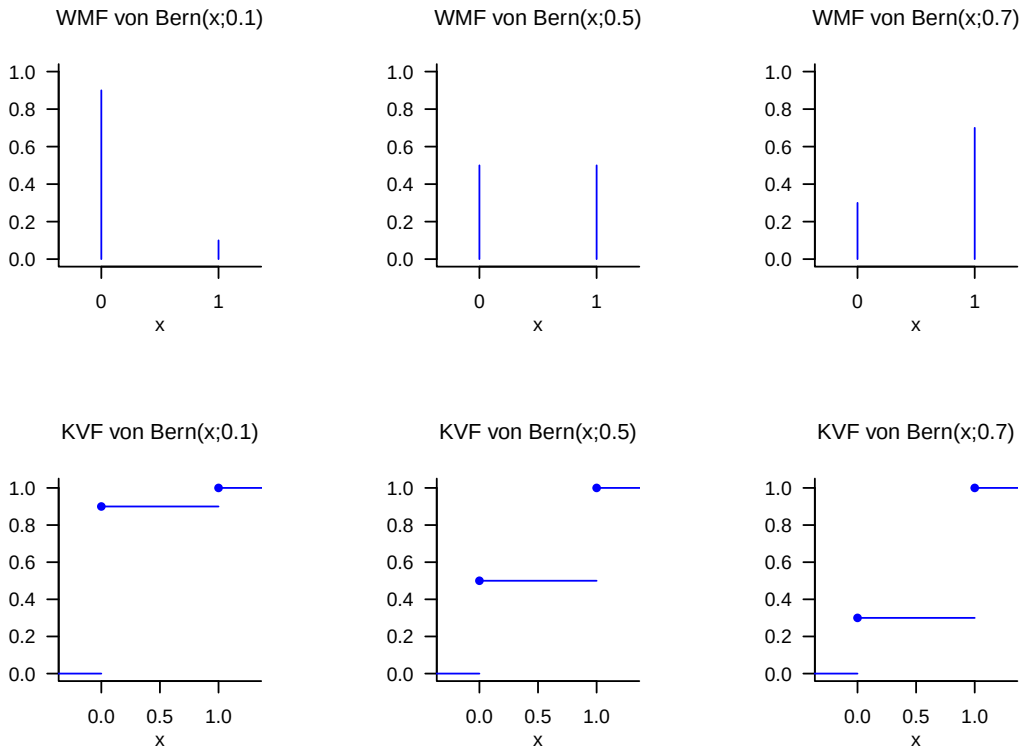


Abbildung 21.10. WMFen und KVFen von Bernoulli-Zufallsvariablen.

KVFen von kontinuierlichen Zufallsvariablen

Die KVFen von kontinuierlichen Zufallsvariablen sind analytisch etwas zugänglicher als die KVFen von diskreten Zufallsvariablen, da sie keine Unstetigkeitsstellen aufweisen. Wir haben zunächst folgendes, vielleicht etwas überraschendes Theorem.

Theorem 21.5 (Kumulative Verteilungsfunktionen von kontinuierlichen Zufallsvariablen)**.** *ξ sei eine kontinuierliche Zufallsvariable mit WDF p und KVF P. Dann gelten*

$$P(x) = \int_{-\infty}^{x} p(s)\, ds \text{ und } p(x) = P'(x). \tag{21.40}$$

∘

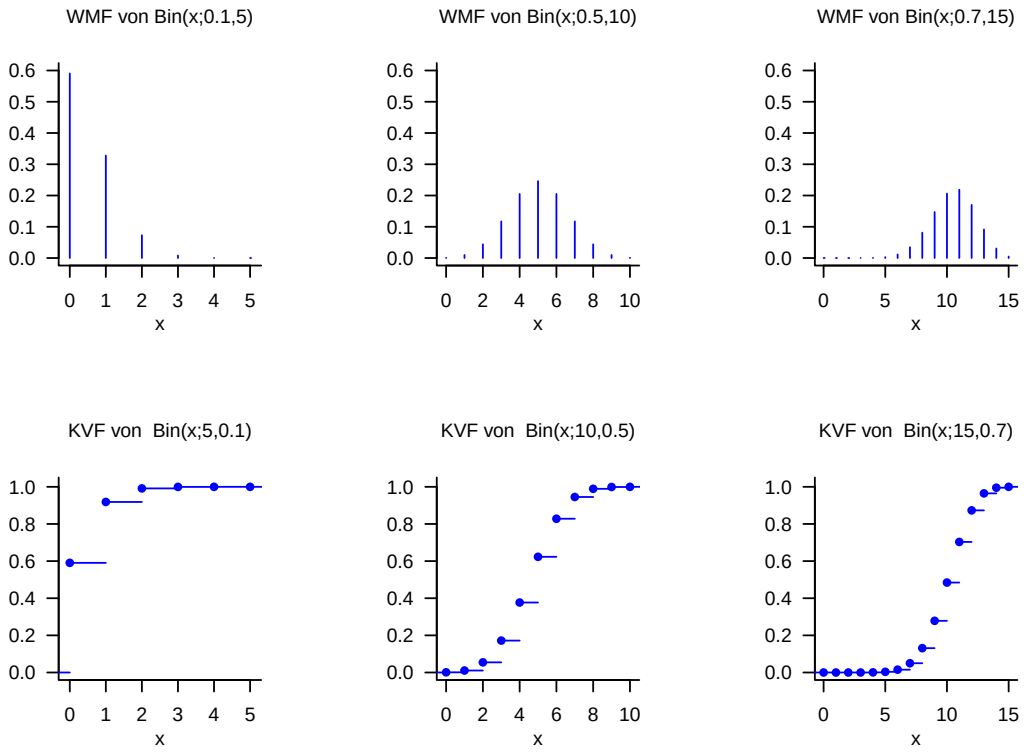


Abbildung 21.11. WMFen und KVFen von Binomial-Zufallsvariablen.

Beweis. Wir halten zunächst fest, dass weil $\mathbb{P}(\xi = x) = 0$ für alle $x \in \mathbb{R}$ gilt, die KVF von ξ keine Sprünge hat, P also stetig ist. Mit den Definitionen von WDF und KVF, folgt, dass P die Form einer Stammfunktion von p hat. Dass p die Ableitung von P ist, folgt dann direkt aus dem ersten Hauptsatz der Differenzial- und Integralrechnung (Theorem 7.5). □

Für kontinuierliche Zufallsvariablen gilt also, dass die KVF der Zufallsvariable eine Stammfunktion der entsprechenden WDF ist, und umgekehrt, dass die WDF die Ableitung der KVF ist. Im Kontext des *Theorems von Radon-Nikodym* wird diese Einsicht auf generelle Maße generalisiert (vgl. Schmidt (2009)). KVFen kontinuierlicher Zufallsvariablen werden auch oft als kumulative Dichtefunktionen (KDFen) bezeichnet.

Als Beispiel betrachten wir die KVF einer normalverteilten Zufallsvariablen. Es sei $\xi \sim N(\mu, \sigma^2)$. Dann ist die WDF von ξ bekanntlich durch

$$p : \mathbb{R} \to \mathbb{R}_{>0}, x \mapsto p(x) := \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right). \tag{21.41}$$

gegeben. Für die KVF von ξ folgt entsprechend, dass

$$P : \mathbb{R} \to]0,1[, x \mapsto P(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{x} \exp\left(-\frac{1}{2\sigma^2}(s-\mu)^2\right) ds. \tag{21.42}$$

Interessanterweise kann das definierende Integral der KVF einer normalverteilten Zufallsvariablen nur numerisch, nicht aber analytisch berechnet werden. Wir visualisieren ausgewählte WDFen und KVFen von normalverteilten Zufallsvariablen in Abbildung 21.12.

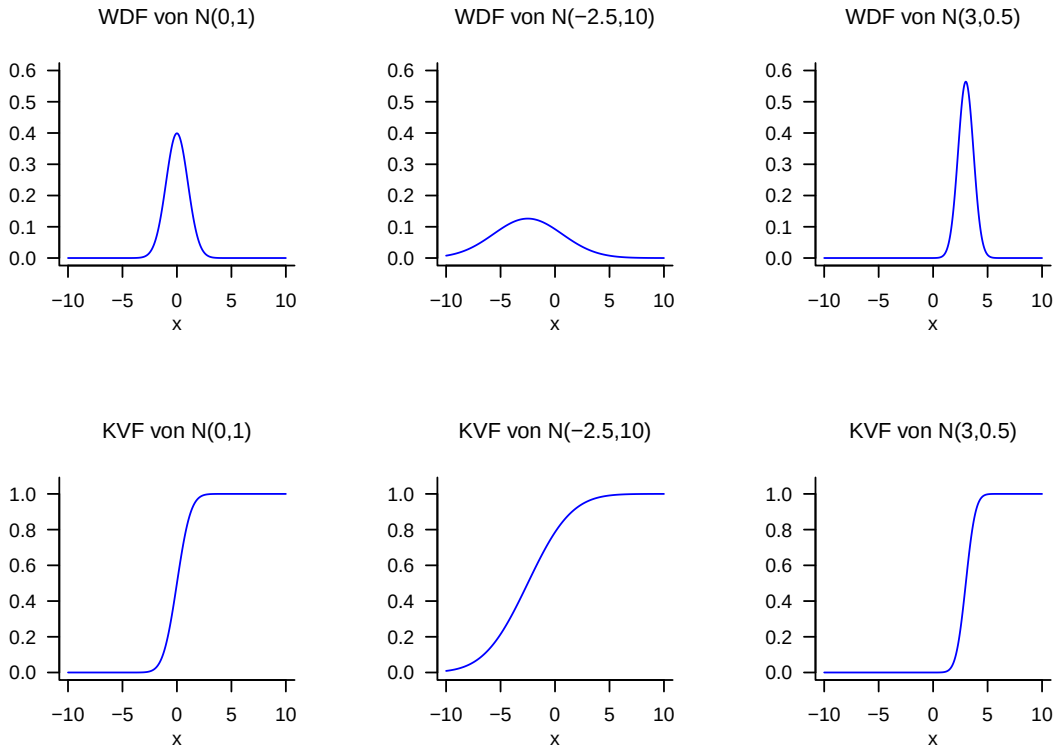


Abbildung 21.12. WDFen und KVFen von normalverteilten Zufallsvariablen.

Inverse kumulative Verteilungsfunktion

Wir beschließen diesen Abschnitt mit dem Begriff der *inversen kumulativen Verteilungsfunktion*, einem technischen Hilfsmittel, dass insbesondere bei Konfidenzintervallen und Hypothesentests der frequentistischen Inferenz zur Bestimmung kritischer Werte benutzt wird. Wir definieren die inverse KVF wie folgt.

Definition 21.14 (Inverse kumulative Verteilungsfunktion)**.** ξ sei eine kontinuierliche Zufallsvariable mit KVF P. Dann heißt die Funktion

$$P^{-1} :]0,1[\rightarrow \mathbb{R}, q \mapsto P^{-1}(q) := \{x \in \mathbb{R} | P(x) = q\} \tag{21.43}$$

die *inverse kumulative Verteilungsfunktion von* ξ.

•

Nach Definition 21.14 gilt offenbar, dass die Funktion P^{-1} die Umkehrfunktion von P ist, also

$$P^{-1}(P(x)) = x. \tag{21.44}$$

Da bekanntlich gilt, dass

$$P(x) = q \Leftrightarrow \mathbb{P}(\xi \leq x) = q \text{ für } q \in]0,1[, \tag{21.45}$$

ist $P^{-1}(q)$ also der Wert x von ξ, so dass $\mathbb{P}(\xi \leq x) = q$. Wir visualisieren die KVFen und inversen KVFen normalverteilter Zufallsvariablen in Abbildung 21.13. Im Falle einer normalverteilten Zufallsvariable $\xi \sim N(0, 1)$ gelten beispielsweise, dass

$$P(1.645) = 0.950 \Leftrightarrow P^{-1}(0.950) = 1.645, \tag{21.46}$$

und

$$P(1.906) = 0.975 \Leftrightarrow P^{-1}(0.975) = 1.960. \tag{21.47}$$

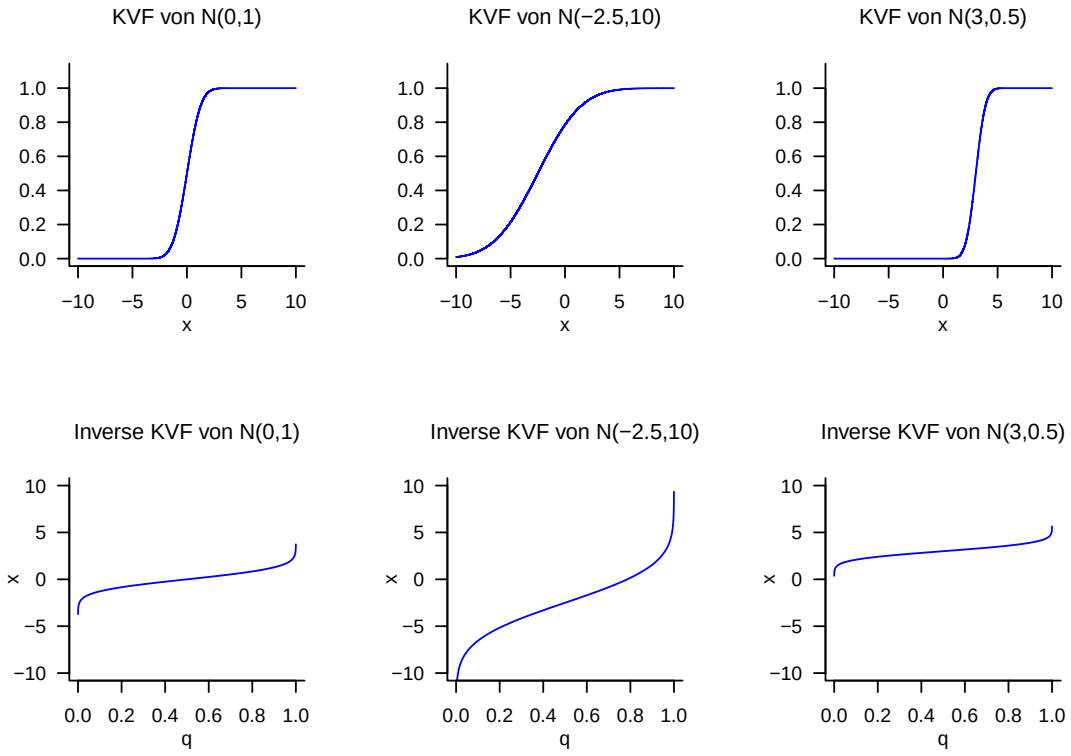


Abbildung 21.13. KVFen und inverse KVFen von normalverteilten Zufallsvariablen.

21.5. Zufallsergebnisse und Zufallsvariablen

Mit den in Kapitel 19 diskutierten *Ergebnissen* ω und den in diesem Kapitel diskutierten Werten von *Zufallsvariablen* ξ haben wir nun zwei Konzepte kennengelernt, die die Unsicherheit über einen zumeist numerischen Wert eines Zufallsvorgangs beschreiben können. So kann man sich zum Beispiel die Augenzahl, die ein Würfel beim einmaligen Werfen annimmt, als Realisierung eines Ergebnisses oder einer Zufallsvariablen vorstellen. Tatsächlich gibt es auch keine standardisierte Antwort auf die Frage, ob man einen Zufallsvorgang lediglich mit einem Wahrscheinlichkeitsraum oder mit dem zugrundeliegenden Wahrscheinlichkeitsraum einer Zufallsvariablen und dem durch beide induzierten Wahrscheinlichkeitsraum modellieren sollte. In der Anwendung wird meist der Begriff der Zufallsvariablen bevorzugt und entsprechende WMFen oder WDFen angegeben, ohne dass ein zugrundeliegender Wahrscheinlichkeitsraum oder die Abbildungsform der Zufallsvariablen spezifiziert würde. Folgende Formulierung ist beispielsweise typisch:

ξ sei eine normalverteilte Zufallsvariable mit Erwartungswertparameter μ und Varianzparameter σ^2.

Implizit werden in dieser Aussage basierend auf der Definition der normalverteilten Zufallsvariable (vgl. Definition 21.9) für ξ der Ergebnisraum $\mathcal{X} := \mathbb{R}$, die σ-Algebra $\mathcal{S} := \mathcal{B}(\mathbb{R})$, und die Verteilung $\mathbb{P}_\xi := N(\mu, \sigma^2)$ festgelegt, also der "induzierte" Wahrscheinlichkeitsraum $(\mathbb{R}, \mathcal{B}(\mathbb{R}), N(\mu, \sigma^2))$ betrachtet. Allerdings bleibt unklar, durch welchen Wahrscheinlichkeitsraum und welche Abbildungsform genau $(\mathbb{R}, \mathcal{B}(\mathbb{R}), N(\mu, \sigma^2))$ nun induziert wurde. Dies kann allerdings immer durch die Annahme, dass ξ die Identitätsfunktion ist, ergänzt werden. Konkret könnte man für den zugrundeliegenden Wahrscheinlichkeitsraum hier $(\mathbb{R}, \mathcal{B}(\mathbb{R}), N(\mu, \sigma^2))$ und für ξ dann

$$\xi : \mathbb{R} \to \mathbb{R}, \omega \mapsto \xi(\omega) := \omega := x \tag{21.48}$$

wählen. Da ξ dann an dem im Rahmen des zugrundeliegenden Wahrscheinlichkeitsraums zufällig realisiertem Ergebnis ω nichts ändert und dieses lediglich in x umbenannt wird, entspricht die Verteilung von ξ hier direkt dem Wahrscheinlichkeitsmaß des zugrundeliegenden Wahrscheinlichkeitsraums.

Allgemein mag man festhalten, dass das Modellieren von Zufallsvorgängen mithilfe von Zufallsvariablen das elementare Wahrscheinlichkeitsraummodell also als Spezialfall enthält, über dies hinausgehend aber die Möglichkeit eröffnet, durch von der Identitätsabbildung verschiedene Zufallsvariablen die Transformation von Wahrscheinlichkeitsmaßen auf unterschiedlichen Messräumen zu formalisieren und zu studieren.

21.6. Literaturhinweise

Die Genese des Begriffs der Zufallsvariablen ist eng mit der Entwicklung der Wahrscheinlichkeitstheorie in den letzten drei Jahrhunderten verflochten, sodass keine für den Begriff entscheidene Publikation angegeben werden kann. Die mathematische Entwicklung des Begriffs der Normalverteilung durch Abraham De Moivre (1667-1754), Pierre Simon Laplace (1749-1827), Johann Carl Friedrich Gauss (1777-1855) und viele andere, ihre deskriptivstatistischen Entsprechungen in der empirischen Forschung des 19. Jahrhunderts, sowie ihre multivariate Generalisierung im ausgehenden 19. Jahrhundert werden ausführlich in Stigler (1986) dargestellt.

Selbstkontrollfragen

1. Geben Sie die Definition des Begriffs der Zufallsvariable wieder.
2. Erläutern Sie die Gleichung $\mathbb{P}_\xi(\xi = x) = \mathbb{P}(\{\xi = x\})$.
3. Erläutern Sie die intuitive Bedeutung von $\mathbb{P}(\xi = x)$.
4. Geben Sie die Definition des Begriffs der Wahrscheinlichkeitsmassefunktion wieder.
5. Geben Sie die Definition des Begriffs der Wahrscheinlichkeitsdichtefunktion wieder.
6. Geben Sie die Definition der WDF einer normalverteilten Zufallsvariable wieder.
7. Geben Sie die Definition des Begriffs der kumulativen Verteilungsfunktion wieder.
8. Schreiben Sie die Überschreitungswahrscheinlichkeit $\mathbb{P}(\xi > x)$ einer Zufallsvariable mithilfe ihrer KVF.
9. Schreiben Sie die Intervallwahrscheinlichkeit $\mathbb{P}(\xi \in]x_1, x_2]$ einer Zufallsvariable mithilfe ihrer KVF.
10. Schreiben Sie den Wert $P(x)$ der KVF einer kontinuierlichen Zufallsvariable mithilfe ihrer WDF p.
11. Schreiben Sie den Wert $p(x)$ der WDF einer kontinuierlichen Zufallsvariable mithilfe ihrer KVF P.
12. Geben Sie die Definition des Begriffs der inversen Verteilungsfunktion wieder.

Lösungen

1. Siehe Definition 21.1.
2. Die Gleichung besagt, dass der von der Verteilung $\mathbb{P}_\xi$ der Zufallsvariable ξ zugeordnete Wahrscheinlichkeitswert für das Ereignis $\xi = x$ in $\mathcal{X}$ definitionsgemäß gleich dem Wert des von dem Wahrscheinlichkeitsmaß $\mathbb{P}$ dem Urbild des Ereignisses $\xi = x$, also der Menge $\{\xi = x\} = \{\omega \in \Omega | \xi(\omega) = x\}$ in $\mathcal{A}$, ist. Siehe Definition 21.3.
3. Intuitiv ist $\mathbb{P}(\xi = x)$ die Wahrscheinlichkeit dafür, dass die Zufallsvariable ξ den Wert x annimmt.
4. Siehe Definition 21.4.
5. Siehe Definition 21.8.
6. Siehe Definition 21.9.
7. Siehe Definition 21.13.
8. Siehe Theorem 21.2.
9. Siehe Theorem 21.3.
10. Siehe Theorem 21.5. Es gilt
$$P(x) = \int_{-\infty}^{x} p(s)\, ds. \tag{21.49}$$
11. Siehe Theorem 21.5. Es gilt
$$p(x) = \frac{d}{dx} P(x) = P'(x). \tag{21.50}$$
12. Siehe Definition 21.14.

22. Zufallsvektoren

Zufallsvektoren sind Tupel von Zufallsvariablen. Da jede Zufallsvariable einer Wahrscheinlichkeitsverteilung unterliegt, unterliegt auch ein Zufallsvektor einer Wahrscheinlichkeitsverteilung. Da ein Zufallsvektor aus zwei oder mehr Zufallsvariablen besteht, beschreibt die Verteilung eines Zufallsvektors die *gemeinsame Verteilung* von zwei oder mehr Zufallsvariablen. In diesem Kapitel wollen wir zunächst den Begriff des Zufallsvektors und seiner assoziierten Wahrscheinlichkeitsverteilung, die oft einfach als eine *multivariate Verteilung* bezeichnet wird, einführen. Wir wollen dann diskutieren, wie die Begriffe der WMF, WDF und KVF von Zufallsvariablen auf Zufallsvektoren übertragen werden können (Kapitel 22.1). Mit den *marginalen Verteilungen* und den *bedingten Verteilungen* führen wir dann nachfolgend Begriffe ein, die in der Betrachtung von Zufallsvariablen nicht auftreten. Schließlich führen wir mit dem Begriff der *unabhängigen Zufallsvariablen* das probabilistische Standardmodell für univariate Datensätze ein. Dies stellt einen Spezialfall der gemeinsamen Verteilung der Zufallsvariablen eines Zufallsvektors dar.

22.1. Definition und multivariate Verteilungen

Die Konstruktion und Definition eines Zufallsvektors ist analog zu der einer Zufallsvariable, mit dem Unterschied, dass es sich bei einer Zufallsvariable um eine skalarwertige, bei einem Zufallsvektor dagegen um eine vektorwertige Abbildung auf dem Ergebnisraum eines Wahrscheinlichkeitsraums handelt.

Definition 22.1 (Zufallsvektor)**.** $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und $(\mathcal{X}, \mathcal{S})$ sei ein n-dimensionaler Messraum. Ein n-dimensionaler *Zufallsvektor* ist definiert als eine Abbildung

$$\xi : \Omega \to \mathcal{X}, \omega \mapsto \xi(\omega) := \begin{pmatrix} \xi_1(\omega) \\ \vdots \\ \xi_n(\omega) \end{pmatrix} \tag{22.1}$$

mit der *Messbarkeitseigenschaft*

$$\{\omega \in \Omega | \xi(\omega) \in S\} \in \mathcal{A} \text{ für alle } S \in \mathcal{S}. \tag{22.2}$$

•

Das Standardbeispiel für den Ergebnisraum eines Zufallsvektors ist $\mathbb{R}^n$, das Standardbeispiel für die auf ihm definierte σ-Algebra ist die n-dimensionale Borelsche σ-Algebra $\mathcal{B}(\mathbb{R}^n)$. Für eine explizite und formale Einführung der n-dimensionalen Borelschen σ-Algebra verweisen wir auf die weiterführende Literatur (z.B. Schmidt (2009)). Wir begnügen uns hier wieder mit der (weiterhin formal falschen) Intuition der n-dimensionalen Borelschen σ-Algebra als Menge aller Teilmengen des $\mathbb{R}^n$. Das Standardbeispiel für einen n-dimensionalen Messraum ist damit $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$.

Wie bei allen vektorwertigen Funktionen nennen wir die den Zufallsvektor konstituierenden Funktionen ξ_i die *Komponentenfunktionen* von ξ. Legen wir den n-dimensionalen Messraum $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ dem Zufallsvektor zugrunde, so haben diese die Form

$$\xi_i : \Omega \to \mathbb{R}, \omega \mapsto \xi_i(\omega). \tag{22.3}$$

Ohne Beweis halten wir fest, dass der Zufallsvektor ξ messbar ist, wenn für alle $i = 1, ..., n$ die Funktionen ξ_i messbar sind und umgekehrt. Damit sind die Komponentenfunktionen eines Zufallsvektors (letztlich nach Definition) Zufallsvariablen. Ein n-dimensionaler Zufallsvektor wird also als eine Konkatenation von n Zufallsvariablen betrachtet, für $n := 1$ entspricht ein Zufallsvektor einer Zufallsvariable.

Zufallsvektoren werden manchmal auch als "multivariate Zufallsvariablen" bezeichnet. Tatsächlich stehen bei der Betrachtung von Zufallsvektoren auch zunächst primär wahrscheinlichkeitstheoretische Aspekte und nicht etwa Aspekte der geometrischen Vektorraumtheorie im Vordergrund. Die Betrachtung von Vektorraumstrukturen ist im Kontext probabilistischer Standardmodelle wie dem Allgemeinen linearen Modell aber durchaus üblich, sodass wir hier den Begriff des Zufallsvektors bevorzugen (vgl. Christensen (2011)). Trotzdem werden wir Zufallsvektoren, wie in vielen Texten der Probabilistik üblich, auch oft in Zeilenform, also etwa als $\xi := (\xi_1, ..., \xi_n)$, notieren.

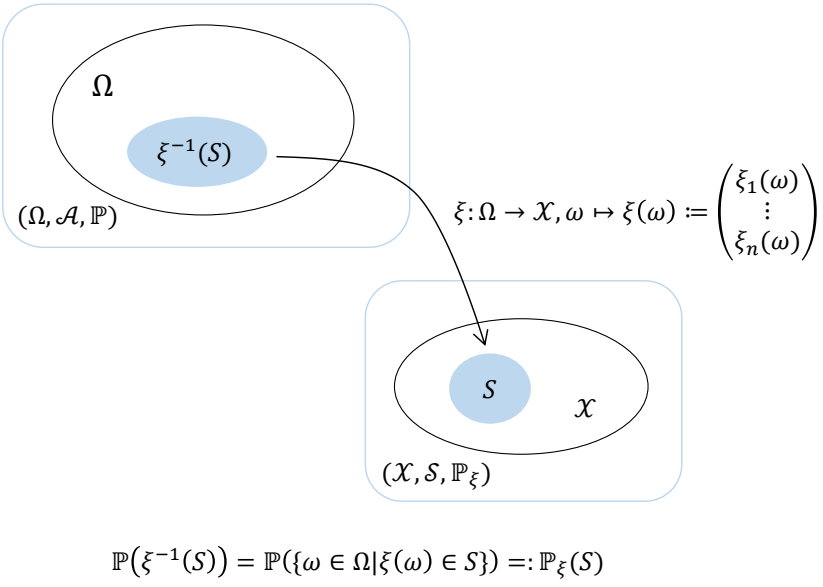


Abbildung 22.1. Konstruktion von Zufallsvektor und multivariater Verteilung.

Das durch die Konstruktion eines Zufallsvektors definierte Bildmaß heißt die *multivariate Verteilung des Zufallsvektors*, wie in folgender Definition ausgeführt (vgl. Abbildung 22.1).

Definition 22.2 (Multivariate Verteilung)**.** $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum, $(\mathcal{X}, \mathcal{S})$ sei ein n-dimensionaler Messraum und

$$\xi : \Omega \to \mathcal{X}, \omega \mapsto \xi(\omega) \tag{22.4}$$

sei ein Zufallsvektor. Dann heißt das Wahrscheinlichkeitsmaß $\mathbb{P}_\xi$, definiert durch

$$\mathbb{P}_\xi : \mathcal{S} \to [0, 1], S \mapsto \mathbb{P}_\xi(S) := \mathbb{P}(\xi^{-1}(S)) = \mathbb{P}\left(\{\omega \in \Omega | \xi(\omega) \in S\}\right) \tag{22.5}$$

die *multivariate Verteilung des Zufallsvektor* ξ.

•

Der Einfachheit halber spricht man oft auch nur von *der Verteilung des Zufallsvektors* ξ oder einer *multivariaten Verteilung*. Die Notationskonventionen für Zufallsvariablen Definition 21.3 gelten für Zufallsvektoren analog. Zum Beispiel gelten

$$\begin{aligned}
\mathbb{P}_\xi(\xi \in S) &:= \mathbb{P}\left(\{\xi \in S\}\right) = \mathbb{P}\left(\{\omega \in \Omega | \xi(\omega) \in S\}\right) \\
\mathbb{P}_\xi(\xi = x) &:= \mathbb{P}\left(\{\xi = x\}\right) = \mathbb{P}\left(\{\omega \in \Omega | \xi(\omega) = x\}\right) \\
\mathbb{P}_\xi(\xi \leq x) &:= \mathbb{P}\left(\{\xi \leq x\}\right) = \mathbb{P}\left(\{\omega \in \Omega | \xi(\omega) \leq x\}\right) \\
\mathbb{P}_\xi(x_1 \leq \xi \leq x_2) &:= \mathbb{P}\left(\{x_1 \leq \xi \leq x_2\}\right) = \mathbb{P}\left(\{\omega \in \Omega | x_1 \leq \xi(\omega) \leq x_2\}\right)
\end{aligned} \tag{22.6}$$

wobei die Relationsoperatoren $<, \leq, >, \geq$ hier *komponentenweise* verstanden werden. So heißt beispielsweise $x \leq y$ für $x, y \in \mathbb{R}^n$, dass für alle Komponenten $x_i, y_i, i = 1, ..., n$ gilt, dass $x_i \leq y_i$. Eben dieser Konvention folgt auch die Definition der *multivariaten kumulativen Verteilungsfunktion* in Generalisierung von Definition 21.13. Wie bei den Zufallsvariablen werden die qualifizierenden Subskripte bezüglich eines speziellen Zufallsvektors im Sinne der Multimethode meist weggelassen. Wir nutzen diese Konvention schon in folgender Definition der multivariaten kumulativen Verteilungsfunktion eines Zufallsvektors ξ.

Definition 22.3 (Multivariate kumulative Verteilungsfunktionen)**.** ξ sei ein Zufallsvektor mit Ergebnisraum $\mathcal{X}$. Dann heißt eine Funktion der Form

$$P : \mathcal{X} \to [0, 1],\ x \mapsto P(x) := \mathbb{P}(\xi \leq x) \tag{22.7}$$

multivariate kumulative Verteilungsfunktion von ξ.

•

Wie kumulative Verteilungsfunktionen können auch multivariate kumulative Verteilungsfunktionen zur Definition von multivariaten Verteilungen genutzt werden. Häufiger ist allerdings, wie im univariaten Fall, die Definition multivariater Verteilungen durch *multivariate Wahrscheinlichkeitsmasse-* oder *Wahrscheinlichkeitsdichtefunktionen*. Wir generalisieren die Definitionen diskreter und kontinuierlicher Zufallsvariablen und ihren assoziierten Wahrscheinlichkeitsmasse- und Wahrscheinlichkeitsdichtefunktionen wie folgt (vgl. Definition 21.4 und Definition 21.8).

Definition 22.4 (Diskreter Zufallsvektor und multivariate Wahrscheinlichkeitsmassefunktion)**.** Ein Zufallsvektor ξ heißt *diskret*, wenn sein Ergebnisraum $\mathcal{X}$ endlich oder abzählbar ist und eine Funktion

$$p : \mathcal{X} \to [0, 1], x \mapsto p(x) \tag{22.8}$$

existiert, für die gilt

(1) $\sum_{x \in \mathcal{X}} p(x) = 1$
(2) $\mathbb{P}(\xi = x) = p(x)$ für alle $x \in \mathcal{X}$.

Eine entsprechende Funktion p heißt *multivariate Wahrscheinlichkeitsmassefunktion (WMF)* von ξ.

•

Der Begriff der multivariaten WMF ist offenbar direkt analog zum Begriff der WMF. Wie univariate WMFen sind multivariate WMFen nicht-negativ und normiert. Der Einfachheit halber spricht man oft einfach von *der WMF eines Zufallsvektors* und verzichtet bei ihrer Bezeichnung, wenn der betreffende Zufallsvektor aus dem Kontext klar ist, auf das ξ Subskript, schreibt also oft einfach p anstelle von p.

Beispiel 22.1 (Diskreter Zufallsvektor)**.** Zur Illustration des Begriffs des diskreten Zufallsvektors und seiner WMF wollen wir ein Beispiel betrachten. Dazu sei $\xi := (\xi_1, \xi_2)$ ein Zufallsvektor, der Werte in $\mathcal{X} := \mathcal{X}_1 \times \mathcal{X}_2$ annimmt, wobei $\mathcal{X}_1 := \{1, 2, 3\}$ und $\mathcal{X}_2 = \{1, 2, 3, 4\}$ seien. Dann entspricht der Ergebnisraum von ξ der in Tabelle 22.1 spezifizierten Menge an Tupeln (x_1, x_2).

Tabelle 22.1. Ergebnisraum

(x_1, x_2)	$x_2 = 1$	$x_2 = 2$	$x_2 = 3$	$x_2 = 4$
$x_1 = 1$	$(1, 1)$	$(1, 2)$	$(1, 3)$	$(1, 4)$
$x_1 = 2$	$(2, 1)$	$(2, 2)$	$(2, 3)$	$(2, 4)$
$x_1 = 3$	$(3, 1)$	$(3, 2)$	$(3, 3)$	$(3, 4)$

Eine exemplarische bivariate WMF der Form

$$p : \{1, 2, 3\} \times \{1, 2, 3, 4\} \to [0, 1], (x_1, x_2) \mapsto p(x_1, x_2) \tag{22.9}$$

ist dann durch Tabelle 22.2 definiert.

Tabelle 22.2. Bivariate WMF $p(x_1, x_2)$

$p(x_1, x_2)$	$x_2 = 1$	$x_2 = 2$	$x_2 = 3$	$x_2 = 4$
$x_1 = 1$	0.1	0.0	0.2	0.1
$x_1 = 2$	0.1	0.2	0.0	0.0
$x_1 = 3$	0.0	0.1	0.1	0.1

Man beachte, dass die so spezifierte Funktion p den Normiertheits- und Nichtnegativitätsansprüchen an eine WMF genügt. Insbesondere gilt hier

$$\sum_{x \in \mathcal{X}} p(x) = \sum_{x_1=1}^{3} \sum_{x_2=1}^{4} p(x_1, x_2) = 1. \tag{22.10}$$

△

Den Begriff des kontinuierlichen Zufallsvektors und der multivariaten Wahrscheinlichkeitsdichtefunktion definieren wir wie folgt.

Definition 22.5 (Kontinuierlicher Zufallsvektor und multivariate Wahrscheinlichkeitdichtefunktion)**.** Ein Zufallsvektor ξ heißt *kontinuierlich*, wenn sein Ergebnisraum durch $\mathbb{R}^n$ gegeben ist und eine Funktion

$$p : \mathbb{R}^n \to \mathbb{R}_{\geq 0}, x \mapsto p(x), \tag{22.11}$$

existiert, für die gilt, dass

(1) $\int_{\mathbb{R}^n} p(x)\, dx = 1$ und

(2) $\mathbb{P}(x_1 \leq \xi \leq x_2) = \int_{x_{1_1}}^{x_{2_1}} \cdots \int_{x_{1_n}}^{x_{2_n}} p(s_1, ..., s_n)\, ds_1 \cdots ds_n$.

Eine entsprechende Funktion p heißt *multivariate Wahrscheinlichkeitsdichtefunktion (WDF) von* ξ.

•

Offenbar ist der Begriff der multivariaten WDF eines kontinuierlichen Zufallsvektors analog zum Begriff der WDF einer kontinuierlichen Zufallsvariable und wie univariate WDFen sind multivariate WDFen nicht-negativ und normiert. Der Einfachheit halber spricht man auch hier oft einfach von *multivariaten WDFen* und verzichtet auf die den Zufallsvektor identifizierenden Subskripte. Wie für kontinuierliche Zufallsvariablen gilt für kontinuierliche Zufallsvektoren

$$\mathbb{P}(\xi = x) = \mathbb{P}(x \leq \xi \leq x) = \int_{x_1}^{x_1} \cdots \int_{x_n}^{x_n} p(s_1, ..., s_n)\, ds_1 \cdots ds_n = 0. \tag{22.12}$$

Das Standardbeispiel für eine multivariate WDF ist die *multivariate Normalverteilung*, die wir in Kapitel 29 ausführlich diskutieren.

22.2. Marginalverteilungen

Hat man die Verteilung eines Zufallsvektors spezifiziert, so kann man sich fragen, welche Verteilungen daraus für die einzelnen Komponenten des Zufallsvektors, also die Zufallsvariablen, die zusammen den Zufallsvektor bilden, folgen. Im Kontext eines Zufallsvektors nennt man diese die *univariaten Marginalverteilungen* des Zufallsvektors. Folgende Definition ist grundlegend.

Definition 22.6 (Univariate Marginalverteilung)**.** $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum, $(\mathcal{X}, \mathcal{S})$ sei ein n-dimensionaler Messraum, $\xi : \Omega \to \mathcal{X}$ sei ein Zufallsvektor, $\mathbb{P}$ sei die Verteilung von ξ, $\mathcal{X}_i \subset \mathcal{X}$ sei der Ergebnisraum der $i$ten Komponente ξ_i von ξ, und $\mathcal{S}_i$ sei eine σ-Algebra auf ξ_i. Dann heißt die durch

$$\mathbb{P}_{\xi_i} : \mathcal{S}_i \to [0, 1], S \mapsto \mathbb{P}\left(\mathcal{X}_1 \times \cdots \times \mathcal{X}_{i-1} \times S \times \mathcal{X}_{i+1} \times \cdots \times \mathcal{X}_n\right) \text{ für } S \in \mathcal{S}_i \tag{22.13}$$

definierte Verteilung die *ite univariate Marginalverteilung von* ξ.

•

Konkret kann man sowohl für diskrete als auch für kontinuierliche Zufallsvektoren die WMFen bzw. WDFen ihrer Komponenten direkt aus der entsprechenden multivariaten WMF bzw. WDF bestimmen. Dies ist die Aussage folgenden Theorems.

Theorem 22.1 (Marginale Wahrscheinlichkeitsmasse- und Wahrscheinlichkeitsdichtefunktionen)**.** *(1)* $\xi = (\xi_1, ..., \xi_n)$ *sei ein* n*-dimensionaler diskreter Zufallsvektor mit WMF* p *und Komponentenergebnisräumen* $\mathcal{X}_1, ..., \mathcal{X}_n$*. Dann ergibt sich die WMF der* i*ten Komponente* ξ_i *von* ξ *als*

$$p : \mathcal{X}_i \to [0, 1], x_i \mapsto p(x_i) := \sum_{x_1} \cdots \sum_{x_{i-1}} \sum_{x_{i+1}} \cdots \sum_{x_n} p(x_1, ..., x_{i-1}, x_i, x_{i+1}, ..., x_n). \tag{22.14}$$

(2) $\xi = (\xi_1, ..., \xi_n)$ sei ein n-dimensionaler kontinuierlicher Zufallsvektor mit WDF p und Komponentenergebnisraum $\mathbb{R}$. Dann ergibt sich die WDF der iten Komponente ξ_i von ξ als

$$p : \mathbb{R} \to \mathbb{R}_{\geq 0}, x_i \mapsto p(x_i) := \int_{x_1} \cdots \int_{x_{i-1}} \int_{x_{i+1}} \cdots \int_{x_n} p(x_1, ..., x_{i-1}, x_i, x_{i+1}, ..., x_n)\, dx_1 \ldots dx_{i-1}\, dx_{i+1} \ldots dx_n. \tag{22.15}$$

∘

Die WMFen der univariaten Marginalverteilungen diskreter Zufallsvektoren ergeben sich also durch Summation über alle Werte der zu der jeweils betrachteten Zufallsvariable komplementären Zufallsvariablen und die WDFen der univariaten Marginalverteilungen kontinuierlicher Zufallsvektoren ergeben sich analog durch Integration über alle Werte der zu der jeweils betrachteten Zufallsvariable komplementären Zufallsvariablen. Für einen Beweis von Theorem 22.1 verweisen wir auf die weiterführende Literatur.

Beispiel 22.2 (Marginale Wahrscheinlichkeitsmassefunktionen)**.** In Fortführung von Beispiel 22.1 ergeben sich für die dort definierte WMF des Zufallsvektors $\xi := (\xi_1, \xi_2)$ für die marginalen WMFen die an den Rändern der von Tabelle 22.3 aufgelisteten WMFen anhand von

$$p(x_1) = \sum_{x_2=1}^{4} p(x_1, x_2) \text{ und } p(x_2) = \sum_{x_1=1}^{3} p(x_1, x_2). \tag{22.16}$$

Tabelle 22.3. Bivariate WMF $p(x_1, x_2)$ mit marginalen WMFen

$p(x_1, x_2)$	$x_2 = 1$	$x_2 = 2$	$x_2 = 3$	$x_2 = 4$	$p(x_1)$
$x_1 = 1$	0.1	0.0	0.2	0.1	0.4
$x_1 = 2$	0.1	0.2	0.0	0.0	0.3
$x_1 = 3$	0.0	0.1	0.1	0.1	0.3
$p(x_2)$	0.2	0.3	0.3	0.2	

Für die Werte $p(x_1)$ werden die entsprechenden Werte von $p(x_1, x_2)$ also zeilenweise und für die Werte von $p(x_2)$ spaltenweise addiert. Man beachte, dass aus der Normiertheit von $p(x_1, x_2)$ die Normiertheit von $p(x_1)$ und $p(x_2)$ direkt folgt, da sich die Gesamtsumme an Wahrscheinlichkeitsmasse nicht ändert:

$$1 = \sum_{x_1=1}^{3} \sum_{x_2=1}^{4} p(x_1, x_2) = \sum_{x_1=1}^{3} p(x_1) = \sum_{x_2=1}^{4} p(x_2). \tag{22.17}$$

Ein Realisierungsbeispiel mithilfe relativer Häufigkeiten mag den Begriff der marginalen WMF intuitiv verdeutlichen. Nehmen wir an, wir hätten $n = 100$ unabhängige Realisierungen von ξ vorliegen. Um die Wahrscheinlichkeiten $p(x_1, x_2)$ zu schätzen, würden wir die Anzahl der Realisierungen von (x_1, x_2) zählen und durch n teilen. Hätten wir beispielsweise 12 Realisierungen von $(3, 2)$ vorliegen, so würden wir $p(3, 2) \approx 12/100 = 0.12$ schätzen. Die Frage nach der marginalen Wahrscheinlichkeit von $x_2 = 2$ entspräche dann der Frage, wie oft unter den Realisierungen solche zu finden sind, bei denen $x_2 = 2$ ist, irrespektive des Wertes von x_1. Dies wäre gerade die Anzahl der Realisierungen der Form $(1, 2), (2, 2)$ und $(3, 2)$. Gäbe es von diesen beispielsweise $0, 22$ und 12 respektive, so würde man die Wahrscheinlichkeit $p(2)$ natürlicherweise durch

$$\frac{0 + 22 + 12}{100} = \frac{0}{100} + \frac{22}{100} + \frac{12}{100} = 0.00 + 0.22 + 0.12 = 0.34 \tag{22.18}$$

schätzen. Anstelle der Wahrscheinlichkeiten $p(1,2)$, $p(2,2)$, $p(3,2)$ addiert man hier also die entsprechenden relativen Häufigkeiten.

△

Marginale Verteilungen im Fall von kontinuierlichen Zufallsvektoren behandeln wir am Standardbeispiel der multivariaten Normalverteilung in Kapitel 29.

22.3. Bedingte Verteilungen

Hat man die Verteilung eines Zufallsvektors spezifiziert, so kann man sich fragen, welche Verteilung daraus für eine einzelne Komponente des Zufallsvektors folgt, wenn man den Wert einer anderen Komponente als bekannt annimmt. Dies führt auf den Begriff der *bedingten Verteilung*, welcher sich natürlicherweise aus dem Begriff der bedingten Wahrscheinlichkeit (vgl. Kapitel 20.2) ergibt. Wir erinnern uns zunächst, dass für einen Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$ und zwei Ereignisse $A, B \in \mathcal{A}$ mit $\mathbb{P}(B) > 0$ die bedingte Wahrscheinlichkeit von A gegeben B definiert ist als

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}. \tag{22.19}$$

Analog wird für zwei Zufallsvariablen ξ_1, ξ_2 mit Ereignisräumen $\mathcal{X}_1, \mathcal{X}_2$ und (messbaren) Mengen $S_1 \in \mathcal{X}_1, S_2 \in \mathcal{X}_2$ die bedingte Verteilung von ξ_1 gegeben ξ_2 mithilfe der Ereignisse

$$A := \{\xi_1 \in S_1\} \text{ und } B := \{\xi_2 \in S_2\} \tag{22.20}$$

definiert. So ergibt sich zum Beispiel die bedingte Wahrscheinlichkeit, dass $\xi_1 \in S_1$ gegeben, dass $\xi_2 \in S_2$ und unter der Annahme, dass $\mathbb{P}(\{\xi_2 \in S_2\}) > 0$, zu

$$\mathbb{P}(\{\xi_1 \in S_1\}|\{\xi_2 \in S_2\}) = \frac{\mathbb{P}(\{\xi_1 \in S_1\} \cap \{\xi_2 \in S_2\})}{\mathbb{P}(\{\xi_2 \in S_2\})}. \tag{22.21}$$

Wir betrachten zunächst die Definition der bedingten Verteilungen von diskreten Zufallsvektoren, die lediglich aus zwei Zufallsvariablen bestehen.

Definition 22.7 (Bedingte Wahrscheinlichkeitsmassefunktion und diskrete bedingte Verteilung)**.** $\xi := (\xi_1, \xi_2)$ sei ein diskreter Zufallsvektor mit Ergebnisraum $\mathcal{X} := \mathcal{X}_1 \times \mathcal{X}_2$, WMF $p(x_1, x_2)$ und marginalen WMFen $p(x_1)$ und $p(x_2)$. Die bedingte WMF von ξ_1 gegeben $\xi_2 = x_2$ ist dann für $p(x_2) > 0$ definiert als

$$p : \mathcal{X}_1 \to [0,1], x_1 \mapsto p(x_1|x_2) := \frac{p(x_1, x_2)}{p(x_2)} \tag{22.22}$$

Analog ist für $p(x_1) > 0$ die bedingte WMF von ξ_2 gegeben $\xi_1 = x_1$ definiert als

$$p : \mathcal{X}_2 \to [0,1], x_2 \mapsto p(x_2|x_1) := \frac{p(x_1, x_2)}{p(x_1)} \tag{22.23}$$

Die bedingten Verteilungen mit WMFen $p(x_1|x_2)$ und $p(x_2|x_1)$ heißen dann die *diskreten bedingten Verteilungen von* ξ_1 *gegeben* $\xi_2 = x_2$ *bzw.* ξ_2 *gegeben* $\xi_1 = x_1$.

•

In Analogie zur Definition der bedingten Wahrscheinlichkeit von Ereignissen gilt also

$$p(x_1|x_2) = \frac{p(x_1, x_2)}{p(x_2)} = \frac{\mathbb{P}(\{\xi_1 = x_1\} \cap \{\xi_2 = x_2\})}{\mathbb{P}(\{\xi_2 = x_2\})}. \tag{22.24}$$

Es ist dabei entscheidend zu erkennen, dass bedingte Verteilungen lediglich normalisierte gemeinsame Verteilungen sind.

Beispiel 22.3 (Bedingte Wahrscheinlichkeitsmassefunktionen)**.** In Fortführung des in Beispiel 22.1 betrachteten Beispiels eines zweidimensionalen Zufallsvektors $\xi := (\xi_1, \xi_2)$ und seiner in Beispiel 22.2 bestimmten Marginalverteilungen ergeben sich die in Tabelle 22.4 dargestellten bedingte WMFen für $p(x_1|x_2)$ und die in Tabelle 22.5 dargestellten bedingte WMFen für $p(x_2|x_1)$.

Tabelle 22.4. Bedingte WMFen $p(x_1|x_2)$

$p(x_1\|x_2)$	$x_2 = 1$	$x_2 = 2$	$x_2 = 3$	$x_2 = 4$
$p(1\|x_2)$	$\frac{0.1}{0.2} = 0.5$	$\frac{0.0}{0.3} = 0.0$	$\frac{0.2}{0.3} = 0.6\bar{6}$	$\frac{0.1}{0.2} = 0.5$
$p(2\|x_2)$	$\frac{0.1}{0.2} = 0.5$	$\frac{0.2}{0.3} = 0.6\bar{6}$	$\frac{0.0}{0.3} = 0.0$	$\frac{0.0}{0.2} = 0.0$
$p(3\|x_2)$	$\frac{0.0}{0.2} = 0.0$	$\frac{0.1}{0.3} = 0.3\bar{3}$	$\frac{0.1}{0.3} = 0.3\bar{3}$	$\frac{0.1}{0.2} = 0.5$

Tabelle 22.5. Bedingte WMFen $p(x_2|x_1)$

$p(x_2\|x_1)$	$p(1\|x_1)$	$p(2\|x_1)$	$p(3\|x_1)$	$p(4\|x_1)$
$x_1 = 1$	$\frac{0.1}{0.4} = 0.25$	$\frac{0.0}{0.4} = 0.00$	$\frac{0.2}{0.4} = 0.50$	$\frac{0.1}{0.4} = 0.25$
$x_1 = 2$	$\frac{0.1}{0.3} = 0.3\bar{3}$	$\frac{0.2}{0.3} = 0.6\bar{6}$	$\frac{0.0}{0.3} = 0.00$	$\frac{0.0}{0.3} = 0.00$
$x_1 = 3$	$\frac{0.0}{0.3} = 0.00$	$\frac{0.1}{0.3} = 0.3\bar{3}$	$\frac{0.1}{0.3} = 0.3\bar{3}$	$\frac{0.1}{0.3} = 0.3\bar{3}$

Man beachte, dass zum einen gilt, dass

$$\sum_{x_1=1}^{3} p(x_1|x_2) = 1 \text{ für alle } x_2 \in \mathcal{X}_2 \text{ und } \sum_{x_2=1}^{4} p(x_2|x_1) = 1 \text{ für alle } x_1 \in \mathcal{X}_1, \tag{22.25}$$

die bedingten WMFen sind also normiert. Zum anderen beachte man die qualitative Ähnlichkeit der WMFen $p(x_1, x_2)$ und $p(x_1|x_2)$ bzw. $p(x_2|x_1)$, die sich einfach daraus ergibt, dass einerseits $p(x_1, x_2)$ und $p(x_1|x_2)$ für alle $x_2 \in \mathcal{X}_2$ bis auf den gemeinsamen Skalierungsfaktor $1/p(x_2)$ und andererseits $p(x_1, x_2)$ und $p(x_2|x_1)$ für alle $x_1 \in \mathcal{X}_1$ bis auf den gemeinsamen Skalierungsfaktor $1/p(x_1)$ identisch sind.

△

Im Fall eines kontinuierlichen Zufallsvektors sind die analogen bedingten WDFen definiert wie folgt.

Definition 22.8 (Bedingte Wahrscheinlichkeitsdichtefunktion und kontinuierliche bedingte Verteilung)**.** $\xi := (\xi_1, \xi_2)$ sei ein kontinuierlicher Zufallsvektor mit Ergebnisraum $\mathbb{R}^2$, WDF $p(x_1, x_2)$ und marginalen WDFen $p(x_1)$ und $p(x_2)$. Die bedingte WDF von ξ_1 gegeben $\xi_2 = x_2$ ist dann für $p(x_2) > 0$ definiert als

$$p : \mathbb{R} \to \mathbb{R}_{\geq 0}, x_1 \mapsto p(x_1|x_2) := \frac{p(x_1, x_2)}{p(x_2)} \tag{22.26}$$

Analog ist für $p(x_1) > 0$ die bedingte WMF von ξ_2 gegeben $\xi_1 = x_1$ definiert als

$$p : \mathbb{R} \to \mathbb{R}_{\geq 0}, x_2 \mapsto p(x_2|x_1) := \frac{p(x_1, x_2)}{p(x_1)} \tag{22.27}$$

Die Verteilungen mit WDFen p und p heißen danndie *kontinuierlichen bedingten Verteilungen von* ξ_1 *gegeben* $\xi_2 = x_2$ *und* ξ_2 *gegeben* $\xi_1 = x_1$, respektive.

•

Man beachte, dass im kontinuierlichen Fall zwar $\mathbb{P}(\xi = x) = 0$, aber nicht notwendig auch $p(x) = 0$ gilt. Die bedingten Verteilungen multivariater Normalverteilungen diskutieren wir in einem eigenen Kapitel.

22.4. Unabhängige Zufallsvariablen

Ähnlich wie die bedingten Wahrscheinlichkeiten von Ereignissen lässt sich auch das Konzept der unabhängigen Ereignisse auf Zufallsvektoren übertragen. Wir definieren zunächst den Begriff der unabhängigen Zufallsvariablen.

Definition 22.9 (Unabhängige Zufallsvariablen)**.** $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und $\xi := (\xi_1, \xi_2)$ ein zweidimensionaler Zufallsvektor. Die Zufallsvariablen ξ_1, ξ_2 mit Ergebnisräumen $\mathcal{X}_1, \mathcal{X}_2$ heißen *unabhängig*, wenn für alle $S_1 \subseteq \mathcal{X}_1$ und $S_2 \subseteq \mathcal{X}_2$ gilt, dass

$$\mathbb{P}(\xi_1 \in S_1, \xi_2 \in S_2) = \mathbb{P}(\xi_1 \in S_1)\mathbb{P}(\xi_2 \in S_2). \tag{22.28}$$

•

Definition 22.9 besagt, dass die Ereignisse $\{\xi_1 \in S_1\}$ und $\{\xi_2 \in S_2\}$ unabhängig sind. Es gilt also auch, dass

$$\mathbb{P}(\{\xi_1 \in S_1\})|\{\xi_2 \in S_2\}) = \mathbb{P}(\{\xi_1 \in S_1\}) \tag{22.29}$$

und das Wissen um das Eintreten des Ereignisses $\{\xi_2 \in S_2\}$ verändert die Wahrscheinlichkeit des Ereignisses $\{\xi_1 \in S_1\}$ nicht. Das Faktorisierungsprinzip zur Modellierung probabilistischer Unabhängigkeit überträgt sich auf WMFen und WDFen von Zufallsvektoren. Dies ist die Aussage folgenden Theorems.

Theorem 22.2 (Unabhängigkeit und Faktorisierung)**.**

(1) $\xi := (\xi_1, \xi_2)$ *sei ein diskreter Zufallsvektor mit Ergebnisraum* $\mathcal{X}_1 \times \mathcal{X}_2$*, WMF* $p(x_1, x_2)$ *und marginalen WMFen* $p(x_1), p(x_2)$*. Dann gilt*

$$\xi_1 \text{ und } \xi_2 \text{ sind unabhängige Zufallsvariablen} \Leftrightarrow$$
$$p(x_1, x_2) = p(x_1)p(x_2) \text{ für alle } (x_1, x_2) \in \mathcal{X}_1 \times \mathcal{X}_2. \tag{22.30}$$

(2) $\xi := (\xi_1, \xi_2)$ *sei ein kontinuierlicher Zufallsvektor mit Ergebnisraum* $\mathbb{R}^2$*, WDF* p *und marginalen WDFen* p, p*. Dann gilt*

$$\xi_1 \text{ und } \xi_2 \text{ sind unabhängige Zufallsvariablen } \Leftrightarrow$$
$$p(x_1, x_2) = p(x_1)p(x_2) \text{ für alle } (x_1, x_2) \in \mathbb{R}^2. \tag{22.31}$$

∘

Generell ist die Unabhängigkeit zweier Zufallsvariablen also äquivalent zur Faktorisierung ihrer gemeinsamen WMF oder WDF. Für einen Beweis von Theorem 22.2 verweisen wir auf die weiterführende Literatur. Theorem 22.2 ist für weite Aspekte der probabilistischen Modellierung grundlegend.

Beispiel 22.4 (Unabhängige Wahrscheinlichkeitsmassefunktionen)**.** Wir betrachten erneut den zweidimensionalen Zufallsvektor $\xi := (\xi_1, \xi_2)$ aus Beispiel 22.1, dessen gemeinsame und marginale WMFen die in Tabelle 22.3 spezifierten Formen haben. Wir fragen zunächst, ob ξ_1 und ξ_2 unabhängig sind. Dies ist nicht der Fall, da hier gilt, dass

$$p(1,1) = 0.10 \neq 0.08 = 0.40 \cdot 0.20 = p(1)p(1). \tag{22.32}$$

Möchten wir basierend auf den Marginalverteilungen von ξ eine gemeinsame Verteilung erzeugen, in der ξ_1 und ξ_2 unabhängig sind, so muss sich jeder Eintrag der gemeinsamen Verteilung $p(\xi_1, \xi_2)$ aus dem jeweiligen Produkt der Marginalwahrscheinlichkeiten ergeben. Die gemeinsame Verteilung von ξ_1 und ξ_2 unter dieser Annahme der Unabhängigkeit von ξ_1 und ξ_2 bei gleichen Marginalverteilungen wie in Tabelle 22.3 ergibt sich zu der in Tabelle 22.6 gemeinsamen WMF.

Tabelle 22.6. Bivariate WMF bei Annahme der Unabhängigkeit von ξ_1 und ξ_2

$p(x_1, x_2)$	$x_2 = 1$	$x_2 = 2$	$x_2 = 3$	$x_2 = 4$	$p(x_1)$
$x_1 = 1$	0.08	0.12	0.12	0.08	0.40
$x_1 = 2$	0.06	0.09	0.09	0.06	0.30
$x_1 = 3$	0.06	0.09	0.09	0.06	0.30
$p(x_2)$	0.20	0.30	0.30	0.20	

Weiterhin ergeben sich im Falle der Unabhängigkeit von ξ_1 und ξ_2 beispielsweise die bedingten WMFen $p(x_2|x_1)$ wie in Tabelle 22.7 dargestellt. Im Falle der Unabhängigkeit von ξ_1 und ξ_2 ändert sich die Verteilung von ξ_2 gegeben (oder im Wissen um) den Wert von ξ_1 also nicht und entspricht jeweils der Marginalverteilung von ξ_2. Dies entspricht natürlich der Intuition der Unabhängigkeit von Ereignissen im Kontext elementarer Wahrscheinlichkeiten.

Tabelle 22.7. Bedingte WMF bei Annahme der Unabhängigkeit von ξ_1 und ξ_2

$p(x_2\|x_1)$	$p(1\|x_1)$	$p(2\|x_1)$		$p(3\|x_1)$
$x_1 = 1$	$\frac{0.08}{0.40} = 0.2$	$\frac{0.12}{0.40} = 0.3$	$\frac{0.12}{0.40} = 0.3$	$\frac{0.08}{0.40} = 0.2$
$x_1 = 2$	$\frac{0.06}{0.30} = 0.2$	$\frac{0.09}{0.30} = 0.3$	$\frac{0.09}{0.30} = 0.3$	$\frac{0.06}{0.30} = 0.2$
$x_1 = 3$	$\frac{0.06}{0.30} = 0.2$	$\frac{0.09}{0.30} = 0.3$	$\frac{0.09}{0.30} = 0.3$	$\frac{0.06}{0.30} = 0.2$

△

Wir wollen abschließend den Begriff der unabhängigen Zufallsvariablen für mehr als zwei Zufallsvariablen definieren.

Definition 22.10 (n unabhängige Zufallsvariablen)**.** $\xi := (\xi_1, ..., \xi_n)$ sei ein n-dimensionaler Zufallsvektor mit Ergebnisraum $\mathcal{X} = \times_{i=1}^{n} \mathcal{X}_i$. Die n Zufallsvariablen $\xi_1, ..., \xi_n$ heißen *unabhängig*, wenn für alle $S_i \subseteq \mathcal{X}_i, i = 1, ..., n$ gilt, dass

$$\mathbb{P}(\xi_1 \in S_1, ..., \xi_n \in S_n) = \prod_{i=1}^{n} \mathbb{P}(\xi_i \in S_i). \tag{22.33}$$

Wenn der Zufallsvektor eine n-dimensionale WMF oder WDF p mit marginalen WMFen oder WDFen $p_{\xi_i}, i = 1, ..., n$ besitzt, dann ist die Unabhängigkeit von $\xi_1, ..., \xi_n$ gleichbedeutend mit der Faktorisierung der gemeinsamen WMF oder WDF, also mit

$$p(\xi_1, ..., \xi_n) = \prod_{i=1}^{n} p(x_i). \tag{22.34}$$

•

Es handelt bei Definition 22.10 also um eine direkte Generalisierung des zweidimensionalen Falls. Sind n Zufallsvariablen nicht nur unabhängig, sondern haben sie auch alle die gleiche Verteilung, so nennt man sie *unabhängig und identisch verteilt (u.i.v.)*.

Definition 22.11 (Unabhängig und identisch verteilte Zufallsvariablen)**.** n Zufallsvariablen $\xi_1, ..., \xi_n$ heißen *unabhängig und identisch verteilt (u.i.v.)*, wenn

(1) $\xi_1, ..., \xi_n$ unabhängige Zufallsvariablen sind, und
(2) die Marginalverteilungen der ξ_i übereinstimmen, also gilt, dass

$$\mathbb{P}(\xi_i) = \mathbb{P}(\xi_j) \text{ für alle } 1 \leq i, j \leq n. \tag{22.35}$$

Wenn die Zufallsvariablen $\xi_1, ..., \xi_n$ unabhängig und identisch verteilt sind und die $i$te Marginalverteilung $\mathbb{P}$ ist, so schreibt man auch

$$\xi_1, ..., \xi_n \sim \mathbb{P}. \tag{22.36}$$

•

Man sagt kurz, dass $\xi_1, ..., \xi_n$ *u.i.v.* sind. Im Englischen spricht man von *independent and identically distributed (i.i.d)* Zufallsvariablen. U.i.v. Zufallsvariablen spielen an vielen Stellen der probabilistischen Modellierung eine wichtige Rolle. So werden, wie wir an späterer Stelle sehen werden, additive Fehlerterme in probabilistischen Modellen meist durch u.i.v. Zufallsvariablen modelliert. Schließlich halten wir fest, dass n u.i.v. normalverteilte Zufallsvariablen als

$$\xi_1, ..., \xi_n \sim N(\mu, \sigma^2) \tag{22.37}$$

geschrieben werden. In Kapitel 29 zeigen wir, wie die gemeinsame Verteilung von n u.i.v. normalverteilten Zufallsvariablen im Sinne eines Zufallsvektors beschaffen ist.

Selbstkontrollfragen

1. Geben Sie die Definition des Begriffs des Zufallsvektors wieder.
2. Geben Sie die Definition des Begriffs der multivariaten Verteilung eines Zufallsvektors wieder.
3. Geben Sie die Definition des Begriffs der multivariaten WMF wieder.
4. Geben Sie die Definition des Begriffs der multivariaten WDF wieder.
5. Geben Sie die Definition des Begriffs der univariaten Marginalverteilung eines Zufallsvektors wieder
6. Wie berechnet man die WMF der $i$ten Komponente eines diskreten Zufallsvektors?
7. Wie berechnet man die WDF der $i$ten Komponente eines kontinuierlichen Zufallsvektors?
8. Geben Sie die Definition des Begriffs der Unabhängigkeit zweier Zufallsvariablen wieder.
9. Wie erkennt man an der gemeinsamen WMF oder WDF eines zweidimensionalen Zufallsvektors $\xi := (\xi_1, \xi_2)$, ob die Komponenten des Zufallsvektors unabhängig sind oder nicht?
10. Geben Sie die Definition des Begriffs der Unabhängigkeit von n Zufallsvariablen wieder.
11. Geben Sie die Definition des Begriffs der unabhängig und identisch verteilten Zufallsvariablen wieder.

Lösungen

1. Siehe Definition 22.1.
2. Siehe Definition 22.2
3. Siehe Definition 22.4.
4. Siehe Definition 22.5.
5. Siehe Definition 22.6.
6. Siehe Theorem 22.1. Man erhält die WMF der $i$ten Komponente eines diskreten Zufallsvektors durch Summation der Werte der WMF des Zufallsvektors über alle Komponenten des Zufallsvektors *außer* der $i$ten Komponente.
7. Siehe Theorem 22.1. Man erhält die WDF der $i$ten Komponente eines kontinuierlichen Zufallsvektors durch Integration der Werte der WDF des Zufallsvektors über alle Komponenten des Zufallsvektors *außer* der $i$ten Komponente.
8. Siehe Definition 22.9.
9. Man prüft, ob sich alle Werte der gemeinsamen WMF oder WDF $p(x_1, x_2)$ des Zufallsvektors durch Multiplikation der entsprechenden marginalen WMF oder WDF Werte $p(x_1)$ und $p(x_2)$ ergeben. Ist dies für alle $(x_1, x_2) \in \mathcal{X}_1 \times \mathcal{X}_2$ der Fall, so sind ξ_1 und ξ_2 unabhängig, ist dies nicht für alle $(x_1, x_2) \in \mathcal{X}_1 \times \mathcal{X}_2$, so sind ξ_1 und ξ_2 nicht unabhängig.
10. Siehe Definition 22.9.
11. Siehe Definition 22.11.

23. Erwartungswerte

In diesem Kapitel führen wir den Begriff des *Erwartungswerts* einer Zufallsvariable ein. Der Erwartungswert dient als eine einzige, skalare Kennzahl, die eine Wahrscheinlichkeitsverteilung zusammenfassend beschreibt und häufig als zentrale charakteristische Größe von Zufallsvariablen verwendet wird. Der Erwartungswert dient dabei als ein Maß der "durchschnittlichen Realisierung" einer Zufallsvariable und bildet die Grundlage für weitere Begriffsbildungen wie die der *Varianz* einer Zufallsvariable und die der *Kovarianz* zweier Zufallsvariablen im Folgenden. Wir ergänzen den Begriff des Erwartungswerts um seine Analoga in Bezug auf Zufallsvektoren und bedingte Verteilungen sowie um sein deskriptivstatistisches Äquivalent, das sogenannte *Stichprobenmittel*.

23.1. Definitionen

Definition 23.1 (Erwartungswert einer Zufallsvariable)**.** $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und ξ sei eine Zufallsvariable. Dann ist der *Erwartungswert von* ξ definiert als

- $\mathbb{E}(\xi) := \sum_{x \in \mathcal{X}} x\, p(x)$, wenn $\xi : \Omega \to \mathcal{X}$ diskret mit WMF p ist.
- $\mathbb{E}(\xi) := \int_{-\infty}^{\infty} x\, p(x)\, dx$, wenn $\xi : \Omega \to \mathbb{R}$ kontinuierlich mit WDF p ist.

•

Der Erwartungswert ist also eine skalare Zusammenfassung der Verteilung einer Zufallsvariable. Eine Definition des Erwartungswertes, die ohne eine Fallunterscheidung in kontinuierliche und diskrete Zufallsvariablen auskommt, ist möglich, erfordert aber mit der Einführung des Lebesgue-Integrals einigen technischen Aufwand. Wir verweisen dafür auf die weiterführende Literatur (vgl. Schmidt (2009), Meintrup & Schäffler (2005)). Es ist wichtig anzuerkennen, dass ein Erwartungswert alleine aufgrund der Festlegung des Ergebnisraums und der Verteilung einer Zufallsvariable mithilfe einer WMF oder WDF bestimmt wird. Nichtsdestotrotz entspricht der Erwartungswert einer Zufallsvariable dem im langfristigen Mittel durchschnittlich zu erwartenden Wert der Zufallsvariable. Dieser Umstand wird unter dem Begriff des *Gesetzes der großen Zahlen* (vgl. Kapitel 27.1) formalisiert. Wir betrachten zunächst drei Beispiele für Definition 23.1.

Beispiel 23.1 (Erwartungswert einer diskreten Zufallsvariable)**.** ξ sei eine Zufallsvariable mit Ergebnisraum $\mathcal{X} := \{-1, 0, 1\}$ und WMF

$$p(-1) := \frac{1}{4}, \quad p(0) := \frac{1}{2}, \quad p(1) := \frac{1}{4}. \tag{23.1}$$

Dann gilt

$$\mathbb{E}(\xi) = 0. \tag{23.2}$$

△

Beweis. Nach Definition 23.1 ergibt sich

$$\begin{aligned}\mathbb{E}(\xi) &= \sum_{x \in \mathcal{X}} xp(x) \\ &= -1 \cdot p(-1) + 0 \cdot p(0) + 1 \cdot p(1) \\ &= -1 \cdot \frac{1}{4} + 0 \cdot \frac{1}{2} + 1 \cdot \frac{1}{4} \\ &= 0.\end{aligned} \tag{23.3}$$

□

Beispiel 23.2 (Erwartungswert einer Bernoulli Zufallsvariable)**.** Es sei $\xi \sim \text{Bern}(\mu)$. Dann gilt $\mathbb{E}(\xi) = \mu$.

△

Beweis. ξ ist diskret mit $\mathcal{X} = \{0, 1\}$. Also gilt nach Definition 23.1

$$\begin{aligned}&= \sum_{x \in \{0,1\}} x \, \text{Bern}(x; \mu) \\ &= 0 \cdot \mu^0 (1-\mu)^{1-0} + 1 \cdot \mu^1 (1-\mu)^{1-1} \\ &= 1 \cdot \mu^1 (1-\mu)^0 \\ &= \mu.\end{aligned} \tag{23.4}$$

□

Beispiel 23.3 (Erwartungswert einer normalverteilten Zufallsvariable)**.** Es sei $\xi \sim N(\mu, \sigma^2)$. Dann gilt $\mathbb{E}(\xi) = \mu$.

△

Beweis. Wir verzichten auf einen Beweis. □

Intuitiv mag man sich Definition 23.1 wie in Beispiel 23.4 dargestellt erklären.

Beispiel 23.4 (Erwartungswert und Mittelwert)**.** Wir betrachten eine diskrete Zufallsvariable ξ mit Ergebnisraum $\{1, 2, 3\}$ und WMF definiert durch

$$p(1) := \frac{1}{4}, \quad p(2) := \frac{1}{4}, \quad p(3) := \frac{1}{2}. \tag{23.5}$$

Es gilt also

$$\begin{aligned}\mathbb{E}(\xi) &= \sum_{x \in \{1,2,3\}} xp(x) \\ &= 1 \cdot p(1) + 2 \cdot p(2) + 3 \cdot p(3) \\ &= 1 \cdot \frac{1}{4} + 2 \cdot \frac{1}{4} + 3 \cdot \frac{1}{2} \\ &= \frac{9}{4}.\end{aligned} \tag{23.6}$$

Stellen wir uns nun $n = 100$ unabhängige Realisierungen $x_1, ..., x_{100}$ der Zufallsvariable vor. Gemäß ihrer WMF würden wir in etwa 25 Einsen, 25 Zweien und 50 Dreien erwarten. Nehmen wir konkret

an, wir hätten 27 Einsen, 22 Zweien und 51 Dreien vorliegen. Der Mittelwert dieser Zahlen ergibt sich dann zu (vgl. Kapitel 3)

$$\begin{aligned}\bar{x} &= \frac{1}{100}\sum_{i=1}^{n} x_i \\ &= \frac{1}{100}\left(27 \cdot 1 + 22 \cdot 2 + 51 \cdot 3\right) \\ &= \frac{1}{100}\left(1 \cdot 27 + 2 \cdot 22 + 3 \cdot 51\right) \\ &= 1 \cdot \frac{27}{100} + 2 \cdot \frac{22}{100} + 3 \cdot \frac{51}{100} \\ &= 1 \cdot 0.27 + 2 \cdot 0.22 + 3 \cdot 0.51 \\ &= 2.24.\end{aligned} \tag{23.7}$$

Versteht man in dieser Rechnung die Faktoren $0.27 \approx \frac{1}{4}$, $0.22 \approx \frac{1}{4}$ und $0.51 \approx \frac{1}{2}$ als Schätzungen $\hat{p}(1)$, $\hat{p}(2)$ und $\hat{p}(3)$ für die WMF Werte $p(1)$, $p(2)$ und $p(3)$, so fällt mit

$$\bar{x} = \sum_{x \in \{1,2,3\}} x\hat{p}(x) \approx \sum_{x \in \{1,2,3\}} xp(x) = \mathbb{E}(\xi) \tag{23.8}$$

die formale Ähnlichkeit der Bildung eines Mittelwerts von Realisierungen einer diskreten Zufallsvariablen und zwischen der Definition des Erwartungswerts einer eben solchen direkt ins Auge.

△

In Abgrenzung zu Definition 23.1 definieren wir aufbauend auf Beispiel 23.4 das sogenannte *Stichprobenmittel*.

Definition 23.2 (Stichprobenmittel)**.** $\xi_1, ..., \xi_n$ seien Zufallsvariablen. Dann nennt man $\xi_1, ..., \xi_n$ auch eine *Stichprobe*. Das *Stichprobenmittel* von $\xi_1, ..., \xi_n$ ist definiert als der arithmetische Mittelwert

$$\bar{\xi} := \frac{1}{n}\sum_{i=1}^{n} \xi_i. \tag{23.9}$$

•

Es ist zentral zu erkennen, dass $\mathbb{E}(\xi)$ eine feste Kennzahl einer Zufallsvariable ξ ist und insbesondere selbst keine Zufallsvariable ist. $\bar{\xi}$ hingegen ist eine Kennzahl einer Stichprobe $\xi_1, ..., \xi_n$ und als Funktion von Zufallsvariablen damit selbst eine Zufallsvariable. In Beispiel 23.4 modelliert man beispielsweise jede Realisierung x_i für $i = 1, ..., n$ als eine Realisierung der Zufallsvariable $\xi_i := \xi$ für $i = 1, ..., n$. Da $\bar{\xi}$ eine skalierte Summe von Zufallsvariablen ist, ist $\bar{\xi}$ auch selbst eine Zufallsvariable. Realisierungen der Zufallsvariable $\bar{\xi}$ bezeichnen wir wie im Folgenden mit $\bar{x}$.

Beispiel 23.5 (Stichprobenmittel)**.** Als Beispiel für die Realisation eines Stichprobenmittels betrachten wir die in Tabelle 23.1 gezeigten Realisationen der Zufallsvariablen $\xi_1, ..., \xi_{10} \sim N(1, 2)$.

Tabelle 23.1. Stichprobenrealisation

x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}
0.54	1.01	-3.28	0.35	2.75	-0.51	2.32	1.49	0.96	1.25

Die Stichprobenmittelrealisation ist

$$\bar{x} = \frac{1}{10}\sum_{i=1}^{10} x_i = \frac{6.88}{10} = 0.68. \tag{23.10}$$

△

In Verallgemeinerung von Definition 23.1 gilt folgende Definition für den Erwartungswert einer Funktion einer Zufallsvariable.

Definition 23.3 (Erwartungswert einer Funktion einer Zufallsvariable)**.** $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum, ξ sei eine Zufallsvariable mit Ergebnisraum $\mathcal{X}$ und $f : \mathcal{X} \to \mathcal{Z}$ sei eine Funktion mit Zielmenge $\mathcal{Z}$. Dann ist der *Erwartungswert der Funktion f der Zufallsvariable ξ* definiert als

- $\mathbb{E}(f(\xi)) := \sum_{x\in\mathcal{X}} f(x)\, p(x)$, wenn $\xi : \Omega \to \mathcal{X}$ diskret mit WMF p ist,
- $\mathbb{E}(f(\xi)) := \int_{-\infty}^{\infty} f(x)\, p(x)\, dx$, wenn $\xi : \Omega \to \mathbb{R}$ kontinuierlich mit WDF p ist.

•

Der Erwartungswert einer Zufallsvariable ergibt sich anhand von Definition 23.3 als der Spezialfall, in dem gilt, dass

$$f : \mathcal{X} \to \mathcal{Z}, x \mapsto f(x) := x. \tag{23.11}$$

In der englischsprachigen Literatur ist Definition 23.3 auch als "Law of the unconscious statistician" bekannt und wird oft auch direkt zur Definition des Erwartungswertes herangezogen. Folgendes Theorem gibt ein erstes Beispiel für den Erwartungswert einer Funktion einer Zufallsvariable.

Theorem 23.1 (Erwartungswert bei linear-affiner Transformation einer Zufallsvariable)**.** *ξ sei eine Zufallsvariable mit Ergebnisraum $\mathcal{X}$ und es sei*

$$f : \mathcal{X} \to \mathcal{Z}, x \mapsto f(x) := ax + b \text{ für } a, b \in \mathbb{R} \tag{23.12}$$

eine linear-affine Funktion. Dann gilt

$$\mathbb{E}(f(\xi)) = \mathbb{E}(a\xi + b) = a\mathbb{E}(\xi) + b. \tag{23.13}$$

∘

Beweis. Die Aussage des Theorems folgt mit den Linearitätseigenschaften von Summen und Integralen. Wir betrachten den Fall einer diskreten Zufallsvariable ξ mit endlichem Ergebnisraum $\mathcal{X}$ und WMF p. Es gilt

$$\begin{aligned}
\mathbb{E}(f(\xi)) &= \mathbb{E}(a\xi + b) \\
&= \sum_{x\in\mathcal{X}} (ax + b)p(x) \\
&= \sum_{x\in\mathcal{X}} axp(x) + bp(x) \\
&= a\sum_{x\in\mathcal{X}} xp(x) + b\sum_{x\in\mathcal{X}} p(x) \\
&= a\mathbb{E}(\xi) + b.
\end{aligned} \tag{23.14}$$

□

Betrachtet man anstelle einer Zufallsvariable einen Zufallsvektor, so erweitert sich die Definition des Erwartungswerts wie folgt.

Definition 23.4 (Erwartungswert eines Zufallsvektors)**.** ξ sei ein n-dimensionaler Zufallsvektor. Dann ist der *Erwartungswert von* ξ definiert als der n-dimensionale reelle Vektor

$$\mathbb{E}(\xi) := \begin{pmatrix} \mathbb{E}(\xi_1) \\ \vdots \\ \mathbb{E}(\xi_n) \end{pmatrix}. \tag{23.15}$$

•

Der Erwartungswert eines Zufallsvektors ist also der Vektor der Erwartungswerte seiner Komponenten. Die Berechnung eines Erwartungswerts eines Zufallsvektors ist damit auf die Bestimmung der Erwartungswerte der den Zufallsvektor konstituierenden Zufallsvektoren bezüglich ihrer marginalen Verteilungen zurückgeführt. In Analogie zu Definition 23.3 definiert man für die Funktion eines Zufallsvektors den Erwartungswert dieser Transformation wie folgt.

Definition 23.5 (Erwartungswert einer Funktion eines Zufallsvektors)**.** $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum, ξ sei ein Zufallsvektor mit Ergebnisraum $\mathcal{X}$ und $f : \mathcal{X} \to \mathcal{Z}$ sei eine Funktion mit Zielmenge $\mathcal{Z}$. Dann ist der *Erwartungswert der Funktion* f *des Zufallsvektors* ξ definiert als

- $\mathbb{E}(f(\xi)) := \sum_{x \in \mathcal{X}} f(x)\, p(x)$, wenn $\xi : \Omega \to \mathcal{X}$ diskret mit WMF p ist,
- $\mathbb{E}(f(\xi)) := \int_{-\infty}^{\infty} f(x)\, p(x)\, dx$, wenn $\xi : \Omega \to \mathbb{R}$ kontinuierlich mit WDF p ist.

•

23.2. Eigenschaften

Folgende Aussagen sind insbesondere beim Rechnen mit Stichproben relevant.

Theorem 23.2 (Erwartungswert bei linear-affiner Kombination von Zufallsvariablen)**.** *ξ sei ein n-dimensionaler Zufallsvektor mit Komponenten $\xi_1, ..., \xi_n$ und Ergebnisraum $\mathcal{X} := \mathcal{X}_1 \times \cdots \times \mathcal{X}_n$. Die Komponenten besitzen endliche erste absolute Momente, also $\mathbb{E}(|\xi_i|) < \infty$ für $i = 1, ..., n$. Weiterhin sei*

$$f : \mathcal{X} \to \mathcal{Z}, x \mapsto f(x) := a_0 + \sum_{i=1}^{n} a_i x_i \text{ für } a_0, ..., a_n \in \mathbb{R}. \tag{23.16}$$

eine linear-affine Kombination der Komponenten von ξ. Dann gilt

$$\mathbb{E}(f(\xi)) = \mathbb{E}\left(a_0 + \sum_{i=1}^{n} a_i \xi_i\right) = a_0 + \sum_{i=1}^{n} a_i \mathbb{E}(\xi_i). \tag{23.17}$$

◦

Beweis. Wie unten gezeigt, folgt das Theorem aus der Linearität von Summen und Integralen sowie dem Satz von Fubini zur Vertauschung der Summations- bzw. Integrationsreihenfolge. Wir beschränken uns auf den diskreten Fall, wobei wir zur Vereinfachung der Notation $\sum_{x_i \in \mathcal{X}_i}$ als $\sum_{x_i}$ schreiben. Es gilt dann

$$
\begin{aligned}
\mathbb{E}(f(\xi)) &= \mathbb{E}\left(a_0 + \sum_{i=1}^{n} a_i \xi_i\right) \\
&= \mathbb{E}(a_0 + a_1\xi_1 + \cdots + a_n\xi_n) \\
&= \sum_{x_1} \cdots \sum_{x_n} (a_0 + a_1 x_1 + \cdots + a_n x_n) p(x_1, ..., x_n) \\
&= \sum_{x_1} \cdots \sum_{x_n} (a_0 p(x_1, ..., x_n) + a_1 x_1 p(x_1, ..., x_n) + \cdots + a_n x_n p(x_1, ..., x_n)) \\
&= \sum_{x_1} \cdots \sum_{x_n} a_0 p(x_1, ..., x_n) + \sum_{x_1} \cdots \sum_{x_n} a_1 x_1 p(x_1, ..., x_n) + \cdots + \sum_{x_1} \cdots \sum_{x_n} a_n x_n p(x_1, ..., x_n) \\
&= a_0 \sum_{x_1} \cdots \sum_{x_n} p(x_1, ..., x_n) + a_1 \sum_{x_1} \cdots \sum_{x_n} x_1 p(x_1, ..., x_n) + \cdots + a_n \sum_{x_n} \cdots \sum_{x_1} x_n p(x_1, ..., x_n) \\
&= a_0 + a_1 \sum_{x_1} x_1 \sum_{x_2} \cdots \sum_{x_n} p(x_1, ..., x_n) + \cdots + a_n \sum_{x_n} x_n \sum_{x_{n-1}} \cdots \sum_{x_1} p(x_1, ..., x_n) \\
&= a_0 + a_1 \sum_{x_1} x_1 p(x_1) + \cdots + a_n \sum_{x_n} x_n p(x_n) \\
&= a_0 + a_1 \mathbb{E}(\xi_1) + \cdots + a_n \mathbb{E}(\xi_n) \\
&= a_0 + \sum_{i=1}^{n} a_i \mathbb{E}(\xi_i)
\end{aligned}
\tag{23.18}
$$

Analog folgt das Resultat für einen kontinuierlichen Zufallsvektor. □

Theorem 23.3 (Erwartungswert des Produkts unabhängiger Zufallsvariablen)**.** *ξ sei ein n-dimensionaler Zufallsvektor mit unabhängigen Komponenten $\xi_1, ..., \xi_n$ und Ergebnisraum $\mathcal{X} := \mathcal{X}_1 \times \cdots \times \mathcal{X}_n$. Weiterhin sei*

$$
f : \mathcal{X} \to \mathcal{Z}, x \mapsto f(x) := \prod_{i=1}^{n} x_i. \tag{23.19}
$$

das Produkt der Komponenten von ξ. Dann gilt

$$
\mathbb{E}(f(\xi)) = \prod_{i=1}^{n} \mathbb{E}(\xi_i). \tag{23.20}
$$

∘

Beweis. Wie unten gezeigt, folgt das Theorem mit den Linearitätseigenschaften von Summen und Integralen, sowie Fubini's Theorem zur Vertauschung von Summations- bzw. Integrationsreihenfolge. Wir beschränken uns auf den diskreten Fall, wobei wir zur Vereinfachung der Notation $\sum_{x_i \in \mathcal{X}_i}$ als $\sum_{x_i}$ schreiben. Weil die Komponenten von $\xi_1, ..., \xi_n$ als unabhängig vorausgesetzt sind, gilt zunächst für die WMF des Zufallsvektors

$$
p(x_1, ..., x_n) = \prod_{i=1}^{n} p(x_i). \tag{23.21}
$$

Weiterhin gilt also

$$\begin{aligned}
\mathbb{E}\left(\prod_{i=1}^{n} \xi_i\right) &= \sum_{x_1} \cdots \sum_{x_n} \left(\prod_{i=1}^{n} x_i\right) p(x_1, \ldots, x_n) \\
&= \sum_{x_1} \cdots \sum_{x_n} \prod_{i=1}^{n} x_i \prod_{i=1}^{n} p(x_i) \\
&= \sum_{x_1} \cdots \sum_{x_n} \prod_{i=1}^{n} x_i p(x_i) \\
&= \prod_{i=1}^{n} \sum_{x_i} x_i p(x_i) \\
&= \prod_{i=1}^{n} \mathbb{E}(\xi_i).
\end{aligned} \tag{23.22}$$

□

23.3. Bedingter Erwartungswert

Betrachtet man bei der Bildung eines Erwartungswertes nun anstelle der Verteilung einer Zufallsvariable die bedingte Verteilung einer Zufallsvariable, so ist man entsprechend auf den Begriff des bedingten Erwartungswerts geführt.

Definition 23.6 (Bedingter Erwartungswert)**.** Gegeben sei ein Zufallsvektor $\xi := (\xi_1, \xi_2)$ mit Ergebnisraum $\mathcal{X} := \mathcal{X}_1 \times \mathcal{X}_2$, WMF oder WDF $p(x_1, x_2)$. Für einen Wert $x_2 \in \mathcal{X}_2$ mit positiver marginaler WMF bzw. positiver marginaler WDF sei $p(x_1|x_2)$ die bedingte WMF bzw. WDF. Es gelte $\sum_{x_1 \in \mathcal{X}_1} |x_1| p(x_1|x_2) < \infty$ im diskreten Fall bzw. $\int_{\mathcal{X}_1} |x_1| p(x_1|x_2)\, dx_1 < \infty$ im kontinuierlichen Fall. Dann ist der *bedingte Erwartungswert* von ξ_1 gegeben $\xi_2 = x_2$ definiert als

- $\mathbb{E}(\xi_1|\xi_2 = x_2) := \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1|x_2)$, wenn ξ ein diskreter Zufallsvektor ist.
- $\mathbb{E}(\xi_1|\xi_2 = x_2) := \int_{\mathcal{X}_1} x_1 p(x_1|x_2)\, dx_1$, wenn ξ ein kontinuierlicher Zufallsvektor ist.

•

Der bedingte Erwartungswert einer Zufallsvariable ist also der Erwartungswert einer Zufallsvariable in einer bedingten Verteilung. Man beachte, dass wir in Definition 23.6 den bedingten Erwartungswert für einen festen Wert x_2 von ξ_2 definiert haben. Bei einem festen Wert x_2 von ξ_2 ist $\mathbb{E}(\xi_1|\xi_2 = x_2)$ damit ein fester Wert und durch Austauschen der Subskripte erhält man entsprechend $\mathbb{E}(\xi_2|\xi_1 = x_1)$.

Allgemein ist $\mathbb{E}(\xi_1|\xi_2)$ allerdings eine Zufallsvariable, da ξ_2 eine Zufallsvariable ist und nur mit einer gewissen Wahrscheinlichkeit einen Wert $\xi_2 = x_2$ annimmt. Wir werden später sehen, dass analog zu Definition 23.6 bedingte Varianzen, bedingte Kovarianzen und bedingte Korrelationen definiert werden. In der Psychologie ist der Begriff des bedingten Erwartungswerts zentral, denn in der klassischen Testtheorie sind die wahren Werte von Personen bei Testmessungen als bedingte Erwartungswerte definiert. Zur Verdeutlichung von Definition 23.6 betrachten wir ein Beispiel für einen diskreten Zufallsvektor.

Beispiel 23.6 (Bedingter Erwartungswert eines diskreten Zufallsvektors)**.** Für einen zweidimensionalen Zufallsvektor $\xi := (\xi_1, \xi_2)$, der Werte in $\mathcal{X} := \mathcal{X}_1 \times \mathcal{X}_2$ mit $\mathcal{X}_1 := \{1, 2, 3, 4\}$ und $\mathcal{X}_2 = \{1, 2, 3\}$ annehme, seien bedingte WMFen für $p(x_1|x_2)$ für alle $x_1 \in \mathcal{X}_1$ wie in Tabelle 23.2 spezifiziert

Tabelle 23.2. Bedingte Wahrscheinlichkeitsverteilung von x_1 gegeben x_2

$p(x_1\|x_2)$	$x_2 = 1$	$x_2 = 2$	$x_2 = 3$
$p(x_1 = 1\|x_2)$	$\frac{1}{4}$	$\frac{1}{3}$	0
$p(x_1 = 2\|x_2)$	0	$\frac{2}{3}$	$\frac{1}{3}$
$p(x_1 = 3\|x_2)$	$\frac{1}{2}$	0	$\frac{1}{3}$
$p(x_1 = 4\|x_2)$	$\frac{1}{4}$	0	$\frac{1}{3}$

Dann ergeben sich die bedingten Erwartungswerte

$$\begin{aligned}
\mathbb{E}(\xi_1|\xi_2 = 1) &= \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1|x_2 = 1) = 1 \cdot \frac{1}{4} + 2 \cdot 0 + 3 \cdot \frac{1}{2} + 4 \cdot \frac{1}{4} = \frac{11}{4} \\
\mathbb{E}(\xi_1|\xi_2 = 2) &= \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1|x_2 = 2) = 1 \cdot \frac{1}{3} + 2 \cdot \frac{2}{3} + 3 \cdot 0 + 4 \cdot 0 = \frac{5}{3} \\
\mathbb{E}(\xi_1|\xi_2 = 3) &= \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1|x_2 = 3) = 1 \cdot 0 + 2 \cdot \frac{1}{3} + 3 \cdot \frac{1}{3} + 4 \cdot \frac{1}{3} = 3.
\end{aligned} \tag{23.23}$$

△

Das folgende Theorem, der sogenannte *Satz vom iterierten Erwartungswert*, stellt einen Zusammenhang zwischen dem (marginalen) Erwartungswert einer Zufallsvariable und dem bedingten Erwartungswert dieser Zufallsvariable her. Das Theorem wird manchmal auch als *Satz vom totalen Erwartungswert* bezeichnet.

Theorem 23.4 (Satz vom iterierten Erwartungswert)**.** *Gegeben sei ein Zufallsvektor* $\xi := (\xi_1, \xi_2)$*, wobei* $\mathbb{E}(|\xi_1|) < \infty$ *gilt. Dann gilt*

$$\mathbb{E}(\xi_1) = \mathbb{E}\left(\mathbb{E}\left(\xi_1|\xi_2\right)\right). \tag{23.24}$$

∘

Beweis. Wir beschränken uns auf den Beweis für einen diskreten Zufallsvektor, der Beweis für einen kontinuierlichen Zufallsvektor folgt analog. Die folgenden Summen über x_2 laufen nur über Werte mit $p(x_2) > 0$. Es gilt

$$\begin{aligned}
\mathbb{E}(\xi_1) &= \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1) \\
&= \sum_{x_1 \in \mathcal{X}_1} x_1 \sum_{x_2 \in \mathcal{X}_2} p(x_1, x_2) \\
&= \sum_{x_1 \in \mathcal{X}_1} x_1 \sum_{x_2 \in \mathcal{X}_2} p(x_1|x_2) p(x_2) \\
&= \sum_{x_1 \in \mathcal{X}_1} \sum_{x_2 \in \mathcal{X}_2} x_1 p(x_1|x_2) p(x_2) \\
&= \sum_{x_2 \in \mathcal{X}_2} \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1|x_2) p(x_2) \\
&= \sum_{x_2 \in \mathcal{X}_2} \mathbb{E}(\xi_1|\xi_2 = x_2) p(x_2) \\
&= \mathbb{E}\left(\mathbb{E}(\xi_1|\xi_2)\right).
\end{aligned} \tag{23.25}$$

□

Offenbar bezeichnen die verschiedenen Erwartungswerte in Theorem 23.4 Erwartungswert bezüglich unterschiedlicher Verteilungen: der Erwartungswert auf der linken Seite der Gleichung bezeichnet den Erwartungswert bezüglich der marginalen Verteilung von ξ_1, der äußere Erwartungswert auf der rechten Seite der Gleichung bezeichnet den Erwartungswert bezüglich der marginalen Verteilung von ξ_2 und der innere Erwartungswert auf der rechten Seite der Gleichung bezeichnet den bedingten Erwartungswert von ξ_1 gegeben ξ_2.

Selbstkontrollfragen

1. Geben Sie die Definition des Erwartungswerts einer Zufallsvariable wieder.
2. Erläutern Sie den Begriff des Erwartungswerts einer Zufallsvariable.
3. Berechnen Sie den Erwartungswert einer Bernoulli-Zufallsvariable.
4. Geben Sie die Definition des Begriffs der Stichprobe wieder.
5. Geben Sie die Definition des Stichprobenmittels wieder.
6. Erläutern Sie die Unterschiede zwischen einem Erwartungswert und einem Stichprobenmittel.
7. Geben Sie die Definition des Erwartungswerts einer Funktion einer Zufallsvariable wieder.
8. Geben Sie das Theorem zum Erwartungswert bei linear-affiner Transformation einer Zufallsvariable wieder.
9. Geben Sie die Definition des Erwartungswerts eines Zufallsvektors wieder.
10. Geben Sie die Definition des Erwartungswerts einer Funktion eines Zufallsvektors wieder.
11. Geben Sie das Theorem zum Erwartungswert bei linear-affiner Kombination von Zufallsvariablen wieder.
12. Geben Sie das Theorem zum Erwartungswert des Produkts unabhängiger Zufallsvariablen wieder.

Lösungen

1. Siehe Definition 23.1.
2. Siehe Erläuterungen in der Nachfolge von Definition 23.1, insbesondere auch Beispiel 23.4.
3. Siehe Beispiel 23.2.
4. Siehe Definition 23.2.
5. Siehe Definition 23.2.
6. Siehe Erläuterungen zu Beispiel 23.4, Definition 23.2 und Beispiel 23.5.
7. Siehe Definition 23.3.
8. Siehe Theorem 23.1.
9. Siehe Definition 23.4.
10. Siehe Definition 23.5.
11. Siehe Theorem 23.2.
12. Siehe Theorem 23.3.

24. Varianzen

In diesem Kapitel führen wir den Begriff der *Varianz* einer Zufallsvariable ein. Wie der Erwartungswert dient die Varianz als eine einzige, skalare Kennzahl, die eine Wahrscheinlichkeitsverteilung zusammenfassend beschreibt und häufig als zentrale charakteristische Größe von Zufallsvariablen verwendet wird. Die Varianz dient dabei als ein Maß für die "Variabilität" einer Zufallsvariable. Letztlich handelt es sich bei der Varianz einer Zufallsvariable um eine spezielle Kovarianz (vgl. Kapitel 25), nämlich die Kovarianz einer Zufallsvariable mit sich selbst. Eng verwandt mit dem Begriff der Varianz ist der Begriff der Standardabweichung, den wir parallel einführen wollen. Wir ergänzen diese Begriffe vorliegenden Kapitel durch ihre deskriptiv-statistischen Äquivalente, die sogenannte *Stichprobenvarianz* und *Stichprobenstandardabweichung* sowie ihr Auftreten in bedingten Verteilungen.

24.1. Definition

Definition 24.1 (Varianz und Standardabweichung)**.** ξ sei eine Zufallsvariable mit endlichem Erwartungswert $\mathbb{E}(\xi)$. Dann ist die *Varianz von* ξ definiert als

$$\mathbb{V}(\xi) := \mathbb{E}\left((\xi - \mathbb{E}(\xi))^2\right) \tag{24.1}$$

und die *Standardabweichung von* ξ ist definiert als

$$\mathbb{S}(\xi) := \sqrt{\mathbb{V}(\xi)}. \tag{24.2}$$

•

Die Varianz einer Zufallsvariable ξ mit Ergebnisraum $\mathcal{X}$ ist nach Definition 23.3 also der Erwartungswert der Funktion

$$f : \mathcal{X} \to \mathcal{Z}, x \mapsto f(x) := (x - \mathbb{E}(\xi))^2 \tag{24.3}$$

und damit die erwartete quadrierte Abweichung einer Zufallsvariable von ihrem Erwartungswert. Die Quadrierung der Abweichung der Zufallsvariable von ihrem Erwartungswert ist dabei nötig, da andernfalls mit Theorem 23.1 immer gelten würde, dass

$$\mathbb{E}(\xi - \mathbb{E}(\xi)) = \mathbb{E}(\xi) - \mathbb{E}(\xi) = 0. \tag{24.4}$$

Intuitiv misst die Varianz also die *Streuung* oder *Variabilität* einer Zufallsvariable. Insbesondere besagt die in Kapitel 26 genauer diskutierte *Chebyshev Ungleichung*, dass

$$\mathbb{P}(|\xi - \mathbb{E}(\xi)| \geq x) \leq \frac{\mathbb{V}(\xi)}{x^2}. \tag{24.5}$$

Mit der Chebyshev Ungleichung gelten beispielsweise, dass

$$\mathbb{P}\left(|\xi - \mathbb{E}(\xi)| \geq 2\sqrt{\mathbb{V}(\xi)}\right) \leq \frac{\mathbb{V}(\xi)}{\left(2\sqrt{\mathbb{V}(\xi)}\right)^2} = \frac{1}{4} \tag{24.6}$$

und

$$\mathbb{P}\left(|\xi - \mathbb{E}(\xi)| \geq 3\sqrt{\mathbb{V}(\xi)}\right) \leq \frac{\mathbb{V}(\xi)}{\left(3\sqrt{\mathbb{V}(\xi)}\right)^2} = \frac{1}{9}. \tag{24.7}$$

Für eine Zufallsvariable gilt also immer, dass die Wahrscheinlichkeit für eine absolute Abweichung vom doppelten ihrer Standardabweichung höchstens 1/4 ist, also frequentistisch betrachtet nur für etwa ein Viertel ihrer Realisierungen zutrifft, und die Wahrscheinlichkeit für eine absolute Abweichung vom dreifachen ihrer Standardabweichung höchstens 1/9 ist, also frequentistisch betrachtet nur für etwa ein Zehntel ihrer Realisierungen zutrifft, jeweils unabhängig davon, von welcher genauen Form die Verteilung der Zufallsvariable ist. Neben der Varianz gibt es allerdings viele weitere Maße für die Variabilität von Zufallsvariablen. Hier seien die *erwartete absolute Abweichung* einer Zufallsvariable von ihrem Erwartungswert

$$\mathbb{A}(\xi) := \mathbb{E}(|\xi - \mathbb{E}(\xi)|) \tag{24.8}$$

und die sogenannte *Entropie* einer Zufallsvariable

$$\mathbb{H}(\xi) := -\mathbb{E}(\ln p(x)) \tag{24.9}$$

genannt. Wir verdeutlichen die Definition der Varianz in Definition 24.1 zunächst an einigen Beispielen.

Beispiel 24.1 (Varianz einer diskreten Zufallsvariable)**.** ξ sei eine Zufallsvariable mit Ergebnisraum $\mathcal{X} := \{-1, 0, 1\}$ und WMF

$$p(-1) = \frac{1}{4}, \quad p(0) = \frac{1}{2}, \quad p(1) = \frac{1}{4}. \tag{24.10}$$

Dann gilt

$$\mathbb{V}(\xi) = \frac{1}{2}. \tag{24.11}$$

△

Beweis. Nach Definition 24.1 ergibt sich mit dem in Beispiel 23.1 bestimmten Erwartungswert derselben Zufallsvariable

$$\begin{aligned}
\mathbb{V}(\xi) &= \mathbb{E}\left((\xi - \mathbb{E}(\xi))^2\right) \\
&= \mathbb{E}\left((\xi - 0)^2\right) \\
&= \mathbb{E}\left(\xi^2\right) \\
&= \sum_{x \in \mathcal{X}} x^2 \, p(x) \\
&= (-1)^2 \cdot p(-1) + 0^2 \cdot p(0) + 1^2 \cdot p(1) \\
&= 1 \cdot \frac{1}{4} + 0 \cdot \frac{1}{2} + 1 \cdot \frac{1}{4} \\
&= \frac{1}{2}.
\end{aligned} \tag{24.12}$$

□

Beispiel 24.2 (Varianz einer Bernoulli-Zufallsvariable)**.** Es sei $\xi \sim \text{Bern}(\mu)$. Dann ist die Varianz von ξ gegeben durch

$$\mathbb{V}(\xi) = \mu(1-\mu). \tag{24.13}$$

△

Beweis. ξ ist eine diskrete Zufallsvariable und es gilt $\mathbb{E}(\xi) = \mu$. Also gilt

$$\begin{aligned}
\mathbb{V}(\xi) &= \mathbb{E}\left((\xi-\mu)^2\right) \\
&= \sum_{x\in\{0,1\}} (x-\mu)^2 \text{Bern}(x;\mu) \\
&= (0-\mu)^2\mu^0(1-\mu)^{1-0} + (1-\mu)^2\mu^1(1-\mu)^{1-1} \\
&= \mu^2(1-\mu) + (1-\mu)^2\mu \\
&= \left(\mu^2 + (1-\mu)\mu\right)(1-\mu) \\
&= \left(\mu^2 + \mu - \mu^2\right)(1-\mu) \\
&= \mu(1-\mu).
\end{aligned} \tag{24.14}$$

□

Beispiel 24.3 (Varianz einer normalverteilten Zufallsvariable)**.** Es sei $\xi \sim N(\mu, \sigma^2)$. Dann ist die Varianz von ξ gegeben durch

$$\mathbb{V}(\xi) = \sigma^2. \tag{24.15}$$

△

Beweis. Wir verzichten auf einen Beweis. □

Analog zum Begriff des Stichprobenmittels definiert man die deskriptiv-statistischen Äquivalente von zu Definition 24.1 wie folgt.

Definition 24.2 (Stichprobenvarianz und Stichprobenstandardabweichung)**.** $\xi_1, ..., \xi_n$ seien Zufallsvariablen und $\bar{\xi}$ sei ihr Stichprobenmittel. Die *Stichprobenvarianz von* $\xi_1, ..., \xi_n$ ist definiert als

$$S^2 := \frac{1}{n-1}\sum_{i=1}^{n}(\xi_i - \bar{\xi})^2 \tag{24.16}$$

und die *Stichprobenstandardabweichung von* $\xi_1, ..., \xi_n$ ist definiert als

$$S := \sqrt{S^2}. \tag{24.17}$$

•

Wie im Kontext des Stichprobenmittels ist es zentral zu erkennen, dass $\mathbb{V}(\xi)$ und $\mathbb{S}(\xi)$ Kennzahlen einer Zufallsvariable ξ sind, wohingegen S^2 bzw. S Kennzahlen einer Stichprobe $\xi_1, ..., \xi_n$ sind. Da S^2 und S Funktionen von Zufallsvariablen sind, sind S^2 bzw. S auch selbst Zufallsvariablen. Realisierungen von S^2 und S bezeichnen wir s^2 bzw. s.

Beispiel 24.4 (Stichprobenvarianz und Stichprobenstandardabweichung)**.** Als Beispiel für die Realisationen einer Stichprobenvarianz bzw. einer Stichprobenstandardabweichung betrachten wir erneut die in Tabelle 24.1 gezeigten Realisationen der Zufallsvariablen $\xi_1, ..., \xi_{10} \sim N(1, 2)$ mit Stichprobenmittelrealisation $\bar{x} = 0.68$.

Tabelle 24.1. Stichprobenrealisation

x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}
0.54	1.01	-3.28	0.35	2.75	-0.51	2.32	1.49	0.96	1.25

Die Stichprobenvarianzrealisation ist dann

$$s^2 = \frac{1}{9}\sum_{i=1}^{10}(x_i - \bar{x})^2 = \frac{1}{9}\sum_{i=1}^{10}(x_i - 0.68)^2 = \frac{25.37}{9} = 2.82 \tag{24.18}$$

und die Stichprobenstandardabweichungsrealisation entsprechend

$$s = \sqrt{s^2} = \sqrt{2.82} = 1.68. \tag{24.19}$$

△

Die Begriffe der Varianz und Standardabweichung sind nach Definition 24.1 offenbar äquivalent zueinander, da die eine direkt aus der anderen durch Wurzelziehen bzw. Quadrieren hervorgeht. Die Varianz ist historisch eng sowohl mit dem Exponentialargument der Normalverteilung als auch mit den Quadratsummen der Varianzanalyse verwoben und deshalb in der Modellbildung oft leichter zu handhaben als die Standardabweichung.

Sowohl die Varianz als auch die Stichprobenvarianz messen die Variabilität einer Zufallsvariable allerdings in quadrierten Einheiten. Ein Beispiel hierfür ist die Berechnung der Stichprobenvarianz in Beispiel 24.4, wenn man sich die Realisierungen in Tabelle 24.1 als Längenmessungen in Metern (m) denkt. Nach der Definition 24.2 wird die Einheit bei Berechung der Stichprobenvarianz dann quadriert,

$$s^2 = \frac{1}{9}\sum_{i=1}^{10}(x_i \text{ m} - 0.68 \text{ m})^2 = \frac{1}{9} \cdot 25.37 \text{ m}^2 = 2.82 \text{ m}^2. \tag{24.20}$$

Das resultierende Maß für die Variabilität hätte somit die Einheit einer Fläche (m^2), obwohl die ursprünglichen Daten Längen in Meter (m) darstellen. Das Wurzelziehen korrigiert die Einheiten zurück auf die Einheit der Daten und liefert als Standardabweichung dann ein Variabilitätsmaß in der ursprünglichen Einheit,

$$s = \sqrt{2.82 \text{ m}^2} = \sqrt{2.82}\sqrt{\text{m}^2} = 1.68 \text{ m}. \tag{24.21}$$

Allerdings ist man in den meisten Anwendungskontexten eher an den Verhältnissen von Variabilitäten verschiedener Stichproben interessiert, wofür sich dann sowohl (Stichproben)Varianz als auch (Stichproben)Standardabweichung gleichermaßen eignen.

24.2. Eigenschaften

Die Varianz hat die Eigenschaft, keine negativen Werte anzunehmen.

Theorem 24.1 (Nichtnegativität der Varianz)**.** *ξ sei eine Zufallsvariable mit endlichem zweiten Moment. Dann gilt*

$$\mathbb{V}(\xi) \geq 0. \tag{24.22}$$

∘

Beweis. Wir betrachten den Fall einer diskreten Zufallsvariablen. Dann gilt zunächst

$$(x - \mathbb{E}(\xi))^2 \geq 0 \text{ für alle } x \in \mathcal{X}. \tag{24.23}$$

Weiterhin gilt für die WMF p von ξ, dass

$$p(x) \geq 0 \text{ für alle } x \in \mathcal{X}. \tag{24.24}$$

Also folgt

$$p(x)(x - \mathbb{E}(\xi))^2 \geq 0 \text{ für alle } x \in \mathcal{X}. \tag{24.25}$$

Damit gilt dann aber

$$\mathbb{V}(\xi) = \sum_{x \in \mathcal{X}} p(x)(x - \mathbb{E}(\xi))^2 \geq 0. \tag{24.26}$$

Analog zeigt man die Nichtnegativität der Varianz bei kontinuierlichen Zufallsvariablen. □

Das Berechnen von Varianzen wird durch folgendes Theorem, den sogenannten *Varianzverschiebungssatz* oft erleichtert, insbesondere, wenn der Erwartungswert der quadrierten Zufallsvariable leicht zu bestimmen oder bekannt ist.

Theorem 24.2 (Varianzverschiebungssatz)**.** *ξ sei eine Zufallsvariable. Dann gilt*

$$\mathbb{V}(\xi) = \mathbb{E}\left(\xi^2\right) - \mathbb{E}(\xi)^2. \tag{24.27}$$

∘

Beweis. Mit der Definition der Varianz und der Linearität des Erwartungswerts gilt

$$\begin{aligned}
\mathbb{V}(\xi) &= \mathbb{E}\left((\xi - \mathbb{E}(\xi))^2\right) \\
&= \mathbb{E}\left(\xi^2 - 2\xi\mathbb{E}(\xi) + \mathbb{E}(\xi)^2\right) \\
&= \mathbb{E}(\xi^2) - 2\mathbb{E}(\xi)\mathbb{E}(\xi) + \mathbb{E}\left(\mathbb{E}(\xi)^2\right) \\
&= \mathbb{E}(\xi^2) - 2\mathbb{E}(\xi)^2 + \mathbb{E}(\xi)^2 \\
&= \mathbb{E}(\xi^2) - \mathbb{E}(\xi)^2.
\end{aligned} \tag{24.28}$$

□

In Analogie zu Theorem 23.1 gilt für die Varianz folgendes Resultat.

Theorem 24.3 (Varianz und Standardabweichung bei linear-affiner Transformation einer Zufallsvariable)**.** *ξ sei eine Zufallsvariable und es sei*

$$f : \mathcal{X} \to \mathcal{Z}, x \mapsto f(x) := ax + b \text{ für } a, b \in \mathbb{R} \tag{24.29}$$

eine linear-affine Funktion. Dann gelten

$$\mathbb{V}(f(\xi)) = \mathbb{V}(a\xi + b) = a^2\mathbb{V}(\xi) \tag{24.30}$$

und

$$\mathbb{S}(f(\xi)) = \mathbb{S}(a\xi + b) = |a|\mathbb{S}(\xi) \tag{24.31}$$

∘

Beweis. Es ergibt sich

$$\begin{aligned}
\mathbb{V}(f(\xi)) &= \mathbb{V}(a\xi + b) \\
&= \mathbb{E}\left((a\xi + b - \mathbb{E}(a\xi + b))^2\right) \\
&= \mathbb{E}\left((a\xi + b - a\mathbb{E}(\xi) - b)^2\right) \\
&= \mathbb{E}\left((a\xi - a\mathbb{E}(\xi))^2\right) \\
&= \mathbb{E}\left(a(\xi - \mathbb{E}(\xi))^2\right) \\
&= \mathbb{E}\left(a^2(\xi - \mathbb{E}(\xi))^2\right) \\
&= a^2\mathbb{E}\left((\xi - \mathbb{E}(\xi))^2\right) \\
&= a^2\mathbb{V}(\xi).
\end{aligned} \tag{24.32}$$

Wurzelziehen unter Beachtung von

$$a \geq 0 \Rightarrow a^2 \geq 0 \Rightarrow \sqrt{a^2} = a \geq 0 \Leftrightarrow \sqrt{a^2} = |a| \text{ für } a \geq 0 \tag{24.33}$$

sowie

$$a < 0 \Rightarrow a^2 > 0 \Rightarrow \sqrt{a^2} = -a > 0 \Leftrightarrow \sqrt{a^2} = |a| \text{ für } a < 0 \tag{24.34}$$

zeigt dann das Resultat für die Standardabweichung. □

Die Varianz der Linearkombination zweier unabhängiger Zufallsvariablen lässt sich als modifizierte Linearkombination der Varianzen der Zufallsvariablen schreiben.

Theorem 24.4 (Varianz bei Linearkombination zweier unabhängiger Zufallsvariablen)**.** *ξ_1 und ξ_2 seien zwei unabhängige Zufallsvariablen und es seien $a_1, a_2 \in \mathbb{R}$. Dann gilt*

$$\mathbb{V}\left(a_1\xi_1 + a_2\xi_2\right) = a_1^2\mathbb{V}(\xi_1) + a_2^2\mathbb{V}(\xi_1). \tag{24.35}$$

∘

Beweis. Wir halten zunächst fest, dass mit Theorem 23.2 gilt, dass

$$\mathbb{E}\left(a_1\xi_1 + a_2\xi_2\right) = a_1\mathbb{E}(\xi_1) + a_2\mathbb{E}(\xi_2). \tag{24.36}$$

Weiterhin gilt mit Theorem 23.3, dass

$$\begin{aligned}
\mathbb{E}\left((\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - \mathbb{E}(\xi_2))\right) &= \mathbb{E}\left(\xi_1\xi_2 - \mathbb{E}(\xi_1)\xi_2 - \xi_1\mathbb{E}(\xi_2) + \mathbb{E}(\xi_1)\mathbb{E}(\xi_2)\right) \\
&= \mathbb{E}(\xi_1\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) + \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) \\
&= \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) \\
&= 0.
\end{aligned} \tag{24.37}$$

Es folgt also

$$\begin{aligned}
\mathbb{V}(a_1\xi_1 + a_2\xi_2) &= \mathbb{E}\left((a_1\xi_1 + a_2\xi_2 - \mathbb{E}\left(a_1\xi_1 + a_2\xi_2\right))^2\right) \\
&= \mathbb{E}\left((a_1\xi_1 + a_2\xi_2 - a_1\mathbb{E}(\xi_1) - a_2\mathbb{E}(\xi_2))^2\right) \\
&= \mathbb{E}\left((a_1\xi_1 - a_1\mathbb{E}(\xi_1) + a_2\xi_2 - a_2\mathbb{E}(\xi_2))^2\right) \\
&= \mathbb{E}\left(a_1(\xi_1 - \mathbb{E}(\xi_1)) + (a_2(\xi_2 - \mathbb{E}(\xi_2)))^2\right) \\
&= \mathbb{E}\left(a_1(\xi_1 - \mathbb{E}(\xi_1)))^2 + 2a_1(\xi_1 - \mathbb{E}(\xi_1))(a_2(\xi_2 - \mathbb{E}(\xi_2)) + (a_2(\xi_2 - \mathbb{E}(\xi_2)))^2\right) \\
&= \mathbb{E}\left(a_1^2(\xi_1 - \mathbb{E}(\xi_1))^2 + 2a_1a_2(\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - \mathbb{E}(\xi_2)) + a_2^2(\xi_2 - \mathbb{E}(\xi_2))^2\right) \\
&= a_1^2\mathbb{E}\left((\xi_1 - \mathbb{E}(\xi_1))^2\right) + 2a_1a_2\mathbb{E}\left((\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - \mathbb{E}(\xi_2))\right) + a_2^2\mathbb{E}\left((\xi_2 - \mathbb{E}(\xi_2))^2\right) \\
&= a_1^2\mathbb{V}(\xi_1) + 2a_1a_2\mathbb{E}\left((\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - \mathbb{E}(\xi_2))\right) + a_2^2\mathbb{V}(\xi_2) \\
&= a_1^2\mathbb{V}(\xi_1) + 2a_1a_2 \cdot 0 + a_2^2\mathbb{V}(\xi_2) \\
&= a_1^2\mathbb{V}(\xi_1) + a_2^2\mathbb{V}(\xi_2).
\end{aligned} \tag{24.38}$$

□

Weitergreifendere Aussage zur Varianz der Summe nicht unabhängiger Zufallsvariablen lassen sich erst mithilfe des in Kapitel 25 eingeführten Begriffs der Kovarianz treffen.

24.3. Bedingte Varianz

Definition 24.3 (Bedingte Varianz)**.** Gegeben sei ein Zufallsvektor $\xi := (\xi_1, \xi_2)$ mit Ergebnisraum $\mathcal{X} := \mathcal{X}_1 \times \mathcal{X}_2$ und gemeinsamer WMF oder WDF. Für einen Bedingungswert x_2 mit positiver marginaler WMF bzw. WDF existiere die entsprechende bedingte Verteilung, und es gelte $\mathbb{E}(\xi_1^2|\xi_2 = x_2) < \infty$. Dann ist die *bedingte Varianz von* ξ_1 *gegeben* $\xi_2 = x_2$ definiert als

$$\mathbb{V}(\xi_1|\xi_2 = x_2) := \mathbb{E}\left(\left(\xi_1 - \mathbb{E}(\xi_1|\xi_2 = x_2)\right)^2 |\xi_2 = x_2\right) \tag{24.39}$$

und die *bedingte Standardabweichung von* ξ_1 *gegeben* $\xi_2 = x_2$ ist definiert als

$$\mathbb{S}(\xi_1|\xi_2 = x_2) := \sqrt{\mathbb{V}(\xi_1|\xi_2 = x_2)}. \tag{24.40}$$

•

Für einen festen Bedingungswert x_2 sind die bedingte Varianz und die bedingte Standardabweichung feste Zahlen. Betrachtet man die bedingte Varianz dagegen als Funktion der Zufallsvariablen ξ_2, erhält man die Zufallsvariable $\mathbb{V}(\xi_1|\xi_2)$. Entsprechendes gilt für $\mathbb{S}(\xi_1|\xi_2)$. Auch für die bedingte Varianz gilt ein Verschiebungssatz.

Theorem 24.5 (Verschiebungssatz der bedingten Varianz)**.** *Gegeben sei ein Zufallsvektor* $\xi := (\xi_1, \xi_2)$*, wobei* ξ_1 *ein endliches zweites Moment besitzt. Für alle Bedingungswerte* x_2 *mit positiver marginaler WMF bzw. WDF und endlichem bedingtem zweiten Moment gilt*

$$\mathbb{V}(\xi_1|\xi_2 = x_2) = \mathbb{E}\left(\xi_1^2|\xi_2 = x_2\right) - \mathbb{E}(\xi_1|\xi_2 = x_2)^2 \tag{24.41}$$

◦

Beweis. Wir beschränken uns auf den Beweis für einen diskreten Zufallsvektor. Der Beweis für einen kontinuierlichen Zufallsvektor folgt analog. Mit der Definition des bedingten Erwartungswerts (Definition 23.6) gilt

$$\begin{aligned}
\mathbb{V}(\xi_1|\xi_2 = x_2) &= \mathbb{E}\left((\xi_1 - \mathbb{E}(\xi_1|\xi_2 = x_2))^2 |\xi_2 = x_2\right) \\
&= \mathbb{E}\left(\xi_1^2 - 2\xi_1\mathbb{E}(\xi_1|\xi_2 = x_2) + \mathbb{E}(\xi_1|\xi_2 = x_2)^2|\xi_2 = x_2\right) \\
&= \sum_{x_1 \in \mathcal{X}_1} p(x_1|x_2)\left(x_1^2 - 2x_1\mathbb{E}(\xi_1|\xi_2 = x_2) + \mathbb{E}(\xi_1|\xi_2 = x_2)^2\right) \\
&= \sum_{x_1 \in \mathcal{X}_1} x_1^2 p(x_1|x_2) - \sum_{x_1 \in \mathcal{X}_1} 2x_1\mathbb{E}(\xi_1|\xi_2 = x_2)p(x_1|x_2) + \sum_{x_1 \in \mathcal{X}_1} \mathbb{E}(\xi_1|\xi_2 = x_2)^2 p(x_1|x_2) \\
&= \mathbb{E}(\xi_1^2|\xi_2 = x_2) - 2\mathbb{E}(\xi_1|\xi_2 = x_2)\sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1|x_2) + \mathbb{E}(\xi_1|\xi_2 = x_2)^2 \sum_{x_1 \in \mathcal{X}_1} p(x_1|x_2) \\
&= \mathbb{E}(\xi_1^2|\xi_2 = x_2) - 2\mathbb{E}(\xi_1|\xi_2 = x_2)\mathbb{E}(\xi_1|\xi_2 = x_2) + \mathbb{E}(\xi_1|\xi_2 = x_2)^2 \cdot 1 \\
&= \mathbb{E}(\xi_1^2|\xi_2 = x_2) - 2\mathbb{E}(\xi_1|\xi_2 = x_2)^2 + \mathbb{E}(\xi_1|\xi_2 = x_2)^2 \\
&= \mathbb{E}(\xi_1^2|\xi_2 = x_2) - \mathbb{E}(\xi_1|\xi_2 = x_2)^2
\end{aligned} \tag{24.42}$$

□

Folgendes Theorem, der sogenannte *Satz von der iterierten Varianz* stellt einen Zusammenhang zwischen der Varianz einer Zufallsvariable, ihrer bedingten Varianz und der Varianz ihres bedingten Erwartungswerts her.

Theorem 24.6 (Satz von der iterierten Varianz)**.** *Gegeben sei ein Zufallsvektor* $\xi := (\xi_1, \xi_2)$*, wobei* ξ_1 *ein endliches zweites Moment besitzt. Dann gilt*

$$\mathbb{V}(\xi_1) = \mathbb{E}(\mathbb{V}(\xi_1|\xi_2)) + \mathbb{V}(\mathbb{E}(\xi_1|\xi_2)) \tag{24.43}$$

∘

Beweis. Wir beschränken uns auf den Beweis für einen diskreten Zufallsvektor. Der Beweis für einen kontinuierlichen Zufallsvektor folgt analog. Mit dem Kovarianzverschiebungssatz (Theorem 25.2), dem Satz vom iterierten Erwartungswert (Theorem 23.4) und dem Verschiebungssatz der bedingten Varianz (Theorem 24.5) ergibt sich folgende Rechnung. Die Summen über x_2 laufen nur über Werte mit $p(x_2) > 0$.

$$\begin{aligned}
\mathbb{V}(\xi_1) &= \mathbb{E}(\xi_1^2) - \mathbb{E}(\xi_1)^2 \\
&= \mathbb{E}\left(\mathbb{E}(\xi_1^2|\xi_2)\right) - \mathbb{E}\left(\mathbb{E}(\xi_1|\xi_2)\right)^2 \\
&= \sum_{x_2 \in \mathcal{X}_2} p(x_2)\mathbb{E}(\xi_1^2|\xi_2 = x_2) - \mathbb{E}\left(\mathbb{E}(\xi_1|\xi_2)\right)^2 \\
&= \sum_{x_2 \in \mathcal{X}_2} p(x_2)\left(\mathbb{V}(\xi_1|\xi_2 = x_2) + \mathbb{E}(\xi_1|\xi_2 = x_2)^2\right) - \mathbb{E}\left(\mathbb{E}(\xi_1|\xi_2)\right)^2 \\
&= \sum_{x_2 \in \mathcal{X}_2} p(x_2)\mathbb{V}(\xi_1|\xi_2 = x_2) + \sum_{x_2 \in \mathcal{X}_2} p(x_2)\mathbb{E}(\xi_1|\xi_2 = x_2)^2 - \mathbb{E}\left(\mathbb{E}(\xi_1|\xi_2)\right)^2 \\
&= \mathbb{E}(\mathbb{V}(\xi_1|\xi_2)) + \left(\mathbb{E}\left(\mathbb{E}(\xi_1|\xi_2)^2\right) - \mathbb{E}\left(\mathbb{E}(\xi_1|\xi_2)\right)^2\right) \\
&= \mathbb{E}(\mathbb{V}(\xi_1|\xi_2)) + \mathbb{V}\left(\mathbb{E}(\xi_1|\xi_2)\right)
\end{aligned} \tag{24.44}$$

□

Selbstkontrollfragen

1. Geben Sie die Definition der Varianz und der Standardabweichung einer Zufallsvariable wieder.
2. Erläutern Sie die Definition der Varianz und der Standardabweichung einer Zufallsvariable.
3. Berechnen Sie die Varianz einer Bernoulli-Zufallsvariable.
4. Geben Sie die Definition von Stichprobenvarianz und Stichprobenstandardabweichung wieder.
5. Erläutern Sie die Definitionen der Stichprobenvarianz und der Stichprobenstandardabweichung.
6. Geben Sie das Theorem zur Nichtnegativität der Varianz wieder.
7. Geben Sie das Theorem zum Varianzverschiebungssatz wieder.
8. Geben Sie das Theorem zur Varianz und Standardabweichung bei linear-affiner Transformation einer Zufallsvariable wieder.
9. Geben Sie das Theorem zur Varianz bei Linearkombination zweier unabhängiger Zufallsvariablen wieder.

Lösungen

1. Siehe Definition 24.1.
2. Siehe Erläuterungen zu Definition 24.1.
3. Siehe Beispiel 24.2.
4. Siehe Definition 24.2.
5. Siehe Erläuterungen zu Definition 24.2 sowie Beispiel 24.4.
6. Siehe Theorem 24.1.
7. Siehe Theorem 24.2.
8. Siehe Theorem 24.3.
9. Siehe Theorem 24.4.

25. Kovarianzen

Mit der *Kovarianz* zweier Zufallsvariablen und ihrer standardisierten Form, der *Korrelation*, führen wir in diesem Kapitel skalare Maßzahlen für die linear-affine Abhängigkeit von Zufallsvariablen ein.

25.1. Definitionen

Definition 25.1 (Kovarianz und Korrelation zweier Zufallsvariablen)**.** ξ_1 und ξ_2 seien Zufallsvariablen mit endlichen zweiten Momenten. Ihre *Kovarianz* ist definiert als

$$\mathbb{C}(\xi_1, \xi_2) := \mathbb{E}\left((\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - \mathbb{E}(\xi_2))\right). \tag{25.1}$$

Die *Korrelation* zweier Zufallsvariablen ξ_1 und ξ_2 mit $\mathbb{S}(\xi_1) > 0$ und $\mathbb{S}(\xi_2) > 0$ ist definiert als

$$\rho(\xi_1, \xi_2) := \frac{\mathbb{C}(\xi_1, \xi_2)}{\mathbb{S}(\xi_1)\mathbb{S}(\xi_2)}. \tag{25.2}$$

•

Die Kovarianz einer Zufallsvariable mit sich selbst ist ihre Varianz, denn es gilt

$$\mathbb{C}(\xi_1, \xi_2) = \mathbb{E}\left((\xi_1 - \mathbb{E}(\xi_1))(\xi_1 - \mathbb{E}(\xi_1))\right) = \mathbb{E}\left((\xi_1 - \mathbb{E}(\xi_1))^2\right) = \mathbb{V}(\xi_1). \tag{25.3}$$

Die Zahl $\rho(\xi_1, \xi_2)$ wird auch *Korrelationskoeffizient von* ξ_1 *und* ξ_2 genannt. Wenn $\rho(\xi_1, \xi_2) = 0$ gilt, so werden ξ_1 und ξ_2 *unkorreliert* genannt. In Kapitel 26 zeigen wir in Theorem 26.4, dass

$$-1 \leq \rho(\xi_1, \xi_2) \leq 1. \tag{25.4}$$

Die Definition der Kovarianz nach Definition 25.1 lässt implizit, dass die in ihr auftauchenden Erwartungswerte unterschiedlicher Natur sind. Dabei geht die Definition der Kovarianz zunächst einmal davon aus, dass ξ_1 und ξ_2 die Komponenten eines Zufallsvektors $\xi := (\xi_1, \xi_2)$ mit Ergebnisraum $\mathcal{X}_1 \times \mathcal{X}_2$, gemeinsamer Verteilung $\mathbb{P}(\xi_1, \xi_2)$ und marginalen Verteilungen $\mathbb{P}(\xi_1)$ und $\mathbb{P}(\xi_2)$ sind. Bei den Erwartungswerten $\mathbb{E}(\xi_1)$ und $\mathbb{E}(\xi_2)$ handelt es sich um die Erwartungswerte der Komponenten ξ_1 und ξ_2 bezüglich dieser Marginalverteilungen. Die Kovarianz selbst ist dann der Erwartungswert der Funktion

$$f : \mathcal{X}_1 \times \mathcal{X}_2 \to \mathcal{Z}, (x_1, x_2) \mapsto f(x_1, x_2) := (x_1 - \mathbb{E}(\xi_1))(x_2 - \mathbb{E}(\xi_2)) \tag{25.5}$$

bezüglich der gemeinsamen Verteilung $\mathbb{P}(\xi_1, \xi_2)$. Wir wollen dies am Beispiel eines diskreten Zufallsvektors verdeutlichen.

Beispiel 25.1 (Kovarianz zweier diskreter Zufallsvariablen.)**.** Es $\xi := (\xi_1, \xi_2)$ ein diskreter Zufallsvektor mit Ergebnisraum $\mathcal{X} := \{1, 2\} \times \{1, 2, 3\}$ und der in Tabelle 25.1 dargestellten gemeinsamen WMF $p(x_1, x_2)$ und marginalen WMFen $p(x_1)$ und $p(x_2)$.

Tabelle 25.1. Gemeinsame und marginale WMFen des Zufallsvektors ξ

$p(x_1, x_2)$	$x_2 = 1$	$x_2 = 2$	$x_2 = 3$	$p(x_1)$
$x_1 = 1$	0.10	0.05	0.15	0.30
$x_1 = 2$	0.60	0.05	0.05	0.70
$p(x_2)$	0.70	0.10	0.20	

Mit der Definition der Kovarianz von ξ_1 und ξ_2 gilt dann unter Beachtung von Gleichung 25.5

$$\begin{aligned}\mathbb{C}(\xi_1, \xi_2) &= \mathbb{E}(f(\xi_1, \xi_2)) \\ &= \sum_{x_1=1}^{2} \sum_{x_2=1}^{3} f(x_1, x_2) p(x_1, x_2) \\ &= \sum_{x_1=1}^{2} \sum_{x_2=1}^{3} (x_1 - \mathbb{E}(\xi_1))(x_2 - \mathbb{E}(\xi_2)) p(x_1, x_2)\end{aligned} \tag{25.6}$$

Einsetzen der Werte aus Tabelle 25.1 ergibt dann zunächst

$$\mathbb{E}(\xi_1) = \sum_{x_1=1}^{2} x_1 p(x_1) = 1 \cdot 0.3 + 2 \cdot 0.7 = 1.7 \tag{25.7}$$

und

$$\mathbb{E}(\xi_2) = \sum_{x_2=1}^{3} x_2 p(x_2) = 1 \cdot 0.7 + 2 \cdot 0.1 + 3 \cdot 0.2 = 1.5. \tag{25.8}$$

und damit dann schließlich

$$\begin{aligned}\mathbb{C}(\xi_1, \xi_2) &= \sum_{x_1=1}^{2} \sum_{x_2=1}^{3} (x_1 - 1.7)\,(x_2 - 1.5)\,p(x_1, x_2) \\ &= \sum_{x_1=1}^{2} (x_1 - 1.7)(1 - 1.5)p(x_1, 1) + (x_1 - 1.7)(2 - 1.5)p(x_1, 2) + (x_1 - 1.7)(3 - 1.5)p(x_1, 3) \\ &= \quad (1 - 1.7)(1 - 1.5)p(1, 1) + (1 - 1.7)(2 - 1.5)p(1, 2) + (1 - 1.7)(3 - 1.5)p(1, 3) \\ &\quad\; (2 - 1.7)(1 - 1.5)p(2, 1) + (2 - 1.7)(2 - 1.5)p(2, 2) + (2 - 1.7)(3 - 1.5)p(2, 3) \\ &= (-0.7) \cdot (-0.5) \cdot 0.10 + (-0.7) \cdot 0.5 \cdot 0.05 + (-0.7) \cdot 1.5 \cdot 0.15 \\ &\quad + 0.3 \cdot (-0.5) \cdot 0.60 \;+ 0.3 \cdot 0.5 \cdot 0.05 \quad + 0.3 \cdot 1.5 \cdot 0.05 \\ &= 0.035 - 0.0175 - 0.1575 - 0.09 + 0.0075 + 0.0225 \\ &= -0.2.\end{aligned} \tag{25.9}$$

Die Kovarianz der Zufallsvariablen ξ_1 und ξ_2 mit der in obiger Tabelle festgelegter Verteilung ist also $\mathbb{C}(\xi_1, \xi_2) = -0.2$. Im Gegensatz zur Varianz kann die Kovarianz also offenbar auch negative Werte annehmen.

△

25.2. Eigenschaften

Wir betrachten im Folgenden einige grundlegende Eigenschaften der Kovarianz.

Theorem 25.1 (Symmetrie von Kovarianz und Korrelation)**.** *ξ_1 und ξ_2 seien zwei Zufallsvariablen mit endlichen zweiten Momenten. Für die Aussage zur Korrelation seien zudem $\mathbb{S}(\xi_1) > 0$ und $\mathbb{S}(\xi_2) > 0$ vorausgesetzt. Dann gelten*

$$\mathbb{C}(\xi_1, \xi_2) = \mathbb{C}(\xi_2, \xi_1) \text{ und } \rho(\xi_1, \xi_2) = \rho(\xi_2, \xi_1). \tag{25.10}$$

∘

Beweis. Mit der Kommutativität der Multiplikation gilt zunächst

$$\mathbb{C}(\xi_1, \xi_2) = \mathbb{E}\left((\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - \mathbb{E}(\xi_2))\right) = \mathbb{E}\left((\xi_2 - \mathbb{E}(\xi_2))(\xi_1 - \mathbb{E}(\xi_1))\right) = \mathbb{C}(\xi_2, \xi_1) \tag{25.11}$$

Weiterhin gilt dann

$$\rho(\xi_1, \xi_2) = \frac{\mathbb{C}(\xi_1, \xi_2)}{\mathbb{S}(\xi_1)\mathbb{S}(\xi_2)} = \frac{\mathbb{C}(\xi_2, \xi_1)}{\mathbb{S}(\xi_2)\mathbb{S}(\xi_1)} = \rho(\xi_2, \xi_1) \tag{25.12}$$

□

Wie das Berechnen von Varianzen wird auch das Berechnen von Kovarianzen manchmal durch folgendes Theorem erleichtert.

Theorem 25.2 (Kovarianzverschiebungssatz)**.** *ξ_1 und ξ_2 seien Zufallsvariablen mit endlichen zweiten Momenten. Dann gilt*

$$\mathbb{C}(\xi_1, \xi_2) = \mathbb{E}(\xi_1\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2). \tag{25.13}$$

∘

Beweis. Mit Definition 25.1 gilt

$$\begin{aligned}
\mathbb{C}(\xi_1, \xi_2) &= \mathbb{E}\left((\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - \mathbb{E}(\xi_2))\right) \\
&= \mathbb{E}\left(\xi_1\xi_2 - \xi_1\mathbb{E}(\xi_2) - \mathbb{E}(\xi_1)\xi_2 + \mathbb{E}(\xi_1)\mathbb{E}(\xi_2)\right) \\
&= \mathbb{E}(\xi_1\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) + \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) \\
&= \mathbb{E}(\xi_1\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2).
\end{aligned} \tag{25.14}$$

□

Natürlich ist Theorem 25.2 nur dann wirklich nützlich, wenn $\mathbb{E}(\xi_1\xi_2)$ leicht zu berechnen sind. Der Varianzverschiebungssatz nach Theorem 24.2 ergibt sich aus Theorem 25.2 für den Fall $\xi_1 = \xi_2 := \xi$ anhand von

$$\mathbb{V}(\xi) = \mathbb{C}(\xi, \xi) = \mathbb{E}(\xi\xi) - \mathbb{E}(\xi)\mathbb{E}(\xi) = \mathbb{E}(\xi^2) - \mathbb{E}(\xi)\mathbb{E}(\xi). \tag{25.15}$$

Auch in Hinblick auf die Kovarianz $\mathbb{C}(\xi_1, \xi_2)$ ist man daran interessiert, wie sich diese unter Anwendung linear-affiner Transformationen auf ξ_2 und ξ_2 verhält. Folgendes Resultat zeigt, dass die Kovarianz zweier Zufallsvariablen von ihrem Maßstab abhängt, die Korrelation dagegen nicht. Dies motiviert den häufigen Einsatz der Korrelation als allgemeines, zwischen verschiedenen Anwendungsszenarien vergleichbares Zusammenhangsmaß.

Theorem 25.3 (Kovarianz und Korrelation bei linear-affinen Transformation)**.** *ξ_1 und ξ_2 seien Zufallsvariablen mit gemeinsamen Ergebnisraum $\mathcal{X}_1 \times \mathcal{X}_2$ und es seien*

$$\begin{aligned} f_1 : \mathcal{X}_1 \to \mathcal{Z}_1, x_1 \mapsto f(x_1) := ax_1 + b \\ f_2 : \mathcal{X}_2 \to \mathcal{Z}_2, x_2 \mapsto f(x_2) := cx_2 + d \end{aligned} \tag{25.16}$$

für $a, b, c, d \in \mathbb{R}$ zwei linear-affine Funktionen. Dann gelten

$$\mathbb{C}(f_1(\xi_1), f(\xi_2)) = \mathbb{C}(a\xi_1 + b, c\xi_2 + d) = ac\mathbb{C}(\xi_1, \xi_2). \tag{25.17}$$

und

$$\rho(f_1(\xi_1), f(\xi_2)) = \rho(a\xi_1 + b, c\xi_2 + d) = \rho(\xi_1, \xi_2). \tag{25.18}$$

∘

Beweis. Es gilt zunächst

$$\begin{aligned} \mathbb{C}(a\xi_1 + b, c\xi_2 + d) &= \mathbb{E}((a\xi_1 + b - \mathbb{E}(a\xi_1 + b))(c\xi_2 + d - \mathbb{E}(c\xi_2 + d))) \\ &= \mathbb{E}((a\xi_1 + b - a\mathbb{E}(\xi_1) - b)(c\xi_2 + d - c\mathbb{E}(\xi_2) - d)) \\ &= \mathbb{E}(a(\xi_1 - \mathbb{E}(\xi_1))(c(\xi_2 - c\mathbb{E}(\xi_2))) \\ &= \mathbb{E}(ac((\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - c\mathbb{E}(\xi_2)))) \\ &= ac\mathbb{C}(\xi_1, \xi_2). \end{aligned} \tag{25.19}$$

Also folgt

$$\begin{aligned} \rho(a\xi_1 + b, c\xi_2 + d) &= \frac{\mathbb{C}(a\xi_1 + b, c\xi_2 + d)}{\sqrt{\mathbb{V}(a\xi_1 + b)}\sqrt{\mathbb{V}(c\xi_2 + d)}} \\ &= \frac{ac\mathbb{C}(\xi_1, \xi_2)}{\sqrt{a^2\mathbb{V}(\xi_1)}\sqrt{c^2\mathbb{V}(\xi_2)}} \\ &= \frac{ac\mathbb{C}(\xi_1, \xi_2)}{a\mathbb{S}(\xi_1)c\mathbb{S}(\xi_2)} \\ &= \frac{\mathbb{C}(\xi_1, \xi_2)}{\mathbb{S}(\xi_1)\mathbb{S}(\xi_2)} \\ &= \rho(\xi_1, \xi_2). \end{aligned} \tag{25.20}$$

□

Mithilfe des Begriffes des Kovarianz ist es möglich, weitgreifenderer Aussagen über die Varianzen von Summen und Differenzen von Zufallsvariablen zu treffen als es in Kapitel 24 der Fall war, wo lediglich die Varianzen von Summen unabhängiger Zufallsvariablen betrachtetet wurden. Mit dem folgenden Theorem untersuchen wir zunächst den sehr allgemeinen Fall der Kovarianz zweier Zufallsvariablen, die sich als Linearkombinationen von n Zufallsvariablen $\xi_1, ..., \xi_n$ und m Zufallsvariablen $\zeta_1, ..., \zeta_m$ unter Addition reeller Konstanten ergeben. Hieraus ergeben sich dann eine Reihe von in der Anwendung, insbesondere in der Klassischen Testtheorie, wichtiger Spezialfälle.

Theorem 25.4 (Kovarianz von Linearkombinationen von Zufallsvariablen)**.** *Gegeben seien n Zufallsvariablen $\xi_1, ..., \xi_n$ und $n+1$ reelle Konstanten $a_0, a_1, ..., a_n$ sowie m Zufallsvariablen $\zeta_1, ..., \zeta_m$ und $m+1$ reelle Konstanten $b_0, b_1, ..., b_m$. Alle genannten Zufallsvariablen besitzen endliche zweite Momente. Dann gilt*

$$\mathbb{C}\left(a_0 + \sum_{i=1}^{n} a_i\xi_i, b_0 + \sum_{j=1}^{m} b_j\zeta_j\right) = \sum_{i=1}^{n}\sum_{j=1}^{m} a_ib_j\mathbb{C}(\xi_i, \zeta_j). \tag{25.21}$$

∘

Beweis.

$$
\begin{aligned}
&\mathbb{C}\left(a_0 + \sum_{i=1}^{n} a_i\xi_i, b_0 + \sum_{j=1}^{m} b_j\zeta_j\right) \\
&= \mathbb{E}\left(\left(a_0 + \sum_{i=1}^{n} a_i\xi_i - \mathbb{E}\left(a_0 + \sum_{i=1}^{n} a_i\xi_i\right)\right)\left(b_0 + \sum_{j=1}^{m} b_j\zeta_j - \mathbb{E}\left(b_0 + \sum_{j=1}^{m} b_j\zeta_j\right)\right)\right) \\
&= \mathbb{E}\left(\left(a_0 + \sum_{i=1}^{n} a_i\xi_i - a_0 - \mathbb{E}\left(\sum_{i=1}^{n} a_i\xi_i\right)\right)\left(b_0 + \sum_{j=1}^{m} b_j\zeta_j - b_0 - \mathbb{E}\left(\sum_{j=1}^{m} b_j\zeta_j\right)\right)\right) \\
&= \mathbb{E}\left(\left(\sum_{i=1}^{n} a_i\xi_i - \sum_{i=1}^{n} a_i\mathbb{E}(\xi_i)\right)\left(\sum_{j=1}^{m} b_j\zeta_j - \sum_{j=1}^{m} b_j\mathbb{E}(\zeta_j)\right)\right) \\
&= \mathbb{E}\left(\sum_{i=1}^{n} a_i\xi_i \sum_{j=1}^{m} b_j\zeta_j - \sum_{i=1}^{n} a_i\xi_i \sum_{j=1}^{m} b_j\mathbb{E}(\zeta_j) - \sum_{i=1}^{n} a_i\mathbb{E}(\xi_i) \sum_{j=1}^{m} b_j\zeta_j + \sum_{i=1}^{n} a_i\mathbb{E}(\xi_i) \sum_{j=1}^{m} b_j\mathbb{E}(\zeta_j)\right) \\
&= \mathbb{E}\left(\sum_{i=1}^{n} a_i\xi_i \sum_{j=1}^{m} b_j\zeta_j\right) - \mathbb{E}\left(\sum_{i=1}^{n} a_i\xi_i \sum_{j=1}^{m} b_j\mathbb{E}(\zeta_j)\right) - \mathbb{E}\left(\sum_{i=1}^{n} a_i\mathbb{E}(\xi_i) \sum_{j=1}^{m} b_j\zeta_j\right) + \mathbb{E}\left(\sum_{i=1}^{n} a_i\mathbb{E}(\xi_i) \sum_{j=1}^{m} b_j\mathbb{E}(\zeta_j)\right) \\
&= \sum_{i=1}^{n}\sum_{j=1}^{m} a_ib_j\mathbb{E}(\xi_i\zeta_j) - 2\sum_{i=1}^{n}\sum_{j=1}^{m} a_ib_j\mathbb{E}(\xi_i)\mathbb{E}(\zeta_j) + \sum_{i=1}^{n}\sum_{j=1}^{m} a_ib_j\mathbb{E}(\xi_i)\mathbb{E}(\zeta_j) \\
&= \sum_{i=1}^{n}\sum_{j=1}^{m} a_ib_j\left(\mathbb{E}(\xi_i\zeta_j) - 2\mathbb{E}(\xi_i)\mathbb{E}(\zeta_j) + \mathbb{E}(\xi_i)\mathbb{E}(\zeta_j)\right) \\
&= \sum_{i=1}^{n}\sum_{j=1}^{m} a_ib_j\mathbb{E}\left((\xi_i - \mathbb{E}(\xi_i))(\zeta_j - \mathbb{E}(\zeta_j))\right) \\
&= \sum_{i=1}^{n}\sum_{j=1}^{m} a_ib_j\mathbb{C}(\xi_i, \zeta_j)
\end{aligned}
$$

□

Mit folgenden Theorem betrachten wir nun einen ersten Spezialfall von Theorem 25.4.

Theorem 25.5 (Kovarianz bei paarweiser Addition von Zufallsvariablen)**.** $\xi_1, \xi_2, \zeta_1, \zeta_2$ *seien vier Zufallsvariablen mit endlichen zweiten Momenten. Dann gilt*

$$\mathbb{C}(\xi_1 + \xi_2, \zeta_1 + \zeta_2) = \mathbb{C}(\xi_1, \zeta_1) + \mathbb{C}(\xi_1, \zeta_2) + \mathbb{C}(\xi_2, \zeta_1) + \mathbb{C}(\xi_2, \zeta_2). \tag{25.22}$$

∘

Beweis. Es seien $n := 2, m := 2, a_0 = b_0 := 0$ und $a_i = b_i := 1$ für $i = 1, 2$. Dann gilt mit Theorem 25.4

$$
\begin{aligned}
\mathbb{C}\left(\xi_1 + \xi_2, \zeta_1 + \zeta_2\right) &= \mathbb{C}\left(a_0 + \sum_{i=1}^{2} a_i\xi_i, b_0 + \sum_{j=1}^{2} b_j\zeta_j\right) \\
&= \sum_{i=1}^{2}\sum_{j=1}^{2} a_ib_j\mathbb{C}\left(\xi_i, \zeta_j\right) \\
&= \sum_{i=1}^{2}\sum_{j=1}^{2} \mathbb{C}\left(\xi_i, \zeta_j\right) \\
&= \mathbb{C}\left(\xi_1, \zeta_1\right) + \mathbb{C}\left(\xi_1, \zeta_2\right) + \mathbb{C}\left(\xi_2, \zeta_1\right) + \mathbb{C}\left(\xi_2, \zeta_2\right).
\end{aligned} \tag{25.23}
$$

□

Folgendes Theorem besagt nun, wie man im Allgemeinen die Varianz einer Linearkombinationen von Zufallsvariablen unter Addition einer Konstante bestimmt werden kann.

Theorem 25.6 (Varianz einer Linearkombination von Zufallsvariablen)**.** *Gegeben seien n Zufallsvariablen $\xi_1, ..., \xi_n$ und $n+1$ reelle Konstanten $a_0, a_1, ..., a_n$. Dann gilt*

$$\mathbb{V}\left(a_0 + \sum_{i=1}^{n} a_i \xi_i\right) = \sum_{i=1}^{n} a_i^2 \mathbb{V}(\xi_i) + 2 \sum_{i=1}^{n-1} \sum_{j=i+1}^{n} a_i a_j \mathbb{C}(\xi_i, \xi_j). \tag{25.24}$$

∘

Beweis. Mit $\mathbb{V}(\xi) = \mathbb{C}(\xi, \xi)$ und Theorem 25.4 gilt zunächst

$$\begin{aligned}
\mathbb{V}\left(a_0 + \sum_{i=1}^{n} a_i \xi_i\right) &= \mathbb{C}\left(a_0 + \sum_{i=1}^{n} a_i \xi_i, a_0 + \sum_{i=1}^{n} a_i \xi_i\right) \\
&= \mathbb{C}\left(a_0 + \sum_{i=1}^{n} a_i \xi_i, a_0 + \sum_{j=1}^{n} a_j \xi_j\right) \\
&= \sum_{i=1}^{n} \sum_{j=1}^{n} a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{i=1}^{n} \sum_{\substack{j=1 \\ j=i}}^{n} a_i a_j \mathbb{C}(\xi_i, \xi_j) + \sum_{i=1}^{n} \sum_{\substack{j=1 \\ j \neq i}}^{n} a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{i=1}^{n} a_i a_i \mathbb{C}(\xi_i, \xi_i) + \sum_{i=1}^{n} \sum_{\substack{j=1 \\ j \neq i}}^{n} a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{i=1}^{n} a_i^2 \mathbb{V}(\xi_i) + \sum_{i=1}^{n} \sum_{\substack{j=1 \\ j \neq i}}^{n} a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{i=1}^{n} a_i^2 \mathbb{V}(\xi_i) + 2 \sum_{i=1}^{n-1} \sum_{j=i+1}^{n} a_i a_j \mathbb{C}(\xi_i, \xi_j),
\end{aligned} \tag{25.25}$$

Dabei wurde in der vierten Gleichung die Doppelsumme in solche Terme aufgespalten für die $i = j$ und für die $i \neq j$ und in der siebten Gleichung ausgenutzt, dass

$$a_i a_j \mathbb{C}(\xi_i, \xi_j) = a_j a_i \mathbb{C}(\xi_j, \xi_i). \tag{25.26}$$

Wir verdeutlichen die daraus folgende Identität

$$\sum_{i=1}^{n} \sum_{\substack{j=1 \\ j \neq i}}^{n} a_i a_j \mathbb{C}(\xi_i, \xi_j) = 2 \sum_{i=1}^{n-1} \sum_{j=i+1}^{n} a_i a_j \mathbb{C}(\xi_i, \xi_j), \tag{25.27}$$

am Beispiel $n = 3$ untenstehend. Analog mag man sich vorstellen, über alle Elemente außer der Diagonalelemente der $i = 1, ..., n$ Zeilen und $j = 1, ..., n$ Spalten einer symmetrischen Matrix mit Einträgen $a_i a_j \mathbb{C}(\xi_i, \xi_j)$ zu summieren. Die linke Seite oberer Gleichung entspricht dann dem zeilenweisen Vorgehen der Summationsbildung für alle Spalteneinträge außer dem, der in der Spalte der jeweils betrachteten Zeile steht, d.h. dem Diagonaleintrag. Die rechte Seite der obigen Gleichung entspricht dann dem Vorgehen, die Symmetrie der Matrix auszunutzen, also die Tatsache zu berücksichtigen, dass die Einträge der Matrix rechts oberhalb und links unterhalb der Diagonalen identisch sind, so dass es genügt, die Einträge der oberen Dreieckshälfte ohne Diagonale aufzuaddieren und zu verdoppeln. Dabei werden für jede Zeile $i = 1, ..., n$ nur gerade die Spalten $j = i + 1, ..., n$ betrachtet, die rechts von der Diagonale stehen und ihre Einträge aufsummiert. In der letzten Zeile steht dabei nur ein Diagonalelement, das nicht zur Summe

gehört, weshalb der Index der äußeren Summe nur bis $n-1$ läuft. Konkret ergibt sich für $n := 3$

$$\begin{aligned}
&\sum_{i=1}^{3}\sum_{\substack{j=1\\j\neq i}}^{3} a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{\substack{j=1\\j\neq 1}}^{3} a_1 a_j \mathbb{C}(\xi_1, \xi_j) + \sum_{\substack{j=1\\j\neq 2}}^{3} a_2 a_j \mathbb{C}(\xi_2, \xi_j) + \sum_{\substack{j=1\\j\neq 3}}^{3} a_3 a_j \mathbb{C}(\xi_3, \xi_j) \\
&= a_1 a_2 \mathbb{C}(\xi_1, \xi_2) + a_1 a_3 \mathbb{C}(\xi_1, \xi_3) + a_2 a_1 \mathbb{C}(\xi_2, \xi_1) + a_2 a_3 \mathbb{C}(\xi_2, \xi_3) + a_3 a_1 \mathbb{C}(\xi_3, \xi_1) + a_3 a_2 \mathbb{C}(\xi_3, \xi_2) \\
&= a_1 a_2 \mathbb{C}(\xi_1, \xi_2) + a_2 a_1 \mathbb{C}(\xi_2, \xi_1) + a_1 a_3 \mathbb{C}(\xi_1, \xi_3) + a_3 a_1 \mathbb{C}(\xi_3, \xi_1) + a_2 a_3 \mathbb{C}(\xi_2, \xi_3) + a_3 a_2 \mathbb{C}(\xi_3, \xi_2) \\
&= 2a_1 a_2 \mathbb{C}(\xi_1, \xi_2) + 2a_1 a_3 \mathbb{C}(\xi_1, \xi_3) + 2a_2 a_3 \mathbb{C}(\xi_2, \xi_3) \\
&= 2\left(a_1 a_2 \mathbb{C}(\xi_1, \xi_2) + a_1 a_3 \mathbb{C}(\xi_1, \xi_3) + a_2 a_3 \mathbb{C}(\xi_2, \xi_3)\right) \\
&= 2\left(\sum_{j=2}^{3} a_1 a_j \mathbb{C}(\xi_1, \xi_j) + \sum_{j=3}^{3} a_2 a_j \mathbb{C}(\xi_2, \xi_j)\right) \\
&= 2\left(\sum_{j=1+1}^{3} a_1 a_j \mathbb{C}(\xi_1, \xi_j) + \sum_{j=2+1}^{3} a_2 a_j \mathbb{C}(\xi_2, \xi_j)\right) \\
&= 2\sum_{i=1}^{2}\sum_{j=i+1}^{3} a_i a_j \mathbb{C}(\xi_i, \xi_j).
\end{aligned} \tag{25.28}$$

□

Theorem 25.7 (Varianzen spezieller Linearkombinationen von Zufallsvariablen)**.**

(1) (Varianz bei Addition zweier Zufallsvariablen). Gegeben seien zwei Zufallsvariablen ξ und ζ. Dann gilt

$$\mathbb{V}(\xi + \zeta) = \mathbb{V}(\xi) + \mathbb{V}(\zeta) + 2\mathbb{C}(\xi, \zeta) \tag{25.29}$$

(2) (Varianz bei Subtraktion zweier Zufallsvariablen). Gegeben seien zwei Zufallsvariablen ξ und ζ. Dann gilt

$$\mathbb{V}(\xi - \zeta) = \mathbb{V}(\xi) + \mathbb{V}(\zeta) - 2\mathbb{C}(\xi, \zeta) \tag{25.30}$$

∘

Beweis. Es seien $n := 2$, $\xi_1 := \xi$, $\xi_2 := \zeta$, $a_0 := 0$, $a_1 := 1$ und $a_2 := 1$. Dann gilt mit Theorem 25.6

$$\begin{aligned}
\mathbb{V}(\xi + \zeta) &= \mathbb{V}(a_0 + a_1\xi_1 + a_2\xi_2) \\
&= \mathbb{V}\left(a_0 + \sum_{i=1}^{2} a_i \xi_i\right) \\
&= \sum_{i=1}^{2} a_i^2 \mathbb{V}(\xi_i) + 2\sum_{i=1}^{2-1}\sum_{j=i+1}^{2} a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{i=1}^{2} a_i^2 \mathbb{V}(\xi_i) + 2\sum_{i=1}^{1}\sum_{j=i+1}^{2} a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{i=1}^{2} a_i^2 \mathbb{V}(\xi_i) + 2\sum_{j=1+1}^{2} a_1 a_j \mathbb{C}(\xi_1, \xi_j) \\
&= \sum_{i=1}^{2} a_i^2 \mathbb{V}(\xi_i) + 2\sum_{j=2}^{2} a_1 a_j \mathbb{C}(\xi_1, \xi_j) \\
&= a_1^2 \mathbb{V}(\xi_1) + a_2^2 \mathbb{V}(\xi_2) + 2a_1 a_2 \mathbb{C}(\xi_1, \xi_2) \\
&= 1^2 \cdot \mathbb{V}(\xi) + 1^2 \cdot \mathbb{V}(\zeta) + 2 \cdot 1 \cdot 1 \cdot \mathbb{C}(\xi, \zeta) \\
&= \mathbb{V}(\xi) + \mathbb{V}(\zeta) + 2\mathbb{C}(\xi, \zeta).
\end{aligned} \tag{25.31}$$

Es seien nun $n \coloneqq 2$, $\xi_1 \coloneqq \xi$, $\xi_2 \coloneqq \zeta$, $a_0 \coloneqq 0$, $a_1 \coloneqq 1$ und $a_2 \coloneqq -1$. Dann gilt mit dem Theorem 25.6

$$\begin{aligned}
\mathbb{V}(\xi - \zeta) &= \mathbb{V}(a_0 + a_1\xi_1 + a_2\xi_2) \\
&= \mathbb{V}\left(a_0 + \sum_{i=1}^{2} a_i\xi_i\right) \\
&= \sum_{i=1}^{2} a_i^2\mathbb{V}(\xi_i) + 2\sum_{i=1}^{2-1}\sum_{j=i+1}^{2} a_i a_j\mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{i=1}^{2} a_i^2\mathbb{V}(\xi_i) + 2\sum_{i=1}^{1}\sum_{j=i+1}^{2} a_i a_j\mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{i=1}^{2} a_i^2\mathbb{V}(\xi_i) + 2\sum_{j=1+1}^{2} a_1 a_j\mathbb{C}(\xi_1, \xi_j) \\
&= \sum_{i=1}^{2} a_i^2\mathbb{V}(\xi_i) + 2\sum_{j=2}^{2} a_1 a_j\mathbb{C}(\xi_1, \xi_j) \\
&= a_1^2\mathbb{V}(\xi_1) + a_2^2\mathbb{V}(\xi_2) + 2a_1a_2\mathbb{C}(\xi_1, \xi_2) \\
&= 1^2 \cdot \mathbb{V}(\xi) + (-1)^2 \cdot \mathbb{V}(\zeta) + 2 \cdot 1 \cdot (-1) \cdot \mathbb{C}(\xi, \zeta) \\
&= \mathbb{V}(\xi) + \mathbb{V}(\zeta) - 2\mathbb{C}(\xi, \zeta).
\end{aligned} \tag{25.32}$$

Alternativ gilt ohne Rückgriff auf Theorem 25.6 und mit Theorem 23.2, dass

$$\begin{aligned}
&\mathbb{V}(a\xi + b\zeta + c) \\
&= \mathbb{E}\left((a\xi + b\zeta + c - a\mathbb{E}(\xi) - b\mathbb{E}(\zeta) - c)^2\right) \\
&= \mathbb{E}\left((a(\xi - \mathbb{E}(\xi)) + b(\zeta - \mathbb{E}(\zeta)))^2\right) \\
&= \mathbb{E}\left(a^2(\xi - \mathbb{E}(\xi))^2 + 2ab(\xi - \mathbb{E}(\xi))(\zeta - \mathbb{E}(\zeta)) + b^2(\zeta - \mathbb{E}(\zeta))^2\right) \\
&= a^2\mathbb{E}\left((\xi - \mathbb{E}(\xi))^2\right) + b^2\mathbb{E}\left((\zeta - \mathbb{E}(\zeta))^2\right) + 2ab\mathbb{E}\left((\xi - \mathbb{E}(\xi))(\zeta - \mathbb{E}(\zeta))\right) \\
&= a^2\mathbb{V}(\xi) + b^2\mathbb{V}(\zeta) + 2ab\mathbb{C}(\xi, \zeta).
\end{aligned} \tag{25.33}$$

Die Spezialfälle folgen dann direkt mit $a \coloneqq b \coloneqq 1$ und $a \coloneqq 1, b \coloneqq -1$, respektive. □

Schließlich wollen wir mit Theorem 13.12 einen ersten Eindruck zum Zusammenhang von Kovarianz und Korrelation mit dem Begriff der Unabhängigkeit von Zufallsvariablen erlangen. Es zeigt sich, dass Kovarianz und Korrelation lediglich für bestimmte Formen der Abhängigkeit von Zufallsvariablen sensitiv sind und insbesondere, dass von einer Kovarianz von null nicht auf die Unabhängigkeit der Zufallsvariablen geschlossen werden kann. Anderseits impliziert die Unabhängigkeit zweier Zufallsvariablen immer, dass ihre Kovarianz null und sie damit unkorreliert sind. Abhängigkeit und Unabhängigkeit von Zufallsvariablen sind also sehr viel allgemeinere Begrifflichkeiten zur Beschreibung des Zusammenhangs von Zufallsvariablen als Kovarianz und Korrelation.

Theorem 25.8 (Korrelation und Unabhängigkeit von Zufallsvariablen)**.** *ξ_1 und ξ_2 seien zwei Zufallsvariablen. Wenn ξ_1 und ξ_2 unabhängig sind, dann ist $\mathbb{C}(\xi_1, \xi_2) = 0$ und ξ_1 und ξ_2 sind folglich unkorreliert. Ist dagegen $\mathbb{C}(\xi_1, \xi_2) = 0$ und sind ξ_1 und ξ_2 somit unkorreliert, dann sind ξ_1 und ξ_2 nicht notwendigerweise unabhängig.*

∘

Beweis. Wir zeigen in einem ersten Schritt, dass aus der Unabhängigkeit von ξ_1 und ξ_2 $\mathbb{C}(\xi_1, \xi_2) = 0$ folgt. Wir zeigen dann durch Angabe eines Beispiels, dass die Kovarianz von abhängigen Zufallsvariablen ξ_1 und ξ_2 durchaus null sein kann.

(1) Wir zeigen, dass aus der Unabhängigkeit von ξ_1 und ξ_2 $\mathbb{C}(\xi_1, \xi_2) = 0$ folgt. Hierzu halten wir als erstes fest, dass für unabhängige Zufallsvariablen gilt, dass

$$\mathbb{E}(\xi_1\xi_2) = \mathbb{E}(\xi_1)\mathbb{E}(\xi_2). \tag{25.34}$$

Mit dem Kovarianzverschiebungssatz folgt dann

$$\mathbb{C}(\xi_1, \xi_2) = \mathbb{E}(\xi_1\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) = \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) = 0. \tag{25.35}$$

Mit der Definition des Korrelationskoeffizienten folgt dann, dass $\rho(\xi_1, \xi_2) = 0$ ist und ξ_1 und ξ_2 somit unkorreliert sind.

(2) Wir zeigen nun durch Angabe eines Beispiels, dass die Kovarianz von abhängigen Zufallsvariablen ξ_1 und ξ_2 null sein kann. Zu diesem Zweck betrachten wir den Fall zweier diskreter Zufallsvariablen ξ_1 und ξ_2 mit Ergebnisräumen $\mathcal{X}_1 = \{-1, 0, 1\}$ und $\mathcal{X}_2 = \{0, 1\}$, marginaler WMF von ξ_1 gegeben durch $p(x_1) := \frac{1}{3}$ für alle $x_1 \in \mathcal{X}_1$ und der Definition von

$$\xi_2 := \xi_1^2. \tag{25.36}$$

Die Definition von ξ_2 impliziert dann die in Tabelle 25.2 gezeigte bedingte WMF.

Tabelle 25.2. Bedingte WMF zum Beweis von Theorem 25.8

$p(x_2\|x_1)$	$x_1 = -1$	$x_1 = 0$	$x_1 = 1$
$x_2 = 0$	0	1	0
$x_2 = 1$	1	0	1

Die marginale WMF $p(x_1)$ und die bedingte WMF $p(x_2|x_1)$ implizieren dann die in Tabelle 25.3 gezeigte gemeinsame WMF.

Tabelle 25.3. Gemeinsame WMF zum Beweis von Theorem 25.8

$p(x_1, x_2)$	$x_1 = -1$	$x_1 = 0$	$x_1 = 1$	$p(x_2)$
$x_2 = 0$	0	1/3	0	1/3
$x_2 = 1$	1/3	0	1/3	2/3
$p(x_1)$	1/3	1/3	1/3	

Anhand von Tabelle 25.3 gilt also zum Beispiel

$$p(-1, 0) = 0 \neq \frac{1}{9} = \frac{1}{3} \cdot \frac{1}{3} = p(-1)p(0). \tag{25.37}$$

Die gemeinsame WMF von ξ_1 und ξ_2 faktorisiert also nicht und ξ_1 und ξ_2 sind damit nicht unabhängig. Allerdings folgt mit

$$\mathbb{E}(\xi_1) = \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1) = -1 \cdot \frac{1}{3} + 0 \cdot \frac{1}{3} + 1 \cdot \frac{1}{3} = 0 \tag{25.38}$$

und

$$\mathbb{E}(\xi_1\xi_2) = \mathbb{E}(\xi_1\xi_1^2) = \mathbb{E}(\xi_1^3) = \sum_{x_1 \in \mathcal{X}_1} x_1^3 p(x_1) = -1^3 \cdot \frac{1}{3} + 0^3 \cdot \frac{1}{3} + 1^3 \cdot \frac{1}{3} = 0, \tag{25.39}$$

sowie dem Kovarianzverschiebungssatz, dass

$$\mathbb{C}(\xi_1, \xi_2) = \mathbb{E}(\xi_1\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) = \mathbb{E}(\xi_1^3) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) = 0 - 0 \cdot \mathbb{E}(\xi_2) = 0. \tag{25.40}$$

Die Kovarianz von ξ_1 und ξ_2 ist also null und ξ_1 und ξ_2 damit unkorreliert, obwohl ξ_1 und ξ_2 nicht unabhängig sind. □

25.3. Bedingte Kovarianz

Wie den Erwartungswert und die Varianz kann man auch die Kovarianz in einer bedingten gemeinsamen Verteilung zweier Zufallsvariablen betrachten. Dies führt auf den Begriff der *bedingten Kovarianz*.

Definition 25.2 (Bedingte Kovarianz)**.** Gegeben sei ein Zufallsvektor $\xi := (\xi_1, \xi_2, \xi_3)$ mit Ergebnisraum $\mathcal{X} := \mathcal{X}_1 \times \mathcal{X}_2 \times \mathcal{X}_3$ und gemeinsamer WMF oder WDF $p(x_1, x_2, x_3)$. Für einen Bedingungswert x_3 mit positiver marginaler WMF bzw. WDF sei $p(x_1, x_2|x_3)$ die entsprechende bedingte WMF bzw. WDF. Es gelte $\mathbb{E}(\xi_1^2|\xi_3 = x_3) < \infty$ und $\mathbb{E}(\xi_2^2|\xi_3 = x_3) < \infty$. Dann ist die bedingte Kovarianz von ξ_1 und ξ_2 gegeben $\xi_3 = x_3$ definiert als

$$\mathbb{C}(\xi_1, \xi_2|\xi_3 = x_3) := \mathbb{E}\left((\xi_1 - \mathbb{E}\left(\xi_1|\xi_3 = x_3\right))\left(\xi_2 - \mathbb{E}\left(\xi_2|\xi_3 = x_3\right)\right)|\xi_3 = x_3\right) \tag{25.41}$$

•

Die bedingte Kovarianz ist der Erwartungswert des Produkts der bedingt zentrierten Zufallsvariablen in ihrer bedingten gemeinsamen Verteilung. Für einen festen Bedingungswert x_3 ist sie eine feste Zahl. Als Funktion der Zufallsvariablen ξ_3 ergibt sich dagegen die Zufallsvariable $\mathbb{C}(\xi_1, \xi_2|\xi_3)$. Auch für die bedingte Kovarianz gilt ein Verschiebungssatz.

Theorem 25.9 (Verschiebungssatz der bedingten Kovarianz)**.** *Gegeben sei ein Zufallsvektor $\xi := (\xi_1, \xi_2, \xi_3)$, wobei ξ_1 und ξ_2 endliche zweite Momente besitzen. Dann gilt fast sicher*

$$\mathbb{C}(\xi_1, \xi_2|\xi_3) = \mathbb{E}\left(\xi_1\xi_2|\xi_3\right) - \mathbb{E}\left(\xi_1|\xi_3\right)\mathbb{E}\left(\xi_2|\xi_3\right). \tag{25.42}$$

∘

Beweis. Ein Beweis ergibt sich durch die Ersetzung der entsprechenden Erwartungswerte im Beweis von Theorem 25.2 durch die entsprechenden bedingten Erwartungswerte. □

25.4. Kovarianzmatrizen

Das multivariate Analogon der Varianz einer Zufallsvariable ist die *Kovarianzmatrix eines Zufallsvektors*. Diese enkodiert neben den Varianzen der Komponenten des Zufallsvektors auch ihre paarweisen Kovarianzen und ist wie folgt definiert.

Definition 25.3 (Kovarianzmatrix eines Zufallsvektors)**.** ξ sei ein n-dimensionaler Zufallsvektor. Dann ist die *Kovarianzmatrix* von ξ definiert als die $n \times n$ Matrix

$$\mathbb{C}(\xi) := \mathbb{E}\left((\xi - \mathbb{E}(\xi))(\xi - \mathbb{E}(\xi))^T\right). \tag{25.43}$$

•

Die Kovarianzmatrix ist in Definition 25.3 formal analog zur Kovarianz zweier Zufallsvariablen definiert. Eine direkte Rückführung des Begriffs der Kovarianzmatrix eines Zufallsvektors auf den Begriff aus dem univariaten Kontext bekannten Begriff der Kovarianz zweier Zufallsvariablen erlaubt folgendesTheorem.

Theorem 25.10 (Eigenschaften der Kovarianzmatrix)**.** *ξ sei ein m-dimensionaler Zufallsvektor und $\mathbb{C}(\xi)$ sei seine Kovarianzmatrix. Dann gelten*

(1) (Elemente) Die Elemente von $\mathbb{C}(\xi)$ sind die Kovarianzen der Komponenten von ξ,

$$\mathbb{C}(\xi) = \left(\mathbb{C}(\xi_i, \xi_j)\right)_{1 \leq i,j \leq m}. \tag{25.44}$$

(2) (Kovarianzmatrixverschiebungssatz) Es gilt

$$\mathbb{C}(\xi) = \mathbb{E}\left(\xi\xi^T\right) - \mathbb{E}(\xi)\mathbb{E}(\xi)^T. \tag{25.45}$$

(3) (Linear-affine Transformation) Für $A \in \mathbb{R}^{n \times m}$ und $b \in \mathbb{R}^n$ gilt

$$\mathbb{C}(A\xi + b) = A\mathbb{C}(\xi)A^T. \tag{25.46}$$

(4) (Matrixeigenschaften) $\mathbb{C}(\xi)$ ist symmetrisch und positiv-semidefinit.

∘

Beweis. (1) Es gilt

$$\begin{aligned}
\mathbb{C}(\xi) &:= \mathbb{E}\left((\xi - \mathbb{E}(\xi))(\xi - \mathbb{E}(\xi))^T\right) \\
&= \mathbb{E}\left(\left(\begin{pmatrix}\xi_1\\ \vdots \\ \xi_n\end{pmatrix} - \begin{pmatrix}\mathbb{E}(\xi_1)\\ \vdots \\ \mathbb{E}(\xi_n)\end{pmatrix}\right)\left(\begin{pmatrix}\xi_1\\ \vdots \\ \xi_n\end{pmatrix} - \begin{pmatrix}\mathbb{E}(\xi_1)\\ \vdots \\ \mathbb{E}(\xi_n)\end{pmatrix}\right)^T\right) \\
&= \mathbb{E}\left(\begin{pmatrix}\xi_1 - \mathbb{E}(\xi_1)\\ \vdots \\ \xi_n - \mathbb{E}(\xi_n)\end{pmatrix}\begin{pmatrix}\xi_1 - \mathbb{E}(\xi_1)\\ \vdots \\ \xi_n - \mathbb{E}(\xi_n)\end{pmatrix}^T\right) \\
&= \mathbb{E}\left(\begin{pmatrix}\xi_1 - \mathbb{E}(\xi_1)\\ \vdots \\ \xi_n - \mathbb{E}(\xi_n)\end{pmatrix}\begin{pmatrix}\xi_1 - \mathbb{E}(\xi_1) & \dots & \xi_n - \mathbb{E}(\xi_n)\end{pmatrix}\right) \\
&= \mathbb{E}\begin{pmatrix}(\xi_1 - \mathbb{E}(\xi_1))(\xi_1 - \mathbb{E}(\xi_1)) & \dots & (\xi_1 - \mathbb{E}(\xi_1))(\xi_n - \mathbb{E}(\xi_n)\\ \vdots & \ddots & \vdots \\ (\xi_n - \mathbb{E}(\xi_n))(\xi_1 - \mathbb{E}(\xi_1)) & \dots & (\xi_n - \mathbb{E}(\xi_n))(\xi_n - \mathbb{E}(\xi_n))\end{pmatrix} \\
&= \left(\mathbb{E}\left((\xi_i - \mathbb{E}(\xi_i))(\xi_j - \mathbb{E}(\xi_j))\right)\right)_{1 \leq i,j \leq n} \\
&= \left(\mathbb{C}(\xi_i, \xi_j)\right)_{1 \leq i,j \leq n}.
\end{aligned} \tag{25.47}$$

(2) Mit den Eigenschaften von Erwartungswerten gilt

$$\begin{aligned}
\mathbb{C}(\xi) &= \mathbb{E}\left((\xi - \mathbb{E}(\xi))(\xi - \mathbb{E}(\xi))^T\right) \\
&= \mathbb{E}\left(\xi\xi^T - \xi\mathbb{E}(\xi)^T - \mathbb{E}(\xi)\xi^T + \mathbb{E}(\xi)\mathbb{E}(\xi)^T\right) \\
&= \mathbb{E}\left(\xi\xi^T\right) - \mathbb{E}(\xi)\mathbb{E}(\xi)^T - \mathbb{E}(\xi)\mathbb{E}(\xi)^T + \mathbb{E}(\xi)\mathbb{E}(\xi)^T \\
&= \mathbb{E}\left(\xi\xi^T\right) - \mathbb{E}(\xi)\mathbb{E}(\xi)^T.
\end{aligned} \tag{25.48}$$

(3) Mit den Eigenschaften von Erwartungswerten gilt

$$\begin{aligned}
\mathbb{C}(A\xi + b) &= \mathbb{E}\left((A\xi + b - \mathbb{E}(A\xi + b))(A\xi + b - \mathbb{E}(A\xi + b))^T\right) \\
&= \mathbb{E}\left((A\xi + b - A\mathbb{E}(\xi) - b)(A\xi + b - A\mathbb{E}(\xi) - b)^T\right) \\
&= \mathbb{E}\left((A(\xi - \mathbb{E}(\xi)))(A(\xi - \mathbb{E}(\xi)))^T\right) \\
&= \mathbb{E}\left(A(\xi - \mathbb{E}(\xi))(\xi - \mathbb{E}(\xi))^T A^T\right) \\
&= A\mathbb{E}\left((\xi - \mathbb{E}(\xi))(\xi - \mathbb{E}(\xi))^T\right) A^T \\
&= A\mathbb{C}(\xi)A^T.
\end{aligned} \tag{25.49}$$

(4) Die Symmetrie von $\mathbb{C}(\xi)$ folgt aus der Symmetrie der Kovarianz einer Zufallsvariable mit

$$\mathbb{C}(\xi_i, \xi_j) = \mathbb{C}(\xi_j, \xi_i) \text{ für alle } i = 1, ..., m, j = 1, ..., m. \tag{25.50}$$

Um die positive Semidefinitheit von $\mathbb{C}(\xi)$ nachzuweisen, ist zu zeigen, dass $a^T\mathbb{C}(\xi)a \geq 0$ für alle $a \in \mathbb{R}^m$ mit $a \neq 0_m$. Sei also $a \in \mathbb{R}^m$ mit $a \neq 0$. Dann gilt mit Aussage (3) für $A := a^T \in \mathbb{R}^{1\times m}$, dass

$$a^T\mathbb{C}(\xi)a = \mathbb{C}(a^T\xi). \tag{25.51}$$

Weiterhin gilt mit der Definition der Kovarianzmatrix aber, dass

$$\mathbb{C}(a^T\xi) = \mathbb{E}\left((a^T\xi - \mathbb{E}(a^T\xi))^2\right) = \mathbb{V}\left(a^T\xi\right). \tag{25.52}$$

Da mit den Eigenschaften der Varianz die Varianz der Zufallsvariable $a^T\xi$ aber immer nichtnegativ ist, folgt

$$a^T\mathbb{C}(\xi)a = \mathbb{V}(a^T\xi) \geq 0 \tag{25.53}$$

und damit die positive Semidefinitheit von $\mathbb{C}(\xi)$. □

Die Diagonalelemente von $\mathbb{C}(\xi)$ sind die Varianzen der Komponenten von ξ, da

$$\mathbb{V}(\xi_i) = \mathbb{C}(\xi_i, \xi_i) \text{ für } i = 1, ...m. \tag{25.54}$$

Eigenschaften (2) und (3) sind im Wesentlichen analog zu den Eigenschaften der Varianz.

Die Kovarianzmatrix eines Zufallsvektors ξ ist also die Matrix der Kovarianzen der Komponenten von ξ. Damit ist auch die Kovarianzmatrix direkt im Sinne des Begriffs der Kovarianz von Zufallsvektoren gegeben. Da die Kovarianz einer Zufallsvariable mit sich selbst bekanntlich ihre Varianz ist, enthält die Kovarianzmatrix auf ihrer Diagonalen die Varianzen der Komponenten von ξ.

Folgendes Theorem dokumentiert eine Schreibweise für die Kovarianzmatrix eines partitionierten Zufallsvektors im Sinne von Erwartungswerten von Zufallsvektorprodukten an, die zum Beispiel im Rahmen der Kanonischen Korrelationsanalyse hilfreich ist.

Theorem 25.11 (Kovarianzmatrizen von Zufallsvektoren)**.** *Es seien*

$$\zeta = \begin{pmatrix} \xi \\ \upsilon \end{pmatrix} \text{ mit } \mathbb{E}(\zeta) := 0_m \tag{25.55}$$

ein $m_\xi + m_\upsilon$-dimensionaler Zufallsvektor und sein Erwartungswertvektor, respektive. Dann kann die $m \times m$ Kovarianzmatrix von ζ geschrieben werden als

$$\mathbb{C}(\zeta) = \begin{pmatrix} \Sigma_{\xi\xi} & \Sigma_{\xi_1\xi_2} \\ \Sigma_{\upsilon\xi} & \Sigma_{\upsilon\upsilon} \end{pmatrix} \in \mathbb{R}^{m\times m} \tag{25.56}$$

wobei

$$\begin{aligned} \Sigma_{\xi\xi} &:= \mathbb{E}\left(\xi\xi^T\right) \in \mathbb{R}^{m_\xi \times m_\xi} \\ \Sigma_{\xi_1\xi_2} &:= \mathbb{E}\left(\xi_1\xi_2^T\right) \in \mathbb{R}^{m_\xi \times m_\upsilon} \\ \Sigma_{\upsilon\xi} &:= \mathbb{E}\left(\upsilon\xi^T\right) \in \mathbb{R}^{m_\upsilon \times m_\xi} \\ \Sigma_{\upsilon\upsilon} &:= \mathbb{E}\left(\upsilon\upsilon^T\right) \in \mathbb{R}^{m_\xi \times m_\upsilon} \end{aligned} \tag{25.57}$$

∘

Beweis. Nach Definition der Kovarianzmatrix eines Zufallsvektors gilt

$$\begin{aligned}
\mathbb{C}(z) &= \mathbb{E}\left((\zeta - \mathbb{E}(\zeta))(\zeta - \mathbb{E}(\zeta))^T\right) \\
&= \mathbb{E}\left((\zeta - 0_m)(\zeta - 0_m)^T\right) \\
&= \mathbb{E}\left(\zeta\zeta^T\right) \\
&= \mathbb{E}\left(\begin{pmatrix}\xi \\ \upsilon\end{pmatrix}\begin{pmatrix}\xi^T & \upsilon^T\end{pmatrix}\right) \\
&= \mathbb{E}\left(\begin{pmatrix}\xi\xi^T & \xi_1\xi_2^T \\ \upsilon\xi^T & \upsilon\upsilon^T\end{pmatrix}\right) \\
&= \begin{pmatrix}\mathbb{E}\left(\xi\xi^T\right) & \mathbb{E}\left(\xi_1\xi_2^T\right) \\ \mathbb{E}\left(\upsilon\xi^T\right) & \mathbb{E}\left(\upsilon\upsilon^T\right)\end{pmatrix} \\
&= \begin{pmatrix}\Sigma_{\xi\xi} & \Sigma_{\xi_1\xi_2} \\ \Sigma_{\upsilon\xi} & \Sigma_{\upsilon\upsilon}\end{pmatrix}
\end{aligned} \tag{25.58}$$

□

Schließlich ist man in manchen Anwendungen an einer normalisierten, maßstabsunabhängigen Repräsentation der Kovarianzen eines Zufallsvektors interessiert. Wie im univariaten Fall bietet sich hierfür die Normalisierung der Kovarianz zweier Zufallsvariablen mithilfe ihrer jeweiligen Varianzen im Sinne einer Korrelation an. Diese Überlegung führt auf den Begriff der *Korrelationsmatrix* eines Zufallsvektors.

Definition 25.4 (Korrelationsmatrix)**.** ξ sei ein n-dimensionaler Zufallsvektor. Dann ist die *Korrelationsmatrix* von ξ definiert als die $n \times n$ Matrix

$$\mathbb{R}(\xi) := \left(\rho_{ij}\right)_{1 \leq i,j \leq n} = \left(\frac{\mathbb{C}(\xi_i, \xi_j)}{\sqrt{\mathbb{V}(\xi_i)}\sqrt{\mathbb{V}(\xi_j)}}\right)_{1 \leq i,j \leq n}. \tag{25.59}$$

•

Da es sich bei den Varianzen der Komponenten von ξ um die Diagonalelemente der Kovarianzmatrix von ξ handelt, ist die Korrelationsmatrix natürlich in der Kovarianzmatrix implizit. Weiterhin gelten, wie immer für Korrelationen, für die Einträge $\rho_{ij}, 1 \leq i, j \leq n$ der Korrelationsmatrix, dass

$$\rho_{ij} \in [-1, 1] \text{ für } 1 \leq i, j \in n \text{ und } \rho_{ii} = 1 \text{ für } 1 \leq i \leq n. \tag{25.60}$$

Selbstkontrollfragen

1. Geben Sie die Definition von Kovarianz und Korrelation zweier Zufallsvariablen wieder.
2. Erläutern Sie die Definition von Kovarianz und Korrelation zweier Zufallsvariablen.
3. Geben Sie das Theorem zur Symmetrie von Kovarianz und Korrelation wieder.
4. Geben Sie das Theorem zur Kovarianz und Korrelation bei linear-affinen Transformation wieder.
5. Erläutern Sie das Theorem zur Kovarianz und Korrelation bei linear-affinen Transformation.
6. Geben Sie das Theorem zu den Varianzen spezieller Linearkombinationen von Zufallsvariablen wieder.
7. Geben Sie das Theorem zur Korrelation und Unabhängigkeit von Zufallsvariablen wieder.

Lösungen

1. Siehe Definition 25.1.
2. Siehe Erläuterungen zu Definition 25.1 und Beispiel 25.1.
3. Siehe Theorem 25.1.
4. Siehe Theorem 25.3.
5. Siehe Erläuterungen zu Theorem 25.3.
6. Siehe Theorem 25.7.
7. Siehe Theorem 25.8.

26. Ungleichungen

Das Thema dieses Kapitels sind Ungleichungen, die in der Wahrscheinlichkeitstheorie häufig zur Abschätzung von Wahrscheinlichkeiten und Erwartungswerten genutzt werden. Wir gliedern die Ungleichungen entsprechend in *Wahrscheinlichkeitsungleichungen* (*Markov-Ungleichung* und *Chebychev Ungleichung*, Kapitel 26.1) und *Erwartungswertungleichungen* (*Cauchy-Schwarz-Ungleichung*, *Korrelationsungleichung* und *Jensensche Ungleichung*, Kapitel 26.2).

26.1. Wahrscheinlichkeitsungleichungen

Die *Markov-Ungleichung* stellt einen Bezug zwischen den Überschreitungswahrscheinlichkeiten (vgl. Theorem 21.2) und dem Erwartungswert einer *nicht-negativen* Zufallsvariablen, also einer Zufallsvariable, für die $\mathbb{P}(\xi \geq 0) = 1$ ist, her. Im Beweis dieser Ungleichung wollen wir nur den Fall einer kontinuierlichen Zufallsvariable betrachten.

Theorem 26.1 (Markov-Ungleichung)**.** *ξ sei eine Zufallsvariable mit $\mathbb{P}(\xi \geq 0) = 1$. Dann gilt für alle $x > 0$, dass*

$$\mathbb{P}(\xi \geq x) \leq \frac{\mathbb{E}(\xi)}{x}. \tag{26.1}$$

∘

Beweis. Wir betrachten den Fall einer kontinuierlichen Zufallsvariable ξ mit WDF p. Wir halten zunächst fest, dass

$$\mathbb{E}(\xi) = \int_{-\infty}^{\infty} s\, p(s)\, ds = \int_{0}^{\infty} s\, p(s)\, ds = \int_{0}^{x} s\, p(s)\, ds + \int_{x}^{\infty} s\, p(s)\, ds, \tag{26.2}$$

weil ξ nicht-negativ ist. Es folgt dann

$$\mathbb{E}(\xi) \geq \int_{x}^{\infty} s\, p(s)\, ds \geq \int_{x}^{\infty} x\, p(s)\, ds = x \int_{x}^{\infty} p(s)\, ds = x\, \mathbb{P}(\xi \geq x). \tag{26.3}$$

Dabei gilt die erste Ungleichung, weil

$$\int_{0}^{x} s\, p(s)\, ds \geq 0, \tag{26.4}$$

und die zweite Ungleichung gilt, weil $x \leq \xi$ für $\xi \in [x, \infty[$. Es folgt also, dass

$$\mathbb{E}(\xi) \geq x\, \mathbb{P}(\xi \geq x) \Leftrightarrow \mathbb{P}(\xi \geq x) \leq \frac{\mathbb{E}(\xi)}{x}. \tag{26.5}$$

□

Gilt beispielweise für eine nichtnegative Zufallsvariable ξ, dass $\mathbb{E}(\xi) = 1$ ist, dann folgt aus der Markov-Ungleichung, dass

$$\mathbb{P}(\xi \geq 100) \leq 0.01. \tag{26.6}$$

Beispiel 26.1 (Markov-Ungleichung)**.** Als Beispiel für die Markov-Ungleichung betrachten wir den Fall einer Gamma-Zufallsvariable $\xi \sim G(\alpha, \beta)$. Gamma-Zufallsvariablen sind bekanntlich definitionsgemäß nicht-negativ (vgl. Definition 21.10) Für den Erwartungswert einer Gamma-Zufallsvariable gilt $\mathbb{E}(\xi) = \alpha\beta$. Wir betrachten konkret den Fall $\alpha := 5$ und $\beta := 2$, sodass ξ auch einer χ^2-Zufallsvariable mit Freiheitsgradparameter $n = 10$ entspricht. In Abbildung 26.1 A stellen wir die KVF P dieser Zufallsvariable dar, in Abbildung 26.1 B visualisieren wir die in der Markov-Ungleichung betrachteten Größen $\mathbb{E}(\xi)/x$ und die Überschreitungswahrscheinlichkeit $\mathbb{P}(\xi \geq x) = 1 - P(x)$. Offensichtlich trifft die Markov-Ungleichung zu.

△

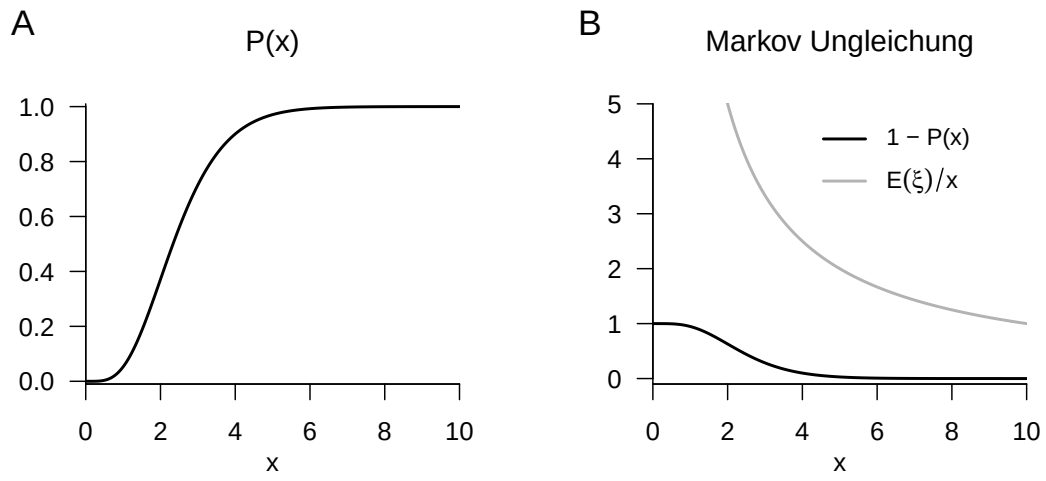


Abbildung 26.1. Markov-Ungleichung am Beispiel einer Gamma-Zufallsvariable.

Die Chebychev Ungleichung setzt die Wahrscheinlichkeit dafür, dass eine Zufallsvariable Werte weit von ihrem Erwartungswert entfernt annimmt, in Bezug zu ihrer Varianz. Wie in Kapitel 24 erläutert, liefert die Chebychev Ungleichung damit eine Begründung dafür, warum die in Definition 24.1 formulierte Größe als ein Maß für die Variabilität einer Zufallsvariable verstanden werden kann. Im Beweis der Chebyshev -Ungleichung wird an entscheidender Stelle auf die Markov Ungleichung zurückgegriffen.

Theorem 26.2 (Chebyshev -Ungleichung)**.** *Es sei ξ eine Zufallsvariable mit Varianz $\mathbb{V}(\xi)$. Dann gilt für alle $x \in \mathbb{R}$*

$$\mathbb{P}(|\xi - \mathbb{E}(\xi)| \geq x) \leq \frac{\mathbb{V}(\xi)}{x^2}. \tag{26.7}$$

∘

Beweis. Wir halten zunächst fest, dass für $a, b \in \mathbb{R}$ gilt, dass aus $a^2 \geq b^2$ folgt, dass $|a| \geq b$. Dazu betrachten wir die folgenden vier möglichen Fälle.

(1) $a^2 \geq b^2$ für $a \geq 0$ und $b \geq 0$. Dann gilt

$$a^2 \geq b^2 \Rightarrow \sqrt{a^2} \geq \sqrt{b^2} \Rightarrow a \geq b \Rightarrow |a| \geq b. \tag{26.8}$$

(2) $a^2 \geq b^2$ für $a < 0$ und $b \geq 0$. Dann gilt

$$a^2 \geq b^2 \Rightarrow \sqrt{a^2} \geq \sqrt{b^2} \Rightarrow -a \geq b \Rightarrow |a| \geq b. \tag{26.9}$$

(3) $a^2 \geq b^2$ für $a \geq 0$ und $b < 0$. Dann gilt

$$a^2 \geq b^2 \Rightarrow \sqrt{a^2} \geq \sqrt{b^2} \Rightarrow a \geq -b \geq b \Rightarrow |a| \geq b. \tag{26.10}$$

(4) $a^2 \geq b^2$ für $a < 0$ und $b < 0$. Dann gilt

$$a^2 \geq b^2 \Rightarrow \sqrt{a^2} \geq \sqrt{b^2} \Rightarrow -a \geq -b > b \Rightarrow |a| \geq b. \tag{26.11}$$

Als Nächstes definieren wir $\upsilon := (\xi - \mathbb{E}(\xi))^2$. Dann gilt offenbar $\upsilon \geq 0$ und es folgt aus der Markov-Ungleichung

$$\begin{aligned} \mathbb{P}\left(\upsilon \geq x^2\right) &\leq \frac{\mathbb{E}(\upsilon)}{x^2} \\ \Leftrightarrow \mathbb{P}\left((\xi - \mathbb{E}(\xi))^2 \geq x^2\right) &\leq \frac{\mathbb{E}\left((\xi - \mathbb{E}(\xi))^2\right)}{x^2} \\ \Leftrightarrow \mathbb{P}(|\xi - \mathbb{E}(\xi)| \geq x) &\leq \frac{\mathbb{V}(\xi)}{x^2}. \end{aligned} \tag{26.12}$$

□

26.2. Erwartungswertungleichungen

Die Cauchy-Schwarz-Ungleichung ist eine zentrale Ungleichung der modernen Mathematik, die in verschiedenen mathematischen Bereichen wie der Analysis, der Vektorraumtheorie und eben auch der Wahrscheinlichkeitstheorie zur Anwendung kommt (vgl. Steele (2006)). In Bezug auf Erwartungswerte von Zufallsvariablen hat sie die folgende Form.

Theorem 26.3 (Cauchy-Schwarz-Ungleichung)**.** *ξ und υ seien zwei Zufallsvariablen und $\mathbb{E}(\xi\upsilon)$ sei endlich. Dann gilt*

$$\mathbb{E}(\xi\upsilon)^2 \leq \mathbb{E}\left(\xi^2\right)\mathbb{E}\left(\upsilon^2\right). \tag{26.13}$$

∘

Für einen Beweis verweisen wir auf den Beweis von Theorem 4.6.2 in DeGroot & Schervish (2012). Analog zu Theorem 26.3 gilt zum Beispiel für Vektoren $x, y \in \mathbb{R}^n$, dass

$$\langle x, y\rangle^2 \leq \langle x, x\rangle\langle x, y\rangle. \tag{26.14}$$

Im Kontext der probabilistischen Datenanalyse ist die Anwendung der Cauchy-Schwarz Ungleichung vor allem im Beweis der sogenannten *Korrelationsungleichung* von Relevanz.

Theorem 26.4 (Korrelationsungleichung)**.** *ξ und υ seien Zufallsvariablen mit $\mathbb{V}(\xi) > 0$ und $\mathbb{V}(\upsilon) > 0$. Dann gelten*

$$\frac{\mathbb{C}(\xi, \upsilon)^2}{\mathbb{V}(\xi)\mathbb{V}(\upsilon)} \leq 1 \text{ und } -1 \leq \rho(\xi, \upsilon) \leq 1. \tag{26.15}$$

∘

Beweis. Mit der Cauchy-Schwarz-Ungleichung für zwei Zufallsvariablen α und β gilt, dass

$$\mathbb{E}(\alpha\beta)^2 \leq \mathbb{E}\left(\alpha^2\right)\mathbb{E}\left(\beta^2\right). \tag{26.16}$$

Wir definieren nun $\alpha := \xi - \mathbb{E}(\xi)$ und $\beta := \upsilon - \mathbb{E}(\upsilon)$. Dann besagt die Cauchy-Schwarz-Ungleichung gerade, dass

$$\mathbb{E}\left((\xi - \mathbb{E}(\xi))(\upsilon - \mathbb{E}(\upsilon))\right)^2 \leq \mathbb{E}\left((\xi - \mathbb{E}(\xi))^2\right)\mathbb{E}\left((\upsilon - \mathbb{E}(\upsilon))^2\right). \tag{26.17}$$

Also gilt

$$\mathbb{C}(\xi, \upsilon)^2 \leq \mathbb{V}(\xi)\mathbb{V}(\upsilon) \Leftrightarrow \frac{\mathbb{C}(\xi, \upsilon)^2}{\mathbb{V}(\xi)\mathbb{V}(\upsilon)} \leq 1. \tag{26.18}$$

Weiterhin folgt aus der Definition der Korrelation dann sofort, dass auch

$$\rho(\xi, \upsilon)^2 \leq 1. \tag{26.19}$$

Dann gilt aber auch

$$|\rho(\xi, \upsilon)| \leq 1 \Leftrightarrow -1 \leq \rho(\xi, \upsilon) \leq 1, \tag{26.20}$$

denn

$$\rho(\xi, \upsilon)^2 \leq 1 \Rightarrow \sqrt{\rho(\xi, \upsilon)^2} \leq \sqrt{1} \Rightarrow \quad \rho(\xi, \upsilon) \leq 1 \Rightarrow |\rho(\xi, \upsilon)| \leq 1 \text{ für } \rho(\xi, \upsilon) \geq 0 \tag{26.21}$$

und

$$\rho(\xi, \upsilon)^2 \leq 1 \Rightarrow \sqrt{\rho(\xi, \upsilon)^2} \leq \sqrt{1} \Rightarrow -\rho(\xi, \upsilon) \leq 1 \Rightarrow |\rho(\xi, \upsilon)| \leq 1 \text{ für } \rho(\xi, \upsilon) < 0. \tag{26.22}$$

□

Die Korrelationsungleichung wird manchmal auch als *Kovarianzungleichung* bezeichnet. Insbesondere besagt sie, dass die Korrelation von Zufallsvariablen normalisiert ist, also immer Werte zwischen -1 und 1 inklusive annimmt (vgl. Kapitel 25).

Die *Jensensche Ungleichung* schließlich liefert Abschätzungen für den Erwartungswert einer durch eine konvexe oder konkave Funktion transformierte Zufallsvariable. Sie kommt in der Betrachtung von Parameterschätzereigenschaften (vgl. Kapitel 37) und insbesondere als Grundlage der variationalen Bayesianischen Inferenz zum Einsatz. Wir erinnern daran, dass sich eine konvexe Funktion g dadurch auszeichnet, dass der Funktionsgraf von g über einem Intervall $[x_1, x_2]$ immer unter der verbindenden Geraden zwischen den Funktionswerten $g(x_1)$ und $g(x_2)$ liegt, wohingegehn bei einer konkaven Funktion g dieser immer über der verbindenden Geraden zwischen den Funktionswerten $g(x_1)$ zu $g(x_2)$ liegt. Wir visualisieren dies für eine konvexe Funktion in Abbildung 26.2.

Theorem 26.5 (Jensensche Ungleichung)**.** *ξ sei eine Zufallsvariable und $g : \mathbb{R} \to \mathbb{R}$ eine konvexe Funktion, d.h.*

$$g(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda g(x_1) + (1 - \lambda)g(x_2) \tag{26.23}$$

für alle $x_1, x_2 \in \mathbb{R}, \lambda \in [0, 1]$. Dann gilt

$$\mathbb{E}(g(\xi)) \geq g(\mathbb{E}(\xi)). \tag{26.24}$$

Analog sei $g : \mathbb{R} \to \mathbb{R}$ eine konkave Funktion, d.h.

$$g(\lambda x_1 + (1 - \lambda)x_2) \geq \lambda g(x_1) + (1 - \lambda)g(x_2) \tag{26.25}$$

für alle $x_1, x_2 \in \mathbb{R}, \lambda \in [0, 1]$. Dann gilt

$$\mathbb{E}(g(\xi)) \leq g(\mathbb{E}(\xi)). \tag{26.26}$$

∘

Beweis. Es sei g eine konvexe Funktion. Dann gilt für die Tangente t von g in $x_0 \in \mathbb{R}$ für alle $x \in \mathbb{R}$, dass

$$g(x) \geq t(x) := g(x_0) + g'(x_0)(x - x_0) \tag{26.27}$$

Wir setzen nun $x := \xi$ und $x_0 := \mathbb{E}(\xi)$. Dann gilt mit obiger Ungleichung, dass

$$g(\xi) \geq g(\mathbb{E}(\xi)) + g'(\mathbb{E}(\xi))(\xi - \mathbb{E}(\xi)) \tag{26.28}$$

Erwartungswertbildung ergibt dann

$$\begin{aligned} &\mathbb{E}(g(\xi)) \geq \mathbb{E}(g(\mathbb{E}(\xi))) + \mathbb{E}(g'(\mathbb{E}(\xi))(\xi - \mathbb{E}(\xi))) \\ \Leftrightarrow\ &\mathbb{E}(g(\xi)) \geq g(\mathbb{E}(\xi)) + g'(\mathbb{E}(\xi))\mathbb{E}((\xi - \mathbb{E}(\xi))) \\ \Leftrightarrow\ &\mathbb{E}(g(\xi)) \geq g(\mathbb{E}(\xi)) + g'(\mathbb{E}(\xi))(\mathbb{E}(\xi) - \mathbb{E}(\xi)) \\ \Leftrightarrow\ &\mathbb{E}(g(\xi)) \geq g(\mathbb{E}(\xi)). \end{aligned} \tag{26.29}$$

Sei nun g eine konkave Funktion. Dann ist $-g$ eine konvexe Funktion. Mit der Jensenschen Ungleichung für konvexe Funktionen folgt dann die Jensensche Ungleichung für konkave Funktionen aus

$$\begin{aligned} &\mathbb{E}(-g(\xi)) \geq -g(\mathbb{E}(\xi)) \\ \Leftrightarrow\ &-\mathbb{E}(g(\xi)) \geq -g(\mathbb{E}(\xi)) \\ \Leftrightarrow\ &\mathbb{E}(g(\xi)) \leq g(\mathbb{E}(\xi)). \end{aligned} \tag{26.30}$$

□

Im Kontext der variationalen Bayesianischen Inferenz ist grundlegend, dass der Logarithmus ist eine konkave Funktion ist und damit für eine beliebige Zufallsvariable ξ gilt, dass

$$\mathbb{E}(\ln \xi) \leq \ln \mathbb{E}(\xi). \tag{26.31}$$

Selbstkontrollfragen

1. Geben Sie die Markov-Ungleichung wieder.
2. Geben Sie die Chebyshev -Ungleichung wieder.
3. Geben Sie die Cauchy-Schwarz-Ungleichung wieder
4. Geben Sie die Korrelationsungleichung wieder.

Lösungen

1. Siehe Theorem 26.1.
2. Siehe Theorem 26.2.
3. Siehe Theorem 26.3.
4. Siehe Theorem 26.4.

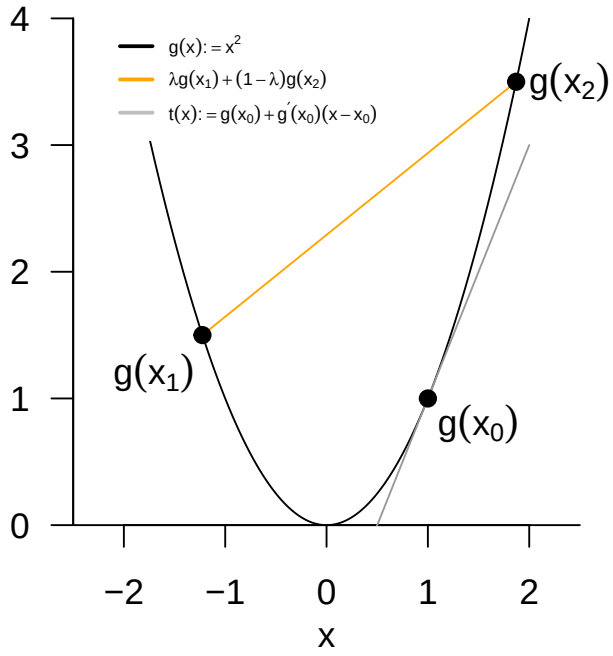


Abbildung 26.2. Darstellung der konvexen Funktion $g(x) := x^2$ mit $x_1 := -\sqrt{1.5}, x_2 := \sqrt{3.5}, \lambda \in [0, 1]$ und $x_0 := 1$.

27. Grenzwerte

In diesem Kapitel beschäftigen wir uns mit für die probabilistische Modellbildung und Datenanalyse grundlegenden Grenzwertaussagen zu Folgen von Zufallsvariablen. Dabei liefern die *Gesetze der großen Zahlen* (Kapitel 27.1) zunächst eine grundlegende Begründung für die Mittelwertbildung im Rahmen der probabilistischen Inferenz. Die *zentralen Grenzwertsätze* liefern dann die Begründung für die weite Verbreitung von Normalverteilungsannahmen zu unbekannten Einflüssen im Rahmen der probabilistischen Modellformulierung (Kapitel 27.2). Die mathematische Tiefe dieser Grenzwertaussagen kann in dieser einführenden Betrachtung nicht ausgeschöpft werden, sodass wir uns mit zahlreichen Vereinfachungen begnügen müssen. Ein minimales Vorwissen zu Funktionenfolgen und ihren Grenzfunktionen liefert Kapitel 5.

27.1. Gesetze der großen Zahlen

Es gibt ein *schwaches Gesetz der großen Zahlen* und ein *starkes Gesetz der großen Zahlen*. Intuitiv besagen beide Gesetze, dass sich das Stichprobenmittel von unabhängigen und identisch verteilten Zufallsvariablen für eine große Anzahl an Zufallsvariablen dem Erwartungswert der zugrundeliegenden Verteilung nähert. Das schwache und das starke Gesetz der großen Zahlen unterscheiden sich in Hinblick auf die zu ihrer Formulierung benutzen Formen der *Konvergenz von Zufallsvariablen*. Das schwache Gesetz basiert auf der *Konvergenz in Wahrscheinlichkeit*. Das starke Gesetz basiert auf der *fast sicheren Konvergenz*. Wir begnügen uns hier mit dem Begriff der Konvergenz in Wahrscheinlichkeit und damit dem schwachen Gesetz der großen Zahlen.

Definition 27.1 (Konvergenz in Wahrscheinlichkeit)**.** Eine Folge von Zufallsvariablen $\xi_1, \xi_2, ...$ *konvergiert gegen eine Zufallsvariable* ξ *in Wahrscheinlichkeit*, wenn für jedes noch so kleine $\epsilon > 0$ gilt, dass

$$\lim_{n\to\infty} \mathbb{P}(|\xi_n - \xi| < \epsilon) = 1 \Leftrightarrow \lim_{n\to\infty} \mathbb{P}(|\xi_n - \xi| \geq \epsilon) = 0. \tag{27.1}$$

Die Konvergenz von $\xi_1, \xi_2, ...$ gegen ξ in Wahrscheinlichkeit wird geschrieben als

$$\xi_n \xrightarrow[n\to\infty]{\mathrm{P}} \xi. \tag{27.2}$$

•

$\xi_n \xrightarrow[n\to\infty]{\mathrm{P}} \xi$ heißt also, dass sich die Wahrscheinlichkeit dafür, dass ξ_n in dem zufälligen Intervall

$$]\xi - \epsilon, \xi + \epsilon[\tag{27.3}$$

liegt, unabhängig davon, wie klein dieses Intervall sein mag, 1 nähert, wenn n gegen Unendlich geht. Intuitiv heißt das, dass sich für $n \to \infty$ und eine konstante Zufallsvariable

$\xi := a$ die Verteilung von ξ_n mehr und mehr um a konzentriert, wenn n gegen Unendlich strebt. Mithilfe der Konvergenz in Wahrscheinlichkeit formuliert man das schwache Gesetz der großen Zahlen wie folgt.

Theorem 27.1 (Schwaches Gesetz der großen Zahlen)**.** *$\xi_1, ..., \xi_n$ seien unabhängig und identisch verteilte Zufallsvariablen mit $\mathbb{E}(\xi_i) = \mu$ für alle $i = 1, ..., n$. Weiterhin bezeichne*

$$\bar{\xi}_n := \frac{1}{n} \sum_{i=1}^{n} \xi_i \tag{27.4}$$

das Stichprobenmittel der $\xi_i, i = 1, ..., n$. Dann konvergiert $\bar{\xi}_n$ in Wahrscheinlichkeit gegen μ,

$$\bar{\xi}_n \xrightarrow[n \to \infty]{P} \mu. \tag{27.5}$$

∘

Beweis. Mit Theorem 23.2 gilt zunächst, dass

$$\mathbb{E}\left(\bar{\xi}_n\right) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^{n} \xi_i\right) = \frac{1}{n} \sum_{i=1}^{n} \mathbb{E}\left(\xi_i\right) = \frac{1}{n} n \mathbb{E}\left(\xi_i\right) = \mathbb{E}\left(\xi_i\right) = \mu. \tag{27.6}$$

Der Erwartungswert μ der $i$ten Stichprobenvariable ξ_i stimmt also mit dem Erwartunsgwert des Stichprobenmittels $\bar{\xi}_n$ überein. Weiterhin halten wir fest, dass mit Theorem 25.6 und Theorem 25.8 bei Unabhängigkeit der Zufallsvariablen gilt, dass

$$\mathbb{V}\left(\bar{\xi}_n\right) = \mathbb{V}\left(\frac{1}{n} \sum_{i=1}^{n} \xi_i\right) = \frac{1}{n^2} \sum_{i=1}^{n} \mathbb{V}\left(\xi_i\right) = \frac{1}{n^2} n \mathbb{V}\left(\xi_i\right) = \frac{\mathbb{V}\left(\xi_i\right)}{n}. \tag{27.7}$$

Die Varianz des Stichprobenmittels ergibt sich also durch Teilen der Varianz der $i$ten Stichprobenvariable durch n. Mit Theorem 26.2 gilt dann aber

$$\mathbb{P}(|\bar{\xi}_n - \mathbb{E}\left(\bar{\xi}_n\right)| \geq \epsilon) \leq \frac{\mathbb{V}\left(\bar{\xi}_n\right)}{\epsilon^2} = \frac{\mathbb{V}\left(\xi_i\right)}{n\epsilon^2}. \tag{27.8}$$

Dann aber gilt für beliebige $\mathbb{V}\left(\xi_i\right) \geq 0$ und $\epsilon > 0$ und mit der Nichtnegativität der Wahrscheinlichkeit

$$\lim_{n \to \infty} \mathbb{P}(|\bar{\xi}_n - \mathbb{E}\left(\bar{\xi}_n\right)| \geq \epsilon) \leq \lim_{n \to \infty} \frac{\mathbb{V}\left(\xi_i\right)}{n\epsilon^2} \Leftrightarrow \lim_{n \to \infty} \mathbb{P}(|\bar{\xi}_n - \mu| \geq \epsilon) \leq 0 \Leftrightarrow \lim_{n \to \infty} \mathbb{P}(|\bar{\xi}_n - \mu| \geq \epsilon) = 0 \tag{27.9}$$

und es ist alles gezeigt. □

Intuitiv heißt

$$\bar{\xi}_n \xrightarrow[n \to \infty]{\mathrm{P}} \mu, \tag{27.10}$$

dass die Wahrscheinlichkeit, dass das Stichprobenmittel nahe dem Erwartungswert der zugrundeliegenden Verteilung liegt, sich 1 nähert, wenn n gegen Unendlich strebt.

Beispiel 27.1 (Simulation des schwachen Gesetzes der großen Zahlen)**.** Zur Veranschaulichung von Theorem 27.1 betrachten wir den Fall von u.i.v. normalverteilten Zufallsvariablen $\xi_1, ..., \xi_n \sim N(0, 1)$. Abbildung 27.1 A zeigt Realisationen der von Stichprobenmitteln $\bar{\xi}_n$ als Funktion von n. Man erkennt, dass für größeres n mehr Realisierungen von $\bar{\xi}_n$ in der Nähe des Erwartungswerts der $\xi_i, i = 1, ..., n$ liegen. Basierend auf diesen Stichprobenmittelrealisationen zeigt Abbildung 27.1 B Schätzungen der Wahrscheinlichkeit $\mathbb{P}(|\bar{\xi}_n - \mu| \geq \epsilon)$ als Funktionen von n und ϵ. Für ein großes ϵ reicht ein geringes n aus, um die Wahrscheinlichkeit für eine absolute Abwecihung des Stichprobenmittels vom Erwartungswert klein werden zu lassen. Für ein kleineres ϵ ist dafür ein größeres n nötig. In jedem Fall sinken die Abweichungswahrscheinlichkeiten jedoch mit größerem n.

△

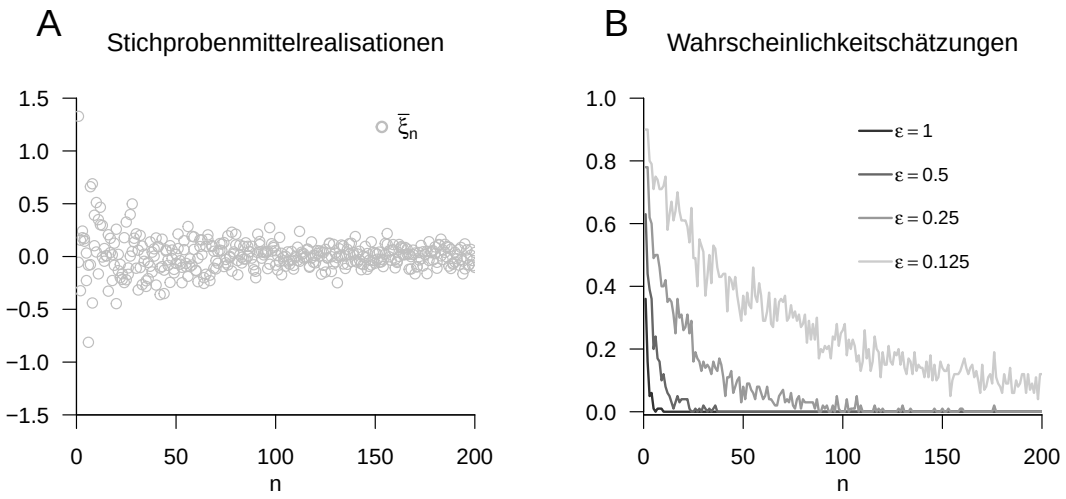


Abbildung 27.1. Simulation des schwachen Gesetz der großen Zahlen.

27.2. Zentrale Grenzwertsätze

Die zentralen Grenzwertsätze besagen intuitiv, dass die Summe von unabhängigen Zufallsvariablen mit Erwartungswert null *asymptotisch*, also für unendlich viele Zufallsvariablen, normalverteilt mit Erwartungswertparameter null ist. Modelliert man eine beliebige Messgröße y also als Summe eines deterministischen Einflusses μ und der Summe

$$\varepsilon := \sum_{i=1}^{n} \xi_i \tag{27.11}$$

einer Vielzahl von unabhängigen Zufallsvariablen $\xi_i, i = 1, ..., n$, die unbekannte Einflüsse modellieren sollen, so ist für großes n die Annahme

$$y = \mu + \varepsilon \text{ mit } \varepsilon \sim N(0, \sigma^2) \tag{27.12}$$

mathematisch gerechtfertigt. Wie wir später sehen werden, liegt die Annahme in Gleichung 27.12 einer großen Vielzahl von probabilistischen Modellen zugrunde.

Formal werden verschiedene Formen von zentralen Grenzwertsätzen, je nach Ausgestaltung der zugrundeliegenden Annahmen und ihrer Beweisführung unterschieden. In der sogenannten *Lindeberg und Lévy Form* des zentralen Grenzwertsatzes werden unabhängige und identische Zufallsvariablen vorausgesetzt. In der *Liapunov Form* dagegen werden nur unabhängige Zufallsvariablen vorausgesetzt. In beiden Formulierungen des zentralen Grenzwertsatzes ist die betrachtete Konvergenz von Zufallsvariablen die *Konvergenz in Verteilung*, welche wir zunächst einführen.

Definition 27.2 (Konvergenz in Verteilung)**.** Eine Folge $\xi_1, \xi_2, ...$ von Zufallsvariablen *konvergiert in Verteilung gegen eine Zufallsvariable* ξ, wenn

$$\lim_{n \to \infty} P_{\xi_n}(x) = P_{\xi}(x) \tag{27.13}$$

für alle ξ an denen P_ξ stetig ist. Die Konvergenz in Verteilung von $\xi_1, \xi_2, ...$ gegen ξ wird geschrieben als

$$\xi_n \xrightarrow[n\to\infty]{\text{D}} \xi. \tag{27.14}$$

Gilt $\xi_n \xrightarrow[n\to\infty]{\text{D}} \xi$, dann heißt die Verteilung von ξ die *asymptotische Verteilung der Folge* $\xi_1, \xi_2, ...$

•

Die Konvergenz in Verteilung ist also eine Aussage zur Konvergenz von Funktionenfolgen, speziell von KVFen. Ohne Begründung merken wir an, dass die oben betrachtete Konvergenz in Wahrscheinlichkeit die Konvergenz in Verteilung impliziert. Wir geben nun zunächst den zentralen Grenzwertsatz nach Lindeberg und Lévy an. Für einen Beweis verweisen wir auf Henze (2024).

Theorem 27.2 (Zentraler Grenzwertsatz nach Lindeberg und Lévy)**.** *$\xi_1, ..., \xi_n$ seien unabhängig und identisch verteilte Zufallsvariablen mit*

$$\mathbb{E}(\xi_i) := \mu \text{ und } \mathbb{V}(\xi_i) := \sigma^2 > 0 \text{ für alle } i = 1, ..., n. \tag{27.15}$$

Weiterhin sei ζ_n die Zufallsvariable definiert als

$$\zeta_n := \sqrt{n}\left(\frac{\bar{\xi}_n - \mu}{\sigma}\right). \tag{27.16}$$

Dann gilt für alle $z \in \mathbb{R}$

$$\lim_{n\to\infty} P_{\zeta_n}(z) = \Phi(z), \tag{27.17}$$

wobei Φ die kumulative Verteilungsfunktion der Standardnormalverteilung bezeichnet.

∘

Wir zeigen an späterer Stelle, dass damit für $n \to \infty$ auch gilt, dass

$$\sum_{i=1}^{n} \xi_i \sim N(\mu, n\sigma^2) \text{ und } \bar{\xi}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right). \tag{27.18}$$

Beispiel 27.2 (Simulation des zentralen Grenzwertsatzes nach Lindeberg und Lévy)**.** Wir betrachten den Fall von u.i.v. χ^2-Zufallsvariablen $\xi_1, ..., \xi_n \sim \chi^2(3)$. Offenbar ist die funktionale Form der $\chi^2(3)$-Verteilung von der Standardnormalverteilung recht verschieden, insbesondere nehmen χ^2-Zufallsvariablen mit von null verschiedener Wahrscheinlichkeit nur nicht-negative Werte an (vgl. Kapitel 21.3). Nichtsdestotrotz resultiert ihre standardisierte Summe asymptotisch in einer Normalverteilung, wie in Abbildung 27.2 visualisiert. Dazu nutzen wir auf Ebene der Implementation die Tatsache, für die χ^2-Zufallsvariablen $\xi_i, i = 1, ..., n$ mit Freiheitsgradparameter 3 gilt, dass

$$\mathbb{E}(\xi_i) = 3 \text{ und } \mathbb{V}(\xi_i) = 6. \tag{27.19}$$

Die Abbildungen in Abbildung 27.2 A zeigen Histogrammschätzer der Wahrscheinlichkeitsdichte von

$$\zeta_n := \sqrt{n}\left(\frac{\bar{\xi}_n - \mu}{\sigma}\right) \tag{27.20}$$

basierend auf 1000 Realisationen von ζ_n für $n = 2$ und $n = 200$, sowie die WDF von $N(0, 1)$. Offenbar ist die Verteilung der Realisationen von ζ_2 der Standardnormalverteilung noch sehr unähnlich,

wohingegen sich die Verteilung der Realisationen von ζ_{200} der Standardnormalverteilung schon annähert. Abbildung 27.2 B zeigt die entsprechenden geschätzten KVFen über die Theorem 27.2 formal eine Aussage trifft.

△

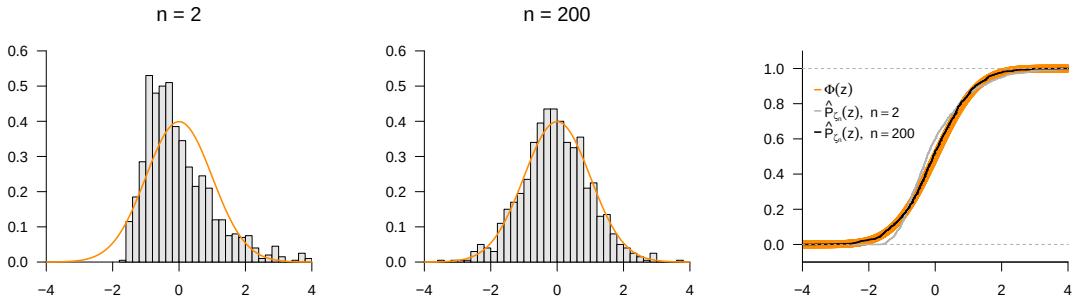


Abbildung 27.2. Simulation des Zentralen Grenzwertsatzes nach Lindeberg und Lévy.

Der zentrale Grenzwertsatz nach Liapounov generalisiert Theorem 27.2 auf den Fall nicht notwendig identisch verteilter Zufallsvariablen. Für einen Beweis verweisen wir wiederum auf Henze (2024).

Theorem 27.3 (Zentraler Grenzwertsatz nach Liapounov)**.** *$\xi_1, ..., \xi_n$ seien unabhängige aber nicht notwendigerweise identisch verteilten Zufallsvariablen mit*

$$\mathbb{E}(\xi_i) := \mu_i \text{ und } \mathbb{V}(\xi_i) := \sigma_i^2 > 0 \text{ für alle } i = 1, ..., n. \tag{27.21}$$

Weiterhin sollen für $\xi_1, ..., \xi_n$ folgende Eigenschaften gelten:

$$\mathbb{E}(|\xi_i - \mu_i|^3) < \infty \text{ und } \lim_{n\to\infty} \frac{\sum_{i=1}^n \mathbb{E}\left(|\xi_i - \mu_i|^3\right)}{(\sum_{i=1}^n \sigma_i^2)^{3/2}} = 0. \tag{27.22}$$

Dann gilt für die Zufallsvariable ζ_n definiert als

$$\zeta_n := \frac{\sum_{i=1}^n \xi_i - \sum_{i=1}^n \mu_i}{\sqrt{\sum_{i=1}^n \sigma_i^2}}, \tag{27.23}$$

für alle $z \in \mathbb{R}$, dass

$$\lim_{n\to\infty} P_{\zeta_n}(z) = \Phi(z), \tag{27.24}$$

wobei Φ die KVF der Standardnormalverteilung bezeichnet.

∘

Wir zeigen an späterer Stelle, dass damit für $n \to \infty$ auch gilt, dass

$$\sum_{i=1}^n \xi_i \sim N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right). \tag{27.25}$$

27.3. Literaturhinweise

Zur mathematik-geschichtlichen Genese der Zentralen Grenzwertsätze siehe Fischer (2011) und Ulyanov (2024). Zum zentralen Grenzwertsatz nach Lindeberg-Lévy, siehe Lindeberg (1922) und Lévy (1937), zum zentralen Grenzwertsatz nach Liapunov, siehe Liapounoff (1900) und Liapounoff (1901).

Selbstkontrollfragen

1. Geben Sie das Schwache Gesetz der großen Zahlen wieder.
2. Erläutern Sie den zentralen Grenzwertsatz nach Lindeberg und Lévy.
3. Warum sind die zentralen Grenzwertsätze für die probabilistische Modellbildung wichtig?

Lösungen

1. Siehe Theorem 27.1.
2. Der zentrale Grenzwertsatz nach Lindeberg und Lévy besagt, dass die standardisierte Summe unabhängig und identisch verteilter Zufallsvariablen asymptotisch normalverteilt ist.
3. Die zentralen Grenzwertsätze begründen die häufige Annahme normalverteilter unbekannter Einflüsse als Stör-, Fehler-, Abweichungs- oder Unsicherheitsvariablen in probabilistischen Modellen.

28. Transformationen

Die Transformation von Zufallsvektoren und die Analyse ihrer resultierenden Verteilungen ist ein zentrales Thema der probabilistischen Modellierung und in besonderem Maße der Frequentistischen Inferenz. Mit einer *Transformation* soll hier die Anwendung einer Funktion auf einen Zufallsvektor gemeint sein, die seine Komponenten entweder individuell transformiert oder miteinander verknüpft. Die zentrale Fragestellung dabei ist folgende: "Wenn ein Zufallsvektor ξ eine vorgegebene Verteilung hat, wie ist dann der Zufallsvektor υ, der sich durch Transformation von ξ ergibt, verteilt?" Für die in diesem Kapitel behandelten Fälle gilt dabei, dass man explizite Lösungen für die Verteilung der transformierten Zufallsvektoren angeben kann. Diese gehören zu den klassischen Resultaten der Frequentistischen Inferenz und sind für das Verständnis von klassischer Frequentistischer Inferenzverfahren wie Konfidenzintervallen und Hypothesentests essenziell.

Für eine erste Intuition hierzu beschränken wir uns auf den Fall einer einzelnen Zufallsvariable. Man kann sich dann die Transformation einer Zufallsvariable anhand der Transformation ihrer unabhängig und identisch verteilten Realisierungen verdeutlichen. Betrachtet man beispielsweise die Zufallsvariable $\xi \sim N(0,1)$ und ihre Transformation $\upsilon := \xi^2$ und sind $x_1 = 0.10, x_2 = -0.20, x_3 = 0.80$ drei Realisierungen von drei unabhängigen Kopien von ξ, so entspricht dies den Realisierungen $y_1 = x_1^2 = 0.01, y_2 = x_2^2 = 0.04, y_3 = x_3^2 = 0.64$ von υ. In diesem Beispiel fällt auf, dass υ keine negativen Werte annimmt, die Verteilung von υ ordnet negativen Werten daher eine Wahrscheinlichkeitsdichte von 0 zu. Untenstehender **R** Code simuliert diese Überlegungen. Abbildung 28.1 zeigt das Histogramm der gewonnenen Realisierungen der hier betrachteten Zufallsvariable ξ und Abbildung 28.2 zeigt das Histogramm der quadrierten Realisierungen von ξ, also unabhängig und identisch verteilte Realisierungen von υ.

```
# Simulationsspezifikation
n       = 1e4                          # Anzahl von u.i.v. Realisierungen (ZVen)
mu      = 1                            # Erwartungswertparameter von \xi
sigsqr  = 2                            # Varianzparameter von \xi

# Quadrieren einer Zufallsvariable
x       = rnorm(n, mu, sqrt(sigsqr))   # Realisierungen x_i, i = 1,....,n von \xi
y       = x^2                          # Realisierungen y_i = x_i^2 von \upsilon

# Ausgabe der ersten acht Werte der Realisierungen von \xi und von \upsilon
print(x[1:8], digits = 2)
```

```
[1]  1.08 -1.07  2.13  1.32  1.03 -0.76 -1.06  1.99
```

```
print(y[1:8], digits = 2)
```

```
[1] 1.16 1.15 4.53 1.73 1.07 0.57 1.12 3.94
```

Grundlegend für die nachfolgenden Betrachtungen ist folgendes Theorem, das wir nicht beweisen wollen.

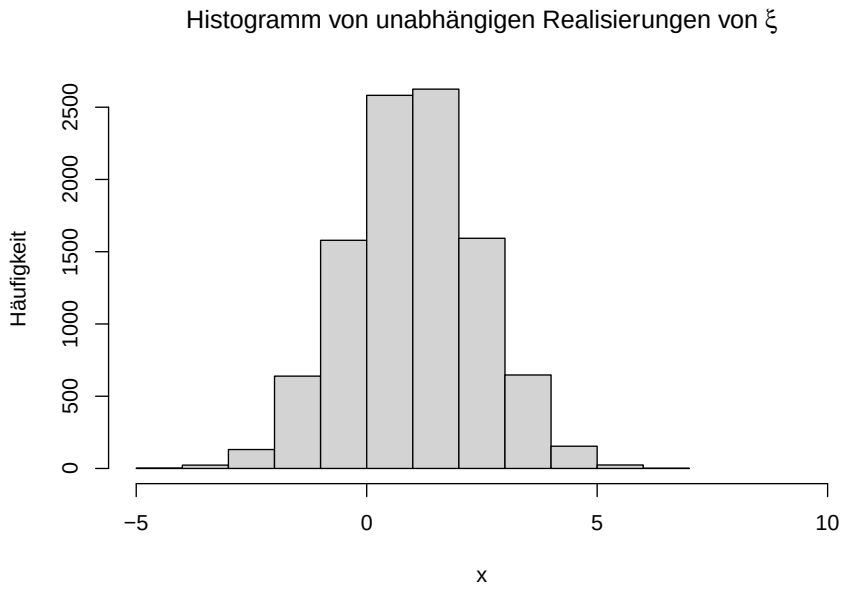


Abbildung 28.1. Histogramm von 10.000 Realisierungen unabhängig und identisch normalverteilter Zufallsvariablen.

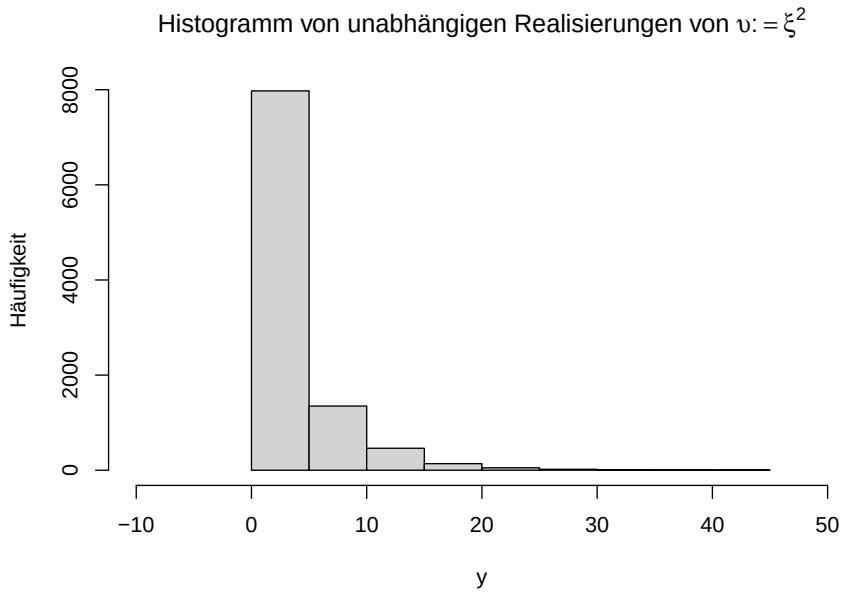


Abbildung 28.2. Histogramm von 10.000 quadrierten Realisierungen unabhängig und identisch normalverteilter Zufallsvariablen.

Theorem 28.1 (Transformation eines Zufallsvektors)**.** *$\xi : \Omega \to \mathcal{X}$ sei ein Zufallsvektor und $f : \mathcal{X} \to \mathbb{R}^m$ sei eine multivariate vektorwertige Funktion. Dann ist*

$$\upsilon : \Omega \to \mathbb{R}, \omega \mapsto \upsilon(\omega) := (f \circ \xi)(\omega) := f(\xi(\omega)) \tag{28.1}$$

ein Zufallsvektor.

∘

Das Theorem formalisiert die oben etablierte Intuition, dass die Anwendung einer Funktion auf eine zufällige Größe im Allgemeinen wieder eine zufällige Größe ergibt. In einem Beweis von Theorem 28.1 müsste die Messbarkeit von υ als Folge der Messbarkeit von ξ nachgewiesen werden. Im Folgenden ist oft $\mathcal{X} := \mathbb{R}$ und $f : \mathbb{R} \to \mathbb{R}$. Wir schreiben in diesem Fall in der Regel einfach $\upsilon := f(\xi)$ und nennen υ die *transformierte Zufallsvariable*.

In Kapitel 28.1 betrachten wir Theoreme zur Transformation von Zufallsvariablen in Abhängigkeit von der Art der betrachteten Funktion f. In Kapitel 28.2 betrachten wir ein Theorem zur Transformation von Zufallsvektoren bei bijektiver Transformationsfunktion und die Bestimmung von Verteilungen bei der binären Verknüpfungen von Zufallsvariablen.

28.1. Univariate Transformationstheoreme

Theorem 28.2 gibt eine Formel zur Berechnung der WDF p_υ von $\upsilon := f(\xi)$, wenn ξ eine Zufallsvariable mit WDF p_ξ ist und f eine bijektive Funktion ist.

Theorem 28.2 (Univariate WDF Transformation bei bijektiven Abbildungen)**.** *ξ sei eine Zufallsvariable mit WDF p_ξ für die $\mathbb{P}(]a, b[) = 1$ gilt, wobei a und/oder b entweder endlich oder unendlich seien. Weiterhin sei*

$$\upsilon := f(\xi), \tag{28.2}$$

wobei die univariate reellwertige Funktion $f :]a, b[\to \mathbb{R}$ differenzierbar und bijektiv auf $]a, b[$ sei. $f(]a, b[)$ sei das Bild von $]a, b[$ unter f. Schließlich sei $f^{-1}(y)$ der Wert der Umkehrunktion von $f(x)$ für $y \in f(]a, b[)$ und $f'(x)$ sei die Ableitung von f an der Stelle x. Dann ist die WDF von υ gegeben durch

$$p_\upsilon : \mathbb{R} \to \mathbb{R}_{\geq 0}, y \mapsto p_\upsilon(y) := \begin{cases} \frac{1}{|f'(f^{-1}(y))|} p_\xi\left(f^{-1}(y)\right) & \text{für } y \in f(]a, b[) \\ 0 & \text{für } y \in \mathbb{R} \setminus f(]a, b[). \end{cases} \tag{28.3}$$

∘

Beweis. Wir halten zunächst fest, dass weil f eine differenzierbare bijektive Funktion auf $]a, b[$ ist, f entweder strikt wachsend oder strikt fallend ist. Nehmen wir zunächst an, dass f auf $]a, b[$ strikt wachsend ist. Dann ist auch f^{-1} für alle $y \in f(]a, b[)$ wachsend, und es gilt

$$P_\upsilon(y) = \mathbb{P}(\upsilon \leq y) = \mathbb{P}\left(f(\xi) \leq y\right) = \mathbb{P}\left(f^{-1}(f(\xi)) \leq f^{-1}(y)\right) = \mathbb{P}\left(\xi \leq f^{-1}(y)\right) = P_\xi\left(f^{-1}(y)\right).$$

P_υ ist also differenzierbar an allen Stellen y, an denen sowohl f^{-1} als auch P_ξ differenzierbar sind. Mit der Kettenregel und dem Satz von der Umkehrabbildung $(f^{-1}(x))' = 1/f'(f^{-1}(x))$, folgt dann, dass die WDF p_υ sich ergibt wie folgt:

$$p_\upsilon(y) = \frac{d}{dy} P_\upsilon(y) = \frac{d}{dy} P_\xi\left(f^{-1}(y)\right) = p_\xi\left(f^{-1}(y)\right) \frac{d}{dy} f^{-1}(y) = \frac{1}{f'\left(f^{-1}(y)\right)} p_\xi\left(f^{-1}(y)\right),$$

Weil f^{-1} strikt wachsend ist, ist $d/dy(f^{-1}(y))$ positiv und das Theorem trifft zu. Analog gilt, dass wenn f auf $]a, b[$ strikt fallend ist, dann ist auch f^{-1} für alle $y \in f(]a, b[)$ fallend und es gilt

$$P_\upsilon(y) = \mathbb{P}(f(\xi) \leq y) = \mathbb{P}\left(f^{-1}(f(\xi)) \geq f^{-1}(y)\right) = \mathbb{P}\left(\xi \geq f^{-1}(y)\right) = 1 - P_\xi\left(f^{-1}(y)\right),$$

Mit der Kettenregel und dem Satz von der Umkehrabbildung folgt dann

$$p_\upsilon(y) = \frac{d}{dy}(1 - P_\upsilon(y)) = -\frac{d}{dy}P_\xi\left(f^{-1}(y)\right) = -p_\xi\left(f^{-1}(y)\right)\frac{d}{dy}f^{-1}(y) = -\frac{1}{f'\left(f^{-1}(y)\right)}p_\xi\left(f^{-1}(y)\right).$$

Weil f^{-1} strikt fallend ist, ist $d/dy(f^{-1}(y))$ negativ, so dass $-d/dy(f^{-1}(y))$ gleich $|d/dy(f^{-1}(y))|$ ist und das Theorem trifft zu. □

Ein wichtiger Anwendungsfall von Theorem 28.2 ist Theorem 28.3. Im Vergleich zu Theorem 28.2 gibt Theorem 28.3 eine vereinfachte Formel zur Berechnung der WDF p_υ von $\upsilon := f(\xi)$ an, wenn f eine linear-affine Funktion ist.

Theorem 28.3 (Univariates WDF Transformationstheorem bei linear-affinen Abbildungen)**.** *ξ sei eine Zufallsvariable mit WDF p_ξ und es sei*

$$\upsilon = f(\xi) \text{ mit } f(\xi) := a\xi + b \text{ für } a \neq 0. \tag{28.4}$$

Dann ist die WDF von υ gegeben durch

$$p_\upsilon : \mathbb{R} \to \mathbb{R}_{\geq 0}, y \mapsto p_\upsilon(y) := \frac{1}{|a|}p_\xi\left(\frac{y-b}{a}\right). \tag{28.5}$$

∘

Beweis. Wir halten zunächst fest, dass

$$f^{-1} : \mathbb{R} \to \mathbb{R}, y \mapsto f^{-1}(y) = \frac{y-b}{a} \tag{28.6}$$

ist, weil dann $f \circ f^{-1} = \mathrm{id}_\mathbb{R}$ gilt, wie man anhand von

$$f(f^{-1}(x)) = a\left(\frac{x-b}{a}\right) + b = x - b + b = x \text{ für alle } x \in \mathbb{R} \tag{28.7}$$

einsieht. Wir halten weiterhin fest, dass

$$f' : \mathbb{R} \to \mathbb{R}, x \mapsto f'(x) = \frac{d}{dx}(ax + b) = a. \tag{28.8}$$

Also folgt mit Theorem 28.2, dass

$$\begin{aligned} p_\upsilon : \mathbb{R} \to \mathbb{R}_{\geq 0}, y \mapsto p_\upsilon(y) &= \frac{1}{|f'\left(f^{-1}(y)\right)|}p_\xi\left(f^{-1}(y)\right) \\ &= \frac{1}{|a|}p_\xi\left(\frac{y-b}{a}\right). \end{aligned} \tag{28.9}$$

□

Theorem 28.4 gibt eine Formel zur Berechnung der WDF p_υ von $\upsilon := f(\xi)$ an, wenn f zumindest in Teilen bijektiv ist.

Theorem 28.4 (Univariate WDF Transformation bei stückweise bijektiven Abbildungen)**.** *ξ sei eine Zufallsvariable mit Ergebnisraum $\mathcal{X}$ und WDF p_ξ. Weiterhin sei*

$$\upsilon = f(\xi), \tag{28.10}$$

wobei f so beschaffen sei, dass der Ergebnisraum von ξ in eine endliche Anzahl von Mengen $\mathcal{X}_1, ..., \mathcal{X}_k$ mit einer entsprechenden Anzahl von Mengen $\mathcal{Y}_1 := f(\mathcal{X}_1), ..., \mathcal{Y}_k := f(\mathcal{X}_k)$ im Ergebnisraum $\mathcal{Y}$ von υ partitioniert werden kann (wobei nicht notwendigerweise $\mathcal{Y}_i \cap \mathcal{Y}_j = \emptyset, 1 \leq i, j \leq k$ gelten muss), sodass die Abbildung f für alle $\mathcal{X}_1, ..., \mathcal{X}_k$ bijektiv ist (d.h. f ist eine stückweise *bijektive Abbildung). Für $i = 1, ..., k$ bezeichne f_i^{-1} die Umkehrfunktion von f auf $\mathcal{Y}_i$. Schließlich nehmen wir an, dass die Ableitungen f_i' für alle $i = 1, ..., k$ existieren und stetig sind. Dann ist eine WDF von υ durch*

$$p_\upsilon : \mathcal{Y} \to \mathbb{R}_{\geq 0}, y \mapsto p_\upsilon(y) := \sum_{i=1}^{k} 1_{\mathcal{Y}_i}(y) \frac{1}{|f_i'(f_i^{-1}(y))|} p_\xi\left(f_i^{-1}(y)\right). \tag{28.11}$$

gegeben.

∘

Für einen Beweis verweisen wir auf Casella & Berger (2002).

28.2. Multivariate Transformationstheoreme

Theorem 28.5 liefert eine Formel zur Berechnung der WDF p_υ von $\upsilon := f(\xi)$, wenn ξ ein Zufallsvektor mit WDF p_ξ ist und f eine bijektive multivariate vektorwertigeFunktion ist. Es handelt sich dabei um eine direkte Generalisierung von Theorem 28.2.

Theorem 28.5 (Multivariate WDF Transformation bei bijektiven Abbildungen)**.** *ξ sei ein n-dimensionaler Zufallsvektor mit Ergebnisraum $\mathbb{R}^n$ und WDF p_ξ. Weiterhin sei*

$$\upsilon := f(\xi), \tag{28.12}$$

wobei die multivariate vektorwertige Funktion $f : \mathbb{R}^n \to \mathbb{R}^n$ differenzierbar und bijektiv auf $]a, b[$ sei. Schließlich seien

$$J^f(x) = \left(\frac{\partial}{\partial x_j} f_i(x)\right)_{1 \leq i \leq n, 1 \leq j \leq n} \in \mathbb{R}^{n \times n} \tag{28.13}$$

die Jacobi-Matrix von f an der Stelle $x \in \mathbb{R}^n$, $|J^f(x)|$ die Determinante von $J^f(x)$, und es sei $|J^f(x)| \neq 0$ für alle $x \in \mathbb{R}^n$. Dann ist eine WDF von υ durch

$$p_\upsilon : \mathbb{R}^n \to \mathbb{R}_{\geq 0}, y \mapsto p_\upsilon(y) := \begin{cases} \frac{1}{|J^f(f^{-1}(y))|} p_\xi\left(f^{-1}(y)\right) & \text{für } y \in f(\mathbb{R}^n) \\ 0 & \text{für } y \in \mathbb{R}^n \setminus f(\mathbb{R}^n) \end{cases} \tag{28.14}$$

gegeben.

∘

Für einen Beweis verweisen wir auf Billingsley (1995).

Das folgende sogenannte *Konvolutionstheorem* liefert eine Formel zur Berechnung der WDF p_υ von $\upsilon := \xi_1 + \xi_2$, wenn ξ_1 und ξ_2 zwei Zufallsvariablen mit WDFen p_{ξ_1} und p_{ξ_2} sind.

Theorem 28.6 (Summe unabhängiger Zufallsvariablen (Konvolution))**.** *ξ_1 und ξ_2 seien zwei kontinuierliche unabhängige Zufallsvariablen mit WDF p_{ξ_1} und p_{ξ_2}, respektive. $\upsilon := \xi_1 + \xi_2$ sei die Summe von ξ_1 und ξ_2. Dann ergibt sich eine WDF der Verteilung von υ als*

$$p_\upsilon(y) = \int_{-\infty}^{\infty} p_{\xi_1}(y - x_2) p_{\xi_2}(x_2)\, dx_2 = \int_{-\infty}^{\infty} p_{\xi_1}(x_1) p_{\xi_2}(y - x_1)\, dx_1 \tag{28.15}$$

Die Formel für die WDF p_υ heißt Konvolution *oder* Faltung *von p_{ξ_1} und p_{ξ_2}.*

∘

Beweis. Wir nutzen das multivariate WDF Transformationstheorem für bijektive Abbildungen. Dazu definieren wir zunächst

$$f : \mathbb{R}^2 \to \mathbb{R}^2, x \mapsto f(x) := \begin{pmatrix} x_1 + x_2 \\ x_2 \end{pmatrix} := \begin{pmatrix} z_1 \\ z_2 \end{pmatrix} \tag{28.16}$$

Die inverse Funktion von f ist dann gegeben durch

$$f : \mathbb{R}^2 \to \mathbb{R}^2, z \mapsto f(z) := \begin{pmatrix} z_1 - x_2 \\ z_2 \end{pmatrix} \tag{28.17}$$

weil dann $f \circ f^{-1} = \mathrm{id}_{\mathbb{R}^2}$ gilt, wie man anhand von

$$f^{-1}\left(f(x)\right) = f^{-1}\begin{pmatrix} x_1 + x_2 \\ x_2 \end{pmatrix} = \begin{pmatrix} x_1 + x_2 - x_2 \\ x_2 \end{pmatrix} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \tag{28.18}$$

einsieht. Die Jacobimatrix von f ergibt sich zu

$$J^f(x) = \begin{pmatrix} \frac{\partial}{\partial x_1} f_1(x) & \frac{\partial}{\partial x_2} f_1(x) \\ \frac{\partial}{\partial x_1} f_2(x) & \frac{\partial}{\partial x_2} f_2(x) \end{pmatrix} = \begin{pmatrix} \frac{\partial}{\partial x_1}(x_1 + x_2) & \frac{\partial}{\partial x_2}(x_1 + x_2) \\ \frac{\partial}{\partial x_1} x_2 & \frac{\partial}{\partial x_2} x_2 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \tag{28.19}$$

und die Jacobideterminante damit zu $|J^f(x)| = 1$. Wir halten weiterhin fest, dass die Unabhängigkeit von ξ_1 und ξ_2 impliziert, dass

$$p_{\xi_1, \xi_2}(x_1, x_2) = p_{\xi_1}(x_1) p_{\xi_2}(x_2) \tag{28.20}$$

impliziert. Einsetzen und Integration hinsichtlich x_2 ergibt dann
für $z \in f(\mathbb{R}^2)$

$$\begin{aligned} p_\zeta(z) &= \frac{1}{|J^f\left(f^{-1}(z)\right)|} p_\xi\left(f^{-1}(z)\right) \\ &= \frac{1}{1} p_{\xi_1, \xi_2}\left(z_1 - x_2, x_2\right) \\ &= p_{\xi_1}(z_1 - x_2) p_{\xi_2}(x_2) \end{aligned} \tag{28.21}$$

Integration über x_2 ergibt dann eine WDF für die marginale Verteilung von ζ_1

$$p_{\zeta_1}(z_1) = \int_{-\infty}^{\infty} p_{\xi_1}(z_1 - x_2) p_{\xi_2}(x_2)\, dx_2 \tag{28.22}$$

Mit $\zeta_1 = \xi_1 + \xi_2 = \upsilon$ ergibt sich dann die erste Form des Konvolutionstheorems zu

$$p_\upsilon(y) = \int_{-\infty}^{\infty} p_{\xi_1}(y - x_2) p_{\xi_2}(x_2)\, dx_2. \tag{28.23}$$

□

Selbstkontrollfragen

1. Erläutern Sie das Konzept der Transformation einer Zufallsvariable am Beispiel von $\upsilon := \xi^2$.

Lösungen

1. Siehe Erläuterungen zu Abbildung 28.1 und Abbildung 28.2.

29. Normalverteilungen

Die multivariate Normalverteilung ist die multivariate Generalisierung der univariaten Normalverteilung. Die Motivation für die verbreiteten Normalverteilungsannahmen in der probabilistischen Modellierung liegt bekanntermaßen im Zentralen Grenzwertsatz: In probabilistischen Modellen repräsentieren probabilistische Terme die Summation sehr vieler Zufallsvorgänge, die durch die deterministischen Bestandteile des jeweiligen Modells, also eine formalisierte wissenschaftliche Theorie, nicht erklärt werden. Nach dem Zentralen Grenzwertsatz ist die Summe dieser nicht erklärten Zufallsvorgänge dann aber gerade normalverteilt.

Über diesen grundlegenden Aspekt hinaus hat die Normalverteilung viele günstige mathematische Eigenschaften, die ihren Einsatz in vielen Bereichen der probabilistischen Modellierung ermöglichen. Anwendungen multivariater Normalverteilungen finden sich damit im Kontext des Allgemeinen linearen Modells, den Generalisierungen des Allgemeinen Modells zu Hierarchischen linearen Modellen oder Multivariaten Allgemeinen linearen Modellen, der Bayesianischen Inferenz bei Normalverteilungsannahmen und nicht zuletzt der Theorie probabilistischer Filter, wie zum Beispiel dem Kalman-Bucy Filter.

29.1. Konstruktion multivariater Normalverteilungen

In diesem Abschnitt wollen wir zeigen, wie ein bivariat normalverteilter Zufallsvektor durch Transformation und Konkatenation zweier univariat normalverteilter Zufallsvariablen konstruiert werden kann. Dazu erinnern wir zunächst an den Begriff der normalverteilten Zufallsvariable. Wir wiederholen die entsprechende Definition aus Kapitel 21 hier, um die Terminologie für die multivariaten Normalverteilungen einzuführen.

Definition 29.1 (Normalverteilte Zufallsvariable)**.** ξ sei eine Zufallsvariable mit Ergebnisraum $\mathbb{R}$ und WDF

$$p : \mathbb{R} \to \mathbb{R}_{>0}, x \mapsto p(x) := \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right). \tag{29.1}$$

Dann sagen wir, dass ξ einer *Normalverteilung (oder Gauß-Verteilung)* mit *Erwartungswertparameter* $\mu \in \mathbb{R}$ und *Varianzparameter* $\sigma^2 > 0$ unterliegt und nennen ξ eine *normalverteilte Zufallsvariable*. Wir kürzen dies mit $\xi \sim N(\mu, \sigma^2)$ ab. Die WDF einer normalverteilten Zufallsvariablen bezeichnen wir mit

$$N\left(x; \mu, \sigma^2\right) := \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right). \tag{29.2}$$

•

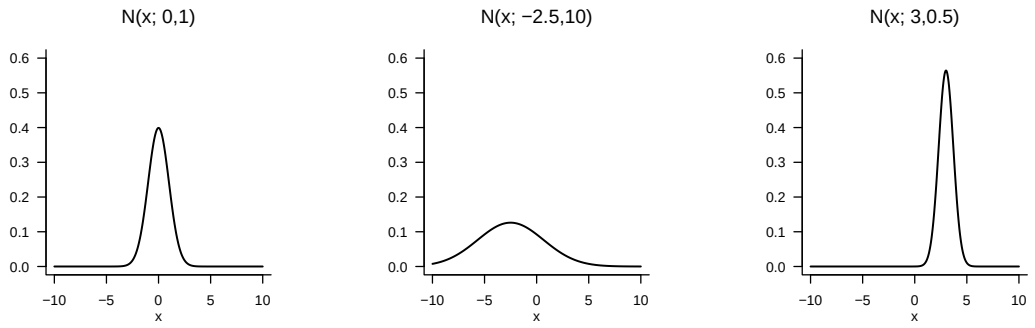


Abbildung 29.1. Wahrscheinlichkeitsdichtefunktionen univariater Normalverteilungen.

Visuell entspricht der Parameter μ einer normalverteilten Zufallsvariablen dem Wert höchster Wahrscheinlichkeitsdichte und der Parameter σ^2 spezifiziert die Breite der WDF (Abbildung 29.1). Weiterhin gelten für den Erwartungswert und die Varianz einer normalverteilten Zufallsvariablen bekanntlich

$$\mathbb{E}(\xi) = \mu \text{ und } \mathbb{V}(\xi) = \sigma^2. \tag{29.3}$$

Eine normalverteilte Zufallsvariable der Form $\xi \sim N(0, 1)$ schließlich heißt auch *standardnormalverteilt*.

Folgendes Theorem zeigt, wie zwei unabhängige, univariat standardnormalverteilte Zufallsvariablen kombiniert werden können, um einen bivariat verteilten Zufallsvektor zu konstruieren. Die Verteilung eines ebensolchen Zufallsvektors wird dann als *bivariate Normalverteilung* bezeichnet.

Theorem 29.1 (Konstruktion bivariater Normalverteilungen)**.** *$\zeta_1 \sim N(0, 1)$ und $\zeta_2 \sim N(0, 1)$ seien zwei unabhängige standardnormalverteilte Zufallsvariablen. Weiterhin seien $\mu_1, \mu_2 \in \mathbb{R}$, $\sigma_1, \sigma_2 > 0$ und $\rho \in]-1, 1[$. Schließlich seien*

$$\begin{aligned} \xi_1 &:= \sigma_1\zeta_1 + \mu_1 \\ \xi_2 &:= \sigma_2\left(\rho\zeta_1 + (1-\rho^2)^{1/2}\zeta_2\right) + \mu_2. \end{aligned} \tag{29.4}$$

Dann hat die WDF des Zufallsvektors $\xi := (\xi_1, \xi_2)^T$, also der gemeinsamen Verteilung von ξ_1 und ξ_2, die Form

$$p : \mathbb{R}^2 \to \mathbb{R}_{>0},\ x \mapsto p(x) := (2\pi)^{-\frac{n}{2}}|\Sigma|^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)\right), \tag{29.5}$$

wobei $n := 2$ und $\mu \in \mathbb{R}^2$ und $\Sigma \in \mathbb{R}^{2\times 2}$ durch

$$\mu = \begin{pmatrix}\mu_1 \\ \mu_2\end{pmatrix} \text{ und } \Sigma = \begin{pmatrix}\sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_2\sigma_1 & \sigma_2^2\end{pmatrix} \tag{29.6}$$

gegeben sind.

∘

Für einen Beweis des Theorems verweisen wir auf DeGroot & Schervish (2012).

Beispiel 29.1 (Konstruktion einer bivariaten Normalverteilung)**.** Folgender **R** Code zeichnet das obige Theorem anhand konkreter Beispielwerte für $\mu_1, \mu_2, \sigma_1, \sigma_2$ und ρ nach und gibt die Parameter μ und Σ der resultierenden bivariaten WDF aus.

```
# Parameterdefinitionen
mu_1   = 5.0                                          # \mu_1
mu_2   = 4.0                                          # \mu_2
sig_1  = 1.5                                          # \sigma_1
sig_2  = 1.0                                          # \sigma_2
rho    = 0.9                                          # \rho

# Realisierungen der standardnormalverteilten ZVen
n      = 100                                          # Anzahl Realisierungen
zeta_1 = rnorm(n)                                     # \zeta_1 \sim N(0,1)
zeta_2 = rnorm(n)                                     # \zeta_1 \sim N(0,1)

# Evaluation von Realisierungen von \xi_1 und \xi_2
xi_1   = sig_1*zeta_1 + mu_1                          # Realsierungen von zeta_1
xi_2   = sig_2*(rho*zeta_1 + sqrt(1-rho^2)*zeta_2) + mu_2 # Realsierungen von zeta_2

# Parameter der gemeinsamen Verteilung von \xi_1 und \xi_2
mu     = matrix(c(mu_1,                               # \mu \in \mathbb{R}^2
                  mu_2),
                nrow = 2, byrow = TRUE)
Sigma  = matrix(c(sig_1^2       , rho*sig_1*sig_2,    # \Sigma \in \mathbb{R}^{2 x 2}
                rho*sig_1*sig_2, sig_2^2),
                nrow = 2, byrow = TRUE)
print(mu)
```

```
     [,1]
[1,]    5
[2,]    4
```

```
print(Sigma)
```

```
     [,1] [,2]
[1,] 2.25 1.35
[2,] 1.35 1.00
```

Die durch obigen **R** Code generierten Realisierungen von $\xi = (\xi_1, \xi_2)^T$, sowie die Isokonturen der durch Theorem 29.1 postulierten WDF sind in Abbildung 29.2 dargestellt.

△

29.2. Definition multivariater Normalverteilungen

Wir wollen die multivariate Normalverteilung nun formal einführen und erste Eigenschaften angeben. Wir nutzen dazu folgende Definition.

Definition 29.2. ξ sei ein n-dimensionaler Zufallsvektor mit Ergebnisraum $\mathbb{R}^n$ und WDF

$$p : \mathbb{R}^n \to \mathbb{R}_{>0},\ x \mapsto p(x) := (2\pi)^{-\frac{n}{2}} |\Sigma|^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1} (x-\mu)\right). \tag{29.7}$$

Dann sagen wird, dass ξ einer *multivariaten (oder n-dimensionalen) Normalverteilung* mit *Erwartungswertparameter* $\mu \in \mathbb{R}^n$ und positiv-definitem *Kovarianzmatrixparameter* $\Sigma \in \mathbb{R}^{n \times n}$ unterliegt und nennen ξ einen *(multivariat) normalverteilten Zufallsvektor*. Wir kürzen dies mit $\xi \sim N(\mu, \Sigma)$ ab. Die WDF eines multivariat normalverteilten Zufallsvektors bezeichnen wir mit

$$N(x; \mu, \Sigma) := (2\pi)^{-\frac{n}{2}} |\Sigma|^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1} (x-\mu)\right). \tag{29.8}$$

•

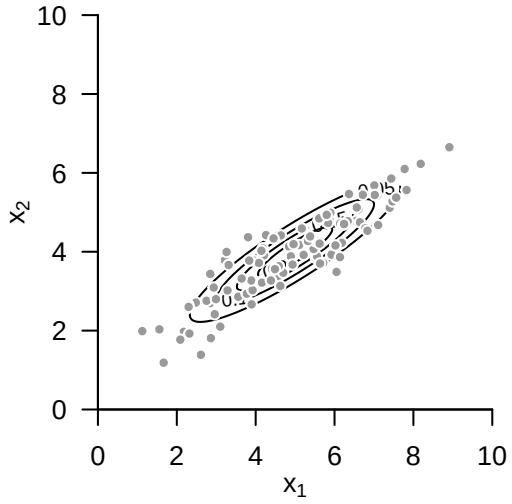


Abbildung 29.2. Konstruktion einer bivariaten Normalverteilung.

Beispiel 29.2 (Bivariate Normalverteilungen)**.** Abbildung 29.3 A,B,C zeigen die Isokonturen der WDFen bivariat normalverteilter Zufallsvektoren für $\mu = (1, 1)^T$ und

$$\Sigma_A := \begin{pmatrix} 0.20 & 0.15 \\ 0.15 & 0.20 \end{pmatrix}, \quad \Sigma_B := \begin{pmatrix} 0.20 & 0.00 \\ 0.00 & 0.20 \end{pmatrix}, \quad \Sigma_C := \begin{pmatrix} 0.20 & -0.15 \\ -0.15 & 0.20 \end{pmatrix} \tag{29.9}$$

respektive. Abbildung 29.4 A,B und C zeigen jeweils 200 Realisierungen der entsprechenden Zufallsvektoren.

△

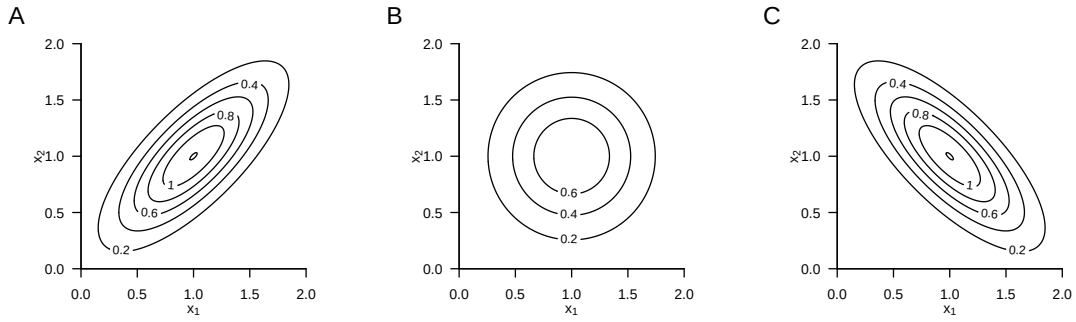


Abbildung 29.3. Wahrscheinlichkeitsdichtefunktionen bivariater Normalverteilungen.

Ohne Beweis halten wir fest, dass wie im Fall einer univariat normalverteilten Zufallsvariable, der Erwartungswert und die Kovarianzmatrix eines normalverteilten Zufallsvektors durch die entsprechenden Parameter gegeben sind.

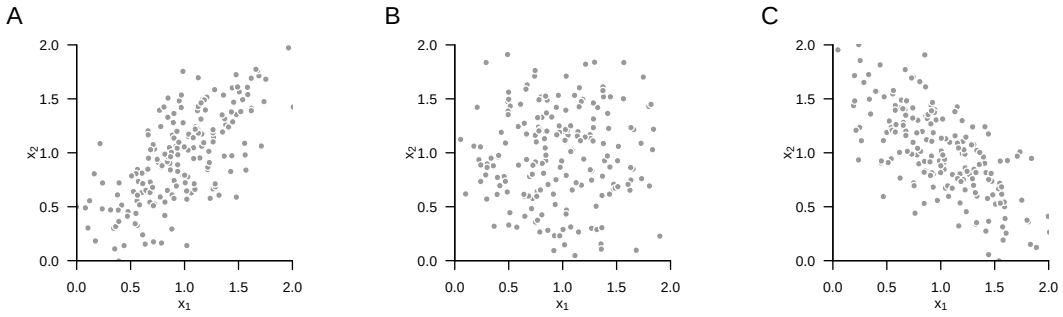


Abbildung 29.4. Realisierungen bivariat normalverteilter Zufallsvektoren.

Theorem 29.2 (Erwartungswert und Kovarianzmatrix normalverteilter Zufallsvektoren)**.** *$\xi \sim N(\mu, \Sigma)$ sei ein multivariat normalverteilter Zufallsvektor mit Erwartungswertparameter $\mu \in \mathbb{R}^n$ und Kovarianzmatrixparameter $\Sigma \in \mathbb{R}^{n \times n}$ pd. Dann gelten*

$$\mathbb{E}(\xi) = \mu \text{ und } \mathbb{C}(\xi) = \Sigma. \tag{29.10}$$

∘

Wie im Falle der univariat normalverteilten Zufallsvariablen entspricht der Parameter $\mu \in \mathbb{R}^n$ dem Wert höchster Wahrscheinlichkeitsdichte der multivariaten Normalverteilung. Analog zum Varianzparameter der univariat normalverteilten Zufallsvariable spezifizieren die Diagonalelemente von $\Sigma \in \mathbb{R}^{n \times n}$ pd die Breite der WDF bezüglich der Zufallsvektorkomponenten $\xi_1, ..., \xi_n$. Allgemein spezifiziert im Falle des multivariat normalverteilten Zufallsvektors das i, jte Element von $\Sigma \in \mathbb{R}^{n \times n}$ pd hier nun die Kovarianz der Zufallsvektorkomponenten ξ_i und ξ_j.

29.3. Sphärizität

Folgendes Theorem ist für die grundlegende Theorie des Allgemeinen linearen Modells zentral.

Theorem 29.3 (Sphärische multivariate Normalverteilung)**.** *Für $i = 1, ..., n$ seien $N(x_i; \mu_i, \sigma^2)$ die WDFen von n unabhängigen univariaten normalverteilten Zufallsvariablen $\xi_1, ..., \xi_n$ mit $\mu_1, ..., \mu_n \in \mathbb{R}$ und $\sigma^2 > 0$. Weiterhin sei $N(x; \mu, \sigma^2 I_n)$ die WDF eines n-variaten normalverteilten Zufallsvektors ξ mit Erwartungswertparameter $\mu := (\mu_1, ..., \mu_n)^T \in \mathbb{R}^n$. Dann gilt*

$$p_\xi(x) = p_{\xi_1, ..., \xi_n}(x_1, ..., x_n) = \prod_{i=1}^{n} p_{\xi_i}(x_i) \tag{29.11}$$

und insbesondere

$$N(x; \mu, \sigma^2 I_n) = \prod_{i=1}^{n} N(x_i; \mu_i, \sigma^2) \tag{29.12}$$

für alle $x = (x_1, ..., x_n)^T \in \mathbb{R}^n$.

∘

Beweis. Wir zeigen die Identität der multivariaten WDF $N(x; \mu, \sigma^2 I_n)$ mit dem Produkt von n univariaten WDFen $N(x_i; \mu_i, \sigma^2 I_n)$, wobei μ_i der $i$te Eintrag von $\mu \in \mathbb{R}^n$ ist. Es ergibt sich

$$\begin{aligned}
N\left(x; \mu, \sigma^2 I_n\right) &= (2\pi)^{-\frac{n}{2}} \left|\sigma^2 I_n\right|^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(x-\mu)^T(\sigma^2 I_n)^{-1}(x-\mu)\right) \\
&= \left(\prod_{i=1}^{n} 2\pi^{-\frac{1}{2}}\right) \left(\sigma^2\right)^{-\frac{n}{2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^T(x-\mu)\right) \\
&= \left(\prod_{i=1}^{n} \left(2\pi\sigma^2\right)^{-\frac{1}{2}}\right) \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu_i)^2\right) \\
&= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \prod_{i=1}^{n} \exp\left(-\frac{1}{2\sigma^2}(x_i-\mu_i)^2\right) \\
&= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x_i-\mu_i)^2\right) \\
&= \prod_{i=1}^{n} N\left(x_i; \mu_i, \sigma^2\right).
\end{aligned} \tag{29.13}$$

□

Einen Kovarianzmatrixparameter der Form $\Sigma = \sigma^2 I_n$ nennt man auch *sphärisch*, da die Isokonturen der WDF eines normalverteilten Zufallsvektors mit einem solchen Kovarianzmatrixparameter *Sphären* bilden (zum Beispiel Kreise bei $n = 2$ und Kugeln bei $n = 3$). Eine multivariate Normalverteilung mit sphärischem Kovarianzmatrixparameter nennt man entsprechend eine *sphärische Normalverteilung*. Theorem 29.3 besagt, dass die WDF eines n-dimensionalen normalverteilten Zufallsvektors mit sphärischem Kovarianzparameter der gemeinsamen WDF von n unabhängigen univariat normalverteilten Zufallsvariablen entspricht und umgekehrt. Eine Realisierung eines n-dimensionalen normalverteilten Zufallsvektors entspricht also den Realisierungen von n unabhängigen univariat normalverteilten Zufallsvariablen und umgekehrt. Man beachte, dass die Identität der Verteilungen der $\xi_i, i = 1, ..., n$ hier nicht vorausgesetzt ist, insbesondere können sich ihre Erwartungswertparameter $\mu_i, i = 1, ..., n$ explizit unterscheiden.

29.4. Marginale, bedingte und gemeinsame Verteilungen

Multivariate Normalverteilungen haben die Eigenschaft, dass auch alle anderen assoziierten Verteilungen Normalverteilungen sind und deren Erwartungswert- und Kovarianzmatrixparameter aus den Parametern der jeweils komplementären Verteilung errechnet werden können. Speziell gilt zum einen, dass die uni- und multivariaten Marginalverteilungen multivariater Normalverteilungen wiederum Normalverteilungen sind. Zum anderen lassen sich wie alle multivariaten Verteilungen multivariate Normalverteilungen multiplikativ in eine marginale und eine bedingte Verteilung zerlegen. Insbesondere sind nun aber bei multivariaten Normalverteilungen diese Verteilungen wiederum (multivariate) Normalverteilungen, deren Parameter aus den Parametern der gemeinsamen Verteilung errechnet werden können und umgekehrt. Wir fassen obige Erkenntnisse formal in den folgenden drei Theoremen zusammen.

Theorem 29.4 (Marginale Normalverteilungen)**.** *Es sei $n := k + l$ und $\xi = (\xi_1, ..., \xi_n)^T$ sei ein n-dimensionaler normalverteilter Zufallsvektor mit Erwartungswertparameter*

$$\mu = \begin{pmatrix} \mu_\upsilon \\ \mu_\zeta \end{pmatrix} \in \mathbb{R}^n, \tag{29.14}$$

mit $\mu_\upsilon \in \mathbb{R}^k$ *und* $\mu_\zeta \in \mathbb{R}^l$ *und Kovarianzmatrixparameter*

$$\Sigma = \begin{pmatrix} \Sigma_{\upsilon\upsilon} & \Sigma_{\upsilon\zeta} \\ \Sigma_{\zeta\upsilon} & \Sigma_{\zeta\zeta} \end{pmatrix} \in \mathbb{R}^{n \times n}, \tag{29.15}$$

mit $\Sigma_{\upsilon\upsilon} \in \mathbb{R}^{k \times k}$, $\Sigma_{\upsilon\zeta} \in \mathbb{R}^{k \times l}$, $\Sigma_{\zeta\upsilon} \in \mathbb{R}^{l \times k}$, *und* $\Sigma_{\zeta\zeta} \in \mathbb{R}^{l \times l}$. *Dann sind* $\upsilon := (\xi_1, ..., \xi_k)^T$ *und* $\zeta := (\xi_{k+1}, ..., \xi_n)^T$ *normalverteilte Zufallsvektoren der Dimension* k *bzw.* l, *und es gilt*

$$\upsilon \sim N(\mu_\upsilon, \Sigma_{\upsilon\upsilon}) \text{ und } \zeta \sim N(\mu_\zeta, \Sigma_{\zeta\zeta}). \tag{29.16}$$

∘

Die Marginalverteilungen einer multivariaten Normalverteilung sind also auch Normalverteilungen und die Parameter der Marginalverteilungen ergeben sich aus den Parametern der gemeinsamen Verteilung. Für Beweise dieses Theorems verweisen wir auf Mardia et al. (1979) und Anderson (2003).

29.5. Marginale Normalverteilungen

Abbildung 29.5 visualisiert Theorem 29.4 für den Fall $n := 2, k := 1, l := 1$,

$$\mu := \begin{pmatrix} 1 \\ 2 \end{pmatrix} \in \mathbb{R}^2 \text{ und } \Sigma := \begin{pmatrix} 0.10 & 0.08 \\ 0.08 & 0.15 \end{pmatrix} \in \mathbb{R}^{2 \times 2}. \tag{29.17}$$

Abbildung 29.5 A zeigt dabei die WDF des bivariaten Zufallsvektors ξ und Abbildung 29.5 B und C die WDFen der entsprechenden marginalen Zufallsvariablen υ und ζ.

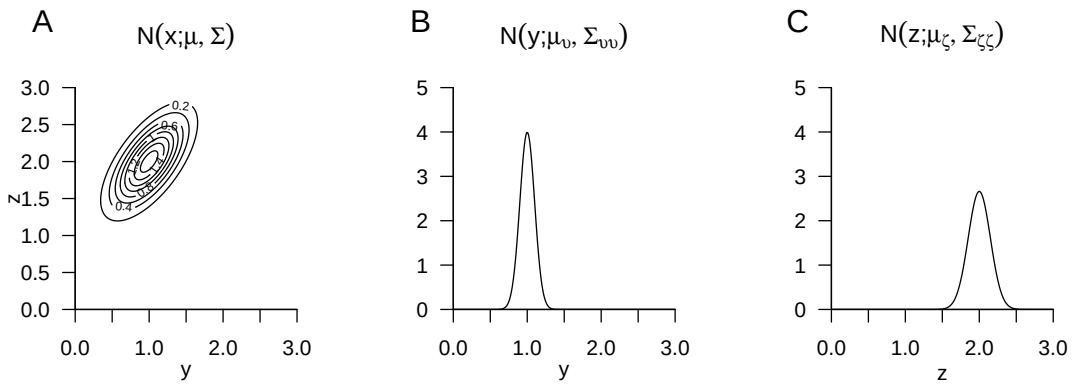


Abbildung 29.5. Marginale Verteilungen eines bivariaten normalverteilten Zufallsvektor.

Mithilfe einer marginalen und einer bedingten multivariaten Normalverteilung lässt sich eine gemeinsame multivariate Normalverteilung konstruieren, deren Parameter sich aus den Parametern der marginalen und bedingten Verteilung ergeben. Dies ist die zentrale Aussage folgenden Theorems.

Theorem 29.5 (Gemeinsame Normalverteilungen)**.** *ξ sei ein m-dimensionaler normalverteilter Zufallsvektor mit WDF*

$$p_\xi : \mathbb{R}^m \to \mathbb{R}_{>0},\ x \mapsto p_\xi(x) := N(x; \mu_\xi, \Sigma_{\xi\xi}) \text{ mit } \mu_\xi \in \mathbb{R}^m, \Sigma_{\xi\xi} \in \mathbb{R}^{m\times m}, \tag{29.18}$$

$A \in \mathbb{R}^{n\times m}$ sei eine Matrix, $b \in \mathbb{R}^n$ sei ein Vektor und υ sei ein n-dimensionaler bedingt normalverteilter Zufallsvektor mit bedingter WDF

$$p_{\upsilon|\xi}(\cdot|x) : \mathbb{R}^n \to \mathbb{R}_{>0},\ y \mapsto p_{\upsilon|\xi}(y|x) := N(y; Ax + b, \Sigma_{\upsilon\upsilon}) \text{ mit } \Sigma_{\upsilon\upsilon} \in \mathbb{R}^{n\times n}. \tag{29.19}$$

Die Matrizen $\Sigma_{\xi\xi}$ und $\Sigma_{\upsilon\upsilon}$ seien symmetrisch und positiv definit. Die bedingte Kovarianzmatrix $\Sigma_{\upsilon\upsilon}$ sei unabhängig von x. Dann ist der $m+n$-dimensionale Zufallsvektor $(\xi, \upsilon)^T$ normalverteilt mit (gemeinsamer) WDF

$$p_{\xi,\upsilon} : \mathbb{R}^{m+n} \to \mathbb{R}_{>0},\ \begin{pmatrix} x \\ y \end{pmatrix} \mapsto p_{\xi,\upsilon}\left(\begin{pmatrix} x \\ y \end{pmatrix}\right) = N\left(\begin{pmatrix} x \\ y \end{pmatrix}; \mu_{\xi,\upsilon}, \Sigma_{\xi,\upsilon}\right), \tag{29.20}$$

mit $\mu_{\xi,\upsilon} \in \mathbb{R}^{m+n}$ und $\Sigma_{\xi,\upsilon} \in \mathbb{R}^{(m+n)\times(m+n)}$ und insbesondere

$$\mu_{\xi,\upsilon} = \begin{pmatrix} \mu_\xi \\ A\mu_\xi + b \end{pmatrix} \text{ und } \Sigma_{\xi,\upsilon} = \begin{pmatrix} \Sigma_{\xi\xi} & \Sigma_{\xi\xi}A^T \\ A\Sigma_{\xi\xi} & \Sigma_{\upsilon\upsilon} + A\Sigma_{\xi\xi}A^T \end{pmatrix}. \tag{29.21}$$

∘

Die Parameter der gemeinsamen Verteilung ergeben sich also als linear-affine Transformationen der Parameter der induzierenden marginalen und bedingten Verteilungen.

Beispiel 29.3 (Gemeinsame Normalverteilungen)**.** Abbildung 29.6 visualisiert Theorem 29.5 für den Fall $m := 1, n := 1, \mu_\xi := 1, \Sigma_{\xi\xi} := 0.2, A := 1, b := 1$ und $\Sigma_{\upsilon\upsilon} := 0.1$. Abbildung 29.6 A zeigt dabei die WDF der Zufallsvariable ξ, Abbildung 29.6 B zeigt die WDF der bedingten Verteilung der Zufallsvariable υ gegeben ξ und Abbildung 29.5 C schließlich zeigt die WDFen des induzierten bivariaten Zufallsvektors (ξ, υ).

△

Die Definition einer multivariaten Normalverteilung erlaubt es weiterhin, die bedingten Verteilungen aller Komponenten des entsprechenden Zufallsvektors direkt mithilfe der Parameter der multivariaten Normalverteilung zu bestimmen. Dies ist die zentrale Aussage folgenden Theorems.

Theorem 29.6 (Bedingte Normalverteilungen)**.** *(ξ, υ) sei ein $m+n$-dimensionaler normalverteilter Zufallsvektor mit WDF*

$$p_{\xi,\upsilon} : \mathbb{R}^{m+n} \to \mathbb{R}_{>0},\ \begin{pmatrix} x \\ y \end{pmatrix} \mapsto p_{\xi,\upsilon}\left(\begin{pmatrix} x \\ y \end{pmatrix}\right) := N\left(\begin{pmatrix} x \\ y \end{pmatrix}; \mu_{\xi,\upsilon}, \Sigma_{\xi,\upsilon}\right), \tag{29.22}$$

mit

$$\mu_{\xi,\upsilon} = \begin{pmatrix} \mu_\xi \\ \mu_\upsilon \end{pmatrix}, \Sigma_{\xi,\upsilon} = \begin{pmatrix} \Sigma_{\xi\xi} & \Sigma_{\xi\upsilon} \\ \Sigma_{\upsilon\xi} & \Sigma_{\upsilon\upsilon} \end{pmatrix}, \tag{29.23}$$

mit $x, \mu_\xi \in \mathbb{R}^m, y, \mu_\upsilon \in \mathbb{R}^n$ und $\Sigma_{\xi\xi} \in \mathbb{R}^{m\times m}, \Sigma_{\xi\upsilon} \in \mathbb{R}^{m\times n}, \Sigma_{\upsilon\upsilon} \in \mathbb{R}^{n\times n}$. Dann ist die bedingte Verteilung von ξ gegeben υ eine m-dimensionale Normalverteilung mit bedingter WDF

$$p_{\xi|\upsilon}(\cdot|y) : \mathbb{R}^m \to \mathbb{R}_{>0}, x \mapsto p_{\xi|\upsilon}(x|y) := N(x; \mu_{\xi|\upsilon}, \Sigma_{\xi|\upsilon}) \tag{29.24}$$

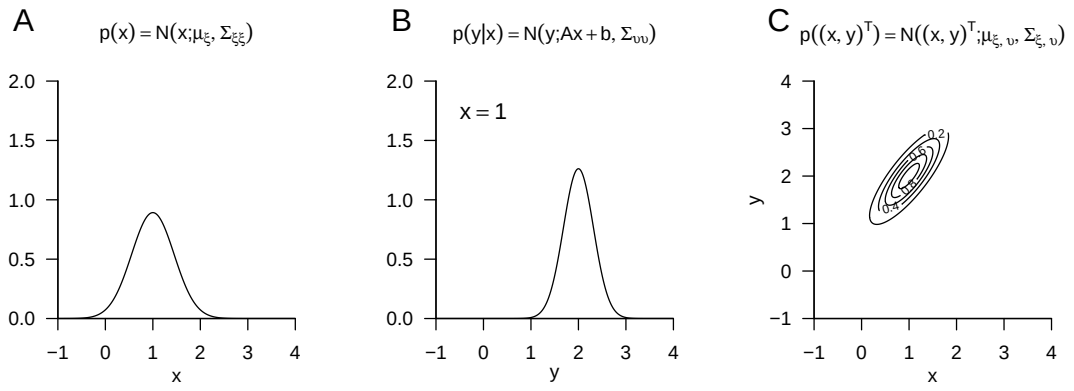


Abbildung 29.6. Gemeinsame Verteilungen einer marginalen und einer auf dieser bedingten normalverteilten Zufallsvariablen.

mit

$$\mu_{\xi|\upsilon} = \mu_\xi + \Sigma_{\xi\upsilon}\Sigma_{\upsilon\upsilon}^{-1}(y - \mu_\upsilon) \in \mathbb{R}^m \tag{29.25}$$

und

$$\Sigma_{\xi|\upsilon} = \Sigma_{\xi\xi} - \Sigma_{\xi\upsilon}\Sigma_{\upsilon\upsilon}^{-1}\Sigma_{\upsilon\xi} \in \mathbb{R}^{m\times m}. \tag{29.26}$$

∘

Im Zusammenspiel mit Theorem 29.5 und Theorem 29.4 können die Parameter bedingter und marginaler Normalverteilungen also aus den Parametern der komplementären bedingten und marginalen Normalverteilungen bestimmt werden.

Beispiel 29.4 (Bedingte Normalverteilungen)**.** Abbildung 29.7 visualisiert Theorem 29.6 für den Fall $m := 2, n := 1$,

$$\mu := \begin{pmatrix} 1 \\ 2 \end{pmatrix} \text{ und } \Sigma := \begin{pmatrix} 0.12 & 0.09 \\ 0.09 & 0.12 \end{pmatrix} \tag{29.27}$$

Dabei zeigt Abbildung 29.7 A die WDF des bivariaten Zufallsvektors $(\xi, \upsilon)^T$ und Abbildung 29.7 B und C zeigen die WDF der bedingten Verteilung der Zufallsvariable ξ gegeben $\upsilon = 1.5$ und $\upsilon = 2.8$, respektive.

△

29.6. Multivariate Transformationen

In diesem Abschnitt stellen wir einige Resultate zu den Verteilungen transformierter normalverteilter Zufallsvektoren zusammen. Wir verzichten dabei auf Beweise.

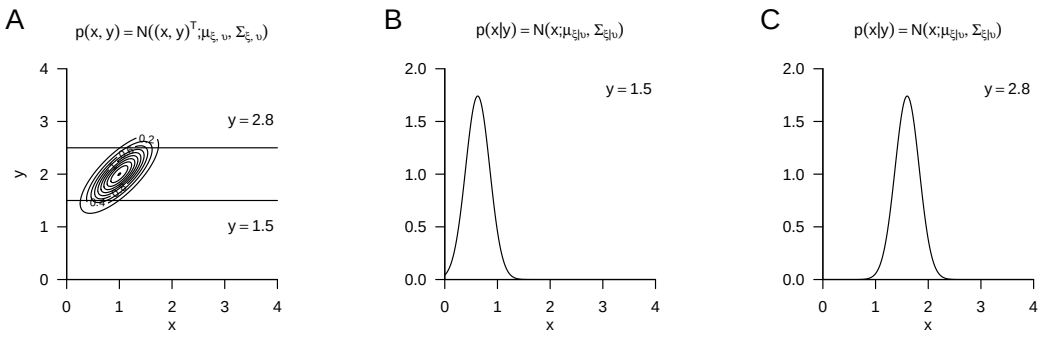


Abbildung 29.7. Bedingte Normalverteilungen

Theorem 29.7 (Invertierbare lineare Transformation eines normalverteilten Zufallsvektors)**.** *$\xi \sim N(\mu_\xi, \Sigma_\xi)$ sei ein normalverteilter n-dimensionaler Zufallsvektor und es sei $\zeta := A\xi$ mit einer invertierbaren Matrix $A \in \mathbb{R}^{n \times n}$. Dann gilt*

$$\zeta \sim N\left(\mu_\zeta, \Sigma_\zeta\right) \text{ mit } \mu_\zeta = A\mu_\xi \text{ und } \Sigma_\zeta = A\Sigma_\xi A^T. \tag{29.28}$$

∘

Nach Theorem 29.7 ergibt die invertierbare lineare Transformation eines multivariat normalverteilten Zuallsvektors also wiederum einen multivariat normalverteilten Zufallsvektor und die Parameter der Verteilung dieses normalverteilten Zufallsvektors ergeben sich aus den Parametern der Verteilung des ursprünglichen Zufallsvektors und der Transformationsmatrix.

Beispiel 29.5 (Invertierbare lineare Transformation einer bivariaten Normalverteilung)**.** Als Beispiel betrachten wir die invertierbare lineare Transformation eines bivariaten normalverteilten Zufallsvektors ξ. Es seien

$$\mu_\xi := \begin{pmatrix} 1 \\ 1 \end{pmatrix} \text{ und } \Sigma_\xi := \begin{pmatrix} 0.20 & 0.15 \\ 0.15 & 0.20 \end{pmatrix} \tag{29.29}$$

der Erwartungswert- und Kovarianzmatrixparameter von ξ, respektive, und es sei

$$A := \begin{pmatrix} -2 & 1 \\ -1 & 2 \end{pmatrix} \tag{29.30}$$

die Transformationsmatrix. Da $|A| = -3 \neq 0$ ist A invertierbar und es gilt nach Theorem 29.7, dass

$$\zeta \sim N(\mu_\zeta, \Sigma_\zeta) \text{ mit } \mu_\zeta = A\mu_\xi = \begin{pmatrix} -1 \\ 1 \end{pmatrix} \text{ und } A\Sigma_\xi A^T = \begin{pmatrix} 0.40 & 0.05 \\ 0.05 & 0.40 \end{pmatrix}. \tag{29.31}$$

Abbildung 29.8 A zeigt Isokonturen der WDF von ξ und Realisierungen $x^{(i)} \in \mathbb{R}^2$ von ξ für $i = 1, ..., 50$. Abbildung 29.8 B zeigt die transformierten Realisierungen $z^{(i)} = Ax^{(i)} \in \mathbb{R}^2$ von ζ sowie die Isokonturen der WDF von ζ nach Theorem 29.7.

△

Die Tatsache, dass ein linear transformierter normalverteilter Zufallsvektor wiederum normalverteilt ist und dass sich die Parameter der Verteilung des transformierten Zufallsvektors aus den Parametern der Verteilung des ursprünglichen Zufallsvektors sowie den

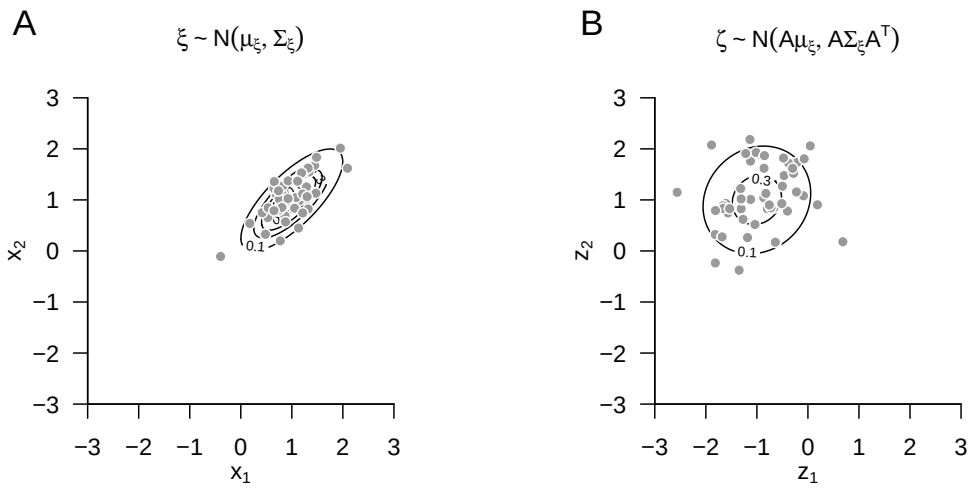


Abbildung 29.8. Invertierbare lineare Transformation eines normalverteilten Zufallsvektors

Transformationsparametern bestimmen lassen, bleibt auch im Falle einer nicht notwendigerweise invertierbaren linearen Transformation und auch im Falle einer nicht notwendigerweise invertierbaren linear-affinen Transformation wahr. Dies ist die Aussage folgenden zentralen Theorems.

Theorem 29.8 (Linear-affine Transformation eines normalverteilten Zufallsvektors)**.** $\xi \sim N(\mu_\xi, \Sigma_\xi)$ *sei ein normalverteilter n-dimensionaler Zufallsvektor und es sei*

$$\zeta := A\xi + b \text{ mit } A \in \mathbb{R}^{m \times n} \text{ und } b \in \mathbb{R}^m. \tag{29.32}$$

Dann gilt

$$\zeta \sim N(\mu_\zeta, \Sigma_\zeta) \text{ mit } \mu_\zeta = A\mu_\xi + b \in \mathbb{R}^m \text{ und } \Sigma_\zeta = A\Sigma_\xi A^T \in \mathbb{R}^{m \times m}. \tag{29.33}$$

∘

Die resultierende Normalverteilung kann degeneriert sein. Ist Σ_ξ positiv definit, so ist $A\Sigma_\xi A^T$ genau dann positiv definit, wenn A vollen Zeilenrang besitzt.

Für einen Beweis verweisen wir auf Anderson (2003).

29.7. Transformationen normalverteilter Zufallsvariablen

In diesem Abschnitt diskutieren wir sechs Transformationen normalverteilter Zufallsvariablen, die in der Frequentistischen Inferenz zentrale Rollen spielen und bei denen es sich um Anwendungen von den in Kapitel 28 eingeführten Transformationstheoremen handelt. Unsere Aussagen sind dabei meist von der allgemeinen Form "Wenn $\xi_i, i = 1, ..., n$ unabhängig und identisch normalverteilte Zufallsvariablen sind und $v := f(\xi_1, ..., \xi_n)$ eine Transformation dieser Zufallsvariablen ist, dann ist die WDF von v durch die Formel $p_v := \{\text{Formel}\}$ gegeben und man nennt die Verteilung von v *Verteilungsname*". Aussagen dieser Form

sind für die Frequentistische Inferenz zentral, weil erstens die Zentralen Grenzwertsätze die Annahme additiv unabhängig normalverteilter Störvariablen, und damit normalverteilter Daten, begründet, zweitens, wie wir in Kapitel 30 sehen werden, es sich bei Schätzern und Statistiken um Transformationen von Zufallsvariablen handelt, und drittens, Parameterschätzergütekriterien, Konfidenzintervalle und Hypothesentests der Frequentistischen Inferenz durch die Verteilungen der jeweiligen Schätzer und Statistiken charakterisiert und begründet sind.

Summationstransformation

In diesem Abschnitt betrachten wir die resultierenden Verteilungen bei Summation und Mittelwertbildung von unabhängig und identisch normalverteilten Zufallsvariablen. Speziell besagt Theorem 29.9, dass die Summe unabhängig normalverteilter Zufallsvariablen wiederum normalverteilt ist und gibt die Parameter dieser Verteilung an, während Theorem 29.10 besagt, dass das Stichprobenmittel unabhängig normalverteilter Zufallsvariablen wiederum normalverteilt ist und gibt die Parameter dieser Verteilung an.

Theorem 29.9 (Summationstransformation)**.** *Für $i = 1, ..., n$ seien $\xi_i \sim N(\mu_i, \sigma_i^2)$ unabhängige normalverteilte Zufallsvariablen. Dann gilt für die Summe $\upsilon := \sum_{i=1}^{n} \xi_i$, dass*

$$\upsilon \sim N\left(\sum_{i=1}^{n} \mu_i, \sum_{i=1}^{n} \sigma_i^2\right) \tag{29.34}$$

Für unabhängige und identisch normalverteilte Zufallsvariablen $\xi_i \sim N(\mu, \sigma^2)$ gilt folglich

$$\upsilon \sim N(n\mu, n\sigma^2). \tag{29.35}$$

∘

Beweis. Wir skizzieren mithilfe von Theorem 28.6, dass für $\xi_1 \sim N(\mu_1, \sigma_1^2)$, $\xi_2 \sim N(\mu_2, \sigma_2^2)$, und $\upsilon := \xi_1 + \xi_2$ gilt, dass $\upsilon \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$. Für $n > 2$ folgt das Theorem dann durch Iteration. Mit der Definition der WDF der Normalverteilung erhalten wir zunächst

$$\begin{aligned}
p_\upsilon(y) &= \int_{-\infty}^{\infty} p_{\xi_1}(x_1) p_{\xi_2}(y - x_1)\, dx_1 \\
&= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}\sigma_1} \exp\left(-\frac{1}{2}\left(\frac{x_1 - \mu_1}{\sigma_1}\right)^2\right) \frac{1}{\sqrt{2\pi}\sigma_2} \exp\left(-\frac{1}{2}\left(\frac{y - x_1 - \mu_2}{\sigma_2}\right)^2\right) dx_1 \\
&= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{1}{2}\left(\frac{x_1 - \mu_1}{\sigma_1}\right)^2 - \frac{1}{2}\left(\frac{y - x_1 - \mu_2}{\sigma_2}\right)^2\right) dx_1.
\end{aligned} \tag{29.36}$$

Mit einigem algebraischen Aufwand erhält man die Identität

$$-\frac{1}{2}\left(\frac{x_1 - \mu_1}{\sigma_1}\right)^2 - \frac{1}{2}\left(\frac{y - x_1 - \mu_2}{\sigma_2}\right)^2 = -\frac{(y - \mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)} - \frac{((\sigma_1^2 + \sigma_2^2)x_1 - \sigma_1^2 y + \mu_2\sigma_1^2 - \mu_1\sigma_2^2)^2}{2\sigma_1^2\sigma_2^2(\sigma_1^2 + \sigma_2^2)}, \tag{29.37}$$

so dass weiterhin gilt, dass

$$\begin{aligned}
p_\upsilon(y) &= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(y - \mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)} - \frac{((\sigma_1^2 + \sigma_2^2)x_1 - \sigma_1^2 y + \mu_2\sigma_1^2 - \mu_1\sigma_2^2)^2}{2\sigma_1^2\sigma_2^2(\sigma_1^2 + \sigma_2^2)}\right) dx_1 \\
&= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(y - \mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right) \exp\left(-\frac{((\sigma_1^2 + \sigma_2^2)x_1 - \sigma_1^2 y + \mu_2\sigma_1^2 - \mu_1\sigma_2^2)^2}{2\sigma_1^2\sigma_2^2(\sigma_1^2 + \sigma_2^2)}\right) dx_1 \\
&= \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(y - \mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right) \int_{-\infty}^{\infty} \exp\left(-\frac{((\sigma_1^2 + \sigma_2^2)x_1 - \sigma_1^2 y + \mu_2\sigma_1^2 - \mu_1\sigma_2^2)^2}{2\sigma_1^2\sigma_2^2(\sigma_1^2 + \sigma_2^2)}\right) dx_1.
\end{aligned} \tag{29.38}$$

Für das verbleibende Integral zeigt man mithilfe der Integration durch Substitution, dass

$$\int_{-\infty}^{\infty} \exp\left(-\frac{((\sigma_1^2+\sigma_2^2)x_1 - \sigma_1^2 y + \mu_2\sigma_1^2 - \mu_1\sigma_2^2)^2}{2\sigma_1^2\sigma_2^2(\sigma_1^2+\sigma_2^2)}\right) dx_1 = \frac{\sqrt{2\pi}\sigma_1\sigma_2}{\sqrt{\sigma_1^2+\sigma_2^2}}. \tag{29.39}$$

Es ergibt sich also

$$\begin{aligned} p_v(y) &= \frac{1}{2\pi\sigma_1\sigma_2}\frac{\sqrt{2\pi}\sigma_1\sigma_2}{\sqrt{\sigma_1^2+\sigma_2^2}}\exp\left(-\frac{(y-\mu_1-\mu_2)^2}{2(\sigma_1^2+\sigma_2^2)}\right) \\ &= \frac{(2\pi)^{-1}(2\pi)^2}{\sqrt{\sigma_1^2+\sigma_2^2}}\exp\left(-\frac{(y-\mu_1-\mu_2)^2}{2(\sigma_1^2+\sigma_2^2)}\right) \\ &= \frac{1}{\sqrt{2\pi}\sqrt{\sigma_1^2+\sigma_2^2}}\exp\left(-\frac{(y-\mu_1-\mu_2)^2}{2(\sigma_1^2+\sigma_2^2)}\right). \end{aligned} \tag{29.40}$$

Schließlich folgt, dass

$$p_v(y) = \frac{1}{\sqrt{2\pi(\sigma_1^2+\sigma_2^2)}}\exp\left(-\frac{1}{2(\sigma_1^2+\sigma_2^2)}\left(y-(\mu_1+\mu_2)\right)^2\right) = N(y;\mu_1+\mu_2,\sigma_1^2+\sigma_2^2) \tag{29.41}$$

Ein einfacheres Vorgehen ergibt sich vermutlich nach Fouriertransformation der WDF im Sinne der sogenannten charakteristischen Funktion einer Zufallsvariable. In diesem Fall würde die Faltung der WDFen der Multiplikation der charakteristischen Funktionen entsprechen. □

Ein wichtiger Anwendungsfall von Theorem 29.9 ist das nachfolgende Theorem 29.10 sowie die in Gleichung 27.18 und Gleichung 27.25 erwähnten Generalisierungen der Zentralen Grenzwertsätze. Wir visualisieren Theorem 29.9 exemplarisch in Abbildung 29.9.

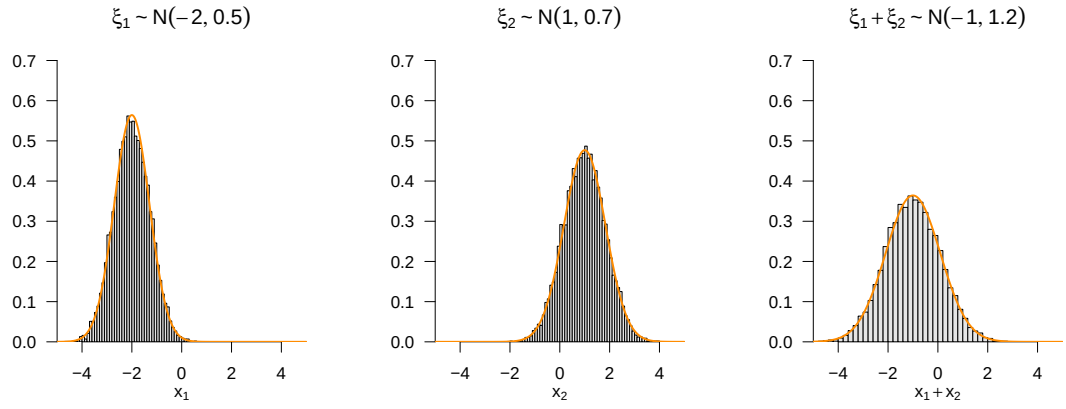


Abbildung 29.9. Summation normalverteilter Zufallsvariablen.

Mittelwerttransformation

Theorem 29.10 (Mittelwertstransformation). *Für $i = 1, ..., n$ seien $\xi_i \sim N(\mu, \sigma^2)$ unabhängig und identisch normalverteilte Zufallsvariablen. Dann gilt für das Stichprobenmittel $\bar{\xi}_n := \frac{1}{n}\sum_{i=1}^{n}\xi_i$, dass*

$$\bar{\xi}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right). \tag{29.42}$$

∘

Beweis. Wir halten zunächst fest, dass mit dem Theorem zur Summe von unabhängig normalverteilten Zufallsvariablen gilt, dass $\bar{\xi}_n = \frac{1}{n}\upsilon$ mit $\upsilon := \sum_{i=1}^{n} \xi_i \sim N(n\mu, n\sigma^2)$. Einsetzen in Theorem 28.3 ergibt dann

$$\begin{aligned}
p_{\bar{\xi}_n}(\bar{x}_n) &= \frac{1}{|1/n|} N\left(n\bar{x}_n; n\mu, n\sigma^2\right) \\
&= \frac{n}{\sqrt{2\pi n\sigma^2}} \exp\left(-\frac{1}{2n\sigma^2}\left(n\bar{x}_n - n\mu\right)^2\right) \\
&= \frac{n}{\sqrt{2\pi n\sigma^2}} \exp\left(-\frac{1}{2n\sigma^2}\left(n\bar{x}_n - n\mu\right)^2\right) \\
&= nn^{-\frac{1}{2}} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(n\bar{x}_n)^2}{2n\sigma^2} + \frac{2(n\bar{x}_n)(n\mu)}{2n\sigma^2} - \frac{(n\mu)^2}{2n\sigma^2}\right) \\
&= \sqrt{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{n\bar{x}_n^2}{2\sigma^2} + \frac{2n\bar{x}_n\mu}{2\sigma^2} - \frac{n\mu^2}{2\sigma^2}\right) \\
&= \frac{1}{1/\sqrt{n}} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{\bar{x}_n^2}{2(\sigma^2/n)} + \frac{2\bar{x}_n\mu}{2(\sigma^2/n)} - \frac{\mu^2}{2(\sigma^2/n)}\right) \\
&= \frac{1}{\sqrt{2\pi(\sigma^2/n)}} \exp\left(-\frac{1}{2(\sigma^2/n)}(\bar{x}_n - \mu)^2\right) \\
&= N\left(\bar{x}_n; \mu, \sigma^2/n\right)
\end{aligned} \tag{29.43}$$

□

Wichtige Anwendungsfälle von Theorem 29.10 sind die Analyse von Erwartungswertschätzern in Kapitel 31 sowie die in Gleichung 27.18 erwähnte Generalisierung des Zentralen Grenzwertsatzes nach Lindeberg-Lévy. Wir visualisieren Theorem 29.10 exemplarisch in Abbildung 29.10.

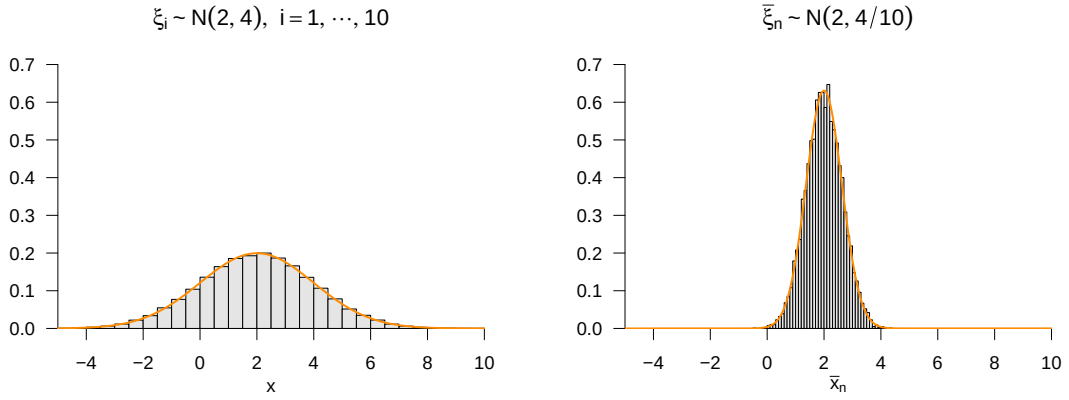


Abbildung 29.10. Mittelwertbildung bei normalverteilten Zufallsvariablen.

Z-Transformation

Das Theorem 29.11 besagt, dass Subtraktion des Erwartungswertparameters und gleichzeitige Division mit der Wurzel des Varianzparameters die Verteilung einer normalverteilten Zufallsvariable in eine Standardnormalverteilung transformiert.

Theorem 29.11 (Z-Transformation)**.** *Es sei $\upsilon \sim N(\mu, \sigma^2)$ eine normalverteilte Zufallsvariable. Dann ist die Zufallsvariable*

$$Z := \frac{\upsilon - \mu}{\sigma} \tag{29.44}$$

eine standardnormalverteilte Zufallsvariable, es gilt also $Z \sim N(0, 1)$.

∘

Beweis. Wir nutzen Theorem 28.3. Dazu halten wir zunächst fest, dass die Z-Transformation einer Funktion der Form

$$f(v) := \frac{v - \mu}{\sigma} =: Z \tag{29.45}$$

entspricht. Wir stellen weiterhin fest, dass die Umkehrfunktion von f durch

$$f^{-1}(Z) := \sigma Z + \mu \tag{29.46}$$

gegeben ist, da für alle $z \in \mathbb{R}$ mit $z = y - \mu\sigma$ gilt, dass

$$\zeta^{-1}(z) = \zeta^{-1}\left(\frac{y - \mu}{\sigma}\right) = \frac{\sigma(y - \mu)}{\sigma} + \mu = y - \mu + \mu = y. \tag{29.47}$$

Schließlich stellen wir fest, dass für die Ableitung f' von f gilt, dass

$$f'(y) = \frac{d}{dy}\left(\frac{y - \mu}{\sigma}\right) = \frac{d}{dy}\left(\frac{y}{\sigma} - \frac{\mu}{\sigma}\right) = \frac{1}{\sigma}. \tag{29.48}$$

Einsetzen in Theorem 28.3 ergibt dann

$$\begin{aligned} p_Z(z) &= \frac{1}{|1/\sigma|} N\left(\sigma z + \mu; \mu, \sigma^2\right) \\ &= \frac{1}{1/\sqrt{\sigma^2}} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}\left(\sigma z + \mu - \mu\right)^2\right) \\ &= \frac{\sqrt{\sigma^2}}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}\sigma^2 z^2\right) \\ &= \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}z^2\right) \\ &= N(z; 0, 1) \end{aligned} \tag{29.49}$$

also, dass $Z \sim N(0, 1)$. □

Wichtige Anwendungsfälle von Theorem 29.11 sind neben der häufig angewandten Standardisierung von normalverteilten Zufallsvariablen im Sinne der sogenannten *Z-Werte (Z-Scores)* die Z-Konfidenzintervallstatistik und die Z-Teststatistik. Wir visualisieren Theorem 29.11 exemplarisch in Abbildung 29.11.

χ^2-Transformation

Mit der χ^2-Transformation führen wir nun eine erste Transformation unabhängig und identisch normalverteilter Zufallsvariablen ein, die *nicht* wiederum auf eine Normalverteilung führt. Speziell besagt Theorem 29.12, dass die Summe quadrierter unabhängiger standardnormalverteilter Zufallsvariablen eine χ^2-verteilte Zufallsvariable ist. Dazu erinnern wir zunächst an den Begriff der χ^2-Zufallsvariable als Spezialfall der in Kapitel 21 betrachteten Gammazufallsvariablen (vgl. Definition 21.10).

Definition 29.3 (χ^2-Zufallsvariable)**.** U sei eine Zufallsvariable mit Ergebnisraum $\mathbb{R}_{>0}$ und WDF

$$p : \mathbb{R}_{>0} \to \mathbb{R}_{>0}, u \mapsto p(u) := \frac{1}{\Gamma\left(\frac{n}{2}\right) 2^{\frac{n}{2}}} u^{\frac{n}{2}-1} \exp\left(-\frac{1}{2}u\right), \tag{29.50}$$

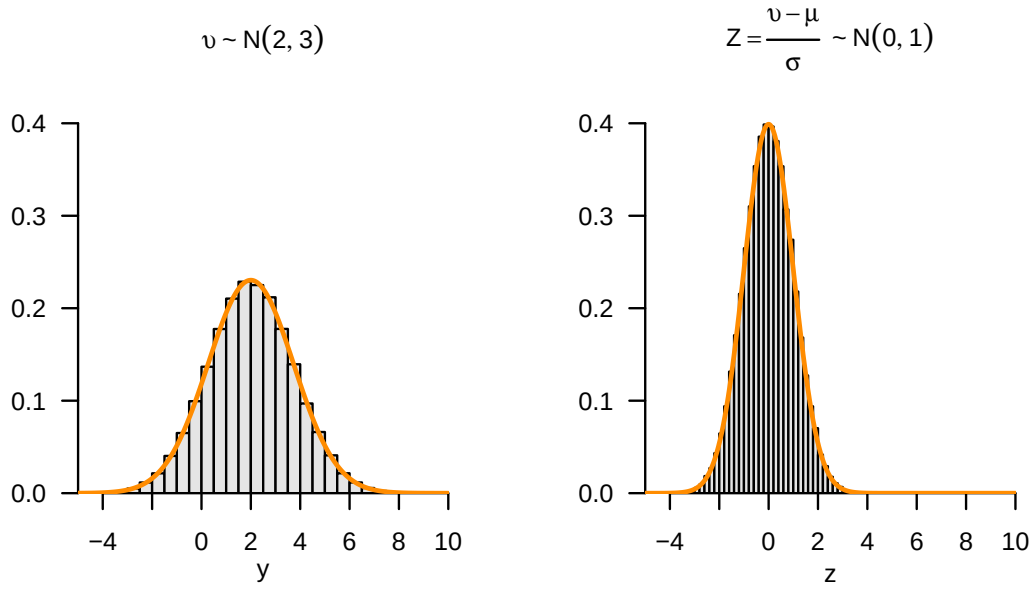


Abbildung 29.11. Z-Transformation normalverteilter Zufallsvariablen.

wobei Γ die Gammafunktion bezeichne. Dann sagen wir, dass U einer χ^2-Verteilung mit Freiheitsgradparameter n unterliegt und nennen U eine χ^2-Zufallsvariable mit Freiheitsgradparameter n. Wir kürzen dies mit $U \sim \chi^2(n)$ ab. Die WDF einer χ^2-Zufallsvariable bezeichnen wir mit

$$\chi^2(u; n) := \frac{1}{\Gamma\left(\frac{n}{2}\right) 2^{\frac{n}{2}}} u^{\frac{n}{2}-1} \exp\left(-\frac{1}{2}u\right). \tag{29.51}$$

•

Wir erinnern daran, dass die WDF der χ^2-Verteilung der WDF $G\left(u; \frac{n}{2}, 2\right)$ einer Gammaverteilung entspricht. In Abbildung 29.12 visualisieren wir exemplarisch einige WDFen von χ^2-Zufallsvariablen. Wir beobachten, dass mit ansteigendem n sich $\chi^2(u; n)$ verbreitert und Wahrscheinlichkeitsmasse zu größeren Werten von u verschoben wird.

Theorem 29.12 (χ^2-Transformation)**.** *$Z_1, ..., Z_n \sim N(0, 1)$ seien unabhängig und identisch standardnormalverteilte Zufallsvariablen. Dann ist die Zufallsvariable*

$$U := \sum_{i=1}^{n} Z_i^2 \tag{29.52}$$

eine χ^2-verteilte Zufallsvariable mit Freiheitsgradparameter n, es gilt also $U \sim \chi^2(n)$. Insbesondere gilt für $Z \sim N(0, 1)$ und $U := Z^2$, dass $U \sim \chi^2(1)$.

∘

Beweis. Wir zeigen das Theorem nur für den Fall $n := 1$ mithilfe von Theorem 28.4. Danach ist die WDF einer Zufallsvariable $U := f(Z)$, welche aus der Transformation einer Zufallsvariable Z mit WDF p_ζ durch eine stückweise bijektive Abbildung hervorgeht, gegeben durch

$$p_U(u) = \sum_{i=1}^{k} 1_{U_i} \frac{1}{|f_i'(f_i^{-1}(u))|} p_\zeta\left(f_i^{-1}(u)\right). \tag{29.53}$$

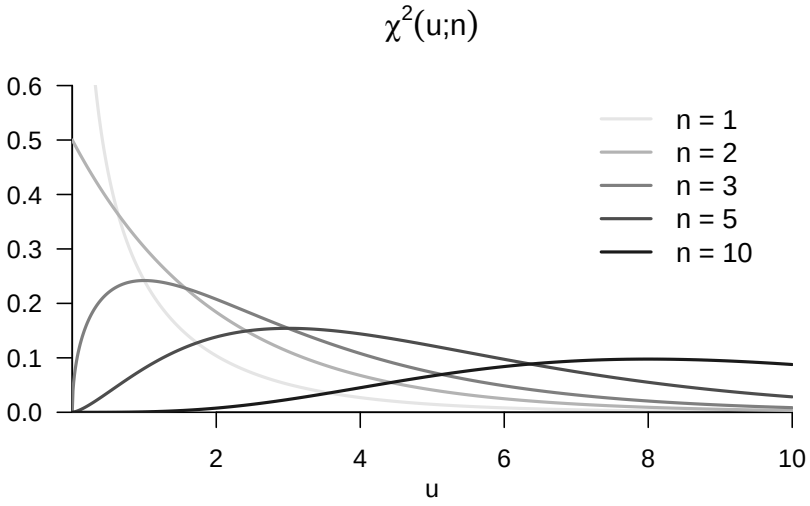


Abbildung 29.12. WDFen von χ^2 Zufallsvariablen.

Wir definieren

$$\mathcal{U}_1 :=]-\infty, 0[, \mathcal{U}_2 :=]0, \infty[, \text{ und } \mathcal{U}_i := \mathbb{R}_{>0} \text{ für } i = 1, 2, \tag{29.54}$$

sowie

$$f_i : \mathcal{Z}_i \to \mathcal{U}_i, x \mapsto f_i(z) := z^2 =: u \text{ für } i = 1, 2. \tag{29.55}$$

Die Ableitung und die Umkehrfunktion der f_i ergeben sich zu

$$f_i' : \mathcal{Z}_i \to \mathcal{Z}_i, x \mapsto f_i'(z) = 2z \text{ für } i = 1, 2, \tag{29.56}$$

und

$$f_1^{-1} : \mathcal{U}_1 \to \mathcal{U}_1, u \mapsto f_1^{-1}(u) = -\sqrt{u} \text{ und } f_2^{-1} : \mathcal{U}_2 \to \mathcal{U}_2, u \mapsto f_2^{-1}(u) = \sqrt{u}, \tag{29.57}$$

respektive. Einsetzen ergibt dann

$$\begin{aligned}
p_U(u) &= 1_{\mathcal{U}_1}(u) \frac{1}{|f_1'(f_1^{-1}(u))|} p_\zeta\left(f_1^{-1}(u)\right) + 1_{\mathcal{U}_2}(u) \frac{1}{|f_2'(f_2^{-1}(u))|} p_\zeta\left(f_2^{-1}(u)\right) \\
&= \frac{1}{|2(-\sqrt{u})|} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(-\sqrt{u})^2\right) + \frac{1}{|2(\sqrt{u})|} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(\sqrt{u})^2\right) \\
&= \frac{1}{2\sqrt{u}} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}u\right) + \frac{1}{2\sqrt{u}} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}u\right) \\
&= \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{u}} \exp\left(-\frac{1}{2}u\right).
\end{aligned} \tag{29.58}$$

Andererseits gilt, dass mit $\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$, die PDF einer χ^2-Zufallsvariable U mit $n = 1$ durch

$$\frac{1}{\Gamma\left(\frac{1}{2}\right) 2^{\frac{1}{2}}} u^{\frac{1}{2}-1} \exp\left(-\frac{1}{2}u\right) = \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{u}} \exp\left(-\frac{1}{2}u\right) \tag{29.59}$$

gegeben ist. Also gilt, dass wenn $Z \sim N(0, 1)$ ist, dann ist $U := Z^2 \sim \chi^2(1)$. □

Wichtige Anwendungsfälle sind die U-Konfidenzintervallstatistik sowie die im Folgenden eingeführten t- und F-Zufallsvariablen. Wir visualisieren Theorem 29.12 exemplarisch in Abbildung 29.13.

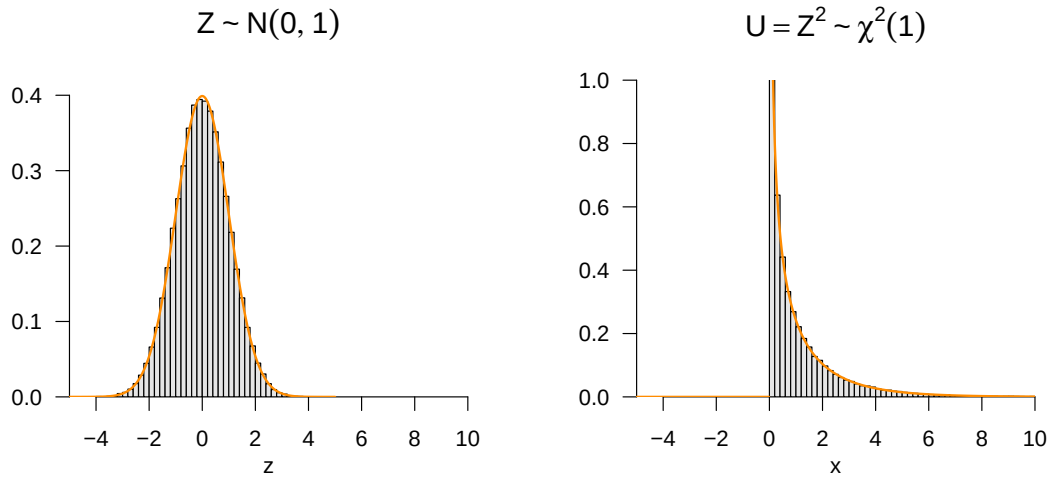


Abbildung 29.13. χ^2-Transformation normalverteilter Zufallsvariablen.

T-Transformation

Das in diesem Abschnitt betrachtete Theorem geht auf Student (1908) zurück und ist das zentrale und stilprägende Resultat der Entwicklung der Frequentistischen Inferenz in der ersten Hälfte der 20. Jahrhunderts. Hald (2007) und Zabell (2008) geben hierzu einen historischen Überblick. Das zentrale Theorem 29.13 besagt dabei, dass die Zufallsvariable, die sich durch Division einer standardnormalverteilten Zufallsvariable durch die Quadratwurzel einer χ^2-verteilten Zufallsvariable geteilt durch ein n, ergibt, eine t-verteilte Zufallsvariable ist. Dabei ist eine t-verteilte Zufallsvariable wie folgt definiert.

Definition 29.4 (t-Zufallsvariable)**.** T sei eine Zufallsvariable mit Ergebnisraum $\mathbb{R}$ und WDF

$$p : \mathbb{R} \to \mathbb{R}_{>0}, t \mapsto p(t) := \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}, \tag{29.60}$$

wobei Γ die Gammafunktion bezeichne. Dann sagen wir, dass T einer t-Verteilung mit Freiheitsgradparameter n unterliegt und nennen T eine t-Zufallsvariable mit Freiheitsgradparameter n. Wir kürzen dies mit $T \sim t(n)$ ab. Die WDF einer t-Zufallsvariable bezeichnen wir mit

$$T(t; n) := \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}. \tag{29.61}$$

•

In Abbildung 29.14 visualisieren wir exemplarisch einige WDFen von t-Zufallsvariablen. Wir beobachten, dass die t-Verteilung immer um 0 symmetrisch ist und ein steigendes n Wahrscheinlichkeitsmasse aus den Ausläufen zum Zentrum verschiebt. Wir merken an, dass ab etwa $n = 30$ gilt, dass $T(t; n) \approx N(0, 1)$.

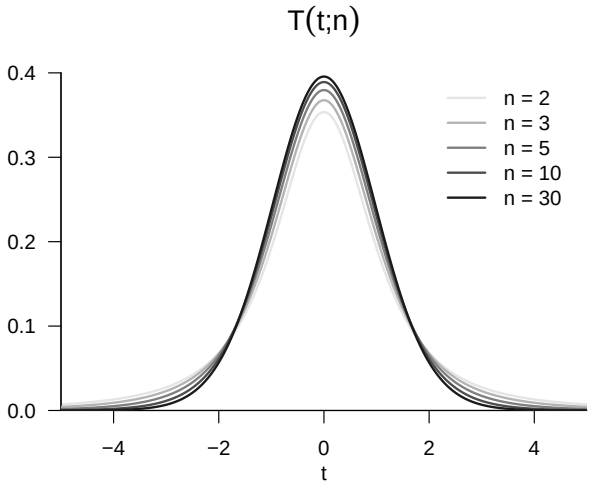


Abbildung 29.14. WDFen von T-Zufallsvariablen.

Theorem 29.13 (T-Transformation)**.** *$Z \sim N(0,1)$ sei eine standardnormalverteilte Zufallsvariable, $U \sim \chi^2(n)$ sei eine χ^2-Zufallsvariable mit Freiheitsgradparameter n, und Z und U seien unabhängig. Dann ist die Zufallsvariable*

$$T := \frac{Z}{\sqrt{U/n}} \tag{29.62}$$

eine t-verteilte Zufallsvariable mit Freiheitsgradparameter n, es gilt also $T \sim t(n)$.

∘

Beweis. Wir halten zunächst fest, dass die zweidimensionale WDF der gemeinsamen (unabhängigen) Verteilung von Z und U durch

$$p_{Z,U}(z,u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}z^2\right) \frac{1}{\Gamma(\frac{n}{2})2^{\frac{n}{2}}} u^{\frac{n}{2}-1} \exp\left(-\frac{1}{2}u\right). \tag{29.63}$$

gegeben ist. Wir betrachten dann die multivariate vektorwertige Abbildung

$$f : \mathbb{R}^2 \to \mathbb{R}^2, (z,u) \mapsto f(z,u) := \left(\frac{z}{\sqrt{u/n}}, u\right) =: (t,w) \tag{29.64}$$

und benutzen das multivariate WDF Transformationstheorem für bijektive Abbildungen um die WDF von (t,w) herzuleiten. Dazu erinnern wir uns, dass wenn ξ ein n-dimensionaler Zufallsvektor mit WDF p_ξ und $\upsilon := f(\xi)$ für eine differenzierbare und bijektive Abbildung $f : \mathbb{R}^n \to \mathbb{R}^n$ ist, die WDF des Zufallsvektors υ durch

$$p_\upsilon : \mathbb{R}^n \to \mathbb{R}_{\geq 0}, y \mapsto p_\upsilon(y) := \frac{1}{|J^f(f^{-1}(y))|} p_\xi\left(f^{-1}(y)\right) \tag{29.65}$$

gegeben ist. Für die im vorliegenden Fall betrachtete Abbildung halten wir zunächst fest, dass

$$f^{-1} : \mathbb{R}^2 \to \mathbb{R}^2, (t,w) \mapsto f^{-1}(t,w) := \left(\sqrt{w/n}t, w\right). \tag{29.66}$$

Dies ergibt sich direkt aus

$$f^{-1}(f(z,u)) = f^{-1}\left(\frac{z}{\sqrt{u/n}}, u\right) = \left(\frac{\sqrt{u/n}z}{\sqrt{u/n}}, u\right) = (z,u) \text{ für alle } (z,u) \in \mathbb{R}^2. \tag{29.67}$$

Wir halten dann fest, dass die Determinante der Jacobi-Matrix von f an der Stelle (z, u) durch

$$|J^f(z,u)| = \begin{vmatrix} \frac{\partial}{\partial z}\left(\frac{z}{\sqrt{u/n}}\right) & \frac{\partial}{\partial u}\left(\frac{z}{\sqrt{u/n}}\right) \\ \frac{\partial}{\partial z}u & \frac{\partial}{\partial u}u \end{vmatrix} = \left(\frac{v}{n}\right)^{-1/2}, \tag{29.68}$$

gegeben ist, sodass folgt, dass

$$\frac{1}{|J^f\left(f^{-1}(z,u)\right)|} = \left(\frac{w}{n}\right)^{1/2}. \tag{29.69}$$

Einsetzen ergibt dann

$$p_{T,W}(t,w) = \left(\frac{w}{n}\right)^{1/2} p_{Z,V}\left(\sqrt{w/n}t, w\right), \tag{29.70}$$

Es folgt also

$$\begin{aligned}
p_T(t) &= \int_0^\infty p_{T,W}(t,w)\,dw \\
&= \int_0^\infty \left(\frac{w}{n}\right)^{1/2} p_{Z,V}\left(\sqrt{w/n}t, w\right)\,dw \\
&= \int_0^\infty \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(\sqrt{w/n}t)^2\right) \frac{1}{\Gamma(\frac{n}{2})2^{\frac{n}{2}}} w^{\frac{n}{2}-1} \exp\left(-\frac{1}{2}w\right) \left(\frac{w}{n}\right)^{1/2} dw \\
&= \frac{1}{\sqrt{2\pi}} \frac{1}{\Gamma(\frac{n}{2})2^{\frac{n}{2}} n^{\frac{1}{2}}} \int_0^\infty \exp\left(-\frac{1}{2}\frac{w}{n}t^2\right) w^{\frac{n}{2}-1} \exp\left(-\frac{1}{2}w\right) w^{1/2}\,dw \\
&= \frac{1}{\sqrt{2\pi}} \frac{1}{\Gamma(\frac{n}{2})2^{\frac{n}{2}} n^{\frac{1}{2}}} \int_0^\infty \exp\left(-\frac{1}{2}\frac{w}{n}t^2 - \frac{1}{2}w\right) w^{\frac{n}{2}-1} w^{\frac{1}{2}}\,dw \\
&= \frac{1}{\sqrt{2\pi}} \frac{1}{\Gamma(\frac{n}{2})2^{\frac{n}{2}} n^{\frac{1}{2}}} \int_0^\infty \exp\left(-\frac{1}{2}\left(\frac{w}{n}t^2 + w\right)\right) w^{\frac{n+1}{2}-1}\,dw \\
&= \frac{1}{\sqrt{2\pi}} \frac{1}{\Gamma(\frac{n}{2})2^{\frac{n}{2}} n^{\frac{1}{2}}} \int_0^\infty \exp\left(-\frac{1}{2}\left(1 + \frac{t^2}{n}\right)\right) w^{\frac{n+1}{2}-1}\,dw
\end{aligned} \tag{29.71}$$

Wir stellen dann fest, dass der Integrand auf der linken Seite der obigen Gleichung dem Kern einer Gamma WDF mit Parametern $\alpha = \frac{n+1}{2}$ und $\beta = \frac{2}{1+\frac{t^2}{n}}$ entspricht, wie man leicht einsieht:

$$\begin{aligned}
\Gamma(w;\alpha,\beta) &= \frac{1}{\Gamma(\alpha)\beta^\alpha} w^{\alpha-1} \exp\left(-\frac{w}{\beta}\right) \\
\Rightarrow \Gamma\left(w; \frac{n+1}{2}, \frac{2}{1+\frac{t^2}{n}}\right) &= \frac{1}{\Gamma(\frac{n+1}{2})\left(\frac{2}{1+\frac{t^2}{n}}\right)^{\frac{n+1}{2}}} w^{\frac{n+1}{2}-1} \exp\left(-\frac{w}{\frac{2}{1+\frac{t^2}{n}}}\right) \\
&= \frac{1}{\Gamma(\frac{n+1}{2})\left(\frac{2}{1+\frac{t^2}{n}}\right)^{\frac{n+1}{2}}} \exp\left(-\frac{1}{2}\left(1+\frac{t^2}{n}\right)\right) w^{\frac{n+1}{2}-1}.
\end{aligned}$$

Es ergibt sich also

$$p_T(t) = \frac{1}{\sqrt{2\pi}} \frac{1}{\Gamma(\frac{n}{2})2^{\frac{n}{2}} n^{\frac{1}{2}}} \int_0^\infty \Gamma\left(w; \frac{n+1}{2}, \frac{2}{1+\frac{t^2}{n}}\right) dw. \tag{29.72}$$

Schließlich stellen wir fest, dass der Integralterm in obiger Gleichung dem Normalisierungsterm einer Gamma WDF entspricht. Abschließend ergibt sich also

$$p_T(t) = \frac{1}{\sqrt{2\pi}} \frac{1}{\Gamma(\frac{n}{2})2^{\frac{n}{2}} n^{\frac{1}{2}}} \Gamma\left(\frac{n+1}{2}\right) \left(\frac{2}{1+\frac{t^2}{n}}\right)^{\frac{n+1}{2}}. \tag{29.73}$$

Die Verteilung von $Z/\sqrt{U/n}$ hat also die WDF einer t-Zufallsvariable. □

Wichtige Anwendungsfälle sind die T-Konfidenzintervallstatistik sowie die T-Teststatistiken der Theorie von Hypothesentests im Kontext des Allgemeinen Linearen Modells. Wir visualisieren Theorem 29.13 exemplarisch in Abbildung 29.15.

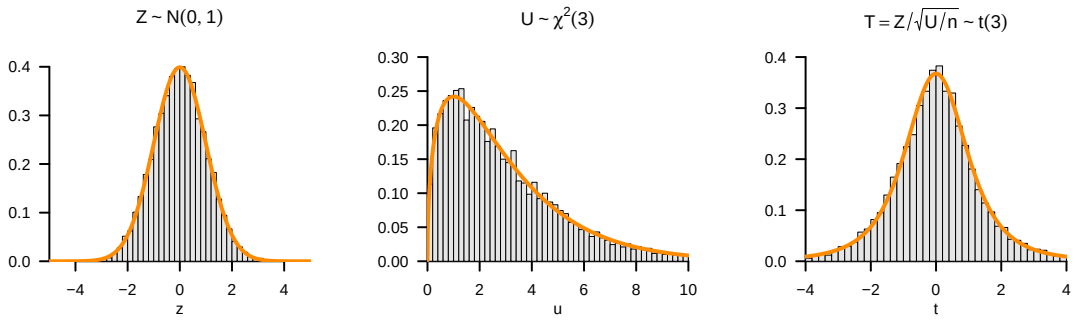


Abbildung 29.15. T-Transformation normalverteilter Zufallsvariablen.

Nichtzentrale T-Transformation

In diesem Abschnitt betrachten wir den Fall, dass der Erwartungswertparameter der Zählervariable der in Theorem 29.13 betrachteten Zufallsvariable T von null verschieden ist, dass es sich bei der Zählervariable also nicht um eine nach $N(0,1)$, sondern eine nach $N(\mu,1)$ verteilte Zufallsvariable für ein beliebiges $\mu \in \mathbb{R}$ handelt. Die so entstehende Zufallsvariable T folgt dann einer sogenannten *nichtzentralen-t-Verteilung*. Eine frühe ausführliche Diskussion dieser Verteilung findet sich zum Beispiel in Johnson & Welch (1940). Eine entsprechende nichtzentralen-t-verteilte Zufallsvariable ist wie folgt definiert (vgl. Lehmann (1986)).

Definition 29.5 (Nichtzentrale t-Zufallsvariable)**.** T sei eine Zufallsvariable mit Ergebnisraum $\mathbb{R}$ und WDF

$$p : \mathbb{R} \to \mathbb{R}_{>0}, t \mapsto p(t) := \frac{1}{2^{\frac{n-1}{2}} \Gamma\left(\frac{n}{2}\right) (n\pi)^{\frac{1}{2}}} \times \int_0^\infty \tau^{\frac{n-1}{2}} \exp\left(-\frac{\tau}{2}\right) \exp\left(-\frac{1}{2}\left(t\left(\frac{\tau}{n}\right)^{\frac{1}{2}} - \delta\right)^2\right) d\tau. \quad (29.74)$$

Dann sagen wir, dass T einer nichtzentralen t-Verteilung mit Nichtzentralitätsparameter δ und Freiheitsgradparameter n unterliegt und nennen T eine *nichtzentrale t-Zufallsvariable mit Nichtzentralitätsparameter δ und Freiheitsgradparameter n*. Wir kürzen dies mit $t(\delta, n)$ ab. Die WDF einer nichtzentralen t-Zufallsvariable bezeichnen wir mit $t(T; \delta, n)$. Die KVF und inverse KVF einer nichtzentralen t-Zufallsvariable bezeichnen wir mit $\Psi(\cdot; \delta, n)$ und $\Psi^{-1}(\cdot; \delta, n)$, respektive.

•

Ohne Beweis merken wir an, dass eine nichtzentrale t-Zufallsvariable mit $\delta = 0$ einer t-Zufallsvariable entspricht, es gelten also

$$t(T; 0, n) = t(T; n) \quad (29.75)$$

sowie

$$\Psi(T; 0, n) = \Psi(T; n) \text{ und } \Psi^{-1}(T; 0, n) = \Psi^{-1}(T; n). \quad (29.76)$$

In Abbildung 29.16 visualisieren wir exemplarisch einige WDFen von nichtzentralen t-Zufallsvariablen. Wir beobachten, dass ein positiver Nichtzentralitätsparameter δ die Verteilung nach rechts verschiebt und die Verteilungen mit steigendem Freiheitsgradparameter n sich entsprechend lokalisierten Normalverteilungen mit Varianzparameter 1 annähern. Man beachte auch die Nichtsymmetrie der WDFen für kleine Freiheitsgradparameter bei von Null verschiedenem positivem Nichtzentralitätsparameter.

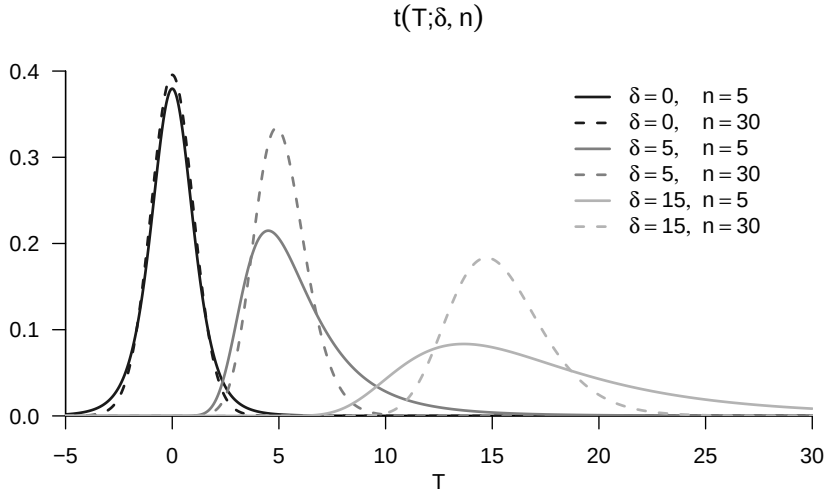


Abbildung 29.16. WDFen von Nichtzentralen-T-Zufallsvariablen.

Eine nichtzentrale t-Zufallsvariable ist das Resultat einer nichtzentralen T-Transformation, wie folgendes Theorem besagt.

Theorem 29.14 (Nichtzentrale T-Transformation)**.** *$v \sim N(\mu, 1)$ sei eine normalverteilte Zufallsvariable, $U \sim \chi^2(n)$ sei eine χ^2-Zufallsvariable mit Freiheitsgradparameter n, und v und U seien unabhängige Zufallsvariablen. Dann ist die Zufallsvariable*

$$T := \frac{v}{\sqrt{U/n}} \tag{29.77}$$

eine nichtzentrale t-Zufallsvariable mit Nichtzentralitätsparameter μ und Freiheitsgradparameter n, also $T \sim t(\mu, n)$.

∘

Wir verzichten auf einen Beweis. Wichtige Anwendungsfälle sind die Testgütefunktionen der T-Test-Varianten im Kontext des Allgemeinen Linearen Modells. Wir visualisieren Theorem 29.14 exemplarisch in Abbildung 29.17.

F-Transformation

Das in diesem Abschnitt zentrale Theorem 29.15 besagt, dass die Zufallsvariable, die sich durch Division zweier jeweils durch ihre Freiheitsgradparameter geteilter χ^2-verteilter Zufallsvariablen ergibt, eine F-verteilte Zufallsvariable ist. Dabei ist eine F-verteilte Zufallsvariable wie folgt definiert.

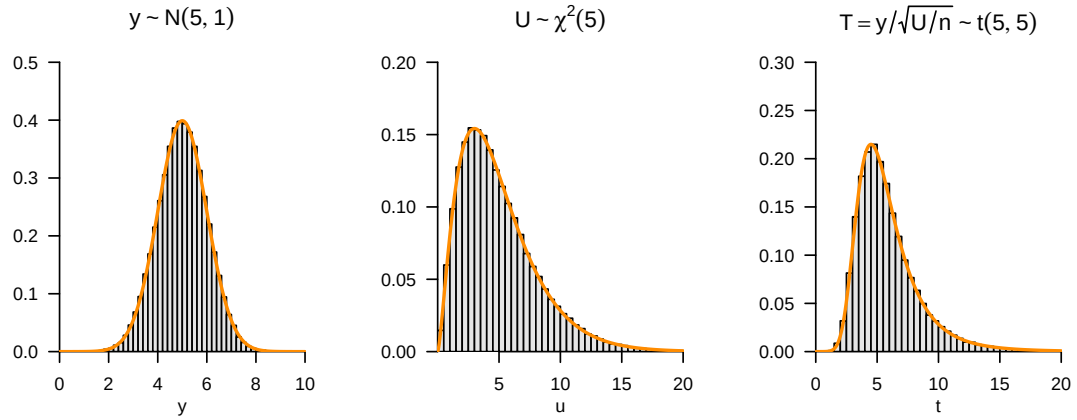


Abbildung 29.17. Nichtzentrale T-Transformation normalverteilter Zufallsvariablen.

Definition 29.6 (F-Zufallsvariable)**.** F sei eine Zufallsvariable mit Ergebnisraum $\mathbb{R}_{>0}$ und WDF

$$p_F : \mathbb{R} \to \mathbb{R}_{>0}, f \mapsto p_F(f) := \left(\frac{n}{m}\right)^{\frac{n}{2}} \frac{\Gamma\left(\frac{n+m}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\Gamma\left(\frac{m}{2}\right)} \frac{f^{\frac{n}{2}-1}}{\left(1+\frac{n}{m}f\right)^{\frac{n+m}{2}}}, \tag{29.78}$$

wobei Γ die Gammafunktion bezeichne. Dann sagen wir, dass F einer F-Verteilung mit Freiheitsgradparametern n, m unterliegt und nennen F eine F-Zufallsvariable mit Freiheitsgradparametern n, m. Wir kürzen dies mit $F \sim F(n, m)$ ab. Die WDF einer F-Zufallsvariable bezeichnen wir mit

$$F(f; n, m) := \left(\frac{n}{m}\right)^{\frac{n}{2}} \frac{\Gamma\left(\frac{n+m}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\Gamma\left(\frac{m}{2}\right)} \frac{f^{\frac{n}{2}-1}}{\left(1+\frac{n}{m}f\right)^{\frac{n+m}{2}}}. \tag{29.79}$$

•

In Abbildung 29.18 visualisieren wir exemplarisch einige WDFen von F-Zufallsvariablen. Wir beobachten, dass die Form der WDFen zunächst primär durch den Freiheitsgradparameter n und dann sekundär durch den Freiheitsgradparameter m bestimmt werden.

Theorem 29.15 (F-Transformation)**.** *$V \sim \chi^2(n)$ und $W \sim \chi^2(m)$ seien zwei unabhängige χ^2-Zufallsvariablen mit Freiheitsgradparametern n und m, respektive. Dann ist die Zufallsvariable*

$$F := \frac{V/n}{W/m} \tag{29.80}$$

eine F-verteilte Zufallsvariable mit Freiheitsgradparametern n, m, es gilt also $F \sim F(n, m)$.

∘

Das Theorem kann bewiesen werden, indem man zunächst ein Transformationstheorem für Quotienten von Zufallsvariablen mithilfe von Theorem 28.1 und Marginalisierung herleitet und dieses Theorem dann auf die WDF von χ^2-verteilten Zufallsvariablen anwendet. Wir visualisieren Theorem 29.15 exemplarisch in Abbildung 29.19. Wichtige Anwendungsfälle von Theorem 29.15 sind die im Rahmen der Theorie des Allgemeinen linearen Modells betrachteten F-Statistiken.

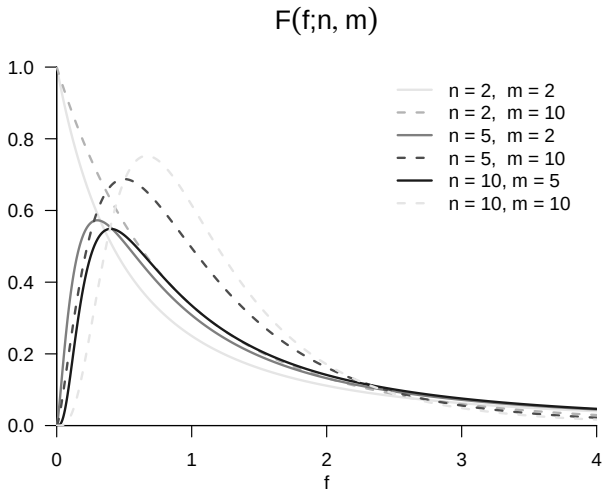


Abbildung 29.18. WDFen von F-verteilten Zufallsvariablen.

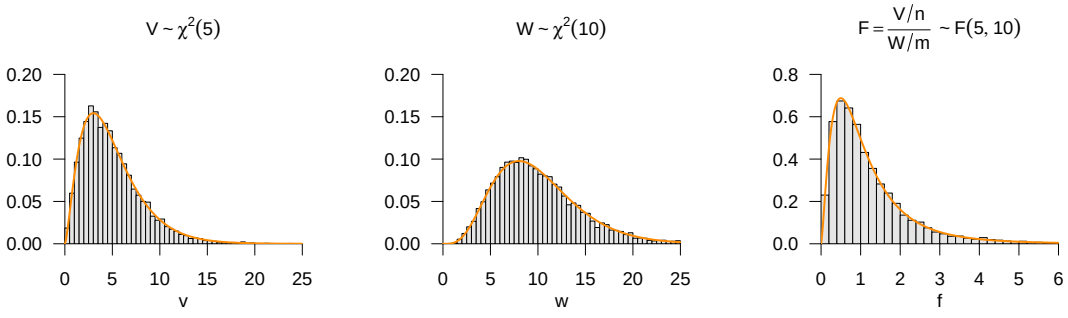


Abbildung 29.19. F-Transformation normalverteilter Zufallsvariablen.

29.8. Literaturhinweise

Die Entwicklung der bivariaten Normalverteilung hat ihre Ursprünge in der statistischen Literatur zur Mitte des 19. Jahrhunderts, insbesondere in den Arbeiten von Francis Galton (1822-1911). Die mathematische Formalisierung der bivariaten Normalverteilung geht dabei wohl auf Pearson (1896) zurück (Seal (1967)). Die ursprüngliche Formulierung der multivariaten Normalverteilung wird bei Edgeworth (1892) verortet. Tong (1990) gibt einen umfassenden Überblick zur Theorie und Anwendung der multivariaten Normalverteilung.

Selbstkontrollfragen

1. Geben Sie das Summationstransformationstheorem wieder.
2. Geben Sie das Mittelwerttransformationstheorem wieder.
3. Geben Sie das Z-Transformationstheorem wieder.
4. Geben Sie das χ^2-Transformationstheorem wieder.
5. Beschreiben Sie die WDF der t-Verteilung in Abhängigkeit ihres Freiheitsgradparameters.
6. Geben Sie das T-Transformationstheorem wieder.
7. Geben Sie das F-Transformationstheorem wieder.

Lösungen

1. Siehe Theorem 29.9.
2. Siehe Theorem 29.10.
3. Siehe Theorem 29.11.
4. Siehe Theorem 29.12.
5. Siehe Abbildung 29.14.
6. Siehe Theorem 29.13.
7. Siehe Theorem 29.15.

Teil IV.

Inferenz

30. Frequentistische Inferenz

30.1. Frequentistische Inferenzmodelle

Mit folgender Definition wollen wir zunächst einige grundlegende Begrifflichkeiten bei der Betrachtung Frequentistischer Inferenzmodelle einführen.

Definition 30.1 (Frequentistische Inferenzmodelle)**.** Ein *Frequentistisches Inferenzmodell* ist ein Tupel

$$\mathcal{M} := (\mathcal{Y}, \mathcal{A}, \{\mathbb{P}_\theta | \theta \in \Theta\}) \tag{30.1}$$

bestehend aus einem *Datenraum* $\mathcal{Y}$, einer σ-Algebra $\mathcal{A}$ auf $\mathcal{Y}$ und einer mindestens zweielementigen Menge $\{\mathbb{P}_\theta | \theta \in \Theta\}$ von Wahrscheinlichkeitsmaßen auf $(\mathcal{Y}, \mathcal{A})$, die durch $\theta \in \Theta$ indiziert sind. Wenn $\Theta \subset \mathbb{R}^k$ ist, heißt ein Frequentistisches Inferenzmodell auch *parametrisches Frequentistisches Inferenzmodell* und Θ heißt *Parameterraum* des Frequentistischen Inferenzmodells. Ein Frequentistisches Inferenzmodell $\mathcal{M}$ heißt ein *diskretes Modell*, wenn $\mathcal{Y}$ endlich oder abzählbar ist und jedes $\mathbb{P}_\theta$ eine WMF p_θ besitzt. Ein Frequentistisches Inferenzmodell $\mathcal{M}$ heißt ein *stetiges Modell*, wenn $\mathcal{Y} \subset \mathbb{R}^n$ ist und jedes $\mathbb{P}_\theta$ eine WDF p_θ besitzt. Wenn der Datenraum $\mathcal{Y}$ eines Frequentistischen Inferenzmodells $\mathcal{M}$ eindimensional ist, also zum Beispiel $\mathcal{Y} := \mathbb{R}$, spricht man von einem *univariaten Frequentistischen Inferenzmodell*. Wenn der Datenraum $\mathcal{Y}$ eines Frequentistischen Inferenzmodells $\mathcal{M}$ mehrdimensional ist, also zum Beispiel $\mathcal{Y} := \mathbb{R}^m$ für $m > 1$, spricht man von einem *multivariaten Frequentistischen Inferenzmodell*. Für ein Frequentistisches Inferenzmodell $\mathcal{M}_0 := (\mathcal{Y}_0, \mathcal{A}_0, \{\mathbb{P}_\theta^0 | \theta \in \Theta\})$ wird das Frequentistische Inferenzmodell $\mathcal{M} := (\mathcal{Y}, \mathcal{A}, \{\mathbb{P}_\theta | \theta \in \Theta\})$, für das $\mathcal{Y}$ das n-fache kartesische Produkt von $\mathcal{Y}_0$ mit sich selbst, $\mathcal{A}$ die entsprechende Produkt-σ-Algebra und $\{\mathbb{P}_\theta | \theta \in \Theta\}$ die entsprechende Menge an Produktmaßen ist, ein (zu $\mathcal{M}_0$ gehöriges) *Frequentistisches Produktmodell* genannt.

•

Vor dem Hintergrund eines Frequentistischen Inferenzmodells wird der Vorgang der Datenbeobachtung durch einen Zufallsvektor y, der Werte in $\mathcal{Y}$ annimmt und dessen Verteilung einer der prinzipiell möglichen Verteilungen $\mathbb{P}_\theta$ entspricht, beschrieben. Man nennt diesen Zufallsvektor *Daten*, *Beobachtung*, *Messung* oder *Stichprobe*. Im Gegensatz zum Wahrscheinlichkeitsraummodell betrachtet man bei Frequentistische Inferenzmodellen also explizit zwei oder mehr Wahrscheinlichkeitsmaße, die die Verteilung von y mutmaßlich bestimmen. Eine Realisierung von y, also konkret vorliegende Datenwerte, nennt man *Datensatz*, *Beobachtungswert*, *Messwert* oder *Stichprobenwert*. Erwartungswerte und (Ko)Varianzen von y bezüglich $\mathbb{P}_\theta$ schreibt man meist als $\mathbb{E}_\theta(y)$, $\mathbb{V}_\theta(y)$ und $\mathbb{C}_\theta(y)$. Frequentistische Produktmodelle modellieren die n-fache unabhängige Wiederholung eines Zufallsvorgangs. Die entsprechende Menge von Zufallsvektoren $y_1, ..., y_n$ entspricht dann einer Menge von n unabhängigen Zufallsvektoren.

In einem konkreten Datenanalyseproblem auf Grundlage eines parameterischen Frequentistischen Produktmodells nimmt man an, dass die beobachteten Werte von $y_1, ..., y_n$ durch

genau ein Wahrscheinlichkeitsmaß $\mathbb{P}_\theta$ mit Parameter $\theta \in \Theta$ generiert wurde. In der Anwendung wird dieses $\theta \in \Theta$ dann als *wahrer, aber unbekannter, Parameterwert* bezeichnet. Der wahre, aber unbekannten, Parameterwert θ bleibt dabei auch nach jeglicher Form von Inferenz unbekannt. Allgemeines Ziel von parameterischen Inferenzverfahren ist es damit, basierend auf einem vorliegenden Datensatz eine möglichst valide Aussage hinsichtlich des wahren, aber unbekannten Parameters θ zu treffen. In diesem Sinn ist der wahre, aber unbekannte Parameterwert, nur indirekt beobachtbar. Dies wird manchmal auch durch die Sprechweisen ausgedrückt, dass der wahre, aber unbekannte Parameterwert *unbeobachtbar* oder *latent*, d.h. nicht unmittelbar sichtbar oder zu erfassen, ist. In der mathematischen Analyse von Inferenzverfahren betrachtet man alle möglichen wahren, aber unbekannten, Parameterwerte, verzichtet daher also meist auf eine explizite notationelle Auszeichung des wahren, aber unbekannten, Parameterwerts.

Mit dem univariaten Normalverteilungsmodell und dem Bernoullimodell wollen wir zwei erste Beispiel für Frequentistische Inferenzmodelle geben.

Beispiel 30.1 (Normalverteilungsmodell)**.** Das univariate parametrische Produktmodell

$$\mathcal{M} := (\mathcal{Y}, \mathcal{A}, \{\mathbb{P}_\theta | \theta \in \Theta\}) \tag{30.2}$$

mit

$$\mathcal{Y} := \mathbb{R}^n, \mathcal{A} := \mathcal{B}(\mathbb{R}^n), \mathbb{P}_\theta^0 := N(\mu, \sigma^2), \theta := (\mu, \sigma^2), \Theta := \mathbb{R} \times \mathbb{R}_{>0}, \tag{30.3}$$

also

$$\{\mathbb{P}_\theta | \theta \in \Theta\} := \left\{ \prod_{i=1}^{n} N(\mu, \sigma^2) | (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_{>0} \right\}, \tag{30.4}$$

und damit

$$y_1, ..., y_n \sim N(\mu, \sigma^2) \text{ mit } (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_{>0} \tag{30.5}$$

heißt *Normalverteilungsmodell*.

△

Das Normalverteilungsmodell ist Grundlage vieler populärer statistischen Verfahren die im Rahmen des Allgemeinen linearen Modells integrativ betrachtet werden. Man beachte, dass die Annahme normalverteilter Daten dabei durch additive normalverteilte Fehlerterme motiviert ist, wie wir in Kapitel 27 schon kurz angerissen haben und an späterer Stelle vertiefen werden.

Beispiel 30.2 (Bernoullimodell)**.** Das univariate parametrische Produktmodell

$$\mathcal{M} := (\mathcal{Y}, \mathcal{A}, \{\mathbb{P}_\theta | \theta \in \Theta\}) \tag{30.6}$$

mit

$$\mathcal{Y} := \{0,1\}^n, \mathcal{A} := \mathcal{P}\left(\{0,1\}^n\right), \mathbb{P}_\theta^0 := \text{Bern}(\mu), \theta := \mu, \Theta :=]0,1[, \tag{30.7}$$

also

$$\{\mathbb{P}_\theta | \theta \in \Theta\} := \left\{ \prod_{i=1}^{n} \text{Bern}(\mu) | \mu \in]0,1[\right\}, \tag{30.8}$$

und damit

$$y_1, ..., y_n \sim \text{Bern}(\mu) \text{ mit } \mu \in]0,1[, \tag{30.9}$$

heißt *Bernoullimodell*.

△

30.2. Statistiken und Schätzer

Vor dem Hintergrund Frequentistischer Inferenzmodelle wollen wir nun formalisieren, was unter den Begriffen einer *Statistik* und eines *Schätzers* zu verstehen ist.

Definition 30.2 (Statistik)**.** $\mathcal{M}$ sei ein Frequentistisches Inferenzmodell und $(\Sigma, \mathcal{S})$ sei ein Messraum. Dann ist eine *Statistik* ein Zufallsvektor der Form

$$S : \mathcal{Y} \to \Sigma. \tag{30.10}$$

•

Sowohl Daten als auch Statistiken werden in der Frequentistischen Inferenz also durch Zufallsvektoren (im univariaten Fall entsprechend durch Zufallsvariablen) modelliert. Allerdings unterscheiden sich diese Zufallsvektoren hinsichtlich ihrer intuitiven Bedeutung fundamental: Daten repräsentieren den Ausgang von Messvorgängen unter Unsicherheit, Statistiken dagegen modellieren von Datenwissenschaftler:innen konstruierte Funktionen von Daten. Diese liefern im besten Fall datenbasierte Informationen, aus denen sich Schlüsse über die latenten datengenerierenden Zufallsvorgänge ziehen lassen. Die Tatsache, dass Statistiken zufällig sind, ergibt sich dabei daraus, dass sie als Funktionen auf zufällige Daten angewendet werden (vgl. etwa Theorem 21.1).

Beispiel 30.3 (Beispiele für Statistiken)**.** $\mathcal{M}$ sei das Normalverteilungsmodell. Dann sind zum Beispiel folgende Zufallsvariablen Statistiken:

- Das *Stichprobenmittel*

$$\bar{y} : \mathbb{R}^n \to \mathbb{R}, y \mapsto \bar{y}(y) := \frac{1}{n} \sum_{i=1}^{n} y_i, \tag{30.11}$$

- Die *Stichprobenvarianz*

$$s^2 : \mathbb{R}^n \to \mathbb{R}_{\geq 0}, y \mapsto s^2(y) := \frac{1}{n-1} \sum_{i=1}^{n} (y_i - \bar{y}(y))^2, \tag{30.12}$$

- Die *Stichprobenstandardabweichung*

$$s : \mathbb{R}^n \to \mathbb{R}_{\geq 0}, y \mapsto s(y) := \sqrt{s^2(y)}, \tag{30.13}$$

△

Oft bleibt wie in Beispiel 30.3 das Wesen von Statistiken als Zufallsvariablen oder Zufallsvektoren notationell eher implizit. Dies ändert allerdings nichts an der fundamental zu beachtenden Tatsache, dass Statistiken als Funktionen von zufallsabhängigen Werten selbst wiederum Zufallsvariablen oder Zufallsvektoren sind.

Definition 30.3 (Schätzer)**.** $\mathcal{M}$ sei ein Frequentistisches Inferenzmodell, $(\Sigma, \mathcal{S})$ sei ein Messraum und $\tau : \Theta \to \Sigma$ sei eine Abbildung, die jedem $\theta \in \Theta$ eine Kenngröße $\tau(\theta) \in \Sigma$ zuordnet. Dann heißt eine Statistik

$$\hat{\tau} : \mathcal{Y} \to \Sigma \tag{30.14}$$

ein *Schätzer* für τ.

•

Schätzer schätzen also Funktionen der Parameter eines parametrischen Frequentistischen Inferenzmodells. Typische Beispiele für solche Funktionen sind

- $\tau(\theta) := \theta$ für die Schätzung des Parameters θ,
- $\tau(\theta) := \theta_i$ mit $\theta \in \mathbb{R}^d, d > 1$ für die Schätzung einer Komponente des Parameters θ,
- $\tau(\theta) := \mathbb{E}_\theta(y_1)$ für die Schätzung des Erwartungswerts,
- $\tau(\theta) := \mathbb{V}_\theta(y_1)$ für die Schätzung der Varianz.

Im Falle $\tau(\theta) := \theta$, also der Schätzung von Parametern, schreibt man üblicherweise $\hat{\theta}$. Man beachte, dass Schätzer Zahlwerte in Σ annehmen, bei der Schätzung von Parametern etwa in Θ. Sie heißen deshalb auch *Punktschätzer*. Dies ist ein Charakteristikum Frequentistischer Inferenzverfahren. Im Rahmen der Bayesianischen Inferenz können Schätzer auch generalisierte Formen annehmen, zum Beispiel werden dort auch Wahrscheinlichkeitsverteilungen als Schätzer betrachtet. Schließlich ist festzuhalten, dass die Definition eines Schätzers keinerlei Aussage über die Validität von Schätzern macht. Nicht jeder Schätzer ist damit *per se* ein guter Schätzer. In der Frequentistischen Inferenz definiert man deshalb zusätzlich *Schätzgütekriterien*, wie in Kapitel 31 ausführlich dargestellt.

Beispiel 30.4 (Schätzer im Normalverteilungsmodell)**.** $\mathcal{M}$ sei das Normalverteilungsmodell. Dann ist das Stichprobenmittel $\bar{y} : \mathbb{R}^n \to \mathbb{R}$ ein Schätzer für

$$\tau : \mathbb{R} \times \mathbb{R}_{>0} \to \mathbb{R}, (\mu, \sigma^2) \mapsto \tau(\mu, \sigma^2) := \mu. \tag{30.15}$$

Ebenso ist $\bar{y}$ ein Schätzer für

$$\tau : \mathbb{R} \times \mathbb{R}_{>0} \to \mathbb{R}, (\mu, \sigma_2) \mapsto \tau(\mu, \sigma^2) := \mathbb{E}_{\mu,\sigma^2}(y_1). \tag{30.16}$$

Weiterhin ist die konstante Funktion

$$\hat{\tau} : \mathbb{R}^n \to \mathbb{R}, y \mapsto \hat{\tau}(y) := 42 \tag{30.17}$$

ein Schätzer für

$$\tau : \mathbb{R} \times \mathbb{R}_{>0} \to \mathbb{R}_{>0}, (\mu, \sigma_2) \mapsto \tau(\mu, \sigma^2) := \sigma^2. \tag{30.18}$$

Dass eine Funktion $\hat{\tau} : \mathcal{Y} \to \Sigma$ ein Schätzer ist impliziert also keinesfalls, dass sie ein guter Schätzer ist.

△

30.3. Standardannahmen und Standardproblemstellungen

Wir wollen die in diesem Kapitel bisher betrachteten Konzepte noch einmal unter dem Begriff der *datenanalytischen Standardannahmen der Frequentistischen Inferenz* zusammenfassen (vgl. auch Abbildung 30.1). Dazu sei $\mathcal{M}$ ein univariates parametrisches Frequentistisches Produktmodell und es seien $y_1, ..., y_n \sim \mathbb{P}_\theta$ die Zufallsvariablen der Stichprobe, die wir etwa in einem Zufallsvektor $y := (y_1, ..., y_n)$ zusammenfassen können. Von einem konkret vorliegenden Datensatz, den wir etwa in einem n-dimensionalen reellen Vektor zusammenfassen können, *wird dann angenommen, dass er eine der möglichen Realisierungen von y auf Grundlage einer Verteilung $\mathbb{P}_\theta$ mit wahrem, aber unbekannten, Parameter θ ist.* Aus Frequentistischer Sicht kann man dabei die Beobachtung eines Datensatzes unendlich oft wiederholen und zu jeder Datenrealisierung Schätzer oder Statistiken auswerten, so zum Beispiel das Stichprobenmittel:

Datenrealisierung $y^{(1)} := \left(y_1^{(1)}, ..., y_n^{(1)}\right)$ mit $\bar{y}^{(1)} = \frac{1}{n}\sum_{i=1}^{n} y_i^{(1)}$

Datenrealisierung $y^{(2)} := \left(y_1^{(2)}, ..., y_n^{(2)}\right)$ mit $\bar{y}^{(2)} = \frac{1}{n}\sum_{i=1}^{n} y_i^{(2)}$

Datenrealisierung $y^{(3)} := \left(y_1^{(3)}, ..., y_n^{(3)}\right)$ mit $\bar{y}^{(3)} = \frac{1}{n}\sum_{i=1}^{n} y_i^{(3)}$

Datenrealisierung $y^{(4)} := \left(y_1^{(4)}, ..., y_n^{(4)}\right)$ mit $\bar{y}^{(4)} = \frac{1}{n}\sum_{i=1}^{n} y_i^{(4)}$

Datenrealisierung $y^{(5)} := \left(y_1^{(5)}, ..., y_n^{(4)}\right)$ mit $\bar{y}^{(5)} = \frac{1}{n}\sum_{i=1}^{n} y_i^{(5)}$

...

Vor diesem Hintergrund behandelt die Frequentistische Inferenz dann üblicheweise folgende Standardproblemstellungen:

(1) *Punktschätzung.* Ziel der Punktschätzung ist es, auf Grundlage beobachteter Daten einen präzisen und im Frequentistischen Sinn möglichst guten Tipp für den wahren, aber unbekannten, Parameterwert abzugeben.

(2) *Konfidenzintervallbestimmung.* Ziel der Konfidenzintervallbestimmung ist es, basierend auf der angenommenen Datenverteilung und den beobachteten Daten durch eine Intervallschätzung einen möglichst sicheren, wenn auch oft unpräzisen, Tipp für den wahren, aber unbekannten, Parameterwert abzugeben.

(3) *Hypothesentests.* Ziel des Frequentistischen Hypothesentestens ist es, basierend auf der angenommenen Verteilung der Daten in einer möglichst zuverlässigen Form zu entscheiden, ob ein wahrer, aber unbekannter Parameterwert in einer von zwei sich gegenseitig ausschließenden Untermengen des Parameterraumes liegt.

Verfahren zur Lösung dieser Problemstellungen bezeichnen wir als *Frequentistische Inferenzverfahren.* Um die Qualität von Frequentistischen Inferenzverfahren zu beurteilen, betrachtet man üblicherweise die Verteilungen von Schätzern und Statistiken unter der Annahme von $y = (y_1, ..., y_n) \sim \mathbb{P}_\theta$. Man fragt zum Beispiel nach der Verteilung der oben skizzierten Realisierungen $\bar{y}^{(1)}$, $\bar{y}^{(2)}$, $\bar{y}^{(3)}$, $\bar{y}^{(4)}$, … also nach der Verteilung der Zufallsvariable $\bar{y}_n$. Wenn ein Inferenzverfahren auf Grundlage dieser Annahmen für "gut" befunden wir, so heißt das also lediglich, dass das Verfahren "bei häufiger Anwendung im Mittel" gut ist. Im Einzelfall, also im Anwendungsnormalfall eines einzelnen vorliegenden Datensatzes, kann das Inferenzverfahren auch "schlecht" sein. Wir werden diese Denkweise insbesondere im Kontext der Punktschätzung und der Konfidenzintervalle vertiefen. Ebenso beurteilt die Frequentistische Inferenz die *Stärke empirischer Evidenz* vor dem Hintergrund der angenommenen Verteilung von Schätzern und Statistiken in Szenarien, in denen angenommen wird, der interessierende Effekt *nicht* existiert, sogenannten *Nullhypothesen.* Diese Denkweise verdeutlichen wir im Rahmen der Betrachtung von Hypothesentests.

Beispiel 30.5 (Anwendungsbeispiel)**.** Für ein erstes Anwendungsbeispiel Frequentistischer Inferenzverfahren betrachten wir die evidenzbasierte Evaluation einer Psychotherapie bei Depression. Dazu sei der in Tabelle 41.1 dargestellte Datensatz von an $n = 12$ Patient:innen Differenzen von Prä- und Post-Therapie erhobenen BDI-II Scores gegeben (`dBDI`; Beck (1961), Beck et al. (1996)). Die `dBDI` Werte sollen dabei die Reduktion des BDI-II Scores der Patient:innen über den Zeitraum der Therapie wiederspiegeln. Hohe positive Werte von `dBDI` entsprechen also einer starken Abnahme der durch den BDI-II Score quantifizierten Depressionssymptomatik, Werte um null entsprechen keiner wesentlichen Änderung und negative Werte entsprechen einer Zunahme der durch den BDI-II Score quantifizierten Depressionssymptomatik.

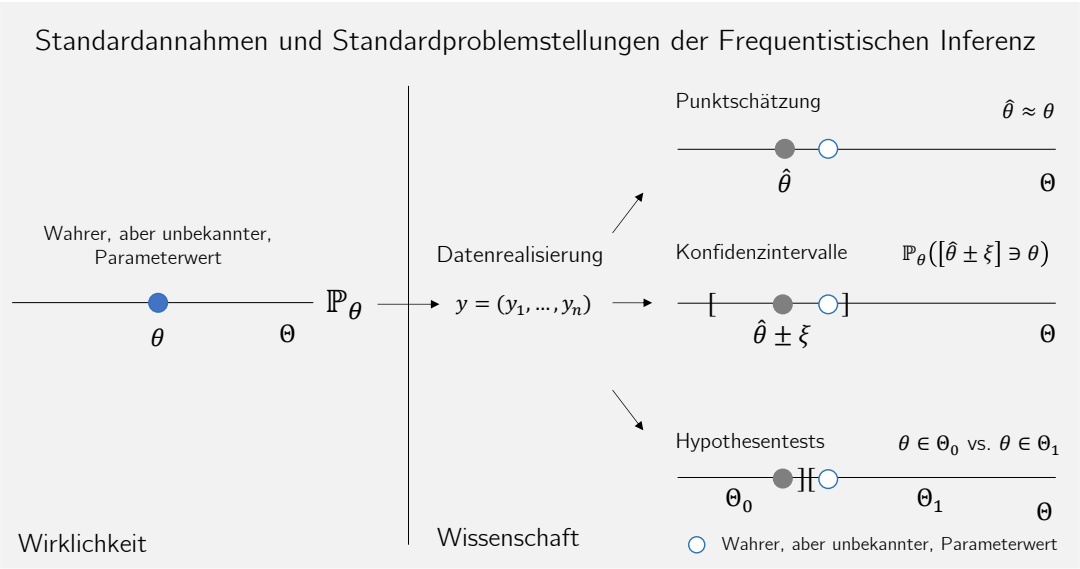


Abbildung 30.1. Standardannahmen und Standardproblemstellungen Frequentistischer Inferenz. Die Frequentistische Inferenz unterstellt, dass es in der Wirklichkeit einen wahren, aber unbekannten, Parameterwert des Wahrscheinlichkeitsmaßes $\mathbb{P}_\theta$ gibt, dass als Modell für die Erhebung eines Datensatzes dient. Ein konkret vorliegender Datenzsatz ist dann eine (und insbesondere *nur* eine) der möglichen Realisierungen des anhand $\mathbb{P}_\theta$ verteilten Zufallsvektors $y := (y_1, \ldots, y_n)$. Auf Grundlage dieser Realisierung beabsichtigen die Verfahren zur Behandlung der Frequentistischen Standardproblemstellungen von Punktschätzung, Konfidenzintervallbestimmung und Hypothesentestauswertung möglichst valide Aussagen hinsichtlich des wahren, aber unbekannten, Parameterwerts zu machen, die in den Kapiteln Kapitel 31, Kapitel 32 und Kapitel 33 diskutiert werden sollen. Der tatsächliche wahre, aber unbekannte, Parameterwert bleibt dabei aber auch nach Abschluss eines Inferenzverfahrens immer unbekannt.

Tabelle 30.1. Pr<U+00E4>-Post-Therapie BDI-II Reduktionsscores von n = 12 Patient:innen

dBDI
-1
3
-2
9
3
-2
4
5
5
1
9
4

Für jeden der $n := 12$ `dBDI` Werte legen wir nun das Modell

$$y_i := \mu + \varepsilon_i \text{ mit } \varepsilon_i \sim N(0, \sigma^2) \text{ u.i.v. für } i = 1, ..., n \tag{30.19}$$

zugrunde. Damit wird der `dBDI` Wert der $i$ten Patient:in also mithilfe einer über die Gruppe von Patient:innen identischen BDI-II Score Reduktion $\mu \in \mathbb{R}$ und einer Patient:innen-spezifischen normalverteilten BDI-II Score Reduktionsabweichung ε_i erklärt und es wird angenommen, dass sich diese Reduktionsabweichungen zwischen Patient:innen nicht gegenseitig beeinflussen. Intuitiv wird also davon ausgegangen, dass die Therapie einen Effekt hat, der bei allen Patient:innen zur gleichen BDI-II Score Reduktion μ führt, und dass sich die Unterschiede in den beobachteten `dBDI` Werten durch eine Vielzahl weiterer Zufallsvorgänge, die in der Summe normalverteilt und zentriert sind, erklären lässt. Alternativ mag man diese Abweichungen als Realisierungen der Unsicherheit verstehen, mit der das Modell in Gleichung 30.19 behaftet ist.

Aus Gleichung 30.19 folgt dann direkt

$$y_1, ..., y_n \sim N(\mu, \sigma^2), \tag{30.20}$$

denn für $i = 1, ..., n$ und mit

$$y_i = f(\varepsilon_i) \text{ mit } f : \mathbb{R} \to \mathbb{R}, e_i \mapsto f(e_i) := e_i + \mu. \tag{30.21}$$

gilt für die WDFen der y_i, dass

$$\begin{aligned} p_{y_i}(y_i) &= \frac{1}{|1|} p_{\varepsilon_i}\left(\frac{y_i - \mu}{1}\right) \\ &= N\left(y_i - \mu; 0, \sigma^2\right) \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(y_i - \mu - 0)^2\right) \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(y_i - \mu)^2\right) \\ &= N(y_i; \mu, \sigma^2) \end{aligned} \tag{30.22}$$

Die Standardproblemstellungen der Frequentistischen Inferenz führen in diesem Anwendungsszenario dann auf folgende Fragen, die wir jeweils in den Kapiteln zur Punktschätzung, Konfidenzintervallbestimmung, und Hypothesentestevaluation wieder aufgreifen wollen:

(1) Was sind sinnvolle Tipps für die wahren, aber unbekannten, Parameterwerte μ und σ^2, also den wahren, aber unbekannten, Erwartungswert der BDI-II Score Reduktion und ihre wahre, aber unbekannte, Varianz? Wie gut ist die Therapie also in diesem quantitativen Sinn, wenn wir versuchen, die Patient:innen-abhängigen Abweichungen zu berücksichtigen und wie groß ist die in der Datengeneration inhärente Unsicherheit?

(2) Wie kann im Sinne einer Intervallschätzung eine möglichst sichere Schätzung des wahren, aber unbekannten, Erwartungswert der BDI-II Score Reduktion gelingen? Wie unpräzise muss eine solche Schätzung sein, um möglichst verlässlich zu sein?

(3) Entscheiden wir uns sinnvollerweise für eine der Hypothesen, dass die Therapie nicht wirksam ist ($\mu = 0$) oder dass sie etwa im positiven ($\mu > 0$) oder auch im negativen Sinne wirksam ist ($\mu < 0$)? Und wenn wir uns für eine dieser Hypothesen entscheiden sollten, mit welcher Fehlerwahrscheinlichkeit täten wir dies? Wie hoch ist also die einer solchen Entscheidung innewohnende Unsicherheit?

△

Selbstkontrollfragen

1. Geben Sie die Definition eines parametrischen Frequentistischen Inferenzmodells wieder.
2. Was ist der Unterschied zwischen einem univariaten und einem multivariaten Produktmodell?
3. Geben Sie die Definition des Normalverteilungsmodells wieder.
4. Geben Sie die Definition des Bernoullimodells wieder.
5. Geben Sie die Definition des Begriffs der Statistik wieder.
6. Geben Sie die Definition des Begriffs des Schätzers wieder.
7. Erläutern Sie die Standardproblemstellungen der Frequentistischen Inferenz.
8. Erläutern Sie die Standardannahmen der Frequentistischen Inferenz.

Lösungen

1. Siehe Definition 30.1.
2. Siehe Definition 30.1.
3. Siehe Beispiel 30.1.
4. Siehe Beispiel 30.2.
5. Siehe Definition 30.2.
6. Siehe Definition 30.3.
7. Siehe Kapitel 30.3.
8. Siehe Kapitel 30.3.

31. Punktschätzung

In diesem Kapitel gehen wir im Sinne der in Kapitel 30 eingeführten Begrifflichkeiten immer von einem parametrischem Produktmodell

$$\mathcal{M} := \{\mathcal{Y}, \mathcal{A}, \{\mathbb{P}_\theta | \theta \in \Theta\}\} \tag{31.1}$$

mit n-dimensionalen Stichprobenraum (z.B. $\mathcal{Y} := \mathbb{R}^n$), d-dimensionalen Parameteraum $\Theta \subset \mathbb{R}^d$ und gegebener WMF oder WDF p_θ für alle $\theta \in \Theta$ aus. $y := (y_1, ..., y_n)$ bezeichnet die zu $\mathcal{M}$ gehörende Stichprobe unabhängig und identisch verteilter Zufallsvariablen, es gilt also durchgängig

$$y_1, ..., y_n \sim \mathbb{P}_\theta. \tag{31.2}$$

Wesen und Ziel der hier behandelten *Punktschätzung* ist es, basierend auf der Stichprobe einen möglichst guten Tipp für eine interessierende Kennzahl der Verteilung $\mathbb{P}_\theta$ einer Stichprobenvariable anzugeben. Dabei ist der Tipp von der gleichen mathematischen Wesensart wie die entsprechende Kennzahl, also zum Beispiel ein skalarer Wert für einen skalaren Parameter. Dies ist nicht die einzige Möglichkeit der Schätzung, mit den Konfidenzintervallen werden wir in Kapitel 32 eine Möglichkeit der Schätzung von skalaren Werten durch Intervalle kennenlernen. Die zu schätzenden Kennzahlen von $\mathbb{P}_\theta$ sind oft schlicht die wahren, aber unbekannten, Parameter selbst. Wir widmen uns diesem Fall ausführlich in Kapitel 31.1. Allerdings sind viele grundlegende Resultate der Frequentistischen Punktschätzung auch dann valide, wenn es sich bei zu schätzenden Kennzahlen nicht um die Parameter selbst, sondern Funktionen von ihnen handelt. Beispiel hierfür sind die Schätzung des Erwartungswerts, der Varianz oder der Standardabweichung von $\mathbb{P}_\theta$. Beginnen wollen wir allerdings mit der *Parameterschätzung*. Um den wahren, aber unbekannten, Parameter eines Inferenzmodells zu schätzen, nutzt man in der Frequentistischen Inferenz sogenannte *Parameterpunktschätzer*.

Definition 31.1. $\mathcal{M} := (\mathcal{Y}, \mathcal{A}, \{\mathbb{P}_\theta | \theta \in \Theta\})$ sei ein Frequentistisches Inferenzmodell, $(\Theta, \mathcal{S})$ sei ein Messraum und $\hat{\theta} : \mathcal{Y} \to \Theta$ sei eine Abbildung. Dann nennt man $\hat{\theta}$ einen *Parameterpunktschätzer* für θ.

•

Parameterpunktschätzer werden meist auch einfach als *Parameterschätzer* bezeichnet. Im Sinne von Definition 30.3 sind Parameterpunktschätzer Schätzer mit $\tau := \mathrm{id}_\Theta$. Parameterpunktschätzer sind also Funktionen von Daten und nehmen Zahlwerte im Parameterraum an. Als Funktionen von Zufallsvariablen sind Parameterschätzer natürlich auch Zufallsvariablen. Oft wird dabei notationell nicht zwischen $\hat{\theta}$ als Zufallsvariable und $\hat{\theta}(y)$ als Wert dieser Zufallsvariable unterschieden.

Definition 31.1 macht offenbar keine Angabe darüber, wie ein Parameterpunktschätzer zu konstruieren ist oder inwieweit er dann ein sinnvoller Schätzer sein mag. Im Folgenden werden wir mit der *Maximum-Likelihood-Schätzung* zunächst ein allgemeines Prinzip

diskutieren, das es erlaubt, für ein gegebenes Frequentistisches Inferenzmodell Parameterschätzer zu bestimmen, die, wie wir an späterer Stelle sehen werden, garantiert bestimmte wünschenswerte Eigenschaften haben (Kapitel 31.4). Dabei beziehen sich diese Eigenschaften allgemein auf sein qualitatives Verteilungsverhalten bei festem Stichprobenumfang bzw. im Grenzübergang zu einem unendlich großen Stichprobenumfang. Wir führen diese Eigenschaften in Kapitel 31.2 und Kapitel 31.3 ein.

31.1. Maximum-Likelihood-Schätzung

Die Grundidee der Maximum-Likelihood-Schätzung ist es, als Tipp für einen wahren, aber unbekannten, Parameterwert denjenigen Parameterwert zu wählen, für den die Wahrscheinlichkeit der beobachteten Daten maximal ist. Dafür ist es zunächst nötig, die Wahrscheinlichkeit beobachteter Daten eines Frequentistischen Inferenzmodells als Funktion des betreffenden Parameters zu betrachten. Dies ermöglichen und formalisieren die *Likelihood-Funktion* und ihr Logarithmus, die *Log-Likelihood-Funktion*. Wir definieren diese Begriffe hier für parametrische Produktmodelle.

Definition 31.2 (Likelihood-Funktion und Log-Likelihood-Funktion)**.** $\mathcal{M}$ sei ein parametrisches Produktmodell mit WMF oder WDF p_θ. Dann ist die *Likelihood-Funktion* definiert als

$$L : \Theta \to [0, \infty[, \theta \mapsto L(\theta) := \prod_{i=1}^{n} p_\theta(y_i) \tag{31.3}$$

und die *Log-Likelihood-Funktion* ist definiert als

$$\ell_n : \Theta \to \mathbb{R}, \theta \mapsto \ell(\theta) := \ln L(\theta). \tag{31.4}$$

•

Die Likelihood-Funktion ist also eine Funktion des Parameters und ihre Funktionswerte sind die Werte der gemeinsamen WMF bzw. WDF beobachteter Datenwerte $y_1, ..., y_n$. Generell gibt es keinen Grund anzunehmen, dass eine Likelihood-Funktion über dem Parameterraum zu 1 integriert, die Likelihood-Funktion ist also im Allgemeinen keine WMF oder WDF. Die Log-Likelihood-Funktion ist schlicht die logarithmierte Likelihood-Funktion. Ein nach dem Prinzip der Maximum-Likelihood-Schätzung gewonnener Parameterschätzer soll nun die Likelihood-Funktion bzw. die Log-Likelihood-Funktion maximieren. Dies führt auf folgende Definition des Begriffs des *Maximum-Likelihood Schätzers*.

Definition 31.3 (Maximum-Likelihood-Schätzer)**.** $\mathcal{M}$ sei ein parametrisches Produktmodell mit Parameter $\theta \in \Theta$. Ein *Maximum-Likelihood-Schätzer* von θ ist definiert als

$$\hat{\theta}^{\text{ML}} : \mathcal{Y} \to \Theta, y \mapsto \hat{\theta}^{\text{ML}}(y) := \text{argmax}_{\theta \in \Theta} L(\theta) = \text{argmax}_{\theta \in \Theta} \ell(\theta) \tag{31.5}$$

•

Man beachte bei Definition 31.3, dass eine Maximumstelle der Log-Likelihood-Funktion der Maximumstelle der Likelihood-Funktion entspricht, weil die Logarithmusfunktion eine monoton steigende Funktion ist. Das Arbeiten mit der Log-Likelihood-Funktion ist allerdings oft einfacher als das direkte Arbeiten mit der Likelihood-Funktion, zum Beispiel, wenn in der WMF oder WDF des Modells Exponentialfunktionen auftauchen. Weiterhin beachte man bei Definition 31.3, dass Definition 31.2 impliziert, dass

$$\hat{\theta}^{\text{ML}}(y) = \text{argmax}_{\theta \in \Theta} \prod_{i=1}^{n} p_\theta(y_i) = \text{argmax}_{\theta \in \Theta} \sum_{i=1}^{n} \ln p_\theta(y_i) \tag{31.6}$$

was die Abhängigkeit eines Maximum-Likelihood-Schätzers von den Daten verdeutlicht.

Mit Definition 31.3 handelt es sich bei der Maximum-Likelihood Schätzung also um das Problem, Extremalstellen einer Funktion zu bestimmen. Für diese Extremalstellen stellt die Differenzialrechnung bekanntlich notwendige und hinreichende Bedingungen bereit (vgl. Kapitel 6.2). In ihrer Anwendung auf die Gewinnung von Maximum-Likelihood-Schätzern begnügt man sich zumeist aufgrund der funktionellen Form der betrachteten Funktionen mit dem Erfülltsein der notwendigen Bedingung. Je nach Beschaffenheit der Log-Likelihood Funktion bieten sich dann Methoden der analytischen oder der numerischen Optimierung an. In den folgenden klassischen Beispielen nutzen wir einen analytischen Ansatz. Wir gehen dabei in folgenden Schritten vor:

(1) Formulierung der Log-Likelihood-Funktion.
(2) Bestimmung der ersten Ableitung der Log-Likelihood-Funktion und Nullsetzen.
(3) Auflösen nach potenziellen Maximumstellen.

In Theorem 31.1 zeigen wir, dass der Maximum-Likelihood-Schätzer für den Parameter des Bernoullimodells aus Beispiel 30.2 durch das entsprechende Stichprobenmittel gegeben ist und in Theorem 31.2 zeigen wir, dass die Maximum-Likelihood-Schätzer für den Erwartungswert- und Varianzparameter des Normalverteilungsmodells aus Beispiel 30.1 durch das Stichprobenmittel und eine modifizierte Stichprobenvarianz, respektive, gegeben sind.

Beispiele

Theorem 31.1 (Maximum-Likelihood-Schätzer des Bernoullimodells)**.** *$\mathcal{M}$ sei das Bernoullimodell, es gelte also $y_1, ..., y_n \sim Bern(\mu)$. Dann ist*

$$\hat{\mu}^{ML} : \{0,1\}^n \to [0,1], y \mapsto \hat{\mu}^{ML}(y) := \frac{1}{n} \sum_{i=1}^{n} y_i \tag{31.7}$$

ein Maximum-Likelihood-Schätzer von μ

∘

Beweis. Wir formulieren zunächst die Log-Likelihood-Funktion. Für die Likelihood-Funktion gilt

$$L :]0,1[\to]0,1[, \mu \mapsto L(\mu) := \prod_{i=1}^{n} \mu^{y_i} (1-\mu)^{1-y_i} = \mu^{\sum_{i=1}^{n} y_i} (1-\mu)^{n - \sum_{i=1}^{n} y_i}. \tag{31.8}$$

Logarithmieren ergibt

$$\ell :]0,1[\to \mathbb{R}, \mu \mapsto \ell(\mu) = \ln \mu \sum_{i=1}^{n} y_i + \ln(1-\mu) \left(n - \sum_{i=1}^{n} y_i \right). \tag{31.9}$$

Wir werten dann die Ableitung der Log-Likelihood-Funktion aus. Es gilt

$$\begin{aligned}\frac{d}{d\mu}\ell(\mu) &= \frac{d}{d\mu}\left(\ln\mu\sum_{i=1}^{n}y_i + \ln(1-\mu)\left(n-\sum_{i=1}^{n}y_i\right)\right)\\ &= \frac{d}{d\mu}\ln\mu\sum_{i=1}^{n}y_i + \frac{d}{d\mu}\ln(1-\mu)\left(n-\sum_{i=1}^{n}y_i\right)\\ &= \frac{1}{\mu}\sum_{i=1}^{n}y_i - \frac{1}{1-\mu}\left(n-\sum_{i=1}^{n}y_i\right).\end{aligned} \tag{31.10}$$

Nullsetzen ergibt dann folgende *Maximum-Likelihood-Gleichung* als notwendige Bedingung für einen Maximum-Likelihood-Schätzer im Bernoullimodell:

$$\frac{1}{\hat{\mu}^{\text{ML}}}\sum_{i=1}^{n}y_i - \frac{1}{1-\hat{\mu}^{\text{ML}}}\left(n-\sum_{i=1}^{n}y_i\right) = 0. \tag{31.11}$$

Auflösen der Maximum-Likelihood-Gleichung nach $\hat{\mu}^{\text{ML}}$ ergibt dann

$$\begin{aligned}&\frac{1}{\hat{\mu}^{\text{ML}}}\sum_{i=1}^{n}y_i - \frac{1}{1-\hat{\mu}^{\text{ML}}}\left(n-\sum_{i=1}^{n}y_i\right) = 0\\ \Leftrightarrow\ &\hat{\mu}^{\text{ML}}(1-\hat{\mu}^{\text{ML}})\left(\frac{1}{\hat{\mu}^{\text{ML}}}\sum_{i=1}^{n}y_i - \frac{1}{1-\hat{\mu}^{\text{ML}}}\left(n-\sum_{i=1}^{n}y_i\right)\right) = 0\\ \Leftrightarrow\ &\sum_{i=1}^{n}y_i - \hat{\mu}^{\text{ML}}\sum_{i=1}^{n}y_i - n\hat{\mu}^{\text{ML}} + \hat{\mu}^{\text{ML}}\sum_{i=1}^{n}y_i = 0\\ \Leftrightarrow\ &n\hat{\mu}^{\text{ML}} = \sum_{i=1}^{n}y_i\\ \Leftrightarrow\ &\hat{\mu}^{\text{ML}} = \frac{1}{n}\sum_{i=1}^{n}y_i.\end{aligned} \tag{31.12}$$

$\hat{\mu}^{\text{ML}} = \frac{1}{n}\sum_{i=1}^{n}y_i$ ist also ein Kandidat für einen Maximum-Likelihood-Schätzer von μ. Dies könnte durch Betrachten der zweiten Ableitung von ℓ verifiziert werden, worauf wir hier aber verzichten wollen. □

Theorem 31.2 (Maximum-Likelihood-Schätzer des Normalverteilungsmodells)**.** *$\mathcal{M}$ sei das Normalverteilungsmodell, es gelte also $y_1, ..., y_n \sim N(\mu, \sigma^2)$. Dann sind*

$$\hat{\mu}^{ML} : \mathbb{R}^n \to \mathbb{R}, y \mapsto \hat{\mu}^{ML}(y) := \frac{1}{n}\sum_{i=1}^{n}y_i \tag{31.13}$$

und

$$\hat{\sigma^2}^{ML} : \mathbb{R}^n \to \mathbb{R}_{\geq 0}, y \mapsto \hat{\sigma}^{2^{ML}}(y) := \frac{1}{n}\sum_{i=1}^{n}\left(y_i - \hat{\mu}^{ML}\right)^2. \tag{31.14}$$

Maximum-Likelihood-Schätzer für μ und σ^2, respektive.

∘

Beweis. Wir formulieren zunächst die Log-Likelihood-Funktion. Für die Likelihood-Funktion ergibt sich

$$\begin{aligned}L : \mathbb{R}\times\mathbb{R}_{>0} \to \mathbb{R}_{>0}, (\mu,\sigma^2) \mapsto L(\mu,\sigma^2) &:= \prod_{i=1}^{n}\frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{1}{2\sigma^2}(y_i-\mu)^2\right)\\ &= \left(2\pi\sigma^2\right)^{-\frac{n}{2}}\exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i-\mu)^2\right).\end{aligned} \tag{31.15}$$

Logarithmieren ergibt dann

$$\ell : \mathbb{R}\times\mathbb{R}_{>0} \to \mathbb{R}, (\mu,\sigma^2) \mapsto \ell_n(\mu,\sigma^2) = -\frac{n}{2}\ln 2\pi - \frac{n}{2}\ln\sigma^2 - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i-\mu)^2. \tag{31.16}$$

Die Auswertung der partiellen Ableitungen der Log-Likelihood-Funktion ergeben dann

$$\frac{\partial}{\partial \mu}\ell(\mu, \sigma^2) = -\frac{\partial}{\partial \mu}\frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i - \mu)^2 = -\frac{1}{2\sigma^2}\sum_{i=1}^{n}\frac{\partial}{\partial \mu}(y_i - \mu)^2 = \frac{1}{\sigma^2}\sum_{i=1}^{n}(y_i - \mu) \tag{31.17}$$

und

$$\frac{\partial}{\partial \sigma^2}\ell(\mu, \sigma^2) = -\frac{n}{2}\frac{\partial}{\partial \sigma^2}\ln \sigma^2 - \frac{\partial}{\partial \sigma^2}\frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i - \mu)^2 = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}\sum_{i=1}^{n}(y_i - \mu)^2. \tag{31.18}$$

Das System der Maximum-Likelihood-Gleichungen als Ausdruck der notwendigen Bedingungen für Extremstellen der Log-Likelihood-Funktion hat in diesem Fall also die Form

$$\sum_{i=1}^{n}(y_i - \hat{\mu}^{\text{ML}}) = 0 \text{ und } -\frac{n}{2\hat{\sigma}^{2\text{ML}}} + \frac{1}{2\hat{\sigma}^{4\text{ML}}}\sum_{i=1}^{n}(y_i - \mu)^2 = 0. \tag{31.19}$$

Lösen des Systems der Maximum-Likelihood-Gleichungen ergibt dann zunächst

$$\sum_{i=1}^{n}(y_i - \hat{\mu}^{\text{ML}}) = 0 \Leftrightarrow \sum_{i=1}^{n} y_i = n\hat{\mu}^{\text{ML}} \Leftrightarrow \hat{\mu}^{\text{ML}} = \frac{1}{n}\sum_{i=1}^{n} y_i. \tag{31.20}$$

Damit ist

$$\hat{\mu}^{\text{ML}} = \frac{1}{n}\sum_{i=1}^{n} y_i \tag{31.21}$$

ein potenzieller Maximum-Likelihood-Schätzer von μ. Einsetzen dieses Schätzers in die zweite Maximum-Likelihood-Gleichung ergibt dann

$$\begin{aligned} -\frac{n}{2\hat{\sigma}^{2\text{ML}}} + \frac{1}{2\hat{\sigma}^{4\text{ML}}}\sum_{i=1}^{n}(y_i - \hat{\mu}^{\text{ML}})^2 &= 0 \\ \Leftrightarrow -n\hat{\sigma}^{2\text{ML}} + \sum_{i=1}^{n}(y_i - \hat{\mu}^{\text{ML}})^2 &= 0 \\ \Leftrightarrow \hat{\sigma}^{2\text{ML}} &= \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{\mu}^{\text{ML}})^2. \end{aligned} \tag{31.22}$$

Also ist

$$\hat{\sigma}^{2\text{ML}} = \frac{1}{n}\sum_{i=1}^{n}\left(y_i - \hat{\mu}^{\text{ML}}\right)^2 \tag{31.23}$$

ein potenzieller Maximum-Likelihood-Schätzer von σ^2. Beide potenziellen Maximum-Likelihood-Schätzer können durch Betrachten der zweiten Ableitung von ℓ verifiziert werden, worauf wir hier verzichten wollen. □

Man beachte bei Theorem 31.2, dass $\hat{\mu}^{\text{ML}}$ mit dem Stichprobenmittel $\bar{y}$ identisch ist, aber $\hat{\sigma}^{2\text{ML}}$ nicht mit der Stichprobenvarianz S^2 übereinstimmt. Im Gegensatz zur Stichprobenvarianz findet sich im Maximum-Likelihood-Schätzer von σ^2 der multiplikative Faktor $\frac{1}{n}$, nicht, wie in der Stichprobenvarianz, der multiplikative Faktor $\frac{1}{n-1}$. Wir werden auf diesen Unterschied im Kontext der Schätzereigenschaften zurückkommen.

Beispiel 31.1 (Anwendungsbeispiel)**.** Zum Abschluss dieses Abschnitts wollen wir Theorem 31.2 im Kontext des Anwendungsbeispiels aus Beispiel 30.5 betrachten. Wir hatten dort den beobachteten `dBDI` Werten das Normalverteilungsmodell

$$y_1, ..., y_n \sim N(\mu, \sigma^2) \tag{31.24}$$

zugrundegelegt. Die Maximum-Likelihood-Schätzer für die Parameter dieses Modells lassen sich dann anhand von Theorem 31.2 mithilfe der **R** Stichprobenmittel- und Stichprobenvarianzfunktionen `mean()` und `var()` und unter Beachtung der Identität

$$\frac{n-1}{n}s^2 = \frac{n-1}{n}\cdot\frac{1}{n-1}\sum_{i=1}^{n}(y_i - \bar{y})^2 = \frac{1}{n}\sum_{i=1}^{n}\left(y_i - \hat{\mu}^{\text{ML}}\right)^2 = \hat{\sigma}^{2\text{ML}} \tag{31.25}$$

wie in folgendem **R** Code auswerten.

```
D           = read.csv("./_data/bdi-ii-datensatz.csv")      # Datensatzeinlesen
y           = D$dBDI                                       # Datenauswahl
mu_hat      = mean(y)                                      # Maximum-Likelihood-Schätzung des Erwartungswertparameters
n           = length(y)                                    # Anzahl der Datenpunkte
sigsqr_hat  = ((n-1)/n)*var(y)                             # Maximum-Likelihood-Schätzung des Varianzparameters
cat("mu_hat     :", mu_hat,"\nsigsqr_hat :", sigsqr_hat)   # Ausgabe
```

```
mu_hat     : 3.166667
sigsqr_hat : 12.63889
```

Basierend auf dem Prinzip der Maximum-Likelihood-Schätzung und den vorliegenden $n = 12$ Datenpunkten sind also

$$\hat{\mu}^{\text{ML}} = 3.17 \text{ und } \hat{\sigma}^{2^{\text{ML}}} = 12.6 \tag{31.26}$$

Tipps für die wahren, aber unbekannten, Parameter des Modells.

31.2. Schätzereigenschaften bei endlichen Stichproben

Allgemein betreffen Frequentistische Schätzereigenschaften die Verteilung von Schätzern in Abhängigkeit der Verteilung der ihnen zugrundeliegenden Daten. Weil Daten in der Frequentistischen Inferenz zufällig sind, sind auch Schätzer zufällig. Speziell werden beobachtete Datenwerte als Realisierungen von Zufallsvariablen interpretiert. Schätzer als Funktionen von Zufallsvariablen sind damit auch Zufallsvariablen, auch wenn sie natürlich bei Vorliegen eines konkreten Datensatzes nur einen konkreten Wert annehmen. Wir unterscheiden zwischen *Schätzereigenschaften bei endlichen Stichproben* und *Asymptotischen Schätzereigenschaften*. Erstere sind Inhalt dieses Abschnittes und betreffen die Eigenschaften eines Schätzers für einen festen Stichprobenumfang n, letztere sind Inhalt von Kapitel 31.3 und betreffen die Eigenschaften eines Schätzers im Grenzfall $n \to \infty$ von großen Stichprobenumfängen.

Es sei zunächst (Σ, S) ein Messraum und $\hat{\tau} : \mathcal{Y} \to \Sigma$ ein Schätzer von $\tau : \Theta \to \Sigma$ (vgl. Definition 30.3). In der Folge betrachten wir neben Parameterschätzern der Form

$$\tau : \Theta \to \Sigma, \tau(\theta) := \theta \tag{31.27}$$

auch wiederholt solche Schätzer, die bei parametrischen Produktmodellen nur Funktionen der Parameter wie den Erwartungswert, die Varianz oder die Standardabweichung der Stichprobenvariablen schätzen. Da nach Annahme die Verteilungen der Stichprobenvariablen $y_1, ..., y_n$ identisch sind, handelt es sich dabei um Schätzer der Form

$$\tau : \Theta \to \Sigma, \theta \mapsto \tau(\theta) \text{ mit } \tau(\theta) := \mathbb{E}_\theta(y_1), \tau(\theta) := \mathbb{V}_\theta(y_1) \text{ und } \tau(\theta) := \mathbb{S}_\theta(y_1). \tag{31.28}$$

Speziell wollen wir in diesem Abschnitt vier Aspekte von Schätzereigenschaften bei endlichen Stichproben beleuchten. In Kapitel 31.2.1 beschäftigen wir uns zunächst mit der *Erwartungstreue* eines Schätzers. Dabei heißt ein Schätzer *erwartungstreu*, wenn sein Erwartungswert mit dem wahren, aber unbekannten, Wert $\tau(\theta)$ für alle $\theta \in \Theta$ identisch ist. In Kapitel 31.2.2 führen wir mit den Begriffen der *Varianz* und des *Standardfehlers* eines Schätzers zwei Maße für die Frequentistische Variabilität von Schätzern ein. Mit dem *mittleren quadratischen Fehler* eines Schätzers $\hat{\tau}$ als Erwartungswert der quadrierten Abweichung von $\hat{\tau}(y)$ von $\tau(\theta)$ führen wir dann in Kapitel 31.2.3 eine Schätzereigenschaft ein,

die es erlaubt, die Genauigkeit und die Variabilität eines Schätzers im Sinne eines sogenannten *Bias-Variance-Tradeoffs* miteinander in Beziehung zu setzen. Die in Kapitel 31.2.4 diskutierte *Cramér-Rao-Ungleichung* schließlich gibt eine untere Schranke für die Varianz erwartungstreuer Schätzer an. Ein erwartungstreuer Schätzer mit Varianz gleich der in der Cramér-Rao-Ungleichung gegebenen unteren Schranke hat die kleinstmögliche Varianz aller erwartungstreuen Schätzer und ist in diesem Sinne ein optimaler Schätzer.

31.2.1. Erwartungstreue

Der Begriff der Erwartungstreue eines Schätzers ergibt sich im Kontext des *Fehlers* und des *systematischen Fehlers* eines Schätzers wie folgt.

Definition 31.4 (Fehler, Systematischer Fehler und Erwartungstreue)**.** $y = (y_1, ..., y_n)$ sei eine Stichprobe eines Frequentistischen Inferenzmodells und $\hat{\tau}$ sei ein Schätzer für τ.

- Der *Fehler* von $\hat{\tau}$ ist definiert als

$$\hat{\tau}(y) - \tau(\theta). \tag{31.29}$$

- Der *systematische Fehler* (engl. *Bias*) von $\hat{\tau}$ ist definiert als

$$\mathrm{B}(\hat{\tau}) := \mathbb{E}_\theta(\hat{\tau}(y)) - \tau(\theta). \tag{31.30}$$

- Der Schätzer $\hat{\tau}$ heißt *erwartungstreu* (engl. *unbiased*), wenn

$$\mathrm{B}(\hat{\tau}) = 0 \Leftrightarrow \mathbb{E}_\theta(\hat{\tau}(y)) = \tau(\theta) \text{ für alle } \theta \in \Theta \text{ und alle } n \in \mathbb{N}. \tag{31.31}$$

  Andernfalls heißt $\hat{\tau}$ *verzerrt (engl. biased).*

•

Man beachte, dass in Definition 31.4 der Fehler eines Schätzers von der spezifischen Realisation der Stichprobe y abhängt. Der systematische Fehler dagegen ist der erwartete Fehler über Stichprobenrealisationen und damit von einer spezifischen Realisation unabhängig. Für den speziellen Fall eines Parameterpunktschätzers gilt nach Definition 31.4, dass er erwartungstreu ist, wenn gilt, dass

$$\mathbb{E}_\theta(\hat{\theta}) = \theta. \tag{31.32}$$

Als erste Beispiele für erwartungstreue Schätzer betrachten wir in folgendem Theorem das Stichprobenmittel und die Stichprobenvarianz als Schätzer für den Erwartungswert und die Varianz einer Stichprobenvariable.

Theorem 31.3 (Erwartungstreue von Stichprobenmittel und Stichprobenvarianz)**.** $y := (y_1, ..., y_n)$ *sei die Stichprobe eines parametrischen Produktmodells. Dann gelten*

(1) Das Stichprobenmittel

$$\bar{y} := \frac{1}{n} \sum_{i=1}^{n} y_i \tag{31.33}$$

ist ein erwartungstreuer Schätzer des Erwartungswerts $\mathbb{E}_\theta(y_1)$.

(2) Die Stichprobenvarianz

$$S^2 := \frac{1}{n-1}\sum_{i=1}^{n}(y_i - \bar{y})^2 \tag{31.34}$$

ist ein erwartungstreuer Schätzer der Varianz $\mathbb{V}_\theta(y_1)$.

∘

Beweis. (1) Die Erwartungstreue des Stichprobenmittels ergibt sich mit Theorem 23.2 aus

$$\mathbb{E}_\theta(\bar{y}) = \mathbb{E}_\theta\left(\frac{1}{n}\sum_{i=1}^{n} y_i\right) = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}_\theta\left(y_i\right) = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}_\theta\left(y_1\right) = \frac{1}{n}n\mathbb{E}_\theta\left(y_1\right) = \mathbb{E}_\theta\left(y_1\right). \tag{31.35}$$

(2) Um die Erwartungstreue der Stichprobenvarianz zu zeigen, halten wir zunächst fest, dass mit Theorem 25.6 bei Unabhängigkeit der betrachteten Zufallsvariablen gilt, dass

$$\mathbb{V}_\theta(\bar{y}) = \mathbb{V}_\theta\left(\frac{1}{n}\sum_{i=1}^{n} y_i\right) = \frac{1}{n^2}\sum_{i=1}^{n}\mathbb{V}_\theta\left(y_i\right) = \frac{1}{n^2}\sum_{i=1}^{n}\mathbb{V}_\theta\left(y_1\right) = \frac{1}{n^2}n\mathbb{V}_\theta\left(y_1\right) = \frac{\mathbb{V}_\theta\left(y_1\right)}{n}. \tag{31.36}$$

Weiterhin gilt für den Term der summierten quadratischen Abweichungen in der Stichprobenvarianz, dass

$$\sum_{i=1}^{n}\left(y_i - \bar{y}\right)^2 = \sum_{i=1}^{n}(y_i - \mathbb{E}_\theta(y_1))^2 - n(\bar{y} - \mathbb{E}_\theta(y_1))^2, \tag{31.37}$$

weil

$$\begin{aligned}
\sum_{i=1}^{n}\left(y_i - \bar{y}\right)^2 &= \sum_{i=1}^{n}\left(y_i - \mathbb{E}_\theta(y_1) - \bar{y} + \mathbb{E}_\theta(y_1)\right)^2 \\
&= \sum_{i=1}^{n}\left((y_i - \mathbb{E}_\theta(y_1)) - (\bar{y} - \mathbb{E}_\theta(y_1))\right)^2 \\
&= \sum_{i=1}^{n}(y_i - \mathbb{E}_\theta(y_1))^2 - 2(\bar{y} - \mathbb{E}_\theta(y_1))\left(\sum_{i=1}^{n}(y_i - \mathbb{E}_\theta(y_1))\right) + \sum_{i=1}^{n}(\bar{y} - \mathbb{E}_\theta(y_1))^2 \\
&= \sum_{i=1}^{n}(y_i - \mathbb{E}_\theta(y_1))^2 - 2(\bar{y} - \mathbb{E}_\theta(y_1))\left(\sum_{i=1}^{n} y_i - n\mathbb{E}_\theta(y_1)\right) + n(\bar{y} - \mathbb{E}_\theta(y_1))^2 \\
&= \sum_{i=1}^{n}(y_i - \mathbb{E}_\theta(y_1))^2 - 2(\bar{y} - \mathbb{E}_\theta(y_1))\left(n\left(\frac{1}{n}\sum_{i=1}^{n} y_i\right) - n\mathbb{E}_\theta(y_1)\right) + n(\bar{y} - \mathbb{E}_\theta(y_1))^2 \\
&= \sum_{i=1}^{n}(y_i - \mathbb{E}_\theta(y_1))^2 - 2n(\bar{y} - \mathbb{E}_\theta(y_1))^2 + n(\bar{y} - \mathbb{E}_\theta(y_1))^2 \\
&= \sum_{i=1}^{n}(y_i - \mathbb{E}_\theta(y_1))^2 - n(\bar{y} - \mathbb{E}_\theta(y_1))^2.
\end{aligned} \tag{31.38}$$

Zusammen ergibt sich also

$$\begin{aligned}
\mathbb{E}_\theta\left((n-1)S^2\right) &= \mathbb{E}_\theta\left(\sum_{i=1}^{n}\left(y_i - \bar{y}\right)^2\right) && (31.39)\\
&= \mathbb{E}_\theta\left(\sum_{i=1}^{n}(y_i - \mathbb{E}_\theta(y_1))^2 - n(\bar{y} - \mathbb{E}_\theta(y_1))^2\right) && (31.40)\\
&= \sum_{i=1}^{n}\mathbb{E}_\theta\left((y_i - \mathbb{E}_\theta(y_1))^2\right) - n\mathbb{E}_\theta\left((\bar{y} - \mathbb{E}_\theta(y_1))^2\right) && (31.41)\\
&= n\mathbb{V}_\theta(y_1) - n\mathbb{V}_\theta(\bar{y}) && (31.42)\\
&= n\mathbb{V}_\theta(y_1) - n\frac{\mathbb{V}_\theta(y_1)}{n} && (31.43)\\
&= n\mathbb{V}_\theta(y_1) - \mathbb{V}_\theta(y_1) && (31.44)\\
&= (n-1)\mathbb{V}_\theta(y_1). && (31.45)
\end{aligned}$$

Schließlich ergibt sich dann

$$\mathbb{E}_\theta\left(S^2\right) = \mathbb{E}_\theta\left(\frac{1}{n-1}(n-1)S^2\right) = \frac{1}{n-1}\mathbb{E}_\theta\left((n-1)S^2\right) = \frac{1}{n-1}(n-1)\mathbb{V}_\theta(y_1) = \mathbb{V}_\theta(y_1) \tag{31.46}$$

und damit die Erwartungstreue der Stichprobenvarianz als Schätzer der Varianz. □

Natürlich sind in Theorem 31.3 aufgrund der identischen Verteilung der Stichprobenvariablen eines parametrischen Produktmodells das Stichprobenmittel und die Stichprobenvarianz auch erwartungstreue Schätzer des Erwartungswertes und der Varianz einer beliebigen Stichprobenvariablen y_i mit $1 \leq i \leq n$. Man beachte, dass im Beweis der Erwartungstreue der Stichprobenvarianz der Nenner $n-1$ in der Definition der Stichprobenvarianz eine entscheidende Rolle spielt.

Obwohl die Stichprobenvarianz ein unverzerrter Schätzer der Varianz einer Stichprobenvariable eines parametrischen Produktmodells ist, trifft dies auf die Stichprobenstandardabweichung als Schätzer der Standardabweichung nicht zu. Dies ist Inhalt des folgenden Theorems.

Theorem 31.4 (Verzerrtheit der Stichprobenstandardabweichung)**.** *$y = (y_1, ..., y_n)$ sei die Stichprobe eines parametrischen Produktmodells. Dann ist die Stichprobenstandardabweichung*

$$S := \sqrt{S^2} \tag{31.47}$$

ein verzerrter Schätzer der Standardabweichung $\mathbb{S}_\theta(y_1)$.

∘

Beweis. Wir halten zunächst fest, dass $\sqrt{\cdot}$ eine strikt konkave Funktion und $\sigma^2 > 0$ ist. Dann aber gilt mit der Jensenschen Ungleichung $\mathbb{E}(f(\xi)) < f(\mathbb{E}(\xi))$ für strikt konkave Funktionen (vgl. Theorem 26.5), dass

$$\mathbb{E}_\theta(S) = \mathbb{E}_\theta\left(\sqrt{S^2}\right) < \sqrt{\mathbb{E}_\theta(S^2)} = \sqrt{\mathbb{V}_\theta(y_1)} = \mathbb{S}_\theta(y_1). \tag{31.48}$$

□

Allgemein führen nicht-lineare Transformationen von erwartungstreuen Schätzern oft auf verzerrte Schätzer, was wir hier aber nicht weiter vertiefen wollen.

Beispiel 31.2 (Simulationsbeispiel)**.** Folgender **R** Code demonstriert exemplarisch die Begriffe der Unverzerrtheit und Verzerrtheit von Stichprobenmittel, Stichprobenvarianz und Stichprobenstandardabweichung am Beispiel eines parametrischen Produktmodells mit Stichprobenverteilung

$$y_1, ..., y_{12} \sim N(1.7, 2) \tag{31.49}$$

Dabei werden die Erwartungswerte der Schätzer anhand ihrer Stichprobenmittel über viele Realisierungen von $y_1, ..., y_{12}$ als Funktion der Anzahl an Realisierungen (Simulationen) geschätzt.

```
# Modellformulierung
set.seed(0)                         # Zufallszahlengenerator
mu      = 1.7                       # wahrer, aber unbekannter, Erwartungswertparameter
sigsqr  = 2                         # wahrer, aber unbekannter, Varianzparameter
n       = 12                        # Stichprobenumfang n
nsim    = 5e4                       # Anzahl der Simulationen
y_bar   = rep(NaN,nsim)             # Stichprobenmittelarray
s_sqr   = rep(NaN,nsim)             # Stichprobenvarianzarray
s       = rep(NaN,nsim)             # Stichprobenstandardabweichungarray

# Simulationsiterationen
for(sim in 1:nsim){

    # Stichprobenrealisation von y_1,...,y_{12}
    y          = rnorm(n,mu,sqrt(sigsqr))
```

```
    # Erwartungswert-, Varianz-, Standardabweichung-Schätzer
    y_bar[sim] = mean(y)             # Stichprobenmittel
    s_sqr[sim] = var(y)              # Stichprobenvarianz
    s[sim]     = sd(y)               # Stichprobenstandardabweichung
}

# Erwartungswertschaetzung
E_hat_y_bar = cumsum(y_bar)/(1:nsim) # \mathbb{E}(\bar{y}) Schaetzungen
E_hat_s_sqr = cumsum(s_sqr)/(1:nsim) # \mathbb{E}(S^2) Schaetzungen
E_hat_s     = cumsum(s)    /(1:nsim) # \mathbb{E}(S) Schaetzungen
```

Abbildung 31.1 visualisiert die Ergebnisse obiger Simulation. Gezeigt sind Schätzungen der Erwartungswerte von Stichprobenmittel, Stichprobenvarianz und Stichprobenstandardabweichung als Funktion der Anzahl an Realisierungen der Stichprobenvariablen $y_1, ..., y_{12}$ sowie die wahren, aber unbekannten, Werte des Erwartungswerts, der Varianz und der Standardabweichung der $y_1, ..., y_{12}$. Es fällt auf, dass diese Schätzungen bei geringer Realisierungsanzahl variabler ausfallen. Ab einer Schätzung basierend auf etwa 10.000 Realisierungen von $y_1, ..., y_{12}$ entsprechen die Stichprobenmittel von $\bar{y}$ und S^2 gemäß ihrer Erwartungstreue ihren wahren, aber unbekannten, Werten. Die Stichprobenstandardabweichung dagegen zeigt gemäß ihrer Verzerrtheit auch bei weiter ansteigenden Anzahlen von der Realisierungen von $y_1, ..., y_{12}$ konstant eine zu niedrige Schätzung der wahren, aber unbekannten, Standardabweichung.

△

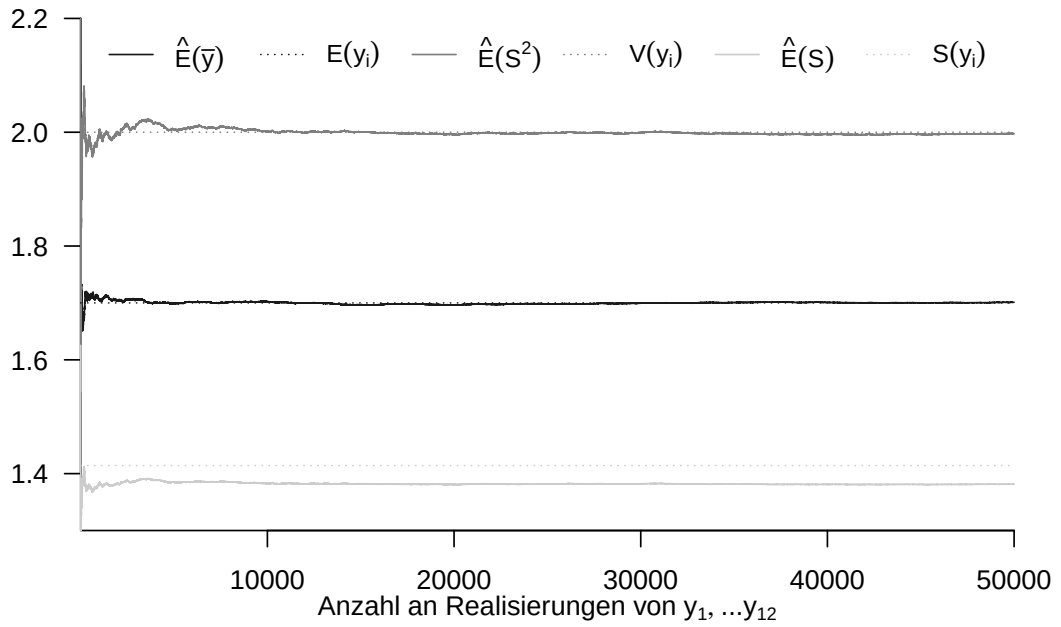


Abbildung 31.1. Simulation der Erwartungstreue von Stichprobenmittel und Stichprobenvarianz als Schätzer des Erwartungswerts und der Varianz bei normalverteilten Stichprobenvariablen und Simulation der Verzerrtheit der Stichprobenstandardabweichung als Schätzer der Standardabweichung bei normalverteilten Stichprobenvariablen

31.2.2. Varianz und Standardfehler

Im vorherigen Abschnitt haben wir den Erwartungswert eines Schätzers betrachtet. In diesem Abschnitt betrachten wir seine Varianz und seine Standardabweichung. Wir nutzen folgende Definition.

Definition 31.5 (Varianz und Standardfehler)**.** $y = (y_1, ..., y_n)$ sei die Stichprobe eines Frequentistischen Inferenzmodells und $\hat{\tau}$ sei ein Schätzer von τ.

- Die *Varianz* von $\hat{\tau}$ ist definiert als

$$\mathbb{V}_\theta(\hat{\tau}) := \mathbb{E}_\theta\left((\hat{\tau}(y) - \mathbb{E}_\theta(\hat{\tau}(y)))^2\right). \tag{31.50}$$

- Der *Standardfehler* von $\hat{\tau}$ ist definiert als

$$\mathrm{SE}(\hat{\tau}) := \sqrt{\mathbb{V}_\theta(\hat{\tau})}. \tag{31.51}$$

•

Die Varianz eines Schätzers $\hat{\tau}$ ist also als die Varianz der Zufallsvariable $\hat{\tau}(y)$ definiert. Der Standardfehler eines Schätzers $\hat{\tau}$ ist als die Standardabweichung von $\hat{\tau}(y)$ definiert. Als erstes Beispiel für einen Standardfehler betrachten wir den *Standardfehler des Stichprobenmittels*.

Theorem 31.5 (Standardfehler des Stichprobenmittels)**.** $y = (y_1, ..., y_n)$ *sei die Stichprobe eines parametrischen Produktmodells. Dann ist der Standardfehler des Stichprobenmittels gegeben durch*

$$SE(\bar{y}) = \frac{\mathbb{S}_\theta(y_1)}{\sqrt{n}}. \tag{31.52}$$

.

∘

Beweis. Mit der Varianz des Stichprobenmittels ergibt sich

$$\mathrm{SE}(\bar{y}) = \sqrt{\mathbb{V}_\theta(\bar{y})} = \sqrt{\frac{\mathbb{V}_\theta(y_1)}{n}} = \frac{\mathbb{S}_\theta(y_1)}{\sqrt{n}}. \tag{31.53}$$

□

Der Standardfehler des Mittelwerts beschreibt die Variabilität des Stichprobenmittels. Da die Standardabweichung $\mathbb{S}_\theta(y_1)$ unbekannt ist, ist auch der Standardfehler $\mathrm{SE}(\bar{y})$ unbekannt, kann also nur geschätzt werden. Mit der Stichprobenstandardabweichung als verzerrtem Schätzer der Standardabweichung $\mathbb{S}_\theta(y_1)$ ergibt sich ein ebenfalls verzerrter Schätzer für den Standardfehler des Stichprobenmittels als

$$\hat{\mathrm{SE}}(\bar{y}) = \frac{S}{\sqrt{n}}. \tag{31.54}$$

Als zweites Beispiel wollen wir den Standardfehler des Maximum-Likelihood-Schätzers für den Parameter eines Bernoulli-Modells betrachten.

Theorem 31.6 (Standardfehler des Maximum-Likelihood-Schätzers des Bernoullimodellparameters)**.** *$y = (y_1, ..., y_n)$ sei die Stichprobe eines Bernoullimodells und $\hat{\mu}^{ML}$ sei der Maximum-Likelihood-Schätzer für den Bernoullimodellparameter μ. Dann ist der Standardfehler von $\hat{\mu}^{ML}$ gegeben durch*

$$SE(\hat{\mu}^{ML}) = \sqrt{\frac{\mu(1-\mu)}{n}}. \tag{31.55}$$

∘

Beweis. Es gilt

$$\text{SE}(\hat{\mu}^{\text{ML}}) = \sqrt{\mathbb{V}_\mu(\hat{\mu}^{\text{ML}})} = \sqrt{\mathbb{V}_\mu\left(\frac{1}{n}\sum_{i=1}^{n} y_i\right)} = \sqrt{\frac{1}{n^2}\sum_{i=1}^{n}\mathbb{V}_\mu(y_i)} = \sqrt{\frac{n\mu(1-\mu)}{n^2}} = \sqrt{\frac{\mu(1-\mu)}{n}}, \tag{31.56}$$

wobei die dritte Gleichung mit der Unabhängigkeit der y_i und die vierte Gleichung mit der Varianz

$$\mathbb{V}_\mu(y_1) = \mathbb{V}_\mu(y_i) = \mu(1-\mu) \tag{31.57}$$

der Stichprobenvariablen folgt. □

Wie im Falle des Standardfehlers des Stichprobenmittels ist auch der Standardfehler des Maximum-Likelihood-Schätzers des Bernoullimodellparameters ein wahrer, aber unbekannter, Wert. Ein Schätzer für $\text{SE}(\hat{\mu}^{\text{ML}})$ ergibt sich mit dem Maximum-Likelihood-Schätzer für den Bernoullimodellparameter durch

$$\hat{\text{SE}}(\hat{\mu}^{\text{ML}}) = \sqrt{\frac{\hat{\mu}^{\text{ML}}(1-\hat{\mu}^{\text{ML}})}{n}}. \tag{31.58}$$

Beispiel 31.3 (Simulationsbeispiel)**.** Folgender **R** Code simuliert die Verteilung des Maximum-Likelihood-Schätzers für den Parameter eines Bernoullimodells mit wahrem, aber unbekanntem, Parameterwert $\mu := 0.4$ für die Stichprobenumfänge $n = 20, n = 100$ und $n = 200$. Abbildung 31.2 visualisiert die resultierenden Verteilungen mithilfe von Histogrammen. Die Variabilität der Schätzwerte, also die Breite der Histogrammverteilungen, hängt dabei offenbar vom Stichprobenumfang ab. Höhere Stichprobenumfänge resultieren in einer geringeren Variabilität des Schätzers. Diesen Gedanken werden wir in Kapitel 31.3 vertiefen.

```
# Modellformulierung
mu       = 0.4                                                  # wahrer, aber unbekannter, Parameterwert
n_all    = c(20,100,200)                                        # Stichprobenumfänge n
ns       = 1e4                                                  # Anzahl der Simulationen
mu_hat   = matrix(rep(NaN, length(n_all)*ns), nrow = length(n_all)) # Maximum-Likelihood-Schätzerarray

# Stichprobenumfängeiterationen
for(i in seq_along(n_all)){

    # Simulationsiterationen
    for(s in 1:ns){
        y              = rbinom(n_all[i],1,mu)                 # Stichprobenrealisation von y_1,...,y_n
        mu_hat[i,s]  = mean(y)                                 # Stichprobenmittel
    }
}
```

△

△

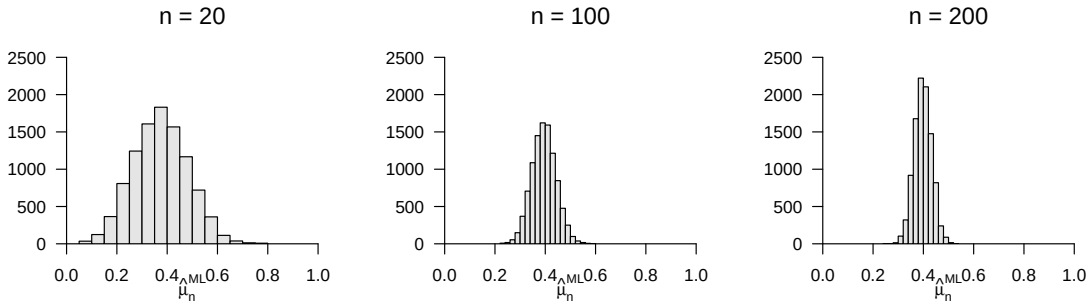


Abbildung 31.2. Simulation der Verteilung des Maximum-Likelihood-Schätzers eines Bernoullimodells. Die Variabilität des Schätzers hängt dabei offenbar vom Stichprobenumfang n ab.

31.2.3. Mittlerer quadratischer Fehler

Mit der Erwartungstreue und der Varianz eines Schätzers haben wir in den beiden vorherigen Abschnitten zwei unabhängige Kriterien für die Güte von Schätzern kennengelernt. Der in diesem Abschnitt eingeführte *Mittlere quadratische Fehler* eines Schätzers ermöglicht eine integrierte Betrachtung der Genauigkeit (Erwartungstreue) und Variabilität (Varianz) eines Schätzers im Sinne seiner sogenannten *Bias-Varianz-Zerlegung*. Wir definieren den mittleren quadratischen Fehler eines Schätzers zunächst wie folgt.

Definition 31.6 (Mittlerer quadratischer Fehler)**.** $y = (y_1, ..., y_n)$ sei die Stichprobe eines parametrischen Produktmodells und $\hat{\tau}$ ein Schätzer für τ. Dann ist der *mittlere quadratischer Fehler (engl. mean squared error)* von $\hat{\tau}$ definiert als

$$\text{MQF}(\hat{\tau}) := \mathbb{E}_\theta \left((\hat{\tau}(y) - \tau(\theta))^2 \right). \tag{31.59}$$

•

Der mittlere quadratische Fehler von $\hat{\tau}$ ist also die erwartete quadrierte Abweichung von $\hat{\tau}(y)$ von $\tau(\theta)$. Man beachte, dass in Abgrenzung dazu die Varianz von $\hat{\tau}$ die erwartete quadrierte Abweichung von $\hat{\tau}$ von $\mathbb{E}_\theta(\hat{\tau}(y))$ ist. Dabei kann, wie in Kapitel 31.2.1 gesehen $\mathbb{E}_\theta(\hat{\tau}(y))$ mit $\tau(\theta)$ übereinstimmen, ein Schätzer also erwartungstreu sein, er muss es aber nicht. Nutzt man den mittleren quadratischen Fehler als Gütekriterium für einen Schätzer, zum Beispiel indem man versucht, einen Schätzer mit möglichst geringem mittleren quadratischen Fehler zu konstruieren, so kann man dabei eventuelle leichte Abweichungen von der Erwartungstreue zugunsten einer geringen Schätzervarianz in Kauf nehmen. Für den mittleren quadratischen Fehler gilt nämlich folgendes Theorem.

Theorem 31.7 (Zerlegung des mittleren quadratischen Fehlers)**.** *$y = (y_1, ..., y_n)$ sei die Stichprobe eines parametrischen Produktmodells, $\hat{\tau}$ sei ein Schätzer für τ, und $MQF(\hat{\tau})$ sei der mittlere quadratische Fehler von $\hat{\tau}$. Dann gilt*

$$MQF(\hat{\tau}) = B(\hat{\tau})^2 + \mathbb{V}_\theta(\hat{\tau}). \tag{31.60}$$

∘

Beweis. Zur Vereinfachung der Notation seien $\tau := \tau(\theta)$, $\hat{\tau} := \hat{\tau}(y)$ und $\bar{\tau}_n := \mathbb{E}_\theta(\hat{\tau}(y))$. Dann gilt:

$$\begin{aligned}
\mathbb{E}_\theta\left((\hat{\tau} - \tau)^2\right) &= \mathbb{E}_\theta\left((\hat{\tau} - \bar{\tau}_n + \bar{\tau}_n - \tau)^2\right) \\
&= \mathbb{E}_\theta\left((\hat{\tau} - \bar{\tau}_n)^2 + 2(\hat{\tau} - \bar{\tau}_n)(\bar{\tau}_n - \tau) + (\bar{\tau}_n - \tau)^2\right) \\
&= \mathbb{E}_\theta\left((\hat{\tau} - \bar{\tau}_n)^2\right) + 2\mathbb{E}_\theta\left((\hat{\tau} - \bar{\tau}_n)(\bar{\tau}_n - \tau)\right) + \mathbb{E}_\theta\left((\bar{\tau}_n - \tau)^2\right) \\
&= \mathbb{E}_\theta\left((\hat{\tau} - \bar{\tau}_n)^2\right) + 2\mathbb{E}_\theta\left(\hat{\tau}\bar{\tau}_n - \hat{\tau}\tau - \bar{\tau}_n\bar{\tau}_n + \bar{\tau}_n\tau\right) + \mathbb{E}_\theta\left((\bar{\tau}_n - \tau)^2\right) \\
&= \mathbb{E}_\theta\left((\hat{\tau} - \bar{\tau}_n)^2\right) + 2\left(\bar{\tau}_n\bar{\tau}_n - \bar{\tau}_n\tau\right) + \mathbb{E}_\theta\left((\bar{\tau}_n - \tau)^2\right) \\
&= \mathbb{E}_\theta\left((\hat{\tau} - \bar{\tau}_n)^2\right) + 0 + \mathbb{E}_\theta\left((\bar{\tau}_n - \tau)^2\right) \\
&= \mathbb{E}_\theta\left((\bar{\tau}_n - \tau)^2\right) + \mathbb{E}_\theta\left((\hat{\tau} - \bar{\tau}_n)^2\right) \\
&= \mathbb{E}_\theta\left((\mathbb{E}_\theta(\hat{\tau}) - \tau)^2\right) + \mathbb{E}_\theta\left((\hat{\tau} - \mathbb{E}_\theta(\hat{\tau}))^2\right) \\
&= (\mathbb{E}_\theta(\hat{\tau}) - \tau)^2 + \mathbb{V}_\theta(\hat{\tau}) \\
&= \mathrm{B}(\hat{\tau})^2 + \mathbb{V}_\theta(\hat{\tau}).
\end{aligned} \tag{31.61}$$

□

31.2.4. Cramér-Rao-Ungleichung

Hat man mehrere erwartungstreue Schätzer vorliegen, so gilt, dass derjenige Schätzer mit der kleinsten Varianz am verlässlichsten seinen Zweck erfüllt. Weil aber die Stichprobenrealisierungen Frequentistischer Inferenzmodelle in aller Regel variabel sind, kann auch die Variabilität erwartungstreuer Schätzer nicht beliebig klein sein. Die *Cramér-Rao-Ungleichung* gibt eine untere Schranke für die Varianz erwartungstreuer Schätzer an. Ein erwartungstreuer Schätzer mit Varianz gleich dieser unteren Schranke hat damit die kleinstmögliche Varianz aller erwartungstreuer Schätzer und ist - in diesem Sinne - ein optimaler Schätzer.

Die Cramér-Rao-Ungleichung basiert auf dem Begriff der sogenannten *Fisher-Information*, welche wiederum auf dem Begriff der *Scorefunktion* eines Frequentistischen Inferenzmodells beruht. Wir führen im Folgenden also zunächst diese beiden Begrifflichkeiten ein, bevor die Cramér-Rao-Ungleichung formuliert und bewiesen werden soll.

Dabei gelten die vorgestellten Resultate allgemein nur unter einer Reihe mathematischer Annahmen, den sogenannten *Fisher-Regularitätsbedingungen*. Diese bestehen für ein Frequentistisches Inferenzmodell mit WMF oder WDF p_θ und Parameterraum Θ darin, dass angenommen wird, dass (1) Θ eine offene Menge ist, der wahre, aber unbekannte, Parameterwert damit nicht an einer Parameterraumgrenze liegen kann, (2) die Teilmenge von Θ, auf der p_θ von null verschiedene Werte annimmt, nicht von θ abhängt, (3) das Modell selbst identifizierbar ist, dass also WMFen oder WDFen mit unterschiedlichen Parameterwerten unterschiedliche Funktionen sind und damit unterschiedliche Stichprobenverteilungen implizieren, (4) die Likelihood-Funktion des Modells zweimal stetig differenzierbar und (5) dass für die Likelihood-Funktion Integration und Differentiation vertauscht werden dürfen. Wir setzen die Fisher-Regularitätsbedingungen also als erfüllt voraus und wollen nur Modelle mit eindimensionalem Parameterräumen $\Theta \subseteq \mathbb{R}$ betrachten. Wir definieren zunächst die Begriffe der *Scorefunktion* und der *Fisher-Information* wie folgt.

Definition 31.7 (Scorefunktion und Fisher-Information)**.** $y = (y_1, ..., y_n)$ sei die Stichprobe eines parametrischen Produktmodells mit eindimensionalem Parameter $\theta \in \Theta \subseteq \mathbb{R}$ und ℓ sei die zugehörige Log-Likelihood-Funktion. Dann gelten:

- Die erste Ableitung von ℓ wird *Scorefunktion der Stichprobe* genannt und wird mit

$$S(\theta) := \frac{d}{d\theta}\ell(\theta) \tag{31.62}$$

bezeichnet. Für $n = 1$ schreiben wir $S(\theta) := S_1(\theta)$ und nennen $S(\theta)$ *Scorefunktion einer Zufallsvariable.*
- Die negative zweite Ableitung von ℓ wird *Fisher-Information der Stichprobe* genannt und mit

$$I(\theta) := -\frac{d^2}{d\theta^2}\ell(\theta) \tag{31.63}$$

bezeichnet. Für $n = 1$ schreiben wir $I(\theta) := I_1(\theta)$ und nennen $I(\theta)$ die *Fisher-Information einer Zufallsvariable.*

•

Da Likelihood- und Log-Likelihood-Funktionen von der Realisierung einer Stichprobe abhängen, sind sie vor dem Hintergrund eines Frequentistischen Inferenzmodells zufällige Funktionen. Da die Fisher-Information als Funktion der Log-Likelihood-Funktion damit auch eine Zufallsvariable ist, muss man zwischen den *beobachteten* und den *erwarteten* Werten der Fisher-Information unterscheiden.

Definition 31.8 (Beobachtete und erwartete Fisher-Information)**.** $y = (y_1, ..., y_n)$ sei die Stichprobe eines parametrischen Produktmodells mit eindimensionalem Parameter $\theta \in \Theta \subseteq \mathbb{R}$, ℓ sei die zugehörige Log-Likelihood-Funktion und $\hat{\theta}^{\text{ML}}$ sei ein Maximum-Likelihood-Schätzer von θ. Dann gelten:

- Die *beobachtete Fisher-Information der Stichprobe* ist definiert als

$$I\left(\hat{\theta}^{\text{ML}}\right) := -\frac{d^2}{d\theta^2}\ell\left(\hat{\theta}^{\text{ML}}\right), \tag{31.64}$$

die beobachtete Fisher-Information der Stichprobe ist also die Fisher-Information an der Stelle des Maximum-Likelihood-Schätzers $\hat{\theta}^{\text{ML}}$.
- Die *erwartete Fisher-Information der Stichprobe* ist definiert als

$$J(\theta) := \mathbb{E}_\theta(I(\theta)). \tag{31.65}$$

Für $n = 1$ schreiben wir $J(\theta) := J_1(\theta)$ und nennen $J(\theta)$ die *erwartete Fisher-Information einer Zufallsvariable.*

•

Bevor wir diese Begrifflichkeiten anhand des Bernoullimodells (Theorem 31.10) und des Normalverteilungsmodells (Theorem 31.12 und Theorem 31.11) verdeutlichen wollen, führen wir mit der *Additivität der Fisher-Information* bei parametrischen Produktmodellen (Theorem 31.8) und dem Erwartungswert und der Varianz der Scorefunktion (Theorem 31.9) noch wichtige Eigenschaften der genannten Begriffe ein, die die folgende Diskussion vereinfachen.

Theorem 31.8 (Additivität der Fisher-Information)**.** *$y = (y_1, ..., y_n)$ sei die Stichprobe eines parametrischen Produktmodells mit Parameter $\theta \in \Theta \subseteq \mathbb{R}$, ℓ sei die zugehörige Log-Likelihood-Funktion und $I(\theta)$ und $J(\theta)$ seien die Fisher-Information und die erwartete Fisher-Information der Stichprobe, respektive. Dann gilt*

$$I(\theta) = nI_1(\theta) \text{ und } J(\theta) = nJ_1(\theta). \tag{31.66}$$

∘

Beweis. Wir zeigen das Resultat für die erwartete Fisher-Information, das Resultat für die beobachtete Fisher-Information gilt dann implizit. Mit der Linearität von Ableitungen und Erwartungswerten gilt

$$\begin{aligned}
J(\theta) &= \mathbb{E}_\theta\left(-\frac{d^2}{d\theta^2}\ell(\theta)\right) \\
&= \mathbb{E}_\theta\left(-\frac{d^2}{d\theta^2}\ln\left(\prod_{i=1}^{n} p_\theta(y_i)\right)\right) \\
&= \mathbb{E}_\theta\left(-\frac{d^2}{d\theta^2}\sum_{i=1}^{n}\ln p_\theta(y_i)\right) \\
&= \mathbb{E}_\theta\left(-\frac{d^2}{d\theta^2}\sum_{i=1}^{n}\ln p_\theta(y_1)\right) \\
&= \mathbb{E}_\theta\left(-\frac{d^2}{d\theta^2}\ell_1(\theta)n\right) \\
&= n\mathbb{E}_\theta\left(-\frac{d^2}{d\theta^2}\ell_1(\theta))\right) \\
&= nJ(\theta).
\end{aligned} \tag{31.67}$$

□

Nach Theorem 31.8 genügt es zur Berechnung der beobachteten oder erwarteten Fisher-Information einer Stichprobe bei parametrischen Produktmodellen also, die beobachtete oder erwartete Fisher-Information einer der Zufallsvariablen der Stichprobe zu berechnen. Weitere Vereinfachungen in der Bestimmung von Fisher-Informationen und der Begründung der Cramér-Rao-Ungleichung ergeben sich durch die im folgenden Theorem formulierten Identitäten.

Theorem 31.9 (Erwartungswert und Varianz der Scorefunktion)**.** *Der Erwartungswert der Scorefunktion einer Zufallsvariable ist*

$$\mathbb{E}_\theta(S(\theta)) = 0 \tag{31.68}$$

und die Varianz der Scorefunktion einer Zufallsvariable ist

$$\mathbb{V}_\theta(S(\theta)) = J(\theta). \tag{31.69}$$

∘

Beweis. Wir betrachten nur den Fall, dass p_θ eine WDF ist und zeigen zunächst, dass $\mathbb{E}_\theta(S(\theta)) = 0$ ist.

$$\begin{aligned}
\mathbb{E}_\theta(S(\theta)) &= \int S(\theta) p_\theta(x)\, dx \\
&= \int \frac{d}{d\theta} \ell(\theta) p_\theta(x)\, dx \\
&= \int \frac{d}{d\theta} \ln L(\theta) p_\theta(x)\, dx \\
&= \int \frac{1}{L(\theta)} \frac{d}{d\theta} L(\theta) p_\theta(x)\, dx \\
&= \int \frac{1}{p_\theta(x)} \frac{d}{d\theta} L(\theta) p_\theta(x)\, dx \\
&= \int \frac{d}{d\theta} L(\theta)\, dx \\
&= \frac{d}{d\theta} \int p_\theta(x)\, dx \\
&= \frac{d}{d\theta} 1 \\
&= 0.
\end{aligned} \tag{31.70}$$

Mit der Definition der Varianz folgt dann sofort, dass $\mathbb{V}_\theta(S(\theta)) = \mathbb{E}_\theta(S(\theta)^2)$ ist. Als Nächstes zeigen wir, dass $J(\theta) = \mathbb{E}_\theta(S(\theta)^2)$ und deshalb $\mathbb{V}_\theta(S(\theta)) = J(\theta)$ ist.

$$\begin{aligned}
J(\theta) &= \mathbb{E}_\theta \left(-\frac{d^2}{d\theta^2} \ln L(\theta) \right) \\
&= \mathbb{E}_\theta \left(-\frac{d}{d\theta} \frac{\frac{d}{d\theta} L(\theta)}{L(\theta)} \right) \\
&= \mathbb{E}_\theta \left(-\frac{\frac{d^2}{d\theta^2} L(\theta) L(\theta) - \frac{d}{d\theta} L(\theta) \frac{d}{d\theta} L(\theta)}{L(\theta) L(\theta)} \right) \\
&= -\mathbb{E}_\theta \left(\frac{\frac{d^2}{d\theta^2} L(\theta)}{L(\theta)} \right) + \mathbb{E}_\theta \left(\frac{\left(\frac{d}{d\theta} L(\theta)\right)^2}{(L(\theta))^2} \right) \\
&= -\int \frac{\frac{d^2}{d\theta^2} L(\theta)}{L(\theta)} p_\theta(x)\, dx + \int \frac{\left(\frac{d}{d\theta} L(\theta)\right)^2}{(L(\theta))^2} p_\theta(x)\, dx \\
&= -\frac{d^2}{d\theta^2} \int p_\theta(x)\, dx + \int \left(\frac{1}{L(\theta)} \frac{d}{d\theta} L(\theta) \right)^2 p_\theta(x)\, dx \\
&= -\frac{d^2}{d\theta^2} 1 + \int \left(\frac{d}{d\theta} \ln L(\theta) \right)^2 p_\theta(x)\, dx \\
&= \mathbb{E}_\theta \left(S(\theta)^2 \right).
\end{aligned} \tag{31.71}$$

□

Der Erwartungswert der Ableitung der Log-Likelihood-Funktion ist also immer Null und die erwartete Fisher-Information ist immer gleich der Varianz der Scorefunktion. Wir wollen die Scorefunktion und die verschiedenen Formen der Fisher-Information nun für die uns vertrauten Frequentistischen Inferenzmodelle konkret berechnen. Nachfolgendes Theorem fasst zunächst die Ergebnisse für das Bernoullimodell zusammen.

Theorem 31.10 (Scorefunktion und Fisher-Informationen des Bernoullimodells)**.** *Es sei $y = (y_1, ..., y_n)$ die Stichprobe eines Bernoullimodells mit Parameter $\mu \in]0, 1[$. Dann gelten:*

- *Die Scorefunktion der Stichprobe ist*

$$S :]0, 1[\to \mathbb{R}, \mu \mapsto S(\mu) := \frac{1}{\mu} \sum_{i=1}^{n} y_i - \frac{1}{1-\mu} \left(n - \sum_{i=1}^{n} y_i \right). \tag{31.72}$$

- *Die Fisher-Information der Stichprobe ist*

$$I :]0,1[\rightarrow \mathbb{R}, \mu \mapsto I(\mu) := I(\mu) = \frac{ny}{\mu^2} + \frac{n(1-y)}{1-\mu}^2. \tag{31.73}$$

- *Die beobachtete Fisher-Information der Stichprobe ist*

$$I :]0,1[\rightarrow \mathbb{R}, \hat{\mu}^{ML} \mapsto I\left(\hat{\mu}^{ML}\right) := \frac{ny}{\hat{\mu}_n^{ML^2}} + \frac{n(1-y)}{1-\hat{\mu}^{ML}}. \tag{31.74}$$

- *Die erwartete Fisher-Information der Stichprobe ist*

$$J :]0,1[\rightarrow \mathbb{R}, \mu \mapsto J(\mu) := \frac{n}{\mu(1-\mu)}. \tag{31.75}$$

∘

Beweis. Die Scorefunktion wurde bereits im Kontext der Maximum-Likelihood-Schätzung von μ hergeleitet. Wir betrachten die Fisher-Information einer einzelnen Bernoulli-Zufallsvariable y.

$$\begin{aligned}
I(\mu) &:= -\frac{d^2}{d\mu^2}\ell_1(\mu) \\
&= -\frac{d^2}{d\mu^2}\ln p_\mu(y) \\
&= -\frac{d^2}{d\mu^2}\left(y\ln\mu + (1-y)\ln(1-\mu)\right) \\
&= -\frac{\partial}{\partial\mu}\left(\frac{\partial}{\partial\mu}\left(y\ln\mu + (1-y)\ln(1-\mu)\right)\right) \\
&= -\frac{\partial}{\partial\mu}\left(\frac{y}{\mu} + \frac{(1-y)}{1-\mu}\right) \\
&= -\left(-\frac{y}{\mu^2} - \frac{(1-y)}{1-\mu}^2\right) \\
&= \frac{y}{\mu^2} + \frac{(1-y)}{1-\mu}^2.
\end{aligned} \tag{31.76}$$

Damit ergibt sich die erwartete Fisher-Information der Zufallsvariable y als

$$\begin{aligned}
J(\mu) &= \mathbb{E}_\mu(I(\mu)) \\
&= \mathbb{E}_\mu\left(\frac{y}{\mu^2} + \frac{(1-y)}{1-\mu}^2\right) \\
&= \frac{\mathbb{E}_\mu(y)}{\mu^2} + \frac{(1-\mathbb{E}_\mu(y))}{1-\mu}^2 \\
&= \frac{\mu}{\mu^2} + \frac{(1-\mu)}{1-\mu}^2 \\
&= \frac{1}{\mu(1-\mu)}.
\end{aligned} \tag{31.77}$$

Mit der Additivitätseigenschaft der Fisher-Information und der Definition der beobachteten Fisher-Information ergibt sich dann sofort

$$I(\mu) = \frac{ny}{\mu^2} + \frac{n(1-y)}{1-\mu}^2 \text{ und } J(\mu) = \frac{n}{\mu(1-\mu)}. \tag{31.78}$$

□

Die Scorefunktion und die Fisher-Informationen des Normalverteilungsmodells betrachten wir lediglich unter der zusätzlichen Annahme eines bekannten Varianzparameters (Theorem 31.11) bzw. eines bekannten Erwartungswertparameters (Theorem 31.12)

Theorem 31.11 (Scorefunktion und Fisher-Informationen des Normalverteilungsmodells bei bekanntem Varianzparameter)**.** *$y = (y_1, ..., y_n)$ sei die Stichprobe eines Normalverteilungsmodells und der Varianzparameter σ^2 sei als bekannt vorausgesetzt. Dann gelten:*

- *Die Scorefunktion der Stichprobe ist*

$$S : \mathbb{R} \to \mathbb{R}, \mu \mapsto S(\mu) := \frac{1}{\sigma^2} \sum_{i=1}^{n} (y_i - \mu). \tag{31.79}$$

- *Die Fisher-Information der Stichprobe ist*

$$I : \mathbb{R} \to \mathbb{R}, \mu \mapsto I(\mu) := \frac{n}{\sigma^2}. \tag{31.80}$$

- *Die beobachtete Fisher-Information der Stichprobe ist*

$$I(\hat{\mu}_n^{ML}) = \frac{n}{\sigma^2}. \tag{31.81}$$

- *Die erwartete Fisher-Information der Stichprobe ist*

$$J : \mathbb{R} \to \mathbb{R}, \mu \mapsto J(\mu) := \frac{n}{\sigma^2}. \tag{31.82}$$

∘

Beweis. Wir erinnern uns, dass die Log-Likelihood-Funktion eines Normalverteilungsmodells bei bekanntem Varianzparameter σ^2 durch

$$\ell : \mathbb{R} \to \mathbb{R}, \mu \mapsto \ell(\mu) := -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^{n} (y_i - \mu)^2 \tag{31.83}$$

gegeben ist. Damit ergibt sich die Scorefunktion als

$$S(\mu) = \frac{\partial}{\partial \mu} \ell(\mu) = \frac{1}{\sigma^2} \sum_{i=1}^{n} (y_i - \mu) \tag{31.84}$$

Die Fisher-Information der Stichprobe ergibt sich als

$$I(\mu) = -\frac{d^2}{d\mu^2} \ell(\mu) = -\frac{\partial}{\partial \mu} S(\mu) = -\frac{1}{\sigma^2} \frac{\partial}{\partial \mu} \left(\sum_{i=1}^{n} y_i - n\mu \right) = \frac{n}{\sigma^2}. \tag{31.85}$$

Die beobachtete Fisher-Information ist die Fisher-Information an der Stelle des Maximum-Likelihood-Schätzers $\hat{\mu}_n^{\text{ML}}$. Die erwartete Fisher-Information schließlich ergibt sich als

$$J(\mu) = \mathbb{E}_\mu(I(\mu)) = \mathbb{E}_\mu \left(\frac{n}{\sigma^2} \right) = \frac{n}{\sigma^2}. \tag{31.86}$$

□

Theorem 31.12 (Scorefunktion und Fisher-Informationen des Normalverteilungsmodells bei bekanntem Erwartungswertparameter)**.** *$y = (y_1, ..., y_n)$ sei die Stichprobe eines Normalverteilungsmodells und der Varianzparameter σ^2 sei als bekannt vorausgesetzt. Dann gelten:*

- *Die Scorefunktion der Stichprobe ist gegeben durch*

$$S : \mathbb{R}_{>0} \to \mathbb{R}, \sigma^2 \mapsto S(\sigma^2) := -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^{n} (y_i - \mu)^2 \tag{31.87}$$

- *Die Fisher-Information der Stichprobe ist gegeben durch*

$$I : \mathbb{R}_{>0} \to \mathbb{R}, \sigma^2 \mapsto I(\sigma^2) := \frac{1}{\sigma^6} \sum_{i=1}^{n} (y_i - \mu)^2 - \frac{n}{2\sigma^4} \tag{31.88}$$

- *Die beobachtete Fisher-Information der Stichprobe ist gegeben durch*

$$I(\hat{\sigma}_n^{2\,ML}) = \frac{n}{2\hat{\sigma}_{ML}^4} \tag{31.89}$$

- *Die erwartete Fisher-Information der Stichprobe ist gegeben durch*

$$J : \mathbb{R}_{>0} \to \mathbb{R}, \sigma^2 \mapsto J(\sigma^2) := \frac{n}{2\sigma^4}. \tag{31.90}$$

∘

Beweis. Wir erinnern uns, dass die Log-Likelihood-Funktion der Stichprobe eines Normalverteilungsmodells bei bekanntem Erwartungswertparameter μ durch

$$\ell : \mathbb{R}_{>0} \to \mathbb{R}, \sigma^2 \mapsto \ell(\sigma^2) := -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^{n} (y_i - \mu)^2. \tag{31.91}$$

gegeben ist. Die Scorefunktion ergibt sich also als

$$S(\sigma^2) = \frac{\partial}{\partial \sigma^2} \ell(\sigma^2) = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^{n} (y_i - \mu)^2. \tag{31.92}$$

Die Fisher-Information der Stichprobe ergibt sich als

$$\begin{aligned} I(\sigma^2) &= -\frac{\partial}{\partial \sigma^2} S(\sigma^2) \\ &= -\frac{\partial}{\partial \sigma^2} \left(\frac{n}{2\sigma^4} - \frac{1}{\sigma^6} \sum_{i=1}^{n} (y_i - \mu)^2 \right) \\ &= \frac{1}{\sigma^6} \sum_{i=1}^{n} (y_i - \mu)^2 - \frac{n}{2\sigma^4}. \end{aligned} \tag{31.93}$$

Die beobachtete Fisher-Information ist die Fisher-Information an der Stelle des Maximum-Likelihood-Schätzers $\hat{\sigma}^{2^{\mathrm{ML}}}$,

$$\begin{aligned} I(\hat{\sigma}_n^{2\,\mathrm{ML}}) &= \frac{\sum_{i=1}^{n} (y_i - \mu)^2}{\left(\hat{\sigma}_n^{2\,\mathrm{ML}}\right)^3} - \frac{n}{2\left(\hat{\sigma}_n^{2\,\mathrm{ML}}\right)^2} \\ &= \frac{\sum_{i=1}^{n} (y_i - \mu)^2}{\frac{1}{n^3}\left(\sum_{i=1}^{n} (y_i - \mu)^2\right)^3} - \frac{n}{2\left(\hat{\sigma}_n^{2\,\mathrm{ML}}\right)^2} \\ &= \frac{1}{\frac{1}{n^3}\left(\sum_{i=1}^{n} (y_i - \mu)^2\right)^2} - \frac{n}{2\left(\hat{\sigma}_n^{2\,\mathrm{ML}}\right)^2} \\ &= \frac{n}{\left(\hat{\sigma}_n^{2\,\mathrm{ML}}\right)^2} - \frac{n}{2\left(\hat{\sigma}_n^{2\,\mathrm{ML}}\right)^2} \\ &= \frac{n}{2\left(\hat{\sigma}_n^{2\,\mathrm{ML}}\right)^2} \\ &= \frac{n}{2\hat{\sigma}_n^{4\,\mathrm{ML}}}. \end{aligned} \tag{31.94}$$

Die erwartete Fisher-Information ergibt sich schließlich als

$$\begin{aligned}
J(\sigma^2) &= \mathbb{E}_{\sigma^2}(I(\sigma^2)) \\
&= \mathbb{E}_{\sigma^2}\left(\frac{1}{\sigma^6}\sum_{i=1}^{n}(y_i-\mu)^2 - \frac{n}{2\sigma^4}\right) \\
&= \frac{1}{\sigma^6}\sum_{i=1}^{n}\mathbb{E}_{\sigma^2}\left((y_i-\mu)^2\right) - \frac{n}{2\sigma^4} \\
&= \frac{1}{\sigma^6}\sum_{i=1}^{n}\sigma^2 - \frac{n}{2\sigma^4} \\
&= \frac{n\sigma^2}{\sigma^6} - \frac{n}{2\sigma^4} \\
&= \frac{n}{\sigma^4} - \frac{n}{2\sigma^4} \\
&= \frac{n}{2\sigma^4}.
\end{aligned} \tag{31.95}$$

□

Mit den oben diskutierten Eigenschaften der Scorefunktion können wir nun die Cramér-Rao-Ungleichung formulieren und beweisen.

Theorem 31.13 (Cramér-Rao-Ungleichung)**.** *Gegeben sei ein Frequentistisches Inferenzmodell mit eindimensionalem Parameter $\theta \in \Theta \subseteq \mathbb{R}$, WMF oder WDF p_θ und $\hat{\tau}$ sei ein erwartungstreuer Schätzer von $\tau(\theta)$. Dann gilt*

$$\mathbb{V}_\theta(\hat{\tau}) \geq \frac{\left(\frac{d}{d\theta}\tau(\theta)\right)^2}{J(\theta)}. \tag{31.96}$$

Speziell gilt für einen Parameterschätzer mit $\tau(\theta) := \theta$ und somit

$$\hat{\tau} = \hat{\theta} \text{ und } \left(\frac{d}{d\theta}\tau(\theta)\right)^2 = 1, \tag{31.97}$$

dass

$$\mathbb{V}_\theta(\hat{\theta}) \geq \frac{1}{J(\theta)}. \tag{31.98}$$

Die rechte Seite obiger Ungleichungen wird dabei Cramér-Rao-Schranke *genannt.*

∘

Beweis. Wir halten zunächst fest, dass für die Zufallsvariablen $S(\theta)$ und $\hat{\tau}$ mit der Korrelationsungleichung (Theorem 26.4) und der Identität von $\mathbb{V}_\theta(S(\theta))$ und $J(\theta)$ (Theorem 31.9) gilt, dass

$$\frac{\mathbb{C}_\theta(S(\theta),\hat{\tau})^2}{\mathbb{V}_\theta(S(\theta))\mathbb{V}_\theta(\hat{\tau})} \leq 1 \Leftrightarrow \mathbb{V}_\theta(\hat{\tau}) \geq \frac{\mathbb{C}_\theta(S(\theta),\hat{\tau})^2}{J(\theta)}. \tag{31.99}$$

Mit dem Kovarianzverschiebungssatz (Theorem 25.2), der Tatsache, dass der Erwartungswert der Scorefunktion immer Null ist (Theorem 31.9) und der vorausgesetzten Erwartungstreue von $\hat{\tau}$ ergibt sich dann

zunächst

$$\begin{aligned}
\mathbb{C}_\theta(S(\theta), \hat{\tau}) &= \mathbb{E}_\theta(S(\theta)\hat{\tau}) - \mathbb{E}_\theta(S(\theta))\mathbb{E}_\theta(\hat{\tau}) \\
&= \mathbb{E}_\theta(S(\theta)\hat{\tau}) \\
&= \int S(\theta)\,\hat{\tau}\,p_\theta(x)\,dx \\
&= \int \frac{d}{d\theta} \ln L(\theta)\,\hat{\tau}\,p_\theta(x)\,dx \\
&= \int \frac{\frac{d}{d\theta}L(\theta)}{L(\theta)}\,\hat{\tau}\,p_\theta(x)\,dx \\
&= \int \frac{\frac{d}{d\theta}L(\theta)}{p_\theta(x)}\,\hat{\tau}\,p_\theta(x)\,dx \\
&= \int \frac{d}{d\theta}L(\theta)\,\hat{\tau}\,dx \\
&= \frac{d}{d\theta}\int L(\theta)\,\hat{\tau}\,dx \\
&= \frac{d}{d\theta}\int \hat{\tau}\,p_\theta(x)\,dx \\
&= \frac{d}{d\theta}\mathbb{E}_\theta(\hat{\tau}) \\
&= \frac{d}{d\theta}\tau(\theta).
\end{aligned} \tag{31.100}$$

Damit folgt dann aber direkt

$$\mathbb{V}_\theta(\hat{\tau}) \geq \frac{\left(\frac{d}{d\theta}\tau(\theta)\right)^2}{J(\theta)}. \tag{31.101}$$

□

Für Parameterschätzer gilt also insbesondere, dass die Varianz eines erwartungstreuen Parameterschätzers $\hat{\theta}$ immer größer oder gleich der reziproken erwarteten Fisher-Information $J(\theta)$ ist. Im Fall, dass sogar

$$\mathbb{V}_\theta(\hat{\theta}) = \frac{1}{J(\theta)} \tag{31.102}$$

ist, ist die Varianz des Parameterschätzers minimal und der Schätzer somit als optimaler Schätzer im Sinne der Cramér-Rao-Ungleichung nachgewiesen. Wir kommen auf diesen Gedanken in Kapitel 31.4 zurück.

31.3. Asymptotische Schätzereigenschaften

In diesem Abschnitt geben wir eine Kurzeinführung in die *Asymptotische Statistik* (Vaart (1998)). Die Asymptotische Statistik ist der Bereich der Frequentistischen Inferenz, der sich mit dem Verhalten von Statistiken und Schätzern bei großen Stichprobenumfängen beschäftigt. Dabei werden Methoden der Asymptotischen Statistik zum einen benutzt um, wie hier, qualitative Schätzereigenschaften zu studieren und andererseits um Schätzereigenschaften bei großen Stichprobenumfängen approximieren zu können. Da Stichprobenumfänge heutzutage durchaus groß sein können, sind die Methoden der Asymptotischen Statistik also für die Anwendung gut motiviert und dort vielseitig einsetzbar.

In Fortführung von Kapitel 31.2 wollen wir in diesem Abschnitt vier asymptotische Schätzereigenschaften beleuchten. Um zu betonen, dass in diesem Abschnitt die Eigenschaften eines Schätzers $\hat{\tau}$ vom Stichprobenumfang n abhängen, schreiben wir in diesem Abschnitt für einen Schätzer $\hat{\tau}_n$. In Kapitel 31.3.1 betrachten wir die *Asymptotische Erwartungstreue*

eines Schätzers. Dabei heißt ein Schätzer $\hat{\tau}_n$ für τ *asymptotisch erwartungstreu*, wenn der Erwartungswert von $\hat{\tau}_n$ für große Stichprobenumfänge $n \to \infty$ mit dem wahren, aber unbekannten, Wert $\tau(\theta)$ identisch ist. In Kapitel 31.3.2 führen wir den Begriff der *Konsistenz* eines Schätzers ein. Intuitiv heißt ein Schätzer $\hat{\tau}_n$ für τ *konsistent*, wenn für große Stichprobenumfänge $n \to \infty$ die Wahrscheinlichkeit dafür, dass $\hat{\tau}_n(y)$ vom wahren, aber unbekannten, Wert $\tau(\theta)$ abweicht, beliebig klein wird. Für große Stichprobenumfänge resultieren die Verteilungen von Schätzern oft in Normalverteilungen. In Kapitel 31.3.3 führen wir mit dem Begriff der *Asymptotischen Normalverteilung* eine entsprechende Formalisierung ein. Ein Schätzer $\hat{\tau}_n$ für τ heißt dann *asymptotisch normalverteilt*, wenn für große Stichprobenumfänge $n \to \infty$, die Verteilung von $\hat{\tau}_n$ durch eine Normalverteilung gegeben ist. In Kapitel 31.3.4 schließlich betrachten wir mit der *Asymptotischen Effizienz* ein Optimalitätskriterium für Schätzer bei gegen unendlich strebenden Stichprobenumfängen. Danach heißt ein Schätzer $\hat{\tau}_n$ für τ *asymptotisch effizient*, wenn für große Stichprobenumfänge $n \to \infty$ die Verteilung von $\hat{\tau}_n$ durch eine Normalverteilung mit Erwartungswertparameter $\tau(\theta)$ und Varianzparameter gleich der Cramér-Rao-Schranke gegeben ist.

31.3.1. Asymptotische Erwartungstreue

Die Asymptotische Erwartungstreue eines Schätzers verfeinert den Begriff des erwartungstreuen Schätzers wie folgt.

Definition 31.9 (Asymptotische Erwartungstreue)**.** $y = (y_1, ..., y_n)$ sei die Stichprobe eines parametrischen Produktmodells und $\hat{\tau}_n$ sei ein Schätzer für τ. $\hat{\tau}_n$ heißt *asymptotisch erwartungstreu*, wenn gilt, dass

$$\lim_{n \to \infty} \mathbb{E}_\theta(\hat{\tau}_n(y)) = \tau(\theta) \text{ für alle } \theta \in \Theta. \tag{31.103}$$

•

Asymptotisch erwartungstreue Schätzer sind also nur erwartungstreu, wenn der Stichprobenumfang gegen Unendlich geht. Erwartungstreue Schätzer sind immer auch asymptotisch erwartungstreu, da ihre Erwartungstreue vom Stichprobenumfang unabhängig sind. Als Beispiel für einen nur asymptotisch erwartungstreuen Schätzer betrachten wir den Maximum-Likelihood-Schätzer des Varianzparameters des Normalverteilungsmodells.

Theorem 31.14 (Asymptotische Erwartungstreue des Varianzparameterschätzers)**.** *$y = (y_1, ..., y_n)$ sei die Stichprobe eines Normalverteilungsmodells mit Varianzparameter σ^2. Dann ist der Maximum-Likelihood-Schätzer von σ^2,*

$$\hat{\sigma}_n^{2^{ML}} := \frac{1}{n} \sum_{i=1}^{n} (y_i - \bar{y}_n)^2, \tag{31.104}$$

nicht erwartungstreu, aber asymptotisch erwartungstreu.

∘

Beweis. Mit der Erwartungstreue der Stichprobenvarianz ergibt sich zunächst (vgl. Theorem 31.3)

$$\mathbb{E}_{\mu,\sigma^2}\left(\hat{\sigma}_n^{2\text{ML}}\right) = \mathbb{E}_{\mu,\sigma^2}\left(\frac{1}{n}\sum_{i=1}^{n}(y_i - \bar{y}_n)^2\right) = \frac{1}{n}\mathbb{E}_{\mu,\sigma^2}\left(\sum_{i=1}^{n}(y_i - \bar{y}_n)^2\right) = \frac{n-1}{n}\sigma^2. \tag{31.105}$$

Also gilt

$$\mathbb{E}_{\mu,\sigma^2}\left(\hat{\sigma}_n^{2\text{ML}}\right) \neq \sigma^2 \tag{31.106}$$

und $\hat{\sigma}_n^{2\text{ML}}$ kein erwartungstreuer Schätzer von σ^2. Allerdings gilt auch

$$\frac{n-1}{n} \to 1 \text{ für } n \to \infty, \tag{31.107}$$

so dass

$$\lim_{n\to\infty} \mathbb{E}_{\mu,\sigma^2}\left(\hat{\sigma}_n^{2\text{ML}}\right) = \lim_{n\to\infty} \frac{n-1}{n}\sigma^2 = \sigma^2 \lim_{n\to\infty} \frac{n-1}{n} = \sigma^2 \tag{31.108}$$

gilt und der Maximum-Likelihood-Schätzer von σ^2 damit asymptotisch erwartungstreu ist. □

Beispiel 31.4 (Simulationsbeispiel)**.** Folgender **R** Code simuliert das Verhalten des Maximum-Likelihood-Schätzers für den Varianzparameter eines Normalverteilungsmodells mit wahren, aber unbekannten, Parametern $\mu = 1$ und $\sigma^2 = 2$ in Abhängigkeit des Stichprobenumfangs.

```
# Modellformulierung
mu         = 1                                          # wahrer, aber unbekannter, Erwartungswertparameter
sigsqr     = 2                                          # wahrer, aber unbekannter, Varianzparameter
n          = seq(1,100, by = 2)                         # Stichprobenumfänge
ns         = 1e3                                        # Anzahl Simulationen pro Stichprobenumfang
sigsqr_ml = matrix(rep(NaN, length(n)*ns),ncol = length(n)) # \hat{\sigma^2}^{ML} Array

# Simulation
for(i in seq_along(n)){                                 # Stichprobenumfangsiterationen
    for(s in 1:ns){                                     # Stichprobenrealisierungsiterationen
        y              = rnorm(n[i], mu, sqrt(sigsqr))  # Stichprobenrealisation
        sigsqr_ml[s,i]  = ((n[i]-1)/n[i])*var(y)        # \hat{\sigma^2}^{ML}
    }
}
E_sigsqr_ml = colMeans(sigsqr_ml)                       # Schätzererwartungswertschätzung
```

Wir visualisieren den basierend auf obigen Simulationen geschätzten Erwartungswert des Schätzers in Abhängigkeit des Stichprobenumfangs in Abbildung 31.3. Für kleine Stichprobenumfänge unterschätzt der Schätzer den wahren, aber unbekannten, Varianzparameter deutlich, für größere Stichprobenumfänge dagegen nicht.

△

31.3.2. Konsistenz

Der Begriff der Konsistenz eines Schätzers verallgemeinert das Schwache Gesetz der Großen Zahlen von Stichprobenmitteln und Erwartungswerten (vgl. Theorem 27.1) auf beliebige Schätzer und wahre, aber unbekannte, Parameterwerte.

Definition 31.10 (Konsistenz)**.** $y := (y_1, ..., y_n)$ sei die Stichprobe eines parametrischen Produktmodells und $\hat{\tau}_n$ sei ein Schätzer von τ. Dann heißt eine Folge von Schätzern $\hat{\tau}_1, \hat{\tau}_2, ...$ eine *konsistente Folge von Schätzern*, wenn für jedes noch so kleine $\epsilon > 0$ und jedes $\theta \in \Theta$ gilt, dass

$$\lim_{n\to\infty} \mathbb{P}_\theta\left(|\hat{\tau}_n(y) - \tau(\theta)| \geq \epsilon\right) = 0. \tag{31.109}$$

Wenn $\hat{\tau}_1, \hat{\tau}_2, ...$ eine konsistente Folge von Schätzern ist, dann heißt $\hat{\tau}_n$ ein *konsistenter Schätzer*.

•

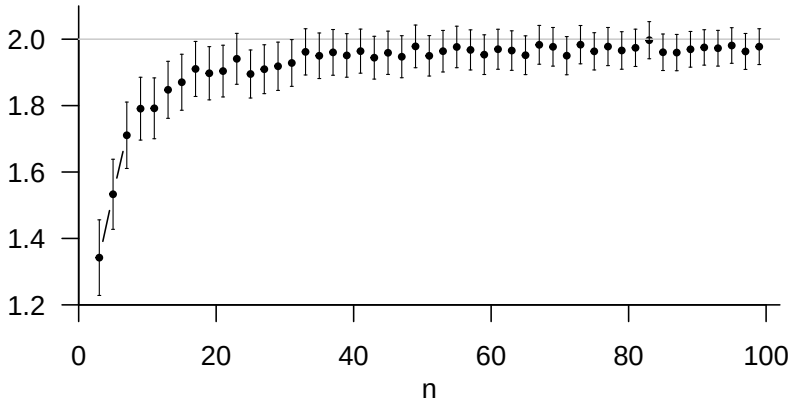


Abbildung 31.3. Simulation des Erwartungswerts des Maximum-Likelihood-Schätzers für den Varianzparameter eines Normalverteilungsmodells. Bei kleinen Stichprobenumfängen unterschätzt der Maximum-Likelihood-Schätzer den wahren, aber unbekannten, Varianzparameter systematisch, bei größeren Stichprobenumfängen ist der Schätzer in etwa erwartungstreu.

Die Intuition zu Definition 31.10 entspricht dem Gesetz der Großen Zahlen. Für Stichprobenumfänge mit $n \to \infty$ wird die Wahrscheinlichkeit, dass $\hat{\tau}_n(y)$ beliebig nah bei $\tau(\theta)$ liegt bzw. die Wahrscheinlichkeit, dass $\hat{\tau}_n(y)$ weit von $\tau(\theta)$ abweicht, klein. Allerdings müssen diese Eigenschaften für alle möglichen wahren, aber unbekannten, Parameterwerte gelten. Wie unten gezeigt werden soll, ist das Stichprobenmittel ein konsistenter Schätzer für den Erwartungswertparameter eines Normalverteilungsmodells.

Beispiel 31.5. Analog zu Kapitel 27.1 demonstrieren wir die Bedeutung der Konsistenz mithilfe der Simulation für $\mu = 1$ und $\sigma^2 = 2$ anhand folgenden **R** Codes.

```
# Modellformulierung
mu      = 1                                     # wahrer, aber unbekannter, Wert von \mu
sigsqr  = 2                                     # wahrer, aber unbekannter, Wert von \sigma^2
n       = seq(1,1e3,by = 10)                    # Stichprobenumfang n
eps     = c(0.15, 0.10, 0.05)                   # \epsilon Werte
ne      = length(eps)                           # Anzahl \epsilon Werte
nn      = length(n)                             # Anzahl Stichprobenumfänge
ns      = 1000                                  # Anzahl Simulationen
E       = array(rep(NaN,nn*ne*ns),dim = c(nn,ne,ns)) # Ereignisindikatorarray

# Simulation
for(e in seq_along(eps)){                       # \epsilon Iterationen
    for(i in seq_along(n)){                     # n Iterationen
        for(s in 1:ns){                         # Simulationsiterationen

            # Stichprobenrealisationen
            y   = rnorm(n[i], mu, sqrt(sigsqr))
            if(abs(mean(y) - mu) >= eps[e]){    # |y_bar - \mu)| \ge \epsilon
                E[i,e,s] = 1
            } else {                            # |y_bar - \mu)| < \epsilon
                E[i,e,s] = 0
            }
        }
    }
}

# Schaetzung von \mathbb{P}(|\hat{\tau}_n(y)-\tau(\theta)| \ge \epsilon)
P_hat       = apply(E, c(1,2), mean)
```

Wir visualisieren die Schätzung der Wahrscheinlichkeit $\mathbb{P}(|\hat{\tau}_n(y) - \tau(\theta)| \geq \epsilon)$ für dieses Beispiel in Abbildung 31.4 in Abhängigkeit des Stichprobenumfangs und des Kriteriumwerts ϵ. Bei größeren Werten von ϵ genügen geringe Stichprobenumfänge für eine geringe

Wahrscheinlichkeit der Abweichung des Schätzers vom wahren, aber unbekannten, Parameterwert, bei kleineren Werten von ϵ sind dazu größere Stichprobenumfänge nötig.

△

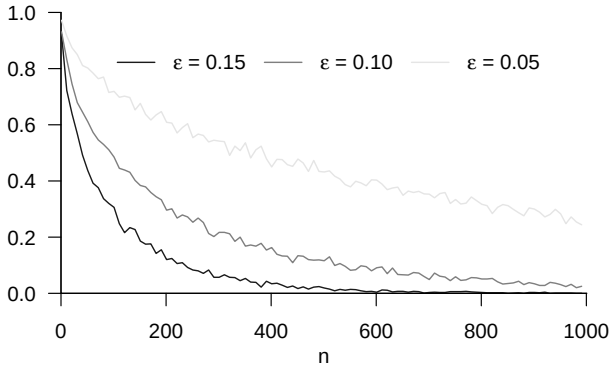


Abbildung 31.4. Simulation der Konsistenz des Stichprobenmittels als Schätzer für den Erwartungswertparameter des Normalverteilungsmodells.

Die in Theorem 31.15 und Theorem 31.16 angegebenen Kriterien für die Konsistenz von Schätzern vereinfachen den Nachweis der Konsistenz eines Schätzers mithilfe des Mittleren Quadratischen Fehlers (Definition 31.6).

Theorem 31.15 (Mittlerer Quadratischer Fehler Kriterium für Konsistenz)**.** *$y := (y_1, ..., y_n)$ sei die Stichprobe eines parametrischen Produktmodells und $\hat{\tau}_n$ sei ein Schätzer von τ. Wenn gilt, dass*

$$\lim_{n \to \infty} MQF(\hat{\tau}_n) = 0, \tag{31.110}$$

dann ist $\hat{\tau}_n$ ein konsistenter Schätzer.

∘

Beweis. Mit der Chebychev-Ungleichung gilt, dass

$$\mathbb{P}_\theta \left(|\hat{\tau}_n(y) - \tau(\theta)| \geq \epsilon \right) \leq \frac{\mathbb{E}_\theta \left((\hat{\tau}_n(y) - \tau(\theta))^2 \right)}{\epsilon^2} \tag{31.111}$$

Grenzwertbildung ergibt dann

$$\lim_{n \to \infty} \mathbb{P}_\theta \left(|\hat{\tau}_n(y) - \tau(\theta)| \geq \epsilon \right) \leq \frac{1}{\epsilon^2} \lim_{n \to \infty} \mathbb{E}_\theta \left((\hat{\tau}_n(y) - \tau(\theta))^2 \right). \tag{31.112}$$

Wenn also $\lim_{n \to \infty} \mathbb{E}_\theta \left((\hat{\tau}_n(y) - \tau(\theta))^2 \right) = 0$ gilt, dann gilt mit $\mathbb{P}_\theta(|\hat{\tau}_n(y) - \tau(\theta)| \geq \epsilon) \geq 0$, dass

$$\lim_{n \to \infty} \mathbb{P}_\theta \left(|\hat{\tau}_n(y) - \tau(\theta)| \geq \epsilon \right) = 0. \tag{31.113}$$

Also ist $\hat{\tau}_n$ ein konsistenter Schätzer. □

Theorem 31.16 (Bias-Varianz-Kriterium für Konsistenz)**.** *$y := (y_1, ..., y_n)$ sei die Stichprobe eines parametrischen Produktmodells und $\hat{\tau}_n$ sei ein Schätzer von τ. Wenn*

$$\lim_{n\to\infty} B(\hat{\tau}_n) = 0 \text{ und } \lim_{n\to\infty} \mathbb{V}_\theta(\hat{\tau}_n) = 0 \tag{31.114}$$

gelten, dann ist $\hat{\tau}_n$ ein konsistenter Schätzer

∘

Beweis. Wenn $n \to \infty$, dann gilt $\mathrm{B}(\hat{\tau}_n) \to 0$, also auch $\mathrm{B}(\hat{\tau}_n)^2 \to 0$. Wenn für $n \to \infty$ sowohl $\mathrm{B}(\hat{\tau}_n)^2 \to 0$ als auch $\mathbb{V}_\theta(\hat{\tau}_n) \to 0$, dann gilt auch $\lim_{n\to\infty} \mathrm{MQF}(\hat{\theta}_n) = 0$. Also gilt mit Theorem 31.15, dass $\hat{\tau}_n$ konsistent ist. □

Als Anwendung von Theorem 31.16 wollen wir mit folgendem Theorem die Konsistenz des Stichprobenmittels als Schätzer für den Erwartungswert bei Normalverteilung nachweisen.

Theorem 31.17 (Konsistenz des Erwartungswertschätzers bei Normalverteilung)**.** *Es sei y die Stichprobe eines Normalverteilungsmodells. Dann ist $\bar{y}_n$ ein konsistenter Schätzer von $\mathbb{E}(y_1)$.*

∘

Beweis. Mit der Erwartungstreue des Stichprobenmittels als Schätzer für den Erwartungswert gilt zunächst

$$\lim_{n\to\infty} \mathrm{B}(\bar{y}_n) = 0. \tag{31.115}$$

Weiterhin gilt mit der Varianz des Stichprobenmittels

$$\lim_{n\to\infty} \mathbb{V}_\theta(\bar{y}_n) = \lim_{n\to\infty} \frac{1}{n}\mathbb{V}(y_1) = 0. \tag{31.116}$$

Mit dem Bias-Varianz-Kriterium folgt dann die Konsistenz von $\bar{y}_n$ als Schätzer von $\mathbb{E}(y_1)$ □

Man beachte, dass Theorem 31.17 natürlich auch schon im Schwachen Gesetz der Großen Zahlen impliziert ist (vgl. Theorem 27.1).

31.3.3. Asymptotische Normalität

In manchen Fällen nähert sich die frequentistische Verteilung eines Schätzers bei großen Stichprobenumfängen einer Normalverteilung. Man nennt einen solchen Schätzer dann *asymptotisch normalverteilt*.

Definition 31.11 (Asymptotisch normalverteilter Schätzer)**.** $y = (y_1, ..., y_n)$ sei die Stichprobe eines parametrischen Produktmodells und $\hat{\theta}_n$ sei ein Parameterschätzer für θ. Weiterhin sei

$$\tilde{\theta} \sim N(\mu, \sigma^2) \tag{31.117}$$

eine normalverteilte Zufallsvariable mit Erwartungswertparameter μ und Varianzparameter σ^2. Wenn $\hat{\theta}_n$ in Verteilung gegen $\tilde{\theta}$ konvergiert, wenn also für die KVFen P_n und P von $\hat{\theta}_n$ und $\tilde{\theta}$, respektive, gilt, dass

$$\lim_{n\to\infty} P_n(\hat{\theta}_n) = P(\tilde{\theta}), \tag{31.118}$$

dann heißt $\hat{\theta}_n$ *asymptotisch normalverteilt* und wir schreiben

$$\hat{\theta}_n \overset{a}{\sim} N(\mu, \sigma^2). \tag{31.119}$$

•

Als Beispiel für einen asymptotisch normalverteilten Schätzer betrachten wir in Kapitel 31.3.4 den Maximum-Likelihood-Schätzer des Bernoullimodellparameters. Es ist bemerkenswert, dass dieser Schätzer asymptotisch normalverteilt ist, da die Stichprobenvariablen des Bernoullimodells lediglich die Werte null und eins annehmen.

31.3.4. Asymptotische Effizienz

In manchen Fällen lassen sich neben der asymptotischen Normalität eines Schätzers auch in der Form des Frequentistischen Modells begründete Aussagen zum Erwartungswertparameter und Varianzparameter dieser asymptotischen Normalverteilung machen. Der Begriff des *effizienten Schätzers* formuliert einen solchen Spezialfall.

Definition 31.12. $y = (y_1, ..., y_n)$ sei die Stichprobe eines parametrischen Produktmodells und $\hat{\theta}_n$ sei ein Parameterschätzer für θ. Weiterhin sei $J(\theta)$ die erwartete Fisher-Information der Stichprobe y. Wenn gilt, dass

$$\hat{\theta}_n \overset{a}{\sim} N\left(\theta, J(\theta)^{-1}\right), \tag{31.120}$$

dann heißt $\hat{\theta}_n$ *asymptotisch effizient*.

•

Ein asymptotisch effizienter Schätzer ist offenbar auch immer asymptotisch normalverteilt und erwartungstreu. Die Varianz der asymptotischen Verteilung eines Schätzers nennt man auch die *asymptotische Varianz*. Für einen asymptotisch effizienten Schätzers ist die asymptotische Varianz mit der Cramér-Rao-Schranke identisch und damit in der Menge der erwartungstreuen asymptotisch normalverteilten Schätzer minimal.

Beispiel 31.6. Als Beispiel für einen asymptotisch effizienten Schätzer betrachten wir den Maximum-Likelihood-Schätzer des Bernoullimodellparameters. Folgender **R** Code simuliert die Frequentistische Verteilung dieses Schätzers und bestimmt die WDF seiner asymptotischen Verteilung

```
# Modellformulierung
mu          = 0.4                                                    # wahrer, aber unbekannter, Parameterwert
n_all       = c(1e1,5e1,1e2)                                         # Stichprobenumfang
ns          = 1e4                                                    # Anzahl Stichprobenrealisierungen
mu_hat   = matrix(rep(NaN, length(n_all)*ns), nrow = length(n_all))  # Maximum-Likelihood-Schätzerarray
mu_hat_r = 1e3                                                       # Maximum-Likelihood-Schätzerraumaufloesung
mu_hat_y = seq(0,1,len = mu_hat_r)                                   # Maximum-Likelihood-Schätzerraum
mu_hat_p = matrix(rep(NaN, length(n_all)*mu_hat_r), nrow = length(n_all))  # Maximum-Likelihood-WDF-Array

# Stichprobenumfängeiterationen
for(i in seq_along(n_all)){

    # Simulationsiterationen
    for(s in 1:ns){
        y           = rbinom(n_all[i],1,mu)                          # Stichprobenrealisation
        mu_hat[i,s] = mean(y)                                        # Maximum-Likelihood-Schätzerrealisation
    }
    mu_hat_p[i,] = dnorm(mu_hat_y, mu, sqrt(mu*(1-mu)/n_all[i]))     # WDF der asymptotischen Verteilung
}
```

△

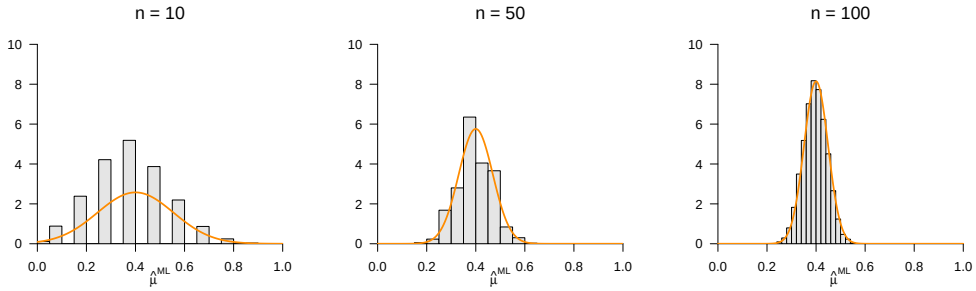


Abbildung 31.5. Simulation der asymptotischen Effizienz des Maximum-Likelihood-Parameterschätzers für den Parameter eines Bernoullimodells. Mit steigendem Stichprobenumfang gleicht sich die durch ein Histogramm dargestellte Verteilung der simulierten Schätzerwerte der in Definition 31.12 formulierten Normalverteilung

31.4. Eigenschaften von Maximum-Likelihood-Schätzern

Das Maximum-Likelihood-Prinzip zur Gewinnung von Schätzern für Parameter Frequentistischer Inferenzmodelle ist durch folgendes Theorem zu den Eigenschaften von Maximum-Likelihood-Schätzern begründet.

Theorem 31.18 (Eigenschaften von Maximum-Likelihood-Schätzern)**.** *y sei die Stichprobe eines parametrischen Produktmodells und $\hat{\theta}_n^{ML}$ sei ein Maximum-Likelihood-Schätzer für θ. Dann gilt, dass $\hat{\theta}_n^{ML}$*

(1) nicht notwendigerweise erwartungstreu, aber
(2) asymptotisch erwartungstreu,
(3) konsistent,
(4) asymptotisch normalverteilt und
(5) asymptotisch effizient

ist.

∘

Für einen Beweis von Theorem 31.18 verweisen wir auf Held & Sabanés Bové (2014), Abschnitt 3.4. Nutzt man also das Maximum-Likelihood-Prinzip zur Gewinnung eines Schätzers, so erfüllt der gewonnene Schätzer garantiert die in Theorem 31.18 zusammengefassten Schätzergütekriterien.

31.5. Literaturhinweise

Die in diesem Kapitel vorgestellten Resultate gehen in ganz wesentlicher Weise auf Fisher (1922) zurück. Aldrich (1997) gibt dazu eine historische Einordnung.

Selbstkontrollfragen

1. Geben Sie die Definition des Begriffs eines Parameterpunktschätzers wieder.
2. Erläutern Sie den Begriff des Parameterpunktschätzers.
3. Geben Sie die Definition der Begriffe der Likelihood-Funktion und der Log-Likelihood-Funktion wieder.
4. Geben Sie die Definition des Begriffs des Maximum-Likelihood-Schätzers wieder.
5. Erläutern Sie das Vorgehen zur Gewinnung von Maximum-Likelihood-Schätzern.
6. Geben Sie das Theorem zum Maximum-Likelihood-Schätzer des Bernoullimodellparameters wieder.
7. Geben Sie das Theorem zu den Maximum-Likelihood-Schätzern der Normalverteilungsmodellparameter wieder.
8. Geben Sie die Definition des Begriffs der Erwartungstreue eines Schätzers wieder.
9. Erläutern Sie den Begriff der Erwartungstreue eines Schätzers.
10. Geben Sie die Definition der Begriffe der Varianz und des Standardfehlers eines Schätzers wieder.
11. Geben Sie die Definition des Begriffs der Asymptotischen Erwartungstreue eines Schätzers wieder.
12. Erläutern Sie den Begriff der asymptotischen Erwartungstreue eines Schätzers.
13. Geben Sie die Definition des Begriffs der Konsistenz eines Schätzers wieder.
14. Erläutern Sie den Begriff der Konsistenz eines Schätzers.
15. Geben Sie die ersten drei Aussagen des Theorems zu den Eigenschaften von Maximum-Likelihood-Schätzern wieder.

Lösungen

1. Siehe Definition 31.1.
2. Ein Parameterpunktschätzer gibt basierend auf einer Stichprobe einen Tipp für den entsprechenden wahren, aber unbekannten, Parameter an.
3. Siehe Definition 31.2.
4. Siehe Definition 31.3.
5. Um einen Maximum-Likelihood-Schätzer zu gewinnen, formuliert man zunächst die Log-Likelihood-Funktion und bestimmt dann die Nullstellen ihrer Ableitung als potenzielle Maximumstellen. Dazu nutzt man in klassischen Beispielen meist die analytische, in der Anwendung auf komplexere Modelle dagegen meist die numerische Optimierung.
6. Siehe Theorem 31.1.
7. Siehe Theorem 31.2.
8. Siehe Definition 31.4.
9. Ein Schätzer heißt erwartungstreu, wenn sein Erwartungswert mit dem von ihm geschätzten wahren, aber unbekannten, Wert identisch ist.
10. Siehe Definition 31.5.
11. Siehe Definition 31.9.
12. Ein Schätzer heißt asymptotisch erwartungstreu, wenn sein Erwartungswert für gegen unendlich gehende Stichprobenumfänge mit dem von ihm geschätzten wahren, aber unbekannten, Wert identisch ist.
13. Siehe Definition 31.10.
14. Ein Schätzer heißt konsistent, wenn für große Stichprobenumfänge die Wahrscheinlichkeit dafür, dass der Schätzerwert vom wahren, aber unbekannten, Wert abweicht, beliebig klein wird.
15. Siehe Theorem 31.18, Aussagen (1), (2) und (3).

32. Konfidenzintervalle

Konfidenzintervalle stellen eine Intervallschätzung wahrer, aber unbekannter, Parameter dar, die so konstruiert ist, dass sie in den meisten Fällen zutrifft. Dabei wird die gegenüber der Punktschätzung gewonnene Sicherheit der Akkuratheit der Schätzung durch einen Verlust der Genauigkeit der Schätzung ermöglicht. Im Bereich der Punktschätzung erfolgt die Schätzung eines wahren, aber unbekannten, Parameterwerts von zum Beispiel $\theta = 2$ durch einen Punktschätzer sehr genau, z.B. durch $\widehat{\theta} = 2.14$. Jedoch ist diese Schätzung vor dem Hintergrund der verschwindenen Wahrscheinlichkeit einer kontinuierlichen Zufallsvariable genau *einen* reellen Wert anzunehmen mit hoher Sicherheit falsch. Die Schätzung eines wahren, aber unbekannten, Parameters durch ein Intervall von z.B. $[1.94, 2.34]$ ist gröber. Solch eine Schätzung kann jedoch so konstruiert werden, dass sie mit einer hohen gewünschten Wahrscheinlichkeit tatsächlich zutrifft. Um diese Intuition formal darzustellen, fokussieren wir in diesem Kapitel zunächst auf eindimensionale Parameterräume. Wir betrachten also $\Theta \subseteq \mathbb{R}$ und damit in der Tat nur Konfidenz*intervalle*, d.h. Teilmengen von $\mathbb{R}$. Eine Generalisierung der hier vorgestellten Konzepte auf höher dimensionale Parameterräume im Sinne von Konfidenz*mengen* ist jedoch relativ unproblematisch möglich.

32.1. Definition

Definition 32.1 (δ-Konfidenzintervall)**.** Es sei y die Stichprobe eines Frequentistischen Inferenzmodells mit wahrem, aber unbekannten Parameter, $\theta \in \Theta$, es sei $\delta \in]0, 1[$ und es seien $G_u(y)$ und $G_o(y)$. Dann heißt ein Intervall der Form

$$\kappa(y) := [G_u(y), G_o(y)], \tag{32.1}$$

sodass

$$\mathbb{P}_\theta\left(\kappa(y) \ni \theta\right) = \mathbb{P}_\theta\left(G_u(y) \leq \theta \leq G_o(y)\right) = \delta \text{ für alle } \theta \in \Theta \tag{32.2}$$

gilt, ein *δ-Konfidenzintervall für θ*. δ ist die Überdeckungswahrscheinlichkeit von $\kappa(y)$ für θ und wird meist *Konfidenzlevel* genannt. Die Statistiken $G_u(y)$ und $G_o(y)$ heißen die *untere* bzw. die *obere Grenze* des Konfidenzintervalls.

•

Man beachte, dass, wie in allen Frequentistischen Inferenzmodellen, der Parameter θ hier ein wahrer, aber unbekannter, Wert und damit insbesondere fest, nicht zufällig, ist. Weil die oberen und unteren Grenzen eines Konfidenzintervalls als Funktionen der zufälligen Stichprobe Zufallsvariablen sind, ist das durch sie definierte Konfidenzintervall allerdings ein zufälliges Intervall. Die etwas ungewöhnliche Schreibweise $\kappa(y) \ni \theta$ bedeutet schlicht $\theta \in \kappa(y)$. Da $\kappa(y)$ in dem Ausdruck $\mathbb{P}_\theta\left(\kappa(y) \ni \theta\right)$ wie beschrieben die zufällige Entität ist, steht $\kappa(y)$ konventionellerweise links Man denke in dieser Hinsicht zum Beispiel an einen Ausdruck wie $\mathbb{P}(\xi = x)$. Ein δ-Konfidenzintervall überdeckt den wahren, aber unbekannten, Parameter θ nach Definition 32.1 mit Wahrscheinlichkeit δ. Dabei wird oft eine hohe

Überdeckungswahrscheinlichkeit von $\delta := 0.95$ gewählt. In diesem Fall spricht man dann von einem 95%-*Konfidenzintervall*.

Intuitiv mag man δ-Konfidenzintervalle auf zwei Arten interpretieren. Im ersten Fall geht man von der Wiederholung der unabhängigen Realisierung von Stichproben bei identischem wahren, aber unbekannten, Parameter θ aus. Wiederholt man die Realisierung von Daten also "unter immer den gleichen Umständen", so überdeckt ein δ-Konfidenzintervall diesen wahren, aber unbekannten, Parameter im langfristigen Mittel in $\delta \cdot 100\%$ der realisierten Fälle. Alternativ gilt diese Frequentistische Wahrscheinlichkeit für die Überdeckung des wahren, aber unbekannten, Parameters nach Definition 32.1 jedoch auch für jeden beliebigen wahren, aber unbekannten, Parameterwert $\theta_i, i = 1, 2, ...$ Auch wenn man also unterschiedliche, wahre, aber unbekannte, Parameterwerte $\theta_1, \theta_2, ...$ betrachtet und in jedem Fall eine, von den anderen Realisierungen unabhängige, Realisierung der Stichprobe erfasst, so überdecken die entsprechenden δ-Konfidenzintervalle diese wahren, aber unbekannten, Parameter im langfristigen Mittel in $\delta \cdot 100\%$ der Fälle. Intuitiv braucht man also "eine Studie", also die Untersuchung eines wahren, aber unbekannten, Parameterwerts, nicht unter den gleichen Umständen "unendlich oft wiederholen", um von der Überdeckungswahrscheinlichkeit eines Konfidenzintervalls zu profitieren, sondern es genügt in "unterschiedlichen Studien", also den Untersuchungen unterschiedlicher wahrer, aber unbekannter Parameter, Konfidenzintervalle gemäß Definition 32.1 zu bestimmen. Auch in diesem Fall ist ihre Überdeckungswahrscheinlichkeit für die wahren, aber unbekannten Parameter, gesichert.

Um nun für gegebene frequentistische Inferenzmodelle δ-Konfidenzintervalle durch eine konkrete Angabe der Statistiken $G_u(y)$ und $G_o(y)$ zu konstruieren, geht man vor wie folgt. Zunächst definiert man das Inferenzmodell und legt damit die Verteilung der Stichprobe y fest. In einem zweiten Schritt definiert man eine Statistik, also eine Funktion der Stichprobe, die als Grundlage für $G_u(y)$ und $G_o(y)$ dient und analysiert ihre, auf der Stichprobenverteilung basierende, Verteilung. Hat man die entsprechende Verteilung gefunden, so kann man diese dazu nutzen, die Überdeckungswahrscheinlichkeit des wahren, aber unbekannten, Parameters durch ein entsprechend definiertes Konfidenzintervall zu sichern. Wir zeichnen dieses Verfahren in der Entwicklung und den konstruktiven Beweisen der folgenden Beispiele nach.

32.2. Beispiele für Konfidenzintervalle

Konfidenzintervall für den Erwartungswertparameter des Normalverteilungsmodells

Wir betrachten die Konstruktion eines δ-Konfidenzintervalls für den Erwartungswertparameter des Normalverteilungsmodells. Zu diesem Zweck definieren wir zunächst folgende Konfidenzintervallstatistik.

Definition 32.2 (T-Konfidenzintervallstatistik)**.** Gegeben sei das Normalverteilungsmodell

$$y_1, ..., y_n \sim N(\mu, \sigma^2) \tag{32.3}$$

Dann heißt die mit dem Stichprobenmittel und der Stichprobenstandardabweichung

$$\bar{y} := \frac{1}{n}\sum_{i=1}^{n} y_i \text{ und } S := \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(y_i - \bar{y})^2}, \tag{32.4}$$

definierte Statistik

$$T := \sqrt{n}\frac{\bar{y} - \mu}{S} \tag{32.5}$$

T-Konfidenzintervallstatistik.

•

Für die Verteilung der T-Konfidenzintervallstatistik gilt folgendes Theorem.

Theorem 32.1 (Verteilung der T-Konfidenzintervallstatistik)**.** *Die T-Konfidenzintervallstatistik ist eine t-verteilte Zufallsvariable mit Parameter $n-1$, es gilt also*

$$T \sim t(n-1) \tag{32.6}$$

◦

Man beachte, dass die T-Konfidenzintervallstatistik nach Definition 32.2 eine Funktion der Stichprobe ist, während ihre Verteilung nach Theorem 32.1 unabhängig von den wahren, aber unbekannten, Parametern der Stichprobenverteilung ist. Man nennt dies auch die *Pivoteigenschaft* der T-Konfidenzintervallstatistik. Für die folgenden Entwicklungen erinnern wir daran, dass wir die WDF einer t-verteilten Zufallsvariable mit t, die KVF einer t-verteilten Zufallsvariable mit Ψ und die inverse KVF einer t-verteilten Zufallsvariable mit Ψ^{-1} bezeichnen. Folgender **R** Code simuliert zunächst die Verteilung der T-Konfidenzintervallstatistik.

```
# Modellformulierung
mu       = 10                                  # wahrer, aber unbekannter, Erwartungswertparameter
sigsqr   = 4                                   # wahrer, aber unbekannter, Varianzparameter
n        = 12                                  # Stichprobenumfang
ns       = 1e4                                 # Anzahl Stichprobenrealisierungen
res      = 1e3                                 # Ergebnisraumauflösung

# analytische Definitionen und Resultate
yx       = seq(3,17,len = res)                 # y_i Raum
ssqrx    = seq(0,20,len = res)                 # S^2 Raum
tx       = seq(-4,4,len = res)                 # T Raum
p_y_i    = dnorm(yx,mu,sqrt(sigsqr))           # y_i WDF
p_y_bar  = dnorm(yx,mu,sqrt(sigsqr/n))         # y_bar WDF
p_sqr    = dchisq(ssqrx,n-1)                   # S^2 WDF
p_t      = dt(tx,n-1)                          # T WDF

# Simulation
y_i      = rep(NaN,ns)                         # y_i Array
y_bar    = rep(NaN,ns)                         # \bar{y} Array
S        = rep(NaN,ns)                         # S Array
TKS      = rep(NaN,ns)                         # T-Konfidenzintervallstatistik Array
for(s in 1:ns){                                  # Simulationsiterationen
  y        = rnorm(n,mu,sqrt(sigsqr))          # Stichprobenrealisierung
  y_i[s]   = y[1]                              # Stichprobenrealisierung y_i mit i = 1
  y_bar[s] = mean(y)                           # Stichprobenmittelrealisierung
  S[s]     = sd(y)                             # Stichprobenstandardabweichungrealisierung
  TKS[s]   = sqrt(n)*((y_bar[s]-mu)/S[s])      # T-Konfidenzintervallstatistikrealisierung
}
```

In Abbildung 32.1 visualisieren wir die Verteilung der T-Konfidenzintervallstatistik als Resultat der ihr zugrundeliegenden Verteilungen der Stichprobenvariablen, des Stichprobenmittels und der Stichprobenvarianz (vgl. Theorem 29.13). Mithilfe der Verteilung der T-Konfidenzintervallstatistik können wir jetzt folgendes Theorem zum Konfidenzintervall für den Erwartungswertparameter des Normalverteilungsmodells beweisen.

Theorem 32.2 (Konfidenzintervall für den Erwartungswertparameter des Normalverteilungsmodells)**.** *Gegeben sei das Normalverteilungsmodell*

$$y_1, ..., y_n \sim N(\mu, \sigma^2) \tag{32.7}$$

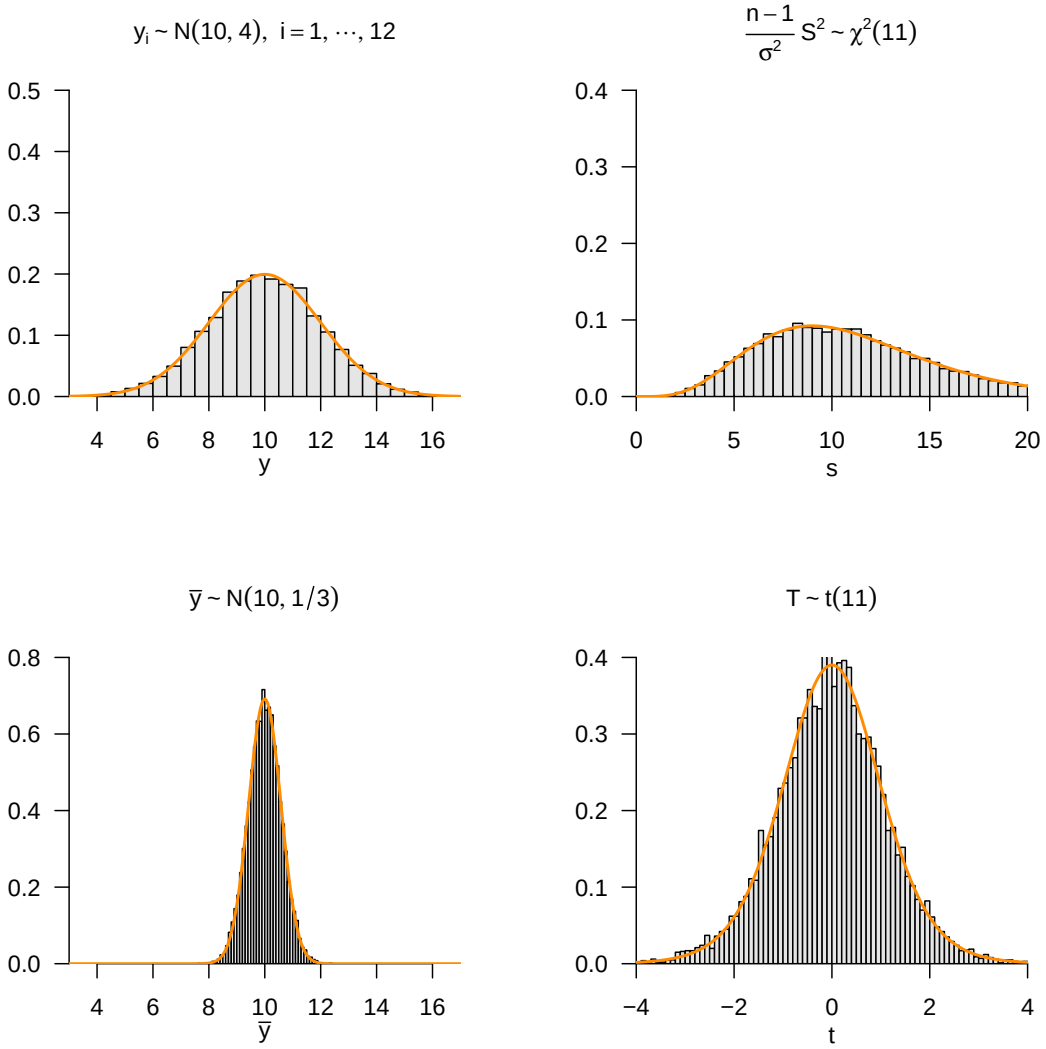


Abbildung 32.1. Simulation der Verteilung der T-Konfidenzintervallstatistik und der ihr zugrundeliegenden Verteilungen der Stichprobenvariable, des Stichprobenmittels und der Stichprobenvarianz.

mit wahren, aber unbekannten, Parametern μ und σ^2, es sei $\delta \in]0,1[$ und es sei

$$t_\delta := \Psi^{-1}\left(\frac{1+\delta}{2}; n-1\right). \tag{32.8}$$

mit der inversen KVF Ψ^{-1} einer t-verteilten Zufallsvariable. Dann gilt für das Intervall

$$\kappa(y) := \left[\bar{y} - \frac{S}{\sqrt{n}}t_\delta, \bar{y} + \frac{S}{\sqrt{n}}t_\delta\right], \tag{32.9}$$

mit dem Stichprobenmittel und der Stichprobenstandardabweichung

$$\bar{y} := \frac{1}{n}\sum_{i=1}^{n} y_i \text{ und } S := \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(y_i - \bar{y})^2}, \tag{32.10}$$

respektive, dass

$$\mathbb{P}_\mu(\kappa(y) \ni \mu) = \delta. \tag{32.11}$$

∘

Beweis. Für $\delta \in]0,1[$ seien zunächst

$$t_1 := \Psi^{-1}\left(\frac{1-\delta}{2}; n-1\right) \text{ und } t_2 := \Psi^{-1}\left(\frac{1+\delta}{2}; n-1\right) \tag{32.12}$$

definiert. Dann gilt

$$\frac{1+\delta}{2} - \frac{1-\delta}{2} = \delta \tag{32.13}$$

und weiterhin gilt mit der Symmetrie der WDF der t-Verteilung, dass

$$t_1 = -t_2. \tag{32.14}$$

Definitionsgemäß gilt dann aber mit Definition 32.2 und Theorem 32.1, dass

$$\mathbb{P}_\mu\left(-t_\delta \leq T \leq t_\delta\right) = \delta. \tag{32.15}$$

Damit folgt dann aber direkt

$$\begin{aligned}
\delta &= \mathbb{P}_\mu\left(-t_\delta \leq T \leq t_\delta\right) \\
&= \mathbb{P}_\mu\left(-t_\delta \leq \frac{\sqrt{n}}{S}(\bar{y} - \mu) \leq t_\delta\right) \\
&= \mathbb{P}_\mu\left(-\frac{S}{\sqrt{n}}t_\delta \leq \bar{y} - \mu \leq \frac{S}{\sqrt{n}}t_\delta\right) \\
&= \mathbb{P}_\mu\left(-\bar{y} - \frac{S}{\sqrt{n}}t_\delta \leq -\mu \leq -\bar{y} + \frac{S}{\sqrt{n}}t_\delta\right) \\
&= \mathbb{P}_\mu\left(\bar{y} + \frac{S}{\sqrt{n}}t_\delta \geq \mu \geq \bar{y} - \frac{S}{\sqrt{n}}t_\delta\right) \\
&= \mathbb{P}_\mu\left(\bar{y} - \frac{S}{\sqrt{n}}t_\delta \leq \mu \leq \bar{y} + \frac{S}{\sqrt{n}}t_\delta\right) \\
&= \mathbb{P}_\mu\left(\left[\bar{y} - \frac{S}{\sqrt{n}}t_\delta, \bar{y} + \frac{S}{\sqrt{n}}t_\delta\right] \ni \mu\right). \\
&= \mathbb{P}_\mu\left(\kappa(y) \ni \mu\right).
\end{aligned} \tag{32.16}$$

□

Der entscheidende Schritt zur Sicherung der Überdeckungswahrscheinlichkeit δ des wahren, aber unbekannten, Erwartungswertparameters durch das in Theorem 32.2 definierte Konfidenzintervall ist die Definition von

$$t_\delta := \Psi^{-1}\left(\frac{1+\delta}{2}; n-1\right). \tag{32.17}$$

Wie im Beweis von Theorem 32.2 nachgezeichnet, ist die Überdeckungswahrscheinlichkeit des Konfidenzintervalls für den wahren, aber unbekannten, Erwartungswertparameter äquivalent zu der Tatsache, dass bei Wahl eben dieses t_δ die T-Konfidenzintervallstatistik eine Wahrscheinlichkeit von δ dafür hat, einen Wert im Intervall $[-t_\delta, t_\delta]$ anzunehmen. Wir visualisieren die Wahl von t_δ für den Fall $\delta := 0.95$ und $n := 5$ in Abbildung 32.2. In diesem Fall ergibt sich

$$-t_\delta = \Psi^{-1}(0.025; 4) = -2.57 \text{ und } t_\delta = \Psi^{-1}(0.975; 4) = 2.57. \tag{32.18}$$

Abbildung 32.2 A zeigt diese Wahl aus Perspektive der WDF der T-Konfidenintervallstatistik. Die von $-t_\delta$ und t_δ eingeschlossene Wahrscheinlichkeitsmasse beträgt nach Konstruktion δ, T nimmt mit einer Wahrscheinlichkeit von δ also einen Wert zwischen $-t_\delta$ und t_δ an. Abbildung 32.2 B zeigt die entsprechende Perspektive der KVF der T-Konfidenintervallstatistik. Basierend auf der Vorgabe von $\frac{1-\delta}{2}$ und $\frac{1+\delta}{2}$ werden anhand der inversen KVF Ψ^{-1} die entsprechenden Werte für $-t_\delta$ und t_δ bestimmt. Man beachte, dass die hier gegebene Zentralität der Wahrscheinlichkeitsmasse in Definition 32.1 nicht implizit ist, sondern sich aus den Gegebenheiten der Verteilung der T-Konfidenzintervallstatistik, insbesondere ihrer Symmetrie um 0, ergibt.

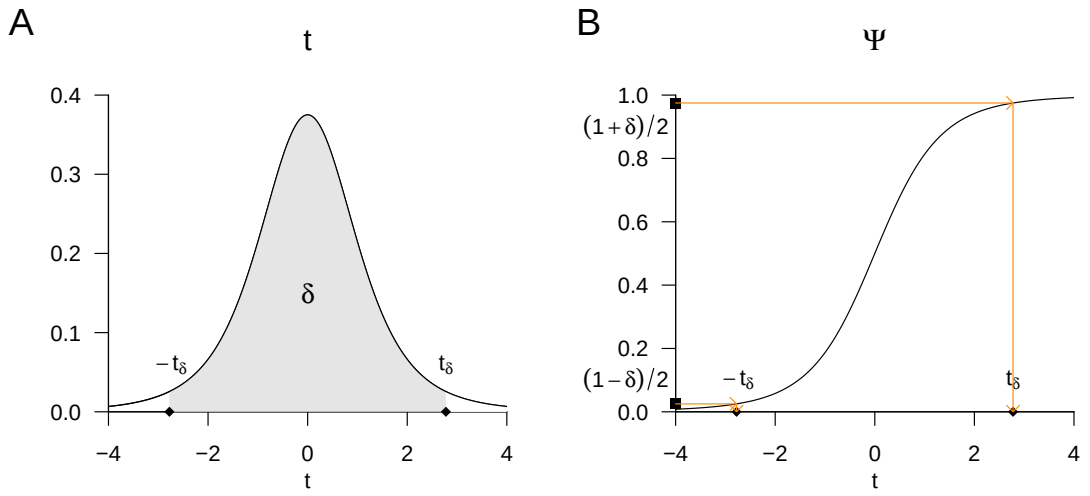


Abbildung 32.2. Sicherung der Überdeckungswahrscheinlichkeit des Konfidenzintervalls für den Erwartungswertparameter des Normalverteilungsmodells für $\delta := 0.95$ und $n := 5$ aus Perspektive der WDF (A) und der KVF (B) der Verteilung der T-Konfidenzintervallstatistik.

Abschließend wollen wir die Überdeckungswahrscheinlichkeit des durch Theorem 32.2 gegebenen Konfidenzintervalls mithilfe einer Simulation demonstrieren. Wir betrachten dabei lediglich die erste Interpretation eines Konfidenzintervalls bei konstantem, wahrem, aber unbekanntem, Parameter. Folgender **R** Code bestimmt in diesem Sinne zu jeder Stichprobenrealisierung das entsprechende Konfidenzintervall.

```
# Modellformulierung
set.seed(1)                                     # Zufallszahlengenerator
mu      = 2                                     # wahrer, aber unbekannter, Erwartungswertparameter
sigsqr  = 1                                     # wahrer, aber unbekannter, Varianzparameter
sigma   = sqrt(sigsqr)                          # wahrer, aber unbekannter, Standardabweichungsparameter
n       = 12                                    # Stichprobenumfang
delta   = 0.95                                  # Konfidenzbedingung
t_delta = qt((1+delta)/2,n-1)                   # \Psi^-1((\delta + 1)/2, n-1)

# Stichprobenrealisierungen
ns      = 1e2                                   # Anzahl Stichprobenrealisierungen
y_bar   = rep(NaN,ns)                           # Stichprobenmittelarray
S       = rep(NaN,ns)                           # Standardabweichungsarray
kappa   = matrix(rep(NaN,2*ns), ncol = 2)       # Konfidenzintervallarray
for(i in 1:ns){
   y          = rnorm(n,mu,sigma)               # Stichprobenrealisierung
   y_bar[i]   = mean(y)                         # Stichprobenmittel
   S[i]       = sd(y)                           # Stichprobenstandardabweichung
   kappa[i,1] = y_bar[i] - (S[i]/sqrt(n))*t_delta  # untere Konfidenzintervallgrenze
   kappa[i,2] = y_bar[i] + (S[i]/sqrt(n))*t_delta  # obere Konfidenzintervallgrenze
}
```

Wir visualisieren die Ergebnisse dieser Simulation in Abbildung 32.3.

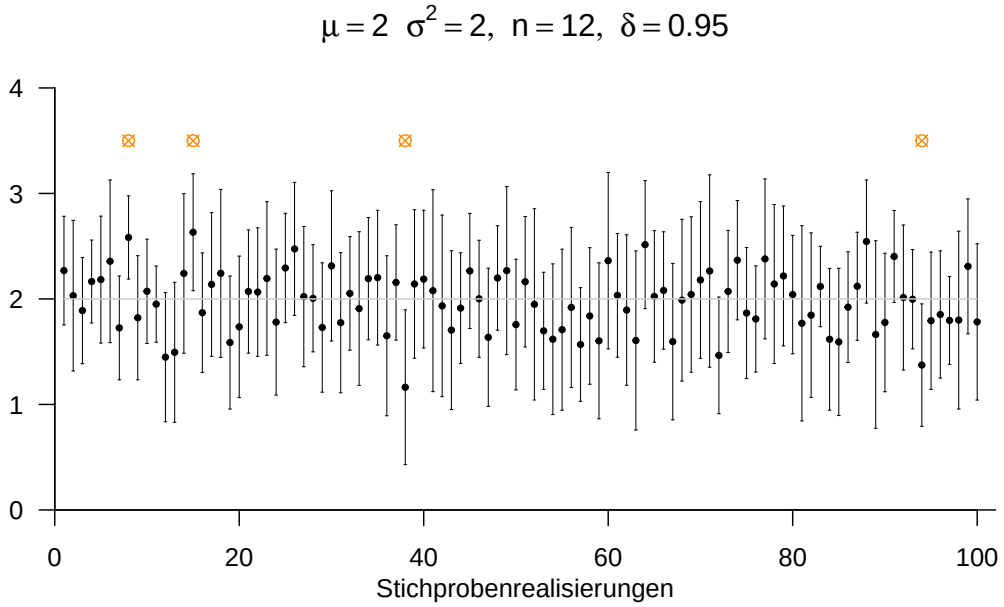


Abbildung 32.3. Simulation der Überdeckungswahrscheinlichkeit des Konfidenzintervalls für den Erwartungswertparameter des Normalverteilungsmodells bei konstanten, wahren, aber unbekannten, Erwartungswertparameter $\mu := 2$ für $\sigma^2 := 2, n := 12$ und einer gewünschten Überdeckungswahrscheinlichkeit von $\delta := 0.95$. Die Abbildung zeigt für jede Stichprobenrealisierung das Konfidenzintervall und den entsprechenden Erwartungswertparameterschätzer. In der vorliegenden Simulation überdecken die Konfidenzintervalle den durch eine graue Linie eingezeichneten immer gleichen wahren, aber unbekannten, Erwartungswertparameter $\mu := 2$ in 96 von 100 Fällen. Die Stichprobenrealisierungen, für die dies nicht der Fall ist, sind mit einem orangen Kreis markiert

Konfidenzintervall für den Varianzparameter des Normalverteilungsmodells

Wir betrachten die Konstruktion eines δ-Konfidenzintervalls für den Varianzparameter des Normalverteilungsmodells. Zu diesem Zweck definieren zunächst folgende Konfidenzintervallstatistik.

Definition 32.3 (U-Konfidenzintervallstatistik)**.** Gegeben sei das Normalverteilungsmodell

$$y_1, ..., y_n \sim N(\mu, \sigma^2) \tag{32.19}$$

Dann heißt die mit der Stichprobenvarianz

$$\frac{1}{n-1} \sum_{i=1}^{n} (y_i - \bar{y})^2 \tag{32.20}$$

definierte Statistik

$$U := \frac{n-1}{\sigma^2} S^2 \tag{32.21}$$

U-Konfidenzintervallstatistik.

•

Für die Verteilung der U-Konfidenzintervallstatistik gilt folgendes Theorem.

Theorem 32.3 (Verteilung der U-Konfidenzintervallstatistik)**.** *Die U-Konfidenzintervallstatistik ist eine χ^2-verteilte Zufallsvariable mit Parameter $n-1$, es gilt also*

$$U \sim \chi^2(n-1) \tag{32.22}$$

◦

Für einen Beweis von Theorem 32.3 verweisen wir auf Casella & Berger (2002). Wie die T-Konfidenzintervallstatistik besitzt auch die U-Konfidenzintervallstatistik die Pivoteigenschaft, da sie eine Funktion der Stichprobe ist, aber ihre Verteilung nach Theorem 32.3 nicht von den wahren, aber unbekannten, Verteilungsparametern der Stichprobe abhängt. Für die folgenden Entwicklungen erinnern wir daran, dass wir die WDF einer χ^2-verteilten Zufallsvariable mit χ^2, die KVF einer χ^2-verteilten Zufallsvariable mit Ξ und die inverse KVF einer χ^2-verteilten Zufallsvariable mit Ξ^{-1} bezeichnen. Folgender **R** Code simuliert zunächst die Verteilung der U-Konfidenzintervallstatistik.

```
# Modellformulierung
mu      = 10                                # wahrer Erwartungswertparameter
sigsqr  = 4                                 # wahrer bekannter Varianzparameter
n       = 12                                # Stichprobenumfang
ns      = 1e4                               # Anzahl Stichprobenrealisierungen
res     = 1e3                               # Ergebnisraumauflösung

# analytische Definitionen und Resultate
yx      = seq(3,17,len = res)               # y_i Raum
ux      = seq(0,30,len = res)               # U Raum
p_y_i   = dnorm(yx,mu,sqrt(sigsqr))         # y_i WDF
p_y_bar = dnorm(yx,mu,sqrt(sigsqr/n))       # y_bar WDF
p_u     = dchisq(ux,n-1)                    # U WDF

# Simulation
y_i     = rep(NaN,ns)                       # y_i Array
y_bar   = rep(NaN,ns)                       # \bar{y} Array
S_sqr   = rep(NaN,ns)                       # S^2 Array
UKS     = rep(NaN,ns)                       # U-Konfidenzintervallstatistik Array
for(s in 1:ns){                             # Simulationsiterationen
  y         = rnorm(n,mu,sqrt(sigsqr))      # Stichprobenrealisierung
  y_i[s]    = y[1]                          # Stichprobenrealisierung y_i mit i = 1
  y_bar[s]  = mean(y)                       # Stichprobenmittelrealisierung
  S_sqr[s]  = var(y)                        # Stichprobenvarianzrealisierung
  UKS[s]    = ((n-1)/sigsqr)*S_sqr[s]       # U-Konfidenzintervallstatistikrealisierung
}
```

Mithilfe der Verteilung der U-Konfidenzintervallstatistik können wir jetzt folgendes Theorem zum Konfidenzintervall für den Varianzparameter des Normalverteilungsmodells beweisen.

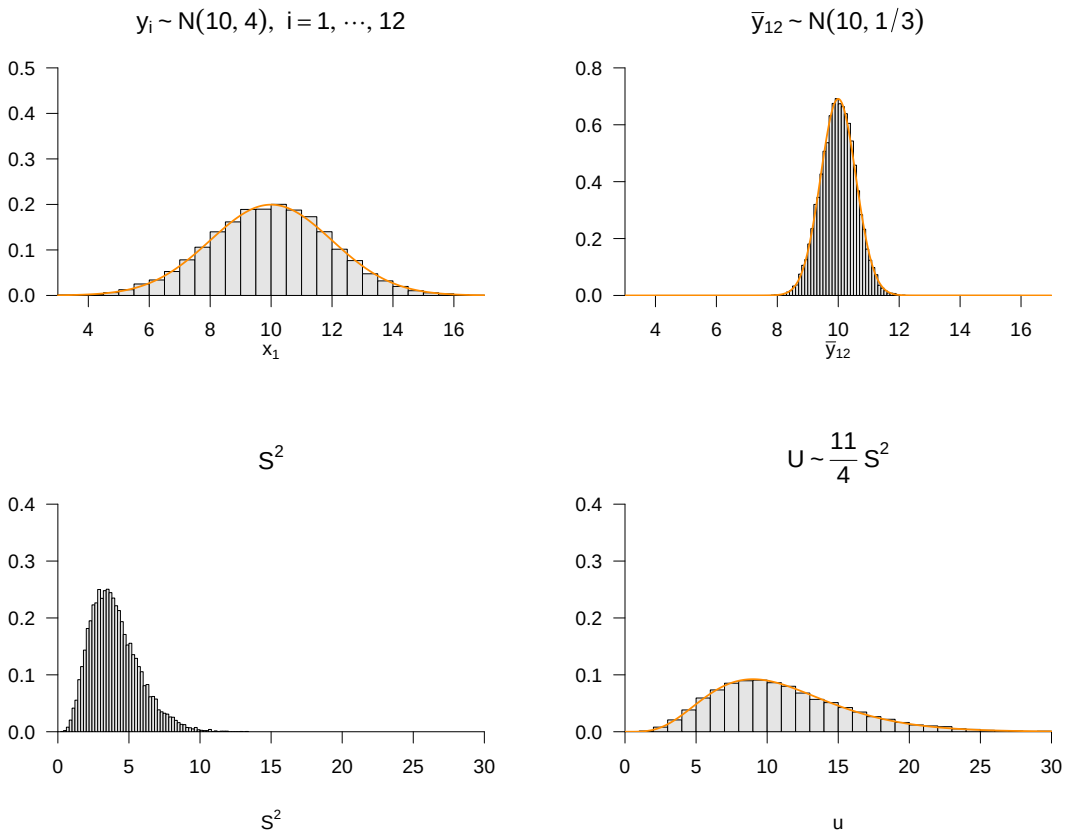


Abbildung 32.4. Simulation der Verteilung der U-Konfidenzintervallstatistik und der ihr zugrundeliegenden Verteilungen der Stichprobenvariable, des Stichprobenmittels und der Stichprobenvarianz.

Theorem 32.4 (Konfidenzintervall für den Varianzparameter des Normalverteilungsmodells)**.** *Gegeben sei das Normalverteilungsmodell*

$$y_1, ..., y_n \sim N(\mu, \sigma^2) \tag{32.23}$$

mit wahren, aber unbekannten, Parametern μ und σ^2, es sei $\delta \in]0, 1[$ und es seien

$$u_\delta := \Xi^{-1}\left(\frac{1-\delta}{2}; n-1\right) \text{ und } u'_\delta := \Xi^{-1}\left(\frac{1+\delta}{2}; n-1\right) \tag{32.24}$$

mit der inversen KVF Ξ^{-1} einer χ^2-verteilten Zufallsvariable. Dann gilt für das Intervall

$$\kappa(y) := \left[\frac{(n-1)S^2}{u'_\delta}, \frac{(n-1)S^2}{u_\delta}\right]. \tag{32.25}$$

mit der Stichprobenvarianz

$$S^2 := \frac{1}{n-1}\sum_{i=1}^{n}(y_i - \bar{y})^2, \tag{32.26}$$

dass

$$\mathbb{P}_{\sigma^2}(\kappa(y) \ni \sigma^2) = \delta. \tag{32.27}$$

∘

Beweis. Definitionsgemäß gilt mit Definition 32.3 und Theorem 32.3, dass

$$\mathbb{P}_{\sigma^2}\left(u_\delta \leq U \leq u'_\delta\right) = \delta. \tag{32.28}$$

Damit folgt dann aber direkt

$$\begin{aligned}
\delta &= \mathbb{P}_{\sigma^2}\left(u_\delta \leq U \leq u'_\delta\right) \\
&= \mathbb{P}_{\sigma^2}\left(u_\delta \leq \frac{n-1}{\sigma^2}S^2 \leq u'_\delta\right) \\
&= \mathbb{P}_{\sigma^2}\left(u_\delta^{-1} \geq \frac{\sigma^2}{(n-1)S^2} \geq {u'_\delta}^{-1}\right) \\
&= \mathbb{P}_{\sigma^2}\left(\frac{(n-1)S^2}{u_\delta} \geq \sigma^2 \geq \frac{(n-1)S^2}{u'_\delta}\right) \\
&= \mathbb{P}_{\sigma^2}\left(\frac{(n-1)S^2}{u'_\delta} \leq \sigma^2 \leq \frac{(n-1)S^2}{u_\delta}\right) \\
&= \mathbb{P}_{\sigma^2}\left(\left[\frac{(n-1)S^2}{u'_\delta}, \frac{(n-1)S^2}{u_\delta}\right] \ni \sigma^2\right).
\end{aligned} \tag{32.29}$$

□

Wie im Falle von Theorem 32.2 ist der entscheidende Schritt zur Sicherung der Überdeckungswahrscheinlichkeit δ des wahren, aber unbekannten, Varianzparameters durch das in Theorem 32.4 definierte Konfidenzintervall die Definition von

$$u_\delta := \Xi^{-1}\left(\frac{1-\delta}{2}; n-1\right) \text{ und } u'_\delta := \Xi^{-1}\left(\frac{1+\delta}{2}; n-1\right). \tag{32.30}$$

Wie im Beweis von Theorem 32.4 nachgezeichnet, ist die Überdeckungswahrscheinlichkeit des Konfidenzintervalls für den wahren, aber unbekannten, Varianzparameter äquivalent zu der Tatsache, dass bei Wahl eben dieser Werte von u_δ und u'_δ die U-Konfidenzintervallstatistik eine Wahrscheinlichkeit von δ dafür hat, einen Wert im

Intervall $[u_\delta, u'_\delta]$ anzunehmen. Wir visualisieren die Wahl von u_δ und u'_δ für den Fall $\delta := 0.95$ und $n := 10$ in Abbildung 32.5. In diesem Fall ergibt sich

$$u_\delta := \Xi^{-1}(0.025; 9) = 2.70 \text{ und } u'_\delta := \Xi^{-1}(0.975; 9) = 19.0. \tag{32.31}$$

Abbildung 32.5 A zeigt diese Wahl aus Perspektive der WDF der U-Konfidenintervallstatistik. Die von u_δ und u'_δ eingeschlossene Wahrscheinlichkeitsmasse beträgt nach Konstruktion δ, U nimmt mit einer Wahrscheinlichkeit von δ also einen Wert zwischen u_δ und u'_δ an. Abbildung 32.5 B zeigt die entsprechende Perspektive der KVF der U-Konfidenintervallstatistik. Basierend auf der Vorgabe von $\frac{1-\delta}{2}$ und $\frac{1+\delta}{2}$ werden anhand der inversen KVF Ξ^{-1} die entsprechenden Werte für u_δ und u'_δ bestimmt. Man beachte, dass in diesem Fall die Wahrscheinlichkeitsmasse recht arbiträr hinsichtlich des Modalwerts der Verteilung der U-Konfidenzintervallstatistik lokalisiert ist. Dementsprechend gibt es weitergehende Verfahren, die Überdeckungswahrscheinlichkeit einer Konfidenzintervallstatistik so zu lokalisieren, dass sie beispielsweise ein maximales Intervall in ihrem Ergebnisraum einnimmt oder eine Symmetrieeigenschaft um den Erwartungswert erfüllt. Wir wollen diese hier aber nicht vertiefen.

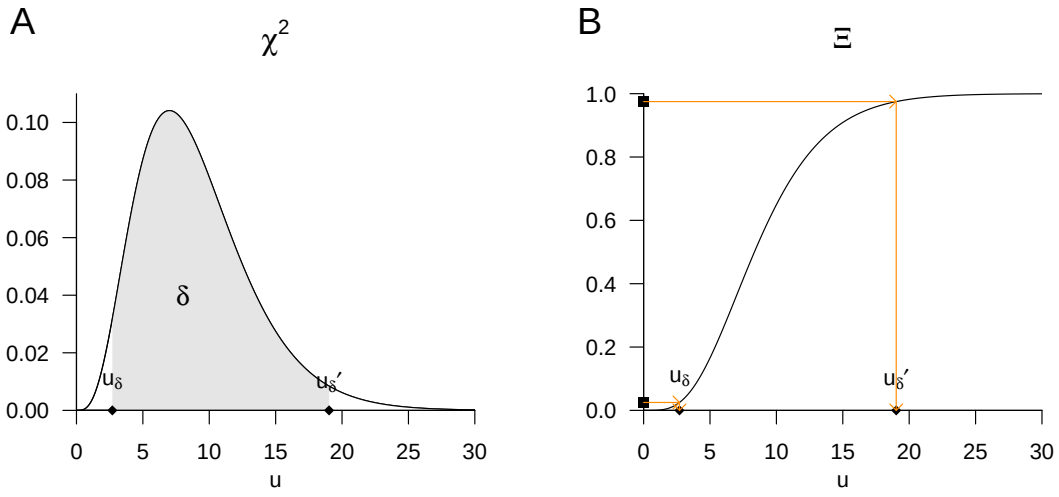


Abbildung 32.5. Sicherung der Überdeckungswahrscheinlichkeit des Konfidenzintervalls für den Varianzparameter des Normalverteilungsmodells für $\delta := 0.95$ und $n := 10$ aus Perspektive der WDF (A) und der KVF (B) der Verteilung der U-Konfidenzintervallstatistik.

Abschließend wollen wir die Überdeckungswahrscheinlichkeit des durch Theorem 32.4 gegebenen Konfidenzintervalls mithilfe einer Simulation demonstrieren. Dazu betrachten wir zunächst die in Kapitel 32.1 gegebene erste Interpretation eines Konfidenzintervalls bei immer gleichem wahrem, aber unbekanntem, Parameter. Folgender **R** Code bestimmt in diesem Sinne zu jeder Stichprobenrealisierung das entsprechende Konfidenzintervall.

```
# Modellformulierung
set.seed(1)                                 # Zufallszahlengenerator
mu          = 2                             # wahrer, aber unbekannter,  Erwartungswertparameter
sigsqr      = 2                             # wahrer, aber unbekannter,  Varianzparameter
n           = 12                            # Stichprobenumfang
delta       = 0.95                          # Konfidenzbedingung
u_delta     = qchisq((1-delta)/2, n - 1)    # \Xi^2((1-\delta)/2; n - 1)
u_delta_p   = qchisq((1+delta)/2, n - 1)    # \Xi^2((1+\delta)/2; n - 1)

# Stichprobenrealisierungen
ns          = 1e2                           # Anzahl Simulationen
y_bar       = rep(NaN,ns)                   # Stichprobenmittelarray
S2          = rep(NaN,ns)                   # Stichprobenvarianzarray
```

```
kappa       = matrix(rep(NaN,2*ns), ncol = 2)   # Konfidenzintervallarray
for(i in 1:ns){                                 # Simulationsiterationen
   y            = rnorm(n,mu,sqrt(sigsqr))      # Stichprobenrealisierung
   S2[i]        = var(y)                        # Stichprobenvarianz
   kappa[i,1]   = (n-1)*S2[i]/u_delta_p         # untere Konfidenzintervallgrenze
   kappa[i,2]   = (n-1)*S2[i]/u_delta           # obere Konfidenzintervallgrenze
}
```

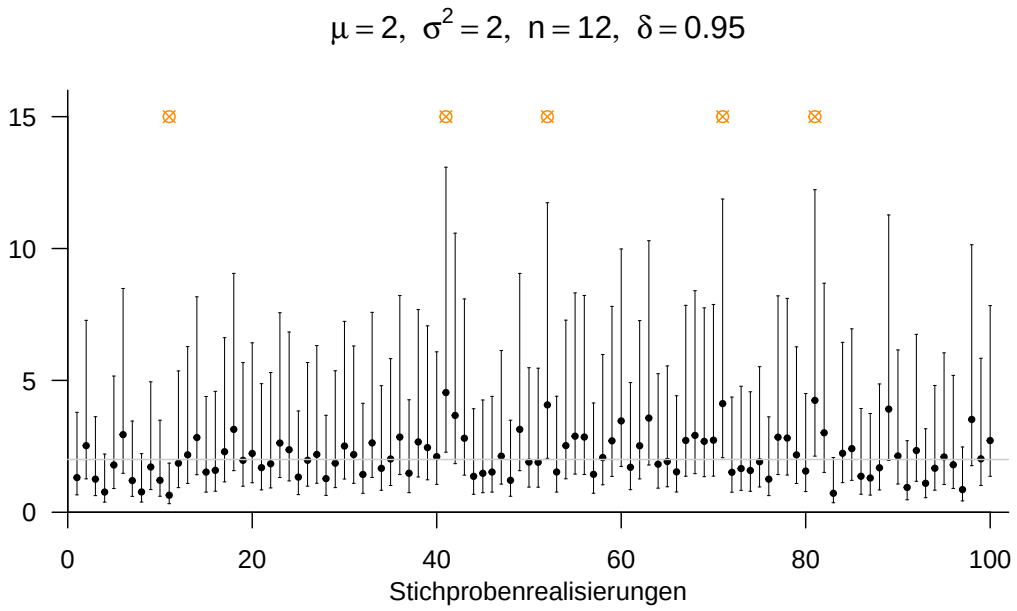


Abbildung 32.6. Simulation der Überdeckungswahrscheinlichkeit des Konfidenzintervalls für den Varianzparameter des Normalverteilungsmodells bei konstanten, wahren, aber unbekannten, Varianzparameter $\sigma^2 := 2$ für $\mu := 2, n := 12$ und einer gewünschten Überdeckungswahrscheinlichkeit von $\delta := 0.95$. Die Abbildung zeigt für jede Stichprobenrealisierung das Konfidenzintervall und den entsprechenden Varianzparameterschätzer. In der vorliegenden Simulation überdecken die Konfidenzintervalle den durch eine graue Linie eingezeichneten immer gleichen wahren, aber unbekannten, Varianzparameter $\sigma^2 := 2$ in 95 von 100 Fällen. Die Stichprobenrealisierungen, für die dies nicht der Fall ist, sind mit einem orangen Kreis markiert. Man beachte, dass die Konfidenzintervalle nicht symmetrisch um den Varianzparameterschätzer angeordnet sind

Beispiel 32.1 (Anwendungsbeispiel)**.** Zum Abschluss dieses Abschnitts wollen wir die Evaluation von Konfidenzintervallen für den Erwartungswert und den Varianzparameter bei Normalverteilung nun im Kontext von Beispiel 30.5 betrachten. Dazu werten wir zunächst einmal die unverzerrten Punktschätzer von μ und σ^2, also das Stichprobenmittel und die Stichprobenvarianz des Datensatzes mithilfe folgenden **R** Codes aus.

```
D           = read.csv("./_data/bdi-ii-datensatz.csv")      # Datensatzeinlesen
y           = D$dBDI                                        # Datenauswahl
mu_hat      = round(mean(y),2)                              # Stichprobenmittel
sigsqr_hat  = round(var(y),2)                               # Stichprobenvarianz
cat("mu_hat     :", mu_hat,"\nsigsqr_hat :", sigsqr_hat)    # Ausgabe
```

```
mu_hat     : 3.17
sigsqr_hat : 13.79
```

Basierend auf diesen Schätzern und den vorliegenden $n = 12$ Datenpunkten sind also

$$\hat{\mu} = 3.17 \text{ und } \hat{\sigma}^2 = 13.8 \tag{32.32}$$

sinnvolle Tipps für μ und σ^2. Neben diesen Punktschätzern, die zwar sehr genau sind, mit einer Wahrscheinlichkeit von 0 aber den wahren, aber unbekannten Parametern, entsprechen, bestimmen wir zusätzlich die 95%-Konfidenzintervallschätzungen für μ und σ^2. Folgender **R** Code bestimmt das 95%-Konfidenzintervall für den Erwartungswertparameter.

```
# Konfidenzintervall für den Erwartungswertparameter
delta    = 0.95                                 # Konfidenzlevel
n        = length(y)                            # Anzahl Datenpunkte
t_delta  = qt((1+delta)/2,n-1)                  # \psi^-1((\delta+1)/2,n-1)
y_bar    = mean(y)                              # Stichprobenmittel
s        = sd(y)                                # Stichprobenstandardabweichung
mu_hat   = y_bar                                # Erwartungswertparameterschätzer
kappa_u  = y_bar - (s/sqrt(n))*t_delta          # untere Konfidenzintervallgrenze
kappa_o  = y_bar + (s/sqrt(n))*t_delta          # obere  Konfidenzintervallgrenze
cat("kappa_u:", kappa_u, "\nkappa_o:", kappa_o)    # Ausgabe
```

```
kappa_u: 0.8074098
kappa_o: 5.525923
```

Das 0.95-Konfidenzintervall für den Erwartungswertparameter ist also

$$\kappa(y) = [0.80, 5.52]. \tag{32.33}$$

Im langfristigen Mittel überdeckt ein auf diese Weise berechnetes Konfidenzintervall den wahren, aber unbekannten, Erwartungswertparameter in 95 von 100 Fällen. In diesem Sinne liegt der wahre, aber unbekannte, Therapieeffekt also sehr sicher in einem Intervall zwischen 0.80 und 5.52 BDI-II Score Pre-Post-Differenzen.

Folgender **R** Code bestimmt das 95%-Konfidenzintervall für den Varianzparameter.

```
# Konfidenzintervall für den Varianzparameter
delta       =  0.95                             # Konfidenzlevel
n           = length(y)                         # Anzahl Datenpunkte
u_delta_u   = qchisq((1-delta)/2, n - 1)        # \Xi^2((1-\delta)/2; n - 1)
u_delta_o   = qchisq((1+delta)/2, n - 1)        # \Xi^2((1+\delta)/2; n - 1)
s2          = var(y)                            # Stichprobenvarianz
sigsqr_hat  = s2                                # Varianzparameterschätzer
kappa_u     = (n-1)*s2/u_delta_o                # untere Konfidenzintervallgrenze
kappa_o       = (n-1)*s2/u_delta_u              # obere Konfidenzintervallgrenze
cat("kappa_u:", kappa_u, "\nkappa_o:", kappa_o)    # Ausgabe
```

```
kappa_u: 6.919084
kappa_o: 39.74756
```

Das 0.95-Konfidenzintervall für den Varianzparameter ist also

$$\kappa(y) = [6.91, 39.74]. \tag{32.34}$$

Im langfristigen Mittel überdeckt ein auf diese Weise berechnetes Konfidenzintervall den wahren, aber unbekannten, Varianzparameter in 95 von 100 Fällen. In diesem Sinne liegt die wahre, aber unbekannte, Therapieeffektstreuung also sehr sicher in einem Intervall zwischen 6.91 und 39.74 quadrierten BDI-II Score Pre-Post-Differenzen.

△

32.3. Literaturhinweise

Die in diesem Kapitel vorgestellten Ergebnisse gehen in ganz wesentlicher Weise auf Neyman (1937) zurück.

Selbstkontrollfragen

1. Geben Sie die Definition des Begriffs eines δ-Konfidenzintervalls wieder.
2. Erläutern Sie die zwei Interpretationen eines δ-Konfidenzintervalls.
3. Erläutern Sie die typischen Schritte zur Konstruktion eines δ-Konfidenzintervalls.
4. Geben Sie das Theorem zum Konfidenzintervall für den Erwartungswertparameter des Normalverteilungsmodells wieder.
5. Geben Sie das Theorem zum Konfidenzintervall für den Varianzparameter des Normalverteilungsmodells wieder.

Lösungen

1. Siehe Definition 32.1.
2. Siehe Diskussion im Anschluss an Definition 32.1.
3. Siehe letzter Absatz der Diskussion im Anschluss an Definition 32.1.
4. Siehe Theorem 32.2.
5. Siehe Theorem 32.4.

33. Hypothesentests

Die grundlegende Logik Frequentistischer Hypothesentests kann am Beispiel des Normalverteilungsmodells grob wie folgt umrissen werden. Man unterstellt, dass ein beobachteter Datensatz eine Realisierung einer Stichprobe $y_1, ..., y_n \sim N(\mu, \sigma^2)$ ist und berechnet basierend auf dem Datensatz eine *Teststatistik*, zum Beispiel das anhand der Stichprobenstandardabweichung und der Stichprobengröße normalisierte Stichprobenmittel $\sqrt{n}\frac{\bar{y}}{s}$.

Man fragt sich dann, wie wahrscheinlich es wohl wäre, den beobachteten oder einen extremeren Wert der Teststatistik unter der Annahme eines *Nullmodells* zu observieren. Dabei versteht man unter einem *Nullmodell* intuitiv ein Wahrscheinlichkeitsverteilungsmodell bei dem kein "interessanter Effekt" vorliegt, also zum Beispiel im Sinne des Normalverteilungsmodells $\mu = 0$ gilt. Dabei ist der Begriff der Wahrscheinlichkeit natürlich frequentistisch zu verstehen, also als idealisierte relative Häufigkeit, wenn man viele Stichprobenrealisationen des Nullmodells generieren würde. Je nach Beschaffenheit des zugrundeliegenden frequentistischen Inferenzmodells und der betrachteten Teststatistik kann es dabei durchaus möglich sein, diese Wahrscheinlichkeit exakt zu bestimmen.

Ist nun die betrachtete Wahrscheinlichkeit dafür, den beobachteten oder einen extremeren Wert der Teststatistik unter Annahme des Nullmodells zu observieren groß, so schließt man intuitiv, dass "es wohl ganz plausibel ist, dass das Nullmodell die Daten generiert hat". Im Wissenschaftsjargon spricht man dann von einem "statistisch nicht-signifikanten Ergebnis". Ist die betrachtete Wahrscheinlichkeit dafür, den beobachteten oder einen extremeren Wert der Teststatistik unter Annahme des Nullmodells zu observieren, dagegen klein, so schließt man intuitiv, dass "es wohl nicht so plausibel, dass das Nullmodell die Daten generiert hat". Im Wissenschaftsjargon spricht man in diesem Fall von einem "statistisch signifikanten Ergebnis".

Wie immer in der Frequentistischen Statistik weiß man nach Durchführung einer solchen Prozedur natürlich nicht, ob im vorliegenden Fall nun wirklich das Nullmodell oder ein anderes Modell die Daten generiert hat. Nan weiß nur, wie oft man bei dieser Prozedur im Mittel richtig oder falsch liegen würde, wenn alle Annahmen zuträfen und man diese Prozedur sehr oft wiederholen würde.

In den folgenden Abschnitten wollen wir diese intuitiven Gedanken formalisieren. Dabei ist es wichtig, immer zwischen Hypothesen im Sinne der Frequentistischen Inferenz und dem generellen Begriff der wissenschaftlichen Hypothese zu unterscheiden. Das Aufstellen einer wissenschaftlichen Hypothese impliziert keineswegs die Notwendigkeit eines frequentistischen Hypothesentests. Es bedeutet lediglich, dass bei quantitativer Arbeitsweise Unsicherheit anhand beobachteter, für die Hypothese relevanter Daten sinnvoll quantifiziert und kommuniziert werden sollte. Frequentistische Hypothesentests sind dabei nur eine, wenn auch sehr populäre, der vielen Möglichkeiten, dies zu tun. Es sei schon an dieser Stelle erwähnt, dass das "Nullhypothesen-Signifikanz-Testen", wie wir es im Folgenden darlegen, wissenschaftliche umstritten ist (vgl. zum Beispiel Amrhein & Greenland (2018) und McShane et al. (2019)).

33.1. Testhypothesen und Tests

Im Kontext eines frequentistischen Hypothesentests wird der Begriff des frequentistischen Inferenzmodells (vgl. Definition 30.1) zunächst durch die sogenannten *Testhypothesen* zu einem *Testszenario* erweitert. Wir nutzen dazu folgende Definition.

Definition 33.1 (Testhypothesen und Testszenario)**.** Gegeben sei ein Frequentistisches Inferenzmodell mit Stichprobe y, Ergebnisraum $\mathcal{Y}$ und Parameterraum Θ. Weiterhin sei $\{\Theta_0, \Theta_1\}$ eine Partition des Parameterraums, so dass

$$\Theta = \Theta_0 \cup \Theta_1 \text{ und } \Theta_0 \cap \Theta_1 = \emptyset. \tag{33.1}$$

Dann ist eine *Testhypothese* eine Aussage über den wahren, aber unbekannten, Parameter θ in Hinblick auf die Untermengen Θ_0 und Θ_1 des Parameterraums. Speziell werden die Aussagen

- $\theta \in \Theta_0$ als *Nullhypothese* und
- $\theta \in \Theta_1$ als *Alternativhypothese*

bezeichnet. Der Einfachheit halber bezeichnet man auch Θ_0 und Θ_1 direkt als Nullhypothese bzw. Alternativhypothese. Die Einheit aus Frequentistischem Inferenzmodell und Testhypothesen wird als *Testszenario* bezeichnet.

•

Je nach Beschaffenheit von Θ_0 und Θ_1 unterscheidet man zunächst *einfache* und *zusammengesetzte* Testhypothesen.

Definition 33.2 (Einfache und zusammengesetzte Testhypothesen)**.** Für die Testhypothesen Θ_i mit $i = 0, 1$ gilt:

- Enthält Θ_i nur ein einziges Element, so heißt Θ_i *einfach*.
- Enthält Θ_i mehr als ein Element, so heißt Θ_i *zusammengesetzt*.

•

Man beachte, dass weil nach Annahme der wahre, aber unbekannte, Parameter θ die Verteilung $\mathbb{P}_\theta$ der Stichprobe festlegt, eine einfache Testhypothese der Festlegung der Stichprobenverteilung auf genau eine Verteilung entspricht. Eine zusammengesetzte Testhypothese entspricht dagegen einer Menge möglicher Verteilungen der Stichprobe. Ein Beispiel für eine einfache Testhypothese in einem Testszenario mit Parameterraum $\Theta := \mathbb{R}$ ist

$$\Theta_0 := \{0\}. \tag{33.2}$$

Die entsprechende zusammengesetzte Alternativhypothese ist dann gegeben durch

$$\Theta_1 = \mathbb{R} \setminus \{0\}. \tag{33.3}$$

Die Nullhypothese, also die Aussage "$\theta \in \Theta_0$" entspricht dabei der Aussage "$\theta = 0$", da Θ_0 nur das eine Element 0 enthält.

Ist der Parameterraum eines Testszenarios eindimensional, so unterscheidet man weiterhin *einseitige* und *zweiseitige* Testhypothesen.

Definition 33.3 (Einseitige und zweiseitige Testhypothesen)**.** Gegeben sei ein Testszenario mit eindimensionalem Parameteraum $\Theta := \mathbb{R}$ und es sei $\theta_0 \in \Theta$. Dann werden zusammengesetzte Nullhypothesen der Form $\Theta_0 :=]-\infty, \theta_0]$ oder $\Theta_0 := [\theta_0, \infty[$ *einseitige Nullhypothesen* genannt und auch in der Form $H_0 : \theta \leq \theta_0$ bzw. $H_0 : \theta \geq \theta_0$ geschrieben. Die entsprechenden Alternativhypothesen haben dabei die Form $\Theta_1 :=]\theta_0, \infty[$ bzw. $\Theta_1 :=]-\infty, \theta_0[$, auch geschrieben als $H_1 : \theta > \theta_0$ bzw. $H_1 : \theta < \theta_0$. Bei einer einfachen Nullhypothese der Form $\Theta_0 := \{\theta_0\}$, auch geschrieben als $H_0 : \theta = \theta_0$, wird die Alternativhypothese $\Theta_1 := \Theta \backslash \{\theta_0\}$, auch geschrieben als $H_1 : \theta \neq \theta_0$, *zweiseitige Alternativhypothese* genannt.

•

Vor dem Hintergrund eines Testszenarios definieren wir nun den Begriff des *Tests*.

Definition 33.4 (Test)**.** Gegeben sei ein Testszenario. Dann ist ein *Test* eine Abbildung ϕ aus dem Ergebnisraum der Stichprobe $\mathcal{Y}$ in die Menge $\{0, 1\}$, also

$$\phi : \mathcal{Y} \to \{0, 1\}, y \mapsto \phi(y), \tag{33.4}$$

wobei

- $\phi(y) = 0$ das Nichtablehnen der Nullhypothese und
- $\phi(y) = 1$ das Ablehnen der Nullhypothese

repräsentieren.

•

Der Testbegriff ist nicht trivial, da Tests wie Schätzer und Konfidenzintervalle, als Funktionen der Stichprobenvariablen selbst Zufallsvariablen sind. Eigentlich sind Tests damit auf Zufallsvektorräumen definiert. Der Einfachheit halber betrachten wir in Definition 33.4 eine konkrete Realisierung $y \in \mathcal{Y}$ der Stichprobe y, die durch ϕ in die Menge $\{0, 1\}$ abgebildet wird. Der Funktionswert $\phi(y)$ von ϕ ist vor diesem Hintergrund also eine Realisierung der Zufallsvariable $\phi(y)$.

In der Anwendung ist man oft an Tests interessiert, die eine bestimmte Struktur haben. Wir formalisieren diese Struktur unter dem Begriff der *Standardtests*.

Definition 33.5 (Standardtest)**.** Gegeben sei ein Testszenario. Dann ist ein *Standardtest* ϕ definiert als die Verkettung einer *Teststatistik*

$$\gamma : \mathcal{Y} \to \Gamma \tag{33.5}$$

und einer *Entscheidungsregel*

$$\delta : \Gamma \to \{0, 1\} \tag{33.6}$$

kann also geschrieben werden als

$$\phi := \delta \circ \gamma : \mathcal{Y} \to \{0, 1\}. \tag{33.7}$$

•

Wie oben ist auch bei Definition 33.5 zu beachten, dass die Teststatistik eine Funktion der Stichprobenvariablen, also von Zufallsvariablen ist, die wir hier als Funktion der Werte dieser Zufallsvariablen in $\mathcal{Y}$ definiert haben. Ebenso ist zu beachten, dass die Entscheidungsregel eine Funktion der zufälligen Teststatistik ist, die wir hier gleichfalls als Funktion der Werte dieser Zufallsvariable mit Ergebnisraum Γ geschrieben haben. Teststatistik und Entscheidungsregel sind in einem Testszenario also Zufallsvariablen. Entsprechend ist, wenn y eine Realisierung der Stichprobe y ist, $\gamma(y) \in \Gamma$ eine Realisierung von $\gamma(y)$ und $(\delta \circ \gamma)(y)$ eine Realisierung von $(\delta \circ \gamma)(y)$.

Die verteilungstheoretischen Eigenschaften eines Tests ergeben sich aus den ihnen zugrundeliegenden verteilungstheoretischen Eigenschaften des entsprechenden Frequentistischen Inferenzmodells und damit natürlich insbesondere der Verteilung der Stichprobenvariablen. Eine wichtige Brücke zwischen diesen beiden Ebenen bilden die Begriffe des *kritischen Bereichs* und des *Ablehnungsbereichs* eines Tests.

Definition 33.6 (Kritischer Bereich eines Tests)**.** Gegeben sei ein Testszenario und ein Test ϕ. Dann heißt

$$K := \{y \in \mathcal{Y} | \phi(y) = 1\} \subset \mathcal{Y}, \tag{33.8}$$

also die Untermenge des Ergebnisraums $\mathcal{Y}$ der Stichprobe y, für die der Test den Wert 1 annimmt, *kritischer Bereich* des Tests

•

Man beachte, dass vor dem Hintergrund von Definition 33.6 die zufälligen Ereignisse $\{y \in K\}$ und $\{\phi(y) = 1\}$, dass also die Stichprobe einen Wert im kritischen Bereichs des Tests annimmt bzw. dass der Test den Wert 1 annimmt, äquivalent sind und damit die gleiche Wahrscheinlichkeit haben. Fragt man also nach der Wahrscheinlichkeit, dass ein Test den Wert 1 annimmt, also die Nullhypothese abgelehnt wird, so entspricht diese Wahrscheinlichkeit genau der Wahrscheinlichkeit, dass die Stichprobe einen Wert im kritischen Bereichs des Tests annimmt. Da die Verteilung der Stichprobe aber als bekannt vorausgesetzt ist, kann die Wahrscheinlichkeit für das Ablehnen der Nullhypothese basierend auf ihr bestimmt werden. Hat man speziell einen Standardtest vorliegen, so überträgt sich das Gesagte unmittelbar auch auf die zwischen Stichprobe und Test geschaltete Teststatistik. Dies führt auf die folgende Definition.

Definition 33.7 (Ablehnungsbereich eines Standardtests)**.** Gegeben sei ein Testszenario und ein Standardtest ϕ mit Teststatistik γ. Dann heißt

$$A := \{\gamma(y) \in \Gamma | \phi(y) = 1\} \subset \Gamma, \tag{33.9}$$

also die Untermenge des Ergebnisraums Γ der Teststatistik, für die der Test den Wert 1 annimmt, *Ablehnungsbereich des Tests.*

•

Wie zum Begriff des kritischen Bereichs angemerkt gilt auch hier, dass die Ereignisse $\{\phi(y) = 1\}$ und $\{\gamma(y) \in A\}$ äquivalent sind und damit die gleiche Wahrscheinlichkeit besitzen. Insgesamt gelten mit Definition 33.6 und Definition 33.7 für einen Standardtest also

$$\{y \in K\} \Leftrightarrow \{\gamma(y) \in A\} \Leftrightarrow \{\phi(y) = 1\} \tag{33.10}$$

und

$$\mathbb{P}_\theta\left(\{y \in K\}\right) = \mathbb{P}_\theta\left(\{\gamma(y) \in A\}\right) = \mathbb{P}_\theta\left(\{\phi(y) = 1\}\right). \tag{33.11}$$

Dabei soll das Subskript θ andeuten, dass die entsprechenden Verteilungen durch den Parameter der Stichprobenverteilung festgelegt sind.

In der Anwendung basiert die in Definition 33.5 allgemein angebene Form der Entscheidungsregel eines Standardtest meist darauf, dass eine beobachtete Teststatistik mit Ergebnisraum $\Gamma := \mathbb{R}$ einen bestimmten sogenannten *kritischen Wert* $k \in \mathbb{R}$ überschreitet oder unterschreitet. Dies führt auf die Konzepte der *einseitigen* und *zweiseitigen kritischen Wert-basierte Tests*.

Definition 33.8 (Kritischer Wert-basierte Tests)**.** Ein *kritischer Wert-basierter Test* ist ein Standardtest, bei dem die Entscheidungsregel δ von einem kritischen Wert k der Teststatistik mit Ergebnisraum $\mathbb{R}$ abhängt. Speziell ist

- ein *einseitiger kritischer Wert-basierter Test* von der Form

$$\phi : \mathcal{Y} \to \{0,1\}, y \mapsto \phi(y) := 1_{\{\gamma(y) \geq k\}} = \begin{cases} 1 & \gamma(y) \geq k \\ 0 & \gamma(y) < k \end{cases}, \tag{33.12}$$

- ein *zweiseitiger kritischer Wert-basierter Test* von der Form

$$\phi : \mathcal{Y} \to \{0,1\}, y \mapsto \phi(y) := 1_{\{|\gamma(y)| \geq k\}} = \begin{cases} 1 & |\gamma(y)| \geq k \\ 0 & |\gamma(y)| < k \end{cases}. \tag{33.13}$$

•

Mit der Definition kritischer Wert-basierter Tests ist die praktische Durchführung eines Hypothesentests nun vorgezeichnet. Wie immer in der Frequentistischen Inferenz legt man vorliegenden Daten zunächst ein Frequentistisches Inferenzmodell zugrunde, nimmt also an, dass die vorliegenden Daten eine Realisierung einer Stichprobe sind. Basierend auf dieser Realisierung berechnet man eine Teststatistik und vergleicht diese abschließend mit einem kritischen Wert, um dann entweder die Nullhypothese nicht abzulehnen oder die Nullhypothese abzulehnen. Im folgenden Abschnitt wollen wir der Frage nachgehen, wie vor dem Hintergrund von Null- und Alternativhypothese dabei der kritische Wert eines kritischen Wert-basierten Tests so bestimmt werden kann, dass man im Sinne der frequentistischen Wahrscheinlichkeit möglichst gute Testentscheidungen trifft.

33.2. Testgütekriterien und Testkonstruktion

Die Tatsache, dass in einem Testszenario der wahre, aber unbekannte, Parameter im Bereich der Nullhypothese oder der Alternativhypothese liegen kann und man gleichzeitig basierend auf dem Wert des Tests die Nullhypothese entweder ablehnen oder nicht ablehnen kann, impliziert, dass eine Testentscheidung richtig oder falsch sein kann. Untenstehende Definition soll dahingehend zunächst begriffliche Klarheit schaffen.

Definition 33.9 (Richtige Testentscheidungen und Testfehler)**.** Gegeben seien ein Testszenario und ein Test. Dann gibt es mit dem Nichtablehnen der Nullhypothese $\phi(y) = 0$, wenn die Nullhypothese $\theta \in \Theta_0$ zutrifft, und dem Ablehnen der Nullhypothese $\phi(y) = 1$, wenn die Alternativhypothese $\theta \in \Theta_1$ zutrifft, zwei Formen der *richtigen Testentscheidung*. Ebenso gibt es zwei Arten von *Testfehlern*. Das Ablehnen der Nullhypothese $\phi(y) = 1$, wenn die Nullhypothese $\theta \in \Theta_0$ zutrifft, heißt *Typ I Fehler*. Das Nichtablehen der Nullhypothese $\phi(y) = 0$, wenn die Alternativhypothese $\theta \in \Theta_1$ zutrifft, heißt *Typ II Fehler*.

•

Testentscheidung

Wahrer, aber unbekannter, Parameter	$\phi(y) = 0$	$\phi(y) = 1$
$\theta \in \Theta_0$	Richtige Entscheidung	Typ I Fehler
$\theta \in \Theta_1$	Typ II Fehler	Richtige Entscheidung

Abbildung 33.1. Richtige Testentscheidungen und Typ I und Typ II Fehler

Abbildung 33.1 gibt eine Übersicht zu den möglichen richtigen Testentscheidungen und Testfehlern bei Durchführung eines Tests. Natürlich möchte man präferentiell eine richtige Testentscheidung treffen. Das entscheidende Werkzeug, um vor dem frequentistischen Hintergrund des Testszenarios möglichst gute Tests zu konstruieren, ist dann die sogenannte *Testgütefunktion*.

Definition 33.10 (Testgütefunktion)**.** Gegeben sei ein Testszenario und ein Test ϕ. Dann ist die *Testgütefunktion* von ϕ definiert als

$$q_\phi : \Theta \to [0, 1], \theta \mapsto q_\phi(\theta) := \mathbb{P}_\theta(\phi(y) = 1). \tag{33.14}$$

Für $\theta \in \Theta_1$ heißt q_ϕ auch *Trennschärfefunktion* oder *Powerfunktion*.

•

Man beachte, dass $\mathbb{P}_\theta$ in Definition 33.10 die Verteilung der Zufallsvariable $\phi(y)$ unter der Annahme, dass die Verteilung von y durch θ festgelegt ist, bezeichnen soll. Für jedes $\theta \in \Theta$ liefert q_ϕ also die Wahrscheinlichkeit dafür, dass die Nullhypothese durch den Test ϕ abgelehnt wird. Für diese Wahrscheinlichkeiten gelten mit den Begriffen des kritischen Bereichs (vgl. Definition 33.6) und des Ablehnungsbereichs (vgl. Definition 33.7)

$$\mathbb{P}_\theta(\phi(y) = 1) = \mathbb{P}_\theta(\gamma(y) \in A) = \mathbb{P}_\theta(y \in K). \tag{33.15}$$

Die Testgütefunktion ist spezifisch für einen gegebenen Test. Ändert sich der Test, zum Beispiel, weil bei einem kritischen Wert-basierten Test ein anderer kritischer Wert gewählt wird, ändern sich obige Wahrscheinlichkeiten und damit die Testgütefunktion.

Mithilfe der Testgütefunktion geschieht die Testkonstruktion dann gemäß folgender Überlegungen. Im Idealfall hätte man einen Test ϕ mit

$$q_\phi(\theta) = \mathbb{P}_\theta(\phi(y) = 1) = 0 \text{ für } \theta \in \Theta_0 \text{ und } q_\phi(\theta) = \mathbb{P}_\theta(\phi(y) = 1) = 1 \text{ für } \theta \in \Theta_1. \quad (33.16)$$

Die Testentscheidung eines solchen Tests wäre mit Wahrscheinlichkeit 1 richtig, da ein solcher Test die Nullhypothese mit Wahrscheinlichkeit 0 ablehnt, wenn sie zutrifft, und die Nullhypothese mit Wahrscheinlichkeit 1 ablehnt, wenn sie nicht zutrifft. Allgemeiner sind natürlich kleine Werte von q_ϕ für $\theta \in \Theta_0$, also kleine Wahrscheinlichkeiten dafür, die Nullhypothese abzulehnen, wenn sie zutrifft, und große Werte von q_ϕ für $\theta \in \Theta_1$, also große Wahrscheinlichkeiten dafür, die Nullhypothese abzulehnen, wenn sie nicht zutrifft, zur Testfehlerminimierung günstig. Allerdings bestehen im Allgemeinen Abhängigkeiten zwischen den Werten der Testgütefunktion für $\theta \in \Theta_0$ und $\theta \in \Theta_1$, wie folgende Beispiele illustrieren sollen.

Beispiel (A) Es sei ϕ_a ein Test definiert durch

$$\phi_a : \mathcal{Y} \to \{0, 1\}, y \mapsto \phi_a(y) := 0. \quad (33.17)$$

ϕ_a sei also ein Test, der die Nullhypothese unabhängig von den beobachteten Daten nie ablehnt. Für ϕ_a gilt dann

$$q_{\phi_a}(\theta) = \mathbb{P}_\theta(\phi(y) = 1) = 0 \text{ für } \theta \in \Theta_0. \quad (33.18)$$

Allerdings gilt für ϕ_a dann auch automatisch

$$q_{\phi_a}(\theta) = \mathbb{P}_\theta(\phi(y) = 1) = 0 \text{ für } \theta \in \Theta_1. \quad (33.19)$$

ϕ_a hat also eine minimale Sensitivität dafür, die Tatsache, dass die Alternativhypothese zutrifft, zu detektieren.

Beispiel (B) Umgekehrt sei ϕ_b ein Test definiert durch

$$\phi_b : \mathcal{Y} \to \{0, 1\}, y \mapsto \phi_b(y) := 1. \quad (33.20)$$

ϕ_b sei also ein Test, der die Nullhypothese, unabhängig von den beobachteten Daten immer ablehnt. Für ϕ_b gilt dann

$$q_{\phi_b}(\theta) = \mathbb{P}_\theta(\phi(y) = 1) = 1 \text{ für } \theta \in \Theta_1. \quad (33.21)$$

ϕ_b ist also maximal sensitiv für das Zutreffen der Alternativhypothese. Allerdings gilt für ϕ_b dann auch automatisch

$$q_{\phi_b}(\theta) = \mathbb{P}_\theta(\phi(y) = 1) = 0 \text{ für } \theta \in \Theta_0, \quad (33.22)$$

und ϕ_b resultiert auch immer in der Ablehnung der Nullhypothese, wenn diese zutrifft und generiert in diesem Sinne viele falsch positive Resultate.

Vor dem Hintergrund dieser Beispiele muss es also das Ziel der Testkonstruktion sein, eine angemessene Balance zwischen kleinen Werten der Testgütefunktion bei Zutreffen der Nullhypothese und großen Werten der Testgütefunktion bei Zutreffen der Alternativhypothese zu finden. Die populärste Methode, dies zu erreichen ist es, in einem ersten Schritt einen kleinen Wert $\alpha_0 \in [0, 1]$ zu wählen und sicherzustellen, dass

$$q_\phi(\theta) \leq \alpha_0 \text{ für alle } \theta \in \Theta_0, \quad (33.23)$$

dass also die Wahrscheinlichkeit für das Ablehnen der Nullhypothese, wenn diese zutrifft, also die Wahrscheinlichkeit für einen Typ I Fehler, höchstens α_0 beträgt. Konventionelle Werte für ein solches α_0 sind $\alpha_0 := 0.001$ und $\alpha_0 := 0.05$. Unter allen Tests (und, bei Optimierung von Stichprobengrößen, Frequentistischen Inferenzmodellen), die die Ungleichung (33.23) erfüllen, sucht man dann in einem zweiten Schritt einen Test, für den $q_\phi(\theta)$ für $\theta \in \Theta_1$ so groß wie möglich ist. Dieses zweischrittige Vorgehen ist nicht alternativlos, man könnte ja beispielsweise auch eine lineare Kombinationen von Typ I und Typ II Fehlern gleichzeitig minimieren. Allerdings ist das skizzierte zweischrittige Vorgehen das in der Anwendung populärste, sodass wir uns in der Folge darauf beschränken. Ungleichung (33.23) motiviert dann zunächst die Definition der Begriffe des *Level-α_0-Tests*, des *Signifikanzlevel* α_0 und des *Testumfangs* α.

Definition 33.11 (Level-α_0-Test, Signifikanzlevel α_0 und Testumfang α)**.** Gegeben seien ein Testszenario, ein Test ϕ, seine Testgütefunktion q_ϕ und ein $\alpha_0 \in [0, 1]$. ϕ heißt ein *Level-α_0-Test*, wenn gilt, dass

$$q_\phi(\theta) \leq \alpha_0 \text{ für alle } \theta \in \Theta_0. \tag{33.24}$$

Wenn ϕ ein Level-α_0-Test ist, nennt man den Wert α_0 auch das *Signifikanzlevel* des Tests. Weiterhin heißt die Zahl

$$\alpha := \max_{\theta \in \Theta_0} q_\phi(\theta) \tag{33.25}$$

der *Testumfang* von ϕ.

•

Nach Definition 33.11 ist der Testumfang α die maximale Wahrscheinlichkeit für einen Typ I Fehler und ein Test ist dann, und nur dann, ein Level-α_0-Test, wenn diese maximale Wahrscheinlichkeit kleiner oder gleich dem Signifikanzlevel α_0 ist. Es ist dabei für die Anwendung wichtig, sich die feinen Unterschiede zwischen der Wahrscheinlichkeit eines Typ I Fehlers, dem Testumfang und dem Signifikanzlevel eines Tests zu verdeutlichen. Vor dem Hintergrund des Unterschiedes von einfachen und zusammengesetzten Nullhypothesen (vgl. Definition 33.2) muss man zunächst die Begriffe der Typ I Fehler Wahrscheinlichkeit und des Testumfangs differenzieren. Bei einer einfachen Nullhypothese Θ_0 ist der Testumfang immer gleich der Wahrscheinlichkeit eines Typ I Fehlers, da gilt dass

$$\alpha := \max_{\theta \in \Theta_0} q_\phi(\theta) = \max_{\theta \in \{\theta_0\}} q_\phi(\theta) = q_\phi(\theta_0) = \mathbb{P}_{\theta_0}(\phi(y) = 1). \tag{33.26}$$

Bei einer zusammengesetzten Nullhypothese Θ_0 gibt es je nach Wert von $\theta \in \Theta_0$ verschiedene Wahrscheinlichkeiten für einen Typ I Fehler. Die größte dieser Wahrscheinlichkeiten ist der Testumfang

$$\alpha := \max_{\theta \in \Theta_0} q_\phi(\theta) = \max_{\theta \in \Theta_0} \mathbb{P}_\theta(\phi(y) = 1). \tag{33.27}$$

Ebenso klar sollte man die Begriffe des Signifikanzlevel α_0 und des Testumfangs α voneinander abgrenzen. Ein Signifikanzlevel ist eine frei gewählte obere Grenze für die maximale Wahrscheinlichkeit eines Typ I Fehlers. Die tatsächliche maximale Wahrscheinlichkeit für einen Typ I Fehler, kann mit dieser identisch sein, wie in den meisten Fällen der Kapitel 33.3 diskutierten Beispiele, muss es aber nicht, wie zum Beispiel in multiplen Testszenarien mit nicht unabhängigen Stichprobenvariablen. Man nennt dementsprechend einen Test *exakt*, wenn sein Testumfang mit seinem Signifikanzlevel identisch ist, wenn also gilt

$$\alpha = \alpha_0. \tag{33.28}$$

Ein Test, für den der Testumfang kleiner als sein Signifikanzlevel ist, für den also gilt

$$\alpha < \alpha_0, \tag{33.29}$$

wird *konservativ* genannt. Ein Test schließlich, dessen Testumfang größer als sein Signifikanzlevel ist,

$$\alpha > \alpha_0 \tag{33.30}$$

und der damit natürlich kein Level-α_0-Test sein kann, wird *liberal* genannt.

p-Wert

Ein definierendes Charakterstikum eines Tests ist seine binäre Wertemenge. Resultat eines Tests ist entweder $\phi(y) = 0$, die Nullhypothese wird nicht abgelehnt, oder $\phi(y) = 1$, die Nullhypothese wird abgelehnt. Als finales Resultat einer Datenanalyse wird dabei die einem Datensatz innewohnende Information maximal komprimiert. Insbesondere supprimiert das alleinige Berichten des Testergbnisses interessante Information über das Signal-zu-Rauschen-Verhältnis des betrachteten Datensatzes. So ist es ja beispielsweise möglich, dass die Nullhypothese im Kontext eines kritischen Wert-basierten Tests deshalb abgelehnt wird, weil die Teststatistik den kritischen Wert nur um wenige Nachkommastellen übertroffen. Andererseits ist es genauso möglich, dass die Nullhypothese abgelehnt wird, weil die Testsstatistik ein Vielfaches des kritischen Werts angenommen hat. In beiden Fällen wäre das Testergebnis mit $\phi(y) = 1$ identisch. Neben der reinen Testumfangkontrolle eines Tests und des Berichtens des binären Testergebnisses hat es sich deshalb für kritische Wert-basierte Tests eingebürgert, basierend auf dem beobachteten Wert der Teststatistik auch alle Werte des Signifikanzlevel α_0, für die ein Level-α_0-Test das Ergebnis $\phi(y) = 1$ hätte, für die die Nullhypothese also abgelehnt würde, zu betrachten. Diese Überlegung führt auf folgende allgemeine Definition des sogenannten p-Werts, wobei p für *probability* steht.

Definition 33.12 (p-Wert)**.** ϕ sei ein Test. Dann ist der *p-Wert* das kleinste Signifikanzlevel α_0, bei dem die Nullhypothese basierend auf einem vorliegenden Wert der Teststatistik abgelehnt wird.

•

Insbesondere in einfachen Anwendungsbeispielen, wie dem in Kapitel 33.3.1 betrachteten Einstichproben-T-Test-Szenario spiegeln p-Werte dann die Antwort auf die intuitive Frage, wie wahrscheinlich es im Frequentistischen Sinne wäre, den beobachteten oder einen extremeren Wert der Teststatistik unter der Annahme eines Nullmodells zu observieren. Dabei ist in vielen Bereichen der Grundlagenwissenschaft das Berichten von p-Werten sehr populär, aber auch umstritten (vgl. Wasserstein et al. (2019)). Dabei gilt es, p-Werte nicht überzuinterpretieren. Basierend auf dem Gesagten gibt es keine Gründe, zu folgenden Fehlschlüssen zu gelangen, trotzdem weisen wir vorsorglich daraufhin: p-Werte quantifizieren nicht die Wahrscheinlichkeit dafür, dass die Nullhypothese wahr ist, man kann aufgrund von $p < 0.05$ nicht darauf schließen, dass die Alternativhypothese zutrifft, und man kann aufgrund von $p \geq 0.05$ nicht darauf schließen, dass die Nullhypothese zutrifft.

Ebenso wie der Wert einer Teststatistik und eines Tests quantifizieren p-Werte das in einem vorliegenden Datensatz beobachtete Signal-zu-Rauschen-Verhältnis. Nicht weniger, aber auch nicht mehr.

Anmerkungen zur Wahl von Null- und Alternativhypothese

Wir wollen diesen Abschnitt mit einigen Anmerkungen zur Durchführung von Hypothesentests abschließen. Vor dem Hintergrund der skizzierten Theorie der Hypothesentests stellt sich zunächst die Frage, wie in einem konkreten Anwendungskontext die Zuordnung von Null- und Alternativhypothese zu den Gegenständen des wissenschaftlichen Interesses, also zu den wissenschaftlichen Hypothesen, vorgenommen wird.

Möchte man beispielsweise einen Test durchführen, um im Sinne der frequentistischen Inferenz zu entscheiden, ob ein bestimmtes Psychotherapieverfahren in einer klinischen Studie wirksam war oder nicht, stellt sich die Frage, ob die Abwesenheit eines Therapieeffekts als Null- oder als Alternativhypothese zu formulieren ist.

Hierzu ist anzumerken, dass das oben beschriebene zweischrittige Vorgehen zur Testkonstruktion – bei dem zunächst durch die Wahl eines Signifikanzniveaus der Testumfang festgelegt wird und erst in einem zweiten Schritt dafür gesorgt wird, dass die Wahrscheinlichkeit, die Nullhypothese abzulehnen, sofern die Alternativhypothese zutrifft, möglichst groß ist – eine deutliche Asymmetrie in der Behandlung von Null- und Alternativhypothese impliziert. Mit diesem Vorgehen werden Typ-I-Fehler als schwerwiegender eingestuft als Typ-II-Fehler.

Dies legt eine mögliche Strategie zur Festlegung von Null- und Alternativhypothese nahe: Die Nullhypothese ist jene wissenschaftliche Hypothese, bei deren zugehöriger Testentscheidung man einen Fehler besonders vermeiden möchte bzw. deren Fehlerwahrscheinlichkeit man primär kontrollieren will. In der Wissenschaft gilt es als gängiger Standard, die falsche Bestätigung der eigenen, favorisierten Theorie (etwa die fälschliche Bestätigung, dass ein selbst entwickeltes Psychotherapieverfahren wirksamer ist als ein anderes) als schwerwiegenderen Fehler zu bewerten als deren falsche Zurückweisung.

Entsprechend sollte die falsche Konfirmation der eigenen Theorie einen Typ-I-Fehler darstellen, während ihre falsche Ablehnung als Typ-II-Fehler zu klassifizieren ist. Damit die falsche Konfirmation der eigenen Theorie tatsächlich einem Typ-I-Fehler entspricht – also dem Ablehnen der Nullhypothese, obwohl diese zutrifft –, muss die eigene Theorie als Alternativhypothese formuliert werden. Die fälschliche Ablehnung der Alternativhypothese stellt dann einen Typ-II-Fehler dar.

Intuitiv ergibt sich somit folgende Zuordnung:

$$\text{Nicht-favorisierte wissenschaftliche Hypothese} \rightarrow \text{Nullhypothese}$$
$$\text{Favorisierte wissenschaftliche Hypothese} \rightarrow \text{Alternativhypothese}$$

Hypothesentests in Entscheidungskontexten und Grundlagenwissenschaft

Weiterhin stellt sich die Frage, ob man zur Evaluation wissenschaftlicher Hypothesen überhaupt einen Hypothesentest durchführen sollte. Oberflächlich betrachtet liefern Hypothesentests zunächst einfache binäre Aussagen der Form *"Die Hypothese ist gegeben die Evidenz abzulehnen oder zu akzeptieren"*. Solche Aussagen können in konkreten Entscheidungskontexten hilfreich sein, wenn tatsächlich eine Entscheidung getroffen werden muss. Allerdings ist hierzu anzumerken, dass frequentistische Hypothesentests – wie gesehen – ohne explizite Entscheidungsnutzenfunktion formuliert sind und potenzielle Entscheidungskosten somit nicht explizit in die Entscheidungsfindung einbezogen werden. Für

diesen Zweck existiert eine Reihe sehr zugänglicher Theorien, die es erlauben, im langfristigen Mittel gute Entscheidungen unter Unsicherheit zu treffen, vgl. zum Beispiel Pratt et al. (1995), Puterman (1994) oder Kochenderfer et al. (2022).

Wendet man sich von praktisch relevanten Entscheidungskontexten dem Bereich der Grundlagenwissenschaften zu, deren Wesen es ja gerade ist, keine finalen Wahrheiten zu etablieren, sondern vielmehr das Ausmaß der Unsicherheit über den jeweils aktuellen Theoriestand zu quantifizieren und zu kommunizieren, erscheint die Binarität der Hypothesentestentscheidung im besten Fall überflüssig, im schlimmsten Fall grob irreführend. Fragestellungen der Grundlagenwissenschaften sollten daher prinzipiell nicht als Entscheidungsprobleme formuliert werden.

Trotz der weit verbreiteten Auffassung, dass bayesianische Herangehensweisen wie Positive Predictive Values oder Bayes Factors hier Vorteile böten, ist dies nicht der Fall, solange die mit einer bestimmten Modellpräferenz verbundene Unsicherheit nicht klar mitkommuniziert wird. Nichtsdestotrotz bleibt das frequentistische Hypothesentesten auch in der grundlagenorientierten Wissenschaftsgemeinschaft weiterhin sehr populär, mitunter allerdings nur unter dem Deckmantel von Forderungen nach Grundlagenstudien mit "höherer Power". Um einen Zugang zur psychologisch-naturwissenschaftlichen Literatur zu behalten, ist es daher bislang unumgänglich, sich auch mit dem aus grundlagenwissenschaftlicher Perspektive eigentlich wenig sinnvollen Hypothesentesten auseinanderzusetzen.

33.3. Testbeispiele

33.3.1. Einstichproben-T-Test

Das Anwendungsszenario eines Einstichproben-T-Test ist dadurch gekennzeichnet, dass n univariate Datenpunkte einer Stichprobe (Gruppe) randomisierter experimenteller Einheiten betrachtet werden, von denen angenommen wird, dass sie Realisierungen von n unabhängigen und identisch normalverteilten Zufallsvariablen sind. Hinsichtlich der identischen univariaten Normalverteilungen $N(\mu, \sigma^2)$ dieser Zufallsvariablen wird angenommen, dass sowohl der Erwartungswertparameter μ als auch der Varianzparameter σ^2 unbekannt sind. Schließlich wird vorausgesetzt, dass ein Interesse an einem inferentiellen Vergleich des unbekannten Erwartungswertparameters μ mit einem vorgebenenen Wert μ_0 im Sinne eines Hypothesentests besteht.

Dabei gibt es allerdings mindestens vier Szenarien, die potenziell von Interesse sein können. Ein erster Fall ist das Szenario einer einfachen Nullhypothese und einer einfachen Alternativhypothese,

$$H_0 : \mu = \mu_0 \text{ und } H_1 : \mu = \mu_1. \tag{33.31}$$

Dieser Fall ist in der Theorie sehr gut verstanden und Grundlage des sogenannten *Neymann-Pearson-Lemmas* (Neyman & Pearson (1933)). Seine praktische Relevanz ist aber eher gering, da die Alternativhypothese von einer genauen Spezifikation des Erwartungswertparameters ausgeht. Ein zweiter Fall ist das Szenario einer einfachen Nullhypothese und einer zusammengesetzten Alternativhypothese

$$H_0 : \mu = \mu_0 \text{ und } H_1 : \mu \neq \mu_0. \tag{33.32}$$

In diesem Fall spricht man auch von einer *ungerichteten Hypothese* und nutzt in der Regel einen zweiseitigen Test. Intuitiv entspricht dies der ungerichteten Frage nach inferenzieller

Evidenz für einen Unterschied. Es ist dieser Fall, den wir im Folgenden detailliert betrachten werden. Schließlich gibt es noch mindestens zwei Szenarien mit zusammengesetzten Null- und Alternativhypothesen, etwa der Form

$$H_0 : \mu \leq \mu_0 \text{ und } H_1 : \mu > \mu_0 \text{ oder } H_0 : \mu \geq \mu_0 \text{ und } H_1 : \mu < \mu_0. \tag{33.33}$$

Man spricht in diesem Fall auch von *gerichteten* Hypothesen und nutzt in der Regel einseitige Tests. Diese Fälle betrachten wir im Folgenden nicht.

Frequentistisches Inferenzmodell

Definition 33.13 (Frequentistisches Inferenzmodell des Einstichproben-T-Tests)**.** Das Frequentistische Inferenzmodell des Einstichproben-T-Tests ist das Normalverteilungsmodell

$$y_1, ..., y_n \sim N(\mu, \sigma^2) \text{ mit } (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_{>0}. \tag{33.34}$$

•

Wir erinnern daran, dass aus generativer Sicht das Normalverteilungsmodell dem Modell

$$y_i = \mu + \varepsilon_i \text{ mit } \varepsilon_i \sim N(0, \sigma^2) \text{ für } i = 1, ..., n \tag{33.35}$$

entspricht (vgl. Beispiel 30.5). Die Annahme unabhängig und identisch normalverteilter Zufallsvariablen als Grundlage der Modellierung der Beobachtung von n Datenpunkten ist wie in Beispiel 30.5 gesehen äquivalent zu der Annahme, dass sich jede einen Datenpunkt modellierende Zufallsvariable y_i als Summe aus einem festen, wahren, aber unbekannten, über Zufallsvariablen konstanten Wert μ und aus einem Zufallsvariablen- bzw. Datenpunkt-spezifischen Abweichungsterm ε_i ergibt. Dabei modelliert, wie gesehen, μ den tatsächlichen im wissenschaftlichen Anwendungskontext angenommenen Effekt von Interesse. ε_i dagegen modelliert den Aspekt der Datenvariabilität, der nicht durch μ erklärt werden kann, sondern im Sinne des Zentralen Grenzwertsatzes aus der Summation unendlich vieler Störeinflüsse hervorgeht und damit als Unsicherheit über die Erklärung der Datenvariabilität durch μ verbleibt.

Testhypothesen

Wir betrachten den Fall des Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese.

Definition 33.14 (Einfache Nullhypothese und zusammengesetzte Alternativhypothese des Einstichproben-T-Tests)**.** Gegeben sei das Frequentistische Inferenzmodell des Einstichproben-T-Tests

$$y_1, ..., y_n \sim N(\mu, \sigma^2) \text{ mit } (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_{>0} \tag{33.36}$$

und es sei $\Theta := \mathbb{R}$ der Parameterunterraum des Parameters von Interesse μ. Dann sind für den *Nullhypothesenparameterwert* $\mu_0 \in \mathbb{R}$ die *einfache Nullhypothese* und die *zusammengesetzte Alternativhypothese* des Einstichproben-T-Tests gegeben durch

$$\Theta_0 := \{\mu_0\} \Leftrightarrow H_0 : \mu = \mu_0 \text{ und } \Theta_1 := \mathbb{R} \setminus \{\mu_0\} \Leftrightarrow H_1 : \mu \neq \mu_0. \tag{33.37}$$

•

Man beachte, dass die einfache Nullhypothese und die zusammengesetzte Alternativhypothese durch den Wert $\mu_0 \in \mathbb{R}$ parameterisiert sind. Je nach Wahl von μ_0 ergeben sich also verschiedene Hypothesenszenarien. Wird beispielsweise $\mu_0 := 0$ gewählt, so entspricht die Nullhypothese $\Theta_0 := \{0\}$ der Aussage, dass der wahre, aber unbekannte, Parameter μ gleich 0 ist und die Alternativhypothese $\Theta_1 := \mathbb{R} \setminus \{0\}$ der Aussage, dass der wahre, aber unbekannte, Parameter μ ungleich 0 ist. Wird dagegen beispielsweise $\mu_0 := 2$ gewählt, so entspricht die Nullhypothese $\Theta_0 := \{2\}$ der Aussage, dass der wahre, aber unbekannte, Parameter μ gleich 2 ist und die Alternativhypothese $\Theta_1 := \mathbb{R} \setminus \{2\}$ der Aussage, dass der wahre, aber unbekannte, Parameter μ ungleich 2 ist. Im Anwendungskontext ist μ_0 dementsprechend ein frei gewählter (und damit natürlich bekannter) Parameter des Einstichproben-T-Tests, wohingegen μ wahr, aber unbekannt, ist und bleibt.

Definition der Teststatistik

Mit der *Einstichproben-T-Test-Statistik* definieren wir nun eine Teststatistik, die als Grundlage eines kritischen Wert-basierten Tests dienen kann und deren Betrag eine Abweichung von der Nullhypothese anzeigen kann.

Definition 33.15 (Einstichproben-T-Test-Statistik)**.** Gegeben sei das Testszenario eines Einstichproben-T-Tests mit Stichprobe $y_1, ..., y_n$, Stichprobenmittel $\bar{y}$, Stichprobenstandardabweichung S und Nullhypothesenparameter μ_0. Dann ist die *Einstichproben-T-Test-Statistik* definiert als

$$T := \sqrt{n}\frac{\bar{y} - \mu_0}{S}. \tag{33.38}$$

•

Offenbar hat die Einstichproben-T-Test-Statistik eine hohe Ähnlichkeit mit der T-Konfidenzintervallstatistik (vgl. Definition 32.2). Man beachte allerdings, dass im Fall der Einstichproben-T-Test-Statistik der Nullhypothesenparameter μ_0 nicht identisch mit dem in der T-Konfidenzintervallstatistik auftauchendem wahren, aber unbekannten, Parameterwert μ sein muss.

Da die Einstichproben-T-Test-Statistik im Kontext des Einstichproben-T-Tests zentral ist, ist es sinnvoll, sich ihrer intuitiven Mechanik bewusst zu sein. Im Zähler des Bruchs der Einstichproben-T-Test-Statistik erscheint zunächst die Differenz zwischen dem Stichprobenmittel $\bar{y}$ und dem unter der Nullhypothese angenommenen Parameter μ_0. Wie bereits gesehen, ist das Stichprobenmittel ein unverzerrter Schätzer des Erwartungswertparameters μ der Stichprobenvariablen. Die Differenz $\bar{y} - \mu_0$ stellt somit eine Schätzung der Abweichung des wahren, aber unbekannten Erwartungswertparameters vom Nullhypothesenparameter dar und liefert dem Betrag nach Evidenz für eine Abweichung von der Nullhypothese. Grob betrachtet stellt der Zähler $\bar{y} - \mu_0$ damit ein Maß für das der Stichprobe innewohnende "Signal" dar, verstanden als Abweichung von der Nullhypothese bzw. als "systematische Variabilität".

Der Nenner der Einstichproben-T-Test-Statistik erlaubt es, dieses Signal in Einheiten der Stichprobenstandardabweichung S auszudrücken. Gilt beispielsweise $\bar{y} - \mu_0 = 2$ und ist $S = 1$, so beträgt die Abweichung des Stichprobenmittels vom Nullhypothesenparameter zwei Standardabweichungen. Ist dagegen $S = 2$, so entspricht die Abweichung hier einer Standardabweichung. Darüber hinaus ist der Nenner S ein Maß für die beobachtete Datenvariabilität und ein Schätzer der Standardabweichung σ der Fehlerterme in der generativen

Form des Einstichproben-T-Test-Modells. Grob betrachtet repräsentiert der Nenner der Einstichproben-T-Test-Statistik somit das den Daten innewohnende "Rauschen" bzw. ihre "unsystematische Variabilität". Insgesamt kann der Bruch $\frac{\bar{y}-\mu_0}{S}$ daher als Schätzung des "Signal-zu-Rauschen-Verhältnisses" der Daten interpretiert werden.

Schließlich wird dieses Verhältnis in der Einstichproben-T-Test-Statistik mit der Wurzel der Stichprobengröße $\sqrt{n}$ gewichtet. Intuitiv reflektiert diese Gewichtung die Tatsache, dass einem gegebenen Signal-zu-Rauschen-Verhältnis mehr Validität beigemessen werden kann, wenn es auf einer größeren Anzahl von Beobachtungen basiert, als wenn es auf wenigen Datenpunkten beruht.

Insgesamt liefert die Einstichproben-T-Test-Statistik somit eine skalare Zusammenfassung der den Daten innewohnenden Evidenz gegen die Nullhypothese, bei der sowohl die Datenvariabilität als auch der Stichprobenumfang berücksichtigt werden.

Verteilung der Teststatistik

Für die Verteilung der Einstichproben-T-Test-Statistik gilt nun folgendes Theorem.

Theorem 33.1 (Verteilung der Einstichproben-T-Test-Statistik)**.** *Gegeben sei das Testszenario eines Einstichproben-T-Tests mit Stichprobe $y_1, ..., y_n$, Stichprobenmittel $\bar{y}$, Stichprobenstandardabweichung S, Nullhypothesenparameter μ_0 und Einstichproben-T-Test-Statistik definiert als*

$$T := \sqrt{n}\frac{\bar{y} - \mu_0}{S}. \tag{33.39}$$

Dann ist T eine nichtzentrale t-Zufallsvariable mit Nichtzentralitätsparameter

$$d = \sqrt{n}\frac{\mu - \mu_0}{\sigma} \tag{33.40}$$

und Freiheitsgradparameter $n - 1$, es gilt also $T \sim t(d, n - 1)$

∘

Man beachte, dass im Falle des Zutreffens der Nullhypothese der Nullhypothesenparameter μ_0 mit dem wahren, aber unbekannten, Erwartungswertparameter μ identisch ist und der Nichtzentralitätsparameter der Verteilung der Einstichproben-T-Test-Statistik den Wert $d = 0$ annimmt. Im Falle des Zutreffens der Nullhypothese des Einstichproben-T-Test-Szenarios ist die Einstichproben-T-Test-Statistik also eine t-verteilte Zufallsvariable mit Freiheitsgradparameter $n-1$. Wir visualisieren die Verteilung der Einstichproben-T-Test-Statistik exemplarisch für ein Einstichproben-T-Test-Szenario mit $n = 12$, wahren, aber unbekannten, Parametern $\mu = 3$ und $\sigma^2 = 2$ und Nullhypothesenparameter $\mu_0 = 0$ in Abbildung 33.2 (B). Die Parameter dieser Verteilung ergeben sich dabei zu

$$d = \sqrt{n}\frac{\mu - \mu_0}{\sigma} = \sqrt{12}\frac{3 - 0}{\sqrt{2}} \approx 7.34 \tag{33.41}$$

und

$$n - 1 = 11. \tag{33.42}$$

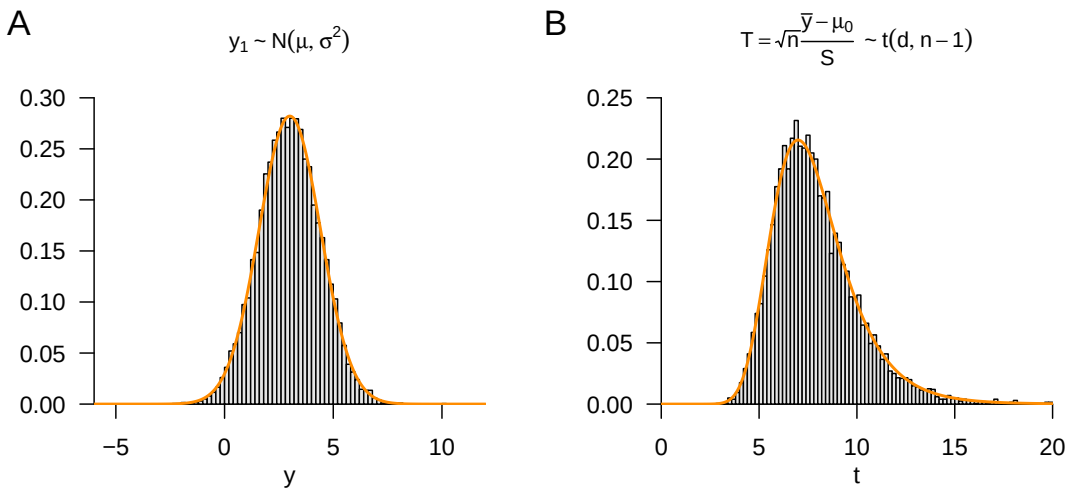


Abbildung 33.2. Verteilung der Einstichproben-T-Test-Statistik für $n = 12, \mu = 3, \sigma^2 = 2$ und $\mu_0 = 0$. (A) Verteilung der Stichprobenvariablen. (B) Verteilung der Einstichproben-T-Test-Statistik.

Testdefinition

Wir können nun den zweiseitigen Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese definieren und seine Testgütefunktion analysieren.

Definition 33.16 (Zweiseitiger Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese)**.** Gegeben seien das Frequentistische Inferenzmodell des Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese und T bezeichne die Einstichproben-T-Test-Statistik. Dann ist der *zweiseitige Einstichproben-T-Test mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese* definiert als der zweiseitige kritische Wert-basierte Test

$$\phi : \mathcal{Y} \to \{0, 1\}, y \mapsto \phi(y) := 1_{\{|T| \geq k\}} = \begin{cases} 1 & |T| > k \\ 0 & |T| \leq k \end{cases}. \tag{33.43}$$

•

Der zweiseitige Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese nimmt also den Wert 0 an, wenn der Betrag der Einstichproben-T-Test-Statistik kleiner als der kritische Wert ist und er nimmt den Wert 1 an, wenn der Betrag der Einstichproben-T-Test-Statistik gleich oder größer als der kritische Wert ist.

Testgütefunktion

Für die Kontrolle des Testumfangs durch Wahl eines kritischen Werts und zur Bestimmung der Powerfunktion dieses Tests ist nun folgendes Theorem maßgeblich.

Theorem 33.2 (Testgütefunktion des zweiseitigen Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese)**.** *ϕ sei der zweiseitige Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese. Dann ist die Testgütefunktion von ϕ gegeben durch*

$$q_\phi : \mathbb{R} \to [0,1], \mu \mapsto q_\phi(\mu) := 1 - \Psi(k; d_\mu, n-1) + \Psi(-k; d_\mu, n-1), \tag{33.44}$$

wobei $\Psi(\cdot; d_\mu, n-1)$ die KVF der nichtzentralen t-Verteilung mit Nichtzentralitätsparameter

$$d_\mu := \sqrt{n}\frac{\mu - \mu_0}{\sigma} \tag{33.45}$$

und Freiheitsgradparameter $n-1$ bezeichnet.

∘

Beweis. Die Testgütefunktion des betrachteten Test im vorliegenden Testszenario ist definiert als

$$q_\phi : \mathbb{R} \to [0,1], \mu \mapsto q_\phi(\mu) := \mathbb{P}_\mu(\phi(y) = 1). \tag{33.46}$$

Da die Wahrscheinlichkeiten für $\phi(y) = 1$ und dafür, dass die zugehörige Teststatistik im Ablehnungsbereich des Tests liegt, gleich sind, benötigen wir also zunächst die Verteilung der Teststatistik. Wir haben oben bereits gesehen, dass die Einstichproben-T-Test-Statistik T anhand einer nichtzentralen t-Verteilung $t(d_\mu, n-1)$ mit Nichtzentralitätsparameter d_μ verteilt ist. Der Ablehnungsbereich des zweiseitigen Einstichproben-T-Tests ist

$$A =]-\infty, -k] \cup]k, \infty[. \tag{33.47}$$

Mit diesem Ablehungsbereich ergibt sich dann

$$\begin{aligned}
q_\phi(\mu) &= \mathbb{P}_\mu(\phi(y) = 1) \\
&= \mathbb{P}_\mu\left(T \in]-\infty, -k] \cup]k, \infty[\right) \\
&= \mathbb{P}_\mu\left(T \in]-\infty, -k]\right) + \mathbb{P}_\mu\left(T \in]k, \infty[\right) \\
&= \mathbb{P}_\mu(T \leq -k) + \mathbb{P}_\mu(T > k) \\
&= \mathbb{P}_\mu(T \leq -k) + (1 - \mathbb{P}_\mu(T \leq k)) \\
&= 1 - \mathbb{P}_\mu(T \leq k) + \mathbb{P}_\mu(T \leq -k) \\
&= 1 - \Psi(k; d_\mu, n-1) + \Psi(-k; d_\mu, n-1),
\end{aligned} \tag{33.48}$$

wobei $\Psi(\cdot; d_\mu, n-1)$ die KVF der nichtzentralen T-Verteilung mit Nichtzentralitätsparameter d_μ und Freiheitsgradparameter $n-1$ bezeichnet. □

In Abbildung 33.3 visualisieren wir die Testgütefunktion des zweiseitigen Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese aus Theorem 33.2 für $\sigma^2 = 9$ und $\mu_0 = 4$ in Abhängigkeit vom kritischen Wert k. Man beachte dabei zunächst, dass die Testgütefunktion als Funktion von μ sowohl das Szenario des Zutreffens der Nullhypothese $\mu = \mu_0$ als auch das Szenario des Zutreffens der Alternativhypothese $\mu \neq \mu_0$ abdeckt. Man beachte weiterhin, dass der Wert der Testgütefunktion, also die Wahrscheinlichkeit dafür, dass der Test den Wert 1 annimmt, sowohl bei positiven als auch bei negativen Abweichungen des wahren, aber unbekannten, Erwartungswertparameters μ vom Nullhypothesenparameter μ_0 ansteigt. Dies ist natürlich der Tatsache geschuldet ist, dass die Testentscheidung auf dem Betrag der Teststatistik beruht. Schließlich ist die genaue Form und Lage der Testgütefunktion von der Wahl des kritischen Werts k abhängig. Wird dieser größer gewählt, ist also ein größerer absoluter Wert der Teststatistik für dafür notwendig, dass der Test den Wert 1 annimmt, so ist die Wahrscheinlichkeit dafür, bei ansonsten konstanten Parametern, kleiner als bei kleineren Werten des kritischen Werts.

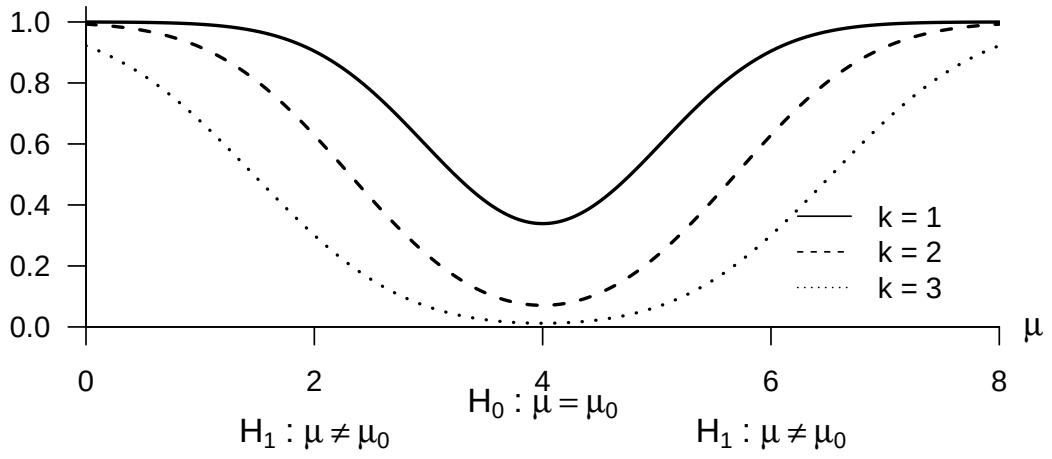


Abbildung 33.3. Testgütefunktion des zweiseitigen Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese für $\sigma^2 = 9, \mu_0 = 4, n = 12$ und $k = 1, 2, 3$.

Testumfangkontrolle

Die Werte der Testgütefunktion bei $\mu = \mu_0$ in Abbildung 33.3 geben einen visuellen Eindruck davon, wie der kritische Wert den Testumfang kontrolliert. Die exakte Bestimmung des kritischen Werts bei einem gewünschten Testumfang ist Inhalt folgenden Theorems.

Theorem 33.3 (Testumfangkontrolle für den zweiseitigen Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese)**.** *ϕ sei der zweiseitige Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese. Dann ist ϕ ein Level-α_0-Test mit Testumfang α_0, wenn der kritische Wert definiert ist durch*

$$k_{\alpha_0} := \Psi^{-1}\left(1 - \frac{\alpha_0}{2}; n - 1\right), \tag{33.49}$$

wobei $\Psi^{-1}(\cdot; n-1)$ die inverse KVF der t-Verteilung mit Freiheitsgradparameter $n-1$ bezeichnet.

∘

Beweis. Damit der betrachtete Test ein Level-α_0-Test ist, muss bekanntlich $q_\phi(\mu) \leq \alpha_0$ für alle $\mu \in \{\mu_0\}$, also hier $q_\phi(\mu_0) \leq \alpha_0$, gelten. Weiterhin ist der Testumfang des betrachteten Tests durch $\alpha = \max_{\mu \in \{\mu_0\}} q_\phi(\mu)$, also hier durch $\alpha = q_\phi(\mu_0)$ gegeben. Wir müssen also zeigen, dass die Wahl von k_{α_0} garantiert, dass ϕ ein Level-α_0-Test mit Testumfang α_0 ist. Dazu merken wir zunächst an, dass für $\mu = \mu_0$ gilt, dass

$$\begin{aligned} q_\phi(\mu_0) &= 1 - \Psi(k; d_{\mu_0}, n-1) + \Psi(-k; d_{\mu_0}, n-1) \\ &= 1 - \Psi(k; 0, n-1) + \Psi(-k; 0, n-1) \\ &= 1 - \Psi(k; n-1) + \Psi(-k; n-1), \end{aligned} \tag{33.50}$$

wobei $\Psi(\cdot; d, n-1)$ und $\Psi(\cdot; n-1)$ die KVF der nichtzentralen t-Verteilung mit Nichtzentralitätsparameter d und Freiheitsgradparameter $n-1$ sowie der t-Verteilung mit Freiheitsgradparameter $n-1$, respektive, bezeichnen. Sei nun also $k := k_{\alpha_0}$. Dann gilt

$$\begin{aligned} q_\phi(\mu_0) &= 1 - \Psi(k_{\alpha_0}; n-1) + \Psi(-k_{\alpha_0}; n-1) \\ &= 1 - \Psi(k_{\alpha_0}; n-1) + (1 - \Psi(k_{\alpha_0}; n-1) \\ &= 2(1 - \Psi(k_{\alpha_0}; n-1)) \\ &= 2\left(1 - \Psi\left(\Psi^{-1}\left(1 - \frac{\alpha_0}{2}, n-1\right), n-1\right)\right) \\ &= 2\left(1 - 1 + \frac{\alpha_0}{2}\right) \\ &= \alpha_0, \end{aligned} \tag{33.51}$$

wobei die zweite Gleichung mit der Symmetrie der t-Verteilung folgt. Es folgt also direkt, dass bei der Wahl von $k = k_{\alpha_0}$, $q_\phi(\mu_0) \leq \alpha_0$ ist und der betrachtete Test somit ein Level-α_0-Test ist. Weiterhin folgt direkt, dass der Testumfang des betrachteten Tests bei der Wahl von $k = k_{\alpha_0}$ gleich α_0 ist. □

Man beachte, dass nach Theorem 33.3 der hier betrachtete Test insbesondere exakt ist, der Testumfang also mit dem Signifikanzlevel identisch ist. In Abbildung 33.4 visualisieren wir die Wahl des kritischen Werts k_{α_0} in einem zweiseitigen Einstichproben-T-Test-Szenario mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese für $\alpha_0 := 0.05$ und $n = 12$.

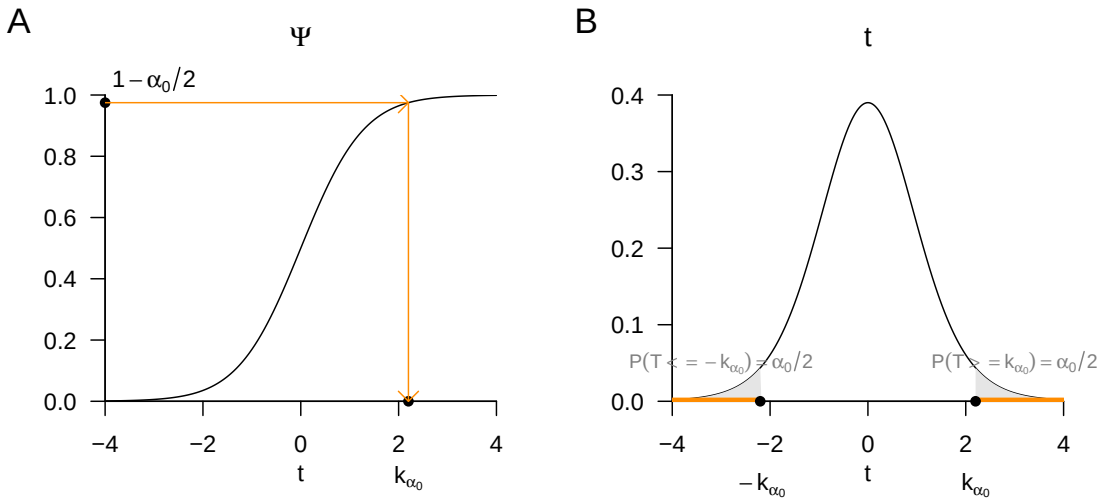


Abbildung 33.4. Bestimmung des kritischen Werts k_{α_0} für den zweiseitigen Einstichproben-T-Tests mit einfacher Nullhypothese für $n = 12$ und $\alpha_0 := 0.05$ zu Kontrolle des Testumfangs (A) Für ein gewähltes α_0 ist der kritische Wert des betrachteten Tests nach Theorem 33.3 durch den Wert der inversen KVF der t-Verteilung mit Freiheitsgradparameter $n-1$ an der Stelle $1 - \frac{\alpha_0}{2}$ gegeben. Die Abbildung zeigt die Bestimmung dieses Werts zu $k_{0.05} = 2.2$ anhand der KVF der t-Verteilung mit Freiheitsgradparameter $n-1$. (B) Die Abbildung zeigt den aus der Wahl von k_{α_0} resultierenden Ablehnungsbereich des betrachteten Tests als grau hinterlegte Flächen unter der WDF der t-Verteilung mit Freiheitsgradparameter $n-1$. Die symmetrische Verteilung der Teilmengen des Ablehnungsbereichs in den Ausläufern der WDF ergibt sich dabei aus der Definition des Tests als Funktion des Betrages der Einstichproben-T-Test-Statistik, also insbesondere des zweiseitigen Charakters des hier betrachteten Tests.

Folgender **R** Code demonstriert die Bestimmung des kritischen Werts des zweiseitigen Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese mithilfe der inversen KVF der t-Verteilung, die in **R** als die Funktion `qt()` implementiert ist. Darüber hinaus simuliert der Code 10^6 Stichprobenrealisationen für

das hier betrachtete Testszenario bei Zutreffen der Nullhypothese und wertet den betrachteten Test aus. Es zeigt sich, dass die geschätzte Wahrscheinlichkeit dafür, dass der Test bei Zutreffen der Nullhypothese den Wert 1 annimmt, mit dem gewünschten Wert von $\alpha_0 = 0.05$ sehr gut übereinstimmt.

```
# Modellparameter
n          = 12                                    # Anzahl der Datenpunkte
mu         = 0                                     # wahrer, aber unbekannter, Erwartungswertparameter
sigsqr     = 2                                     # wahrer, aber unbekannter, Varianzparameter

# Testparameter
mu_0       = 0                                     # Nullhypothesenparameter, hier \mu = \mu_0
alpha_0    = 0.05                                  # Signifikanzlevel
k_alpha_0 = qt(1-alpha_0/2,n-1)                    # Kritischer Wert

# Simulation der Testumfangkontrolle
set.seed(1)                                        # Random number generator seed
nsim       = 1e6                                   # Anzahl Simulationen
phi        = rep(NaN,nsim)                         # Testentscheidungsarray
for(j in 1:nsim){                                  # Simulationsiterationen
    y      = rnorm(n, mu, sqrt(sigsqr))                    # y_i \sim N(\mu,\Sigma), i = 1,...,n
    y_bar  = mean(y)                               # Stichprobenmittel
    s      = sd(y)                                 # Stichprobenstandardabweichung
    Tee    = sqrt(n)*((y_bar - mu_0)/s)            # Einstichproben-T-Test-Statistik
    if(abs(Tee) > k_alpha_0){                      # Test 1_{\vert t \vert >= k_alpha_0}
        phi[j] = 1                                 # Ablehnen der Nullhypothese
    } else {
        phi[j] = 0                                 # Nichtablehnen der Nullhypothese
    }
}
```

```
Kritischer Wert              = 2.2
Gesch<U+00E4>tzter Testumfang alpha = 0.05
```

p-Wert

Der mit einem vorliegenden Wert der Teststatistik des zweiseitigen Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese assoziierte p-Wert ergibt sich aus folgendem Theorem wie folgt.

Theorem 33.4 (p-Wert des zweiseitigen Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese)**.** *Gegeben sei der zweiseitige Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese und t sei ein Wert der Einstichproben-T-Test-Statistik. Dann gilt*

$$p\text{-}Wert = 2(1 - \Psi(|t|; n-1)), \tag{33.52}$$

wobei $\Psi(\cdot; n-1)$ die KVF der t-Verteilung mit Freiheitsgradparameter $n-1$ bezeichnet.

∘

Beweis. Nach Definition 33.12 ist der p-Wert das kleinste Signifikanzlevel α_0, bei dem für den betrachteten Test die Nullhypothese basierend auf dem Wert von t abgelehnt wird. Im vorliegenden Fall wird die Nullhypothese für jedes α_0 mit

$$|t| \geq \Psi^{-1}\left(1 - \frac{\alpha_0}{2}; n-1\right) \tag{33.53}$$

abgelehnt, vgl. Theorem 33.3. Für diese α_0 gilt, dass

$$\alpha_0 \geq 2(1 - \Psi(|t|; n-1)), \tag{33.54}$$

denn

$$
\begin{aligned}
|t| &\geq \Psi^{-1}\left(1-\frac{\alpha_0}{2}; n-1\right) \\
\Leftrightarrow \Psi(|t|; n-1) &\geq \Psi\left(\Psi^{-1}\left(1-\frac{\alpha_0}{2}; n-1\right); n-1\right) \\
\Leftrightarrow \Psi(|t|; n-1) &\geq 1-\frac{\alpha_0}{2} \\
\Leftrightarrow \mathbb{P}(T \leq |t|) &\geq 1-\frac{\alpha_0}{2} \\
\Leftrightarrow \frac{\alpha_0}{2} &\geq 1-\mathbb{P}(T \leq |t|) \\
\Leftrightarrow \alpha_0 &\geq 2(1-\Psi(|t|; n-1)).
\end{aligned}
\tag{33.55}
$$

Das kleinste $\alpha_0 \in [0, 1]$ mit

$$\alpha_0 \geq 2\mathbb{P}(T \geq |t|) \tag{33.56}$$

ist dann entsprechend

$$\alpha_0 = 2(1-\Psi(|t|; n-1)). \tag{33.57}$$

□

In Abbildung 33.5 visualisieren wir die Bestimmung von p-Werten für $t = 2.26$ und für $t = 3.81$, welche sich zu $\text{p} = 0.045$ und $\text{p} = 0.003$, respektive, ergeben. Man beachte, dass zum Beispiel der p-Wert zu $t = -2.26$ auch $\text{p} = 0.045$ beträgt.

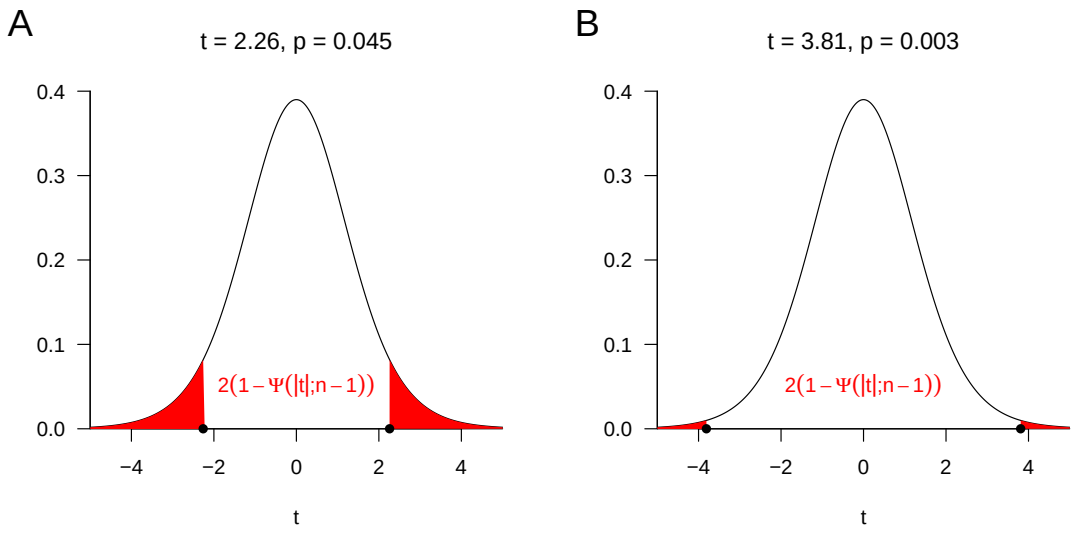


Abbildung 33.5. p-Werte für zwei mögliche Werte der Einstichproben-T-Test-Statistik bei $n = 12$. Die Bereiche im Ergebnisraum der Einstichproben-T-Test-Statistik, über denen die roten Flächen eingezeichnet sind, markieren die Bereiche, in denen $|T| \geq |t|$ gilt. Die summierten ihnen zugeordneten Wahrscheinlichkeiten, also die entsprechenden roten Flächen unter der WDF der t-Verteilungen entsprechen dem p-Wert

Powerfunktion

Die Powerfunktion eines Tests ist die Testgütefunktion eines Tests für den Bereich des Parameterraums, der der Alternativhypothese entspricht. Änderungen im Wert der Powerfunktion eines Tests, oft einfach als *Power des Tests* bezeichnet, ergeben sich also zunächst einmal durch Änderungen des Wertes des wahren, aber unbekannten, Parameters im Bereich der Alternativhypothese. Allerdings hat es sich eingebürgert, die Wahrscheinlichkeit dafür, dass ein Test den Wert 1 annimmt, also die Nullhypothese abgelehnt wird,

nicht ausschließlich als Funktion des wahren, aber unbekannten, Parameters, sondern auch weiterer und in der praktischen Anwendung relevanter, Parameter eines Testszenarios zu betrachten. An erster Stelle ist hier der Stichprobenumfangs n von Interesse. Im Kontext der praktischen Durchführung von *Poweranalysen* fragt man dann meist danach, welcher Stichprobenumfang bei Annahme eines Wertes für den wahren, aber unbekannten, Parameter im Bereich der Alternativhypothese mit einer bestimmten Wahrscheinlichkeit dafür, die Nullhypothese abzulehnen, assoziiert ist. Basierend auf der asymmetrischen Behandlung von Typ I und Typ II Fehlerwahrscheinlichkeiten (vgl. Kapitel 33.2) setzt man dahingehend zunächst ein Signifikanzlevel α_0 zur Kontrolle des Testumfangs fest. Für den hier diskutierten zweiseitigen Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese betrachten wir also die Testgütefunktion

$$q_\phi : \mathbb{R} \to [0,1], \mu \mapsto q_\phi(\mu) := 1 - \Psi(k_{\alpha_0}; d_\mu, n-1) + \Psi(-k_{\alpha_0}; d_\mu, n-1) \tag{33.58}$$

bei kontrolliertem Testumfang, also für

$$k_{\alpha_0} := \Psi^{-1}\left(1 - \frac{\alpha_0}{2}; n-1\right) \tag{33.59}$$

mit festem α_0 als Funktion des Nichtzentralitätsparameters d und des Stichprobenumfangs n. Insbesondere hängt dabei der Nichtzentralitätsparameter d vom Verhältnis der wahren, aber unbekannten, Parameter μ und σ^2, also dem wahren, aber unbekannten, Signal-zu-Rauschen-Verhältnis des Testszenarios und k_{α_0} von n ab. Diese Überlegungen führen auf folgende Definition.

Definition 33.17 (Powerfunktion des zweiseitigen Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese)**.** Gegeben sei der zweiseitige Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese. Dann ist die *Powerfunktion* des Tests gegeben durch

$$\pi : \mathbb{R} \times \mathbb{N} \to [0,1], (d,n) \mapsto \pi(d,n) := 1 - \Psi(k_{\alpha_0}; d, n-1) + \Psi(-k_{\alpha_0}; d, n-1). \tag{33.60}$$

•

Folgender **R** Code demonstriert die Auswertung der Powerfunktion des zweiseitigen Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese in einem Szenario mit $\alpha_0 := 0.05$ mithilfe der **R** Implementationen der KVF und der inversen KVF der nichtzentralen t-Verteilung, `pt()` bzw. `qt()`.

```
alpha_0     = 0.05                                                  # Signifikanzlevel
d_min       = -5                                                    # minimaler Nichtzentralitätsparameter
d_max       =  5                                                    # maximaler Nichtzentralitätsparameter
d_res       = 50                                                    # Auflösung Nichtzentralitätsparameter
d           = seq(d_min, d_max, len = d_res)                        # Nichtzentralitätsparameterraum
n_min       = 1                                                     # minimaler Stichprobenumfang
n_max       = 30                                                    # maximaler Stichprobenumfang
n_res       = 50                                                    # Auflösung Stichprobenumfang
n           = seq(n_min,n_max, len = n_res)                         # maximaler Stichprobenumfang
pi          = matrix(rep(NaN, d_res*n_res), nrow = d_res)           # Powerfunktionsarray
for(i in 1:d_res){                                                  # Nichtzentralitätsparameteriterationen
  for(j in 1:n_res){                                                # Stichprobenumfangiterationen
    k_alpha_0 = qt(1 - alpha_0/2, n[j]-1)                           # kritischer Wert
    pi[i,j]   = 1-pt(k_alpha_0, n[j]-1, d[i])+pt(-k_alpha_0, n[j]-1, d[i])  # Auswertung der Powerfunktion
  }
}
```

Wir visualisieren die Abhängigkeit der Powerfunktion des zweiseitigen Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese vom Nichtzentralitätsparameter und Stichprobenumfang in Abbildung 33.6 und Abbildung 33.7. Generell steigt die Powerfunktion des betrachteten Tests mit positiver oder negativer Abweichung des Nichtzentralitätsparameters vom Nullhypothesenszenario $d = 0$ und steigendem

Stichprobenumfang n monoton. Je nach Wahl des Signifikanzlevel erfolgt dieser Anstieg steiler bzw. weniger steil.

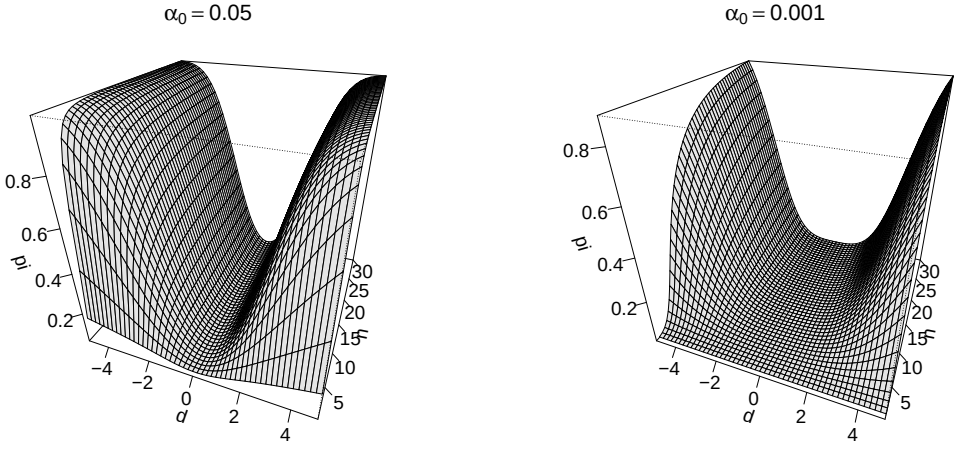


Abbildung 33.6. Powerfunktionen des zweiseitigen Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese. (A) Abhängigkeit der Powerfunktion π vom Nichtzentralitätsparameter d und Stichprobenumfang n bei Wahl von $\alpha_0 := 0.05$. (B) Abhängigkeit der Powerfunktion π vom Nichtzentralitätsparameter d und Stichprobenumfang n bei Wahl von $\alpha_0 := 0.001$

Praktische Durchführung

Vor dem Hintergrund der in den bisherigen Abschnitten diskutierten Theorie des zweiseitigen Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese ergibt folgendes routiniertes Durchführen des Tests: Man nimmt an, dass ein vorliegender univariater Datensatz eine Realisierung des Frequentistischen Inferenzmodells $y_1, ..., y_n \sim N(\mu, \sigma^2)$ des Einstichproben-T-Tests mit wahren, aber unbekannten, Parametern μ und $\sigma^2 > 0$ ist. Man nimmt ferner an, dass man entscheiden muss, ob für einen gewählten Nullhypothesenparameter μ_0 eher die Nullhypothese $H_0 : \mu = \mu_0$ oder die Alternativhypothese $H_1 : \mu \neq \mu_0$ zutrifft. Um den Testumfang über viele Wiederholungen dieser Testprozedur zu kontrollieren, wählt ein Signifikanzlevel α_0 und bestimmt den zugehörigen kritischen Wert k_{α_0}, sodass zum Beispiel bei einem Stichprobenumfang von $n = 12$ und der Wahl von $\alpha_0 := 0.05$ ein kritischer Wert von $k_{0.05} = 2.20$ gewählt wird. Anhand des Stichprobenumfangs n, des Nullhypothesenparameters μ_0, des Stichprobenmittels $\bar{y}$ und der Stichprobenstandardabweichung s berechnet man sodann den Wert der Einstichproben-T-Test-Statistik

$$t := \sqrt{n} \left(\frac{\bar{y} - \mu_0}{s} \right). \tag{33.61}$$

Wenn dieses für den vorliegenden Datensatz so bestimmte t größer als k_{α_0} ist oder wenn t kleiner als $-k_{\alpha_0}$ ist, lehnt man die Nullhypothese ab. Andernfalls lehnt man die Nullhypothese nicht ab. Die hier entwickelte Theorie garantiert dann, dass man im langfristigen Mittel in höchstens $\alpha_0 \cdot 100$ von 100 Fällen die Nullhypothese fälschlicherweise ablehnt. Weiterhin bestimmt man basierend auf dem vorliegenden Wert der Einstichproben-T-Test-

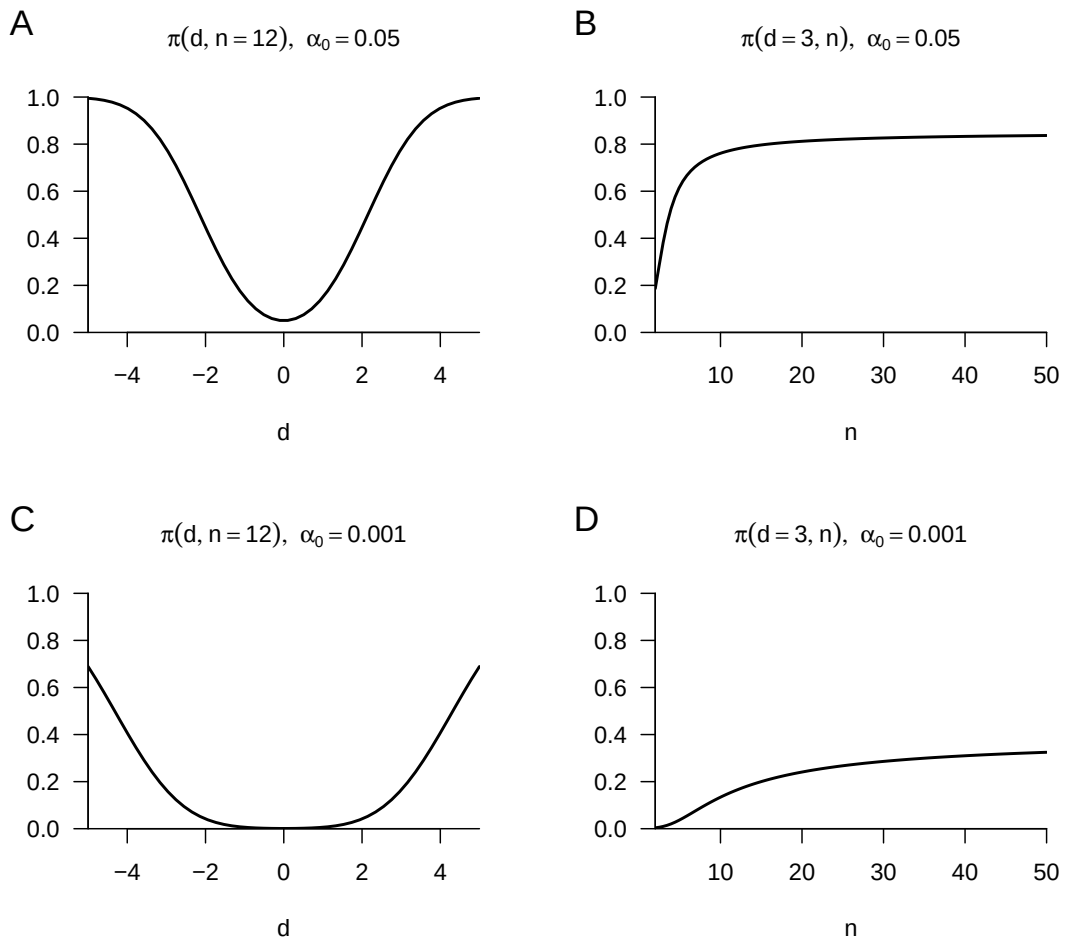


Abbildung 33.7. Schnitte der Powerfunktionen des zweiseitigen Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese. (A) Abhängigkeit der Powerfunktion π vom Nichtzentralitätsparameter d bei konstantem Stichprobenumfang $n = 12$ und Wahl von $\alpha_0 := 0.05$. (B) Abhängigkeit der Powerfunktion vom Stichprobenumfang n π bei Nichtzentralitätsparameter $d = 3$ und Wahl von $\alpha_0 := 0.05$. (C) Abhängigkeit der Powerfunktion π vom Nichtzentralitätsparameter d bei konstantem Stichprobenumfang $n = 12$ und Wahl von $\alpha_0 := 0.001$. (D) Abhängigkeit der Powerfunktion vom Stichprobenumfang n π bei Nichtzentralitätsparameter $d = 3$ und Wahl von $\alpha_0 := 0.001$.

Statistik den zugehörigen p-Wert durch

$$\text{p-Wert} = 2(1 - \Psi(|t|; n-1)) \tag{33.62}$$

Folgender **R** Code demonstriert dieses Vorgehen bei Annahme eines vorliegenden Datenvektors `y` der Länge `n`.

```
n           = length(y)                                 # Stichprobenumfang
mu_0        = 0                                         # Nullhypothesenparameter
alpha_0     = 0.05                                      # Signifikanzlevel
k_alpha_0   = qt(1-alpha_0/2,n-1)                       # kritischer Wert
Tee         = sqrt(n)*((mean(y) - mu_0)/sd(y))          # Einstichproben-T-Test-Statistik
if(abs(Tee) > k_alpha_0){phi = 1} else {phi = 0}        # Testauswertung
p           = 2*(1 - pt(abs(Tee),n-1))                      # p-Wert Evaluation
```

Will man eine Poweranalyse zur Optimierung des Stichprobenumfangs durchführen, so gilt natürlich zunächst grundsätzlich, dass mit steigendem Stichprobenumfang die Powerfunktion des Tests ansteigt. Vor dem Gesichtspunkt der Power des Tests ist ein größerer Stichprobenumfang also immer besser als ein kleinerer Stichprobenumfang. Allerdings bleiben dabei mögliche Kosten für die Erhöhung des Stichprobenumfangs, wie zum Beispiel mögliche Risiken für die Studienteilnehmer:innen, unberücksichtigt. Weiterhin ist der Wert, den die Powerfunktion bei einem gewählten Stichprobenumfang annimmt, immer von den wahren, aber unbekannten, Parameterwerten μ und σ, die in den Wert des Nichtzentralitätsparameters d einfließen, abhängig. Würde man diese Werte in einem gegebenen Anwendungskontext schon sehr genau kennen, so würde man vermutlich keine Studie durchführen. Generell wird im Rahmen der Studienplanung deshalb folgendes Vorgehen favorisiert. Zunächst entscheidet man sich für ein Signifikanzlevel α_0 zur Kontrolle des Testumfangs und evaluiert die Powerfunktion. Man überlegt sich dann einen Nichtzentralitätswert d^*, den man mit einer Power von mindestens β detektieren möchte, wobei ein konventioneller Wert $\beta = 0.8$ ist. Man wertet dann die für einen Powerfunktionswert

$$\pi(d = d^*, n) = \beta \tag{33.63}$$

nötige Stichprobengröße aus. Aufgrund der Monotonie der Powerfunktion des zweiseitigen Einstichproben-T-Tests mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese im Bereich nicht-negativer Nichtzentralitätsparameter ist dann gewährleistet, dass die Power des Tests für Nichtzentralitätsparameter, die größer als d^* sind, größer oder gleich β sind. Folgender **R** Code implementiert dieses Vorgehen zur Optimierung des Stichprobenumfangs und Abbildung 33.8 visualisiert es.

```
# Powerfunktionsbasierte Stichprobenumfangsoptimierung
alpha_0   = 0.05                                                    # Signifikanzlevel
beta      = 0.8                                                     # gewünschter Powerfunktionswert
d_stern   = 3                                                       # fester Nichtzentralitätsparameter
n_min     = 2                                                       # minimal betrachteter Stichprobenumfang
n_max     = 20                                                      # maximal betrachteter Stichprobenumfang
n_res     = 1e2                                                     # Auflösung des Stichprobenumfangraums
n         = seq(n_min,n_max, len = n_res)                           # Stichprobenumfangraum
k_alpha_0 = qt(1-alpha_0/2, n-1)                                    # kritische Werte in Abhängigkeit vom Stichprobenumfang
pi_n      = 1-pt(k_alpha_0, n-1, d_stern)+pt(-k_alpha_0, n-1, d_stern)  # Powerfunktion bei festem Nichtzentralitätsparameter
i         = 1                                                       # Indexinitialisierung
n_min     = NaN                                                     # minimales n Initialisierung
while(pi_n[i] < beta){                                              # Solange \pi(d*,n) < \beta
    n_min = n[i]                                                    # Aufnahme des minimal nötigen ns
    i     = i + 1}                                                  # und Erhöhung des Indexes
cat("Minimal nötiges n =", ceiling(n_min))                          # Ausgabe
```

```
Minimal n<U+00F6>tiges n = 16
```

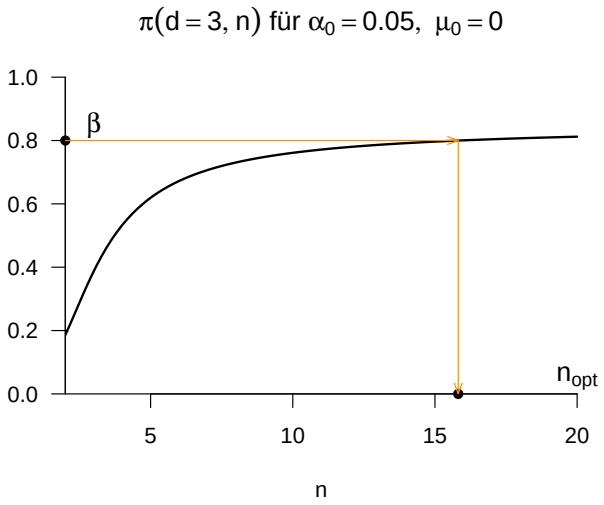


Abbildung 33.8. Praktische Durchführung einer powerfunktionsbasierten Stichprobenumfangoptimierung. Bei gewähltem Signifikanzlevel α_0 und fest angenommenen Nichtzentralitätsparameter d^* evaluiert man den Stichprobenumfang für den die Testpowerfunktion einen Wert von β oder größer hat.

Anwendungsbeispiel

Abschließend wollen wir oben skizziertes Vorgehen noch an Beispiel 30.5 demonstrieren. Inhaltlich entspricht in diesem Fall die einfache Nullhypothese $H_0 : \mu = 0$ der Hypothese, dass die Therapie keinen Effekt auf BDI-II Reduktionsscores hat. Die zusammengesetzte Alternativhypothese $H_1 : \mu \neq 0$ entspricht der Hypothese, dass die Therapie einen systematischen von null verschiedenen Effekt auf BDI-II Reduktionsscores hat. Untenstehender **R** Code wendet das oben demonstrierte Verfahren zur Evaluation der Hypothesen auf den Prä-Post-Therapie BDI-II Reduktionsscore Datensatz von $n = 12$ Patient:innen an und evaluiert darüber hinaus zusätzlich das 95%-Konfidenzintervall für den Erwartungswertparameter.

```
D         = read.csv("./_data/bdi-ii-datensatz.csv")      # Datensatzeinlesen
y         = D$dBDI                                       # Datenauswahl
n         = length(y)                                    # Stichprobenumfang
mu_hat    = mean(y)                                      # Erwartungswertparameterschätzer
delta     = 0.95                                         # Konfidenzlevel
t_delta   = qt((1+delta)/2,n-1)                          # \Psi^-1((\delta + 1)/2, n-1)
G_u       = mean(y) - (sd(y)/sqrt(n))*t_delta            # untere Konfidenzintervallgrenze
G_o       = mean(y) + (sd(y)/sqrt(n))*t_delta            # obere  Konfidenzintervallgrenze
mu_0      = 0                                            # Nullhypothesenparameter, hier \mu = \mu_0
alpha_0   = 0.05                                         # Signifikanzlevel
k_alpha_0 = qt(1-alpha_0/2,n-1)                          # kritischer Wert
Tee       = sqrt(n)*((mean(y) - mu_0)/sd(y))             # T-Teststatistik
if(abs(Tee) > k_alpha_0){phi = 1} else {phi = 0}         # Test 1_{\vert t \vert >= k_alpha_0}
p         = 2*(1 - pt(abs(Tee),n-1))                         # p-Wert
```

```
Parametersch<U+00E4>tzwert    = 3.17
95%-Konfidenzintervall = 0.81 5.53
Signifikanzlevel       = 0.05
Kritischer Wert        = 2.2
Teststatistik          = 2.95
Testwert               = 1
p-Wert                 = 0.01
```

Die gleiche Analyse kann auch mit der in **R** implementierten Funktion `t.test()` durch-

geführt werden, die Syntax zu ihrer Benutzung und die Formatierung der durch sie bestimmten Ergebnisse finden sich untensstehend.

```
t.test(y)
```

```
    One Sample t-test

data:  y
t = 2.9542, df = 11, p-value = 0.01311
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 0.8074098 5.5259235
sample estimates:
mean of x
 3.166667
```

Im vorliegenden Fall würde man die Nullhypothese also bei einem Signifikanzlevel von $\alpha_0 = 0.05$ ablehnen. Ob die Nullhypothese allerdings im vorliegenden Fall zutrifft oder nicht bleibt, wie der wahre, aber unbekannte, Erwartungswertparameter unbekannt. Im langfristigen Mittel jedoch lehnt man basierend auf den oben beschriebenen Annahmen die Nullhypothese in nur 5 von 100 Fällen fälschlicherweise ab.

33.4. Konfidenzintervalle und Hypothesentests

In diesem Abschnitt untersuchen wir, inwieweit Konfidenzintervalle und Hypothesentests als äquivalent angesehen werden können. Wir wollen dabei von dem Szenario eines Konfidenzintervalls ausgehen.

Theorem 33.5 (Dualität von Konfidenzintervallen und Hypothesentests)**.** *Es sei y die Stichprobe eines Frequentistischen Inferenzmodells mit Ergebnisraum $\mathcal{Y}$ und Parameterraum Θ. Weiterhin sei für ein $\delta \in]0,1[$ mit $[G_u(y), G_o(y)]$ ein δ-Konfidenzintervall für den wahren, aber unbekannten, Parameter $\theta \in \Theta$ definiert. Dann gilt, dass der Hypothesentest definiert durch*

$$\phi_\theta : \mathcal{Y} \to \{0,1\}, y \mapsto \phi(y) := \begin{cases} 0, & [G_u(y), G_o(y)] \ni \theta_0 \\ 1, & [G_u(y), G_o(y)] \not\ni \theta_0 \end{cases} \tag{33.64}$$

ein Hypothesentest vom Signifikanzlevel $\alpha_0 = 1 - \delta$ für die Hypothesen

$$\Theta_0 := \{\theta_0\} \text{ und } \Theta_1 := \Theta \setminus \{\theta_0\}. \tag{33.65}$$

∘

Beweis. Aufgrund der einfachen Nullhypothese und somit $\alpha_0 = \alpha$ folgt

$$\alpha_0 = \alpha = \mathbb{P}_{\theta_0}(\phi(y) = 1) = \mathbb{P}_{\theta_0}([G_u(y), G_o(y)] \not\ni \theta_0) = 1 - \mathbb{P}_{\theta_0}([G_u(y), G_o(y)] \ni \theta_0) = 1 - \delta. \tag{33.66}$$

□

Theorem 33.5 besagt also, dass man mithilfe eines δ-Konfidenzintervalls einen Hypothesentest mit Signifikanzlevel $\alpha_0 = 1 - \delta$ mit einfacher Nullhypothese und zusammengesetzter Alternativhypothese konstruieren kann. Dazu ist bei diesem Test die Nullhypothese $\theta = \theta_0$ jeweils abzulehnen, wenn das Konfidenzintervall den Nullhypothesenparameter θ_0 nicht überdeckt. Anhand folgenden Theorems wollen wir Theorem 33.5 für das in Kapitel 32.2 betrachtete Konfidenzintervall für den Erwartungswertparameter des Normalverteilungsmodells und den in Kapitel 33.3.1 betrachteten Einstichproben-T-Test konkretisieren.

Theorem 33.6 (Dualität von Erwartungswertkonfidenzintervall und Einstichproben-T--Test)**.** *Gegeben sei das Normalverteilungsmodell und es sei*

$$\kappa := \left[\bar{y} - \frac{S}{\sqrt{n}} t_\delta, \bar{y} + \frac{S}{\sqrt{n}} t_\delta\right]. \tag{33.67}$$

das mithilfe von

$$t_\delta := \Psi^{-1}\left(\frac{1+\delta}{2}; n-1\right) \tag{33.68}$$

in Theorem 32.2 definierte δ-Konfidenzintervall für den Erwartungswertparameter. Dann ist mit Theorem 33.5 der Test

$$\phi : \mathcal{Y} \to \{0,1\}, y \mapsto \phi(y) := \begin{cases} 0, & \left[\bar{y} - \frac{S}{\sqrt{n}} t_\delta, \bar{y} + \frac{S}{\sqrt{n}} t_\delta\right] \ni \mu_0 \\ 1, & \left[\bar{y} - \frac{S}{\sqrt{n}} t_\delta, \bar{y} + \frac{S}{\sqrt{n}} t_\delta\right] \not\ni \mu_0 \end{cases} \tag{33.69}$$

ein Test der einfachen Nullhypothese $H_0 : \mu = \mu_0$ und der zusammengesetzten Alternativhypothese $H_1 : \mu \neq \mu_0$ mit Signifikanzlevel $\alpha_0 = 1 - \delta$.

∘

Beweis. Es gilt

$$\mathbb{P}_{\mu_0}(\phi(y) = 1) = 1 - \mathbb{P}_{\mu_0}(\phi(y) = 0) = 1 - \mathbb{P}_{\mu_0}\left(\left[\bar{y} - \frac{S}{\sqrt{n}} t_\delta, \bar{y} + \frac{S}{\sqrt{n}} t_\delta\right] \ni \mu_0\right) = 1 - \delta. \tag{33.70}$$

□

Folgender **R** Code simuliert diesen Konfidenzintervall-basierten Hypothesentest bei Zutreffen der Nullhypothese und gibt Schätzungen für das Konfidenzlevel und das Signifikanzlevel über 100 Realisierungen einer Stichproben mit Stichprobenumfang $n = 12$ mit wahren, aber unbekannten, Parametern $\mu = 2$ und $\sigma^2 = 1$ an.

```
n       = 12                                    # Stichprobenumfang
mu      = 2                                     # wahrer, aber unbekannter, Erwartungswertparameter
sigsqr  = 1                                     # wahrer, aber unbekannter, Varianzparameter
delta   = 0.95                                  # Konfidenzlevel
t_delta = qt((1+delta)/2, n-1)                  # \Psi^{-1}((\delta + 1)/2, n-1)
mu_0    = mu                                    # Nullhypothesenparameter bei Zutreffen von H_0
set.seed(1)                                     # random number generator seed
ns      = 1e2                                   # Anzahl Simulationen
y_bar   = rep(NaN,ns)                           # Stichprobenmittelarray
s       = rep(NaN,ns)                           # Stichprobenstandardabweichungarray
kappa   = matrix(rep(NaN,2*ns), ncol = 2)       # Konfidenzintervallarray
kfn     = rep(NaN,ns)                           # Überdeckungsindikatorarray
phi     = rep(NaN,ns)                           # Testarray
for(i in 1:ns){                                 # Simulationsiterationen
  y          = rnorm(n,mu_0,sqrt(sigsqr))       # Stichprobenrealisierung
  y_bar[i]   = mean(y)                          # Stichprobenmittel
  s[i]       = sd(y)                            # Stichprobenstandardabweichung
  kappa[i,1] = y_bar[i] - (s[i]/sqrt(n))*t_delta  # untere Konfidenzintervallgrenze
  kappa[i,2] = y_bar[i] + (s[i]/sqrt(n))*t_delta  # obere Konfidenzintervallgrenze
  if(kappa[i,1] <= mu_0 & mu_0 <= kappa[i,2]){
      kfn[i] = 1} else{kfn[i] = 0}              # Überdeckungsindikatorevaluation
  if(kappa[i,1] <= mu_0 & mu_0 <= kappa[i,2]){
      phi[i] = 0} else{phi[i] = 1}}             # Testevaluation
```

```
cat(   "Geschätztes Konfidenzniveau =", round(mean(kfn),2),    # Ausgabe
     "\nGeschätzter Testumfang      =", round(mean(phi),2))
```

```
Gesch<U+00E4>tztes Konfidenzniveau = 0.96
Gesch<U+00E4>tzter Testumfang      = 0.04
```

Wir visualisieren die Ergebnisse dieser Simulation in Abbildung 33.9.

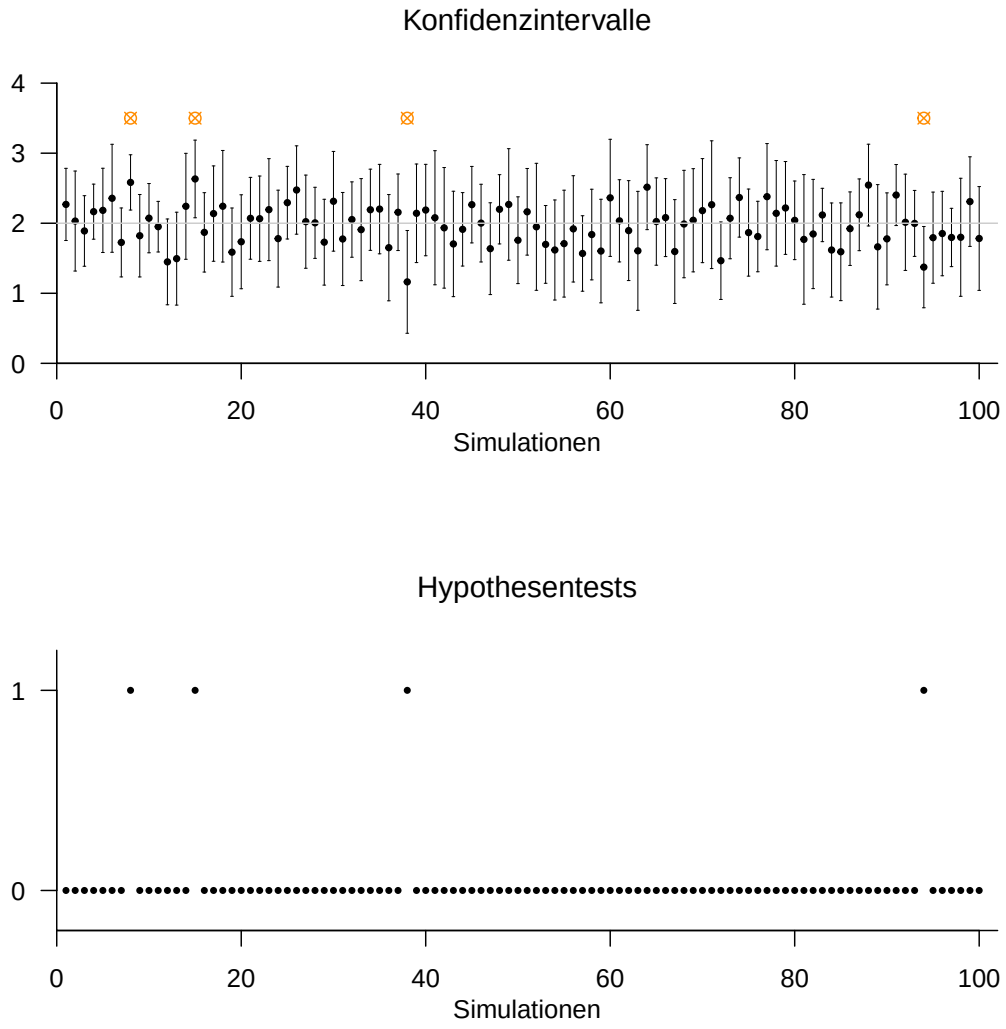


Abbildung 33.9. Dualität von Konfidenzintervall und Hypothesentest am Beispiel des Normalverteilungsmodells. Nutzt man das δ-Konfidenzintervall für den Erwartungswertparameter um bei Nichtüberdeckung des Nullhypothesenparameters die Nullhypothese abzulehnen, so ergibt sich in diesem Fall ein Hypothesentest mit Signifikanzlevel $\alpha_0 = 1 - \delta$.

33.5. Literaturhinweise

Die hier präsentierte Theorie der Hypothesentests geht im Wesentlichen auf Neyman & Pearson (1928) und Neyman & Pearson (1933) zurück. Gigerenzer (2004) und Lehmann

(2011) geben historische Einordnungen der Genese des Hypothesentestbegriffs.

Selbstkontrollfragen

1. Erläutern Sie die grundlegende Logik frequentistischer Hypothesentests.
2. Geben Sie die Definition der Begriffe der Testhypothesen und des Testszenario wieder.
3. Geben Sie die Definition der Begriffe der einfachen und zusammengesetzten Testhypothesen wieder.
4. Geben Sie die Definition der Begriffe einseitigen und zweiseitigen Testhypothesen wieder.
5. Geben Sie die Definition des Begriff des Tests wieder.
6. Geben Sie die Definition des Begriffs des Standardtests wieder.
7. Geben Sie die Definition des Begriffs des kritischen Bereichs wieder.
8. Geben Sie die Definition des Begriffs des Ablehungsbereichs wieder
9. Geben Sie die Definition des Begriffs des kritischen Wert-basierten Tests wieder.
10. Geben Sie die Definition der Begriffe der richtigen Testentscheidungen und der Testfehler wieder.
11. Geben Sie die Definition des Begriffs der Testgütefunktion wieder.
12. Erläutern Sie die Bedeutung der Testgütefunktion für die Konstruktion von Hypothesentests.
13. Geben Sie die Definition des Begriffs des Level-α_0-Tests wieder.
14. Geben Sie die Definition des Begriffs des Signifikanzlevel α_0 wieder
15. Geben Sie die Definition des Begriffs des Testumfangs α wieder.
16. Geben Sie die Definition des Begriffs des p-Werts wieder.

Lösungen

1. Siehe einführende Bemerkungen dieses Kapitels.
2. Siehe Definition 33.1.
3. Siehe Definition 33.2.
4. Siehe Definition 33.3.
5. Siehe Definition 33.4.
6. Siehe Definition 33.5.
7. Siehe Definition 33.6.
8. Siehe Definition 33.7.
9. Siehe Definition 33.8.
10. Siehe Definition 33.9.
11. Siehe Definition 33.10.
12. Siehe Erläuterungen zu Definition 33.10.
13. Siehe Definition 33.11.
14. Siehe Definition 33.11.
15. Siehe Definition 33.11.
16. Siehe Definition 33.12.

Teil V.

Allgemeines Lineares Modell

34. Regression

Fundamentales Ziel von Regressionsanalysen ist es, Beziehungen zwischen unabhängigen und abhängigen Variablen zu modellieren. Ein zentrales Thema dabei ist die Anpassung von Funktionen an beobachtete Datensätze. Mit dem Begriff der Ausgleichsgerade im Rahmen der Methode der kleinsten Quadrate und dem Begriff der einfachen linearen Regression wollen wir uns in diesem Abschnitt diesen zentralen Themen der probabilistischen Datenmodellierung schrittweise nähern. Dabei unterscheiden sich die Konzepte von Ausgleichsgerade und einfacher lineare Regression in einem zentralem Aspekt: bei der Ausgleichsgerade werden unabhängige und abhängige Variable nicht als Zufallsvariablen modelliert, im Rahmen der einfachen linearen Regression nimmt die abhängige Variable dann die Form einer Zufallsvariablen an. Im Kontext der Korrelation schließlich werden sowohl abhängige als auch unabhängige Variable als Zufallsvariablen modelliert.

Um die Konzepte dieses Abschnittes zu verdeutlichen, betrachten wir einen Beispieldatensatz in dem die Anzahl an Psychotherapiestunden als unabhängige Variable x der Symptomreduktion einer Gruppe von $n = 20$ Patient:innen als abhängige Variable y gegenüber gestellt wird (Abbildung 42.3). Die visuelle Inspektion dieses Datensatzes legt nahe, dass ein Mehr an Therapiestunden ein Mehr an Symptomreduktion impliziert. Ziel der Methode der kleinsten Quadrate und der einfachen linearen Regression ist es, diesen intuitiven funktionalen Zusammenhang zwischen unabhängiger und abhängiger Variable auf eine quantitative Basis zu stellen.

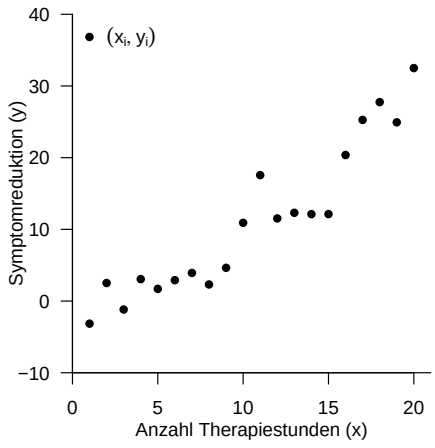


Abbildung 34.1. Beispieldatensatz.

34.1. Methode der kleinsten Quadrate

Wir definieren zunächst den Begriff der *Ausgleichsgerade*.

Definition 34.1 (Ausgleichsgerade)**.** Für $\beta := (\beta_0, \beta_1)^T \in \mathbb{R}^2$ heißt die linear-affine Funktion

$$f_\beta : \mathbb{R} \to \mathbb{R}, x \mapsto f_\beta(x) := \beta_0 + \beta_1 x \tag{34.1}$$

für die für einen Datensatz $\{(x_1, y_1), \dots, (x_n, y_n)\} \subset \mathbb{R}^2$ die Funktion

$$q : \mathbb{R}^2 \to \mathbb{R}_{\geq 0}, \beta \mapsto q(\beta) := \sum_{i=1}^{n} \left(y_i - f_\beta(x_i)\right)^2 = \sum_{i=1}^{n} \left(y_i - (\beta_0 + \beta_1 x_i)\right)^2 \tag{34.2}$$

der quadrierten vertikalen Abweichungen der y_i von den Funktionswerten $f_\beta(x_i)$ ihr Minimum annimmt, Ausgleichsgerade für den Datensatz $\{(x_1, y_1), \dots, (x_n, y_n)\}$.

•

Bei der Ausgleichsgerade handelt es sich also um eine linear-affine Funktion der Form

$$f_\beta : \mathbb{R} \to \mathbb{R}, x \mapsto f_\beta(x) := \beta_0 + \beta_1 x \tag{34.3}$$

Abbildung 34.2 zeigt drei durch jeweils andere Werte von β_0 und β_1 parameterisierte linearaffine Funktionen zusammen mit der Wertemenge des Beispieldatensatzes.

Wie bei allen linear-affinen Funktionen entspricht bei f_β der Wert von β_0 dem Wert, den f_β für $x = 0$ annimmt,

$$f_\beta(0) = \beta_0 + \beta_1 \cdot 0 = \beta_0 \tag{34.4}$$

und damit graphisch dem Schnittpunkt des Funktionsgraphen mit der y-Achse. Da β_0 damit dem Versatz (engl. *offset*) des Funktionsgraphen von $y = 0$ an der Stelle $x = 0$ entspricht, nennt man β_0 auch häufig den *Offsetparameter*. Analog entspricht wie bei allen linear-affinen Funktionen der Wert von β_1 dem Wert der Funktionswertdifferenz pro Argumenteinheitsdifferenz. Beispielsweise gilt etwa für $\beta_0 = 5$ und $\beta_1 = 0.5$, dass

$$\begin{aligned} f_\beta(2) - f_\beta(1) &= (5 + 0.5 \cdot 2) - (5 + 0.5 \cdot 1) = 1 - 0.5 = 0.5 \\ f_\beta(9) - f_\beta(8) &= (5 + 0.5 \cdot 9) - (5 + 0.5 \cdot 8) = 9.5 - 8 = 0.5 \end{aligned} \tag{34.5}$$

Für eine Argumentdifferenz von 1 ergibt sich also eine Funktionswertdifferenz von 0.5. β_1 enkodiert also die Stärke der Änderung der Funktionswerte pro Argumentseinheitsdifferenz und damit die Steigung (engl. slope) des Graphen der linear-affinen Funktion. Entsprechend wird β_1 *Steigungsparameter* oder *Slopeparameter* genannt.

Nach Definition ist die Ausgleichsgerade nun allerdings nicht eine beliebige linearaffine Funktion der Form f_β, sondern eben jene, die für einen gegebenen Datensatze $\{(x_1, y_1), \dots, (x_n, y_n)\}$ die Summe der quadrierten vertikalen Abweichnungen

$$q(\beta) := \sum_{i=1}^{n} \left(y_i - (\beta_0 + \beta_1 x_i)\right)^2 \tag{34.6}$$

minimiert. Für eine fest vorgegebenen Datensatz von (x_i, y_i) Paaren ist der Wert dieser Summe abhängig von den Werten von β_0 und β_1 und kann deshalb durch Wahl geeigneter

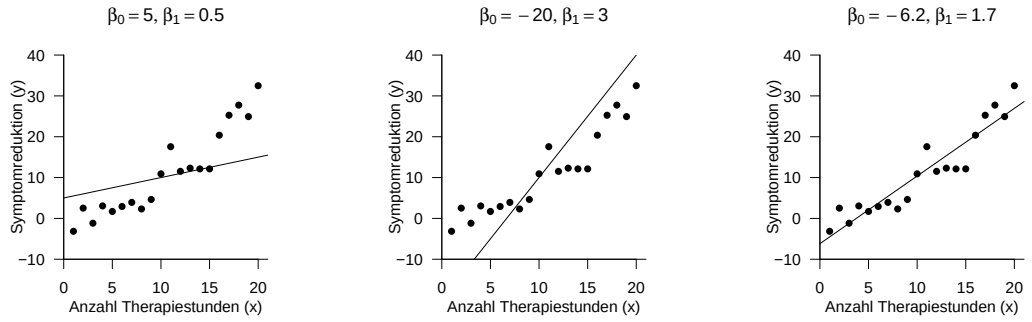


Abbildung 34.2. Linear-affine Funktionen mit unterschiedlichen Parameterwerten vor dem Hintergrund des Beispieldatensatzes.

Werte von β_0 und β_1 minimiert werden. Da hierbei eine Summe von quadrierten Abweichungen zwischen Datenpunkten und Werten der Ausgleichsgerade minimiert wird, spricht man auch oft etwas ungenau von der *Methode der kleinsten Quadrate* (engl. *method of least squares*). Abbildung 1.3 zeigt die vertikalen Abweichungen zwischen y_i und $\beta_0 + \beta_1 x_i$ für $i = 1, \ldots, n$ des Beispieldatensatzes als orange Linien sowie die Summe ihrer Quadrate $q(\beta)$ im Titel. Für die Parameterwerte $\beta_0 = -6.2$ und $\beta_1 = 1.7$ (vgl. Abbildung 34.2) immt diese Summe ihren kleinsten Wert an.

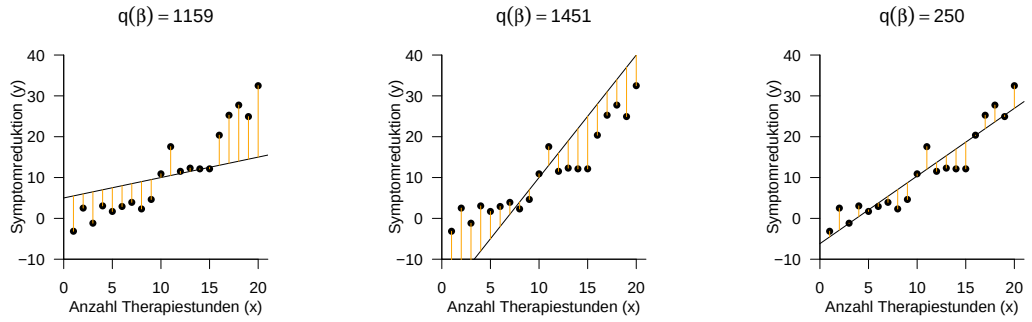


Abbildung 34.3. Vertikale Abweichungen und Quadratsummen bei unterschiedlichen Parameterwerten.

Konkrete Formeln zur Bestimmung der Parameterwerte der Ausgleichsgerade stellt Theorem 34.1 bereit.

Theorem 34.1 (Ausgleichsgerade)**.** *Für einen Datensatz* $\{(x_1, y_1), \ldots, (x_n, y_n)\} \subset \mathbb{R}^2$ *hat die Ausgleichsgerade die Form*

$$f_\beta : \mathbb{R} \to \mathbb{R}, x \mapsto f_\beta(x) := \hat{\beta}_0 + \hat{\beta}_1 x \tag{34.7}$$

wobei mit der Stichprobenkovarianz c_{xy} *der* (x_i, y_i)*-Werte, der Stichprobenvarianz* s_x^2 *der* x_i*-Werte und den Stichprobenmitteln* $\bar{x}$ *und* $\bar{y}$ *der* x_i *- und* y_i*-Werte, respektive, gilt, dass*

$$\hat{\beta}_1 = \frac{c_{xy}}{s_x^2} \text{ und } \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}. \tag{34.8}$$

∘

Beweis. Wir betrachten die Summe der quadrierten vertikalen Abweichungen der y_i von den Funktionswerten $f(x_i)$ als Funktion von β_0 und β_1 und bestimmen Werte $\hat{\beta}_0$ und $\hat{\beta}_1$, für die diese Funktion ihr Minimum annimmt, die Summe der quadrierten vertikalen Abweichungen der y_i von den Funktionswerten $f(x_i)$ also minimal wird. Wir betrachten die Funktion

$$q : \mathbb{R}^2 \to \mathbb{R}, (\beta_0, \beta_1) \mapsto q(\beta_0, \beta_1) := \sum_{i=1}^{n} (y_i - (\beta_0 + \beta_1 x))^2 \tag{34.9}$$

Um das Minimum dieser Funktion zu bestimmen, berechnen wir zunächst die partiellen Ableitungen hinsichtlich β_0 und β_1 und setzen diese gleich 0. Es ergibt sich zunächst

$$\begin{aligned}
\frac{\partial}{\partial \beta_0} q(\beta_0, \beta_1) &= \frac{\partial}{\partial \beta_0} \left(\sum_{i=1}^{n} (y_i - (\beta_0 + \beta_1 x_i))^2 \right) \\
&= \sum_{i=1}^{n} \frac{\partial}{\partial \beta_0} (y_i - (\beta_0 + \beta_1 x_i))^2 \\
&= \sum_{i=1}^{n} 2 (y_i - (\beta_0 + \beta_1 x_i)) \frac{\partial}{\partial \beta_0} (y_i - \beta_0 - \beta_1 x_i) \\
&= -2 \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i) .
\end{aligned} \tag{34.10}$$

Weiterhin ergibt sich

$$\begin{aligned}
\frac{\partial}{\partial \beta_1} q(\beta_0, \beta_1) &= \frac{\partial}{\partial \beta_1} \left(\sum_{i=1}^{n} (y_i - (\beta_0 + \beta_1 x_i))^2 \right) \\
&= \sum_{i=1}^{n} \frac{\partial}{\partial \beta_1} (y_i - (\beta_0 + \beta_1 x_i))^2 \\
&= \sum_{i=1}^{n} 2 (y_i - (\beta_0 + \beta_1 x_i)) \frac{\partial}{\partial \beta_1} (y_i - \beta_0 - \beta_1 x_i) \\
&= -2 \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i) x_i .
\end{aligned} \tag{34.11}$$

Nullsetzen beider partieller Ableitungen ergibt dann

$$\begin{aligned}
&\frac{\partial}{\partial \beta_0} q(\beta_0, \beta_1) = 0 \text{ und } \frac{\partial}{\partial \beta_1} q(\beta_0, \beta_1) = 0 \\
\Leftrightarrow\ & -2 \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i) = 0 \text{ und } -2 \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i) x_i = 0 \\
\Leftrightarrow\ & \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i) = 0 \text{ und } \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i) x_i = 0
\end{aligned} \tag{34.12}$$

und weiter

$$\begin{aligned}
&\sum_{i=1}^{n} y_i - \sum_{i=1}^{n} \beta_0 - \beta_1 \sum_{i=1}^{n} x_i = 0 \text{ und } \sum_{i=1}^{n} y_i x_i - \sum_{i=1}^{n} \beta_0 x_i - \beta_1 \sum_{i=1}^{n} x_i^2 = 0 \\
\Leftrightarrow\ & \beta_0 n + \beta_1 \sum_{i=1}^{n} x_i = \sum_{i=1}^{n} y_i \text{ und } \beta_0 \sum_{i=1}^{n} x_i + \beta_1 \sum_{i=1}^{n} x_i^2 = \sum_{i=1}^{n} y_i x_i
\end{aligned} \tag{34.13}$$

Das sich hier ergebende Gleichungssystem

$$\begin{aligned}
\beta_0 n + \beta_1 \sum_{i=1}^{n} x_i &= \sum_{i=1}^{n} y_i \\
\beta_0 \sum_{i=1}^{n} x_i + \beta_1 \sum_{i=1}^{n} x_i^2 &= \sum_{i=1}^{n} y_i x_i
\end{aligned} \tag{34.14}$$

wird System der Normalengleichungen genannt und beschreibt die notwendige Bedingung für ein Minimum von q. Aufösen dieses Gleichungssystems nach β_0 und β_1 liefert dann die Werte $\hat{\beta}_0$ und $\hat{\beta}_1$ des Theorems. Um dies zu sehen, halten wir zunächst fest, dass mit der ersten Gleichung des Systems der Normalengleichungen gilt

$$n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^{n} x_i = \sum_{i=1}^{n} y_i \Leftrightarrow \hat{\beta}_0 + \hat{\beta}_1 \bar{x} = \bar{y} \Leftrightarrow \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \tag{34.15}$$

Einsetzen der Form von $\hat{\beta}_0$ in die zweite Gleichung des Systems der Normalengleichungen ergibt dann zunächst

$$\begin{aligned}
\hat{\beta}_0 \sum_{i=1}^{n} x_i + \hat{\beta}_1 \sum_{i=1}^{n} x_i^2 &= \sum_{i=1}^{n} y_i x_i \\
\Leftrightarrow \left(\bar{y} - \hat{\beta}_1 \bar{x}\right) \sum_{i=1}^{n} x_i + \hat{\beta}_1 \sum_{i=1}^{n} x_i^2 &= \sum_{i=1}^{n} y_i x_i \\
\Leftrightarrow \bar{y} \sum_{i=1}^{n} x_i - \hat{\beta}_1 \bar{x} \sum_{i=1}^{n} x_i + \hat{\beta}_1 \sum_{i=1}^{n} x_i^2 &= \sum_{i=1}^{n} y_i x_i \\
\Leftrightarrow -\hat{\beta}_1 \bar{x} \sum_{i=1}^{n} x_i + \hat{\beta}_1 \sum_{i=1}^{n} x_i^2 &= \sum_{i=1}^{n} y_i x_i - \bar{y} \sum_{i=1}^{n} x_i \\
\Leftrightarrow \hat{\beta}_1 \left(\sum_{i=1}^{n} x_i^2 - \bar{x} \sum_{i=1}^{n} x_i \right) &= \sum_{i=1}^{n} y_i x_i - \bar{y} \sum_{i=1}^{n} x_i .
\end{aligned} \tag{34.16}$$

Wir halten nun zunächst fest, dass gilt

$$\begin{aligned}
\sum_{i=1}^{n} x_i^2 - \bar{x} \sum_{i=1}^{n} x_i &= \sum_{i=1}^{n} x_i^2 - 2\bar{x} \sum_{i=1}^{n} x_i + \bar{x} \sum_{i=1}^{n} x_i \\
&= \sum_{i=1}^{n} x_i^2 - 2\bar{x} \sum_{i=1}^{n} x_i + n \left(\frac{1}{n} \sum_{i=1}^{n} x_i \right) \bar{x} \\
&= \sum_{i=1}^{n} x_i^2 - 2\bar{x} \sum_{i=1}^{n} x_i + n\bar{x}^2 \\
&= \sum_{i=1}^{n} (x_i^2 - 2\bar{x}x_i + \bar{x}^2) \\
&= \sum_{i=1}^{n} (x_i - \bar{x})^2
\end{aligned} \tag{34.17}$$

Weiterhin halten wir zunächst fest, dass gilt

$$\begin{aligned}
\sum_{i=1}^{n} y_i x_i - \bar{y} \sum_{i=1}^{n} x_i &= \sum_{i=1}^{n} y_i x_i - \bar{y} \sum_{i=1}^{n} x_i - n\bar{y}\bar{x} + n\bar{y}\bar{x} \\
&= \sum_{i=1}^{n} y_i x_i - \bar{y} \sum_{i=1}^{n} x_i - \sum_{i=1}^{n} y_i \bar{x} + \sum_{i=1}^{n} \bar{y}\bar{x} \\
&= \sum_{i=1}^{n} y_i x_i - \sum_{i=1}^{n} y_i \bar{x} - \sum_{i=1}^{n} \bar{y} x_i + \sum_{i=1}^{n} \bar{y}\bar{x} \\
&= \sum_{i=1}^{n} (y_i x_i - y_i \bar{x} - \bar{y} x_i + \bar{y}\bar{x}) \\
&= \sum_{i=1}^{n} (y_i - \bar{y}) (x_i - \bar{x}) .
\end{aligned} \tag{34.18}$$

In der Fortsetzung von (1.16) ergibt sich dann

$$\begin{aligned}
\hat{\beta}_1 \left(\sum_{i=1}^{n} x_i^2 - \bar{x} \sum_{i=1}^{n} x_i \right) &= \sum_{i=1}^{n} y_i x_i - \bar{y} \sum_{i=1}^{n} x_i \\
\Leftrightarrow \hat{\beta}_1 \left(\sum_{i=1}^{n} (x_i - \bar{x})^2 \right) &= \sum_{i=1}^{n} (y_i - \bar{y}) (x_i - \bar{x}) \\
\Leftrightarrow \hat{\beta}_1 &= \frac{\sum_{i=1}^{n} (y_i - \bar{y}) (x_i - \bar{x})}{\sum_{i=1}^{n} (x_i - \bar{x})^2} \\
\Leftrightarrow \hat{\beta}_1 &= \frac{c_{xy}}{s_x^2} .
\end{aligned} \tag{34.19}$$

□

Theorem 34.1 besagt, dass die Parameterwerte, die für einen gegebenen Datensatz $\{(x_1, y_1), \ldots, (x_n, y_n)\}$ die Summe der quadrierten vertikalen Abweichungen für eine

linear-affine Funktion minimieren mithilfe der Stichprobenmittel der x_i–und y_i-Werte, der Stichprobenvarianz der x_i-Werte und der Stichprobenkovarianz der x_i - und y_i-Werte berechnet werden können. Die Terminologie orientiert sich hier an den Begrifflichkeiten der deskriptiven Statistik, insbesondere werden die x_i-Werte häufig nicht als Realisationen von Zufallsvariablen verstanden, der Begriff der Stichprobe wird jedoch trotzdem verwendet. Aus der Anwendungsperspektive können nach Theorem 34.1 die Parameter der Ausgleichsgerade also mithilfe der bekannten Funktionen für die Auswertung deskriptiver Statistiken bestimmt werden. Folgender **R** Code demonstriert dies.

```
# Einlesen des Beispieldatensatzes
D           = read.csv("./_data/501-regression.csv")

# Stichprobenstatistiken
x_bar       = mean(D$x_i)                                   # Stichprobenmittel der x_i-Werte
y_bar       = mean(D$y_i)                                   # Stichprobenmittel der y_i-Werte
s2x         = var(D$x_i)                                    # Stichprobenvarianz der  x_i-Werte
cxy         = cov(D$x_i, D$y_i)                             # Stichprobenkovarianz der (x_i,y_i)-Werte

# Ausgleichsgeradenparameter
beta_1_hat  = cxy/s2x                                       # \hat{\beta}_1, Steigungsparameter
beta_0_hat  = y_bar - beta_1_hat*x_bar                      # \hat{\beta}_0, Offsetparameter

# Ausgabe
cat("beta_0_hat:", beta_0_hat,
    "\nbeta_1_hat:", beta_1_hat)
```

```
beta_0_hat: -6.194704
beta_1_hat: 1.657055
```

Eine typische Visualisierung der Ausgleichsgerade eines Datensatzes wie in Abbildung 34.4 implementiert folgender **R** Code.

```
# Datenwerte
plot(
D$x_i,
D$y_i,
pch         = 16,
xlab        = "Anzahl Therapiestunden (x)",
ylab        = "Symptomreduktion (y)",
xlim        = c(0,21),
ylim        = c(-10, 40),
main        = TeX("$\\hat{\\beta}_0 =  -6.19, \\hat{\\beta}_1 = 1.66$"))

# Ausgleichsgerade
abline(
coef        = c(beta_0_hat, beta_1_hat),
lty         = 1,
col         = "black")

# Legende
legend(
"topleft",
c(TeX("$(x_i,y_i)$"), TeX("$f(x) = \\hat{\\beta}_0 + \\hat{\\beta}_1x$")),
lty        = c(0,1),
pch        = c(16, NA),
bty        = "n")
```

Die Idee, bei einem gegebenen Datensatz von (x_i, y_i) Paaren die Summe der quadrierten vertikalen Abweichungen zwischen einer Funktion der x_i-Werte und den y_i-Werten zu minimieren und so eine Funktion möglichst gut an eine Wertemenge anzupassen, ist nicht auf linear-affine Funktionen beschränkt. Folgende Definition verallgemeinert die Definition der Ausgleichsgerade auf Polynomfunktionen beliebigen Grades.

Definition 34.2 (Ausgleichspolynom)**.** Für $\beta := (\beta_0, \dots, \beta_k)^T \in \mathbb{R}^{k+1}$ heißt die Polynomfunktion k-ten Grades

$$f_\beta : \mathbb{R} \to \mathbb{R}, x \mapsto f_\beta(x) := \sum_{i=0}^{k} \beta_i x^i \tag{34.20}$$

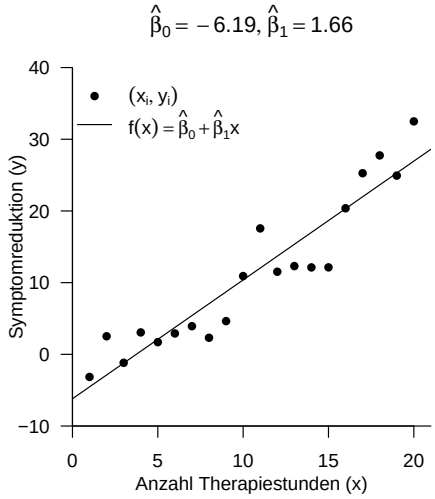


Abbildung 34.4. Ausgleichsgerade für den Beispieldatensatz.

für die für einen Datensatz $\{(x_1, y_1), \ldots, (x_n, y_n)\} \subset \mathbb{R}^2$ die Funktion

$$q : \mathbb{R}^{k+1} \to \mathbb{R}_{\geq 0}, \beta \mapsto q(\beta) := \sum_{i=1}^{n} \left(y_i - f_\beta(x_i)\right)^2 = \sum_{i=1}^{n} \left(y_i - \sum_{i=0}^{k} \beta_i x^i\right)^2 \tag{34.21}$$

der quadrierten vertikalen Abweichungen der y_i von den Funktionswerten $f_\beta(x_i)$ ihr Minimum annimmt, das *Ausgleichspolynom k-ten Grades für den Datensatz* $\{(x_1, y_1), \ldots, (x_n, y_n)\}$.

•

Die Ausgleichsgerade ist damit das Ausgleichspolynom ersten Grades. Wir wollen den Begriff des Ausgleichspolynoms hier nicht weiter vertiefen und werden insbesondere die Parameterwerte $\widehat{\beta}_0, \ldots, \widehat{\beta}_k$, für die die Funktion q ihr Minimum annimmt an späterer Stelle im Rahmen der Theorie des Allgemeinen Linearen Modells allgemein bestimmen. In Abbildung 34.5 visualisieren beispielhaft die Ausgleichspolynome ersten bis vierten Grades für den Beispieldatensatz wobei der Wert der Funktion q an der Minimumsstelle jeweils im Titel vermerkt ist.

34.2. Einfache lineare Regression

Eine Ausgleichsgerade erlaubt Aussagen über unbeobachtete der abhängigen Variable. Allerdings erlaubt eine Ausgleichsgerade nur implizite Aussagen über die mit der Anpassung einer linear-affinen Funktion an einen Datensatz verbundene Unsicherheit. In der einfachen linearen Regression wird die Idee einer Ausgleichsgerade um eine probabilistische Komponente erweitert. Die einfache lineare Regression erlaubt damit insbesondere im Sinne der Frequentistischen Inferenz Konfidenzintervalle für die Ausgleichsgeradenparameter anzugeben und Hypothesentests bezüglich der Ausgleichsgeradenparameter durchzuführen. Wir wollen hier zunächst nur das Modell der einfachen linearen Regression und die

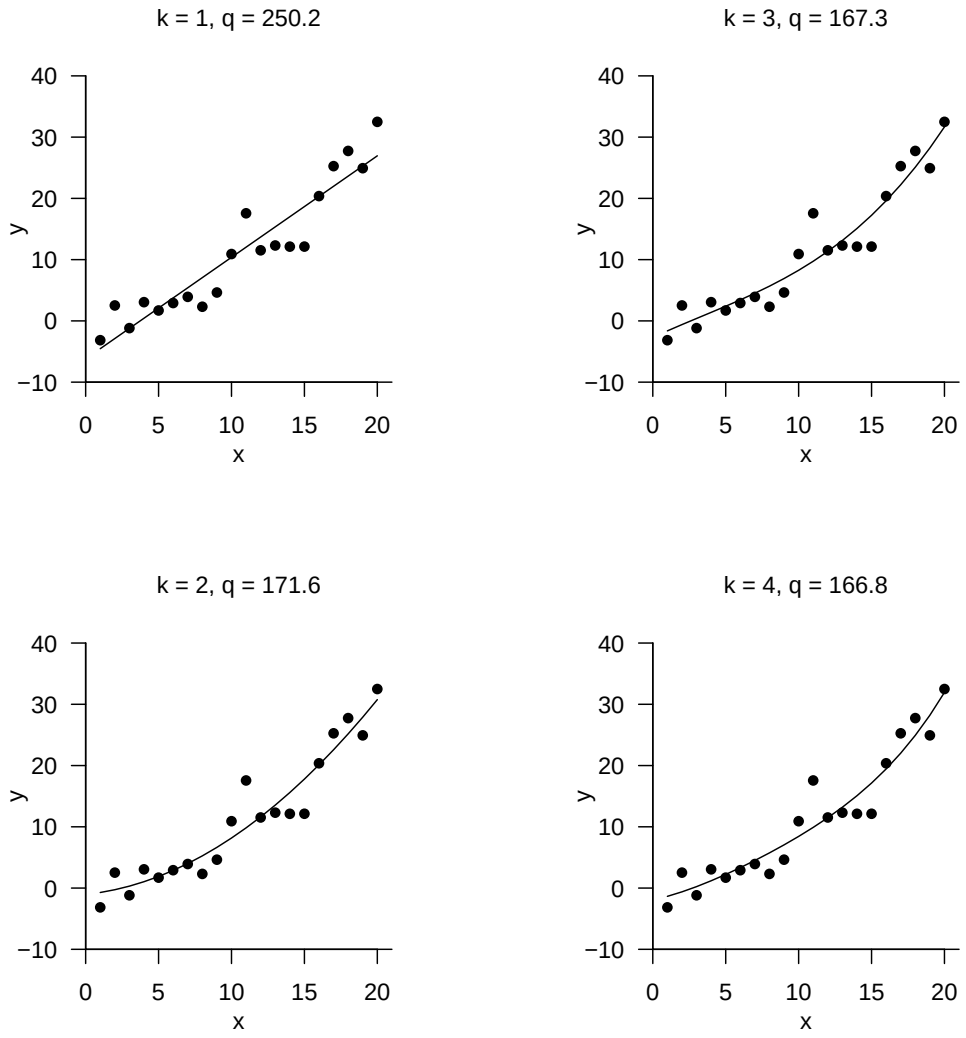


Abbildung 34.5. Ausgleichspolynome ersten bis vierten Grades für den Beispieldatensatz.

auf ihm basierende Maximum-Likelihood Schätzung der Ausgleichsgeradenparameter betrachten.

Die Bewertung der mit dieser Schätzung verbundenen Unsicherheit sowie parameterzentrierte Hypothesentests behandeln wir dann an späterer Stelle zunächst im Kontext des Allgemeinen Linearen Modells. Wir beginnen mit folgender Definition.

Definition 34.3 (Modell der einfachen linearen Regression)**.** Es sei

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i \text{ mit } \varepsilon_i \sim N\left(0, \sigma^2\right) \text{ u.i.v. für } i = 1, \dots, n \tag{34.22}$$

wobei

- y_i beobachtbare Zufallsvariablen sind, die Werte einer abhängigen Variable modellieren,
- $x_i \in \mathbb{R}$ fest vorgegebene Prädiktorwerte oder Regressorwerte sind, die Werte einer unabhängigen Variable modellieren,
- $\beta_0, \beta_1 \in \mathbb{R}$ wahre, aber unbekannte, Offset- und Steigungsparameterwerte sind und
- ε_i unabhängig und identisch normalverteilte nicht-beobachtbare Zufallsvariablen mit wahrem, aber unbekanntem, Varianzparameter $\sigma^2 > 0$ sind, die Fehler-oder Störvariablen modellieren.

Dann heißt Gleichung 34.22 *Modell der einfachen linearen Regression.*

•

Im Gegensatz zur Ausgleichsgerade treten im Modell der einfachen linearen Regression also explizit Zufallsvariablen auf. Speziell definiert das Modell der einfachen linearen Regression wie n beobachtbare (abhängige) Zufallsvariablen y_i anhand der Werte x_i einer unabhängigen Variable, der Parameterwerte β_0 und β_1 sowie durch Addition der normalverteilten Fehlervariablen ε_i generiert wird. Das Modell hat dabei drei Parameter, den Offsetparameter β_0, den Steigungsparameter β_1 und den Varianzparameter σ^2 der normalverteilten Fehlervariablen. Addition der festen Werte β_0 und $\beta_1 x_i$ zu der normalverteilten Zufallsvariable ε_i impliziert dabei eine Normalverteilung von y_i. Dies ist die Aussage folgenden Theorems.

Theorem 34.2 (Datenverteilung der einfachen linearen Regression)**.** *Das Modell der einfachen linearen Regression*

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i \text{ mit } \varepsilon_i \sim N\left(0, \sigma^2\right) \text{ u.i.v. für } i = 1, \dots, n \tag{34.23}$$

lässt sich mit $\mu_i := \beta_0 + \beta_1 x_i$ *äquivalent in der Form*

$$y_i \sim N\left(\mu_i, \sigma^2\right) \text{ u.v. für } i = 1, \dots, n \tag{34.24}$$

schreiben.

∘

Beweis. Wir zeigen die Äquivalenz für ein i, die Unabhängigkeit der y_i zeigen wir an späterer Stelle im Rahmen des Allgemeinen Linearen Modells. Die Äquivalenz beider Modellformen für ein i folgt direkt aus der Transformation normalverteilter Zufallsvariablen durch linear-affine Funktionen. Speziell gilt im vorliegenden Fall für $\varepsilon_i \sim N(0, \sigma^2)$, dass

$$y_i = f(\varepsilon_i) \text{ mit } f : \mathbb{R} \to \mathbb{R}, \varepsilon_i \mapsto f(\varepsilon_i) := \varepsilon_i + (\beta_0 + \beta_1 x_i) \tag{34.25}$$

Mit dem WDF Transformationstheorem bei linear-affinen Abbildungen folgt dann

$$\begin{aligned} p_{y_i}(y_i) &= \frac{1}{|1|} p_{\varepsilon_i}\left(\frac{y_i - \beta_0 - \beta_1 x_i}{1}\right) \\ &= N(y_i - \beta_0 - \beta_1 x_i; 0, \sigma^2) \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(y_i - \beta_0 - \beta_1 x_i - 0)^2\right) \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(y_i - (\beta_0 + \beta_1 x_i))^2\right) \\ &= N(y_i; \beta_0 + \beta_1 x_i, \sigma^2). \end{aligned} \tag{34.26}$$

Definition von $\mu_i := \beta_0 + \beta_1 x_i$ ergibt dann die Aussage des Theorems. □

Theorem 34.2 besagt insbesondere, dass die Datenvariablen y_i univariat normalverteilte Zufallsvariablen sind, deren Erwartungswertparameter jeweils vom Wert der unabhängigen Variable x_i abhängen. Abbildung 1.6 visualisiert das Modell und eine Realisation der einfachen linearen Regression für wahre, aber unbekannte, Parameterwerte $\beta_0 := 0, \beta_1 := 1$ und $\sigma^2 := 1$.

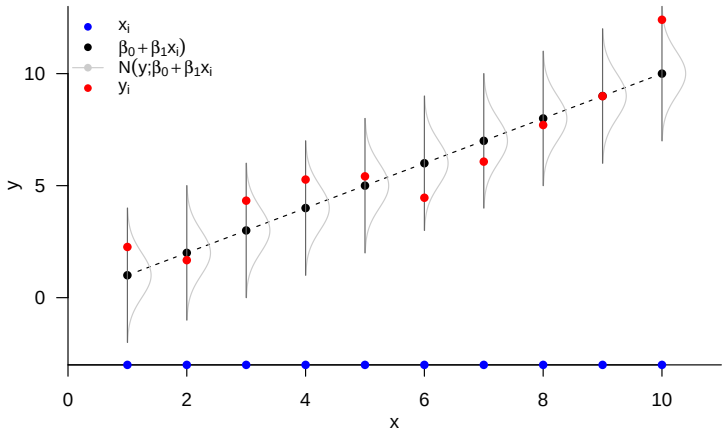


Abbildung 34.6. Modell der einfachen linearen Regression für $\beta_0 := 0, \beta_1 := 1$ und $\sigma^2 := 1$.

Da es sich bei dem Modell der einfachen linearen Regression um ein parametrisches Frequentistisches Modell handelt, können Schätzer für die Modellparameter mithilfe des Maximum-Likelihood-Prinzips gewonnen werden. Insbesondere stellt sich dabei heraus, dass die Maximum-Likelihood-Schätzer des Offset- und des Steigungsparameters mit den Werten der Ausgleichsgeradenparameter identisch sind. Dies ist eine der Aussagen des folgenden Theorems. Wir verzichten hier bei den Schätzern aus Gründen der notationstechnischen Übersichtlichkeit auf ^{ML} Superskripte.

Theorem 34.3 (Maximum-Likelihood-Schätzung der einfachen linearen Regression)**.**

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i \text{ mit } \varepsilon_i \sim N\left(0, \sigma^2\right) \text{ u.i.v. für } i = 1, \dots, n \tag{34.27}$$

das Modell der einfachen linearen Regression. Dann sind Maximum-Likelihood-Schätzer der Modellparameter β_0, β_1 und σ^2 gegeben durch

$$\hat{\beta}_1 := \frac{c_{xy}}{s_x^2}, \quad \hat{\beta}_0 := \bar{y} - \hat{\beta}_1 \bar{x} \quad \text{und } \hat{\sigma}^2 := \frac{1}{n} \sum_{i=1}^{n} \left(y_i - \left(\hat{\beta}_0 + \hat{\beta}_1 x_i\right)\right)^2 \tag{34.28}$$

∘

Beweis. Wir zeigen zunächst, dass die Ausgleichsgeradenparameter $\hat{\beta}_0$ und $\hat{\beta}_1$ den entsprechenden Maximum-Likelihood-Schätzern gleichen. Dazu halten wir zunächst fest, dass aufgrund der Unabhängigkeit der $y_1, \dots, y_n$ die Likelihood-Funktion des Modells der einfachen linearen Regression bezüglich β_0 und β_1 die Form

$$\begin{aligned} L : \mathbb{R}^2 \to \mathbb{R}_{>0}, (\beta_0, \beta_1) \mapsto L\left(\beta_0, \beta_1\right) :&= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}\left(y_i - \left(\beta_0 + \beta_1 x_i\right)\right)^2\right) \\ &= \left(2\pi\sigma^2\right)^{-\frac{n}{2}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^{n} \left(y_i - \left(\beta_0 + \beta_1 x_i\right)\right)^2\right) \end{aligned} \tag{34.29}$$

hat. Weil für die Exponentialfunktion für $a < b \leq 0$ gilt, dass $\exp(a) < \exp(b)$, wird der Exponentialterm dieser Likelihood-Funktion maximal, wenn der nicht-negative Term

$$q := \sum_{i=1}^{n} \left(y_i - \left(\beta_0 + \beta_1 x_i\right)\right)^2 \tag{34.30}$$

minimal und damit $-q$ maximal wird. Im Rahmen des Beweises der Ausgleichsgeradenform haben wir aber schon gezeigt, dass der Term (1.30) für

$$\hat{\beta}_1 := \frac{c_{xy}}{s_x^2} \text{ und } \hat{\beta}_0 := \bar{y} - \hat{\beta}_1 \bar{x} \tag{34.31}$$

minimal wird und damit $\hat{\beta}_1$ und $\hat{\beta}_0$ die Likelihood-Funktion maximieren.

In einem zweiten Schritt betrachten wir nun die Likelihood-Funktion des Modells der einfachen linearen Regression bezüglich σ^2 an der Stelle von $\hat{\beta}_0$ und $\hat{\beta}_1$. Wir erhalten die Likelihood-Funktion

$$L : \mathbb{R}_{>0} \to \mathbb{R}_{>0}, \sigma^2 \mapsto L\left(\sigma^2\right) = \left(2\pi\sigma^2\right)^{-\frac{n}{2}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^{n} \left(y_i - \left(\hat{\beta}_0 + \hat{\beta}_1 x_i\right)\right)^2\right) \tag{34.32}$$

und die entsprechende Log-Likelihood-Funktion

$$\ell : \mathbb{R}_{>0} \to \mathbb{R}, \sigma^2 \mapsto \ell\left(\sigma^2\right) = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^{n} \left(y_i - \left(\hat{\beta}_0 + \hat{\beta}_1 x_i\right)\right)^2 \tag{34.33}$$

In Analogie zu der Herleitung des Maximum-Likelihood-Schätzers für σ^2 im Normalverteilungsmodell ergibt sich unter Beachtung von

$$\hat{\mu} = \hat{\beta}_0 + \hat{\beta}_1 x_i \tag{34.34}$$

dann hier

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^{n} \left(y_i - \left(\hat{\beta}_0 + \hat{\beta}_1 x_i\right)\right)^2 \tag{34.35}$$

□

In der Anwendung ist die Maximum-Likelihood-Schätzung der Parameter der einfachen linearen Regression also im Wesentlichen mit der Bestimmung der Ausgleichsgeradenparameter identisch, wie folgender **R** Code zur Schätzung der Parameter für den Beispieldatensatz demonstriert.

```
# Einlesen des Beispieldatensatzes
fname       = "./_data/501-regression.csv"
D           = read.table(fname, sep = ",", header = TRUE)

# Stichprobenstatistiken
n           = length(D$y_i)                                          # Anzahl Datenpunkte
x_bar       = mean(D$x_i)                                            # Stichprobenmittel der x_i-Werte
y_bar       = mean(D$y_i)                                            # Stichprobenmittel der y_i-Werte
s2x         = var(D$x_i)                                             # Stichprobenvarianz der  x_i-Werte
cxy         = cov(D$x_i, D$y_i)                                      # Stichprobenkovarianz der (x_i,y_i)-Werte

# Parameterschätzer
beta_1_hat  = cxy/s2x                                                # \hat{\beta}_1, Steigungsparameter
beta_0_hat  = y_bar - beta_1_hat*x_bar                               # \hat{\beta}_0, Offsetparameter
sigsqr_hat  = (1/n)*sum((D$y_i-(beta_0_hat+beta_1_hat*D$x_i))^2)     # Varianzparameter


# Ausgabe
cat("beta_0_hat:"  , beta_0_hat,
    "\nbeta_1_hat:", beta_1_hat,
    "\nsigsqr_hat:", sigsqr_hat)
```

```
beta_0_hat: -6.194704
beta_1_hat: 1.657055
sigsqr_hat: 12.50892
```

34.3. Literaturhinweise

Die Idee der Minimierung einer Summe von quadrierten Abweichungen bei der Anpassung einer Polynomfunktion an beobachtete Werte geht auf die Arbeiten von Legendre (1805) und Gauss (1809) im Kontext der Bestimmung von Planetenbahnen zurück. Eine historische Einordnung dazu gibt Stigler (1981). Der Begriff der Regression geht zurück auf Galton (1886). Stigler (1986) gibt dazu einen ausführlichen historischen Überblick.

35. Korrelation

Die Konzepte der Regression und der Korrelation sind eng miteinander verwoben und dienen letztlich der Quantifizierung linear-affiner Abhängigkeiten zwischen unabhängigen und abhängigen Variablen. Ein zentrales Thema dieses Abschnittes sind damit die Äquivalenzen zwischen beiden Konzepten. Im Gegensatz zur Regression werden bei der Korrelation sowohl die abhängige als auch die unabhängige Variable als Zufallsvariablen modelliert, die probabilistische Komplexität der Korrelation ist also etwas höher als die der Regression und des Allgemeinen Linearen Modells. Um uns den Zusammenhängen von Regression und Korrelation zu nähern, erinnern wir Kapitel 35.1 zunächst an den Begriff und die Mechanik der Stichprobenkorrelation. In Kapitel Kapitel 35.2 widmen wir uns anhand der R^2 Statistik dem Zusammenhang zwischen Stichprobenkorrelation und Ausgleichsgerade und geben ein erstes Beispiel für die Idee einer Varianzzerlegung. In Kapitel Kapitel 35.3 schließlich diskutieren wir erste Aspekte zum Verständnis der Stichprobenkorrelation im probabilistischen Kontext. Als Anwendungsbeispiel betrachten wir durchgängig den in Kapitel 34 eingeführten Beispieldatensatz zum Zusammenhang von Psychotherapiedauer und Symptomreduktion.

35.1. Grundlagen

Wir erinnern zunächst an den Begriff der Korrelation zweier Zufallsvariablen.

Definition 35.1 (Korrelation)**.** Die Korrelation zweier Zufallsvariablen ξ und υ ist definiert als

$$\rho(\xi, \upsilon) := \frac{\mathbb{C}(\xi, \upsilon)}{\mathbb{S}(\xi)\mathbb{S}(\upsilon)} \tag{35.1}$$

wobei $\mathbb{C}(\xi, \upsilon)$ die Kovarianz von ξ und υ und $\mathbb{S}(\xi)$ und $\mathbb{S}(\upsilon)$ die Standardabweichungen von ξ und υ, respektive, bezeichnen.

•

Die Zahl $\rho(\xi, \upsilon)$ wird auch Korrelationskoeffizient von ξ und υ genannt. Wir haben bereits gesehen, dass $-1 \leq \rho(\xi, \upsilon) \leq 1$ gilt und dass ξ und υ unkorreliert genannt werden, wenn $\rho(\xi, \upsilon) = 0$ ist. Weiterhin haben wir bereits gesehen, dass aus der Unabhängigkeit der Zufallsvariablen ξ und υ immer die Unkorreliertheit von ξ und υ folgt, dass aber im Allgemeinen aus der Unkorreliertheit von ξ und υ nicht die Unabhängigkeit von ξ und υ folgt.

Liegen von zwei Zufallsvariablen Realisationen als ein bivariater Datensatz vor, so kann man anhand folgender Definition die realisationsspezifische Stichprobenkorrelation bestimmen.

Definition 35.2 (Stichprobenkorrelation). $\{(x_1, y_1), \ldots, (x_n, y_n)\} \subset \mathbb{R}^2$ sei ein Datensatz. Weiterhin seien:

- Die Stichprobenmittel der x_i und y_i definiert als

$$\bar{x} := \frac{1}{n}\sum_{i=1}^{n} x_i \text{ und } \bar{y} := \frac{1}{n}\sum_{i=1}^{n} y_i \tag{35.2}$$

- Die Stichprobenstandardabweichungen x_i und y_i definiert als

$$s_x := \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2} \text{ und } s_y := \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(y_i - \bar{y})^2}. \tag{35.3}$$

- Die Stichprobenkovarianz der $(x_1, y_1), \ldots, (x_n, y_n)$ definiert als

$$c_{xy} := \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}) \tag{35.4}$$

Dann ist die *Stichprobenkorrelation* der $(x_1, y_1), \ldots, (x_n, y_n)$ definiert als

$$r_{xy} := \frac{c_{xy}}{s_x s_y} \tag{35.5}$$

und wird auch *Pearson's Stichprobenkorrelationskoeffizient* genannt.

•

Folgender **R** Code wertet die Stichprobenkorrelation des Beispieldatensatzes aus.

```
# Laden des Beispieldatensatzes
fname = "./_data/502-korrelation.csv"                          # Dateipfad
D     = read.table(fname, sep = ",", header = TRUE)            # Laden als Dataframe
x_i   = D$x_i                                                  # x_i Werte
y_i   = D$y_i                                                  # y_i Werte
n     = length(x_i)                                            # n

# "Manuelle" Berechnung der Stichprobenkorrelation
x_bar = (1/n)*sum(x_i)                                         # \bar{x}
y_bar = (1/n)*sum(y_i)                                         # \bar{y}
s_x   = sqrt(1/(n-1)*sum((x_i - x_bar)^2))                     # s_x
s_y   = sqrt(1/(n-1)*sum((y_i - y_bar)^2))                     # s_y
c_xy  = 1/(n-1) * sum((x_i - x_bar) * (y_i - y_bar))           # c_{xy}
r_xy  = c_xy/(s_x * s_y)                                       # r_{xy}
print(r_xy)                                                    # Ausgabe
```

```
[1] 0.9378162
```

```
# Automatische Berechnung mit cor()
r_xy  = cor(x_i,y_i)                                           # r_{xy}
print(r_xy)                                                    # Ausgabe
```

```
[1] 0.9378162
```

Im Beispieldatensatz sind die Anzahl der Therapiestunden und die Symptomreduktion also mit $r_{xy} = 0.93$ hoch korreliert. Allgemein spricht man bei absoluten Werten von r_{xy} größer als etwa 0.70 von hoher Korrelation, bei absoluten Werten von r_{xy} zwischen etwa 0.30 und 0.70 von mittlerer Korrelation und bei absoluten Werten von r_{xy} zwischen 0.00 und 0.30 von niedriger Korrelation. Eine niedrige Korrelation zweier Variablen bedeutet

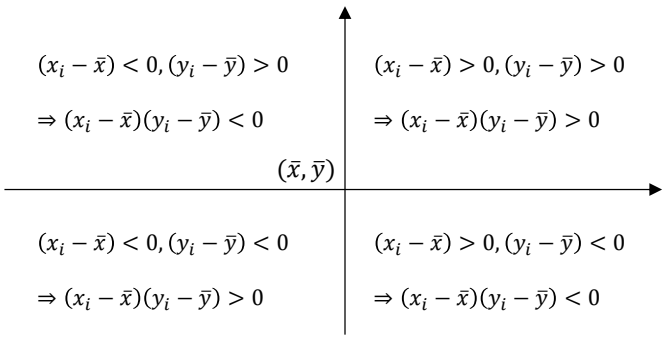


Abbildung 35.1. Mechanik der Stichprobenkorrelationssummenterme.

aber nicht zwangsläufig, dass diese Korrelation irrelevant ist (man denke an Gesundheitsrisikofaktoren), genauso wenig wie eine hohe Korrelation zweier Variablen trivial sein kann (man denke an die Korrelation von Körpergröße und Schuhgröße).

Da die Stichprobenkorrelation lediglich die auf das Intervall $[-1, 1]$ normalisierte Stichprobenkovarianz c_{xy} ist, wird die Höhe der Stichprobenkorrelation und insbesondere ihr Vorzeichen entscheidend durch die Werte Stichprobenkovarianzsummenterme $(x_i - \bar{x})(y_i - \bar{y})$ bestimmt. Dabei ist es entscheidend, wie häufig über die Datenpaare (x_i, y_i) hinweg die x_i und y_i gleichartig oder entgegengesetzt von ihren jeweiligen Stichprobenmitteln abweichen. Dies ist schematisch in Abbildung 35.1 dargestellt. Bei häufiger richtungsgleicher Abweichung von ihren jeweiligen Mittelwerten, sowohl in positiver als auch in negativer Richtung, ergibt das Produkt $(x_i - \bar{x})(y_i - \bar{y})$ eine positive Zahl, trägt also zu einer positiven Stichprobenkovarianz bei. Bei häufiger entgegengesetzter Abweichung von ihren jeweiligen Mittelwerten ergibt das Produkt $(x_i - \bar{x})(y_i - \bar{y})$ häufig eine negative Zahl, trägt also zu einer negativen Stichprobenkovarianz bei. Kommen sowohl richtungsgleiche als auch entgegengesetzte Abweichungen der x_i und y_i häufig vor, so gleichen sich positive und negative Beiträge zur Stichprobenkovarianzsumme eher aus und es resultiert eine geringe Stichprobenkovarianz bzw. ein Stichprobenkorrelationskoeffizient nahe Null. Abbildung 2.2 zeigt bivariate Datensätze von jeweils $n = 30$ Datenpunkten zusammen mit ihren jeweiligen Stichprobenkorrelationskoeffizienten.

Der Vorteil des Stichprobenkorrelationskoeffizienten gegenüber der Stichprobenkovarianz als Zusammenhangsmaß ist es, dass der absolute Wert des Stichprobenkorrelationskoeffizienten bei linear-affiner Transformation der zugrundeliegende Wertemenge gleich bleibt, wohingegen die Stichprobenkovarianz ihren Wert je nach gewähltem Maßstab ändert. Man sagt deshalb auch, dass der Stichprobenkorrelationkoeffizient maßstabsunabhängig ist. Dies ist die zentrale Aussage folgenden Theorems.

Theorem 35.1 (Stichprobenkorrelation bei linear affiner Transformation)**.** *Für einen Datensatz* $\{(x_i, y_i)\}_{i=1,\ldots n} \subset \mathbb{R}^2$ *sei* $\{(\tilde{x}_i, \tilde{y}_i)\}_{i=1,\ldots n} \subset \mathbb{R}^2$ *der linear-affin transformierte Datensatz mit*

$$(\tilde{x}_i, \tilde{y}_i) = \left(a_x x_i + b_x, a_y y_i + b_y\right), a_x, a_y \neq 0. \tag{35.6}$$

gegeben. Dann gilt

$$\left|r_{\tilde{x}\tilde{y}}\right| = \left|r_{xy}\right|. \tag{35.7}$$

°

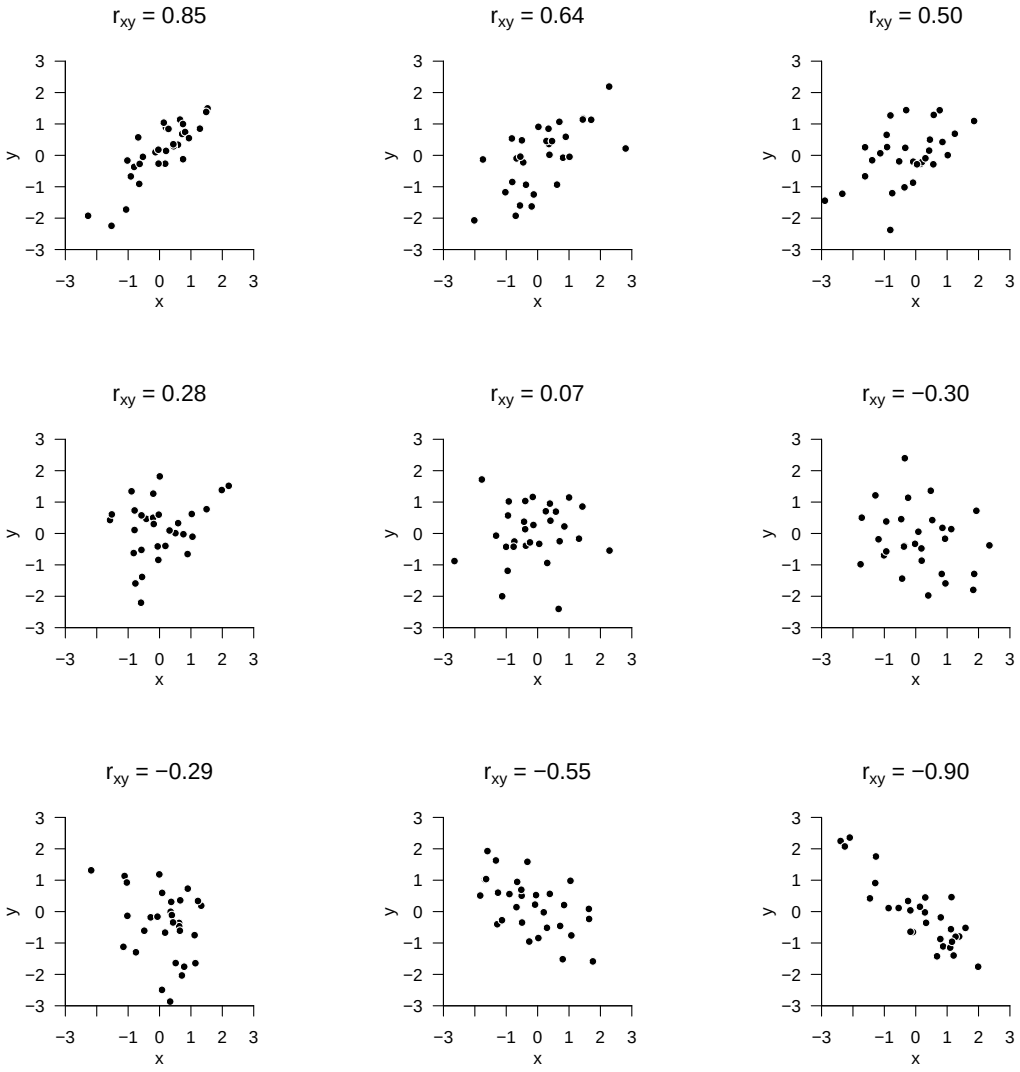


Abbildung 35.2. Beispiele bivariater Datensätze und ihrer Stichprobenkorrelationen.

Beweis.

$$\begin{aligned}
r_{\tilde{x}\tilde{y}} &:= \frac{\frac{1}{n-1}\sum_{i=1}^{n}\left(\tilde{x}_i - \bar{\tilde{x}}\right)\left(\tilde{y}_i - \bar{\tilde{y}}\right)}{\sqrt{\frac{1}{n-1}\left(\sum_{i=1}^{n}\tilde{x}_i - \bar{\tilde{x}}\right)^2}\sqrt{\frac{1}{n-1}\left(\sum_{i=1}^{n}\tilde{y}_i - \bar{\tilde{y}}\right)^2}} \\
&= \frac{\sum_{i=1}^{n}\left(a_x x_i + b_x - \left(a_x\bar{x} + b_x\right)\right)\left(a_y y_i + b_y - \left(a_y\bar{y} + b_y\right)\right)}{\sqrt{\sum_{i=1}^{n}\left(a_x x_i + b_x - \left(a_x\bar{x} + b_x\right)\right)^2}\sqrt{\sum_{i=1}^{n}\left(a_y y_i + b_y - \left(a_y\bar{y} + b_y\right)\right)^2}} \\
&= \frac{a_x a_y \sum_{i=1}^{n}\left(x_i - \bar{x}\right)\left(y_i - \bar{y}\right)}{\sqrt{a_x^2\sum_{i=1}^{n}\left(x_i - \bar{x}\right)^2}\sqrt{a_y^2\sum_{i=1}^{n}\left(y_i - \bar{y}\right)^2}} \\
&= \frac{a_x a_y}{|a_x|\,|a_y|}\frac{\sum_{i=1}^{n}\left(x_i - \bar{x}\right)\left(y_i - \bar{y}\right)}{\sqrt{\sum_{i=1}^{n}\left(x_i - \bar{x}\right)^2}\sqrt{\sum_{i=1}^{n}\left(y_i - \bar{y}\right)^2}} \\
&= \frac{a_x a_y}{|a_x|\,|a_y|}\frac{c_{xy}}{s_x s_y} \\
&= \frac{a_x a_y}{|a_x|\,|a_y|} r_{xy}.
\end{aligned} \tag{35.8}$$

Also folgt, durch Durchspielen aller möglichen Vorzeichenfälle, dass

$$\left|r_{\tilde{x}\tilde{y}}\right| = \left|r_{xy}\right|. \tag{35.9}$$

□

35.2. Korrelation und Bestimmheitsmaß

Das sogenannte Bestimmtheitsmaß R^2 ist eine beliebte, häufig reportierte Statistik zur Beschreibung der Zusammenhangsstärke der Werte einer unabhängigen und einer abhängigen Variable. Numerisch handelt es sich bei R^2 lediglich um den quadrierten Stichprobenkorrelationskoeffizienten. Ist die Stichprobenkorrelation zum Beispiel $r_{xy} = 0.5$, dann ist $R^2 = 0.5^2 = 0.25$, ist die Stichprobenkorrelation dagegen $r_{xy} = -0.5$, dann gilt analog $R^2 = (-0.5)^2 = 0.25$. An diesen Beispielen erkennt man, dass R^2 weniger Information über die Rohdaten enthält als r_{xy}, da das Vorzeichen und damit die Richtung des Zusammenhangs wegfällt. Per se ist die Angabe von R^2 anstelle von r_{xy} als Deskriptivstatistik zur Beschreibung der Zusammenhangsstärke der Werte von unabhängiger und abhängiger Variable ohne Vorteil. Wir wollen hier trotzdem etwas genauer auf R^2 eingehen, da ein tieferes Verständnis von R^2 einerseits den Einstieg in das Konzept der Varianzzerlegungen erlaubt und andererseits die Zusammenhänge zwischen den Konzepten der Ausgleichsgerade und der Stichprobenkorrelation weiter verdeutlicht. Wir erweitern dazu zunächst die Beschreibung der Ausgleichsgerade aus Kapitel 34.1 durch die Begriffe der erklärten Werte und der Residuen.

Definition 35.3 (Erklärte Werte und Residuen einer Ausgleichsgerade.)**.** Gegeben sei ein Datensatz $\{(x_1, y_1), \ldots, (x_n, y_n)\} \subset \mathbb{R}^2$ und die zu diesem Datensatz gehörende Ausgleichsgerade

$$f_{\hat{\beta}} : \mathbb{R} \to \mathbb{R}, x \mapsto f_{\hat{\beta}}(x) := \hat{\beta}_0 + \hat{\beta}_1 x \tag{35.10}$$

Dann werden für $i = 1, \ldots, n$

$$\hat{y}_i := \hat{\beta}_0 + \hat{\beta}_1 x_i \tag{35.11}$$

die durch die Ausgleichsgerade *erklärten Werte* genannt und

$$\hat{\varepsilon}_i := y_i - \hat{y}_i \tag{35.12}$$

werden die *Residuen* der Ausgleichsgerade genannt.

•

Etwas allgemeiner formuliert sind die *erklärten Werte* damit die Datenvorhersage des Modells basierend auf den geschätzten Parameterwerten, während die Residuen die Differenzen zwischen den geschätzten Datenvorhersagen und den beobachteten Datenwerten bezeichnen. Abbildung 35.3 verdeutlicht diese Begriffe am Beispiel der Ausgleichsgerade des Beispieldatensatzes.

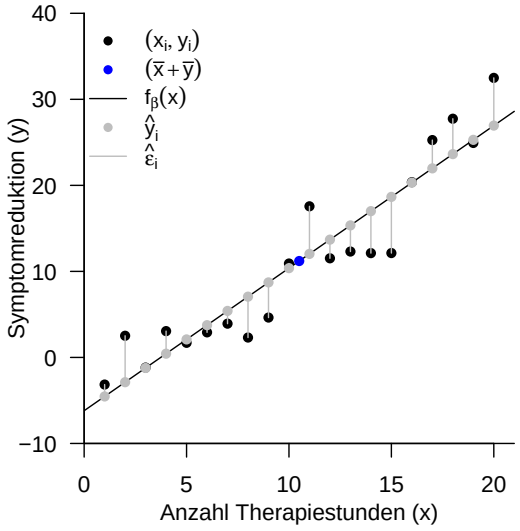


Abbildung 35.3. Ausgleichsgerade, erklärte Werte und Residuen für den Beispieldatensatz..

Mithilfe der Begriffe der erklärten Werte und Residuen lässt sich nun folgende Quadratsummenzerlegung beim Vorliegen einer Ausgleichsgerade eines Datensatzes angeben.

Theorem 35.2 (Quadratsummenzerlegung bei Ausgleichsgerade)**.** *Für einen Datensatz* $\{(x_1, y_1), \ldots, (x_n, y_n)\} \subset \mathbb{R}^2$ *und seine zugehörige Ausgleichsgerade* $f_{\hat{\beta}}$ *seien für*

$$\bar{y} := \frac{1}{n}\sum_{i=1}^{n} y_i \text{ und } \hat{y}_i := \hat{\beta}_0 + \hat{\beta}_1 x_i, \text{ für } i = 1, \ldots, n \tag{35.13}$$

das Stichprobenmittel der y_i*-Werte und die durch die Ausgleichsgerade erklärten Werte, respektive. Weiterhin seien*

- *die Total Sum of Squares definiert als*

$$SQT := \sum_{i=1}^{n} (y_i - \bar{y})^2 \tag{35.14}$$

- *die Explained Sum of Squares definiert als*

$$SQE := \sum_{i=1}^{n} (\hat{y}_i - \bar{y})^2 \tag{35.15}$$

- *die Residual Sum of Squares definiert als*

$$SQR := \sum_{i=1}^{n} \left(y_i - \hat{y}_i\right)^2 \tag{35.16}$$

Dann gilt

$$SQT = SQE + SQR \tag{35.17}$$

∘

Beweis.

$$\begin{aligned}
\text{SQT} &= \sum_{i=1}^{n} \left(y_i - \bar{y}\right)^2 \\
&= \sum_{i=1}^{n} \left(y_i - \hat{y}_i + \hat{y}_i - \bar{y}\right)^2 \\
&= \sum_{i=1}^{n} \left(\left(y_i - \hat{y}_i\right) + \left(\hat{y}_i - \bar{y}\right)\right)^2 \\
&= \sum_{i=1}^{n} \left(\left(y_i - \hat{y}_i\right)^2 + 2\left(y_i - \hat{y}_i\right)\left(\hat{y}_i - \bar{y}\right) + \left(\hat{y}_i - \bar{y}\right)^2\right) \\
&= \sum_{i=1}^{n} \left(\hat{y}_i - \bar{y}\right)^2 + 2\sum_{i=1}^{n} \left(y_i - \hat{y}_i\right)\left(\hat{y}_i - \bar{y}\right) + \sum_{i=1}^{n} \left(y_i - \hat{y}_i\right)^2 \\
&= \text{SQE} + 2\sum_{i=1}^{n} \left(y_i - \hat{y}_i\right)\left(\hat{y}_i - \bar{y}\right) + \text{SQR} \\
&= \text{SQE} + \text{SQR}
\end{aligned} \tag{35.18}$$

Dabei ergibt sich die letzte Gleichung mit

$$\bar{\hat{y}} := \frac{1}{n}\sum_{i=1}^{n} \hat{y}_i = \frac{1}{n}\sum_{i=1}^{n} \left(\hat{\beta}_0 + \hat{\beta}_1 x_i\right) = \hat{\beta}_0 + \hat{\beta}_1 \bar{x} = \bar{y} - \hat{\beta}_1 \bar{x} + \hat{\beta}_1 \bar{x} = \bar{y} \tag{35.19}$$

und damit auch

$$\bar{\hat{y}} = \bar{y} \Leftrightarrow \frac{1}{n}\sum_{i=1}^{n} \hat{y}_i = \frac{1}{n}\sum_{i=1}^{n} y_i \Leftrightarrow \sum_{i=1}^{n} \hat{y}_i = \sum_{i=1}^{n} y_i \Leftrightarrow \bar{y}\sum_{i=1}^{n} \hat{y}_i = \bar{y}\sum_{i=1}^{n} y_i \tag{35.20}$$

sowie

$$\bar{\hat{y}} = \bar{y} \Leftrightarrow \frac{1}{n}\sum_{i=1}^{n} \hat{y}_i = \frac{1}{n}\sum_{i=1}^{n} y_i \Leftrightarrow \sum_{i=1}^{n} y_i = \sum_{i=1}^{n} \hat{y}_i \Leftrightarrow \sum_{i=1}^{n} y_i\hat{y}_i = \sum_{i=1}^{n} \hat{y}_i\hat{y}_i \tag{35.21}$$

aus

$$\begin{aligned}
\sum_{i=1}^{n} \left(y_i - \hat{y}_i\right)\left(\hat{y}_i - \bar{y}\right) &= \sum_{i=1}^{n} \left(y_i\hat{y}_i - y_i\bar{y} - \hat{y}_i\hat{y}_i + \hat{y}_i\bar{y}\right) \\
&= \sum_{i=1}^{n} y_i\hat{y}_i - \sum_{i=1}^{n} y_i\bar{y} - \sum_{i=1}^{n} \hat{y}_i\hat{y}_i + \sum_{i=1}^{n} \hat{y}_i\bar{y} \\
&= \sum_{i=1}^{n} y_i\hat{y}_i - \sum_{i=1}^{n} \hat{y}_i\hat{y}_i + \bar{y}\sum_{i=1}^{n} \hat{y}_i - \bar{y}\sum_{i=1}^{n} y_i \\
&= 0 + 0 \\
&= 0
\end{aligned} \tag{35.22}$$

□

Die Begriffsbildungen von Theorem 35.2 erklären sich intuitiv wie folgt:

- SQT repräsentiert die Gesamtvariabilität der y_i-Werte um ihren Mittelwert $\bar{y}$.

- SQE repräsentiert die Variabilität der erklärten Werte $\hat{y}_i$ um ihren Mittelwert. Große Werte von SQE repräsentieren damit eine große absolute Steigung der y_i mit den x_i und kleine Werte von SQE repräsentieren eine kleine absolute Steigung der y_i mit den x_i. SQE ist somit ein Maß für die Stärke des linearen Zusammenhangs der x_{i-} und y_i-Werte
- SQR ist die Summe der quadrierten Residuen, denn es gilt

$$\text{SQR} := \sum_{i=1}^{n} \left(y_i - \hat{y}_i\right)^2 := \sum_{i=1}^{n} \hat{\varepsilon}_i^2 \tag{35.23}$$

Große Werte von SQR repräsentieren damit große Abweichungen der erklärten von den beobachteten y_i-Werten und kleine Werte von SQR repräsentieren geringe Abweichungen der erklärten von den beobachteten y_i-Werten. SQR ist also ein Maß für die Güte der Beschreibung der Datenmenge durch die Ausgleichsgerade.

Die zentrale Aussage des Theorem 2.1 ist nun, dass sich die Gesamtstreung der y_i-Werte um ihren Mittelwert $\bar{y}$ gerade aus der Summe der Stärke des linearen Zusammenhangs der x_{i-}und y_i-Werte (also des "deterministischen Einflusses" der x_i auf die y_i) sowie den den Abweichungen von diesem linearen Zusammenhang (also dem "Rauschen") zusammensetzt. Obwohl es sich bei SQT formal nicht um ein Varianzmaß handelt, spricht man in diesem Zusammenhang auch oft von einer Varianzzerlegung in erklärte Varianz und Residualvarianz. Dieses Motiv ist ein zentraler Aspekt des Allgemeinen Linearen Modells und wird in späteren Kapiteln erneut aufgegriffen werden. Für den Moment erlaubt Theorem 2.1 nun folgende Defintion des Bestimmtheitsmaßes R^2.

Definition 35.4 (Bestimmtheitsmaß R^2)**.** Für einen Datensatz $\{(x_1, y_1), \ldots, (x_n, y_n)\} \subset \mathbb{R}^2$ und seine zugehörige Ausgleichsgerade $f_{\hat{\beta}}$ sowie die zugehörigen Explained Sum of Squares SQE und Total Sum of Squares SQT heißt

$$\text{R}^2 := \frac{\text{SQE}}{\text{SQT}} \tag{35.24}$$

das *Bestimmtheitsmaß* oder der *Determinationskoeffizient.*

•

Folgendes Theorem liefert nun den oben erwähnten Zusammenhang zwischen dem Bestimmtheitsmaß und der Stichprobenkorrelation.

Theorem 35.3 (Stichprobenkorrelation und Bestimmtheitsmaß)**.** *Für einen Datensatz* $\{(x_1, y_1), \ldots, (x_n, y_n)\} \subset \mathbb{R}^2$ *sei* R^2 *das Bestimmtheitsmaß und* r_{xy} *sei die Stichprobenkorrelation. Dann gilt*

$$\text{R}^2 = r_{xy}^2 \tag{35.25}$$

∘

Beweis. Wir halten zunächst fest, dass mit

$$\bar{\hat{y}} := \frac{1}{n}\sum_{i=1}^{n} \hat{y}_i = \frac{1}{n}\sum_{i=1}^{n} \left(\hat{\beta}_0 + \hat{\beta}_1 x_i\right) = \hat{\beta}_0 + \hat{\beta}_1 \bar{x} = \bar{y} - \hat{\beta}_1 \bar{x} + \hat{\beta}_1 \bar{x} = \bar{y} \tag{35.26}$$

folgt, dass

$$\begin{aligned}
\text{SQE} &= \sum_{i=1}^{n} \left(\hat{y}_i - \bar{y}\right)^2 \\
&= \sum_{i=1}^{n} \left(\hat{y}_i - \bar{\bar{y}}\right)^2 \\
&= \sum_{i=1}^{n} \left(\hat{\beta}_0 + \hat{\beta}_1 x_i - \hat{\beta}_0 - \hat{\beta}_1 \bar{x}\right)^2 \\
&= \sum_{i=1}^{n} \left(\hat{\beta}_1 \left(x_i - \bar{x}\right)\right)^2 \\
&= \hat{\beta}_1^2 \sum_{i=1}^{n} \left(x_i - \bar{x}\right)^2
\end{aligned} \tag{35.27}$$

Damit ergibt sich dann

$$\begin{aligned}
\text{R}^2 &= \frac{\text{SQE}}{\text{SQT}} \\
&= \frac{\sum_{i=1}^{n} \left(\hat{y}_i - \bar{y}\right)^2}{\sum_{i=1}^{n} \left(y_i - \bar{y}\right)^2} \\
&= \hat{\beta}_1^2 \frac{\sum_{i=1}^{n} \left(x_i - \bar{x}\right)^2}{\sum_{i=1}^{n} \left(y_i - \bar{y}\right)^2} \\
&= \frac{c_{xy}^2}{s_x^4} \frac{\frac{1}{n-1} \sum_{i=1}^{n} \left(x_i - \bar{x}\right)^2}{\frac{1}{n-1} \sum_{i=1}^{n} \left(y_i - \bar{y}\right)^2} \\
&= \frac{c_{xy}^2}{s_x^4} \frac{s_x^2}{s_y^2} \\
&= \frac{c_{xy}^2}{s_x^2 s_y^2} \\
&= \left(\frac{c_{xy}}{s_x s_y}\right)^2 \\
&= r_{xy}^2.
\end{aligned} \tag{35.28}$$

□

Man beachte, dass mit $-1 \leq r_{xy} \leq 1$ aus Theorem 35.3 direkt folgt, dass $0 \leq \text{R}^2 \leq 1$. Nach Definition 35.4 gilt $\text{R}^2 = 0$ genau dann, wenn $\text{SQE} = 0$ ist. $\text{R}^2 = 0$ bedeutet also, dass die erklärte Datenvariabilität durch die Ausgleichsgerade gleich Null ist und beschreibt damit den Fall einer denkbar schlechten Datenerklärung durch die Ausgleichsgerade. Andererseits gilt $\text{R}^2 = 1$ genau dann, wenn $\text{SQE} = \text{SQT}$ ist. $\text{R}^2 = 1$ bedeutet also, dass die Gesamtstreuung gleich der durch die Ausgleichsgerade erklärten Streuung ist und beschreibt den Fall, dass sämtliche Datenvariabilität durch die Ausgleichsgerade erklärt werden kann. Man sagt deshalb auch oft etwas ungenau, dass R^2 die durch die Ausgleichsgerade erklärte Varianz an der Gesamtvarianz der Daten repräsentiert. Neben der jeweiligen Stichprobenkorrelation ist in Abbildung 35.2 auch jeweils das Bestimmtheitsmaß für die bivariaten Beispieldatensätze aufgeführt.

35.3. Korrelation und linear-affine Abhängigkeit

Die Tatsache, dass stochastische Unabhängigkeit zwar Unkorreliertheit impliziert, dass umgekehrt die Unkorreliertheit zweier Zufallsvariablen aber nicht ihre stochatische Unabhängigkeit impliziert, deutet daraufhin, dass die Korrelation zweier Zufallsvariablen nur

bestimmte Formen der Abhängigkeit zwischen Variablen misst. Abbildung 2.4 verdeutlicht dies anhand dreier Simulationsbeispiele.

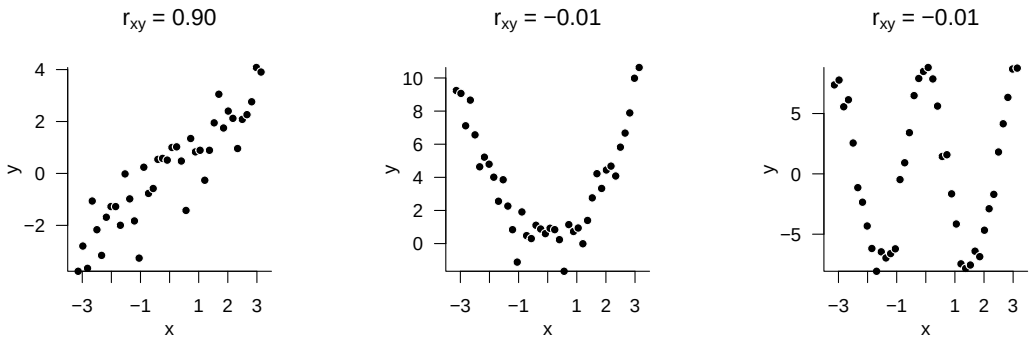


Abbildung 35.4. Korrelation und Abhängigkeit.

Abbildung 35.4 A zeigt eine Realisation des Modells

$$y_i = x_i + \varepsilon_i \text{ mit } \varepsilon_i \sim N(0,1) \text{ für } i = 1, ..., n. \tag{35.29}$$

Die Stichprobenkorrelationen des Datensatzes $\{(x_i, y_i)\}_{i=1}^n$ ergibt sich hier zu $r_{xy} = 0.90$. Es besteht eine klare Abhängigkeit des Wertes der y_i Realisation y_i vom Wert x_i: je höher der Wert von x_i, desto höher der Erwartungswert für den Wert von y_i. Abbildung 35.4 B zeigt eine Realisation des Modells

$$y_i = x_i^2 + \varepsilon_i \text{ mit } \varepsilon_i \sim N(0,1) \text{ für } i = 1, ..., n. \tag{35.30}$$

Die Stichprobenkorrelationen des Datensatzes $\{(x_i, y_i)\}_{i=1}^n$ ergibt sich hier zu $r_{xy} = -0.01$. Die Stichprobenkorrelation ist also minimal. Es besteht aber auch hier eine klare Abhängigkeit des Wertes der y_i Realisation y_i vom Wert x_i : je höher oder je niedriger der Wert von x_i, desto höher der Erwartungswert für den Wert von y_i, es besteht ein quadratischer Zusammenhang. Ein ähnliches Bild ergibt sich beim Betrachten von Abbildung 35.4 C einer Realisation des Modells

$$y_i = 8\cos(2x_i) + \varepsilon_i \text{ mit } \varepsilon_i \sim N(0,1) \text{ für } i = 1, ..., n. \tag{35.31}$$

Auch hier ergibt sich das Bild einer Abhängigkeit des Wertes der y_i Realisation y_i vom Wert x_i, in diesem Fall im Sinne einer zyklischen Abhängigkeit, die Stichprobenkorrelation ist aber mit $r_{xy} = -0.01$ wiederum minimal. Diese Simulationsbeispiele belegen also intuitiv, dass die Stichprobenkorrelation verschwindend gering sein kann, auch wenn klare Abhängigkeiten zwischen zwei Variablen bestehen. Als allgemeines Maß für die Abhängigkeit zweier Variablen ist die Korrelation also ungeeignet. Diesen Umstand zugrunde liegt die Tatsache, dass die Korrelation lediglich ein Maß für den linear-affinen Zusammenhang zweier Zufallsvariablen, nicht aber für ihre stochastische Abhängigkeit ist. Wir formalisieren und präzisieren diese Aussage in folgenden Theorem.

Theorem 35.4 (Korrelation und linear-affine Abhängigkeit)**.** *x und y seien zwei Zufallsvariablen mit positiver Varianz. Dann besteht genau dann eine lineare-affine Abhängigkeit der Form*

$$y = \beta_0 + \beta_1 x \text{ mit } \beta_0, \beta_1 \in \mathbb{R} \tag{35.32}$$

zwischen x und y, wenn

$$\rho(x,y) = 1 \text{ oder } \rho(x,y) = -1 \tag{35.33}$$

gilt.

∘

Beweis. Wir beschränken uns auf den Beweis der Aussage, dass aus $y = \beta_0 + \beta_1 x$ folgt, dass $\rho(x,y) = \pm 1$ ist. Dazu halten wir zunächst fest, dass mit den Theoremen zu den Eigenschaften von Erwartungswert und Varianz gilt, dass

$$\mathbb{E}(y) = \beta_0 + \beta_1 \mathbb{E}(x) \text{ und } \mathbb{V}(y) = \beta_1^2 \mathbb{V}(x) \tag{35.34}$$

Wegen $\mathbb{V}(x) > 0$ und $\mathbb{V}(y) > 0$ gilt damit $\beta_1 \neq 0$. Es folgt dann

$$\beta_1 > 0 \Rightarrow \mathbb{S}(y) = \beta_1 \mathbb{S}(x) > 0 \text{ und } \beta_1 < 0 \Rightarrow \mathbb{S}(y) = -\beta_1 \mathbb{S}(x) > 0. \tag{35.35}$$

Weiterhin gilt

$$\begin{aligned} y - \mathbb{E}(y) &= \beta_0 + \beta_1 x - \mathbb{E}(y) \\ &= \beta_0 + \beta_1 x - \beta_0 - \beta_1 \mathbb{E}(x) \\ &= \beta_1 x - \beta_1 \mathbb{E}(x) \\ &= \beta_1 (x - \mathbb{E}(x)). \end{aligned} \tag{35.36}$$

Für die Kovarianz von x und y ergibt sich also

$$\begin{aligned} \mathbb{C}(x,y) &= \mathbb{E}((y - \mathbb{E}(y))(x - \mathbb{E}(x))) \\ &= \mathbb{E}\left(\beta_1 (x - \mathbb{E}(x))(x - \mathbb{E}(x))\right) \\ &= \beta_1 \mathbb{E}\left((x - \mathbb{E}(x))^2\right) \\ &= \beta_1 \mathbb{V}(x). \end{aligned} \tag{35.37}$$

Damit ergibt für die Korrelation von x und y

$$\rho(x,y) = \frac{\mathbb{C}(x,y)}{\mathbb{S}(x)\mathbb{S}(y)} = \pm \frac{\beta_1 \mathbb{V}(x)}{\mathbb{S}(x)\beta_1 \mathbb{S}(x)} = \pm \frac{\beta_1 \mathbb{V}(x)}{\beta_1 \mathbb{V}(x)} = \pm 1 \tag{35.38}$$

□

Die Korrelation zweier Zufallsvariablen wird also genau dann maximal, wenn zwischen den beiden Zufallsvariablen ein linear-affiner Zusammenhang besteht. Dabei impliziert die linear-affine Abhängigkeit von y von x auch immer die linear-affine Abhängigkeit von x von y, denn

$$y = \beta_0 + \beta_1 x \Leftrightarrow -\beta_0 + y = \beta_1 x \Leftrightarrow x = -\frac{\beta_0}{\beta_1} + \frac{1}{\beta_1} y \Leftrightarrow x = \tilde{\beta}_0 + \tilde{\beta}_1 y \tag{35.39}$$

mit

$$\tilde{\beta}_0 = -\frac{\beta_0}{\beta_1} \text{ und } \tilde{\beta}_1 = \frac{1}{\beta_1}. \tag{35.40}$$

35.4. Literaturhinweise

Der Begriff der Korrelation erscheint, allerdings basierend auf früheren Arbeiten zum Beispiel von Bravais (1844), zunächst bei Galton (1890) (vgl. Stigler (1986)) und wird unter anderem durch die Arbeiten von Pearson (1895), Pearson (1896), Pearson (1900), Pearson (1901) im Kontext multivariater Normalverteilungen weiter ausgearbeitet. Eine frühe Studie zum Verhältnis von Korrelation und Kausalität ist Wright (1921).

36. Modellformulierung

36.1. Allgemeine Theorie

Wir definieren das Allgemeine Lineare Modell (ALM) wie folgt.

Definition 36.1 (Allgemeines Lineares Modell)**.** Es sei

$$y = X\beta + \varepsilon \tag{36.1}$$

wobei

- y ein n-dimensionaler beobachtbarer Zufallsvektor ist, der *Daten* genannt wird,
- $X \in \mathbb{R}^{n\times p}$ für $n > p$ und $\mathrm{rg}(X) = p$ eine Matrix ist, die *Designmatrix* genannt wird,
- $\beta \in \mathbb{R}^p$ ein unbekannter Parametervektor ist, der *Betaparametervektor* genannt wird,
- ε ein n-dimensionaler nicht-beobachtbarer Zufallsvektor ist, der *Zufallsfehler* genannt wird und für den angenommen wird, dass mit einem unbekannten Varianzparameter $\sigma^2 > 0$ gilt, dass
$$\varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \tag{36.2}$$

Dann heißt Gleichung 36.1 *Allgemeines Lineares Modell (ALM).*

•

In Gleichung 36.1 bezeichnen wir $X\beta \in \mathbb{R}^n$ als den *deterministischen Aspekt* des ALMs und ε als den *probabilistischen Aspekt* des ALMs. Das ALM postuliert also, dass Daten aus der Addition eines deterministischen Aspektes $X\beta \in \mathbb{R}^n$ unter der Addition eines multivariat normalverteilten probabilistischen Aspektes ε zustande kommen. Man beachte, dass $X\beta \in \mathbb{R}^n$ ein n-dimensionaler Vektor und ε ein n-dimensionaler Zufallsvektor ist. Der resultierende Vektor y ist ein Zufallsvektor, weil er aus der Addition des Zufallsvektors ε zu dem Vektor $X\beta \in \mathbb{R}^n$ resultiert. Das ALM ist also ein probabilitisches Modell bei dem durch y vorliegende Datensätze modelliert werden. Generativ betrachtet entsteht im ALM ein Datensatz $y \in \mathbb{R}^n$ als Realisierung von y dann durch Addition des deterministischen Modellaspekts und einer nicht direkt beobachtbaren Realisierung $e \in \mathbb{R}^n$ von ε,

$$y = X\beta + e \tag{36.3}$$

mit $y \in \mathbb{R}^n, X\beta \in \mathbb{R}^n$ und $e \in \mathbb{R}^n$.

Die Gesamtzahl an Parametern des ALMs beträt $p + 1$, bestehend aus p skalaren Betaparametern und einem Varianzparameter σ^2. Der Betaparametervektor $\beta \in \mathbb{R}^p$ wird dabei auch Gewichtsvektor oder Effektvektor genannt. Seine Einträge wichten die Einträge der Spalten der Designmatrix $X \in \mathbb{R}^{n\times p}$ in der Erzeugung des deterministischen Modellaspekts $X\beta \in \mathbb{R}^n$. Die Spalten der Designmatrix werden in unterschiedlichen Kontexten

unterschiedlich bezeichnet, gebräuchliche Bezeichungen sind zum Beispiel Prädiktoren, Regressoren oder Kovariaten. Allgemein betrachtet modellieren die Spalten der Designmatrix unabhängige Variablen und der Datenvektor abhängige Variablen.

Man beachte, dass der Kovarianzmatrixparameter von ε als sphärisch angenommen wird. Damit folgt direkt, dass die $\varepsilon_1, \dots, \varepsilon_n$ unabhängige normalverteilte Zufallsvariablen mit identischem Varianzparameter sind. Weil für ε zusätzlich der Erwartungswertparameter als $0_n \in \mathbb{R}^n$ angenommen wird, sind die $\varepsilon_1, \dots, \varepsilon_n$ auch identisch normalverteilte Zufallsvariablen. Wenn $x_{ij} \in \mathbb{R}$ das ijte Element der Designmatrix $X \in \mathbb{R}^{n \times p}$ bezeichnet, dann gilt damit für jede Komponente $y_i, i = 1, \dots, n$ von y nach Gleichung 36.1, dass

$$y_i = x_{i1}\beta_1 + x_{i2}\beta_2 + \dots + x_{ip}\beta_p + \varepsilon_i \text{ mit } \varepsilon_1, \dots, \varepsilon_n \sim N\left(0, \sigma^2\right). \tag{36.4}$$

Die in Gleichung 36.1 implizite Verteilung des Datenvektors y halten wir in folgendem Theorem fest.

Theorem 36.1 (Datenverteilung des Allgemeinen Linearen Modells)**.** *Es sei*

$$y = X\beta + \varepsilon \text{ mit } \varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \tag{36.5}$$

das ALM. Dann gilt

$$y \sim N\left(\mu, \sigma^2 I_n\right) \text{ mit } \mu := X\beta \in \mathbb{R}^n \tag{36.6}$$

∘

Beweis. Mit dem Theorem zur linear-affinen Transformation von multivariaten Normalverteilungen gilt für

$$\varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \text{ und } y := I_n\varepsilon + X\beta, \tag{36.7}$$

dass

$$y \sim N\left(I_n 0_n + X\beta, I_n\left(\sigma^2 I_n\right) I_n^T\right) = N\left(X\beta, \sigma^2 I_n\right). \tag{36.8}$$

Mit der Definition $\mu := X\beta \in \mathbb{R}^n$ folgt die Aussage des Theorems dann direkt. □

Im ALM sind die Daten y also ein n-dimensionaler normalverteilter Zufallsvektor mit Erwartungswertparameter $\mu = X\beta \in \mathbb{R}^n$ und Kovarianzmatrixparameter $\sigma^2 I_n \in \mathbb{R}^{n \times n}$. Das ALM ist also eine multivariate Normalverteilung deren Erwartungswertparameter mithilfe einer Designmatrix und eines Betaparametervektors parameterisiert ist. Weiterhin sind die Komponenten $y_1, \dots, y_n$ von y, also die Zufallsvariablen, die skalare Datenpunkte modellieren, damit unabhängige normalverteilte Zufallsvariablen der Form

$$y_i \sim N\left((X\beta)_i, \sigma^2\right) \text{ für } i = 1, \dots, n. \tag{36.9}$$

Da im Allgemeinen aber $(X\beta)_i \neq (X\beta)_j$ für $i \neq j$ gilt, sind die $y_i, i = 1, \dots, n$ im Allgemeinen aber nicht identisch verteilt. Das Szenario unabhängig und identisch normalverteilter Zufallsvariablen kann aber natürlich als Spezialfall des ALMs formuliert werden.

Beispiel 36.1 (Unabhängige und identisch normalverteilte Zufallsvariablen)**.** Wir betrachten das Szenario von n unabhängigen und identisch normalverteilten Zufallsvariablen mit Erwartungswertparameter $\mu \in \mathbb{R}$ und Varianzparameter σ^2,

$$y_1, \dots, y_n \sim N\left(\mu, \sigma^2\right). \tag{36.10}$$

Dann gilt, dass Gleichung 36.10 äquivalent ist zu

$$y_i = \mu + \varepsilon_i, \varepsilon_i \sim N\left(0, \sigma^2\right) \text{ für } i = 1, \dots, n \text{ mit unabhängigen } \varepsilon_i. \tag{36.11}$$

In Matrixschreibweise ist dies wiederum äquivalent zu dem ALM Spezialfall

$$y \sim N\left(X\beta, \sigma^2 I_n\right) \text{ mit } X := 1_n \in \mathbb{R}^{n\times 1}, \beta := \mu \in \mathbb{R}^1, \sigma^2 > 0. \tag{36.12}$$

In **R** können Realisierungen des ALMs leicht mithilfe eines Zufallszahlengenerators für multivariate Normalverteilungen durch Spezifikation der entsprechenden Erwartungs- und Kovarianzparameter gewonnen werden. Folgender **R** Code zeigt, wie n unabhängig und identisch normalverteilte skalare Datenpunkte im Sinne des ALMs realisiert werden können. Man beachte, dass n skalare Datenpunkte dabei einer Realisierung des ALMs entsprechen.

```
# Modellformulierung
library(MASS)                                   # Multivariate Normalverteilung
set.seed(0)                                     # Zufallzahlengeneratorseed
n      = 12                                     # Anzahl von Datenpunkten
p      = 1                                      # Anzahl von Betaparametern
X      = matrix(rep(1,n), nrow = n)             # Designmatrix
I_n    = diag(n)                                # n x n Einheitsmatrix
beta   = 2                                      # wahrer, aber unbekannter, Betaparameter
sigsqr = 1                                      # wahrer, aber unbekannter, Varianzparameter

# Datenrealisierung
y      = mvrnorm(1, X %*% beta, sigsqr*I_n)     # eine Realisierung eines n-dimensionalen ZVs
```

```
Realisierungen:  1.2 2.76 4.4 1.99 1.71 1.07 0.46 2.41 3.27 3.33 1.67 3.26
```

△

Beispiel 36.2 (Einfache lineare Regression)**.** Wir betrachten das generative Modell der einfachen linearen Regression

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \varepsilon_i \sim N\left(0, \sigma^2\right) \text{ für } i = 1, \ldots, n, \tag{36.13}$$

Wir haben bereits gesehen, dass dieses Modell äquivalent ist zu dem Normalverteilungsmodell der Regression

$$y_i \sim N\left(\mu_i, \sigma^2\right) \text{ mit } \mu_i := \beta_0 + \beta_1 x_i \text{ für } i = 1, \ldots, n. \tag{36.14}$$

In Matrixschreibweise ist dies wiederum äquivalent zu dem ALM Spezialfall

$$y \sim N\left(X\beta, \sigma^2 I_n\right) \text{ mit } X := \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} \in \mathbb{R}^{n\times 2}, \beta := \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} \in \mathbb{R}^2, \sigma^2 > 0. \tag{36.15}$$

R Code zur Simulation von Realisierungen einer einfachen linearen Regression hat dementsprechend eine sehr ähnliche Struktur wie obiger **R** Code zur Simulation von Realisierungen von n unabhängig und identisch normalverteilten Zufallsvariablen.

```
# Modellformulierung
library(MASS)                                   # Multivariate Normalverteilung
set.seed(0)                                     # Zufallzahlengeneratorseed
n      = 10                                     # Anzahl von Datenpunkten
p      = 2                                      # Anzahl von Betaparametern
x      = 1:n                                    # Prädiktorwerte
X      = matrix(c(rep(1,n),x), nrow = n)        # Designmatrix
I_n    = diag(n)                                # n x n Einheitsmatrix
beta   = matrix(c(0,1), nrow = p)               # wahrer, aber unbekannter, Betaparameter
sigsqr = 1                                      # wahrer, aber unbekannter, Varianzparameter

# Datenrealisierung
y      = mvrnorm(1, X %*% beta, sigsqr*I_n)     # eine Realisierung eines n-dimensionalen ZVs
```

```
Realisierungen:  3.4 1.99 2.71 3.07 3.46 6.41 8.27 9.33 8.67 11.26
```

Wir visualisieren obige Realisierung in Abbildung 36.1.

△

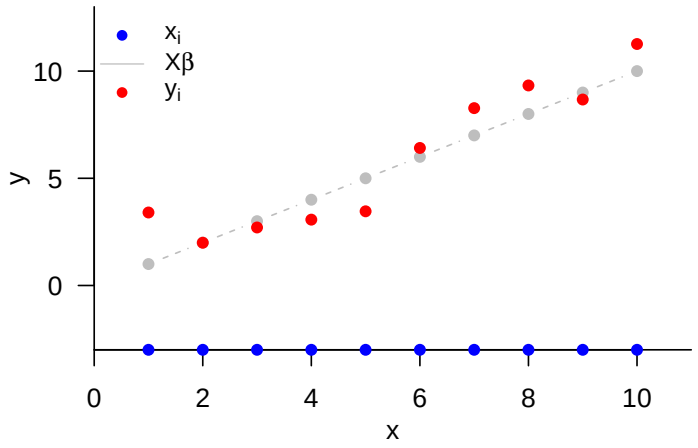


Abbildung 36.1. Realisierung einer einfachen linearen Regression.

36.2. Identifizierbarkeit und Schätzbarkeit

Wir haben oben gesehen, dass die Datenverteilung des ALM durch

$$y \sim N\left(\mu, \sigma^2 I_n\right) \text{ mit } \mu := X\beta \in \mathbb{R}^n \text{ für } X \in \mathbb{R}^{n \times p}, \beta \in \mathbb{R}^p \tag{36.16}$$

gegeben ist. Das ALM ist also eine multivariate Normalverteilung mit einer speziellen Erwartungswertparameterisierung. Um die Begriffe der Identifizierbarkeit und Schätzbarkeit im Kontext von ALMs einzuführen ist es hilfreich den Begriff der *Parametrisierung einer multivariaten Normalverteilung* zunächst etwas zu verallgemeinern.

Definition 36.2 (Betaparameterisieruhg)**.** $N\left(\mu, \sigma^2 I_n\right)$ sei eine multivariate Normalverteilung mit sphärischem Kovarianzmatrixparameter. Dann bezeichnen wir eine multivariate, vektorwertige Funktion der Form

$$f : \mathbb{R}^p \to \mathbb{R}^n, \beta \mapsto f(\beta) =: \mu \tag{36.17}$$

als eine Betaparametrisierung von μ.

•

Das ALM beruht offenbar auf der Designmatrix-abhängigen Betaparametrisierung

$$f : \mathbb{R}^p \to \mathbb{R}^n, \beta \mapsto f(\beta) := X\beta. \tag{36.18}$$

Mit Hilfe des Begriffs der Betaparametrisierung können wir nun den Begriff der *Betaparameteridentifizierbarkeit* formulieren:

Definition 36.3 (Betaparameteridentifizierbarkeit). $N\left(\mu, \sigma^2 I_n\right)$ sei eine multivariate Normalverteilung mit sphärischem Kovarianzmatrixparameter und f sei eine Betaparametrisierung von μ. β heißt dann und nur dann identifizierbar, wenn für beliebige $\beta_1, \beta_2 \in \mathbb{R}^p$ gilt, dass aus $f\left(\beta_1\right) = f\left(\beta_2\right)$ folgt, dass $\beta_1 = \beta_2$ gilt.

•

Die Betaparameter allgemeiner linearer Modelle, deren Designmatrix vollen Rang hat, sind identifizierbar. Dies ist die Aussage folgenden Theorems:

Theorem 36.2 (Betaparameteridentifizierbarkeit bei vollem Designmatrixrang). *$y \sim N\left(X\beta, \sigma^2 I_n\right)$ sei die Datenverteilung eines ALMs mit $rg(X) = p$. Dann ist β identifizierbar.*

∘

Beweis. Für $X \in \mathbb{R}^{n \times p}$ impliziert $\text{rg}(X) = p$, dass $\left(X^T X\right) \in \mathbb{R}^{p \times p}$ eine invertierbare Matrix ist. Dann aber gilt für beliebige $\beta_1, \beta_2 \in \mathbb{R}^p$

$$\begin{aligned} f\left(\beta_1\right) = f\left(\beta_2\right) &\Leftrightarrow X\beta_1 = X\beta_2 \\ &\Leftrightarrow X^T X\beta_1 = X^T X\beta_2 \\ &\Leftrightarrow \left(X^T X\right)^{-1} X^T X\beta_1 = \left(X^T X\right)^{-1} X^T X\beta_2 \\ &\Leftrightarrow \beta_1 = \beta_2. \end{aligned} \tag{36.19}$$

□

Im Rahmen der Analyse schätzbarer Funktionen benötigen wir weiterhin den Begriff der Identifizierbarkeit von vektorwertigen Funktionen der Betaparameter. Wir definieren:

Definition 36.4 (Identifizierbarkeit von Funktionenen der Betaparameter). $N\left(\mu, \sigma^2 I_n\right)$ sei eine multivariate Normalverteilung mit sphärischem Kovarianzmatrixparameter und f sei eine Betaparametrisierung von μ. Weiterhin sei

$$g : \mathbb{R}^p \to \mathbb{R}^k, \beta \mapsto g(\beta) \tag{36.20}$$

eine Funktion des Betaparametervektors. g heißt dann und nur dann identifizierbar, wenn für beliebige $f\left(\beta_1\right), f\left(\beta_2\right) \in \mathbb{R}^n$ gilt, dass aus $f\left(\beta_1\right) = f\left(\beta_2\right)$ folgt, dass $g\left(\beta_1\right) = g\left(\beta_2\right)$.

•

Schätzbare Funktionen sind lineare Funktionen von β, die identifizierbar sind. Allgemein gilt folgendes Theorem:

Theorem 36.3 (Identifizierbare Betaparameterfunktionen). *$N\left(\mu, \sigma^2 I_n\right)$ sei eine multivariate Normalverteilung mit sphärischem Kovarianzmatrixparameter und f sei eine Betaparametrisierung von μ. Weiterhin sei*

$$g : \mathbb{R}^p \to \mathbb{R}^k, \beta \mapsto g(\beta) \tag{36.21}$$

eine Funktion des Betaparametervektors. Die Funktion g ist dann und nur dann identifizierbar, wenn g eine Funktion von f ist, wenn also eine Funktion ϕ existiert, so dass

$$g = \phi \circ f \tag{36.22}$$

∘

Beweis. Wir zeigen die Aussage lediglich in eine Richtung. ⇒ Wir nehmen an, es existiert eine Funktion ϕ, so dass

$$g = \phi \circ f. \tag{36.23}$$

Dann impliziert die Tatsache, dass eine Funktion einem Argument genau einen Funktionswert zuordnet, dass gilt

$$f(\beta_1) = f(\beta_2) \Leftrightarrow \phi(f(\beta_1)) = \phi(f(\beta_2)) \Leftrightarrow g(\beta_1) = g(\beta_2) \tag{36.24}$$

Also ist g identifizierbar, denn aus $f(\beta_1) = f(\beta_2)$ folgt, dass $g(\beta_1) = g(\beta_2)$. □

Wie oben bereits erwähnt sind schätzbare Funktionen lineare Funktionen von β, die identifizierbar sind. Die klassische Definition einer schätzbaren Funktion ist folgende.

Definition 36.5 (Schätzbare Funktion)**.** $N(X\beta, \sigma^2 I_n)$ sei ein ALM. Dann heißt eine lineare Funktion

$$g : \mathbb{R}^p \to \mathbb{R}^k, \beta \mapsto g(\beta) := C^T\beta \tag{36.25}$$

mit $C \in \mathbb{R}^{p\times k}$ schätzbar, wenn eine Matrix $P \in \mathbb{R}^{n\times k}$ existiert, so dass

$$C^T\beta = P^T X\beta. \tag{36.26}$$

•

Diese Definition erschließt sich wie folgt: Nach dem Theorem zu identifizierbaren Funktionen muss eine identifizierbare lineare Funktion von β eine Funktion der Form

$$g(\beta) = (\phi \circ f)(\beta) \tag{36.27}$$

sein. Da weiterhin gilt, dass für ein ALM $f(\beta) = X\beta$ und dass g eine lineare Funktion ist, also mithilfe einer Matrix C^T geschrieben werden kann, muss auch ϕ eine lineare Funktion sein. Damit kann aber auch ϕ geschrieben werden als

$$\phi(f(\beta)) = \phi(X\beta) = P^T X\beta \tag{36.28}$$

mit einer geeigneten Matrix $P \in \mathbb{R}^{n\times k}$.

36.3. Designspektrum

Die Wahl von Designmatrix und Betaparameter öffnet eine große Freiheit zur Implementation verschiedenster Erwartungswertparameterszenarien der ALM Datenverteilung. Prinzipiell liegen dabei alle speziellen Designs in einem Kontinuum zwischen folgenden beiden Extrema:

(1) Die Erwartungswerte aller Datenvariablen sind identisch, d.h.

$$y_i \sim N(\mu, \sigma^2) \text{ u.i.v. für } i = 1, \dots, n \tag{36.29}$$

also

$$y = X\beta + \varepsilon \text{ mit } X := 1_n \in \mathbb{R}^{n\times 1}, \beta := \mu \in \mathbb{R}, \varepsilon \sim N(0_n, \sigma^2 I_n). \tag{36.30}$$

(2) Die Erwartungswerte aller Datenvariablen sind paarweise verschieden, d.h.

$$y_i \sim N\left(\mu_i, \sigma^2\right) \text{ u.v. für } i = 1, \dots, n, \tag{36.31}$$

also

$$y = X\beta + \varepsilon \text{ mit } X := I_n \in \mathbb{R}^{n \times n}, \beta := \left(\mu_1, \dots, \mu_n\right)^T \in \mathbb{R}^n, \varepsilon \sim N\left(0_n, \sigma^2 I_n\right). \tag{36.32}$$

In Szenario (1) wird jegliche Datenvariabilität dem Zufallsfehlerterm zugeschrieben, in Szenario (2) wird dagegen jegliche Datenvariabilität dem Erwartungswertparameter zugeschrieben. Beide Extremszenarien sind wissenschaftlich nicht ergiebig, da sie keine theoriegeleitete systematische Abhängigkeit zwischen unabhängigen und abhängigen Variablen repräsentieren. Alle im weiteren Verlauf betrachteten ALM Designs liegen damit zwischen den beiden Extremszenarien und repräsentieren verschiedene Formen der systematischen Abhängigkeit zwischen unabhängigen und abhängigen Variablen. Insbesondere unterscheidet man

(1) *Faktorielle Designs*, bei denen die Designmatrix im Wesentlichen nur 1en und 0en und manchmal -1en enthält. In diesem Fall repräsentieren die Betaparameter Gruppenerwartungswerte und wir werden sehen, dass die Betaparameterschätzer in der Repräsentationen von Gruppenstichprobenmitteln resultieren. Man sagt manchmal, dass faktorielle Designs der Untersuchung von *Unterschiedshypothesen* dienen. Beispiele für faktorielle Designs sind verschiedene Designs zur Implementation von T-*Tests* und *Varianzanalysen*.
(2) *Parameterische Designs*, bei denen die Designmatrix aus Spalten mit kontinuierlichen reellen Werten besteht. Vor allem in diesem Kontext werden die Spalten der Designmatrix oft als *Regressoren* oder *Prädiktoren* bezeichnet. In diesem Fall repräsentieren die Betaparameter partielle Steigungsparameter und wir werden sehen, dass sich die entsprechenden Betaparameterschätzer als normalisierte Regressor-Daten Kovarianzen ergeben. Man sagt manchmal, dass parametrische Designs zur Untersuchung von *Zusammenhangshypothesen* dienen. Beispiele für parametrische Designs sind verschiedene Designs zur Implementation von *einfacher linearer Regression* und insbesondere *multipler linearer Regression*.
(3) *Faktoriell-parametrische Designs*, bei denen die Spalten der Designmatrix sowohl faktorielle als auch parametrische Prädiktoren repräsentieren. In diesem Kontext werden die parametrischen Regressoren oft als *Kovariaten* betrachtet. Gemischt faktoriell-parametrische Designs sind das zentrale Charakteristikum der *Kovarianzanalyse* die auf eine kontrollierte Untersuchung von Unterschiedshypothesen bei Vorliegen weiterer möglicher Abhängigkeiten zwischen unabhängigen und abhängigen Variablen bzw. auf die kontrollierte Untersuchung von Zusammenhangshypothesen bei Vorliegen weiterer möglicher Gruppenunterschiede abzielt.

36.4. Literaturhinweise

Das Allgemeine Lineare Modell hat eine lange Geschichte, deren moderne Inkarnation üblicherweise auf die Arbeiten von Legendre (1805) und Gauss (1809) zurückgeführt wird. Matrixbasierte Formulierungen der multiplen Regression finden sich spätestens bei Aitken (1936) und Scheffé (1959). Eingang in den psychologischen Methodenkanon findet das Allgemeine Lineare Modell spätestens mit Cohen (1968). Seal (1967) gibt einen ausführlichen

Überblick zur Geschichte des Allgemeinen Linearen Modells im 19. und der ersten Hälfte des 20. Jahrhunderts. Die in diesem Abschnitt gegebene Diskussion von Identifizierbarkeit und Schätzbarkeit beruht auf der Darstellung in Christensen (2011).

37. Parameterschätzung

In diesem Abschnitt betrachten wir die Frequentistische Punktschätzung von Betaparametervektor und Varianzparameter im ALM. Als Beispielanwendungen betrachten wir das Szenario n unabhängig und identisch normalverteilter Zufallsvariablen und das Szenario der einfachen linearen Regression. Wir schließen mit der Dokumentation der Frequentistischen Parameterschätzerverteilungen des ALMs.

37.1. Betaparameterschätzung

Wir fassen die Frequentistische Punktschätzung des Betaparametervektors in folgendem Theorem zusammen.

Theorem 37.1 (Betaparameterschätzer)**.** *Es sei*

$$y = X\beta + \varepsilon \text{ mit } \varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \tag{37.1}$$

das Allgemeine Lineare Modell und es sei

$$\hat{\beta} := \left(X^T X\right)^{-1} X^T y. \tag{37.2}$$

Dann gelten:

(1) $\hat{\beta}$ ist der KQ-Schätzer von $\beta \in \mathbb{R}^p$, für einen beliebigen festen Wert $y \in \mathbb{R}^n$ von y gilt also

$$\hat{\beta} = \text{argmin}_{\tilde{\beta}}(y - X\tilde{\beta})^T(y - X\tilde{\beta}). \tag{37.3}$$

(2) $\hat{\beta}$ ist ein unverzerrter Maximum-Likelihood-Schätzer von $\beta \in \mathbb{R}^p$.

∘

Beweis. (1) Wir zeigen in einem ersten Schritt, dass $\hat{\beta}$ ein KQ-Schätzer ist, dass also $\hat{\beta}$ für einen beliebigen festen Wert $y \in \mathbb{R}^n$ von y die Summe der Abweichungsquadrate

$$(y - X\tilde{\beta})^T(y - X\tilde{\beta}) = \sum_{i=1}^{n} \left(y_i - (X\tilde{\beta})_i\right)^2 \tag{37.4}$$

minimiert (die Notation $\tilde{\beta}$ für das Minimierungsargument dient hier lediglich dazu, es vom wahrem, aber unbekannten, Parameterwert $\beta \in \mathbb{R}^p$ abzugrenzen und ist ansonsten ohne Bedeutung). Dazu halten wir zunächst fest, dass

$$\hat{\beta} = \left(X^T X\right)^{-1} X^T y \Leftrightarrow X^T X\hat{\beta} = X^T y \Leftrightarrow X^T y - X^T X\hat{\beta} = 0_p \Leftrightarrow X^T(y - X\hat{\beta}) = 0_p. \tag{37.5}$$

Weiterhin gilt dann auch, dass

$$X^T(y - X\hat{\beta}) = 0_p \Leftrightarrow \left(X^T(y - X\hat{\beta})\right)^T = 0_p^T \Leftrightarrow (y - X\hat{\beta})^T X = 0_p^T \tag{37.6}$$

Weiterhin halten wir ohne Beweis fest, dass für jede Matrix $X \in \mathbb{R}^{n \times p}$ gilt, dass

$$z^T X^T X z \geq 0 \text{ für alle } z \in \mathbb{R}^p. \tag{37.7}$$

Wir betrachten nun für festes y und ein beliebiges $\tilde{\beta}$ die Summe der Abweichungsquadrate

$$(y - X\tilde{\beta})^T (y - X\tilde{\beta}) \tag{37.8}$$

Es ergibt sich

$$\begin{aligned}
&(y - X\tilde{\beta})^T (y - X\tilde{\beta}) \\
&= (y - X\hat{\beta} + X\hat{\beta} - X\tilde{\beta})^T (y - X\hat{\beta} + X\hat{\beta} - X\tilde{\beta}) \\
&= ((y - X\hat{\beta}) + X(\hat{\beta} - \tilde{\beta}))^T ((y - X\hat{\beta}) + X(\hat{\beta} - \tilde{\beta})) \\
&= (y - X\hat{\beta})^T (y - X\hat{\beta}) + (y - X\hat{\beta})^T X(\hat{\beta} - \tilde{\beta}) + (\hat{\beta} - \tilde{\beta})^T X^T (y - X\hat{\beta}) + (\hat{\beta} - \tilde{\beta})^T X^T X(\hat{\beta} - \tilde{\beta}) \\
&= (y - X\hat{\beta})^T (y - X\hat{\beta}) 0_p^T (\hat{\beta} - \tilde{\beta}) + (\hat{\beta} - \tilde{\beta})^T 0_p + (\hat{\beta} - \tilde{\beta})^T X^T X(\hat{\beta} - \tilde{\beta}) \\
&= (y - X\hat{\beta})^T (y - X\hat{\beta}) + (\hat{\beta} - \tilde{\beta})^T X^T X(\hat{\beta} - \tilde{\beta})
\end{aligned} \tag{37.9}$$

Auf der rechten Seite obiger Gleichung ist nur der zweite Term von $\tilde{\beta}$ abhängig. Da für diesen Term gilt, dass

$$(\hat{\beta} - \tilde{\beta})^T X^T X(\hat{\beta} - \tilde{\beta}) \geq 0 \tag{37.10}$$

nimmt dieser Term genau dann seinen Minimalwert 0 an, wenn

$$(\hat{\beta} - \tilde{\beta}) = 0_p \Leftrightarrow \tilde{\beta} = \hat{\beta} \tag{37.11}$$

Also gilt

$$\hat{\beta} = \text{argmin}_{\tilde{\beta}} (y - X\tilde{\beta})^T (y - X\tilde{\beta}). \tag{37.12}$$

(2) Um zu zeigen, dass $\hat{\beta}$ ein Maximum-Likelihood-Schätzer ist, betrachten wir für einen beliebigen Wert $y \in \mathbb{R}^n$ von y und festes $\sigma^2 > 0$ die Log-Likelihood-Funktion

$$\ell : \mathbb{R}^p \to \mathbb{R}, \tilde{\beta} \mapsto \ln p_{\tilde{\beta}}(v) = \ln N\left(y; X\tilde{\beta}, \sigma^2 I_n\right) \tag{37.13}$$

wobei gilt, dass

$$\begin{aligned}
\ln N\left(y; X\tilde{\beta}, \sigma^2 I_n\right) &= \ln\left((2\pi)^{-\frac{n}{2}} \left|\sigma^2 I_n\right|^{-\frac{1}{2}} \exp\left(-\frac{1}{2\sigma^2}(y - X\tilde{\beta})^T (y - X\tilde{\beta})\right)\right) \\
&= -\frac{n}{2} \ln 2\pi - \frac{1}{2} \ln\left|\sigma^2 I_n\right| - \frac{1}{2\sigma^2}(y - X\tilde{\beta})^T (y - X\tilde{\beta})
\end{aligned} \tag{37.14}$$

Dabei hängt allein der Term $-\frac{1}{2\sigma^2}(y - X\tilde{\beta})^T (y - X\tilde{\beta})$ von $\tilde{\beta}$ ab. Weil aber $(y - X\tilde{\beta})^T (y - X\tilde{\beta}) \geq 0$ gilt, wird dieser Term aufgrund des negativen Vorzeichens maximal, wenn $(y - X\tilde{\beta})^T (y - X\tilde{\beta})$ minimal wird. Dies ist aber wie oben gezeigt genau für $\tilde{\beta} = \hat{\beta}$ der Fall. Die Unverzerrtheit von $\hat{\beta}$ schließlich ergibt sich aus

$$\mathbb{E}(\hat{\beta}) = \mathbb{E}\left(\left(X^T X\right)^{-1} X^T y\right) = \left(X^T X\right)^{-1} X^T \mathbb{E}(v) = \left(X^T X\right)^{-1} X^T X\beta = \beta. \tag{37.15}$$

□

Theorem 37.1 gibt mit

$$\hat{\beta} = \left(X^T X\right)^{-1} X^T y \tag{37.16}$$

eine Formel an, um β anhand der Designmatrix und einer Realisierung $y \in \mathbb{R}^n$ von y konkret zu schätzen. Als Zufallsvektor ist $\hat{\beta}$ ist ein unverzerrter Schätzer von β und als Maximum-Likelihood-Schätzer insbesondere auch konsistent, asymptotisch normalverteilt und asymptotisch effizient. Wir sehen an späterer Stelle, dass $\hat{\beta}$ sogar normalverteilt ist. Neben den genannten Eigenschaften hat $\hat{\beta}$ noch weitere gute Eigenschaften. Zum Beispiel besitzt $\hat{\beta}$ die kleinste Varianz in der Klasse der linearen unverzerrten Schätzer von β. Diese Eigenschaft ist Kernaussage des *Gauss-Markov-Theorems*, auf das wir hier aber nicht näher eingehen wollen.

Mithilfe des Betaparameterschätzers können wir die Begriffe der erklärten Daten, des Residuenvektors und der Residuen definieren, die wir an vielen Stellen benötigen werden.

Definition 37.1 (Erklärte Daten, Residuenvektor und Residuen)**.** Es sei

$$y = X\beta + \varepsilon \,\text{mit}\, \varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \tag{37.17}$$

das Allgemeine Lineare Modell und es sei

$$\hat{\beta} := \left(X^T X\right)^{-1} X^T y. \tag{37.18}$$

der Betaparameterschätzer. Dann heißt der Zufallsvektor

$$\hat{y} := X\hat{\beta} = X\left(X^T X\right)^{-1} X^T y \tag{37.19}$$

die *erklärten Daten*, der Zufallsvektor

$$\hat{\varepsilon} := y - \hat{y} = y - X\hat{\beta} \tag{37.20}$$

heißt *Residuenvektor* und für $i = 1, \ldots, n$ heißen die Komponenten dieses Zufallsvektors

$$\hat{\varepsilon}_i := y_i - \hat{y}_i = y_i - (X\hat{\beta})_i \tag{37.21}$$

die *Residuen*.

•

37.2. Varianzparameterschätzung

Wir fassen die Frequentistische Punktschätzung des Varianzparameters in folgendem Theorem zusammen, das wir an dieser Stelle nicht beweisen wollen.

Theorem 37.2 (Varianzparameterschätzer)**.** *Es sei*

$$y = X\beta + \varepsilon \;\; \textit{mit}\; \varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \tag{37.22}$$

das Allgemeine Lineare Modell. Dann ist

$$\hat{\sigma}^2 := \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n - p} \tag{37.23}$$

ein unverzerrter Schätzer von $\sigma^2 > 0$.

∘

Theorem 37.2 gibt mit

$$\hat{\sigma}^2 = \frac{(y - X\hat{\beta})^T (y - X\hat{\beta})}{n - p} \tag{37.24}$$

eine Formel an, um σ^2 anhand der Designmatrix, des Betaparameterschätzers und einer Realisierung $y \in \mathbb{R}^n$ von y zu schätzen. Offenbar gilt mit Theorem 37.2, dass

$$\hat{\sigma}^2 = \frac{1}{n - p} \sum_{i=1}^{n} \left(y_i - (X\hat{\beta})_i\right)^2 \tag{37.25}$$

$\hat{\sigma}^2$ wird also durch die Summe der quadrierten Residuen, also als eine Summe von Abweichungsquadraten geschätzt. Für einen Beweis von Theorem 37.2 verweisen wir zum Beispiel auf S. R. Searle (1971), S. R. Searle & Gruber (2017) oder Rencher & Schaalje (2008). Aus probabilistischer Perspektive handelt es sich bei $\hat{\sigma}^2$ nicht um einen Maximum-Likelihood-Schätzer, sondern um einen Restricted Maximum-Likelihood-Schätzer von σ^2 (vgl. Harville (1977), Foulley (1993), Starke & Ostwald (2017)). Aus geometrischer Perspektive handelt es sich bei $\hat{\sigma}^2$ um einen KQ-Schätzer (vgl. Christensen (2011)).

37.3. Unabhängig identisch normalverteilte Zufallsvariablen

Als erste Anwendung von Theorem 37.1 und Theorem 37.2 analysieren wir das Szenario von n unabhängigen und identisch normalverteilten Zufallsvariablen mit Erwartungswertparameter $\mu \in \mathbb{R}$ und Varianzparameter σ^2,

$$y_i \sim N\left(\mu, \sigma^2\right) \text{ für } i = 1, \dots, n. \tag{37.26}$$

Schreibt man dieses Modell in seiner Designmatrixform (vgl. Gleichung 36.10) dann gilt, wie unten gezeigt,

$$\hat{\beta} = \frac{1}{n}\sum_{i=1}^{n} y_i =: \bar{y} \text{ und } \hat{\sigma}^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(y_i - \bar{y}\right)^2 =: s_y^2 \tag{37.27}$$

In diesem Fall ist also der Betaparameterschätzer mit dem Stichprobenmittel $\bar{y}$ der $y_1, \dots, y_n$ und der Varianzparameterschätzer mit der Stichprobenvarianz s_y^2 der $y_1, \dots, y_n$ identisch.

Gleichung 37.27 ergibt sich wie folgt. Zum einen gilt

$$\begin{aligned}
\hat{\beta} &= \left(X^T X\right)^{-1} X^T y \\
&= \left(1_n^T 1_n\right)^{-1} 1_n^T v \\
&\left(1 \quad \cdots \quad 1\right) \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}^{-1} \left(1 \quad \cdots \quad 1\right) \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} \\
&= n^{-1} \sum_{i=1}^{n} y_i \\
&= \frac{1}{n} \sum_{i=1}^{n} y_i \\
&=: \bar{y}.
\end{aligned} \tag{37.28}$$

Zum anderen gilt

$$\begin{aligned}
\hat{\sigma}^2 &= \frac{1}{n-1}(y - X\hat{\beta})^T (y - X\hat{\beta}) \\
&= \frac{1}{n-1}\left(v - 1_n \bar{y}\right)^T \left(v - 1_n \bar{y}\right) \\
&= \frac{1}{n-1}\left(\begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} - \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \bar{y}^T\right)\left(\begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} - \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \bar{y}\right) \\
&= \frac{1}{n-1}\begin{pmatrix} y_1 - \bar{y} & \cdots & y_n - \bar{y} \end{pmatrix} \begin{pmatrix} y_1 - \bar{y} \\ \vdots \\ y_n - \bar{y} \end{pmatrix} \\
&= \frac{1}{n-1}\sum_{i=1}^{n}\left(y_i - \bar{y}\right)^2 \\
&= s_y^2.
\end{aligned} \tag{37.29}$$

Wir demonstrieren die Parameterschätzung in diesem Szenario in folgendem **R** Code.

```
# Modellformulierung
library(MASS)
n          = 12                                    # Multivariate Normalverteilung
p          = 1                                     # Anzahl Datenpunkte
X          = matrix(rep(1,n), nrow = n)            # Anzahl Betaparameter
I_n        = diag(n)                               # Designmatrix
beta       = 2                                     # n x n Einheitsmatrix
sigsqr     = 1                                     # wahrer, aber unbekannter, Betaparameter
                                                   # wahrer, aber unbekannter, Varianzparameter

# Datenrealisierung
y          =  mvrnorm(1, X %*% beta, sigsqr*I_n)   # eine Realisierung eines n-dimensionalen ZVs
```

```
# Parameterschätzung
beta_hat   = solve(t(X) %*% X) %*% t(X) %*% y                    # Betaparameterschätzer
eps_hat    = y - X %*% beta_hat                                  # Residuenvektor
sigsqr_hat = (t(eps_hat) %*% eps_hat) /(n-p)                     # Varianzparameterschätzer
```

```
beta       :  2
hat{beta}  :  2.213135
sigsqr     :  1
hat{sigsqr}:  0.7347729
```

Die Frequentistische Bedeutung der Schätzerunverzerrtheit in diesem Szenario simuliert folgender **R** Code.

```
# Modellformulierung
library(MASS)                                                    # Multivariate Normalverteilung
n          = 12                                                  # Anzahl Datenpunkte
p          = 1                                                   # Anzahl Betaparameter
X          = matrix(rep(1,n), nrow = n)                          # Designmatrix
I_n        = diag(n)                                             # n x n Einheitsmatrix
beta       = 2                                                   # wahrer, aber unbekannter, Betaparameter
sigsqr     = 1                                                   # wahrer, aber unbekannter, Varianzparameter

# Frequentistische Simulation
nsim       = 1e4                                                 # Anzahl Datenrealisierungen
beta_hat   = rep(NaN,nsim)                                       # \hat{\beta} Realisierungsarray
sigsqr_hat = rep(NaN,nsim)                                       # \hat{sigsqr} Realisierungsarray
for(i in 1:nsim){                                                # Simulationsiterationen
  y            = mvrnorm(1, X %*% beta, sigsqr*I_n)              # Datenrealisierung
  beta_hat[i]  = solve(t(X) %*% X) %*% t(X) %*% y                # Betaparameterschätzer
  eps_hat      = y - X %*% beta_hat[i]                           # Residuenvektor
  sigsqr_hat[i] = (t(eps_hat) %*% eps_hat) /(n-p)                # Varianzparameterschätzer
}
```

```
Wahrer, aber unbekannter, Betaparameter                 :  2
Gesch<U+00E4>tzter Erwartungswert des Betaparametersch<U+00E4>tzers    :  2.000018
Wahrer, aber unbekannter, Varianzparameter              :  1
Gesch<U+00E4>tzter Erwartungswert des Varianzparametersch<U+00E4>tzers :  0.9904665
```

37.4. Einfache lineare Regression

Als zweite Anwendung von Theorem 37.1 und Theorem 37.2 analysieren wir das Szenario der einfachen linearen Regression

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i \text{ mit } \varepsilon_i \sim N\left(0, \sigma^2\right) \text{ für } i = 1, \dots, n. \tag{37.30}$$

Basierend auf der Designmatrixform Gleichung 36.15 dieses Modells ergibt sich, wie unten gezeigt,

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix} = \begin{pmatrix} \bar{y} - \frac{c_{xy}}{s_x^2}\bar{x} \\ \frac{c_{xy}}{s_x^2} \end{pmatrix} \text{ und } \hat{\sigma}^2 = \frac{1}{n-2}\sum_{i=1}^{n}\left(y_i - \left(\hat{\beta}_0 + \hat{\beta}_1 x_i\right)\right)^2 \tag{37.31}$$

wobei $\bar{x}$ und $\bar{y}$ die Stichprobenmittel der $x_1, \dots, x_n$ und $y_1, \dots, y_n, c_{xv}$ die Stichprobenkovarianz der $x_1, \dots, x_n$ und $y_1, \dots, y_n$ und s_x^2 die Stichprobenvarianz der $x_1, \dots, x_n$ bezeichnen. Wie in Kapitel 1 sind die Bezeichnungen Stichprobenkovarianz und Stichprobenvarianz bezüglich der $x_1, \dots, x_n$ hier lediglich formal gemeint, da keine Annahme zugrundeliegt, dass die $x_1, \dots, x_n$ Realisierungen von Zufallsvariablen sind.

Wir halten also fest, dass für eine parametrische Designmatrixspalte sich der entsprechende Betaparameterschätzer aus der Stichprobenkovarianz der respektiven Spalte mit den Daten geteilt durch die Stichprobenvarianz der entsprechenden Spalte ergibt und somit einer standardisierten Stichprobenkovarianz entspricht. Ein Vergleich mit den Parametern der

Ausgleichsgerade in Kapitel 34 zeigt weiterhin die Identität der Betaparameterschätzerkomponenten $\hat{\beta}_0$ und $\hat{\beta}_1$ mit den dort unter dem Kriterium der Minimierung der quadrierten vertikalen Abweichungen hergeleiteten Parametern. Dies überrascht nicht, da sowohl $\hat{\beta}$ als auch die Parameter der Ausgleichsgerade bei festem Wert $y \in \mathbb{R}^n$ von y den Wert

$$q(\tilde{\beta}) = \sum_{i=1}^{n} \left(y_i - \left(\tilde{\beta}_0 + \tilde{\beta}_1 x_i\right)\right)^2 = (y - X\tilde{\beta})^T (y - X\tilde{\beta}) \tag{37.32}$$

hinsichtlich $\tilde{\beta}$ minimieren.

Um die Form des Betaparameterschätzers in Gleichung 37.31 herzuleiten, halten wir zunächst fest, dass

$$\begin{aligned}
\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^{n} (x_i y_i - x_i \bar{y} - \bar{x} y_i + \bar{x}\bar{y}) \\
&= \sum_{i=1}^{n} x_i y_i - \sum_{i=1}^{n} x_i \bar{y} - \sum_{i=1}^{n} \bar{x} y_i + \sum_{i=1}^{n} \bar{x}\bar{y} \\
&= \sum_{i=1}^{n} x_i y_i - \bar{y} \sum_{i=1}^{n} x_i - \bar{x} \sum_{i=1}^{n} y_i + n\bar{x}\bar{y} \\
&= \sum_{i=1}^{n} x_i y_i - \bar{y} n \bar{x} - \bar{x} n \bar{y} + n\bar{x}\bar{y} \\
&= \sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y} - n\bar{x}\bar{y} + n\bar{x}\bar{y} \\
&= \sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}
\end{aligned} \tag{37.33}$$

Weiterhin halten wir fest, dass

$$\begin{aligned}
\sum_{i=1}^{n} (x_i - \bar{x})^2 &= \sum_{i=1}^{n} (x_i^2 - 2x_i\bar{x} + \bar{x}^2) \\
&= \sum_{i=1}^{n} x_i^2 - \sum_{i=1}^{n} 2x_i\bar{x} + \sum_{i=1}^{n} \bar{x}^2 \\
&= \sum_{i=1}^{n} x_i^2 - 2\bar{x} \sum_{i=1}^{n} x_i + n\bar{x}^2 \\
&= \sum_{i=1}^{n} x_i^2 - 2\bar{x} n \bar{x} + n\bar{x}^2 \\
&= \sum_{i=1}^{n} x_i^2 - 2n\bar{x}^2 + n\bar{x}^2 \\
&= \sum_{i=1}^{n} x_i^2 - n\bar{x}^2.
\end{aligned} \tag{37.34}$$

Aus der Definition von $\hat{\beta}$ ergibt sich

$$\begin{aligned}
\hat{\beta} &= (X^T X)^{-1} X^T y \\
&= \left(\begin{pmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_n \end{pmatrix} \begin{pmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} \right)^{-1} \begin{pmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_n \end{pmatrix} \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} \\
&= \begin{pmatrix} n & \sum_{i=1}^{n} x_i \\ \sum_{i=1}^{n} x_i & \sum_{i=1}^{n} x_i^2 \end{pmatrix} \begin{pmatrix} \sum_{i=1}^{n} y_i \\ \sum_{i=1}^{n} x_i y_i \end{pmatrix} \\
&= \begin{pmatrix} n & n\bar{x} \\ n\bar{x} & \sum_{i=1}^{n} x_i^2 \end{pmatrix}^{-1} \begin{pmatrix} n\bar{y} \\ \sum_{i=1}^{n} x_i y_i \end{pmatrix}
\end{aligned} \tag{37.35}$$

Die Inverse von $X^T X$ ist gegeben durch

$$\frac{1}{s_x^2} \begin{pmatrix} \frac{s_x^2}{n} + \bar{x}^2 & -\bar{x} \\ -\bar{x} & 1 \end{pmatrix}, \tag{37.36}$$

weil

$$
\begin{aligned}
&\frac{1}{s_x^2}\begin{pmatrix} \frac{s_x^2}{n} + \bar{x}^2 & -\bar{x} \\ -\bar{x} & 1 \end{pmatrix}\begin{pmatrix} n & n\bar{x} \\ n\bar{x} & \sum_{i=1}^n x_i^2 \end{pmatrix} \\
&= \frac{1}{s_x^2}\begin{pmatrix} \frac{ns_x^2}{n} + n\bar{x}^2 - n\bar{x}^2 & \frac{s_x^2 n\bar{x}}{n} + n\bar{x}^2\bar{x} - \bar{x}\sum_{i=1}^n x_i^2 \\ -\bar{x}n + n\bar{x} & -n\bar{x}^2 + \sum_{i=1}^n x_i^2 \end{pmatrix} \\
&= \frac{1}{s_x^2}\begin{pmatrix} s_x^2 & s_x^2\bar{x} - \bar{x}\left(\sum_{i=1}^n x_i^2 - n\bar{x}^2\right) \\ 0 & \sum_{i=1}^n x_i^2 - n\bar{x}^2 \end{pmatrix} \\
&= \frac{1}{s_x^2}\begin{pmatrix} s_x^2 & s_x^2\bar{x} - \bar{x}s_x^2 \\ 0 & s_x^2 \end{pmatrix} \\
&= \frac{1}{s_x^2}\begin{pmatrix} s_x^2 & 0 \\ 0 & s_x^2 \end{pmatrix} \\
&= \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}.
\end{aligned} \tag{37.37}
$$

Es ergibt sich also

$$
\begin{aligned}
\hat{\beta} = \begin{pmatrix} \frac{1}{n} + \frac{\bar{x}^2}{s_x^2} & -\frac{\bar{x}}{s_x^2} \\ -\frac{\bar{x}}{s_x^2} & \frac{1}{s_x^2} \end{pmatrix}\begin{pmatrix} n\bar{y} \\ \sum_{i=1}^n x_i y_i \end{pmatrix} &= \begin{pmatrix} \left(\frac{1}{n} + \frac{\bar{x}^2}{s_x^2}\right) n\bar{y} - \frac{\bar{x}\sum_{i=1}^n x_i y_i}{s_x^2} \\ \frac{\sum_{i=1}^n x_i y_i}{s_x^2} - \frac{n\bar{x}\bar{y}}{s_x^2} \end{pmatrix} \\
&= \begin{pmatrix} \frac{n\bar{y}}{n} + \frac{\bar{x}^2 n\bar{y}}{s_x^2} - \frac{\bar{x}\sum_{i=1}^n x_i y_i}{s_x^2} \\ \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{s_x^2} \end{pmatrix} \\
&= \begin{pmatrix} \bar{y} + \frac{\bar{x}n\bar{x}\bar{y} - \bar{x}\sum_{i=1}^n x_i y_i}{s_x^2} \\ \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{s_x^2} \end{pmatrix} \\
&= \begin{pmatrix} \bar{y} - \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{s_x^2}\bar{x} \\ \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{s_x^2} \end{pmatrix} \\
&= \begin{pmatrix} \bar{y} - \frac{c_{xy}}{s_x^2}\bar{x} \\ \frac{c_{xy}}{s_x^2} \end{pmatrix}.
\end{aligned} \tag{37.38}
$$

Wir demonstrieren die Parameterschätzung in diesem Szenario in folgendem **R** Code. Man beachte die weitgehende Übereinstimmung mit der Implementation der Parameterschätzung im Szenario der unabhängig und identisch normalverteilten Zufallsvariablen - lediglich die Designmatrix und die Dimension des Betaparameters ändern sich.

```
# Modellformulierung
library(MASS)                                                  # Multivariate Normalverteilung
n          = 10                                                # Anzahl Datenpunkte
p          = 2                                                 # Anzahl Betaparameter
x          = 1:n                                               # Prädiktorwerte
X          = matrix(c(rep(1,n),x), nrow = n)                   # Designmatrix
I_n        = diag(n)                                           # n x n Einheitsmatrix
beta       = matrix(c(0,1), nrow = p)                          # wahrer, aber unbekannter, Betaparameter
sigsqr     = 1                                                 # wahrer, aber unbekannter, Varianzparameter

# Datenrealisierung
y          = mvrnorm(1, X %*% beta, sigsqr*I_n)                # eine Realisierung eines n-dimensionalen ZVs

# Parameterschätzung
beta_hat   = solve(t(X) %*% X) %*% t(X) %*% y                  # Betaparameterschätzer
eps_hat    = y - X %*% beta_hat                                # Residuenvektor
sigsqr_hat = (t(eps_hat) %*% eps_hat) /(n-p)                   # Varianzparameterschätzer
```

```
beta       :  0 1
hat{beta}  :  0.408796 0.9173959
sigsqr     :  1
hat{sigsqr}:  0.9521951
```

Analog zum Szenario der unabhängig und identisch normalverteilten Zufallsvariablen kann auch hier die Frequentistische Bedeutung der Schätzerunverzerrtheit simuliert werden.

```r
# Modellformulierung
library(MASS)
n          = 10                                          # Multivariate Normalverteilung
p          = 2                                           # Anzahl Datenpunkte
x          = 1:n                                         # Anzahl Betaparameter
X          = matrix(c(rep(1,n),x), nrow = n)             # Prädiktorwerte
I_n        = diag(n)                                     # Designmatrix
beta       = matrix(c(0,1), nrow = p)                    # n x n Einheitsmatrix
sigsqr     = 1                                           # wahrer, aber unbekannter, Betaparameter
                                                         # wahrer, aber unbekannter, Varianzparameter
# Frequentistische Simulation
nsim       = 1e4                                         # Anzahl Realisierungen des n-dimensionalen ZVs
beta_hat   = matrix(rep(NaN,p*nsim), nrow = p)           # \hat{\beta} Realisierungsarray
sigsqr_hat = rep(NaN,nsim)                               # \hat{sigsqr} Realisierungsarray
for(i in 1:nsim){                                        # Simulationsiterationen
  y             = mvrnorm(1, X %*% beta, sigsqr*I_n)     # Datenrealisierung
  beta_hat[,i]  = solve(t(X) %*% X) %*% t(X) %*% y       # Betaparameterschätzer
  eps_hat       = y - X %*% beta_hat[,i]                 # Residuenvektor
  sigsqr_hat[i] = (t(eps_hat) %*% eps_hat) /(n-p)        # Varianzparameterschätzer
}
```

```
Wahrer, aber unbekannter, Betaparameter                 :  0 1
Gesch<U+00E4>tzter Erwartungswert des Betaparametersch<U+00E4>tzers    :  -0.00478494 1.000763
Wahrer, aber unbekannter, Varianzparameter              :  1
Gesch<U+00E4>tzter Erwartungswert des Varianzparametersch<U+00E4>tzers :  1.004918
```

37.5. Frequentistische Schätzerverteilungen

Wir dokumentieren die Frequentistische Verteilung des Betaparameterschätzers in folgendem Theorem.

Theorem 37.3 (Frequentistische Verteilung des Betaparameterschätzers.)**.** *Es sei*

$$y = X\beta + \varepsilon \text{ mit } \varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \tag{37.39}$$

das ALM. Weiterhin sei

$$\hat{\beta} := \left(X^T X\right)^{-1} X^T y \tag{37.40}$$

der Betaparameterschätzer. Dann gilt

$$\hat{\beta} \sim N\left(\beta, \sigma^2 \left(X^T X\right)^{-1}\right). \tag{37.41}$$

∘

Beweis. Das Theorem folgt direkt mit dem Theorem zur linearen Transformation von multivariaten Normalverteilungen. Speziell gilt hier:

$$\hat{\beta} \sim N\left(\left(X^T X\right)^{-1} X^T X\beta, \left(X^T X\right)^{-1} X^T \left(\sigma^2 I_n\right) \left(\left(X^T X\right)^{-1} X^T\right)^T\right). \tag{37.42}$$

Der Erwartungswertparameter vereinfacht sich dann zu

$$\left(X^T X\right)^{-1} X^T X\beta = \beta. \tag{37.43}$$

Der Kovarianzmatrixparamter vereinfacht sich wie folgt:

$$\begin{aligned}\left(X^T X\right)^{-1} X^T \left(\sigma^2 I_n\right) \left(\left(X^T X\right)^{-1} X^T\right)^T &= \left(X^T X\right)^{-1} X^T \left(\sigma^2 I_n\right) X \left(X^T X\right)^{-1} \\ &= \sigma^2 \left(X^T X\right)^{-1} X^T X \left(X^T X\right)^{-1} \\ &= \sigma^2 \left(X^T X\right)^{-1}\end{aligned} \tag{37.44}$$

Dabei hier die erste Gleichung aus der Tatsache, dass sowohl $X^T X$ als auch ihre Inverse $\left(X^T X\right)^{-1}$ symmetrische Matrizen sind. Damit folgt dann aber sofort

$$\hat{\beta} \sim N\left(\beta, \sigma^2 \left(X^T X\right)^{-1}\right). \tag{37.45}$$

□

Mit Theorem 6.3 folgt also inbesondere auch für den Erwartungswert und die Kovarianzmatrix des Betaparameterschätzers, dass

$$\mathbb{E}(\hat{\beta}) = \beta \text{ und } \mathbb{C}(\hat{\beta}) = \sigma^2 \left(X^T X\right)^{-1} \tag{37.46}$$

Als Diagonalelemente von $\mathbb{C}(\hat{\beta})$ hängen die Varianzen der Betaparameterschätzerkomponenten also sowohl vom Varianzparameter der Fehlervariablen als auch von der Designmatrix ab. Insbesondere bei festem, wahren, aber unbekannten $\sigma^2 > 0$ kann also die Designmatrix so gewält werden, dass die Varianz der Betaparameterschätzerkomponenten minimiert wird.

Die Frequentistische Verteilung des Varianzparameterschätzers dokumentieren wir in folgendem Theorem, welches wir an dieser Stelle nicht beweisen wollen.

Theorem 37.4 (Frequentistische Verteilung des Varianzparameterschätzers)**.** *Es sei*

$$y = X\beta + \varepsilon \text{ mit } \varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \tag{37.47}$$

das ALM. Weiterhin sei

$$\hat{\sigma}^2 = \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n-p} \tag{37.48}$$

der Varianzparameterschätzer. Dann gilt

$$\frac{n-p}{\sigma^2}\hat{\sigma}^2 \sim \chi^2(n-p). \tag{37.49}$$

∘

Da es sich bei $(n-p)\hat{\sigma}^2$ um eine Summe normalverteilter Zufallsvariablen handelt, liegt die χ^2-Verteilung im Lichte der χ^2-Transformation bei normalverteilten Zufallsvariablen zumindest nahe. Allerdings ist $\hat{\sigma}^2$ selbst nicht χ^2 verteilt, sondern lediglich seine durch Multiplikation mit $\frac{n-p}{\sigma^2}$ skalierte Version. Wir wollen die Frequentistischen Schätzerverteilungen aus Theorem 37.3 und Theorem 37.4 noch an den beiden Standardbeispielen verdeutlichen.

Beispiel 37.1 (Verteilung des Stichprobenmittels)**.** Es sei

$$y \sim N\left(X\beta, \sigma^2 I_n\right) \text{ mit } X := 1_n \in \mathbb{R}^{n\times 1}, \beta := \mu \in \mathbb{R} \text{ und } \sigma^2 > 0 \tag{37.50}$$

das ALM Szenario unabhängiger und identisch normalverteilter Zufallsvariablen bei bekannter Varianz. Wir haben bereits gesehen, dass in diesem Fall $\hat{\beta}$ mit dem Stichprobenmittel $\bar{y}$ identisch ist. Theorem 37.3 impliziert dann mit

$$\left(X^T X\right)^{-1} = \left(1_n^T 1_n\right)^{-1} = \frac{1}{n}, \tag{37.51}$$

dass

$$\bar{y} \sim N\left(\mu, \frac{\sigma^2}{n}\right). \tag{37.52}$$

Das Stichprobenmittel von n unabhängigen und identisch normalverteilten Zufallsvariablen mit Erwartungswertparameter μ und Varianzparameter σ^2 ist also normalverteilt mit Erwartungswertparameter μ und Varianzparameter σ^2/n. Wir haben diese Tatsache bereits im Kontext der Transformationen der Normalverteilungen unter dem Begriff der Mittelwertstransformation gesehen.

△

Beispiel 37.2 (Betaparameterschätzerverteilung bei einfacher linearer Regression)**.** Es sei

$$y \sim N\left(X\beta, \sigma^2 I_n\right) \text{ mit } \begin{pmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} \in \mathbb{R}^{n\times 2}, \beta \in \mathbb{R}^2 \text{ und } \sigma^2 > 0 \tag{37.53}$$

das Szenario der einfachen linearen Regression. Wir haben bereits gesehen, dass

$$\sigma^2 \left(X^T X\right)^{-1} = \frac{\sigma^2}{s_{xx}} \begin{pmatrix} \frac{s_{xx}}{n} + \bar{x}^2 & -\bar{x} \\ -\bar{x} & 1 \end{pmatrix} \text{ mit } s_{xx} := \sum_{i=1}^{n} \left(x_i - \bar{x}\right)^2 \tag{37.54}$$

Die Varianz des Offsetparameterschätzers hängt damit sowohl von der Summe der quadrierten Differenzen der Werte der unabhängigen Variable von ihrem Stichprobenmittel und dem Stichprobenmittel der Werte der unabhängigen Variable selbst ab. Die Varianz des Steigungsparameterschätzers hängt dagegen nur von der Summe der quadrierten Differenzen der unabhängigen Variable von ihrem Stichprobenmittel ab. Die Kovarianz von Offset- und Steigungsparameterschätzern schließlich hängt vom Mittelwert der Werte der unabhängigen Variable ab. Folgender **R** Code simuliert die frequentistischen Verteilungen von Beta- und Varianzparameterschätzern im Szenario der einfachen linearen Regression.

```
# Modellformulierung
library(MASS)
n         = 10                                  # Multivariate Normalverteilung
p         = 2                                   # Anzahl von Datenpunkten
x         = 1:n                                 # Anzahl von Betparametern
X         = matrix(c(rep(1,n),x), nrow = n)     # Prädiktorwerte
I_n       = diag(n)                             # Designmatrix
beta      = matrix(c(0,1), nrow = p)            # n x n Einheitsmatrix
sigsqr    = .5                                  # wahrer,aber unbekannter,Betaparameter
                                                # wahrer,aber unbekannter,Varianzparameter

# Frequentistische Simulation
nsim      = 10                                  # Anzahl Realisierungen n-dimensionaler ZV
y         = matrix(rep(NaN,n*nsim), nrow = n)   # y Realisierungsarray
beta_hat = matrix(rep(NaN,p*nsim), nrow = p)    # \hat{\beta} Realisierungsarray
for(i in 1:nsim){
  y[,i]        = mvrnorm(1, X %*% beta, sigsqr*I_n)   # eine Realisierung n-dimensionaler ZV
  beta_hat[,i] = solve(t(X) %*% X) %*% t(X) %*% y[,i] # \hat{\beta} = (X^T)X^{-1}X^Ty
}
```

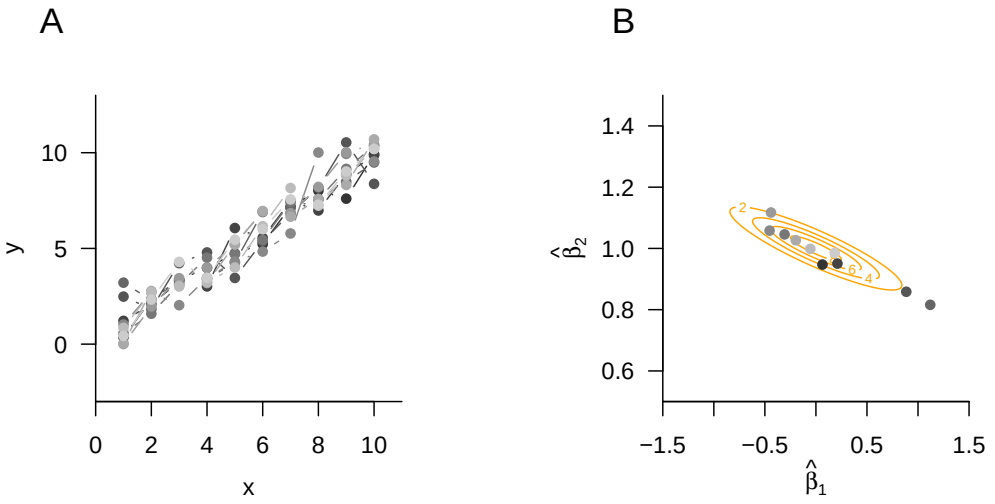


Abbildung 37.1. Frequentistische Betaparameterschätzerverteilung bei einfacher linearer Regression.

Abbildung 37.1 zeigt 10 Realisationen des Modells einer einfachen linearen Regression und Abbildung 37.1 B zeigt die entsprechenden Betaparameterschätzerrealisationen sowie die analytische Verteilung des Betaparameterschätzers.

△

37.6. Literaturhinweise

Plackett (1949) gibt einen historischen Überblick zur Entwicklung der Betaparameterschätzung und insbesondere des Gauss-Markov-Theorems. Das Problem der Varianzparameterschätzung im ALM im Sinne der Restricted-Maximum-Likelihood-Methode erscheint zunächst in Patterson & Thompson (1971) (vgl. Harville (1977)), Verbyla (1990)) und bleibt, in verallgemeinerten ALMs, Gegenstand aktueller Forschung (vgl. Lindholm & Wahl (2020)).

38. T-Statistiken

In diesem Abschnitt führen wir T-Statistiken als Maße zur Evaluation von Betaparameterschätzern im ALM ein. T-Statistiken quantifizieren dabei die geschätzten Effekte des Betaparameterschätzers in Bezug zur durch den Varianzparameterschätzer geschätzten Residualvariabilität. Der Wert einer T-Statistik ist also zunächst einmal einfach als Signal-zu-Rauschen-Verhältnis (Signal-to-Noise Ratio) zu verstehen.

T-Statistiken erlauben weiterhin die Evaluation von Linearkombinationen der Komponenten des Betaparameterschätzers im Sinne Frequentistischer Konfidenzintervalle und Hypothesentests. Wir betrachten hier zunächst nur die funktionale Form von T-Statistiken und ihre Frequentistische Verteilung zum Zwecke der Konfidenzintervallbestimmung. Der Einsatz von T-Teststatistiken im Rahmen von Einstich- und Zweistichproben T-Tests ist das Thema von Kapitel 40.

38.1. Definition und Beispiele

Vor dem Hintergrund des ALMs und seiner Parameterpunktschätzer definieren wir die T-Statistik wie folgt.

Definition 38.1 (T-Statistik)**.** Es sei

$$y = X\beta + \varepsilon \text{ mit } \varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \tag{38.1}$$

das ALM. Weiterhin seien

$$\hat{\beta} := \left(X^T X\right)^{-1} X^T y \text{ und } \hat{\sigma}^2 := \frac{(y - X\hat{\beta})^T (y - X\hat{\beta})}{n - p} \tag{38.2}$$

die Betaparameter- und Varianzparameterschätzer, respektive. Dann ist für einen Kontrastgewichtsvektor $c \in \mathbb{R}^p$ und einen Parameter $\beta_0 \in \mathbb{R}^p$ die T-Statistik definiert als

$$T := \frac{c^T \hat{\beta} - c^T \beta_0}{\sqrt{\hat{\sigma}^2 c^T \left(X^T X\right)^{-1} c}}. \tag{38.3}$$

•

Geeignete Wahlen des Kontrastgewichtsvektors $c \in \mathbb{R}^p$ und des Parameters $\beta_0 \in \mathbb{R}^p$ erlauben eine Vielzahl von Einsatzmöglichkeiten der T-Statistik. Betrachten wir zunächst den Kontrastgewichtsvektor. Offenbar dient der Kontrastgewichtsvektor dazu, den Zufallsvektor $\hat{\beta} \in \mathbb{R}^p$ in die Zufallsvariable $c^T \hat{\beta}$ zu transformieren und sichert damit die Skalarität der T-Statistik. Weiterhin erlaubt die Wahl von p-dimensionalen Einheitsvektoren für den Kontrastgewichtsvektor die Auswahl einzelner Komponenten des Betaparameters zur

Evaluation mithilfe der T-Statistik. Schließlich erlaubt eine generelle Wahl des Kontrastgewichtsvektors die Evaluation beliebiger Linearkombination der Betaparameterkomponenten, wie zum Beispiel Differenzen einzelner Komponenten. Beispielhaft seien für $\hat{\beta} \in \mathbb{R}^2$ hier folgende Möglichkeiten für die Wahl von $c \in \mathbb{R}^2$ hinsichtlich des Skalarproduktes $c^T\hat{\beta}$ aufgeführt:

$$c := \begin{pmatrix}1\\0\end{pmatrix} \Rightarrow c^T\hat{\beta} = \hat{\beta}_1, \quad c := \begin{pmatrix}0\\1\end{pmatrix} \Rightarrow c^T\hat{\beta} = \hat{\beta}_2, \quad c := \begin{pmatrix}1\\-1\end{pmatrix} \Rightarrow c^T\hat{\beta} = \hat{\beta}_1 - \hat{\beta}_2. \tag{38.4}$$

Die Wahl des Parameters $\beta_0 \in \mathbb{R}^p$ eröffnet die Möglichkeit, die T-Statistik unterschiedlich einzusetzen. Wählt man zum Beispiel $\beta_0 := 0_p$, so erhält man mit der T-Statistik eine Deskriptivstatistik, die es erlaubt, geschätzte Regressoreffekte, also Komponenten oder Linearkombinationen von $\hat{\beta}$, im Sinne eines Signal-zu-Rauschen-Verhältnisses in Bezug zu der durch $\hat{\sigma}^2$ quantifizierten Residualdatenvariabilität zu setzen. Der Nenner der T-Statistik stellt dabei sicher, dass insbesondere die adäquate (Ko)Standardabweichung der entsprechenden Betaparameterkomponentenkombination als Bezugsgröße dient, da es sich bei $\hat{\sigma}^2 \left(X^TX\right)^{-1}$ bekanntlich um die Kovarianz des Betaparameterschätzers handelt (vgl. Theorem 37.3).

Wählt man für β_0 dagegen β, also den wahren, aber unbekannten, Betaparameterwert, so eröffnet die T-Statistik die Möglichkeit, für einzelne Komponenten des Betaparametervektors Konfidenzintervalle zu bestimmen. Wir vertiefen diesen Aspekt der T-Statistik in Kapitel 38.2. Deklariert man schließlich β_0 im Kontext eines Testszenarios als das Element einer Nullhypothese, so eröffnet die T-Statistik die hypothesentestbasierte Inferenz über Betaparameterkomponenten und ihrer Linearkombinationen. Anwendungsfälle dieser Art diskutieren wir ausführlich in Kapitel 40.

Die Anwendung der T-Statistik zum Zwecke der Frequentistischen Inferenz im Sinne von Konfidenzintervallen und Hypothesentests basiert dabei natürlich auf der Frequentistischen Verteilung der T-Statistik vor dem Hintergrund des ALMs. Diese ist der zentrale Inhalt folgenden Theorems, auf dessen Beweis wir verzichten.

Theorem 38.1 (Frequentistische Verteilung der T-Statistik)**.** *Es sei*

$$y = X\beta + \varepsilon \text{ mit } \varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \tag{38.5}$$

das ALM. Weiterhin seien

$$\hat{\beta} := \left(X^TX\right)^{-1} X^Ty \text{ und } \hat{\sigma}^2 := \frac{(y - X\hat{\beta})^T(y - X\hat{\beta})}{n-p} \tag{38.6}$$

die Betaparameter- und Varianzparameterschätzer, respektive. Schließlich sei für einen Kontrastgewichtsvektor $c \in \mathbb{R}^p$ und einen Parameter $\beta_0 \in \mathbb{R}^p$

$$T := \frac{c^T\hat{\beta} - c^T\beta_0}{\sqrt{\hat{\sigma}^2 c^T \left(X^TX\right)^{-1} c}} \tag{38.7}$$

die T-Statistik. Dann gilt

$$T \sim t(\delta, n-p) \text{ mit } \delta := \frac{c^T\beta - c^T\beta_0}{\sqrt{\sigma^2 c^T \left(X^TX\right)^{-1} c}}. \tag{38.8}$$

∘

Im Allgemeinen ist die T-Statistik also nichtzentral t-verteilt. Gilt dabei, wie bei der Bestimmung von Konfidenzintervallen (vgl. Kapitel 38.2) $\beta_0 := \beta$ oder gilt in einem Testszenario bei Zutreffen der Nullhypothese $\beta := \beta_0$ (vgl. Kapitel 40), so ist die T-Statistik sogar t-verteilt, jeweils mit Freiheitsgradparameter $n - p$. Gilt in einem Testszenario dagegen, dass die Nullhypothese nicht zutrifft, so kann die Verteilung der T-Statistik aus Theorem 38.1 zur Herleitung der Testgütefunktion und damit zur Bestimmung der Power des Tests genutzt werden (vgl. Kapitel Kapitel 40). Wir werden diese Aspekte an gegebener Stelle vertiefen. An dieser Stelle wollen wir die T-Statistik und ihre Verteilung zunächst nur an den Beispielen der unabhängigen identisch normalverteilten Zufallsvariablen und der einfachen linearen Regression illustrieren.

Beispiel 38.1 (T-Statistik bei unabhängigen normalverteilten Zufallsvariablen)**.** Es sei

$$y \sim N\left(X\beta, \sigma^2 I_n\right) \text{ mit } X := 1_n \in \mathbb{R}^{n\times 1}, \beta := \mu \in \mathbb{R} \text{ und } \sigma^2 > 0 \tag{38.9}$$

das ALM Szenario unabhängiger und identisch normalverteilter Zufallsvariablen und es seien $c := 1$ und $\beta_0 := \mu_0 \in \mathbb{R}$. Dann gilt für die T-Statistik

$$T = \frac{c^T\hat{\beta} - c^T\mu_0}{\sqrt{\hat{\sigma}^2 c^T \left(X^T X\right)^{-1} c}} = \frac{1^T\bar{v} - 1^T\mu_0}{\sqrt{s_v^2 1^T \left(1_n^T 1_n\right)^{-1} 1}} = \sqrt{n}\left(\frac{\bar{v} - \mu_0}{s_v}\right) \tag{38.10}$$

Dies entspricht offenbar der bekannten Einstichproben-T-Teststatistik (vgl. Kapitel 33). Wie diese nimmt die hier betrachtete T-Statistik, bei Konstanz der jeweils komplementären Terme, große absolute Werte für eine große absolute Differenz von $\bar{v} - \mu_0$ (oft als Effekt bezeichnet), sowie für kleine Werte von s_v^2 (also eine geringe Datenvariabilität) und einen großen Wert von n (also einen großen Stichprobenumfang) an. Folgender **R** Code simuliert die Frequentistische Verteilung dieser T-Statistik für die Fälle $\beta = \beta_0$ und $\beta \neq \beta_0$.

```
# Libraries
library(MASS)                                                    # multivariate Normalverteilung

# Modellformulierung
n          = 12                                                  # Anzahl von Datenpunkten
p          = 1                                                   # Anzahl von Betaparametern
X          = matrix(c(rep(1,n)), nrow = n)                       # Designmatrix
I_n        = diag(n)                                             # Einheitsmatrix
beta       = c(0,1)                                              # wahre , aber unbekannte , Betaparameter
nscn       = length(beta)                                        # Anzahl wahrer, aber unbekannter, Hypothesenszenarien
sigsqr     = 1                                                   # wahrer, aber unbekannter, Varianzparameter
c          = 1                                                   # Kontrastvektor von Interessse
beta_0     = 0                                                   # Nullhypothesenbetaparameter

# Frequentistische Simulation
nsim       = 1e4                                                 # Anzahl Simulationen
delta      = rep(NaN, nscn)                                      # Anzahl Nichtzentralitätsparameter
Tee        = matrix(rep(NaN, nscn*nsim), ncol = nscn)            # T-Teststatistik Realisierungsarray
for(s in 1:nscn){                                                # Hypothesenszenarien
  delta[s]    = ((t(c) %*% beta[s] - t(c) %*% beta_0)/           # Nichtzentralitätsparameter
                 sqrt(sigsqr*t(c)%*%solve(t(X)%*%X)%*%c))
  for(i in 1:nsim){                                              # Simulationsiterationen
    y          = mvrnorm(1, X %*% beta[s], sigsqr*I_n)           # y
    beta_hat   = solve(t(X) %*% X) %*% t(X) %*% y                # \hat{\beta}
    eps_hat    = y - X %*% beta_hat                              # \hat{\eps}
    sigsqr_hat = (t(eps_hat) %*% eps_hat)/(n-p)                  # \hat{\sigma}^2
    Tee[i,s]   = ((t(c) %*% beta_hat - t(c) %*% beta_0)/         # T
                   sqrt(sigsqr_hat*t(c)%*%solve(t(X)%*%X)%*%c))
  }
}
```

Abbildung 38.1 A und B zeigen die resultierenden simulierten und analytischen Verteilungen der T-Statistik.

△

Beispiel 38.2 (T-Statistik bei einfacher linearer Regression)**.** In diesem Beispiel wollen wir nicht auf die spezifische Form der T-Statistik eingehen, aber anhand einer Simulation demonstrieren,

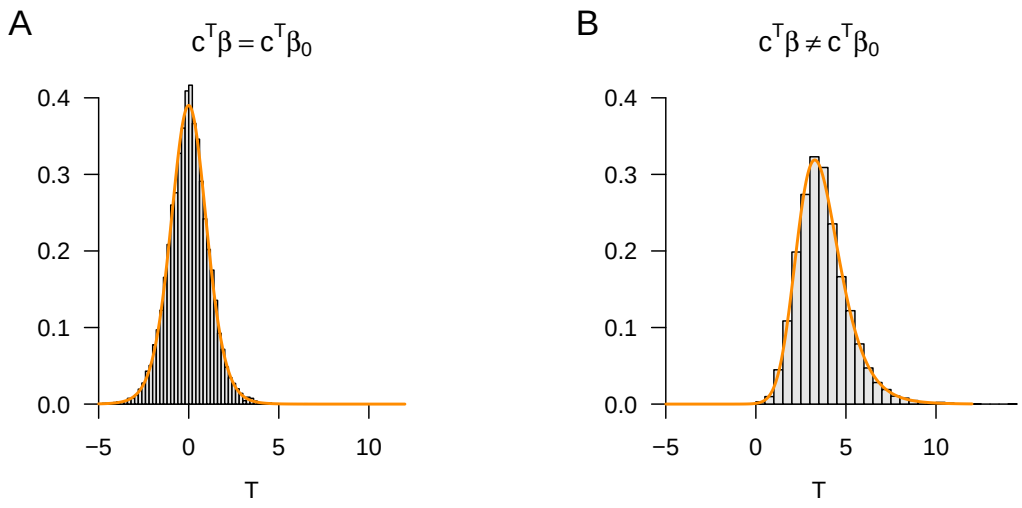


Abbildung 38.1. Verteilungen der T-Statistik bei unabhängig und identisch normalverteilten Zufallsvariablen.

wie sich das Prinzip der T-Statistik im Kontext der einfachen linearen Regression darstellt. Dazu betrachten wir das bekannte Beispielmodell der einfachen linearen Regression (vgl. Kapitel 36), in diesem Fall mit den wahren, aber unbekannten, Parameterwerten $\beta_A := (1, 0)$ und $\beta_B := (1, 1)$. Weiterhin betrachten wir den Kontrastgewichtsvektor $c := (0, 1)$, so dass die T-Statistik zur Evaluation des Steigungsparameters der einfachen linearen Regression genutzt werden kann. Schließlich betrachten wir in beiden Fällen den Parameter $\beta_0 := (0, 0)^T$, so dass im Fall von β_A gilt, dass $c^T\beta = c^T\beta_0$ und im Fall von β_B gilt, dass $c^T\beta \neq c^T\beta_0$. Folgender **R** Code implementiert die skizzierten Szenarien, Abbildung 38.2 A und B zeigen die resultierenden simulierten und analytischen Verteilungen der T-Statistik.

```
# Modellformulierung
library(MASS)
n           = 10                                    # multivariate Normalverteilung
p           = 2                                     # Anzahl von Datenpunkten
x           = 1:n                                   # Anzahl von Betaparametern
X           = matrix(c(rep(1,n),x), ncol = p)       # Prädiktorwerte
I_n         = diag(n)                               # Designmatrix
beta        = matrix(c(1,0,1,1), nrow = 2)          # Einheitsmatrix
nscn        = ncol(beta)                            # wahre, aber unbekannte, Betaparameter
sigsqr      = 1                                     # Anzahl wahrer, aber unbekannter, Hypothesenszenarien
c           = matrix(c(0,1), nrow = 2)              # wahrer, aber unbekannter, Varianzparameter
beta_0      = matrix(c(0,0), nrow = 2)              # Kontrastvektor von Interessse
                                                    # Nullhypothesenbetaparameter

# Frequentistische Simulation
nsim        = 1e4                                   # Anzahl Simulationen
delta       = rep(NaN, nscn)                        # Anzahl Nichtzentralitätsparameter
Tee         = matrix(rep(NaN, nscn*nsim), ncol = nscn) # T-Teststatistik Realisierungsarray
for(s in 1:nscn){                                   # Hypothesenszenarien
  delta[s]    = ((t(c) %*% beta[,s] - t(c) %*% beta_0)/ # Nichtzentralitätsparameter
                 sqrt(sigsqr*t(c)%*%solve(t(X)%*%X)%*%c))
  for(i in 1:nsim){                                 # Simulationsiterationen
    y          = mvrnorm(1, X %*% beta[,s], sigsqr*I_n) # y
    beta_hat   = solve(t(X) %*% X) %*% t(X) %*% y   # \hat{\beta}
    eps_hat    = y - X %*% beta_hat                 # \hat{\eps}
    sigsqr_hat = (t(eps_hat) %*% eps_hat)/(n-p)     # \hat{\sigma}^2
    Tee[i,s]   = ((t(c) %*% beta_hat - t(c) %*% beta_0)/ # T
                   sqrt(sigsqr_hat*t(c)%*%solve(t(X)%*%X)%*%c))
  }
}
```

△

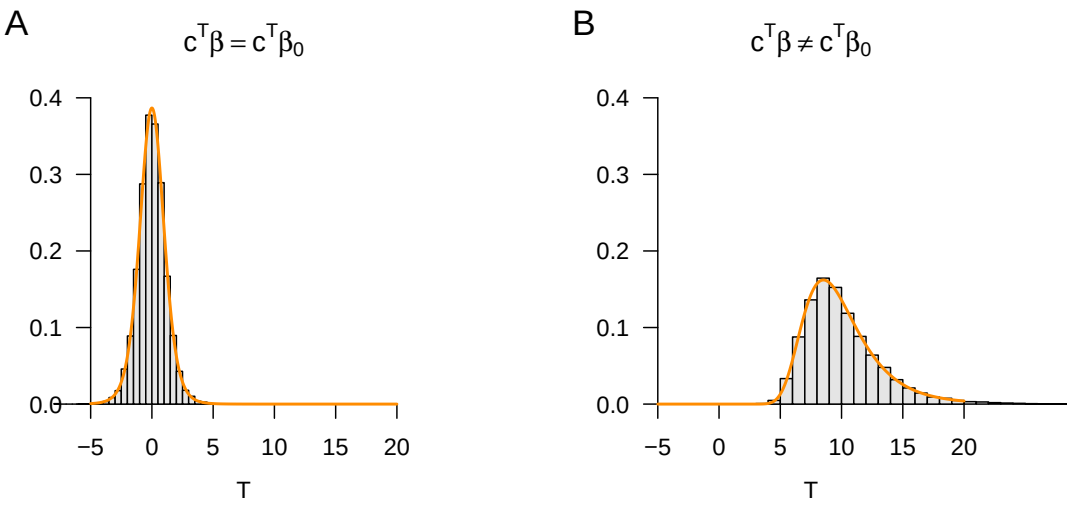


Abbildung 38.2. Verteilungen der T-Statistik bei einfacher linearer Regression.

38.2. Konfidenzintervalle für Betaparameterkomponenten

Mithilfe der T-Statistik können Konfidenzintervalle für die Komponenten des Betaparametervektors bestimmt werden. Das folgende Theorem ist die zentrale Aussage dieses Abschnitts.

Theorem 38.2 (Konfidenzintervalle für Betaparameterkomponenten)**.** *Es sei*

$$y = X\beta + \varepsilon \text{ mit } \varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \tag{38.11}$$

das ALM,

$$\hat{\beta} := \left(X^T X\right)^{-1} X^T y \text{ und } \hat{\sigma}^2 := \frac{(y - X\hat{\beta})^T (y - X\hat{\beta})}{n - p} \tag{38.12}$$

seien die Betaparameter- und Varianzparameterschätzer, respektive und für ein $\delta \in]0, 1[$ *sei*

$$t_\delta := \Psi^{-1}\left(\frac{1+\delta}{2}; n - p\right). \tag{38.13}$$

Schließlich sei für $j = 1, \ldots, p$

$$\lambda_j := \left(\left(X^T X\right)^{-1}\right)_{jj} \text{ das jte Diagonalelement von } \left(X^T X\right)^{-1} \tag{38.14}$$

Dann ist für $j = 1, \ldots, p$

$$\kappa_j := \left[\hat{\beta}_j - \hat{\sigma}\sqrt{\lambda_j} t_\delta, \hat{\beta}_j + \hat{\sigma}\sqrt{\lambda_j} t_\delta\right] \tag{38.15}$$

ein δ*-Konfidenzintervall für die jte Komponente* β_j *des Betaparameters* $\beta = \left(\beta_1, \ldots, \beta_p\right)^T$*.*

∘

Beweis. Wir müssen zeigen, dass

$$\mathbb{P}\left(\kappa_j \ni \beta_j\right) = \delta. \tag{38.16}$$

Dazu halten wir zunächst fest, dass für alle $j = 1, \ldots, p$ bei Wahl von $\beta_0 = \beta$ und $c := e_j$ nach Theorem 38.1 für $T \sim t(\delta, n-p)$ gilt, dass

$$T = \frac{e_j^T \hat{\beta} - e_j^T \beta}{\sqrt{\sigma^2 e_j^T \left(X^T X\right)^{-1} e_j}} = \frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{\sigma}^2 \left(\left(X^T X\right)^{-1}\right)_{jj}}} = \frac{\hat{\beta}_j - \beta_j}{\hat{\sigma}\sqrt{\lambda_j}} =: T_j \tag{38.17}$$

und

$$\delta = \frac{e_j^T \beta - e_j^T \beta}{\sqrt{\sigma^2 e_j^T \left(X^T X\right)^{-1} e_j}} = 0 \tag{38.18}$$

Damit gilt dann auch sofort, dass $T_j \sim t(n-p)$. Weiterhin erinnern wir daran (vgl. Kapitel 32), dass per Definition von t_δ gilt, dass

$$\mathbb{P}\left(-t_\delta \leq T_j \leq t_\delta\right). \tag{38.19}$$

Aus der Definition eines δ-Konfidenzintervalls folgt dann

$$\begin{aligned}
\delta &= \mathbb{P}\left(-t_\delta \leq T_j \leq t_\delta\right) \\
&= \mathbb{P}\left(-t_\delta \leq \frac{\hat{\beta}_j - \beta_j}{\hat{\sigma}\sqrt{\lambda_j}} \leq t_\delta\right) \\
&= \mathbb{P}\left(-t_\delta \hat{\sigma}\sqrt{\lambda_j} \leq \hat{\beta}_j - \beta_j \leq t_\delta \hat{\sigma}\sqrt{\lambda_j}\right) \\
&= \mathbb{P}\left(-\hat{\beta}_j - t_\delta \hat{\sigma}\sqrt{\lambda_j} \leq -\beta_j \leq -\hat{\beta}_j + t_\delta \hat{\sigma}\sqrt{\lambda_j}\right) \\
&= \mathbb{P}\left(\hat{\beta}_j + t_\delta \hat{\sigma}\sqrt{\lambda_j} \geq \beta_j \geq \hat{\beta}_j - t_\delta \hat{\sigma}\sqrt{\lambda_j}\right) \\
&= \mathbb{P}\left(\hat{\beta}_j - t_\delta \hat{\sigma}\sqrt{\lambda_j} \leq \beta_j \leq \hat{\beta}_j + t_\delta \hat{\sigma}\sqrt{\lambda_j}\right) \\
&= \mathbb{P}\left(\left[\hat{\beta}_j - \hat{\sigma}\sqrt{\lambda_j} t_\delta, \hat{\beta}_j + \hat{\sigma}\sqrt{\lambda_j} t_\delta\right] \ni \beta_j\right) \\
&= \mathbb{P}\left(\kappa_j \ni \beta_j\right)
\end{aligned} \tag{38.20}$$

und damit ist alles gezeigt. □

Beispiel 38.3 (Konfidenzintervall bei unabhängigen normalverteilten Zufallsvariablen)**.** Wie gewohnt betrachten wir als erstes Beispiel die ALM Form des Szenarios unabhängig und identisch normalverteilter Zufallsvariablen

$$y \sim N\left(X\beta, \sigma^2 I_n\right) \text{ mit } X := 1_n \in \mathbb{R}^n, \beta := \mu \in \mathbb{R}, \sigma^2 > 0 \tag{38.21}$$

Dann gelten, wie bereits gesehen

$$\hat{\beta} = \frac{1}{n}\sum_{i=1}^{n} v_i =: \bar{v}, \hat{\sigma}^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(v_i - \bar{v}\right)^2 =: s_v^2 \text{ und } \lambda_1 = \left(1_n^T 1_n\right)^{-1} = \frac{1}{n}. \tag{38.22}$$

Nach Theorem 38.2 gilt dann, dass

$$\kappa := \left[\bar{v} - \frac{s}{\sqrt{n}} t_\delta, \bar{v} + \frac{s}{\sqrt{n}} t_\delta\right] \tag{38.23}$$

ein δ-Konfidenzintervall für β ist und dieses ist offenbar identisch mit dem bekannten δ-Konfidenzintervall für den Erwartungsparameter der Normalverteilung.

△

Beispiel 38.4 (Konfidenzintervall bei einfacher linearer Regression)**.** In diesem Beispiel wollen wir nicht auf die spezifische Form der Konfidenzintervalle für den Offset- und Steigungsparameter eingehen, sondern lediglich anhand folgender Simulation an die Frequentistische Bedeutung eines δ-Konfidenzintervalls erinnern: Realisierungen von δ-Konfidenzintervallen überdecken den

wahren, aber unbekannten, Parameterwert mit einer frequentistischen Wahrscheinlichkeit von δ. Abbildung 38.3 zeigt, basierend auf folgendem **R** Code, dass dies in der konkreten Simulation mit $\delta = 0.95$ für den Offsetparameter in 94 von 100 und für den Steigungsparameter in 93 von 100 Fällen der Fall ist.

```
# Modellformulierung
library(MASS)                                                  # multivariate Normalverteilung
set.seed(0)                                                    # Random number generator seed
ns          = 1e2                                              # Anzahl Simulationen
n           = 10                                               # Anzahl von Datenpunkten
p           = 2                                                # Anzahl von Betaparametern
x           = 1:n                                              # Prädiktorwerte
X           = matrix(c(rep(1,n),x), ncol = p)                  # Designmatrix
I_n         = diag(n)                                          # Einheitsmatrix
beta        = matrix(c(1,2), nrow = 2)                         # wahre, aber unbekannte, Betaparameter
sigsqr      = 1                                                # wahrer, aber unbekannter, Varianzparameter
delta       = 0.95                                             # Konfidenzbedingung
t_delta     = qt((1+delta)/2,n-1)                              # \Psi^{-1}((1+\delta)/2,n-1)
lambda      = diag(solve(t(X) %*% X))                          # \lambda_j Werte

# Simulation
kappa       = array(rep(NaN, ns*p*p), dim=c(ns,2,2))           # Konfidenzintervallarray
beta_hat    = matrix(rep(NaN,p*ns), nrow = p)                  # Betaparameterschätzer
for(i in 1:ns){                                                # Iteration über Realisierungen
  y             = mvrnorm(1, X %*% beta, sigsqr*I_n)           # Datenrealisierung
  beta_hat[,i]  = solve(t(X) %*% X) %*% t(X) %*% y             # \hat{\beta}
  eps_hat       = y - X %*% beta_hat[,i]                       # \hat{\varepsilon}
  sigsqr_hat    = (t(eps_hat) %*% eps_hat)/(n-p)               # \hat{\sigma}^2
  for(j in 1:p){                                               # Iteration über Betaarraykomponenten
    kappa[i,1,j] = beta_hat[j,i]-sqrt(sigsqr_hat*lambda[j])*t_delta  # untere KI Grenze
    kappa[i,2,j] = beta_hat[j,i]+sqrt(sigsqr_hat*lambda[j])*t_delta  # obere  KI Grenze
  }
}
```

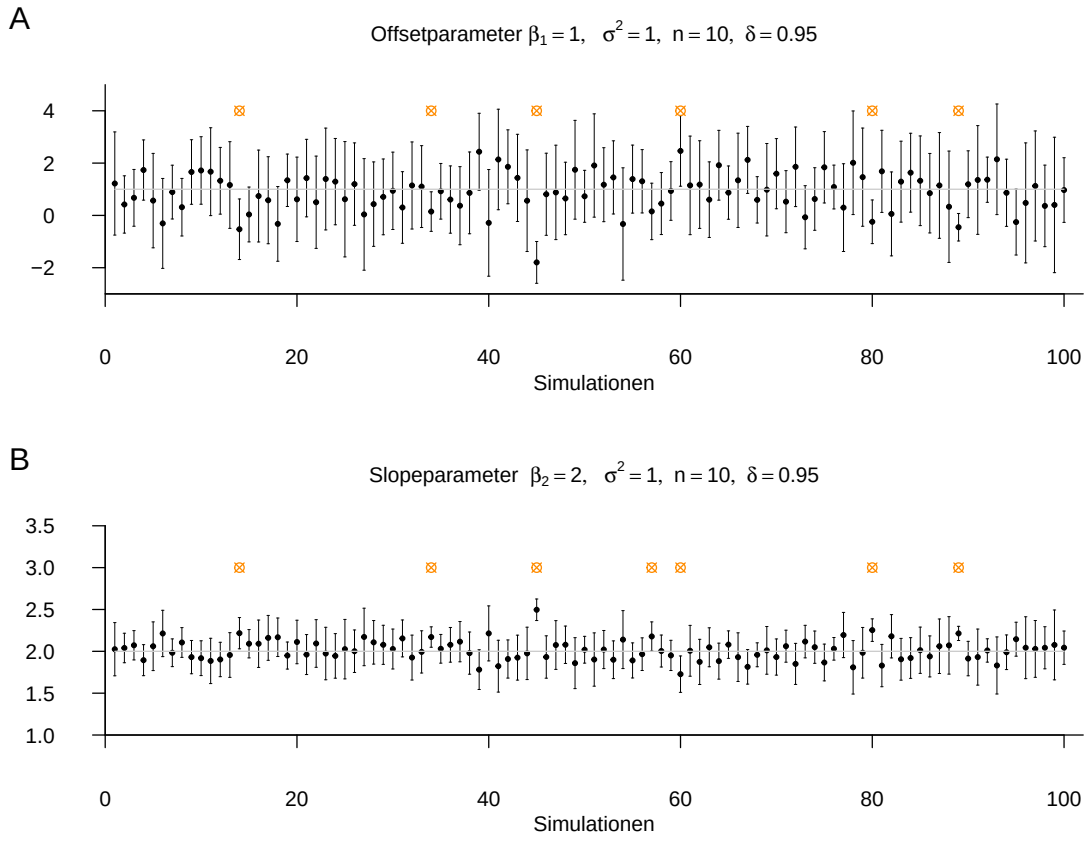


Abbildung 38.3. Konfidenzintervalle für Betaparameterkomponenten bei einfacher linearer Regression.

△

38.3. Literaturhinweise

Box (1981) und Zabell (2008) geben einen historischen Überblick zur Entwicklung der T-Statistik und ihrer Verteilung im Kontext der Arbeiten von Student (1908) und Fisher (1925a), Fisher (1925c) und Fisher (1925b). Die Theorie der Konfidenzintervalle geht auf Neyman (1935) und Neyman (1937) zurück.

39. F-Statistiken

In diesem Abschnitt führen wir F-Statistiken vor dem Hintergrund Likelihood-Quotienten-Statistik-basierter Modellvergleiche ein. Die (maximierte oder marginale) Likelihood eines Datensatzes unter einem gegebenen probabilistischen Modell als Modellvergleichskriterium heranzuziehen ist dabei ein weit verbreitetes Verfahren in der probabilistischen Datenanalyse. Im Gegensatz zu T-Statistiken kann das Ziel der Berechnung von F-Statistiken damit insbesondere sein, nicht nur Linearkombinationen von Betaparameterschätzwerten probabilistisch zu evaluieren, sondern die Modellanpassung an einen Datensatz insgesamt zu evaluieren. Die Modellvergleichskapazität von F-Statistiken ist allerdings etwas beschränkt, da sich die F-Statistik nur auf ALMs und insbesondere geschachtelte ALMs bezieht, in denen ein Modell Bestandteil eines anderen Modells ist. F-Statistiken bilden üblicherweise die Grundlage für Hypothesentests im Rahmen varianzanalytischer Verfahren. Der Einsatz von F-Statistiken ist aber per se nicht auf Varianzanalysen beschränkt, sondern kann auch bei parametrischen ALM Designs angebracht sein. Im Folgenden führen wir zunächst den Begriff der Likelihood-Quotienten-Statistik ein und betrachten dann die Definition der F-Statistik vor diesem Hintergrund. Wir schließen mit der Frequentistischen Verteilung der F-Statistik.

39.1. Likelihood-Quotienten-Statistiken

Wir definieren den Begriff der Likelihood-Quotienten-Statistik wie folgt.

Definition 39.1 (Likelihood-Quotienten-Statistik)**.** Gegeben seien zwei Frequentistische Inferenzmodelle

$$\mathcal{M}_0 := \left(\mathcal{Y}, \mathcal{A}, \left\{\mathbb{P}^0_{\theta_0} \mid \theta_0 \in \Theta_0\right\}\right) \text{ und } \mathcal{M}_1 := \left(\mathcal{Y}, \mathcal{A}, \left\{\mathbb{P}^1_{\theta_1} \mid \theta_1 \in \Theta_1\right\}\right) \tag{39.1}$$

mit identischem Datenraum, identischer σ-Algebra und potentiell distinkten Mengen von Wahrscheinlichkeitsmaßen und Parameterräumen. Sei weiterhin v ein Zufallsvektor mit Datenraum $\mathcal{Y}$. Seien schließlich L^y_0 und L^y_1 die Likelihood-Funktionen von $\mathcal{M}_0$ und $\mathcal{M}_1$, respektive, wobei das Superskript ^{y} jeweils an die Datenabhängigkeit der Likelihood-Funktion erinnern soll. Dann wird

$$\Lambda := \frac{\max_{\theta_0 \in \Theta_0} L^y_0(\theta_0)}{\max_{\theta_1 \in \Theta_1} L^y_1(\theta_1)} \tag{39.2}$$

Likelihood-Quotienten-Statistik genannt.

•

Eine Likelihood-Quotienten-Statistik setzt die Wahrscheinlichkeitsmasse/-dichte eines beobachteten Datensatzes $y \in \mathcal{Y}$ unter zwei Frequentistischen Inferenzmodellen nach Optimierung der jeweiligen Modellparameter ins Verhältnis. Ein hoher Wert der Likelihood-Quotienten-Statistik entspricht einer höheren Wahrscheinlichkeitsmasse/-dichte des beobachteten Datensatzes $y \in \mathcal{Y}$ unter $\mathcal{M}_0$ als unter $\mathcal{M}_1$ und vice versa.

Die Wahrscheinlichkeitsmassen/dichten beobachteter Daten nach Modellschätzung unter verschiedenen Modellen zu betrachten ist ein allgemeines Vorgehen zum Vergleich von Modellen. Letztlich erlaubt dieses Vorgehen, verschiedene wissenschaftliche Theorien über die Genese beobachtbarer Daten quantitativ zu vergleichen und die damit verbundene Unsicherheit zu quantifizieren. Modellvergleiche sind ein zentrales Thema in der Bayesianischen Inferenz, die die Logik von Likelihood-Quotienten-Statistiken zum Beispiel unter den Begriffen der Bayes Factors oder der des Bayesian Information Criterion auf allgemeine probabilistische Modelle generalisiert. Allerdings sind, wie hier gesehen, Modellvergleiche auch im Rahmen der Frequentistischen Inferenz möglich und sinnvoll, Modellvergleiche sind also kein

Mit dem *reduzierten Modell* und dem *vollständigen Modell* betrachten wir im Folgenden zwei spezielle Formen von $\mathcal{M}_0$ und $\mathcal{M}_1$, respektive, im Kontext des ALMs.

Definition 39.2 (Vollständiges und reduziertes Modell.)**.** Für $p > 1$ mit $p = p_0 + p_1$ seien

$$X \coloneqq \begin{pmatrix} X_0 & X_1 \end{pmatrix} \in \mathbb{R}^{n \times p} \text{ mit } X_0 \in \mathbb{R}^{n \times p_0} \text{ und } X_1 \in \mathbb{R}^{n \times p_1} \tag{39.3}$$

sowie

$$\beta \coloneqq \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} \in \mathbb{R}^{p} \text{ mit } \beta_0 \in \mathbb{R}^{p_0} \text{ und } \beta_1 \in \mathbb{R}^{p_1} \tag{39.4}$$

Partitionierungen einer $n \times p$ Designmatrix und eines p-dimensionalen Betaparametervektors. Dann nennen wir

$$y = X\beta + \varepsilon \text{ mit } \varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \tag{39.5}$$

das *vollständige Modell* und

$$y = X_0\beta_0 + \varepsilon_0 \text{ mit } \varepsilon_0 \sim N\left(0_n, \sigma^2 I_n\right) \tag{39.6}$$

das *reduzierte Modell* und sprechen von einer *Partitionierung eines (vollständigen) Modells*.

•

Man sagt auch, dass das reduzierte Modell im vollständigen Modell *geschachtelt (engl. nested)* ist. Die Likelihood-Quotienten-Statistik beim Vergleich eines vollständigen und eines reduzierten Modells hat eine einfache Form. Diese ist der zentrale Aspekt folgenden Theorems.

Theorem 39.1 (Likelihood-Quotienten-Statistik von vollständigem und reduziertem Modell.)**.** *Für $p = p_0 + p_1, p > 1$ sei eine Partitionierung eines vollständigen ALMs gegeben und es seien $\hat{\sigma}^2$ und $\hat{\sigma}_0^2$ die Maximum-Likelihood-Schätzer des Varianzparameters unter vollständigem und reduziertem Modell, respektive. Weiterhin seien die zwei parametrischen statistischen Modelle $\mathcal{M}_0$ und $\mathcal{M}_1$ in der Definition der Likelihood-Quotienten-Statistik durch das reduzierte Modell und das vollständige Modell gegeben. Dann gilt*

$$\Lambda = \left(\frac{\hat{\sigma}^2}{\hat{\sigma}_0^2}\right)^{\frac{n}{2}} \tag{39.7}$$

◦

Beweis. Wir erinnern zunächst daran, dass die Maximum-Likelihood-Schätzer des Varianzparameters durch

$$\hat{\sigma}^2 = \frac{1}{n}(y - X\hat{\beta})^T(y - X\hat{\beta}) \text{ und } \hat{\sigma}_0^2 = \frac{1}{n}\left(y - X_0\hat{\beta}_0\right)^T\left(y - X_0\hat{\beta}_0\right) \tag{39.8}$$

respektive, gegeben sind, wobei $\hat{\beta}$ und $\hat{\beta}_0$ die Maximum-Likelihood-Schätzer der Betaparameter unter vollständigem und reduziertem Modell, respektive, bezeichnen. Weiterhin halten wir fest, dass für die Likelihood-Funktion des vollständigen Modells an der Stelle der Maximum-Likelihood-Schätzer gilt, dass

$$\begin{aligned} L_1^y\left(\hat{\beta}, \hat{\sigma}^2\right) &= (2\pi)^{-\frac{n}{2}}\left(\hat{\sigma}^2\right)^{-\frac{n}{2}} \exp\left(-\frac{1}{2\hat{\sigma}^2}(y - X\hat{\beta})^T(y - X\hat{\beta})\right) \\ &= (2\pi)^{-\frac{n}{2}}\left(\hat{\sigma}^2\right)^{-\frac{n}{2}} \exp\left(-\frac{n}{2}\frac{(y - X\hat{\beta})^T(y - X\hat{\beta})}{(y - X\hat{\beta})^T(y - X\hat{\beta})}\right) \\ &= (2\pi)^{-\frac{n}{2}}\left(\hat{\sigma}^2\right)^{-\frac{n}{2}} e^{-\frac{n}{2}} \end{aligned} \tag{39.9}$$

und analog, dass für die Likelihood-Funktion des reduzierten Modells an der Stelle der Maximum-Likelihood-Schätzer gilt, dass

$$L_0^y\left(\hat{\beta}_0, \hat{\sigma}_0^2\right) = (2\pi)^{-\frac{n}{2}}\left(\hat{\sigma}_0^2\right)^{-\frac{n}{2}} e^{-\frac{n}{2}} \tag{39.10}$$

Damit ergibt sich dann aber

$$\Lambda = \frac{\max_{\theta_0 \in \Theta_0} L_0^y(\theta_0)}{\max_{\theta_1 \in \Theta_1} L_1^y(\theta_1)} = \frac{L_0^y\left(\hat{\beta}_0, \hat{\sigma}_0^2\right)}{L_1^y\left(\hat{\beta}, \hat{\sigma}^2\right)} = \frac{(2\pi)^{-\frac{n}{2}}\left(\hat{\sigma}_0^2\right)^{-\frac{n}{2}} e^{-\frac{n}{2}}}{(2\pi)^{-\frac{n}{2}}\left(\hat{\sigma}^2\right)^{-\frac{n}{2}} e^{-\frac{n}{2}}} = \left(\frac{\hat{\sigma}_0^2}{\hat{\sigma}^2}\right)^{-\frac{n}{2}} = \left(\frac{\hat{\sigma}^2}{\hat{\sigma}_0^2}\right)^{\frac{n}{2}}. \tag{39.11}$$

□

39.2. Definition und Verteilung

Wir definieren nun die F-Statistik vor dem Hintergrund eines vollständigen und eines reduzierten Modells.

Definition 39.3 (F-Statistik)**.** Für $X \in \mathbb{R}^{n \times p}, \beta \in \mathbb{R}^p$ und $\sigma^2 > 0$ sei ein ALM der Form

$$y = X\beta + \varepsilon \text{ mit } \varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \tag{39.12}$$

mit der Partitionierung

$$X = \begin{pmatrix} X_0 & X_1 \end{pmatrix}, X_0 \in \mathbb{R}^{n \times p_0}, X_1 \in \mathbb{R}^{n \times p_1}, \text{ und } \beta := \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}, \beta_0 \in \mathbb{R}^{p_0}, \beta_1 \in \mathbb{R}^{p_1} \tag{39.13}$$

mit $p = p_0 + p_1$ gegeben. Weiterhin seien mit

$$\hat{\beta}_0 := \left(X_0^T X_0\right)^{-1} X_0^T y \text{ und } \hat{\beta} := \left(X^T X\right)^{-1} X^T y \tag{39.14}$$

die Residuenvektoren

$$\hat{\varepsilon}_0 := y - X_0\hat{\beta}_0 \text{ und } \hat{\varepsilon} := y - X\hat{\beta} \tag{39.15}$$

definiert. Dann ist die *F-Statistik* definiert als

$$F := \frac{\left(\hat{\varepsilon}_0^T\hat{\varepsilon}_0 - \hat{\varepsilon}^T\hat{\varepsilon}\right)/p_1}{\hat{\varepsilon}^T\hat{\varepsilon}/(n - p)} \tag{39.16}$$

•

Der Zähler der F-Statistik

$$\frac{\hat{\varepsilon}_0^T\hat{\varepsilon}_0 - \hat{\varepsilon}^T\hat{\varepsilon}}{p_1} \tag{39.17}$$

misst, inwieweit die p_1 Regressoren in X_1 die Residualquadratsumme reduzieren und zwar im Verhältnis zur Anzahl dieser Regressoren. Das heißt, dass bei gleicher Größe der Residualquadratsummenreduktion (und gleichem Nenner) ein größerer F Wert resultiert, wenn diese durch weniger zusätzliche Regressoren resultiert, also p_1 klein ist (und vice versa). Im Sinne der Anzahl der Spalten von X und der entsprechenden Komponenten von β favorisiert die F-Statistik also weniger "komplexe" Modelle.

Für den Nenner der F-Statistik gilt

$$\frac{\hat{\varepsilon}^T\hat{\varepsilon}}{n-p} = \hat{\sigma}^2 \tag{39.18}$$

wobei $\hat{\sigma}^2$ hier der aufgrund des vollständigen Modells geschätzte Schätzer von σ^2 ist. Man beachte, dass dieser Schätzer aufgrund des Nenners $n-p$ nicht mit dem oben betrachteten Maximum-Likelihood-Schätzer des Varianzparameters mit Nenner n identisch ist. Werden die Daten tatsächlich unter dem reduzierten Modell generiert, so kann das vollständige Modell dies durch $\hat{\beta}_2 \approx 0_{p_1}$ abbilden und erreicht eine ähnliche σ^2 Schätzung wie das reduzierte Modell. Werden die Daten de-facto unter dem vollständigem Modell generiert, so ist $\hat{\varepsilon}^T\hat{\varepsilon}/(n-p)$ ein besserer Schätzer von σ^2 als $\hat{\varepsilon}_0^T\hat{\varepsilon}_0/(n-p)$, da sich für diesen die Datenvariabilität, die nicht durch die p_0 Regressoren in X_0 erklärt wird, in der Schätzung von σ^2 widerspiegeln würde. Der Nenner der F-Statistik ist also in beiden Fällen der sinnvollere Schätzer von σ^2.

Zusammengenommen misst die F-Statistik also die Residualquadratsummenreduktion durch die p_1 Regressoren in X_1 gegenüber den p_0 Regressoren in X_0 pro Datenvariabilitäts (σ^2) - und Regressor (p_1)-Einheit.

Beispiel 39.1 (F-Statistik bei einfacher linearer Regression)**.** Exemplarisch evaluiert untenstehender **R** Code die F-Statistik im Kontext folgender Partitionierung des Modells der einfachen linearen Regression

$$X = \begin{pmatrix} X_0 & X_1 \end{pmatrix}, X_0 := 1_n, X_1 := (x_1, \ldots, x_n)^T, \beta := \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} \tag{39.19}$$

und zwar einmal für den Fall, dass $\beta = (1,0)^T$, also dass das reduzierte Modell das wahre, aber unbekannte, datenerzeugende Modell ist und einmal für den Fall, dass $\beta = (1,0.5)^T$, also dass das vollständige Modell das wahre, aber unbekannte, datenerzeugende Modell ist. Im Sinne obiger Diskussion ergibt sich im ersten Fall eine F-Statistik nahe Null, im zweiten Fall dagegen eine hohe F-Statistik.

```
# Modellformulierung
library(MASS)                                          # Multivariate Normalverteilung
nmod   = 2                                             # Anzahl Modelle
n      = 10                                            # Anzahl Datenpunkte
p      = 2                                             # Anzahl Betaparameter
p_0    = 1                                             # Anzahl Betaparameter reduziertes Modell
p_1    = 1                                             # Anzahl zusätzlicher Betaparameter vollständiges Modell
p      = p_0 + p_1                                     # Anzahl Betaparameter im vollständigem Modell
x      = 1:n                                           # Prädiktorwerte
X      = matrix(c(rep(1,n),x), nrow = n)               # Designmatrix des vollständigen Modells
X_0    = X[,1]                                         # Designmatrix des reduzierten Modells
I_n    = diag(n)                                       # n x n Einheitsmatrix
beta   = matrix(c(1,0,1,.5), nrow = 2)                 # wahre , aber unbekannte , Betaparameter
nscn   = ncol(beta)                                    # Anzahl wahrer, aber unbekannter, Hypothesenszenarien
sigsqr = 1                                             # wahrer, aber unbekannter, Varianzparameter

# Modellsimulation und Evaluierung
Eff    = matrix(rep(NaN, nscn), nrow = nscn)           # F-Statistiik Realisierungsarray
for(s in 1:nscn){                                      # Szenarieniterationen
```

```
  y              = mvrnorm(1, X %*%beta[,s], sigsqr*I_n)             # Datenrealisierung
  beta_hat_0     = solve(t(X_0)%*%X_0)%*%t(X_0)%*%y                  # Betaparameterschätzer reduziertes Modell
  beta_hat       = solve(t(X)  %*%X  )%*%t(X)  %*%y                  # Betaparameterschätzer vollständiges Modell
  eps_0_hat      = y-X_0%*%beta_hat_0                                # Residuenvektor reduziertes Modell
  eps_hat        = y-X%*%beta_hat                                    # Residuenvektor vollständiges Modell
  eps_0_eps_0_hat = t(eps_0_hat) %*% eps_0_hat                       # RQS reduziertes Modell
  eps_eps_hat    = t(eps_hat)   %*% eps_hat                          # RQS vollständiges Modell
  Eff[s]         = (((eps_0_eps_0_hat-eps_eps_hat)/p_1)/             # F-Statistik
                      (eps_eps_hat/(n-p)))}
```

```
F-Statistik f<U+00FC>r beta_1  = 0_{p_1}: 0.574832
F-Statistik f<U+00FC>r beta_1 != 0_{p_1}: 5.317227
```

△

Die Likelihood-Quotienten-Statistik und die F-Statistik von vollständigem und reduziertem Modell sind ineinander überführbar. Dies ist die zentrale Aussage folgenden Theorems.

Theorem 39.2 (F-Statistik und Likelihood-Quotienten-Statistik.)**.** *Es sei die Partitionierung eines ALMs in ein vollständiges und ein reduziertes Modell gegeben und F und Λ seien die entsprechenden F- und Likelihood-Quotienten-Statistiken. Dann gilt*

$$F = \frac{n-p}{p_1}\left(\Lambda^{-\frac{2}{n}} - 1\right). \tag{39.20}$$

∘

Beweis. Wir erinnern zunächst daran, dass die Maximum-Likelihood-Schätzer des Varianzparameters durch

$$\hat{\sigma}^2 = \frac{1}{n}(y - X\hat{\beta})^T(y - X\hat{\beta}) = \frac{\hat{\varepsilon}^T\hat{\varepsilon}}{n} \text{ und } \hat{\sigma}_0^2 = \frac{1}{n}\left(y - X_0\hat{\beta}_0\right)^T\left(y - X_0\hat{\beta}_0\right) = \frac{\hat{\varepsilon}_0^T\hat{\varepsilon}_0}{n} \tag{39.21}$$

gegeben sind. Mit der Definition der F-Statistik und der Form der Likelihood-Quotienten-Statistik für den Vergleich von reduziertem und vollständigem Modell ergibt sich dann

$$\begin{aligned} F &= \frac{\left(\hat{\varepsilon}_0^T\hat{\varepsilon}_0 - \hat{\varepsilon}^T\hat{\varepsilon}\right)/p_1}{\hat{\varepsilon}^T\hat{\varepsilon}/(n-p)} \\ &= \frac{n\left(\hat{\sigma}_0^2 - \hat{\sigma}^2\right)/p_1}{n\hat{\sigma}^2/(n-p)} \\ &= \frac{n-p}{p_1}\frac{\hat{\sigma}_0^2 - \hat{\sigma}^2}{\hat{\sigma}^2} \\ &= \frac{n-p}{p_1}\left(\frac{\hat{\sigma}_0^2}{\hat{\sigma}^2} - \frac{\hat{\sigma}^2}{\hat{\sigma}^2}\right) \\ &= \frac{n-p}{p_1}\left(\Lambda^{-\frac{2}{n}} - 1\right). \end{aligned} \tag{39.22}$$

□

Zwischen der F-Statistik und der Likelihood-Quotienten-Statistik besteht also ein nichtlinearer, reziproker Zusammenhang, den wir für $n = 12, p = 2$ und $p_1 = 1$ in Abbildung 39.1 visualisieren. Man beachte, dass für $\Lambda = 1$ gilt, dass $F = 0$. Ein Wert von $F = 0$ impliziert also, dass das reduzierte Modell gegenüber dem vollständigen Modell im Lichte eines beobachteten Datensatzes die gleiche Plausibilität besitzt.

Wir dokumentieren die Frequentistische Verteilung der F-Statistik in folgendem Theorem, auf dessen Beweis wir verzichten.

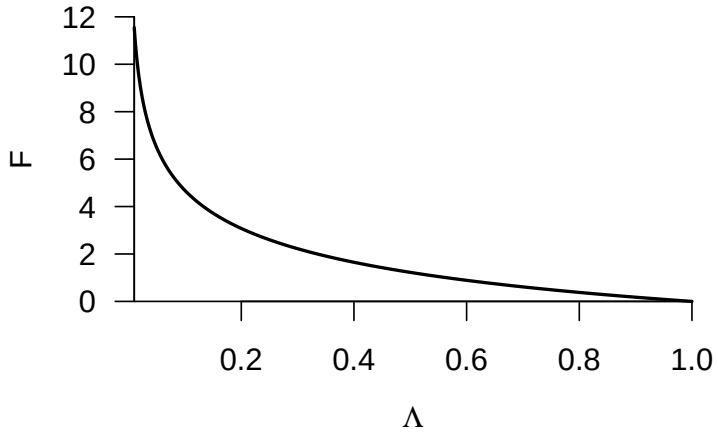


Abbildung 39.1. Zusammenhang von F- und Likelihood-Quotienten-Statistik.

Theorem 39.3 (F-Statistik)**.** *Für $X \in \mathbb{R}^{n \times p}, \beta \in \mathbb{R}^p$ und $\sigma^2 > 0$ sei ein ALM der Form*

$$y = X\beta + \varepsilon \text{ mit } \varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \tag{39.23}$$

mit der Partitionierung

$$X = \begin{pmatrix} X_0 & X_1 \end{pmatrix}, X_0 \in \mathbb{R}^{n \times p_0}, X_1 \in \mathbb{R}^{n \times p_1}, \text{ und } \beta := \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}, \beta_0 \in \mathbb{R}^{p_0}, \beta_1 \in \mathbb{R}^{p_1} \tag{39.24}$$

mit $p = p_0 + p_1$ gegeben. Schließlich sei

$$c := \begin{pmatrix} 0_{p_0} \\ 1_{p_1} \end{pmatrix} \in \mathbb{R}^p \tag{39.25}$$

ein Vektor. Dann gilt

$$F \sim f\left(\delta, p_1, n - p\right) \text{ mit } \delta := \frac{c^T \beta \left(c^T \left(X^T X\right)^{-1} c\right)^{-1} c^T \beta}{\sigma^2} \tag{39.26}$$

∘

Man beachte, dass die F-Statistik eine Funktion des Parameterschätzers, δ dagegen eine Funktion der wahren, aber unbekannten, Parameter ist. Wie die Verteilung der T-Statistik kann die Verteilung der F-Statistik für die Evaluation von Frequentistischen Konfidenzintervallen und Hypothesentests genutzt werden. Insbesondere letzteren Aspekt verdeutlichen wir in Kapitel 41 und Kapitel 42.

Beispiel 39.2 (Verteilung der F-Statistik bei einfacher linearer Regression)**.** Exemplarisch evaluieren wir mithilfe untenstehenden **R** Codes die Verteilung der F-Statistik im Kontext der Partitionierung des Modells der einfachen linearen Regression und zwar erneut einmal für den Fall, dass

$\beta = (1, 0)^T$, also dass das reduzierte Modell das wahre, aber unbekannte, datenerzeugende Modell ist und einmal für den Fall, dass $\beta = (1, 0.5)^T$, also dass das vollständige Modell das wahre, aber unbekannte, datenerzeugende Modell ist. Abbildung 8.2 A und B visualisieren die resultierenden Verteilungen, respektive.

```
# Modellformulierung
library(MASS)
nmod   = 2                                          # Anzahl Modelle
n      = 10                                         # Anzahl Datenpunkte
p_0    = 1                                          # Anzahl Betaparameter im reduzierten Modell
p_1    = 1                                          # Anzahl additiver Betaparameter im vollständigen Modell
p      = p_0 + p_1                                  # Anzahl Betaparameter im vollständigem Modell
x      = 1:n                                        # Prädiktorwerte
X      = matrix(c(rep(1,n),x), nrow = n)            # Designmatrix des vollständigen Modells
X_0    = X[,1]                                      # Designmatrix des reduzierten Modells
I_n    = diag(n)                                    # n x n Einheitsmatrix
beta   = matrix(c(1,0,1,.5), nrow = 2)              # wahre , aber unbekannte , Betaparameter
nscn   = ncol(beta)                                 # Anzahl wahrer, aber unbekannter, Hypothesenszenarien
sigsqr = 1                                          # wahrer, aber unbekannter, Varianzparameter
c      = matrix((c(0,1)), nrow = 2)                 # Vektor

# Frequentistische Simulation
nsim   = 1e4                                        # Anzahl Realisierungen des n-dimensionalen ZVs
delta  = rep(NaN,nscn)                              # Nichtzentralitätsparameterarray
Eff    = matrix(rep(NaN, nscn*nsim), nrow = nscn)   # F-Statistiik Realisierungsarray
for(s in 1:nscn){                                   # Szenarieniterationen
  delta[s] = (t(t(c)%*%beta[,s])%*%                 # Nichtzentralitätsparameter
              solve(t(c)%*%solve(t(X)%*%X)%*%c) %*%
              (t(c)%*%beta[,s])/sigsqr)
  for(i in 1:nsim){                                 # Simulationsiterationen
    y              = mvrnorm(1, X %*%beta[,s], sigsqr*I_n)  # Datenrealisierung
    beta_hat_0     = solve(t(X_0)%*%X_0)%*%t(X_0)%*%y       # Betaparameterschätzer reduziertes Modell
    beta_hat       = solve(t(X)  %*%X  )%*%t(X)  %*%y       # Betaparameterschätzer vollständiges Modell
    eps_0_hat      = y-X_0%*%beta_hat_0                     # Residuenvektor reduziertes Modell
    eps_hat        = y-X%*%beta_hat                         # Residuenvektor vollständiges Modell
    eps_0_eps_0_hat = t(eps_0_hat) %*% eps_0_hat            # RQS reduziertes Modell
    eps_eps_hat    = t(eps_hat)   %*% eps_hat               # RQS vollständiges Modell
    Eff[s,i]       = (((eps_0_eps_0_hat-eps_eps_hat)/p_1)/  # F-Statistik
                      (eps_eps_hat/(n-p)))}}
```

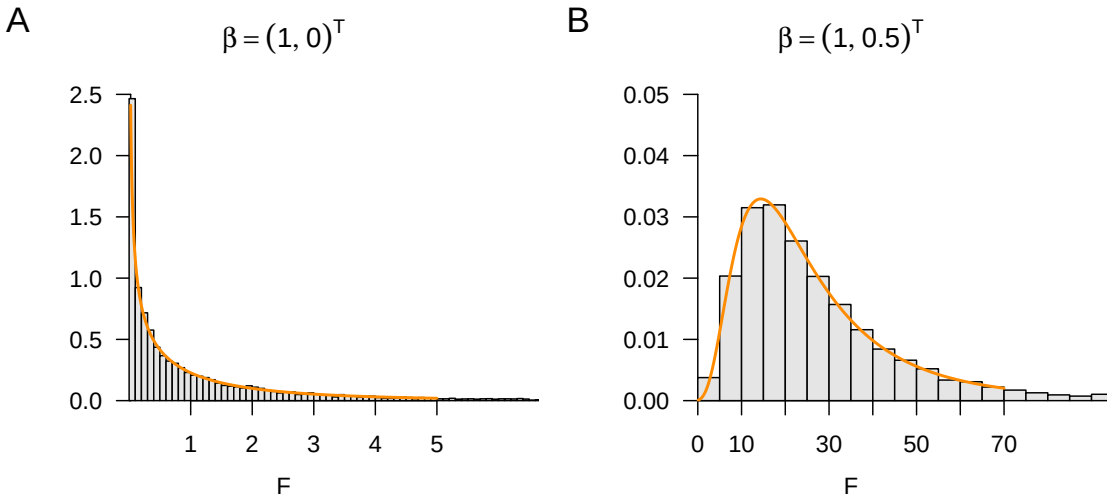


Abbildung 39.2. Exemplarische F-Statistik Verteilungen unter reduziertem und vollständigem wahren, aber unbekanntem, datenerzeugenden Modell bei einfacher lineare Regression.

△

39.3. Literaturhinweise

Die Popularität von F-Statistiken, insbesondere im Kontext der Varianzanalyse, wird allgemein auf Fisher (1925b) zurückgeführt. Seal (1967) gibt einen historischen Überblick.

Likelihood-Quotienten-Statistiken werden insbesondere von Neyman & Pearson (1928) und Wilks (1938) betrachtet. Lehmann (2011) gibt einen integrierten historischen Überblick zu beiden Ansätzen. Die hier diskutierte Äquivalenz von Likelihood-Quotienten-Statistik und F-Statistik basiert auf der Darstellung in Seber & Lee (2003).

40. T-Tests

40.1. Einstichproben-T-Tests

Anwendungsszenario

Das Anwendungsszenario eines Einstichproben-T-Test ist bekanntlich dadurch gekennzeichnet, dass n univariate Datenpunkte einer Stichprobe (Gruppe) randomisierter experimenteller Einheiten betrachtet werden, von denen angenommen wird, dass sie Realisierungen von n unabhängigen und identisch normalverteilten Zufallsvariablen sind. Hinsichtlich der identischen univariaten Normalverteilungen $N(\mu, \sigma^2)$ dieser Zufallsvariablen wird angenommen, dass sowohl der Erwartungswertparameter μ als auch der Varianzparameter σ^2 unbekannt sind. Schließlich wird vorausgesetzt, dass ein Interesse an einem inferentiellen Vergleich des unbekannten Erwartungswertparameters μ mit einen vorgebenenen Wert μ_0 (z.B. $\mu_0 := 0$) besteht.

Anwendungsbeispiel

Für ein konkretes Anwendungsbeispiel betrachten wir die Analyse von Pre-PostInterventions-BDI-Differenzwerten einer Gruppe von $n = 12$ Patient:innen wie in Tabelle 40.1 dargestellt. Die ersten beiden Spalten dieser Tabelle listen die patientenspezifische BDI Werte vor (PreBDI) und nach (PosBDI) der psychotherapeutischen Intervention, die dritte Spalte dBDI zeigt die entsprechenden PreBDI-PosBDI Differenzwerte. Ein positiver Wert entspricht hier einer Verbesserung der Depressionssymptomatik und ein negativer Wert einer Verschlechterung der Depressionssymptomatik

Tabelle 40.1. Pre- und Post-Intervention BDI Werte

PreBDI	PosBDI	dBDI
29	28	1
32	26	6
33	29	4
28	26	2
31	30	1
32	27	5
33	27	6
30	27	3
29	27	2
30	28	2
33	29	4
31	25	6

Bei der Anwendung eines Einstichproben-T-Tests auf die dBDI Daten dieses Datensatzes nehmen wir also an, dass die `dBDI` Daten Realisierungen von $n = 12$ unabhängig normalverteilten Zufallsvariablen $y_i \sim N(\mu, \sigma^2)$ sind. Wir nehmen weiterhin an, dass wir

daran interessiert sind, unsere Unsicherheit beim inferentiellen Vergleich des wahren, aber unbekannten, Erwartungswertparameters μ mit einem Vergleichswert μ_0 im Sinne eines Hypothesentests zu quantifizieren.

Unabhängig von diesem inferenzstatistischen Vorgehen betrachten wir zunächst die deskriptiven Statistiken der dBDI Daten, wie in Tabelle 40.2 dargestellt. Es fällt insbesondere auf, dass das Stichprobenmittel im Vergleich zur Standardabweichung relativ klein ist. Im Gruppenmittel unterscheiden sich die PreBDI und PosBDI also zwar in positiver Richtung, was eine Verringerung der Depressionssymptomatik impliziert, allerdings streuen die Daten auch über Patient:innen deutlich, wie auch bereits aus Tabelle 40.1 ersichtlich.

Tabelle 40.2. Deskriptivstatistiken der Pre-Post BDI Differenzwerte

	n	Max	Min	Median	Mean	Var	Std
F2F	12	6	1	3.5	3.5	3.73	1.93

Modellformulierung

Wir definieren nun das Einstichproben-T-Test-Modell wie folgt.

Definition 40.1 (Einstichproben-T-Test-Modell)**.** Für $i = 1, \dots, n$ seien y_i Zufallsvariablen, die die n Datenpunkte eines Einstichproben-T-Test-Szenarios modellieren. Dann hat das Einstichproben-T-Test-Modell die strukturelle Form

$$y_i = \mu + \varepsilon_i \text{ mit } \varepsilon_i \sim N\left(0, \sigma^2\right) \text{ u.i.v für } i = 1, \dots, n \text{ mit } \mu \in \mathbb{R} \text{ und } \sigma^2 > 0, \tag{40.1}$$

die Datenverteilungsform

$$y_i \sim N\left(\mu, \sigma^2\right) \text{ u.i.v für } i = 1, \dots, n \text{ mit } \mu \in \mathbb{R} \text{ und } \sigma^2 > 0, \tag{40.2}$$

und für den Datenvektor $y = \left(y_1, \dots, y_n\right)^T$ die Designmatrixform

$$y = X\beta + \varepsilon \text{ mit } X := 1_n \in \mathbb{R}^{n \times 1}, \beta := \mu \in \mathbb{R}, \varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \text{ und } \sigma^2 > 0. \tag{40.3}$$

•

Das Modell des Einstichproben-T-Tests ist offenbar mit dem dem Modell unabhängiger und identisch normalverteilter Zufallsvariablen identisch (vgl. Kapitel 36). Die Äquivalenz von struktureller, Datenverteilungs- und Designmatrixform des Einstichproben-T-TestModells wurde in Kapitel 36 bereits ausführlich diskutiert. Die Simulation von Daten basierend auf dem Einstichproben-T-Test-Modell hat dementsprechend die gleiche Form wie die Simulation unabhängig und identisch normalverteilter Zufallsvariablen. Unterer **R** Code demonstriert dies.

```
# Modellformulierung
library(MASS)                                    # Multivariate Normalverteilung
n      = 12                                      # Anzahl von Datenpunkten
p      = 1                                       # Anzahl von Betaparameter
X      = matrix(rep(1,n), nrow = n)              # Designmatrix
I_n    = diag(n)                                 # n x n Einheitsmatrix
beta   = 5                                       # wahrer, aber unbekannter, Betaparameter
sigsqr = 14                                      # wahrer, aber unbekannter, Varianzparameter

# Datenrealisierung
y      = mvrnorm(1, X %*% beta, sigsqr*I_n)      # eine Realisierung eines n-dimensionalen ZVs
```

Modellschätzung

Da die Form des Einstichproben-T-Test-Modells mit dem Szenario unabhängig und identisch normalverteilter Zufallsvariablen identisch ist, trifft dies auch auf die entsprechenden Beta- und Varianzparameterschätzer zu. Es ergibt sich also folgendes Theorem, das bereits in Kapitel 37 bewiesen wurde.

Theorem 40.1 (Parameterschätzer im Einstichproben-T-Test-Modell)**.** *Gegeben sei die Designmatrixform des Einstichproben-T-Test-Modells. Dann ergeben sich für den Betaparameterschätzer*

$$\hat{\beta} = \frac{1}{n}\sum_{i=1}^{n} y_i =: \bar{y} \tag{40.4}$$

und für den Varianzparameterschätzer

$$\hat{\sigma}^2 = \frac{1}{n-1}\sum_{i=1}^{n} (y_i - \bar{y})^2 =: s_y^2 \tag{40.5}$$

$\bar{y}$ und s_y^2 bezeichnen hier also wiederum das Stichprobenmittel und die Stichprobenvarianz der Zufallsvariablen $y_1, \ldots, y_n$.

∘

40.2. Modellevaluation

Basierend auf Definition 38.1 formulieren wir nun die T-Teststatistik für das Einstichproben-T-Test Szenario und geben ihre frequentistische Verteilung an.

Theorem 40.2 (T-Teststatistik des Einstichproben-T-Tests)**.** *Gegeben sei die Designmatrixform des Einstichproben-T-Test-Modells. Dann ergibt sich für die T-Teststatistik mit*

$$c := 1 \text{ und } c^T\beta_0 =: \mu_0, \tag{40.6}$$

dass

$$T = \sqrt{n}\left(\frac{\bar{y} - \mu_0}{s_y}\right) \tag{40.7}$$

und es gilt, dass

$$T \sim t(\delta, n-1) \text{ mit } \delta = \sqrt{n}\left(\frac{\mu - \mu_0}{\sigma}\right). \tag{40.8}$$

∘

Beweis. Mit Theorem 38.1 gilt

$$T = \frac{c^T\hat{\beta} - c^T\beta_0}{\sqrt{\hat{\sigma}^2 c^T (X^TX)^{-1} c}} = \frac{1^T\bar{y} - 1^T\mu_0}{\sqrt{s_y^2 1^T (1_n^T 1_n)^{-1} 1}} = \sqrt{n}\left(\frac{\bar{y} - \mu_0}{s_y}\right). \tag{40.9}$$

Weiterhin gilt mit demselben Theorem

$$\delta = \frac{c^T\beta - c^T\beta_0}{\sqrt{\sigma^2 c^T (X^TX)^{-1} c}} = \frac{1^T\mu - 1^T\mu_0}{\sqrt{\sigma^2 1^T (1_n^T 1_n)^{-1} 1}} = \sqrt{n}\left(\frac{\mu - \mu_0}{\sigma}\right). \tag{40.10}$$

□

Die Formen der T-Teststatistik und ihre Verteilung im Einstichproben-T-Test-Spezialfall des ALMs sind also natürlicherweise mit den entsprechenden Formen im ALM-freien Kontext identisch. Die enstprechende Theorie zu Konfidenzintervallen und der Kontrolle des Testumfangs bei Einstichproben-T-Tests sowie der Gebrauch der Testgütefunktion zur Evaluation der Testtrennschärfe (Power) folgt also analog.

Anwendungsbeispiel

Folgender **R** Code demonstriert die Evaluation eines 95%-Konfidenzintervalls für den Erwartungswertparameter μ sowie Durchführung eines zweiseitigen Einstichproben-T-Tests mit einfacher Nullhypothese $\Theta_0 := \{0\}$ und Signifikanzlevel $\alpha_0 := 0.05$ für das oben skizzierte Anwendungsbeispiel.

```
# Datenanalyse
D           = read.csv("./_data/507-t-tests.csv")                    # Laden des Datensatzes
y           = D$dBDI[D$COND == "F2F"]                                # Post-Pre Differenzwerte
n           = length(y)                                              # Anzahl Datenpunkte
p           = 1                                                      # Anzahl Betaparameter
c           = 1                                                      # Kontrastgewichtsvektor
mu_0        = 0                                                      # Nullhypothesenparameter
delta       = 0.95                                                   # Konfidenzlevel
alpha_0     = 0.05                                                   # Signifikanzlevel
X           = matrix(rep(1,n), nrow = n)                             # Einstichproben-T-Test Designmatrix
beta_hat    = solve(t(X)%*%X)%*%t(X)%*%y                             # Betaparameterschätzer
eps_hat     = y - X %*% beta_hat                                     # Residuenvektor
sigsqr_hat  = (t(eps_hat) %*% eps_hat)/(n-p)                         # Varianzparameterschätzer
t_delta     = qt((1+delta)/2,n-1)                                    # \Psi^{-1}(1+\delta)/2, n-1)
lambda      = diag(solve(t(X) %*% X))                                # \lambda_j Werte
kappa_u     = beta_hat - sqrt(sigsqr_hat*lambda)*t_delta              # untere Konfidenzintervallgrenze
kappa_o     = beta_hat + sqrt(sigsqr_hat*lambda)*t_delta              # obere Konfidenzintervallgrenze
t_num       = t(c) %*% beta_hat - mu_0                               # Zähler der Einstichproben-T-Teststatistik
t_den       = sqrt(sigsqr_hat %*% t(c) %*% solve(t(X) %*% X) %*% c)  # Nenner der Einstichproben-T-Teststatistik
t           = t_num/t_den                                            # Wert der Einstichproben-T-Teststatistik
pval        = 2*(1 - pt(abs(t), n-1))                                # p-Wert bei zweiseitigem Einstichproben-T-Test
k_alpha_0   = qt(1-alpha_0/2, n-1)                                   # kritischer Wert
if(abs(t) > k_alpha_0){phi = 1} else {phi = 0}                       # Einstichproben-T-Test
```

```
Betaparametersch<U+00E4>tzer            :  3.5
95%-Konfidenzintervall          :  2.27 4.73
Varianzparametersch<U+00E4>tzer         :  3.73
alpha_0                         :  0.05
Kritischer Wert                 :  2.2
Einstichproben-T-Teststatistik  :  6.28
phi                             :  1
p-Wert                          :  0
```

Die Nullhypothese wird in diesem Fall bei einem einem kritischen Wert von $k_{0.05} = 2.20$ und einem Wert der T-Statistik von $T = 3.91$ abgelehnt. Das 95/%-Konfidenzintervall für den wahren, aber unbekannten, Erwartungswertparameter ist $[2.26, 8.07]$, überdeckt also den Nullhypothesenparameterwert $\mu_0 = 0$ nicht.

40.3. Zweistichproben-T-Tests

Anwendungsszenario

Das Anwendungsszenario eines Zweistichproben-T-Tests für unabhängige Stichproben ist bekanntlich dadurch gekennzeichnet, dass insgesamt n univariate Datenpunkte zweier Stichproben (Gruppen) randomisierter experimenteller Einheiten betrachtet werden. Es wird dabei insbesondere angenommen, dass die n_1 univariaten Datenpunkte der ersten Gruppe Realisierungen von n_1 unabhängigen und identisch normalverteilten Zufallsvariablen mit Erwartungswertparameter μ_1 und Varianzparameter σ^2 sind, während weiterhin

angenommen wird, dass die n_2 univariaten Datenpunkte der zweiten Gruppe Realisierungen von n_2 unabhängigen und identisch normalverteilten Zufallsvariablen mit Erwartungswertparameter μ_2 und Varianzparameter σ^2 sind. Es wird also insbesondere angenommen, dass sich die wahren, aber unbekannten, Erwartungswertparameter beider Gruppen von Zufallsvariablen unterscheiden können, die Varianzparameter beider Gruppen dagegen werden als identisch angenommen. Schließlich wird voraussgesetzt, dass ein Interesse am inferentiellen Vergleich der unbekannten Erwartungswertparameter μ_1 und μ_2 besteht, so zum Beispiel ihrer Gleichheit $\mu_1 = \mu_2$ oder Verschiedenheit $\mu_1 \neq \mu_2$.

Anwendungsbeispiel

Für ein konkretes Anwendungsbeispiel betrachten wird die Analyse von Pre-Post-Interventions-BDI-Differenzwerten zweier Gruppen von je 12 Patient:innen in unterschiedlichen Therapiesettings, wie in Tabelle 40.3 dargestellt. Die erste Spalte der Tabelle (`COND`) listet das patientenspezifische Therapiesetting (F2F: face-to-face, ONL: online) auf. Die zweite Spalte der Tabelle (`dBDI`) listet die entsprechenden patientenspezifischen Pre-Post-Interventions-BDI-Differenzwerte auf. Positive Werte entsprechen hier erneut einer Abnahme der Depressionssymptomatik, negative Werte einer Zunahme der Depressionssymptomatik.

Tabelle 40.3. Pre-Post-BDI Differenzwerte f<U+00FC>r zwei Stichproben

COND	dBDI
F2F	1
F2F	6
F2F	4
F2F	2
F2F	1
F2F	5
F2F	6
F2F	3
F2F	2
F2F	2
F2F	4
F2F	6
ONL	9
ONL	2
ONL	10
ONL	-1
ONL	4
ONL	11
ONL	10
ONL	15
ONL	4
ONL	5
ONL	10
ONL	10

Zu Anwendung eines Zweistichproben-T-Tests auf die dBDI Daten nehmen wir an, dass die 12 Datenpunkte der F2F Therapiegruppe Realisierungen von $n_1 = 12$ unabhängig und identisch normalverteilten Zufallsvariablen $y_{1_j} \sim N\left(\mu_1, \sigma^2\right)$ mit $j = 1, \ldots, n_1$ sind und dass die 12 Datenpunkte der ONL Therapiegruppe Realisierungen von $n_2 = 12$ unabhängig und identisch normalverteilten Zufallsvariablen $y_{2_j} \sim N\left(\mu_2, \sigma^2\right)$ mit $j = 1, \ldots, n_2$ sind.

Unabhängig von dem unten beschriebenen inferenzstatistischen Vorgehen betrachten wir auch hier zunächst die deskriptiven Statistiken der Therapiesetting-spezifischen dBDI Werte. Diese sind in Tabelle 40.4 aufgeführt.

Tabelle 40.4. Deskriptivstatistiken der Pre-Post BDI Differenzwerte bei unterschiedlichen Therapiesettings

	n	Max	Min	Median	Mean	Var	Std
F2F	12	6	1	3.5	3.50	3.73	1.93
ONL	12	15	-1	9.5	7.42	20.81	4.56

Modellformulierung

Mit dem Index i für die Gruppen und dem Index j für die experimentellen Einheiten in jeder Gruppe definieren wir das Zweistichproben-T-Test-Modell wie folgt.

Definition 40.2 (Zweistichproben-T-Test-Modell)**.** Für $i = 1, 2$ und $j = 1, \dots, n_i$ seien y_{ij} Zufallsvariablen, die die $n = n_1 + n_2$ Datenpunkte eines Zweistichproben-T-Test-Szenarios modellieren. Dann hat das Zweistichproben-T-Test-Modell die strukturelle Form

$$y_{ij} = \mu_i + \varepsilon_{ij} \text{ mit } \varepsilon_{ij} \sim N\left(0, \sigma^2\right) \text{ u.i.v. mit } \mu_i \in \mathbb{R} \text{ und } \sigma^2 > 0, \tag{40.11}$$

die Datenverteilungsform

$$y_{ij} \sim N\left(\mu_i, \sigma^2\right) \text{ u.i.v. mit } \mu_i \in \mathbb{R} \text{ und } \sigma^2 > 0, \tag{40.12}$$

und für den n-dimensionalen Datenvektor definiert als

$$y := \left(y_{11}, \cdots, y_{1n_1}, y_{21}, \cdots, y_{2n_2}\right)^T \tag{40.13}$$

die Designmatrixform

$$y = X\beta + \varepsilon \tag{40.14}$$

mit

$$X := \begin{pmatrix} 1_{n_1} & 0_{n_1} \\ 0_{n_2} & 1_{n_2} \end{pmatrix} \in \mathbb{R}^{n \times 2}, \beta := \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} \in \mathbb{R}^2, \varepsilon \sim N\left(0_n, \sigma^2 I_n\right), \sigma^2 > 0. \tag{40.15}$$

•

Die hier gewählte Definition des Zweistichproben-T-Test-Modells in Designmatrixform ist nicht die einzig mögliche, jedoch diejenige, unter der sich am klarsten die Äquivalenz zum Zweistichproben-T-Test-Modell im ALM-freien Kontext erkennen lässt. In Kapitel 41 lernen wir eine alternative Parameterisierung auch des Zweistichproben-T-Test-Modells kennen. Wie schon beim Szenario des Einstichproben-T-Tests ergibt sich die Äquivalenz der in Definition 40.2 formulierten Modellformen mit den Ergebnissen in Kapitel 36. Die Simulation von Daten basierend auf dem Zweistichproben-T-Test-Modell ist, bis auf die Definition von Designmatrix und Betaparametervektor mit den bisher bekannten Simulationen von ALM Spezialfällen identisch, wie folgender **R** Code demonstriert.

```
# Modellformulierung
library(MASS)                                # Multivariate Normalverteilung
n_1    = 12                                  # Anzahl von Datenpunkten Gruppe 1
n_2    = 12                                  # Anzahl von Datenpunkten Gruppe 2
n      = n_1 + n_2                           # Gesamtanzahl Datenpunkte
p      = 2                                   # Anzahl von Betaparameter
X      = matrix(c(rep(1,n_1), rep(0,n_1),    # Designmatrix
                  rep(0,n_2), rep(1,n_2)),
                  nrow  = n)
I_n    = diag(n)                             # n x n Einheitsmatrix
beta   = matrix(c(1,2), nrow = p)            # wahrer, aber unbekannter, Betaparameter
sigsqr = 10                                  # wahrer, aber unbekannter, Varianzparameter

# Datenrealisierung
y      = mvrnorm(1, X %*% beta, sigsqr*I_n)  # eine Realisierung eines n-dimensionalen ZVs
```

Modellschätzung

Die beiden Betaparameterkomponenten des Zweistichproben-T-Test-Modells in Designmatrixform werden wenig überraschend durch die entsprechenden Gruppenstichprobenmittel geschätzt. Für den Varianzparameterschätzer ergibt sich die sogenannte *gepoolte Stichprobenvarianz*. Dies sind die beiden Kernaussagen folgenden Theorems.

Theorem 40.3 (Parameterschätzung im Zweistichproben-T-Test-Modell)**.** *Gegeben sei die Designmatrixform des Zweistichproben-T-Test-Modells. Dann ergeben sich für den Betaparameterschätzer*

$$\hat{\beta} = \begin{pmatrix} \frac{1}{n_1} \sum_{j=1}^{n_1} y_{1j} \\ \frac{1}{n_2} \sum_{j=1}^{n_2} y_{2j} \end{pmatrix} =: \begin{pmatrix} \bar{y}_1 \\ \bar{y}_2 \end{pmatrix} \tag{40.16}$$

und für den Varianzparameterschätzer

$$\hat{\sigma}^2 = \frac{\sum_{j=1}^{n_1} \left(y_{1j} - \bar{y}_1\right)^2 + \sum_{j=1}^{n_2} \left(y_{2j} - \bar{y}_2\right)^2}{n_1 + n_2 - 2} =: s_{12}^2 \tag{40.17}$$

∘

Beweis. Für $i = 1, 2$ sei $y_i := \left(y_{i1}, \dots, y_{in_i}\right)^T$. Dann ergibt sich für den Betaparameterschätzer

$$\begin{aligned}
\hat{\beta} &= \left(X^T X\right)^{-1} X^T y \\
&= \left(\begin{pmatrix} 1_{n_1} & 0_{n_2} \\ 0_{n_1} & 1_{n_2} \end{pmatrix} \begin{pmatrix} 1_{n_1} & 0_{n_1} \\ 0_{n_2} & 1_{n_2} \end{pmatrix} \right)^{-1} \begin{pmatrix} 1_{n_1} & 0_{n_2} \\ 0_{n_1} & 1_{n_2} \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} \\
&= \begin{pmatrix} n_1 & 0 \\ 0 & n_2 \end{pmatrix}^{-1} \begin{pmatrix} \sum_{j=1}^{n_1} & y_{1j} \\ \sum_{j=1}^{n_2} y_{2j} & \end{pmatrix} \\
&= \begin{pmatrix} n_1^{-1} & 0 \\ 0 & n_2^{-1} \end{pmatrix} \begin{pmatrix} \sum_{j=1}^{n_1} & y_{1j} \\ \sum_{j=1}^{n_2} & y_{2j} \end{pmatrix} \\
&= \begin{pmatrix} \frac{1}{n_1} \sum_{j=1}^{n_1} y_{1j} \\ \frac{1}{n_2} \sum_{j=1}^{n_2} y_{2j} \end{pmatrix} \\
&=: \begin{pmatrix} \bar{y}_1 \\ \bar{y}_2 \end{pmatrix}
\end{aligned} \tag{40.18}$$

Gleichsam ergibt sich für Varianzparameterschätzer mit $n = n_1 + n_2$ und $p = 2$

$$
\begin{aligned}
\hat{\sigma}^2 &= \frac{(y - X\hat{\beta})^T (y - X\hat{\beta})}{n - p} \\
&= \frac{1}{n_1 + n_2 - 2} \left(\begin{pmatrix} y_1 \\ y_2 \end{pmatrix} - \begin{pmatrix} 1_{n_1} & 0_{n_1} \\ 0_{n_2} & 1_{n_2} \end{pmatrix} \begin{pmatrix} \bar{y}_1 \\ \bar{y}_2 \end{pmatrix} \right)^T \left(\begin{pmatrix} y_1 \\ y_2 \end{pmatrix} - \begin{pmatrix} 1_{n_1} & 0_{n_1} \\ 0_{n_2} & 1_{n_2} \end{pmatrix} \begin{pmatrix} \bar{y}_1 \\ \bar{y}_2 \end{pmatrix} \right) \\
&= \frac{1}{n_1 + n_2 - 2} \begin{pmatrix} y_{11} - \bar{y}_1 \\ \vdots \\ y_{1n_1} - \bar{y}_1 \\ y_{21} - \bar{y}_2 \\ \vdots \\ y_{2n_2} - \bar{y}_2 \end{pmatrix} \begin{pmatrix} y_{11} - \bar{y}_1 \\ \vdots \\ y_{1n_1} - \bar{y}_1 \\ y_{21} - \bar{y}_2 \\ \vdots \\ y_{2n_2} - \bar{y}_2 \end{pmatrix} \\
&= \frac{\sum_{j=1}^{n_1} \left(y_{1j} - \bar{y}_1 \right)^2 + \sum_{j=1}^{n_2} \left(y_{2j} - \bar{y}_2 \right)^2}{n_1 + n_2 - 2} \\
&=: s_{12}^2.
\end{aligned} \tag{40.19}
$$

□

Man beachte, dass sich die Stichprobenvarianz s_y^2 der Komponenten von y im Allgemeinen von der gepoolten Stichprobenvarianz s_{12}^2 unterscheidet. Dies ist nicht zuletzt dadurch bedingt, dass die Stichprobenvarianz basierend auf dem Gesamtstichprobenmittel $\bar{y}$, die gepoolte Stichprobenvarianz dagegen basierend auf den gruppenspezifischen Stichprobenmittel $\bar{y}_1$ und $\bar{y}_2$ ermittelt wird. Wir wollen das Konzept der gepoolten Stichprobenvarianz hier aber nicht weiter vertiefen.

Modellevaluation

Basierend auf Theorem 38.1 formulieren wir nun die T-Teststatistik für das in Definition 40.2 in Designmatrixform definierte Zweistichproben-T-Test-Modell und geben ihre frequentistische Verteilung an.

Theorem 40.4 (T-Teststatistik des Zweistichproben-T-Tests)**.** *Gegeben sei die Designmatrixform des Zweistichproben-T-Tests. Dann ergibt sich für die T-Teststatistik mit*

$$c := (1, -1)^T \text{ und } c^T \beta_0 =: \mu_0, \tag{40.20}$$

dass

$$T = \sqrt{\frac{n_1 n_2}{n_1 + n_2}} \left(\frac{\bar{y}_1 - \bar{y}_2 - \mu_0}{s_{12}} \right) \tag{40.21}$$

und es gilt

$$T \sim t\left(\delta, n_1 + n_2 - 2\right) \text{ mit } \delta = \sqrt{\frac{n_1 n_2}{n_1 + n_2}} \left(\frac{\mu_1 - \mu_2 - \mu_0}{\sigma} \right). \tag{40.22}$$

∘

Beweis. Mit Theorem 38.1 gilt zunächst für die Zähler von T und δ, dass

$$c^T \hat{\beta} - c^T \beta_0 = \begin{pmatrix} 1 & -1 \end{pmatrix} \begin{pmatrix} \bar{y}_1 \\ \bar{y}_2 \end{pmatrix} - \mu_0 = \bar{y}_1 - \bar{y}_2 - \mu_0 \tag{40.23}$$

und

$$c^T \beta - c^T \beta_0 = \begin{pmatrix} 1 & -1 \end{pmatrix} \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} - \mu_0 = \mu_1 - \mu_2 - \mu_0 \tag{40.24}$$

respektive. Weiterhin gilt für die Nenner von T und δ, dass

$$c^T \left(X^T X\right)^{-1} c = \begin{pmatrix} 1 & -1 \end{pmatrix} \begin{pmatrix} n_1^{-1} & 0 \\ 0 & n_2^{-1} \end{pmatrix} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} n_1^{-1} & -n_2^{-1} \end{pmatrix} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \frac{1}{n_1} + \frac{1}{n_2} \tag{40.25}$$

Außerdem gilt

$$\left(\frac{1}{n_1} + \frac{1}{n_2}\right)^{-\frac{1}{2}} = \left(\frac{n_2}{n_1 n_2} + \frac{n_1}{n_1 n_2}\right)^{-\frac{1}{2}} = \left(\frac{n_1 + n_2}{n_1 n_2}\right)^{-\frac{1}{2}} = \left(\frac{n_1 n_2}{n_1 + n_2}\right)^{\frac{1}{2}} \tag{40.26}$$

Zusammengenommen folgt direkt, dass

$$T = \sqrt{\frac{n_1 n_2}{n_1 + n_2}} \left(\frac{\bar{y}_1 - \bar{y}_2 - \mu_0}{s_{12}}\right) \text{ und } \delta = \sqrt{\frac{n_1 n_2}{n_1 + n_2}} \left(\frac{\mu_1 - \mu_2 - \mu_0}{\sigma}\right). \tag{40.27}$$

□

Die Formen der T-Teststatistik und ihre Verteilung im Zweistichproben-T-Test Modell in Designmatrixform sind also wiederum natürlicherweise mit den entsprechenden Formen im ALM-freien Kontext identisch. Die enstprechende zur Kontrolle des Testumfangs bei Zweistichproben-T-Tests sowie der Gebrauch der Testgütefunktion zur Evaluation der Testtrennschärfe (Power) folgt also analog.

Anwendungsbeispiel

Folgender **R** Code demonstriert die Evaluation von 95%-Konfidenzintervallen für die Erwartungswertparameter μ_1 und μ_2 sowie Durchführung eines zweiseitigen ZweistichprobenT-Tests mit Nullhypothese

$$\Theta_0 := \left\{ \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} \in \mathbb{R}^2 \mid \mu_1 = \mu_2 \right\} \tag{40.28}$$

und Signifikanzlevel $\alpha_0 := 0.05$ für das oben skizzierte Anwendungsbeispiel.

```
# Dateneinlesen
D           = read.csv("./_data/507-t-tests.csv")              # Dataframe
y_1         = D$dBDI[D$COND == "F2F"]                          # BDI Differenzwerte in der F2F Gruppe
y_2         = D$dBDI[D$COND == "ONL"]                          # BDI Differenzwerte in der ONL Gruppe

# Modellformulierung
n_1         = length(y_1)                                      # Anzahl Datenpunkte Gruppe 1 (F2F)
n_2         = length(y_1)                                      # Anzahl Datenpunkte Gruppe 2 (ONL)
n           = n_1 + n_2                                        # Gesamtanzahl Datenpunkte
y           = matrix(c(y_1, y_2), nrow = n)                    # Datenvektor
p           = 2                                                # Anzahl Betaparameter
X           = matrix(c(rep(1,n_1), rep(0,n_2),                 # Zweistichproben-T-Test Designmatrix
                       rep(0,n_1), rep(1,n_2)),
                     nrow = n)

# Parameterschätzng
beta_hat    = solve(t(X) %*% X) %*% t(X) %*% y                 # Betaparameterschätzer
eps_hat     = y - X %*% beta_hat                               # Residuenvektor
sigsqr_hat  = (t(eps_hat) %*% eps_hat) /(n-p)                  # Varianzparameterschätzer

# Konfidenzintervall
delta       = 0.95                                             # Konfidenzbedingung
t_delta     = qt((1+delta)/2,n-1)                              # \Psi^{-1}((1+\delta)/2,n-1)
lambda      = diag(solve(t(X) %*% X))                          # \lambda_j Werte
kappa       = matrix(rep(NaN,p*2), nrow = p)                   # \beta_j Konfidenintervall array
for(j in 1:p){                                                 # Iteration über \beta_j
  kappa[j,1] = beta_hat[j]-sqrt(sigsqr_hat*lambda[j])*t_delta  # untere KI Grenze
  kappa[j,2] = beta_hat[j]+sqrt(sigsqr_hat*lambda[j])*t_delta} # obere KI Grenze

# Hypothesentest
c           = matrix(c(1,-1), nrow = 2)                        # Kontrastgewichtsvektor
mu_0        = 0                                                # Nullhypothese H_0
alpha_0     = 0.05                                             # Signifikanzniveau
k_alpha_0   = qt(1 - (alpha_0/2), n-1)                         # kritischer Wert
t_num       = t(c) %*% beta_hat - mu_0                         # T-Teststatistik Zähler
t_den       = sqrt(sigsqr_hat*t(c) %*% solve(t(X) %*% X)%*%c)  # T-Teststatistik Nenner
t           = t_num/t_den                                      # T-Teststatistik
if(abs(t) >= k_alpha_0){phi = 1} else {phi = 0}                # Test 1_{|T(X) >= k_alpha_0|}
pval      = 2*(1-pt(abs(t), n_1+n_2-2))                        # p-Wert
```

```
Betaparametersch<U+00E4>tzer            :  3.5 7.42
95%-Konfidenzintervalle         :  1.41 5.32 5.59 9.51
Varianzparametersch<U+00E4>tzer         :  12.27
alpha_0                         :  0.05
Kritischer Wert                 :  2.07
Einstichproben-T-Teststatistik  :  -2.74
phi                             :  1
p-Wert                          :  0.01
```

Die Nullhypothese würde in diesem Fall bei einem kritischen Wert von $k_{0.05} = 2.07$ und einem Wert der T-Statistik von $T = -033$ nicht verworfen werden. Inferenzstatisch besteht also keine Evidenz dafür, dass sich der wahre, aber unbekannte Erwartungswertparameter im F2F Therapiesetting vom wahren, aber unbekannte Erwartungswertparameter im ONL Therapiesetting unterscheidet. Die 95%Konfidenzintervalle für die wahren, aber unbekannten, Erwartungswertparameter μ_1 und μ_2 sind $[2.60, 7.74]$ und $[3.18, 8.32]$, respektive.

40.4. Literaturhinweise

Obwohl die frequentistische Literatur der ersten Hälfte des 20. Jahrhunderts von der Äquivalenz regressions- und varianzanalytischer linearer Modelle durchdrungen ist, fällt es schwer eine definite Quelle anzugeben, die hinsichtlich der Beschreibung von T-Tests als Spezialfälle des ALM Priorität hätte. Es sei hier deshalb eher allgemein auf Fisher (1925a) und Fisher (1935) verwiesen.

41. Einfaktorielle Varianzanalyse

41.1. Anwendungsszenario

Das Anwendungsszenario einer einfaktoriellen Varianzanalyse ist durch das Vorliegen von n univariaten Datenpunkten von zwei oder mehr Gruppen randomisierter experimenteller Einheiten gekennzeichnet, die sich hinsichtlich der Level eines experimentellen Faktors unterscheiden. Ist die Anzahl an Datenpunkten in jeder Gruppe gleich, so spricht man auch von einem balancierten einfaktoriellen Varianzanalysedesign. Von den Datenpunkten der i-ten Gruppe bzw. des i-ten Faktorlevels wird dabei angenommen, dass sie Realisierungen von jeweils n_i unabhängigen und identisch normalverteilten Zufallsvariablen sind, deren wahre, aber unbekannte, Erwartungswertparameter sich potentiell über die Gruppen hinweg unterscheiden und deren wahrer, aber unbekannter, Varianzparameter über Gruppen hinweg identisch ist. In diesen Grundannahmen handelt es sich bei dem Szenario der einfaktoriellen Varianzanalyse also um eine direkte Generalisierung des Einstich- und Zweistichproben-T-Test-Szenarios zu (potentiell) mehr als zwei Gruppen. Umgekehrt können die Einstichproben- und Zweistichproben-T-Test Szenarien natürlich auch als einfaktorielle Varianzanalyseszenarien betrachtet werden, bei denen der experimentelle Faktor (nur) ein oder zwei Level, respektive, aufweist. Schließlich wird wie im Falle der T-Test Szenarien meist vorausgesetzt, dass ein Interesse an einem inferentiellen Vergleich der wahren, aber unbekannten, faktorlevelspezifischen Erwartungswertparameter besteht.

41.2. Anwendungsbeispiel

Als konkretes Anwendungsbeispiel betrachten wir die Analyse von Pre-Post-Interventions-BDI-Differenzwerten von drei Gruppen von jeweils 12 Patient:innen, die unterschiedliche Therapiesettings (Face-to-Face und Online) bzw. eine Wartelistenkontrollbedingung durchlaufen haben, wie in Tabelle 41.1 exemplarisch dargestellt. Die erste Spalte der Tabelle (`COND`) listet das patient:innenspezifische Therapiesetting (`F2F`: face-to-face, `ONL`: online, `WLC`: waitlist control) für jeweils drei Patient:innen jeder Studiengruppe auf. Die zweite Spalte der Tabelle (`dBDI`) list die entsprechenden patient:innenspezifischen Pre-PostInterventions-BDI-Differenzwerte. Positive Werte enstprechen hier wieder einer Abnahme der Depressionssymptomatik, negative Werte einer Zunahme der Depressionssymptomatik.

Tabelle 41.1. Exemplarische Pre-Post-Intervention-BDI-Differenzwerte des Beispieldatensatzes

	COND	dBDI
1	F2F	9
2	F2F	7
3	F2F	10
4	F2F	11
13	ONL	2

Tabelle 41.1. Exemplarische Pre-Post-Intervention-BDI-Differenzwerte des Beispieldatensatzes

	COND	dBDI
14	ONL	7
15	ONL	9
16	ONL	9
17	ONL	8
25	WLC	-1
26	WLC	2
27	WLC	-3
28	WLC	-1
29	WLC	0

Abbildung 41.1 zeigt eine Visualisierung des gesamten Datensatzes. Die Balken repräsentieren die gruppenspezifischen Stichprobenmittelwerte, die zugehörigen Fehlerbalken die gruppenspezifischen Stichprobenstandardabweichungen. Die Punktwolken repräsentieren die gruppenspezifischen Datenpunkte. In den F2F und ONL Gruppen ist die Veränderung des BDI Wertes stärker ausgeprägt als in der WLC Gruppe.

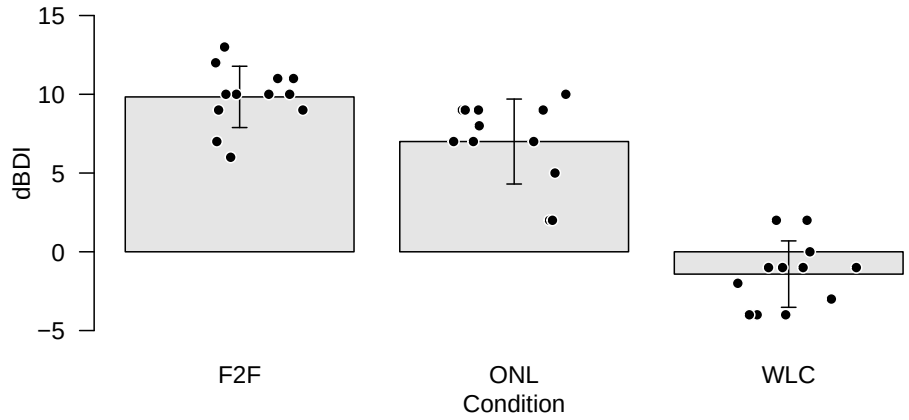


Abbildung 41.1. Datendarstellung des Anwendungsbeispiels zur Einfaktoriellen Varianzanalyse.

In Tabelle 41.2 fassen wir die Deskriptivstatistiken des Beispieldatensatzes, aufgeschlüsselt nach Therapiebedingungen, zusammen.

Tabelle 41.2. Deskriptivstatistiken der Pre-Post BDI Differenzwerte

	n	Max	Min	Median	Mean	Var	Std
F2F	12	13	6	10.0	9.83	3.79	1.95
ONL	12	10	2	7.5	7.00	7.27	2.70
WLC	12	2	-4	-1.0	-1.42	4.45	2.11

41.3. Modellformulierung

Wir definieren das Modell der EVA zunächst in Erwartungswertparameterdarstellung. Dabei nutzen wir den Index i um die experimentellen Gruppen zu indizieren und den Index j um die experimentellen Einhe*i*-ten innerhalb der Gruppen zu indizieren.

Definition 41.1 (EVA-Modell in Erwartungswertparameterdarstellung)**.** Für $i = 1, \dots, p$ und $j = 1, \dots, n_i$ seien y_{ij} Zufallsvariablen, die die $n := \sum_{i=1}^{p} n_i$ Datenpunkte eines EVA Szenarios modellieren. Dann hat das EVA-Modell in Erwartungswertparameterdarstellung die strukturelle Form

$$y_{ij} = \mu_i + \varepsilon_{ij} \text{ mit } \varepsilon_{ij} \sim N\left(0, \sigma^2\right) \text{ u.i.v. mit } \mu_i \in \mathbb{R}, \sigma^2 > 0, \tag{41.1}$$

die Datenverteilungsform

$$y_{ij} \sim N\left(\mu_i, \sigma^2\right) \text{ u.v. mit } \mu_i \in \mathbb{R}, \sigma^2 > 0. \tag{41.2}$$

und für den n-dimensionalen Datenvektor definiert als

$$y := \left(y_{11}, \dots, y_{1n_1}, y_{21}, \dots, y_{2n_2}, \dots, y_{p1}, \dots, y_{pn_p}\right)^T \tag{41.3}$$

die Designmatrixform

$$y = X\beta + \varepsilon \tag{41.4}$$

mit

$$X := \begin{pmatrix} 1_{n_1} & 0_{n_1} & \cdots & 0_{n_1} \\ 0_{n_2} & 1_{n_2} & \cdots & 0_{n_2} \\ \vdots & \vdots & \ddots & \vdots \\ 0_{n_p} & 0_{n_p} & \cdots & 1_{n_p} \end{pmatrix}, \beta := \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{pmatrix} \in \mathbb{R}^p, \varepsilon \sim N\left(0_n, \sigma^2 I_n\right), \sigma^2 > 0. \tag{41.5}$$

Für $n_i := m$ für alle $i = 1, \dots, p$ heißt das Modell balanciert.

•

Der Vergleich mit der Definition des Modells des Zweistichproben-T-Tests in Definition 40.2 zeigt, dass es sich bei dieser Formulierung des EVA-Modells um die direkte Generalisierung des Zweistichproben-T-Test Modells von $p = 2$ für ein beliebiges $p \in \mathbb{N}$ handelt.

Motivation der Effektdarstellung

Das EVA-Modell in Erwartungswertparameterdarstellung ist ein valides Modell, auf dessen Grundlage sowohl Parameterschätzung als auch Parameter- und Modellinferenz für das EVA-Szenario entwickelt werden können (vgl. Georgii (2009)). Im Sinne der Konsistenz mit den Modellen der mehrfaktoriellen Varianzanalyse bietet sich jedoch eine Reparametrisierung des Betaparametervektors an. Kern dieser Reparametrisierung ist es, den Erwartungswertparameter der i-ten Gruppe als Summe eines gruppenübergreifenden Erwartungswertparameters $\mu_0 \in \mathbb{R}$ und eines gruppenspezifischen Effektparameters $\alpha_i \in \mathbb{R}$ zu modellieren,

$$\mu_i := \mu_0 + \alpha_i \text{ für } i = 1, \dots, p. \tag{41.6}$$

Dabei modelliert α_i die Differenz zwischen dem i-ten Erwartungswertparameter μ_i und dem gruppenübergreifenden Erwartungswertparameter μ_0,

$$\alpha_i = \mu_i - \mu_0 \text{ für } i = 1, \dots, p. \tag{41.7}$$

Allerdings hat die in dieser Form vorgenommene Reparametrisierung einen entscheidenden Nachteil: es werden p Erwartungswertparameter $\mu_i, i = 1, \dots, p$ durch die $p+1$ Parameter μ_0 und $\alpha_i, i = 1, \dots, p$ dargestellt. Diese Darstellung ist im Allgemeinen nicht eindeutig. Zum Beispiel können die Erwartungswertparameter $\mu_1 = 3, \mu_2 = 5, \mu_3 = 6$ sowohl durch den gruppenspezifischen Erwartungswertparameter $\mu_0 = 0$ und die gruppenunspezifischen Effektparameter $\alpha_1 = 3, \alpha_2 = 5, \alpha_3 = 6$ als auch durch den gruppenunspezifischen Erwartungswertparameter $\mu_0 = 1$ und die gruppenspezifischen Effektparameter $\alpha_1 = 2, \alpha_2 = 4, \alpha_3 = 5$ dargestellt werden. Man sagt in diesem Kontext auch, dass das EVA-Modell in der Form von Gleichung 41.6 überparametrisiert ist.

Datenanalytisch hat die Überparametrisierung eines Varianzanalysemodells den Nachteil, dass aus p geschätzten Erwartungswertparametern $p+1$ Betaparameterschätzer bestimmt werden müssten, was wie oben gesehen nicht eindeutig erfolgen kann. Um diese Probleme in der Effektparameterdarstellung des EVA-Modells zu umgehen und diese konsistent auf mehrfaktorielle Varianzanalysemodelle zu übertragen, bietet sich die Einführung der Nebenbedingung

$$\alpha_1 := 0 \tag{41.8}$$

an. Es wird also ein Effektparameter von vornherein als identisch Null angenommen. Für die gruppenspezifischen Erwartungswertparameter ergibt sich damit

$$\begin{aligned} \mu_1 &:= \mu_0 \\ \mu_i &:= \mu_0 + \alpha_i \text{ für } i = 2, \dots, p. \end{aligned} \tag{41.9}$$

Hierbei wird die erste Gruppe nun als Referenzgruppe bezeichnet und die α_i modellieren die Differenz zwischen dem Erwartungswertparameter der i-ten Gruppe und dem Erwartungswertparameter der ersten Gruppe:

$$\alpha_i = \mu_i - \mu_0 = \mu_i - \mu_1 \text{ für } i = 1, \dots, p. \tag{41.10}$$

μ_0 ist, unter der Nebenbedingung $\alpha_1 := 0$ also kein gruppenübergreifender Erwartungswertparameter mehr, sondern identisch mit dem Erwartungswertparameter der ersten Gruppe. Welche tatsächliche experimentelle Gruppe dabei als "erste Gruppe" definiert wird, ist datenanalytisch unerheblich. Datenanalytisch entscheidend dagegegen ist, dass der entsprechenden Erwartungswertparameterschätzer $\hat{\mu}_0$ korrekt als Erwartungswertparameterschätzer der Referenzgruppe und die $\hat{\alpha}_i$ für $i = 2, \dots, p$ korrekt als geschätzte Erwartungswertparameterdifferenzen zwischen dem Erwartungswertparameter der Referenzgruppe und dem Erwartungswertparameter der i-ten Gruppe verstanden werden.

Wir formalisieren das oben Gesagte in folgendem Theorem.

Theorem 41.1 (EVA-Modell in Effektdarstellung mit Referenzgruppe)**.** *Gegeben sei das EVA-Modell in Erwartungswertparameterdarstellung. Dann können die Zufallsvariablen, die die Datenpunkte des EVA-Szenarios modellieren, äquivalent in der strukturellen Form*

$$\begin{aligned} y_{1j} &= \mu_0 + \varepsilon_{1j} \quad \textit{mit } \varepsilon_{1j} \sim N(0, \sigma^2) \;\; \textit{u.i.v. für } j = 1, \dots, n_1 \\ y_{ij} &= \mu_0 + \alpha_i + \varepsilon_{ij} \; \textit{mit } \varepsilon_{ij} \sim N(0, \sigma^2) \;\; \textit{u.i.v. für } i = 2, \dots, p, j = 1, \dots, n_i \end{aligned} \tag{41.11}$$

mit

$$\alpha_i := \mu_i - \mu_1 \text{ für } i = 2, \dots, p \tag{41.12}$$

und in der entsprechenden Datenverteilungsform

$$\begin{aligned} y_{1j} &\sim N(\mu_0, \sigma^2) \quad \text{u.i.v. für } j = 1, \dots, n_i \text{ mit } \mu_1 \in \mathbb{R}, \sigma^2 > 0 \\ y_{ij} &\sim N(\mu_0 + \alpha_i, \sigma^2) \quad \text{u.v. für } i = 2, \dots, p, j = 1, \dots, n_i \text{ mit } \alpha_i \in \mathbb{R}, \sigma^2 > 0 \end{aligned} \tag{41.13}$$

geschrieben werden.

∘

Beweis. Nach Definition gilt

$$\mu_i = \mu_0 + \mu_i - \mu_0. \tag{41.14}$$

Die Parametrisierungen mit μ_i und mit $\mu_0 + \mu_i - \mu_0$ sind also gleich und damit äquivalent. Dann folgt aber auch

$$\mu_i = \mu_0 + (\mu_i - \mu_0) =: \mu_0 + \alpha_i \text{ für } i = 1, \dots, p. \tag{41.15}$$

Mit $\alpha_1 := 0$ gilt dann $\mu_1 = \mu_0$ und $\mu_i = \mu_0 + \alpha_i$ für $i = 2, \dots, p$, wie im Theorem behauptet. □

Basierend auf Theorem 41.1 definieren wir nun das Modell der EVA in Effektdarstellung.

Definition 41.2 (EVA-Modell in Effektdarstellung mit Referenzgruppe)**.** Für $i = 1, \dots, p$ und $j = 1, \dots, n_i$ seien y_{ij} Zufallsvariablen, die die $n := \sum_{i=1}^{p} n_i$ Datenpunkte eines EVA-Szenarios modellieren. Dann hat das EVA-Modell in Effektdarstellung die strukturelle Form

$$\begin{aligned} y_{1j} &= \mu_0 + \varepsilon_{1j} \quad \text{mit } \varepsilon_{1j} \sim N(0, \sigma^2) \text{ u.i.v. für } j = 1, \dots, n_1 \\ y_{ij} &= \mu_0 + \alpha_i + \varepsilon_{ij} \text{ mit } \varepsilon_{ij} \sim N(0, \sigma^2) \text{ u.i.v. für } i = 2, \dots, p, j = 1, \dots, n_i \end{aligned} \tag{41.16}$$

mit

$$\alpha_i := \mu_i - \mu_1 \text{ für } i = 2, \dots, p, \tag{41.17}$$

die Datenverteilungsform

$$\begin{aligned} y_{1j} &\sim N(\mu_0, \sigma^2) \quad \text{u.i.v. für } j = 1, \dots, n_i \text{ mit } \mu_0 \in \mathbb{R}, \sigma^2 > 0 \\ y_{ij} &\sim N(\mu_0 + \alpha_i, \sigma^2) \quad \text{u.v. für } i = 2, \dots, p, j = 1, \dots, n_i \text{ mit } \alpha_i \in \mathbb{R}, \sigma^2 > 0 \end{aligned} \tag{41.18}$$

und die Designmatrixform

$$y = X\beta + \varepsilon \text{ mit } \varepsilon \sim N(0_n, \sigma^2 I_n) \tag{41.19}$$

und

$$n := \sum_{i=1}^{p} n_i, y := \begin{pmatrix} y_{11} \\ \vdots \\ y_{1n_1} \\ y_{21} \\ \vdots \\ y_{2n_2} \\ \vdots \\ y_{p1} \\ \vdots \\ y_{pn_p} \end{pmatrix} \in \mathbb{R}^n, X := \begin{pmatrix} 1_{n_1} & 0_{n_1} & \cdots & 0_{n_1} \\ 1_{n_2} & 1_{n_2} & \cdots & 0_{n_2} \\ \vdots & \vdots & \ddots & \vdots \\ 1_{n_p} & 0_{n_p} & \cdots & 1_{n_p} \end{pmatrix} \in \mathbb{R}^{n \times p}, \beta := \begin{pmatrix} \mu_0 \\ \alpha_2 \\ \vdots \\ \alpha_p \end{pmatrix} \in \mathbb{R}^p \text{ und } \sigma^2 > 0. \tag{41.20}$$

•

Beispiel 41.1 (Erwartungswert- und Effektparameterdarstellung des EVA-Modells)**.** Um die Unterschiede und Gemeinsamkeiten zwischen der Erwartungswertparameterdarstellung und der Effektparameterdarstellung des EVA-Modells in ihrer Designmatrixform zu verdeutlichen, betrachten wir ein Beispielszenario mit $n_i := 4$ und $p = 3$ für $i = 1, \ldots, p$, also $n = 12$. Für die Erwartunswertparameterdarstellung gilt dann

$$y = X\beta + \varepsilon \text{ mit } \varepsilon \sim N\left(0_{12}, \sigma^2 I_{12}\right) \tag{41.21}$$

mit

$$y := \begin{pmatrix} y_{11} \\ y_{12} \\ y_{13} \\ y_{21} \\ y_{22} \\ y_{23} \\ y_{31} \\ y_{32} \\ y_{33} \\ y_{41} \\ y_{42} \\ y_{43} \end{pmatrix}, X := \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{pmatrix} \in \mathbb{R}^{12\times 3}, \beta := \begin{pmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \end{pmatrix} \in \mathbb{R}^3 \text{ und } \sigma^2 > 0. \tag{41.22}$$

Für die Effektparameterdarstellung dagegen gilt

$$y = X\beta + \varepsilon \text{ mit } \varepsilon \sim N\left(0_{12}, \sigma^2 I_{12}\right) \tag{41.23}$$

mit

$$y := \begin{pmatrix} y_{11} \\ y_{12} \\ y_{13} \\ y_{21} \\ y_{22} \\ y_{23} \\ y_{31} \\ y_{32} \\ y_{33} \\ y_{41} \\ y_{42} \\ y_{43} \end{pmatrix}, X := \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \end{pmatrix} \in \mathbb{R}^{12\times 3}, \beta := \begin{pmatrix} \mu_0 \\ \alpha_2 \\ \alpha_3 \end{pmatrix} \in \mathbb{R}^3 \text{ und } \sigma^2 > 0 \tag{41.24}$$

Folgender **R** Code demonstriert die Realisierung von Daten in einem EVA-Szenario mit eben dieser Effektparameterdarstellung.

```
# Modellformulierung
library(MASS)
m      = 4                                                    # Multivariate Normalverteilung
p      = 3                                                    # Anzahl von Datenpunkten der iten Gruppe
n      = p*m                                                  # Anzahl Gruppen
Xt     = cbind(                                               # Gesamtanzahl Datenpunkte
           matrix(1,nrow = n, ncol = 1),                      # Designmatrix
           kronecker(diag(p), matrix(1,nrow = m,ncol = 1)))
X      = Xt[,-2]
I_n    = diag(n)                                              # n x n Einheitsmatrix
beta   = matrix(c(10,-3,-12), nrow = p)                       # \beta = (\mu_0,\alpha_2,\alpha_3,\alpha_4)
sigsqr = 14                                                   # \sigma^2
y      = mvrnorm(1, X %*% beta, sigsqr*I_n)                   # eine Realisierung eines n-dimensionalen ZVs
print(X)
```

```
      [,1] [,2] [,3]
 [1,]    1    0    0
 [2,]    1    0    0
 [3,]    1    0    0
 [4,]    1    0    0
 [5,]    1    1    0
 [6,]    1    1    0
 [7,]    1    1    0
 [8,]    1    1    0
 [9,]    1    0    1
[10,]    1    0    1
[11,]    1    0    1
[12,]    1    0    1
```

△

41.4. Modellschätzung

Wir betrachten nun die Betaparameterschätzung in der Effektparameterdarstellung des EVA-Modells mit Referenzgruppe. Entsprechend der Interpretation der Betaparameterkomponenten werden dabei μ_0 durch das Stichprobenmittel der Referenzgruppe und die $\alpha_2, \ldots, \alpha_p$ durch die Differenzen des jeweiligen Gruppenstichprobenmittels und des Referenzgruppenstichprobenmittels geschätzt. Auf die Schätzung des Varianzparameters, der sich wie im Zweistichproben-T-Test Modell zu einer *gepoolten Stichprobenvarianz* ergibt, wollen wir hier nicht weiter eingehen.

Theorem 41.2 (Betaparameterschätzung im EVA-Modell)**.** *Gegeben sei die Designmatrixform des EVA in Effektdarstellung mit Referenzgruppe. Dann ergibt sich für den Betaparameterschätzer*

$$\hat{\beta} := \begin{pmatrix} \hat{\mu}_0 \\ \hat{\alpha}_2 \\ \vdots \\ \hat{\alpha}_p \end{pmatrix} = \begin{pmatrix} \bar{y}_1 \\ \bar{y}_2 - \bar{y}_1 \\ \vdots \\ \bar{y}_p - \bar{y}_1 \end{pmatrix} \tag{41.25}$$

wobei

$$\bar{y}_i := \frac{1}{n_i} \sum_{j=1}^{n_i} y_{ij} \tag{41.26}$$

das Stichprobenmittel der i-ten Gruppe bezeichnet.

∘

Beweis. Wir halten zunächst fest, dass

$$\begin{aligned} X^T X &= \begin{pmatrix} 1 & \cdots & 1 & 1 & \cdots & 1 & \cdots & 1 & \cdots & 1 \\ 0 & \cdots & 0 & 1 & \cdots & 1 & \cdots & 0 & \cdots & 0 \\ & \vdots & & & \vdots & & \vdots & & \vdots & \\ 0 & \cdots & 0 & 0 & \cdots & 0 & \cdots & 1 & \cdots & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 & & 0 \\ \vdots & \vdots & \cdots & \vdots \\ 1 & 0 & & 0 \\ 1 & 1 & & 0 \\ \vdots & \vdots & \cdots & \vdots \\ 1 & 1 & & 0 \\ & & & \\ \vdots & \vdots & \cdots & \vdots \\ 1 & 0 & & 1 \\ \vdots & \vdots & \cdots & \vdots \\ 1 & 0 & & 1 \end{pmatrix} \\ &= \begin{pmatrix} n & n_2 & n_3 & \cdots & n_p \\ n_2 & n_2 & 0 & \cdots & 0 \\ n_3 & 0 & n_3 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ n_p & 0 & 0 & \cdots & n_p \end{pmatrix}. \end{aligned} \tag{41.27}$$

Die Inverse von $X^T X$ ist

$$(X^T X)^{-1} = \begin{pmatrix} \frac{1}{n_1} & -\frac{1}{n_1} & \cdots & -\frac{1}{n_1} \\ -\frac{1}{n_1} & \frac{n_1+n_2}{n_1 n_2} & \cdots & \frac{1}{n_1} \\ \vdots & \vdots & \ddots & \vdots \\ -\frac{1}{n_1} & \frac{1}{n_1} & \cdots & \frac{n_1+n_p}{n_1 n_p} \end{pmatrix} \tag{41.28}$$

So gilt zum Beispiel für $p = 3$, dass

$$X^T X = \begin{pmatrix} n & n_2 & n_3 \\ n_2 & n_2 & 0 \\ n_3 & 0 & n_3 \end{pmatrix} \text{ und } \left(X^T X\right)^{-1} = \begin{pmatrix} \frac{1}{n_1} & -\frac{1}{n_1} & -\frac{1}{n_1} \\ -\frac{1}{n_1} & \frac{n_1+n_2}{n_1 n_2} & \frac{1}{n_1} \\ -\frac{1}{n_1} & \frac{1}{n_1} & \frac{n_1+n_3}{n_1 n_3} \end{pmatrix} \tag{41.29}$$

Wir halten weiterhin fest, dass

$$\begin{aligned} X^T y &= \begin{pmatrix} 1 & \cdots & 1 & 1 & \cdots & 1 & \cdots & 1 & \cdots & 1 \\ 0 & \cdots & 0 & 1 & \cdots & 1 & \cdots & 0 & \cdots & 0 \\ & \vdots & & & \vdots & & \vdots & & & \\ 0 & \cdots & 0 & 0 & \cdots & 0 & \cdots & 1 & \cdots & 1 \end{pmatrix} \begin{pmatrix} y_{11} \\ \vdots \\ y_{1n_1} \\ y_{21} \\ \vdots \\ y_{2n_2} \\ \vdots \\ y_{p1} \\ \vdots \\ y_{pn_p} \end{pmatrix} \\ &= \begin{pmatrix} \sum_{i=1}^{p} \sum_{j=1}^{n_i} y_{ij} \\ \sum_{j=1}^{n_2} y_{2j} \\ \vdots \\ \sum_{j=1}^{n_p} y_{pj} \end{pmatrix}. \end{aligned} \tag{41.30}$$

Es ergibt sich also

$$\hat{\beta} = \left(X^T X\right)^{-1} X^T y = \begin{pmatrix} \frac{1}{n_1} & -\frac{1}{n_1} & \cdots & -\frac{1}{n_1} \\ -\frac{1}{n_1} & \frac{n_1+n_2}{n_1 n_2} & \cdots & \frac{1}{n_1} \\ \vdots & \vdots & \ddots & \vdots \\ -\frac{1}{n_1} & \frac{1}{n_1} & \cdots & \frac{n_1+n_p}{n_1 n_p} \end{pmatrix} \begin{pmatrix} \sum_{i=1}^{p} \sum_{j=1}^{n_i} y_{ij} \\ \sum_{j=1}^{n_2} y_{2j} \\ \vdots \\ \sum_{j=1}^{n_p} y_{pj} \end{pmatrix} \tag{41.31}$$

Für die erste Komponente von $\hat{\beta}$ ergibt sich damit

$$\begin{aligned} \hat{\beta}_0 &= \frac{1}{n_1} \sum_{i=1}^{p} \sum_{j=1}^{n_i} y_{ij} - \frac{1}{n_1} \sum_{j=1}^{n_2} y_{2j} - \cdots - \frac{1}{n_1} \sum_{j=1}^{n_p} y_{pj} \\ &= \frac{1}{n_1} \left(\left(\sum_{j=1}^{n_1} y_{1j} + \sum_{j=1}^{n_2} y_{2j} + \cdots + \sum_{j=1}^{n_p} y_{pj} \right) - \sum_{j=1}^{n_2} y_{2j} - \cdots - \sum_{j=1}^{n_p} y_{pj} \right) \\ &= \frac{1}{n_1} \sum_{j=1}^{n_1} y_{1j} \\ &= \bar{y}_1. \end{aligned} \tag{41.32}$$

Für die zweite Komponente von $\hat{\beta}$ und analog für alle weiteren ergibt sich

$$\begin{aligned} \hat{\beta}_2 &= -\frac{1}{n_1} \sum_{i=1}^{p} \sum_{j=1}^{n_i} y_{ij} + \frac{n_1+n_2}{n_1 n_2} \sum_{j=1}^{n_2} y_{2j} + \frac{1}{n_1} \sum_{j=1}^{n_3} y_{3j} + \cdots + \frac{1}{n_1} \sum_{j=1}^{n_p} y_{pj} \\ &= \frac{n_1+n_2}{n_1 n_2} \sum_{j=1}^{n_2} y_{2j} - \frac{1}{n_1} \left(\left(\sum_{j=1}^{n_1} y_{1j} + \sum_{j=1}^{n_2} y_{2j} + \cdots + \sum_{j=1}^{n_p} y_{pj} \right) - \sum_{j=1}^{n_3} y_{3j} - \cdots - \sum_{j=1}^{n_p} y_{pj} \right) \\ &= \frac{n_1+n_2}{n_1 n_2} \sum_{j=1}^{n_2} y_{2j} - \frac{1}{n_1} \sum_{j=1}^{n_1} y_{1j} - \frac{1}{n_1} \sum_{j=1}^{n_2} y_{2j} \\ &= \frac{n_1+n_2}{n_1 n_2} \sum_{j=1}^{n_2} y_{2j} - \frac{n_2}{n_1 n_2} \sum_{j=1}^{n_2} y_{2j} - \frac{1}{n_1} \sum_{j=1}^{n_1} y_{1j} \\ &= \frac{n_1}{n_1 n_2} \sum_{j=1}^{n_2} y_{2j} - \frac{1}{n_1} \sum_{j=1}^{n_1} y_{1j} \\ &= \frac{1}{n_2} \sum_{j=1}^{n_2} y_{2j} - \frac{1}{n_1} \sum_{j=1}^{n_1} y_{1j} \\ &= \bar{y}_2 - \bar{y}_1. \end{aligned} \tag{41.33}$$

□

Folgender **R** Code implementiert die Parameterschätzung des EVA-Modells für den Beispieldatensatz. Neben der mithilfe des Betaparameterschätzers gewonnnenen Schätzwerte für den Referenzgruppen- und Effektparameter evaluiert der Code auch die stichprobenmittel(differenzen)basierten Schätzer aus Theorem 41.2. Weiterhin evaluiert der Code neben dem Varianzparameterschätzer auch die gepoolte Stichprobenvarianz sowie die Gesamtstichprobenvarianz, die sich deutlich unterscheiden.

```
# Datenmanagement
D           = read.csv("./_data/508-einfaktorielle-varianzanalyse.csv")          # Dataframe
y           = D$dBDI                                                             # Datenvektor
y_1         = D$dBDI[D$COND == "F2F"]                                            # Daten F2F
y_2         = D$dBDI[D$COND == "ONL"]                                            # Daten ONL
y_3         = D$dBDI[D$COND == "WLC"]                                            # Daten WLC

# Modellformulierung
p           = 3                                                                  # drei Gruppen
m           = length(y_1)                                                        # balancierters Design
n           = p*m                                                                # Datenvektordimension
Xt          = cbind(                                                             # Designmatrix
              matrix(1, nrow = n, ncol = 1),
              kronecker(diag(p), matrix(1, nrow = m, ncol = 1)))
X           = Xt[,-2]

# Modellschätzung
beta_hat    = solve(t(X) %*% X) %*% t(X) %*% y                                   # Betaparameterschätzer
eps_hat     = y - X %*% beta_hat                                                 # Residuenvektor
sigsqr_hat  = (t(eps_hat) %*% eps_hat) /(n-p)                                    # Varianzparameterschätzer
s_sqr_123   = ((m-1)*var(y_1) +                                                  # gepoolte Stichprobenvarianz
               (m-1)*var(y_2) +
               (m-1)*var(y_3))/(m+m+m-p)
```

```
hat{beta}                                    :  9.83 -2.83 -11.25
bar{y}_1,bar{y}_2,bar{y}_3                   :  9.83 7 -1.42
bar{y}_1,bar{y}_2-bar{y}_1,bar{y}_3-bar{y}_1 :  9.83 -2.83 -11.25
hat{sigsqr}                                  :  5.17
s_123^2                                      :  5.17
s_y^2                                        :  28.35
```

41.5. Modellevaluation

Prinzipiell sind alle Parameterschätzwerte in einem EVA-Modell von Interesse und können mithilfe von T-Statistiken im Sinne von Konfidenzintervallen oder Hypothesentests evaluiert werden. Traditionell steht im EVA-Szenario allerdings häufig die Evaluation der Nullhypothese, dass die wahren, aber unbekannten, Erwartungswertparameter aller Gruppen identisch sind, im Vordergrund. Vor dem Hintergrund der EVA Effektdarstellung mit Referenzgruppe entspricht dies der Nullhypothese, dass die Effektparameter gleich Null sind, formal

$$\Theta_0 := \left\{ \begin{pmatrix} \mu_0 \\ \alpha_2 \\ \vdots \\ \alpha_p \end{pmatrix} \in \mathbb{R}^p \mid \alpha_i = 0 \text{ für } i = 2, \dots, p \right\} = \mathbb{R} \times \left\{0_{p-1}\right\} \tag{41.34}$$

und

$$\Theta_1 := \left\{ \begin{pmatrix} \mu_0 \\ \alpha_2 \\ \vdots \\ \alpha_p \end{pmatrix} \in \mathbb{R}^p \mid \alpha_i \neq 0 \text{ für mindestens ein } i = 2, \dots, p \right\} = \mathbb{R}^p \backslash \Theta_0. \tag{41.35}$$

Zur Evaluation der Nullhypothese wird dabei wird im Allgemeinen eine F-Statistik genutzt. Im Folgenden wollen wir zunächst diese F-Statistik anhand einer Quadratsummenzerlegung der Datenvariabilität in einem EVA-Szenario entwickeln. In diesem Kontext führen

wir mit η^2 (Eta-Quadrat) auch ein zu dem aus Kapitel 35 bekannten Bestimmheitsmaß $\mathbf{R}^2$ analoges Effektstärkenmaß ein. Ausgestattet mit der speziellen Form der F-Statistik für das EVA-Modell diskutieren wir dann den traditionellen Test der EVA Nullhypothese.

41.5.1. Quadratsummenzerlegung und Bestimmheitsmaß η^2

Die Variabilität der Daten eines EVA-Szenarios lässt sich wie in folgendem Theorem dargestellt im Sinne einer Quadratsummenzerlegung schreiben.

Theorem 41.3 (Quadratsummenzerlegung bei einfaktorieller Varianzanalyse)**.** *Für $i = 1, \ldots, p$ und $j = 1, \ldots, n_i$ sei y_{ij} die jte Datenvariable in der i-ten Gruppe eines EVA-Szenarios. Weiterhin seien mit $n := \sum_{i=1}^{p} n_i$*

$$\bar{y} := \frac{1}{n} \sum_{i=1}^{p} \sum_{j=1}^{n_i} y_{ij} \text{ und } \bar{y}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} y_{ij} \tag{41.36}$$

das Gesamtstichprobenmittel und ite Stichprobenmittel, respektive. Schließlich seien

- *die Total-Sum-of-Squares definiert als*

$$SQT := \sum_{i=1}^{p} \sum_{j=1}^{n_i} \left(y_{ij} - \bar{y}\right)^2 \tag{41.37}$$

- *die Between-Sum-of-Squares definert als*

$$SQB := \sum_{i=1}^{p} n_i \left(\bar{y}_i - \bar{y}\right)^2 \tag{41.38}$$

  und die Within-Sum-of-Squares definiert als

$$SQW := \sum_{i=1}^{p} \sum_{j=1}^{n_i} \left(y_{ij} - \bar{y}_i\right)^2 \tag{41.39}$$

  Dann gilt

$$SQT = SQB + SQW. \tag{41.40}$$

∘

Beweis. Es gilt

$$
\begin{aligned}
\text{SQT} &= \sum_{i=1}^{p}\sum_{j=1}^{n_i}\left(y_{ij}-\bar{y}\right)^2 \\
&= \sum_{i=1}^{p}\sum_{j=1}^{n_i}\left(y_{ij}-\bar{y}_i+\bar{y}_i-\bar{y}\right)^2 \\
&= \sum_{i=1}^{p}\sum_{j=1}^{n_i}\left(\left(y_{ij}-\bar{y}_i\right)+\left(\bar{y}_i-\bar{y}\right)\right)^2 \\
&= \sum_{i=1}^{p}\sum_{j=1}^{n_i}\left(\left(y_{ij}-\bar{y}_i\right)^2+2\left(y_{ij}-\bar{y}_i\right)\left(\bar{y}_i-\bar{y}\right)+\left(\bar{y}_i-\bar{y}\right)^2\right) \\
&= \sum_{i=1}^{p}\left(\sum_{j=1}^{n_i}\left(y_{ij}-\bar{y}_i\right)^2+\sum_{j=1}^{n_i}2\left(y_{ij}-\bar{y}_i\right)\left(\bar{y}_i-\bar{y}\right)+\sum_{j=1}^{n_i}\left(\bar{y}_i-\bar{y}\right)^2\right) \\
&= \sum_{i=1}^{p}\left(\sum_{j=1}^{n_i}\left(y_{ij}-\bar{y}_i\right)^2+2\left(\bar{y}_i-\bar{y}\right)\sum_{j=1}^{n_i}\left(y_{ij}-\bar{y}_i\right)+n_i\left(\bar{y}_i-\bar{y}\right)^2\right) \\
&= \sum_{i=1}^{p}\left(\sum_{j=1}^{n_i}\left(y_{ij}-\bar{y}_i\right)^2+2\left(\bar{y}_i-\bar{y}\right)\sum_{j=1}^{n_i}\left(y_{ij}-\frac{1}{n_i}\sum_{j=1}^{n_i}y_{ij}\right)+n_i\left(\bar{y}_i-\bar{y}\right)^2\right) \\
&= \sum_{i=1}^{p}\left(\sum_{j=1}^{n_i}\left(y_{ij}-\bar{y}_i\right)^2+2\left(\bar{y}_i-\bar{y}\right)\left(\sum_{j=1}^{n_i}y_{ij}-\sum_{j=1}^{n_i}\left(\frac{1}{n_i}\sum_{j=1}^{n_i}y_{ij}\right)\right)+n_i\left(\bar{y}_i-\bar{y}\right)^2\right) \\
&= \sum_{i=1}^{p}\left(\sum_{j=1}^{n_i}\left(y_{ij}-\bar{y}_i\right)^2+2\left(\bar{y}_i-\bar{y}\right)\left(\sum_{j=1}^{n_i}y_{ij}-\frac{n_i}{n_i}\sum_{j=1}^{n_i}y_{ij}\right)+n_i\left(\bar{y}_i-\bar{y}\right)^2\right) \\
&= \sum_{i=1}^{p}\left(\sum_{j=1}^{n_i}\left(y_{ij}-\bar{y}_i\right)^2+2\left(\bar{y}_i-\bar{y}\right)\left(\sum_{j=1}^{n_i}y_{ij}-\sum_{j=1}^{n_i}y_{ij}\right)+n_i\left(\bar{y}_i-\bar{y}\right)^2\right) \\
&= \sum_{i=1}^{p}\left(\sum_{j=1}^{n_i}\left(y_{ij}-\bar{y}_i\right)^2+n_i\left(\bar{y}_i-\bar{y}\right)^2\right) \\
&= \sum_{i=1}^{p}\sum_{j=1}^{n_i}\left(y_{ij}-\bar{y}_i\right)^2+\sum_{i=1}^{p}n_i\left(\bar{y}_i-\bar{y}\right)^2 \\
&= \text{SQW}+\text{SQB}
\end{aligned}
\tag{41.41}
$$

und damit direkt

$$\text{SQT} = \text{SQB} + \text{SQW} \tag{41.42}$$

□

Die Quadratsummenzerlegung im Szenario der EVA ist offenbar analog zur Quadratsummenzerlegung bei einer Ausgleichsgerade (vgl. Kapitel 34.1). Dementsprechend wird die Within-Sum-of-Squares der EVA auch häufig als Residual-Sum-of-Squares bezeichnet. Die Begriffsbildungen von Theorem 41.3 ergeben sich intuitiv wiederum wie folgt:

- SQT repräsentiert die Gesamtvariabilität der Daten y_{ij} um das Gesamtstichprobenmittel $\bar{y}$.
- SQB repräsentiert die anhand des jeweiligen Gruppenumfangs n_i gewichtete Variabilität der Gruppenstichprobenmittel um das Gesamtstichprobenmittel. Große Werte von SQB implizieren also eine große Abhängigkeit der Gruppenstichprobenmittel von dem jeweils betrachteten Faktorlevel i, kleine Werte von SQB dagegen eine geringe Abhängigkeit der Gruppenstichprobenmittel von dem jeweils betrachteten Faktorlevel. In diesem Sinne repräsentiert SQB also die durch die Betrachtung des jeweiligen Faktorlevels erklärte Datenvariabilität und ist analog zur Explained-Sum-of-Squares (SQE) der Quadratsummenzerlegung bei einer Ausgleichsgerade.

- SQW repräsentiert die über Faktorlevel summierte Datenvariabilität, die nach Erklärung der Datenvariabilität in der i-ten Gruppe durch ihr jeweiliges Stichprobenmittel verbleibt. Damit ist die SQW analog zur Residual-Sum-of-Squares der Quadratsummenzerlegung bei einer Ausgleichsgerade.

In der Zusammenschau quantifiziert SQB also die Stärke der Unterschiede zwischen den Faktorleveln. Das Effekstärkenmaß η^2 und die F-Statistik der EVA setzen die SQB nun jeweils in ein anderers Verhältnis: η^2 vergleicht die SQB mit der SQT und betrachtet damit den Anteil der Variabilität zwischen den Faktorleveln an der Gesamtvariabilität der Daten. Die F-Statistik dagegen vergleicht die SQB mit der SQW und setzt damit den Einfluß der Faktorenlevel in das Verhältnis mit der nicht erklärten Datenvariabilität nach Subtraktion dieses Einflußes. Wir betrachten an dieser Stelle zunächst das Effektstärkemaß η^2 mithilfe folgender Definition.

Definition 41.3 (Effektstärkenmaß η^2)**.** Für ein EVA-Szenario seien die Between-Sum-of-Squares SQB und die Total-Sum-of-Squares SQT definiert wie in Theorem 41.3. Dann ist das Effektstärkenmaß η^2 definiert als

$$\eta^2 := \frac{\text{SQB}}{\text{SQT}} \tag{41.43}$$

•

Der Vergleich mit Definition 35.4, dass η^2 analog zum Bestimmtheitsmaß R^2 definiert ist. Wie oben beschrieben gibt η^2 den Anteil der Datenvariabilität zwischen den Faktorleveln an der Gesamtdatenvariabilität an. Schließlich folgt mit

$$\text{SQT} = \text{SQB} + \text{SQW} \tag{41.44}$$

analog zu R^2 sofort, dass für $\text{SQT} \neq 0$ gilt, dass $\eta^2 \in [0, 1]$, weil einerseits

$$\text{SQB} = 0 \Rightarrow \text{SQT} = \text{SQW} \text{ und } \eta^2 = 0 \tag{41.45}$$

und andererseits

$$\text{SQW} = 0 \Rightarrow \text{SQT} = \text{SQB} \text{ und } \eta^2 = 1. \tag{41.46}$$

41.5.2. F-Teststatistik

Wir wollen nun zeigen, dass für die Designmatrixform der Effektdarstellung mit Referenzgruppe des EVA-Modells die F-Statistik bei der Partitionierung $p_0 := 1$ und $p_1 := p - 1$ (vgl. Kapitel 39) als Verhältnis skalierter Versionen der SQB und SQW geschrieben werden kann. Dabei impliziert $p_0 := 1$ hier insbesondere, dass das betrachtete reduzierte EVA-Modell die Designmatrix $X_0 := 1_n$ und den Betaparameter $\beta := \mu_0$ hat, und damit insbesondere auch, dass das reduzierte EVA-Modell keine Effektparameter hat. Die dabei relevanten Skalierungsfaktoren beziehen die SQB und SQW jeweils auf die Anzahl der Effektparameter bzw. die Differenz aus Gesamtanzahl der Datenpunkte und Anzahl der Betaparameter, respektive. Es gilt folgendes Theorem.

Theorem 41.4 (F-Statistik der einfaktoriellen Varianzanalyse)**.** *Es sei*

$$y = X\beta + \varepsilon \text{ mit } \varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \tag{41.47}$$

die Designmatrixform der Effektdarstellung mit Referenzgruppe des EVA-Modells. Weiterhin sei dieses Modell im Sinne von Definition 39.2 partioniert mit $p_0 := 1$ *und* $p_1 := p-1$*. Schließlich seien*

- *die Mean-Between-Sum-of-Squares definiert als*

$$MSB := \frac{SQB}{p-1} \tag{41.48}$$

- *und die Mean-Within-Sum-of-Squares definiert als*

$$MSW := \frac{SQW}{n-p} \tag{41.49}$$

wobei $p-1$ *auch als Between-Freiheitsgrade und* $n-p$ *auch als Within-Freiheitsgrade bezeichnet werden. Dann gilt mit der Definition der F-Statistik (Definition 39.3), dass*

$$F = \frac{MSB}{MSW}. \tag{41.50}$$

∘

Beweis. Wir halten zunächst fest, dass für den Betaparameterschätzer des reduzierten Modells gilt, dass

$$\hat{\beta}_0 = \left(X_0^T X_0\right)^{-1} X_0^T y = \left(1_n^T 1_n\right)^{-1} 1_n^T y = \frac{1}{n}\sum_{i=1}^{p}\sum_{j=1}^{n_i} y_{ij} = \bar{y} \tag{41.51}$$

Weiterhin ergibt sich

$$\hat{\varepsilon}_0^T \hat{\varepsilon}_0 = \left(y - X_0\hat{\beta}_0\right)^T \left(y - X_0\hat{\beta}_0\right) = \left(y - 1_n\bar{y}\right)^T \left(y - 1_n\bar{y}\right) = \sum_{i=1}^{p}\sum_{j=1}^{n_i}\left(y_{ij} - \bar{y}\right)^2 = \text{SQT}. \tag{41.52}$$

Der Betaparameterschätzer des vollständigen Modells ergibt sich wie oben gesehen zu

$$\hat{\beta} = \begin{pmatrix} \hat{\mu}_0 \\ \hat{\alpha}_2 \\ \vdots \\ \hat{\alpha}_m \end{pmatrix} = \begin{pmatrix} \frac{1}{n_1}\sum_{j=1}^{n_1} y_{1j} \\ \frac{1}{n_2}\sum_{j=1}^{n_2} y_{2j} - \frac{1}{n_1}\sum_{j=1}^{n_1} y_{1j} \\ \vdots \\ \frac{1}{n_m}\sum_{j=1}^{n_m} y_{mj} - \frac{1}{n_1}\sum_{j=1}^{n_1} y_{1j} \end{pmatrix} = \begin{pmatrix} \bar{y}_1 \\ \bar{y}_2 - \bar{y}_1 \\ \vdots \\ \bar{y}_p - \bar{y}_1 \end{pmatrix}, \tag{41.53}$$

so dass

$$
\begin{aligned}
\hat{\varepsilon}^T\hat{\varepsilon} &= (y - X\hat{\beta})^T(y - X\hat{\beta}) \\
&= \left(\begin{pmatrix} y_{11} \\ \vdots \\ y_{1n_1} \\ y_{21} \\ \vdots \\ y_{2n_2} \\ \vdots \\ y_{p1} \\ \vdots \\ y_{pn_p} \end{pmatrix} - \begin{pmatrix} 1 & 0 & \dots & 0 \\ \vdots & \vdots & \dots & \vdots \\ 1 & 0 & & 0 \\ 1 & 1 & & 0 \\ \vdots & \vdots & \dots & \vdots \\ 1 & 1 & & 0 \\ \vdots & \vdots & \dots & \vdots \\ 1 & 0 & & 1 \\ \vdots & \vdots & \dots & \vdots \\ 1 & 0 & & 1 \end{pmatrix} \begin{pmatrix} \bar{y}_1 \\ \bar{y}_2 - \bar{y}_1 \\ \bar{y}_p - \bar{y}_1 \end{pmatrix}\right)^T \left(\begin{pmatrix} y_{11} \\ \vdots \\ y_{1n_1} \\ y_{21} \\ \vdots \\ y_{2n_2} \\ \vdots \\ y_{p1} \\ \vdots \\ y_{pn_p} \end{pmatrix} - \begin{pmatrix} 1 & 0 & \dots & 0 \\ \vdots & \vdots & \dots & \vdots \\ 1 & 0 & & 0 \\ 1 & 1 & & 0 \\ \vdots & \vdots & \dots & \vdots \\ 1 & 1 & & 0 \\ \vdots & \vdots & \dots & \vdots \\ 1 & 0 & & 1 \\ \vdots & \vdots & \dots & \vdots \\ 1 & 0 & & 1 \end{pmatrix} \begin{pmatrix} \bar{y}_1 \\ \bar{y}_2 - \bar{y}_1 \\ \bar{y}_p - \bar{y}_1 \end{pmatrix}\right) \\
&= \begin{pmatrix} y_{11} - \bar{y}_1 \\ \vdots \\ y_{1n_1} - \bar{y}_1 \\ y_{21} - \bar{y}_1 - \bar{y}_2 + \bar{y}_1 \\ \vdots \\ y_{2n_2} - \bar{y}_1 - \bar{y}_2 + \bar{y}_1 \\ \vdots \\ y_{p1} - \bar{y}_1 - \bar{y}_p + \bar{y}_1 \\ \vdots \\ y_{pn_p} - \bar{y}_1 - \bar{y}_p + \bar{y}_1 \end{pmatrix}^T \begin{pmatrix} y_{11} - \bar{y}_1 \\ \vdots \\ y_{1n_1} - \bar{y}_1 \\ y_{21} - \bar{y}_1 - \bar{y}_2 + \bar{y}_1 \\ \vdots \\ y_{2n_2} - \bar{y}_1 - \bar{y}_2 + \bar{y}_1 \\ \vdots \\ y_{p1} - \bar{y}_1 - \bar{y}_p + \bar{y}_1 \\ \vdots \\ y_{pn_p} - \bar{y}_1 - \bar{y}_p + \bar{y}_1 \end{pmatrix} \\
&= \begin{pmatrix} y_{11} - \bar{y}_1 \\ \vdots \\ y_{1n_1} - \bar{y}_1 \\ y_{21} - \bar{y}_2 \\ \vdots \\ y_{2n_2} - \bar{y}_2 \\ \vdots \\ y_{p1} - \bar{y}_p \\ \vdots \\ y_{pn_p} - \bar{y}_p \end{pmatrix}^T \begin{pmatrix} y_{11} - \bar{y}_1 \\ \vdots \\ y_{1n_1} - \bar{y}_1 \\ y_{21} - \bar{y}_2 \\ \vdots \\ y_{2n_2} - \bar{y}_2 \\ \vdots \\ y_{p1} - \bar{y}_p \\ \vdots \\ y_{pn_p} - \bar{y}_p \end{pmatrix} \\
&= \sum_{i=1}^{p}\sum_{j=1}^{n_i} \left(y_{ij} - \bar{y}_i\right)^2 \\
&= \text{SQW}\,.
\end{aligned}
\tag{41.54}
$$

Mit dem Theorem zur Quadratsummenzerlegung bei einfaktorieller Varianzanalyse

$$\text{SQT} = \text{SQB} + \text{SQW} \Leftrightarrow \text{SQB} = \text{SQT} - \text{SQW} \tag{41.55}$$

folgt sofort, dass

$$\text{SQB} = \text{SQT} - \text{SQW} = \hat{\varepsilon}_0^T\hat{\varepsilon}_0 - \hat{\varepsilon}^T\hat{\varepsilon}. \tag{41.56}$$

Dann aber folgt auch direkt, dass

$$\frac{\text{MSB}}{\text{MSW}} = \frac{\frac{\text{SQB}}{p-1}}{\frac{\text{SQW}}{n-p}} = \frac{\frac{\hat{\varepsilon}_0^T\hat{\varepsilon}_0 - \hat{\varepsilon}^T\hat{\varepsilon}}{p-1}}{\frac{\hat{\varepsilon}^T\hat{\varepsilon}}{n-p}} = F \tag{41.57}$$

□

Gegeben die sehr ähnlichen Definitionen des Effektstärkemaßes η^2 und der F-Statistik der EVA ist folgendes Resultat naheliegend.

Theorem 41.5 (Effektstärkenmaß η^2 und F-Teststatistik.)**.** *Für ein EVA-Szenario mit p Gruppen und Gesamtdatenpunktanzahl n seien das Effektstärkenmaß η^2 und die F-Statistik*

der einfaktoriellen Varianzanalyse gegeben. Dann gilt

$$\eta^2 = \frac{F(p-1)}{F(p-1) + (n-p)} \tag{41.58}$$

∘

Beweis. Wir halten zunächst fest, dass

$$F = \frac{\text{SQB}}{\text{SQW}} \cdot \frac{n-p}{p-1} \Leftrightarrow \text{SQB} = \frac{p-1}{n-p} \cdot \text{SQW} \cdot F. \tag{41.59}$$

Damit folgt dann

$$\begin{aligned}
\eta^2 &= \frac{\text{SQB}}{\text{SQT}} \\
&= \frac{\text{SQB}}{\text{SQB} + \text{SQW}} \\
&= \frac{\frac{p-1}{n-p} \cdot \text{SQW} \cdot F}{\frac{p-1}{n-p} \cdot \text{SQW} \cdot F + \text{SQW}} \\
&= \frac{\frac{F(p-1)}{n-p} \cdot \text{SQW}}{\frac{F(p-1)}{n-p} \cdot \text{SQW} + \text{SQW}} \\
&= \frac{\frac{F(p-1)}{n-p} \cdot \text{SQW}}{\left(\frac{F(p-1)}{n-p} + 1\right) \cdot \text{SQW}} \\
&= \frac{\frac{F(p-1)}{n-p}}{\frac{F(p-1)}{n-p} + \frac{n-p}{n-p}} \\
&= \frac{\frac{F(p-1)}{n-p}}{\frac{F(p-1)+(n-p)}{n-p}} \\
&= \frac{F(p-1)}{F(p-1) + (n-p)}
\end{aligned} \tag{41.60}$$

□

Intuitiv ist dabei das Verhältnis von η^2 und F-Statistik analog zum Verhältnis von Cohen's d und der T-Statistik bei Einstich- und Zweistichproben-T-Tests. Insbesondere ist die gleichzeitige Angabe von η^2 und der F-Statistik bei bekannten Gruppengrößen redundant.

41.5.3. F-Test der einfaktoriellen Varianzanalyse

Wir wollen nun den Gebrauch der F-Statistik zur Durchführung eines Tests der Nullhypothese (Gleichung 41.34) diskutieren. Wir erinnern daran, dass diese Nullhypothese intuitiv besagt, dass die Erwartungswerte über alle Level des Faktors identisch sind bzw. dass alle Effektparameter gleich Null sind. Das Verwerfen dieser Nullhypothese impliziert also, dass inferentielle Evidenz dahingehend besteht, dass zumindest ein Effektparameter von Null verschieden ist. Allerdings impliziert das Verwerfen der Nullhypothese des F-Tests der einfaktoriellen Varianzanalyse keine Aussage darüber, um welchen Effektparameter es sich dabei genau handelt. Wir definieren den F-Test der einfaktoriellen Varianzanalyse wie folgt.

Definition 41.4 (F-Test der einfaktoriellen Varianzanalyse)**.** Gegeben sei das EVA-Modell in Effektparameterdarstellung mit Referenzgruppe sowie die Null- und Alternativhypothesen

$$\Theta_0 := \left\{ \begin{pmatrix} \mu_0 \\ \alpha_2 \\ \vdots \\ \alpha_p \end{pmatrix} \in \mathbb{R}^p \mid \alpha_i = 0 \text{ für } i = 2, \dots, p \right\} \text{ und } \Theta_1 := \mathbb{R}^p \backslash \Theta_0. \tag{41.61}$$

Weiterhin sei die F-Teststatistik definiert durch

$$F = \frac{\text{MSB}}{\text{MSW}} \tag{41.62}$$

mit der Mean-Between-Sum-of-Squares MSB und der Mean-Within-Sum-of-Squares definiert wie in Theorem 41.4. Dann ist der F-Test der einfaktoriellen Varianzanalyse definiert als der kritische Wert-basierte Test

$$\phi(y) := 1_{\{F \geq k\}} := \begin{cases} 1 & F \geq k \\ 0 & F < k \end{cases} \tag{41.63}$$

•

Der Kontrolle der Typ-I-Fehlerwahrscheinlichkeit liegt die f-Verteilung der F-Statistik zugrunde. Dies ist die Kernaussage folgenden Theorems.

Theorem 41.6 (Testumfangskontrolle des F-Tests der einfaktoriellen Varianzanalyse)**.** *ϕ sei der F-Test der einfaktoriellen Varianzanalyse. Dann ist ϕ ein Level-α_0-Test mit Testumfang α_0, wenn der kritische Wert definiert ist durch*

$$k_{\alpha_0} := \varphi^{-1}\left(1 - \alpha_0; p - 1, n - p\right), \tag{41.64}$$

wobei $\varphi^{-1}(\cdot; p-1, n-p)$ die inverse KVF der f-Verteilung mit Freiheitsgradparametern $p-1$ und $n-p$ ist.

∘

Beweis. Die Testgütefunktion des betrachteten Tests im vorliegenden Testszenario ist definiert als

$$q : \mathbb{R} \to [0, 1], \beta \mapsto q_\phi(\beta) := \mathbb{P}_\beta(\phi = 1). \tag{41.65}$$

Wir haben in Kapitel 39 gesehen, dass die F-Statistik für $p_1 = p - 1$ nach einer nichtzentralen f-Verteilung verteilt ist,

$$F \sim f(\delta, p - 1, n - p). \tag{41.66}$$

Weiterhin ist der Ablehnungsbereich des hier betrachteten Tests gegeben als $[k, \infty[$. Für die funktionale Form der Testgütefunktion ergibt sich also

$$\begin{aligned} \mathbb{P}_\beta(\phi = 1) &= \mathbb{P}_\beta(F \in [k, \infty[) \\ &= \mathbb{P}_\beta(F \geq k) \\ &= 1 - \mathbb{P}_\beta(F \leq k) \\ &= 1 - \varphi(k; \delta, p - 1, n - p), \end{aligned} \tag{41.67}$$

wobei $\varphi(k; \delta, p - 1, n - p)$ den Wert der KVF der nichtzentralen f-Verteilung an der Stelle k und mit Nichtzentralitätsparameter δ sowie Freiheitsgradparametern $p - 1$ und $n - p$ bezeichnet (vgl. Kapitel 39). Damit der betrachtete Test ein Level-α_0-Test ist, muss bekanntlich gelten, dass

$$q_\phi(\beta) \leq \alpha_0 \text{ für alle } \beta \in \Theta_0 \text{ mit } \Theta_0 = \mathbb{R} \times \left\{0_{p-1}\right\}. \tag{41.68}$$

Mit der Form des Nichtzentralitätsparameters gegeben durch (vgl. Theorem 39.3)

$$\delta = \frac{1}{\sigma^2} c^T \beta \left(c^T \left(X^T X \right)^{-1} c \right)^{-1} c^T \beta \tag{41.69}$$

folgt mit $\beta \in \Theta_0$ aus

$$c = \begin{pmatrix} 0 \\ 1_{p-1} \end{pmatrix} \in \mathbb{R}^p \text{ und } \beta = \begin{pmatrix} \mu_0 \\ 0_{p-1} \end{pmatrix} \in \mathbb{R}^p \tag{41.70}$$

dann aber $\delta = 0$ und somit

$$q_\phi(\beta) = 1 - \varphi(k; p-1, n-p) \text{ für alle } \beta \in \Theta_0. \tag{41.71}$$

wobei $\varphi(k; p-1, n-p)$ den Wert der KVF der f-Verteilung an der Stelle k mit Freiheitsgradparametern $p-1$ und $n-p$ bezeichnet. Der Testumfang des betrachteten Tests ergibt sich als

$$\alpha = \max_{\beta \in \Theta_0} q_\phi(\beta) = 1 - \varphi(k; p-1, n-p) \tag{41.72}$$

da $q_\phi(\beta)$ für $\beta \in \Theta_0$ nicht von μ_0 abhängt. Wir müssen also lediglich zeigen, dass die Wahl von k_{α_0} wie im Theorem garantiert, dass ϕ den Testumfang α_0 hat. Sei also $k := k_{\alpha_0}$. Dann gilt für alle $\beta \in \Theta_0$

$$q_\phi(\beta) = 1 - \varphi\left(\varphi^{-1}\left(1-\alpha_0; p-1, n-p\right); p-1, n-p\right) = 1 - 1 - \alpha_0 = \alpha_0 \tag{41.73}$$

und damit ist alles gezeigt. □

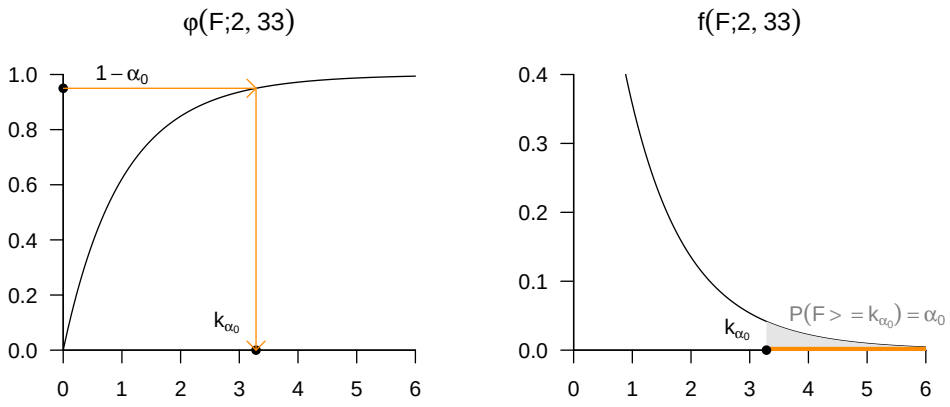


Abbildung 41.2. Exemplarischer kritischer Wert und Ablehnungsbereich bei einem F-Test der einfaktorieller Varianzanalyse.

In Abbildung 41.2 visualisieren wir die Wahl des kritischen Wertes k_{α_0} zur Kontrolle des Testumfangs mithilfe der KVF der f-Verteilung sowie den resultierenden Ablehnungsbereich für $\alpha_0 := 0.05$, einem Faktor mit drei Leveln $p = 3$ und einem balancierten Design mit Gruppenumfang $m = 12$, also $n = 3 \cdot 12 = 36$. In diesem Fall würde die Nullhypothese bei einem Wert der F-Statistik von größer als 3.28 verworfen werden.

p-Wert

Es sei f ein vorliegender Wert der F-Statistik im Kontext einer einfaktoriellen Varianzanalyse. Dann ergibt sich der zu f gehörige p-Wert anhand folgenden Theorems.

Theorem 41.7 (p-Wert der F-Statistik bei einfaktorieller Varianzanalyse)**.** *Gegeben sei das in Definition 41.4 spezifizierte Szenario eines F-Tests bei einfaktorieller Varianzanalyse. Dann ergibt sich der zu einem vorliegenden Wert f der F-Statistik zugehörige p-Wert als*

$$p\text{-}Wert = \mathbb{P}(F \geq f) = 1 - \varphi(f; p-1, n-p) \tag{41.74}$$

∘

Beweis. Nach Definition ist der p-Wert das kleinste Signifikanzlevel α_0, bei welchem man die Nullhypothese basierend auf einem vorliegenden Wert der Teststatistik ablehnen würde. Bei $F = f$ würde H_0 für jedes α_0 mit $f \geq \varphi^{-1}(1-\alpha_0; p-1, n-p)$ abgelehnt werden. Für ein solches α_0 gilt aber

$$\alpha_0 \geq \mathbb{P}(F \geq f), \tag{41.75}$$

denn

$$\begin{aligned} & f \geq \varphi^{-1}(1-\alpha_0; p-1, n-p) \\ \Leftrightarrow\ & \varphi(f; p-1, n-p) \geq \varphi\left(\varphi^{-1}(1-\alpha_0; p-1, n-p), p-1, n-p\right) \\ \Leftrightarrow\ & \varphi(f; p-1, n-p) \geq 1-\alpha_0 \\ \Leftrightarrow\ & \mathbb{P}(F \leq f) \geq 1-\alpha_0 \\ \Leftrightarrow\ & \alpha_0 \geq 1-\mathbb{P}(F \leq f) \\ \Leftrightarrow\ & \alpha_0 \geq \mathbb{P}(F \geq f) \end{aligned} \tag{41.76}$$

Das kleinste $\alpha_0 \in [0,1]$ mit $\alpha_0 \geq \mathbb{P}(F \geq f)$ ist dann $\alpha_0 = \mathbb{P}(F \geq f)$, also folgt

$$\text{p-Wert} = \mathbb{P}(F \geq f) = 1 - \varphi(f; p-1, n-p) \tag{41.77}$$

□

Praktisches Vorgehen

Aus dem in diesem Abschnitt Gesagten ergibt sich folgendes Vorgehen zur Evaluation eines EVA-Modells mithilfe eines F-Tests: Man nimmt zunächst einmal an, dass ein vorliegender Datensatz von p Gruppendatensätzen

$$y_{11}, \dots, y_{1n_1}, y_{21}, \dots, y_{2n_2}, \dots, y_{p1}, \dots, y_{pn_p} \tag{41.78}$$

Realisationen von

$$y_{1j} \sim N(\mu_0, \sigma^2) \tag{41.79}$$

und

$$y_{ij} \sim N(\mu_0 + \alpha_i, \sigma^2) \tag{41.80}$$

für $i = 2, \dots, p$ mit wahren, aber unbekannten, Parametern $\mu_0, \alpha_i, i = 2, \dots, p$ und $\sigma^2 > 0$ sind. Weiterhin nimmt man an, dass man entscheiden möchte, ob die Nullhypothese identischer wahrer, aber unbekannter, Erwartungswertparameter über Faktorlevel bzw. zu Null identischer wahrer, aber unbekannter, Effektparameter eher zutrifft oder eher nicht (vgl. Gleichung 41.34). Dazu wählt man zunächst ein Signifikanzniveau α_0 und bestimmt den zugehörigen Freiheitsgradparameter-abhängigen kritischen Wert k_{α_0}. Zum Beispiel gilt bei Wahl von $\alpha_0 := 0.05, p = 3, m = 12, i = 1, 2, 3$ und somit $n = 36$, dass $k_{\alpha_0} = \varphi^{-1}(1 - 0.05; 2, 33) \approx 3.28$ ist. Man nutzt dann den vorliegenden Datensatz zur Berechnung der MSB und MSW und bestimmt damit den realisierten Wert der F-Statistik f. Wenn f größer gleich k_{α_0} ist, lehnt man die Nullhypothese ab, andernfalls nicht. Insgesamt garantiert die in diesem Abschnitt entwickelte Theorie dann, dass man im Mittel in höchstens $\alpha_0 \cdot 100$ von 100 Fällen die Nullhypothese fälschlicherweise ablehnt. Schließlich mag man den zu dem Wert f assoziierten p-Wert als $1 - \varphi(f; p-1, n-p)$ bestimmen und in der Dokumentation der Analyse vermerken.

41.5.4. Anwendungsbeispiel

Folgender **R** Code implementiert das obige praktische Vorgehen für den Beispieldatensatz.

```
# Datenmanagement
D           = read.csv("./_data/508-einfaktorielle-varianzanalyse.csv")          # Datensatz
y           = D$dBDI                                                             # Datenvektor
n           = length(y)                                                          # Gesamtdatenumfang
p           = 3                                                                  # Anzahl Gruppen
m           = n/p                                                                # Anzahl Datenpunkte pro Gruppe

# Modellformulierung
Xt          = cbind(                                                              # Designmatrix vollständiges Modell
              matrix(1, nrow = n, ncol = 1),
              kronecker(diag(p),
                        matrix(1, nrow = m, ncol = 1)))
X           = Xt[,-2]
X_0         = X[,1]                                                              # Designmatrix reduziertes Modell

# F-Teststatistikevaluation
beta_hat    = solve(t(X) %*% X) %*% t(X) %*% y                                   # Betaparameterschätzer vollständiges Modell
beta_hat_0  = solve(t(X_0) %*% X_0) %*% t(X_0) %*% y                             # Betaparameterschätzer reduziertes Modell
eps_hat     = y - X %*% beta_hat                                                 # Residuenvektor vollständiges Modell
eps_hat_0   = y - X_0 %*% beta_hat_0                                             # Residuenvektor reduziertes Modell
SQT         = t(eps_hat_0) %*% eps_hat_0                                         # Sum of Squares Total
SQW         = t(eps_hat)   %*% eps_hat                                           # Sum of Squares Within
SQB         = SQT - SQW                                                          # Sum of Squares Between
DFB         = p - 1                                                              # Between Degrees of Freedom
DFW         = n - p                                                              # Within  Degrees of Freedom
DFB         = p - 1                                                              # Between Degrees of Freedom
MSB         = SQB/DFB                                                            # Mean Sum of Squares Between
MSW         = SQW/DFW                                                            # Mean Sum of Squares Within
Eff         = MSB/MSW                                                            # F-Teststatistik
pW          = 1 - pf(Eff, p-1, n-p)                                               # p-Wert

# F-Test Evaluation
alpha_0     = 0.05                                                               # Signifikanzlevel
k_alpha_0   = qf(1 - alpha_0, p-1,n-p)                                           # kritischer Wert
if(Eff > k_alpha_0){phi = 1} else {phi = 0}                                      # Testwert
```

```
DFB : 2
DFW : 33
SQB : 821.72
SQW : 170.58
MSB : 410.86
MSW : 5.17
F   : 79.48
p   : 0
phi : 1
```

Im vorliegenden Fall würde die Nullhypothese

$$\Theta_0 := \left\{ \begin{pmatrix} \mu_0 \\ \alpha_2 \\ \alpha_3 \end{pmatrix} \in \mathbb{R}^3 \mid \alpha_i = 0 \text{ für } i = 2, 3 \right\} \tag{41.81}$$

verworfen werden.

Folgender **R** Code demonstriert die Durchführung und Dokumentation der gleichen Analyse mithilfe der **R** Funktion `aov()`.

```
D       = read.csv("./_data/508-einfaktorielle-varianzanalyse.csv")              # Daten
res.aov = aov(D$dBDI ~ D$COND, data = D)                                         # Modellformulierung und Modellschätzung
summary(res.aov)                                                                 # Modellevaluation
```

```
            Df Sum Sq Mean Sq F value   Pr(>F)
D$COND       2  821.7   410.9   79.48 2.41e-13 ***
Residuals   33  170.6     5.2
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

41.6. Literaturhinweise

Die Popularität varianzanalytischer Verfahren wird im Allgemeinen auf Fisher (1925b) und Fisher (1935) zurückgeführt. Everitt & Howell (2005) und Stigler (1986) geben einen kurzen und einen ausführlichen historischen Überblick, respektive.

42. Zweifaktorielle Varianzanalyse

42.1. Anwendungsszenario

Das klassische Anwendungsszenario einer zweifaktoriellen Varianzanalyse (ZVA) ist ein randomisiertes zweifaktorielles vollständig gekreuztes Studiendesign bestehend aus einer univariaten abhängige Variable bestimmt an randomisierten experimentellen Einheiten und zwei unabhängigen Variablen, die in der Regel jeweils mindestens zweistufig sind. Im Kontext der Varianzanalyse werden die unabhängigen Variablen bekanntlich auch Faktoren und ihre Ausprägungsstufen Faktorlevel genannt. Im Falle eines vollständig gekreuzten Designs wird jedes Level eines Faktors mit allen Level des anderen Faktors kombiniert. Die Kombination zweier spezifischer Faktorlevel wird dann auch Zelle des Designs genannt. Da den Zellen eines ZVA Designs üblicherweise Gruppen von experimentellen Einheiten zugeordnet werden, werden sie auch oft Gruppen oder experimentelle Bedingungen genant.

Spezielle zweifaktorielle Studiendesigns werden üblicherweise anhand ihrer Faktorlevel bezeichnet. Ein $I \times J$ Studiendesign und seine entsprechende $I \times J$ zweifaktorielle Varianzanalyse impliziert also, dass I Faktorlevel des ersten Faktors, im Folgenden als Faktor A bezeichnet, mit J Faktorleveln des zweiten Faktors, im Folgenden als Faktor B bezeichnet, gekreuzt werden. Folgende Tabelle gibt für einige der möglichen ZVA-Designs die Bezeichnung und die Level der jeweiligen Faktoren an.

2×2 ZVA	$\Rightarrow$	Faktor A mit Level 1,2	Faktor B mit Level 1,2
2×3 ZVA	$\Rightarrow$	Faktor A mit Level 1,2	Faktor B mit Level 1,2,3
4×2 ZVA	$\Rightarrow$	Faktor A mit Level 1,2,3,4	Faktor B mit Level 1,2
3×1 ZVA	$\Rightarrow$	Faktor A mit Level 1,2,3	Faktor B mit Level 1

Generell sind 2×2 ZVA-Designs sehr populär und ermöglichen es, die wesentlichen Charakteristika zweifaktorieller Varianzanalysedesigns zu diskutieren. Wir fokussieren im Folgenden daher weitgehend auf diesen Fall. In Abbildung 42.1 A visualisieren wir das konzeptuelle Design einer 2×2 ZVA, wobei wir die Zellen des Designs hier und im Folgenden mit A1B1, A1B2, A2B1 und A2B2 bezeichnen.

Abbildung 42.1 B visualisiert, dass zu jeder Zelle des Designs eine Gruppe von Datenpunkten korrespondiert. Wir nutzen dabei folgende Indexkonvention: y_{ijk} bezeichnet den Datenwert der k-ten experimentellen Einheit im i-ten Level von Faktor A und j-ten Level von Faktor B, wobei $k = 1, \ldots, n_{ij}$ und im vorliegenden Fall $i = 1, 2$ sowie $j = 1, 2$. Ist die Anzahl an Datenwerten n_{ij} in jeder Zelle identisch, so spricht man wiederum von einem balancierten Design.

Haupteffekte und Interaktionen

Intuitiv ist man in ZVA-Designs an Haupteffekten und Interaktionen interessiert, die sich zunächst rein deskriptiv auf das Muster der zellspezifischen Gruppenmittelwerte beziehen.

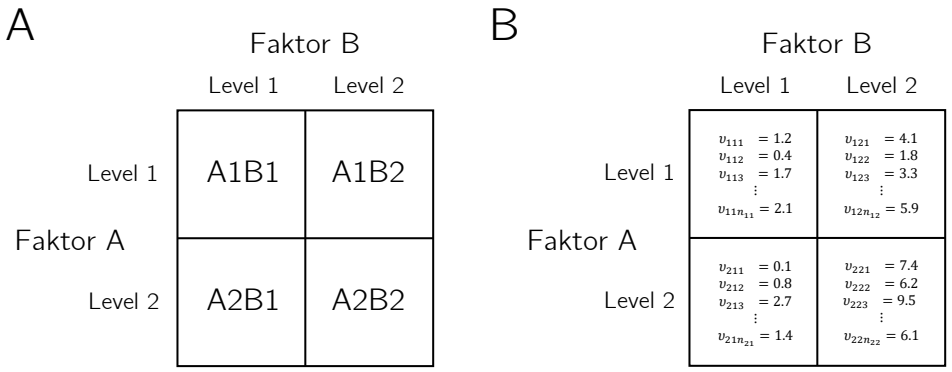


Abbildung 42.1. Konzeptuelles Design und Datennotation einer 2×2 ZVA.

Für den Fall einer 2×2 ZVA spricht man dabei intuitiv vom Vorliegen eines *Haupteffekts von Faktor A*, wenn sich die Gruppenmittelwerte zwischen Level 1 und Level 2 von Faktor A, jeweils gemittelt über die zwei Level von Faktor B, unterscheiden. Weiterhin spricht man vom Vorliegen eines *Haupteffekts von Faktor B*, wenn sich die Gruppenmittelwerte zwischen Level 1 und Level 2 von Faktor B, jeweils gemittelt über die zwei Level von Faktor A, unterscheiden.

Vom Vorliegen einer *Interaktion der Faktoren A und B* schließlich spricht man, wenn der Unterschied der Gruppenmittelwerte von Faktor A zwischen Level 1 und 2 unterschiedlich für Level 1 und Level 2 von Faktor B ausgeprägt ist bzw. wenn der Unterschied der Gruppenmittelwerte von Faktor B zwischen Level 1 und 2 unterschiedlich für Level 1 und Level 2 von Faktor A ausgeprägt ist.

Haupteffekte beziehen sich intuitiv also auf (marginale) Unterschiede (Differenzen), während sich Interaktionen auf Unterschiede von Unterschieden (Differenzen von Differenzen) beziehen. Dabei besagt das Vorliegen einer Interaktion also lediglich, dass sich die Unterschiede der Gruppenmittelwerte zwischen den Leveln eines experimentellen Faktors in Abhängigkeit von den Leveln des anderen experimentellen Faktors ändern, impliziert aber keine Aussage darüber, warum dies so ist. In anderen Worten sind Haupteffekte und Interaktionen bei Varianzanalysen Datenmuster, aber keine wissenschaftlichen Theorien. Die frequentitistisch-inferenzstatistische Absicherung dieser Datenmuster ist das Thema dieses Kapitels.

Anwendungsbeispiel

Für ein konkretes Anwendungsbeispiel aus dem Bereich der Interventionsevaluation betrachten wir eine BDI-Pre-Postinterventionsdifferenzwertanalyse für je zwei Settings (Face-to-Face und Online) und Varianten (Mindfulness und Exercise) der kognitiven Verhaltenstherapie (`CBT`, Abbildung 42.2). Setting sei Faktor (A) mit Leveln (1) Face-to-face (`F2F`) und (2) Online (`ONL`) und Variante sei Faktor (B) mit Leveln (1) Mindfulness (`MND`) und

(2) Exercise (`EXC`). Jeder der durch Kreuzung der Faktorlevel entstehenden Interventionsbedingungen sei eine Gruppe (Stichprobe) von $n_{ij} := 12$ Patient:innen zugeordnet und für jede Patient:in sei die Differenz zwischen Preinterventions und Postinterventions BDI Wert bestimmt worden und mit dBDI bezeichnet.

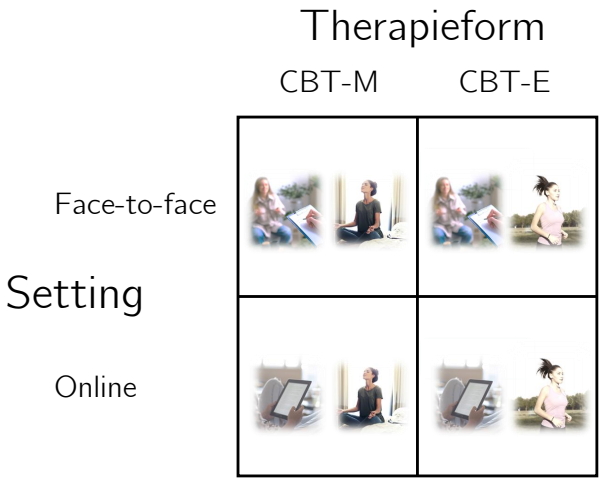


Abbildung 42.2. Konzeptuelles Design des Anwendungsbeispiels.

Tabelle 42.1. Pre-Post-BDI-Differenzwerte der Faktorlevelkombinationen

Setting	Variant	dBDI
F2F	MND	12
F2F	MND	11
F2F	MND	8
F2F	MND	8
F2F	MND	12
F2F	MND	12
F2F	MND	9
F2F	MND	10
F2F	MND	12
F2F	MND	13
F2F	MND	10
F2F	MND	9
F2F	EXC	14
F2F	EXC	11
F2F	EXC	15
F2F	EXC	16
F2F	EXC	15
F2F	EXC	19
F2F	EXC	16
F2F	EXC	14
F2F	EXC	11
F2F	EXC	15
F2F	EXC	15
F2F	EXC	17
ONL	MND	4
ONL	MND	10
ONL	MND	12
ONL	MND	13
ONL	MND	12
ONL	MND	12
ONL	MND	13
ONL	MND	10
ONL	MND	10
ONL	MND	13
ONL	MND	4
ONL	MND	8
ONL	EXC	16
ONL	EXC	19
ONL	EXC	14
ONL	EXC	17
ONL	EXC	17
ONL	EXC	16
ONL	EXC	13
ONL	EXC	16
ONL	EXC	20
ONL	EXC	13
ONL	EXC	16
ONL	EXC	13

Tabelle 42.1 zeigt einen Beispieldatensatz. Dabei repräsentiert jede Zeile eine Patient:in, die Spalte Setting bezeichnet das dieser Patient:in entsprechende Level des Therapiesettingfaktors und die Spalte Variant das dieser Patient:in entsprechende Level des Therapievariantenfaktors. Der entsprechende dBDI Zeilenwert bildet den Pre-Post-InterventionsBDI-Differenzwert der entsprechenden Patient:in ab. Hohe Werte zeigen dabei eine starke Verbesserung, geringe Werte eher eine leichte Verbesserung der Depressionssymptomatik an.

Abbildung 42.3 schließlich zeigt zwei häufig genutzte Visualisationsformen für Deskriptivstatistiken (hier Gruppenmittelwerte und Standardabweichungen) in 2×2 ZVA Szenarien. Abbildung 42.3 A zeigt die faktorlevelkombinationsspezifischen Gruppenmittelwerte und ihre Standardabweichungen als Balkendiagramm. Abbildung 42.3 B zeigt die gleichen Daten als Liniendiagramm mit Fehlerbalken. Dabei entsprechen die zwei Linien den beiden Leveln des Settingfaktors F2F (dunkelgraue Linie) und ONL (hellgraue Linie). Die auf der x-Achse abgetragenen Werte dagegen entsprechen den beiden Leveln des Variantenfaktors MND und EXC. Für das Verständnis dieser Art der Visualisierung ist es sicherlich hilfreich, die Korrespondenz zwischen den in Abbildung 42.3 A und Abbildung 42.3 B einmal explizit durch nachzeichnen herzustellen.

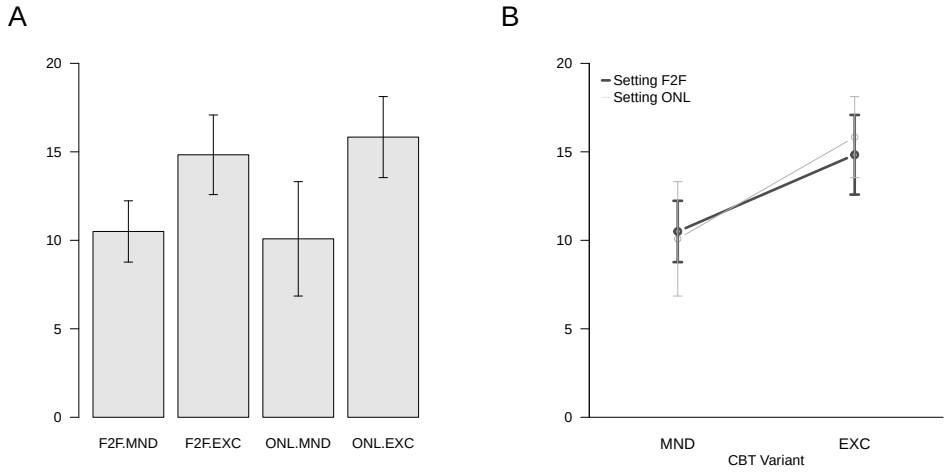


Abbildung 42.3. Visualisierung des Beispieldatensatzes als Balken- und Liniendiagramm.

42.2. Modellformulierung

Um nun den Spezialfall des ALMs für das ZVA Szenario zu diskutieren, gehen wir in zwei Schritten vor. In einem ersten Schritt führen mit dem *Modell der additiven ZVA* ein Modell ein, das lediglich die Haupteffekte der Faktoren, nicht aber ihre Interaktion modellieren kann. Entsprechend können auf Grundlage dieses Modells Haupteffektparameter geschätzt und inferenzstatistisch evaluiert werden. In einem zweiten Schritt führen wir mit dem Modell der ZVA mit Interaktion ein Modell ein, das sowohl die Haupteffekte der Faktoren als auch ihre Interaktion modelliert und auf dessen Grundlage entsprechend sowohl Haupteffekts- als auch Interaktionsparameter geschätzt und inferenzstatistisch evaluiert werden können. In beiden Fällen ist das zentrale Thema der Modellformulierung wie bei der EVA von einer Intuition zur Modellierung der Erwartungswertparameter der Zellen des ZVA Szenarios zu einer nicht überparameterisierten Darstellung mithilfe von Effektparametern zu kommen.

42.2.1. Modell der additiven ZVA

In Analogie zur EVA möchte man im Modell der additiven ZVA die Gruppenerwartungswerte μ_{ij} mit $i = 1, \dots, I$ für die Level von Faktor A und $j = 1, \dots, J$ für die Level von Faktor B als Summe eines gruppenunspezifischen Erwartungswertes und den Effekten der Level von Faktor A und der Level von Faktor B modellieren.

Wir bezeichnen dabei den gruppenunspezifischen Erwartungswertparameter mit μ_0, den Effekt von Level i von Faktor A mit α_i und den Effekt von Level j von Faktor B mit β_j (β_j bezeichnet hier also nicht den j-ten Eintrag des Betaparametervektors). Dann ergibt sich zum Beispiel für $I := J := 2$

$$\begin{array}{c|c} \mu_{11} := \mu_0 + \alpha_1 + \beta_1 & \mu_{12} := \mu_0 + \alpha_1 + \beta_2 \\ \hline \mu_{21} := \mu_0 + \alpha_2 + \beta_1 & \mu_{22} := \mu_0 + \alpha_2 + \beta_2 \end{array} \tag{42.1}$$

Wie im Falle der EVA ist diese Darstellung der Gruppenerwartungswerte μ_{ij} allerdings überparameterisiert, speziell werden die vier Erwartungswertparameter $\mu_{11}, \mu_{12}, \mu_{21}$ und μ_{22} in obiger Formulierung durch die fünf Parameter $\mu_0, \alpha_1, \alpha_2, \beta_1$ und β_2 dargestellt. Um eine eindeutige Darstellung der μ_{ij} zu gewährleisten, bietet sich auch hier die Restriktion an, den Effekt des ersten Levels jedes Faktors als Null zu definieren

$$\alpha_1 := \beta_1 := 0 \tag{42.2}$$

und damit die Faktorlevelkombination A1B1 als Referenzgruppe zu etablieren. Es ergibt sich somit zum Beispiel für für $I := J := 2$

$$\begin{array}{c|c} \mu_{11} := \mu_0 & \mu_{12} := \mu_0 + \beta_2 \\ \hline \mu_{21} := \mu_0 + \alpha_2 & \mu_{22} := \mu_0 + \alpha_2 + \beta_2 \end{array} \tag{42.3}$$

Hier werden nun also die vier Erwartungswertparameter $\mu_{11}, \mu_{12}, \mu_{21}$ und μ_{22} durch nur drei Effektparameter μ_0, α_2 und β_2 dargestellt (in diesem Sinne ist das Modell der additiven ZVA sogar unterparameterisiert, was im folgenden Abschnitt die Einführung eines Interaktionsparameters erlaubt). Allerdings ändern sich bei dieser *Effektdarstellung des Modells der additiven* 2×2 *ZVA mit Referenzgruppe* analog zur EVA die Interpretationen der Parameter μ_0, α_2, β_2 im Vergleich zum überparameterisierten Fall ohne Referenzgruppe: μ_0 entspricht dem Erwartungswert der Faktorlevelkombination A1B1, α_2 der Differenz beim Übergang von Level 1 zu Level 2 von Faktor A und β_2 der Differenz beim Übergang von Level 1 zu Level 2 von Faktor B. Wir fassen obige Überlegungen in folgender Definition zusammen.

Definition 42.1 (Modell der additiven ZVA mit Referenzgruppe)**.** y_{ijk} mit $i = 1, \dots, I, j = 1, \dots, J, k = 1, \dots, n_{ij}$ sei die Zufallsvariable, die den $k$ten Datenpunkt zum $i$ten Level von Faktor A und dem $j$ten Level von Faktor B in einem ZVA Anwendungsszenario modelliert. Dann hat das Modell der additiven ZVA mit Referenzgruppe die strukturelle Form

$$y_{ijk} = \mu_{ij} + \varepsilon_{ijk} \text{ mit } \varepsilon_{ijk} \sim N\left(0, \sigma^2\right) \text{ u.i.v. für } i = 1, \dots, I, j = 1, \dots, J, k = 1, \dots, n_{ij} \tag{42.4}$$

und die Datenverteilungsform

$$y_{ijk} \sim N\left(\mu_{ij}, \sigma^2\right) \text{ u.v. für } i = 1, \dots, I, j = 1, \dots, J, k = 1, \dots, n_{ij} \tag{42.5}$$

Innerhalb jeder Faktorlevelkombination (i, j) sind die $y_{ijk}, k = 1, \ldots, n_{ij}$, dabei identisch verteilt. mit

$$\mu_{ij} := \mu_0 + \alpha_i + \beta_j \text{ für } i = 1, \ldots, I, j = 1, \ldots, J \text{ mit } \alpha_1 := \beta_1 := 0. \tag{42.6}$$

und $\sigma^2 > 0$.

•

Wir verzichten in Definition 42.1 auf die Angabe einer allgemeinen Designmatrixform, die wir im Folgenden lediglich für den 2×2 ZVA Spezialfall betrachten.

Die Expressivität des Modells der additiven ZVA ist, wie schon oben betont, auf das Abbilden von Haupteffekten beschränkt. Wir verdeutlichen dies in folgenden Parameterbeispielen und der zugehörigen fig-zva-add-beispiele.

Beispiel 42.1 (Additive ZVA mit einem Haupteffekt von Faktor A)**.** Es seien $\mu_0 := 1, \alpha_2 := 1$ und $\beta_2 := 0$, der Effektparameter für den Haupteffekt von Faktor A sei also von Null verschieden, der Effektparameter für den Haupteffekt von Faktor B dagegen gleich Null. Dann ergibt sich für die Gruppenerwartungswerte

$$\begin{array}{l|l} \mu_{11} = \mu_0 + \alpha_1 + \beta_1 = 1 + 0 + 0 = 1 & \mu_{12} = \mu_0 + \alpha_1 + \beta_2 = 1 + 0 + 0 = 1 \\ \mu_{21} = \mu_0 + \alpha_2 + \beta_1 = 1 + 1 + 0 = 2 & \mu_{22} = \mu_0 + \alpha_2 + \beta_2 = 1 + 1 + 0 = 2 \end{array} \tag{42.7}$$

fig-zva-add-beispiele A zeigt Visualisierungen dieses Erwartungswertmusters in der Balkendiagramm- und Liniendiagrammform von Abbildung 42.3.

△

Beispiel 42.2 (Additive ZVA mit einem Haupteffekt von Faktor B)**.** Es seien $\mu_0 := 1, \alpha_2 := 0$ und $\beta_2 := 1$, der Effektparameter für den Haupteffekt von Faktor A sei also gleich Null, der Effektparameter für den Haupteffekt von Faktor B dagegen von Null verschieden. Dann ergibt sich für die Gruppenerwartungswerte

$$\begin{array}{l|l} \mu_{11} = \mu_0 + \alpha_1 + \beta_1 = 1 + 0 + 0 = 1 & \mu_{12} = \mu_0 + \alpha_1 + \beta_2 = 1 + 0 + 1 = 2 \\ \mu_{21} = \mu_0 + \alpha_2 + \beta_1 = 1 + 0 + 0 = 1 & \mu_{22} = \mu_0 + \alpha_2 + \beta_2 = 1 + 0 + 1 = 2 \end{array} \tag{42.8}$$

fig-zva-add-beispiele B zeigt Visualisierungen dieses Erwartungswertmusters in der Balkendiagramm- und Liniendiagrammform von Abbildung 42.3.

△

Beispiel 42.3 (Additive ZVA mit Haupteffekten beider Faktoren)**.** Es seien $\mu_0 := 1, \alpha_2 := 1$ und $\beta_2 := 1$, die Effektparameter für die Haupteffekte beider Faktoren seien also von Null verschieden. Dann ergibt sich für die Gruppenerwartungswerte

$$\begin{array}{l|l} \mu_{11} = \mu_0 + \alpha_1 + \beta_1 = 1 + 0 + 0 = 1 & \mu_{12} = \mu_0 + \alpha_1 + \beta_2 = 1 + 0 + 1 = 2 \\ \mu_{21} = \mu_0 + \alpha_2 + \beta_1 = 1 + 1 + 0 = 2 & \mu_{22} = \mu_0 + \alpha_2 + \beta_2 = 1 + 1 + 1 = 3 \end{array} \tag{42.9}$$

Abbildung 42.4 C zeigt Visualisierungen dieses Erwartungswertmusters in der Balkendiagramm- und Liniendiagrammform von Abbildung 42.3.

△

```
pdf
  2
```

In Hinblick auf die Liniendiagrammform der Gruppenerwartungswerte der additiven ZVA fällt auf, dass die den Leveln von Faktor A entsprechenden Linien immer parallel sind.

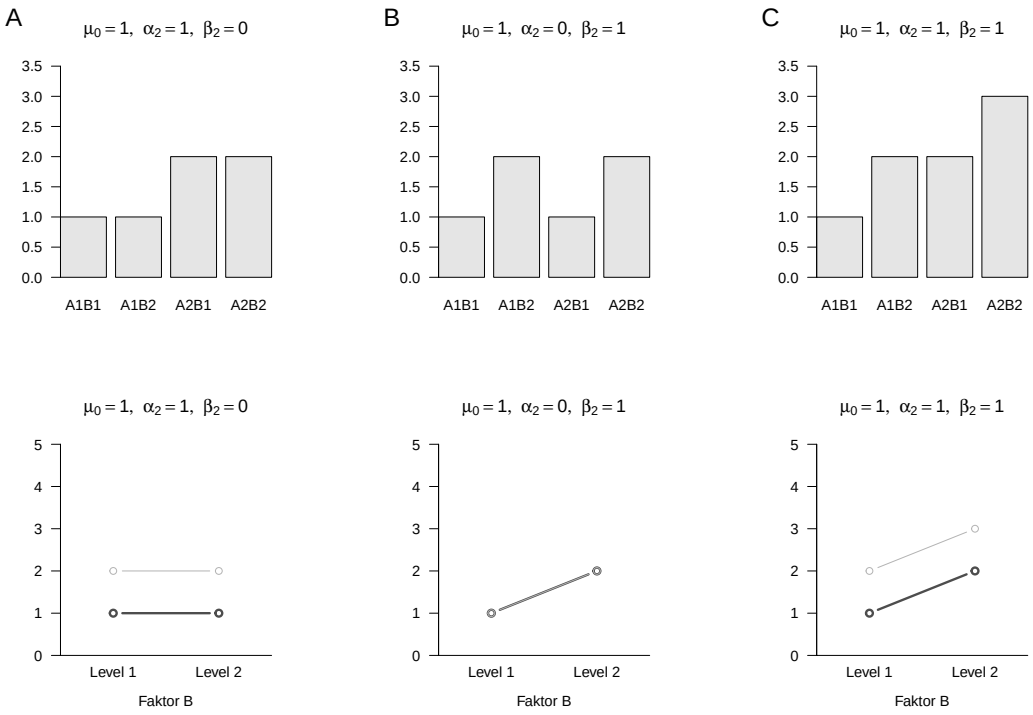


Abbildung 42.4. Gruppenerwartungswerte der Beispielparameterszenarien in Balken- und Liniendiagrammform im Modell der additiven ZVA.

Für den Fall der 2×2 ZVA gibt Definition 42.2 abschließend das Modell der additiven ZVA mit Referenzgruppe inklusive seiner Designmatrixform an.

Definition 42.2 (Modell der additiven 2×2 ZVA mit Referenzgruppe)**.** y_{ijk} mit $i = 1, 2, j = 1, 2, k = 1, \dots, n_{ij}$ sei die Zufallsvariable, die den $k$ten Datenpunkt zum $i$ten Level von Faktor A und dem $j$ten Level von Faktor B in einem 2×2 ZVA Anwendungsszenario modelliert. Dann hat mit $\sigma^2 > 0$ das *Modell der additiven* 2×2 *ZVA mit Referenzgruppe* die strukturelle Form

$$y_{ijk} = \mu_{ij} + \varepsilon_{ijk} \text{ mit } \varepsilon_{ijk} \sim N\left(0, \sigma^2\right) \text{ u.i.v. für } i = 1, 2, j = 1, 2, k = 1, \dots, n_{ij}, \quad (42.10)$$

die Datenverteilungsform

$$y_{ijk} \sim N\left(\mu_{ij}, \sigma^2\right) \text{ u.v. für } i = 1, 2, j = 1, 2, k = 1, \dots, n_{ij} \quad (42.11)$$

Innerhalb jeder Faktorlevelkombination (i, j) sind die $y_{ijk}, k = 1, \dots, n_{ij}$, dabei identisch verteilt. mit

$$\mu_{ij} := \mu_0 + \alpha_i + \beta_j \text{ für } i = 1, 2, j = 1, 2 \text{ mit } \alpha_1 := \beta_1 := 0, \quad (42.12)$$

sowie die Designmatrixform

$$y \sim N\left(X\beta, \sigma^2 I_n\right) \tag{42.13}$$

wobei

$$y := \begin{pmatrix} y_{111} \\ \vdots \\ y_{11n_{11}} \\ y_{121} \\ \vdots \\ y_{12n_{12}} \\ y_{211} \\ \vdots \\ y_{21n_{21}} \\ y_{221} \\ \vdots \\ y_{22n_{22}} \end{pmatrix}, X = \begin{pmatrix} 1 & 0 & 0 \\ \vdots & \vdots & \vdots \\ 1 & 0 & 0 \\ 1 & 0 & 1 \\ \vdots & \vdots & \vdots \\ 1 & 0 & 1 \\ 1 & 1 & 0 \\ \vdots & \vdots & \vdots \\ 1 & 1 & 0 \\ 1 & 1 & 1 \\ \vdots & \vdots & \vdots \\ 1 & 1 & 1 \end{pmatrix} \in \mathbb{R}^{n \times 3}, \beta := \begin{pmatrix} \mu_0 \\ \alpha_2 \\ \beta_2 \end{pmatrix} \in \mathbb{R}^3 \text{ und } \sigma^2 > 0. \tag{42.14}$$

•

42.2.2. Modell der ZVA mit Interaktion

In der ZVA mit Interaktion möchte man die Gruppenerwartungswerte μ_{ij} mit $i = 1, \dots, I$ für die Level von Faktor A und $j = 1, \dots, J$ für die Level von Faktor B als Summe eines gruppenunspezifischen Erwartungswertes, der Effekte der Level von Faktor A und Faktor B und der Interaktion der Level der Faktoren modellieren. Wir bezeichnen dazu den gruppenunspezifischen Erwartungswertparameter mit μ_0, den Effekt von Level i von Faktor A mit α_i, den Effekt von Level j von Faktor B mit β_j, und die Interaktion von Level i von Faktor A mit Level j von Faktor B mit γ_{ij}. Dann ergibt sich zum Beispiel für $I := J := 2$

$$\begin{array}{l|l} \mu_{11} := \mu_0 + \alpha_1 + \beta_1 + \gamma_{11} & \mu_{12} := \mu_0 + \alpha_1 + \beta_2 + \gamma_{12} \\ \hline \mu_{21} := \mu_0 + \alpha_2 + \beta_1 + \gamma_{21} & \mu_{22} := \mu_0 + \alpha_2 + \beta_2 + \gamma_{22} \end{array} \tag{42.15}$$

Wie in der additiven ZVA ist diese Darstellung der Gruppenerwartungswerte μ_{ij} multipel überparameterisiert, speziell werden die vier Erwartungswertparameter $\mu_{11}, \mu_{12}, \mu_{21}$ und μ_{22} in obiger Formulierung durch die neun Parameter μ_0, α_1, α_2, β_1, β_2, γ_{11}, γ_{12}, γ_{21} und γ_{11} dargestellt. Um eine eindeutige Darstellung der μ_{ij} zu gewährleisten, bietet sich auch hier die Restriktion an, den Effekt des ersten Levels jedes Faktors und jeder Interaktion als Null zu definieren

$$\alpha_1 := \beta_1 := \gamma_{i1} := \gamma_{1j} := 0 \text{ für } i = 1, \dots, I, j = 1, .., J \tag{42.16}$$

und damit die Faktorlevelkombination A1B1 als Referenzgruppe zu etablieren. Es ergibt sich somit zum Beispiel für $I := J := 2$:

$$\begin{array}{l|l} \mu_{11} := \mu_0 & \mu_{12} := \mu_0 + \beta_2 \\ \hline \mu_{21} := \mu_0 + \alpha_2 & \mu_{22} := \mu_0 + \alpha_2 + \beta_2 + \gamma_{22} \end{array} \tag{42.17}$$

Hier werden nun also die vier Erwartungswertparameter $\mu_{11}, \mu_{12}, \mu_{21}$ und μ_{22} durch die vier Effektparameter μ_0, α_2, β_2 und γ_{22} dargestellt. Natürlich ändern sich auch bei dieser Effektdarstellung des Modells der 2×2 ZVA mit Interaktion und Referenzgruppe

die Interpretationen der Parameter $\mu_0, \alpha_2, \beta_2, \gamma_{22}$ im Vergleich zum überparameterisierten Fall ohne Referenzgruppe: μ_0 entspricht dem Erwartungswert der Faktorlevelkombination A1B1, α_2 der Differenz beim Übergang von Level 1 zu Level 2 von Faktor A, β_2 der Differenz beim Übergang von Level 1 zu Level 2 von Faktor B und γ_{22} der Differenz beim Übergang von Level 1 zu Level 2 von Faktor B im Unterschied zum Übergang von Level 1 zu Level 2 von Faktor A. Wir fassen obige Überlegungen in folgender Definition zusammen, wobei wir wiederum auf die Angabe einer allgemeinen Designmatrixform verzichten wollen.

Definition 42.3 (Modell der ZVA mit Interaktion und Referenzgruppe)**.** y_{ijk} mit $i = 1, \dots, I, j = 1, \dots, J, k = 1, \dots, n_{ij}$ sei die Zufallsvariable, die den $k$ten Datenpunkt zum $i$ten Level von Faktor A und dem $j$ten Level von Faktor B in einem ZVA Anwendungsszenario modelliert. Dann hat das Modell der ZVA mit Interaktion und Referenzgruppe die strukturelle Form

$$y_{ijk} = \mu_{ij} + \varepsilon_{ijk} \text{ mit } \varepsilon_{ijk} \sim N\left(0, \sigma^2\right) \text{ u.i.v. für } i = 1, \dots, I, j = 1, \dots, J, k = 1, \dots, n_{ij} \tag{42.18}$$

und die Datenverteilungsform

$$y_{ijk} \sim N\left(\mu_{ij}, \sigma^2\right) \text{ u.v. für } i = 1, \dots, I, j = 1, \dots, J, k = 1, \dots, n_{ij} \tag{42.19}$$

Innerhalb jeder Faktorlevelkombination (i, j) sind die $y_{ijk}, k = 1, \dots, n_{ij}$, dabei identisch verteilt. mit

$$\mu_{ij} := \mu_0 + \alpha_i + \beta_j + \gamma_{ij} \tag{42.20}$$

sowie

$$\alpha_1 := \beta_1 := \gamma_{i1} := \gamma_{1j} := 0 \text{ für } i = 1, \dots, I, j = 1, \dots, J \tag{42.21}$$

und $\sigma^2 > 0$.

•

Die Expressivität des Modells der ZVA mit Interaktion entspricht nun dem Betrachten von Haupteffekten und Interaktion wie einleitend zum Anwendungsszenario der ZVA diskutiert. Wir wollen dies mithilfe folgender Parameterbeispiele und der zugehörigen Abbildung 42.5 verdeutlichen.

Beispiel 42.4 (ZVA mit positiver Interaktion ohne Haupteffekte)**.** Es seien $\mu_0 := 1, \alpha_2 := 0, \beta_2 := 0$ und $\gamma_{22} = 2$, die Effektparameter für die Haupteffekte beider Faktoren seien also gleich Null, aber der Effektparameter für die Interaktion der Faktoren positiv. Dann ergibt sich für die Gruppenerwartungswerte

$$\begin{array}{l|l} \mu_{11} = \mu_0 + \alpha_1 + \beta_1 + \gamma_{11} = 1 + 0 + 0 + 0 = 1 & \mu_{12} = \mu_0 + \alpha_1 + \beta_2 + \gamma_{12} = 1 + 0 + 0 + 0 = 1 \\ \mu_{21} = \mu_0 + \alpha_2 + \beta_1 + \gamma_{21} = 1 + 0 + 0 + 0 = 1 & \mu_{22} = \mu_0 + \alpha_2 + \beta_2 + \gamma_{22} = 1 + 0 + 0 + 2 = 3 \end{array} \tag{42.22}$$

Abbildung 42.5 A zeigt Visualisierungen dieses Erwartungswertmusters in Balkendiagramm- und Liniendiagrammform.

△

Beispiel 42.5 (ZVA mit negativer Interaktion und zwei Haupteffekten)**.** Es seien $\mu_0 := 1, \alpha_2 := 1, \beta_2 := 1$ und $\gamma_{22} = -2$. Die Effektparameter für die Haupteffekte beider Faktoren seien also gleich und der Effektparameter für die Interaktion der Faktoren negativ. Dann ergibt sich für die Gruppenerwartungswerte

$$\begin{array}{l|l} \mu_{11} = \mu_0 + \alpha_1 + \beta_1 + \gamma_{11} = 1 + 0 + 0 + 0 = 1 & \mu_{12} = \mu_0 + \alpha_1 + \beta_2 + \gamma_{12} = 1 + 0 + 1 + 0 = 2 \\ \mu_{21} = \mu_0 + \alpha_2 + \beta_1 + \gamma_{21} = 1 + 0 + 1 + 0 = 2 & \mu_{22} = \mu_0 + \alpha_2 + \beta_2 + \gamma_{22} = 1 + 1 + 1 - 2 = 1 \end{array} \tag{42.23}$$

Abbildung 42.5 B zeigt Visualisierungen dieses Erwartungswertmusters in Balkendiagramm- und Liniendiagrammform.

△

Beispiel 42.6 (ZVA mit einem Haupteffekt von Faktor A und positiver Interaktion)**.** Es seien $\mu_0 := 1, \alpha_2 := 1, \beta_2 := 0$ und $\gamma_{22} = 1$, der Effektparameter für Faktor A sei also positiv, der Effektparameter für Faktor B gleich Null und der Effektparameter für die Interaktion der Faktoren positiv. Dann ergibt sich für die Gruppenerwartungswerte

$$\begin{array}{l|l} \mu_{11} = \mu_0 + \alpha_1 + \beta_1 + \gamma_{11} = 1 + 0 + 0 + 0 = 1 & \mu_{12} = \mu_0 + \alpha_1 + \beta_2 + \gamma_{12} = 1 + 0 + 0 + 0 = 1 \\ \mu_{21} = \mu_0 + \alpha_2 + \beta_1 + \gamma_{21} = 1 + 1 + 0 + 0 = 2 & \mu_{22} = \mu_0 + \alpha_2 + \beta_2 + \gamma_{22} = 1 + 1 + 0 + 1 = 3 \end{array} \tag{42.24}$$

Abbildung 42.5 C zeigt Visualisierungen dieses Erwartungswertmusters in Balkendiagramm- und Liniendiagrammform.

△

Beispiel 42.7 (ZVA mit einem Haupteffekt von Faktor B und positiver Interaktion)**.** Es seien $\mu_0 := 1, \alpha_2 := 0, \beta_2 := 1$ und $\gamma_{22} = 1$, der Effektparameter für Faktor A sei also gleich Null, der Effektparameter für Faktor B positiv und der Effektparameter für die Interaktion der Faktoren wiederum positiv. Dann ergibt sich für die Gruppenerwartungswerte

$$\begin{array}{l|l} \mu_{11} = \mu_0 + \alpha_1 + \beta_1 + \gamma_{11} = 1 + 0 + 0 + 0 = 1 & \mu_{12} = \mu_0 + \alpha_1 + \beta_2 + \gamma_{12} = 1 + 0 + 1 + 0 = 2 \\ \mu_{21} = \mu_0 + \alpha_2 + \beta_1 + \gamma_{21} = 1 + 0 + 0 + 0 = 1 & \mu_{22} = \mu_0 + \alpha_2 + \beta_2 + \gamma_{22} = 1 + 0 + 1 + 1 = 3 \end{array} \tag{42.25}$$

Abbildung 42.5 D zeigt Visualisierungen dieses Erwartungswertmusters in Balkendiagramm- und Liniendiagrammform.

△

Die obigen Beispiele zeigen, dass die Expressivität der ZVA mit Interaktion im Sinne der durch das Modell abzubildenden Datenmuster ungleich höher als die Expressivität des rein additiven Modells der ZVA ist. Insbesondere bilden obige vier Beispiele bei Weitem nicht den gesamten kombinatorischen qualitativen Parameterraum der ZVA mit Interaktion ab. Hinsichtlich der Liniendiagrammvisualisation der Gruppenerwartungswertparameter bei ZVA mit Interaktion fällt auf, dass ein von Null verschiedener Interaktionsterm immer impliziert, dass die die Level von Faktor A repräsentierenen Linien immer nicht parallel verlaufen.

Abschließend geben wir in Definition 42.4 den Spezialfall des Modells der 2×2 ZVA mit Interaktion und Referenzgruppe inklusiver seiner Designmatrixform an.

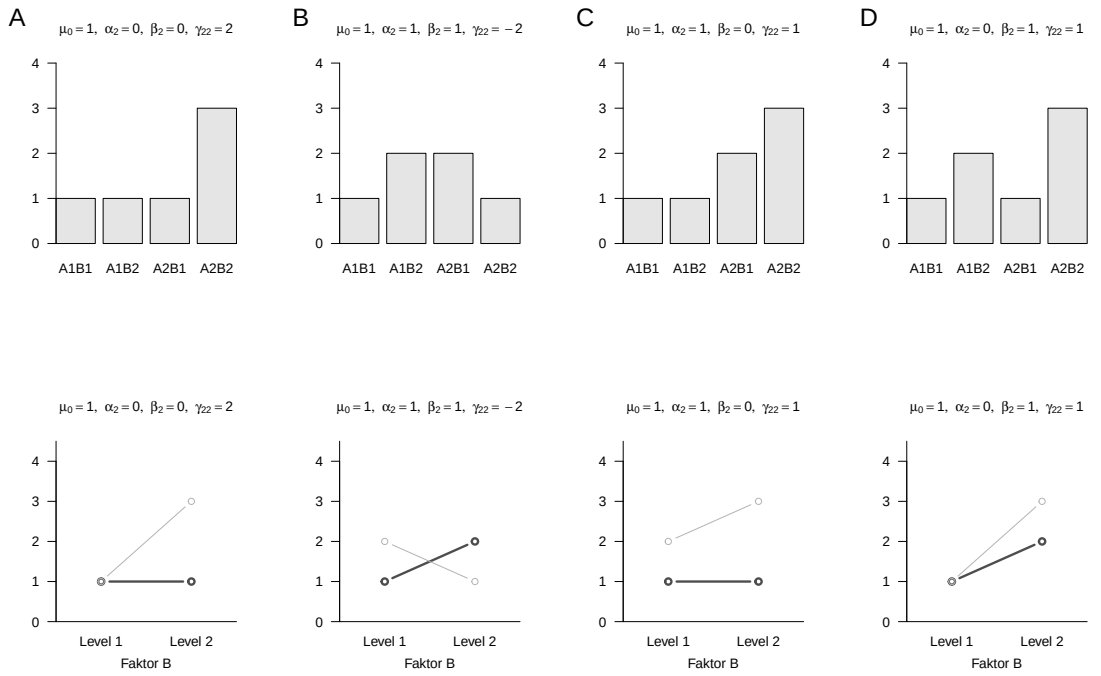


Abbildung 42.5. Gruppenerwartungswerte der Beispielparameterszenarien in Balken- und Liniendiagrammform im Modell der ZVA mit Interaktion.

Definition 42.4 (Modell der 2×2 ZVA mit Interaktion und Referenzgruppe.)**.** y_{ijk} mit $i = 1, 2, j = 1, 2, k = 1, \dots, n_{ij}$ sei die Zufallsvariable, die den k-ten Datenpunkt zum i-ten Level von Faktor A und dem j-ten Level von Faktor B in einem 2×2 ZVA Anwendungsszenario modelliert. Dann hat das Modell der 2×2 ZVA mit Interaktion und Referenzgruppe für $\sigma^2 > 0$ die strukturelle Form

$$y_{ijk} = \mu_{ij} + \varepsilon_{ijk} \text{ mit } \varepsilon_{ijk} \sim N\left(0, \sigma^2\right) \text{ u.i.v. für } i = 1, 2, j = 1, 2, k = 1, \dots, n_{ij}, \quad (42.26)$$

die Datenverteilungsform

$$y_{ijk} \sim N\left(\mu_{ij}, \sigma^2\right) \text{ u.v. für } i = 1, 2, j = 1, 2, k = 1, \dots, n_{ij} \quad (42.27)$$

Innerhalb jeder Faktorlevelkombination (i, j) sind die $y_{ijk}, k = 1, \dots, n_{ij}$, dabei identisch verteilt. mit

$$\mu_{ij} := \mu_0 + \alpha_i + \beta_j + \gamma_{ij} \quad (42.28)$$

sowie

$$\alpha_1 := \beta_1 := \gamma_{i1} := \gamma_{1j} := 0 \text{ für } i = 1, \dots, I, j = 1, \dots, J \quad (42.29)$$

und für $n := \sum_{i=1}^{2} \sum_{i=1}^{2} n_{ij}$ die Designmatrixform

$$y \sim N\left(X\beta, \sigma^2 I_n\right), \text{ mit} \quad (42.30)$$

$$y := \begin{pmatrix} y_{111} \\ \vdots \\ y_{11n_{11}} \\ y_{121} \\ \vdots \\ y_{12n_{12}} \\ y_{211} \\ \vdots \\ y_{21n_{21}} \\ y_{221} \\ \vdots \\ y_{22n_{22}} \end{pmatrix}, X = \begin{pmatrix} 1 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 1 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & 1 & 1 & 1 \end{pmatrix} \in \mathbb{R}^{n \times 4}, \beta := \begin{pmatrix} \mu_0 \\ \alpha_2 \\ \beta_2 \\ \gamma_{22} \end{pmatrix} \in \mathbb{R}^4 \text{ und } \sigma^2 > 0. \tag{42.31}$$

•

Beispiel 42.8 (Designmatrix des 2×2 ZVA-Modells mit Interaktion)**.** Als konkretes Beispiel für die Designmatrixform des in Definition 42.4 definierten Modells betrachten wir das Szenario $n_{ij} := 4$, also $n = 16$. Dann gilt

$$y = X\beta + \varepsilon \text{ mit } \varepsilon \sim N\left(0_{16}, \sigma^2 I_{16}\right) \tag{42.32}$$

mit

$$y := \begin{pmatrix} y_{111} \\ y_{112} \\ y_{113} \\ y_{114} \\ y_{121} \\ y_{122} \\ y_{123} \\ y_{124} \\ y_{211} \\ y_{212} \\ y_{213} \\ y_{214} \\ y_{221} \\ y_{222} \\ y_{223} \\ y_{224} \end{pmatrix}, X := \begin{pmatrix} 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \end{pmatrix} \in \mathbb{R}^{16 \times 4}, \beta := \begin{pmatrix} \mu_0 \\ \alpha_2 \\ \beta_2 \\ \gamma_{22} \end{pmatrix} \in \mathbb{R}^4 \text{ und } \sigma^2 > 0. \tag{42.33}$$

Folgender **R** Code erlaubt die Realisierung von Daten im Falle dieses Beispiels.

```
library(MASS)                                                    # Multivariate Normalverteilung
I      = 2                                                       # Anzahl Level Faktor A
J      = 2                                                       # Anzahl Level Faktor B
n_ij   = 4                                                       # Anzahl von Datenpunkten der i,jten Gruppe
n      = I*J*n_ij                                                # Anzahl Datenpunkte
p      = 1 + (I-1)+(J-1)+(I*J-3)                                 # Anzahl Parameter
D      = matrix(c(1,0,0,0,                                       # Prototypische Designmatrix für balancierte Designs
                  1,0,1,0,
                  1,1,0,0,
                  1,1,1,1),
                nrow  = p,
                byrow = TRUE)
C      = matrix(rep(1,n_ij),nrow = n_ij)                         # Prototypischer Zellenvektor für balancierte Designs
X      = kronecker(D,C)                                          # Kroneckerprodukt Designmatrix Erzeugung
I_n    = diag(n)                                                 # n x n Einheitsmatrix
beta   = matrix(c(1,1,1,1), nrow = p)                            # \beta = (\mu_0,\alpha_2,\alpha_3,\alpha_4)
sigsqr = 10                                                      # \sigma^2
y      = mvrnorm(1, X %*% beta, sigsqr*I_n)                      # eine Realisierung eines n-dimensionalen ZVs
```

△

42.3. Modellschätzung

Wir betrachten im Folgenden die Betaparameterschätzer im additiven 2×2 ZVA Modell mit Referenzgruppe und im 2×2 ZVA mit Interaktion und Referenzgruppe. Dabei stellt sich wenig überraschend heraus, dass sich die Schätzer für die Komponenten des Betaparameters der in Definition 42.2 und Definition 42.4 formulierten Modelle als gewichtete Summen der gruppenspezifischen Stichprobenmittel ergeben. Die genaue Form dieser gewichteten Summen ist Inhalt der beiden folgenden Theoreme. Der Einfachheit halber gehen wir dabei jeweils von einem balancierten Design aus. Wir beginnen mit der Betaparameterschätzung im additiven 2×2 ZVA Modell mit Referenzgruppe.

Theorem 42.1 (Betaparameterschätzung im additiven 2×2 ZVA Modell mit Referenzgruppe)**.** *Gegeben sei die Designmatrixform eines balancierten additiven 2×2 ZVA Modells mit Referenzgruppe. Dann ergibt sich für den Betaparameterschätzer*

$$\hat{\beta} := \begin{pmatrix} \hat{\mu}_0 \\ \hat{\alpha}_2 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} \frac{3}{4}\bar{y}_{11} + \frac{1}{4}\left(\bar{y}_{12} + \bar{y}_{21}\right) - \frac{1}{4}\bar{y}_{22} \\ \frac{1}{2}\left(\bar{y}_{21} + \bar{y}_{22}\right) - \frac{1}{2}\left(\bar{y}_{11} + \bar{y}_{12}\right) \\ \frac{1}{2}\left(\bar{y}_{12} + \bar{y}_{22}\right) - \frac{1}{2}\left(\bar{y}_{11} + \bar{y}_{21}\right) \end{pmatrix}, \tag{42.34}$$

wobei

$$\bar{y}_{ij} := \frac{1}{n_{ij}} \sum_{k=1}^{n_{ij}} y_{ijk} \text{ für } 1 \leq i, j \leq 2 \tag{42.35}$$

das Stichprobenmittel der i, jten Gruppe des 2×2 ZVA-Designs bezeichnet.

∘

Beweis. Wir bestimmen zunächst $X^T y, X^T X$ und $\left(X^T X\right)^{-1}$ bei konstantem n_{ij} für $1 \leq i, j \leq 2$. Es ergeben sich

$$X^T y = \begin{pmatrix} 1 & \cdots & 1 & 1 & \cdots & 1 & 1 & \cdots & 1 & 1 & \cdots & 1 \\ 0 & \cdots & 0 & 0 & \cdots & 0 & 1 & \cdots & 1 & 1 & \cdots & 1 \\ 0 & \cdots & 0 & 1 & \cdots & 1 & 0 & \cdots & 0 & 1 & \cdots & 1 \end{pmatrix} \begin{pmatrix} y_{111} \\ \vdots \\ y_{11n_{11}} \\ y_{121} \\ \vdots \\ y_{12n_{12}} \\ y_{211} \\ \vdots \\ y_{21n_{21}} \\ y_{221} \\ \vdots \\ y_{22n_{22}} \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^{2} \sum_{k=1}^{2} \sum_{k=1}^{n_{ij}} y_{ijk} \\ \sum_{j=1}^{2} \sum_{k=1}^{n_{2j}} y_{2jk} \\ \sum_{i=1}^{2} \sum_{k=1}^{n_{i2}} y_{i2k} \end{pmatrix}, \tag{42.36}$$

$$X^T X = \begin{pmatrix} 1 & \cdots & 1 & 1 & \cdots & 1 & 1 & \cdots & 1 & 1 & \cdots & 1 \\ 0 & \cdots & 0 & 0 & \cdots & 0 & 1 & \cdots & 1 & 1 & \cdots & 1 \\ 0 & \cdots & 0 & 1 & \cdots & 1 & 0 & \cdots & 0 & 1 & \cdots & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 & 0 \\ \vdots & \vdots & \vdots \\ 1 & 0 & 0 \\ 1 & 0 & 1 \\ \vdots & \vdots & \vdots \\ 1 & 0 & 1 \\ 1 & 1 & 0 \\ \vdots & \vdots & \vdots \\ 1 & 1 & 0 \\ 1 & 1 & 1 \\ \vdots & \vdots & \vdots \\ 1 & 1 & 1 \end{pmatrix} = n_{ij} \begin{pmatrix} 4 & 2 & 2 \\ 2 & 2 & 1 \\ 2 & 1 & 2 \end{pmatrix}, \tag{42.37}$$

sowie

$$(X^TX)^{-1} = n_{ij}\begin{pmatrix}4 & 2 & 2\\ 2 & 2 & 1\\ 2 & 1 & 2\end{pmatrix}^{-1} = \frac{1}{n_{ij}}\begin{pmatrix}\frac{3}{4} & -\frac{1}{2} & -\frac{1}{2}\\ -\frac{1}{2} & 1 & 0\\ -\frac{1}{2} & 0 & 1\end{pmatrix}. \tag{42.38}$$

Es ergibt sich also

$$\hat{\beta} = \begin{pmatrix}\hat{\mu}_0\\ \hat{\alpha}_2\\ \hat{\beta}_2\end{pmatrix} = \frac{1}{n_{ij}}\begin{pmatrix}\frac{3}{4} & -\frac{1}{2} & -\frac{1}{2}\\ -\frac{1}{2} & 1 & 0\\ -\frac{1}{2} & 0 & 1\end{pmatrix}\begin{pmatrix}\sum_{i=1}^{2}\sum_{j=1}^{2}\sum_{k=1}^{n_{ij}} y_{ijk}\\ \sum_{j=1}^{2}\sum_{k=1}^{n_{2j}} y_{2jk}\\ \sum_{i=1}^{2}\sum_{k=1}^{n_{i2}} y_{i2k}\end{pmatrix}. \tag{42.39}$$

Damit ergibt sich dann

$$\begin{aligned}\hat{\mu}_0 &= \frac{1}{n_{ij}}\left(\frac{3}{4}\sum_{i=1}^{2}\sum_{j=1}^{2}\sum_{k=1}^{n_{ij}} y_{ijk} - \frac{1}{2}\sum_{j=1}^{2}\sum_{k=1}^{n_{2j}} y_{2jk} - \frac{1}{2}\sum_{i=1}^{2}\sum_{k=1}^{n_{i2}} y_{i2k}\right)\\ &= \frac{1}{n_{ij}}\left(\frac{3}{4}\sum_{k=1}^{n_{11}} y_{11k} + \frac{3}{4}\sum_{k=1}^{n_{12}} y_{12k} + \frac{3}{4}\sum_{k=1}^{n_{21}} y_{21k} + \frac{3}{4}\sum_{k=1}^{n_{22}} y_{22k}\right)\\ &+ \frac{1}{n_{ij}}\left(-\frac{1}{2}\sum_{k=1}^{n_{21}} y_{21k} - \frac{1}{2}\sum_{k=1}^{n_{22}} y_{22k} - \frac{1}{2}\sum_{k=1}^{n_{12}} y_{12k} - \frac{1}{2}\sum_{k=1}^{n_{22}} y_{22k}\right)\\ &= \frac{1}{n_{ij}}\left(\frac{3}{4}\sum_{k=1}^{n_{11}} y_{11k} + \frac{1}{4}\sum_{k=1}^{n_{12}} y_{12k} + \frac{1}{4}\sum_{k=1}^{n_{21}} y_{21k} - \frac{1}{4}\sum_{k=1}^{n_{22}} y_{22k}\right)\\ &= \frac{3}{4}\bar{y}_{11} + \frac{1}{4}\left(\bar{y}_{12} + \bar{y}_{21}\right) - \frac{1}{4}\bar{y}_{22}\end{aligned} \tag{42.40}$$

sowie

$$\begin{aligned}\hat{\alpha}_2 &= \frac{1}{n_{ij}}\left(-\frac{1}{2}\sum_{i=1}^{2}\sum_{j=1}^{2}\sum_{k=1}^{n_{ij}} y_{ijk} + \sum_{j=1}^{2}\sum_{k=1}^{n_{2j}} y_{2jk}\right)\\ &= \frac{1}{n_{ij}}\left(-\frac{1}{2}\sum_{k=1}^{n_{11}} y_{11k} - \frac{1}{2}\sum_{k=1}^{n_{12}} y_{12k} - \frac{1}{2}\sum_{k=1}^{n_{21}} y_{21k} - \frac{1}{2}\sum_{k=1}^{n_{22}} y_{22k} + \sum_{k=1}^{n_{21}} y_{21k} + \sum_{k=1}^{n_{22}} y_{22k}\right)\\ &= \frac{1}{n_{ij}}\left(-\frac{1}{2}\sum_{k=1}^{n_{11}} y_{11k} - \frac{1}{2}\sum_{k=1}^{n_{12}} y_{12k} + \frac{1}{2}\sum_{k=1}^{n_{21}} y_{21k} + \frac{1}{2}\sum_{k=1}^{n_{22}} y_{22k}\right)\\ &= \frac{1}{2}\left(\bar{y}_{21} + \bar{y}_{22}\right) - \frac{1}{2}\left(\bar{y}_{11} + \bar{y}_{12}\right)\end{aligned} \tag{42.41}$$

und analog für $\hat{\beta}_2$. □

Beispiel 42.9 (Betaparameterschätzung im additiven 2×2 ZVA-Modell)**.** Wir verdeutlichen den in Theorem 42.1 formulierten Zusammenhang zwischen den Betaparameterschätzerkomponenten und den gruppenspezifischen Stichprobenmitteln mithilfe folgenden **R** Codes am Beispieldatensatz.

```
# Datenreformatierung
D          = read.csv("./_data/509-zweifaktorielle-varianzanalyse.csv")        # Datensatz
A1B1       = D$dBDI[D$Setting == "F2F" & D$Variant == "MND" ]                  # Face-to-face, mindfulness
A1B2       = D$dBDI[D$Setting == "F2F" & D$Variant == "EXC" ]                  # Face-to-face, exercise
A2B1       = D$dBDI[D$Setting == "ONL" & D$Variant == "MND" ]                  # Online      , mindfulness
A2B2       = D$dBDI[D$Setting == "ONL" & D$Variant == "EXC" ]                  # Online      , exercise

# Datenmatrix für Gruppenmittelwerte
n_ij       = length(A1B1)                                                      # Anzahl Datenpunkte pro Gruppe
Y          = matrix(c(A1B1,A1B2,A2B1,A2B2), nrow = n_ij)                       # Datenmatrix
bar_y      = colMeans(Y)                                                       # Zellenmittelwerte

# Modellschätzung
I          = 2                                                                 # Anzahl Level Faktor A (Therapiesetting)
J          = 2                                                                 # Anzahl Level Faktor B (Therapievariante)
n          = I*J*n_ij                                                          # Anzahl Datenpunkte
p          = 1 + (I-1)+(J-1)+(I*J-3)                                           # Anzahl Parameter
D          = matrix(c(1,0,0,                                                   # Prototypische Designmatrix für balancierte Designs
                      1,0,1,
                      1,1,0,
                      1,1,1), nrow = p, byrow = TRUE)
C          = matrix(rep(1,n_ij),nrow = n_ij)                                   # Prototypischer Zellenvektor für balancierte Designs
X          = kronecker(D,C)                                                    # Kroneckerprodukt Designmatrix
y          = matrix(c(A1B1,A1B2,A2B1,A2B2), nrow = n)                          # Datenvektor
beta_hat   = solve(t(X) %*% X) %*% t(X) %*% y                                  # Betaparameterschätzer
eps_hat    = y - X %*% beta_hat                                                # Residuenvektor
sigsqr_hat = (t(eps_hat) %*% eps_hat) /(n-p)                                   # Varianzparameterschätzer
```

```
hat{beta}                                              :  10.15 0.29 5.04
hat{sigsqr}                                            :  6.07
bar{y}_11,bar{y}_12,bar{y}_21,bar{y}_22                :  10.5 14.83 10.08 15.83
3/4bar{y}_11 + 1/4(bar{y}_12 + bar{y}_21) - 1/4bar{y}_22 :  10.15
1/2(bar{y}_21 + bar{y}_22) - 1/2(bar{y}_11 + bar{y}_12)  :  0.29
1/2(bar{y}_12 + bar{y}_22) - 1/2(bar{y}_11 + bar{y}_21)  :  5.04
```

△

Für die Betaparameterschätzung im 2×2 ZVA Modell mit Interaktion und Referenzgruppe ergibt sich folgendes Theorem.

Theorem 42.2 (Betaparameterschätzung im 2×2 ZVA Modell mit Interaktion und Referenzgruppe)**.** *Gegeben sei die Designmatrixform eines balancierten 2×2 ZVA Modells mit Interaktion und Referenzgruppe. Dann ergibt sich für den Betaparameterschätzer*

$$\hat{\beta} := \begin{pmatrix} \hat{\mu}_0 \\ \hat{\alpha}_2 \\ \hat{\beta}_2 \\ \hat{\gamma}_{22} \end{pmatrix} = \begin{pmatrix} \bar{y}_{11} \\ \bar{y}_{11} - \bar{y}_{11} \\ \bar{y}_{12} - \bar{y}_{11} \\ (\bar{y}_{11} - \bar{y}_{12}) - (\bar{y}_{21} - \bar{y}_{22}) \end{pmatrix} \tag{42.42}$$

wobei

$$\bar{y}_{ij} := \frac{1}{n_{ij}} \sum_{k=1}^{n_{ij}} y_{ijk} \text{ für } 1 \leq i, j \leq 2 \tag{42.43}$$

das Stichprobenmittel der i,jten Gruppe des 2×2 ZVA-Designs bezeichnet.

∘

Beweis. Wir bestimmen zunächst $X^T y, X^T X$ und $\left(X^T X\right)^{-1}$ bei konstantem n_{ij} für $1 \leq i, j \leq 2$. Es ergeben sich

$$X^T y = \begin{pmatrix} 1 & \cdots & 1 & 1 & \cdots & 1 & 1 & \cdots & 1 & 1 & \cdots & 1 \\ 0 & \cdots & 0 & 0 & \cdots & 0 & 1 & \cdots & 1 & 1 & \cdots & 1 \\ 0 & \cdots & 0 & 1 & \cdots & 1 & 0 & \cdots & 0 & 1 & \cdots & 1 \\ 0 & \cdots & 0 & 0 & \cdots & 0 & 0 & \cdots & 0 & 1 & \cdots & 1 \end{pmatrix} \begin{pmatrix} y_{111} \\ \vdots \\ y_{11n_{11}} \\ y_{121} \\ \vdots \\ y_{12n_{12}} \\ y_{211} \\ \vdots \\ y_{21n_{21}} \\ y_{221} \\ \vdots \\ y_{22n_{22}} \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^{2} \sum_{j=1}^{2} \sum_{k=1}^{n_{ij}} y_{ijk} \\ \sum_{j=1}^{2} \sum_{k=1}^{n_{2j}} y_{2jk} \\ \sum_{i=1}^{2} \sum_{k=1}^{n} y_{i2k} \\ \sum_{k=1}^{n_{22}} y_{22k} \end{pmatrix}, \tag{42.44}$$

$$X^T X = \begin{pmatrix} 1 & \cdots & 1 & 1 & \cdots & 1 & 1 & \cdots & 1 & 1 & \cdots & 1 \\ 0 & \cdots & 0 & 0 & \cdots & 0 & 1 & \cdots & 1 & 1 & \cdots & 1 \\ 0 & \cdots & 0 & 1 & \cdots & 1 & 0 & \cdots & 0 & 1 & \cdots & 1 \\ 0 & \cdots & 0 & 0 & \cdots & 0 & 0 & \cdots & 0 & 1 & \cdots & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 1 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & 1 & 1 & 1 \end{pmatrix} = n_{ij} \begin{pmatrix} 4 & 2 & 2 & 1 \\ 2 & 2 & 1 & 1 \\ 2 & 1 & 2 & 1 \\ 1 & 1 & 1 & 1 \end{pmatrix}, \tag{42.45}$$

sowie

$$(X^TX)^{-1} = n_{ij}\begin{pmatrix}4 & 2 & 2 & 1\\ 2 & 2 & 1 & 1\\ 2 & 1 & 2 & 1\\ 1 & 1 & 1 & 1\end{pmatrix}^{-1} = \frac{1}{n_{ij}}\begin{pmatrix}1 & -1 & -1 & 1\\ -1 & 2 & 1 & -2\\ -1 & 1 & 2 & -2\\ 1 & -2 & -2 & 4\end{pmatrix} \tag{42.46}$$

Es ergibt sich also

$$\hat{\beta} = \begin{pmatrix}\hat{\mu}_0\\ \hat{\alpha}_2\\ \hat{\beta}_2\\ \hat{\gamma}_{22}\end{pmatrix} = \frac{1}{n_{ij}}\begin{pmatrix}1 & -1 & -1 & 1\\ -1 & 2 & 1 & -2\\ -1 & 1 & 2 & -2\\ 1 & -2 & -2 & 4\end{pmatrix}\begin{pmatrix}\sum_{i=1}^{2}\sum_{j=1}^{2}\sum_{k=1}^{n_{ij}} y_{ijk}\\ \sum_{j=1}^{2}\sum_{k=1}^{n_{2j}} y_{2jk}\\ \sum_{i=1}^{2}\sum_{k=1}^{n_{i2}} y_{i2k}\\ \sum_{k=1}^{n_{22}} y_{22k}\end{pmatrix} \tag{42.47}$$

Damit ergibt sich dann

$$\begin{aligned}\hat{\mu}_0 &= \frac{1}{n_{ij}}\left(\sum_{i=1}^{2}\sum_{j=1}^{2}\sum_{k=1}^{n_{ij}} y_{ijk} - \sum_{j=1}^{2}\sum_{k=1}^{n_{2j}} y_{2jk} - \sum_{i=1}^{2}\sum_{k=1}^{n_{i2}} y_{i2k} + \sum_{k=1}^{n_{22}} y_{22k}\right)\\ &= \frac{1}{n_{ij}}\left(\sum_{k=1}^{n_{11}} y_{11k} + \sum_{k=1}^{n_{12}} y_{12k} + \sum_{k=1}^{n_{21}} y_{21k} + \sum_{k=1}^{n_{22}} y_{22k}\right)\\ &+ \frac{1}{n_{ij}}\left(-\sum_{k=1}^{n_{21}} y_{21k} - \sum_{k=1}^{n_{22}} y_{22k} - \sum_{k=1}^{n_{12}} y_{12k} - \sum_{k=1}^{n_{22}} y_{22k} + \sum_{k=1}^{n_{22}} y_{22k}\right)\\ &= \frac{1}{n_{11}}\sum_{k=1}^{n_{11}} y_{11k}\\ &= \bar{y}_{11}\end{aligned} \tag{42.48}$$

sowie

$$\begin{aligned}\hat{\alpha}_2 &= \frac{1}{n_{ij}}\left(-\sum_{i=1}^{2}\sum_{j=1}^{2}\sum_{k=1}^{n_{ij}} y_{ijk} + 2\sum_{j=1}^{2}\sum_{k=1}^{n_{2j}} y_{2jk} + 1\sum_{i=1}^{2}\sum_{k=1}^{n_{i2}} y_{i2k} - 2\sum_{k=1}^{n_{22}} y_{22k}\right)\\ &= \frac{1}{n_{ij}}\left(-\sum_{k=1}^{n_{11}} y_{11k} - \sum_{k=1}^{n_{12}} y_{12k} - \sum_{k=1}^{n_{21}} y_{21k} - \sum_{k=1}^{n_{22}} y_{22k}\right)\\ &+ \frac{1}{n_{ij}}\left(2\sum_{k=1}^{n_{21}} y_{21k} + 2\sum_{k=1}^{n_{22}} y_{22k} + \sum_{k=1}^{n_{12}} y_{12k} + \sum_{k=1}^{n_{22}} y_{22k} - 2\sum_{k=1}^{n_{22}} y_{22k}\right)\\ &= \frac{1}{n_{ij}}\left(\sum_{k=1}^{n_{21}} y_{21k} - \sum_{k=1}^{n_{11}} y_{11k}\right)\\ &= \bar{y}_{21} - \bar{y}_{11}\end{aligned} \tag{42.49}$$

und analog für $\hat{\beta}_2$. Schließlich ergibt sich

$$\begin{aligned}\hat{\gamma}_{22} &= \frac{1}{n_{ij}}\left(\sum_{i=1}^{2}\sum_{j=1}^{2}\sum_{k=1}^{n_{ij}} y_{ijk} - 2\sum_{j=1}^{2}\sum_{k=1}^{n_{2j}} y_{2jk} - 2\sum_{i=1}^{2}\sum_{k=1}^{n_{i2}} y_{i2k} + 4\sum_{k=1}^{n_{22}} y_{22k}\right)\\ &= \frac{1}{n_{ij}}\left(\sum_{k=1}^{n_{11}} y_{11k} + \sum_{k=1}^{n_{12}} y_{12k} + \sum_{k=1}^{n_{21}} y_{21k} + \sum_{k=1}^{n_{22}} y_{22k}\right)\\ &+ \frac{1}{n_{ij}}\left(-2\sum_{k=1}^{n_{21}} y_{21k} - 2\sum_{k=1}^{n_{22}} y_{22k} - 2\sum_{k=1}^{n_{12}} y_{12k} - 2\sum_{k=1}^{n_{22}} y_{22k} + 4\sum_{k=1}^{n_{22}} y_{22k}\right)\\ &= \frac{1}{n_{ij}}\left(\sum_{k=1}^{n_{11}} y_{11k} + \sum_{k=1}^{n_{22}} y_{22k} - \sum_{k=1}^{n_{12}} y_{12k} - \sum_{k=1}^{n_{21}} y_{21k}\right)\\ &= \bar{y}_{11} + \bar{y}_{22} - \bar{y}_{12} - \bar{y}_{21}\\ &= (\bar{y}_{11} - \bar{y}_{12}) - (\bar{y}_{21} - \bar{y}_{22}).\end{aligned} \tag{42.50}$$

□

Auch hier vedeutlichen wir den in obigem Theorem formulierten Zusammenhang zwischen den Betaparameterschätzerkomponenten und den gruppenspezifischen Stichprobenmitteln anhand des Beispieldatensatzes mithilfe folgenden **R** Codes.

```
# Datenreformatierung
D          = read.csv("./_data/509-zweifaktorielle-varianzanalyse.csv")        # Datensatz
A1B1       = D$dBDI[D$Setting == "F2F" & D$Variant == "MND" ]                  # Face-to-face, mindfulness
A1B2       = D$dBDI[D$Setting == "F2F" & D$Variant == "EXC" ]                  # Face-to-face, exercise
A2B1       = D$dBDI[D$Setting == "ONL" & D$Variant == "MND" ]                  # Online      , mindfulness
A2B2       = D$dBDI[D$Setting == "ONL" & D$Variant == "EXC" ]                  # Online      , exercise

# Datenmatrix für Gruppenmittelwerte
n_ij       = length(A1B1)                                                     # Anzahl Datenpunkte pro Gruppe
Y          = matrix(c(A1B1,A1B2,A2B1,A2B2), nrow = n_ij)                      # Datenmatrix
bar_y      = colMeans(Y)                                                      # Zellenmittelwerte

# Modellschätzung
I          = 2                                                                # Anzahl Level Faktor A (Therapiesetting)
J          = 2                                                                # Anzahl Level Faktor B (Therapievariante)
n          = I*J*n_ij                                                         # Anzahl Datenpunkte
p          = 1 + (I-1)+(J-1)+(I*J-3)                                          # Anzahl Parameter
D          = matrix(c(1,0,0,0,                                                # Prototypische Designmatrix
                      1,0,1,0,
                      1,1,0,0,
                      1,1,1,1), nrow = p, byrow = TRUE)
C          = matrix(rep(1,n_ij),nrow = n_ij)                                  # Prototypischer Zellenvektor
X          = kronecker(D,C)                                                   # Kroneckerprodukt Designmatrix
y          = matrix(c(A1B1,A1B2,A2B1,A2B2), nrow = n)                         # Datenvektor
beta_hat   = solve(t(X) %*% X) %*% t(X) %*% y                                 # Betaparameterschätzer
eps_hat    = y - X %*% beta_hat                                               # Residuenvektor
sigsqr_hat = (t(eps_hat) %*% eps_hat) /(n-p)                                  # Varianzparameterschätzer
```

```
hat{beta}                                       :  10.5 -0.42 4.33 1.42
hat{sigsqr}                                     :  5.94
bar{y}_11,bar{y}_12,bar{y}_21,bar{y}_22         :  10.5 14.83 10.08 15.83
bar{y}_11                                       :  10.5
bar{y}_21 - bar{y}_11                           :  -0.42
bar{y}_12 - bar{y}_11                           :  4.33
bar{y}_11 + bar{y}_22 - bar{y}_12 + bar{y}_21   :  1.42
```

42.4. Modellevaluation

Die inferenzstatistische Evaluation von Haupteffekt- und Interaktionsparametern in ZVA-Modellen in allgemeiner Form kann aus mindestens drei Blickwinkeln betrachtet werden. Analog zur EVA können auch für die ZVA Quadratsummenzerlegungen entwickelt werden und zur Definition entsprechender F-Statistiken eingesetzt werden. Wir folgen hier dem alternativen Ansatz, F-Statistiken für Haupteffekte und Interaktionen vor dem Hintergrund von Modellvergleichen in den entsprechenden ZVA-Modellen zu formulieren. Einen integrativen Blick auf beide Ansätze bietet die Theorie der Allgemeinen Linearen Hypothese, auf deren Diskussion wir hier aber verzichten. Dementsprechend beschränken wir uns hier auf (1) die Evaluation der Haupteffekte im additiven Modell der 2×2 ZVA mit Referenzgruppe und (2) die Evaluation der Interaktion im Modell der 2×2 ZVA mit Interaktion und Referenzgruppe. Für beide Evaluationen formulieren wir (1) die zugrundeliegenden Modelle und Teststatistiken, (2) die Testhypothesen und Tests und (3) die Prozeduren zur Testumfangskontrolle und Auswertung des p-Wertes.

Evaluation von Haupteffekten im additiven Modell der 2×2 ZVA

Theorem 42.3 (Teststatistiken für Haupteffekte)**.** *Es sei*

$$y = X\beta + \varepsilon \text{ mit } \varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \tag{42.51}$$

die Designmatrixform des additiven Modells der 2×2 ZVA mit Referenzgruppe, wobei die $n \times 1$ Spalten von X bezeichnet seien durch

$$X := \begin{pmatrix} X_{\mu_0} & X_{\alpha_2} & X_{\beta_2} \end{pmatrix} \in \mathbb{R}^{n \times 3}. \tag{42.52}$$

Dann gelten

(A) Eine F-Teststatistik für den Haupteffekt von Faktor A ist die F-Statistik des ALMs mit

$$X_A := \begin{pmatrix} X_{\mu_0} & X_{\beta_2} & X_{\alpha_2} \end{pmatrix} \in \mathbb{R}^{n\times 3}, \beta_A := \begin{pmatrix} \mu_0 \\ \beta_2 \\ \alpha_2 \end{pmatrix} \in \mathbb{R}^3 \text{ und } p_0 := 2, p_1 := 1 \quad (42.53)$$

(B) Eine F-Teststatistik für den Haupteffekt von Faktor B ist die F-Statistik des ALMs mit

$$X_B := \begin{pmatrix} X_{\mu_0} & X_{\alpha_2} & X_{\beta_2} \end{pmatrix} \in \mathbb{R}^{n\times 3}, \beta_B := \begin{pmatrix} \mu_0 \\ \alpha_2 \\ \beta_2 \end{pmatrix} \in \mathbb{R}^3 \text{ und } p_0 := 2, p_1 := 1 \quad (42.54)$$

∘

Definition 42.5 (Testhypothesen und Tests für Haupteffekte)**.** Gegeben sei das Modell der additiven 2×2 ZVA und die F-Teststatistiken für die Haupteffekte von Faktor A und B seien mit F_A und F_B bezeichnet und wie oben definiert. Dann gelten folgende Definitionen:

(A) Der kritische Wert-basierte Test

$$\phi_A(y) := 1_{\{F_A \geq k\}} \text{ mit Nullhypothese } H_0^A : \alpha_2 = 0 \quad (42.55)$$

definiert den F-Test des Haupteffekts von Faktor A im Modell mit X_A, β_A.

(B) Der kritische Wert-basierte Test

$$\phi_B(y) := 1_{\{F_B \geq k\}} \text{ mit Nullhypothese } H_0^B : \beta_2 = 0 \quad (42.56)$$

definiert den F-Test des Haupteffekts von Faktor B im Modell mit X_B, β_B.

•

Theorem 42.4 (Testumfangskontrolle und p-Werte für Haupteffekte)**.** *Mit obigen Definitionen und der KVF φ der f-Verteilung gelten:*

(A) ϕ_A ist ein Level- α_0-Test mit Testumfang α_0, wenn der kritische Wert definiert ist durch

$$k_{\alpha_0}^A := \varphi^{-1}(1-\alpha_0; 1, n-3). \quad (42.57)$$

Der zu einem beobachteten Wert f_A von F_A assoziierte p-Wert ist gegeben durch

$$p_A - \text{ Wert } := 1 - \varphi(f_A; 1, n-3). \quad (42.58)$$

(B) ϕ_B ist ein Level- α_0-Test mit Testumfang α_0, wenn der kritische Wert definiert ist durch

$$k_{\alpha_0}^B := \varphi^{-1}(1-\alpha_0; 1, n-3). \quad (42.59)$$

Der zu einem beobachteten Wert f_B von F_B assoziierte p-Wert ist gegeben durch

$$p_B - \text{ Wert } := 1 - \varphi(f_B; 1, n-3). \quad (42.60)$$

∘

Anwendungsbeispiel

Die Anwendung des oben formulierten Evaluationsverfahrens für die Haupteffekte im Modell der additiven 2×2 ZVA mit Referenzgruppe anhand des Beispieldatensatzes demonstriert folgender **R** Code.

```
D          = read.csv("./_data/509-zweifaktorielle-varianzanalyse.csv")        # Datensatz
A1B1       = D$dBDI[D$Setting == "F2F" & D$Variant == "MND" ]                  # Face-to-face, mindfulness
A1B2       = D$dBDI[D$Setting == "F2F" & D$Variant == "EXC" ]                  # Face-to-face, exercise
A2B1       = D$dBDI[D$Setting == "ONL" & D$Variant == "MND" ]                  # Online      , mindfulness
A2B2       = D$dBDI[D$Setting == "ONL" & D$Variant == "EXC" ]                  # Online      , exercise
I          = 2                                                                 # Anzahl Level Faktor Setting
J          = 2                                                                 # Anzahl Level Faktor Variante
n_ij       = length(A1B1)                                                      # balanciertes ANOVA Design
n          = I*J*n_ij                                                          # Anzahl Datenpunkte
p          = 3                                                                 # Anzahl Parameter vollständiges Modell
y          = matrix(c(A1B1,A1B2,A2B1,A2B2), nrow = n)                          # Datenvektor
D          = matrix(c(1,0,0,1,0,1,1,1,0,1,1,1),                                # Prototypische Designmatrix
                    nrow = I*J,byrow=TRUE)
C          = matrix(rep(1,n_ij),nrow = n_ij)                                   # Prototypischer Zellenvektor
X          = kronecker(D,C)                                                    # ZVA Kroneckerprodukt Designmatrix
XH         = list(X[,c(1,3,2)], X)                                             # Modellvarianten
alpha_0    = 0.05                                                              # Signifikanzlevel
Eff        = rep(NaN,2)                                                        # F-Teststatistik Arrayinitialisierung
k_alpha_0  = rep(NaN,2)                                                        # Kritischer Wert Arrayinitialisierung
phi        = rep(NaN,2)                                                        # Testwert Arrayinitialisierung
p_vals     = rep(NaN,2)                                                        # p-Wert Arrayinitialisierung
for(i in 1:2){                                                                 # Iteration über Modellvarianten
    X            = XH[[i]]                                                     # Designmatrix vollständiges Modell
    X_0          = X[,-3]                                                      # Designmatrix reduziertes Modell
    p            = ncol(X)                                                     # Anzahl Parameter vollständiges Modell
    p_0          = ncol(X_0)                                                   # Anzahl Parameter reduziertes Modell
    p_1          = p - p_0                                                     # Anzahl zusätzlicher Parameter im vollst. Modell
    beta_hat_0   = solve(t(X_0)%*%X_0)%*%t(X_0)%*%y                            # Betaparameterschätzer reduziertes Modell
    beta_hat     = solve(t(X) %*%X )%*%t(X) %*%y                               # Betaparameterschätzer vollständiges Modell
    eps_hat_0    = y-X_0%*%beta_hat_0                                          # Residuenvektor reduziertes Modell
    eps_hat      = y - X%*%beta_hat                                            # Residuenvektor vollständiges Modell
    eh0_eh0      = t(eps_hat_0) %*% eps_hat_0                                  # RQS reduziertes Modell
    eh_eh        = t(eps_hat) %*% eps_hat                                      # RQS vollständiges Modell
    sigsqr_hat   = eh_eh/(n-p)                                                 # Varianzparameterschätzer vollst. Modell
    Eff[i]       = ((eh0_eh0-eh_eh)/p_1)/sigsqr_hat                            # F-Statistik
    k_alpha_0[i] = qf(1-alpha_0, p_1, n-p)                                     # kritischer Wert
    if(Eff[i] >= k_alpha_0[i]){ phi[i] = 1 }                                   # H_0 Ablehnen
    else {                      phi[i] = 0 }                                   # H_A Annehmen
    p_vals[i]    = 1 - pf(Eff[i], p_1,n-p)                                     # p-Wert
}
```

```
            f     k phi p.Wert
Setting  0.172 4.057   0   0.68
Variant 51.356 4.057   1   0.00
```

Für den Haupteffekt des Faktors Settings ergibt sich dabei ein Wert der F-Statistik von $F_A = 0.17$ bei einem kritischen Wert von $k_{0.05} = 4.06$. Die Nullhypothese eines wahren, aber unbekannten, Effektparameterwertes von Null für den Faktor Setting würde im Lichte der in Abbildung 42.3 visualisierten Daten also nicht verworfen werden. Für den Haupteffekt des Faktors Variant dagegen ergibt ein Wert der F-Statistik von $F_B = 51.36$ bei dem gleichen kritischen Wert von $k_{0.05} = 4.06$. Die Nullhypothese eines wahren, aber unbekannten, Effektparameterwertes von Null für den Faktor Variant würde im Lichte der in Abbildung 42.3 visualisierten Daten mit einem Signifikanzlevel von $\alpha_0 := 0.05$ also verworfen werden.

Folgender **R** Code demonstriert die gleiche Analyse mithilfe der **R** Funktion `aov()`.

```
D          = read.csv("./_data/509-zweifaktorielle-varianzanalyse.csv")        # Datensatz
res.aov    = aov(dBDI ~ Setting + Variant, data = D)                           # Modellformulierung und Modellschätzung
summary(res.aov)                                                               # Modellevaluation
```

```
            Df Sum Sq Mean Sq F value   Pr(>F)
Setting      1   1.02    1.02   0.172     0.68
Variant      1 305.02  305.02  51.356 5.78e-09 ***
Residuals   45 267.27    5.94
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

normalsize

Folgender **R** Code schließlich demonstriert die gleiche Analyse mithilfe der **R** Funktionen `lm()` und `anova()`.

```
D          = read.csv("./_data/509-zweifaktorielle-varianzanalyse.csv")         # Datensatz
glm        = lm(dBDI ~ Setting + Variant, data = D)                             # Modellformulierung und Modellschätzung
anova(glm)                                                                      # Modellevaluation
```

```
Analysis of Variance Table

Response: dBDI
          Df  Sum Sq Mean Sq F value    Pr(>F)
Setting    1   1.021   1.021  0.1719    0.6804
Variant    1 305.021 305.021 51.3559 5.779e-09 ***
Residuals 45 267.271   5.939
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Evaluation der Interaktion im Modell der 2×2 ZVA mit Interaktion

Theorem 42.5 (Teststatistik für die Interaktion)**.** *Es sei*

$$y = X\beta + \varepsilon \text{ mit } \varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \tag{42.61}$$

die Designmatrixform des 2×2 ZVA Modells mit Interaktion und Referenzgruppe. Dann ist die F-Statistik mit $p_0 := 3$ und $p_1 := 1$ eine F-Teststatistik für die Interaktion von Faktor A und Faktor B.

∘

Definition 42.6 (Testhypothese und Test für die Interaktion)**.** Die F-Teststatistik für die Interaktion von Faktor A und Faktor B sei mit $F_{A\times B}$ bezeichnet und wie oben definiert. Dann definiert der kritische Wert-basierte Test

$$\phi_{A\times B}(y) := 1_{\{F_{A\times B} \geq k\}} \text{ mit Nullhypothese } H_0^{A\times B} : \gamma_{22} = 0 \tag{42.62}$$

den F-Test der Interaktion von Faktor A und Faktor B.

•

Theorem 42.6 (Testumfangskontrolle und p-Wert für die Interaktion)**.** *Mit obigen Definition und der KVF φ der f-Verteilung gilt, dass $\phi_{A\times B}$ ein Level- α_0-Test mit Testumfang α_0 ist, wenn der kritische Wert definiert ist durch*

$$k_{\alpha_0}^{A\times B} := \varphi^{-1}\left(1 - \alpha_0; 1, n-4\right). \tag{42.63}$$

Der zu einem beobachteten Wert $f_{A\times B}$ von $F_{A\times B}$ assoziierte p-Wert ist gegeben durch

$$p_{A\times B} - \ \textit{Wert} \ := 1 - \varphi\left(f_{A\times B}; 1, n-4\right). \tag{42.64}$$

∘

Anwendungsbeispiel

Die Anwendung des oben formulierten Evaluationsverfahrens für die Interaktion der Faktoren im Modell der 2×2 ZVA mit Interaktion und Referenzgruppe anhand des Beispieldatensatzes demonstriert folgender **R** Code.

```
D          = read.csv("./_data/509-zweifaktorielle-varianzanalyse.csv")        # Datensatz
A1B1       = D$dBDI[D$Setting == "F2F" & D$Variant == "MND" ]                  # Face-to-face, mindfulness
A1B2       = D$dBDI[D$Setting == "F2F" & D$Variant == "EXC" ]                  # Face-to-face, exercise
A2B1       = D$dBDI[D$Setting == "ONL" & D$Variant == "MND" ]                  # Online      , mindfulness
A2B2       = D$dBDI[D$Setting == "ONL" & D$Variant == "EXC" ]                  # Online      , exercise
I          = 2                                                                 # Anzahl Level Faktor Setting
J          = 2                                                                 # Anzahl Level Faktor Variante
n_ij       = length(A1B1)                                                      # balanciertes ANOVA Design
n          = I*J*n_ij                                                          # Anzahl Datenpunkte
p          = 4                                                                 # Anzahl Parameter vollständiges Modell
y          = matrix(c(A1B1,A1B2,A2B1,A2B2), nrow = n)                          # Datenvektor
D          = matrix(c(1,0,0,0,1,0,1,0, 1,1,0,0,1,1,1,1),nrow = I*J,byrow=TRUE) # Prototypische Designmatrix
C          = matrix(rep(1,n_ij),nrow = n_ij)                                   # Prototypischer Zellenvektor
X          = kronecker(D,C)                                                    # ZVA Kroneckerprodukt Designmatrix
XH         = list(X[,c(1,3,2)], X)                                             # Modellvarianten
alpha_0    = 0.05                                                              # Signifikanzlevel
X          = XH[[i]]                                                           # Designmatrix vollständiges Modell
X_0        = X[,-4]                                                            # Designmatrix reduziertes Modell
p          = ncol(X)                                                           # Anzahl Parameter vollständiges Modell
p_0        = ncol(X_0)                                                         # Anzahl Parameter reduziertes Modell
p_1        = p - p_0                                                           # Anzahl zusätzlicher Parameter im vollst. Modell
beta_hat_0 = solve(t(X_0)%*%X_0)%*%t(X_0)%*%y                                  # Betaparameterschätzer reduziertes Modell
beta_hat   = solve(t(X) %*%X )%*%t(X) %*%y                                     # Betaparameterschätzer vollständiges Modell
eps_hat_0  = y-X_0%*%beta_hat_0                                                # Residuenvektor reduziertes Modell
eps_hat    = y - X%*%beta_hat                                                  # Residuenvektor vollständiges Modell
eh0_eh0    = t(eps_hat_0) %*% eps_hat_0                                        # RQS reduziertes Modell
eh_eh      = t(eps_hat) %*% eps_hat                                            # RQS vollständiges Modell
sigsqr_hat = eh_eh/(n-p)                                                       # Varianzparameterschätzer vollst. Modell
f          = ((eh0_eh0-eh_eh)/p_1)/sigsqr_hat                                  # F-Statistik
k_alpha_0  = qf(1-alpha_0, p_1, n-p)                                           # kritischer Wert
if(f >= k_alpha_0){phi = 1} else {phi = 0}                                     # Test
p_val      = 1 - pf(f, p_1,n-p)                                                # p-Wert
```

```
                     f     k phi p.Wert
Setting x Variant 1.014 4.062   0  0.319
```

Es ergibt sich dabei eine Wert der F-Statistik von $F_{A\times B} = 1.01$ bei einem kritischen Wert von $k_{0.05} = 4.06$. Die Nullhypothese eines wahren, aber unbekannten, Effektparameterwertes von Null für den Interaktionseffekt würde im Lichte der in Abbildung 42.3 visualisierten Daten also nicht verworfen werden.

Folgender **R** Code demonstriert die gleiche Analyse mithilfe der **R** Funktion `aov()`.

```
D          = read.csv("./_data/509-zweifaktorielle-varianzanalyse.csv")        # Datensatz
res.aov    = aov(dBDI ~ Setting + Variant + Setting:Variant, data = D)         #  Modellformulierung und Modellschätzung
summary(res.aov)                                                               # Modellevaluation
```

```
              Df Sum Sq Mean Sq F value  Pr(>F)
Setting        1   1.02    1.02   0.172   0.680
Variant        1 305.02  305.02  51.372 6.5e-09 ***
Setting:Variant  1   6.02    6.02   1.014   0.319
Residuals     44 261.25    5.94
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Folgender **R** Code schließlich demonstriert die gleiche Analyse mithilfe der **R** Funktionen `lm` und `anova()`.

```
D          = read.csv("./_data/509-zweifaktorielle-varianzanalyse.csv")        # Datensatz
glm        = lm(dBDI ~ Setting + Variant + Setting:Variant, data = D)          # Modellformulierung und Modellschätzung
anova(glm)                                                                     # Modellevaluation
```

```
Analysis of Variance Table

Response: dBDI
              Df  Sum Sq Mean Sq F value    Pr(>F)
Setting        1   1.021   1.021  0.1719    0.6804
Variant        1 305.021 305.021 51.3719 6.502e-09 ***
Setting:Variant  1   6.021   6.021  1.0140    0.3194
Residuals     44 261.250   5.938
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

42.5. Literaturhinweise

Die Popularität varianzanalytischer Verfahren wird im Allgemeinen auf Fisher (1925b) und Fisher (1935) zurückgeführt. Everitt & Howell (2005) und Stigler (1986) geben einen kurzen und einen ausführlichen historischen Überblick, respektive.

43. Partielle Korrelation

43.1. Motivation

Zur Motivation des Begriffs der partiellen Korrelation betrachten wir zunächst den in Abbildung 43.1 visualisierten Beispieldatensatz zum Zusammenhang von Eiskonsum und Sonnenbrandinzidenz. Wir stellen uns vor, dass jeder der in Abbildung 43.1 abgebildeten Datenpunkte ein Wertepaar aus einem durchschnittlichen und normalisierten Eiskonsum und einer durchschnittlichen und normalisierten Sonnenbrandinzidenz eines Landes über einen gewissen Erhebungszeitraum ist. Visuell betrachtet sieht man eine Tendenz dafür, dass hohe Werte des Eiskonsums mit eher hohen Werten der Sonnenbrandinzidenz auftreten, während niedrige Werte des Eiskonsums mit eher niedrigen Werten der Sonnenbrandinziden zusammen auftreten. Die Bestimmung des Stichprobenkorrelationskoeffizienten zu diesem Datensatz ergibt mit $r = 0.46$ eine mittelstarke positive Korrelation.

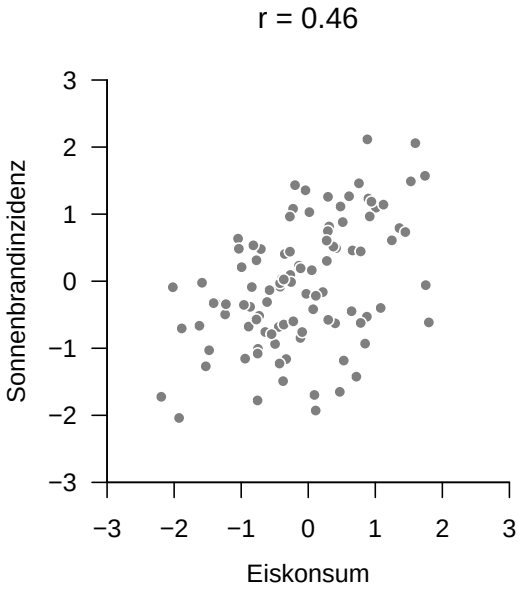


Abbildung 43.1. Beispielszenario zur Evaluation bedingter und partieller Korrelationen.

Intuitiv ist es jedoch eher unplausibel, dass Eiskonsum ursächlich Sonnenbrand hervorruft bzw. das Sonnenbrand den Eiskonsum erhöht (allerdings sind diese Szenarien auch nicht gänzlich auszuschließen: ein bestimmter Eiskonsum könnte eine allergische Reaktion hervorrufen mit Symptomen, die dem Sonnenbrand sehr ähnlich sind, andersherum wäre es denkbar, dass bei Sonnenbrand zur Abkühlung gerne Eis konsumiert wird. Wir wollen diese eher unplausiblen Erklärungsansätze hier jedoch nicht weiter verfolgen). Der in Abbildung 43.1 dargestellte Datensatz ist also ein Beispiel dafür, dass Korrelation als Maß für

den linearen Zusammenhang zweier Zufallsvariablen lediglich ein Maß für die Koinzidenz bestimmter Datenwerte ist, jedoch keine Kausalerklärung der Werte einer abhängigen Variable aus den Werten einer unabhängigen Variable impliziert. In Kurzform hat sich zur Beschreibung dieser Tatsache seit Beginn der modernen Inferenzstatistik am Anfang des 20. Jahrhunderts der Leitsatz "Correlation is not causation" eingebürgert.

Basierend auf dem negativen Ergebnis, dass eine mittelstarke Korrelation wie im Beispiel von Eiskonsum und Sonnenbrandinzidenz nur sehr unplausibel durch eine direkte kausale Beziehung der beiden Variablen zu erklären ist, stellt sich die Frage, inwieweit andere datenanalytische Verfahren hier Abhilfe schaffen können. Dabei stellt sich natürlich zunächst das philosophische Problem, was Kausalität eigentlich bedeuten soll und als nächstes die Frage, wie ein solcher Begriff mit den Mitteln der Wahrscheinlichkeitstheorie und Inferenzstatistik evaluiert werden könnte. Diesen Ansatz verfolgt das Gebiet der Kausalen Inferenz, wie zum Beispiel durch die Arbeiten von Pearl (2000) und Imbens & Rubin (2015) repräsentiert. Wir wollen an dieser Stelle diesen Ansatz nicht vertiefen, sondern stattdessen fragen, wie im obigen Beispiel anhand weiterer Daten die beobachtete Korrelation von Eiskonsum und Sonnenbrandinzidenz so aufgeklärt werden kann, dass die statistische Beschreibung des in Abbildung 43.1 dargestellten Datensatzes plausibler erscheint. Dies ist das zentrale Thema der partiellen Korrelation.

Dazu nehmen wir an, dass der Zusammenhang von Eiskonsum und Sonnenbrandinzidenz (Abbildung 43.2 A) plausibel durch die Kovariation beider Variablen mit einer dritten Variable, nämlich der Anzahl der im Erhebungszeitraum und Land auftretenden Anzahl an Sommertagen, d.h. Tagen mit einer maximalen Temperatur von über 25° Celsius, erklärt werden kann (Abbildung 43.2 B).

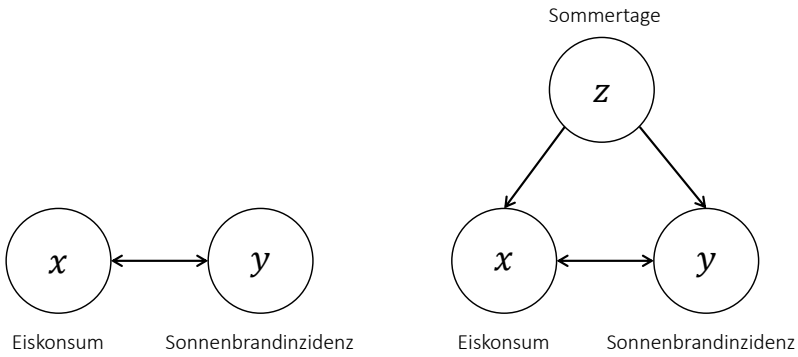


Abbildung 43.2. Zufallsvariablen im Beispielszenario.

Intuitiv erklärt sich die positive Korrelation von Eiskonsum und Sonnenbrandinziden dann wie folgt. Treten im Erhebungszeitraum in einem Land mehr Sommertage auf, so steigt in diesem Land sowohl der Eiskonsum als auch die Sonnenbrandinzidenz, treten dagegen weniger Sommertage auf, so fallen in diesem Land sowohl der Eiskonsum als auch die Sonnenbrandinzidenz. Lässt man die Anzahl der Sommertage außer Acht, so treten also hohe Werte von Eiskonsum und Sonnenbrandinzidenz als auch niedrige Werte von Eiskonsum und Sonnenbrandinzidenz häufig zusammen auf und es ergibt sich die in Abbildung 43.1 implizierte positive Korrelation.

Die entscheidende Frage in diesem Kontext ist also, ob bei gleicher Anzahl von Sommertagen Evidenz für eine Korrelation von Eiskonsum und Sonnenbrandinzidenz besteht oder

nicht. In diesem Fall würde die Kovarianz von Eiskonsum und Sonnenbrandinzidenz also bedingt auf einer konstanten Anzahl von Sommertagen betrachtet werden. Die datenanalytischen Werkzeuge, bei Vorliegen von Realisationen von drei Zufallsvariablen eben diese Form einer bedingten Korrelation zu evaluieren, stellen der Begriff der bedingten Korrelation und der eng verwandte Begriff der partiellen Korrelation bereit. Intuitiv handelt es sich dabei um die Korrelation zweier Zufallsvariablen (z.B. Eiskonsum und Sonnenbrandinzidenz) nachdem aus beiden Zufallsvariablen der Einfluß einer dritten Zufallsvariable (z.B. Anzahl an Sommertagen) "herausgerechnet" wurde. Die Begriffe der bedingten und partiellen Korrelation sind dabei nicht auf das Szenario von drei Zufallsvariablen beschränkt, sondern können für beliebig viele Zufallsvariablen generalisiert werden. Wir beschränken uns in diesem Abschnitt allerdings auf das Szenario dreier Zufallsvariablen um die Grundlagen der Theorie zu verdeutlichen.

Wir gehen dabei wie folgt vor. In Kapitel 12.2 führen wir mit der bedingten Kovarianz und der bedingten Korrelation zunächst allgemeine Maße für den auf den Werten einer dritten Zufallsvariable bedingten linear-affinen Zusammenhang zweier Zufallsvariablen ein, verdeutlichen dann die Begriffe anhand des Szenarios dreier gemeinsam multivariat normalverteilter Zufallsvariablen und diskutieren schließlich den Zusammenhang zwischen bedingter Korrelation und paarweisen (unbedingten) Korrelation. In Kapitel 12.3 führen wir mit der partiellen Korrelation dann ein regressionsbasiertes Maß für den bedingten Zusammenhang zweier Zufallsvariablen ein. Dabei ergibt sich insbesondere, dass im Falle von gemeinsam multivariat normalverteilten Zufallsvariablen bedingte und partielle Korrelation identisch sind. Wir schließen diesen Abschnitt mit der Evaluation der partiellen Korrelation von Eiskonsum und Sonnenbrandinzidenz im Lichte des Wissens um die Anzahl an Sommertagen für den in Abbildung 43.1 visualisierten Beispieldatensatz.

43.2. Bedingte Korrelation

Wir definieren zunächst die bedingte Kovarianz und die bedingte Korrelation zweier Zufallsvariablen gegeben eine dritte Zufallsvariable.

Definition 43.1 (Bedingte Kovarianz und bedingte Korrelation)**.** Gegeben seien drei Zufallsvariablen x, y, z einer gemeinsamen Verteilung $\mathbb{P}_{x,y,z}(x, y, z)$. Weiterhin sei $\mathbb{P}_{x,y|z}(x, y)$ die bedingte Verteilung von x und y gegeben z. Dann heißt die Kovarianz von x und y in der Verteilung $\mathbb{P}_{x,y|z}(x, y)$ die bedingte Kovarianz von x und y gegeben z und wird mit $\mathbb{C}(x, y|z)$ bezeichnet. Weiterhin seien $\mathbb{P}_{x,y|z}(x)$ und $\mathbb{P}_{x,y|z}(y)$ die marginalen Verteilungen von x und y gegeben z, respektive, und $\mathbb{S}(x|z), \mathbb{S}(y|z)$ die Standardabweichungen von x und y hinsichtlich $\mathbb{P}_{x,y|z}(y)$ und $\mathbb{P}_{x,y|z}(x)$, respektive. Dann heißt die Korrelation von x und y in der Verteilung $\mathbb{P}_{x,y|z}(x, y)$,

$$\rho(x, y|z) := \frac{\mathbb{C}(x, y|z)}{\mathbb{S}(x|z)\mathbb{S}(y|z)} \tag{43.1}$$

die *bedingte Korrelation* von x und y gegeben z

•

Die bedingte Kovarianz zweier Zufallsvariablen ist also definiert als die Kovarianz zweier Zufallsvariablen in einer auf einer dritten Zufallsvariable bedingten Verteilung. Gleiches

gilt für die bedingte Korrelation zweier Zufallsvariablen. Durch Vertauschen in obiger Definition kann man analog $\rho(y, z|x)$ und $\rho(x, z|y)$ definieren. Wir verdeutlichen Definition 43.1 als nächstes an einem Beispiel.

Beispiel 43.1 (Partielle Korrelation bei einer multivariaten Normalverteilung)**.** Die Zufallsvariablen x, y, z seien multivariat normalverteilt, d.h. für $\gamma := (x, y, z)^T$ gelte, dass

$$\gamma \sim N(\mu, \Sigma) \tag{43.2}$$

mit

$$\mu := \begin{pmatrix} \mu_y \\ \mu_x \\ \mu_z \end{pmatrix} \text{ und } \Sigma := \begin{pmatrix} \sigma_x^2 & \sigma_{x,y}^2 & \sigma_{x,z}^2 \\ \sigma_{y,x}^2 & \sigma_y^2 & \sigma_{y,z}^2 \\ \sigma_{z,x}^2 & \sigma_{z,y}^2 & \sigma_z^2 \end{pmatrix} \tag{43.3}$$

Wir nehmen an, dass wir die bedingte Korrelation von x und y gegeben z bestimmen wollen und wenden uns entprechend der bedingten Verteilung von x und y gegeben z zu. Nach Theorem 29.6 wissen wir, dass diese bedingte Verteilung ebenfalls eine Normalverteilung ist, deren Kovarianzmatrixparameter wir aus dem Kovarianzmatrixparameter der gemeinsamen Verteilung von x, y, z bestimmen können. Wir definieren zu diesem Zweck zunächst

$$\Sigma_{x,y} := \begin{pmatrix} \sigma_x^2 & \sigma_{x,y}^2 \\ \sigma_{y,x}^2 & \sigma_y^2 \end{pmatrix}, \Sigma_z := (\sigma_z^2) \text{ und } \Sigma_{(x,y),z} := \Sigma_{z,(x,y)}^T := \begin{pmatrix} \sigma_{x,z}^2 \\ \sigma_{y,z}^2 \end{pmatrix} \tag{43.4}$$

so dass für den Kovarianzmatrixparameter der gemeinsamen Verteilung von x, y, z gilt, dass

$$\Sigma = \begin{pmatrix} \Sigma_{x,y} & \Sigma_{(x,y),z} \\ \Sigma_{z,(x,y)} & \Sigma_z \end{pmatrix} \tag{43.5}$$

Mit Theorem 4.8 ergibt sich der Kovarianzmatrixparameter des Zufallsvektors $(x, y)^T$ dann zu

$$\Sigma_{x,y|z} = \Sigma_{x,y} - \Sigma_{(x,y),z}\Sigma_z^{-1}\Sigma_{z,(x,y)} \tag{43.6}$$

Mit den Eigenschaften von multivariaten Normalverteilungen gilt dann, dass die Diagonaleinträge von $\Sigma_{x,y|z}$ den bedingten Varianzen von x und y gegeben z entsprechen und dass der Nichtdiagonaleintrag von $\Sigma_{x,y|z}$ die bedingte Kovarianz von x und y gegeben z ist. In anderen Worten gilt

$$\Sigma_{x,y|z} = \begin{pmatrix} \mathbb{C}(x, x|z) & \mathbb{C}(x, y|z) \\ \mathbb{C}(y, x|z) & \mathbb{C}(y, y|z) \end{pmatrix} \tag{43.7}$$

Die bedingte Korrelation $\rho(x, y|z)$ von x und y gegeben z ergibt sich dann aus den Einträgen von $\Sigma_{x,y|z}$ gemäß

$$\rho(x, y|z) = \frac{\mathbb{C}(x, y|z)}{\sqrt{\mathbb{C}(x, x|z)}\sqrt{\mathbb{C}(y, y|z)}} \tag{43.8}$$

Sei konkret etwa der Kovarianzmatrixparameter von $(x, y, z)^T$ gegeben als

$$\Sigma := \begin{pmatrix} 1.0 & 0.5 & 0.9 \\ 0.5 & 1.0 & 0.5 \\ 0.9 & 0.5 & 1.0 \end{pmatrix} \tag{43.9}$$

Dann ergibt sich

$$\rho(x, y) = 0.50 \text{ und } \rho(x, y|z) \approx 0.13 \tag{43.10}$$

Folgender **R** Code demonstriert die Auswertung dieser bedingten Korrelation.

```
# Bedingte Korrelation bei Normalverteilung
S         = matrix(c( 1,.5,.9,                                    # \Sigma
                     .5, 1,.5,
                     .9,.5, 1), nrow  = 3, byrow = TRUE)
rho_xy    = S[1,2]/(sqrt(S[1,1])*sqrt(S[2,2]))                    # \rho(x,y)
S_xy_z    = S[1:2,1:2] -  S[1:2,3] %*% solve(S[3,3]) %*%S[3,1:2]  # \Sigma_{x,y|z}
rho_xy_z  = S_xy_z[1,2]/(sqrt(S_xy_z[1,1])*sqrt(S_xy_z[2,2]))     # \rho(x,y|z)
```

```
rho(x,y)   : 0.5
rho(x,y|z) : 0.13
```

△

43.3. Bedingte Korrelation bei Normalverteilung

Für den Fall dreier gemeinsam normalverteilter Zufallsvariablen eröffnet folgendes Theorem eine Möglichkeit, die bedingte Korrelation zweier dieser Zufallsvariablen gegeben die dritte auf Grundlage der (unbedingten) paarweisen Korrelationen der Zufallsvariablen zu bestimmen. So kann bei gemeinsamer Normalverteilung von x, y, z zum Beispiel $\rho(x, y|z)$ aus den Korrelationen $\rho(x, y), \rho(x, z)$, und $\rho(y, z)$ bestimmt werden. Speziell gilt folgendes Theorem.

Theorem 43.1 (Bedingte Korrelation und Korrelationen bei Normalverteilung)**.** *x, y, z seien drei gemeinsam multivariat normalverteilte Zufallsvariablen. Dann gilt*

$$\rho(x, y|z) = \frac{\rho(x, y) - \rho(x, z)\rho(y, z)}{\sqrt{(1 - \rho(x, z)^2)}\sqrt{(1 - \rho(y, z)^2)}} \tag{43.11}$$

∘

Beweis. Ohne Beschränkung der Allgemeinheit betrachten wir den Fall eines standardisierten multivariat normalverteilten Zufallsvektors $\gamma := (x, y, z)^T$ mit Kovarianzmatrixparameter

$$\Sigma := \begin{pmatrix} 1 & \rho(x, y) & \rho(x, z) \\ \rho(y, x) & 1 & \rho(y, z) \\ \rho(z, x) & \rho(z, y) & 1 \end{pmatrix} \tag{43.12}$$

Wir definieren nun zunächst

$$\Sigma_{x,y} := \begin{pmatrix} 1 & \rho(x, y) \\ \rho(y, x) & 1 \end{pmatrix}, \Sigma_z := (1) \text{ und } \Sigma_{(x,y),z} := \Sigma^T_{z,(x,y)} := \begin{pmatrix} \rho(x, z) \\ \rho(y, z) \end{pmatrix}, \tag{43.13}$$

so dass

$$\Sigma = \begin{pmatrix} \Sigma_{x,y} & \Sigma_{(x,y),z} \\ \Sigma_{z,(x,y)} & \Sigma_z \end{pmatrix}. \tag{43.14}$$

Mit dem Theorem 29.6 ist dann die Kovarianzmatrix des Zufallsvektors (x, y) gegeben durch

$$\Sigma_{x,y|z} = \Sigma_{x,y} - \Sigma_{(x,y),z}\Sigma_z^{-1}\Sigma_{z,(x,y)} \tag{43.15}$$

Es ergibt sich also

$$\begin{aligned} \begin{pmatrix} \sigma^2_{x,x|z} & \sigma^2_{x,y|z} \\ \sigma^2_{y,x|z} & \sigma^2_{y,y|z} \end{pmatrix} &= \begin{pmatrix} 1 & \rho(x, y) \\ \rho(y, x) & 1 \end{pmatrix} - \begin{pmatrix} \rho(x, z) \\ \rho(y, z) \end{pmatrix} (1)^{-1} \begin{pmatrix} \rho(x, z) & \rho(y, z) \end{pmatrix} \\ &= \begin{pmatrix} 1 & \rho(x, y) \\ \rho(y, x) & 1 \end{pmatrix} - \begin{pmatrix} \rho(x, z)\rho(x, z) & \rho(x, z)\rho(y, z) \\ \rho(y, z)\rho(x, z) & \rho(y, z)\rho(y, z) \end{pmatrix} \\ &= \begin{pmatrix} 1 - \rho(x, z)^2 & \rho(x, y) - \rho(x, z)\rho(y, z) \\ \rho(y, x) - \rho(y, z)\rho(x, z) & 1 - \rho(y, z)^2 \end{pmatrix}. \end{aligned} \tag{43.16}$$

Es ergibt sich also

$$\rho(x, y|z) = \frac{\sigma^2_{x,y|z}}{\sqrt{\sigma^2_{x,x|z}}\sqrt{\sigma^2_{y,y|z}}} = \frac{\rho(x, y) - \rho(x, z)\rho(y, z)}{\sqrt{1 - \rho(x, z)^2}\sqrt{1 - \rho(y, z)^2}} \tag{43.17}$$

Im Falle des Vorliegens von Realisierungen von x, y, z ergibt sich ein entsprechender Schätzer für $\rho(x, y|z)$ mit den Stichprobenkorrelationen $r_{x,y}, r_{x,z}, r_{y,z}$ dann zu

$$r_{x,y|z} = \frac{r_{x,y} - r_{x,z}r_{y,z}}{\sqrt{(1 - r^2_{x,z})}\sqrt{(1 - r^2_{y,z})}} \tag{43.18}$$

□

43.4. Partielle Korrelation

Wir definieren als nächstes die partielle Korrelation zweier Zufallsvariablen gegeben eine dritte Zufallsvariable.

Definition 43.2 (Partielle Korrelation.)**.** x, y, z seien Zufallsvariablen mit linear-affinen Abhängigkeiten zwischen x und z sowie zwischen y und z,

$$\begin{aligned} x &:= \beta_0^{x,z} + \beta_1^{x,z} z \\ y &:= \beta_0^{y,z} + \beta_1^{y,z} z \end{aligned} \tag{43.19}$$

mit Residualvariablen

$$\begin{aligned} \varepsilon^{x,z} &:= x - \beta_0^{x,z} - \beta_1^{x,z} z \\ \varepsilon^{y,z} &:= y - \beta_0^{y,z} - \beta_1^{y,z} z \end{aligned} \tag{43.20}$$

Dann ist die partielle Korrelation von x und y mit auspartialisiertem z definiert als

$$\rho(x, y \backslash z) := \rho\left(\varepsilon^{x,z}, \varepsilon^{y,z}\right). \tag{43.21}$$

•

Intuitiv entsprechen in obiger Definition die Zufallsvariable $\varepsilon^{x,z}$ der Zufallsvariable x, aus der der Einfluss von z "herausgerechnet" wurde, und die Zufallsvariable $\varepsilon^{y,z}$ der Zufallsvariable y, aus der der Einfluss von z "herausgerechnet" wurde. Damit entspricht $\rho(x, y \backslash z)$ dann intuitiv der Korrelation von x und y, aus denen jeweils der Einfluss von z "herausgerechnet" wurde. Wir geben als nächstes einen Schätzer für die partielle Korrelation zweier Zufallsvariablen gegeben eine dritte Zufallsvariable an.

Definition 43.3 (Partielle Stichprobenkorrelation)**.** x, y, z seien Zufallsvariablen mit linear-affinen Abhängigkeiten zwischen y und z sowie zwischen x und z wie in der Definition der partiellen Korrelation. Weiterhin seien

- $\{(x_i, y_i, z_i)\}_{i=1,\dots,n}$ eine Menge von Realisierungen des Zufallsvektors $(x, y, z)^T$,
- $\hat{\beta}_0^{x,z}, \hat{\beta}_1^{x,z}$ die Ausgleichsgeradenparameter für $\{(x_i, z_i)\}_{i=1,\dots,n}$,
- $\hat{\beta}_0^{y,z}, \hat{\beta}_1^{y,z}$ die Ausgleichsgeradenparameter für $\{(y_i, z_i)\}_{i=1,\dots,n}$.

Schließlich seien für $i = 1, \dots, n$

- $e_i^{x,z} := x_i - \hat{\beta}_0^{x,z} - \hat{\beta}_1^{x,z} z_i$
- $e_i^{y,z} := y_i - \hat{\beta}_0^{y,z} - \hat{\beta}_1^{y,z} z_i$

die Residualwerte der jeweiligen Ausgleichsgeraden. Dann heißt die Stichprobenkorrelation der Wertemenge $\{(e_i^{y,z}, e_i^{x,z})\}_{i=1,\dots,n}$ *partielle Stichprobenkorrelation der x_i und y_i mit auspartialisierten z_i.*

•

Für den Fall, dass x, y, z multivariat normalverteilt sind, gibt folgendes Theorem, auf dessen Beweis wir hier verzichten wollen, den Zusammenhang zwischen bedingter und partieller Korrelation an.

Theorem 43.2 (Bedingte und Partielle Korrelation bei Normalverteilung)**.** *x, y, z seien drei gemeinsam multivariat normalverteilte Zufallsvariablen. Dann gilt*

$$\rho(x, y|z) = \rho(x, y\backslash z) \tag{43.22}$$

∘

Man beachte, dass obiges Theorem im Falle dreier multivariat normalverteilter Zufallsvariablen gilt. Im Allgemeinen, also für beliebige Verteilungen der drei Zufallsvariablen gilt die Identität von bedingter und partieller Korrelationen nicht. Weitere Details in diesem Zusammenhang diskutieren zum Beispiel Lawrance (1976) und Baba et al. (2004).

Aus Theorem 43.2 folgt mit Theorem 43.2 dann unmittelbar, dass bei gemeinsamer Normalverteilung von x, y, z die partielle Korrelation $\rho(x, y|z)$ ebenso wie die bedingte Korrelation $\rho(x, y\backslash z)$ basierend auf den (unbedingten) Korrelationen $\rho(x, y), \rho(x, z)$ und $\rho(y, z)$ bestimmt werden kann, bzw. im Falle der jeweiligen Stichprobenäquivalente durch diese geschätzt werden kann.

Folgender **R** Code demonstriert die Auswertung der partiellen Stichprobenkorrelation basierend auf einem simulierten Datensatz dreier multivariat normalverteilter Zufallsvariablen. Dabei bestimmen wir die partielle Korrelation einmal basierend aus den Residualstichprobenkorrelation wie in Definition 43.3 und einmal basierend auf den paarweisen Stichprobenkorrelationen anhand von Theorem 43.2. Schließlich stellt das **R** Paket `ppcor`mit `pcor()` eine Funktion zur automatisierten Auswertung partieller Stichprobenkorrelationen bereit, auch ihre Anwendung demonstrieren wir untenstehend. Das Resultat ist natürlich in allen drei Fällen identisch.

```
# Modellformulierung und Datenrealisierung
library(MASS)                                                    # Multivariate Normalverteilung
set.seed(1)                                                      # reproduzierbare Daten
S     = matrix(c( 1,.5,.9,                                       # Kovarianzmatrixparameter \Sigma
                 .5, 1,.5,
                 .9,.5, 1),nrow=3,byrow=TRUE)
n     = 1e6                                                      # Anzahl Realisierungen
xyz   = mvrnorm(n,rep(0,3),S)                                    # Realisierungen

# Partielle Stichprobenkorrelation als Residualstichprobenkorrelation
bars  = apply(xyz, 2, mean)                                      # Stichprobenmittel
s     = apply(xyz, 2, sd)                                        # Stichprobenstandardabweichungen
c     = cov(xyz)                                                 # Stichprobenkovarianzen
b_xz1 = c[1,3]/c[3,3]                                            # beta_1 (x,z)
b_xz0 = bars[1] - b_xz1*bars[3]                                  # beta_0 (x,z)
b_yz1 = c[2,3]/c[3,3]                                            # beta_1 (y,z)
b_yz0 = bars[2] - b_yz1*bars[3]                                  # beta_0 (y,z)
e_xz  = xyz[,1] - b_xz1*xyz[,3] - b_xz0                          # Residualwerte e^{x,z}
e_yz  = xyz[,2] - b_yz1*xyz[,3] - b_yz0                          # Residualwerte e^{y,z}
pr_e  = cor(e_xz,e_yz)                                           # \rho(x,y\z)

# Partielle Stichprobenkorrelation aus Stichprobenkorrelationen
r      = cor(xyz)                                                # Stichprobenkorrelationsmatrix
pr_r_n = r[1,2]-r[1,3]*r[2,3]                                    # \rho(x,y\z) Formel Zähler
pr_r_d = sqrt((1-r[1,3]^2)*(1-r[2,3]^2))                         # \rho(x,y\z) Formel Nenner
pr_r   = pr_r_n/pr_r_d                                           # \rho(x,y\z)

# partielle Stichprobenkorrelation aus Toolbox
library(ppcor)                                                   # Laden der Toolbox
pr_t   = pcor(xyz)                                               # \rho(x,y\z),\rho(x,z\y),\rho(y,z\x)
```

```
r(x,y)                         : 0.5
r(x,y/z) aus Residuenkorrelation : 0.13
r(x,y/z) aus Korrelationen       : 0.13
r(x,y/z) aus Toolbox             : 0.13
```

Anwendungsbeispiel

Mithilfe oben eingeführten **R** Codes wenden wir uns nun abschließend dem eingangs diskutierten Beispiel zum Zusammenhang von Eiskonsum und Sonnenbrandinzidenz zu. Wir nehmen an, dass zu jedem Wertepaar von Eiskonsum (x_i) und Sonnenbrandinzidenz (y_i) der korrespondierende Wert der Anzahl der Sommertage (z_i) im betrachteten Erhebungszeitraum und Land verfügbar ist. Dann eröffnet obige Theorie die Möglichkeit, die partielle Korrelation von Eiskonsum und Sonnenbrandinziden nach Korrektur für die Anzahl der Sommertage zu bestimmen.

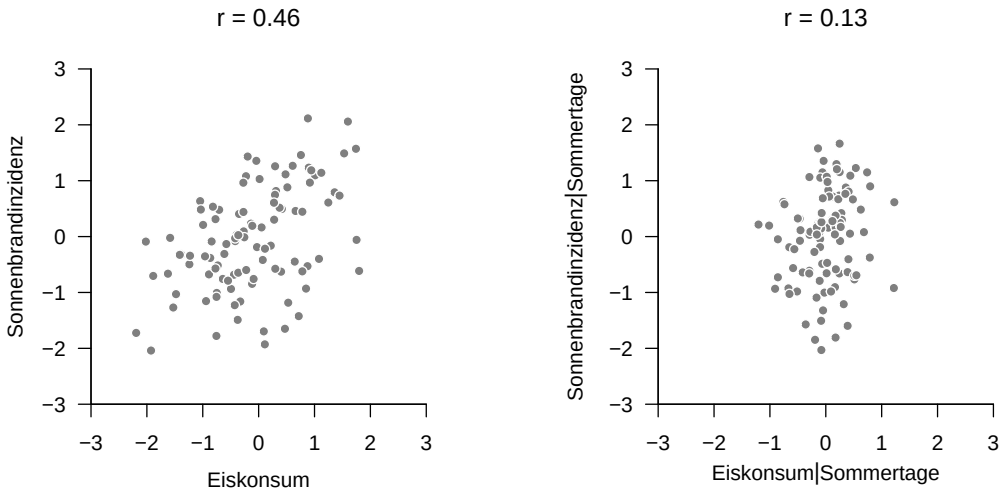


Abbildung 43.3. Evaluation der partiellen Korrelation im Beispielszenario.

Abbildung 43.3

Dazu stellt Abbildung 43.3 mit der Achsenbeschriftung `Eiskonsum | Sommertage` die Residualwerte

$$e_i^{x,z} := x_i - \hat{\beta}_0^{x,z} - \hat{\beta}_1^{x,z} z_i \tag{43.23}$$

und mit der Achsenbeschriftung `Sonnenbrandinzidenz | Sommertage` die Residualwerte

$$e_i^{y,z} := y_i - \hat{\beta}_0^{y,z} - \hat{\beta}_1^{y,z} z_i \tag{43.24}$$

dar. Man erkennt, dass kein systematischer Zusammenhang hoher bzw. niedriger Werte von `Eiskonsum | Sommertage` mit hohen bzw. niedrigen Werten von `Sonnenbrandinzidenz | Sommertage` besteht. Die Korrelation dieser Residualwerte beträgt dementsprechend auch nur $r = 0.17$ und nicht, wie im Falle der nicht für die Kovariation mit der Anzahl der Sommertage korrigierten Werte von Eiskonsum und Sonnenbrandinzidenz, $r = 0.46$ (vgl. Abbildung 43.1). Der bei der nicht durch die Anzahl der Sommertage informierten Korrelationsanalyse implizierte Zusammenhang von Eiskonsum und Sonnenbrandinzidenz lässt sich also durch die Kovariation beider Variablen mit der Drittvariable Sommertage aufklären bzw. "wegerklären".

43.5. Literaturhinweise

Die Theorie partielle und bedingter Korrelationen findet spätestens seit Beginn der modernen Korrelationsanalyse zu Beginn des 20. Jahrhunderts Beachtung, man vergleiche hierzu zum Beispiel Pearson (1920), Yule (1907) oder Fisher (1924).

44. Multiple Regression

44.1. Anwendungsszenario

Bei der multiplen Regression handelt es sich um die Generalisierung der einfachen linearen Regression im Kontext von mehr als einer kontinuierlichen unabhängigen Variable. Wie bei der einfachen linearen Regression betrachtet man eine univariate abhängige Variable, deren Werte an randomisierten experimentellen Einheiten bestimmt werden. Die unabhängigen Variablen werden bei der multiplen Regression je nach Kontext Regressoren, Prädiktoren, Kovariaten, Features oder einfach Spalten der Designmatrix genannt. Ähnlich wie bei der einfachen linearen Regression ist das Ziel einer multiplen Regressionsanalyse, das Erklärungspotential für Variationen der abhängigen Variablen durch Variation der unabhängigen Variablen zu quantifizieren. In Erweitertung der einfachen linearen Regression liegt ein Augenmerk dabei insbesondere darauf, den Einfluss einzelner unabhängiger Variablen auf die abhängige Variable im Kontext der Variation anderer unabängiger Variablen zu ermitteln. Darüber hinaus mag ein Ziel auch die Prädiktion der Werte der abhängigen Variablen für Werte der unabhängigen Variable nach Schätzung der entsprechenden Wichtungsbetaparameter anhand eines "Trainingsdatensatzes" sein.

Anwendungsbeispiel

Um einige Grundprinzipien der multiplen Regressionsanalyse zu verdeutlichen, beschränken wir uns in diesem Abschnitt meist auf den Fall zweier kontinuierlicher unabhängiger Variablen. Als Anwendungsbeispiel betrachten wir dazu den Effekt einer Psychotherapie auf die Depressionssymptomatik in Abhängigkeit vom Alter der Patient:innen und der Dauer der Therapie. Tabelle 44.1 zeigt einen Beispieldatensatz bestehend aus Datenwerten von $n = 20$ Patient:innen, wobei Alter das Patient:innenalter, Dauer die Therapiedauer und dBDI die Pre-Post-Interventions-BDI-Differenzwerte bezeichnen.

Tabelle 44.1. Pre-Post-BDI-Differenzwerte in Abh<U+00E4>ngigkeit von Patient:innenalter und Therapiedauer

Alter	Dauer	dBDI
36	23	35.4
42	15	17.5
54	20	17.8
74	14	-5.2
32	15	17.7
74	17	-2.4
77	12	-9.7
60	17	10.2
58	22	19.7
24	16	29.3
32	18	26.3
31	19	26.0

Tabelle 44.1. Pre-Post-BDI-Differenzwerte in Abh<U+00E4>ngigkeit von Patient:innenalter und Therapiedauer

Alter	Dauer	dBDI
61	18	5.8
43	14	11.0
66	22	15.8
50	20	22.0
63	22	11.2
80	13	-8.8
43	21	28.0
67	17	8.4

Abbildung 44.1 visualisiert den Beispieldatensatz, wobei die dBDI Werte der Höhe gemäß im dreidimensionalen Raum anhand ihrer Koordinaten in der Alter-Dauer-Ebene abgetragen sind. Die Visualisierung der multiple Regression, insbesondere für mehr als zwei unabhängige Variablen, stößt sehr schnell an ihre Grenzen.

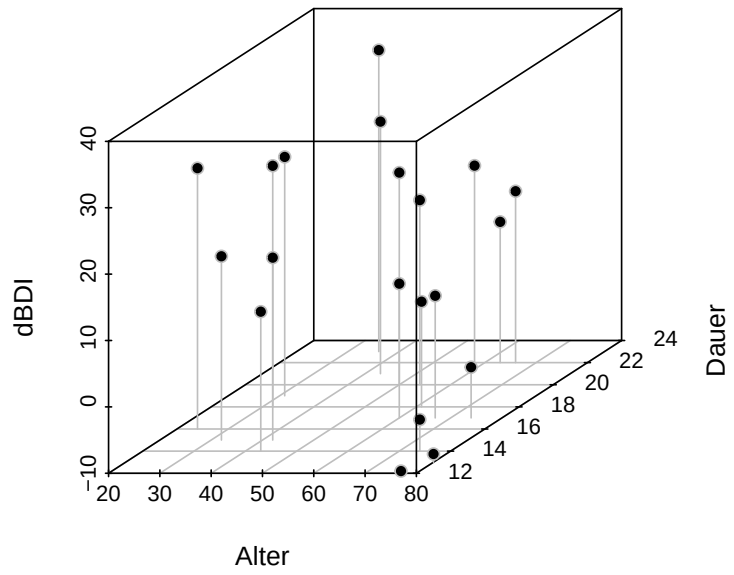


Abbildung 44.1. Visualisierung des Beispieldatensatzes als Punktwolke

44.2. Modellformulierung

Das Modell der multiplen Regression ist mit der allgemeinen Form des Allgemeinen Linearen Modells identisch. Der Vollständigkeit halber geben wir folgende Definition.

Definition 44.1 (Modell der multiplen Regression)**.** y_i mit $i = 1, \dots, n$ sei die Zufallsvariable, die den i-ten Wert einer abhängigen Variable modelliert. Dann hat das *Modell der multiplen Regression* die strukturelle Form

$$y_i = x_{i1}\beta_1 + \cdots + x_{ip}\beta_p + \varepsilon_i \text{ mit } \varepsilon_i \sim N\left(0, \sigma^2\right) \text{ u.i.v. für } i = 1, \dots, n \text{ und } \sigma^2 > 0,$$

wobei $x_{ij} \in \mathbb{R}$ mit $1 \leq i \leq n$ und $1 \leq j \leq p$ den i-ten Wert der j-ten unabhängigen Variable bezeichnet. Die unabhängigen Variablen werden auch *Regressoren*, *Prädiktoren*, *Kovariaten* oder *Features* genannt. Mit

$$x_i := \left(x_{i1}, \dots, x_{ip}\right)^T \in \mathbb{R}^p \text{ und } \beta := \left(\beta_1, \dots, \beta_p\right)^T \in \mathbb{R}^p$$

hat das Modell der multiplen Regression die Datenverteilungsform

$$y_i \sim N\left(\mu_i, \sigma^2\right) \text{ u.v. für } i = 1, \dots, n, \text{ wobei } \mu_i := x_i^T\beta.$$

In diesem Zusammenhang wird $x_i \in \mathbb{R}^p$ auch als $i$ter *Featurevektor* bezeichnet. Die Designmatrixform des Modells der multiplen Regression schließlich ist gegeben durch

$$y = X\beta + \varepsilon \text{ mit } \varepsilon \sim N\left(0_n, \sigma^2 I_n\right)$$

mit

$$y := \left(y_1, \dots, y_n\right)^T, X := \left(x_{ij}\right)_{1 \leq i \leq n, 1 \leq j \leq p} \in \mathbb{R}^{n \times p}, \beta := \left(\beta_1, \dots, \beta_p\right)^T \in \mathbb{R}^p \text{ und } \sigma^2 > 0.$$

•

Folgender **R** Code nutzt das Modell der multiplen Regression auf Definition 13.1, um den in Tabelle 44.1 dargestellten Beispieldatensatz zu erzeugen.

```
library(MASS)                                                    # Multivariate Normalverteilung
set.seed(1)                                                      # reproduzierbare Daten
n             = 20                                               # Anzahl Datenpunkte
p             = 3                                                # Anzahl Parameter
x_1           = round(runif(n,20,80))                            # Regressorwerte Alter
x_2           = round(runif(n,12,24))                            # Regressorwerte Therapiedauer
X             = matrix(c(rep(1,n),x_1,x_2), nrow = n)            # Designmatrix
I_n           = diag(n)                                          # Identitätsmatrix
beta          = matrix(c(5,-.5,2), nrow = p)                     # Betaparametervektor
sigsqr        = 10                                               # Varianzparameter
y             = mvrnorm(1, X %*% beta, sigsqr*I_n)               # eine Realisierung eines n-dimensionalen ZVs
D             = data.frame(Alter = x_1, Dauer = x_2, dBDI  = y)  # Dataframeformatierung
write.csv(D, "./_data/511-multiple-regression.csv", row.names = FALSE)  # Datenspeichern
```

44.3. Modellschätzung

Das Modell der multiplen Regression erlaubt eine allgemeine Einsicht in die Bedeutung des Betaparameterschätzers

$$\hat{\beta} := \left(X^T X\right)^{-1} X^T y$$

Insbesondere wird bei der Beschäftigung mit dem Betaparameterschätzer im Kontext der multiplen Regression deutlich, dass $X^T y$ die Kovariation der Regressoren mit den Daten und $X^T X$ die Kovariation der Regressoren untereinander quantifiziert, so dass für den Betaparameterschätzer eine Intuition als "regressorkovariationsnormalisierte Regressordatenkovariation" ergibt. Wir wollen dies im Folgenden am Beispiel einer multiplen Regression mit einem Interzeptregressor und zwei Regressoren für zwei unabhängige Variablen vertiefen. Dabei zeigen wir einmal die Form des Betaparameterschätzers in Form von Stichprobenkorrelationen (Theorem 13.1) und einmal in Form von partiellen Stichprobenkorrelationen (Theorem 13.2).

Theorem 44.1 (Betaparameterschätzer und Korrelationen)**.** *Gegeben sei ein multiples Regressionsmodel der Form*

$$y = X\beta + \varepsilon, \varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \text{ mit } X := \begin{pmatrix} 1 & x_{11} & x_{12} \\ \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} \end{pmatrix} \text{ und } \beta := \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix}.$$

Dann gilt

$$\hat{\beta} = \begin{pmatrix} \bar{y} - \hat{\beta}_1 \bar{x}_1 - \hat{\beta}_2 \bar{x}_2 \\ \frac{r_{y,x_1} - r_{y,x_2} r_{x_1,x_2}}{1 - r^2_{x_1,x_2}} \frac{s_y}{s_{x_1}} \\ \frac{r_{y,x_2} - r_{y,x_1} r_{x_1,x_2}}{1 - r^2_{x_1,x_2}} \frac{s_y}{s_{x_2}} \end{pmatrix},$$

wobei für die y_i, x_{i1} und x_{i2} mit $i = 1, \ldots, n$, $\bar{\cdot}, s_\cdot$ und $r_{\cdot,\cdot}$, die entsprechenden Stichprobenmittel, Stichprobenstandardabweichungen, und Stichprobenkorrelationen bezeichnen.

∘

Beweis. Wir erinnern zunächst daran, dass die Form des Betaparameterschätzers bekanntlich zum System der Normalengleichungen äquivalent ist (vgl. Kapitel 37)

$$\hat{\beta} = \left(X^T X\right)^{-1} X^T y \Leftrightarrow X^T X \hat{\beta} = X^T y.$$

Ausschreiben des Normalengleichungssystems für den hier betrachteten Spezialfall ergibt dann zunächst

$$\begin{aligned} & X^T X \hat{\beta} = X^T y \\ \Leftrightarrow & \begin{pmatrix} 1 & \cdots & 1 \\ x_{11} & \cdots & x_{n1} \\ x_{12} & \cdots & x_{n2} \end{pmatrix} \begin{pmatrix} 1 & x_{11} & x_{12} \\ \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} \end{pmatrix} \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} 1 & \cdots & 1 \\ x_{11} & \cdots & x_{n1} \\ x_{12} & \cdots & x_{n2} \end{pmatrix} \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} \\ \Leftrightarrow & \begin{pmatrix} n & \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i2} \\ \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i1}^2 & \sum_{i=1}^n x_{i1} x_{i2} \\ \sum_{i=1}^n x_{i2} & \sum_{i=1}^n x_{i2} x_{i1} & \sum_{i=1}^n x_{i2}^2 \end{pmatrix} \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n y_i x_{i1} \\ \sum_{i=1}^n y_i x_{i2} \end{pmatrix} \\ \Leftrightarrow & \begin{pmatrix} n & \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i2} \\ \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i1}^2 & \sum_{i=1}^n x_{i1} x_{i2} \\ \sum_{i=1}^n x_{i2} & \sum_{i=1}^n x_{i2} x_{i1} & \sum_{i=1}^n x_{i2}^2 \end{pmatrix} \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n y_i x_{i1} \\ \sum_{i=1}^n y_i x_{i2} \end{pmatrix} \end{aligned}$$

und damit

$$\begin{aligned} & X^T X \hat{\beta} = X^T y \\ \Leftrightarrow & \begin{pmatrix} n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_{i1} + \hat{\beta}_2 \sum_{i=1}^n x_{i2} \\ \hat{\beta}_0 \sum_{i=1}^n x_{i1} + \hat{\beta}_1 \sum_{i=1}^n x_{i1}^2 + \hat{\beta}_2 \sum_{i=1}^n x_{i1} x_{i2} \\ \hat{\beta}_0 \sum_{i=1}^n x_{i2} + \hat{\beta}_1 \sum_{i=1}^n x_{i1} x_{i2} + \hat{\beta}_2 \sum_{i=1}^n x_{i2}^2 \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n y_i x_{i1} \\ \sum_{i=1}^n y_i x_{i2} \end{pmatrix}. \end{aligned}$$

Aus der Gleichung der ersten Vektorkomponenten folgt dann direkt die Form von $\hat{\beta}_0$ mit

$$\begin{aligned} & \sum_{i=1}^n y_i = n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_{i1} + \hat{\beta}_2 \sum_{i=1}^n x_{i2} \\ \Leftrightarrow & \frac{1}{n} \sum_{i=1}^n y_i = \hat{\beta}_0 + \hat{\beta}_1 \frac{1}{n} \sum_{i=1}^n x_{i1} + \hat{\beta}_2 \frac{1}{n} \sum_{i=1}^n x_{i2} \\ \Leftrightarrow & \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}_1 - \hat{\beta}_2 \bar{x}_2. \end{aligned}$$

Einsetzen dieser Form von $\hat{\beta}_0$ in die Gleichung der zweiten Vektorkomponenten ergibt dann

$$\begin{aligned}
\hat{\beta}_0 \sum_{i=1}^{n} x_{i1} + \hat{\beta}_1 \sum_{i=1}^{n} x_{i1}^2 + \hat{\beta}_2 \sum_{i=1}^{n} x_{i1} x_{i2} &= \sum_{i=1}^{n} y_i x_{i1} \Leftrightarrow \\
\left(\bar{y} - \hat{\beta}_1 \bar{x}_1 - \hat{\beta}_2 \bar{x}_2\right) \sum_{i=1}^{n} x_{i1} + \hat{\beta}_1 \sum_{i=1}^{n} x_{i1}^2 + \hat{\beta}_2 \sum_{i=1}^{n} x_{i1} x_{i2} &= \sum_{i=1}^{n} y_i x_{i1} \\
\Leftrightarrow \bar{y} \sum_{i=1}^{n} x_{i1} - \hat{\beta}_1 \bar{x}_1 \sum_{i=1}^{n} x_{i1} - \hat{\beta}_2 \bar{x}_2 \sum_{i=1}^{n} x_{i1} + \hat{\beta}_1 \sum_{i=1}^{n} x_{i1}^2 + \hat{\beta}_2 \sum_{i=1}^{n} x_{i1} x_{i2} &= \sum_{i=1}^{n} y_i x_{i1} \\
\Leftrightarrow \hat{\beta}_1 \sum_{i=1}^{n} x_{i1}^2 - \hat{\beta}_1 \bar{x}_1 \sum_{i=1}^{n} x_{i1} + \hat{\beta}_2 \sum_{i=1}^{n} x_{i1} x_{i2} - \hat{\beta}_2 \bar{x}_2 \sum_{i=1}^{n} x_{i1} &= \sum_{i=1}^{n} y_i x_{i1} - \bar{y} \sum_{i=1}^{n} x_{i1} \\
\Leftrightarrow \hat{\beta}_1 \left(\sum_{i=1}^{n} x_{i1}^2 - \bar{x}_1 \sum_{i=1}^{n} x_{i1} \right) + \hat{\beta}_2 \left(\sum_{i=1}^{n} x_{i1} x_{i2} - \bar{x}_2 \sum_{i=1}^{n} x_{i1} \right) &= \sum_{i=1}^{n} y_i x_{i1} - \bar{y} \sum_{i=1}^{n} x_{i1}
\end{aligned}$$

Im Beweis des Theorems zur Ausgleichsgerade (vgl. Kapitel 34) haben wir gesehen, dass

$$\begin{aligned}
\sum_{i=1}^{n} x_{i1}^2 - \bar{x}_1 \sum_{i=1}^{n} x_{i1} &= \sum_{i=1}^{n} (x_{i1} - \bar{x}_1)(x_{i1} - \bar{x}_1) \\
\sum_{i=1}^{n} x_{i1} x_{i2} - \bar{x}_2 \sum_{i=1}^{n} x_{i1} &= \sum_{i=1}^{n} (x_{i1} - \bar{x}_1)(x_{i2} - \bar{x}_2) \\
\sum_{i=1}^{n} y_i x_{i1} - \bar{y} \sum_{i=1}^{n} x_{i1} &= \sum_{i=1}^{n} (y_i - \bar{y})(x_{i1} - \bar{x}_1)
\end{aligned}$$

Es ergibt sich also, dass

$$\begin{aligned}
\hat{\beta}_1 \sum_{i=1}^{n} (x_{i1} - \bar{x}_1)(x_{i1} - \bar{x}_1) + \hat{\beta}_2 \sum_{i=1}^{n} (x_{i1} - \bar{x}_1)(x_{i2} - \bar{x}_2) &= \sum_{i=1}^{n} (y_i - \bar{y})(x_{i1} - \bar{x}_1) \\
\Leftrightarrow \hat{\beta}_1 \frac{\sum_{i=1}^{n} (x_{i1} - \bar{x}_1)(x_{i1} - \bar{x}_1)}{n-1} + \hat{\beta}_2 \frac{\sum_{i=1}^{n} (x_{i1} - \bar{x}_1)(x_{i2} - \bar{x}_2)}{n-1} &= \frac{\sum_{i=1}^{n} (y_i - \bar{y})(x_{i1} - \bar{x}_1)}{n-1}
\end{aligned}$$

Mit den Definitionen von Stichprobenstandardabweichung und -korrelation folgt dann weiter

$$\begin{aligned}
\hat{\beta}_1 s_{x_1} s_{x_1} + \hat{\beta}_2 c_{x_1, x_2} &= c_{y, x_1} \\
\Leftrightarrow \hat{\beta}_1 \frac{s_{x_1} s_{x_1}}{s_y s_{x_1}} + \hat{\beta}_2 \frac{c_{x_1, x_2}}{s_y s_{x_1}} &= \frac{c_{y, x_1}}{s_y s_{x_1}} \\
\Leftrightarrow \hat{\beta}_1 \frac{s_{x_1}}{s_y} + \hat{\beta}_2 \frac{c_{x_1, x_2}}{s_y s_{x_1}} &= r_{y, x_1} \\
\Leftrightarrow \hat{\beta}_1 \frac{s_{x_1}}{s_y} + \hat{\beta}_2 \frac{c_{x_1, x_2} s_{x_2}}{s_y s_{x_1} s_{x_2}} &= r_{y, x_1} \\
\Leftrightarrow \hat{\beta}_1 \frac{s_{x_1}}{s_y} + \hat{\beta}_2 \frac{s_{x_2}}{s_y} r_{x_1, x_2} &= r_{y, x_1}
\end{aligned}$$

Definition von

$$b_j := \frac{s_{x_j}}{s_y}, j = 1, 2$$

erlaubt dann die Schreibweise

$$b_1 + b_2 r_{x_1, x_2} = r_{y, x_1}$$

Schließlich folgt analog durch Vertauschen der Subskripte aus der Gleichung der dritten Vektorkomponenten

$$b_1 r_{x_1, x_2} + b_2 = r_{y, x_2}$$

Insgesamt haben wir also gesehen, dass die Definition des Betaparameterschätzers Spezialfall des Allgemeinen Linearen Modells ergibt, dass mit

$$\hat{\beta}_j = b_j \frac{s_y}{s_{x_j}}, j = 1, 2$$

gilt, dass

$$\begin{aligned}
r_{y, x_1} &= b_1 + b_2 r_{x_1, x_2} \\
r_{y, x_2} &= b_1 r_{x_1, x_2} + b_2
\end{aligned}$$

Damit folgt aus der zweiten Gleichung dann sofort

$$b_2 = r_{y,x_2} - b_1 r_{x_1,x_2}.$$

Einsetzen in die erste Gleichung ergibt dann

$$\begin{aligned}
b_1 + (r_{y,x_2} - b_1 r_{x_1,x_2})\, r_{x_1,x_2} &= r_{y,x_1} \\
\Leftrightarrow b_1 + r_{y,x_2} r_{x_1,x_2} - b_1 r_{x_1,x_2}^2 &= r_{y,x_1} \\
\Leftrightarrow r_{y,x_2} r_{x_1,x_2} + b_1 \left(1 - r_{x_1,x_2}^2\right) &= r_{y,x_1} \\
\Leftrightarrow b_1 \left(1 - r_{x_1,x_2}^2\right) &= r_{y,x_1} - r_{y,x_2} r_{x_1,x_2} \\
\Leftrightarrow b_1 &= \frac{r_{y,x_1} - r_{y,x_2} r_{x_1,x_2}}{1 - r_{x_1,x_2}^2}
\end{aligned}$$

Für b_2 ergibt sich damit weiterhin

$$\begin{aligned}
b_2 &= r_{y,x_2} - b_1 r_{x_1,x_2} \\
\Leftrightarrow b_2 &= r_{y,x_2} - \left(\frac{r_{y,x_1} - r_{y,x_2} r_{x_1,x_2}}{1 - r_{x_1,x_2}^2}\right) r_{x_1,x_2} \\
\Leftrightarrow b_2 &= \frac{r_{y,x_2}\left(1 - r_{x_1,x_2}^2\right)}{1 - r_{x_1,x_2}^2} - \frac{r_{y,x_1} r_{x_1,x_2} - r_{y,x_2} r_{x_1,x_2}^2}{1 - r_{x_1,x_2}^2} \\
\Leftrightarrow b_2 &= \frac{r_{y,x_2} - r_{y,x_2} r_{x_1,x_2}^2 - r_{y,x_1} r_{x_1,x_2} + r_{y,x_2} r_{x_1,x_2}^2}{1 - r_{x_1,x_2}^2} \\
\Leftrightarrow b_2 &= \frac{r_{y,x_2} - r_{y,x_1} r_{x_1,x_2}}{1 - r_{x_1,x_2}^2}
\end{aligned}$$

Damit folgen dann aber

$$\begin{aligned}
\hat{\beta}_1 = b_1 \frac{s_y}{s_{x_1}} &= \left(\frac{r_{y,x_1} - r_{y,x_2} r_{x_1,x_2}}{1 - r_{x_1,x_2}^2}\right) \frac{s_y}{s_{x_1}} \\
\hat{\beta}_2 = b_2 \frac{s_y}{s_{x_2}} &= \left(\frac{r_{y,x_2} - r_{y,x_1} r_{x_1,x_2}}{1 - r_{x_1,x_2}^2}\right) \frac{s_y}{s_{x_2}}
\end{aligned}$$

und es ist alles gezeigt. □

Exemplarisch wollen wir die Stichprobenkorrelationsform des Betaparameterschätzers für β_1

$$\hat{\beta}_1 = \frac{r_{y,x_1} - r_{y,x_2} r_{x_1,x_2}}{1 - r_{x_1,x_2}^2} \frac{s_y}{s_{x_1}}$$

betrachten. Man erkennt unter anderem:

- Nur im Fall $r_{x_1,x_2} = 0$ und $s_y = s_{x_1}$ gilt $\hat{\beta}_1 = r_{y,x_1}$. Die Betaparameterschätzer der multiplen Regression sind also im Allgemeinen nicht mit den Stichprobenkorrelationen zwischen dem entsprechenden Regressor und den Daten identisch.
- Im Fall $r_{x_1,x_2} = \pm 1$ ist $\hat{\beta}_1$ nicht definiert. Vollständig korrelierte Regressoren ergeben also ein nicht schätzbares Modell.
- Je größer $\left|r_{x_1,x_2}\right|$, desto größer der von r_{y,x_1} subtrahierte Term $r_{y,x_2} r_{x_1,x_2}$. Die paarweise Korrelation von Regressoren untereinander reduziert also den Betaparameterschätzerwert für einen Regressor.
- Je größer $\left|r_{y,x_2}\right|$, desto größer der von r_{y,x_1} subtrahierte Term $r_{y,x_2} r_{x_1,x_2}$. Neben der paarweisen Korrelation von Regressoren untereinander reduziert also auch eine hohe Stichprobenkorrelation eines anderen Regressors mit den Daten den Wert eines Betaparameterschätzers.
- Bei identischen Korrelationen und gleich bleibender Regressorstandabweichung steigt $\hat{\beta}_1$ mit s_y. Intuitiv erhält also ein Regressor einen höhreren Betaparameterschätzerwert, wenn er bei gleich Korrelationsstruktur mehr Datenvariabilität erklärt.

Zusammengefasst verdeutlichen obige Punkte, dass der Wert des Betaparameterschätzers eines Regressors im Modell der multiplen Regression allein im Kontext der Korrelationsstruktur der anderen Regressoren mit sich selbst und den Daten betrachtet werden kann und damit keinen modellunabhängigen Absolutbeitrag eines spezifischen Regressors zur Erklärung der Daten abbildet.

Folgender **R** Code demonstriert die Äquivalenz der Matrixschreibweise des Betaparameterschätzers und seiner Darstellung durch Stichprobenmittel, Stichprobenkorrelationen, und Stichprobenstandardabweichungen.

Folgendes Theorem stellt den Bezug zwischen multipler Regression und partiellen Korrelationen zwischen unabhängigen und abhängigen Variablen für das betrachtete Szenario her.

Theorem 44.2 (Betaparameterschätzer und partielle Korrelationen)**.** *Gegeben sei ein multiples Regressionsmodel der Form*

$$y = X\beta + \varepsilon, \varepsilon \sim N\left(0_n, \sigma^2 I_n\right) \text{ mit } X := \begin{pmatrix} 1 & x_{11} & x_{12} \\ \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} \end{pmatrix} \text{ und } \beta := \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix}.$$

Dann gilt

$$\hat{\beta} = \begin{pmatrix} \bar{y} - \hat{\beta}_1 \bar{x}_1 - \hat{\beta}_2 \bar{x}_2 \\ r_{y,x_1 \backslash x_2} \sqrt{\frac{1-r_{y,x_2}^2}{1-r_{x_1,x_2}^2}} \frac{s_y}{s_{x_1}} \\ r_{y,x_2 \backslash x_1} \sqrt{\frac{1-r_{y,x_1}^2}{1-r_{x_2,x_1}^2}} \frac{s_y}{s_{x_2}} \end{pmatrix},$$

wobei für $1 \leq k, l \leq 2$ *und* $i = 1, \ldots, n$

- $r_{y,x_k \backslash x_l}$ *die partielle Stichprobenkorrelation der* y_i *und* x_{ik} *gegeben die* x_{il} *ist,*
- r_{y,x_k} *die Stichprobenkorrelation der* y_i *und* x_{ik} *ist, und*
- r_{x_k,x_l} *die Stichprobenkorrelation der* x_{ik} *und* x_{il} *ist.*

∘

Beweis. Wir betrachten $\hat{\beta}_1$, das Resultat für $\hat{\beta}_2$ folgt dann durch Vertauschen der Indizes. Wir haben in vorherigem Theorem gesehen, dass

$$\hat{\beta}_1 = \frac{r_{y,x_1} - r_{y,x_2} r_{x_1,x_2}}{1 - r_{x_1,x_2}^2} \frac{s_y}{s_{x_1}}$$

Weiterhin haben wir in Kapitel 43 gesehen, dass unter der Annahme der multivariaten Normalverteilung von y, x_1, x_2 ein Schätzer für die partielle Korrelation von y und x_1 gegeben x_2 durch

$$r_{y,2} = \frac{r_{y,x_1} - r_{y,x_2} r_{x_1,x_2}}{\sqrt{1 - r_{y,x_2}^2}\sqrt{1 - r_{x_1,x_2}^2}}$$

gegeben ist. Für $\hat{\beta}_1$ ergibt sich somit

$$\begin{aligned} \hat{\beta}_1 &= \frac{r_{y,x_1} - r_{y,x_2} r_{x_1,x_2}}{1 - r_{x_1,x_2}^2} \frac{s_y}{s_{x_1}} \\ \Leftrightarrow \left(1 - r_{x_1,x_2}^2\right) \hat{\beta}_1 &= \left(r_{y,x_1} - r_{y,x_2} r_{x_1,x_2}\right) \frac{s_y}{s_{x_1}} \\ \Leftrightarrow \frac{1 - r_{x_1,x_2}^2}{\sqrt{1 - r_{y,x_2}^2}\sqrt{1 - r_{x_1,x_2}^2}} \hat{\beta}_1 &= \frac{r_{y,x_1} - r_{y,x_2} r_{x_1,x_2}}{\sqrt{1 - r_{y,2}^2}\sqrt{1 - r_{x_1,x_2}^2}} \frac{s_y}{s_{x_1}} \\ \Leftrightarrow \frac{1 - r_{x_1,x_2}^2}{\sqrt{1 - r_{y,x_2}^2}\sqrt{1 - r_{x_1,x_2}^2}} \hat{\beta}_1 &= r_{y,x_1 \backslash x_2} \frac{s_y}{s_{x_1}} \end{aligned}$$

und damit weiter

$$\begin{aligned}
\hat{\beta}_1 &= r_{y,x_1\setminus x_2}\frac{\sqrt{1-r^2_{y,x_2}}\sqrt{1-r^2_{x_1,x_2}}}{1-r^2_{x_1,x_2}}\frac{s_y}{s_{x_1}}\\
\Leftrightarrow \hat{\beta}_1 &= r_{y,x_1\setminus x_2}\frac{\sqrt{1-r^2_{y,x_2}}\sqrt{1-r^2_{x_1,x_2}}}{\left(\sqrt{1-r^2_{x_1,x_2}}\right)^2}\frac{s_y}{s_{x_1}}\\
\Leftrightarrow \hat{\beta}_1 &= r_{y,x_1\setminus x_2}\frac{\sqrt{1-r^2_{y,x_2}}}{\sqrt{1-r^2_{x_1,x_2}}}\frac{s_y}{s_{x_1}}\\
\Leftrightarrow \hat{\beta}_1 &= r_{y,x_1\setminus x_2}\sqrt{\frac{1-r^2_{y,x_2}}{1-r^2_{x_1,x_2}}}\frac{s_y}{s_{x_1}}
\end{aligned}$$

□

Im Allgemeinen gilt für $1 \leq i,l \leq k$, also dass

$$\hat{\beta}_k \neq r_{y,x_k\setminus x_l}.$$

Betaparameterschätzer sind also im Allgemeinen keine partiellen Stichprobenkorrelationen. Allerdings gilt

$$\hat{\beta}_k = r_{y,x_k\setminus x_l} \text{ für } 1 \leq i,l \leq k$$

genau dann, wenn

$$s_y = s_{x_1} = s_{x_2}$$

und außerdem

$$r_{y,x_k} = r_{x_k,x_l} = 0$$

wenn also die Stichprobenkorrelationen der Daten und der Werte des zweiten Regressors, sowie die Stichprobenkorrelation der Werte der beiden Regressoren gleich Null sind. Dies kann der Fall sein, wenn einer der Regressoren die Daten "sehr gut erklärt" und der andere Regressor von dem ersten "sehr verschieden" ist. Schließlich gilt obige Identität von Betaparameterschätzerkomponente und partieller Stichprobenkorrelation auch dann, wenn

$$\left|r_{y,x_l}\right| = \left|r_{x_k,x_l}\right|,$$

wenn also die obigen Stichprobenkorrelationen dem Betrage nach gleich sind. Dies ist in der Anwendung aber vermutlich selten der Fall.

Folgender **R** Code demonstriert die Äquivalenz der Matrixschreibweise des Betaparameterschätzers und seiner Darstellung durch Stichprobenmittel, Stichprobenkorrelationen, Stichprobenstandardabweichungen und partielle Stichprobenkorrelationen.

```
D          = read.csv("./_data/511-multiple-regression.csv")                  # Dateneinlesen
y          = D$dBDI                                                           # Abhängige Variable
n          = length(y)                                                        # Anzahl Datenpunkte
X          = matrix(c(rep(1,n), D$Alter, D$Dauer), nrow = n)                  # Designmatrix
p          = ncol(X)                                                          # Anzahl Parameter
beta_hat   = solve(t(X) %*% X) %*% t(X) %*% y                                 # Betaparameterschätzer
eps_hat    = y - X %*% beta_hat                                               # Residuenvektor
sigsqr_hat = (t(eps_hat) %*% eps_hat) /(n-p)                                  # Varianzparameterschätzer

# Betaparameterschätzer aus partiellen Korrelationen und Korrelationen
library(ppcor)                                                                # partielle Korrelationentoolbox
y12        = cbind(y,X[,2:3])                                                 # y,x_1,x_2 Matrix
bars       = apply(y12, 2, mean)                                              # Stichprobenmittel
s          = apply(y12, 2, sd)                                                # Stichprobenstandardabweichungen
r          = cor(y12)                                                         # Stichprobenkorrelationen
pr         = pcor(y12)                                                        # partielle Stichprobenkorrelationen
pr         = pr$estimate                                                      # partielle Stichprobenkorrelationen
beta_hat_1 = pr[1,2]*sqrt((1-r[1,3]^2)/(1-r[2,3]^2))*(s[1]/s[2])              # \hat{\beta}_1
beta_hat_2 = pr[1,3]*sqrt((1-r[1,2]^2)/(1-r[3,2]^2))*(s[1]/s[3])              # \hat{\beta}_2
beta_hat_0 = bars[1] - beta_hat_1*bars[2] - beta_hat_2*bars[3]                # \hat{\beta}_0
```

```
Korrelationen  r(dPOMS,AGE),r(dPOMS,BRI),r(AGE,BRI)        : -0.87 0.64 -0.22
Partielle Korrelationen r(dPOMS,AGE|BRI), r(dPOMS,BRI|AGE) : -0.97 0.92
beta_hat ALM Sch<U+00E4>tzer                                      : 11.44 -0.57 1.85
beta_hat aus partieller Korrelation                        : 11.44 -0.57 1.85
```

Abbildung 44.2 visualisiert den Beispieldatensatz zusammen mit der durch den Betaparameterschätzer definierten Regressionsebene.

$$f_{\hat{\beta}} : \mathbb{R}^2 \to \mathbb{R}, (x_1, x_2) \mapsto f_{\hat{\beta}}(x_1 x, x_2) := \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2$$

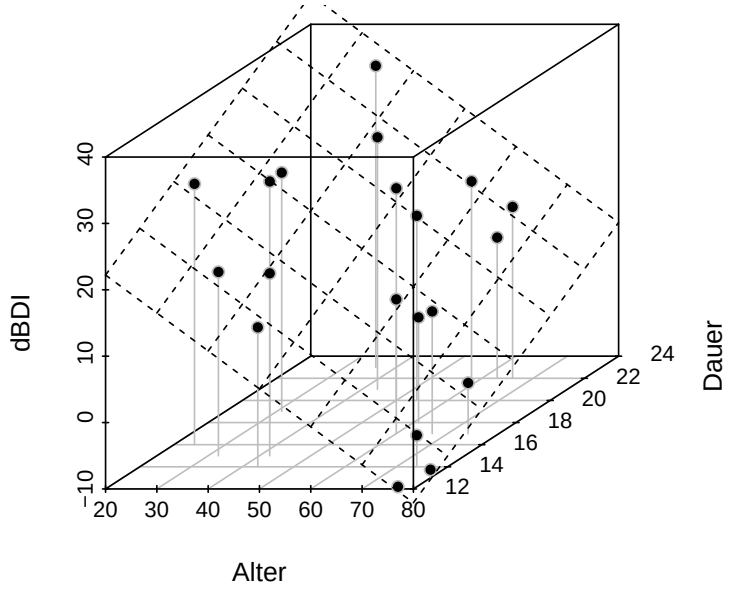


Abbildung 44.2. Visualisierung von Beispieldatensatz und Regressionsebene

44.4. Modellevaluation

Die allgemeine Theorie der T- und F-Statistiken bietet eine Vielzahl von Möglichkeiten, verschiedenste Hypothesen im Kontext der multiplen Regression inferenzstatistisch zu evaluieren. Für das Anwendungsbeispiel könnte zum Beispiel folgende Auswahl von Kontrastgewichtsvektoren und Null- und Alternativhypothesen zunächst von Interesse sein:

$$c := \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \Leftrightarrow H_0 : \beta_2 = 0, H_A : \beta_2 \neq 0 \text{ und } c := \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} \Leftrightarrow H_0 : \beta_3 = 0, H_A : \beta_3 \neq 0$$

Dabei würde das Ablehnen der jeweiligen Nullhypothese jeweils inferenzstatistische Evidenz für einen Effekt des Patient:innenalters bzw. der Therapiedauer auf die Pre-PostBDI-Differenz im Kontext der Präsenz der jeweils anderen unabhängigen Variable und des Interzeptterms implizieren.

Weiterhin könnte folgender Kontrastgewichtsvektor mit folgenden Null- und Alternativhypothesen von Interesse sein:

$$c := \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix} \Leftrightarrow H_0 : \beta_2 - \beta_3 = 0, H_A : \beta_2 - \beta_3 \neq 0$$

In diesem Fall würde das Ablehnen der Nullhypothese inferenzstatistische Evidenz für einen differentiellen Einfluss von Patient:innenalter und Therapiedauer implizieren, je nach Vorzeichen der T-Statistik dabei einen stärkeren Effekt des Patient:innenalters oder der Therapiedauer.

Folgender **R** Code evaluiert evaluiert die angesprochenen T-Tests.

```
D          = read.csv("./_data/511-multiple-regression.csv")                # Datensatz
y          = D$dBDI                                                         # Abhängige Variable
n          = length(y)                                                      # Anzahl Datenpunkte
X          = matrix(c(rep(1,n), D$Alter, D$Dauer), nrow = n)                # Designmatrix
p          = ncol(X)                                                        # Anzahl Parameter
beta_hat   = solve(t(X) %*% X) %*% t(X) %*% y                               # Betaparameterschätzer
eps_hat    = y - X %*% beta_hat                                             # Residuenvektor
sigsqr_hat = (t(eps_hat) %*% eps_hat) /(n-p)                                # Varianzparameterschätzer
C          = cbind(diag(p), matrix(c(0,1,-1), nrow = 3))                    # Kontrastgewichtsvektoren
ste        = rep(NaN, ncol(C))                                              # Kontraststandardfehler
tee        = rep(NaN, ncol(C))                                              # T-Statistiken
pvals      = rep(NaN, ncol(C))                                              # p-Werte
for(i in 1:ncol(C)){                                                        # Kontrastiterationen
    c        = C[,i]                                                        # Kontrastgewichtsvektor
    t_num    = t(c)%*%beta_hat                                              # Zähler der T-Statistik
    ste[i]   = sqrt(sigsqr_hat*t(c)%*%solve(t(X)%*%X)%*%c)                  # Kontraststandardfehler/Nenner der T-Statistik
    tee[i]   = t_num/ste[i]                                                 # T-Statistik
    pvals[i] = 2*(1 - pt(abs(tee[i]),n-p))                                  # p-Wert
}
```

```
            Estimate Std. Error t value Pr(>|t|)
(Interzept)    11.44       4.20    2.73     0.01
Alter          -0.57       0.04  -16.00     0.00
Dauer           1.85       0.19    9.97     0.00
Alter-Dauer    -2.42       0.18  -13.37     0.00
```

Der Beispieldatensatz liefert also inferenstatistische Inferenz für einen negativen Zusammenhang zwischen Therapieerfolg und Patient:innenalter und einen positiven Zusammenhang zwischen Therapieerfolg und Therapiedauer. Die Differenz der beiden Effekte ist dabei deutlich ausgeprägt.

Etwas globaler könnte man einen F-Test basierend auf einer Modellpartition mit $p_0 := 1$ nutzen, um etwa zu klären, ob die Daten die Annahme, dass Patient:innenalter und Therapie überhaupt zur Erklärung der Pre-Post-BDI-Differenzwertvariation, bestätigen. Folgender **R** Code evaluiert den angesprochenen F-Test.

```
D          = read.csv("./_data/511-multiple-regression.csv")                # Datensatz
y          = D$dBDI                                                         # Abhängige Variable
n          = length(y)                                                      # Anzahl Datenpunkte
X          = matrix(c(rep(1,n), D$Alter, D$Dauer), nrow = n)                # Desigmatrix vollständiges Modell
p          = ncol(X)                                                        # Anzahl Parameter vollständiges Modell
p_0        = 1                                                              # Anzahl Parameter reduziertes Modell
p_1        = p - p_0                                                        # Anzahl zusätzlicher Parameter im vollst. Modell
X_0        = X[,1:p_0]                                                      # Designmatrix reduzierters Modell
beta_hat_0 = solve(t(X_0)%*%X_0)%*%t(X_0)%*%y                               # Betaparameterschätzer reduziertes Modell
beta_hat   = solve(t(X) %*%X )%*%t(X) %*%y                                  # Betaparameterschätzer vollständiges Modell
eps_hat_0  = y - X_0 %*% beta_hat_0                                         # Residuenvektor reduziertes Modell
eps_hat    = y - X %*% beta_hat                                             # Residuenvektor vollständiges Modell
eh0_eh0    = t(eps_hat_0) %*% eps_hat_0                                     # RQS reduziertes Modell
eh_eh      = t(eps_hat) %*% eps_hat                                         # RQS vollständiges Modell
```

```
sigsqr_hat = eh_eh/(n-p)                                    # Varianzparameterschätzer vollst. Modell
f          = ((eh0_eh0-eh_eh)/p_1)/sigsqr_hat               # F-Statistik
pval       = 1 - pf(f,p_1,n-p)                              # p-Wert
```

```
F-statistic: 223.7 on 2 and 17 DF p-value:  6.17950135506362e-13
```

Der Beispieldatenzsatz enthält also deutliche Evidenz dafür, dass sowohl Patient:innenalter als auch Therapiedauer zur Erklärung der Pre-Post-BDI-Differenzwertvariation über Patient:innen beiträgt.

Eine direkte Implementation obiger Analyse erlaubt das Zusammenspiel der **R** Funktionen `lm()` und `summary()`, wie untenstehender **R** Code demonstriert.

```
D     = read.csv("./_data/511-multiple-regression.csv")     # Datensatz
alm   = lm(dBDI ~ Alter + Dauer, data = D)                  # Modellformulierung und Modellschätzung
summary(alm)                                                # Modellevaluation
```

```
Call:
lm(formula = dBDI ~ Alter + Dauer, data = D)

Residuals:
    Min      1Q  Median      3Q     Max
-4.9474 -2.0549  0.6748  1.9590  3.7926

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 11.43949    4.19776   2.725   0.0144 *
Alter       -0.57162    0.03573 -15.997 1.11e-11 ***
Dauer        1.85132    0.18577   9.966 1.63e-08 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.612 on 17 degrees of freedom
Multiple R-squared:  0.9634,    Adjusted R-squared:  0.9591
F-statistic: 223.7 on 2 and 17 DF,  p-value: 6.179e-13
```

44.5. Literaturhinweise

Die moderne Geschichte der multiplen Regression wird oft in den Arbeiten von Legendre (1805) und Gauss (1809) zur Berechnung von Planetenbahnen verankert. Die heutige Theorie der multiplen Regression sehr breit gefächert, so dass wir in diesem Abschnitt nur einen ersten Eindruck von ihrem Wesen vermitteln können. Weiterführende Einsichten bieten zum Beispiel Draper & Smith (1998), Hocking (2003) und Fox (2016).

Referenzen

Abbott, S. (2015). *Understanding Analysis*. Springer New York. https://doi.org/10.1007/978-1-4939-2712-8

Aitken, A. C. (1936). IV.—On Least Squares and Linear Combination of Observations. *Proceedings of the Royal Society of Edinburgh*, *55*, 42–48. https://doi.org/10.1017/S0370164600014346

Aldrich, J. (1997). R.A. Fisher and the Making of Maximum Likelihood 1912-1922. *Statistical Science*, *12*(3), 162–176. https://doi.org/10.1214/ss/1030037906

Amrhein, V., & Greenland, S. (2018). Remove, Rather than Redefine, Statistical Significance. *Nature Human Behaviour*, *2*(1), 4–4. https://doi.org/10.1038/s41562-017-0224-0

Anderson, T. W. (2003). *An Introduction to Multivariate Statistical Analysis* (3rd ed). Wiley-Interscience.

Arens, T., Hettlich, F., Karpfinger, C., Kockelkorn, U., Lichtenegger, K., & Stachel, H. (2018). *Mathematik*. Springer Berlin Heidelberg. https://doi.org/10.1007/978-3-662-56741-8

Baba, K., Shibata, R., & Sibuya, M. (2004). Partial Correlation and Conditional Correlation as Measures of Conditional Independence. *Australian <Html_ent Glyph="@amp;" Ascii="&"/> New Zealand Journal of Statistics*, *46*(4), 657–664. https://doi.org/10.1111/j.1467-842X.2004.00360.x

Bärwolff, G. (2017). *Höhere Mathematik für Naturwissenschaftler und Ingenieure*. Springer Berlin Heidelberg. https://doi.org/10.1007/978-3-662-55022-9

Bayes, T. (1763). An essay towards solving a problem in the doctrine of chances. By the late Rev. Mr. Bayes, F. R. S. communicated by Mr. Price, in a letter to John Canton, A. M. F. R. S. *Philosophical Transactions of the Royal Society of London*, *53*, 370–418. https://doi.org/10.1098/rstl.1763.0053

Beck, A. T. (1961). An Inventory for Measuring Depression. *Archives of General Psychiatry*, *4*(6), 561. https://doi.org/10.1001/archpsyc.1961.01710120031004

Beck, A. T., Steer, R. A., Ball, R., & Ranieri, W. F. (1996). Comparison of Beck Depression Inventories-IA and-II in Psychiatric Outpatients. *Journal of Personality Assessment*, *67*(3), 588–597. https://doi.org/10.1207/s15327752jpa6703_13

Becker, R. A., Chambers, J. M., & Wilks, A. R. (1988). *The New S Language: A Programming Environment for Data Analysis and Graphics* (Reprint). Chapman & Hall.

Bertram, M. G., Sundin, J., Roche, D. G., Sánchez-Tójar, A., Thoré, E. S. J., & Brodin, T. (2023). Open Science. *Current Biology*, *33*(15), R792–R797. https://doi.org/10.1016/j.cub.2023.05.036

Billingsley, P. (1995). *Probability and Measure* (3rd ed). Wiley.

Borel, É. (1898). *Leçons Sur La Théorie Des Fonctions*. Paris: Gauthier Villars.

Box, J. F. (1981). Gosset, Fisher, and the t Distribution. *The American Statistician*, *35*(2), 61. https://doi.org/10.2307/2683142

Bravais, A. (1844). *Analyse Mathématique : Sur Les Probabilités Des Erreurs de Situation d'un Point*.

Burden, R. L., Faires, J. D., & Burden, A. M. (2016). *Numerical Analysis* (Tenth edition). Cengage Learning.

Cantor, G. (1874). Über Eine Eigenschaft Des Inbegriffes Aller Reellen Algebraischen Zahlen. *Jahresbericht der Deutschen Mathematiker-Vereinigung*, *1*.

Cantor, G. (1891). Über Eine Elementare Frage Der Mannigfaltigkeitslehre. *Jahresbericht der Deutschen Mathematiker-Vereinigung*, *1*, 75–78.

Cantor, G. (1895). Beiträge Zur Begründung Der Transfiniten Mengenlehre. *Mathematische Annalen*, *46*(4), 481–512. https://doi.org/10.1007/BF02124929

Casella, G., & Berger, R. (2002). *Statistical Inference* (2. Aufl.). Thomson Learning.

Chiossi, S. G. (2021). *Essential Mathematics for Undergraduates: A Guided Approach to Algebra, Geometry, Topology and Analysis*. Springer International Publishing. https://doi.org/10.1007/978-3-030-87174-1

Christensen, R. (2011). *Plane Answers to Complex Questions*. Springer New York. https://doi.org/10.1007/978-1-4419-9816-3

Cohen, J. (1968). Multiple Regression as a General Data-Analytic System. *Psychological Bulletin*, *70*(6, Pt.1), 426–443. https://doi.org/10.1037/h0026714

Cotton, R. (2013). *Learning R* (First Edition). O'Reilly.

Dahm, M. (2005). *Grundlagen Der Mensch-Computer-Interaktion*. Pearson Studium.

De Finetti, B. (1975). *Theory of Probability*. John Wiley & Sons.

DeGroot, M. H., & Schervish, M. J. (2012). *Probability and Statistics* (4th ed). Addison-Wesley.

Deisenroth, M. P., Faisal, A. A., & Ong, C. S. (2020). *Mathematics for Machine Learning* (1. Aufl.). Cambridge University Press. https://doi.org/10.1017/9781108679930

Draper, N., & Smith, H. (1998). *Applied Regression Analysis*. Wiley-Interscience.

Edgeworth, F. Y. (1892). The Law of Error and Correlated Averages. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, *34*(210), 429–438. https://doi.org/10.1080/14786449208620355

Everitt, B., & Howell, D. C. (Hrsg.). (2005). *Encyclopedia of Statistics in Behavioral Science*. John Wiley & Sons.

Fischer, H. (2011). *A History of the Central Limit Theorem*. Springer New York. https://doi.org/10.1007/978-0-387-87857-7

Fisher, R. A. (1922). On the Mathematical Foundations of Theoretical Statistics. *Philosophical Transactions of the Royal Society of London. Series A, Containing Papers of a Mathematical or Physical Character*, *222*(594-604), 309–368. https://doi.org/10.1098/rsta.1922.0009

Fisher, R. A. (1924). The Distribution of the Partial Correlation Coefficient. *Metron*, *3*, 329–332.

Fisher, R. A. (1925a). Applications of "Student's" Distribution. *Metron*, *5*, 90–104.

Fisher, R. A. (1925b). *Statistical Methods for Research Workers*. Oliver & Boyd.

Fisher, R. A. (1925c). Theory of Statistical Estimation. *Mathematical Proceedings of the Cambridge Philosophical Society*, *22*(5), 700–725. https://doi.org/10.1017/S0305004100009580

Fisher, R. A. (1935). *The Design of Experiments* (1. ed). Hafner Press.

Foulley, J. (1993). *A Simple Argument Showing How to Derive Restricted Maximum Likelihood*.

Fox, J. (2016). *Applied Regression Analysis and Generalized Linear Models* (Third Edition). SAGE.

Friston, K. J. (2005). A Theory of Cortical Responses. *Philosophical Transactions of the Royal Society B: Biological Sciences*, *360*(1456), 815–836. https://doi.org/10.1098/rstb.2005.1622

Galton, F. (1886). Regression Towards Mediocrity in Hereditary Stature. *The Journal of*

the Anthropological Institute of Great Britain and Ireland, *15*, 246. https://doi.org/10.2307/2841583

Galton, F. (1890). Kinship and Correlation. *Statistical Science*, *4*(2). https://doi.org/10.1214/ss/1177012581

Gauss, C. F. (1809). *Theoria Motus Corporum Coelestium in Sectionibus Conicis Solem Ambientium*. Cambridge University Press.

Gigerenzer, G. (2004). Mindless Statistics. *The Journal of Socio-Economics*, *33*(5), 587–606. https://doi.org/10.1016/j.socec.2004.09.033

Gillies, D. (2000). Varieties of Propensity. *The British Journal for the Philosophy of Science*, *51*(4), 807–835. https://doi.org/10.1093/bjps/51.4.807

Golub, G. H., & Van Loan, C. F. (2013). *Matrix Computations* (Fourth edition). The Johns Hopkins University Press.

Gray, R. (1994). Georg Cantor and Transcendental Numbers. *The American Mathematical Monthly*, *101*(9), 819–832. https://doi.org/10.1080/00029890.1994.11997035

Hájek, A. (2019). Interpretations of Probability. In E. N. Zalta (Hrsg.), *The Stanford Encyclopedia of Philosophy* (Fall 2019). Metaphysics Research Lab, Stanford University.

Hald, A. (1990). *A History of Probability and Statistics and Their Applications before 1750*. Wiley.

Hald, A. (2007). *A History of Parametric Statistical Inference from Bernoulli to Fisher, 1713-1935*. Springer.

Harville, D. A. (1977). Maximum Likelihood Approaches to Variance Component Estimation and to Related Problems. *Journal of the American Statistical Association*, *72*(358), 320. https://doi.org/10.2307/2286796

Hautzinger, M., Keller, F., & Kühner, C. (2006). *BDI-II Beck Depressions-Inventar*. Pearson.

Held, L., & Sabanés Bové, D. (2014). *Applied Statistical Inference*. Springer Berlin Heidelberg. https://doi.org/10.1007/978-3-642-37887-4

Henze, N. (2018). *Stochastik für Einsteiger*. Springer Fachmedien Wiesbaden. https://doi.org/10.1007/978-3-658-22044-0

Henze, N. (2024). *Stochastik: Eine Einführung mit Grundzügen der Maßtheorie: Inkl. zahlreicher Erklärvideos*. Springer Berlin Heidelberg. https://doi.org/10.1007/978-3-662-68649-2

Herzog, S., & Ostwald, D. (2013). Sometimes Bayesian Statistics Are Better. *Nature*, *494*(7435), 35–35. https://doi.org/10.1038/494035b

Hesse, C. (2009). *Wahrscheinlichkeitstheorie* (2. Aufl.). Vieweg + Teubner.

Hocking, R. (2003). *Methods and Applications of Linear Models - Regression and the Analysis of Variance*. Wiley.

Huber, P. J. (1981). *Robust Statistics*. Wiley.

Hyndman, R. J., & Fan, Y. (1996). Sample Quantiles in Statistical Packages. *The American Statistician*, *50*(4), 361. https://doi.org/10.2307/2684934

Ihaka, R., & Gentleman, R. (1996). R: A Language for Data Analysis and Graphics. *Journal of Computational and Graphical Statistics*, *5*(3), 2999–2314.

Imbens, G., & Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction*. Academic Press.

Jaynes, E. (1968). Prior Probabilities. *IEEE Transactions on Systems Science and Cybernetics*, *4*(3), 227–241. https://doi.org/10.1109/TSSC.1968.300117

Jeffreys, H. (1939). *Theory Of Probability*. Oxford Classic Texts in the Physical Sciences.

Johnson, N. L., & Welch, B. L. (1940). Applications of the Non-Central t-Distribution. *Biometrika*, *31*(3/4), 362. https://doi.org/10.2307/2332616

Kochenderfer, M. J., Wheeler, T. A., & Wray, K. H. (2022). *Algorithms for Decision Making*. The MIT Press.
Kolmogoroff, A. (1933). *Grundbegriffe der Wahrscheinlichkeitsrechnung*. Springer Berlin Heidelberg. https://doi.org/10.1007/978-3-642-49888-6
Laplace, P. S. (1814). *A Philosophical Essay on Probabilities*.
Lawrance, A. J. (1976). On Conditional and Partial Correlation. *The American Statistician*, *30*(3), 146–149. https://doi.org/10.1080/00031305.1976.10479163
Legendre, A. M. (1805). *Nouvelles Methodes Pour La Determination Des Orbites Des Cometes*. Didot Paris.
Lehmann, E. L. (1986). *Testing Statistical Hypotheses*. Wiley Series in Probability and Statistics.
Lehmann, E. L. (2011). *Fisher, Neyman, and the Creation of Classical Statistics*. Springer New York. https://doi.org/10.1007/978-1-4419-9500-1
Lévy, P. (1937). *Théorie de l'addition des variables aléatoires*. Gauthier-Villars.
Liapounoff, A. M. (1900). Sur Une Proposition de La Théorie Des Probabilités. *Bulletin de l'Académie Impériale des Sciences de Saint-Pétersbourg*, *13*, 359.
Liapounoff, A. M. (1901). Nouvelle Forme Du Théorème Sur La Limite de Probabilité. *Mémoires de l'Académie Impériale des Sciences de Saint Pétersbourg, VIII*, *12*(5).
Lindeberg, J. W. (1922). Eine Neue Herleitung Des Exponentialgesetzes in Der Wahrscheinlichkeitsrechnung,. *Mathematische Zeitschrift*, *15*, 211–225.
Lindholm, M., & Wahl, F. (2020). On the Variance Parameter Estimator in General Linear Models. *Metrika*, *83*(2), 243–254. https://doi.org/10.1007/s00184-019-00751-4
Mardia, K. V., Kent, J. T., & Bibby, J. M. (1979). *Multivariate Analysis*. Academic Press.
McGill, R., Tukey, J. W., & Larsen, W. A. (1978). Variations of Box Plots. *The American Statistician*, *32*(1), 12. https://doi.org/10.2307/2683468
McShane, B. B., Gal, D., Gelman, A., Robert, C., & Tackett, J. L. (2019). Abandon Statistical Significance. *The American Statistician*, *73*(sup1), 235–245. https://doi.org/10.1080/00031305.2018.1527253
Meintrup, D., & Schäffler, S. (2005). *Stochastik: Theorie und Anwendungen*. Springer.
Miedema, F. (2022). *Open Science: The Very Idea*. Springer Netherlands. https://doi.org/10.1007/978-94-024-2115-6
Newton, I. (1687). *Philosophiae Naturalis Principia Mathematica*. Royal Society.
Neyman, J. (1935). On the Problem of Confidence Intervals. *The Annals of Mathematical Statistics*, *6*(3), 111–116. https://doi.org/10.1214/aoms/1177732585
Neyman, J. (1937). Outline of a Theory of Statistical Estimation Based on the Classical Theory of Probability. *Statistical Stimation*.
Neyman, J., & Pearson, E. S. (1933). On the Problem of the Most Efficient Tests of Statistical Hypotheses. *Phil. Trans. R. Soc. Lond. A*, *231*(694-706), 289–337.
Neyman, J., & Pearson, E. S. (1928). On the Use and Interpretation of Certain Test Criteria for Purposes of Statistical Inference: Part I. *Biometrika*, *20A*(1/2), 175. https://doi.org/10.2307/2331945
Patterson, H. D., & Thompson, R. (1971). Recovery of Inter-Block Information When Block Sizes Are Unequal. *Biometrika*, *58*(3), 545–554. https://doi.org/10.1093/biomet/58.3.545
Pearl, J. (2000). *Causality: Models, Reasoning, and Inference*. Cambridge University Press.
Pearson, K. (1895). Note on Regression and Inheritance in the Case of Two Parents. *Proceedings of the Royal Society of London*, *5*, 240–242. https://www.jstor.org/stable/115794
Pearson, K. (1896). Mathematical Contributions to the Theory of Evolution. III. Regression, Heredity, and Panmixia. *Philosophical Transactions of the Royal Society of London.*

Series A, Containing Papers of a Mathematical or Physical Character, *18*, 253–318. https://www.jstor.org/stable/90707

Pearson, K. (1900). On the Criterion That a given System of Deviations from the Probable in the Case of a Correlated System of Variables Is Such That It Can Be Reasonably Supposed to Have Arisen from Random Sampling. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, *50*(302), 157–175. https://doi.org/10.1080/14786440009463897

Pearson, K. (1901). On Lines and Planes of Closest Fit to Systems of Points in Space. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, *2*(11), 559–572. https://doi.org/10.1080/14786440109462720

Pearson, K. (1920). Notes on the History of Correlation. *Biometrika*, *13*(1), 25–45. https://doi.org/10.1093/biomet/13.1.25

Peirce, C. S. (1957). Notes on the Doctrine of Chances. In *Essays in the Philosophy of Science* (S. 74–84). Bobbs-Merrill.

Philip, S., Kew, S., Van Oldenborgh, G. J., Otto, F., Vautard, R., Van Der Wiel, K., King, A., Lott, F., Arrighi, J., Singh, R., & Van Aalst, M. (2020). A Protocol for Probabilistic Extreme Event Attribution Analyses. *Advances in Statistical Climatology, Meteorology and Oceanography*, *6*(2), 177–203. https://doi.org/10.5194/ascmo-6-177-2020

Plackett, R. L. (1949). A Historical Note on the Method of Least Squares. *Biometrika*, *36*(3/4), 458. https://doi.org/10.2307/2332682

Popper, K. R. (1959). The Propensity Interpreation of Probability. *The British Journal for the Philosophy of Science*, *10*(37), 25–42. https://doi.org/10.1093/bjps/X.37.25

Pratt, J., Raiffa, H., & Schlaifer, R. (1995). *Statistical Decision Theory*. MIT Press.

Puterman, M. (1994). *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. John Wiley & Sons.

Ramsey, F. P. (1926). Truth and Probability. In *The Foundations of Mathematics and Other Logical Essays, Chp VII* (S. 156–198). Harcourt, Brace and Company.

Rat für Informationsinfrastrukturen. (2017). *Datenschutz Und Foschungsdaten - Aktuelle Empfehlungen*.

Reichenbach, H. (1949). Philosophical Foundations of Probability. *Proceedings of the Berkeley Symposium on Mathematical Statistics and Probability*, 1–20.

Rencher, A. C., & Schaalje, G. B. (2008). *Linear Models in Statistics* (2nd ed). Wiley-Interscience.

Richter, T., & Wick, T. (2017). *Einführung in die Numerische Mathematik: Begriffe, Konzepte und zahlreiche Anwendungsbeispiele*. Springer Berlin Heidelberg. https://doi.org/10.1007/978-3-662-54178-4

Riley, J. (2017). *Understanding Metadata: What Is Metadata, and What Is It For*. National Information Standards Organization.

Rosenblatt, B. (1997). The Digital Object Identifier: Solving the Dilemma of Copyright Protection Online. *Journal of Electronic Publishing*, *3*(2). https://doi.org/10.3998/3336451.0003.204

Savage, L. J. (1954). *The Foundations of Statistics* (S. xv, 294). John Wiley & Sons.

Scheffé, H. (1959). *The Analysis of Variance* (Wiley classics library ed). Wiley-Interscience Publication.

Schmidt, K. D. (2009). *Maß und Wahrscheinlichkeit*. Springer.

Scott, D. W. (1979). *On Optimal and Data-Based Histograms*. 6.

Seal, H. L. (1967). Studies in the History of Probability and Statistics. XV: The Historical Development of the Gauss Linear Model. *Biometrika*, *54*(1/2), 1. https://doi.org/10.2307/2333849

Searle, S. R. (1971). *Linear Models*. Wiley.
Searle, S. R., & Gruber, M. H. J. (2017). *Linear Models* (Second edition). Wiley.
Searle, S. (1982). *Matrix Algebra Useful for Statistics*. Wiley-Interscience.
Seber, G. A. F., & Lee, A. J. (2003). *Linear Regression Analysis* (2nd ed). Wiley-Interscience.
Spivak, M. (2008). *Calculus* (4. Aufl.). Publish or Perish, Inc.
Starke, L., & Ostwald, D. (2017). Variational Bayesian Parameter Estimation Techniques for the General Linear Model. *Frontiers in Neuroscience*, *11*. https://doi.org/10.3389/fnins.2017.00504
Steele, J. M. (2006). *The Cauchy-Schwarz Master Class: An Introduction to the Art of Mathematical Inequalities* (repr). Cambridge University Press [u.a.].
Stigler, S. M. (1981). Gauss and the Invention of Least Squares. *The Annals of Statistics*, *9*(3). https://doi.org/10.1214/aos/1176345451
Stigler, S. M. (1986). *The History of Statistics: The Measurement of Uncertainty before 1900*. Belknap Press of Harvard University Press.
Strang, G. (2009). *Introduction to Linear Algebra*. Cambridge University Press.
Student. (1908). The Probable Error of a Mean. *Biometrika*, *6*(1), 1–25.
Sturges, H. A. (1926). The Choice of a Class Interval. *Journal of the American Statistical Association*, *21*(153), 65–66. https://doi.org/10.1080/01621459.1926.10502161
Toelch, U., & Ostwald, D. (2018). Digital Open Science—Teaching Digital Tools for Reproducible and Transparent Research. *PLOS Biology*, *16*(7), e2006022. https://doi.org/10.1371/journal.pbio.2006022
Tong, Y. L. (1990). *Multivariate Normal Distribution*. Springer.
Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley Pub. Co.
Ulrich, H., Kock-Schoppenhauer, A.-K., Deppenwiese, N., Gött, R., Kern, J., Lablans, M., Majeed, R. W., Stöhr, M. R., Stausberg, J., Varghese, J., Dugas, M., & Ingenerf, J. (2022). Understanding the Nature of Metadata: Systematic Review. *Journal of Medical Internet Research*, *24*(1), e25440. https://doi.org/10.2196/25440
Ulyanov, V. V. (2024). From Classical to Modern Central Limit Theorems. *arXiv Preprint arXiv:2405.19282v1*. https://arxiv.org/abs/2405.19282v1
Unger, L. (2000). *Grundkurs Mathematik*.
Vaart, A. W. van der. (1998). *Asymptotic Statistics*. Cambridge University Press.
Van Rooij, I., & Wareham, T. (2012). Intractability and Approximation of Optimization Theories of Cognition. *Journal of Mathematical Psychology*, *56*(4), 232–247. https://doi.org/10.1016/j.jmp.2012.05.002
Venn, J. (1876). *The Logic of Chance*. MacMillan.
Verbyla, A. P. (1990). A Conditional Derivation of Residual Maximum Likelihood. *Australian Journal of Statistics*, *32*(2), 227–230. https://doi.org/10.1111/j.1467-842X.1990.tb01015.x
von Mises, R. (1951). *Wahrscheinlichkeit, Statistik Und Wahrheit*. Springer International Publishing. https://doi.org/10.1007/978-3-319-29251-9_9
Von Neumann, J. (1945). *First Draft of a Report on the EDVAC*. Moore School of Electrical Engineering, University of Pennsylvania. https://doi.org/10.5479/sil.538961.3908011475779
Von Plato, J. (1994). *Creating Modern Probability: Its Mathematics, Physics, and Philosophy in Historical Perspective*. Cambridge University Press.
Walley, P. (1991). *Statistical Reasoning with Imprecise Probabilities* (1st ed). Chapman and Hall.
Wasserstein, R. L., Schirm, A. L., & Lazar, N. A. (2019). Moving to a World Beyond „ *p*

< 0.05“. *The American Statistician*, *73*(sup1), 1–19. https://doi.org/10.1080/00031305.2019.1583913

Wickham, H., Averick, M., Bryan, J., Chang, W., McGowan, L., François, R., Grolemund, G., Hayes, A., Henry, L., Hester, J., Kuhn, M., Pedersen, T., Miller, E., Bache, S., Müller, K., Ooms, J., Robinson, D., Seidel, D., Spinu, V., … Yutani, H. (2019). Welcome to the Tidyverse. *Journal of Open Source Software*, *4*(43), 1686. https://doi.org/10.21105/joss.01686

Wilkinson, M. D., Dumontier, M., Aalbersberg, Ij. J., Appleton, G., Axton, M., Baak, A., Blomberg, N., Boiten, J.-W., da Silva Santos, L. B., Bourne, P. E., Bouwman, J., Brookes, A. J., Clark, T., Crosas, M., Dillo, I., Dumon, O., Edmunds, S., Evelo, C. T., Finkers, R., … Mons, B. (2016). The FAIR Guiding Principles for Scientific Data Management and Stewardship. *Scientific Data*, *3*(1), 160018. https://doi.org/10.1038/sdata.2016.18

Wilks, S. S. (1938). The Large-Sample Distribution of the Likelihood Ratio for Testing Composite Hypotheses. *The Annals of Mathematical Statistics*, *9*(1), 60–62. https://doi.org/10.1214/aoms/1177732360

Wright, S. (1921). Correlation and Causation. *Journal of Agriculture Research*, *20*(7), 557–585.

Yule, G. U. (1907). On the Theory of Correlation for Any Number of Variables, Treated by a New System of Notation. *Proceedings of the Royal Society of London. Series A, Containing Papers of a Mathematical and Physical Character*, *79*(529), 182–193. https://www.jstor.org/stable/92723

Zabell, S. L. (2008). On Student's 1908 Article „The Probable Error of a Mean“. *Journal of the American Statistical Association*, *103*(481), 1–7. https://doi.org/10.1198/016214508000000030